英伟达全栈深度研究

NVIDIA 如何在 AI 训练与推理中变得不可或缺 —— 逐层解析

卷一 · 总览与基础

导读、执行摘要、速查表、英伟达飞轮与五篇入门

简体中文参考译文 · 仅供参考，如有出入以英文原文为准
数据与图表截至 2026-11-05 · 仅使用公开信息
英文原版：github.com/FrankHuang94/nvidia_deep_dive_claude

阅读说明

本册为英文研究资料库《NVIDIA Full-Stack Deep Dive》的**简体中文参考译文**，仅供参考；如与英文原文存在任何出入，以英文原文为准。全书共五册，可分册打印。

- **图表**：数据图表与架构图保留英文原版（由仓库中的 CSV 数据生成）；每张图下方的灰色文字为中文图注，概括该图的结论与关键数字。Mermaid 示意图已译为中文。
- **引用**：正文中的灰色上标（如 [S2031]）为来源编号，完整书目见卷五附录“参考文献”（保留英文原题）。
- **可信度标记**：🟢 已确认（公司官方公布）· 🟡 有报道（可信媒体或分析机构）· 🔴 推测（推断、传闻或本资料库的分析）；“估计”表示估算值。
- **对比标记**：🟩 领先 · 🟨 持平 · 🟥 落后 · 🟦 路线不同。
- **三层阅读深度**：每页以“⚡ 要点速览”开篇；正文“原理解析”含“算例”；虚线框为“🔧 技术细节”；页末“🎯 企业发展视角”列出供企业发展团队思考的问题。
- **时效**：数据截至 2026-11-05；英伟达 2027 财年第三季度财报（2026-11-17）与 GTC DC 大会（2026-12-01）晚于此日期。
- **公开信息**：本资料库仅使用公开信息；涉及高通的内容均以问题与选项的形式呈现，不构成建议。

目录

英伟达（NVIDIA）全栈深度解析 4

00 —— 执行摘要：英伟达如何以及为何变得不可或缺 9

速查表 —— 每一层浓缩为一行 20

01 —— 英伟达的飞轮 23

P1 · AI 训练原理 36

P2 · AI 推理原理 46

P3 · 四大瓶颈 55

P4 · 并行方式详解 65

P5 · 芯片经济学入门 76

英伟达（NVIDIA）全栈深度解析

关于本译本：本文件夹（`zh-CN/`）是整个资料库的简体中文参考译文，页面结构与英文版逐页对应。图表（SVG）与各页末尾的来源列表保留英文原样；如译文与英文原文有任何出入，以英文原文为准。可直接打印的 PDF 版本位于 `zh-CN/pdf/`，说明见 pdf/README.md。

英伟达如何以及为何成为 AI 训练与推理中不可或缺的一环——面向企业发展（corp dev）读者的逐层拆解。

可视化研究资料库 · 12 个技术栈层级、5 篇入门、6 个跨层专题、7 个案例研究 · 仅使用公开信息 · **最后核实：2026-11-05**

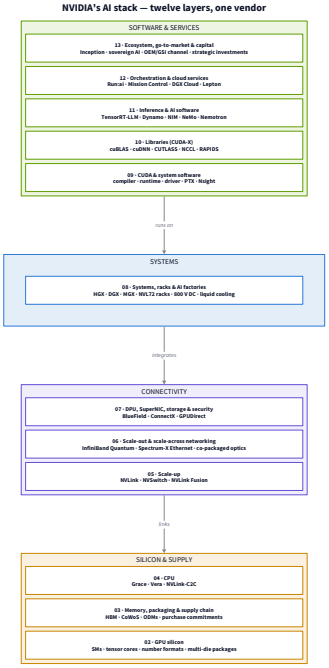
⚡ 要点速览

用五条要点概括核心论点（完整论证）：

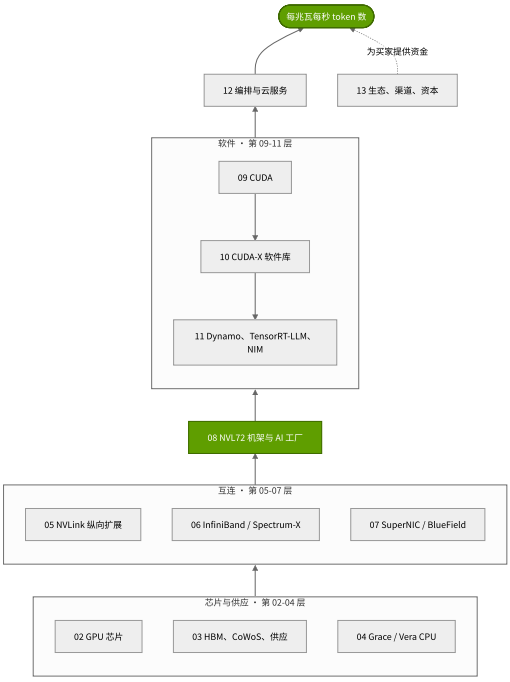
- **1 · 卖的是系统，而不是芯片**。 如今的销售单位是 72 颗 GPU 的 NVL72 机架；英伟达估算，在一座 1 GW AI 工厂 $50–60B 的总预算中，其自身产品约占 ~$35B [S398]。在每用户 50 tokens/s 的条件下，GB300 NVL72 每颗 GPU 的 token（词元）产出约为 H200 的 ~20×，因此一家毛利率 ~75% 的供应商，在聊天速度下仍能提供最便宜的 token（估计 每百万 token ~$0.16）[S621,S14000,S405]。
- **2 · 软件在已售出的硬件上持续复利**。 CUDA 已原生支持本资料库追踪的全部 12 个主流 AI 框架 [S587,S580]，新模型在发布首日（day 0）即可在其上运行 [S633]；仅靠软件优化，就在四个月内把 B200 每颗 GPU 的 DeepSeek-R1 吞吐量从 ~2,000 提升到 4,600 tokens/s [S646]。
- **3 · 规模换来供应与迭代节奏**。 $279B 的供应与产能承诺 [S407]，以及台积电（TSMC）2026 年 ~60% 的 CoWoS 晶圆（🟡 估计）[S379]，支撑英伟达每年推出新一代 GPU、网卡、交换机、CPU 和机架，一直延续到 2028 年的 🟢 Feynman [S35018,S109]。
- **4 · 资本与生态使其成为默认交易对手**。 ~$99B 的股权投资 [S90073]、FY2026 超过 ~$30B 的主权 AI 收入 [S90071]，以及占数据中心收入 45% 的非超大规模买家 [S406]，把需求分散到了最大的几家云厂商之外。 批评者称这一循环为循环融资 [S18007]。
- **5 · 今日不可或缺，边际上可被挑战**。 2025 年英伟达保持了 AI 数据中心芯片收入的 ~87%，而该市场规模扩大了 ~4.2×（估计）[S416,S1,S660,S661,S663]。但 AMD 在纸面参数上已持平或超越 Rubin [S144,S90093]，Anthropic 可使用多达 1M 颗谷歌（Google）TPU [S653]，博通（Broadcom）的 AI 收入已达英伟达数据中心收入的 ~19% [S2516]。🔴 竞争对手 在削弱英伟达的出货量之前，会先在最大买家处压制其定价权 [S15014]。

最新季度：Q2 FY2027 收入 $96.2B（同比 +106%），毛利率 75.0%；Q3 指引 $108B。🟢 管理层将 FY2028 ~70% 的增长 定性为受供应约束，毛利率将在 Q4 FY2027 触底于 71–72% [S405,S3,S90085,S90086]。

🍰 一图看懂技术栈



英伟达 AI 技术栈的分层蛋糕图：共十二层，自下而上从 GPU 芯片开始，经过内存、CPU、NVLink 纵向扩展、网络、DPU 与系统，直到顶层的 CUDA、软件库、推理软件、云服务与生态



每一层都有独立文件夹，包含索引页、深度解析页，以及竞争、历史、路线图与价值链页面。 速查表把每一层浓缩为一行；执行摘要 为每一层给出结论。

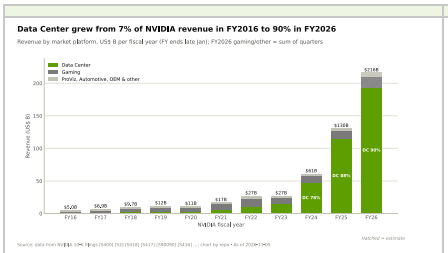
🧭 三条阅读路径

路径	时长	按以下顺序阅读	读完后你能够
⏱️ **30 分钟**	~30 分钟	本 README（5 分钟）→ 00 执行摘要：要点速览、核心论点与护城河部分（12 分钟）→ 速查表（5 分钟）→ 18 看空情景：要点速览与风险热力图（8 分钟）	用数据阐述核心论点、护城河地图与看空情景
🕑 **2 小时**	~2 小时	30 分钟路径 → 入门篇 P2 推理 与 P3 四大瓶颈（30 分钟）→ 十二个层级的索引页，从 02 到 13（45 分钟）→ 14 经济学（10 分钟）→ 15 竞争（10 分钟）→ 19 对高通的启示（10 分钟）	向工程师讲清其中的机制，并检验竞争对手的说法
📚 **完整**	~15–20 小时	README → 00 → 01 飞轮 → 入门篇 P1–P5 → 第 02–13 层（先读索引页，再读深度解析，然后是竞争、历史、路线图与价值链）→ 14 → 15 及其竞争对手页面 → 16 → 17 → 18 → 案例研究 CS1–CS7 → 19；全程把速查表放在手边	对任一层级、交易或竞争对手达到尽职调查级别的深度

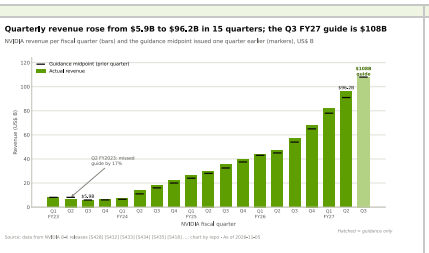
完整路径的英文原文约 ~220,000 词，按每分钟 230 词计约需 16 小时，另加阅读图表的时间 [S1501]。

🖼️ 可视化索引

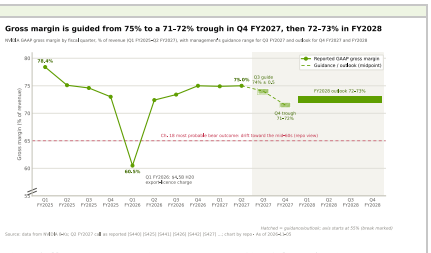
点击缩略图查看全尺寸图表；缩略图下方的链接指向讨论该图表的页面。全部 350+ 张图表 列于图表目录。



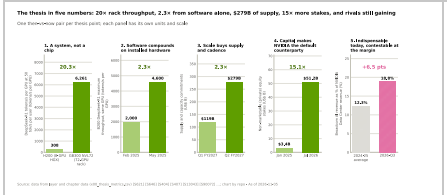
FY2016–FY2026，数据中心占收入比重从 7% 升至 90% [S1,S402] · 00 执行摘要



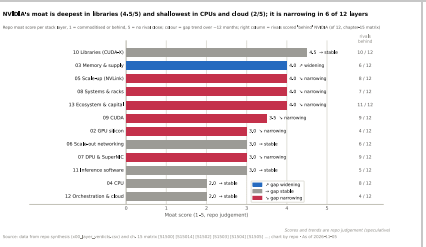
Q2 FY2027 收入 $96.2B；Q3 指引 $108B [S405] · 00 执行摘要



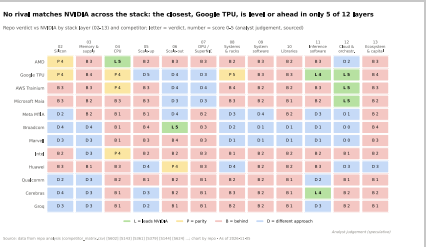
毛利率指引从 75% 降至 71–72% 的低点，之后回到 72–73% [S90085] · 00 执行摘要



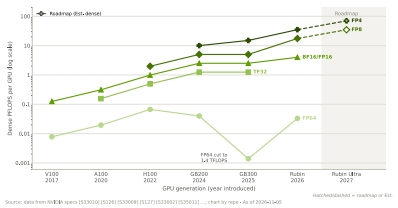
用五组“过去 vs 现在”的数字概括核心论点 [S621,S407] · 00 执行摘要



🔴 护城河在软件库最深（4.5/5），12 层中有 6 层在收窄 [S1500] · 速查表

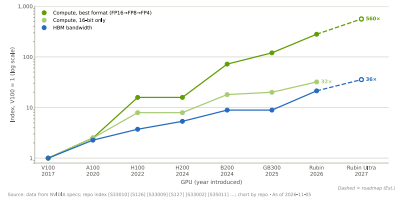


最接近的对手谷歌 TPU 在 12 层中的 5 层持平或领先 [S15014] · 15 竞争格局



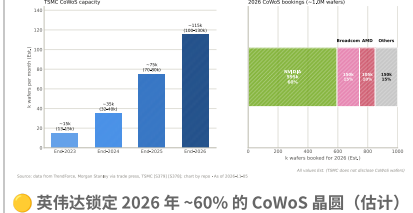
Rubin 的 35 PFLOPS FP4 约为 V100 16 位峰值的 ~280×

S33005,S33010 · 02 GPU 芯片



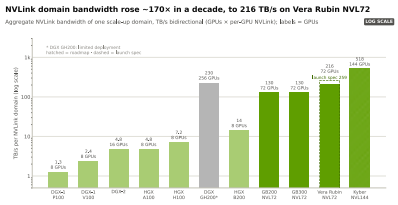
自 V100 以来算力提升 ~280×，HBM 带宽仅 ~21×

S33010,S33007 · 03 内存

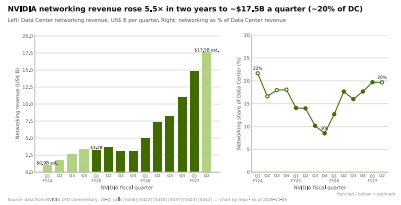


英伟达锁定 2026 年 ~60% 的 CoWoS 晶圆（估计）

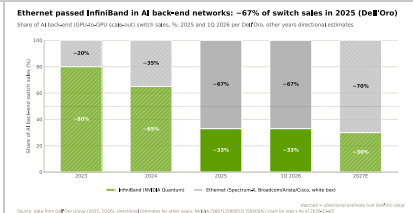
S379 · 03 内存



十年间 NVLink 域带宽提升 ~170×，达 216 TB/s S200 · 05 纵向扩展

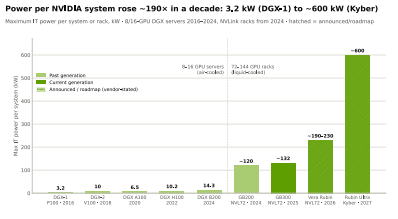


两年间网络收入增长 ~5.5×，达每季度 ~$17.5B（估计） S408 · 06 网络



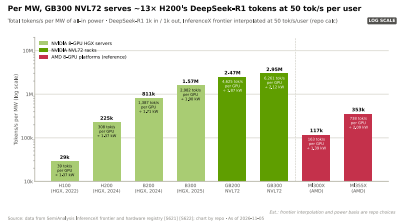
在 AI 后端交换领域，以太网已超越 InfiniBand

S90053,S90054 · 06 网络



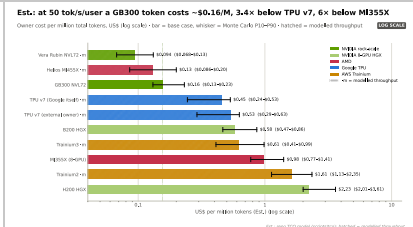
单系统功率：从 3.2 kW（DGX-1）到 ~600 kW（Kyber）

S310,S305 · 08 系统



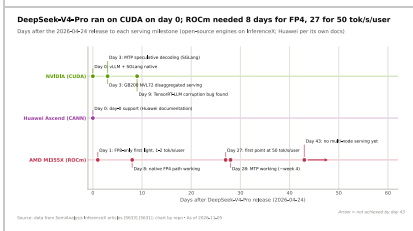
GB300 NVL72 每兆瓦 token 产出约为 H200 的 ~13×

S621,S622 · 08 系统

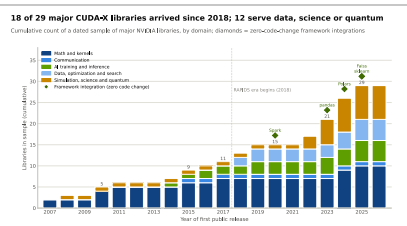


聊天速度下 GB300 每百万 token 约 ~$0.16（估计）

S14000 · 14 经济学

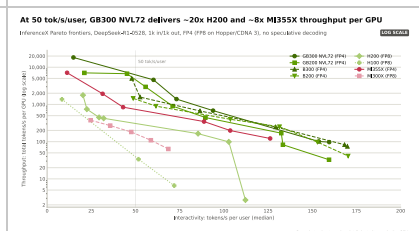


DeepSeek-V4 第 0 天即可在 CUDA 上运行；AMD 需要 8–27 天 S633 · 09 CUDA

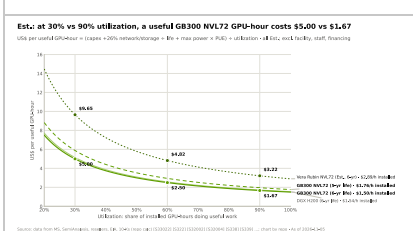


29 个主要 CUDA-X 软件库中有 18 个推出于 2018 年以后

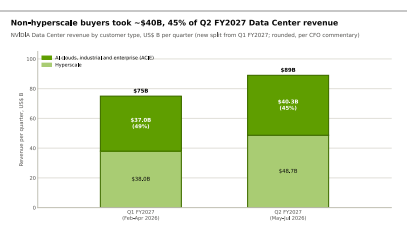
S525,S10035 · 10 软件库



每用户 50 tok/s 时，GB300 NVL72 每 GPU 产出约为 H200 的 ~20× S621 · 11 推理

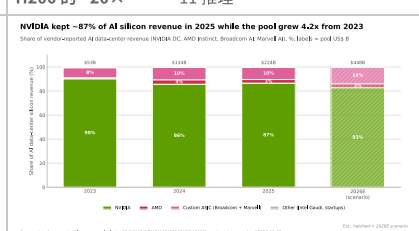


利用率 30% vs 90% 时，每有效 GPU 小时 $5.00 vs $1.67（估计） S332,S324 · 12 云服务

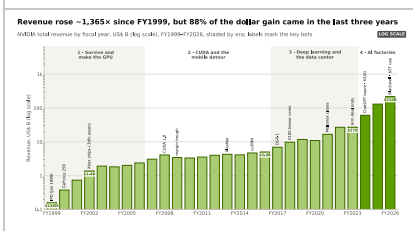


非超大规模买家：占 Q2 FY2027 数据中心收入的 ~45%

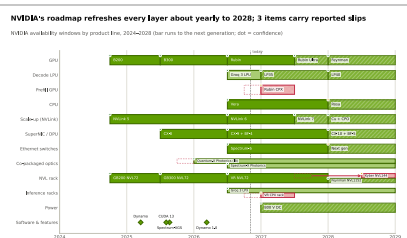
S406 · 13 生态



2025 年占 AI 芯片收入 ~87%，同期市场扩大 ~4.2×（估计） S416,S660 · 15 竞争格局

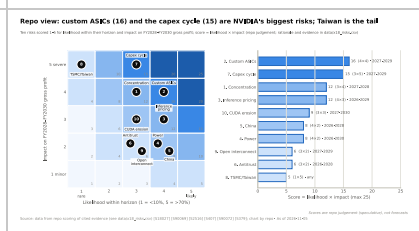


自 FY1999 以来收入增长 ~1,365×；88% 的增量来自最近三年 S16015,S1 · 16 历史



至 2028 年每一层约每年更新一次；3 项有延期报道

S502,S507 · 17 路线图



定制 ASIC（16）与资本开支周期（15）居风险图首位

S18027 · 18 看空情景

提示

算例 —— 如何解读本资料库中的一个数字。 以“GB300 每百万 token ~$0.16”为例。~ 与“估计（Est.）”表明这是 估计值。引用标记 S14000 在参考文献中 指向第 14 章透明的总拥有成本（TCO）模型，其每项输入均列于 `data/x14_tco_scenarios.csv` 并各自注明来源。 该章给出了区间（P10–P90 为 $0.13–0.23），并将模型推算的竞争对手数据标为 🔴 S14000。**结论：** 引用 任何数字之前，先核对三点：限定词（~、估计）、可信度标签（🟢 公司确认、🟡 可信报道、🔴 推测或本资料库分析）， 以及引用标记背后的来源。

🗺️ 资料库地图

部分	页面	回答的问题
综合篇	00 执行摘要 · 速查表 · 01 英伟达的飞轮	答案、各层结论与四个相互强化的循环
入门篇	P1 训练 · P2 推理 · P3 四大瓶颈 · P4 并行方式 · P5 芯片经济学	从零开始掌握所需的工程知识
硬件层	02 GPU 芯片 · 03 内存、封装与供应链 · 04 CPU（Grace、Vera）	计算在哪里发生，谁控制供应
互连层	05 纵向扩展（NVLink） · 06 横向扩展与跨数据中心扩展 · 07 DPU、SuperNIC、存储与安全	数千颗 GPU 如何像一台机器一样工作
系统层	08 系统、机架与 AI 工厂	为什么产品是机架而不是芯片
软件层	09 CUDA · 10 软件库（CUDA-X） · 11 推理与 AI 软件	免费使用的护城河
云与生态层	12 编排与云服务 · 13 生态、市场进入与资本	芯片如何变成付费的 GPU 小时与获得融资的需求
跨层专题	14 训练与推理经济学 · 15 竞争格局 · 16 英伟达如何建成今日格局 · 17 路线图 2025–2028 · 18 弱点与看空情景 · 19 对高通的启示	经济学、竞争对手、历史、路线图、风险与启示
竞争对手页面	AMD · 谷歌 TPU · AWS Trainium · 微软 Maia · Meta MTIA · ASIC 设计服务商 · 英特尔 · 高通 · 初创公司 · 中国	每种挑战者策略各一页
案例研究	CS1 Mellanox · CS2 CUDA · CS3 谷歌 TPU · CS4 AMD–OpenAI · CS5 DeepSeek · CS6 中国 · CS7 吉瓦级工厂	决策、结果及对企业发展的启示
参考资料	术语表 · 参考文献 · 数据字典 · 图表目录 · TCO 模型 · 核实队列 · QA 日志 · 进度	定义、来源、数据、图表与审计轨迹

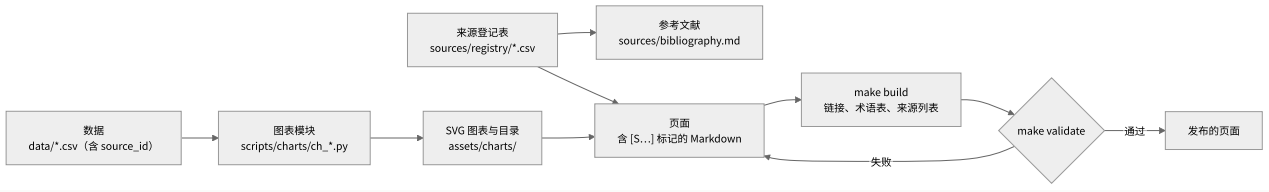
🔬 本资料库的构建方式

项目	本次构建时的数量	存放位置
分析文字	31 篇入门、层级、章节与案例研究共 ~213,000 词（英文），另有本综合篇 ~8,000 词	PROGRESS.md
登记来源	~1,750 条，每条含标题、发布方、日期、URL 与访问日期	参考文献
数据文件	~180 个 CSV、~5,000 行，每行均标注可信度与来源编号	数据字典
图表	~360 张，由 CSV 生成，每张均有结论式标题、替代文字与来源脚注	图表目录
渲染图示	14 张 D2 与 Graphviz 图示（机架、托盘、封装与网络结构剖析，技术栈分层图）	`diagrams/src/`
页面中计入的可视化元素	~1,080 个图表、图示、Mermaid 图与表格	PROGRESS.md
术语表词条	~680 个，首次出现时均加链接	术语表

数量来自 2026-11-05 运行的 `python3 scripts/validate/stats.py` 以及来源登记、数据与目录文件； 随章节编辑而变动 S1501。

每一页都采用相同的方法。事实首先取自一手资料：英伟达及竞争对手的监管文件、财报电话会、产品页面与技术 博客，以及 MLCommons 和 InferenceX 数据；可信的分析师与媒体报道居其次。每个数字都带有引用标记，例如 S405， 可链接到参考文献；前瞻性或有争议的说法标注 🟢/🟡/🔴 标签。每张图表均由 `scripts/charts/` 从 `data/*.csv` 重新生成。校验脚本检查每个 Mermaid 图能否渲染、每个链接与图片能否解析、每张图片是否有替代文字、 每条引用是否已登记，以及每章是否达到可视化配额。

🔧 技术细节：一个数字如何从来源走到页面



每个来源在登记表中占一行，编号取自所属章节的号段（例如本综合篇使用 S1500–S1999）。数据行在 `source_id` 列中引用这些编号，并在 `confidence` 列中标注 confirmed（已确认）、reported（有报道）、estimate（估计） 或 speculative（推测）。图表模块只读取 `data/`，并在每张图表的脚注中标注来源编号与数据截止日期。页面仅以 纯标记引用； `make build` 将其转为链接并重新生成每页的来源列表，因此页面无法引用未登记的来源。综合篇背后的 结论数据见 `data/x00_layer_verdicts.csv`，其图表见 `scripts/charts/ch_syn.py` S1500。

> 注意
>
> **局限性——引用前请先阅读。** - **研究条件限制。** 构建环境阻断了对大多数一手来源（sec.gov、nvidia.com、amd.com 及多数分析师网站）的 直接页面抓取，并限制了网络搜索次数。因此许多事实是通过搜索摘要或监管文件的二手转载核对的。746 行数据 （26%）和 132 个来源已在 docs/VERIFY_QUEUE.md 中标记为待复核。 - **判断均有标注。** 护城河评分、风险评分、TCO 输出与情景测算均为本资料库自身的分析（🔴 或“估计”）， 而非公司数据 [S1500,S18027,S14000]。 - **仅使用公开信息。** 本资料库未使用任何英伟达、高通或客户的保密信息。涉及高通的内容依据公告与监管文件， 并以问题而非建议的形式呈现。 - **时点性。** 数据截至 2026-11-05。Q3 FY2027 业绩（2026-11-17）与 GTC DC 主题演讲（2026-12-01） 均在此之后 [S17005,S90047]。

🛠️ 构建与校验

```
make setup      # 安装 Python + Node 工具链（见 requirements.txt 与 package.json）
make charts     # 从 data/*.csv 重新生成全部图表，并重写图表目录
make diagrams   # 将 diagrams/src 中的 D2 / Graphviz / Mermaid 源文件渲染到 assets/diagrams
make tco        # 重新运行第 14 章 TCO 模型（scripts/tco/）
make build      # 参考文献、术语表、引用与链接规范化、PROGRESS 统计
make validate   # 引用、链接、替代文字、可视化配额与 Mermaid 渲染检查
```

规范：风格指南 · 撰稿人说明 · 规格说明 · 页面模板。

🎯 企业发展视角

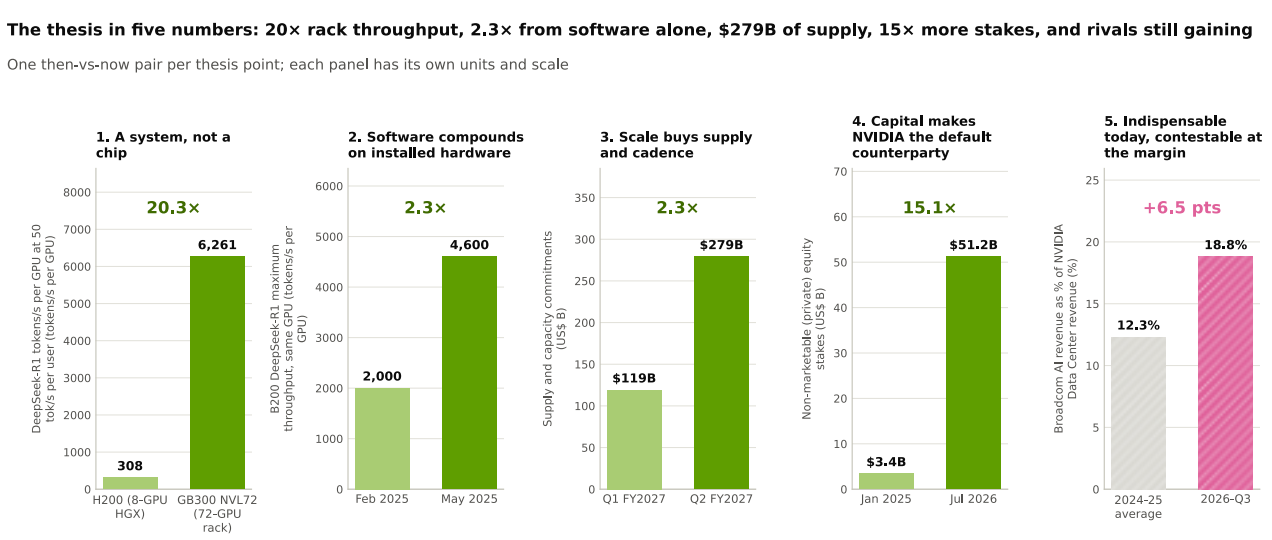
1. **从护城河地图而非规格表入手。** 速查表用一张表展示英伟达的领先在哪些层级深厚、受到挑战 或单薄，以及差距是否在扩大；12 层中有 6 层差距在收窄 🔴 [S1500]。
2. **以英伟达降价后的价格为挑战者定价。** 英伟达可将 GB300 价格下调 ~20% 而仍保持 ~66% 的毛利率 （🔴 第 14 章估计）[S14000]。第二供应商的商业论证应能经受住这一步。
3. **价值池与护城河位于不同层级。** 英伟达在 GPU、纵向扩展（scale-up）、网络和机架上赚钱， 在软件与供应上设防。每一层的价值链页面都列出了该层的非上市公司。
4. **涉及高通（Qualcomm）的具体问题**（逐层看是合作、竞争还是互补，仅基于公开信息），请参阅 第 19 章。

00 —— 执行摘要：英伟达如何以及为何变得不可或缺

综合篇 · 按不同阅读深度把整个资料库浓缩为一页 · 阅读约 ~22 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **一句话答案：英伟达（NVIDIA）把整座 AI 工厂作为一个系统来卖，并且每年更新一次，而竞争对手只卖其中的部件。** 2025 年英伟达拿下了 AI 数据中心芯片收入的 ~87%（2023 年为 ~90%），而这一市场同期从 ~$53B 增长到 ~$224B （估计，本资料库测算）[S416,S1,S660,S661,S663]。数据中心业务占 FY2026 $215.9B 收入的 90% [S1,S402]。
- **约束因素不是需求，而是供应与毛利率。** Q2 FY2027 收入 $96.2B（同比 +106%），GAAP 毛利率 75.0%，Q3 指引为 $108B ± 2% [S405,S3]。🟢 管理层将 FY2028 ~70% 的增长定性为 受供应约束，并指引毛利率因内存成本在 Q4 FY2027 触底于 71–72%， FY2028 回到 72–73% [S90085,S90086,S18000]。
- **护城河在于整体捆绑，而非芯片本身。** 🔴 按本资料库的分层结论，护城河最深的是 软件库（4.5 分，满分 5），其次是供应、纵向扩展、机架与生态（各 4.0），最薄的是 CPU 和云服务 （2.0）[S1500]。12 层中有 6 层的差距在收窄，只有供应层在扩大——该层的承诺额已达 $279B [S407]。
- **赚钱的地方与护城河所在之处并不重合。** GPU 是利润引擎：一颗 B200 的制造成本约 ~$6,400， 售价却为 $30–40K（估计）[S35020,S35026]。CUDA 与 CUDA-X 软件库是最深的护城河，却免费提供， 其价值在于守护这份毛利率 [S1509,S1510]。
- **挑战者真实存在，而且首先在最大买家处以价格取胜。** AMD 的 MI455X 在纸面上持平或超越 Rubin （HBM 432 vs 288 GB，23.3 vs 19.2 TB/s）[S144,S90093,S33005]；Anthropic 可使用多达 1M 颗谷歌（Google） TPU [S653]；博通（Broadcom）的 AI 收入相当于英伟达数据中心收入的比例从 ~12% 升至 ~19% [S2516,S1500]。OpenAI、Anthropic 和 Meta 如今都采用多供应商组合 [S24000,S174,S24004]。
- **看空逻辑在于集中度、融资与替代，而非需求疲软。** 单一直接客户占 Q2 FY2027 收入的 16% [S90069]；英伟达在 H1 FY2027 购入了 $42.4B 的股权，约占收入的 ~24% [S90072,S18007]。🔴 本资料库认为最可能的看空结果是毛利率从 75% 滑向 65% 左右 [S18027]。
- **接下来关注：** 2026-11-17 的 Q3 FY2027 业绩 [S17005]、2026-12-01 的 GTC DC 主题演讲 [S90047]、 Vera Rubin 的量产爬坡 [S90009]、AMD Helios 在 OpenAI 的部署 [S90021]、TPU 对外销售 [S90027]、$12.9B 收购 Hugging Face 的交割 [S11500] 以及中国出口许可 [S90032]。

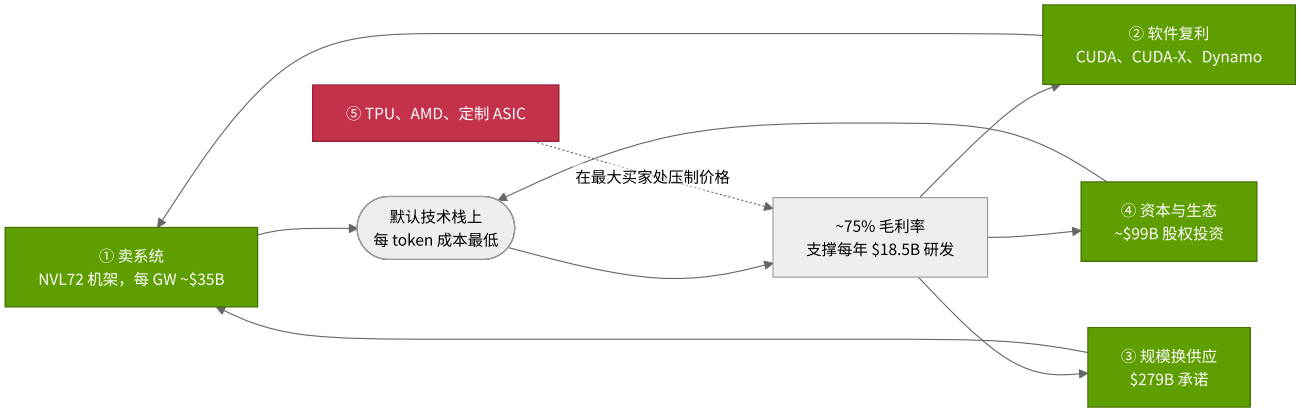


Source: data from layer and chapter data (x00_thesis_metrics.csv) [S621] [S646] [S404] [S407] [S13043] [S90072] …; chart by repo · As of 2026-11-05

五个小柱状图面板，每个对应一条核心论点。1：在每用户 50 tokens/s 下，DeepSeek-R1 每 GPU 每秒 token 数从 H200 的约 308 升至 GB300 NVL72 机架的约 6,261，约 20 倍。2：仅靠软件，B200 在 2025 年 2 月至 5 月间从约 2,000 提升至 4,600 tokens/s/GPU，提升 2.3 倍。3：供应与产能承诺在一个季度内从 $119B 升至 $279B。4：英伟达对非上市公司的股权投资从 $3.4B（2025 年 1 月）增至 $51.2B（2026 年 7 月），约 15 倍。5：博通 AI 收入相当于英伟达数据中心收入的比例，从约 12%（2024-25 年平均）升至 2026 自然年第三季度的约 19%。

五点核心论点

本资料库的核心问题是：英伟达如何以及为何在 AI 训练与推理中变得不可或缺。答案分为五部分：前三点解释 机制，第四点解释强化作用，第五点说明边界。每一点都链接到给出证据的页面。



1. 英伟达卖的是系统，而不是芯片。 销售单位从 2016 年 $129K 的 DGX-1 服务器，扩大到 ~$4.0M 的 GB300 NVL72 机架和 ~$7.8M 的 Vera Rubin NVL72（均为摩根士丹利估计）[S310,S332,S330]。在机架内部，英伟达规定了 GPU、CPU、72 颗 GPU 的 NVLink 域、网卡、铜缆背板、电源架与 液冷；ODM 以 ~2–3% 的毛利率完成组装 [S5000,S332]。英伟达 CEO 估计，在一座 1 GW AI 工厂 $50–60B 的总投资中，英伟达产品约占 ~$35B [S398]。系统之所以重要，是因为 现代模型受限于内存与通信，而非算术运算（P3）。在每用户 50 tokens/s 下，GB300 NVL72 每颗 GPU 可提供 ~6,261 DeepSeek-R1 tokens/s，约为 H200 的 ~20×、AMD MI355X 的 ~8× [S621]。按每兆瓦计，相对 H200 的差距约为 ~13× [S621,S622]。

2. 软件让每颗 GPU 每个季度都产出更多 token（词元）。 CUDA 原生支持本资料库追踪的全部 12 个主流 框架与引擎（36 分中得 36 分），AMD ROCm 为 26 分，高通（Qualcomm）Cloud AI 为 4 分 [S587,S580,S586,S596]。新模型在发布首日（day 0）即可在其上运行。DeepSeek-V4-Pro 发布时，AMD MI355X 用了 8 天 才跑通 FP4，用了 27 天才达到每用户 50 tokens/s [S633,S631]。软件还能提升已装机硬件的性能：在同一台 GB300 NVL72 上，MLPerf DeepSeek-R1 吞吐量一年内提升 2.9× [S601,S603]，仅 TensorRT-LLM 一项就在四个月内把 B200 从 ~2,000 提升到每 GPU 4,600 tokens/s [S646]。锁定效应真实存在，但并不均衡。🔴 本资料库对 自建部署的企业给出 4.5 分（满分 5），对有能力承担迁移成本的前沿实验室给出 2.75 分 [S1509]。

3. 规模换来供应、速度与迭代节奏。 截至 Q2 FY2027，英伟达持有 $279B 的供应与产能承诺，高于一个季度前的 $119B [S407,S404]，并锁定了台积电（TSMC）2026 年 ~60% 的 CoWoS 晶圆（🟡 估计）[S379]。FY2026 研发支出 $18.5B，仅占收入的 ~9% [S401]。这支撑了 年度迭代节奏：2025 年推出 Blackwell Ultra，Vera Rubin 自 2026 年 8 月起出货，🟢 Rubin Ultra 于 2027 下半年推出，🟢 Feynman 于 2028 年推出 [S500,S90009,S35018,S109]。英伟达会在 GPU 出货前 26–40 个月 公布其时间表，使买家可以围绕其日程规划吉瓦级园区（🔴 本资料库分析）[S17006]。

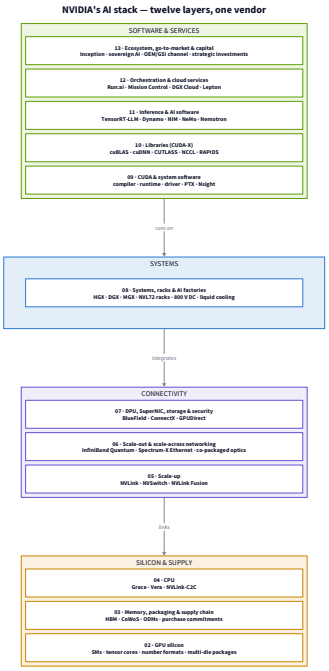
4. 资本与生态使英伟达成为默认交易对手。 英伟达的股权投资合计约 ~$99B（CNBC 根据 2026 年 7 月 10-Q 汇总）[S90073]，其中包括对 OpenAI 的 ~$30B（🟡）以及对 Anthropic 最多 $10B 的投资 [S90015,S90075]。主权 AI 在 FY2026 带来超过 ~$30B 的收入 [S90071]。AI 云、工业与企业 买家（ACIE）贡献了 ~$40.3B，占 Q2 FY2027 数据中心收入的 45%，主要通过合作伙伴与 新兴云服务商（neocloud）实现 [S406]。同一循环也招致 循环融资的批评：H1 FY2027 的股权购买相当于收入的 ~24%，与朗讯（Lucent）2000 年巅峰时的比例相当 [S90072,S18007]。

5. 今日不可或缺，边际上可被挑战。 没有对手能匹敌其整个技术栈。在第 15 章的矩阵中，最接近的 谷歌 TPU 在 12 层中的 5 层持平或领先，而所有“对手 × 层级”单元格中有 60% 为“落后” [S15014]。然而，买家已不必复制整个技术栈就能约束英伟达的定价。按集邦咨询（TrendForce）的统计，定制 ASIC 服务器在 2026 年 AI 服务器出货量中占 ~27.8% [S2517]；自有的 Ironwood TPU 每芯片小时成本约 ~$1.21，而 GB300 约为 ~$2.31（估计，SemiAnalysis）[S622]。🔴 本资料库结论：竞争对手会在削弱英伟达出货量之前很久，就先在最大买家处压制其定价权（第 15 章）。

> **提示**
>
> **算例 —— 毛利率 75% 的供应商为何仍能提供最便宜的 token。** 第 14 章的模型测算，在每用户 50 tokens/s 下，GB300 NVL72 的 token 成本约为每百万 ~$0.16（估计，P10–P90 为 $0.13–0.23）[S14000,S621]。英伟达的 毛利仅占该成本的 ~24%；资本费用约占 ~70%，电费约占 ~6% [S14000]。按每兆瓦计，不同平台的吞吐量 相差 ~30×，因此决定成本的是吞吐量而不是价格。🔴 在该工作点上，即便 MI355X、TPU v7 或 Trainium3 免费，其 token 成本也高于付费购买的 GB300 [S14000]。**结论：** 英伟达的毛利率之所以能维持，是因为其系统降低了买家的每 token 成本。但这一领先是有条件的：在每用户 100 tokens/s 下，GB300（~$1.74/M）与 TPU v7（$1.46–1.72）持平（🔴 模型推算）[S14000]。

> **🔧 技术细节：为何“不可或缺”不等于“垄断”**
>
> 此处的“不可或缺”是指：对 2026 年的大多数买家而言，没有比英伟达机架更快或更便宜的方式，能把资本和 电力大规模转化为 token。这建立在竞争对手必须同时具备的三项能力之上：有竞争力的加速器、72-GPU 级别的 纵向扩展域及其配套网络，以及对每个新模型的首日软件支持。AMD 已具备第一项，正在交付第二项（Helios），并以数周的滞后追赶第三项 [S144,S90020,S631]。谷歌三项俱全，但主要服务于自身工作负载和少数锚定客户 [S653,S552]。
>
> 英伟达所缺乏的，是对其最大客户替代方案的控制力：贡献大部分数据中心收入的买家，同时也在设计 TPU、Trainium、Maia 和 MTIA [S90069,S90026,S90035,S90044]。恰当的模型是：一家掌握定价权的在位者，在市场顶端 面临可信的替代品，在其下则很少——这也是第 18 章最可能的看空结果是毛利率承压、而非销量流失的 原因 [S18027]。

一图看懂技术栈



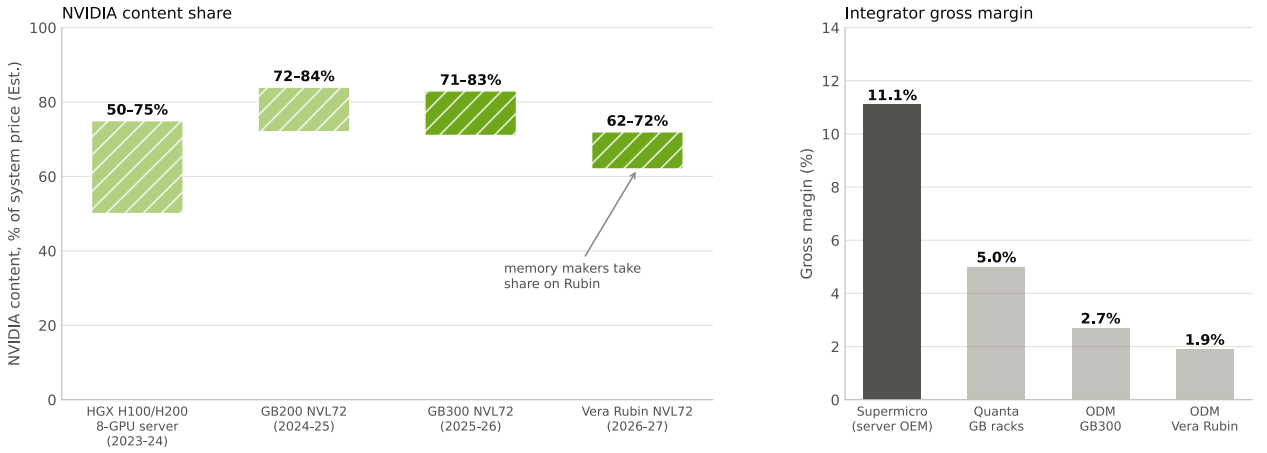
英伟达 AI 技术栈的分层蛋糕图：共十二层，自下而上从 GPU 芯片开始，经过内存、CPU、NVLink 纵向扩展、网络、DPU 与系统，直到顶层的 CUDA、软件库、推理软件、云服务与生态

本资料库把英伟达的 AI 业务拆分为十二层，从底部的 GPU 芯片到顶部的生态、市场进入与资本。可以把这块 “蛋糕” 自下而上当作一个 token 的生成路径来读。芯片与内存负责运算（第 02 层、第 03 层）。 CPU 为它们供给数据（第 04 层）。纵向扩展（scale-up）与 横向扩展（scale-out）网络让数千颗 GPU 像一台机器一样工作 （05、06、 07）。机架把部件变成一台供电、散热完备的计算机 （08）。随后四个软件层把这台计算机转化为高速内核、 实际交付的速度、对外服务的 token 与付费 GPU 小时 （09–12）。 资本与渠道再把这一切转化为获得融资的需求 （13）。

英伟达的特别之处不在于它涉足每一层，而在于它每年把所有层作为一个产品同步更新，因此竞争对手必须 追赶的是一个不断移动的整体，而不是某个部件。

Est.: NVIDIA's share of system value rose from ~50–75% (HGX) to ~71–84% (NVL72)

Left: estimated NVIDIA content as % of system price (range). Right: integrator gross margin (%). Repo estimates from analyst BOMs



Estimates

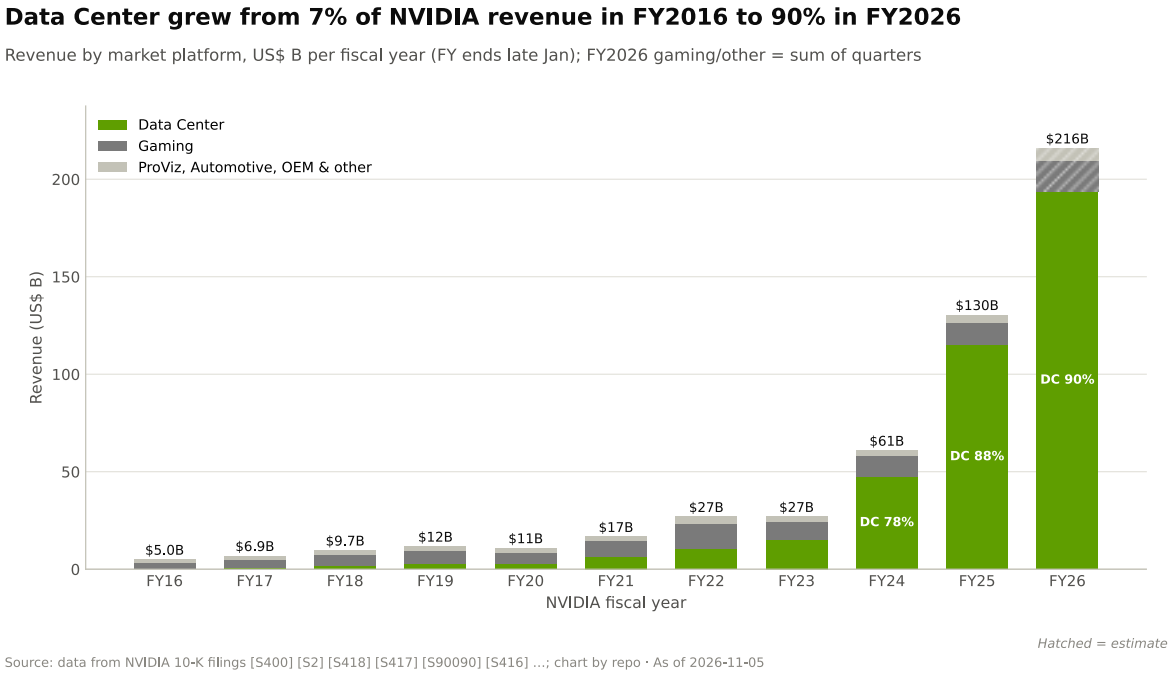
Source: data from analyst BOMs; repo calc [S356] [S322] [S326] [S324] [S332] [S331] …; chart by repo · As of 2026-11-05

双面板图。左：系统价格中支付给英伟达产品的估计比例——HGX H100/H200 8-GPU 服务器约 50-75%，GB200 NVL72 为 72-84%，GB300 NVL72 为 71-83%，Vera Rubin NVL72 为 62-72%，内存涨价使价值转移至 HBM 与 LPDDR 厂商。右：整机集成商毛利率从 11.1%（Supermicro，服务器时代）降至约 5%（广达 GB 机架，凯基证券）、2.7%（GB300 机架 ODM）和 1.9%（Vera Rubin 机架 ODM，摩根士丹利）。

> **提示**
>
> **算例 —— 一吉瓦电力穿过技术栈。** 在 1.15 的 PUE 下，1 GW 可为 IT 设备留下 ~870 MW。一台 GB300 NVL72 需要 ~132 kW，另加 ~21% 分摊的网络与存储功耗，合计约 ~160 kW。这足以容纳 **~5,400 个机架和 ~390,000 颗 GPU**（第 08 层，本资料库测算）[S1508,S387,S337]。英伟达 CEO 为这样一座工厂给出的价格是 **$50–60B，其中 ~$35B 为英伟达产品** [S398]。伯恩斯坦（Bernstein）的 ~$35B 与巴克莱（Barclays）的 $32.5–42B 处于同一量级 [S6025,S27012]。**结论：** 在吉瓦级规模下，英伟达的开票金额约占预算的 58–70%。没有任何单层供应商的钱包份额能接近这一水平。

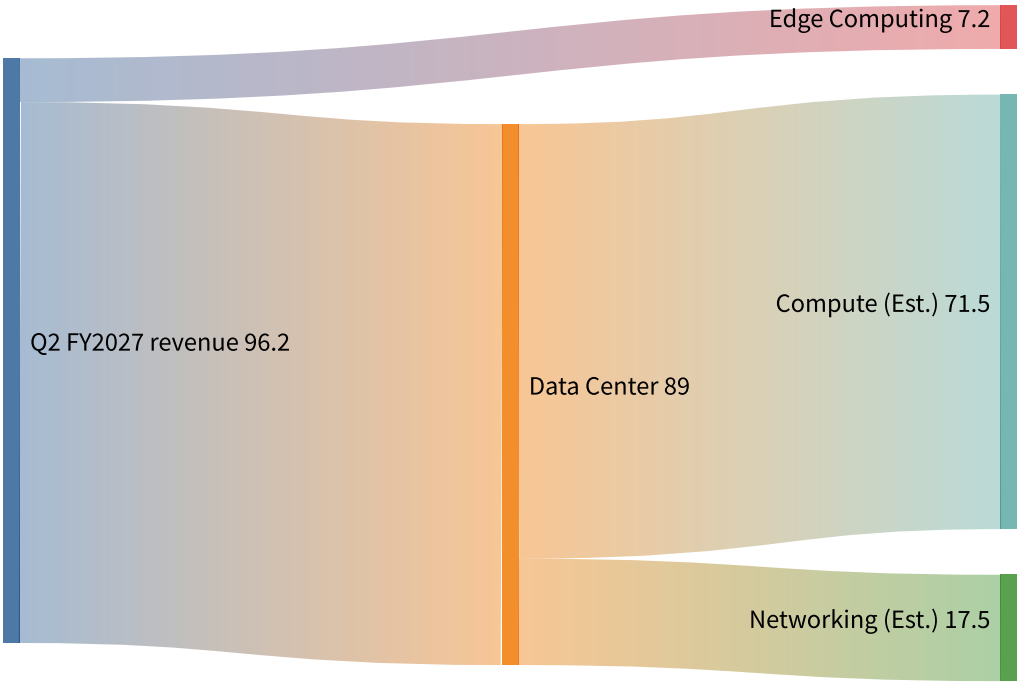
关键数字

指标	数值	为何重要	来源
FY2026 收入	$215.9B（+65%）	约为 FY2016 $5.0B 的 ~43×	S1,S400
FY2026 数据中心收入	$193.7B，占收入的 90%	AI 业务就是公司本身	S1,S402
FY2026 网络收入	~$31.4B（估计），FY2024 为 $8.6B	Mellanox 业务，现占数据中心的 ~20%	S402,S416
Q2 FY2027 收入 / 数据中心	$96.2B（同比 +106%）/ $89.0B（同比 +117%）	增长因 Blackwell Ultra 再度加速	S405
Q2 FY2027 数据中心构成	超大规模云厂商 ~$48.7B（55%）；ACIE ~$40.3B（45%）	近一半需求不经过超大规模云厂商	S406,S90011
Q2 FY2027 网络	~$17.5B（估计，环比 +18%）；Spectrum-X 同比 2.6×	以太网已成为英伟达的增长线	S408,S90012
Q2 FY2027 GAAP 毛利率	75.0%	销量巅峰期的定价权	S405
Q3 FY2027 指引	$108B ± 2%；毛利率 74% ± 50 bp；不含中国数据中心计算产品	业绩将于 2026-11-17 公布	S3,S90085,S17005
FY2028 初步展望	🟢 收入增长 ~70%，受供应约束	市场一致预期原为 ~45%	S90086,S18000
毛利率路径	🟢 Q4 FY2027 触底于 71–72%；FY2028 为 72–73%	内存成本高于计划；随后提价	S90085,S18000
供应与产能承诺	$279B（季度收入的 2.9×）	以配额为武器，下行周期中则是固定成本	S407,S18027
最大直接客户	占 Q2 FY2027 收入的 16%；前三大客户占 H1 的 44%	集中度会放大其他所有风险	S90069
股权投资	~$99B；H1 FY2027 购入 $42.4B	资本循环与循环融资之争	S90073,S90072
AI 数据中心芯片收入份额	~87%（2025）vs ~90%（2023）（估计）	市场扩大至四倍，份额几乎未变	S416,S660,S663
市值	~$5.3–5.8T（2026 年 8–10 月）；🔴 约为 FY2028 指引盈利的 ~14×	市场已按见顶来定价	S18004,S18005,S18027



英伟达 FY2016–FY2026 分业务年度收入堆叠柱状图：数据中心收入从 $0.34B（占 7%）增至 $193.7B（占 90%），游戏业务从 $2.8B 增至约 $16B；总收入从 $5.0B 增至 $216B。

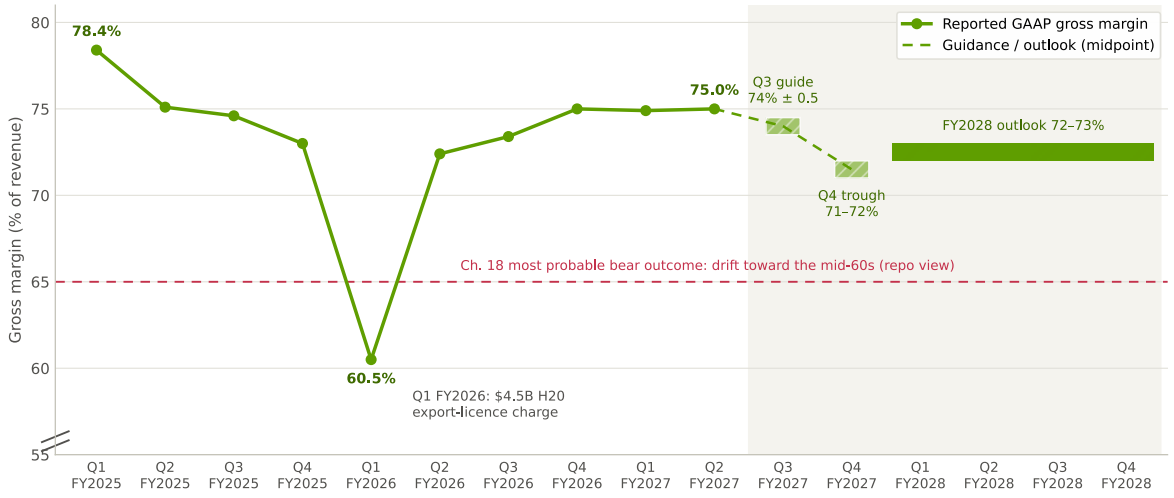
最新季度有两点值得注意。其一，数据中心收入如今可以从两个维度拆分：按客户分，超大规模云厂商与 ACIE 约为 55:45 [S406]；按产品分，计算与网络约为 80:20 [S405,S408]。其二，指引本质上是供应指引：管理层表示 FY2028 的增长受限于供应所能支撑的规模 [S18000]。在 GTC 2026 上，公司估计 Blackwell 加 Vera Rubin 截至 2027 年的需求达 $1 trillion（🟡 各媒体对“订单”还是“收入机会”的表述不一）[S90001,S90002]。



Q2 FY2027 按平台划分的收入，单位 US$ B（图中标签：revenue = 收入，Data Center = 数据中心，Edge Computing = 边缘计算，Compute = 计算，Networking = 网络，Est. = 估计）。计算/网络的拆分，是根据已披露的网络收入环比 +18%、 以 Q1 的 $14.8B 为基数估算的 [S405,S408,S90014]。

Gross margin is guided from 75% to a 71–72% trough in Q4 FY2027, then 72–73% in FY2028

NVIDIA GAAP gross margin by fiscal quarter, % of revenue (Q1 FY2025–Q2 FY2027), with management's guidance range for Q3 FY2027 and outlook for Q4 FY2027 and FY2028



Hatched = guidance/outlook; axis starts at 55% (break marked)

Source: data from NVIDIA 8-Ks; Q2 FY2027 call as reported [S440] [S425] [S441] [S426] [S442] [S427] ...; chart by repo · As of 2026-11-05

英伟达季度 GAAP 毛利率折线图：从 Q1 FY2025 的 78.4%，降至计提 H20 费用的 Q1 FY2026 的 60.5%，再回升至 Q2 FY2027 的 75.0%；随后为管理层指引：Q3 FY2027 为 74% ± 0.5 个百分点，Q4 FY2027 因内存成本高于计划而触底于 71-72%，FY2028 随提价生效回到 72-73%。65% 处的虚线参考线标示第 18 章最可能的看空结果，即毛利率向 65% 左右回落。

提示

算例 —— 指引在美元上意味着什么。 以 Q3 $108B 的收入指引计，每 1 个百分点的毛利率相当于 每季度 ~$1.1B 的毛利，因此指引中从 75% 滑落到 71–72% 低点，在该收入水平下每季度减少毛利 ~$3–4B （本资料库测算）[S3,S90085]。第 18 章的 FY2028 路径为收入 ~$697B、毛利率 ~72.5%，对应 毛利 ~$505B（🔴 本资料库测算）[S18027,S18000]。若毛利率转而滑向 65%——本资料库认为最可能的 看空情景——同等收入下毛利降至 ~$453B，减少 ~$52B。**结论：** 英伟达的盈利风险在于毛利率点数， 而不在于出货量，而如今左右这些点数的是内存价格。

🔧 技术细节：核对 Q2 FY2027 的收入构成数字

Q1 FY2027 网络收入创下 $14.8B 的纪录 [S90014]；英伟达称 Q2 网络收入环比增长 18%，因此本资料库采用 ~$17.5B（14.8 × 1.18），并标注为“估计” [S408,S90012]。计算收入为数据中心收入减去网络收入，约 ~$71.5B。 客户拆分（超大规模云厂商 ~$48.7B、ACIE ~$40.3B）来自 CFO 评论 [S406]。两种拆

分加总均为 $89.0B，但对同一收入的切分方式不同，因此不能放在同一张流向图中。毛利率均为 GAAP 口径；自 Q1 FY2027 以来，GAAP 与非 GAAP 口径相差约 ~0.1 个百分点 [S403]。

逐层结论

每段浓缩了该层的索引页、八问表与竞争页面。分数为本资料库 1–5 分制的护城河评分，箭头为差距趋势，二者均为 🔴 本资料库判断，连同证据记录在 `data/x00_layer_verdicts.csv` 中 [S1500]；速查表把它们汇总在一张表中。

第 02 层 · GPU 芯片 —— 受挑战，3.0 ↘。 Rubin 可提供 35 PFLOPS 的稠密 NVFP4 算力，约为 V100 16 位峰值的 ~280×，但在 16 位下仅为 ~32×，因此大部分提升来自更小的数值格式 [S33005,S33010,S100]。2026 年 9–10 月的规格修订把 Rubin 的 HBM4 带宽从 22 TB/s 下调至 19.2 TB/s，NVLink 6 从每 GPU 3.6 TB/s 下调至 3.0 TB/s [S90006,S90007]。纸面上，AMD MI455X 如今在内存上领先（432 GB、23.3 TB/s，带宽高出 ~21%）[S144,S90093]。🔴 芯片层面的领先以月计，而非以代计 [S1502]。该层仍是利润引擎。

第 03 层 · 内存、封装与供应链 —— 深厚，4.0 ↗。 对推理而言，内存比算力更早成为瓶颈；HBM 约占 B200 制造成本的 ~45%（估计）[S35020]。英伟达与竞争对手 向同样的三家 HBM 厂商采购，因此其优势在于配额而非技术：$279B 的承诺与 2026 年 ~60% 的 CoWoS（🟡 估计）[S407,S379]。这是唯一一个差距在扩大的层级。代价是一笔固定成本，这使英伟达在 $4.5B 的 H20 费用中充当了缓冲垫 [S414]。

第 04 层 · CPU —— 单薄，2.0 →。 Grace 与 Vera 的意义在于集成。一致性 NVLink-C2C 链路为每颗 Vera Rubin GPU 提供到主机 ~900 GB/s 的带宽和 ~750 GB 的 CPU 内存 [S128,S4019,S100,S102]。但 CPU 仅占一个 ~$7.8M 机架的 ~2%（估计）[S331]，而 AMD 256 核的 EPYC Venice 是 Helios 机架的核心 [S4028,S538]。智能体（agentic） AI 可能使独立 CPU 成为新的插槽市场，CPU:GPU 比例正向 1:2–1:1 靠拢 [S4012,S4013]。

第 05 层 · 纵向扩展（NVLink、NVSwitch） —— 深厚，4.0 ↘。 NVL72 是其标志性产品。在 2026 年下调后，Vera Rubin 的 NVLink 域带宽达 216 TB/s，通过铜缆背板传输，每个机架 省去 ~19 kW 功耗和 ~$0.7M 的光学器件（估计）[S200,S201,S5000,S5016]。AMD Helios 宣称通过 UALink-over-Ethernet 达到 260 TB/s，谷歌 TPU pod 可达 9,216 颗芯片 [S226,S232]。开放的 UALink 产品 将于 2027 年推出 [S90051]。NVLink Fusion 是英伟达的反制手段：向 13 家 合作伙伴开放该链路，包括高通、富士通、英特尔（Intel）和 AWS Trainium4，但每个系统中都保留英伟达芯片（🟡） [S131,S518,S5018]。

第 06 层 · 横向扩展网络 —— 受挑战，3.0 →。 Mellanox（2019 年以 $6.9B 收购）已成长为年收入 ~$31.4B 的业务 [S464,S402]。买家选择了以太网——2026 年 1Q 以太网约占 AI 后端交换机销售额的三分之二（🟡 Dell'Oro）——英伟达随之推出 Spectrum-X，同比增长 2.6× [S90054,S408]。博通比 Spectrum-6 早 ~12 个月交付 102.4 Tb/s 交换机，Celestica 在 2026 年 1Q 领跑 AI 后端交换市场 [S274,S6019,S90054]。英伟达的优势在于把网卡（NIC）、交换机和 NCCL 调优打包销售。

第 07 层 · DPU、SuperNIC、存储与安全 —— 受挑战，3.0 ↘。 如今每颗 GPU 都配有自己的 SuperNIC：GB200 上为 400 Gb/s，GB300 上为 800，Vera Rubin 上为 1.6 Tb/s [S266,S264,S33004]。BlueField-4 把闪存变成推理用的 KV 缓存层级 [S7511]。超大规模云厂商 运行自家的卸载方案（AWS Nitro、Google Titanium），而 Helios 为每颗 GPU 配置 2.4 Tb/s 的 AMD Pensando 网卡 [S292,S228]。存储软件的利润流向 VAST Data、DDN 和 WEKA 等合作伙伴 [S1507]。

第 08 层 · 系统、机架与 AI 工厂 —— 深厚，4.0 ↘。 英伟达单系统功率从 3.2 kW（DGX-1）升至 ~132 kW（GB300 NVL72），Kyber 计划达到 ~600 kW，因此液冷 和 800 V 直流供电如今已成为产品的一部分 [S310,S337,S305,S90063]。产出指标是 每兆瓦 token 数，GB300 NVL72 在该指标上领先 [S621,S622]。AMD Helios（31 TB HBM4，约为 Vera Rubin 的 ~1.5×）约自 2026 年 Q3 末开始出货，在纸面上于 7 项机架指标中的 3 项领先 [S90020,S90021,S1508]。

第 09 层 · CUDA 与系统软件 —— 受挑战，3.5 ↘。 护城河在于 长尾：~6M 开发者（自 2025 年以来持平），以及在每个主流框架中的原生支持 [S528,S587]。侵蚀是 真实的。torch.compile、Triton、vLLM 和 SGLang 可在多家厂商的硬件上运行，AMD 在新前沿模型上的滞后已缩短至 26 天，高通于 2026-07-29 完成了对 Modular（Mojo/MAX）约 ~$3.9B 的收购 [S578,S580,S631,S9511]。🔴 3.5 分是第 09 层各细分项平均分 ~3.6 的取整 [S1509]。

第 10 层 · 软件库（CUDA-X） —— 最深，4.5 →。 英伟达称其拥有“数百个 软件库” [S10047]。在本资料库的 15 个领域测试中，没有对手在任何领域领先，AMD 在 3 个领域持平 [S1510]。AI 核心部分 （GEMM、注意力、集合通信）是可复制的；AMD 的 RCCL 就是基于 NCCL 的源代码构建的 [S10002]。数据、仿真与 科学计算库的长尾则难以复制。软件库是免费的，其价值体现在 GPU 定价中。

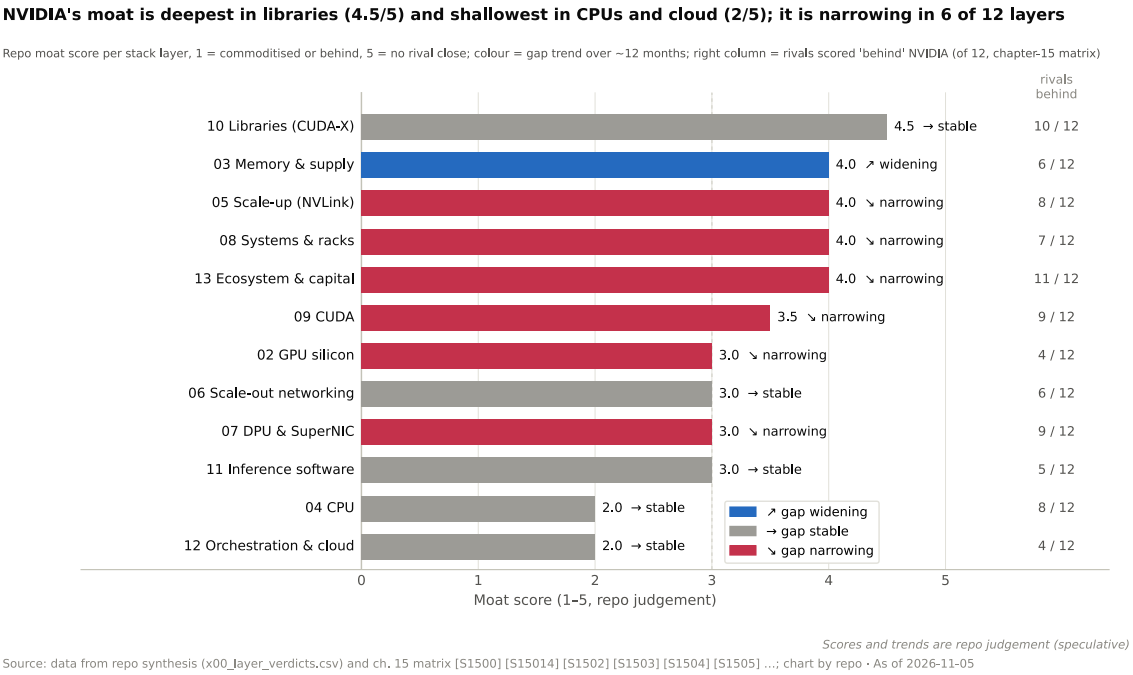
第 11 层 · 推理与 AI 软件 —— 受挑战，3.0 →。 Dynamo 1.0 在 GTC 2026 上以 Apache-2.0 协议开源发布 [S90066]。将预填充（prefill）与解码（decode）分离，使 B200 在长提示词下的 每 GPU 吞吐量提升 ~2.5× [S621]。这一层几乎没有能锁定客户的东西。开源引擎可在 AMD 和 TPU 上运行，谷歌 TPU 服务某一大型模型的每 token 成本比 B200 低 ~18% [S580,S625]。直接软件收入每年约 ~$2B，不到数据中心收入的 1% [S11011]；关键在于带动硬件销售。

第 12 层 · 编排与云服务 —— 单薄，2.0 →。 英伟达收购了控制平面（Run:ai ~$700M、SchedMD），并将其大部分开源 [S479,S12000,S12510]；DGX Cloud 转向内部使用，Lepton 将开发者导流至合作伙伴云（🟡） [S90068,S598]。超大规模云厂商掌握 客户、控制平面以及自研芯片 [S1512]。英伟达以交易对手身份参与，持有 ~$65B 的云服务 承诺以及对 CoreWeave $6.3B 的兜底承诺 [S407,S90067]。

第 13 层 · 生态、市场进入与资本 —— 深厚，4.0 ↘。 主权 AI 在 FY2026 超过 ~$30B，已公布的国家级协议涉及 ~1.03M 颗英伟达 GPU [S90071,S13003,S13000]。对非上市公司的股权投资在 18 个月内从 $3.4B 增至 $51.2B [S13043,S90072]。资产负债表上的 差距在扩大，但需求端的差距在收窄。博通的 AI 收入是“超大规模云厂商 + 博通”联盟最清晰的衡量指标，它相当于英伟达数据中心收入的比例在约两年内从 ~11–14% 升至 ~19% [S2516,S1513]。

> **提示**
>
> **算例 —— 解读一个结论：为什么纵向扩展得 4 分却趋势向下。** 一个 Vera Rubin 机架的 NVLink 网络 承载 72 × 3.0 TB/s = **216 TB/s**，而其 72 块 ConnectX-9 网卡的双向总带宽为 28.8 TB/s：留在机架内部的带宽 是离开机架带宽的 **7.5×** [S200,S33004]。要匹敌这一点，需要同时具备交换芯片、SerDes、 铜缆或光学背板以及集合通信库。这解释了 4 分。AMD Helios 宣称 260 TB/s，UALink 产品预计于 2027 年 推出，因此趋势向下 [S226,S90051]。**结论：** 高分加下行箭头是本资料库中最常见的结论。它描述的是 一种今天真实存在、但已能看到到期日的领先。

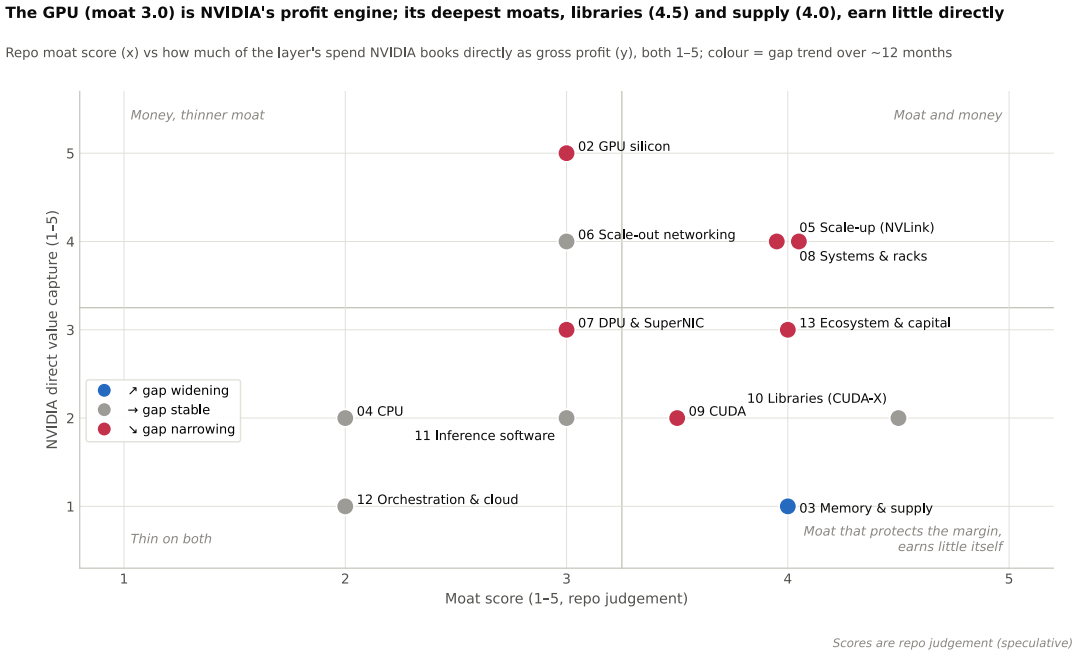
护城河最强与最弱之处



横向柱状图：本资料库对英伟达十二个技术栈层级的护城河评分，按差距趋势着色。软件库（CUDA-X）4.5，稳定；内存与供应 4.0，扩大；NVLink 纵向扩展 4.0、系统与机架 4.0、生态与资本 4.0，均在收窄；CUDA 3.5，收窄；GPU 芯片 3.0 与 DPU/SuperNIC 3.0 收窄；横向扩展网络 3.0 与推理软件 3.0 稳定；CPU 2.0 与编排和云 2.0 稳定。12 层中有 6 层差距在收窄，仅供应层在扩大。被评为落后于英伟达的竞争对手数量，从 12 家中的 4 家（GPU 芯片、云）到 12 家中的 11 家（生态）不等。

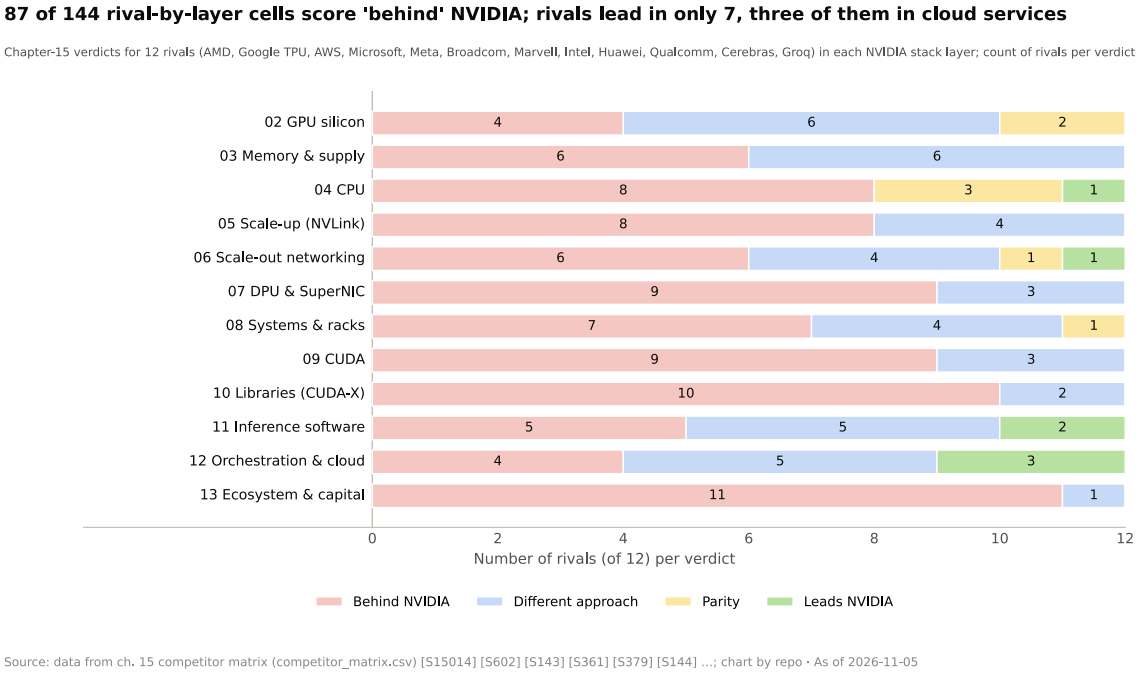
排名	层级	护城河评分	趋势	护城河靠什么守住	在哪里渗漏
1	10 软件库	4.5	→	覆盖每一代 GPU 的调优；15 个领域的广度	AI 核心可复制（RCCL 源自 NCCL） S10002
2	03 内存与供应	4.0	↗	$279B 承诺；2026 年 ~60% 的 CoWoS S407,S379	HBM 厂商攫取利润 S35020
3	05 纵向扩展	4.0	↘	已量产的 72-GPU 域；铜缆背板 S5000	Helios 260 TB/s；UALink 2027 S226,S90051
4	08 系统	4.0	↘	年度机架设计、ODM 生态 S3014	Helios 自 2026 年 Q3 末出货 S90020
5	13 生态与资本	4.0	↘	~$99B 股权投资；渠道覆盖 S90073	博通联盟达英伟达数据中心收入的 ~19% S2516
6	09 CUDA	3.5	↘	长尾、首日支持 S633	前沿实验室迁移；ROCm 滞后 26 天 S631
7	02 GPU 芯片	3.0	↘	迭代节奏、NVFP4、双裸片封装 S100	MI455X 纸面持平或超越 S144,S90093
8	06 横向扩展	3.0	→	网卡–交换机–NCCL 捆绑 S464	商用以太网、超以太网（Ultra Ethernet） S274,S575
9	07 DPU 与 SuperNIC	3.0	↘	ConnectX 在 1.6 Tb/s 上领先 S33004	自研卸载方案；Pensando S292,S228
10	11 推理软件	3.0	→	机架协同设计、逐模型调优 S621	开源引擎；TPU 每 token 成本 S625
11	04 CPU	2.0	→	一致性 C2C 链路 S129	x86 与超大规模云厂商的 Arm 芯片 S4028
12	12 编排与云	2.0	→	配额与资本 S407	超大规模云厂商掌握客户 S90026

有三个规律值得注意。最深的护城河不在芯片，而在软件库、供应配额和机架级系统，这些都复制得慢、 成本高。一半层级的差距在收窄，每次都是因为挑战者攻击了某个*部件*（AMD 的芯片与机架、UALink 的互连网络、 开源推理引擎）。而单薄的层级——CPU 和云——本就是英伟达从不需要赢下的；它通过 NVLink Fusion、对英特尔 $5B 的投资以及对新兴云服务商的兜底将其收编 [S90031,S4009,S90067]。



散点图：按护城河评分（x 轴，1 至 5）与直接价值获取（y 轴，1 至 5）定位英伟达十二个技术栈层级。上方：GPU 芯片（护城河 3.0，价值获取 5）是利润引擎；NVLink 纵向扩展与系统（4.0, 4）以及横向扩展网络（3.0, 4）也盈利丰厚。右下：软件库（4.5, 2）、CUDA（3.5, 2）与内存和供应（4.0, 1）是护城河深、直接收益少的层级，用于守护 GPU 的毛利率。左下：CPU（2.0, 2）与编排和云（2.0, 1）两方面都较弱。生态与资本位于（4.0, 3）。所有评分均为本资料库的判断。

第二张图加入了钱的维度。英伟达在 GPU、纵向扩展网络、横向网络和机架上确认毛利；软件库、CUDA 和供应配额 直接收益很少，但守护着这份利润。只复制盈利部分（芯片、机架）的挑战者会撞上防御层；只复制 防御部分（可移植的编译器）的挑战者，在同时交付硬件之前一无所获。



堆叠横向柱状图：在第 15 章矩阵中，针对英伟达十二个技术栈层级，统计 12 家对手中分别被评为落后、路线不同、持平或领先的数量。144 个单元格中 87 个落后、43 个路线不同、7 个持平、7 个领先。软件库（10 家落后）与生态和资本（11 家落后）是最一边倒的层级；GPU 芯片（4 家落后、2 家持平）与编排和云（4 家落后、3 家领先）竞争最激烈。对手领先的领域包括 CPU（AMD）、横向扩展交换（博通）、推理成本（谷歌 TPU、Cerebras）以及云服务（谷歌、AWS、微软）。

提示

算例 —— 软件差距折算成硬件成本是多少。 DeepSeek-V4-Pro 发布后第 27 天，在 SemiAnalysis 的测试中， B200 每 GPU 的 token 产出约为 MI355X 的 ~5× [S631]。假设 MI355X 每小时的持有成本只有一半 （🔴 示意性假设）。在其软件追上之前，其每 token 成本仍高出 5 ÷ 2 = **2.5×** [S1509]。**结论：** 正是免费的软件层，让英伟达能为付费层收费。每出现一个新的模型 家族，就会重新打开一个窗口，让更便宜的芯片产出更贵的 token。

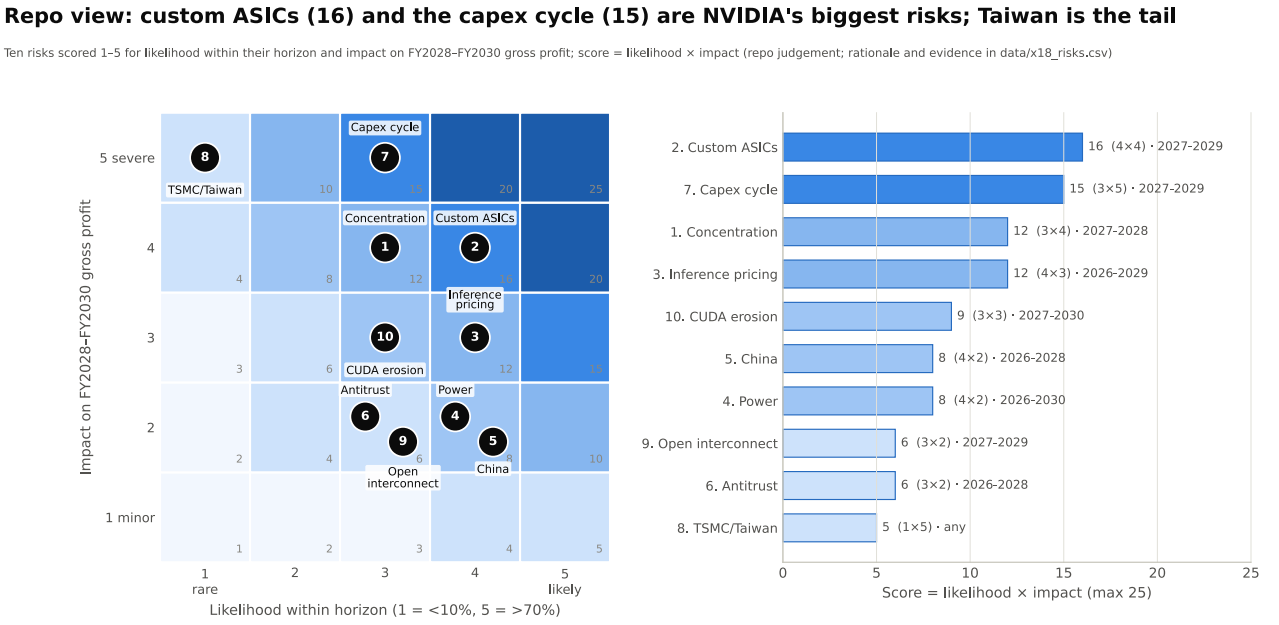
🔧 技术细节：护城河评分如何构建及其局限

每一层都围绕一个问题按 1 至 5 打分：买家或竞争对手要在这一层绕开英伟达，需要多长时间、多少投入？ 输入包括该层的要点速览、八问表（尤其是 Q4 优势来源、Q5 最强挑战者和 Q6 复制成本）、其竞争结论矩阵 以及第 15 章的“对手 × 层级”矩阵 [S1502,S1513,S15014]。3 分表示对手在某些维度上持平，而英伟达在集成上 领先。5 分表示没有对手接近、切换需要数年。没有任何层级得到 5 分。

差距趋势采用层级页面对过去 ~12 个月的描述。若某层情况好坏参半，趋势跟随竞争结论。例如在第 13 层， 资产负债表上的差距在扩大，但层级页面判断需求端差距在收窄，因此箭头向下 [S1513]。价值获取评分（1–5） 衡量的是英伟达把该层支出中的多大比例直接确认为毛利，而不是该层有多重要。

这些是判断而非测量；任何评分都可能上下浮动半分。对手结论计数是机械统计，但对超大规模云厂商和 初创公司给予同等权重。请关注排序与箭头，而不是小数位。

看空情景概要



风险热力图，横轴为可能性，纵轴为影响，均按 1 至 5 评分，另附排序柱状面板。得分（可能性 x 影响）：超大规模云厂商定制 ASIC 16（4x4），循环融资与资本开支周期 15（3x5），客户集中度 12（3x4），推理商品化 12（4x3），软件抽象层侵蚀 CUDA 9（3x3），电力约束 8（4x2），中国与出口管制 8（4x2），反垄断 6（3x2），开放互连标准 6（3x2），台积电/台湾集中度 5（1x5），属于低概率、极端影响的尾部风险。所有评分均为本资料库的判断。

第 18 章逐项给出了针对英伟达最有力且客观的反方论证， 并按可能性与影响为每项风险打分。核心结论是：看空逻辑并不是“需求疲弱”，而是当前需求集中、 部分依靠自身融资且可被替代，并且这三点都会先体现在价格上，再体现在销量上 [S18027]。

风险（第 18 章评分）	一句话看空论点	英伟达最有力的反驳
超大规模云厂商 ASIC（16）	博通季度 AI 收入相当于英伟达数据中心收入的 ~19%；Anthropic 可使用多达 1M 颗 TPU [S2516,S653]	对手压制的是价格而非销量；NVLink Fusion 收编了 Trainium4 [S518]
循环融资与资本开支周期（15）	承诺额为季度收入的 2.9×，而 FY2023 下行前约为 ~1.4× [S407]	单季 $50.3B 的经营现金流足以支撑 [S403]
客户集中度（12）	单一直接客户占 16%；前三大客户占 H1 FY2027 的 44% [S90069]	ACIE 占数据中心收入的 45% 且仍在增长 [S406]
推理商品化（12）	开源引擎随处可运行；TPU 每 token 成本低 ~18% [S580,S625]	机架级推理服务在聊天速度下保持成本领先 [S14000]
软件抽象层（9）	Triton、JAX 与 Mojo 让代码可移植 [S578,S9511]	首日支持与软件库长尾 [S633,S1510]

其余五项风险得分较低。电力约束与中国/出口管制各 8 分，反垄断与开放互连标准各 6 分，台积电/台湾 集中度 5 分，属于低概率、极端影响的尾部风险 [S18027]。结构性要点在于相关性。风险 1、2 和 7 都系于同样五六家 买家，它们既是英伟达最大的客户，也是最有能力的替代者 [S90069,S90011]。

注

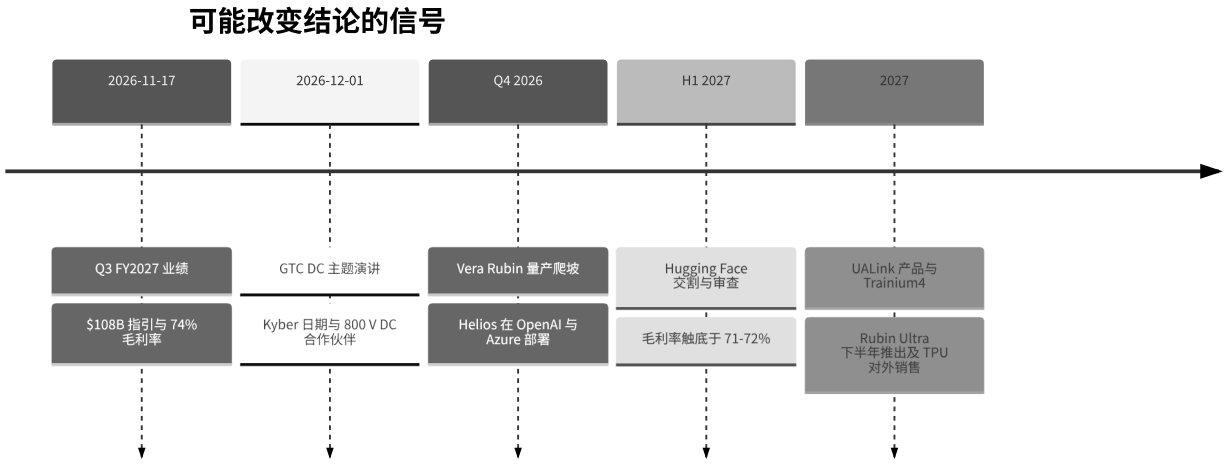
🐂 **看多观点。** 需求仍超过供应，管理层指引 FY2028 增长 ~70%，而市场对公司的估值约为 FY2028 指引 盈利的 14×，这一倍数意味着此后每年仅 ~2% 的增长（🔴 本资料库 测算）[S18000,S18027]。每个挑战者只攻击一两个层级；没有一家能批量交付完整系统。

注意

🐻 **看空观点。** 价格保护伞在顶端已经在收缩。第 14 章估计，GB300 降价 ~20% 即可与谷歌在每用户 100 tokens/s 下的内部 TPU 成本持平 [S14000]。最大的买家已与 AMD、博通和谷歌签下数吉瓦级合同， 使这一威胁变得可信 [S24000,S174,S653]。 需要关注的变量是毛利率，而非收入。

> 提示
>
> **算例 —— ASIC 设定的价格上限。** 案例研究 CS3 估计，若要匹敌 TPU 的每 token 成本，英伟达在该业务上的 毛利率将降至 ~62%（🔴）[S23010]。仅将其应用于超大规模云厂商（约占数据中心收入的 ~55%），其他部分保持 75%：$0.55 \times 62\% + 0.45 \times 75\% \approx 68\%$ [S90011,S18027]。以 FY2028 指引收入 ~$697B 计，比指引的 ~72.5% 低 4.5 个百分点，相当于每年 ~$31B 的毛利（🔴 本资料库测算）。**结论：** 即使英伟达不丢失任何一笔超大规模订单，ASIC 威胁每年也价值数百亿美元。

关注事项：2026 年 11 月至 2027 年年中



事件或信号	时间	关注要点	什么会改变判断
Q3 FY2027 业绩	2026-11-17 [S17005]	数据中心收入对比 $108B 指引；74% 毛利率；“受供应约束”的措辞 [S3,S90085]	若供应相关措辞趋软，将提高奥斯本效应风险 [S17006]
GTC DC 主题演讲	2026-12-01 [S90047]	Kyber 日期、Rubin CPX 进展、800 V DC 合作伙伴 [S507,S90063]	若确认 Kyber 推迟至 2028 年，开放互连机架将多出一年窗口 [S507,S508]
Vera Rubin 爬坡	Q4 2026 量产，H1 2027 持续增长 [S90009]	按修订后 19.2 TB/s 规格的出货情况 [S90006]	若规格进一步下调，将考验路线图的可信度
AMD Helios	首批出货约在 2026 年 Q3 末；OpenAI 自 2026 年 Q4 起 [S90020,S90021]	在 OpenAI、甲骨文（Oracle）与 Azure 的规模部署（🟡）[S90022,S90024]	机架级量产将使 AMD 成为真正的第二供应商
TPU 对外销售	2026–2027	Anthropic 多达 1M 颗 TPU；Meta 洽谈采购；甲骨文自 2027 年起托管 [S653,S90025,S552]	类似商用芯片的 TPU 销售，将在谷歌之外压制英伟达定价
Hugging Face 交割	目标 H1 2027 [S11500]	欧盟审查与美国司法部（DOJ）关注；中立性承诺 [S11027,S11028]	附加条件将考验英伟达作为中立模型平台的定位
中国	持续进行	H200 许可证与已确认收入（尚无）；指引不含中国数据中心计算产品 [S90081,S90032]	波及海湾地区的第三国规则比中国本身更重要 [S18027]
博通 AI 收入	下季度指引 $21.7B [S2516]	ASIC 相当于英伟达数据中心收入的比例	若持续升至 ~20% 以上，将证实 ASIC 风险

> 提示
>
> **算例 —— 估算中国这一期权的价值。** 第 18 章借助案例研究 CS6，估计英伟达在中国数据中心市场的规模 约为每年 ~$17.5B（🔴）。以 75% 毛利率计，对应毛利约 ~$13.1B。对获许可的 H200 销售征收 25% 的收入分成，将有效毛利率压至 50%，即约 ~$8.8B，因此**该分成每年的成本约为 ~$4.4B**，约占 FY2028 指引 毛利的 1% [S18027,S90032]。**结论：** 中国已从支柱变成一项期权。值得关注的政策 风险是任何波及其他地区主权买家的规则。

这对企业发展读者意味着什么

综合分析给出了三种在合作、投资或收购问题上解读技术栈的方式。完整论述——逐层对照高通公开的 数据中心布局——见第 19 章 —— 对高通的启示。该章仅使用 公开信息，并以向管理层提出问题的形式呈现。

层级定位	层级	对挑战者或合作伙伴的含义
既赚钱又设防（利润与护城河兼具）	05 纵向扩展、08 系统	最难正面进攻；可选路径是合作（NVLink Fusion、MGX）或开放替代方案（UALink、ESUN）[S131,S90052]
赚钱，护城河较薄	02 GPU 芯片、06 横向扩展	挑战者已在规格与价格上竞争的领域：AMD、博通、定制 ASIC [S144,S274]
设防，赚钱少	03 供应、09 CUDA、10 软件库	可移植性资产与供应合作是杠杆点：Modular、HBM 基础裸片、CoWoS 配额 [S9511,S3007,S379]
两者皆薄	04 CPU、12 云	开放的插槽：智能体 CPU、调度器与新兴云服务商渠道 [S4013,S12510]

公开案例显示每条路径都有人在走：AWS 在 Trainium4 上采用了 NVLink Fusion [S90034]，AMD 通过收购 ZT Systems（$4.9B）获得了机架设计能力 [S8527]。根据公开信息，高通同时在多条路径上布局：作为 NVLink Fusion 的 CPU 合作伙伴 [S131]、AI200 与 AI250 推理机架 [S173]、支

持 UALink 与 ESUN 的 Dragonfly AI300 [S90060]、约 ~$3.9B 收购 Modular [S9511]，以及与 AWS 的定制芯片协议 [S90087]。第 19 章探讨哪些布局能够产生复利效应。

> **提示**
>
> **算例 —— 价格保护伞能多快收拢。** 假设某挑战者今天的机架定价比英伟达低 30%（🔴 示意性假设）。 如果英伟达将系统价格下调 ~20%——第 14 章估计这一降幅可与谷歌在每用户 100 tokens/s 下的 内部 TPU 成本持平——英伟达仍可保持 ~66% 的毛利率（🔴）[S14000]。挑战者的 折扣将缩小至 1 − 0.70 ÷ 0.80 = **12.5%**。**结论：** 任何第二供应商加速器的商业论证， 都应以英伟达*降价后*的价格来检验，因为英伟达负担得起降价，而挑战者的 价格保护伞会随即收缩。

🎯 企业发展视角

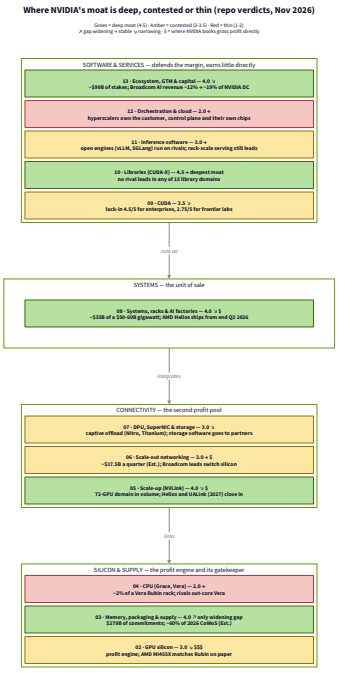
1. **以系统而非芯片为基准进行评估。** 每一项挑战者的主张，都应基于实测吞吐量，换算为指定交互速度下的 每百万 token 成本 [S14000,S621]。芯片层面的持平或领先（AMD 的 MI455X）并未转化为收入上的持平：2023 年初至 2026 年年中， 英伟达相对 AMD 的数据中心收入领先倍数从 3.3× 扩大到 13× [S450,S543,S405]。
2. **跟踪毛利率，而不是份额。** 两年间 AI 芯片收入份额仅从 ~90% 变为 ~87% [S416,S660,S663]。更敏感的信号是毛利率从 75% 走向指引中 71–72% 低点的路径，以及 超大规模云厂商的定价是否会将其推向本资料库 65% 左右的看空情景 [S90085,S18027]。
3. **防御层是可移植性资产被定价的地方。** Groq 约 ~$20B 的授权交易（约为其最近一轮私募估值的 ~2.9×）、 高通约 ~$3.9B 收购 Modular，以及英伟达 $12.9B 的 Hugging Face 交易，定价的都是能改变切换成本的 软件或架构 [S90019,S9511,S11500]。还有哪些独立的编译器、推理服务与 内核资产，谁可能收购它们?
4. **供应是唯一在扩大的差距。** 在英伟达已承诺 $279B、锁定 2026 年 ~60% CoWoS 的情况下 [S407,S379]，新进入者 在 2027–2028 年能获得多少 HBM 与封装产能？供应合作是否比设计类收购更有价值?
5. **合作还是竞争，需要逐层决定。** NVLink Fusion 让竞争对手的 CPU 和加速器能纳入英伟达的机架发布 日程，而 UALink 与 ESUN 保留了一条开放路径 [S131,S90051,S90052]。第 19 章基于公开信息， 梳理每条路径对高通的适用之处。

速查表 —— 每一层浓缩为一行

综合篇 · 一页图表 · 阅读约 ~6 分钟 · 最后核实：2026-11-05 · 各项结论的说明见执行摘要

⚡ 要点速览

- **横向阅读一行**，可以看到一个层级的职能、英伟达（NVIDIA）现有产品 → 下一代、关键指标、优势来源、最强挑战者、 趋势、价值池以及企业发展（corp dev）角度。纵向阅读“护城河 · 趋势”一栏，即可了解全貌。
- **护城河最深：** 软件库（4.5 分，满分 5），其次是内存与供应、纵向扩展（scale-up）、系统和生态（各 4.0）。🔴 **最薄：** CPU 以及编排与云（2.0）[S1500]。
- **12 层中有 6 层差距在收窄**，只有供应层在扩大，该层的承诺额已达 $279B [S1500,S407]。
- **利润集中在四个硬件层：** GPU、NVLink、网络（FY2026 约 ~$31.4B）和机架（每吉瓦约 ~$35B 的 英伟达产品）[S402,S398]。软件层大多免费，用于守护这份毛利 [S1510]。
- **各层最强挑战者：** 芯片和机架上是 AMD，系统和每 token 成本上是谷歌（Google）TPU，以太网和定制 ASIC 上是博通（Broadcom），云上是超大规模云厂商 [S144,S90021,S625,S274,S90026]。



英伟达十二个技术栈层级的分层蛋糕图，按本资料库的护城河结论着色：深厚（绿色）为软件库 4.5、内存与供应 4.0（唯一差距在扩大的层级）、纵向扩展 4.0、系统 4.0 和生态 4.0；受挑战（琥珀色）为 CUDA 3.5、GPU 芯片 3.0、横向扩展网络 3.0、DPU 3.0 和推理软件 3.0；单薄（红色）为 CPU 2.0 以及编排与云 2.0。美元符号标出英伟达直接确认毛利的层级：GPU 芯片、纵向扩展、横向扩展与系统。

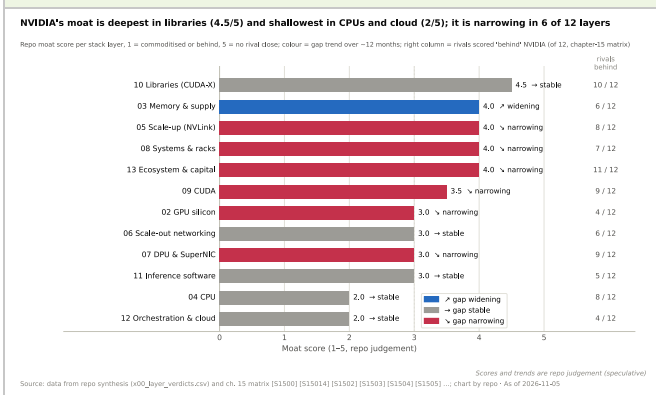
每一层浓缩为一行

护城河 = 本资料库 1–5 分制的护城河评分；箭头 = 差距趋势（↗ 扩大 · → 稳定 · ↘ 收窄）。二者均为 🔴 本资料库判断，记录于 `data/x00_layer_verdicts.csv` [S1500]。

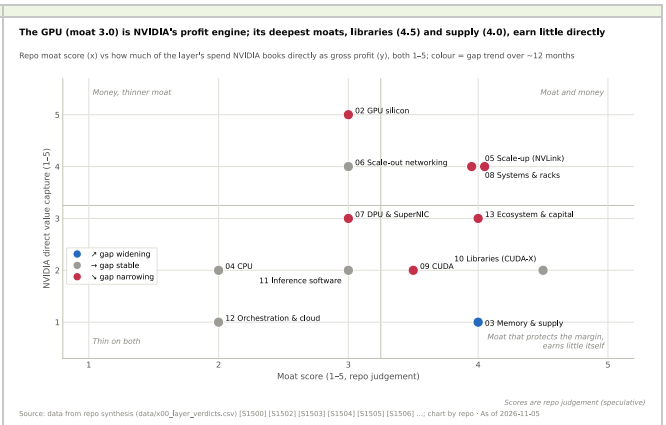
层级	职能	英伟达现在 → 下一代	关键指标	优势来源	最强挑战者	护城河 · 趋势	价值池	企业发展角度
02 GPU 芯片	把电力转化为矩阵运算	Blackwell Ultra → Rubin（2026 年 8 月起出货）→ 🟢 Rubin Ultra（2027 下半年）→ 🟢 Feynman（2028） [S500,S35018,S109]	Rubin：35 PFLOPS 稠密 FP4；288 GB HBM4，带宽 19.2 TB/s [S33005,S90006]	年度迭代节奏、NVFP4、双裸片封装；每代投入 ~$10B [S35028]	AMD MI455X：纸面上 432 GB、20 PFLOPS FP8 [S144]	**3.0 ↘**	利润引擎：B200 制造成本 ~$6.4K，售价 $30–40K（估计） [S35020,S35026]	以 SRAM 优先或容量优先的推理架构作为切入点；Groq 授权交易 ~$20B 🟡 [S90019]
03 内存与供应	为张量核心供给数据；确保 HBM 与封装产能	HBM3E → HBM4（Rubin）→ 🟡 采用定制基础裸片的 HBM4E（2027） [S3007]	$279B 承诺；2026 年 ~60% 的 CoWoS（🟡 估计） [S407,S379]	最大的承诺采购方，每代 HBM 率先导入	AMD 重容量的 HBM4（432 vs 288 GB）；HBM 厂商的定价权 [S144]	**4.0 ↗**	成本转嫁：HBM 约占 B200 制造成本的 ~45%（估计） [S35020]	HBM 基础裸片与控制器 IP；供应合作 vs 设计类收购

层级	职能	英伟达现在 → 下一代	关键指标	优势来源	最强挑战者	护城河·趋势	价值池	企业发展角度
04 CPU	主机：为 GPU 供数，运行推理服务与智能体工具	Grace → Vera（88 个定制核心，也可独立销售）→ 🟡 Rosa（2028） S4000,S90004	Vera Rubin 上每 GPU 的主机链路 ~900 GB/s，DGX H100 为 128 GB/s S128,S4019,S100	一致性 NVLink-C2C 与机架协同设计，而非更强的核心	Helios 中的 AMD EPYC Venice（256 核）；超大规模云厂商的 Arm 芯片 S4028,S538	**2.0 →**	规模小：约占 ~$7.8M Vera Rubin 机架的 ~2%（估计） S331	随着 CPU:GPU 比例向 1:2–1:1 靠拢，智能体 CPU 插槽出现机会 S4012,S4013
05 纵向扩展	让 72 颗 GPU 像一颗一样工作	GB300 NVL72（130 TB/s）→ Vera Rubin NVL72（216 TB/s）→ Kyber NVL144（2027；🟡 有延期报道） S262,S200,S507	每机架 216 TB/s，为该机架横向扩展带宽的 7.5× S200,S33004	交换芯片、SerDes、铜缆背板与 NCCL 每年同步更新 S5000	AMD Helios：基于 UALink-on-Ethernet 达 260 TB/s；TPU pod 达 9,216 颗芯片 S226,S232	**4.0 ↘**	每个机架都含 NVLink 交换托盘与背板；Fusion 授权收入 S131	NVLink Fusion（13 家合作伙伴 🟡）vs UALink/ESUN；UALink 产品 2027 年推出 S518,S90051
06 横向扩展	把多个 NVLink 域连成一台机器	ConnectX-8 800G、Spectrum-X → ConnectX-9 1.6T、CPO 交换机（2026）→ 🟡 ConnectX-10（2028） S264,S6019,S90004	Q2 FY2027 网络收入 ~$17.5B（估计），约占数据中心的 ~20% S408	Mellanox（$6.9B）加上网卡–交换机–NCCL 捆绑 S464	博通 Tomahawk 6，早约 ~12 个月；以太网约占 AI 后端的 ~⅔ 🟡 S274,S90054	**3.0 →**	FY2026 ~$31.4B；光学器件每 GPU ~$6,000 S402,S6016	随着共封装光学转移价值，光学器件、激光器与网卡 IP 值得关注 S90049
07 DPU 与 SuperNIC	安全地把每个字节送入、送出每颗 GPU	ConnectX-8、BlueField-3 → ConnectX-9、BlueField-4（2026）→ 🟡 ConnectX-10、BlueField-5（2028） S7001,S90004	每 GPU 网卡带宽：400 → 800 → 1,600 Gb/s（GB200 → GB300 → Vera Rubin） S266,S264,S33004	Mellanox 的技术积淀，与 DOCA、NCCL 及 GPUDirect 协同设计	自研卸载方案（AWS Nitro、Google Titanium）；AMD Pensando 每 GPU 2.4 Tb/s S292,S228	**3.0 ↘**	网卡 + DPU 约占 NVL72 机架的 ~3–11%（估计）；存储软件利润归合作伙伴 S1507	KV 缓存存储层（BlueField-4 STX）作为新插槽 S7511
08 系统与机架	把芯片变成供电、散热完备的计算机	GB300 NVL72（~132 kW）→ Vera Rubin NVL72（~190–230 kW 🟡）→ 🟢 Kyber（~600 kW，2027） S337,S303,S305	每用户 50 tok/s 下，GB300 NVL72 每兆瓦 token 产出约为 H200 的 ~13×（估计） S621,S622	每年一款集成机架，由 ODM 制造（富士康约占 ~40%） S3014	AMD Helios：31 TB HBM4，约自 2026 年 Q3 末出货 S90021,S90020	**4.0 ↘**	每 GW $50–60B 投资中英伟达产品约 ~$35B；ODM ~2–3% S398,S332	电源、散热与 800 V DC 供应商；AMD 收购 ZT（$4.9B） S90061,S8527
09 CUDA	在发布首日就把模型运算转化为高速内核	CUDA 13.x → cuTile Python、CuTe DSL S527,S9007,S9030	原生支持 12 个主流框架中的 12 个（36/36）；ROCm 26，高通 4 S587,S586,S596	二十年的复利积累；~6M 开发者 S528	PyTorch/Triton/vLLM 搭配 ROCm；TPU 上的 JAX/XLA S578,S580	**3.5 ↘**	免费；通过 GPU 毛利和授权（标价每 GPU 每年 $4,500）获利 S11013	可移植性资产：高通（Qualcomm）已完成收购 Modular（~$3.9B） S9511
10 软件库	把规格表上的 FLOPS 变成实际交付的速度	cuBLAS、cuDNN、CUTLASS、NCCL 2.32 → GPU 发起的 NCCL、CuTe DSL S10038,S10009	仅靠软件：B200 在 4 个月内从 ~2,000 提升到每 GPU 4,600 DeepSeek-R1 tok/s S646	覆盖每一代 GPU 的调优；横跨 15 个领域的广度 S1510	AMD ROCm（RCCL 基于 NCCL 的代码构建） S10002	**4.5 →**	免费；带动 GPU 与 AI Enterprise 销售 S1510	以推理为先的平台在第一天需要哪些软件库家族 S1510
11 推理软件	在每个延迟档位上让每颗 GPU 产出最多 token	TensorRT-LLM、Dynamo 1.0（2026 年 3 月）→ Groq 3 LPX 机架；🟡 Hugging Face S90066,S506,S11500	每用户 50 tok/s 下 GB300 NVL72 每 GPU ~6,261 tok/s，约为 H200 的 ~20× S621	与机架协同设计的推理服务软件；逐模型调优	开源引擎（vLLM、SGLang）；TPU 在某一模型上每 token 成本低 ~18% S580,S625	**3.0 →**	直接软件收入每年约 ~$2B，不到数据中心收入的 1% S11011	模型分发：$12.9B 的 Hugging Face 交易面临欧盟与美国司法部关注 S11500,S11027,S11028
12 编排与云	把机架变成有效、付费的 GPU 小时	Run:ai、Mission Control、Slurm → DSX OS（2026）；DGX Cloud Lepton S12513,S598	利用率 30% vs 90% 时，每有效 GB300 GPU 小时 $5.00 vs $1.67（估计） S332,S324	集成能力加上配额与资本，而非软件授权	超大规模云厂商：掌握客户、控制平面与芯片 S90026,S90035,S90044	**2.0 →**	租赁利润归云厂商；英伟达持有 ~$65B 的云服务承诺 S407	规模化路径：超大规模云厂商、新兴云服务商还是主权客户 S90071
13 生态与资本	把技术转化为获得融资的需求	Inception、GTC、主权协议、~$99B 股权投资 → >$500B 的第三方融资平台（2026 年 8 月） S90073,S12528	非超大规模（ACIE）~$40.3B = Q2 FY2027 数据中心收入的 45%；主权 AI FY2026 >~$30B S406,S90071	装机量生态加上竞争对手无法匹敌的资产负债表	超大规模云厂商 + 博通 ASIC 联盟；AMD 以股权换吉瓦 S2516,S13506	**4.0 ↘**	间接：H1 FY2027 股权净收益 $23.7B，主要为按市值计价 S90072	供应商融资姿态；主权客户多源采购（HUMAIN：英伟达、AMD、高通） S13003,S13517,S90030

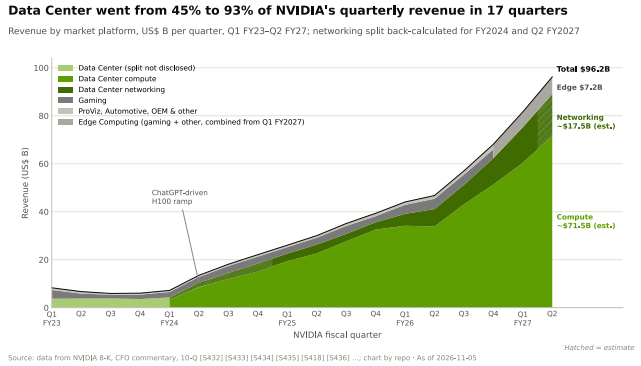
四张图



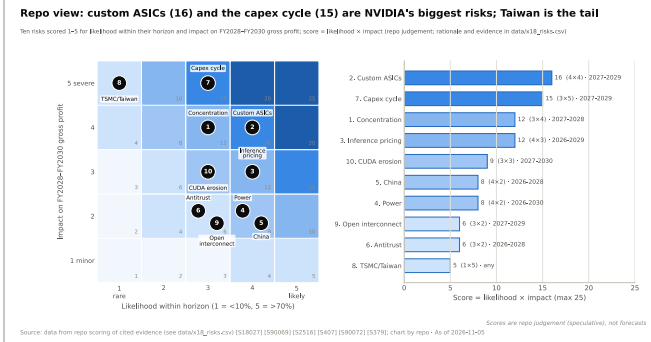
🔴 **各层护城河：** 软件库最深，12 层中有 6 层在收窄 [S1500]



🔴 **护城河 vs 利润：** GPU 负责赚钱，免费软件负责设防 [S1500]



收入结构： 17 个季度内，数据中心占季度收入的比重从 45% 升至 93% [S405] · 01 飞轮



🔴 **风险图：** 定制 ASIC（16）与资本开支周期（15）居首 [S18027] · 18 看空情景

> **提示**
>
> **算例 —— 读懂一行：横向扩展（scale-out）网络。** 关键指标显示，网络业务在 Q2 FY2027 收入 ~$17.5B（估计），约占数据中心收入的 ~20% [S408]。护城河一栏却只有 3.0 且趋势稳定，因为博通 比 Spectrum-6 早 ~12 个月交付了 102.4 Tb/s 交换机，且以太网拿下了 AI 后端交换机销售额的 ~⅔ [S274,S6019,S90054]。两者同时成立：买家为经过调优的网卡（NIC）–交换机–NCCL 捆绑方案向英伟达付费，而不是为别人没有的芯片付费。**结论：** 一个受挑战的层级依然可以是巨大的价值池；企业发展要问的是， 下一步价值会流向哪一部分（光学器件、激光器、网卡 IP） [S90049]。

> 🔧 **技术细节：每一栏的数据来源**
>
> - **职能、现在 → 下一代、关键指标、优势来源、最强挑战者：** 来自各层的索引页及其 八问表（Q1、Q2/Q3、Q4、Q5、Q7），通过该层自身的来源引用 [S1502,S1513]。
> - **护城河 · 趋势：** 本资料库的综合判断，依据各层的竞争结论与第 15 章的 “对手 × 层级”矩阵构建。方法见执行摘要 [S1500,S15014]。
> - **价值池：** 来自各层的价值链页面（Q8）。“免费”指英伟达通过硬件毛利而非该层自身的收入线 实现变现。
> - **企业发展角度：** 是一个问题而非建议，取自各层的“企业发展视角”。关于高通的具体角度（基于公开信息）， 见第 19 章。

🎯 企业发展视角

1. **箭头比分数更重要。** 六个 ↘ 箭头标出了竞争对手正在追赶的地方；每一处都是一个合作窗口， 在位者日后未必还会提供 [S1500]。
2. **利润与护城河相互背离。** 赚钱的四个层级（GPU、纵向扩展、网络、机架）由不赚钱的层级 （CUDA、软件库、供应）守护。挑战者需要同时针对两者制定计划。
3. **单薄的层级是开放的插槽。** CPU 与云编排得分 2.0。英伟达对其采取收编而非争夺的策略 （NVLink Fusion、开源的 Run:ai），因此第三方仍可在此建立地位 [S131,S12510]。
4. **供应是唯一在扩大的差距。** 如果 2027–2028 年的 HBM 和 CoWoS 已被分配 殆尽，表中所有合作问题都将无从谈起 [S407,S379]。

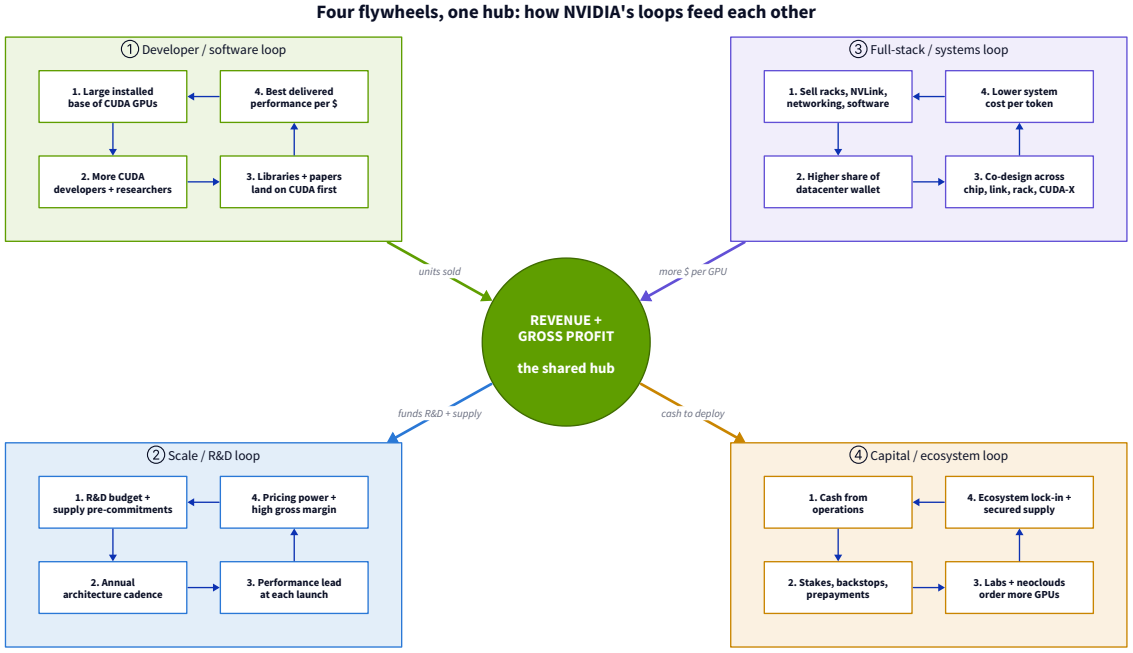
01 —— 英伟达的飞轮

第 01 章 · 四个相互强化的循环：各自有多强，又可能在哪里断裂 · 阅读约 ~28 分钟 · 最后核实：2026-11-05

> 注
>
> **如何阅读本章。** 飞轮是一组相互强化的循环：每转一圈，下一圈就更容易。 人们通常说英伟达（NVIDIA）拥有“CUDA 护城河”。更有用的视角是**四个共享同一枢纽——收入与毛利——的 循环**，而这个枢纽也正是它们可能同时失灵之处。每一节把一个循环当作机制来解释、加以量化， 并在结尾说明它可能如何断裂。各层章节提供更深入的内容。

⚡ 要点速览

- **一个枢纽，四个循环。** FY2026 收入达 $215.9B，约为 FY2016 $5.0B 的 ~43× [S1,S400]， 其中数据中心占 90% [S402]；Q2 FY2027 收入 $96.2B，同比 +106%，Q3 指引为 $108B [S405]。下面的每个循环都在向这个枢纽注入资金，或从中汲取资金。
- **① 开发者循环——规模大，但已不再加速。** 英伟达统计的 CUDA 开发者数量从 2M（2020）增至三倍， 达 ~6M（2025）[S529,S536]，2026 年 3 月仍为 ~6M [S528]；如今承载大部分推理的 开源推理服务栈（vLLM、SGLang）同样能在 AMD、TPU 和 昇腾（Ascend）上运行 [S580,S582]。
- **② 规模 / 研发循环——当下最强。** FY2026 研发支出增长约 ~14× 至 $18.5B，同时占收入比重降至 ~9% [S401,S400]；Q2 FY2027 的供应与产能承诺达 **$279B** [S407]——约为台积电（TSMC）2026 年全部资本开支预算的 5× [S35029]——支撑着年度迭代节奏 （2025 年 Blackwell Ultra、2026 年 Rubin、2027 年 Rubin Ultra、2028 年 Feynman）[S33020,S502]。
- **③ 全栈循环——钱包份额在上升。** 网络收入从 $8.6B（FY2024）增至 $31.4B（FY2026）[S416,S402]，英伟达称其在一座 $50–60B 的吉瓦级 AI 工厂中可拿下 ~$35B [S398]。
- **④ 资本循环——最新、争议最大。** 自 2025 年 9 月以来，英伟达已承诺约 ~$82B 的股权投资、 授权费与兜底承诺（据报道 OpenAI ~$30B、Groq ~$20B，Anthropic 最多 $10B，CoreWeave $8.3B，英特尔（Intel）$5B）[S480,S474,S469,S473,S472,S468]——这正是 循环融资批评的核心 [S431,S449]。
- **定价权是为一切提供资金的产出：** Q2 FY2027 GAAP 毛利率约 ~75% [S405]，而 FY2016 为 56% [S400]；GPU 的估计制造成本约为售价的 ~20% [S35020]。
- **最大的风险在于耦合。** 各循环共享同一枢纽，因此需求一旦停顿，四个循环会同时受到 冲击：$279B 的承诺 [S407]、$36B 的 AI 云产能担保 [S407]，以及占收入 61% 的四家 直接客户（Q3 FY2026）[S412]，会让飞轮变成刹车。上一次 下行周期曾让毛利率在一个季度内跌至 43.5% [S433]。



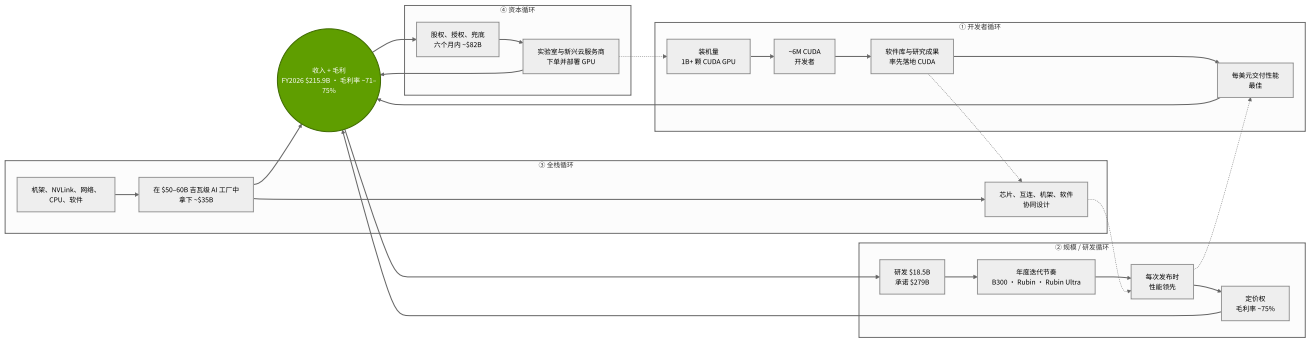
英伟达四个相互强化循环的示意图：开发者/软件、规模/研发、全栈/系统以及资本/生态，每个循环都是四步循环，均通过中央的收入与毛利枢纽相连——开发者循环与全栈循环为枢纽注入资金，规模循环与资本循环从中汲取资金。

1. 什么是飞轮——以及为什么英伟达有四个

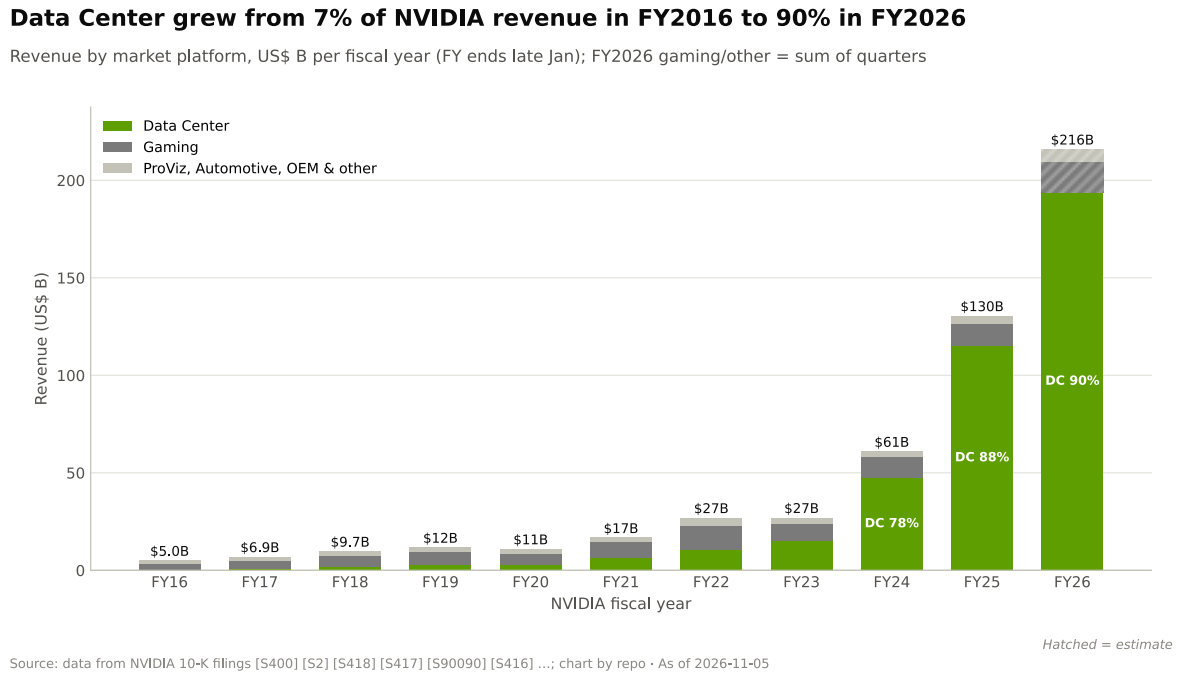
类比。 飞轮是一个沉重的轮子，难以启动，也难以停下。每推一次都会增加一点动量；推够了次数， 轮子自身的重量就会带着它转动。在商业战略中，“推动”是这样一种行动：其结果会使下一次行动更便宜 或更有效。单一循环可以被复制；而四个通过共享枢纽相互供能的循环要

难复制得多，因为对手 必须同时启动所有循环。

整体图景，并标注每一步的最新数字：



枢纽是实打实的钱。收入从 FY2016 的 $5.0B 增至 FY2026 的 $215.9B，几乎全部增量都 来自数据中心：



英伟达 FY2016–FY2026 分业务年度收入堆叠柱状图：数据中心收入从 $0.34B（占 7%）增至 $193.7B（占 90%），游戏业务从 $2.8B 增至约 $16B；总收入从 $5.0B 增至 $216B。

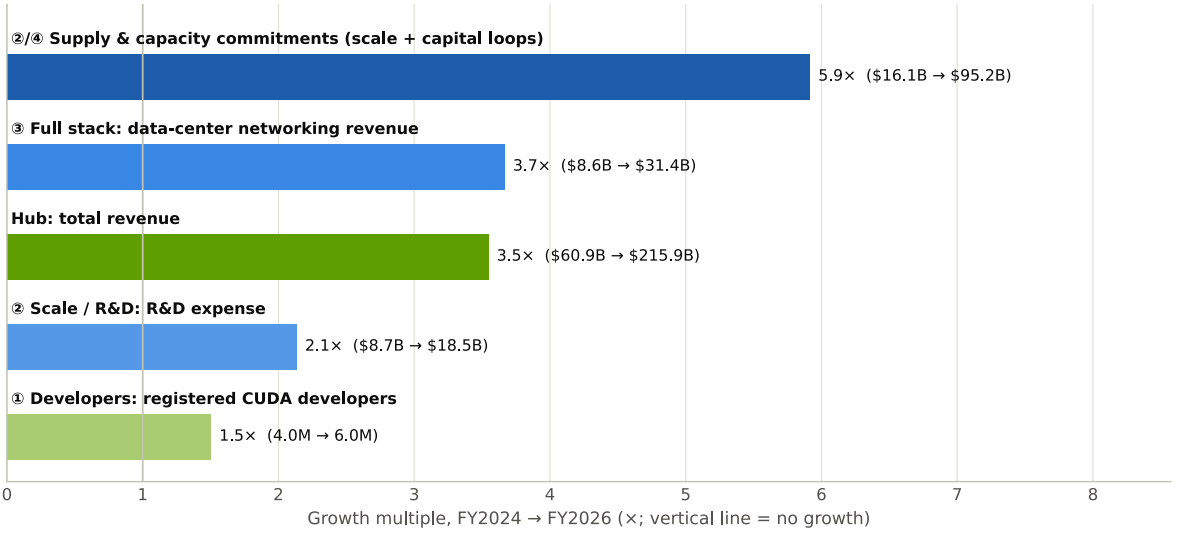
提示

算例 —— FY2026 每一美元收入的去向。 收入 $215.9B；GAAP 毛利率 71.1%（计入 $4.5B 的 H20 出口费用后）→ 毛利约 ~$153.5B [S1,S402,S444]。研发支出 $18.5B， 即**每美元 $0.09** [S401]；营业利润 $130.4B，**每美元 $0.60**；净利润 $120.1B，**每美元 $0.56** [S1,S402]。在随后六个月里，英伟达向客户、合作伙伴和供应商承诺了约 ~$82B （§5）——相当于把**约三分之二的年度净利润**回流到生态中，此外还在 Q1–Q2 FY2027 向股东返还了 约 ~$46B [S403,S405]。 这种资金分配正是飞轮的可见形态：研发为循环 ② 供能，承诺为循环 ② 和 ④ 供能， 股权投资为循环 ④ 供能。

哪些循环在加速？一个简单的检验方法，是比较各循环“引擎指标”在同样两年内的 变化：

Since FY2024 commitments grew 5.9× but CUDA developers only 1.5×

Growth multiple FY2024 → FY2026 of each loop's engine metric (developers: May 2023 → Mar 2025 NVIDIA statements)



Source: data from NVIDIA 10-K filings, CFO commentary and keynotes [S417] [S2] [S416] [S401] [S402] [S1] ...; chart by repo · As of 2026-11-05

横向柱状图：FY2024 至 FY2026 的增长倍数：供应与产能承诺 5.9 倍（$16.1B 增至 $95.2B），网络收入与总收入分别约 3.7 倍和 3.5 倍，研发 2.1 倍，注册 CUDA 开发者 1.5 倍，因此资本与供应循环如今增长最快。

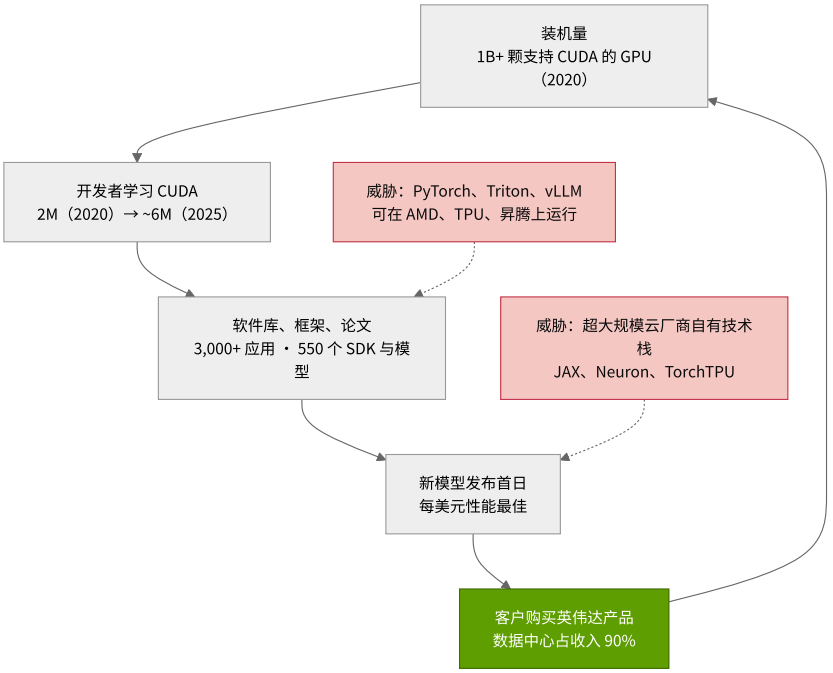
循环	引擎指标	过去	现在	解读
① 开发者	注册 CUDA 开发者	2M（2020）S529	~6M（2026 年 3 月）S528	规模大，增长趋平
② 规模 / 研发	研发支出	$1.33B（FY2016）S400	$18.5B（FY2026）S401	~14×，强度下降
② 规模 / 研发	供应与产能承诺	$4.79B（Q2 FY2022）S420	$279B（Q2 FY2027）S407	~58×（各年科目定义不同 S90092），现已超过一年的收入
③ 全栈	网络收入	$8.6B（FY2024）S416	$31.4B（FY2026）S402	~3.7×，约占数据中心的 ~20%
④ 资本	已承诺的股权投资与兜底	已披露约 ~$0.15B（2023）S481,S482	~$82B（2025 年 9 月–2026 年 2 月）S480,S474,S469	新出现，争议最大

🔧 技术细节：用系统动力学的语言描述强化循环

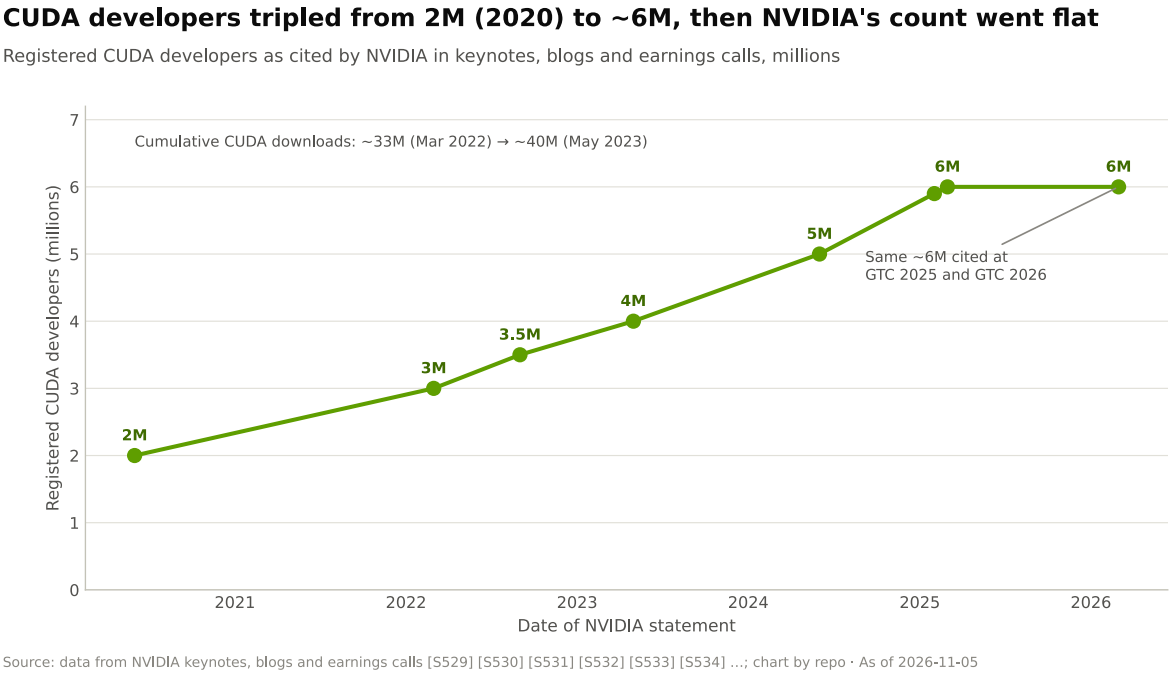
用系统动力学的语言来说，每个循环都是一个*强化*（R）循环：某个变量的增加，经过一段延迟后， 会导致其自身进一步增加。每个真实系统也都有限制增长的*平衡*（B）循环——在这里就是电力与 封装供应、客户预算、反垄断关注以及竞争对手的成本优势。对投资者而言，有两个性质很重要。第一， **延迟**：2018 年学会 CUDA 的开发者会在 2025 年的采购中带来回报，因此开发者循环无论向上还是 向下都反应缓慢。第二，**共享存量**：四个循环都从同一个存量（现金与毛利）中汲取资源， 因此对该存量的冲击会同时传导至每个循环。这就是为什么 §6 把相关性，而非任何单一循环， 视为主要风险。

2. 循环 ① —— 开发者与软件飞轮

机制。 运行同一套软件的 GPU 装机量会吸引开发者；开发者编写 以该软件为前提的软件库、模型与论文；这些软件库使下一代 GPU 的每美元效用高于缺少它们的 替代品；客户购买更多同类 GPU；装机量随之增长。英伟达在 2006–07 年凭借 CUDA 启动了这个飞轮——首个版本于 2007 年 6 月发布 S525——此后在每一代 产品间都保持了兼容。



英伟达自己公布的数字同时显示了规模与放缓。2020 年，它报告在用的 CUDA GPU 超过 1B 颗，每月新增开发者注册 39,000 个、CUDA 下载 438,000 次 [S529]。到 2022 年初，CUDA 累计下载 33M 次，其中仅 2021 年就有 8M 次 [S530]；到 2023 年年中约 ~40M 次，加速应用超过 3,000 个 [S533]。英伟达在 2022 年列出了 550 个 SDK 与 AI 模型 [S532]，以及在其平台上开发的 ~10,000 家初创公司 [S531]。



折线图：英伟达公布的 CUDA 开发者数量：2020 年 2M，2022 年初 3M，2023 年年中 4M，2024 年年中 5M，2025 年 3 月约 6M，2026 年 3 月再次引用的仍是约 6M；CUDA 累计下载量到 2023 年约达 40M 次。

提示

算例 —— 开发者循环造成的切换成本。 一家实验室若已在英伟达的 TensorRT-LLM（仅能在英伟达 GPU 上运行 [S589]）上调优好推理服务，要迁移就必须重新验证内核、量化方案和服务代码。如果 20 名工程师花 4 个月完成移植，按每人年全口径成本 $400K 计算，人工成本约 ~$2.7M（🔴 示意性假设）—— 相对于一台 $3M+ 的 GB200 NVL72 机架 [S326] 微不足道，但对初创公司而言不容小觑，而且每一代模型都会*重复*发生。这个循环真正的锁定效应不在于一次性移植，而在于新模型、新内核（FlashAttention 式注意力、NVFP4 等新数值格式）和新论文往往率先出现在 CUDA 上，因此非英伟达买家总是落后几个月。

为何该循环在边缘处减弱。 对 AI 而言重要的开发者群体，越来越多地是基于框架编写 Python 代码，而不是直接编写 CUDA——而这些框架已经支持多家厂商：

框架 / 软件库（2026 年 11 月）	英伟达	AMD	谷歌（Google）TPU	其他加速器	来源
PyTorch（训练 + eager 模式）	🟩 主干内置 CUDA	🟨 主干内置 ROCm	🟦 通过 TorchTPU（PyTorch/XLA 已弃用）	🟨 主干内置 Intel XPU	S587,S595

框架 / 软件库（2026 年 11 月）	英伟达	AMD	谷歌（Google）TPU	其他加速器	来源
JAX	🟩 支持	🟨 AMD 维护的插件	🟩 原生	🟥 Intel 实验性支持	S577
Triton（内核语言）	🟩 CC 8.0+	🟨 ROCm 6.2+	—	🟨 Intel 主干外后端	S578,S597
vLLM（推理服务）	🟩 主干内置	🟨 主干内置 ROCm	🟨 插件	🟨 Gaudi、昇腾、Trainium 插件	S580,S581
SGLang（推理服务）	🟩 B200/GB300	🟨 MI300X–MI355X	🟨 TorchTPU / SGL-JAX	🟨 昇腾、Intel	S582
TensorRT-LLM	🟩 仅限英伟达	🟥 无	🟥 无	🟥 无	S589
ONNX Runtime	🟩 CUDA、TensorRT	🟨 MIGraphX	—	🟨 OpenVINO、高通（Qualcomm）QNN	S585

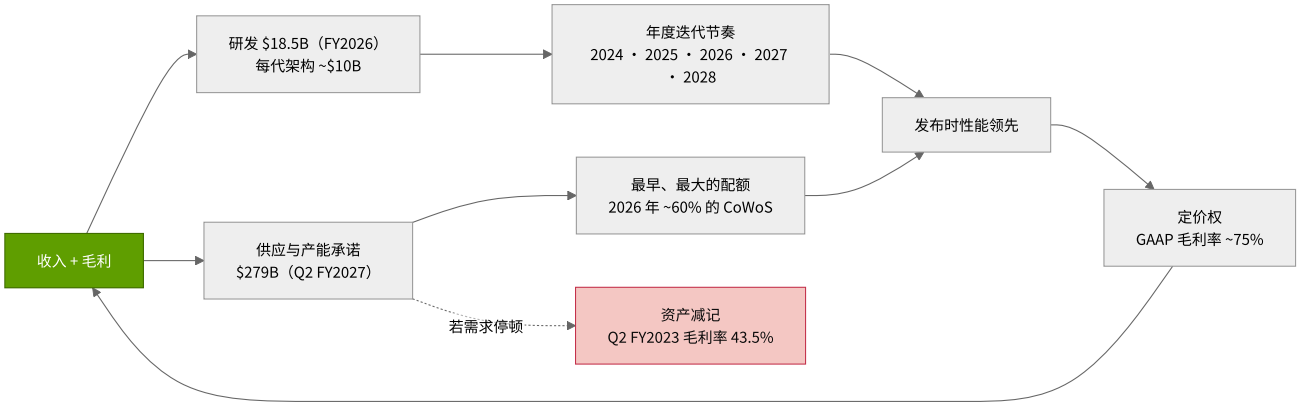
🟩 一等支持 · 🟨 支持，通常由厂商维护或较新 · 🟦 路线不同 · 🟥 无或实验性（本资料库根据所引 README 作出的判断）。

> **注意**
>
> **循环 ① 可能在哪里断裂。** 护城河会上移一层：如果开发者实际接触的框架（PyTorch、vLLM、SGLang、Triton）与硬件无关，切换成本就会缩小到 性能调优——而超大规模云厂商有足够的工程师自己完成这项工作。谷歌与 Meta 于 2026 年 10 月开源了 TorchTPU [S553]；AMD 如今以快速节奏发布 ROCm 版本 [S586]。英伟达自己的开发者数量在 GTC 2025 与 GTC 2026 之间持平于 ~6M [S536,S528]，这是 需要关注的指标。深入阅读：第 09 层 —— CUDA、 第 10 层 —— CUDA-X 软件库以及 CS2 —— CUDA：十五年的赌注。

> **🔧 技术细节：CUDA 锁定效应究竟由什么构成**
>
> “CUDA”是四个层次的简称，它们被侵蚀的速度各不相同：
>
> 1. **编程模型与编译器**（CUDA C++、PTX 虚拟指令集）。PTX 让多年前编写的代码能在新 GPU 上运行，这就是装机量能够复利增长的原因。竞争对手可以模仿该模型（AMD 的 HIP 有意设计得 与 CUDA 相似），因此这一层最容易复制。
> 2. **软件库**——cuBLAS（矩阵运算）、cuDNN（神经网络内核）、NCCL（多 GPU 通信）、TensorRT-LLM（推理）。这些凝聚了多年针对每一代硬件的调优；竞争对手 必须逐个内核地追平。英伟达早在 2022 年就列出了 550 个 SDK 与模型 [S532]。
> 3. **工具**——性能分析器、调试器和容器镜像，让集群从第一天起就能投入使用。
> 4. **习惯**——研究界与开源社区的默认选择。新想法（新的注意力内核、新的 数值格式）往往首先为 CUDA 编写，因为评审者和用户手里有的就是它。
>
> 编译器层面的抽象（PyTorch 编译器、Triton、JAX/XLA）通过为多种后端自动生成内核来攻击第 1–2 层 [S578,S577]；这就是下文将开发者循环评为 “强但受到挑战”的原因。深入阅读见第 09 层。

3. 循环 ② —— 规模与研发飞轮

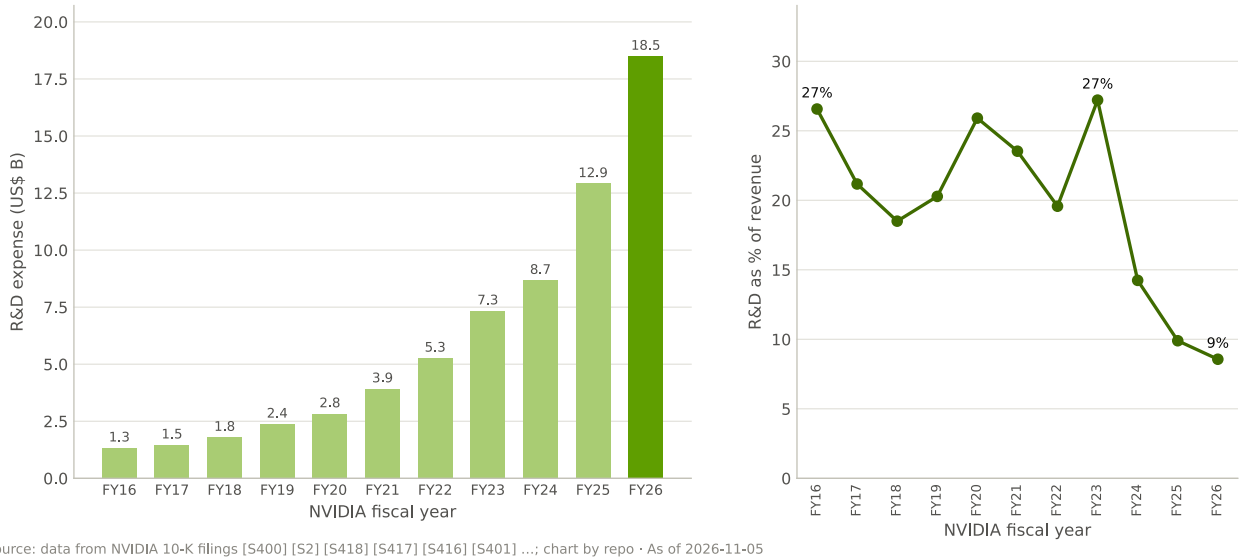
机制。 收入为研发提供资金，并越来越多地用于**预先锁定供应**：提前数年预订晶圆、 HBM、CoWoS 封装与测试产能。这使英伟达能每年批量推出一款新架构，从而在每次发布时 保持性能领先，进而支撑定价与毛利率，再为下一轮提供资金。每转一圈也会抬高对手的门槛—— 对手必须同时追平研发投入与供应预订。



研发：投入更多，强度更低。 英伟达的研发支出从 FY2016 的 $1.33B 增至 FY2026 的 $18.5B（仅最近一年就增长 +43%）[S400,S401]，而占收入的比重从 27% 降至 ~9%—— 典型的经营杠杆。黄仁勋（Jensen Huang）称 Blackwell 的 开发成本约为 ~$10B [S35028]。作为对比，英伟达 2024 自然年 $12.9B 的研发支出已 超过 AMD 和博通（Broadcom），只有英特尔投入更多 [S450,S451,S452]。

R&D spend rose 14× to $18.5B (FY2026) while falling to 9% of revenue

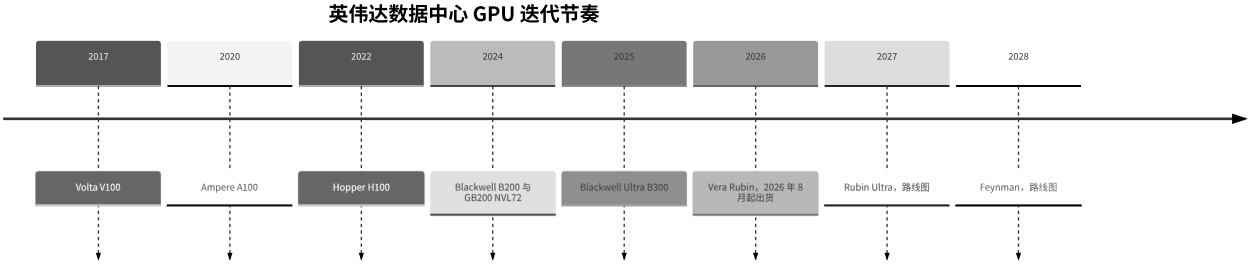
Left: GAAP research and development expense, US$ B per fiscal year. Right: R&D as % of revenue



Source: data from NVIDIA 10-K filings [S400] [S2] [S418] [S417] [S416] [S401] ...; chart by repo · As of 2026-11-05

英伟达研发支出双面板图。左：研发支出从 FY2016 的 $1.33B 增至 FY2026 的 $18.5B，约 14 倍。右：由于收入增长更快，研发强度从占收入的 27% 降至 8.6%。

节奏：从两年一代到一年一代。 在 Blackwell 之前，英伟达大约每两年推出一代数据中心架构；自 2024 年起转为年度节奏，并在周期中段推出“Ultra”升级版：

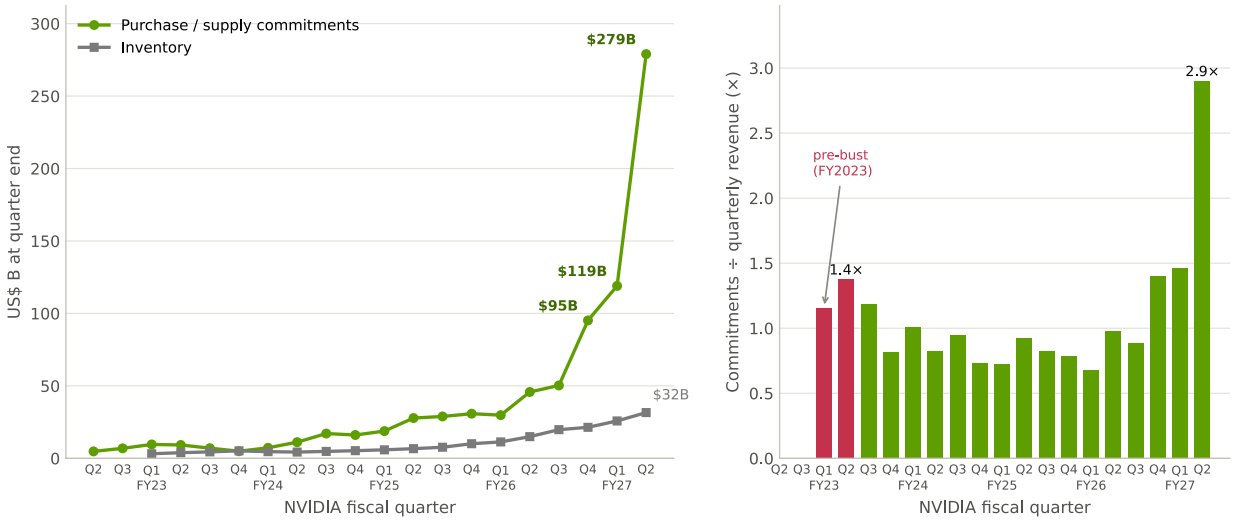


来源：V100 [S126]；A100 [S127]；H100 [S33002]；Blackwell [S396]；Blackwell Ultra 与路线图 [S33020]；Rubin 量产出货 [S500]；Rubin Ultra 与 Feynman [S502]。🟢 2026 年及以前均已确认；🟢 Rubin Ultra 与 Feynman 已发布，但 🟡 有报道称 Kyber 机架推迟至 2028 年 [S507]（英伟达表示其路线图未变 [S508]），另有报道称 Rubin Ultra 将采用双裸片设计 [S509]。

供应预先承诺：最不显眼、却最有力的杠杆。 英伟达的 采购义务——对晶圆、内存、封装与产能的有约束力 订单——从 Q2 FY2022 的 $4.79B [S420] 增至 FY2026 年末的 $95.2B [S401]、Q1 FY2027 的 $119B [S404]，以及 Q2 FY2027 的 **$279B**，主要用于当前及未来架构所需的内存与制造产能 [S407]。10-K 中的 $95.2B 与 10-Q 中的供应与产能承诺 是不同的科目，因此长期序列仅供参考；口径一致的跃升是单季从 $119B → $279B [S90092]。

Supply commitments hit $279B: 2.9× quarterly revenue vs ~1.4× before the 2022 bust

Left: purchase/supply commitments vs inventory, US$ B at quarter end. Right: commitments ÷ that quarter's revenue



Definition widened from Q3 FY2026

Source: data from NVIDIA 10-Q/10-K [S420] [S421] [S432] [S433] [S434] [S435] …; chart by repo · As of 2026-11-05

双面板图。左：英伟达采购义务从 Q2FY22 的 $4.8B 增至 Q2FY27 的 $279B，同期库存达 $31.6B。右：在 FY2023 库存减记之前，承诺额约为季度收入的 1.4 倍，如今为 2.9 倍，主要是用于 Rubin 的内存与产能。

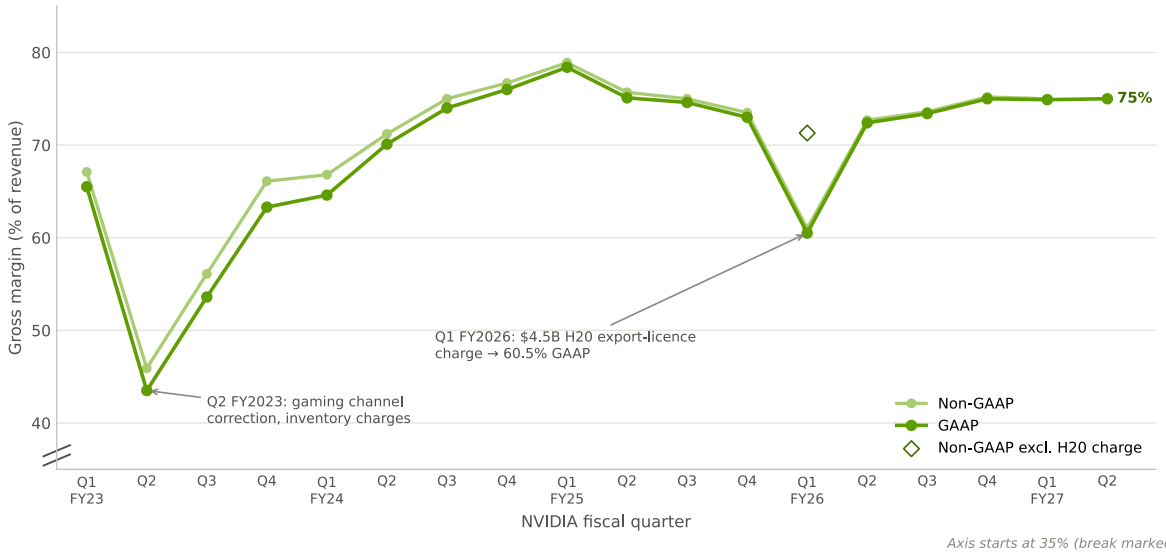
提示

算例 —— 作为护城河的承诺。 $279B 的承诺 [S407] 约为台积电 2026 年全部资本开支预算 $52–56B 的 **5×** [S35029]，媒体估计英伟达拿下了 台积电 2026 年 CoWoS 配额的 ~60%（~595K 片晶圆，博通约 ~150K，AMD 约 ~105K）（🟡）[S379]。这些承诺跨越多年且包含内存，因此这一比较关乎规模，而非 同口径对比。关键在于机制：在供应受限的市场中，**谁为稀缺投入品预先付款，谁就决定了谁能出货**。一个设计有竞争力、却没有 HBM 或 CoWoS 配额的对手，当年什么也卖不出去。参见 P5 —— 芯片经济学入门 与第 03 层。

定价权是该循环的产出。 毛利率从 FY2016 的 56.1% 升至 FY2025 的 75.0% [S400,S416]，在 Blackwell 爬坡期间维持在 ~73–78%，Q2 FY2027 约为 ~75% [S405]。分析师估计 B200 的制造成本约 ~$6,400，而售价为 $30–40K [S35020,S35026]。

Gross margin climbed from 43.5% to ~75%, broken only by the H20 write-down

GAAP and non-GAAP gross margin, % of revenue, Q1 FY23–Q2 FY27; from Q1 FY2027 non-GAAP includes stock-based comp



Axis starts at 35% (break marked)

Source: data from NVIDIA 8-K releases [S432] [S433] [S434] [S435] [S418] [S436] …; chart by repo · As of 2026-11-05

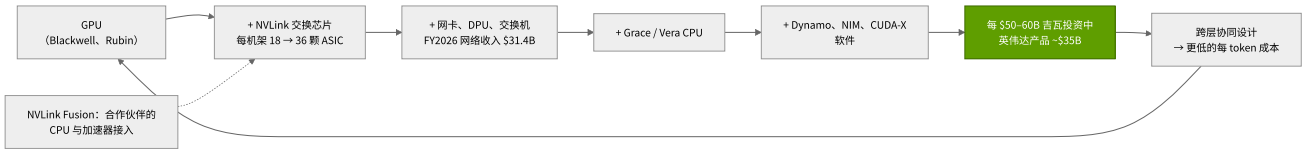
英伟达季度毛利率折线图：GAAP 毛利率在 Q2FY23 触底于 43.5%（游戏库存费用），在 Hopper 爬坡期间升至 75% 以上，Q1 FY2026 因 $4.5B 的 H20 出口管制费用降至 60.5%（剔除该项的非 GAAP 毛利率为 71.3%），Q2FY27 约为 75%。

注意

循环 ② 可能在哪里断裂。 把对手挡在门外的承诺，同样也把英伟达锁在门内。2022 年需求 停顿时，英伟达为库存以及超出需求的采购义务计提了费用 （仅 Q3 FY2023 就约 ~$348M）[S421]，毛利率跌至 43.5% [S433]；Q1 FY2026 的 $4.5B H20 费用 表明，出口政策也会触发同样的机制 [S444]。如今的承诺约为 Q2 FY2023 未履行承诺 $9.2B 的 ~30× [S420,S407]。其他断裂点：某一代产品延期（有报道称的 Kyber 推迟 [S507]、Rubin 下调的 HBM4 带宽规格 [S103,S104]），或对手追平迭代节奏——AMD 已承诺 Instinct 系列采用 年度节奏（2026 年 MI400、2027 年 MI500）[S545]。深入阅读：第 02 层、 17 —— 路线图。

4. 循环 ③ —— 全栈与系统飞轮

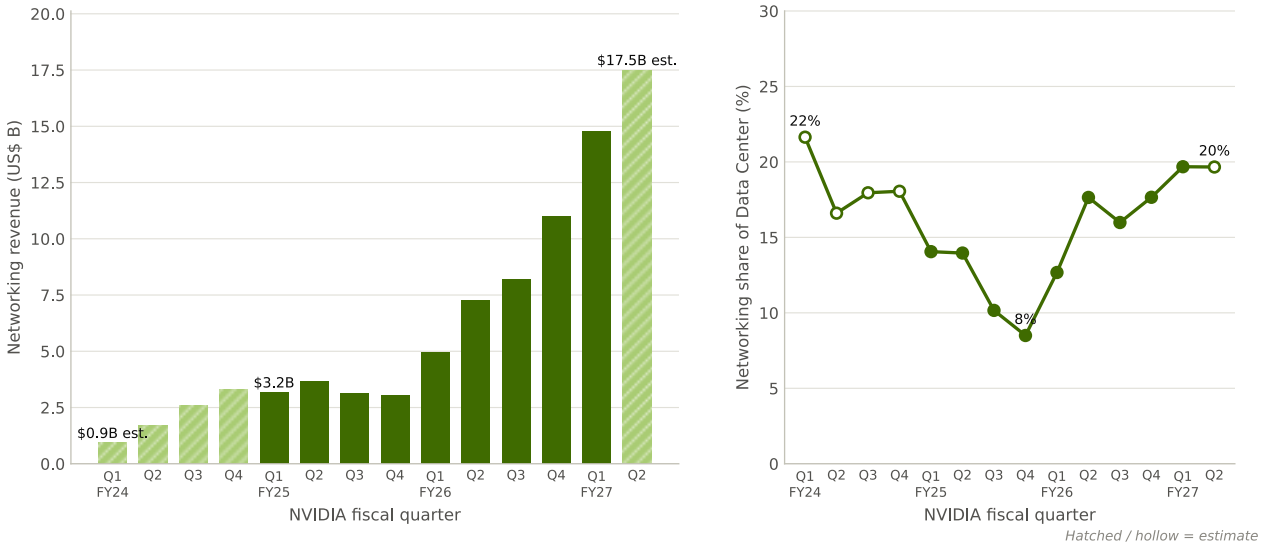
机制。 销售整个机架——GPU、CPU、NVLink 交换芯片、网卡、DPU、参考 设计与软件——提高了英伟达在每一美元客户支出中的钱包份额。 掌控每一层也让英伟达能够进行跨层优化（GPU 中的新数值格式、能完成 全规约（all-reduce）运算的交换机、了解网络拓扑的推理服务运行时），从而 使系统每美元的速度高于由各家最佳部件拼凑而成的组合，进而带动下一个机架的销售。



最好的单一衡量指标是网络。网络收入从 FY2024 的 $8.6B 增至 FY2026 的 $31.4B [S416,S402]， 仅 Q1 FY2027 一个季度就达 $14.8B（同比 +199%）[S409]；Q2 FY2027 又环比增长 18%， 其中 Spectrum-X 以太网收入同比增长 2.6× [S408]。这项业务主要来自 2019 年宣布的 $6.9B Mellanox 收购 [S464]（见 CS1）。

NVIDIA networking revenue rose 5.5× in two years to ~$17.5B a quarter (~20% of DC)

Left: Data Center networking revenue, US$ B per quarter. Right: networking as % of Data Center revenue



Source: data from NVIDIA CFO commentary, 10-Q, calls [S436] [S422] [S440] [S437] [S423] [S441] ...; chart by repo · As of 2026-11-05

双面板图。左：英伟达季度网络收入从 Q1FY24 的 $0.9B（估计）增至 Q2FY27 的约 $17.5B，为 Q1FY25 的 5.5 倍。右：网络业务占数据中心收入的比例在 Blackwell 算力产品爬坡期间降至 8%，随后随 NVLink、Spectrum-X 与 InfiniBand 放量升至约 20%。

提示

算例 —— 一吉瓦中的钱包份额。 英伟达 CEO 估计一座 1 GW AI 工厂的成本 约为 ~$50–60B，其中英伟达产品约 ~$35B [S398]：**占总额的 58–70%**，而分析师估计仅 GPU 就占机架物料成本的 ~51–65% [S332]。摩根士丹利的拆解显示了机架物料成本为何从 GB300 NVL72（~$4.0M）到 Vera Rubin NVL72（~$7.8M）几乎翻倍：内存含量 大幅增加，NVLink 交换 ASIC 从 18 颗翻倍至 36 颗，而 ODM 的毛利率从 2.7% 降至 1.9% [S332]。价值归于芯片供应商——英伟达和内存厂商——而非 组装厂。一年的网络收入（$31.4B）约为 Mellanox 收购价的 ~4.5×。

英伟达如今正把循环 ③ 延伸到并非自己制造的芯片上。**NVLink Fusion** 允许合作伙伴的 CPU 与加速器接入 NVLink 域；首批合作伙伴包括提供定制 CPU 的高通与 富士通，以及联发科、美满电子（Marvell）、世芯（Alchip）和 Astera Labs [S517,S131]，AWS 也表示 Trainium4 将集成 NVLink Fusion [S518,S519]。Groq 授权交易（§5）增加了一款推理芯片， 英伟达如今将其作为 Vera Rubin 平台的一部分销售 [S307,S506]。

注意

循环 ③ 可能在哪里断裂。 最大的买家正在围绕自研芯片构建自己的机架：谷歌 TPU 8t/8i [S550]、AWS Trainium3 UltraServer [S556]、微软（Microsoft）Maia 200 [S558] 以及 Meta 的 MTIA 路线图 [S561]。开放互连旨在将英伟达的互连技术商品化：UALink 1.0 与 2.0 [S573,S574]、支持纵向扩展（scale-up）的超以太网（Ultra Ethernet）1.1 [S575] 以及 OCP ESUN 纵向扩展规范 [S576]。而且最大的 AI 实验室如今都采用双供应商：OpenAI 同时采用博通（10 GW）[S174] 和 AMD（最多 6 GW）[S546]；Anthropic 可使用多达 1M 颗谷歌 TPU [S547]。深入阅读：第 05 层、 第 06 层、 第 08 层、 15 —— 竞争格局。

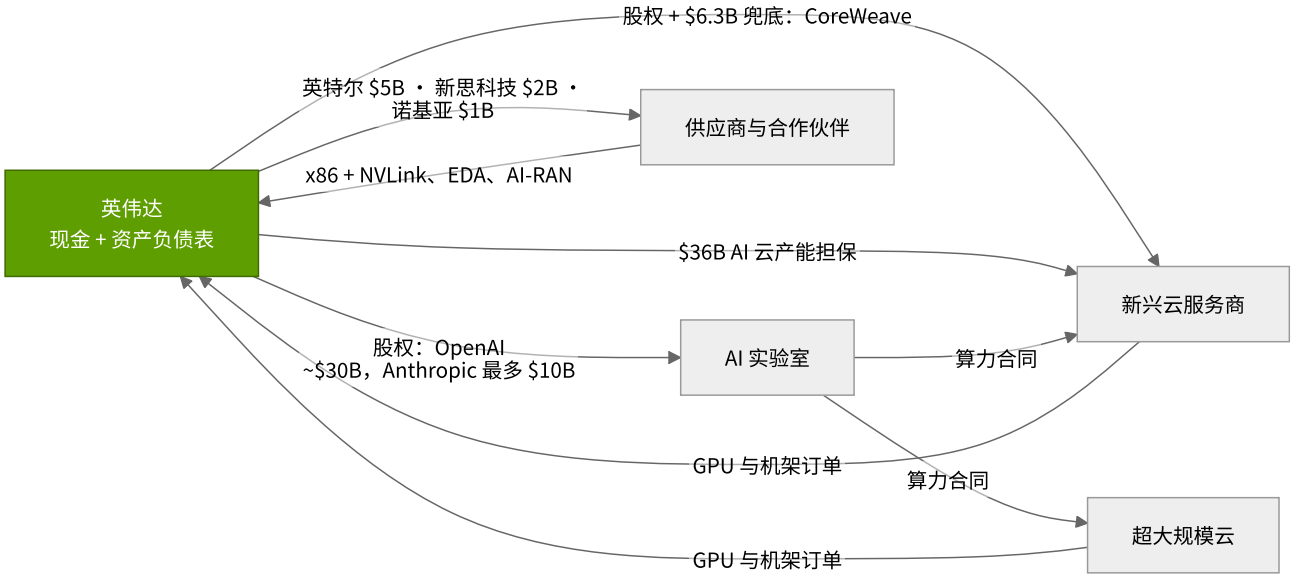
🔧 **技术细节：跨层协同设计的三个例子**

- **数值格式 × 张量核心 × 软件。** NVFP4 以 4 位存储数值，每 16 个值的块配一个 FP8 缩放因子，另加一个张量级缩放因子 [S32017]；GPU 的张量核心、TensorRT-LLM 内核与量化方案是一起设计的，因此客户无需自建工具链就能获得 4 位带来的加速（这对每 FLOP 成本的影响见 P5 §8）。
- **交换机 × 集合通信库。** NVLink 5 为每颗 Blackwell GPU 提供 1.8 TB/s、为一个 NVL72 机架提供 130 TB/s 的纵向扩展带宽 [S34014]；英伟达的 SHARP 网内规约让交换机完成 全规约的运算，使穿越网络的数据量大约减半 [S34024]。买家若将第三方交换机与英伟达 GPU 混用，就会失去这一优势。
- **机架 × 推理服务运行时。** Dynamo 把推理拆分为在不同 GPU 上运行的预填充（prefill）与解码（decode），并按 KV 缓存位置路由请求；英伟达宣称在 GB200 NVL72 上 DeepSeek-R1 可处理的请求最多增加 30×（厂商说法）[S32015]，该软件于 2026 年 3 月发布 1.0 版 [S520]。Groq 3 LPX 机架作为专用解码引擎接入同一平台 [S308]。

每个例子单独来看都只是一点小优势；合在一起，就是英伟达宣称其系统即使在 ~75% 毛利率下仍具有最低每 token 成本的原因（检验见 14 —— 训练与推理经济学）。

5. 循环 ④ —— 资本与生态飞轮，以及“循环融资”批评

机制。 英伟达用现金入股、为其提供资产负债表支持或为其担保产能的对象，是购买并部署其 GPU 的公司——AI 实验室、新兴云服务商（neocloud）（CoreWeave、Lambda、Nebius 等专营 GPU 的云厂商）——以及它所依赖的供应商与平台合作伙伴。这些公司利用这笔资金或由此获得的信誉募集更多资本、订购更多英伟达系统；英伟达的收入及其持股价值随之上升；循环往复。

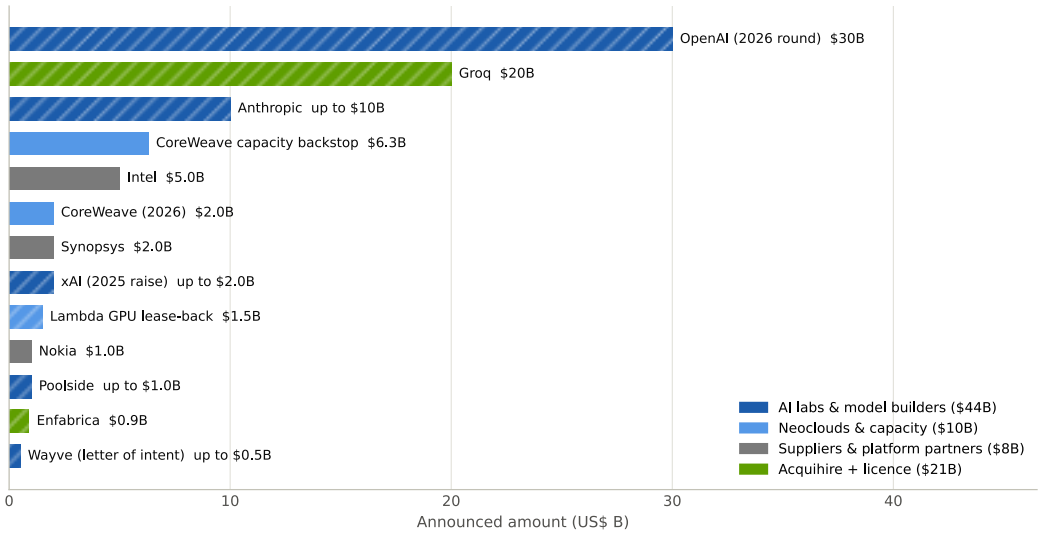


节奏在 2025 年底发生了变化。在大约六个月内，英伟达宣布了：

- **AI 实验室：** 一份意向书，计划随着 10 GW 英伟达系统的部署向 OpenAI 投资最多 $100B [S467]，据报道后被对 OpenAI 2026 年融资轮约 ~$30B 的投资取代（🟡）[S480]；与微软最多 $5B 的投资一起，向 Anthropic 投资最多 $10B，Anthropic 则承诺采购最多 1 GW 的英伟达系统 [S469]；向 xAI 投资最多 $2B，向 Poolside 投资最多 $1B（🟡）[S483]。
- **新兴云服务商与产能：** 一份 $6.3B 的协议，使英伟达有义务在 2032 年 4 月前购买 CoreWeave 未售出的产能 [S473]，以及对 CoreWeave 追加 $2B 的投资 [S472]；与 Lambda 约 ~$1.5B 的 GPU 售后回租（🟡）[S483]；以及截至 Q2 FY2027，**$36B 的 AI 云协议**——据此英伟达购买合作伙伴无法转售的产能——外加 $29B 的多年期云服务承诺 [S407]。
- **供应商、合作伙伴与技术：** 向英特尔投资 $5B [S468]、诺基亚 $1B [S470]、新思科技（Synopsys）$2B [S471]，与 Groq 约 ~$20B 的授权加团队交易（据报道）[S474]，以及以超过 $900M 获得 Enfabrica 的团队与技术 [S475]——这些是为规避并购审查而设计的收购式招聘（acquihire）。

~$82B pledged to labs, neoclouds and partners in six months: ~68% of FY2026 net income

Announced equity stakes, licences and capacity backstops ≥ $0.4B, Sep 2025–Feb 2026, US$ B (hatched = 'up to' or press-reported)



Source: data from NVIDIA, partner releases and filings; press reports [S483] [S475] [S470] [S477] [S471] [S472] …; chart by repo · As of 2026-11-05

横向柱状图：2025 年 9 月至 2026 年 2 月英伟达最大的几笔承诺，合计约 $82B：OpenAI 约 $30B、Groq 授权约 $20B、Anthropic 最多 $10B、CoreWeave 兜底 $6.3B、英特尔 $5B 及其他；AI 实验室约占 $44B。总额约相当于 FY2026 净利润 $120B 的 68%。

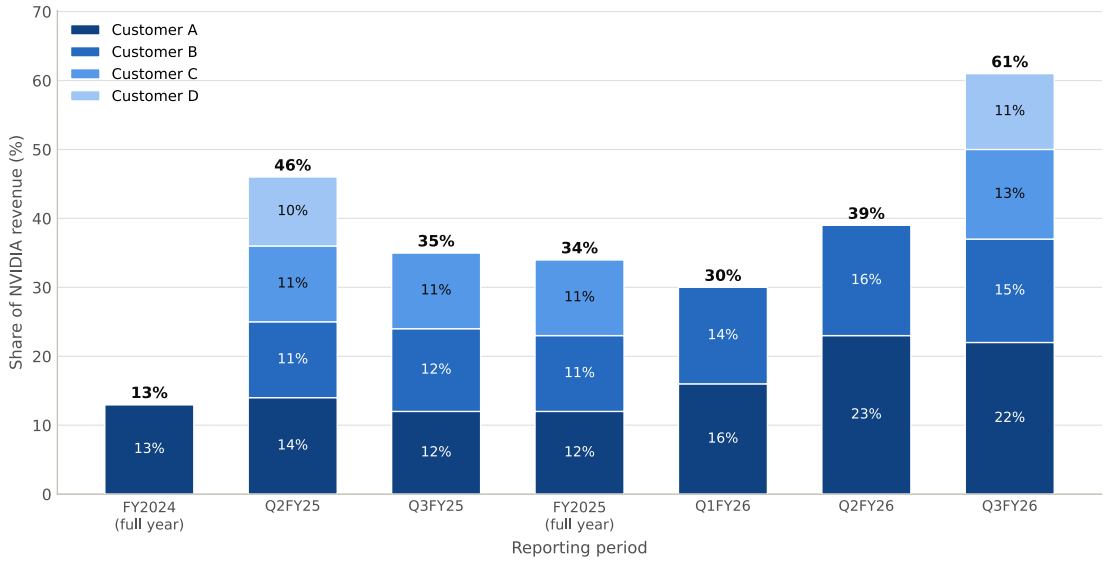
提示

算例 —— 英伟达的一美元股权能走多远？ 以 Anthropic 为例：英伟达 承诺投资最多 $10B [S469]；Anthropic 承诺采购最多 1 GW 的英伟达系统 [S469]；按英伟达 自己估算的每吉瓦 ~$35B 产品价值 [S398]，这意味着**以 $10B 股权换来最多 ~$35B 的潜在英伟达 收入——约 ~3.5×**（🔴 本资料库测算；1 GW 是上限，且 Anthropic 也向 谷歌和 AWS 采购 [S547]）。最初的 OpenAI 意向书结构相同，规模是其 10×：随着 10 GW 中每 1 GW 的部署 逐步投资最多 $100B [S467]，对应约 ~$350B 的隐含英伟达产品价值 （🔴）。看多者视之为附带股权上行空间的廉价获客；看空者则认为这是 英伟达在为自身相当一部分需求提供融资。

以最强形式陈述“循环融资”批评。 (1) *需求质量：* 部分收入来自其支付能力依赖 英伟达资金或担保的公司，因此报告的增长高估了独立需求。(2) *隐性杠杆：* 兜底与产能担保 （CoreWeave $6.3B；$36B AI 云协议）属于或有负债，恰恰会在需求走弱时兑现 [S473,S407]； 在 10-Q 中范围更广的承诺科目达到 $279B（另一个科目 [S90092]）之前，迈克尔·伯里（Michael Burry）就称 $95B 的采购义务“令人不安” [S431]， 而对 Q2 FY2027 10-Q 的二手统计显示，未来承诺总额达 $366B [S430,S449]。 (3) *盈利质量：* Q1 FY2027 净利润中包含约 ~$15.9B 的其他收益，主要是对英特尔等公司持股的 未实现收益 [S403]——英伟达生态消息向好时这些持股升值， 这会在繁荣期美化盈利，在萧条期则会反转。(4) *集中度：* 四家直接客户—— 主要是为超大规模云厂商代工的 OEM 和 ODM——占 Q3 FY2026 收入的 61% [S412]。

Customers at ≥10% of revenue rose from 1 (13%) in FY2024 to 4 (61%) in Q3FY26

Share of revenue per disclosed direct customer, %; letters are not the same company across periods; mostly OEMs/ODMs



Source: data from NVIDIA 10-K/10-Q [S417] [S416] [S426] [S427] [S414] [S413] …; chart by repo · As of 2026-11-05

堆叠柱状图：英伟达披露的占收入 10% 以上的直接客户：FY2024 为 1 家，占 13%；FY2025 为 3 家，占 34%；Q3FY26 为 4 家，合计 61%；大多为替超大规模云厂商生产的 OEM/ODM。

注

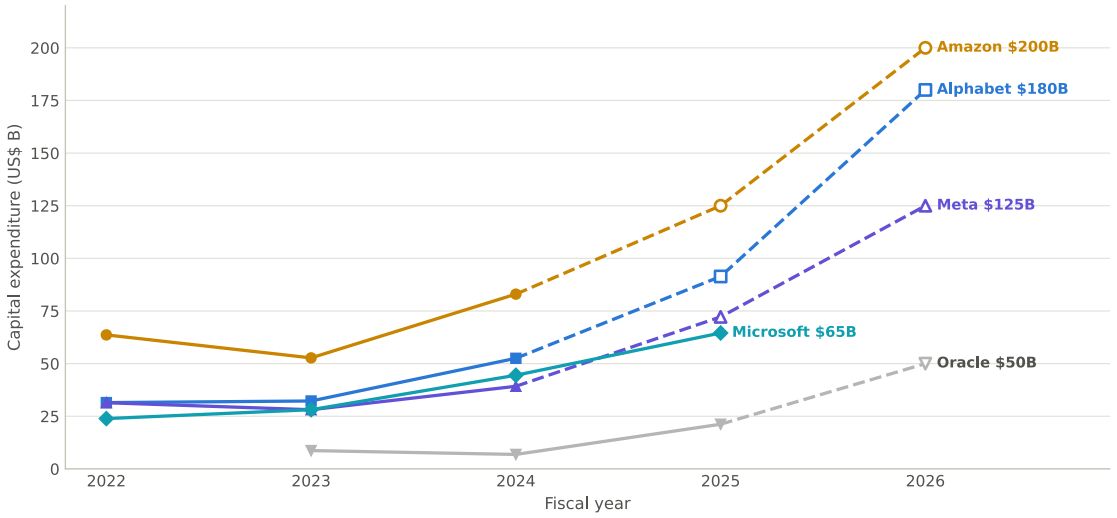
🐂 **看多观点。** 各项承诺合计约 ~$82B，而 FY2026 净利润为 $120B [S1]，且分散 在整个生态中；大部分是对高速增长公司的股权投资，而非贷款。英伟达正在 培育客户、新兴云服务商与合作伙伴，使其*摆脱*对四家超大规模云厂商的依赖——而 与此同时，这些超大规模云厂商自身计划在 2026 年投入约 ~$558B 资本开支（高于其最初指引的 ~$505B）[S12518,S12519,S460,S461,S462]。一家 毛利率 ~75% 的供应商，完全负担得起像平台型公司历来所做的那样去补贴用户采用。

注意

🐻 **看空观点。** 循环 ④ 是唯一一个把英伟达的*周期性*风险转化为*资产负债表* 风险的循环。在下行周期中，被投资的实验室和新兴云服务商会削减订单，产能担保会被触发， 股权投资会被减记，$279B 的供应承诺也会到期——一切同时发生。 2022 年的下行周期，风险敞口只有今天的一小部分，却让毛利率在一个季度内下降约 ~22 个百分点，从 65.5% 降至 43.5% [S432,S433]。参见 18 —— 弱点与看空情景 与第 13 层 —— 生态、市场进入与资本。

Alphabet, Amazon and Meta first guided ~$505B of 2026 capex, 4.0× their $127B in 2022; guides have since risen to ~$558B

Capex, US$ B per fiscal year; 2026 = first guidance (Jan–Feb 2026); dashed/hollow = outlook or unverified; MSFT FY ends Jun (ex-leases), Oracle May



Latest 2026 guide midpoints (Jul–Oct 2026): Big 3 ~$558B

Source: data from company 10-Ks and outlooks [S455] [S460] [S456] [S461] [S457] [S462] ...; chart by repo · As of 2026-11-05

折线图：2022–2026 年超大规模云厂商资本开支：Alphabet、亚马逊和 Meta 合计从 2022 年的 $127B 增至其 2026 年最初指引的约 $505B（亚马逊约 $200B、Alphabet 中值约 $180B、Meta 中值约 $125B），到 2026 年 10 月已上调至约 $558B；微软 FY2025 达 $65B，甲骨文（Oracle）FY2026 指引约 $50B。

🔧 **技术细节：股权投资与兜底如何体现在英伟达的财务报表中**

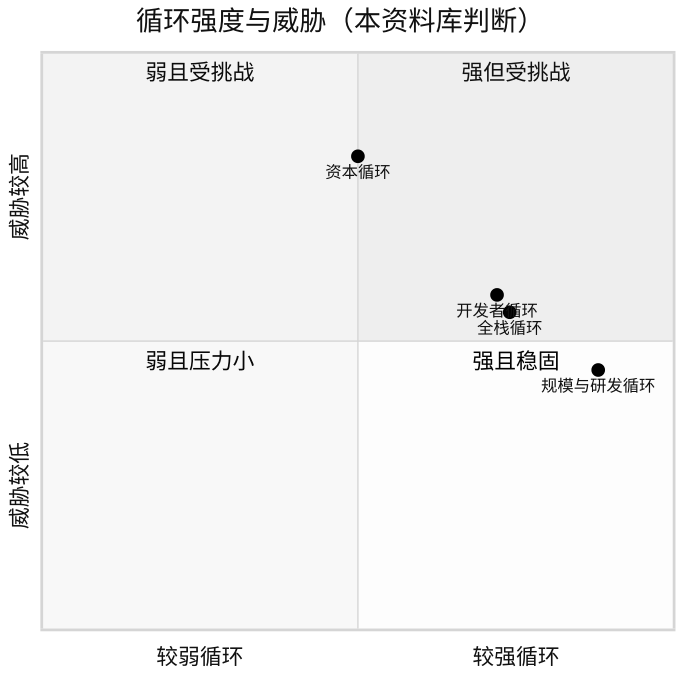
- **对上市公司的股权投资**（英特尔、诺基亚、新思科技、CoreWeave 等出现在 英伟达的 13F 文件中 [S477]）通过“其他收益”按市值计价，不计入毛利率 与营业利润。这就是 Q1 FY2027 净利润（$58.3B）高于营业利润 （$53.5B）的原因 [S403]。
- **产能兜底**属于或有采购承诺：根据 CoreWeave 协议，英伟达 必须在 2032 年 4 月前购买剩余未售出的产能 [S473]；根据 Q2 FY2027 披露的 AI 云协议， 英伟达购买合作伙伴无法转售的承诺产能 [S407]。只有在需求不足时它们才会 成为费用——而这恰恰是它们伤害最大的情景。
- **多年期云服务协议**（Q2 FY2027 为 $29B [S407]）是英伟达回租产能， 部分用于自身研究和 DGX Cloud——对云厂商是收入，对英伟达是成本。
- **意向书不是合同。** 英伟达的 10-Q 警示，无法保证 OpenAI 意向书会形成最终条款 [S412]；据报道，它已被一笔规模较小的股权 投资取代 [S480]。

6. 各循环如何相互咬合——以及各自可能在哪里断裂

各循环并非相互独立。循环 ②（迭代节奏）不断强化留在循环 ① 中的理由（新 功能率先落地 CUDA）；循环 ③（系统）放大了循环 ① 中每位客户的支出； 循环 ④（资本）为循环 ① 招募新客户，并预售循环 ② 中预订的供应。这种 耦合既是护城河——对手必须复制四个循环，而不是一个——也是风险所在。

循环	当前强度	主要威胁	威胁程度	需关注的领先指标
① 开发者 / 软件	🟩 ~6M 开发者、1B+ 颗 GPU、研究以 CUDA 为先 S528,S529	框架抽象（PyTorch、Triton、vLLM、TorchTPU） S580,S553	🟨 上升	开发者数量；vLLM/SGLang 流量中运行在非英伟达硬件上的比例
② 规模 / 研发	🟩 $18.5B 研发、$279B 承诺、年度迭代节奏 S401,S407	需求停顿 → 资产减记；迭代延期；AMD 追平节奏 S421,S507,S545	🟨 中等，影响大	采购义务 ÷ 收入；库存；毛利率
③ 全栈 / 系统	🟩 网络收入 $31.4B；每 GW ~$35B S402,S398	定制 ASIC 机架；UALink、UEC、ESUN S550,S556,S573,S576	🟨 上升	网络占数据中心收入的比重；NVLink Fusion 采用者
④ 资本 / 生态	🟨 已承诺约 ~$82B；$36B 产能担保 S407	循环融资退潮；客户集中度 61% S412,S431	🟥 高	兜底被触发；股权估值变动；被投公司的订单增长

🟩 强 · 🟨 中等 · 🟥 弱或威胁高（本资料库判断，按定义属 🔴 推测）。



重要

最需要记住的一点。 英伟达的优势不在于任何单一循环——每个循环都可能遭到攻击—— 而在于四个循环都流经同一个收入与 ~75% 毛利率的枢纽。这使 系统在繁荣期能够自我供血，而在萧条期则**高度相关**：看起来最新的循环（资本） 和看起来最强的循环（规模，借助 $279B 的承诺），恰恰是会放大 下行的两个。

🔧 技术细节：每个循环陷入停滞需要满足哪些条件

- **循环 ① 停滞的条件**：某种新的模型架构或训练方法率先出现在非 CUDA 硬件上并赢得份额（例如，领先的开放权重模型在 TPU 或 Trainium 上开发和调优），或者推理转向内核调优已自动化的、经过编译且与硬件无关的 计算图。指标：框架发布说明将非英伟达目标列为一级支持。
- **循环 ② 停滞的条件**：超大规模云厂商的资本开支趋平（三家公司对 2026 年的指引约为 ~$505B [S460,S461,S462]，此后上调至 ~$558B [S12518]），而承诺是固定的；或者某一代产品延期一年—— 客户会因此选择等待，而不是购买当前产品。
- **循环 ③ 停滞的条件**：基于以太网的纵向扩展（UEC 1.1、ESUN）以更低成本 达到 NVLink 级别的延迟，使买家能在同一网络中混用 GPU 与 ASIC；英伟达的反制是开放 NVLink 本身（NVLink Fusion）。
- **循环 ④ 停滞的条件**：被投公司无法完成后续融资；若英伟达 必须在租赁价格下跌的市场中履行产能担保，该循环就会反转——2023 年至 2024 年底，H100 的租赁价格已从 每 GPU 小时 ~$8 降至 ~$2 以下 [S393]。

7. 复制这个飞轮需要什么

对手不必在每个方面都击败英伟达；它只需要在每个循环上做到足够好，让自己的飞轮 转起来。下表以英伟达的数字为基准，列出每个循环的入场门槛。

循环	对手必须建立什么	英伟达的基准	复制所需的估计时间 / 成本（🔴 本资料库判断）	当前最接近的挑战者
① 开发者	编译器、调优过的软件库、工具，以及成为研究界的默认选择	~19 年的 CUDA 积累（2007 年 6 月至今）与 ~6M 开发者 [S525,S528]	5–10 年，除非框架将其抽象掉；每年数十亿美元的软件工程投入	谷歌（TPU 原生支持 JAX/XLA） [S577]；AMD ROCm [S586]
② 规模 / 研发	年度架构迭代节奏加多年期供应预订	研发每年 $18.5B；每代架构 ~$10B；$279B 承诺 [S401,S35028,S407]	只有每年 $20B+ 的 AI 收入才能支撑	AMD（年度节奏，2026 年 MI400、2027 年 MI500） [S545]；谷歌 TPU 8 [S550]
③ 全栈	纵向扩展网络、网卡与交换机、机架设计、推理服务软件	FY2026 网络收入 $31.4B；以 $6.9B 收购 Mellanox [S402,S464]	3–5 年；网络能力需通过收购或合作获得	搭配 Pensando 的 AMD Helios [S538]；博通 Tomahawk 6 加定制 XPU [S570,S174]
④ 资本	能够培育客户并担保产能的资产负债表	六个月内承诺约 ~$82B（§5）	只有超大规模云厂商级别的资产负债表才能做到	微软与亚马逊（持股 Anthropic 和 OpenAI） [S469,S480]；谷歌（为 Anthropic 提供 TPU） [S547]

提示

算例 —— 用 AMD 的尺度衡量研发差距。 AMD 2024 年的研发支出约 ~$6.5B，涵盖 CPU、GPU 及其他所有业务 [S450]；英伟达 FY2026 的研发支出为 $18.5B [S401]，约为其 ~2.8×。AMD 2026 年 Q3 的总 收入为 $13.4B [S542]，因此英伟达的年度研发预算约相当于 AMD 1.4 个季度的 全部销售额。AMD 仍然可以竞争——它追平了年度节奏 [S545]，并赢得了 OpenAI 最多 6 GW 的承诺 [S546]——但它的做法是把投入集中在更少的层级上，而这 正是任何挑战者（包括高通）都会面临的取舍。

各循环与技术栈的对应关系

循环	所在层级	案例研究
① 开发者 / 软件	09 CUDA · 10 CUDA-X · 11 推理软件	CS2 CUDA · CS5 DeepSeek
② 规模 / 研发	02 GPU 芯片 · 03 内存、封装与供应链 · 04 CPU	CS6 中国出口管制
③ 全栈 / 系统	05 纵向扩展 · 06 网络 · 07 DPU · 08 系统 · 12 云服务	CS1 Mellanox · CS7 吉瓦级工厂
④ 资本 / 生态	13 生态、市场进入与资本	CS4 AMD–OpenAI · CS3 谷歌 TPU
全部四个（看空情景）	18 弱点与看空情景 · 16 英伟达如何建成今日格局 · 17 路线图	—

🎯 企业发展视角

1. **挑战者能进入哪个循环，而不必同时与四个循环作战？** 在框架已支持多厂商的地方， 开发者循环最弱（vLLM、SGLang、ONNX Runtime、llama.cpp 都列出了高通 或其他非英伟达后端 [S585,S579,S596]）。推理服务是否正是软件 锁定最低、能效最重要的领域?
2. **在循环 ③ 内部合作，还是与之竞争？** NVLink Fusion 将高通列为其定制 CPU 合作伙伴之一 [S517,S131]，而高通的 AI200/AI250 机架则在推理领域与之竞争 [S569,S173]。每条 路径各自要放弃什么——哪些与英伟达相关的标准（NVLink Fusion vs UALink/ESUN）能保留 选择余地?
3. **循环 ④ 已使英伟达成为数据中心新进入者可能争取的大多数买家的战略投资者**（OpenAI、Anthropic、xAI、CoreWeave、Lambda、Nebius）[S480,S469,S483,S473]。哪些 大型 AI 买家*没有*与英伟达存在资金关联？与它们建立可信的第二供应商 关系会是什么样子（参照 AMD–OpenAI，最多 6 GW [S546]）？
4. **供应是一种竞争武器。** 据报道 2026 年 ~60% 的 CoWoS 已分配给英伟达 [S379]， 再加上 $279B 的承诺 [S407]，新进入者在 2027–2028 年实际能获得多少内存与封装 产能？供应合作（HBM 厂商、OSAT、晶圆代工厂）是否比设计类 收购更有价值?
5. **关注耦合指标，而不是新闻标题：** 采购义务 ÷ 收入、库存、 被触发的产能担保以及毛利率。一次同时冲击四个循环的下行周期，正是 英伟达的生态合作伙伴——以及相关资产——能以更优条件获得的情景。

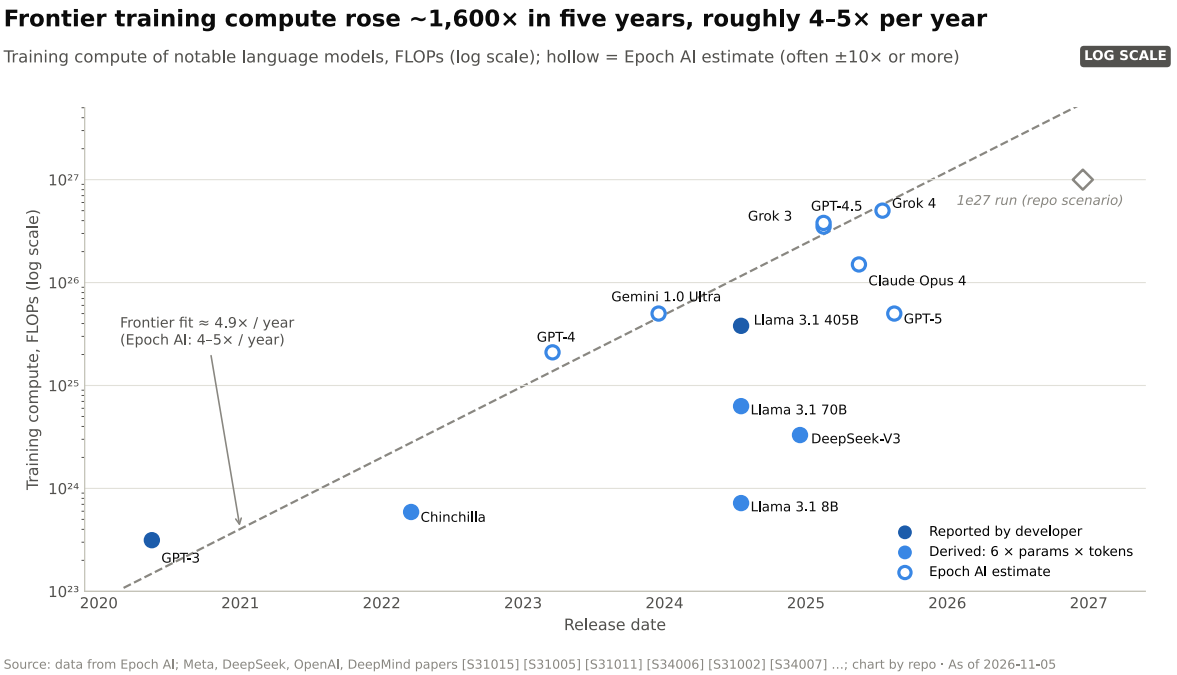
P1 · AI 训练原理

入门篇 P1 · 写给非工程师的基础知识 · 约 22 分钟阅读 · 最近核实：2026-11-05

> **注**
>
> **如果你熟悉电子表格和财务、但不熟悉芯片，请从这里开始。** 本篇解释“训练一个模型”在物理上意味着什么、为何它需要数万块 GPU 连续运行数月，以及应当追问哪些数字。推理（使用已训练好的模型）见 P2；工作如何在多块 GPU 之间拆分见 P4。

⚡ 要点速览

- **训练是一项规模巨大、高度重复的计算。** 模型预测下一个 token（词元），衡量误差，再把每一个参数朝“错得少一点”的方向微调——在数万亿个 token 上反复进行。总计算量 ≈ **6 × 参数量 × 训练 token 数**：Meta 的 Llama 3.1 405B（405B 参数、15.6T token）需要 **3.8 × 10^{25} FLOPs** [S34006]。
- **这可以直接换算为 GPU 时数和美元。** Llama 3.1 405B 消耗了 **30.84M H100 GPU 时** [S31002]；按 DeepSeek 在自身成本测算中采用的 ~$2/GPU 时租赁价格 [S34007]，仅最终一次训练的算力成本就达 **~$62M**（估计，本资料库测算）。
- **GPU 在训练中的实际效率远低于峰值。** Meta 在最多 16,384 块 H100 上测得的**模型 FLOPs 利用率（MFU）为 38–43%** [S34006]；用公布的 FLOPs 除以公布的 GPU 时数，隐含的整体利用率 ~35%，因为重启、评估和数据停顿同样会消耗机时。
- **设定下限的不只是算力，还有内存。** 采用 Adam 优化器的混合精度训练，在计入激活值之前就需要 **~16 字节/参数** [S34004]，是 BF16 推理的 8 倍：一个 405B 模型的训练状态 ~6.5 TB，超过 81 块 H100 的内存总量。
- **前沿模型的训练算力每年增长 ~4–5×** [S31007]：从 2020 年 GPT-3 的 3.1 × 10^{23} FLOPs [S31015]，到 2025 年 Grok 4 的 ~5 × 10^{26}（估计，Epoch AI）[S31008]，五年间增长约 1,600×。
- **训练“配方”已两度改变。** Chinchilla（2022）表明当时的模型训练不足（~20 token/参数为算力最优）[S31005]；此后各实验室有意对较小模型进行**过度训练**（Llama 3.1 8B 每个参数约对应 ~1,875 个 token）[S31002]，并把投入转向**后训练**和**强化学习**：Epoch AI 估计 GPT-5 的总算力*少于* GPT-4.5 [S31010]。
- **在大规模下，硬件故障是常态。** Llama 3 为期 54 天的预训练快照记录了 **466 次作业中断，其中 419 次为非计划中断**，约每三小时一次，GPU 和 HBM 是首要原因 [S34006,S31003]。可靠性、检查点和快速重启本身就是产品的一部分。
- **为何这对英伟达重要：** 训练是高度同步、通信密集的作业，因此胜出的系统不是最快的芯片，而是最快的*集群*：GPU + NVLink 纵向扩展（scale-up） + InfiniBand/以太网横向扩展（scale-out） + NCCL + 具备容错能力的软件。这一组合是英伟达的护城河，也恰恰是看空情景认为效率提升可能将其商品化的部分。



Source: data from Epoch AI; Meta, DeepSeek, OpenAI, DeepMind papers [S31015] [S31005] [S31011] [S34006] [S31002] [S34007] …; chart by repo · As of 2026-11-05

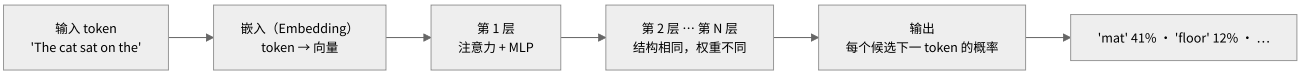
> 对数坐标散点图：主要 AI 模型的训练算力，从 GPT-3（3.1e23 FLOPs，2020 年）到 Grok 4（约 5e26 FLOPs，Epoch AI 估计，2025 年）：五年间增长约 1,600 倍，拟合的前沿趋势约为每年 4.9 倍，与 Epoch AI 每年 4-5 倍的结论一致。Llama 3.1 405B 使用 3.8e25 FLOPs；GPT-5（约 5e25）少于 GPT-4.5（约 3.8e26）。

1. 训练的对象：神经网络、Transformer、token 与参数

类比。 可以把模型想象成一张由数字构成的巨型电子表格。文本从顶部输入，流经数百张做乘法运算的工作表，底部输出每个可能的下一个词的 概率。训练就是不断调整表格中的数字，直到这些概率足够准确。这些数字就是模型的**参数**（也称权重）；除此之外，模型并没有“学到”

任何别的东西。

- 神经网络是由若干层堆叠而成的结构；每一层把输入与一个参数矩阵相乘，再施加一个简单的非线性函数。矩阵乘法正是 GPU 及其张量核心专门为高速执行而设计的那一种运算。
- Transformer 是近年来几乎所有前沿语言模型背后的网络架构。每一层由两部分组成：**注意力（attention）**，即每个 token 回看之前的 token 以获取上下文；以及**前馈模块**（MLP），大部分参数都位于此。Llama 3.1 70B 堆叠了 80 个这样的层 [S32006]。
- **token** 是文本的基本单位：长度为几个字符的词片段。模型读取 token、在 token 上训练，也按 token 计价。



> **提示**
>
> **算例 —— “405B 参数”究竟有多大？** 以 BF16 存储时每个参数占 2 字节，因此仅 Llama 3.1 405B 的权重就有 405B × 2 B = **810 GB**。一块 H100 拥有 80 GB HBM [S33002]，所以仅仅*装下*这个模型就至少需要 11 块 H100，这还没算任何训练状态。即便在 288 GB 的 Blackwell Ultra 或 Rubin GPU 上 [S32004,S33005]，也仍需三块。迫使系统走向多 GPU 的不只是速度，还有模型规模。

> **🔧 技术细节：参数位于何处**
>
> 在稠密 Transformer 中，几乎所有参数都位于每一层的注意力投影矩阵和前馈（MLP）矩阵中；在前沿规模下，嵌入层只占很小一部分。混合专家模型（MoE）用许多“专家”MLP 取代单一 MLP，并把每个 token 路由到其中少数几个，因此总参数量与*激活*参数量不同：DeepSeek-V3 拥有 671B 参数，但每个 token 只激活 37B [S34007]。训练算力随激活参数量扩展，内存则随总参数量扩展。

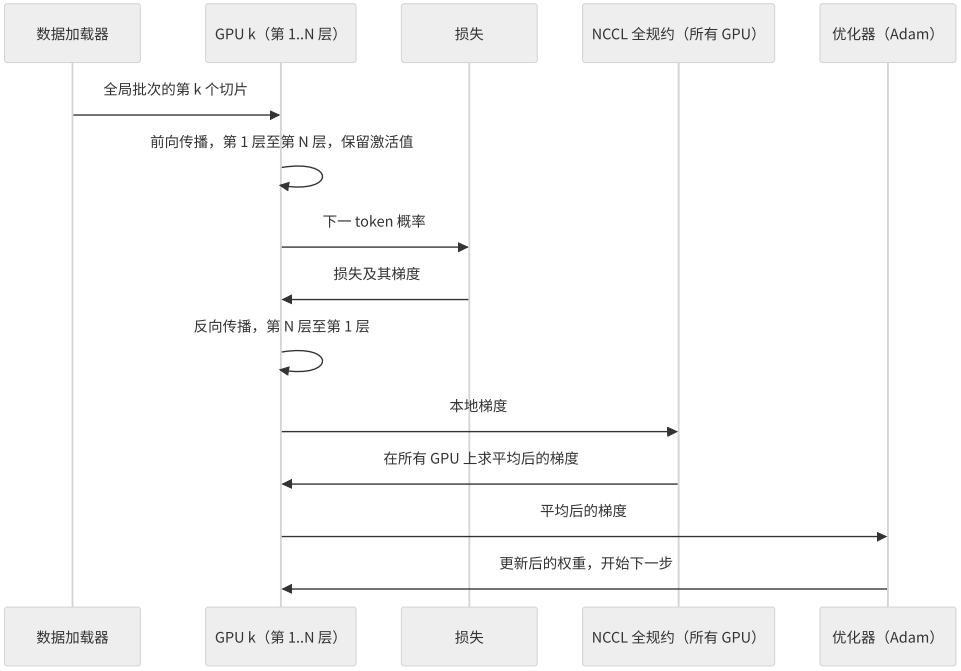
2. 训练循环：前向传播、损失、反向传播、优化器步

训练把同一个循环重复数百万次。每一步处理一个由 token 序列组成的**批次**（前沿模型训练中每批可达数百万个 token）：

1. **前向传播：** 让批次数据流经每一层，预测每个下一 token。
2. **损失：** 将预测与实际的下一 token 比较；损失是衡量“错了多少”的单一数值。
3. **反向传播（backpropagation）：** 逆序遍历各层，为每个参数计算一个梯度：即为降低损失，应朝哪个方向、以多大幅度调整该参数。
4. **同步：** 每块 GPU 处理的是批次中的不同切片，因此需要通过全规约（all-reduce）在 GPU 之间对梯度求平均，通常借助英伟达的 NCCL 库完成 [S34013]。
5. **优化器步：** 优化器（几乎总是 Adam 或其变体）把梯度转换为权重更新。



下面的时序图从数据并行集群中某一块 GPU 的视角展示同一步骤。中间的全规约正是训练成为*网络*问题的原因：在每块 GPU 都贡献完自己的部分之前，任何 GPU 都无法进入下一步。



> 提示
>
> **算例 —— “6 × N × D”从何而来。** 在前向传播中，每个参数对每个 token 执行一次乘法和一次加法： **2 FLOPs**。反向传播要计算两个梯度（分别相对于该层的输入和权重），约 **4 FLOPs**。因此训练成本约为 **每参数每 token ~6 FLOPs** [S31006]。以 Llama 3.1 405B 为例：$6 \times 405 \times 10^{9} \times 15.6 \times 10^{12}$ tokens = $\mathbf{3.79 \times 10^{25}}$ **FLOPs**，与 Meta 公布的 3.8×10^{25} 相符 [S34006]。该规则忽略了随序列长度增长的注意力 计算，因此只是近似值，但它是 Epoch AI 和各实验室通用的标准初步估算方法 [S31011]。

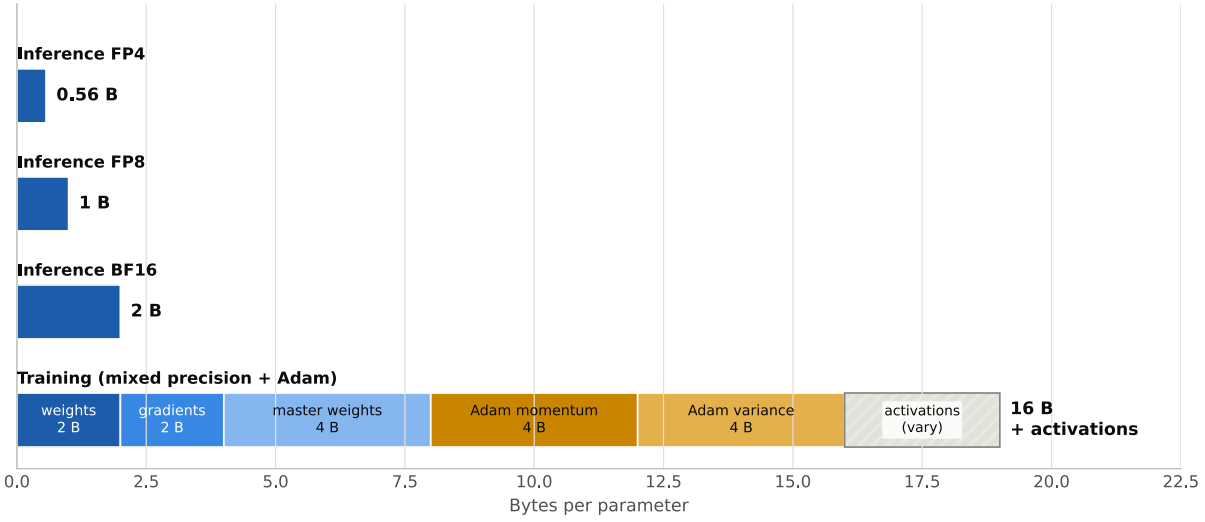
> 🔧 **技术细节：为何反向传播的成本是前向传播的两倍**
>
> 对于计算 $y = W{\cdot}x$ 的一层，反向传播既需要 $\partial \text{loss}/\partial \text{x}$（以继续向更早的层传播），**也**需要 $\partial \text{loss}/\partial \text{W}$（以更新本层权重）。两者都是与前向计算同等规模的矩阵乘法，因此 约为前向 FLOPs 的 2 倍。训练还需要保存前向传播的中间结果（**激活值**）， 供反向传播使用；这是一项规模可观、随批次和序列长度变化的内存开销。工程师通过*激活重计算*以算力换内存： 丢弃部分激活值，并在反向传播时重新计算 [S34008]。

3. 内存：为何训练需要 ~16 字节/参数

机制。 推理只需要权重。训练则需要权重，*再加上*优化器为每个权重保存的全部信息。在标准的混合精度训练中， 算术运算以 BF16（速度快，2 字节）进行，但优化器会保留一份全精度 FP32 “主”副本，以免微小的更新被舍入抹掉，此外还有 Adam 为每个参数维护的两个滑动平均值。

Training needs ~16 bytes per parameter, 8× BF16 inference, before activations

Memory per model parameter by regime and component, bytes (mixed-precision training with the Adam optimizer)



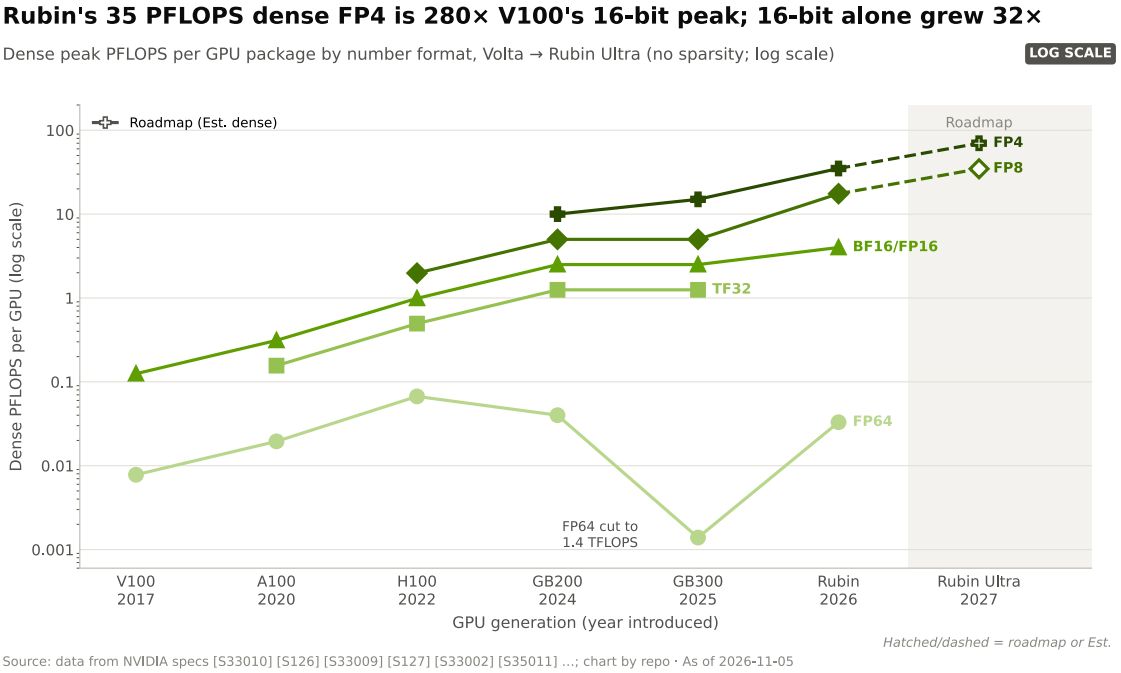
Source: data from ZeRO paper (Microsoft) and NVIDIA NVFP4 documentation [S32017] [S34004]; chart by repo · As of 2026-11-05

每参数字节数的堆叠横向条形图：FP4 推理约 0.56，FP8 推理 1，BF16 推理 2，采用 Adam 的混合精度训练 16（2 权重 + 2 梯度 + 4 FP32 主权重 + 4 动量 + 4 方差），是 BF16 推理的 8 倍。因此一个 405B 模型在计入激活值之前约有 6.5 TB 训练状态，相当于约 81 块 H100 的内存。

组成部分（每参数）	精度	字节	存在原因
工作权重	BF16	2	用于前向和反向计算
梯度	BF16	2（若以 FP32 保存则为 4）	反向传播的输出
主权重	FP32	4	累积微小更新而不因舍入丢失
Adam 动量	FP32	4	梯度的滑动均值
Adam 方差	FP32	4	梯度平方的滑动均值
激活值之前合计		**16（采用 FP32 梯度时 ~18）**	ZeRO 论文的核算口径 [S34004]

> 提示
>
> **算例 —— 405B 模型的内存下限。** 405B 参数 × 16 字节 = **6.5 TB** 训练状态。 分摊到 80 GB 的 H100 上 [S33002]，仅存放这些状态就需要 ⩾ **81 块 GPU**；在 288 GB 的 Blackwell Ultra 或 Rubin GPU 上 [S32004,S33005] 则需要 ⩾ **23 块**。再加上激活值——在长序列下其规模可与训练状态本身相当。没有 任何单块 GPU 或单台服务器能接近这一需求，因此训练状态被**分片**到多块 GPU 上（ZeRO / FSDP） [S34004]，这把 内存问题转化为网络问题：每一步都必须收集和分散这些分片。这一权衡正是 P4 的主题。

降低精度是主要杠杆。 与 BF16 相比，FP8 使每个数值的字节数减半，并使 Hopper 和 Blackwell 上的张量核心 吞吐量翻倍（H100：稠密 BF16 989 TFLOPS，稠密 FP8 1,979 [S33002]）。DeepSeek-V3 采用 FP8 混合精度框架训练 [S34007]；英伟达如今以其 4 位 NVFP4 格式宣传 Rubin 的训练性能 （35 PFLOPS） [S33004]。问题在于：精度每减半一次，都需要新的数值技巧（缩放因子、更高精度的 累加）来避免训练不稳定。



对数坐标折线图：英伟达各代 GPU 按数值格式划分的稠密峰值算力，从 V100（2017 年）到 Rubin Ultra（2027 年路线图）。Rubin 达到 35 PFLOPS FP4 和 17.5 PFLOPS FP8，是 V100 的 125 TFLOPS FP16 的 280 倍，而 16 位吞吐量仅增长 32 倍；FP64 在 Blackwell Ultra 上降至约 1.4 TFLOPS，随后在 Rubin 上回升至 33 TFLOPS。

4. FLOPs 算术：从 6 × N × D 到 GPU 时、MFU 与美元

每一份训练预算都遵循这条链条：

所需 FLOPs（6 × N × D）÷（每 GPU 峰值 FLOPS × MFU）= GPU 秒 → GPU 时 × $/GPU 时 = 成本。

模型 FLOPs 利用率是 GPU 理论峰值中真正转化为有效模型计算的比例。 它是训练中最重要的单一效率指标：综合反映了内核质量、通信重叠、 流水线气泡和掉队节点（straggler）的影响。

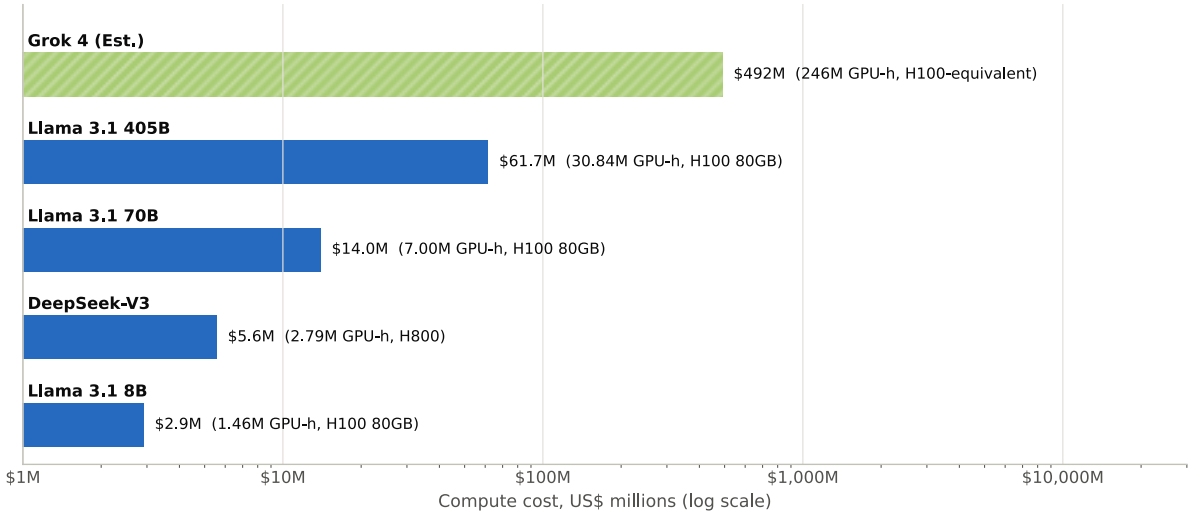
提示

算例 —— 倒推 Llama 3.1 405B。 1. **算力：** 3.8×10^{25} FLOPs [S34006]。 2. **时数：** 30.84M H100 GPU 时 [S31002]。按每块 H100 稠密 BF16 989 TFLOPS [S33002] 计算，这些时数理论上 可提供 30.84M × 3,600 s × 989 × 10^{12} = **1.10 × 10^{26} FLOPs**。 3. **隐含利用率：** 3.8×10^{25} ÷ 1.10×10^{26} = **~35%**，而 Meta 在稳态训练期间测得的 **MFU 为 38–43%** [S34006]。差额来自故障、重启、评估以及长上下文 阶段损失的时间。谷歌公布 PaLM 在 TPU v4 上的 MFU 为 46.2% [S34021]，因此这是行业普遍区间，而非某一家厂商的短板。 4. **墙钟时间：** 30.84M GPU 时 ÷ 16,384 块 GPU ≈ 1,880 小时 ≈ **78 天**（假设每块 GPU 不间断运行）。 5. **美元：** × $2/GPU 时（DeepSeek 公布的租赁价格假设 [S34007]）≈ **$62M**；按 $3 计 ~$93M。 作为参照，H100 租赁价格从 AWS 上市挂牌价（2023 年）的 ~$12/GPU 时，到 2024 年末 GPU 交易平台上的 ~$2 以下不等 [S391,S393]，因此同一次训练的定价可在 ~$60M 至 ~$380M 之间。 **能耗：** 30.84M h × 0.7 kW GPU TDP ≈ 21.6 GWh，仅为 GPU 本身，未计 CPU、网络和冷却；Meta 公布 405B 模型的排放为 8,930 t CO_2e（基于地点法）[S31002]。

Frontier final-run bills span ~88×: $5.6M (DeepSeek-V3) to ~$0.5B (Grok 4, Est.)

GPU-hours × $2/GPU-hour (DeepSeek's rental assumption), US$ M (log scale); hatched = estimate

LOG SCALE



Source: data from Meta model card, DeepSeek-V3 report, Epoch AI [S31002] [S34007] [S34006] [S31008]; chart by repo · As of 2026-11-05

对数坐标横向条形图：按 $2/GPU 时计算的租赁等价算力成本：Llama 3.1 8B 约 $2.9M（1.46M GPU 时），DeepSeek-V3 $5.6M（2.788M H800 时），Llama 3.1 70B $14M，Llama 3.1 405B 约 $62M（30.84M H100 时），Grok 4 约 $492M（Epoch AI 估计为 246M H100 时）。

训练任务	算力	硬件与时间	租赁等价算力成本	数字背后未体现的部分
Llama 3.1 405B（2024 年 7 月）	3.8 × 10^{25} FLOPs S34006	30.84M H100 时，最多 16,384 块 GPU S31002,S34006	按 $2/h 计 ~$62M（估计）	消融实验、较小的测试模型、数据工作
DeepSeek-V3（2024 年 12 月）	~3.3 × 10^{24}（6 × 37B 激活参数 × 14.8T，估计）	在 2,048 块 GPU 上运行 2.788M H800 时 S34007	按 $2/h 公布为 $5.576M S34007	前期研究与自有集群的资本开支 S31013
Grok 4（2025 年 7 月）	~5 × 10^{26}（估计） S31008	~246M H100 等效时（估计） S31008	按 $2/h 计 ~$0.5B（估计）	Epoch 提示存在较大不确定性 S31008

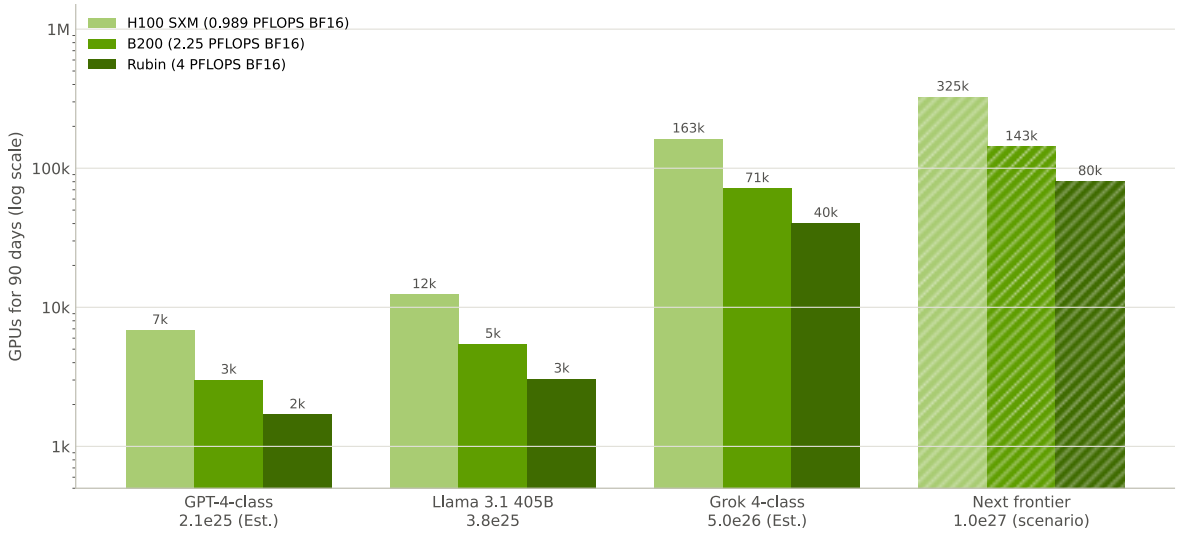
注意

误区与事实：“DeepSeek 用 $6M 训练出了一个前沿模型。” 这 $5.576M 只是最终一次训练的 GPU 时数 × 假设的租赁价格 S34007。它不包括前期研究、失败的训练以及集群本身 S31013。对英伟达而言， 教训是真实的，但范围更窄：算法效率（MoE、FP8）使达到特定能力所需的算力下降了一个数量级， 从而降低了挑战者以及不需要最大规模集群的买家的门槛。参见 CS5。

A Grok 4-scale run in 90 days needs ~163k H100s, or ~40k Rubin GPUs

GPUs needed to finish each training budget in 90 days at 40% BF16 utilization (log scale); hatched = scenario

LOG SCALE



Source: data from Epoch AI, Meta; NVIDIA spec pages [S31011] [S34006] [S31002] [S31008] [S31007] [S33002] …; chart by repo · As of 2026-11-05

分组对数坐标条形图：在 BF16 模型 FLOPs 利用率为 40% 的条件下、90 天内完成一次训练所需的 GPU 数量：GPT-4 级训练（2.1e25 FLOPs，估计）约需 6,800 块 H100；Llama 3.1 405B（3.8e25）约需 12,000 块 H100 或 5,400 块 B200；Grok 4（5e26，估计）约需 160,000 块 H100、71,000 块 B200 或 40,000 块 Rubin GPU；1e27 情景约需 330,000 块 H100 或 80,000 块 Rubin GPU。

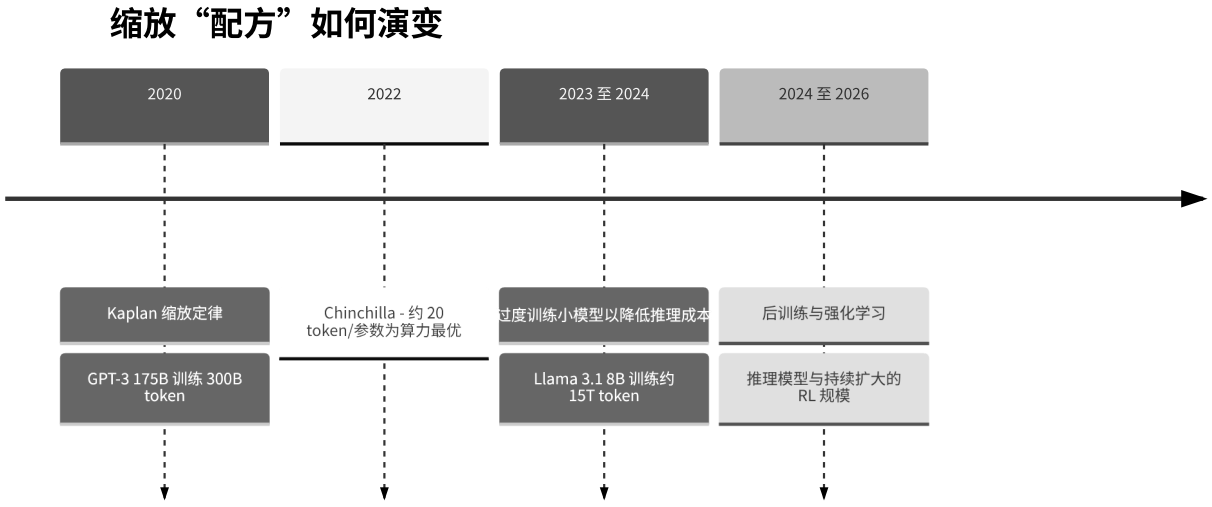
该图把算力预算换算成集群规模。若要在 90 天内以 40% MFU 完成 Grok 4 规模的预算，需要 ~160,000 块 H100、~71,000 块 B200 或 ~40,000 块 Rubin GPU（BF16 峰值分别为 0.989、2.25 和 4 PFLOPS S33002,S33003,S33005）； 一次 10^{27} FLOPs 的训练——大致是每年 4–5× 趋势

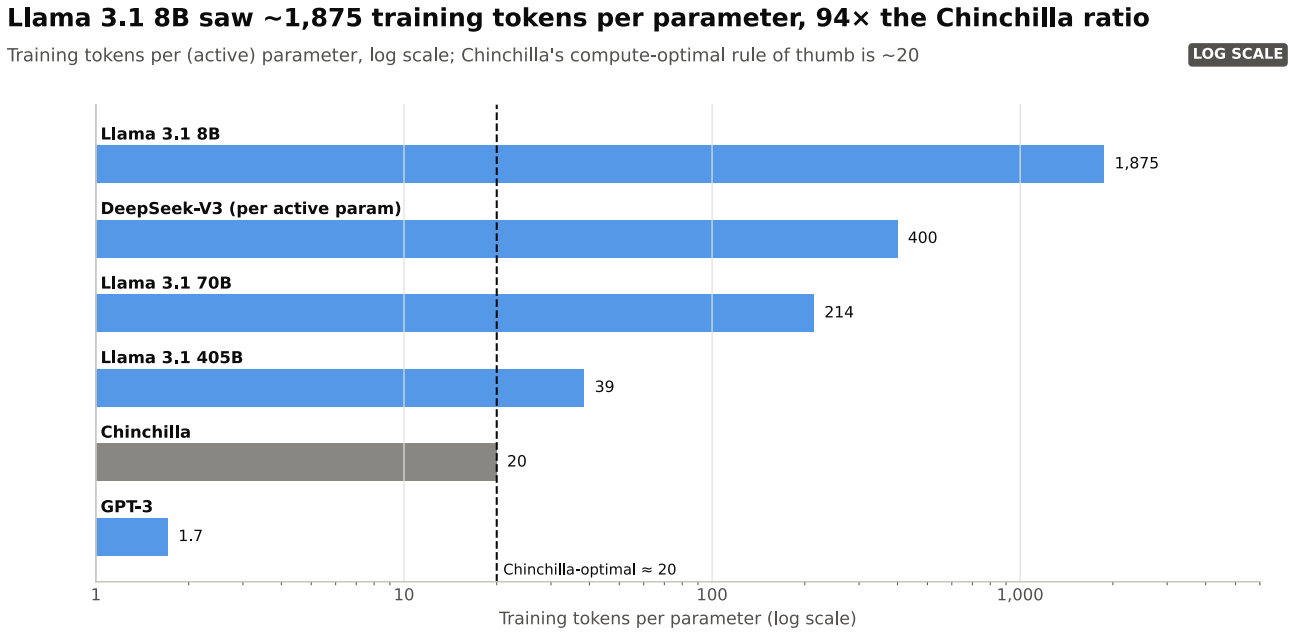
指向的下一站（🔴 本资料库情景）[S31007]——所需数量还要翻倍。这正是 吉瓦级园区背后的算术。

5. 缩放定律：Kaplan → Chinchilla → 过度训练 → 后训练

缩放定律是一条经验曲线：增加参数、数据或算力时，模型损失会以幂律形式可预测地下降。这正是 各实验室持续采购 GPU 的原因：曲线表明更多算力能换来更好的模型，而且迄今为止一直如此。

阶段	关键结论	实践法则	示例
Kaplan 等，2020 年 1 月	损失与参数、数据和算力呈幂律关系；更大的模型样本效率更高 [S31006]	额外算力主要用于扩大模型	GPT-3：175B 参数仅训练 300B token，~1.7 token/参数 [S31015]
Chinchilla，2022 年 3 月	参数与 token 应同比例扩展（Chinchilla 最优）；在相同算力下，用 1.4T token 训练的 70B Chinchilla 胜过 280B 的 Gopher [S31005]	**~20 token/参数**为算力最优	2020–21 年的大多数模型训练不足
过度训练，2023 年起	推理成本主导模型全生命周期成本，因此训练时间长得多的较小模型服务成本更低	远超 20 token/参数	Llama 3.1 8B 训练 ~15T token：~1,875 token/参数 [S31002]
后训练与 RL，2024 年起	在可验证任务（数学、代码）和推理轨迹上进行强化学习，提升每 FLOP 带来的能力	将算力从预训练转向后训练	Epoch AI：GPT-5 ~5 × 10^{25} FLOPs（含 RL），GPT-4.5 > 10^{26}（估计） [S31010]





Source: data from OpenAI, DeepMind, Meta and DeepSeek papers and model cards [S31015] [S31005] [S34006] [S31002] [S34007]; chart by repo · As of 2026-11-05

对数坐标横向条形图：每个激活参数对应的训练 token 数：GPT-3 约 1.7，Chinchilla 20，Llama 3.1 405B 约 39，Llama 3.1 70B 约 214，DeepSeek-V3 每激活参数约 400，Llama 3.1 8B 约 1,875，是算力最优比率的 94 倍，因为过度训练的小模型服务成本更低。

提示

算例 —— 为何要过度训练？ 假设两个模型达到相同质量：一个是按 Chinchilla 比率训练的 70B 模型，另一个是 用多得多的 token 训练的 8B 模型。用 15T token 训练 8B 模型的成本为 $6 \times 8 \times 10^9 \times 15 \times 10^{12} = 7.2 \times 10^{23}$ FLOPs；Chinchilla 最优的 70B 模型成本为 $6 \times 70 \times 10^9 \times 1.4 \times 10^{12} = 5.9 \times 10^{23}$ FLOPs，大致相当。但推理时每生成一个 token 约需 ~2 FLOPs/参数，因此 8B 模型的**服务成本永久低 ~9×**（70 ÷ 8）。8B 模型能否真正 与 70B 模型比肩是一个经验问题；对许多产品而言已足够接近，这就是 “过度训练”的小模型主导实际部署的原因。

向后训练和 RL 的转变对硬件需求意义重大。RL 后训练会生成海量候选答案（一种*推理*负载） 并对其打分，然后用最佳答案进行训练：如今一次训练任务内部就包含一个推理 引擎。Epoch AI 估计 GPT-5 的总训练算力少于 GPT-4.5 [S31010]，但这**并不**意味着算力 需求下降：节省下来的预训练 FLOPs 转移到了 RL、实验，以及最重要的——推理模型的服务（参见 P2）。

注

🐂 **看多观点。** 前沿训练算力仍以每年 4–5× 的速度复合增长 [S31007]；据 Epoch 统计，截至 2024 年底超过 10^{25} FLOPs 的模型有 24 个 [S31014]，到 2025 年年中超过 30 个 [S31009]，预测中位数为到 2028 年底达到 165 个 [S31014]。 每一种新范式（过度训练、RL、推理）都新增了一个算力消耗方向，而非取代原有方向。

注意

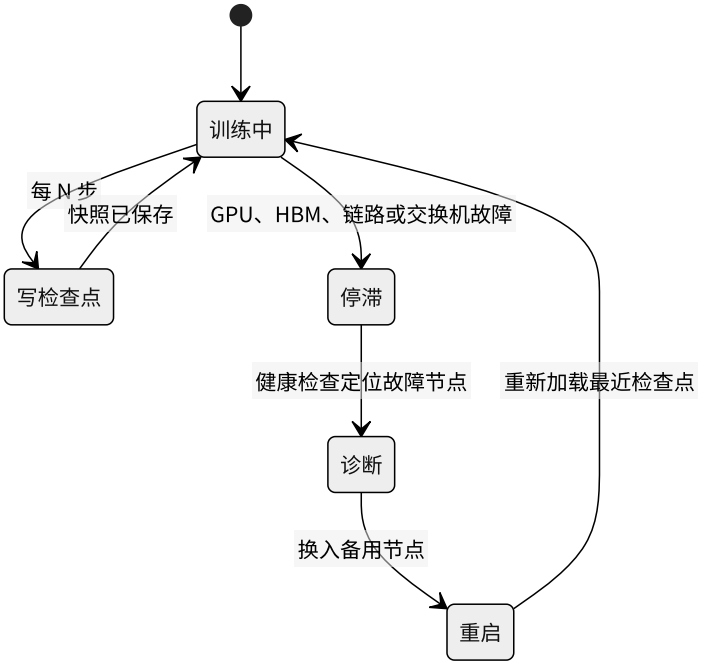
🐻 **看空观点。** 在 GPT-4.5 与 GPT-5 之间，已披露的最大规模预训练任务停止了增长 [S31010]，而 DeepSeek-V3 仅用 2,048 块 GPU 就取得了接近前沿的结果 [S34007]。如果能力提升主要来自算法和 后训练，那么需要 100,000 块 GPU 同步集群的买家会减少——而这正是英伟达全栈 优势（NVLink、InfiniBand、NCCL）最大的配置。训练在总支出中的占比可能缩小，竞争也可能更激烈。

6. 大规模下的故障与检查点

机制。 同步训练就像一支车队：每一步都要等待最慢的 GPU；一旦任何一块 GPU、一个内存堆栈、 一根线缆或一台交换机出现故障，整个作业就会停止。随后作业从最近一次**检查点**重启—— 检查点是写入存储的权重与优化器状态快照——自该检查点以来的所有工作都会丢失。

提示

算例 —— 故障率与集群规模。 Meta 在最多 16,384 块 H100 上为期 54 天的快照中出现了 419 次意外 中断 [S34006]，约**每天 7.8 次，即每 ~3 小时一次** [S31003]。其中 58.7% 与 GPU 相关，包括 30.1% 的 GPU 故障和 17.2% 的 HBM3 内存故障 [S31003]。若故障数随 GPU 数量线性增长（🔴 本资料库 外推），一个 100,000 块 GPU 的作业每天将中断 ~47 次，**约每 30 分钟一次**。405B 模型的每个检查点 约为 ~6.5 TB 的权重加优化器状态（见第 3 节），因此存储带宽和重启速度决定了集群有多少时间 处于有效工作状态。Meta 仍实现了 > **90% 的有效训练时间** [S34006]，靠的是自动化， 而非运气。



🔧 **技术细节：运维方如何维持较高的“有效产出”（goodput）**

运维方衡量的是**有效产出（goodput）**，即真正推进模型训练的 GPU 时数占比。可用杠杆包括：（1）故障越频繁， 检查点就要越频繁，这需要高速并行存储；（2）异步检查点，即先把状态复制到主机内存，再在后台写出； （3）热备节点和自动健康检查，可在几分钟内剔除故障 GPU；（4）遥测系

统，用于发现“变慢但未宕机”的 GPU—— 这类 GPU 会悄无声息地拖慢同步作业。其中若干环节属于英伟达的系统软件和网络产品（第 07、09 和 12 层），也有若干环节是云厂商和初创公司相互竞争的领域。

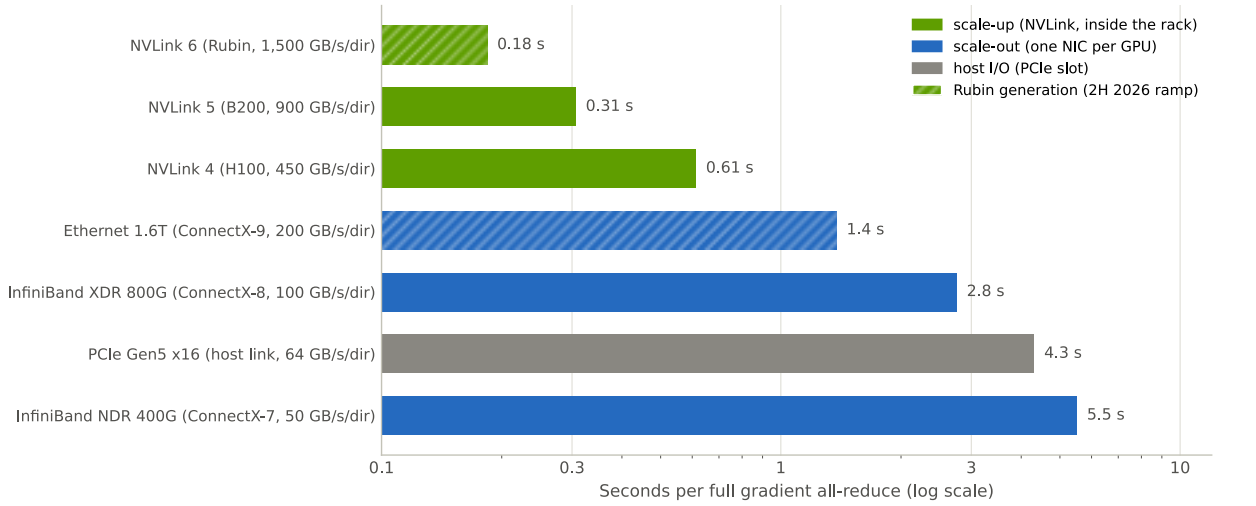
7. 训练需求如何映射到技术栈

上述每一项需求都落在技术栈的某一特定层级上。下表是连接本篇入门与各层深度分析的 桥梁。

A 70B gradient sync takes ~5.5 s over 400G InfiniBand but ~0.3 s over NVLink 5

Ideal ring all-reduce of 140 GB of BF16 gradients across 64 GPUs (276 GB sent per GPU), by per-GPU link; seconds

LOG SCALE

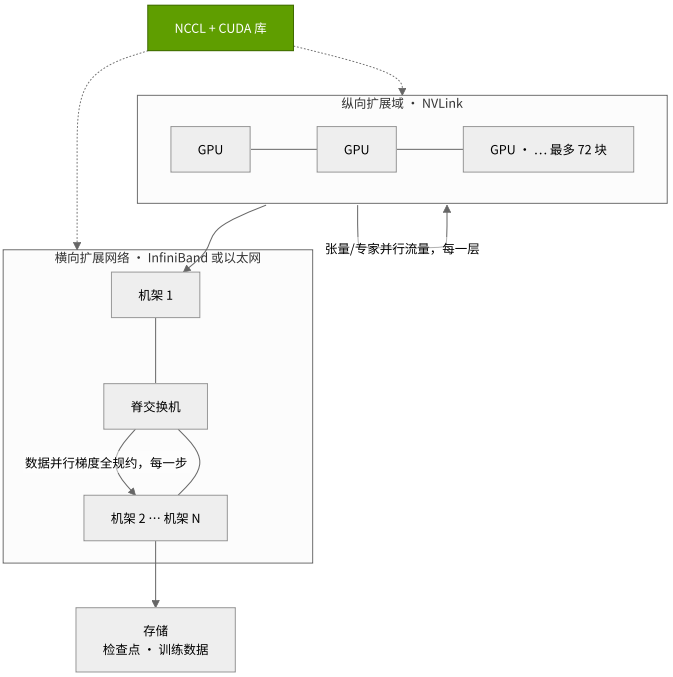


Source: data from link specs via interconnect_specs.csv; ring formula [S251] [S252] [S253] [S222] [S256] [S254] ...; chart by repo · As of 2026-11-05

横向条形图：在 64 块 GPU 间对 140 GB BF16 梯度（一个 700 亿参数模型）执行理想环形全规约所需时间，每块 GPU 约发送 276 GB：InfiniBand NDR 400 Gb/s 约 5.5 秒，PCIe Gen5 x16 约 4.3 秒，InfiniBand XDR 800 Gb/s 约 2.8 秒，NVLink 4 约 0.61 秒，NVLink 5 约 0.31 秒，NVLink 6 约 0.18 秒；NVLink 5 比 400G InfiniBand 快约 18 倍。一块 1.6 Tb/s 的 Rubin 代网卡约需 1.4 秒。

上图的差距说明了为何流量最大、最频繁的通信（每一层内部的张量并行与专家并行交换）都保留在 NVLink 域内，而每步一次的梯度同步则可以跨越较慢的横向扩展网络；P4 会详细推演这些数字。

训练需求	原因	技术栈层级	英伟达产品示例	替代方案
低精度稠密矩阵运算	6 × N × D FLOPs	第 02 层	H100、B200、B300、Rubin 张量核心	TPU、Trainium、MI355X
内存容量与带宽	16 B/参数的状态 + 激活值	第 03 层	基于 CoWoS 的 HBM3E / HBM4	同一批供应商为所有厂商供货
极高速的 GPU 间互连	每一层的张量并行与专家并行流量	第 05 层	NVLink 5/6、NVL72 机架	TPU ICI、UALink、Trainium NeuronLink
全集群梯度同步	每步一次的数据并行全规约	第 06 层	InfiniBand、Spectrum-X 以太网	博通/Arista 以太网、谷歌 Jupiter
检查点 I/O 与数据加载	TB 级快照、流式输入 token	第 07 层	BlueField DPU、SuperNIC	VAST、Weka、DDN 存储
集合通信库与内核	全规约、全收集、FP8 内核	第 09 层与第 10 层	CUDA、NCCL、cuDNN、Megatron	TPU 上的 XLA/JAX、ROCm/RCCL
调度与容错	每隔几小时发生一次故障	第 12 层	DGX Cloud、Mission Control	超大规模云厂商调度器、Slurm、Kubernetes



重要

最需要记住的一点： 训练吞吐量 = 芯片数量 × 利用率，而利用率既取决于芯片，同样取决于内存、 互连、软件和可靠性。这就是英伟达销售的是机架和网络而非单块 GPU 的原因， 也是一个芯片更快但集群更弱的挑战者仍可能输掉训练订单的原因。

与各层的关联

- **第 02 层 · GPU 芯片：** 执行 6 × N × D FLOPs 的地方；精度 格式（BF16 → FP8 → NVFP4）是最大的代际杠杆。
- **第 03 层 · 内存、封装与供应链：** 每参数 16 字节的 状态存放在 HBM 中；HBM 和 CoWoS 的供应决定了训练 GPU 的数量上限。
- **第 05 层 · 纵向扩展（NVLink、NVSwitch）**与 **第 06 层 · 横向扩展网络：** 全规约和 分片流量，使 MFU 维持在 40% 左右而不致崩塌；另见 P4 · 并行方式。
- **第 07 层 · DPU、SuperNIC、存储：** 检查点与数据 流水线。
- **第 08 层 · 系统、机架与 AI 工厂：** 100,000 块 GPU 的 集群和吉瓦级园区如何建成。
- **第 09 层 · CUDA**与 **第 10 层 · CUDA-X 库：** NCCL、cuDNN、Megatron，以及决定 MFU 的各类内核。
- **第 12 层 · 编排与云服务：** 调度、健康 检查和重启自动化。
- 模型全生命周期的经济学：第 14 章 · 训练与推理经济学； 瓶颈直觉：P3；芯片成本：P5。

需要记住的关键数字

指标	数值	来源
训练 FLOPs 经验法则	≈ 6 × 参数量 × token 数	S31006
Llama 3.1 405B 算力	3.8 × 10^{25} FLOPs，训练 15.6T token	S34006
Llama 3.1 405B GPU 时	30.84M H100 时（8B/70B/405B 全系列合计 39.3M）	S31002
实测 MFU，Llama 3 405B	38–43%（BF16，H100）	S34006
每参数内存，混合精度 + Adam	~16 字节（采用 FP32 梯度时 ≈18），不含激活值	S34004
Chinchilla 算力最优比率	~20 token/参数	S31005
前沿算力增速	每年 ~4–5×	S31007
最大的公开估计（2025 年末）	Grok 4 ~5 × 10^{26} FLOPs，~246M H100 时（估计）	S31008
DeepSeek-V3 最终训练成本	2.788M H800 时，按 $2/h 计 $5.576M	S34007
16k GPU 规模下的故障率	54 天内 419 次意外中断（~每 3 小时 1 次）	S34006,S31003

🎯 企业发展视角

1. **利用率是隐藏的价值池。** 一个 MFU 为 40% 的集群有一半以上的峰值 FLOPs 被闲置。能把 MFU 或有效产出提升 5–10 个百分点的软件（编译器、通信重叠、故障预测、检查点）每一美元的价值都高于芯片速度的边际提升。 该领域有哪些独立公司可以成为合作伙伴或收购标的？ 又有哪些会率先被英伟达纳入 CUDA-X 或 Mission Control?

2. **谁掌握训练客户？** 在 Epoch AI 的估计中，算力超过 10^{26} FLOPs 的只有少数几家实验室（在本篇数据中为 xAI、OpenAI 和 Anthropic）[S31011]。这种集中度 使它们有筹码为训练——英伟达根基最深的负载——资助定制芯片（TPU、Trainium、MTIA）。 这种筹码会以多快的速度转化为份额流失？商用芯片挑战者又能在哪里找到位置？
3. **配方转变是一个切入点**。 过度训练和 RL 后训练使算力转向以生成为主、 类似推理的工作（参见 P2），在这类工作中，内存带宽和每 token 成本 比 10 万块 GPU 规模的同步网络更重要。这是否有利于针对推理效率优化的架构？时间表如何？
4. **效率冲击是一把双刃剑**。 DeepSeek 式的效率提升 [S34007] 降低了训练的入场门槛，但从 历史看反而扩大了总需求。应把 10^{25} FLOPs 以上模型的数量（2024 年底为 24 个，预测到 2028 年达 165 个 [S31014]）作为需求信号来跟踪，而非盯住任何一家实验室的集群。
5. **可靠性就是产品**。 在 16k GPU 规模下每隔几小时就发生一次故障 [S34006]，集群级遥测、备件和 重启自动化都是差异化因素。在跨英伟达、AMD 和定制芯片保持厂商中立的可靠性/可观测性工具领域， 是否存在并购机会？

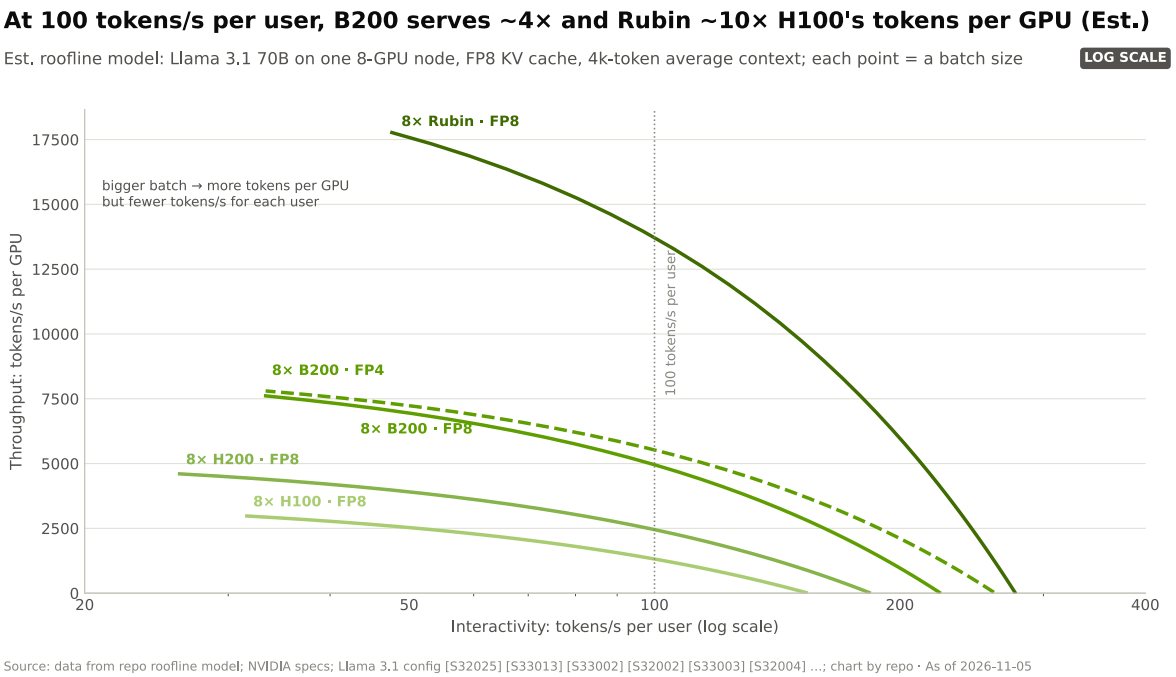
P2 · AI 推理原理

入门篇 P2 · 写给非工程师的基础知识 · 约 22 分钟阅读 · 最近核实：2026-11-05

> **注**
>
> **如果你熟悉电子表格和财务、但不熟悉芯片，请从这里开始。** 推理就是*使用*已训练好的 模型：每一次聊天机器人的回答、每一次代码补全和每一个智能体步骤都是推理。训练（P1）是 一次性的资本项目；推理则是 AI 的经常性销货成本，也是 token 用量以及英伟达收入争夺战增长最快的领域。

⚡ 要点速览

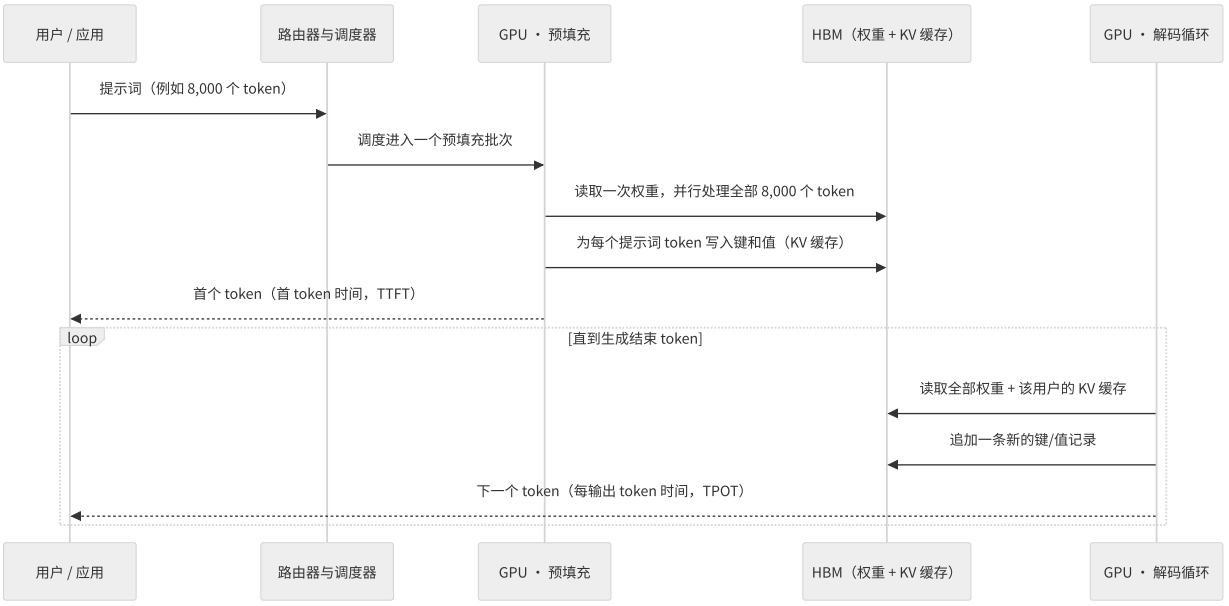
- **每个请求都包含两个瓶颈截然相反的阶段。** 预填充（prefill）一次性读入整个提示词，属于*算力受限*；解码（decode）每次生成一个 token，属于*内存带宽受限*，因为每生成一个新 token 都要从 HBM 中重新读取模型的全部权重 [S32027,S33013]。
- **单用户解码速度 ≈ 内存带宽 ÷ 每个 token 读取的字节数。** 在 H100（3.35 TB/s）上，FP8 精度的 Llama 3.1 70B（权重 70 GB）单条流的速度永远不可能超过 ~48 tokens/s [S33002]；在 Rubin 上（按当前规格为 19.2 TB/s，较发布时的 22 TB/s 有所下调）[S33005,S33007]，上限约为 ~274 tokens/s。
- **KV 缓存是推理的“内存税”。** 对话中的每个 token 都会在 HBM 中留下键（key）和值（value）：即便采用分组查询注意力，一段 128k token 的 Llama 3.1 70B 对话也要占用 ~43 GB [S32006,S32010]。决定一块 GPU 能承载多少用户的是内存*容量*，而非 FLOPs。
- **批处理把闲置的 FLOPs 转化为吞吐量，代价是单用户速度下降。** 连续批处理和分页 KV 内存在同等延迟下把服务吞吐量提高了 2–4× [S32011,S32012]。由此形成每 GPU tokens/s 与每用户 tokens/s 之间的 Pareto 前沿；按本资料库的模型，在每用户 100 tokens/s 时，B200 节点每 GPU 的 token 产出约为 H100 节点的 ~4×，Rubin 约为 ~10×（估计）。
- **各项效率杠杆可以叠加：** 量化至 FP8/NVFP4 [S32017]、推测解码（原论文中提速 2–3×）[S32013]、混合专家模型（DeepSeek-V3 在 671B 参数中仅激活 37B）[S34007]，以及预填充与解码的分离式服务 [S32014,S32015]。
- **需求正在复合增长。** 谷歌每月处理的 token 从 9.7 万亿（2024 年 4 月）增至超过 1.3 千万亿（2025 年 10 月）[S32018,S32020]；微软在 2025 年 1–3 月处理了 100T+ token，是一年前的 5 倍 [S32021]。推理模型和智能体使每项任务的 token 数增加一到三个数量级（估计）[S32025]。
- **为何这对英伟达重要：** 推理是一场每 token 成本的竞争，比训练更易拆分、也更易被争夺。专用芯片（TPU、Trainium、Cerebras、以 SRAM 为主的设计）首先在这里展开竞争。英伟达的应对是机架级 NVLink 域、FP4 和推理服务软件（Dynamo），以及据报道 ~$20B 的 Groq LPU 技术授权加收购式招聘（acquihire）交易（2025 年 12 月），该技术现已作为解码协处理器随 Vera Rubin 平台出货 [S113]。



建模得到的 Pareto 曲线：8 GPU 节点上 Llama 3.1 70B 的每 GPU 吞吐量与每用户速度：批次越大，每 GPU 的 token 数越多，但每个用户的速度越慢。在每用户 100 tokens/s 时，模型给出的每 GPU tokens/s 约为：H100（FP8）1,273，H200 2,293，B200（FP8）4,953，B200（FP4）5,333，Rubin（FP8）13,297；在每用户 50 tokens/s 时，B200 相对 H100 的领先缩小至约 2.8 倍。数据来自简单的 roofline 模型估算，并非基准测试结果。

1. 预填充与解码：瓶颈截然相反的两项工作

类比。 预填充相当于通读整道题目；解码相当于逐字写出答案，而且每写一个字之前，都必须把整本教科书（模型权重） 重新翻一遍。阅读很快，因为所有词可以并行处理。书写很慢，因为它是串行的，而且每一步都要完整遍历一次内存。



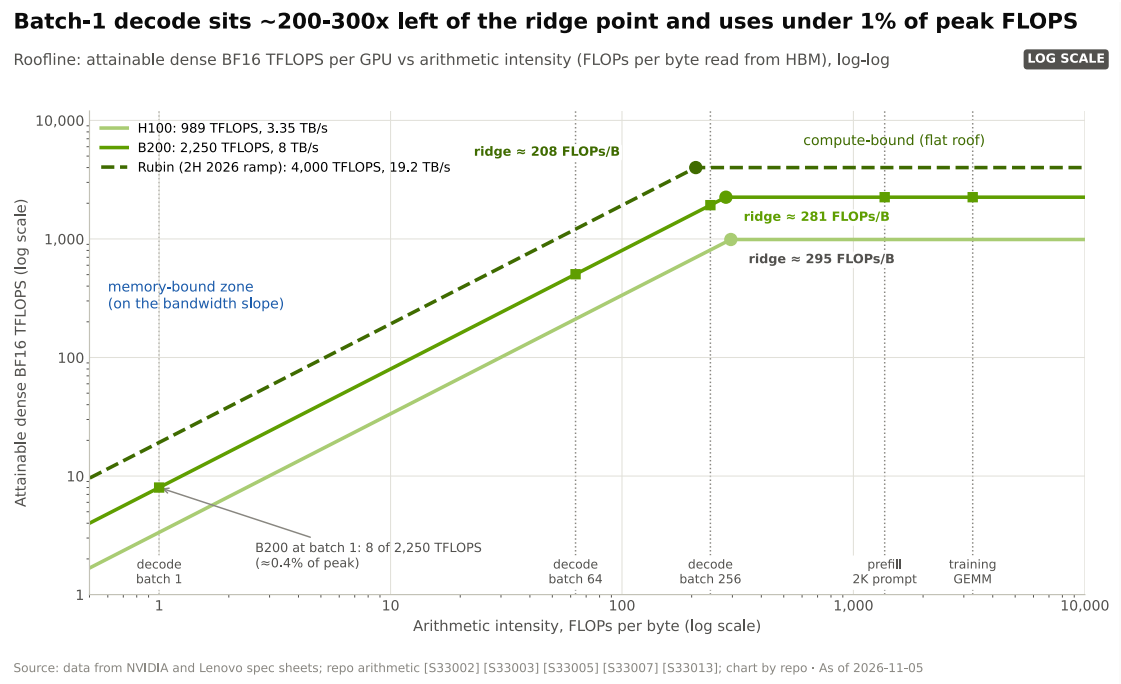
	预填充（上下文阶段）	解码（生成阶段）
每步处理的 token 数	整个提示词，并行处理	每步每用户一个
瓶颈	张量核心 FLOPS（算力受限）	HBM 带宽（内存受限）
影响的延迟指标	首 token 时间（TTFT）	每输出 token 时间（TPOT）
最佳硬件特性	原始 FLOPS，即便搭配较便宜的内存	每 GPU 的带宽与容量
英伟达产品线索	Rubin CPX（GDDR7，上下文阶段）：2025 年发布，随后从 2026 年路线图中撤下 S33023,S115	NVL72 机架中配备大量 HBM 的 GPU；源自 Groq 的 LPX（SRAM）机架 S113

提示

算例 —— 在 Llama 3.1 70B 上处理 8,000 token 的提示词。 前向传播中每个 token 约消耗 ~2 FLOPs/参数，因此预填充需要 $2 \times 70 \times 10^9 \times 8{,}000 = \mathbf{1.1 \times 10^{15}\ FLOPs}$。H100 的稠密 FP8 算力为 1,979 TFLOPS S33002：以峰值计约 ~0.57 s，以现实的 50% 效率计 ~1.1 s，分摊到 8 块 GPU 上 ~0.15 s。解码则不同：每个输出 token 仅需 $2 \times 70 \times 10^9 = 1.4 \times 10^{11}$ FLOPs（H100 算力下 0.07 ms），但必须读取全部 70 GB 的 FP8 权重，在 3.35 TB/s 下耗时 **21 ms**。在批大小为 1 时，解码受内存约束的程度约为受算力约束的 ~300×。

🔧 技术细节：算术强度与“脊点”（ridge point）

算术强度是每从内存搬运一个字节所执行的 FLOPs。对 FP8 模型的单条流进行解码，约为 ~2 FLOPs/字节（每个 1 字节权重对应一次乘加）。H100 的算力为 1,979 TFLOPS、带宽为 3.35 TB/s，“脊点”约为 ~590 FLOPs/字节 S33002；B200 约为 ~560 S33003，Rubin 约为 ~910 S33005。低于脊点时，芯片处于等待内存的状态。批处理能提高算术强度，因为一次权重读取可服务批次中的每一条序列：批大小为 256 时，算术强度约为 ~512 FLOPs/字节，接近脊点（忽略 KV 缓存读取）。下图以 BF16 展示同样的情形，此时两侧都减半：批大小为 1 的解码约为 ~1 FLOP/字节，而 H100 的脊点约为 ~295。roofline 图景将在 P3 · 四大瓶颈中展开 S33013。



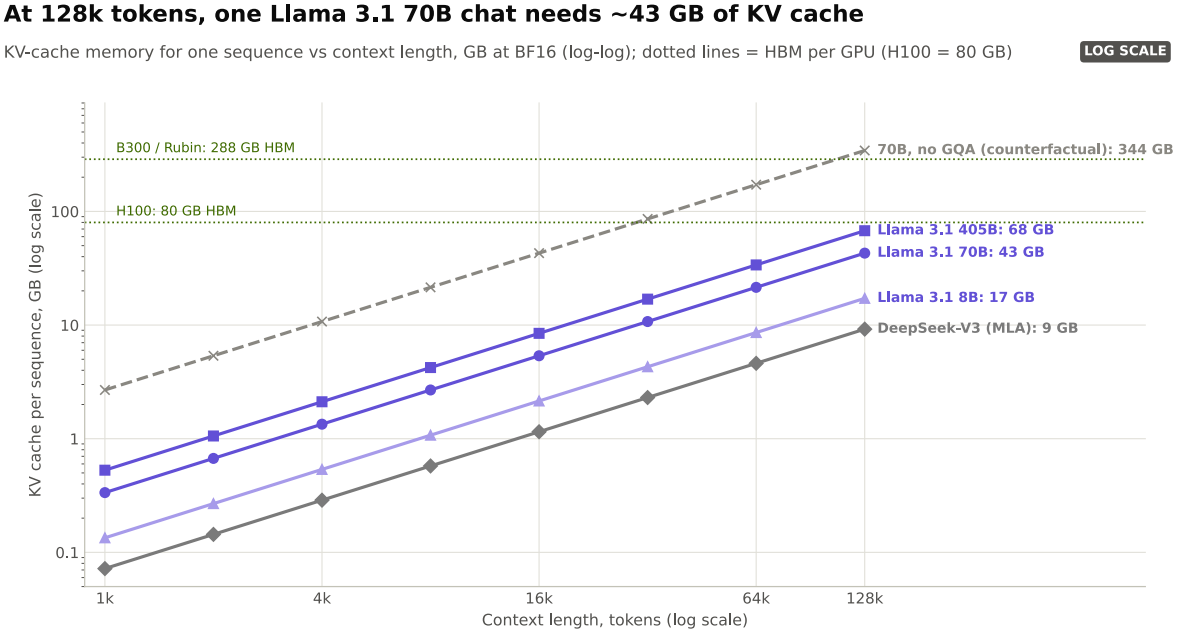
双对数 roofline 图（稠密 BF16）。H100：989 TFLOPS、3.35 TB/s，脊点约 295 FLOPs/字节；B200：2,250 TFLOPS、8 TB/s，脊点约 281 FLOPs/字节；Rubin：4,000 TFLOPS、19.2 TB/s，脊点约 208 FLOPs/字节。批大小为 1 的解码（约 1 FLOP/字节）位于带宽斜坡的最左侧；批大小 64（63）和 256（241）向右移动；预填充（约 1,365）和训练矩阵乘法（约 3,277）位于平坦的算力屋顶上。

2. KV 缓存：随每个 token 增长的内存

机制。 在注意力计算中，每个新 token 都要与之前的每个 token 进行比较。为避免每一步都重新计算之前 token 的“键”和“值”，服务器会把它们存储起来：这就是 KV 缓存。它随上下文长度和 并发用户数线性增长，并且与权重共用同样稀缺的 HBM。

大小公式（每 token）： 2（键和值）× 层数 × KV 头数 × 头维度 × 每个数值的字节数 [S32027]。

> **提示**
>
> **算例 —— Llama 3.1 70B 在其 128k 上下文下。** 该模型有 80 层、8 个 KV 头，头维度为 128 [S32006]。每 token：2 × 80 × 8 × 128 × 2 字节（BF16）= **327,680 字节 ≈ 0.33 MB**。在 131,072 个 token 时：0.33 MB × 131,072 = **单个对话 42.9 GB**，超过一块 80 GB H100 容量的一半 [S33002]。八个这样的用户需要 344 GB， 超过一块 288 GB 的 Rubin GPU [S33005]。如果不采用分组查询注意力（64 个 KV 头而非 8 个），同一个 对话将需要 **344 GB** [S32010]。以 FP8 存储缓存可使上述每个数字减半。



双对数折线图：BF16 下每条序列的 KV 缓存大小与上下文长度的关系。在 131,072 个 token 时：Llama 3.1 8B 约 17 GB，Llama 3.1 70B 约 43 GB（超过一块 80 GB H100 的一半），Llama 3.1 405B 约 68 GB，不采用分组查询注意力的同一 70B 模型约 344 GB（超过一块 288 GB 的 B300 或 Rubin GPU），而采用多头潜在注意力的 DeepSeek-V3 约 9 GB。

模型设计者会直接针对 KV 缓存下手。**分组查询注意力**让每个键/值头被多个 查询头共享（Llama 3.1：64 个查询头对应 8 个 KV 头）[S32010,S32006]。DeepSeek 的**多头潜在注意力 （MLA）**为每层每个 token 只缓存一个压缩后的 576 维潜在向量 [S32009]；DeepSeek-V2 报告称，借此 KV 缓存缩小了 93.3%， 最大生成吞吐量提高到 5.76× [S32026]。在服务端， PagedAttention 像虚拟内存一样把缓存存放在固定大小的页中，从而不会 因碎片化而浪费 HBM [S32011]。

> 🔧 **技术细节：前缀缓存与 KV 卸载**
>
> 许多请求共享一段很长的公共前缀（系统提示词、代码仓库、智能体不断增长的对话记录）。服务器 会保留这些 KV 页并加以复用，因此重复的前缀可以完全跳过预填充；这就是 API 提供商对 “缓存输入” token 的定价远低于新输入 token 的原因。当 HBM 用尽时，不活跃的 KV 页可以被移至 CPU 内存或 SSD， 需要时再调回。这两种技术都使 GPU 周边的网络和内存层级（连接 Grace/Vera CPU 的 NVLink-C2C、 网卡、存储）成为推理性能的一部分，这也是与第 04、07 和 11 层的关联所在。

3. 批处理与连续批处理

机制。 由于解码受内存限制，只服务一个用户的 GPU 几乎所有张量核心都处于闲置状态。在同一步中服务 多个用户，可以把每次权重读取的成本分摊到所有用户身上。早期的服务器采用*静态*批处理：等待 N 个请求凑齐后一起运行，短回答则闲置等待，直到最长的回答完成。**连续批处理**（迭代级调度，由 Orca 提出 [S32012]）允许请求在每一步加入或离开批次。 vLLM 的 PagedAttention 增加了高效的 KV 内存管理，报告称在同等延迟下吞吐量比 FasterTransformer 和 Orca **高 2–4×** [S32011]。

> 提示
>
> **算例 —— 批处理在 8× H100 节点上能带来什么（本资料库模型，估计）。** FP8 精度的 Llama 3.1 70B 拆分到 8 块 H100 上 （合计 26.8 TB/s [S33002]），平均上下文 4k token，FP8 KV 缓存，实际带宽利用率 75%，每步 额外开销 3 ms [S32025]：
>
批大小（并发用户数）	单步时间	每用户 tokens/s	每 GPU tokens/s
1	6.5 ms	~150	~19
8	6.8 ms	~148	~150
64	8.6 ms	~116	~930
256	15.0 ms	~67	~2,130
>
> 从 1 个用户增至 64 个用户，吞吐量提高 ~49×，而每个用户的速度仅下降 ~25%。超过这一点后，KV 缓存读取量 随批次增大而增长，每个用户的速度会急剧下降。运营方的任务是在这条曲线上选出产品的 延迟承诺所允许的那个点。

4. 延迟与吞吐量：各项指标与 Pareto 前沿

指标	衡量内容	谁关心	典型驱动因素
TTFT（首 token 时间）	回答开始前的等待时间	聊天体验、等待工具结果的智能体	预填充算力、排队
TPOT / ITL（每输出 token 时间 / token 间延迟）	流式输出的 token 之间的间隔	阅读速度、智能体循环速度	解码带宽、批大小
每用户 tokens/s（交互速度）	1 ÷ TPOT	高级付费档位、推理模型	每用户可用带宽
每 GPU tokens/s（吞吐量）	所有用户的总输出	运营方的每 GPU 收入	批大小、内存容量
有效产出（goodput）	仍满足延迟目标的吞吐量	受 SLA 约束的服务	以上所有因素 [S32014]

前沿。 把每个批大小画成一个点：x = 每用户 tokens/s，y = 每 GPU tokens/s。曲线向下倾斜： 批次越大，总 token 越多，但单个用户越慢。评判硬件和软件的代际进步，要看它们把*整条*曲线向右上方推了多远， 而不是看某一个峰值数字。本页顶部的图表是基于第一性原理对这一前沿的建模 （一个估计；它忽略了注意力计算、MoE、推测解码、NVL72 纵向扩展和 Dynamo）。

> 提示
>
> **算例 —— 把前沿曲线当作损益表来读。** 在该模型中，每用户 100 tokens/s 时，H100 节点每 GPU 产出 ~1,270 tokens/s，B200 节点 ~4,950，Rubin 节点 ~13,300（估计） [S32025]。每用户 50 tokens/s 时，B200 的领先 缩小至 ~2.8×。每 GPU 时收入 = 每 GPU tokens/s × 3,600 × 每 token 价格：以每百万输出 token $1 的示意价格计， 每 H100 时 ~$4.60，每 B200 时 ~$17.80。产品承诺的速度越快，较新一代硬件的 优势就越大，这正是英伟达在宣传中采用按交互速度加权的比较的原因。

> 注意
>
> **误区与事实：“每 FLOP 最便宜的芯片会赢得推理市场。”** 解码很少用满 FLOPs；它受内存 带宽、KV 容量以及（对大模型而言）GPU 间互连的制约。正确的比较口径是 **在给定延迟目标下**的每 token 成本。在宽松延迟（大批次）下胜出的芯片，在高交互速度下可能大败， 反之亦然。

5. 量化，以及为何解码 tokens/s ≈ 带宽 ÷ 每 token 字节数

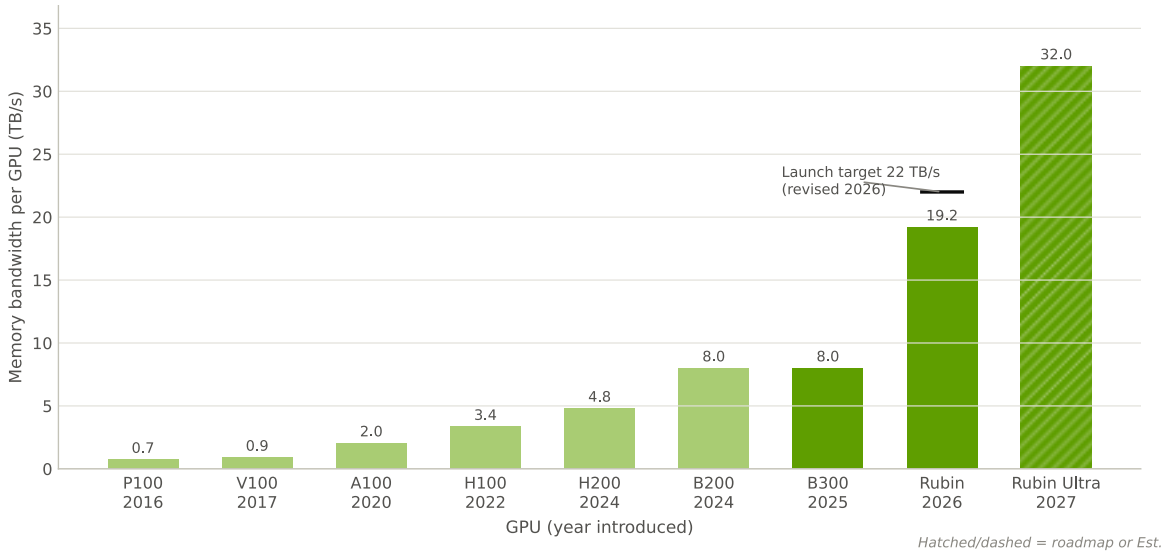
机制。 如果每生成一个 token 都需要把每个权重读取一次，那么单条流所能达到的最高速度就是 内存带宽除以模型字节数。把每个权重的字节数减半（BF16 → FP8 → FP4），大致可使这一上限翻倍，并使 内存占用减半。英伟达的 NVFP4 以 4 位存储数值，每 16 个数值组成的块配

一个 FP8 缩放因子，另加一个张量级 缩放因子 [S32017]，计入缩放因子后约为每个权重 4.5 位。

这一比率中带宽一侧的增长远慢于算力，这就是决定用户体验的是解码而非 FLOPS 的 原因：

HBM bandwidth per GPU rose 26× from P100 to Rubin (0.73 → 19.2 TB/s)

Peak memory bandwidth per GPU package, TB/s; Rubin shown at the revised production figure

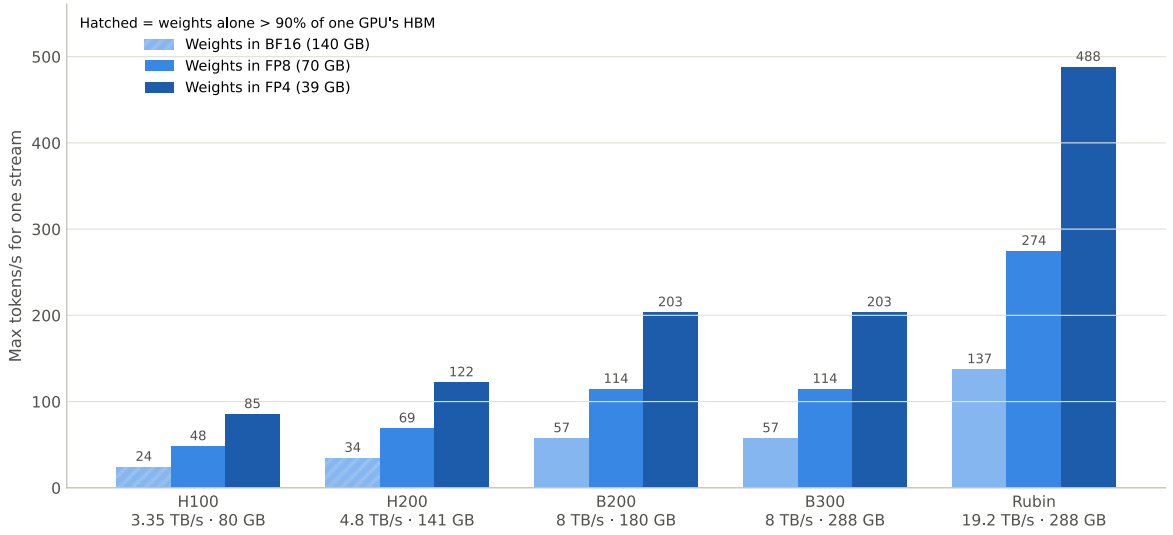


Source: data from NVIDIA specs; press [S125] [S33010] [S126] [S33009] [S127] [S33002] …; chart by repo · As of 2026-11-05

条形图：英伟达各代 GPU 的单卡 HBM 带宽：P100 0.73 TB/s，V100 0.9，A100 2.0，H100 3.35，H200 4.8，B200 和 B300 为 8，Rubin 19.2 TB/s（2026 年末由发布时 22 TB/s 的目标下调），2027 年路线图中的 Rubin Ultra 约 32 TB/s；从 P100 到 Rubin 增长 26 倍。

One Llama 3.1 70B stream at FP8 decodes at most ~48 tokens/s on H100, ~274 on Rubin

Upper bound on single-stream decode = HBM bandwidth ÷ weight bytes read per token, tokens/s per GPU (batch 1, KV reads ignored)



Source: data from NVIDIA specs; Meta Llama 3.1 config; repo calculation [S33002] [S32002] [S33003] [S32004] [S33005] [S33006] …; chart by repo · As of 2026-11-05

分组条形图：每 GPU 运行单条 Llama 3.1 70B 流时解码速度的带宽上限：FP8 权重下，H100（3.35 TB/s）约 48 tokens/s，H200（4.8 TB/s）69，B200 和 B300（8 TB/s）114，Rubin（19.2 TB/s）274；BF16 下这些数字减半，FP4 下大约翻倍。阴影条表示仅权重就超过 GPU 内存 90% 的情形。

提示

算例 —— 单条 Llama 3.1 70B 流：H100、B200 与 Rubin 对比。

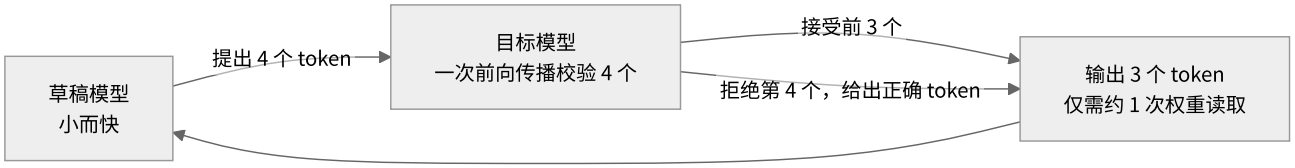
GPU	HBM 带宽	BF16 权重（140 GB）	FP8（70 GB）	FP4（~39 GB）
H100	3.35 TB/s [S33002]	~24 tok/s（80 GB 中放不下）	~48	~85
B200	8 TB/s [S33003]	~57	~114	~203
Rubin	19.2 TB/s [S33005,S33007]	~137	~274	~488

以上为批大小为 1 时的上限（忽略 KV 读取、额外开销和多 GPU 拆分）。Rubin 相对 H100 ~5.7× 的带宽 是其解码更快的主要原因；而英伟达在 2026 年下半年把 Rubin 的标称带宽从 22 TB/s 下调至 19.2 TB/s [S33007,S33008]，使这一上限降低 ~13%（🟡 有报道）。

格式	每权重位数	相对 BF16 的内存	硬件支持	质量风险
BF16	16	1×	所有现役 GPU	基准
FP8	8	0.5×	Hopper 及之后的张量核心 S33002	采用张量级缩放时较小
NVFP4	~4.5（含缩放因子）	~0.28×	Blackwell 和 Rubin 张量核心 S32017	需要块级缩放；因模型而异

6. 推测解码：提前猜测

机制。 由一个小而便宜的*草稿*模型提出接下来的若干个 token；大模型随后在**一次**前向传播中校验所有这些 token（这看起来像一次短的预填充，因此对算力友好），并保留最长的正确 前缀。输出分布在数学上与大模型完全一致 S32013。由于解码受 内存限制，校验四个 token 所需的权重读取量与生成一个 token 大致相同。



> **提示**
>
> **算例 —— 它为何有效。** 如果目标模型平均接受每 4 个草稿 token 中的 3 个，并且每次校验还会额外给出 一个正确 token，那么每一次昂贵的 70 GB 权重读取就能产出 ~4 个 token，而不是 1 个。草稿模型和 校验的开销会抵消其中一部分，这就是原论文报告的提速为 **2–3×** 而非 4× 的原因 S32013。在大批次下收益会缩小，因为此时 GPU 已更接近算力受限。

7. 推理中的混合专家模型

MoE 模型把每个 token 路由到少数几个专家子网络。DeepSeek-V3 拥有 671B 参数，但每个 token 只激活 37B S34007。对推理而言，这把两个瓶颈拆分开来：

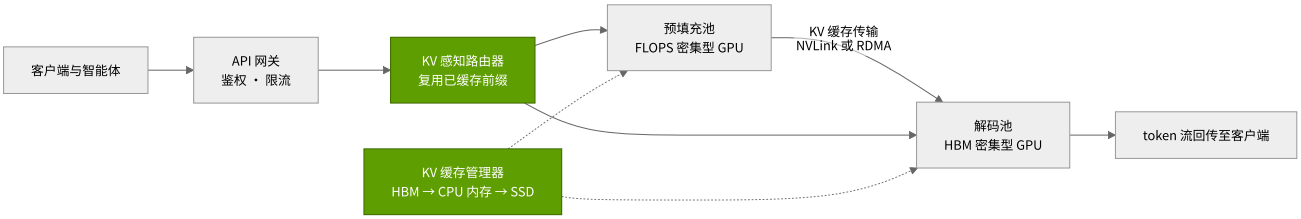
- **每 token 的计算量**与一个 37B 模型相当（便宜）。
- **内存**必须容纳全部 671B 参数：FP8 下 ~671 GB，在计入任何 KV 缓存之前就超过两块 288 GB GPU 的容量。
- **流量：** 在每个 MoE 层，token 都要被分发到其他 GPU 上的专家并再汇总回来（*全交换（all-to-all）*通信）。 DeepSeek 自己的解码部署把专家分布在 320 块 GPU 上 S34007。

> **提示**
>
> **算例 —— 为何 MoE 偏好大型 NVLink 域。** 在小批次下，每个 token 只涉及 ~37B 参数（FP8 下 ~37 GB）， 因此单条流的解码速度几乎与 37B 稠密模型相当。在大批次下，不同 token 命中不同专家， 每一步几乎要读取全部 671 GB，于是吞吐量取决于多块 GPU 的总带宽以及它们之间的全交换网络。 一个 72 GPU 的 NVLink 域可以让全交换通信保持在最快的链路上；而 8 GPU 服务器则会把它推到 较慢的横向扩展网络上。这就是英伟达声称 GB200 NVL72 配合 Dynamo 可服务多达 30× DeepSeek-R1 请求 （🟡 厂商说法）S32015背后的机制；参见第 05 层。

8. 预填充与解码分离

由于预填充受算力限制而解码受带宽限制，在同一批 GPU 上同时运行两者会相互干扰： 一次长时间的预填充会拖慢所有用户的解码步骤。**分离式服务**把两者放在不同的 GPU 池上运行，并在两者之间传输 KV 缓存；DistServe 展示了这种拆分对有效产出的好处 S32014，英伟达的开源 Dynamo 框架（GTC 2025）则以 KV 感知路由将其产品化 S32015。英伟达随后尝试针对每个阶段专门设计*硬件*， 而且其计划变化很快：

- **预填充：** Rubin CPX——一款以 128 GB GDDR7 替代 HBM、面向算力受限的上下文阶段的 GPU——于 2025 年 9 月发布，计划 2026 年底推出 S33023，随后从 GTC 2026 路线图中撤下 S115；英伟达表示该产品被推迟， 以便集中精力于解码 S116。据报道，一款采用 HBM4 的重新设计版本目标为 1Q27（🟡 分析师说法，英伟达未确认） S117。
- **解码：** 在完成 ~$20B 的 Groq 授权与收购式招聘之后，英伟达把 Groq 3 LPU（LP30）加入 Vera Rubin 平台： 每颗芯片 ~500 MB 片上 SRAM、带宽 ~150 TB/s，每个 LPX 机架 256 颗芯片，据英伟达称自 Q3 2026 起出货（🟡 有报道） S113,S114。



提示

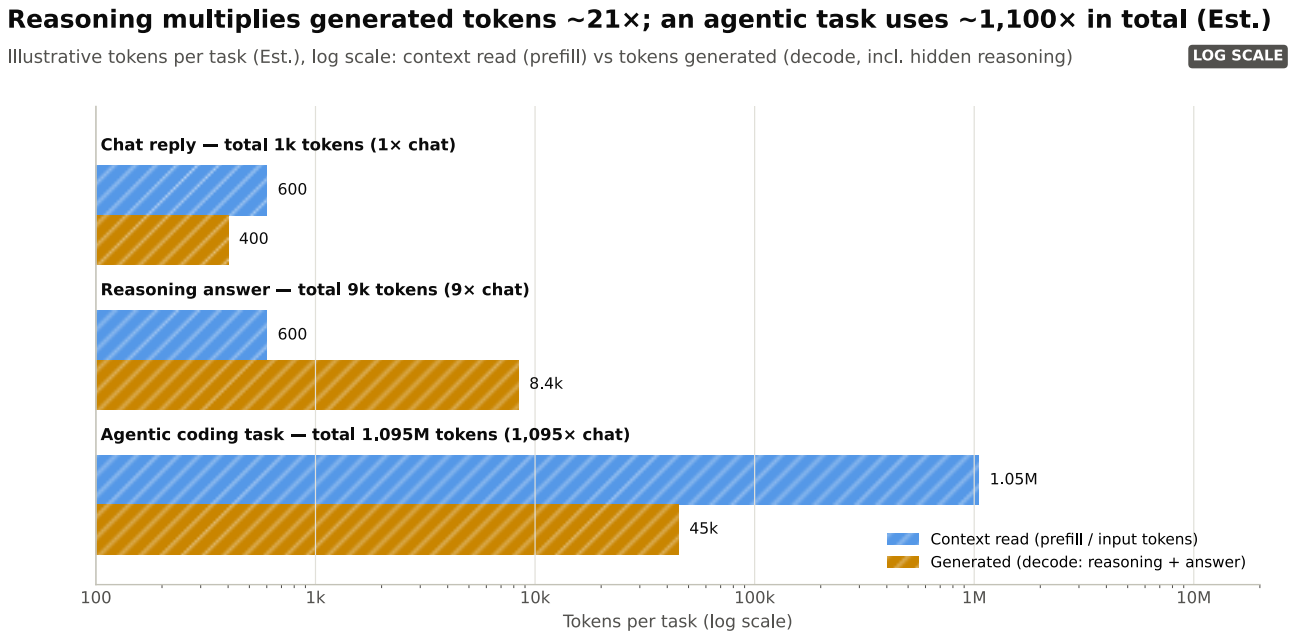
算例 —— 估算 KV 交接的数据量。 Llama 3.1 70B 上一个 8,000 token 的提示词会产生 8,000 × 0.33 MB ≈ **2.6 GB** 的 BF16 KV 缓存（FP8 下为 1.3 GB）[S32006]。要在 ~10 ms 内把它从预填充 GPU 传到解码 GPU，需要 ~130–260 GB/s：通过 NVLink 绰绰有余，通过单个 400 Gb/s（50 GB/s）网络端口则相当吃紧。因此，分离式架构会把推理也拉向训练所使用的同类高速网络。

提示

算例 —— 英伟达为何想要一颗 SRAM 解码芯片。 解码速度 = 带宽 ÷ 每 token 字节数（见第 5 节）。Groq 3 LPU 的片上 SRAM 可提供 ~150 TB/s，约为 Rubin GPU 19.2 TB/s HBM4 带宽的 ~8× [S114,S33005]，但每颗芯片仅能容纳 ~0.5 GB。因此 FP8 精度的 Llama 3.1 70B（70 GB）必须分布在 ~140 颗芯片上，占用一个 LPX 机架 128 GB SRAM 的一半以上 [S114]。这是以极小的单芯片容量换取极高的每字节带宽：对于能装得下的模型，其低延迟解码表现极佳；但对于庞大的 KV 缓存和长上下文则表现不佳，后者仍然需要 HBM。

9. 推理模型、测试时计算、智能体与 token 需求

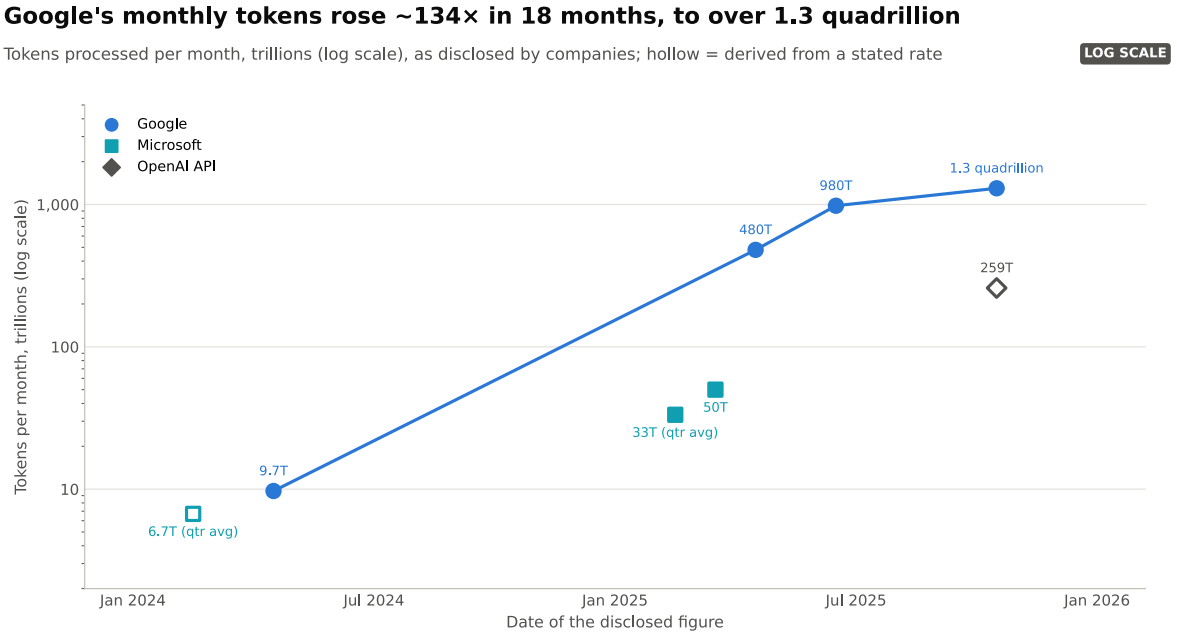
推理模型会先思考再回答：它们生成用户看不到的隐藏思维链 token，但这些 token 按输出计费，并消耗解码时间 [S32024]。OpenAI 建议在起步阶段为推理加输出预留至少 25,000 个 token [S32024]。为获得更好的答案而在每个问题上投入更多推理算力，被称为 测试时计算。**智能体**则循环运行：规划、调用工具、读取结果、重新读取不断增长的 上下文、再次决策，因此一项任务可能涉及数十次模型调用。



示意性对数坐标条形图：每项任务的 token 数：一次聊天回复读取约 600 个 token、生成 400 个；一次推理回答生成约 8,400 个（大部分是隐藏思考），多出 21 倍；一次 30 轮的智能体编程任务重读约 105 万个上下文 token、生成约 4.5 万个，约为聊天总量的 1,095 倍。

提示

算例 —— 每项任务的 token 数（示意，估计）。 一次聊天回复：读取 ~600 个 token，生成 ~400 个。对同一问题的 推理回答：同样读取 600 个，但会生成 ~8,000 个隐藏推理 token 加 400 个 token 的答案，**生成 token 数约为 ~21×**。一个上下文从 10k 增长到 60k token 的 30 轮编程智能体，会重读 ~1.05M 个 token 并 生成 ~45k 个，**约为聊天总量的 ~1,100×** [S32025]。前缀缓存可以降低重读成本，但生成的 token 需要按全价进行解码。英伟达 CEO 在 GTC 2025 上表示，推理和智能体 AI 所需的 计算量轻松达到一年前预期的 100×（🟡 厂商说法）[S33020]。



对数坐标图：已披露的 AI token 用量：谷歌从每月 9.7 万亿 token（2024 年 4 月）增至 480 万亿（2025 年 4 月）、约 980 万亿（2025 年年中）以及超过 1.3 千万亿（2025 年 10 月），18 个月增长约 134 倍。微软在 2025 年 1-3 月处理了超过 100 万亿 token（为一年前的 5 倍），仅 3 月就达 50 万亿；OpenAI 的 API 在 2025 年 10 月约每分钟处理 60 亿 token，约合每月 259 万亿。

披露方	数据	日期	来源
谷歌，全部产品	9.7T tokens/月 → 480T（~50×）	2024 年 4 月 → 2025 年 4 月	S32018
谷歌	~980T tokens/月	2025 年年中	S32019
谷歌	超过 1.3 千万亿 tokens/月	2025 年 10 月	S32020
微软	2025 年 1–3 月处理 100T+ token（同比 5×）；仅 3 月即 50T	2025 年 4 月	S32021
OpenAI API	每分钟 ~6B token（每月 ~259T）	2025 年 10 月	S32022

提示

算例 —— 每月 1.3 千万亿 token 在硬件上意味着什么。 1.3×10^{15} token ÷ 每月 2.59M 秒 ≈ 平均 **500M tokens/s**。按本篇模型给出的数字——B200 节点在每用户 100 tokens/s 下运行 70B 稠密模型时每 GPU ~5,000 tokens/s——这相当于 ~100,000 颗加速器满负荷运行（🔴 仅为示意：谷歌 在很大程度上用自研 TPU 承担这部分负载，模型规模各异，且峰值负载高于平均值）。

注

🐂 **看多观点。** 仅谷歌一家，token 需求在 18 个月内就增长了 ~134× [S32018,S32020]；推理模型和智能体使 每项任务的 token 数成倍增加；客户为之付费的每一点交互速度，都有利于最新、带宽最高的英伟达机架。 推理将成为规模更大的经常性市场，而英伟达的软件（Dynamo、TensorRT-LLM）会进一步放大其硬件领先优势。

注意

🐻 **看空观点。** 推理会拆分为大量小型、彼此独立的作业，并不需要英伟达的同步网络； 而每 token 成本很容易进行基准测试，因此买家可以多源采购。超大规模云厂商已在自研芯片上运行大量 负载（🟡 谷歌的自有模型主要在 TPU 上提供服务），而效率提升（MoE、MLA、FP4、蒸馏）会削减每 token 所需的硬件，其速度可能快于需求增长。

与各层的关联

- **第 02 层 · GPU 芯片：** FP8/FP4 张量核心，以及决定预填充与解码性能的 FLOPS 与带宽之间的平衡。
- **第 03 层 · 内存与封装：** HBM 带宽是解码的 上限，HBM 容量是 KV 缓存的预算；HBM4 是 Rubin 的核心故事。
- **第 04 层 · CPU（Grace、Vera）：** 一致性 CPU 内存可作为 KV 缓存的溢出层。
- **第 05 层 · 纵向扩展（NVLink）：** 在 NVL72 域内以张量并行和专家并行 方式服务大模型与 MoE 模型。
- **第 06 层 · 横向扩展网络**与 **第 07 层 · DPU、SuperNIC、存储：** 分离式服务中的 KV 传输， 以及把 KV 卸载到存储。
- **第 08 层 · 系统与 AI 工厂：** 机架级系统、LPX 解码机架，以及不断调整的预填充硬件计划。
- **第 11 层 · 推理与 AI 软件：** TensorRT-LLM、Dynamo、NIM， 以及开源替代方案（vLLM、SGLang）。
- **第 12 层 · 编排与云服务：** 跨集群的自动扩缩容与 路由。
- 经济学：第 14 章 · 训练与推理经济学； roofline 直觉：P3；多 GPU 拆分：P4。

需要记住的关键数字

指标	数值	来源
单条流的解码上限	≈ HBM 带宽 ÷ 每 token 读取字节数	S33013
Llama 3.1 70B FP8，批大小 1	H100 上 ⩽ ~48 tok/s · B200 上 ~114 · Rubin 上 ~274	S33002,S33003,S33005
每 token KV 缓存，Llama 3.1 70B（BF16）	~0.33 MB（2 × 80 层 × 8 个 KV 头 × 128 × 2 B）	S32006
128k token 时的 KV 缓存，同一模型	每个对话 ~43 GB（无 GQA 时为 344 GB）	S32006,S32010
MLA 对 KV 缓存的缩减（DeepSeek-V2）	−93.3%，最大生成吞吐量 5.76×	S32026
连续批处理 + PagedAttention	同等延迟下吞吐量提高 2–4×	S32011
推测解码（原论文）	提速 2–3×，输出完全相同	S32013
DeepSeek-V3 激活参数与总参数	671B 中激活 37B	S34007
谷歌每月 token 量	9.7T（2024 年 4 月）→ 1.3 千万亿（2025 年 10 月）	S32018,S32020
微软 token 量，2025 年 1–3 月	100T+，同比 5×	S32021

🎯 企业发展视角

1. **真正重要的指标是给定延迟目标下的每 token 成本**。 每一项厂商宣称都应对应到吞吐量–交互速度前沿上的 某一个点。在采信任何“便宜 10×”的说法之前，应要求竞争对手（以及英伟达）提供完整曲线，而非单一峰值。
2. **内存是兵家必争的资源**。 解码受带宽和 KV 容量限制，因此 HBM 供应（第 03 层）和 内存分层（CPU 内存、CXL、SSD 卸载）是推理价值池所在。哪些内存层级和 KV 缓存 软件公司可能对一份以推理为重点的数据中心路线图至关重要?
3. **分离式架构为异构集群打开了大门**。 一旦预填充和解码运行在不同的资源池上， 非英伟达加速器无需两者兼得，只需赢下其中一个阶段即可。英伟达显然也看到了同样的拆分：它发布了一款 预填充 GPU（Rubin CPX）[S33023]，随后将其从 GTC 2026 路线图中撤下 [S115]，接着又据报道斥资 ~$20B 把 Groq 基于 SRAM 的解码架构 收入囊中 [S113]。对挑战者而言，最现实的切入点是解码池、上下文池，还是路由/调度软件? 还有多少专注解码的初创公司保持独立?
4. **效率技术正在快速商品化**。 连续批处理、分页 KV、推测解码和 FP8 都是开放的， 且已被广泛实现 [S32011,S32013]；差异化正在向机架级系统和集群级软件迁移。谁 掌控开源推理服务层（vLLM、SGLang）及其人才，是任何加速器厂商都必须面对的战略问题。
5. **token 增长是需要跟踪的需求信号**。 谷歌 18 个月 ~134× 的增长 [S32018,S32020] 以及推理/智能体带来的 倍增效应 [S32025] 支持推理算力容量的增长；效率提升则指向相反方向。按季度跟踪 已披露的 token 用量与已部署加速器容量之比，就能看出哪一股力量占上风。

P3 · 四大瓶颈

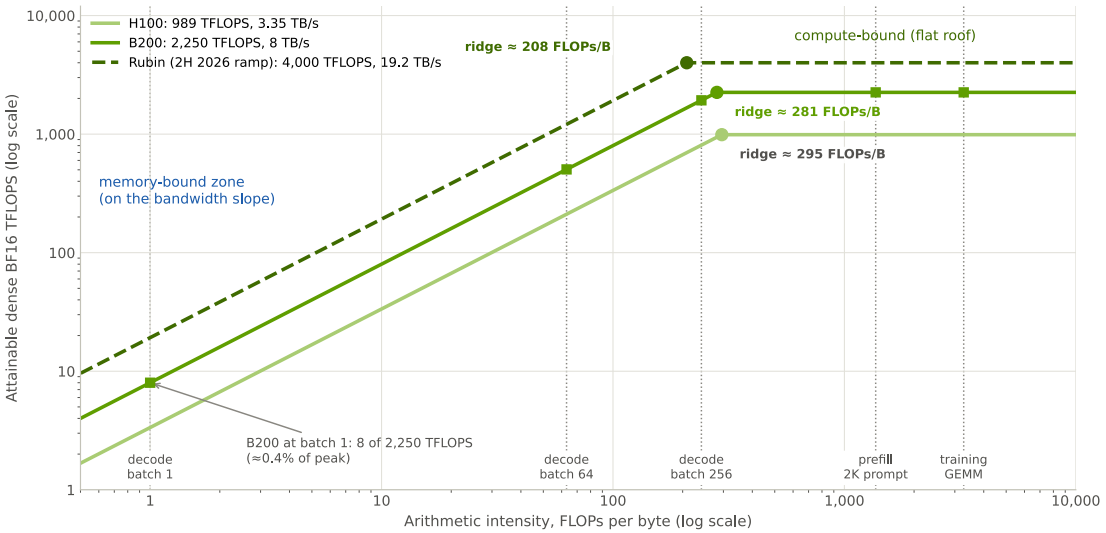
入门篇 P3 · 写给非工程师的基础知识 · 约 22 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **AI 系统的运行速度取决于四种资源中最先耗尽的那一种：** 算力（FLOPS）、内存（HBM 的带宽与容量）、互连（纵向扩展（scale-up）与横向扩展（scale-out）网络）以及电力。为一项并不构成约束的资源多花钱几乎换不来任何收益，这就是为何单看“峰值 PFLOPS”难以判断价值。
- **roofline 模型能告诉你哪一项构成约束。** 用峰值 FLOPS 除以内存带宽即可得到脊点（ridge point）：H100 在稠密 BF16 下约为 295 FLOPs/字节（989 TFLOPS ÷ 3.35 TB/s）[S33002]，B200 约为 ~281（2,250 TFLOPS ÷ 8 TB/s）[S33003]，Rubin 约为 ~208（4,000 TFLOPS ÷ 19.2 TB/s）[S33005,S33007]。每字节 FLOPs 低于该值的工作即为内存受限。
- **聊天机器人式的生成任务严重受限于内存。** 在批大小为 1 时生成一个 token，每读取一个字节的权重只做 ~1 FLOP，因此一块服务 70B 参数 BF16 模型的 B200 只用到了其 2,250 TFLOPS 中的 ~8 TFLOPS，约 0.4%（本资料库基于 [S33003,S33013] 的测算）。批处理会让工作负载在 roofline 上向右移动，直到 KV 缓存耗尽内存容量为止。
- **内存墙真实存在，但标称 FLOPS 夸大了它。** 从 V100 到 Rubin，以最低支持精度计的峰值稠密 FLOPS 增长了 ~280×，而 HBM 带宽仅增长 ~21× [S33010,S33005,S33007]；在同为 16 位精度的可比口径下，差距为 32× 对 21×。从全行业看，峰值 FLOPS 每两年增长 ~3.0×，而 DRAM 带宽为 ~1.6×，互连为 ~1.4× [S33011]。
- **按照阿姆达尔定律（Amdahl's law），通信限制了扩展能力。** 即便是 Meta 精心调优的 Llama 3 405B 训练，在最多 16,384 块 H100 上的 BF16 模型 FLOPs 利用率也只有 38–43% [S34006]；其余大部分损失在通信、流水线气泡和内存停顿上（详见 P4）。
- **电力如今是场址层面的速度上限。** IEA 估计 2024 年数据中心用电 ~415 TWh，并预测到 2030 年达到 ~945 TWh [S33015]；LBNL 测算美国数据中心 2023 年用电 176 TWh（占美国用电量的 4.4%），到 2028 年将达到 325–580 TWh [S33016]。机架功率从四台 DGX H100 系统的 ~41 kW [S33022] 升至一台 GB200 NVL72 的 ~120–132 kW [S33021]，另有报道称 2027 年的 Kyber 机架将达 🟡 ~600 kW [S35019]。
- **英伟达的优势在于同时为这四项瓶颈提供答案**（大容量 HBM 的 GPU、NVLink、InfiniBand/Spectrum-X、液冷机架以及 800 V DC 供电方案 [S33019]）。看空观点则指出：推理的约束性资源 HBM，英伟达和其他所有厂商一样都是向同样的三家存储厂商采购；而英伟达自己的 Rubin HBM4 标称带宽在 2026 年末已从 22 TB/s 下调至 19.2 TB/s [S33006,S33007]。

Batch-1 decode sits ~200-300x left of the ridge point and uses under 1% of peak FLOPS

Roofline: attainable dense BF16 TFLOPS per GPU vs arithmetic intensity (FLOPs per byte read from HBM), log-log



Source: data from NVIDIA and Lenovo spec sheets; repo arithmetic [S33002] [S33003] [S33005] [S33007] [S33013]; chart by repo · As of 2026-11-05

双对数 roofline 图（稠密 BF16）。H100：989 TFLOPS、3.35 TB/s，脊点约 295 FLOPs/字节；B200：2,250 TFLOPS、8 TB/s，脊点约 281 FLOPs/字节；Rubin：4,000 TFLOPS、19.2 TB/s，脊点约 208 FLOPs/字节。批大小为 1 的解码（约 1 FLOP/字节）位于带宽斜坡的最左侧；批大小 64（63）和 256（241）向右移动；预填充（约 1,365）和训练矩阵乘法（约 3,277）位于平坦的算力屋顶上。

从这里开始：一个有四种方式变慢的厨房

想象一个餐厅厨房。**厨师**代表算力：如果所有食材都在手边，他们每分钟能做多少道菜。**储藏室的门**代表内存带宽：食材送到操作台的速度有多快。**储藏室的大小**代表内存容量：你需要的东西是否全都在这栋楼里。**厨房之间的传菜员**代表互连：当一顿饭要由八个厨房共同完成时，盘子必须来回传递。**燃气管道**则代表电力：无论雇多少厨师，灶具能提供的热量都是有限的。

一个厨师出色但储藏室门很窄的厨房，出菜量不会超过那扇门所允许的上限。AI 硬件也是如此。GPU 的标称数字是其峰值 FLOPS（每秒浮点运算次数），但大多数 AI 负载会先撞上另外三项限制中的某一项。系统设计者——以及任何评判竞争对手宣传的人——的任务，就是追问*对于这项负载，究竟是哪种资源构成约束。*

瓶颈	衡量内容	单位	H100 → B200 → Rubin（每 GPU）	何时构成约束	英伟达的应对	最有力的替代方案
算力	每秒算术运算量	PFLOPS（稠密）	BF16 0.99 → 2.25 → 4.0 S33002,S33003,S33005	训练、预填充	张量核心；FP8 → NVFP4 数值格式 S32017	TPU 和 Trainium 的脉动阵列；晶圆级芯片（Cerebras）
内存	从 HBM 读取的每秒字节数；可容纳的 GB 数	TB/s；GB	3.35 → 8 → 19.2 TB/s；80 → 180 → 288 GB S33002,S33003,S33005,S33007	解码、长上下文、MoE 服务	更多、更新的 HBM 堆栈；借助 Rubin CPX 拆分预填充与解码 S33023（已从 GTC 2026 路线图撤下；有报道称将以 HBM4 版本回归，未经确认 🟡 S115,S117）	以 SRAM 为主的芯片（Groq、Cerebras）；基于 LPDDR 的推理卡
互连	GPU 间每秒传输字节数	TB/s（纵向扩展）；Gb/s（横向扩展）	NVLink 0.9 → 1.8 → 3.0 TB/s S34014,S33007；网卡 400 → 800 → 1,600 Gb/s S34015,S33004	大规模训练、MoE 全交换	NVLink/NVSwitch NVL72；InfiniBand 与 Spectrum-X	采用光交换的谷歌 ICI；UALink；以太网纵向扩展
电力	每芯片、每机架、每场址的瓦数	W；kW；MW	700 → 1,000 W S33002,S33003；机架 ~41 → ~120–132 kW S33022,S33021	场址建设、电网接入	液冷；800 V DC 机架 S33019	效率优先的 ASIC；选址靠近廉价电力

重要

最需要记住的一点： 负载的*算术强度*（每搬运一个字节所做的 FLOPs）决定了约束来自算力还是内存；其*通信模式*决定了它能扩展到多大规模；而*场址的电力*则从一开始就决定了你能买多少块 GPU。

1. 算力：每秒多少 FLOPs

它是什么。 现代英伟达 GPU 的大部分 AI 运算在张量核心中完成，这类单元可以一步完成小矩阵的乘法。数据手册上的大数字是*峰值*速率：即每个张量核心在每个周期都满负荷处理形状完美的数据时芯片所能达到的速度。它们取决于数值格式。位数减半，速率大约翻倍：B200 的稠密算力在 BF16 下标称 2.25 PFLOPS，在 FP8 下为 4.5，在 FP4 下为 9 S33003。英伟达的标称数字通常假设 2:4 稀疏性，这会使数字再翻一倍；除非另有说明，本资料库一律引用**稠密**数字。

为何达不到峰值。 只有在大型、形状规整、且操作数已位于片上内存中的矩阵乘法（GEMM）上，芯片才能达到峰值。真实的训练步骤还包括逐元素运算、通信等待和流水线空闲时间。业界指标是模型 FLOPs 利用率（MFU）：有效模型 FLOPs ÷ 峰值 FLOPs。英伟达自己的 Megatron-LM 团队报告，在 3,072 块 A100 上运行 1 万亿参数基准测试时达到了峰值的 52% S34002；Meta 报告 Llama 3 405B 在 H100 上的 BF16 MFU 为 38–43% S34006。

提示

算例 —— Llama 3 405B 的算力账单折合多少 GPU 天。 Meta 训练 Llama 3 405B 使用了 ~3.8×10^{25} FLOPs S34006。按其在 16,384 块 H100 上实际达到的每 GPU ~400 TFLOPS（41% MFU）S34006 计算，集群每秒提供 $16{,}384 \times 400 \times 10^{12} \approx 6.6 \times 10^{18}$ FLOPs，因此纯计算时间为 $3.8 \times 10^{25} \div 6.6 \times 10^{18} \approx 580$ 万秒 ≈ **67 天**。若换成 B200 并保持同样 41% 的 MFU（2,250 中的 ≈ 920 TFLOPS S33003）重新计算，则降至 ~29 天。**商业解读：** 每一代的算力提升都会直接转化为更短的模型产出时间，或在同样日历时间内训练更大的模型——但前提是另外三项瓶颈能够跟上，而这正是本页其余部分的主题。

🔧 技术细节：为何更低的精度是“免费”的算力——以及何时并非如此

4 位数的乘法器所需的晶体管远少于 16 位数的乘法器，因此相同的硅面积每个周期能执行更多运算；位数更少也意味着需要搬运的字节更少，这有助于缓解内存瓶颈。问题在于精度：4 位数值只有 16 个可能的取值，因此 NVFP4 等格式为每 16 个数值组成的块附加一个共享的 FP8 缩放因子，另加一个张量级缩放因子 S32017。端到端的 FP4 训练仍是活跃的研究领域，这就是为何 Rubin 分别给出 NVFP4 “训练”（35 PFLOPS）和“推理”（50 PFLOPS）两个数字 S33004。还要注意 Rubin 如何重新分配其芯片资源：稠密 FP8 为 17.5 PFLOPS，而 BF16 仅 4 PFLOPS，比值为 4.4×，而 B200 上为 2× S33005,S33003——这是押注未来大部分工作将以 8 位或更低精度运行。

2. 内存：带宽、容量与 roofline

直观理解 roofline

每一次计算都需要数据。问题在于，你每从内存中取一个字节能做多少次计算：这就是**算术强度**，单位为 FLOPs/字节。芯片的速度永远不可能超过以下两个上限中较低的那一个：

- **算力屋顶**：峰值 FLOPS，一条水平线；以及
- **带宽斜坡**：内存带宽 × 算术强度，一条斜线（更快地搬运字节，或在每个字节上做更多工作，速度就会更快）。

把两者画在双对数坐标上，就得到了 roofline，它由 Williams、Waterman 和 Patterson 于 2009 年提出 S33001。斜坡与屋顶相交的拐角就是**脊点** = 峰值 FLOPS ÷ 内存带宽。位于脊点左侧时属于内存受限：多出的 FLOPS 处于闲置状态。位于脊点右侧时属于算力受限：多出的带宽处于闲置状态。

提示

算例 —— 三代 GPU 的脊点。 用稠密峰值除以 HBM 带宽（TFLOPS ÷ TB/s = FLOPs/字节）：

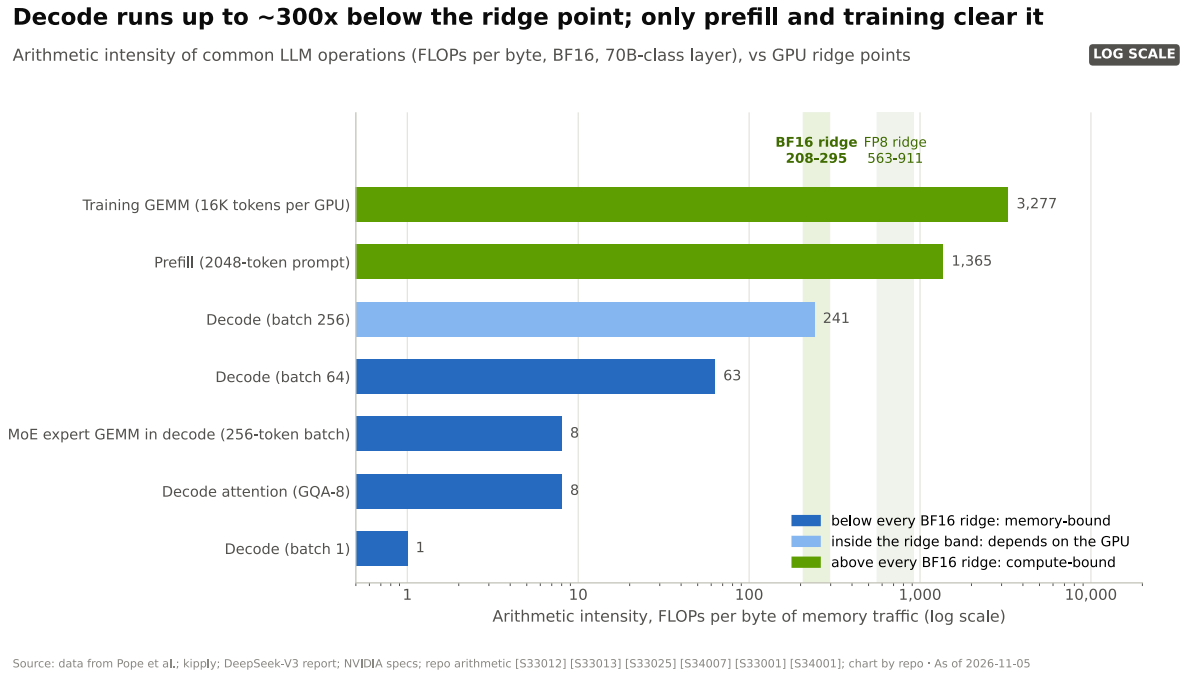
GPU	稠密 BF16	稠密 FP8	稠密 FP4	HBM 带宽	BF16 脊点	FP8 脊点	FP4 脊点
H100 SXM	989 TFLOPS	1,979 TFLOPS	—	3.35 TB/s	**295**	591	—
B200（HGX）	2,250 TFLOPS	4,500 TFLOPS	9,000 TFLOPS	8.0 TB/s	**281**	563	1,125
Rubin	4,000 TFLOPS	17,500 TFLOPS	35,000 TFLOPS（NVFP4 训练）	19.2 TB/s	**208**	911	1,823

来源：[S33002,S33003,S33005,S33004,S33007]。**解读：** 三代以来 BF16 脊点一直保持在 200–300 FLOPs/字节附近，因为英伟达让带宽与 16 位算力大致同步增长。但在 FP8 和 FP4 下，脊点*向右移动*——Rubin 需要 ~900 FLOPs/字节才能让其 FP8 单元保持满载——因此数值格式越“便宜”，就有越多的工作变为内存受限。

为何小批次解码远在脊点左侧

当语言模型生成文本（解码）时，每一步产生一个 token，而每一步都必须从 HBM 中读取模型的*每一个*权重。每个参数对每个 token 约做两次 FLOPs（一次乘法、一次加法），而在 BF16 下每个参数占两个字节。因此在批大小为 1 时，算术强度约为 ~2 FLOPs ÷ 2 字节 ≈ **1 FLOP/字节**——比脊点低了两三百倍[S33012,S33013]。

批处理是解决之道：如果 64 个用户的请求被一起处理，权重只需读取一次就能使用 64 次，算术强度因此升至 ~63 FLOPs/字节；批大小为 256 时达到 ~241，接近 H100 和 B200 的脊点（本资料库基于[S33013]中 GEMM 公式的测算）。相比之下，预填充——读取一个 2,048 token 的提示词——本身就为每次矩阵乘法提供了 2,048 行（~1,365 FLOPs/字节），而每 GPU 处理 16K token 的训练 GEMM 约为 ~3,300，稳稳处于算力受限区间[S33025]。



对数坐标横向条形图：各类负载的算术强度：批大小为 1 的解码约 1 FLOP/字节，解码阶段的注意力和 MoE 专家矩阵乘法约 8，批大小 64 的解码 63，批大小 256 的解码 241，2,048 token 的预填充 1,365，训练矩阵乘法 3,277。H100、B200 和 Rubin 的 BF16 脊点介于 208 至 295 FLOPs/字节之间，FP8 脊点介于 563 至 911 之间，因此只有预填充和训练能越过脊点。

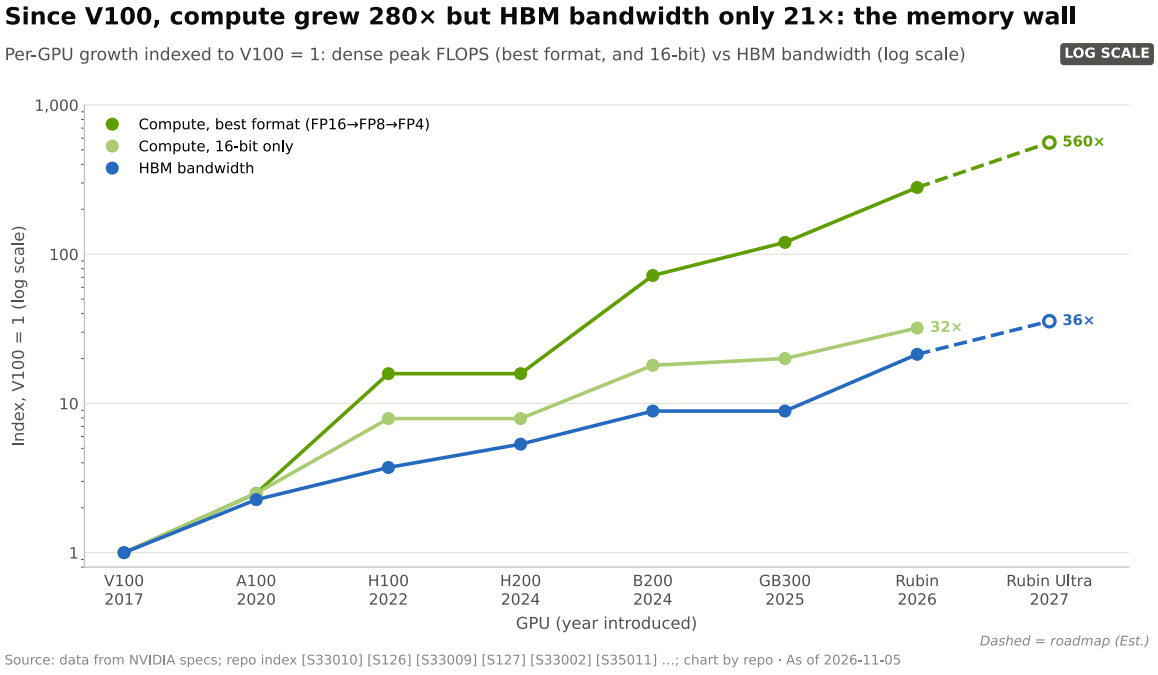
有两类运算*不会*因批处理而改善。**解码阶段的注意力**读取的是每个用户各自的 KV 缓存，因此其强度由模型结构决定——对于 64 个查询头共享 8 个键/值头的模型，约为 8 FLOPs/字节[S33013,S32027]。而在**混合专家模型**中，每个专家只处理路由给它的 token：以 DeepSeek-V3 为例，共 256 个路由专家、每个 token 激活 8 个[S34007]，一个 256 token 的批次分到每个专家只有 ~8 个 token，因此其矩阵乘法的强度又回到 ~8 FLOPs/字节。MoE 节省了 FLOPs，却让服务*更加*受限于内存。

提示

算例 —— 服务一个 70B 参数模型：批大小 1 与批大小 256。 **批大小 1。** 在 BF16 下，权重为 70B × 2 字节 = 140 GB。每生成一个 token 都必须从 HBM 中流式读取全部 140 GB，因此上限为带宽 ÷ 140 GB：一块 H100（80 GB）装不下该模型，因此由两块 H100 拆分承载，速度 ⩽ 2 × 3.35 TB/s ÷ 140 GB ≈ **48 tokens/s**；一块 B200（180 GB）可达 ⩽ 8 ÷ 0.14 ≈ **57 tokens/s**；一块 Rubin ⩽ 19.2 ÷ 0.14 ≈ **137 tokens/s** [S33002,S33003,S33005,S33007]。所用算力：57 tokens/s × 每 token 140 GFLOPs ≈ 8 TFLOPS，仅占 B200 2,250 TFLOPS 的 **0.36%**。 **批大小 256。** 现在同样 140 GB 的读取可服务 256 个用户：理论上 B200 可达 ~14,600 tokens/s，使用 ~2.0 PFLOPS，约为 BF16 峰值的 ~91%。但每个用户的 KV 缓存需要 2 × 80 层 × 8 个 KV 头 × 128 维 × 2 字节 ≈ **每 token 0.33 MB** [S32027]，因此 256 个用户 × 4,096 token 的上下文需要 ~344 GB 的 KV 缓存——而可用空间只有 180 − 140 = 40 GB。40 GB 可容纳 ~122,000 个 token，即在 4K 上下文下 ~30 个用户。**构成约束的是容量，而非带宽或算力。** 把权重量化为 FP8（70 GB）可腾出 ~110 GB，足以容纳 ~80 个用户；Rubin 的 288 GB [S33005] 又能使这一数字大约再翻一倍。这就是每一次“每 GPU 更多 HBM”发布背后的经济逻辑。

内存墙

内存墙指的是这样一个现象：处理器的提速远快于内存为其供给数据的速度。Gholami 等人测算，在二十年间，服务器峰值 FLOPS 每两年增长 ~3.0×，而 DRAM 带宽为 ~1.6×，互连带宽为 ~1.4× [S33011]。英伟达自己的旗舰产品也呈现出相同的规律：



以 V100 = 1 为基准的对数坐标指数图：到 Rubin 时，以最佳支持格式计的稠密算力是 V100 的 280 倍，16 位算力是 32 倍，而 HBM 带宽仅提高 21 倍，因此每一字节的内存带宽必须支撑多得多的运算——正是这堵内存墙使 LLM 解码受限于带宽。

读这张图时要小心，因为它的含义是双向的。从 V100 到 Rubin，低精度 FLOPS 增长了 ~280×，但其中很大一部分来自数值格式的缩小（FP16 → FP8 → FP4），而这每一次*也*都使每个参数的字节数减半——因此实际的墙比标称差距更窄。在同为 16 位精度的可比口径下，算力增长 ~32×，带宽增长 ~21× [S33010,S33005,S33007]。容量增长最慢（~9×，32 GB → 288 GB），这就是为何长上下文和智能体负载越来越多地先撞上容量墙、而非带宽墙。



内存层级每下降一级，可容纳的数据更多，但传输速度大约慢一个数量级；AI 软件的艺术就在于让工作集尽可能停留在这架梯子的高处（H100 L2 容量 [S33024]；HBM 与 NVLink 数据 [S33002,S33005,S33007,S34014]；网卡速率 [S34015]）。

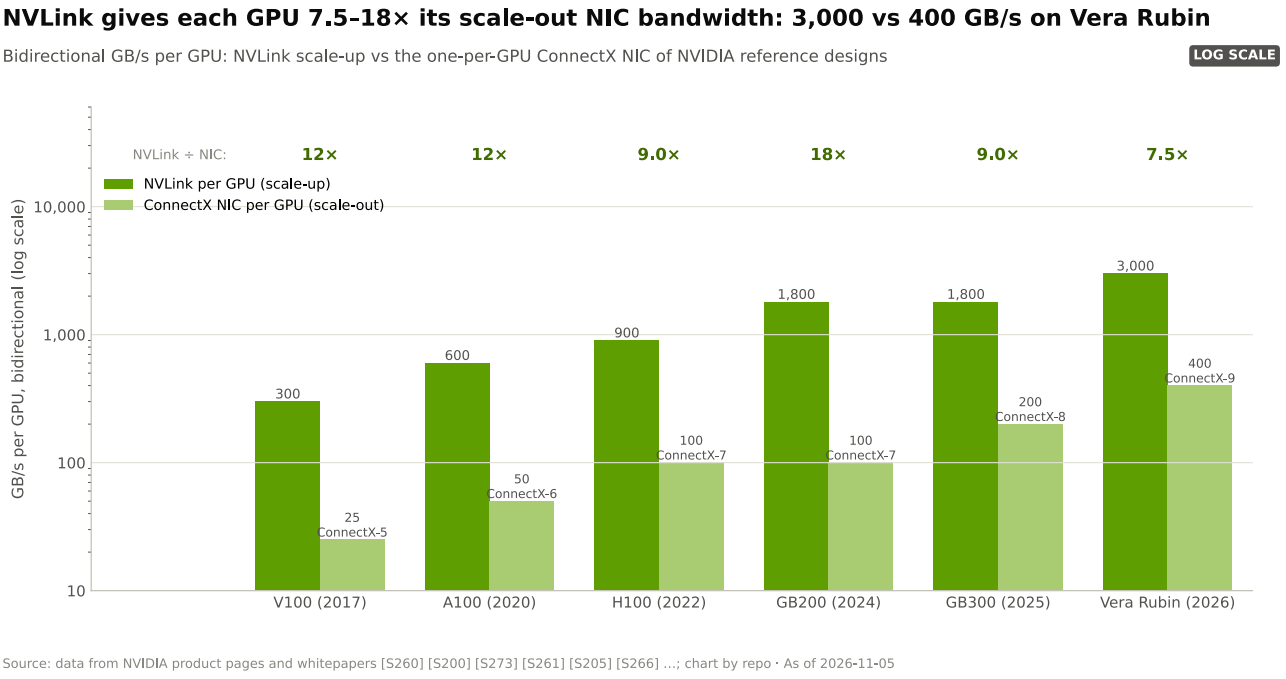
🔧 **技术细节：HBM 为何快，又为何贵**

HBM 把 DRAM 裸片垂直堆叠，并通过硅中介层把这些堆栈放置在距 GPU 仅几毫米的位置，以极宽的总线相连；一个 Rubin 封装搭载八个 HBM4 堆栈 [S33006]。使其快速的是位宽而非时钟频率——而堆叠、硅通孔和先进封装则是其昂贵的原因（参见 P5 和第 03 层）。由此带来两个实际后果：每 GPU 的 HBM 容量随堆栈数量和堆叠高度阶梯式增长；而发布时看似可以实现的 HBM 引脚速率在量产中可能会打折扣——这很可能就是英伟达把 Rubin 标称带宽从 22 TB/s 改为 19.2 TB/s 的原因，英伟达对此的说法是从初步目标调整为系统在量产中可持续达到的水平（🟡）[S33007,S104,S33008]。

> **注意**
>
> **误区与事实：**“Rubin 的 FP8 FLOPS 是 Blackwell 的 4×，所以它服务聊天机器人的速度也快 4×。”小批次解码受 HBM 带宽约束，而带宽只从 8 → 19.2 TB/s（2.4×），并不受 FLOPS 约束 [S33003,S33007]。推理基准测试上的大幅提升来自带宽、容量、更大的 NVLink 域、更低精度的权重以及软件（批处理、推测解码、分离式服务）的综合作用——而非仅靠 FLOPS。

3. 互连：纵向扩展、横向扩展与阿姆达尔定律

它是什么。 一旦一个模型或一项作业跨越多块 GPU，数据就必须在 GPU 之间移动。在机架内部，英伟达通过 NVSwitch 芯片以 NVLink 连接各 GPU——这就是**纵向扩展**域，其表现几乎如同一块巨型 GPU。在机架之间，每块 GPU 都通过各自的网卡接入 InfiniBand 或以太网**横向扩展**网络。每跨越一道边界，带宽就会急剧下降：一块 B200 读取自身 HBM 的速度为 8 TB/s [S33003]，访问 NVL72 中其余 71 块 GPU 的速度为 1.8 TB/s（每个方向 900 GB/s）[S34014]，而访问其他机架中的 GPU 则要通过其自身 400–800 Gb/s 的网卡，即每个方向 50–100 GB/s [S34015]（Rubin 搭配 ConnectX-9 时为每 GPU 1.6 Tb/s [S33004]）。这大致是先下降约 10×，再下降 ~8–18×。



Source: data from NVIDIA product pages and whitepapers [S260] [S200] [S273] [S261] [S205] [S266] …; chart by repo · As of 2026-11-05

分组对数坐标条形图：比较每 GPU 的 NVLink 与网卡带宽：V100 300 对 25 GB/s，H100 900 对 100，GB200 1,800 对 100（18 倍），GB300 1,800 对 200，Vera Rubin 3,000 对 400 GB/s（7.5 倍）：纵向扩展域的带宽始终比横向扩展高出约一个数量级。

一项负载受影响的程度，取决于它必须交换*什么*以及*多频繁*——梯度每个训练步交换一次，激活值每一层交换一次，发往专家的 token 每个 MoE 层交换一次。P4 · 并行方式详解会逐一分析每种模式；这里要说明的是制约所有模式的一般规律。

阿姆达尔定律（1967 年）指出，如果一项作业中有一部分无法通过增加处理器来加速，那么这部分就会限制总加速比 [S33014]：若有 5% 的串行工作，无论用多少处理器都无法突破 20×。在 AI 集群中，“串行”部分通常是*暴露的通信*——即 GPU 等待那些无法与计算重叠的数据的时间。

> **提示**
>
> **算例 —— 为何集群规模翻倍并不能让训练时间减半。** 假设一个训练步需要 10 s 的计算，外加 1 s 无法隐藏的通信。把同一作业分摊到更多 GPU 上（总批大小不变）：计算时间缩短，通信时间不变。

GPU 数（相对值）	每步计算	暴露的通信	单步时间	扩展效率	相对 ×1 的加速比
×1	10.0 s	1.0 s	11.0 s	91%	1.0×
×2	5.0 s	1.0 s	6.0 s	83%	1.8×
×4	2.5 s	1.0 s	3.5 s	71%	3.1×
×8	1.25 s	1.0 s	2.25 s	56%	4.9×
×8，网络速度提高 2×	1.25 s	0.5 s	1.75 s	71%	6.3×

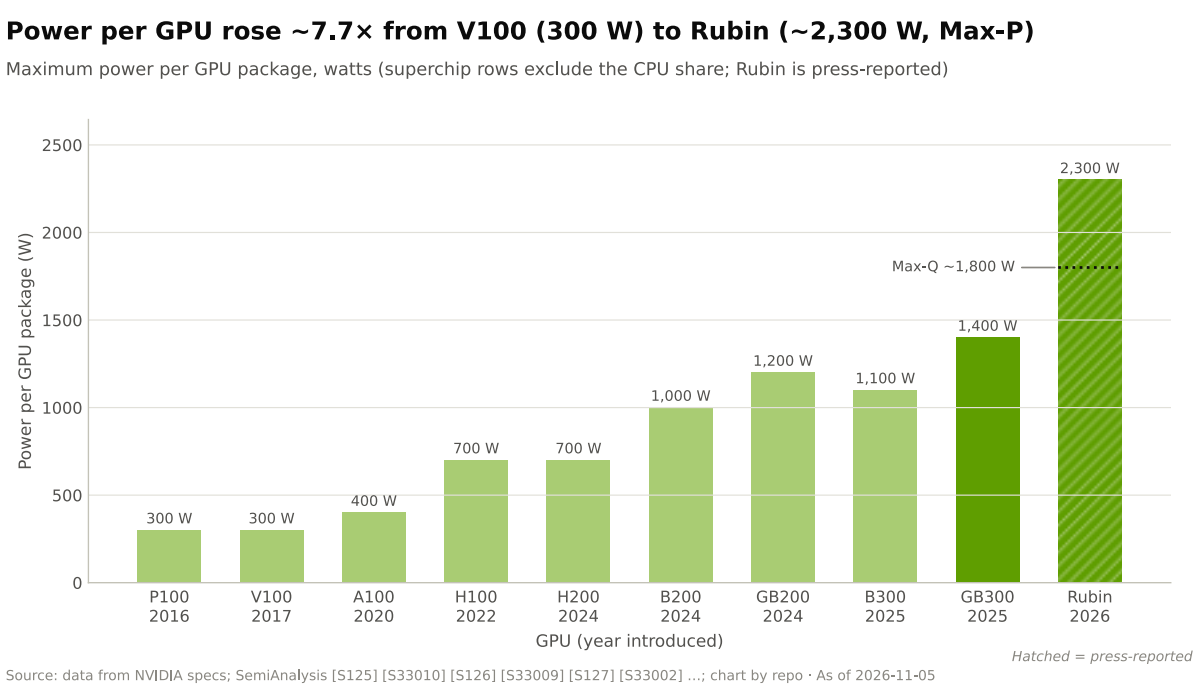
> 数字仅为示意；公式来自阿姆达尔 [S33014]。**商业解读：** 在 ×8 时，最后一次 GPU 数量翻倍只换来 ~1.6× 的提速，而在 GPU 数量不变的情况下把网络速度翻倍，又能多换来 ~1.3×。这从量化角度说明了为何应投资于网络、而不只是购买更多 GPU——也是英伟达把 NVLink、网卡和交换机与 GPU 捆绑销售的原因。

可靠性也是互连瓶颈的一部分。 同步训练作业以其最慢的 GPU 的速度运行，并在任何 GPU 或链路发生故障时停止。Meta 在 Llama 3 为期 54 天的快照中记录了 466 次作业中断，其中 419 次为意外中断，且大多与硬件相关 [S34006]——在 16,384 块 GPU 上约每三小时一次 [S31003]。集群越大，花在检查点和重启上的时间就越多，这也是实际 MFU 停留在 40% 左右的另一个原因。

> **🔧 技术细节：带宽并非唯一的指标——延迟与网内计算**
>
> 对于大消息（梯度、KV 缓存传输），带宽起主导作用；而对于张量并行推理或 MoE 路由中的大量小消息，单条消息的延迟和拥塞表现同样重要。英伟达有两项技术专门针对这一点：**SHARP** 在 InfiniBand（及 NVLink）交换机内部执行规约运算，从而减少数据穿越网络的次数 [S34024]；Spectrum-X 以太网中带拥塞控制的自适应路由则试图在以太网上实现接近 InfiniBand 的尾延迟（参见第 06 层）。竞争性设计做出了不同的取舍——谷歌的 TPU pod 采用环面（torus）拓扑的芯片间直连链路配合光路交换机，而非交换式网络（参见第 05 层）。

4. 电力：每芯片的瓦、每机架的千瓦、每场址的兆瓦

芯片。 板卡功耗每一代都在攀升：V100 为 300 W [S33010]，A100 为 400 W [S33009]，H100 为 700 W [S33002]，HGX B200 为 1,000 W [S33003]。能效提升得更快：稠密 16 位每瓦 TFLOPS 从 ~0.42（V100）升至 ~1.41（H100）再到 ~2.25（B200）——约 5.4×——而单芯片功耗上升 ~3.3×（本资料库基于相同来源的测算）。Rubin 更进一步：据报道每 GPU 的功耗档位约为 ~1.8 kW（Max-Q）和 ~2.3 kW（Max-P）（🟡）[S106]。因此，每块 GPU 每瓦完成的工作多得多，但每个机架消耗的电力也多得多。



条形图：英伟达 GPU 封装功耗：P100 和 V100 为 300 W，A100 400 W，H100 和 H200 700 W，B200 1,000 W，GB200 1,200 W，B300 1,100 W，GB300 1,400 W，Rubin 在其报道的 Max-P 档位下约 2,300 W（Max-Q 为 1,800 W），约为 V100 的 7.7 倍。

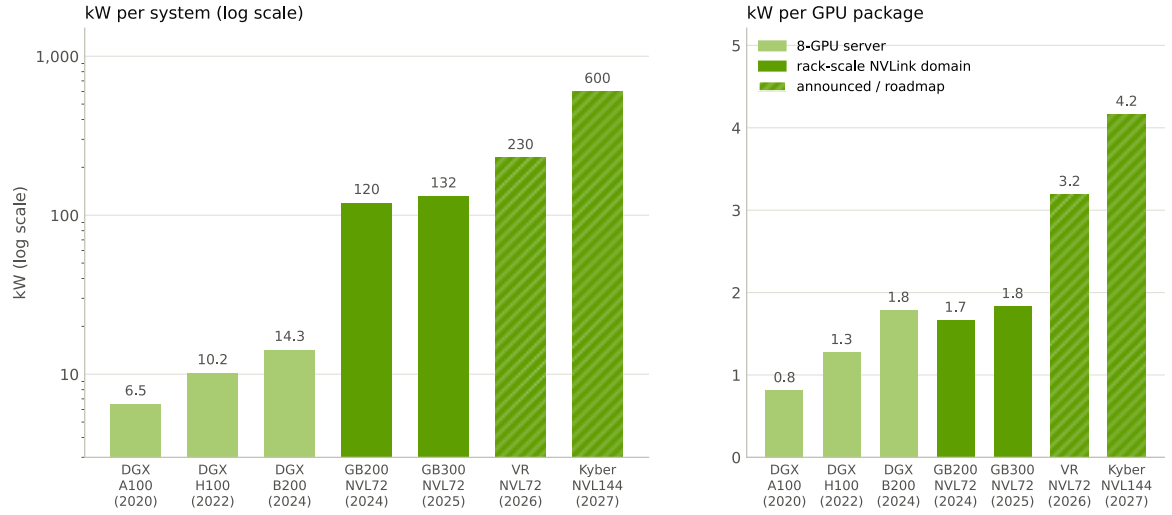
机架。 高密度机架需要液冷，因为空气已无法带走这么多热量。

时期	示例配置	每机架功率	冷却方式	状态
Hopper（2022 年起）	四台 DGX H100 系统（每台 8 块 GPU，最大 ~10.2 kW）	~41 kW	风冷	🟢 单系统数据 [S33022]；机架合计为本资料库测算
Blackwell（2024 年起）	GB200 NVL72（72 块 GPU、36 颗 Grace CPU）	~120–132 kW	直接液冷	🟡 [S33021]
Rubin（2026 年下半年爬坡）	Vera Rubin NVL72	~190–230 kW	直接液冷	🟡 有报道，基于 ~1.8–2.3 kW 的 GPU 功耗档位 [S106]
Rubin Ultra（2027 年下半年）	Kyber 机架（NVL144 封装；GTC 2025 上称为 NVL576）	~600 kW	直接液冷，800 V DC	🟡 [S35019]
2027 年及以后	800 V DC 机架供电架构	每机架最高 ~1 MW	液冷	🟢 设计目标 [S33019]

One NVIDIA scale-up domain draws ~600 kW by 2027, vs 10.2 kW for an 8-GPU DGX H100

kW per system (left) and per GPU package incl. CPUs and switches (right); hatched = not yet shipping

LOG SCALE



Source: data from NVIDIA datasheets, SemiAnalysis and press reports via system_specs.csv [S315] [S316] [S318] [S33022] [S33002] [S319] ...; chart by repo · As of 2026-11-05

两组条形图，数据来自共享的系统规格数据。每系统功率：DGX A100 约 6.5 kW，DGX H100 10.2 kW，DGX B200 约 14.3 kW（各 8 块 GPU）；GB200 NVL72 约 120 kW，GB300 NVL72 约 132 kW，Vera Rubin NVL72 约 230 kW（报道的 Max-P），Rubin Ultra Kyber 机架约 600 kW（144 个封装，路线图）。按每个 GPU 封装计，功率从约 0.8 kW（DGX A100）和 1.3 kW（DGX H100）升至约 3.2 kW（Vera Rubin）和 4.2 kW（Kyber）。

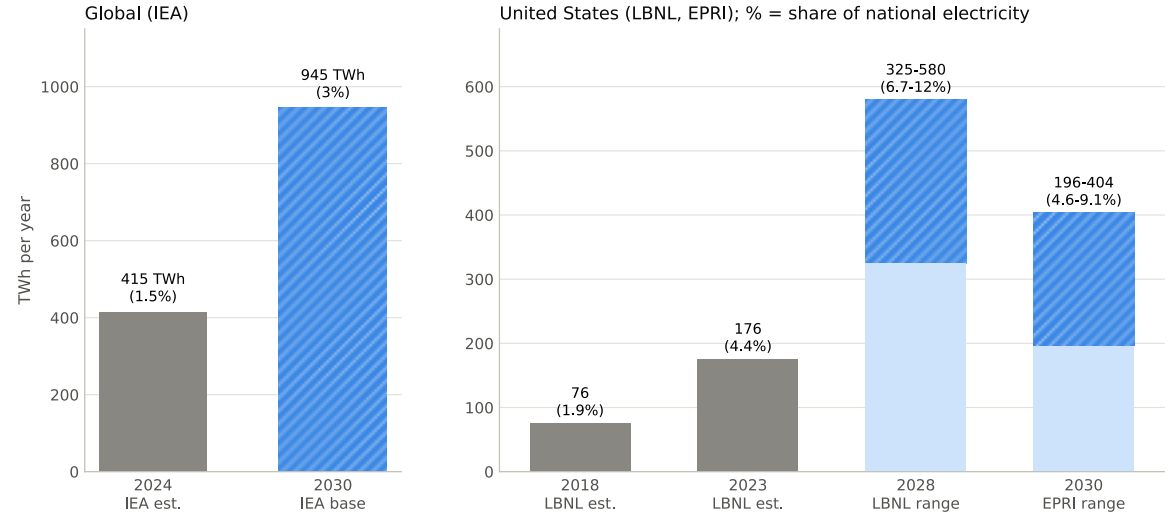


更少的交直流转换环节和更高的配电电压，意味着每兆瓦所需的铜更少、转换损耗更低——这是英伟达公布的自 2027 年起采用 800 V DC 的理由 [S33019]。

场址与电网。 把机架扩展到园区规模，电力就成了整个行业的关卡。

Datacenter electricity could double globally by 2030 and up to triple in the US by 2028

Annual datacenter electricity use, TWh; solid = estimate of actual, hatched = forecast range (low to high)



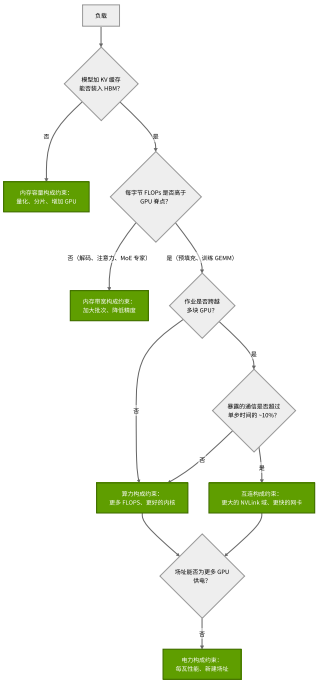
Source: data from IEA Energy and AI (2025); LBNL (2024); EPRI (2024) [S33015] [S33016] [S33017]; chart by repo · As of 2026-11-05

两组条形图。全球（IEA）：2024 年约 415 TWh，约占全球用电量的 1.5%，基准情景下到 2030 年升至约 945 TWh。美国：2018 年 76 TWh，2023 年 176 TWh（占美国用电量的 4.4%，LBNL），LBNL 预测到 2028 年达 325 至 580 TWh（6.7% 至 12%），EPRI 预测到 2030 年达 196 至 404 TWh（4.6% 至 9.1%）。

各方预测在幅度上存在分歧，但方向一致：IEA 的基准情景下，全球数据中心用电到 2030 年将增长一倍以上，达到 ~945 TWh [S33015]；LBNL 预测到 2028 年美国用电量为 325–580 TWh，占全国用电量的 6.7–12% [S33016]；EPRI 2024 年的情景则在 2030 年达到 4.6–9.1% 之间 [S33017]。电网运营商已在其负荷账本中看到这一点——美国最大的电网运营商 PJM 预测，2024 至 2030 年间夏季峰值负荷将增长约 32 GW，主要由数据中心驱动 [S33018]——而 IEA 估计约五分之一的规划中数据中心项目可能因电网约束而延期 [S33015]。大型训练作业还以一种新的方式冲击电网：Meta 报告称，当数千块 GPU 同步启动和停止计算时，数据中心功率会出现数十兆瓦的波动 [S34006]。

> **提示**
>
> **算例 —— 一个 100,000 块 GPU 的 Blackwell 集群对电费意味着什么。** 100,000 块 GPU ÷ 每个 NVL72 机架 72 块 ≈ 1,389 个机架 × ~132 kW [S33021] ≈ **183 MW 的 IT 负载**。假设考虑冷却和损耗后的电能使用效率（PUE）为 1.2，场址用电 ~220 MW。假设平均负载率为 80%，则为 220 MW × 0.8 × 8,760 h ≈ **每年 1.5 TWh**——约占 2024 年全球数据中心总用电量的 0.4% [S33015]——按假设的每 MWh $70 计算，每年 ~$110M。**商业解读：** 与硬件相比，电费只是小头（参见第 14 章），但*拿到* 220 MW 的电网容量可能需要数年时间。当电力成为稀缺投入时，真正重要的指标是**每兆瓦每秒 token 数**，它奖励的是每瓦性能而非每美元性能，并有利于能交付最高效完整系统的厂商。

哪个瓶颈构成约束？一棵决策树



~10% 的阈值只是经验法则，并非定律；脊点数据来自第 2 节的表格。

Compute binds training and prefill; memory and interconnect bind decode and MoE

Which bottleneck binds, by AI workload (repo analysis; Binding = sets the speed limit, Significant, Minor)

	Compute	Memory bandwidth	Memory capacity	Scale-up interconnect	Scale-out network	Power
Pre-training (dense)	**Binding**	Minor	Significant	Significant	Significant	**Binding**
Pre-training (MoE)	Significant	Significant	Significant	**Binding**	**Binding**	**Binding**
Prefill (long prompts)	**Binding**	Minor	Minor	Minor	Minor	Significant
Decode (small batch)	Minor	**Binding**	Significant	Significant	Minor	Minor
Decode (large batch)	Significant	Significant	**Binding**	Significant	Minor	Significant
Long-context reasoning	Minor	**Binding**	**Binding**	**Binding**	Minor	Significant
MoE serving (wide EP)	Minor	**Binding**	Significant	**Binding**	Significant	Significant

Source: data from repo analysis drawing on Llama 3, DeepSeek-V3, Pope et al., IEA [S34006] [S33001] [S34004] [S34001] [S34002] [S33015] ...; chart by repo · As of 2026-11-05

热力图：七类 AI 负载对应六种瓶颈。稠密预训练：算力和电力构成约束。MoE 预训练：纵向扩展与横向扩展互连以及电力构成约束。预填充：算力构成约束。小批次解码：内存带宽构成约束。大批次解码：内存容量构成约束。长上下文推理：内存带宽、内存容量和纵向扩展互连构成约束。MoE 服务：内存带宽和纵向扩展构成约束。

该热力图是本资料库的判断（🔴 分析），以上文的算术以及已公布的 Llama 3 和 DeepSeek-V3 配置为依据 [S34006,S34007]。它对战略的启示是：随着推理、推理模型和 MoE 的增长，**负载结构正从上方几行的算力受限型，转向下方几行的内存受限与互连受限型**——参见 P2。

> 注
>
> 🐂 **看多观点：** 由于约束条件会不断转移，能够同时改善全部四项瓶颈的厂商将胜出。英伟达把 HBM 容量、NVLink 域规模、网卡、交换机、液冷机架以及围绕它们进行调度的软件作为一个整体产品交付，并且每年都能重新调配芯片资源（Rubin 4.4× 的 FP8:BF16 比值，以及面向算力受限预填充的 Rubin CPX [S33005,S33023]，尽管 CPX 已从 GTC 2026 路线图中撤下 [S115]）。竞争对手通常一次只能攻克一个瓶颈。

> 注意
>
> 🐻 **看空观点：** 对不断增长的推理市场而言最关键的瓶颈——内存——是一种大宗商品式投入，英伟达和其他所有厂商一样从 SK 海力士、三星和美光（Micron）采购，而且它自己的 Rubin 标称带宽下调了 13% [S33007]。内存受限的解码奖励的是每美元和每瓦带宽，而非 CUDA 或峰值 FLOPS，这恰恰给推理 ASIC、以 SRAM 为主的设计和基于 LPDDR 的推理卡留下了机会。而当限制部署的是电力而非芯片时，客户可以用运行成本最低的任何芯片来优化每兆瓦 token 数。

与各层的关联

瓶颈	本资料库的深入章节
算力：张量核心、数值格式、裸片	第 02 层 · GPU 芯片 · P1 · 训练
内存：HBM 各代产品、CoWoS、供应	第 03 层 · 内存、封装与供应链 · P2 · 推理 · P5 · 芯片经济学
纵向扩展互连：NVLink、NVSwitch、NVL72	第 05 层 · 纵向扩展 · P4 · 并行方式
横向扩展网络：InfiniBand、Spectrum-X	第 06 层 · 横向扩展与跨数据中心扩展
CPU 内存层：Grace、Vera、NVLink-C2C	第 04 层 · CPU
电力与冷却：机架、800 V DC、AI 工厂	第 08 层 · 系统、机架与 AI 工厂 · CS7 · 吉瓦级 AI 工厂
转移瓶颈的软件：批处理、分离式服务	第 11 层 · 推理与 AI 软件
经济学与风险	14 · 训练与推理经济学 · 18 · 弱点与看空情景

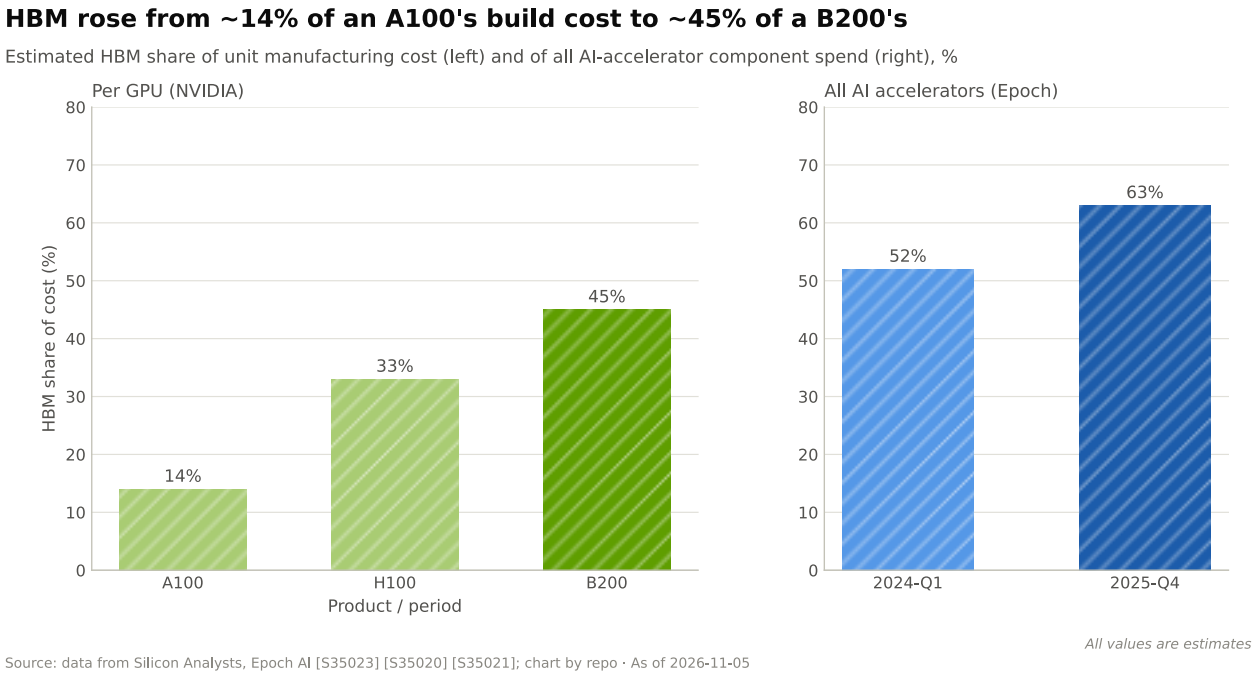
需要记住的关键数字

指标	数值	为何重要
脊点，稠密 BF16	~295（H100）、~281（B200）、~208（Rubin）FLOPs/字节 [S33002,S33003,S33005,S33007]	低于该值的负载属于内存受限
脊点，Rubin FP8	~911 FLOPs/字节 [S33005,S33007]	低精度把更多工作推入内存受限区间
批大小为 1 时的解码强度	~1 FLOP/字节（BF16） [S33013]	使用不到峰值 FLOPS 的 1%
KV 缓存，70B 级模型	每 token ~0.33 MB [S32027]	限制批大小的是容量，而非 FLOPS
每 GPU 的 HBM	80 GB / 3.35 TB/s（H100）→ 288 GB / 19.2 TB/s（Rubin） [S33002,S33005,S33007]	推理的瓶颈

指标	数值	为何重要
每 GPU 的 NVLink	0.9 → 1.8 → 3.0 TB/s（Hopper → Blackwell → Rubin） S34014,S33007	纵向扩展域带宽
每 GPU 的横向扩展网卡	400 → 800 → 1,600 Gb/s（每个方向 50 → 100 → 200 GB/s） S34015,S33004	比 NVLink 低 ~8–18×
前沿训练的实际 MFU	38–43%（Llama 3 405B） S34006	大部分峰值 FLOPS 未被利用
机架功率	~41 kW（4× DGX H100）→ ~120–132 kW（GB200 NVL72）→ ~600 kW（Kyber） S33022,S33021,S35019	迫使采用液冷和 800 V DC
数据中心用电量	~415 TWh（2024 年）→ ~945 TWh（2030 年，IEA 基准情景） S33015	电力是场址层面的限制

🎯 企业发展视角

1. **顺着约束条件去寻找价值池。** 随着负载转向内存受限的推理，价值正向 HBM 厂商和先进封装迁移：HBM 在单位制造成本中的占比从 A100 的 ~14% 升至 B200 的 ~45%（估计，Silicon Analysts 与 Epoch AI） S35023,S35020——参见 P5。哪些合作关系或供应协议能让挑战者以更优的每美元成本优先获得内存带宽或容量？



两组条形图：HBM 在单位成本中的占比从 A100 的约 14% 升至 H100 的约 33%，再到 B200 的约 45%；在全部 AI 加速器中，内存在元器件支出中的占比从 2024 年 Q1 的 52% 升至 2025 年 Q4 的 63%。

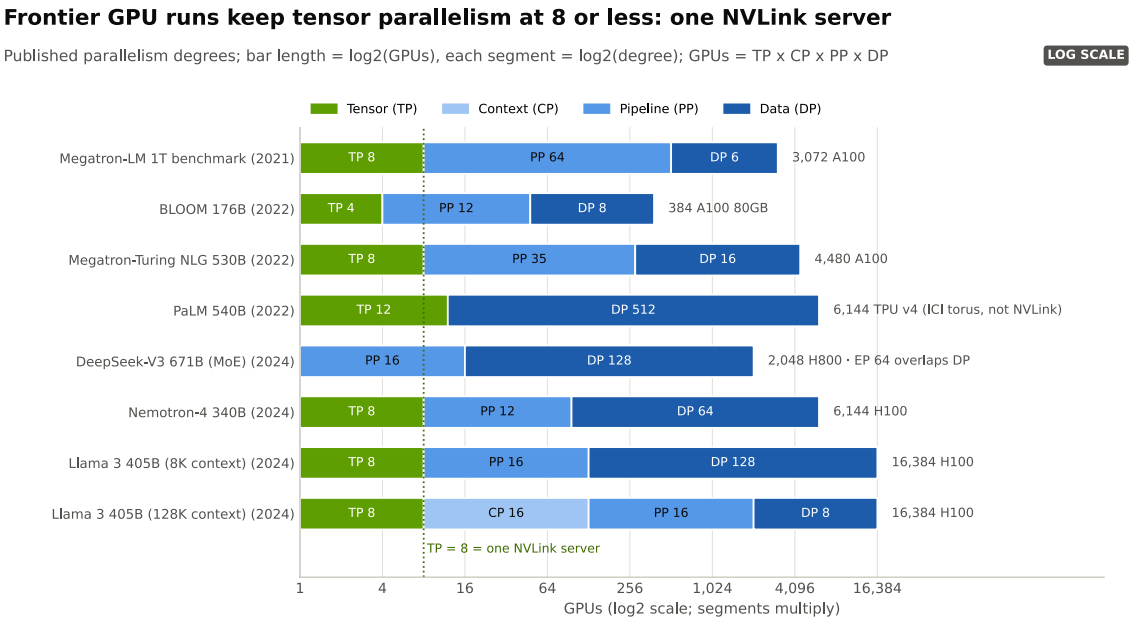
2. **互连是英伟达的整合能力最难被复制的环节。** 只要有钱，任何人都能买到 HBM 和先进制程晶圆；但一个 72 块 GPU、每 GPU 1.8 TB/s 的交换式互连域外加成熟的软件，却不是有钱就能买到的 S34014。到 2027 年，UALink 或基于以太网的纵向扩展方案是否足够可信，使买家能用商用器件搭建出同等的互连域——又由谁来完成集成？
3. **挑战者的产品究竟针对哪个瓶颈？** 一张以峰值 FLOPS 换取大容量、低成本内存的推理卡，针对的是容量墙；一张配备大容量片上 SRAM 的芯片，针对的是带宽墙。应要求竞争对手（也包括我们自己）提供在给定批大小、上下文长度和延迟目标下的每瓦每秒 token 数——而非峰值 TOPS。
4. **受电力约束的部署会改变评分标准。** 当场址的兆瓦数固定时，买家会最大化每兆瓦 token 数 S33015,S33016。这有利于效率优先的设计，也为绕开电网排队的边缘/本地推理打开了空间——这是第 19 章要讨论的问题，应将其视为一种选项，而非建议。
5. **电力与冷却是英伟达并不掌控的价值池。** 800 V DC、液冷和电网设备由电气和热管理厂商供应 S33019；英伟达负责制定参考设计。是否存在非 GPU 公司可以占据的元器件或软件（功率封顶、电网互动式调度）细分领域？

P4 · 并行方式详解

入门篇 P4 · 写给非工程师的基础知识 · 约 22 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **没有任何前沿模型能在单块 GPU 上训练——原因有两个。** *内存：* 使用标准 Adam 优化器训练，每个参数需要 ~16 字节 [S34004]，因此一个 70B 参数的模型需要 ~1.1 TB，在存储任何一个激活值之前就需要十四块 80 GB 的 H100。*时间：* Llama 3 405B 耗费了 ~3.8 × 10^{25} FLOPs [S34006]，若以 Meta 实际达到的 ~400 TFLOPS 计算，一块 H100 需要运行约 3,000 年。
- **拆分工作的方式有五种**——数据并行、张量并行、流水线并行、专家并行和上下文并行——外加对优化器状态的分片。每一种都节省了内存或时间，代价是通信，而通信依靠少数几种集合通信操作：全规约（all-reduce）、全收集（all-gather）、规约散射（reduce-scatter）和全交换（all-to-all）。
- **其中的艺术在于把通信最频繁的拆分放在最快的链路上。** 在一个 70B 的例子中，张量并行每步每 GPU 传输 ~150 GB，而数据并行只有 ~9 GB（本资料库基于 [S34001,S34011] 的估计），因此张量并行放在 NVLink 域内（每块 Blackwell GPU 1.8 TB/s [S34014]），而数据并行和流水线并行则跨越 400 Gb/s–1.6 Tb/s 的网卡 [S34015,S33004]。
- **算例数字：** 对 140 GB 的 BF16 梯度（一个 70B 模型）执行环形全规约，每块 GPU 需发送 ~276 GB——通过 400 Gb/s 的 InfiniBand 网卡（NIC）需 ~5.5 s，通过 NVLink 5 仅需 ~0.31 s（[S34011,S34015,S34014]）。
- **已公开的前沿训练都遵循同一配方。** Llama 3 405B 在 16,384 块 H100 上采用 8 路张量 × 16 路流水线 × 128 路数据并行，MFU 为 41%，并在其 128K token 阶段增加了 16 路上下文并行 [S34006]。在我们的样本中，所有基于 GPU 的训练都把张量并行控制在 ⩽ 8——即一台 NVLink 服务器之内。
- **混合专家模型改变了流量模式。** DeepSeek-V3（671B 总参数、37B 激活参数、每层 256 个路由专家）在 2,048 块 H800 上训练，采用 16 路流水线并行和 64 路专家并行，*完全没有*使用张量并行，并将每个 token 限制在最多 4 个节点内，以驯服 InfiniBand 上的全交换流量 [S34007]。全交换正是 NVL72 级纵向扩展（scale-up）域对 MoE 至关重要的原因。
- **看空/竞争者视角：** 这套配方并非英伟达独有。谷歌训练 PaLM 540B 时通过 TPU ICI 链路采用 12 路模型并行，完全没有使用流水线 [S34021]；开源软件（PyTorch FSDP、DeepSpeed、JAX）实现了本文的每一项技术 [S34005,S34004]；而开放的纵向扩展标准瞄准的恰恰是这些拆分所需要的“高速域”。



Source: data from published training papers [S34002] [S34019] [S34018] [S34021] [S34007] [S34020] ...; chart by repo · As of 2026-11-05

堆叠横向条形图：已公开的训练任务如何分解其 GPU 数量：Megatron 1T 使用 3,072 块 A100（TP 8、PP 64、DP 6）；MT-NLG 530B 使用 4,480 块 A100（TP 8、PP 35、DP 16）；BLOOM 176B 使用 384 块 A100（TP 4、PP 12、DP 8）；PaLM 540B 使用 6,144 颗 TPU v4 芯片（12 路模型并行、512 路数据并行）；Nemotron-4 340B 使用 6,144 块 H100（TP 8、PP 12、DP 64）；Llama 3 405B 使用 16,384 块 H100（TP 8、PP 16、DP 128，长上下文阶段为 TP 8、CP 16、PP 16、DP 8）；DeepSeek-V3 使用 2,048 块 H800（无 TP、PP 16、DP 128，配合 64 路专家并行）。

从这里开始：为什么要拆分工作

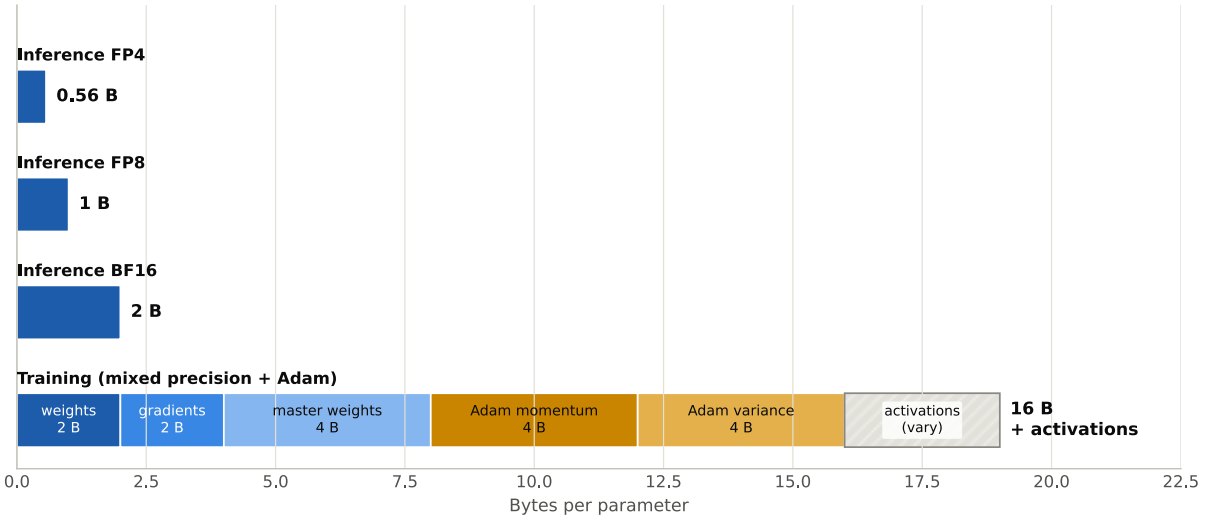
可以把训练模型想象成审计一家巨型公司的账簿。一名会计（一块 GPU）需要上千年才能完成，而且账本根本放不下他的办公桌。你可以雇用数千名会计，并以不同方式分配工作：给每人分配不同月份的交易（**数据并行**）；把每一页账目拆给几个人，每人合计其中几列（**张量并行**）；设立一条流水线，一个小组负责收入，下一个负责成本，再下一个负责税务（**流水线并行**）；把每笔交易只交给负责该类业务的专家（**专**

家并行）；或者把一份超长文档拆成若干章节，由多人并排阅读（**上下文并行**）。每种方案都需要会计之间*沟通*——核对合计数、传递账页——而沟通恰恰是花钱的地方。

> **提示**
>
> **算例 —— 一个 70B 模型仅仅为了在内存中*完成训练*需要多少块 GPU？** 使用 Adam 优化器的混合精度训练，每个参数需要保存 2 字节的 BF16 权重、2 字节的梯度和 12 字节的 FP32 优化器状态（主权重、动量、方差）——合计 ~16 字节 [S34004]。对于 70B 参数，即 $70 \times 10^9 \times 16 \approx$ **1.12 TB**。一块 H100 可容纳 80 GB [S33002]，因此即使拆分得完美无缺，在存储激活值（为反向传播保留的中间结果，对长序列而言其规模可能超过权重）之前也需要 ⩾ 14 块 GPU。B200 的 180 GB [S33003] 可把下限降至 7 块。**解读：** 内存下限迫使我们拆分模型（张量、流水线、分片）；而*时间*预算又迫使我们在另外数千块 GPU 上进行数据并行。

Training needs ~16 bytes per parameter, 8× BF16 inference, before activations

Memory per model parameter by regime and component, bytes (mixed-precision training with the Adam optimizer)



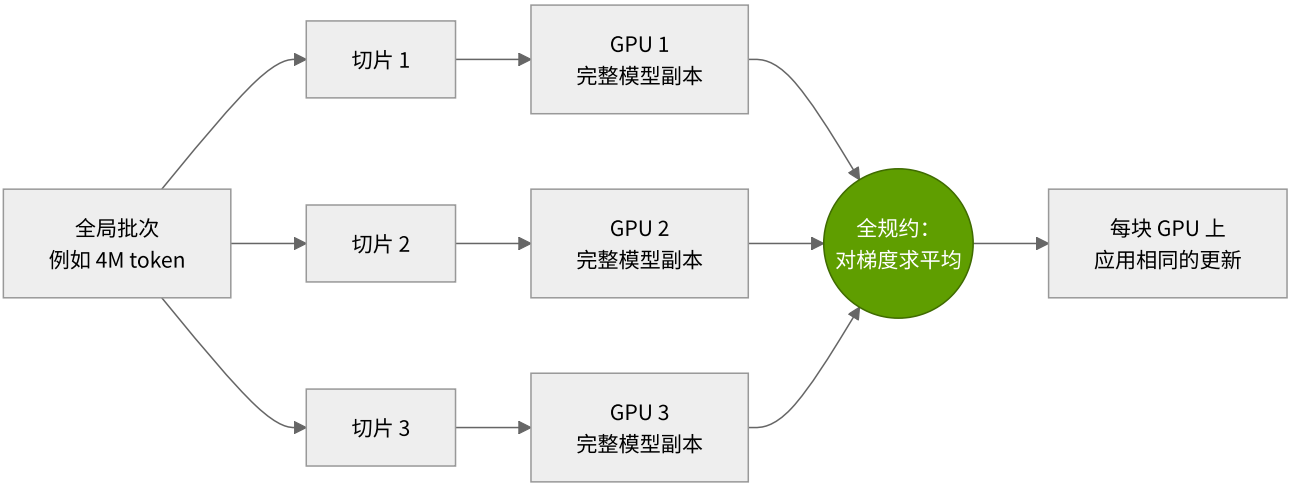
Source: data from ZeRO paper (Microsoft) and NVIDIA NVFP4 documentation [S32017] [S34004]; chart by repo · As of 2026-11-05

每参数字节数的堆叠横向条形图：FP4 推理约 0.56，FP8 推理 1，BF16 推理 2，采用 Adam 的混合精度训练 16（2 权重 + 2 梯度 + 4 FP32 主权重 + 4 动量 + 4 方差），是 BF16 推理的 8 倍。因此一个 405B 模型在计入激活值之前约有 6.5 TB 训练状态，相当于约 81 块 H100 的内存。

策略	拆分的对象	必须交换的内容	使用的集合通信	频率	通常运行在哪里
数据（DP）	训练样本批次	梯度	全规约（FSDP：规约散射 + 全收集）	每步一次，可重叠	横向扩展网络
张量（TP）	每一层的权重矩阵	层的部分输出	全规约（或规约散射 + 全收集）	每层前向 2 次、反向 2 次 [S34001]	NVLink 域内
流水线（PP）	层的堆叠，切分为若干阶段	阶段边界处的激活值	点对点发送 / 接收	每个微批次、每个边界	横向扩展网络即可
专家（EP）	混合专家层中的各个专家	发往专家的 token 及其返回结果	全交换	每个 MoE 层前向 2 次 [S34017]	理想情况下在 NVLink 域内；在网络上需限制路由 [S34007]
上下文（CP）	单条长序列中的 token	注意力的键和值	环形发送 / 接收、全收集或全交换	每个注意力层	NVLink 或网络 [S34009,S34010]

1. 数据并行，以及基于 ZeRO / FSDP 的分片

工作原理。 每块 GPU 都持有一份完整的模型副本，并处理批次中的不同切片。反向传播结束后，每块 GPU 都拥有根据自身切片计算出的梯度；这些梯度必须求平均，使每份副本应用相同的更新。这一求平均操作就是**全规约**。



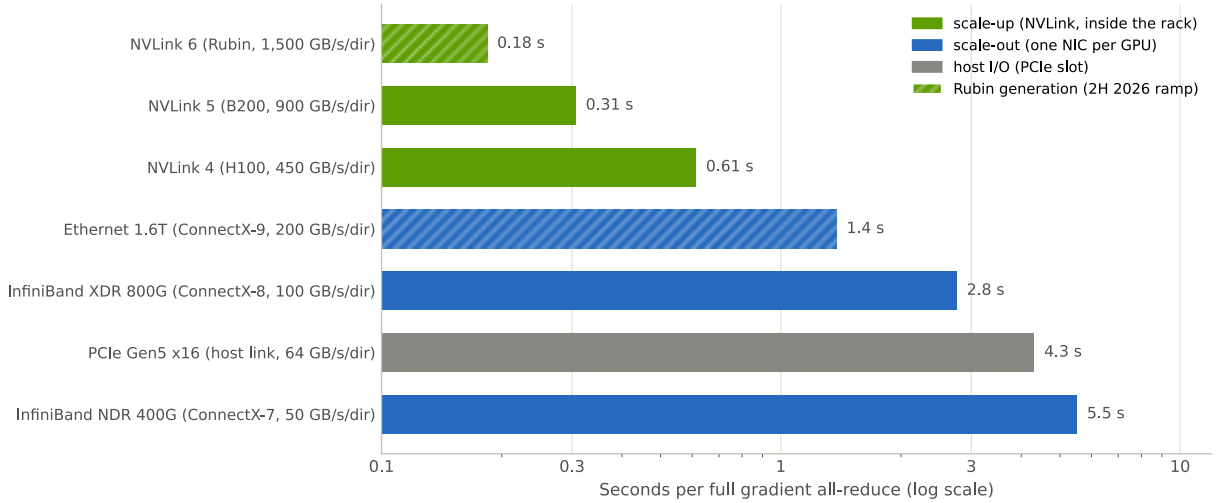
最著名的算法是**环形全规约（ring all-reduce）**，其中每块 GPU 发送和接收的数据量为 $2 \times (N-1)/N$ 倍——约为梯度大小的两倍，与环中 GPU 的数量无关 [S34011,S34012]。正是这种与 N 无关的特性使数据并行具有良好的扩展性；其代价是数据量大，且每块 GPU 都必须装得下完整模型。

> **提示**
>
> **算例 —— 在不同链路上同步一个 70B 模型的梯度。** 在 BF16 下，梯度为 70B × 2 字节 = 140 GB。在 64 块 GPU 间执行环形全规约，每块 GPU 发送 $2 \times 63/64 \times 140 \approx$ **276 GB** [S34011]。再除以各链路的单向带宽：400 Gb/s 的 InfiniBand 网卡传输速度为 50 GB/s → **~5.5 s**；800 Gb/s 网卡 → ~2.8 s [S34015]；H100 上的 NVLink 4（每个方向 450 GB/s）→ ~0.61 s；B200 上的 NVLink 5（900 GB/s）→ **~0.31 s** [S34014]；Rubin 上按当前标称 3.0 TB/s 计的 NVLink 6 → ~0.18 s [S33007]；即便是 Rubin 的 1.6 Tb/s ConnectX-9 网卡（每个方向 200 GB/s）也需要 ~1.4 s [S33004]。以上均为理想时间；实际的集合通信会略逊一筹，而各框架会在后面的层仍在计算时就开始对前面各层的梯度执行全规约，从而隐藏大部分开销。**解读：** NVLink 5 与 400G 网卡之间每 GPU ~18× 的差距，是英伟达销售 NVLink 域、而不仅仅是 GPU 的核心经济原因。

A 70B gradient sync takes ~5.5 s over 400G InfiniBand but ~0.3 s over NVLink 5

Ideal ring all-reduce of 140 GB of BF16 gradients across 64 GPUs (276 GB sent per GPU), by per-GPU link; seconds

LOG SCALE



Source: data from link specs via interconnect_specs.csv; ring formula [S251] [S252] [S253] [S222] [S256] [S254] …; chart by repo · As of 2026-11-05

横向条形图：在 64 块 GPU 间对 140 GB BF16 梯度（一个 700 亿参数模型）执行理想环形全规约所需时间，每块 GPU 约发送 276 GB：InfiniBand NDR 400 Gb/s 约 5.5 秒，PCIe Gen5 x16 约 4.3 秒，InfiniBand XDR 800 Gb/s 约 2.8 秒，NVLink 4 约 0.61 秒，NVLink 5 约 0.31 秒，NVLink 6 约 0.18 秒；NVLink 5 比 400G InfiniBand 快约 18 倍。一块 1.6 Tb/s 的 Rubin 代网卡约需 1.4 秒。

分片解决了内存问题。 微软（Microsoft）的 ZeRO 注意到，朴素的数据并行会把所有东西存储 64 份完全相同的副本。它把优化器状态（第 1 阶段）、梯度（第 2 阶段）乃至权重本身（第 3 阶段）依次分片到各数据并行 GPU 上，并在需要时即时收集各部分 [S34004]。PyTorch 的 FSDP 是内置于框架中的同一思路 [S34005]；Meta 在 Llama 3 中使用了它 [S34006]。

70B 模型，64 块数据并行 GPU	每块 GPU 存储的内容	每 GPU 内存	相对朴素 DP 的通信量
朴素数据并行	全部内容（16 字节/参数）	~1,120 GB	1×
ZeRO-1：分片优化器状态	权重 + 梯度 + 1/64 的优化器状态	~293 GB	1×

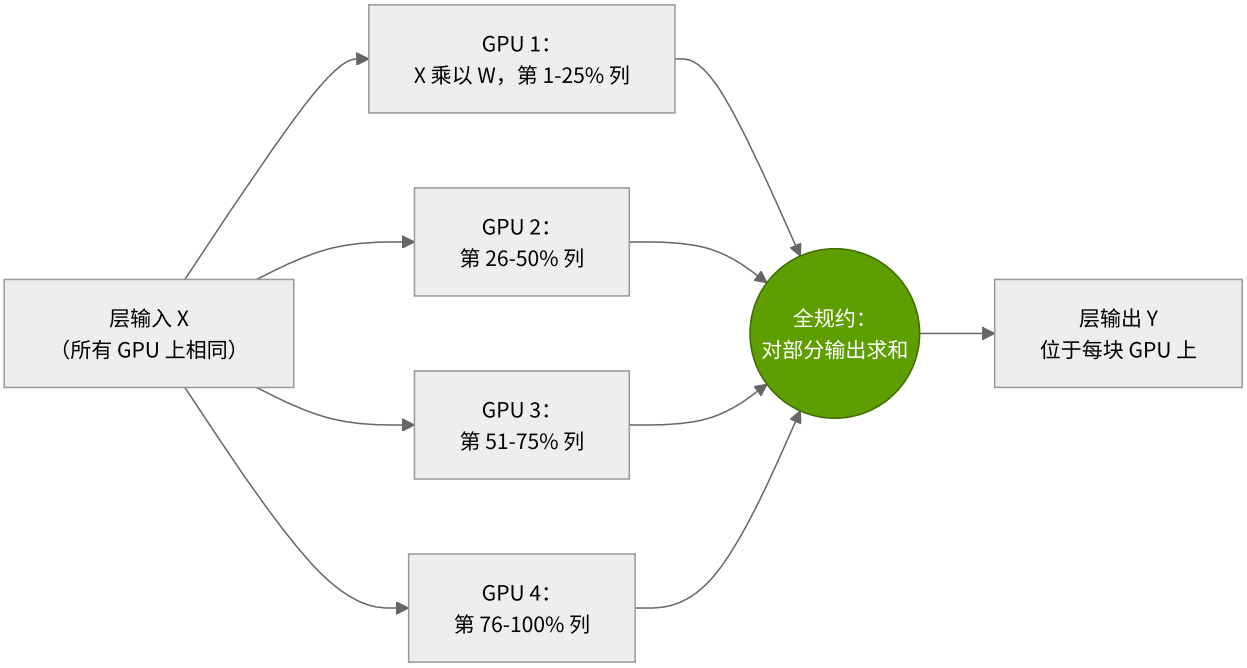
70B 模型，64 块数据并行 GPU	每块 GPU 存储的内容	每 GPU 内存	相对朴素 DP 的通信量
ZeRO-2：同时分片梯度	权重 + 1/64 的梯度和优化器状态	~155 GB	1×
ZeRO-3 / FSDP：同时分片权重	全部内容的 1/64	~17.5 GB	~1.5×

本资料库采用 ZeRO 的 2 + 2 + 12 字节/参数核算口径及其通信分析进行的测算 [S34004]。

> **🔧 技术细节：为何全规约 = 规约散射 + 全收集**
>
> 环形全规约分为两半运行。在**规约散射**阶段，每块 GPU 把数据分成 N 块，每一步把其中一块传给相邻 GPU，并把收到的数据累加；经过 N − 1 步后，每块 GPU 都拥有一个完全求和的数据块。在**全收集**阶段，求和后的数据块再沿环传递 N − 1 步，直到每块 GPU 都拥有全部数据块。每一半中每块 GPU 传输 (N − 1)/N 的数据，因此总计为 2(N − 1)/N；NCCL 的基准测试把由此得出的每链路速率称为“总线带宽”（bus bandwidth）[S34012]。FSDP 只是在规约散射之后就停止（每块 GPU 只需要自己那一份梯度分片），并在每一层计算之前对*权重*执行全收集 [S34005]。网内规约（NVIDIA SHARP）在交换机内部完成累加，从而减少数据穿越网络的次数 [S34024]。

2. 张量并行：拆分每一层

工作原理。 不复制模型，而是把每一层的大型权重矩阵拆分到多块 GPU 上——例如，让 8 块 GPU 各持有八分之一的列。每块 GPU 用相同的输入乘以自己的那一片；然后通过全规约合并部分结果。英伟达的 Megatron-LM 对 Transformer 的矩阵做了巧妙安排，使每一层在前向传播中只需两次全规约，在反向传播中也只需两次 [S34001]。

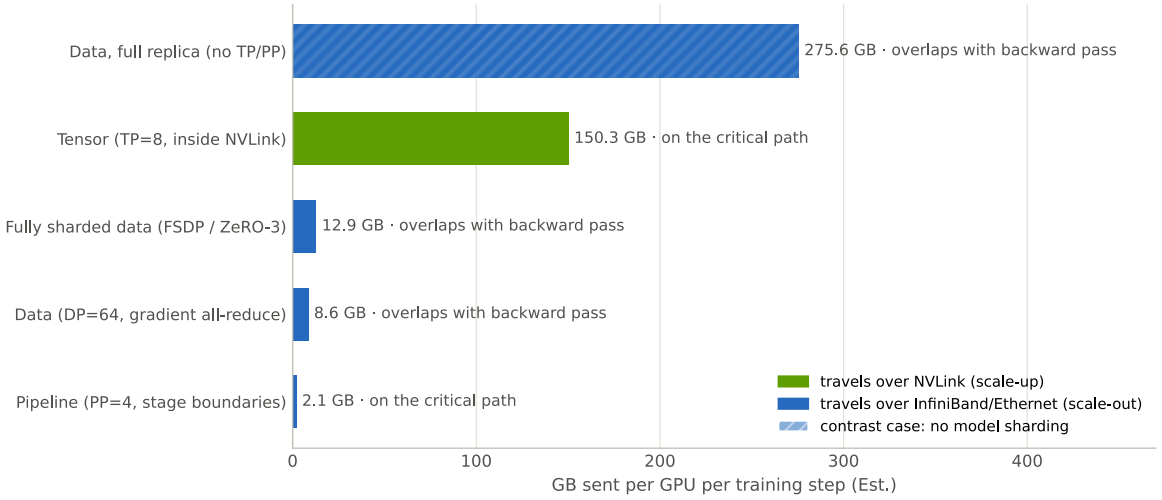


其吸引力在于：每块 GPU 只存储每一层的一部分，单层的计算也完成得更快——这对推理服务的延迟同样有帮助。问题在于：全规约发生在每一层*内部*，位于关键路径上，传输的是完整尺寸的激活值。

> **提示**
>
> **算例 —— 为何张量并行要留在 NVLink 域内。** 以一个 70B 稠密模型（80 层，隐藏维度 8,192）为例，使用 4,096 token 的序列以 BF16 训练，按 TP8 × PP4 × DP64 拆分到 2,048 块 GPU 上，全局批次为 4M token。单条序列在层边界处的激活值为 4,096 × 8,192 × 2 字节 ≈ 67 MB。每块 GPU 所在阶段有 20 层 × 4 次全规约 × 1.75（8 块 GPU 的环形系数）× 67 MB ≈ 每条序列 9.4 GB 的张量并行流量，每步处理 16 条序列 → **每 GPU 每步 ~150 GB** [S34001,S34012]。同一块 GPU 上 2.2B 参数分片的数据并行梯度同步仅为 ~8.6 GB，流水线发送量为 ~2.1 GB。该步的计算量为 6 × 70B × 4.2M token ÷ 2,048 块 GPU ≈ 每 GPU 8.6×10^{14} FLOPs——假设每块 B200 实际达到 1 PFLOPS（约为 BF16 峰值的 ~44% [S33003]），耗时 ~0.86 s。通过 NVLink 5 传输这 150 GB 需要 ~0.17 s（可以承受，且部分可重叠）；通过 400G 网卡则需要 ~3.0 s，**是计算本身耗时的 3.5 倍。解读：** 张量并行只有在纵向扩展链路上才划算，因此 NVLink 域的规模限制了模型能以这种方式拆分到什么程度。

TP moves ~17x more data per GPU per step than DP, which is why it stays on NVLink

Est. GB sent per GPU per training step: 70B dense model, TP8 x PP4 x DP64 on 2,048 GPUs, 4M-token batch, BF16



Source: data from Megatron-LM, ZeRO and ring all-reduce formulas; repo arithmetic [S34002] [S34011] [S34012] [S34004] [S34005] [S34001]; chart by repo · As of 2026-11-05

横向条形图：一个 700 亿参数模型按 8 路张量、4 路流水线和 64 路数据并行拆分时，每 GPU 每个训练步的估计发送数据量：张量并行约 150 GB，数据并行梯度全规约约 8.6 GB，全分片数据并行约 12.9 GB，流水线发送约 2.1 GB；作为对比，每块 GPU 持有完整模型副本的朴素数据并行约需发送 276 GB。

既然一个 NVL72 机架已经能以全速 NVLink 连接 72 块 GPU [S34014]，为什么不采用 72 路张量并行？因为把一个矩阵切成 72 份，每块 GPU 只剩下薄薄的一片，而小矩阵乘法的运行效率远低于峰值（参见 P3 中的 roofline）。Megatron 的作者建议把张量并行限制在一台服务器内，超出部分则使用流水线并行 [S34002]。在实践中，大型 NVLink 域被用于专家并行和推理服务，而不是更宽的张量拆分。

> 🔧 **技术细节：序列并行——配套技巧**
>
> 某些层操作（LayerNorm、dropout）不会被张量并行拆分，因此每块 GPU 都会重复计算和存储它们。英伟达的**序列并行**改为沿序列维度拆分这些操作，并把每次全规约替换为总量相同的一次规约散射加一次全收集——从而在不增加通信成本的情况下节省激活值内存 [S34008]。不要与*上下文并行*（第 5 节）混淆，后者是把注意力计算本身拆分到多块 GPU 上。

3. 流水线并行与气泡

工作原理。 把模型的层切分为连续的**阶段**——第 1–20 层放在 GPU 组 A，第 21–40 层放在 B，依此类推——并像流水线一样把激活值从一个阶段传到下一个阶段。只有点对点发送会跨越边界，而且数据量很小，因此各流水线阶段可以位于不同机架，通过普通的横向扩展网络连接 [S34002]。

问题在于**流水线气泡**：在每一步开始时，后面的阶段要等待工作到达；而在结束时，前面的阶段要等待反向传播返回。GPipe 的解决办法是把每个批次切成许多微批次，让流水线迅速填满 [S34003]。

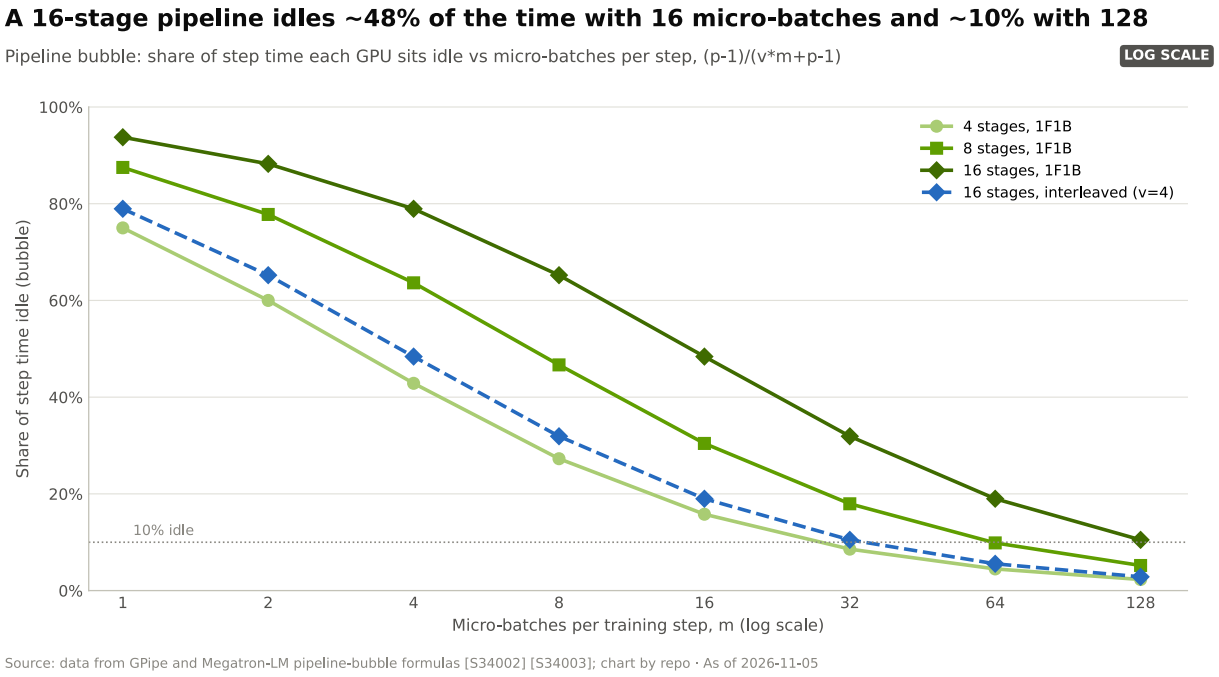


4 个微批次（F1–F4）在 4 阶段流水线中的前向传播：每个阶段在 7 个时间槽中有 3 个处于空闲，即 $(p-1)/(m+p-1) = 3/7 \approx 43\%$ 的气泡。反向传播还会增加一个镜像对称的气泡。

对于 p 个阶段和 m 个微批次，每一步的空闲占比为 $(p-1)/(m+p-1)$；“一前向一反向”（1F1B）调度能控制内存占用，但不改变这一比例；而 Megatron 的**交错式**调度让每块 GPU 负责 v 个不连续的层块，可将气泡缩小约 v 倍 [S34002,S34003]。

提示

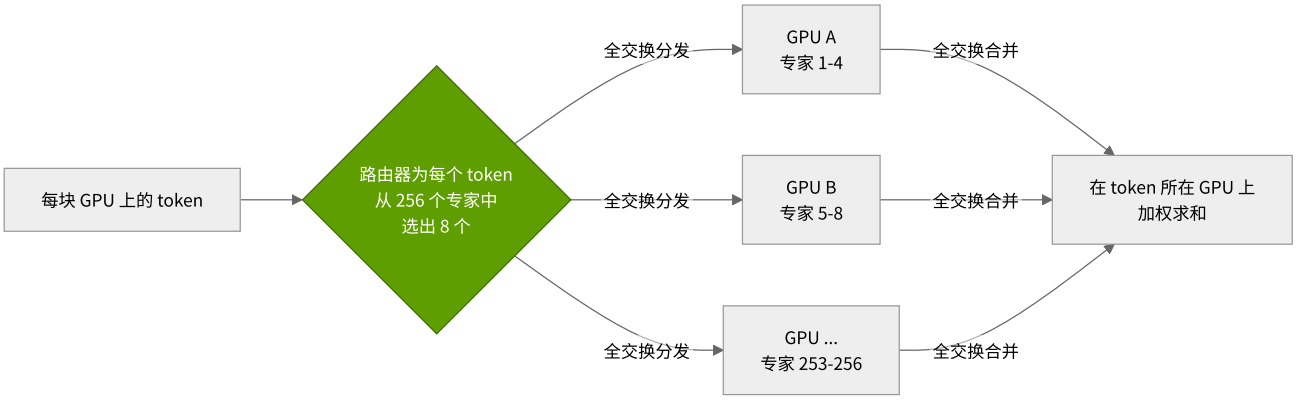
算例 —— 一个 16 阶段流水线需要多少微批次？ 当 p = 16 个阶段时，空闲占比为 15 ÷ (m + 15)。m = 16 个微批次时，GPU 有 **48%** 的时间处于空闲；m = 64 时 ~19%；m = 128 时 ~10%。采用 v = 4 个层块的交错调度，可把 m = 16 时的空闲占比降至 ~19% [S34002]。但微批次并非没有代价：全局批次大小受优化器所能容忍的范围限制（Llama 3 每步 ~16M token [S34006]），因此每条流水线的微批次越多，就意味着数据并行副本越少或微批次越小——而这会损害矩阵乘法效率。**解读：** 流水线深度、微批次数量和数据并行宽度三者之间相互权衡；更快的纵向扩展域让你可以使用更少的流水线阶段，从而获得更小的气泡。



折线图：流水线气泡占比与每步微批次数（对数坐标）的关系。4 个阶段时，空闲占比从 1 个微批次时的 75% 降至 32 个时的约 9%；8 个阶段时，16 个微批次下约为 30%；16 个阶段时，16 个微批次下约为 48%，128 个时约为 10%；采用 4 个虚拟层块的交错调度可把 16 阶段、16 个微批次的气泡降至约 19%。

4. 面向混合专家模型的专家并行

工作原理。 **混合专家模型**（MoE）把每个稠密前馈模块替换为许多较小的“专家”模块，外加一个**路由器**，把每个 token 只发送给其中少数几个专家。DeepSeek-V3 总共有 671B 参数，但每个 token 只激活 37B；每个 MoE 层有 1 个共享专家和 256 个路由专家，每个 token 从中选出 8 个 [S34007]。每 token 的计算量大致按激活参数的比例下降——这正是其吸引力所在。**专家并行**把不同的专家放在不同的 GPU 上，因此每个 MoE 层都必须把每个 token 发送到持有其所选专家的 GPU 上，再把结果取回：每层两次**全交换** [S34017,S34023]。



对网络而言，全交换是最难的集合通信：每块 GPU 同时与其他所有 GPU 通信，流量分布不均（热门专家收到更多 token），而且它位于每个 MoE 层的关键路径上。一个让每块 GPU 都能以全速访问其他所有 GPU 的交换式互连域——这正是 NVLink/NVSwitch 机架所提供的——是它天然的归宿。

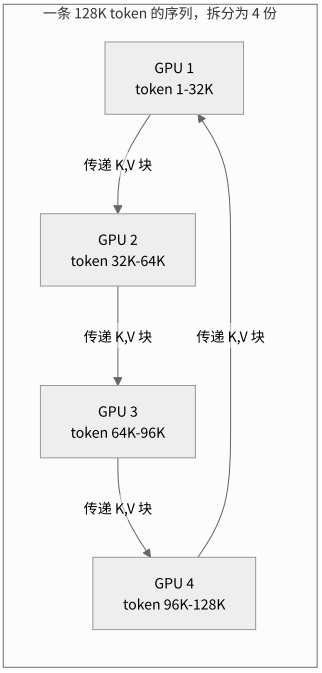
提示

算例 —— DeepSeek-V3 级模型的全交换流量。 隐藏维度为 7,168 [S34007]，以 FP8（每个数值 1 字节）把一个 token 发送给 8 个专家需要 8 × 7,168 ≈ **57 KB**，以 BF16 返回 8 个结果需要 ≈ **115 KB**——每个 token 每个 MoE 层 ~172 KB。共有 58 个 MoE 层（61 层中除前 3 层外的全部）[S34007]，因此一次前向传播约为**每 token ~10 MB**；一块处理 4,096 token 微批次的 GPU 必须收发 ~41 GB 的数据。以 InfiniBand 的 50 GB/s 计算约需 ~0.8 s；以 NVLink 5 的 900 GB/s 计算约需 ~0.05 s [S34014,S34015]。DeepSeek 在受出口管制限制的 H800 上（其实测 NVLink ~160 GB/s，InfiniBand ~50 GB/s）给出的答案是软硬件协同设计：每个 token 最多只能访问 4 个节点上的专家，并且每个节点只穿越一次 InfiniBand，再在节点内部通过 NVLink 扇出，因此跨网络传输的副本最多为 4 份，而非最多 8 份；每块 GPU 的 132 个 SM 中有 20 个专门用于通信；并采用“DualPipe”调度使通信与计算重叠 [S34007]。**解读：** MoE 用网络流量换取 FLOPs，因此价值从原始算力转向纵向扩展带宽和精巧的软件。

推理服务把这一点体现得更加明显。DeepSeek 的解码部署把每个模型副本分布在 40 个节点的 320 块 GPU 上，每块 GPU 放一个路由专家，另有若干 GPU 用于冗余专家和共享专家 [S34007]。如此规模的模型服务本质上是一个集群设计问题，这就是英伟达针对 MoE 推理主推机架级 NVL72 系统及其 Dynamo 推理服务软件的原因（参见第 11 层）。

5. 面向长上下文的上下文并行

工作原理。 注意力机制要把每个 token 与之前的每个 token 进行比较，因此其计算量和激活值内存随序列长度的平方增长。在 128K token 时，单条序列已无法轻松装入一块 GPU。**上下文并行**把一条序列的 *token* 拆分到多块 GPU 上。每块 GPU 为自己那一段查询计算注意力，但需要之前每一段的**键和值**，因此 GPU 之间要交换这些数据——可以在计算的同时沿环传递数据块（Ring Attention [S34009]），可以对其执行全收集（Llama 3 的做法 [S34006]），也可以通过全交换把划分方式从按 token 改为按注意力头（DeepSpeed-Ulysses [S34010]）。



提示

算例 —— 为何 Llama 3 在 128K token 时需要 16 路上下文并行。 Llama 3 405B 有 126 层，以及 8 个维度为 128 的键/值头 [S32008]。其键和值占用 2 × 126 × 8 × 128 × 2 字节 ≈ **每 token 0.52 MB**，因此一条 131,072 token 的序列仅键和值就有 ~68 GB——这还不算规模大得多的激活值。在该阶段，Meta 从 TP8 × PP16 × DP128 切换为 TP8 × **CP16** × PP16 × DP8，GPU 数量保持在 16,384 块，批次保持在 ~16M token，仍实现了 38% 的 MFU，而 8K 上下文时为 41% [S34006]。**解读：** 长上下文训练是以数据并行宽度换取上下文并行宽度；额外的键/值流量之所以可以承受，是因为每块 GPU 在每条序列上的注意力计算量减少了 16 倍。

综合起来：3D、4D 和 5D 并行

实际训练会把这些策略组合成嵌套的维度：GPU 数量 = TP × CP × PP × DP，专家并行通常复用数据并行的 GPU 来承载 MoE 层。规则是把流量最大的维度放在最内层、最快的链路上。Meta 将 Llama 3 的维度排序为 [TP, CP, PP, DP]，从通信需求最大到最小 [S34006]。

3D 布局	流水线阶段 1 第 1-32 层	阶段 2 第 33-64 层	阶段 3 第 65-96 层	阶段 4 第 97-126 层
数据副本 A	服务器：8 块 GPU NVLink 上 TP 8	服务器：8 块 GPU NVLink 上 TP 8	服务器：8 块 GPU NVLink 上 TP 8	服务器：8 块 GPU NVLink 上 TP 8
数据副本 B	服务器：8 块 GPU NVLink 上 TP 8	服务器：8 块 GPU NVLink 上 TP 8	服务器：8 块 GPU NVLink 上 TP 8	服务器：8 块 GPU NVLink 上 TP 8

一个示意性的 3D 布局：张量并行位于每台 8 GPU 服务器内部（NVLink），流水线阶段沿同一行跨越多台服务器，数据并行副本则跨越各行（两者均通过横向扩展网络）。Llama 3 405B 的真实布局为 8 × 16 × 128 = 16,384 块 GPU。

Meta 最大规模训练的公开配置展示了这些维度如何随作业变化而重新调配：

Llama 3 405B 阶段	GPU 数	TP	CP	PP	DP	序列长度	每批 token 数	每 GPU 实际 TFLOPS	BF16 MFU
早期预训练	8,192	8	1	16	64	8,192	~16M	430	43%
主体预训练	16,384	8	1	16	128	8,192	~16M	400	41%
长上下文扩展	16,384	8	16	16	8	131,072	~16M	380	38%

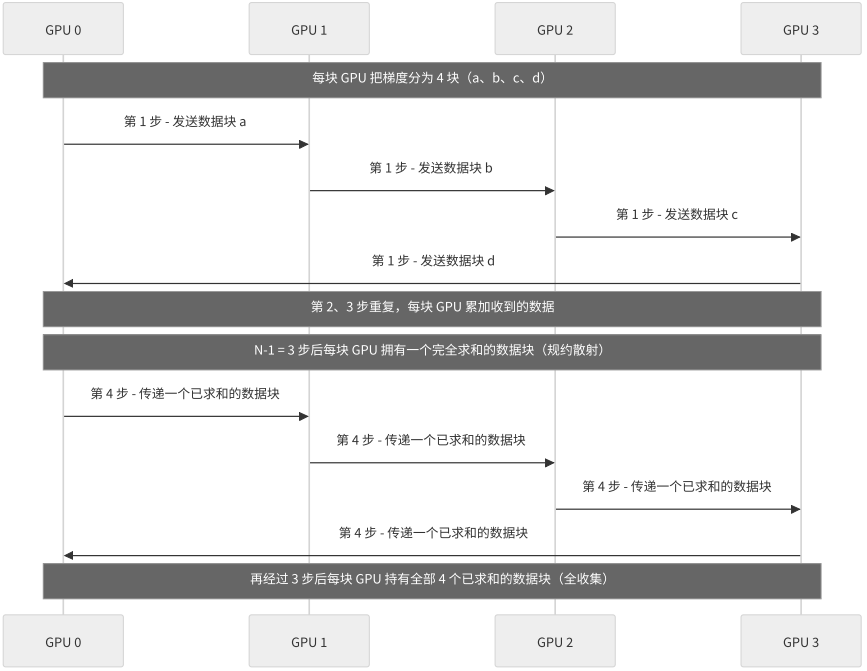
来源：Llama 3 论文，表 4 [S34006]。集群从 8,192 块 GPU 翻倍至 16,384 块，MFU 下降 ~2 个百分点——这正是阿姆达尔定律在起作用（参见 P3）。

> 注意
>
> **误区与事实：**“只要有足够多的 GPU 和足够快的网络，任何模型都能以接近峰值的速度训练。”每一种拆分都会增加通信或空闲时间：Llama 3 405B 在每 GPU 400 Gb/s 的 RoCE 网络 [S34022] 上、服务器内部采用 NVLink 的条件下，只达到了峰值的 38–43% [S34006]；英伟达自己的 1T 参数 Megatron 基准测试在 A100 上达到了 52% [S34002]。剩下的一半 FLOPS 就是并行的代价——也是留给能够降低这一代价者的奖赏。

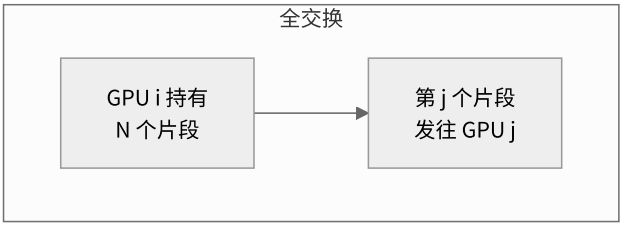
集合通信操作图解

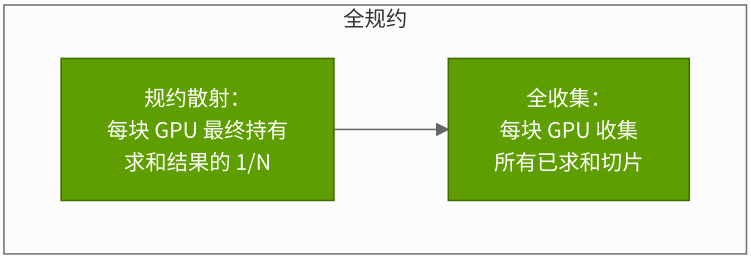
集合通信	每块 GPU 起始持有	每块 GPU 最终持有	每 GPU 发送数据量（环形，N 块 GPU）	用途
全规约	自己的完整向量	所有 GPU 向量之和（或平均）	2(N − 1)/N × 数据量	数据并行梯度；张量并行输出
规约散射	自己的完整向量	求和结果的 1/N 切片	(N − 1)/N × 数据量	FSDP / ZeRO 梯度；序列并行
全收集	一个 1/N 切片	所有 GPU 切片的拼接	(N − 1)/N × 数据量	FSDP 权重；上下文并行的键/值
全交换	N 个不同的片段，每个目的地一个	来自每个来源的一个片段	(N − 1)/N × 数据量	MoE 分发/合并；Ulysses 注意力
广播（broadcast）	一块 GPU 持有数据	所有 GPU 都持有	≈ 数据量	初始权重、检查点

定义及每 GPU 数据量来自 NCCL 文档和基准测试 [S34013,S34012]；环形算法 [S34011]。



4 块 GPU 的环形全规约：共 6 步，每步每块 GPU 传输 1/4 的数据，因此每块 GPU 发送的数据量为梯度大小的 6/4 = 2 × (4 − 1)/4 [S34011]。





🔧 技术细节：为何 NCCL 是英伟达护城河的一部分

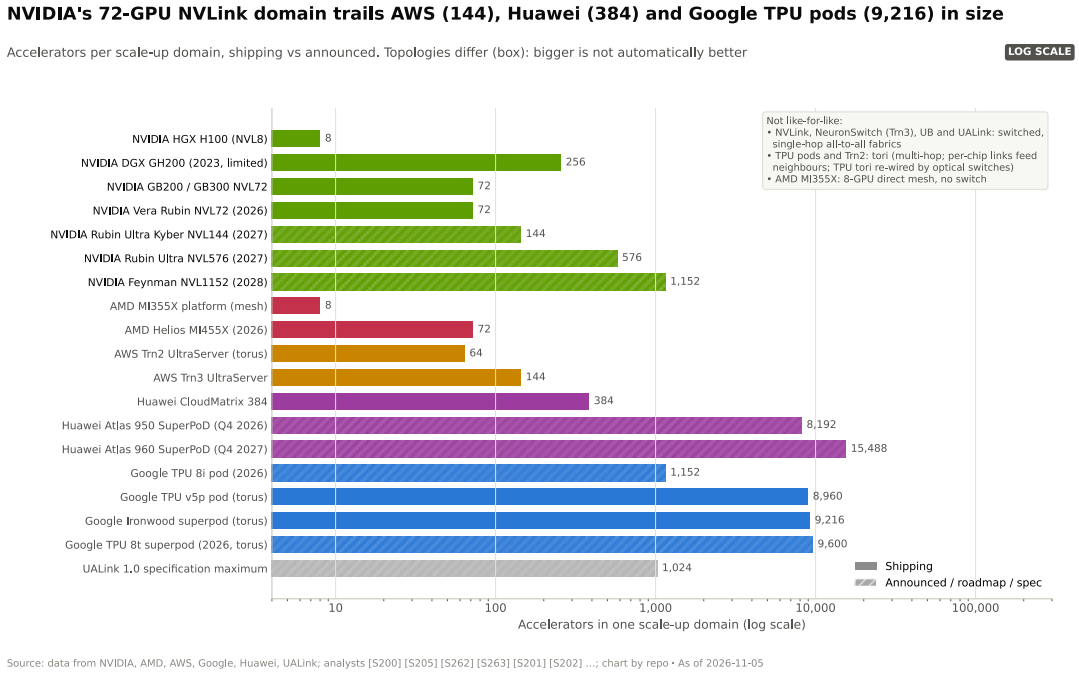
NCCL 是英伟达的集合通信库，它负责选择算法（环形、树形或交换机辅助），把消息拆分成多个通道分布到 NVLink 和网卡上，并让一切与计算重叠——针对其检测到的任何拓扑自动完成 [S34013]。PyTorch 等框架在上述每一种集合通信中都会调用它，因此为 8 GPU 服务器编写的训练脚本无需修改即可在 16,384 块 GPU 的集群上运行。AMD（RCCL）、谷歌（基于 ICI 的 XLA 集合通信）等都有对应方案；差别在于英伟达针对自家 NVLink、NVSwitch、InfiniBand 和 Spectrum-X 硬件（包括交换机内规约）进行的多年调优 [S34024]。详见第 10 层 · 软件库。

注

🐂 **看多观点：** 随着模型转向 MoE、长上下文和推理，通信需求最大的维度（专家并行和上下文并行）增长最快，而它们需要规模最大、速度最快的纵向扩展域。英伟达今天的 NVL72、路线图上更大的 NVLink 域，以及针对它们调优的 NCCL 和 Dynamo，恰好位于流量的去向之处 [S34014,S34007]。

注意

🐻 **看空观点：** 并行本质上是算法，而算法是可以迁移的。DeepSeek 通过重新设计路由和调度，在带宽受限的 H800 上不使用张量并行就训练出了前沿级 MoE 模型 [S34007]；谷歌在 TPU 环面链路上训练 PaLM 时完全没有使用流水线并行 [S34021]；而本页的每一项技术都已存在于开源框架中 [S34004,S34005,S34010]。并且从纸面数据看，英伟达已不再拥有规模最大或速度最快的纵向扩展域：AMD 的 Helios 机架通过 UALink-over-Ethernet 连接 72 块 MI455X GPU，每块最高 3.6 TB/s [S226]，高于 NVLink 6 当前标称的 3.0 TB/s [S33007]；AWS 的 Trn3 UltraServer 连接 144 颗芯片 [S242]；谷歌的 Ironwood pod 规模达到 9,216 颗芯片，尽管采用的是多跳环面结构而非单跳交换 [S232]。如果开放的纵向扩展标准能提供相当的互连域带宽，那么在把工作映射到硬件方面的软件优势就会收窄。



对数坐标横向条形图：各厂商纵向扩展域规模：英伟达 NVL72 目前为 72 块 GPU，2027 年的 Kyber NVL144 和 NVL576 以及 2028 年的 NVL1152（路线图）；AMD Helios 72；AWS Trn3 UltraServer 144；华为 CloudMatrix 384 和 Atlas 950 8,192（2026 年 Q4）；谷歌 Ironwood 9,216 颗和 TPU 8t 9,600 颗芯片，但 TPU pod 采用多跳环面结构而非交换式全交换；UALink 1.0 允许 1,024。

与各层的关联

本页主题	本资料库的深入章节
张量并行和专家并行需要高速纵向扩展域	第 05 层 · 纵向扩展（NVLink、NVSwitch）
数据并行和流水线并行运行在集群网络上；集合通信、SHARP、轨道优化（rail-optimized）网络	第 06 层 · 横向扩展与跨数据中心网络
HBM 容量决定需要拆分到什么程度	第 03 层 · 内存与封装 · P3 · 四大瓶颈
各种拆分必须让 GPU 算力保持满载	第 02 层 · GPU 芯片
NVL72 机架、集群建设及其电力	第 08 层 · 系统、机架与 AI 工厂
NCCL、Megatron 以及实现上述一切的软件库	第 10 层 · 软件库（CUDA-X） · 第 09 层 · CUDA
MoE 服务、分离式推理、Dynamo	第 11 层 · 推理与 AI 软件 · P2 · 推理
算力与 FLOPs 预算为何如此	P1 · AI 训练原理
DeepSeek 协同设计带来的效率冲击	CS5 · DeepSeek 时刻

需要记住的关键数字

指标	数值	为何重要
每参数训练内存（混合精度 Adam）	~16 字节 → 70B 模型 ~1.12 TB [S34004]	迫使进行模型拆分和分片
每 GPU 的环形全规约流量	2(N − 1)/N × 数据量 ≈ 2× [S34011,S34012]	与 GPU 数量无关
70B BF16 梯度同步（64 块 GPU）	400G InfiniBand 上 ~5.5 s，NVLink 5 上 ~0.31 s [S34015,S34014]	每 GPU ~18× 的差距
张量并行全规约次数	每层前向 2 次 + 反向 2 次 [S34001]	TP 留在 NVLink 内的原因
流水线气泡	(p − 1)/(m + p − 1)：16 阶段 × 16 个微批次 → ~48% 空闲 [S34002,S34003]	需要大量微批次或交错调度
Llama 3 405B 布局	TP8 × PP16 × DP128 = 16,384 块 H100，41% MFU；128K 上下文时采用 CP16 [S34006]	4D 并行的参考配方
DeepSeek-V3	总参数 671B / 激活 37B；256 个路由专家，激活 8 个；在 2,048 块 H800 上 PP16 × EP64，无 TP [S34007]	MoE 把瓶颈转移到全交换
MoE 全交换，DeepSeek-V3 级	每 token 每 MoE 层 ~172 KB，每 token 每次前向传播 ~10 MB（本资料库基于 [S34007] 的估计）	纵向扩展带宽成为约束
每 GPU 纵向扩展与横向扩展对比	NVLink 5 1.8 TB/s 对 400–800 Gb/s 网卡；Rubin 3.0 TB/s 对 1.6 Tb/s [S34014,S34015,S33004,S33007]	决定每一种布局的 ~8–18× 落差

🎯 企业发展视角

1. **并行策略决定网络投资的去向。** 张量并行和专家并行购买的是纵向扩展带宽（NVLink 交换机、铜缆背板）；数据并行和流水线并行购买的是横向扩展（网卡、交换机、光模块）。随着 MoE 和长上下文的增长，集群网络支出中会有多大比例转向纵向扩展域——英伟达控制最严密的部分——而 UALink 或以太网纵向扩展又能以多快的速度夺回这部分份额?
2. **映射方面的专有技术是一条有开源“影子”的软件护城河。** NCCL、Megatron-Core 和 Dynamo 凝聚了多年的调优积累 [S34013,S34002]；PyTorch FSDP、DeepSpeed 和 JAX 则提供了可移植的对应方案 [S34005,S34004]。对挑战者而言，“在我们的网络上实现出色的集合通信，并合入 PyTorch 上游”是一项可以自建的资产、可以收购的资产，还是需要与现有框架团队合作?

3. **算法与系统的协同设计可以替代硬件**。 DeepSeek-V3 避免使用张量并行，并限制跨节点流量，以适配受出口管制限制的 GPU [S34007]。未来哪些模型层面的变化（每 token 激活更少专家、更小的隐藏维度、规避通信的注意力机制）会降低大型纵向扩展域的溢价——谁又会因此受益？
4. **推理也正在变成一个并行问题**。 跨数百块 GPU 的大规模专家并行服务 [S34007] 更有利于系统厂商而非芯片厂商。一款注重效率的推理产品能否在较小的互连域内服务前沿 MoE 模型，还是必须接入更大的网络（例如通过 NVLink Fusion 或 UALink）？ 这是第 19 章要讨论的问题，以选项的形式呈现。
5. **集合通信是一个元器件层面的价值池**。 网内规约、全交换加速、拥塞控制和网卡卸载 [S34024] 位于芯片与软件之间。哪些供应商和初创公司掌握了其中的部分环节？对于一个进入数据中心市场的新玩家而言，哪些适合合作、哪些适合收购？

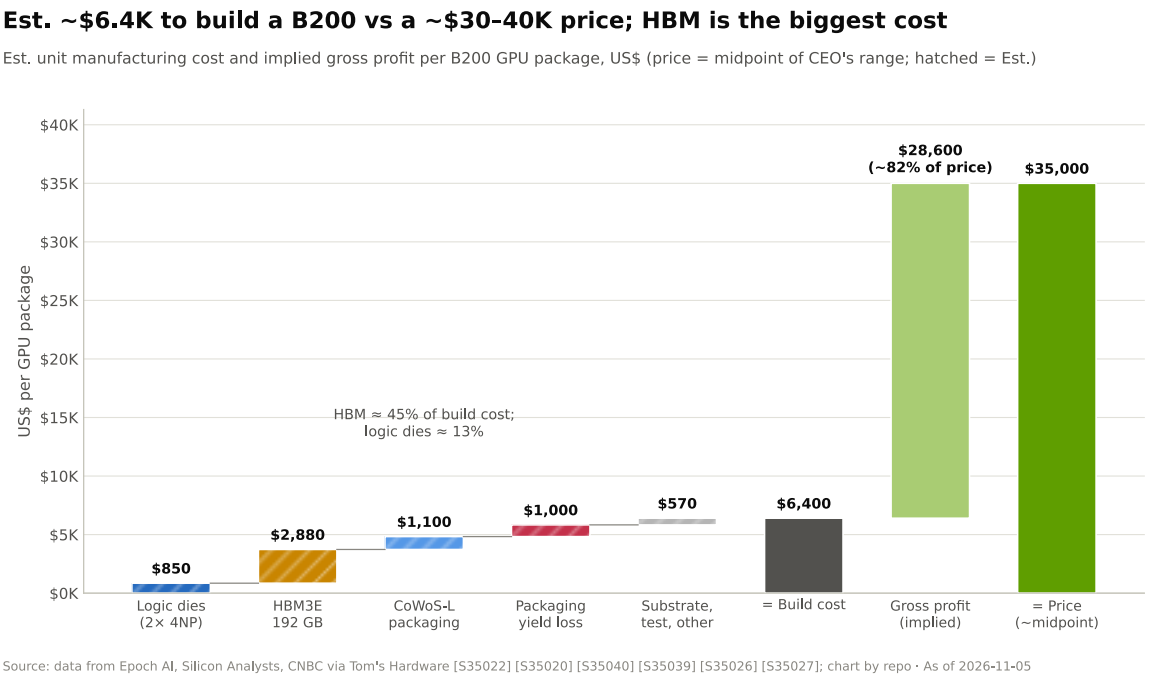
P5 · 芯片经济学入门

入门篇 P5 · 晶圆、良率、光罩尺寸极限、芯粒、封装、HBM 与每 FLOP 成本 · 约 22 分钟阅读 · 最近核实：2026-11-05

> 注
>
> **如果你熟悉电子表格和财务、但不熟悉芯片，请从这里开始。** 本篇把一块 GPU 拆解成一个 成本模型：一片晶圆要多少钱、能切出多少颗可销售的裸片、封装和内存又会增加多少成本， 以及为何最终结果能够支撑英伟达的利润率。每个数字都附有出处；估计值标注“估计”并注明估计方，因为产业链上没有任何一方公布这些价格。

⚡ 要点速览

- **一片先进制程晶圆的价格如今约为三个节点之前（N7 → N2）的 3 倍。** 已公开的估计显示，一片 300 mm 台积电（TSMC）晶圆在 N7 上 ~$9.4K [S35001,S35006]，在 N5/N4 上 ~$17K [S35001,S35020]， 在 N2 上 ~$30K [S35003]；A16 据传最高可达 $45K [S35004]（🔴 传闻）。台积电并不公布价格。
- **大裸片的成本高得不成比例。** 在标准良率模型中，当缺陷密度为 0.1 个/cm² 时，一颗 814 mm² 的 H100 级 裸片无缺陷的概率只有 ~44%，而 100 mm² 的手机芯片约为 ~90%，因此面积是 8 倍，每颗良品裸片的成本却高出 ~21 倍（本资料库模型；输入数据 [S35020,S35008]）。
- **光罩尺寸极限（~858 mm²）迫使英伟达转向多裸片 GPU。** H100 裸片（814 mm²）已用掉其中的 ~95% [S35013,S35010]；B200 将两颗达到光罩尺寸极限的 裸片连接在一起（208B 晶体管）[S35014]；🟢 Rubin Ultra（2027 年下半年）发布时宣布采用四颗裸片 [S35018]，但 🟡 有报道称已改为双裸片版本 [S509]。
- **主导制造成本的是内存和封装，而非 GPU 裸片。** Epoch AI 估计一颗 B200 的制造成本 ~$6,400（区间 $5.7–7.3K），其中高带宽内存（HBM）约占 45%，而两颗逻辑 裸片在计入封装损耗之前仅占 ~13%（估计，Epoch AI；Silicon Analysts）[S35020,S35022]。
- **成本只占售价的一小部分。** 相对于 $30–40K 的 B200 售价 [S35026]，制造成本约为 ~16–21%，即芯片层面的毛利率接近 80%（估计）[S35020]；英伟达公布的公司整体毛利率 更低，因为它销售的是整套系统，并会计提存货减值（见第 7 节）。
- **目前只有台积电能够大规模制造这些产品。** 2026 年 Q2，台积电在全球前十大晶圆代工厂收入中占 72.5% （三星 5.9%）[S35035]，并给出 2026 年 $52–56B 的资本开支指引 [S35029]，约为其 2019 年 水平的 ~3.6 倍 [S35032]——这一规模无任何对手能够企及。
- **每 FLOP 成本持续下降，但主要靠更低精度的运算**，而非更便宜的芯片： 每稠密 PFLOPS 的系统价格从 2017 年 DGX-1 的 FP16（~$155K）降至 Vera Rubin NVL72 的 NVFP4（~$3.1K，估计），下降 ~50×；而在 BF16 口径下，最低点出现在 GB200 NVL72，~$17K [S312,S326,S330,S33005]。



Source: data from Epoch AI, Silicon Analysts, CNBC via Tom's Hardware [S35022] [S35020] [S35040] [S35039] [S35026] [S35027]; chart by repo · As of 2026-11-05

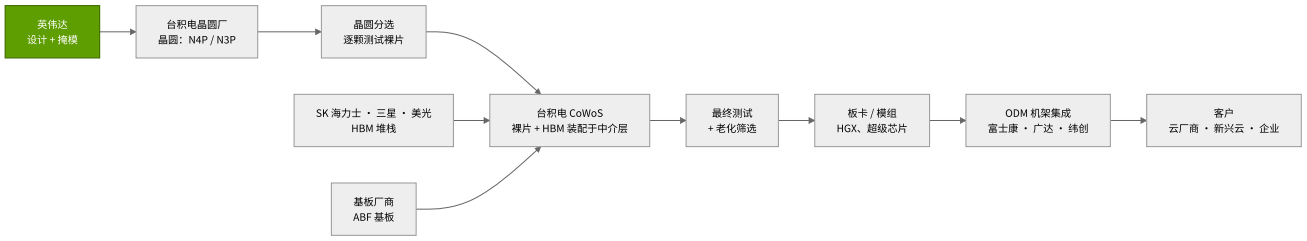
瀑布图：B200 估计成本构成：逻辑裸片约 $850，HBM3E 约 $2,880，CoWoS-L 封装约 $1,100，封装良率损失约 $1,000，其他约 $570，合计约 $6,400；对比约 $35,000 的售价，隐含芯片层面毛利率接近 82%。

1. 从沙子到 GPU：制造链条

可以把芯片制造想象成**在一只餐盘上一层又一层地印制城市地图，重复 80–100 次**。这只餐盘就是晶圆：一片直径 300 mm 的超高纯度硅圆片 [S35001]。 光刻机让光线穿过光掩模 （电路某一层的模板），将图案印到晶圆上；随后通过化学工序进行刻蚀、 沉积和离子注入，每一层都重复这

一循环。完成的晶圆上布满 相同的矩形，每一个都是一颗裸片（die）。裸片在晶圆上完成测试后被切割下来， 良品再与内存一起装配进先进封装中。 到这一步，GPU 才真正诞生。

每一块英伟达数据中心 GPU 在到达客户手中之前，都要经过四类公司或群体之手：



晶圆代工厂（台积电）负责“印制”；存储厂商供应 HBM；基板 厂商供应封装所依托的底层基板；ODM（原始设计 制造商）则负责组装板卡、托盘和机架。英伟达不拥有任何一座工厂。它拥有的是 设计、每一道工序的规格，以及越来越多地在每个环节预付锁定的产能（参见 第 03 层）。

一张表看懂工艺节点

工艺节点是一代制造技术。节点名称 （“N3”“2 nm”）是营销标签，并不对应实际物理尺寸；重要的是，每个节点都能在同样面积内 容纳更多晶体管，而每片晶圆的价格也更高。

台积电节点	首次量产	晶体管 / 设备变化	采用该节点的英伟达数据中心 GPU	估计晶圆价格
N7	2018 S35001	FinFET；首次混用 DUV/EUV	A100（826 mm² 裸片） S35042	~$9.4K S35001,S35006
N5 / N4 系列	2020 S35008	FinFET，更多 EUV 层	H100 采用定制 4N S35011；B200 采用 4NP S35014	~$15–18.5K S35005,S35006
N3 系列	2022 S35002	最后一代 FinFET 节点	🟢 Rubin（N3 级） S35015	~$20–26K S35002,S35003
N2	2025 S35009	首个全环绕栅极（GAA）纳米片节点	—	~$30K S35003
A16	2026 年下半年 S35004	新增背面供电	🟡 有报道称 Feynman（2028）将采用，英伟达未确认 S119	最高 $45K（传闻） S35004

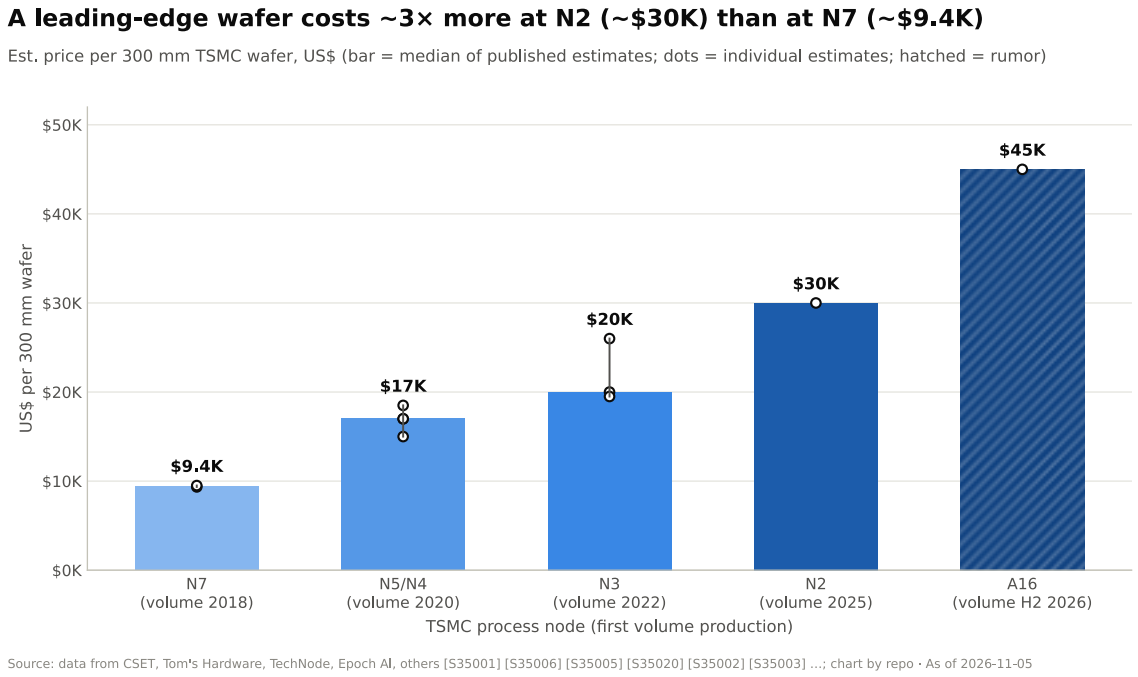
> **提示**
>
> **算例 —— “一片晶圆”能买到什么。** 一片 300 mm 晶圆的面积为 $\pi \times 150^2 \approx 70{,}700$ mm²。扣除圆形边缘处不完整的裸片后，一颗 814 mm² 的 H100 裸片 约可放下 ~63 颗（公式见第 3 节）。按估计每片 4N 级晶圆 $17,000 计算 S35020，每颗*印制出来的*裸片 背后的硅成本约为 ~$270，这还没有计入任何缺陷。本篇余下的内容将解释 为何每块可销售 GPU 的真实成本约为这一数字的 ~25 倍。

🔧 技术细节：节点之间发生了哪些变化

- **EUV。** 极紫外光刻使用 13.5 nm 波长的光，一次曝光即可印制 最精细的层，而使用较老的深紫外光则需要三到四次。每个节点的 EUV 层数越多，工序就越少， 但设备也贵得多，这一点会体现在晶圆价格上。
- **全环绕栅极（N2）。** 晶体管的栅极从四个侧面包裹沟道（纳米片）， 而非三个侧面（FinFET），从而降低漏电。台积电报告称，N2 在同一研发阶段的缺陷密度*低于* N3 S35009。
- **背面供电（A16）。** 把供电线路移到晶体管下方，可以把上层布线资源留给 信号；这对 AI 加速器这类高功耗芯片最为重要。
- **高数值孔径（High-NA）EUV。** 下一代光刻机能印制更精细的图形，但单次曝光面积只有原来的一半 （26×16.5 mm = 429 mm²） S35010——这将更有力地推动多裸片设计（见第 4 节）。

2. 各节点的晶圆价格：为何每一代都更贵

每个节点都需要更多的工艺步骤、更多次 EUV 曝光，以及一座耗资数十亿美元的新晶圆厂，而 台积电的定价就是为了收回这些投资。结果是一道陡峭的阶梯：



条形图：台积电各节点的估计晶圆价格：N7 约 $9,400，N5/N4 约 $17,000，N3 约 $20,000，N2 约 $30,000，A16 据传为 $45,000；因此 N2 晶圆的价格约为 N7 的 3 倍。

关于这些数字，有三点需要了解。第一，它们是**估计值和报道中的报价**，而非 挂牌价格：CSET 的 N7/N5 数字来自一个资本成本模型 [S35001]；N3 和 N2 的数字 来自媒体报道的台积电报价 [S35002,S35003]；A16 的 $45K 是传闻 [S35004]。第二， 估计区间很宽——N3 的估计从 ~$19.5K [S35006] 到 $25–27K [S35003] 不等——因为价格 因客户、采购量和合同年份而异 [S35005]。第三，在需求紧张时，价格**会在节点的生命周期内上涨**： 台积电每片 300 mm 晶圆的综合平均价格在一年内上涨了 22%，从 2022 年 Q4 的 $5,384 升至 2023 年 Q4 的 $6,611（估计，Dan Nystedt）[S35007]；另据报道，N3P 价格在 2025 年上调了 ~20%，挤压了高通（Qualcomm）和联发科等智能手机芯片设计公司 [S35037]。

提示

算例 —— 制程微缩必须能覆盖晶圆涨价。 假设在一片 $17K 的 4N 级晶圆上，一颗 GPU 裸片的良品 硅成本约为 ~$609（第 3 节的模型）。把同一设计迁移到每片 ~$30K 的 N2 上 [S35003]，如果裸片面积没有缩小，每颗良品裸片的成本将是 $609 × 30/17 ≈ $1,075。仅仅为了 打平成本，裸片面积就必须缩小 ~43%（且良率也要相当）。如此幅度的密度提升已不再 是理所当然的事，因此在先进制程上，**每个晶体管的成本如今下降缓慢，甚至不再下降。** 这就是英伟达连续三代产品（H100、B200、 B300）都停留在 4N/4NP 级工艺上、直到 Rubin 才转向 N3 的原因 [S35011,S35014,S35015]。

注意

误区与事实：“摩尔定律让芯片每年都更便宜。” 晶体管仍在变小， 但承载它们的晶圆价格几乎以同样快的速度上涨。如今每美元性能的提升 主要来自架构（更低精度的运算、更大的封装、更快的内存和互连），而非 更便宜的芯片。

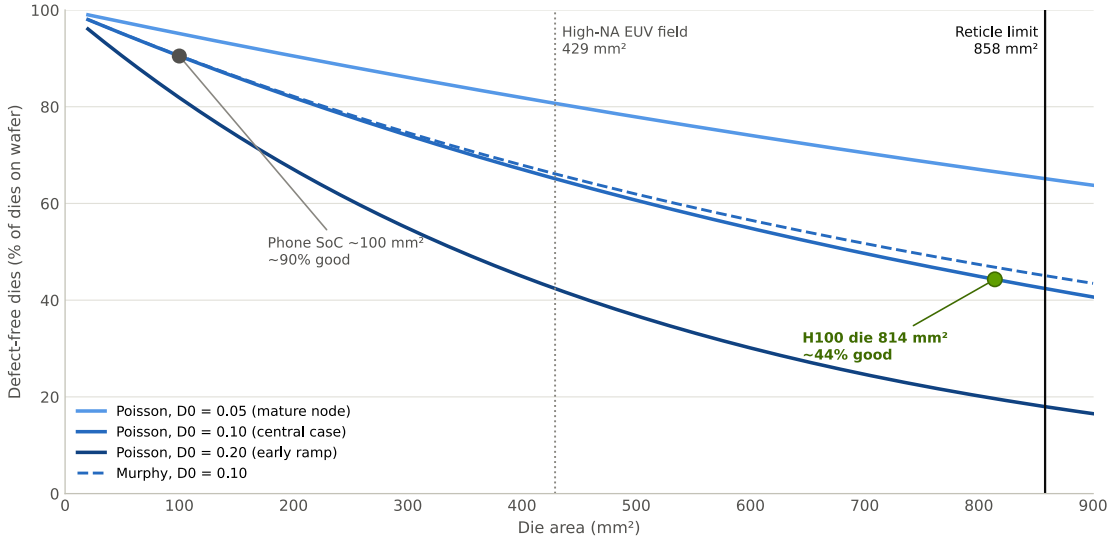
3. 每片晶圆的裸片数与良率：为何大裸片昂贵

类比。 想象雨水落在铺了瓷砖的地面上。雨滴（随机的制造缺陷）以大致固定的 单位面积密度落下。小瓷砖大多保持干燥；大瓷砖则很可能至少被一滴雨打中。裸片上任何位置 出现一个致命缺陷都可能使其报废，因此**良率随裸片面积呈指数下降**。

有两个数字起决定作用。每片晶圆裸片数纯粹是几何问题。缺陷 密度（D0，每 cm^2 的缺陷数）代表晶圆厂的质量水平；台积电只以 相对曲线的形式展示它（同一阶段 N5 低于 N7 [S35008,S35036]；N2 低于 N3 [S35009]），因此本篇 采用 0.05–0.20 的示意区间，并以 0.10 作为基准情形。

An 814 mm² GPU die yields ~44% vs ~90% for a 100 mm² phone chip

Modelled share of defect-free dies vs die area; central case D0 = 0.1 defects/cm² (Poisson and Murphy models; no harvesting)



Source: data from repo yield model; parameters from CSET, SemiEngineering, Epoch AI [S35010] [S35001] [S35008] [S35009] [S35020]; chart by repo · As of 2026-11-05

折线图：建模得到的裸片良率与裸片面积的关系：缺陷密度为每平方厘米 0.1 个时，良率从 100 mm2 裸片的约 90% 降至 814 mm2 H100 级裸片的约 44%；缺陷密度为 0.2 时约为 20%；858 mm2 的光罩尺寸极限限制了裸片尺寸上限。

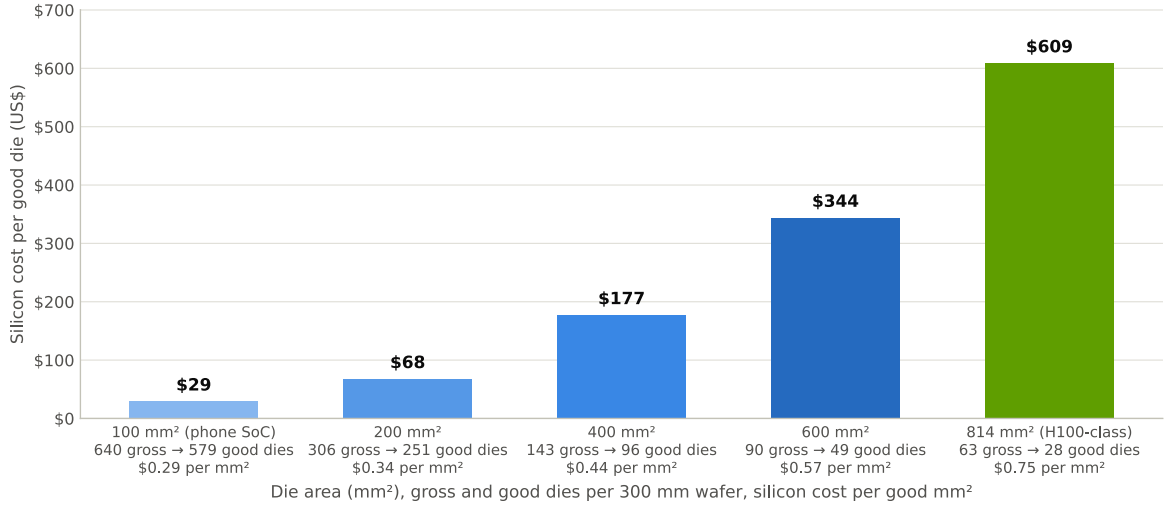
提示

算例 —— 300 mm 晶圆上一颗 ~800 mm² 的裸片。 以 814 mm² 的 H100 裸片为例 [S35013]。1. *每片晶圆毛裸片数* ≈ π·150²/814 − π·300/√(2·814) = 86.8 − 23.4 ≈ **63**。2. *良率*（泊松模型，D0 = 0.10/cm²，面积 8.14 cm²）：e^(−0.814) ≈ **44%** → ~28 颗良品裸片。3. *每颗良品裸片成本*，按每片晶圆 $17,000 计 [S35020]：$17,000 / 28 ≈ **$609**。4. *同一片晶圆，100 mm² 的手机芯片：* 640 颗毛裸片 × 90% 良率 ≈ 579 颗良品 → **每颗 ~$29**。

GPU 裸片面积大 8 倍，成本却高出 ~21 倍：**每 mm² 良品面积 $0.75 对 $0.29**。Epoch AI 的 B200 模型假设裸片良率为 40–70%（中值 60%）[S35020]，在本模型中对应 D0 ≈ 0.05–0.11—— 处于同一量级。

An 8× bigger die costs ~21× more: ~$29 for 100 mm² vs ~$609 for 814 mm²

Modelled silicon cost per defect-free die, $17K 4N-class wafer, 0.1 defects/cm², US$ (excl. test, packaging, harvesting)



Source: data from repo model; wafer price assumption from Epoch AI [S35020] [S35008] [S35009]; chart by repo · As of 2026-11-05

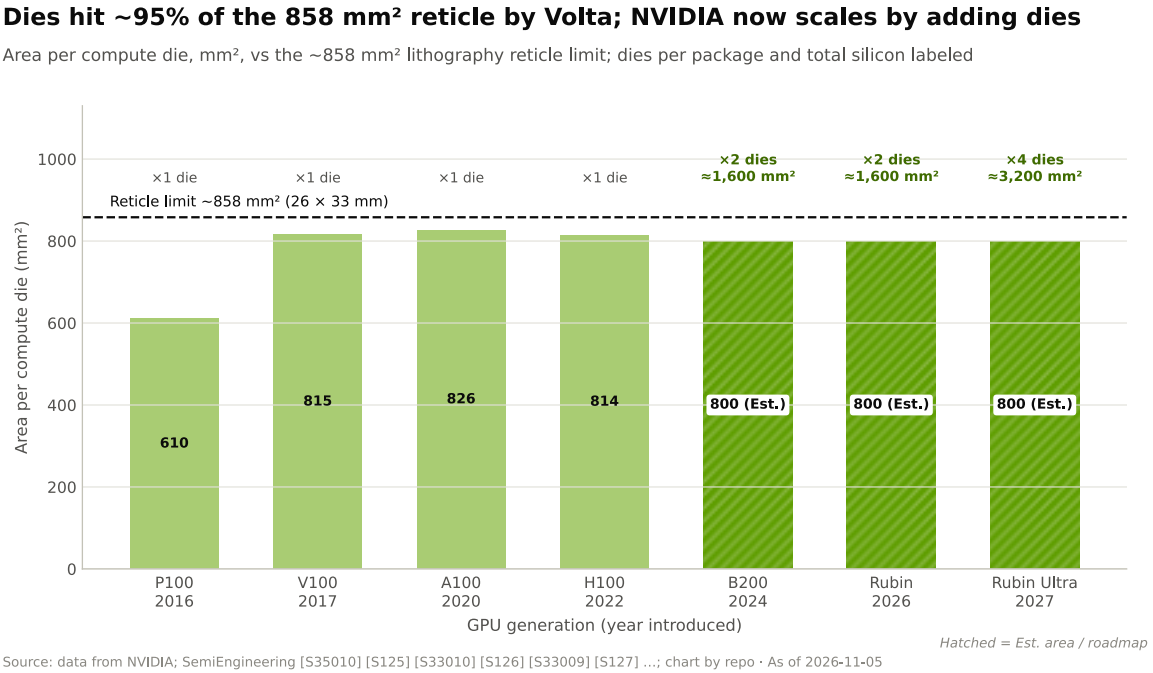
条形图：在一片 $17,000 的晶圆上，建模得到的每颗良品裸片成本：100 mm2 裸片约 $29（每片晶圆 579 颗良品），814 mm2 裸片升至约 $609（28 颗良品）；面积增加 8 倍，成本约高出 21 倍。

业界有两种惯常做法可以缓和这条曲线。**裸片降级利用（die harvesting）**：GPU 由许多 相同的模块构成，因此某个模块存在缺陷的裸片，仍可在关闭该模块后出售。完整的 GH100 裸片 在 144 个流式多处理器中拥有 18,432 个 FP32 核心 [S35042]，而 H100 SXM5 出货时只启用其中 132 个 [S33024]——这是内置的良率缓冲。**冗余设计**：测试后用备用的存储行和 列进行替换。两者都使实际良率高于简单模型的结果，这正是 大裸片 GPU 得以可行的原因。

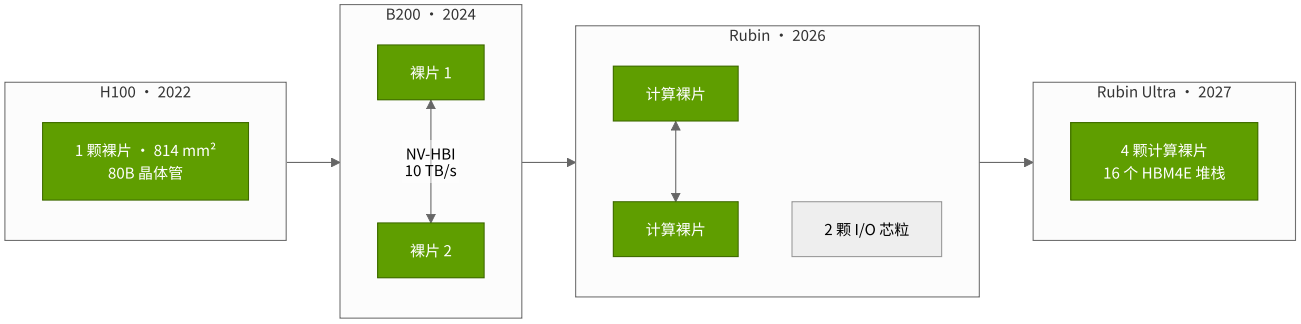
> 🔧 **技术细节：公式及其局限**
>
> - **每片晶圆毛裸片数：** DPW = π·(d/2)²/S − π·d/√(2S)，其中 d = 晶圆直径（mm），S = 裸片 面积（mm²）。第二项近似表示边缘处损失的不完整裸片。实际数量会低几个 百分点，原因是存在划片道（裸片之间的切割通道）和边缘排除区。
> - **泊松良率：** Y = e^(−A·D0)。假设缺陷相互独立且均匀分布；对大裸片而言 偏于悲观。
> - **Murphy 良率：** Y = [(1 − e^(−A·D0)) / (A·D0)]²。假设缺陷呈聚集分布，这会使大裸片的 良率略高（图中虚线：814 mm² 时约为 ~47%，而泊松模型为 ~44%）。
> - **模型未考虑的因素：** 参数良率（能工作但未达到速度或功耗目标的裸片）、 裸片降级利用以及测试成本。应将输出视为数量级参考，而非晶圆厂报价。 模型代码位于 `scripts/charts/ch_primer_p5.py`，输入数据位于 `data/P5_wafer_economics.csv`。

4. 光罩尺寸极限与向多裸片 GPU 的转变

光刻机无法印制任意大的裸片：一次曝光最多覆盖 26 × 33 mm 的区域， 即 ~858 mm² 的**光罩尺寸极限** [S35010]。英伟达的数据中心 GPU 连续三代 撞上这堵墙——V100 为 815 mm² [S126]，A100 为 826 mm² [S127]，H100 为 814 mm² [S35013]——因此此后每增加一个晶体管，要么来自更先进的节点，要么来自 **每个封装中更多的裸片**。



条形图：英伟达各代 GPU 计算裸片面积与 858 mm2 光罩尺寸极限的对比：P100 610 mm2，V100 815、A100 826 和 H100 814 mm2 均约为极限的 95%；Blackwell 和 Rubin 采用两颗光罩尺寸的裸片（约 1,600 mm2 计算硅面积，估计），Rubin Ultra 采用四颗（约 3,200 mm2），因此如今的扩展来自封装更多的裸片，而非更大的裸片。



GPU 封装	计算裸片	晶体管数	每封装 HBM	状态
H100（Hopper）	1 × 814 mm²，台积电 4N	80B [S35011]	80 GB HBM3 [S33002]	🟢 2022 年起出货
B200（Blackwell）	2 颗达到光罩尺寸极限的裸片，台积电 4NP，10 TB/s 裸片间互连	208B [S35014]	物理容量 192 GB（HGX 中启用 180 GB） [S35020,S33003]	🟢 出货中
Rubin	2 颗光罩尺寸的计算裸片 + 2 颗 I/O 芯粒，N3 级	336B [S35015]	288 GB HBM4，8 个堆栈 [S33006]	🟢 量产中；合作伙伴系统 2026 年下半年 [S35016]
Rubin Ultra	4 颗光罩尺寸的计算裸片 [S107]	不适用	1 TB HBM4E，16 个堆栈 [S35018]；🟡 一则报道称已削减至 768 GB [S111]	🟢 路线图 2027 年下半年 [S35018,S33020]；🟡 有报道称将推出双裸片版本 [S509]

工程上的诀窍在于裸片间互连：如果两颗裸片 之间交换数据足够快（英伟达公布 Blackwell 为 10 TB/s [S35014]），软件看到的就是一块 GPU。经济上的诀窍在于，每颗裸片都**在封装之前完成测试**（即已知良品 裸片（known good die）），因此一个缺陷只会报废一颗小裸片，而不是一

颗巨型裸片。这就是 芯粒（chiplet）的逻辑，AMD 在自家加速器中更早、更激进地采用了这一思路 （参见 AMD 竞争）。

> **提示**
>
> **算例 —— 为何两颗 800 mm² 裸片胜过一颗 1,600 mm² 裸片。** 使用第 3 节的模型，取 D0 = 0.10、每片晶圆 $17K：两颗经过测试的 814 mm² 裸片的硅成本为 2 × $609 ≈ **$1,220**。一颗 假想的 1,628 mm² 单裸片（无论如何都无法制造，因为它约为光罩尺寸的 ~1.9 倍）每片晶圆 约可放下 ~27 颗，良率 ~20% → ~5 颗良品 → **每颗 ~$3,100**。拆分裸片可使 硅成本降低 ~60%；代价是需要裸片间互连，以及一个更复杂、更昂贵的封装。

> **重要**
>
> **最需要记住的一点：** 光罩尺寸极限把一个*芯片设计*问题转化成了一个 *封装*问题。一旦 GPU 变为多裸片结构，稀缺资源就从晶圆转向了连接裸片与内存的 先进封装——而这正是 2023–2025 年供应瓶颈出现的地方。

5. 先进封装：CoWoS 及其为何成为瓶颈

一块现代 AI GPU 不是一颗芯片，而是一座小城市：计算裸片和 8–16 个 HBM 堆栈并排放置在 中介层上——中介层是一块薄硅片（或嵌入有机层中的 硅桥），在它们之间承载着数以万计的微细导线。正是这种布线密度 让 HBM 能够提供每秒数 TB 的带宽。台积电的方案是 CoWoS（Chip-on-Wafer-on-Substrate，晶圆上芯片再上基板），共有三种类型：

类型	承载布线的结构	典型用途	估计每 GPU 封装成本
CoWoS-S	一整块单片硅中介层	A100、H100、H200	~$750（H100）[S35040]
CoWoS-L	嵌入较大重布线层中的小型硅桥（局部互连）	B200、B300、Rubin	~$1,100（B200）[S35040]
CoWoS-R	有机重布线层中介层，不含硅	成本更低、密度更低的设计	不适用

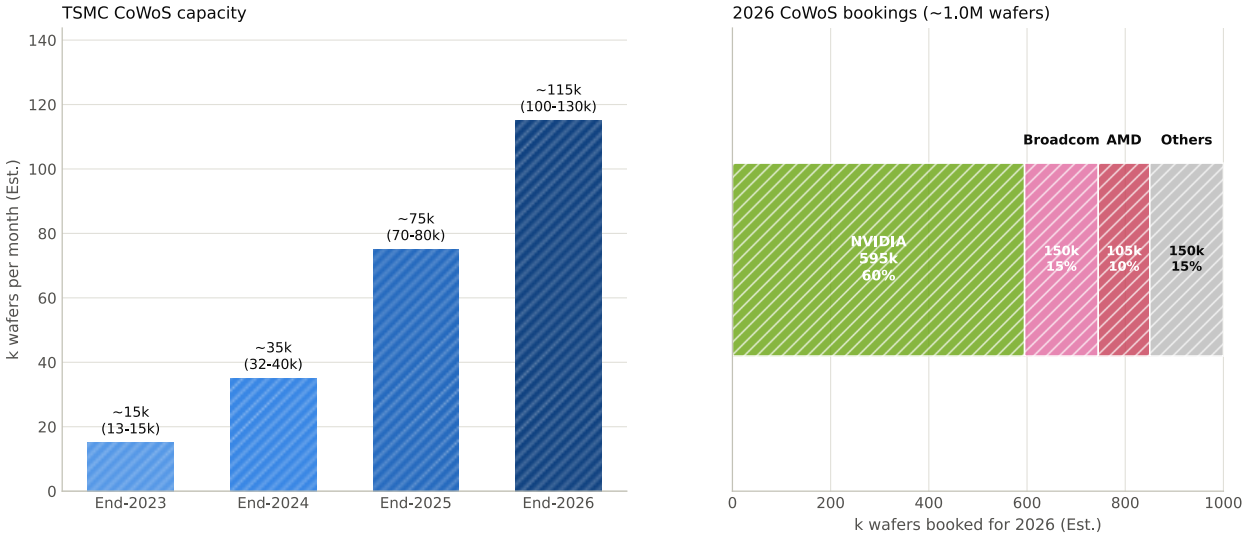
为何采用 CoWoS-L？单片硅中介层本身也受光刻限制——CoWoS-S 最大约为光罩尺寸的 3.3 倍——因此难以从容容纳两颗光罩尺寸的裸片外加八个 HBM 堆栈； 硅桥让封装得以继续变大（台积电路线图显示，2026 年约为光罩尺寸的 ~5.5 倍，2027 年约为 ~9.5 倍），同时 只在裸片相接处保留精细布线 [S380]。代价是复杂度：更多部件必须完美键合， 而且**一个未通过最终测试的封装，会把其中已经付过钱的裸片和 HBM 一并报废** [S35020]。

> **提示**
>
> **算例 —— Epoch 的“封装良率损失”意味着什么。** Epoch AI 的 B200 模型在 ~$850 的逻辑裸片、 ~$2,880 的 HBM 和 ~$1,100 的封装之外，还计入了 ~$1,000 的封装良率损失 （估计）[S35020,S35022,S35039]。如果投入一个封装的部件成本 ~$4,830，而每个良品单元分摊的良率损失 约为 ~$1,000，那么 4,830 × f / (1 − f) = 1,000 → f ≈ 17%，即**大约每六个封装 就有一个失败**（🔴 本资料库推断）。Epoch 指出，Blackwell 封装良率在早期较低，此后 有所改善，但很可能仍落后于 Hopper [S35020]。封装良率每提高几个百分点，就价值 每块 GPU 数百美元——以及大量稀缺的 HBM。

封装为何成为瓶颈。 CoWoS 产能原本是为小众的 HPC 市场设计的，而一旦每一款 AI 加速器都需要它， 产能就必须成倍扩张：台积电表示，2024 年产能增长一倍以上， 2025 年还将再翻一番左右 [S378]。据报道，英伟达占据了 2026 年 CoWoS 配额的 ~60%（~595K 片晶圆），领先于博通（Broadcom，~150K）和 AMD（~105K）（🟡 媒体估计）[S379]。 HBM 供应也面临同样的问题（详见第 03 层）。

Est.: TSMC CoWoS capacity grew ~8× from 2023 to 2026, and NVIDIA booked ~60% of 2026 wafers

Left: year-end CoWoS run-rate, k wafers/month (midpoint of press-reported ranges) · Right: 2026 CoWoS bookings by customer, k wafers



All values Est. (TSMC does not disclose CoWoS wafers)

Source: data from TrendForce, Morgan Stanley via trade press, TSMC [S379] [S378]; chart by repo · As of 2026-11-05

两组估计数据图。左：台积电 CoWoS 产能在 2023 年底约为每月 15k 片晶圆，2024 年 35k，2025 年 75k，2026 年约 115k，增长约 8 倍。右：在 2026 年约 1,000k 片晶圆的 CoWoS 需求中，英伟达约 595k（60%），博通 150k，AMD 105k，其他约 150k。

台积电如今将 2026 年 $52–56B 资本开支预算中的 10–20% 划拨给先进封装、测试和光掩模 [S35029]——一年之内约为 $5–11B 量级。

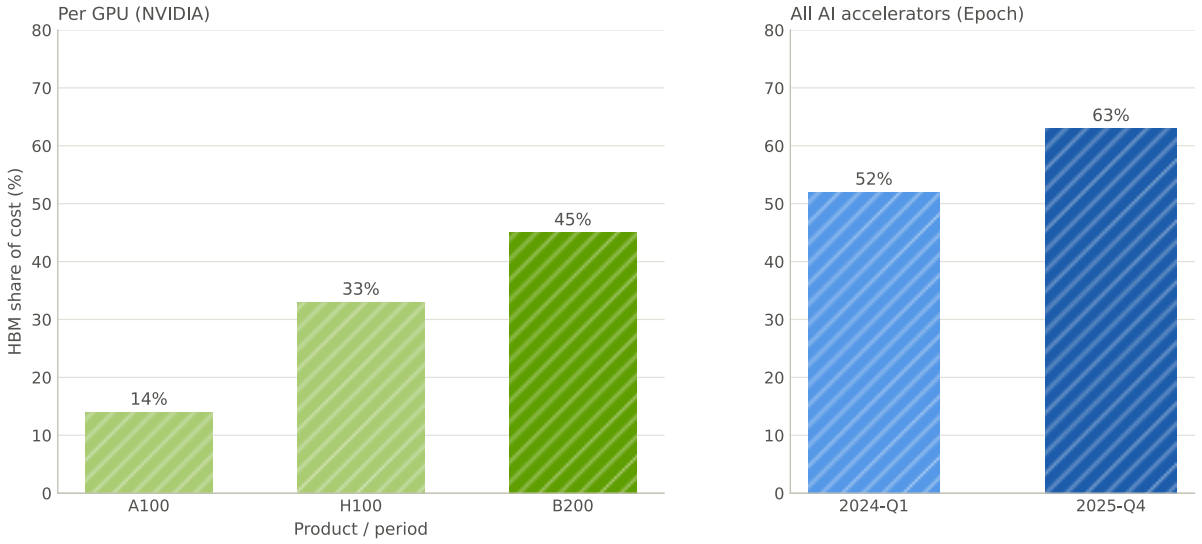
> 🔧 **技术细节：已知良品裸片、基板与外包后道工序**
>
> - **已知良品裸片（KGD）。** 每颗计算裸片和每个 HBM 堆栈都在组装前完成测试；封装一旦键合 便无法返工，因此键合前的测试覆盖率是一项经济决策。
> - **基板。** 中介层安装在有机封装基板（ABF 积层膜）之上，由基板把信号和电源 扇出到电路板。大型 AI 封装使用的是量产中尺寸最大的一批基板，这也是偶尔出现的另一个约束。
> - **OSAT。** 外包半导体封装测试公司（OSAT），如 日月光/矽品和 Amkor，承担部分后道工序；台积电则把最先进的 “晶圆上芯片”（chip-on-wafer）工序基本保留在内部，这也是其牢牢掌控 AI 加速器的原因之一。

6. HBM：成本已超过 GPU 裸片的内存

HBM 是把 8–16 颗 DRAM 裸片堆叠起来、并直接垂直贯穿堆栈布线的内存。一颗 B200 物理上搭载 192 GB HBM3E [S35020]（在 HGX 系统中启用 180 GB [S33003]）；Rubin 在八个堆栈中搭载 288 GB HBM4 [S33006]，每 GPU 带宽最初公布为 22 TB/s [S33006]，如今英伟达产品页上列为 19.2 TB/s [S33007]（🟢 英伟达规格页，于 2026 年 9–10 月修订；原因未作说明 [S90006]）。存储厂商对 HBM 的每 GB 定价是普通 DRAM 的数倍，而每块 GPU 搭载的 HBM 容量每一代都在增加——因此 HBM 在物料成本中的占比持续攀升。

HBM rose from ~14% of an A100's build cost to ~45% of a B200's

Estimated HBM share of unit manufacturing cost (left) and of all AI-accelerator component spend (right), %



All values are estimates

Source: data from Silicon Analysts, Epoch AI [S35023] [S35020] [S35021]; chart by repo · As of 2026-11-05

两组条形图：HBM 在单位成本中的占比从 A100 的约 14% 升至 H100 的约 33%，再到 B200 的约 45%；在全部 AI 加速器中，内存在元器件支出中的占比从 2024 年 Q1 的 52% 升至 2025 年 Q4 的 63%。

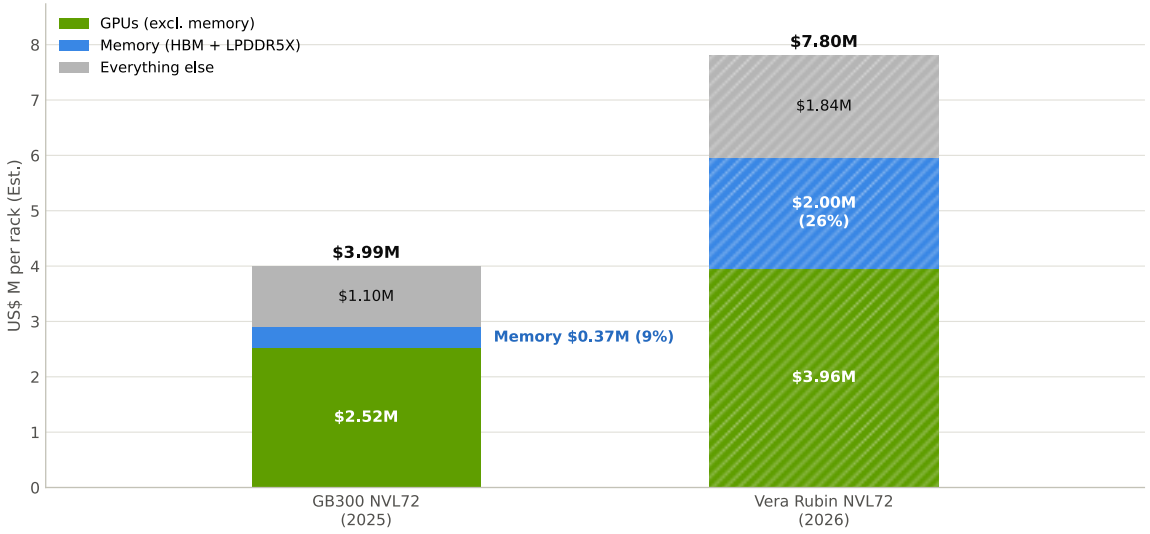
提示

算例 —— 以美元计的 HBM。 按 Epoch 的 HBM3E 中值价格每 GB ~$15 计算 [S35020]，一颗 B200 的 192 GB 成本 ~$2,880，约占其 ~$6,400 制造成本的 ~45%。如果 Rubin 的 288 GB HBM4 按 *同样*的 $15/GB 计价，成本约为 ~$4,320；若 HBM4 溢价 30%，则约为 ~$5,600（🔴 示意性 假设）。无论哪种情况，**仅内存一项的成本就会超过一整颗 B200 的逻辑裸片、封装和 测试成本之和**，这就是 HBM 供应商（SK 海力士、三星、美光（Micron））已成为重要价值 池的原因，也是 Rubin 的带宽规格取决于存储厂商交付能力的原因。

在机架层面同样可以看到这一转变：摩根士丹利的拆解显示，内存在 GB300 NVL72 成本中的占比约为 ~9%，而在 Vera Rubin NVL72 中升至 ~26%（估计）[S332]。

Est.: memory rises from ~9% to ~26% of an NVL72 rack's cost (GB300 → Vera Rubin)

Morgan Stanley rack BOM (ODM price to hyperscaler, May 2026), US$ M · memory = HBM + CPU-attached LPDDR5X



Source: data from Morgan Stanley via PC Gamer, Wccftech, iTiger [S332] [S331] [S330]; chart by repo · As of 2026-11-05

堆叠条形图：NVL72 机架估计成本：GB300 NVL72 为 $3.99M，其中 GPU $2.52M、内存 $0.37M（9%）；Vera Rubin NVL72 为 $7.80M，其中 GPU $3.96M、内存 $2.00M（26%），每机架内存支出增长 5.4 倍。

7. 综合起来：物料清单与售价

一块 GPU 的物料清单（BOM）由四个层次相加而成：良品逻辑裸片、 HBM、封装（含良率损失）以及基板/测试。没有任何厂商公布它；两份独立的 分析师估计给出了其大致范围。

项目（估计）	H100（2023）	B200（2025）	来源
计入良率后的逻辑裸片	~$1,200，含其他（倒挤）	~$850（两颗裸片）	S35023,S35022
HBM	~$1,350（80 GB）	~$2,880（192 GB）	S35023,S35020
先进封装	~$750（CoWoS-S）	~$1,100（CoWoS-L）	S35040
封装良率损失	已含于上方	~$1,000	S35020,S35039
基板、测试及其他	已含于上方	~$570（倒挤）	S35020
制造成本合计	**~$3,320**（Raymond James）	**~$6,400**（Epoch AI；$5.7–7.3K）	S35024,S35020
Epoch 自己的 B200 拆分	—	逻辑（含损失）~$1.7–2.2K；HBM ~$2.7–3.3K；CoWoS-L ~$1.1–1.5K；其他 ~$0.2–0.3K	S355
报道的售价	~$25–30K	~$30–40K	S35024,S35026
制造成本占售价比例	**~11–13%**	**~16–21%**	本资料库测算

提示

算例 —— 从 1,000% 的“加价”到 ~75% 的毛利率。 2023 年那条著名的标题—— 英伟达在每块 H100 上赚取 ~1,000%——不过是 $25–30K ÷ ~$3,320 S35025。换算成毛利率， 芯片层面为 (27,500 − 3,320) / 27,500 ≈ **88%**；B200 则为 (35,000 − 6,400) / 35,000 ≈ **82%**（估计） S35020,S35026。英伟达公布的公司整体毛利率 更低——FY2025 为 75.0%， FY2026 在计提 $4.5B H20 出口相关费用后为 71.1%，Q2 FY2027 约为 ~75% S416,S402,S444,S405——原因有四：（1）大部分收入来自整板、NVLink 交换托盘、Grace/Vera CPU、网络及机架组件，其利润率低于裸 GPU；（2）存货及采购承诺相关费用计入营业成本；（3）保修、运费 以及测试设备折旧；（4）新产品爬坡期间良率较低。研发费用则完全不计入毛利 率：黄仁勋称 Blackwell 的研发成本约为 ~$10B S35028。若分摊到比如 500 万块 GPU 上，每块 ~$2,000（🔴 示意性的出货量）。

注

🐂 **看多观点。** BOM 表明，英伟达的护城河并非便宜的芯片——它向台积电和 HBM 厂商支付的价格与其他所有人相同——而是能够以制造成本 5–6 倍的价格出售产品，因为 GPU 交付时 附带了 CUDA、NVLink 以及围绕它的整套系统。使用同一供应链的竞争对手面临同样的 ~$6K+ 成本下限，而且必须定价低于英伟达才能赢得订单。

注意

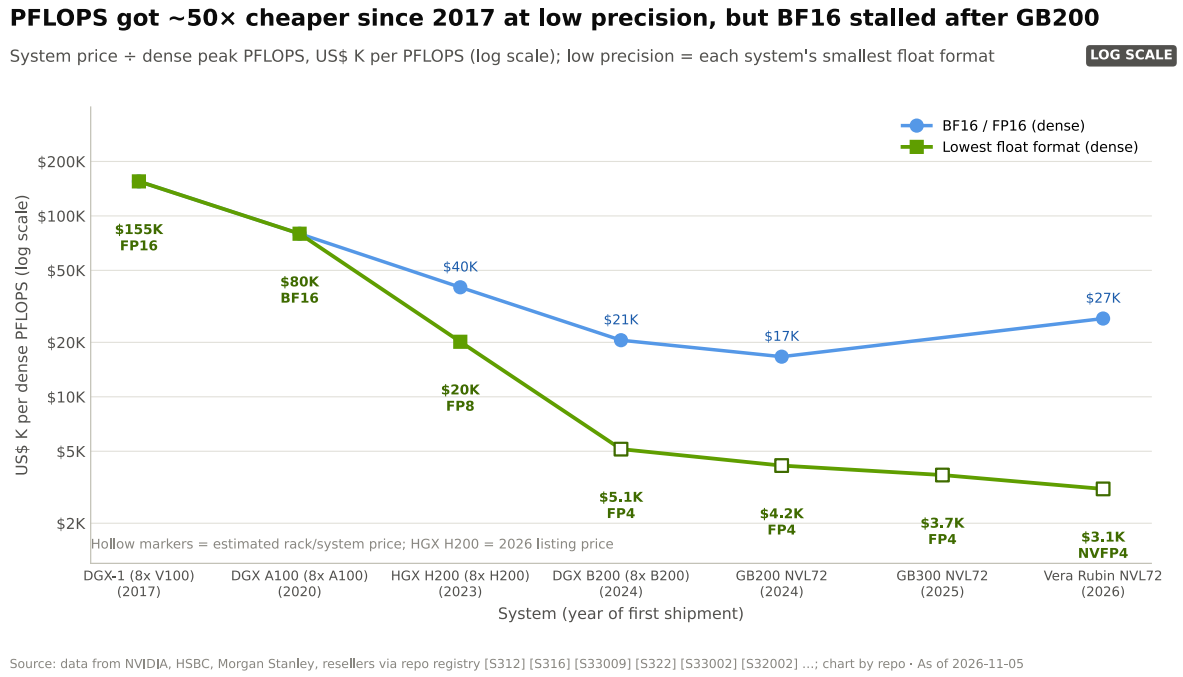
🐻 **看空观点。** ~80% 的芯片层面利润率本身就是一种邀请。定制 ASIC 买家（谷歌、AWS、Meta） 支付的台积电/HBM/CoWoS 成本大致相同，外加一笔设计合作伙伴费用，却完全绕开了英伟达的利润； 随着内存成本占比上升，HBM 厂商也可能分走更大一块蛋糕。参见 看空情景和 训练与推理经济学。

8. 每 FLOP 成本的历史演变

买家最终购买的是算术运算：每单位算力的美元成本。有三个杠杆可以影响它——每个封装中 更多的晶体管、每个晶体管更好的架构，以及**更小的数值 格式**（数值格式每减半一次，张量核心每个周期执行的运算量大约翻倍， 从 BF16 到 FP8 再到 FP4）。英伟达每一代旗舰 GPU 的稠密峰值算力都在陡峭攀升：

GPU（年份）	稠密峰值，原生 AI 格式	稠密 BF16/FP16	来源
V100（2017）	125 TFLOPS FP16	125 TFLOPS	S33010
A100（2020）	312 TFLOPS BF16	312 TFLOPS	S33009
H100（2022）	1,979 TFLOPS FP8	989 TFLOPS	S33002
B200（2024）	9,000 TFLOPS FP4	2,250 TFLOPS	S33003
Rubin（2026）	稠密 FP8 17,500 TFLOPS；NVFP4 推理 50,000	4,000 TFLOPS	S33005,S33004

价格的披露频率远低于 FLOPS，因此最一致的长期序列采用的是整套 系统：早期各代采用英伟达的 DGX 挂牌价 S312,S316，HGX H200 采用 2026 年的一则挂牌信息 S322，Blackwell 和 Rubin 则采用分析师的机架估计（汇丰、摩根士丹利） S326,S332,S330。 用价格除以稠密峰值 PFLOPS，就得到下图。系统价格包含 CPU、网络、 内存和组装，因此绝对水平高于只计算裸 GPU 的结果，但关键在于趋势。



Source: data from NVIDIA, HSBC, Morgan Stanley, resellers via repo registry [S312] [S316] [S33009] [S322] [S33002] [S32002] ...; chart by repo · As of 2026-11-05

对数坐标图：每稠密 PFLOPS 的系统价格：配备 V100 的 DGX-1（FP16，2017 年）约 $155K，降至 Vera Rubin NVL72 在 NVFP4 下（2026 年）的约 $3.1K，下降约 50 倍；在 BF16 口径下，性价比最高的是 GB200 NVL72，约 $17K，而 Vera Rubin NVL72 约为 $27K，因为其性能提升和内存成本都集中在其他方面。

提示

算例 —— 每 FLOP 成本下降 7× 从何而来（单块 GPU，跨两代）。 H100：$27,500 ÷ 0.989 稠密 BF16 PFLOPS ≈ **每 PFLOPS $27.8K** [S33002,S35024]。B200：$35,000 ÷ 2.25 ≈ 同等精度下 **$15.6K**，而 $35,000 ÷ 9.0 ≈ 每稠密 FP4 PFLOPS **$3.9K** [S33003,S35026]。因此，27.8 / 15.6 ≈ **1.8**× 来自更好的双裸片 GPU，而 15.6 / 3.9 = **4**× 来自从 BF16 降到 FP4。制造成本的变化要小得多：H100 每稠密 FP8 PFLOPS 约为 ~$3,320 ÷ 1.98 ≈ $1.7K，而 B200 约为 ~$6,400 ÷ 4.5 ≈ $1.4K（估计）[S35024,S35020]——便宜约 15%——而每 FP8 PFLOPS 的售价下降了 ~44%。根据这些估计，英伟达让渡给买家的代际收益，多于其供应商让渡给英伟达的部分（🔴 本资料库基于两份分析师估计的推断）。系统层面的图表显示了下一步：一台 Vera Rubin NVL72 估计 ~$7.8M，其中 ~$2.0M 是内存 [S330]，因此其 BF16 每 PFLOPS 价格（~$27K）*反而高于* GB200（~$17K），而其 NVFP4 数字（~$3.1K）则是迄今最优 [S33005,S102]。

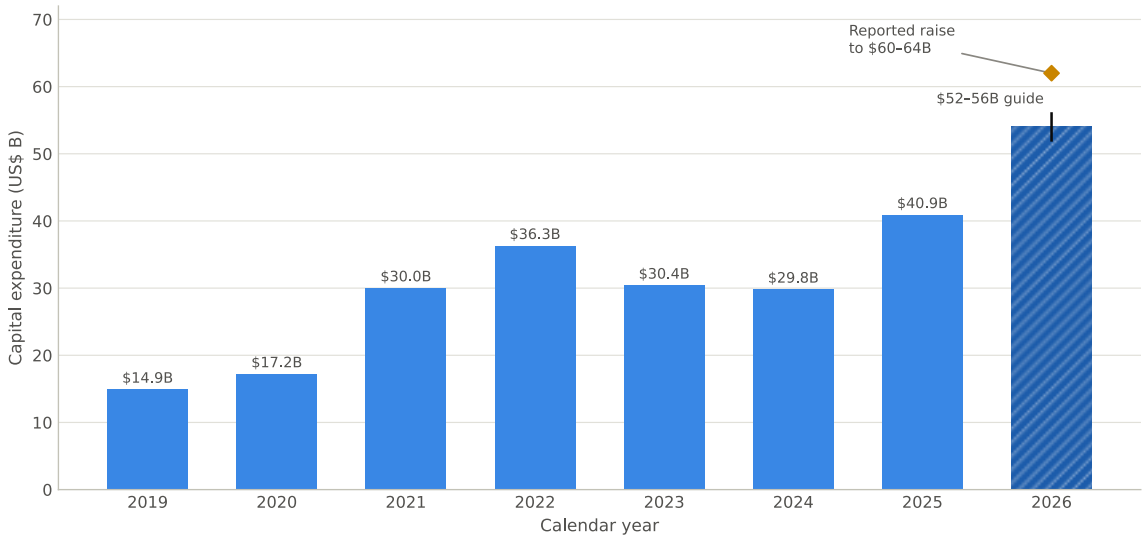
有两点提醒可以让这一分析保持客观。第一，**峰值 FLOPS 并非实际交付的 FLOPS**：真实负载常常受限于内存带宽或网络（参见 P3 —— 四大瓶颈），而 FP4 只在模型质量能够经受 4 位运算的场景下才有帮助。第二，**FLOPS 并不等于 token**：对买家真正重要的数字是每百万 token 的美元成本，它还取决于电力、利用率和软件（参见 14 —— 训练与推理经济学）。Rubin 把每 GPU 的稠密 FP8 提升到 17.5 PFLOPS [S33005]；其价格未公开，而其 HBM4 带宽规格在 2026 年末从 22 TB/s 下调至 19.2 TB/s [S33007]（🟡），这提醒我们路线图上的数字是会变的。

9. 晶圆厂资本开支，以及为何只有台积电能制造这些产品

先进制程制造是一场规模游戏。台积电 2019 年的资本开支为 $14.9B [S35032]，2022 年创下 $36.3B 的纪录 [S35033]，2025 年为 $40.9B，并给出 2026 年 $52–56B 的指引 [S35029]；稍后的一则报道称，管理层先是指向该区间的上限，随后又将其上调至 $60–64B（🟡 单一来源）[S35030]。

TSMC's capex rose ~3.6× from $14.9B (2019) to a guided ~$54B (2026)

TSMC capital expenditure by calendar year, US$ billions (2026 hatched = midpoint of $52–56B guidance, whisker = range)



Source: data from TSMC via AP, TrendForce, SemiWiki, TickerLeague [S35032] [S35031] [S35034] [S35033] [S35029]; chart by repo · As of 2026-11-05

条形图：台积电资本开支：2019 年 $14.9B，2022 年创下当时纪录的 $36.3B，2025 年 $40.9B，2026 年指引为 $52-56B（中值 $54B），约为 2019 年的 3.6 倍；一则报道称 2026 年指引已上调至 $60-64B。

为什么这些投入会转化为对 AI 加速器制造的近乎垄断?

1. **规模为下一个节点提供资金。** 2026 年 Q2，台积电占据全球前十大晶圆代工厂收入的 72.5%（当季 ~$40.2B）； 三星晶圆代工占 5.9%，中芯国际占 5.4% [S35035]。只有领先者的收入足以 支撑每年 $50B+ 的资本开支。
2. **良率学习效应不断累积。** 每一批晶圆都让晶圆厂更清楚缺陷从何而来； 领先者的 D0 曲线下降得更快（见第 3 节），这对 800 mm² 的裸片比对手机芯片更有价值。
3. **封装是捆绑在一起的。** CoWoS 紧邻晶圆厂；一个希望在同一流程中获得 N4P 裸片、 HBM 集成和 CoWoS-L 的客户，实际上只有一家供应商可选。
4. **信任与协同优化。** 英伟达的定制 4N/4NP 工艺 [S35011,S35014] 是与 台积电经过多年共同调优的——更换代工厂就意味着重新设计芯片。

> **提示**
>
> **算例 —— 护城河外的护城河有多宽。** 在一个 ~$53.5B 的季度中 [S35035]，三星晶圆代工 5.9% 的份额 对应 ~$3.2B 的季度收入，即每年 ~$12.6B。因此，台积电 2026 年 ~$54B 的资本开支 中值 [S35029] 约为**三星晶圆代工全年总收入的 ~4 倍**。一个 挑战者若没有国家支持或一个绑定的锚定客户，就不可能在投资上胜过它。

> **注意**
>
> **集中度风险是一把双刃剑。** 同一个事实——所有人都必须在台积电排队——在保护英伟达免受潜在 GPU 对手冲击的同时，也让英伟达、AMD、谷歌和 AWS 同样暴露于一家公司和一座岛屿的风险之下。 参见弱点与看空情景。

与各层的关联

本篇中的概念	最重要的影响领域	延伸阅读
光罩尺寸极限、多裸片 GPU、工艺节点	裸片设计与年度迭代节奏	第 02 层 —— GPU 芯片
CoWoS、HBM、良率、供应承诺	物理瓶颈以及谁获取利润	第 03 层 —— 内存、封装与供应链 · 价值链
裸片间互连 → 芯片间互连	同样的物理原理，更长的距离	第 05 层 —— 纵向扩展（NVLink）
BOM 与售价、系统层面利润率	为何英伟达卖的是机架而非芯片	第 08 层 —— 系统与机架
每 FLOP 成本、每 token 美元成本	买家真正为之付费的东西	14 —— 训练与推理经济学
台积电集中度、ASIC 成本对等	看空情景	18 —— 弱点 · 15 —— 竞争格局
利润为研发和供应提供资金	自我强化的循环	01 —— 英伟达的飞轮

需要记住的关键数字

指标	数值	来源
光罩尺寸极限（单次曝光）	~858 mm²（26 × 33 mm）；High-NA EUV 为 429 mm²	S35010
H100 裸片	814 mm²，80B 晶体管，台积电 4N	S35013,S35011
B200 封装	2 颗裸片，208B 晶体管，10 TB/s 裸片间互连	S35014

指标	数值	来源
晶圆价格，N7 → N2	~$9.4K → ~$30K（估计）	S35001,S35003
814 mm² 裸片在 0.1 缺陷/cm² 下的模型良率	~44%（100 mm² 时 ~90%）	本资料库模型
B200 制造成本	~$6,400（估计，区间 $5.7–7.3K）	S35020
HBM 占 B200 制造成本的比例	~45%（估计）	S35020
B200 售价	~$30–40K	S35026
台积电占前十大晶圆代工厂收入份额，2026 年 Q2	72.5%	S35035
台积电 2026 年资本开支指引	$52–56B	S35029

🎯 企业发展视角

1. **随着 HBM 在成本中的占比从 ~14%（A100）升至 ~45%（B200）**[S35023,S35020]**，利润池将如何转移？** 存储厂商和封装厂正在攫取每颗加速器物料成本中 越来越大的一块；哪些合作关系（HBM 供应、封装产能）能确保获得供应，而不仅仅是 获得价格？
2. **封装如今已是战略性产能。** 如果封装良率每提高几个百分点就价值每块 GPU 数百 美元（见第 5 节），那么是否存在一些封装、测试或裸片间互连 IP 资产——无论是上市 公司还是私营专业公司——它们对一个进入数据中心市场的新玩家的价值，超过其独立 价值？
3. **据报道，N3P 涨价给高通和联发科带来了压力**[S35037]**。** 一个 数据中心加速器项目该如何与同一代工厂的移动业务分享（或争夺）先进制程晶圆和 CoWoS 配额？
4. **芯粒降低了入场门槛。** 由较小的已知良品裸片构成的设计，可以避开 光罩尺寸与良率之墙（见第 4 节）。“芯粒 + 标准互连”的策略能否让挑战者在不具备 英伟达出货规模的情况下达到有竞争力的芯片成本——又要在封装复杂度上付出什么 代价？
5. **成本下限是共享的，价格上限却不是。** 任何使用台积电、HBM 和 CoWoS 的对手，其每颗旗舰加速器的 制造成本都从类似的 ~$6K 以上起步[S35020]。对新进入者而言，问题 不是“我们能否造得更便宜？”，而是“哪位客户会在没有 CUDA 的情况下， 支付一个高于这一成本下限的价格？”