英伟达全栈深度研究

NVIDIA 如何在 AI 训练与推理中变得不可或缺 —— 逐层解析

卷三 · 系统、软件与生态

第 08–13 层：系统与机架、CUDA、软件库、推理软件、云服务、生态与资本

简体中文参考译文 · 仅供参考，如有出入以英文原文为准
数据与图表截至 2026-11-05 · 仅使用公开信息
英文原版：github.com/FrankHuang94/nvidia_deep_dive_claude

阅读说明

本册为英文研究资料库《NVIDIA Full-Stack Deep Dive》的**简体中文参考译文**，仅供参考；如与英文原文存在任何出入，以英文原文为准。全书共五册，可分册打印。

- **图表**：数据图表与架构图保留英文原版（由仓库中的 CSV 数据生成）；每张图下方的灰色文字为中文图注，概括该图的结论与关键数字。Mermaid 示意图已译为中文。
- **引用**：正文中的灰色上标（如 [S2031]）为来源编号，完整书目见卷五附录“参考文献”（保留英文原题）。
- **可信度标记**：🟢 已确认（公司官方公布）· 🟡 有报道（可信媒体或分析机构）· 🔴 推测（推断、传闻或本资料库的分析）；“估计”表示估算值。
- **对比标记**：🟩 领先 · 🟨 持平 · 🟥 落后 · 🟦 路线不同。
- **三层阅读深度**：每页以“⚡ 要点速览”开篇；正文“原理解析”含“算例”；虚线框为“🔧 技术细节”；页末“🎯 企业发展视角”列出供企业发展团队思考的问题。
- **时效**：数据截至 2026-11-05；英伟达 2027 财年第三季度财报（2026-11-17）与 GTC DC 大会（2026-12-01）晚于此日期。
- **公开信息**：本资料库仅使用公开信息；涉及高通的内容均以问题与选项的形式呈现，不构成建议。

目录

第 08 层 —— 系统、机架与 AI 工厂 5

NVL72 机架解剖 9

AI 工厂：每兆瓦 token 数、蓝图与建设速度 13

电力与散热：如今决定节奏的物理规律 19

HGX、DGX、MGX 与 NVL 机架：从芯片到机架级系统 26

系统、机架与 AI 工厂：竞争格局 30

系统、机架与 AI 工厂：历史与英伟达的构建过程 36

系统、机架与 AI 工厂：路线图 40

系统、机架与 AI 工厂：价值链与企业发展视角 44

第 09 层 —— CUDA 与系统软件 51

CUDA 究竟是什么 55

为何护城河在于长尾 60

侵蚀路径：哪些力量可能削弱护城河 68

客观评估：CUDA 护城河到底有多强？ 72

CUDA 与系统软件：竞争格局 76

CUDA 与系统软件：发展历程与英伟达的构建方式 81

CUDA 与系统软件：路线图 85

CUDA 与系统软件：价值链与企业发展视角 89

第 10 层 —— 软件库（CUDA-X） 94

CUDA-X 目录：每个软件库做什么 100

NCCL：多 GPU AI 的隐形黏合剂 105

软件库广度为何产生复利 112

软件库（CUDA-X）：竞争格局 117

软件库（CUDA-X）：发展历程与英伟达的构建方式 125

软件库（CUDA-X）：路线图 131

软件库（CUDA-X）：价值链与企业发展视角 135

第 11 层 —— 推理与 AI 软件 141

推理转向 145

同一硬件上的软件增益 151

TensorRT-LLM 与 Dynamo 156

NIM、NeMo、Nemotron 与 AI Enterprise 161

推理与 AI 软件：竞争格局 166

推理与 AI 软件：发展历程与英伟达的构建之道 174

推理与 AI 软件：路线图 179

推理与 AI 软件：价值链与企业发展视角 182

第 12 层 —— 编排与云服务 188

利用率问题：为什么闲置 GPU 会摧毁投资回报 192

Run:ai、Mission Control 与 Base Command：调度栈 197

超大规模云厂商与新兴云服务商：谁在出租英伟达的 GPU 203
DGX Cloud 与 DGX Cloud Lepton 209
编排与云服务：竞争格局 213
编排与云服务：发展历程与英伟达的构建方式 218
编排与云服务：路线图 223
编排与云服务：价值链与企业发展视角 228
第 13 层 —— 生态、市场进入与资本 235
主权 AI 240
开发者生态与 Inception 245
资本部署 250
企业市场进入：OEM、GSI 与软件合作伙伴 257
生态、市场进入与资本：竞争格局 261
生态、市场进入与资本：发展历程与英伟达如何建成 267
生态、市场进入与资本：路线图 271
生态、市场进入与资本：价值链与企业发展视角 275

第 08 层 —— 系统、机架与 AI 工厂

第 08 层（共 12 层）· 芯片如何组成机架、机架如何组成 AI 工厂，以及为何电力如今决定节奏 · 约 8 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **产品已变成整个机架。** 英伟达（NVIDIA）的销售单元从 2016 年售价 $129K 的 DGX-1 服务器，扩大到约 $4.0M 的 GB300 NVL72 机架，以及约 $7.8M 的 Vera Rubin NVL72（估计，摩根士丹利），72 颗 GPU 处于同一个 NVLink 域（NVL72）中 S310,S332,S330。
- **几乎全部由英伟达设计，由 ODM 制造。** 英伟达规定计算托盘、交换托盘、约 5,000 根线缆组成的铜缆背板（spine）、电源架和液冷方案；富士康（约占 AI 服务器的 40%）等 ODM 负责组装，毛利率仅约 2–3% S5000,S3014,S332。
- **单系统功耗十年间上升约 190 倍：** 从 3.2 kW（DGX-1）到约 132 kW（GB300 NVL72）、约 190–230 kW（Vera Rubin，🟡 有报道），以及 2027 年 Kyber 计划的约 600 kW（🟢 已发布）；因此液冷成为必选项，并催生了 800 V 直流供电标准 S310,S337,S303,S305,S90063。
- **产出指标是每兆瓦 token 数：** 在每用户 50 tokens/s 的速度下，GB300 NVL72 运行 DeepSeek-R1 的每兆瓦 token 数约为 H200 的 13 倍（本资料库根据 InferenceX 估计）；在中等速度下，Vera Rubin 还能再提升约 2 倍 S621,S622,S626。
- **真正的约束往往是电力而非芯片：** 文中引用的 AI 工厂在 4–15 个月内建成，但美国新增发电项目在并网排队中要等待四年以上，北弗吉尼亚的接电等待期最长可达七年 S6000,S8013,S8009,S8010。
- **英伟达如今出售整座 AI 工厂：** 包括 DGX SuperPOD、Vera Rubin DSX 参考设计、Omniverse DSX 数字孪生以及 Mission Control 软件 S396,S8017,S8019。
- **弱点与最强挑战者：** 72 颗 GPU 的机架是一个巨大的故障域，并被锁定在英伟达的物料清单（BOM）上。AMD 的 Helios 机架（72 颗 MI455X、31 TB HBM4，约为 Vera Rubin HBM 容量的 1.5 倍）约从 2026 年第三季度末开始出货；谷歌（Google）的 TPU pod 可扩展至 9,216 颗芯片 S90021,S90020,S350。

Power per NVIDIA system rose ~190× in a decade: 3.2 kW (DGX-1) to ~600 kW (Kyber)

Maximum IT power per system or rack, kW · 8/16-GPU DGX servers 2016–2024, NVLink racks from 2024 · hatched = announced/roadmap

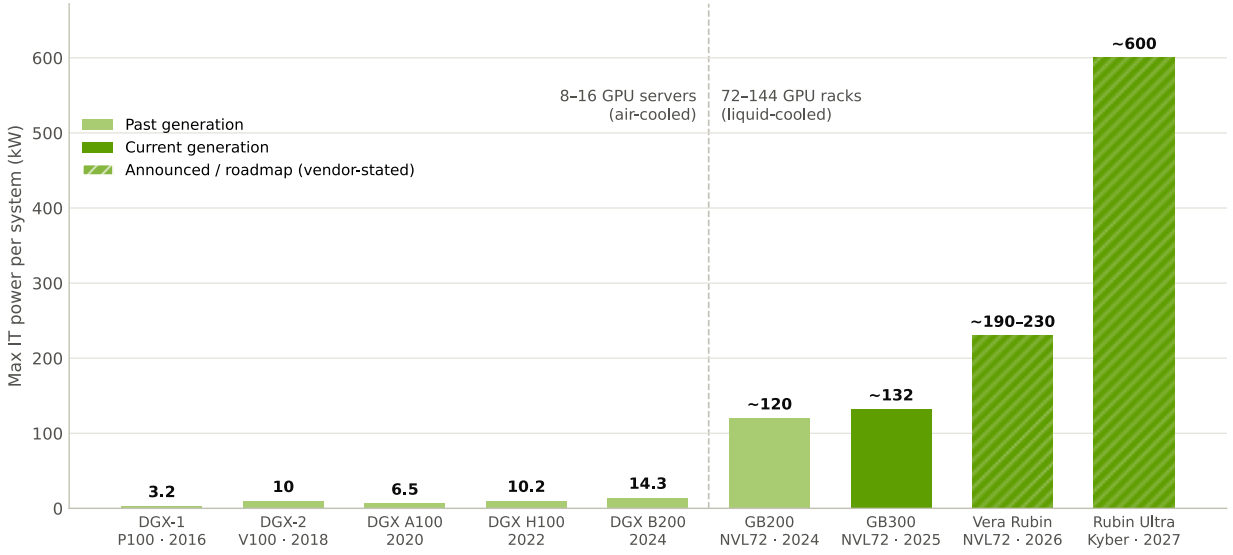

Source: data from NVIDIA, AnandTech, TweakTown, eeNews, Hashrate Index, DCD [S310] [S311] [S125] [S313] [S314] [S315] ...; chart by repo · As of 2026-11-05

英伟达各代系统最大功耗柱状图：DGX-1 为 3.2 kW（2016），DGX-2 为 10 kW，DGX A100 为 6.5 kW，DGX H100 为 10.2 kW，DGX B200 为 14.3 kW；随后进入机架级：GB200 NVL72 约 120 kW，GB300 NVL72 约 132 kW，Vera Rubin NVL72 约 190-230 kW，Rubin Ultra Kyber 机架约 600 kW，约为 DGX-1 的 190 倍。

提示

算例 —— 用英伟达的口径看 1 吉瓦。 在 PUE 为 1.15 时，1 GW 可留出约 870 MW 给 IT 负载[S387,S388]。一个 GB300 NVL72 机架需要约 132 kW，再加上约 21% 分摊的网络与存储功耗，合计约 160 kW[S337,S340]，因此 1 GW 可容纳**约 5,400 个机架、约 390,000 颗 GPU**（本资料库测算）。英伟达 CEO 对这样一座工厂的报价为 **$50–60B，其中约 $35B 属于英伟达的产品**含量[S398]。**结论：**在这一层，英伟达出售的是以兆瓦计的成品算力，1 吉瓦预算中约 58–70% 流向英伟达。

本层在技术栈中的位置

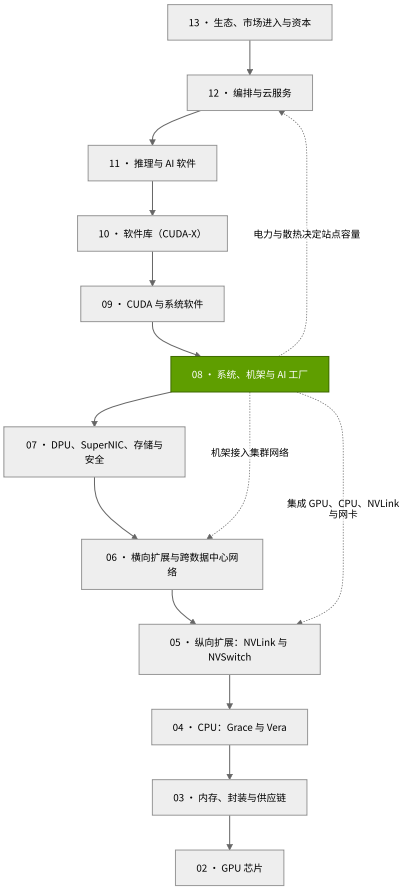

本层结构图

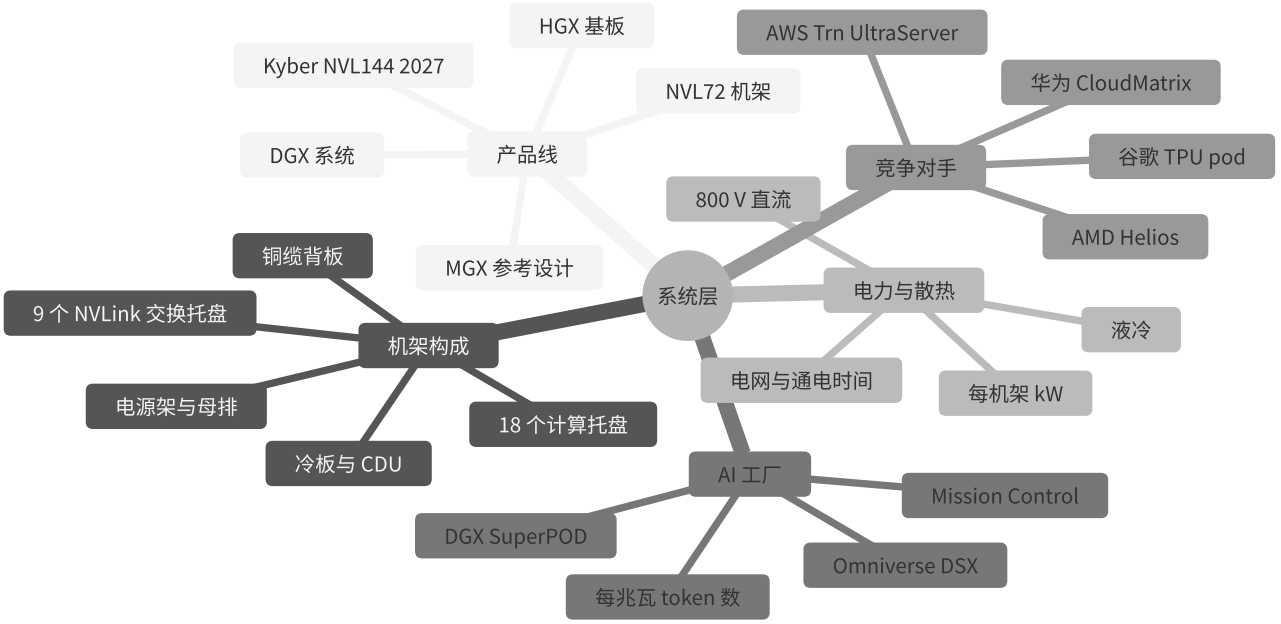

八个问题一览

#	问题	简要回答	详见
Q1	职能是什么？薄弱时会出什么问题？	**[Q1 · 职能与失效后果]** 把芯片变成一台能通电、能散热、能运转的计算机；一旦背板、供电或散热失效，整个 72 颗 GPU 的域都会停摆 S626	NVL72 机架解剖
Q2	关键指标？	**[Q2 · 关键指标]** 在给定每用户速度下的每兆瓦 tokens/s、每机架与每 GPU 的 kW、PUE、通电时间、每 GPU 小时成本	AI 工厂
Q3	代际进步？	**[Q3 · 代际进步]** 单系统功耗 3.2 kW → 约 600 kW；每机架 HBM 13.8 → 20.7 TB；GB300 上每兆瓦 token 数约为 H200 的 13 倍（估计） S310,S305,S337,S621	电力与散热、从 HGX 到 NVL
Q4	优势来源？	将芯片、NVLink、供电与散热整合进每年一代的机架设计，并有一个围绕该设计进行制造的 ODM 生态 S3014	历史与构建过程
Q5	最强挑战者？	AMD Helios 机架（72 颗 MI455X、31 TB HBM4），2026 年下半年起供货；谷歌 TPU pod 达 9,216 颗芯片 S90021,S350	竞争
Q6	复制成本？	需要数年时间和数十亿美元：AMD 为 ZT Systems 的机架设计团队支付了 $4.9B S8527	历史与构建过程
Q7	路线图？	Vera Rubin 于 2026 年第四季度上量；Kyber NVL144（约 600 kW）定于 2027 年下半年（有推迟的报道）；800 V 直流机柜排于 2027 年落地 S90009,S305,S309,S90063	路线图
Q8	价值池与并购？	在 $50–60B 的 1 吉瓦工厂中英伟达约占 $35B；ODM 利润率约 2–3%；其余归电力、散热与设施供应商 S398,S332	价值链与企业发展

本层页面

页面	你将了解
HGX、DGX、MGX 与 NVL 机架	四条产品线、英伟达为何转向机架、1,000 颗 GB300 GPU 的钱都付给了谁
NVL72 机架解剖	托盘、背板、母排、散热；计算托盘示意图；重量、功耗与部件
电力与散热	每机架 kW 的演进轨迹、液冷为何必不可少、800 V 直流、电网限制、100k GPU 设施示例
AI 工厂	每兆瓦 token 数、蓝图（SuperPOD、DSX）、价值从 OEM 转移、首个 token 产出时间
竞争	对比各家机架级系统，并附能力热力图
历史与英伟达的构建过程	从 DGX-1 到 Kyber：时间线、关键决策、复制成本
路线图	Vera Rubin、Kyber、800 V 直流及竞争对手机架，附置信度标签
价值链与企业发展视角	谁拿走了机架上的钱、私营公司、并购

🔧 技术细节：本层如何与相邻层衔接

机架封装了第 05 层的 NVLink 交换机、第 04 层的 CPU 以及第 07 层的 SuperNIC；它接入第 06 层的网络；电力与机架数量决定了第 12 层中云服务商可出租的算力上限（第 14 章对每 token 成本进行建模）。

🎯 企业发展视角

1. **价值已转移到 BOM 规格之中。** 谁来编写机架的物料清单，谁就拿走利润；ODM 仅保留约 2–3%（估计） S332。哪些机架部件（电源、散热、连接器）仍向独立供应商开放？
2. **电力成为新的配额货币。** 在许多地区，已通电的站点、现场发电和 800 V 直流设备比 GPU 更稀缺 S8009,S90061；基础设施合作的重要性可能不亚于芯片设计。
3. **进入机架级市场需要制造与集成能力：** AMD 选择了收购（ZT Systems）而非自建 S8527。
4. **高通（Qualcomm）的问题（仅基于公开信息）：** 鉴于 AI200/AI250 机架功耗约 160 kW 并采用直接液冷 S173，更好的路径是融入与英伟达兼容的机架生态（MGX、NVLink Fusion），还是打造一款以每兆瓦 token 数论成败的独立推理机架？

NVL72 机架解剖

第 08 层 · 系统、机架与 AI 工厂 · 约 9 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **一个机架，一台计算机。** 一个 NVL72 机架容纳 18 个 1U 计算托盘（每个托盘 2 颗 CPU + 4 颗 GPU，合计 72 颗 GPU、36 颗 CPU）和 9 个 NVLink 交换托盘，所有 GPU 通过铜缆背板与其他每一颗 GPU 互连 [S8000,S396]。
- **背板（spine）是关键所在：** 约 5,000 根铜缆（总长约 2 英里）让每颗 GPU 以 1.8 TB/s 的带宽连通全部 72 颗 GPU（合计约 130 TB/s）；不用光器件，每个机架可省下约 20 kW 的光模块功耗 [S5000,S5001]。
- **它本质上是一个供电与管路产品：** 8 个 33 kW 的电源架为约 50 V 直流母排供电；每颗 GPU 和 CPU 上的冷板连接到机架分液歧管和冷却液分配单元（CDU） [S8000,S5007]。
- **规模：** 约 120 kW（GB200）、约 132 kW（GB300）、约 190–230 kW（Vera Rubin，有报道）；重约 1.36 吨（GB200） [S336,S337,S303,S335]。
- **Vera Rubin 重新设计了托盘：** 无线缆、无软管、无风扇，组装时间从约 2 小时缩短到约 5 分钟（英伟达（NVIDIA）的说法），每机架交换芯片数量从 18 颗翻倍至 36 颗 [S8002,S301,S332]。
- **弱点：** 高密度意味着风险集中。早期 GB200 机架在上量阶段遇到铜缆背板的可靠性问题，而如今单个机架是价值约 $4–8M、必须作为整体维护的单元（估计） [S626,S332]。

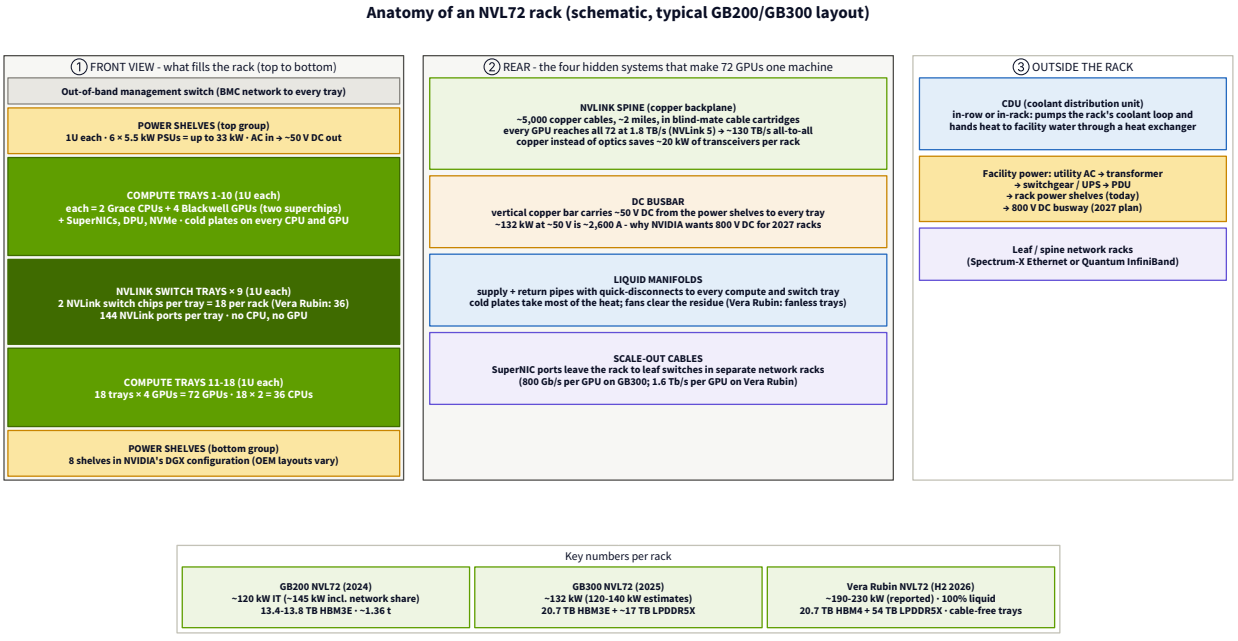

NVL72 机架示意图。正面从上到下：带外管理交换机；上部电源架组（每个电源架含 6 个 5.5 kW 电源模块，最高 33 kW，交流输入、约 50 V 直流输出）；计算托盘 1 至 10；9 个 NVLink 交换托盘，每个含 2 颗交换芯片（每机架 18 颗，Vera Rubin 为 36 颗）；计算托盘 11 至 18（合计 72 颗 GPU 和 36 颗 CPU）；以及下部电源架组，在英伟达的 DGX 配置中共 8 个电源架。背面：由约 5,000 根线缆组成的 NVLink 铜缆背板，让每颗 GPU 以 1.8 TB/s 连通全部 72 颗 GPU；直流母排，在 50 伏电压下为 132 kW 机架输送约 2,600 安培电流；带快插接头的液冷供回液分液歧管；以及连接到独立网络机架的横向扩展线缆。机架外部：冷却液分配单元、设施供电链路以及叶脊（leaf-spine）网络机架。关键数字：GB200 NVL72 约 120 kW、约 1.36 吨，GB300 NVL72 约 132 kW，Vera Rubin NVL72 约 190 至 230 kW，全液冷。

1. 机架：27 个托盘背后隐藏的四大系统

[Q1 · 职能与失效后果] 机架的职能是让 72 颗 GPU 像一台机器一样工作，并在约 130 kW 的功耗下保持供电与冷却。一旦某个隐藏系统失效（背板线缆、冷却液接头、电源架），NVLink 域就会降级，拖慢的是整个机架，而不只是一台服务器 S5007,S626。

机架正面是像抽屉一样堆叠的托盘；真正的工作在背面完成。NVLink 背板把每个托盘盲插接入铜缆卡匣，每个交换托盘有 144 个 NVLink 端口；之所以用铜缆，是因为在约 1 米的距离上不需要耗电的光器件（铜缆背板）S5007,S5008。母排承载来自电源架的约 50 V 直流电 S8000。带快插接头的分液歧管为 GPU、CPU 和交换芯片上的冷板供液 S334。每个托盘都有一个接入带外管理网络的基板管理控制器（BMC） S5007。

机架组成（GB200/GB300）	数量	关键数字
计算托盘	18	72 颗 GPU、36 颗 Grace CPU S8000
NVLink 交换托盘	9	18 颗交换芯片（Vera Rubin 为 36 颗） S8000,S332
电源架	8（DGX 配置）	每个含 6 × 5.5 kW 电源模块，最高 33 kW S8000
NVLink 铜缆	约 5,000 根	总长约 2 英里 S5000
SuperNIC / DPU（GB300）	72 / 18	每颗 GPU 800 Gb/s；每个托盘一颗 BlueField-3 S8001
液冷部件价值	按托盘	每个 GB300 机架约 $50K（摩根士丹利估计） S334
重量	1 个机架	GB200 约 1.36 吨（有报道） S335

提示

算例 —— 清点部件。 芯片：72 颗 GPU + 36 颗 CPU + 18 颗交换芯片 + 72 颗 SuperNIC + 18 颗 DPU = 每个 GB300 机架 **216 颗主要芯片** S8000,S8001。供电：8 个电源架 × 6 个电源模块 = **48 个电源模块**，铭牌容量 8 × 33 kW = 264 kW，对应约 132 kW 的负载，约为 2 倍的冗余余量（本资料库测算） S8000,S337。布线：约 5,000 根背板线缆 S5000。**结论：** NVL72 更像一台小型大型机而非一台服务器，这正是机架集成与老化测试转移到专业 ODM 产线的原因。

🔧 技术细节：母排电流问题

一个 132 kW 的机架在约 50 V 电压下需要 132,000 ÷ 50 ≈ **2,640 A** 电流（本资料库测算） S337。电阻损耗与电流的平方成正比，因此兆瓦级机架需要 800 V 直流（电力与散热） S8016。

2. 计算托盘：5.6 kW GPU 功耗的所在

每个 1U 计算托盘承载两块超级芯片板。在 GB300 上，每块板通过 900 GB/s 的一致性 NVLink-C2C 链路，将一颗 72 核 Grace CPU（约 480 GB LPDDR5X）与两颗 Blackwell Ultra GPU（每颗 288 GB HBM3E）配对 S337,S129。托盘前部有 4 颗 ConnectX-8 SuperNIC（每颗 GPU 一个 800 Gb/s 端口，用于横向扩展）和 1 颗 BlueField-3 DPU，用于存储和多租户流量 S8001。

Anatomy of one NVL72 compute tray (schematic, 1U, top view)

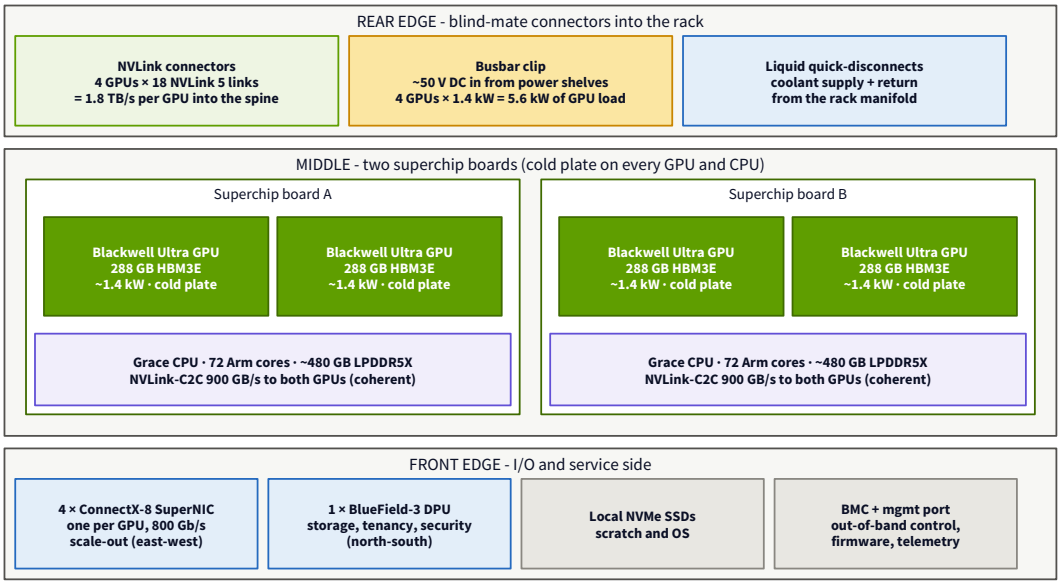

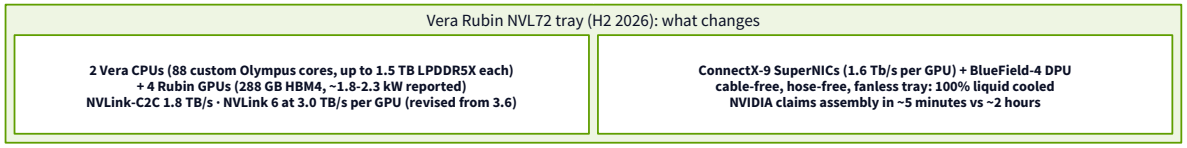

单个 NVL72 计算托盘俯视示意图。后沿：NVLink 连接器（4 颗 GPU × 18 条 NVLink 5 链路，每颗 GPU 以 1.8 TB/s 接入背板）、输送约 50 V 直流电的母排卡扣（4 颗 GPU × 1.4 kW = 5.6 kW 的 GPU 负载）以及液冷快插接头。中部：两块超级芯片板，每块含两颗 Blackwell Ultra GPU（288 GB HBM3E，约 1.4 kW，冷板）和一颗 Grace CPU（72 个 Arm 核心，约 480 GB LPDDR5X，900 GB/s NVLink-C2C）。前沿：4 颗 800 Gb/s 的 ConnectX-8 SuperNIC、1 颗 BlueField-3 DPU、本地 NVMe SSD 以及一个 BMC 管理端口。Vera Rubin 托盘的变化：2 颗 Vera CPU，每颗 88 核、最高 1.5 TB LPDDR5X；4 颗 Rubin GPU，每颗 288 GB HBM4、约 1.8 至 2.3 kW；NVLink 6 每颗 GPU 3.0 TB/s；ConnectX-9 每颗 GPU 1.6 Tb/s，并配 BlueField-4；托盘无线缆、无软管、无风扇，组装约需 5 分钟。

提示

算例 —— 机架的电力去了哪里。 4 颗 GPU × 约 1.4 kW = 每托盘 **5.6 kW** [S32004]；× 18 个托盘 = **约 101 kW 的 GPU 功耗**，约占一个约 132 kW 的 GB300 机架的 76% [S337]。其余约 31 kW 用于 36 颗 CPU、18 颗交换芯片、90 颗网卡与 DPU、水泵和风扇以及电能转换损耗（本资料库测算）。**结论：**散热设计就是 GPU 设计；机架四分之三的热量来自 72 块冷板。

Vera Rubin 对托盘的改动大于对机架的改动。 Oberon 机架框架和背板保持不变，但托盘承载 2 颗 Vera CPU（每颗 88 核、最高 1.5 TB LPDDR5X）和 4 颗 Rubin GPU；在英伟达 2026 年的规格修订后，NVLink 6 为每颗 GPU 3.0 TB/s（原为 3.6）；ConnectX-9 SuperNIC 为每颗 GPU 1.6 Tb/s，并配一颗 BlueField-4 DPU（🟡 每托盘数量为报道数据）[S102,S90006,S511]。该托盘无线缆、无软管、无风扇 [S301]；英伟达称组装时间从约 2 小时降至约 5 分钟 [S8002,S303]。

提示

算例 —— 5 分钟组装一个托盘值多少钱。 GB 系列托盘每个机架需要 18 个托盘 × 2 小时 = **36 个工时**，而 Vera Rubin 为 18 × 5 分钟 = **1.5 小时**（英伟达的说法）[S8002]。1,000 个机架可节省约 34,500 个工时；内部线缆更少也意味着老化测试中的故障更少；SemiAnalysis 预计 Rubin 上量更快，部分原因正在于此 [S626]。**结论：**可制造性如今已成为一项竞争性规格。

🔧 技术细节：交换芯片为何翻倍

NVLink 6 将每颗 GPU 的带宽大约翻倍，因此机架需要 36 颗交换芯片（每个交换托盘 4 颗），而不是 18 颗 [S332]。按修订后的每颗 GPU 3.0 TB/s 计，机架的全交换（all-to-all）带宽约为 72 × 3.0 ≈ 216 TB/s，而发布时公布的是 260 TB/s（本资料库测算）[S90003,S90006]。

3. 重量、功耗与可维护性

一个 GB200 机架重约 1.36 吨，与一辆汽车相当，因此必须先核查楼板承重和运输路线 [S335]。功耗逐代攀升：约 120 kW（GB200）、约 132 kW（GB300；各方估计为 120–140 kW），再到 Vera Rubin 的约 190 kW（Max-Q）至约 230 kW（Max-P）功耗档位（有报道）[S336,S337,S303]。AMD 的双宽 Helios 机架（72 颗 MI455X）估计约 225–245 kW [S344,S346]。

提示

算例 —— 一个机架闲置的代价。 SemiAnalysis 估算一颗 GB300 GPU 的持有成本约为每小时 $2.31，租赁价格约为每小时 $5.00 [S622]。一个机架停机一天，损失 72 × 24 × $2.31 ≈ **$4,000 的持有成本**，或 ≈ **$8,600 的租赁收入**（本资料库测算）。**结论：**在机群规模下，可靠性以及托盘、卡匣和快插接头的快速更换都价值不菲。

注意

🐻 **看空观点：**72 颗 GPU 的 NVLink 域是单一故障域。一次冷却液泄漏或一个有缺陷的背板卡匣，就可能让价值约 $4M 的硬件闲置直至修复；SemiAnalysis 指出，GB200 铜缆背板在上量期间“面临诸多可靠性挑战”[S626]。由 8 GPU 节点构建的横向扩展设计（TPU 立方体、Trainium UltraServer、HGX）在单个节点故障时损失更小。

🎯 企业发展视角

1. **互连与供电硬件是机架的新卡脖子环节。** 背板卡匣、母排、快插接头和冷板都是不起眼但认证门槛很高的部件；哪些供应商已被设计进 Vera Rubin 和 Kyber?
2. **可维护性正在成为护城河。** 托盘组装与老化测试时间决定了新一代产品的上量速度 [S8002,S626]。进入机架级市场的竞争者必须解决制造问题，而不仅是芯片问题。
3. **高通（Qualcomm）的问题（仅基于公开信息）：** AI200/AI250 机架采用 PCIe 纵向扩展和以太网横向扩展，功耗约 160 kW [S173]；若在 CPU 方面加入 NVLink Fusion [S90031]，或在 MGX 式机架上开展合作，能否缩短打造一款经过验证的机架的路径?

AI 工厂：每兆瓦 token 数、蓝图与建设速度

第 08 层 · 系统、机架与 AI 工厂 · 约 11 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **AI 工厂是以单位电力产出来衡量的数据中心。** 英伟达（NVIDIA）的核心指标是每兆瓦每秒 token 数：它给出的数字是 GB300 NVL72 为 2.8M，HGX H200 为 54K，即在其自选工作点上宣称的 50 倍 S8021,S32004。
- **独立数据缩小了差距，但证实了差距的存在：** 根据 InferenceX 的 DeepSeek-R1 数据，在每用户 50 tok/s 时，GB300 NVL72 每兆瓦产出约 2.95M tokens/s，而 H200 约为 225K，约 13 倍（本资料库估计）S621,S622。
- **Vera Rubin 进一步拉大差距：** SemiAnalysis 基于早期工程样品测得，在每用户 100 tok/s 以内，其每兆瓦 token 数约为 GB300 的 2 倍，在接近 200 tok/s 时约为 4 倍 S626。
- **蓝图卖的是整个站点：** DGX SuperPOD（8 个 GB200 机架）、40 个机架的 Vera Rubin POD、配有 Omniverse DSX 数字孪生的 Vera Rubin DSX 参考设计，以及用于运营的 Mission Control 软件 S396,S511,S8017,S8019。
- **速度是稀缺投入：** xAI 用 122 天建成 Colossus 1（100k 颗 Hopper GPU）；Stargate Abilene 的首批 200+ MW 用了约 15 个月；而新增电网供电可能需要 4–7 年 S6000,S8012,S8013,S8009,S8010。
- **看空观点：** 每兆瓦 token 数取决于模型、上下文和交互速度；CoreWeave 宣称 Vera Rubin 提升 10 倍，所用的 GB200 软件基线已是一年前的版本 S626。

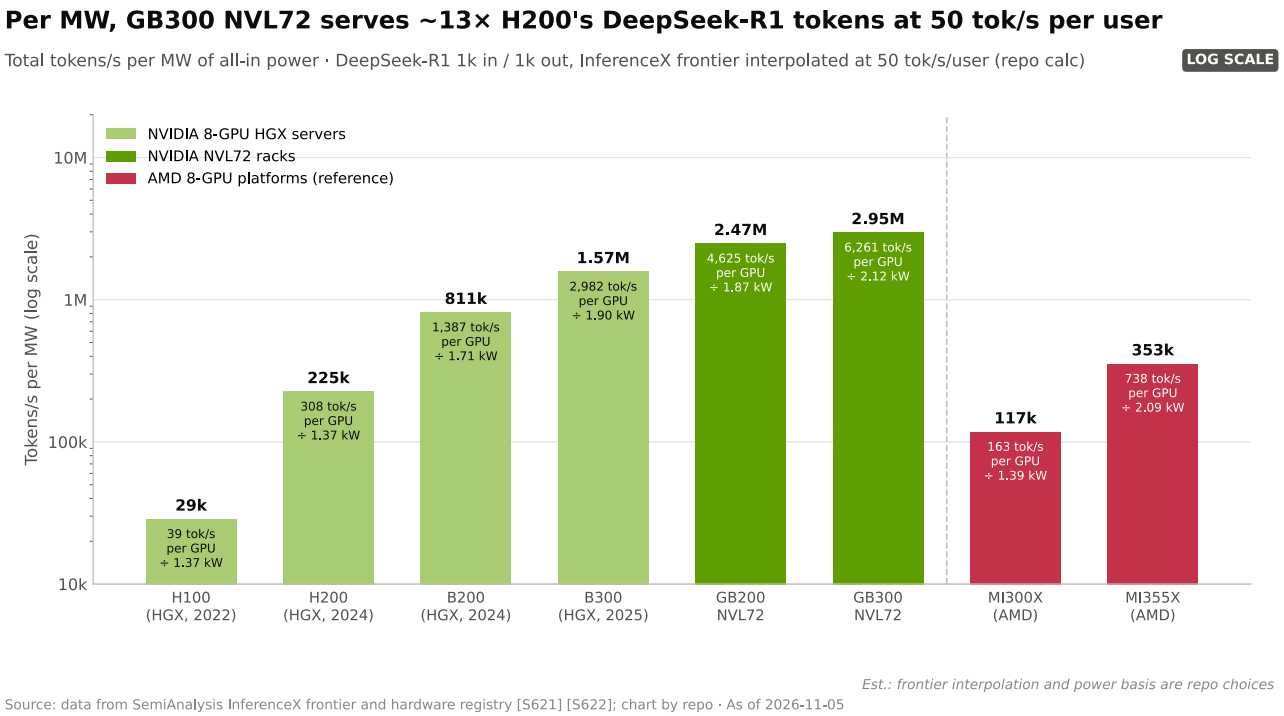

对数刻度柱状图：在每用户 50 tokens/s 下，按全口径功耗计算的 DeepSeek-R1 每兆瓦每秒 token 数（InferenceX 前沿曲线除以 SemiAnalysis 的每 GPU 功耗）：H100 约 29K，H200 约 225K，B200 约 0.8M，B300 约 1.6M，GB200 NVL72 约 2.5M，GB300 NVL72 约 3.0M，约为 H200 的 13 倍；AMD MI300X 约 117K，MI355X 约 353K。

1. AI 工厂的框架：输入电力，输出 token

对 AI 数据中心而言，稀缺的投入是**兆瓦**（电网接入需要数年，参见电力与散热），产出是 **token**。衡量标准是*在给定的每用户速度下*（交互速度）每兆瓦每秒的 token 数，因为批处理更多用户会提高吞吐量，但会拖慢每个用户（即帕累托前沿）。

[Q2 · 关键指标] 五个数字决定了这一层的经济性：（1）在给定交互速度下的**每兆瓦 tokens/s**；（2）**每机架 kW 与每 GPU 全口径功耗**（GB300：约 132 kW、约 2.12 kW）[S337,S622]；（3）**PUE**（2025 年行业平均 1.54，最佳超大规模机群约 1.1）[S8007,S388]；（4）**通电时间与首个 token 产出时间**；（5）**每 GPU 小时成本**，即每百万 token 美元成本的分母（第 14 章）。

> **提示**
>
> **算例 —— 100 MW 能产出什么。** 按每颗 GB300 GPU 全口径约 2.12 kW 计 [S622]，100 MW 可运行**约 47,000 颗 GPU**。按每兆瓦约 2.95M tokens/s（DeepSeek-R1，每用户 50 tok/s，估计）计，该站点每秒产出**约 295M 个 token**，满负荷利用下每年约 **9.3 千万亿（quadrillion）个 token**。同样 100 MW 的 H200（每兆瓦约 225K）每秒只产出约 22M 个 token，**约少 13 倍** [S621,S622]。GPU 小时数则方向相反：1 MW 可容纳 472 颗 GB300（**每年 4.1M GPU 小时**），而 H200 为 730 颗（6.4M），但每个 GB300 GPU 小时产出约 22.5M 个 token，H200 仅约 1.1M（本资料库测算）。**结论：**在电力受限的站点中，一兆瓦旧 GPU 只能赚到零头的 token。

> **注意**
>
> **误区与事实：**“GB300 是 Hopper 的 50 倍。”英伟达的 50 倍是在单一工作点上，将每用户速度约 10 倍的提升乘以每兆瓦吞吐量约 5 倍的提升 [S32004]；根据 InferenceX 数据，本资料库发现在每用户 50 tok/s 时约为 H200 的 13 倍，而在每用户约 100 tok/s 时，GB300 相对 8 GPU B300 服务器的领先几乎消失（估计）[S621]。任何倍数都只是曲线上的一个点。

电力约束的是*数量*，而非成本：电费仅占每 GPU 小时“硬件 + 电力”成本的约 12–19%（本资料库估计，按 6 年寿命、8.1¢/kWh 计）[S389,S382]。

Electricity is only ~12–19% of hardware-plus-power cost per GPU-hour; capex dominates

US$/GPU-hour: price ÷ GPUs ÷ 6 yrs, plus kW/GPU × PUE (1.4 air, 1.15 liquid) × $0.081/kWh · building and network excluded

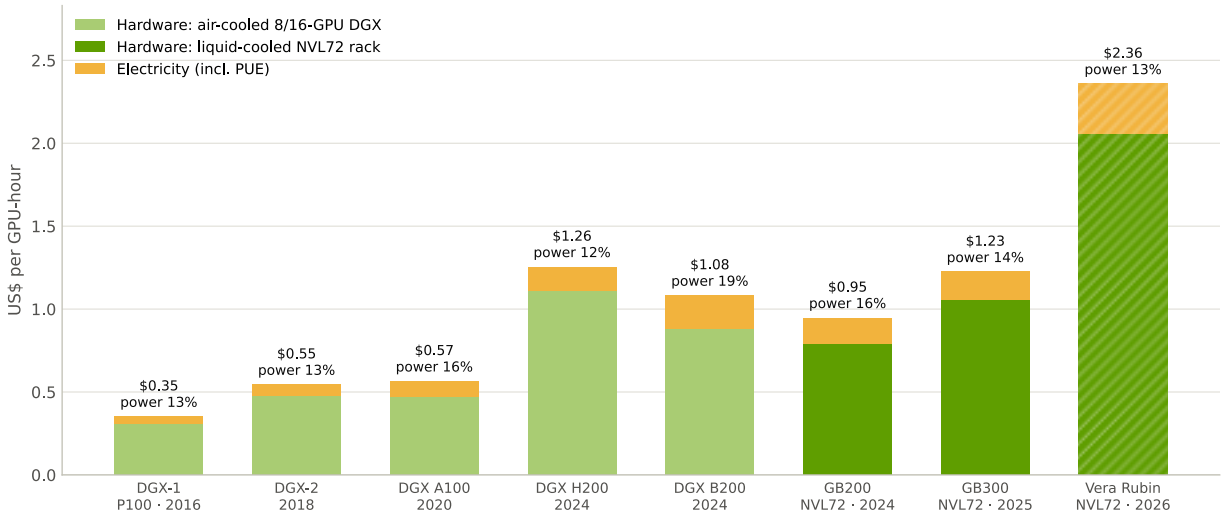

Prices 2024+ Est.; hatched = announced

Source: data from system_specs, tco_model_inputs [S310] [S311] [S125] [S313] [S314] [S315] …; chart by repo · As of 2026-11-05

> 按英伟达系统划分的每 GPU 小时成本堆叠柱状图。按 6 年折旧的硬件成本从约 $0.31（DGX-1，2016）上升到约 $0.79（GB200 NVL72）、$1.05（GB300 NVL72）和 $2.06（Vera Rubin NVL72，估计价格）；电费每 GPU 小时增加约 $0.05 至 $0.30，仅占总额的 12-19%，因此电力限制的是能容纳多少 GPU，而不是每个 GPU 小时的成本。

🔧 技术细节：每兆瓦 token 数图表如何计算

- **吞吐量：** 取 InferenceX 公布的各系统最佳前沿点（DeepSeek-R1，1k 输入 / 1k 输出，不使用投机解码），在每用户 50 tok/s 处做对数线性插值 [S621]。
- **功耗：** 采用 InferenceX 注册表中 SemiAnalysis 给出的每 GPU 全口径功耗（H200 1.37 kW，GB300 2.12，Vera Rubin 3.30）[S622]。
- **注意事项：** 统计的是总 token 数（输入 + 输出），仅一个模型，前沿点稀疏；SemiAnalysis 自己的每兆瓦图表只统计输出 token [S626]。

2. 蓝图与参考架构

英伟达以层层嵌套的参考设计来出售工厂：

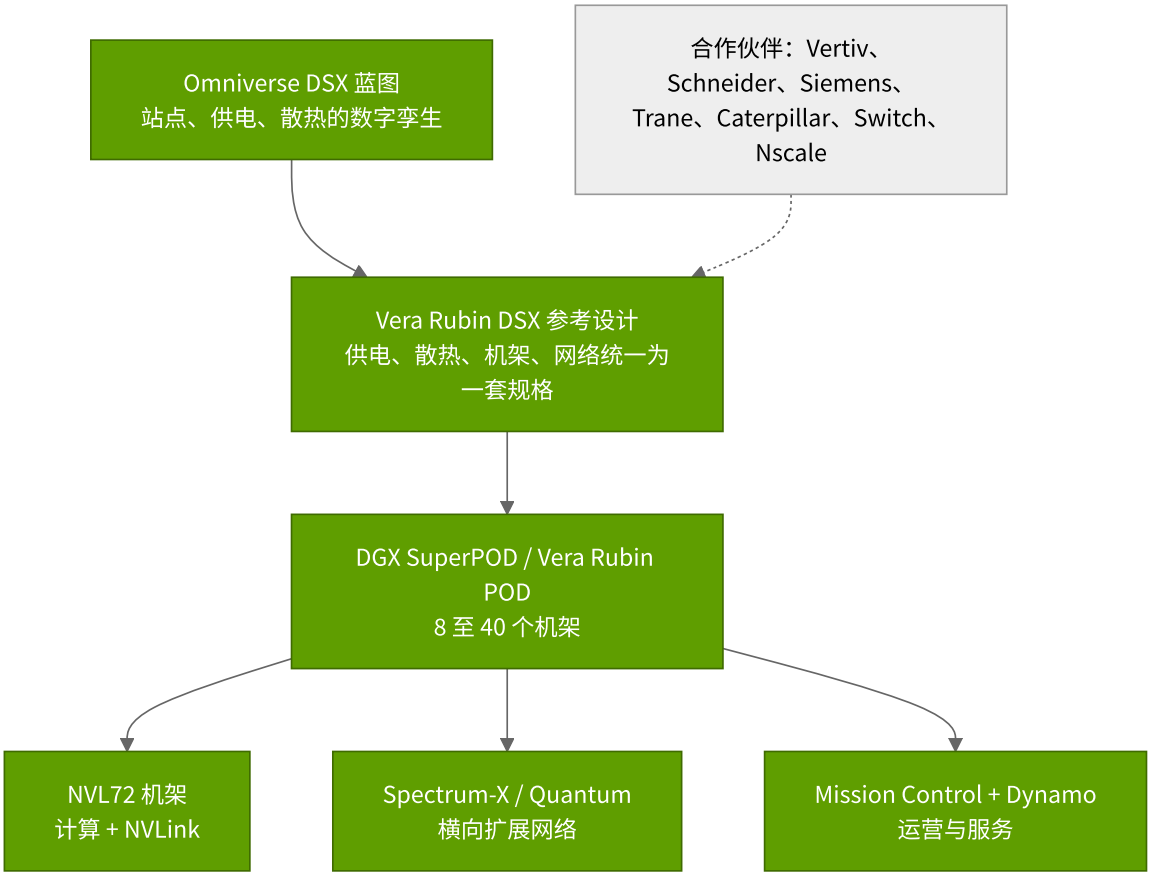

- **DGX SuperPOD：** 8 个 GB200 NVL72 机架，576 颗 GPU，稀疏 FP4 算力 11.5 EF [S396]；Vera Rubin POD 跨 40 个机架，约 60 EF [S511]。
- **Omniverse DSX：** 面向吉瓦级站点的数字孪生蓝图（2025 年 10 月）[S8018]，自 GTC 2026 起随 Vera Rubin DSX 参考设计全面推出，目标是提升每瓦 token 数并缩短投产时间。维谛（Vertiv，预制化 OneCore Rubin DSX）、Switch 以及携手卡特彼勒（Caterpillar）的 Nscale 均基于它进行建设 [S8017,S90063]。
- **Mission Control**（GTC 2025）将 Base Command Manager 与 Run:ai 相结合，实现资源调配、监控和故障诊断的自动化，英伟达称其可将利用率最高提升 5 倍（厂商说法）[S8019,S8020]；Dynamo 1.0 负责推理调度 [S90066]（第 11 层）。

> **提示**
>
> **算例 —— 1 吉瓦中有多少属于英伟达。** 英伟达 CEO 估计一座 1 GW 的 AI 工厂全部投入约 $50–60B，其中约 $35B 为英伟达的产品 [S398]：**约 58–70%**。我们假设的 100,000 颗 GPU 的 GB300 站点（约 255 MW，见电力与散热）按摩根士丹利的价格计，机架约 $5.5B，其中仅 GPU 就约 $3.5B（估计）[S332]。**结论：**参考设计让英伟达能够把剩下的 30–40%（供电、散热、建筑、网络）引导给符合其规格的合作伙伴。

是什么把价值从 OEM 和 ODM 转移给英伟达

1. **BOM 规格：** 英伟达固定了托盘、交换机、背板、供电和散热接口；摩根士丹利预计 ODM 毛利率将从约 2.7%（GB300）降至约 1.9%（Vera Rubin）[S332]。
2. **预装托盘：** 据报道，英伟达将交付 L10 级 Vera Rubin 计算托盘，约占服务器成本的 90%（🟡）[S8022,S329]。

3. **蓝图与软件：** 设施按 DSX 设计，而 Mission Control 和 Dynamo 占据了过去 OEM 管理工具的位置 S8017,S8019。

OEM 保留了企业服务和融资业务，超大规模云厂商则为自研芯片设计机架；具体的美元分配见价值链与企业发展。

3. 首个 token 产出时间：从选址到投产

对一个集群而言，“首个 token 产出时间”是指从选定站点到开始出售 token 所需的月数。链条为**选址与许可 → 电力 → 主体建筑与冷却站 → 机架交付 → 老化测试 → 投产**，而电力通常是耗时最长的环节。

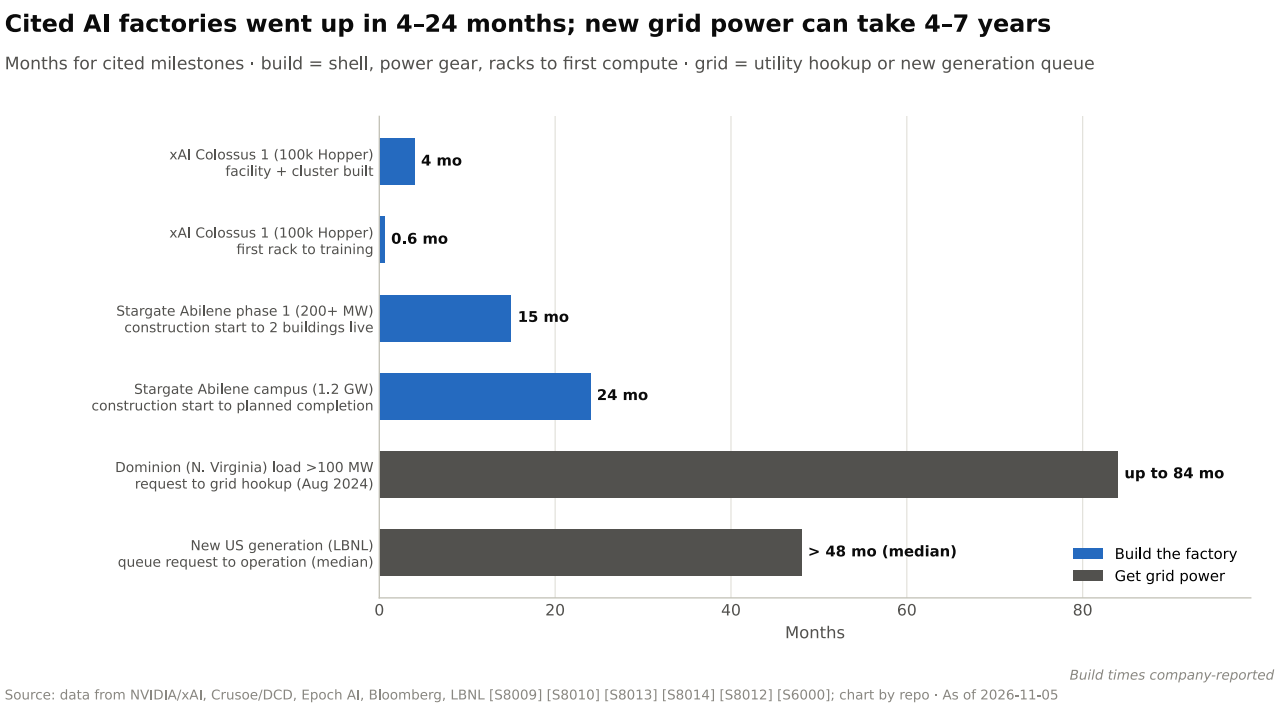

> 以月为单位的横向柱状图。建设里程碑：xAI Colossus 1 从首个机架到开始训练用时 19 天（0.6 个月），设施加 100,000 GPU 集群用时 122 天（4 个月）；Stargate Abilene 首批两栋建筑（200+ MW）自开工起约 15 个月；整个 1.2 GW 园区约 24 个月（目标为 2026 年年中，后来的估计为 2026 年第四季度）。电网里程碑：美国新增发电项目从并网申请到投运的中位时间超过 48 个月（LBNL）；在 Dominion 的北弗吉尼亚服务区，大型数据中心接电最长需 84 个月。

xAI Colossus 1 将孟菲斯一栋现有建筑改造成 100,000 颗 Hopper GPU 的集群，用时 122 天，从首个机架到开始训练仅 19 天（公司说法）S6000。**Stargate Abilene**（Crusoe 为甲骨文（Oracle）和 OpenAI 建设）约于 2024 年 6 月开工，约 2025 年 6 月收到首批 GB200 机架，2025 年 9 月已有两栋建筑、200+ MW 投入运行 S8012,S8013；1.2 GW 园区的目标是 2026 年年中（Epoch AI 估计为 2026 年第四季度）S8013,S8014。

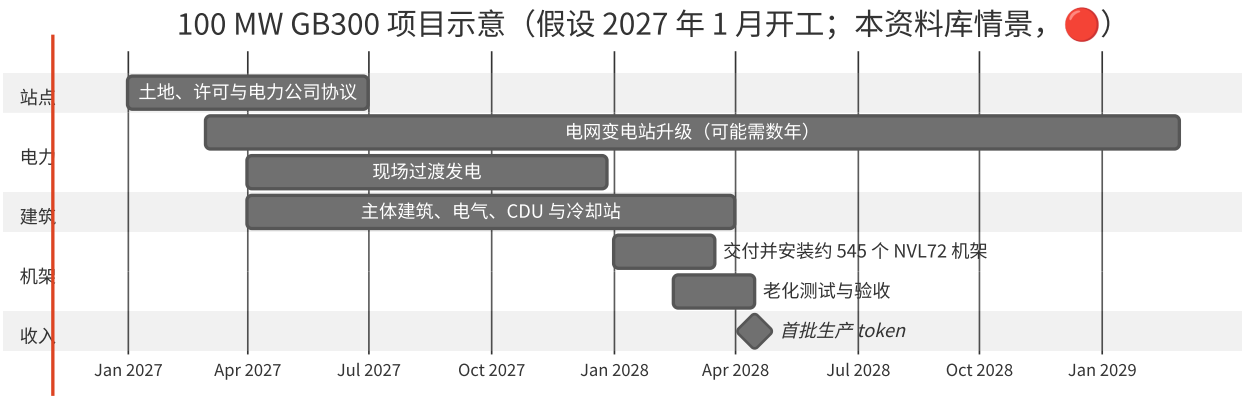

提示

算例 —— 一座 100 MW 的 GB300 机房，从开工到产出 token。 100 MW 在 PUE 1.15 下留出约 87 MW 的 IT 负载；按每机架含网络分摊约 160 kW（132 kW × 145/120）计，可容纳**约 545 个机架、约 39,000 颗 GPU**（本资料库测算）[S337,S340]。若电力已到位，参照 Abilene 的速度（约 12 个月到首批机架，约 15 个月投产）是可信的目标[S8012,S8013]；若需等待新的电网供应，则要再加上**超过四年**的中位排队时间[S8009]。按每 100 MW 约 295M tokens/s（估计）计，每推迟一个月就少产出约 0.8 千万亿个 token。**结论：**凡是能缩短工期的东西，买家都愿意付钱：预制化供电与散热、现场发电、数字孪生、更快的托盘组装。

🔧 技术细节：老化测试对机架级系统为何重要

一台 NVL72 必须以整机架形式通过 NVLink、液冷回路和供电测试，才能开始创收。SemiAnalysis 指出，GB200 铜缆背板在上量期间出现过可靠性问题，并预计得益于无线缆托盘，Vera Rubin 的上量会更快；CoreWeave 首批 Vera Rubin 结果来自一个没有横向扩展网络的试产机架[S626]。

🎯 企业发展视角

1. **指标即市场。** 如果买家把每兆瓦 token 数作为采购标准，竞争对手就必须公布可比的每兆瓦曲线；AMD、TPU 和 Trainium 的宣传数据很少以固定交互速度下的全口径每兆瓦来表述。
2. **通电时间是可交易的资产。** 已通电的土地、现场发电和预制化电站（Vertiv OneCore、Switch EVO）正是基础设施资本流向之处[S8017,S8015]。
3. **参考设计与运营软件把议价权转移**给了英伟达：哪些设施供应商会成为“DSX 认证”供应商？对挑战者而言，一份厂商中立的蓝图或跨厂商的运营层，是否比一颗更快的芯片更重要？
4. **高通（Qualcomm）的问题（仅基于公开信息）：** HUMAIN 计划自 2026 年起部署 200 MW 的高通 AI200/AI250 机架[S173]；在给定交互速度下，什么样的每兆瓦 token 数据才能让这类机架在电力受限的站点中具有说服力？合作伙伴蓝图能否缩短其首个 token 产出时间？

电力与散热：如今决定节奏的物理规律

第 08 层 · 系统、机架与 AI 工厂 · 约 11 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **机架功耗十年间上升约 190 倍：** 从 DGX-1（2016）的 3.2 kW，到 GB200/GB300 NVL72 的约 120–132 kW、Vera Rubin NVL72 的约 190–230 kW（有报道），以及 Kyber（2027）计划的约 600 kW [S310,S336,S337,S303,S305]。
- **风冷已无余地。** 超过 80% 的运营商最高密度机架低于 30 kW [S8008]；而单个 GPU 封装如今功耗最高可达约 2.3 kW（Rubin Max-P，有报道）[S106]，因此每一台 NVL72 都采用直接芯片液冷。
- **液冷正在成为主流：** TrendForce 将高端 AI 芯片的液冷渗透率预估上调至 2026 年约 53%、2027 年约 60%，而 2024 年仅为 14% [S8528,S8004]。
- **800 V 直流是英伟达（NVIDIA）的下一个标准：** 约 20 家电力合作伙伴，2026 年下半年推出 MGX 800 VDC 电源机架，2027 年推出每排 2 MW 的电力中心；若采用 54 V，一个兆瓦级机架需要多达 64U 的电源架 [S90061,S90063,S8016]。
- **对许多项目而言，真正的约束是电力而非芯片：** 美国新增发电项目在并网排队中要等待四年以上，Dominion 对大型数据中心接电给出的等待期最长达七年 [S8009,S8010]。
- **看空要点：** Dell'Oro 认为 800 V 直流目前是一种参考架构，尚非通用标准 [S90062]；为 130 kW 机架建造的设施可能需要改造才能承载 600 kW。

GPU package power rose ~8× since 2016 (300 → 2,300 W); heat per cm² ~3×

Left: max power per GPU package, W · Right: W per cm² of compute silicon (TDP ÷ die area, Est.) · color = cooling in NVIDIA's flagship system

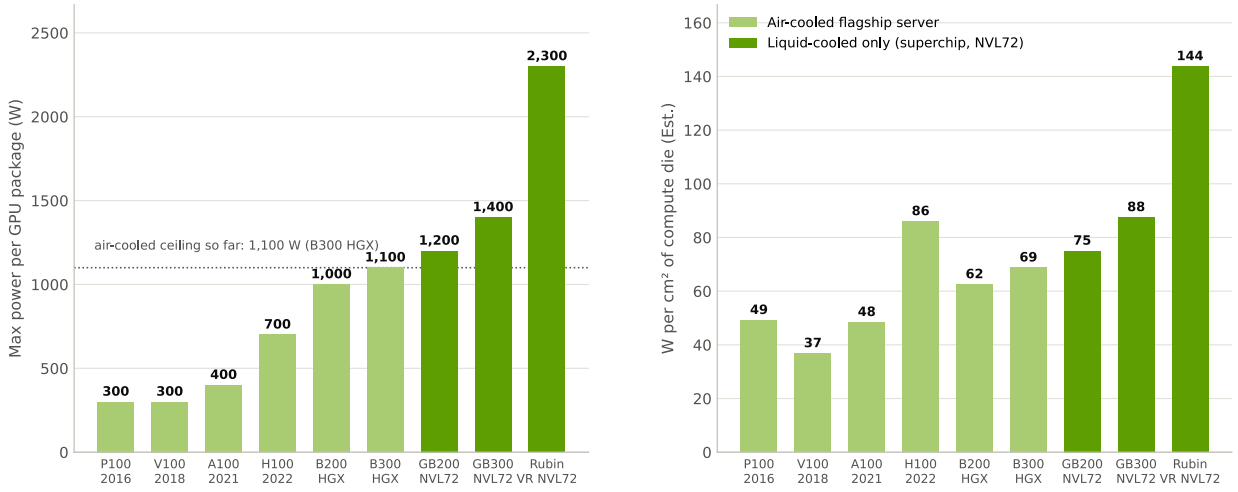

Rubin: reported Max-P TDP; die areas Est.

Source: data from NVIDIA datasheets, reported TDPs [S125] [S33010] [S126] [S33009] [S127] [S33002] …; chart by repo · As of 2026-11-05

按英伟达 GPU 型号划分的两张柱状图。左图：封装功耗从 300 W（P100，2016）上升到 700 W（H100）、1,000-1,100 W（风冷 HGX 服务器中的 B200、B300）、1,200 W（GB200）和 1,400 W（GB300），直至 Rubin 在最高性能档位下的约 2,300 W，约为 8 倍。右图：计算裸片每平方厘米功率从约 49 W 上升到约 144 W（估计），约为 3 倍。所有 1,200 W 以上的超级芯片 GPU 都只以液冷形式出货。

1. 每机架 kW 的演进轨迹

[Q3 · 代际进步] 在英伟达销售 8 GPU 服务器的阶段（2016–2024），单系统功耗从 3.2 kW 缓慢爬升到 14.3 kW；当产品变成整个机架后，功耗跃升了十倍 [S310,S319,S336]。GPU 封装功耗上升约 8 倍，逻辑芯片每平方厘

米的热流密度上升约 3 倍（估计）[S125,S106]。

Power per NVIDIA system rose ~190× in a decade: 3.2 kW (DGX-1) to ~600 kW (Kyber)

Maximum IT power per system or rack, kW · 8/16-GPU DGX servers 2016–2024, NVLink racks from 2024 · hatched = announced/roadmap

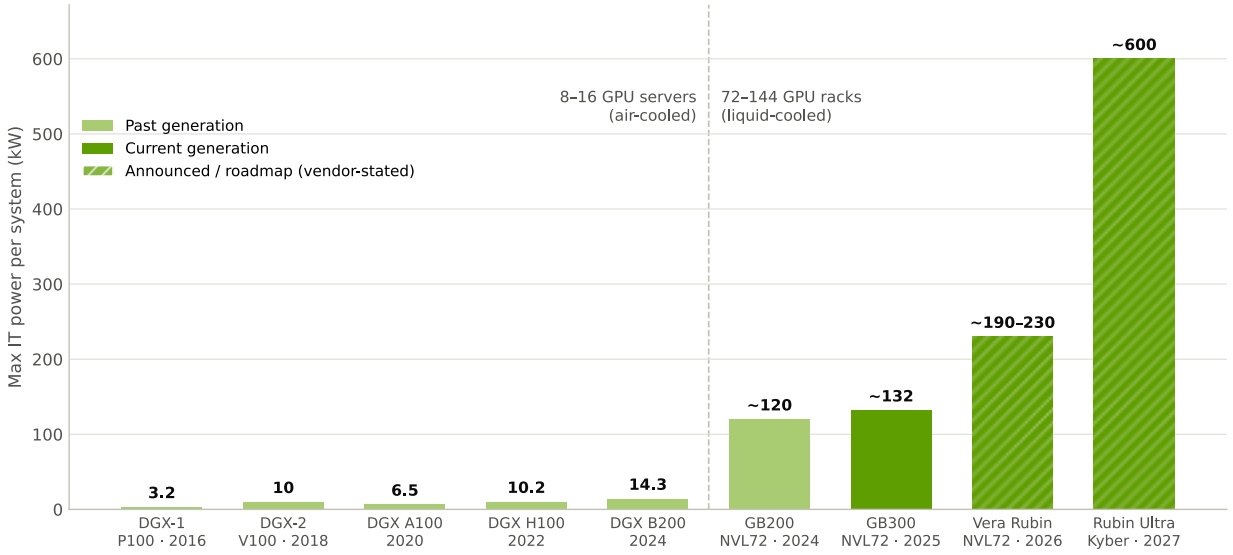

Source: data from NVIDIA, AnandTech, TweakTown, eeNews, Hashrate Index, DCD [S310] [S311] [S125] [S313] [S314] [S315] ...; chart by repo · As of 2026-11-05

英伟达各代系统最大功耗柱状图：DGX-1 为 3.2 kW（2016），DGX-2 为 10 kW，DGX A100 为 6.5 kW，DGX H100 为 10.2 kW，DGX B200 为 14.3 kW；随后进入机架级：GB200 NVL72 约 120 kW，GB300 NVL72 约 132 kW，Vera Rubin NVL72 约 190-230 kW，Rubin Ultra Kyber 机架约 600 kW，约为 DGX-1 的 190 倍。

提示

算例 —— 1 MW IT 电力能容纳什么。 2016 年，1 MW 可供 1,000 ÷ 3.2 ≈ **312 台 DGX-1，约 2,500 颗 GPU** [S310]。2025 年，它可供 1,000 ÷ 132 ≈ **7.6 个 GB300 机架，约 545 颗 GPU** [S337]。但这 545 颗 GPU 的产出要多得多：从 DGX H100 到 Vera Rubin NVL72，每兆瓦稠密 FP8 算力提升约 3.5 倍（估计）[S318,S102]。**结论：**数据中心的容量单位如今是兆瓦，而英伟达每年在每兆瓦上出售的算力都在增加。

1 MW now hosts ~10× fewer NVIDIA GPUs than in 2016, yet up to ~5× Hopper's FP8 per MW

Per MW of system IT power (excludes cooling/PUE): GPU packages (left) and dense FP8 PFLOPS (right) · hatched = announced/roadmap

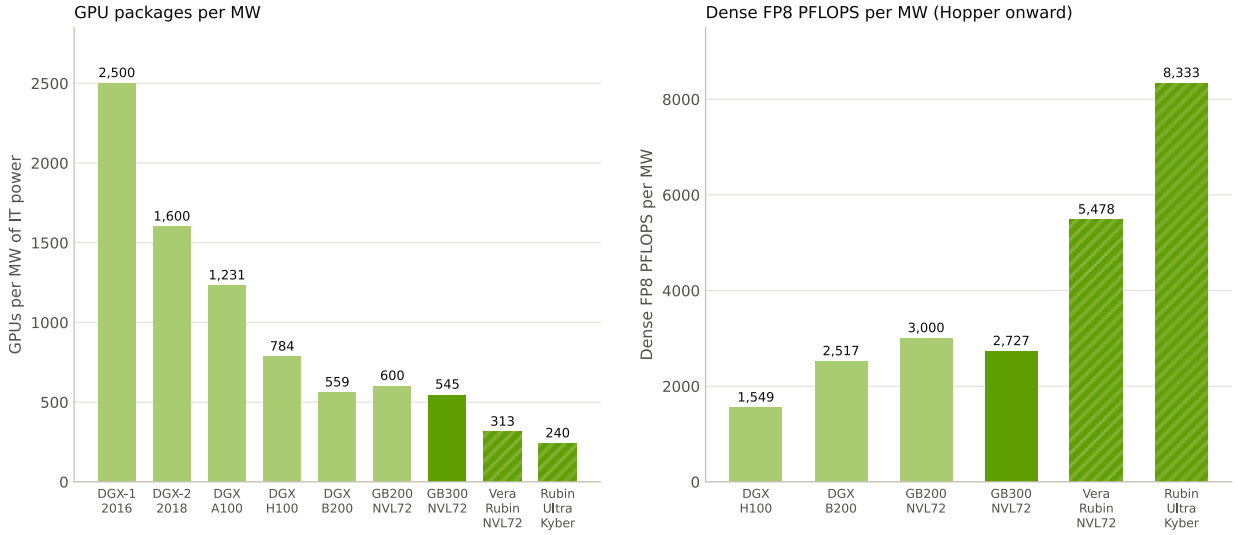

Source: data from NVIDIA, press power estimates (repo calc) [S310] [S311] [S125] [S313] [S314] [S315] ...; chart by repo · As of 2026-11-05

> 按英伟达系统代际划分的两张柱状图。左图：每兆瓦 IT 电力可容纳的 GPU 数量，从 DGX-1 的约 2,500 颗降至 GB200 NVL72 的约 600 颗，Rubin Ultra Kyber 机架为 240 颗。右图：每兆瓦稠密 FP8 PFLOPS 从 DGX H100 的约 1,549 升至 Vera Rubin NVL72 的约 5,478，Kyber 为 8,333，约为 Hopper 的 5 倍。

Vera Rubin NVL72 targets ~5.5 FP8 PFLOPS/kW, ~10× Huawei's CloudMatrix 384

Peak dense FP8 PFLOPS ÷ max IT power · peak specs, not delivered throughput · hatched = roadmap or estimated power

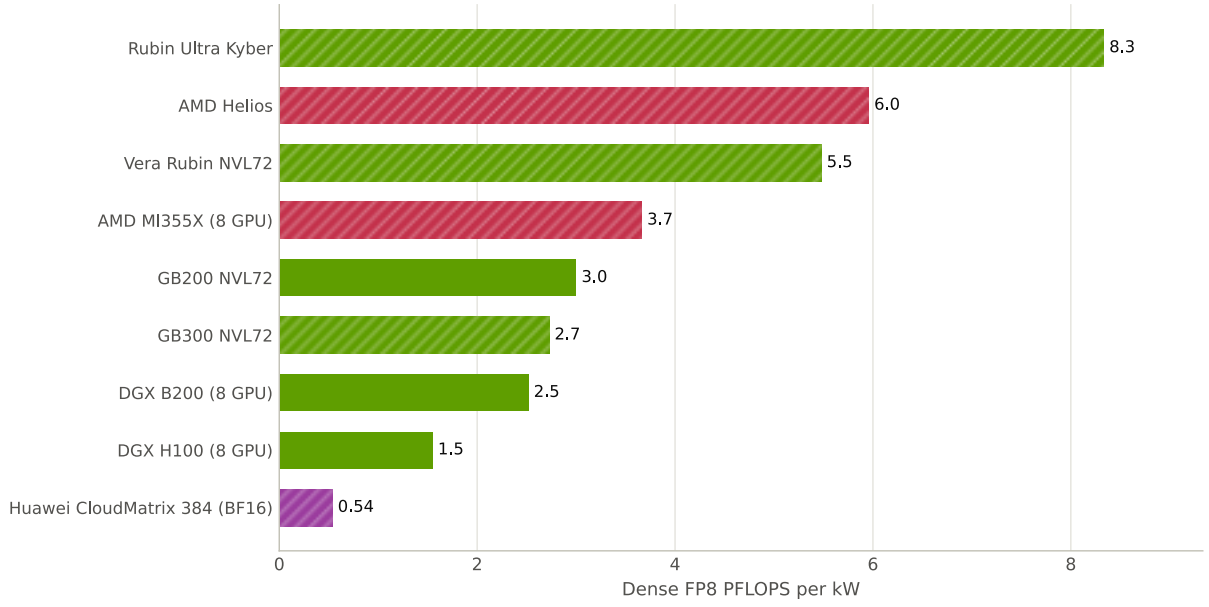

Source: data from NVIDIA, AMD, SemiAnalysis, press (repo calc) [S340] [S163] [S318] [S33022] [S33002] [S319] ...; chart by repo · As of 2026-11-05

> 每千瓦稠密 FP8 PFLOPS 横向柱状图：华为 CloudMatrix 384 约 0.54（BF16），DGX H100 约 1.5，DGX B200 约 2.5，GB300 NVL72 约 2.7，GB200 NVL72 约 3.0，AMD MI355X 平台约 3.7，Vera Rubin NVL72 约 5.5，AMD Helios 约 6.0（基于估计功耗），Rubin Ultra Kyber 约 8.3。

2. 液冷为何成为必选项

散热本质上是一个热量输运问题：带走的热量 = 流量 × 热容 × 温升；每升水能携带的热量约为空气的 **3,500 倍**（每立方米每摄氏度 4.19 MJ 对 1.2 kJ；物理常数）。在每机架 100 kW 以上时，风冷所需的气流相当于一场飓风。

提示

算例 —— 为一个 132 kW 的 GB300 机架散热。 若用空气、温升 15 °C：132,000 W ÷（1.2 kg/m³ × 1,005 J/kg·°C × 15 °C）= 单个机架需要 **7.3 m³/s，约 15,500 CFM** 的风量（本资料库测算）[S337]。若用水、温升 10 °C：132,000 ÷（4,186 × 10）= **每秒 3.2 升（约每分钟 50 美制加仑）**，流经一根直径几厘米的管道。**结论：**在 NVL72 的密度下，风冷所需风量是如今机房为约 30 kW 机架所提供风量的数倍 [S8008]；液冷不是高端选项，而是唯一选项。

方案	热量去向	适用范围	使用者	问题
风冷（配合通道封闭）	风扇 → 室内空气 → 冷水机组	大多数现有机架（超过 80% 运营商的最高密度机架低于 30 kW）[S8008]	最高约 14 kW 的 HGX 服务器 [S321]	风扇功耗、风量上限
直接芯片冷板	冷却液回路 → CDU → 设施冷却水	目前约 120–230 kW，计划约 600 kW [S336,S303,S305]	NVL72 机架、MI355X DLC、谷歌（Google）TPU [S347,S8528]	需要设施冷却水或液-气（L2A）侧柜
浸没式	槽内液体 → 换热器	极高密度	小众（HPC、加密货币挖矿）	维护难度、冷却液成本、供应商认证

CDU 驱动洁净的冷却液回路流经机架冷板，再把热量交给设施冷却水；没有设施冷却水的机房使用液-气侧柜过渡，直到 2027 年起液-液方案普及 [S8528]。无风扇的 Vera Rubin 托盘使用 45 °C 的水运行，在许多气候条件下温度足够高，可以用干冷器替代冷水机组（英伟达的说法）[S8002]。

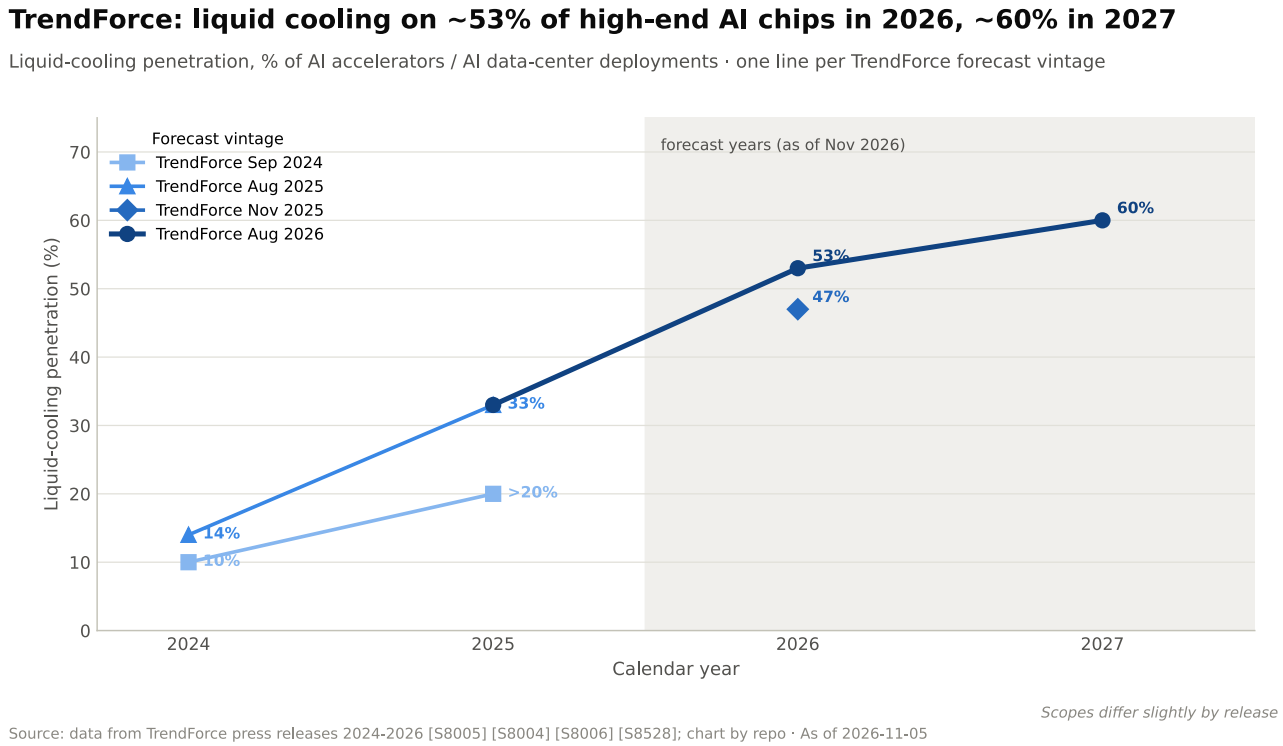

TrendForce 液冷渗透率预估折线图（按预测发布时间划分）。2024 年 9 月版：2024 年约 10%，2025 年超过 20%。2025 年 8 月版：2024 年 14%，2025 年 33%。2025 年 11 月版：2026 年 47%。2026 年 8 月版：2026 年 53%，2027 年约 60%；每一版预测都高于上一版。

🔧 技术细节：PUE 能反映什么、不能反映什么

PUE 等于设施总功耗 ÷ IT 功耗。2025 年行业平均值为 1.54，六年来基本持平 [S8007]；谷歌机群约为 1.09 [S388]。液冷能降低 PUE，因为水泵搬运热量比风扇和冷水机组更便宜；但它也把风扇功耗*计入*了 IT 功耗，因此 PUE 可能会略微美化液冷机房。本资料库对新建液冷 AI 机房取 1.15，对风冷取 1.4（均为假设而非实测）[S387,S388]。

3. 800 V 直流供电架构

目前电力要经过多次转换，最后一步在机架的电源架中完成，由电源架向母排输出约 50 V 直流电 [S8000]。低电压意味着大电流，而大电流意味着大量铜材。英伟达的方案是在设施边界将 13.8 kV 交流电转换为 800 V 直流电，再通过直流母线槽送到各机柜排 [S8016,S90063]。

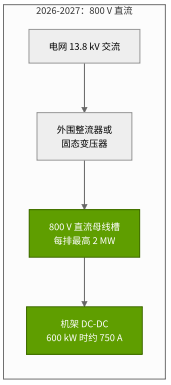

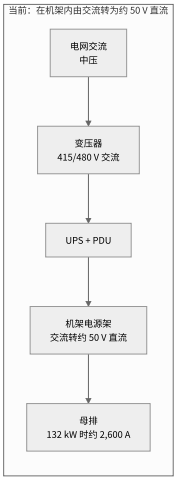

> **提示**
>
> **算例 —— 电压对 Kyber 为何重要。** 一个约 600 kW 的 Kyber 机架 [S305] 在 54 V 下需要 600,000 ÷ 54 ≈ **11,100 A** 电流；在 800 V 下为 **750 A**，约为前者的十五分之一。铜导体截面积随电流增大，电阻损耗随电流平方增大，因此要在 54 V 下达到相同的母排损耗，需要约 15 倍的铜材（本资料库测算）。英伟达称，这样一个机架所需的 54 V 电源架可能占满 **64U**，即整个机架 [S8016]。**结论：** 800 V 直流是兆瓦级机架在物理上得以实现的前提，而不只是锦上添花的能效改进。

现状（🟢 已发布）：包括台达、施耐德、维谛（Vertiv）、ABB、伊顿和西门子在内的约 20 家合作伙伴在 GTC DC 2025 上展示了 800 V 直流部件，CoreWeave、Lambda、Nebius、OCI 和 Together AI 正在按此进行设计 [S90061,S90063]。

> 🔧 **技术细节：800 V 直流尚待解决的问题**
>
> - **标准：** Dell'Oro 将其视为高密度 AI 机房的参考架构，尚非通用标准 [S90062]。
> - **安全：** 直流电弧不像交流电那样会在过零点自行熄灭，因此断路器和人员培训都需要改变。
> - **改造：** 为约 130 kW 机架建造的机房需要新的配电系统才能承载 Kyber 级机架。

4. 电网约束与通电时间

数据中心可以在几个月内建成，电力却可能需要数年（AI 工厂）。在美国，2018–2024 年建成的发电项目，从提交并网申请到投运的中位时间**超过四年**，而 2000–2007 年还不到两年 [S8009]。Dominion 告知北弗吉尼亚的大型（>100 MW）数据中心客户，接电等待期**最长可达七年** [S8010]；截至 2026 年 4 月，ERCOT 跟踪的大型负荷接入申请达**约 410 GW**，其中约 87% 来自数据中心 [S8011]；PJM 预测 2024–2030 年夏季峰值负荷将增长约 32 GW，主要来自数据中心 [S33018]。

建设方的应对是采用表后（behind-the-meter）发电，以燃料成本、审批许可和当地反对为代价换取更短的通电时间：xAI 的 Colossus 2 依靠现场燃气轮机运行，而关于其电网供电情况各方说法不一（🟡）[S8015]。

> **提示**
>
> **算例 —— 100,000 颗 GB300 GPU 的设施电力。** GPU 按约 1.4 kW 计：**140 MW** [S32004]；1,389 个机架按约 132 kW 计：**183 MW** [S337]；网络与存储（+21%，SemiAnalysis 的 GB200 全部计入比例）：**约 38 MW** [S340]；PUE 1.15 下的散热与转换损耗：**约 33 MW**，因此电表处合计**约 255 MW**，若按行业平均 PUE 则为**约 340–346 MW** [S8007,S387]。满负荷用电量：255 MW × 8,760 h = **每年 2.2 TWh**，按美国工业平均电价 8.1¢/kWh 计**约 $181M**，按 5¢ 的购电协议计 $112M，按 10¢ 计 $223M [S389,S390]。**结论：**一个 100k GPU 的 GB300 站点是四分之一吉瓦级的负荷；其年电费约为约 $5.5B 机架采购额的 3%（估计）[S332]。

100,000 GB300 GPUs need ~255 MW at the meter and ~$181M of power a year

Power build-up, MW (repo calc) · 1,389 NVL72 racks at ~132 kW · PUE 1.15 · cost at full load, $0.081/kWh

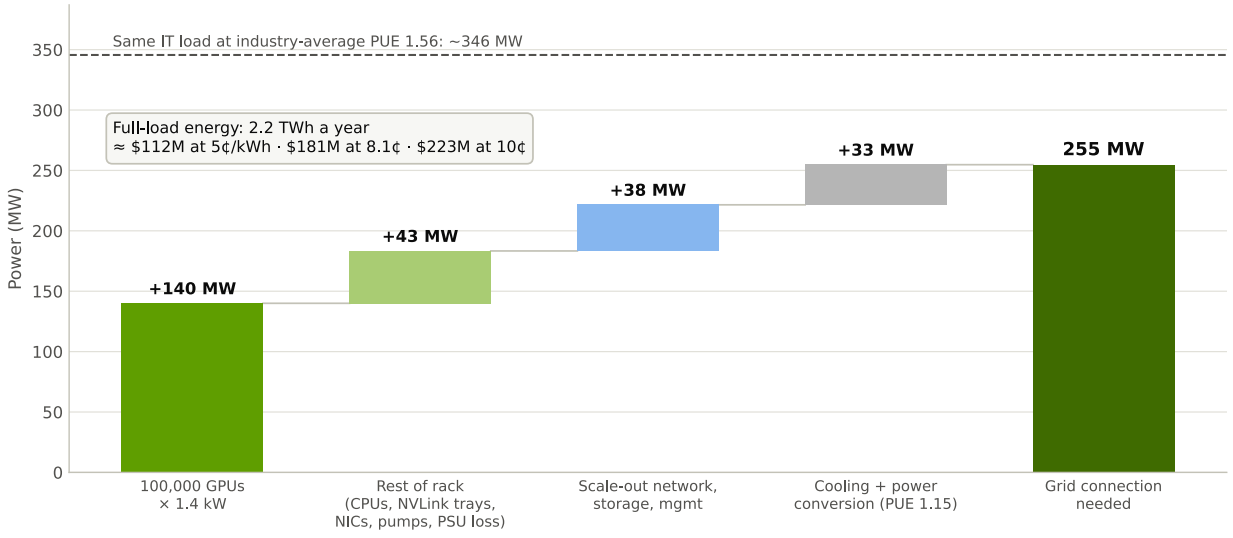

Est. (repo calc)

Source: data from system_specs, gpu_product_specs, tco_model_inputs [S32004] [S338] [S339] [S337] [S332] [S121] ...; chart by repo · As of 2026-11-05

瀑布图：100,000 颗 1,400 W 的 GB300 GPU 功耗约 140 MW；1,389 个 NVL72 机架的其余部分（Grace CPU、NVLink 交换托盘、网卡、水泵、电能转换）增加约 43 MW；横向扩展网络、存储与管理增加约 38 MW（IT 合计 222 MW）；PUE 1.15 下的散热与电能转换开销增加约 33 MW，电表处合计约 255 MW（按行业平均 PUE 1.56 计为 346 MW）。满负荷下每年耗电 2.2 TWh，按每千瓦时 5-10 美分计，电费约 $112M-$223M。

🎯 企业发展视角

1. **电力设备是 AI 基建的第二条供应链。** 维谛（Vertiv）、施耐德、伊顿和台达都在英伟达 800 V 直流合作伙伴名单上 [S90061]；固态变压器、直流断路器和 CDU 是初创公司与收购方活跃的领域（价值链）。

2. **通电时间是竞争武器**。 谁能率先让站点通电，谁就能赢得下一批 GPU 配额；现场发电和已获审批的园区可以获得溢价 [S8015,S8013]。
3. **高通（Qualcomm）的问题（仅基于公开信息）：** 高通的 AI200 机架功耗约 160 kW，采用直接液冷 [S173]；一款能装入现有液冷就绪机房、无需等待 800 V 直流的低功耗推理机架，能否开辟一个被英伟达兆瓦级路线图甩在身后的细分市场?

HGX、DGX、MGX 与 NVL 机架：从芯片到机架级系统

第 08 层 · 系统、机架与 AI 工厂 · 约 10 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **四个产品名词，四种商业模式。** HGX 是供服务器厂商围绕其打造整机的 GPU 基板；DGX 是英伟达（NVIDIA）自有品牌的系统；MGX 是面向合作伙伴的模块化参考架构；NVL 机架（NVL72）则是由 ODM 按英伟达规格制造的整机架级计算机 [S101,S8524,S396]。
- **销售单元十年间扩大约 60 倍：** 2016 年 DGX-1 标价 $129K [S310]；GB300 NVL72 机架约 $4.0M（估计，摩根士丹利），Vera Rubin NVL72 约 $7.8M（估计）[S332,S330]。
- **英伟达如今几乎规定了机架中的一切：** 计算托盘、NVLink 交换托盘、铜缆背板、电源架、母排和液冷接口；2024 年，英伟达将 GB200 NVL72 机架设计贡献给开放计算项目（OCP）[S5001,S8000]。
- **MGX 作为合作伙伴渠道迅速扩张：** 从 2023 年 6 家合作伙伴的 14 款系统，增至 2024 年年中 25 家以上合作伙伴的 90 余款系统 [S8024]；AWS 将把 Trainium4 放入采用 NVLink 的 MGX 机架 [S518]。
- **ODM 负责制造，英伟达负责设计并拿走利润：** 在摩根士丹利的拆解中，72 颗 GPU 约占 GB300 机架价格的 63%，而 ODM 的毛利率约为 2.7%，到 Vera Rubin 时降至约 1.9%（估计）[S332]。
- **弱点：** 机架级锁定会招致抵触：买家保留 8 GPU 的 HGX 以维持供应商选择权，而 AMD 收购了 ZT Systems 的机架设计团队，用于其 72 GPU 的 Helios（2026 年下半年）[S8527,S90020]。

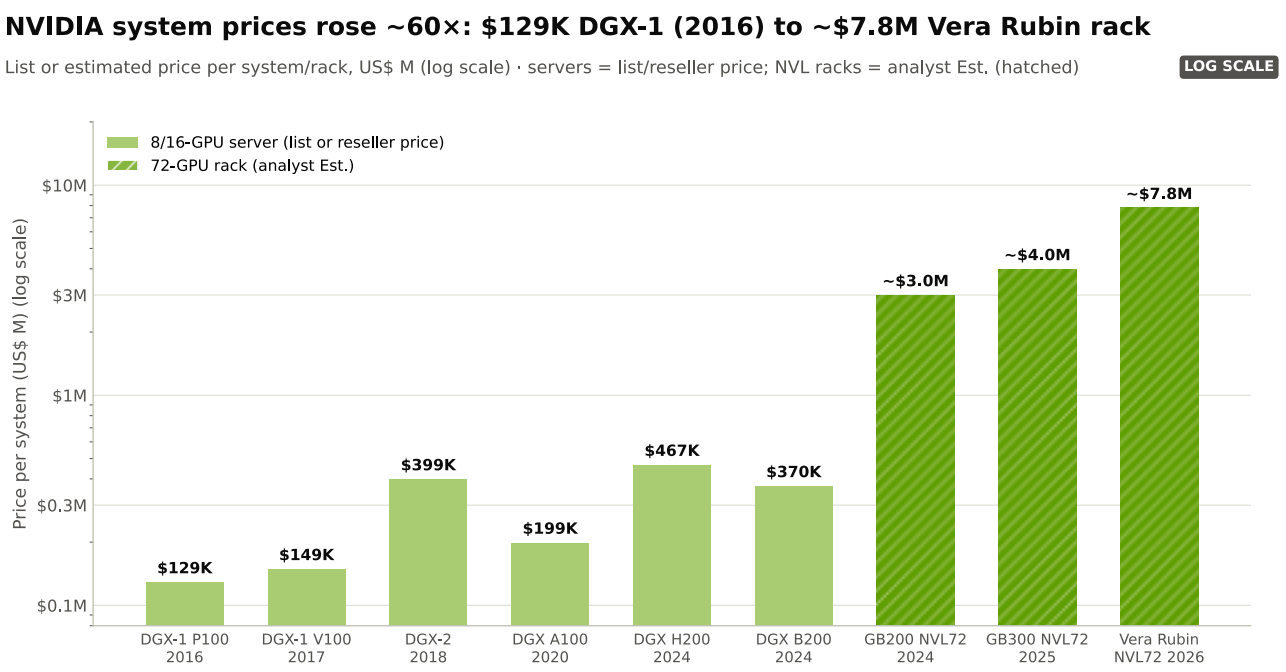

Source: data from AnandTech, TweakTown, resellers, HSBC, Morgan Stanley [S310] [S311] [S125] [S312] [S126] [S313] ...; chart by repo · As of 2026-11-05

英伟达系统价格对数刻度柱状图：DGX-1 为 $129K（2016），DGX-1 V100 为 $149K，DGX-2 为 $399K，DGX A100 为 $199K，DGX H200 约 $467K，DGX B200 约 $370K；随后进入机架级：GB200 NVL72 约 $3.0M，GB300 NVL72 约 $4.0M，Vera Rubin NVL72 约 $7.8M（估计），约为第一代 DGX-1 的 60 倍。

1. 四条产品线及其嵌套关系

可以把这几条产品线想象成尺寸逐级增大的乐高标准件。**HGX**（始于 2017 年与微软（Microsoft）合作的 HGX-1 [S8525]）是一块承载 8 颗 GPU 及其 NVLink 交换芯片的基板，戴尔、HPE、联想、Supermicro 及各

ODM 将其装入自己的机箱，并搭配自选的 CPU 和网卡 [S101]。**DGX** 是英伟达的品牌版本，连同软件与支持服务一并销售，同时也是整个行业的参考设计 [S310,S319]。**MGX** 将基板周围的机箱、托盘、机架和供电标准化，可组合出 100 多种配置，最大可至整机架 [S8524,S8025]。**NVL 机架**把 72 个 GPU 封装和 36 颗 CPU 连成一个纵向扩展域，作为一台整机来构建 [S396,S102]。

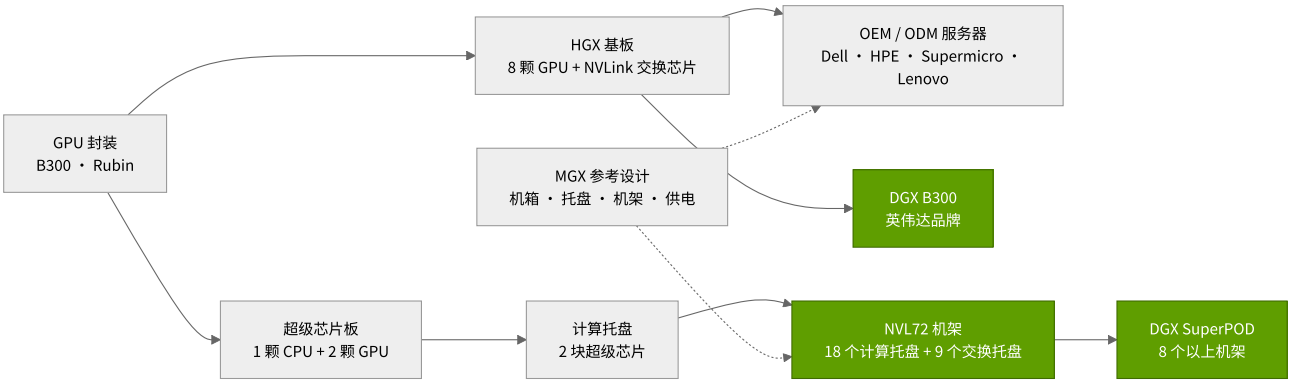

	HGX	DGX	MGX	NVL 机架（NVL72）
是什么	面向合作伙伴的 GPU 基板	英伟达品牌系统	模块化参考架构	整机架即一台计算机
由谁制造	OEM 与 ODM	为英伟达代工的合同制造商	25 家以上合作伙伴 [S8024]	ODM/OEM 按英伟达设计制造；也有 DGX 版本
每个 NVLink 域的 GPU 数	8	8（DGX GB300 为 72）	不定	72；Kyber（2027）为 144 [S305]
功耗与散热	约 10–14 kW，风冷或液冷 [S318,S321]	同左	1U 至整机架	约 120–230 kW，仅液冷 [S336,S303]
价格区间	8× H200 约 $0.32–0.40M [S322]	约 $0.37–0.47M [S320,S322]	不适用	约 $3.0–7.8M（估计） [S326,S330]
买家保留的选择权	最多（CPU、网卡、机箱）	很少	在英伟达框架内选择	最少：英伟达的 BOM

提示

算例 —— 销售单元为何跃升。 一台 DGX H200 搭载 8 颗 GPU，售价约 $467K，每颗 GPU 约 $58K [S322]。一台 GB300 NVL72 搭载 72 颗 GPU，售价约 $3.99M，每颗 GPU 约 $55K（估计） [S332]。按单颗 GPU 计，价格几乎没变；变化在于值得购买的最小单元变成了一个 72 GPU、约 132 kW 的机架 [S337]。**结论：**英伟达放大的是*采购决策的规模*，并随之扩大了由它设计的账单份额。

[Q3 · 代际进步] 每机架 HBM 从 13.8 TB（GB200）增至 20.7 TB（GB300、Vera Rubin），稠密 FP8 算力从 360 PF 增至约 1,260 PF（Vera Rubin） [S121,S337,S102]。

AMD Helios claims ~1.5× Vera Rubin NVL72's HBM (31 vs 21 TB) and ~1.1× its dense FP8

Per scale-up rack or rack-like unit: total HBM (TB, left) and dense FP8 PFLOPS (right) · hatched = announced/roadmap or repo estimate

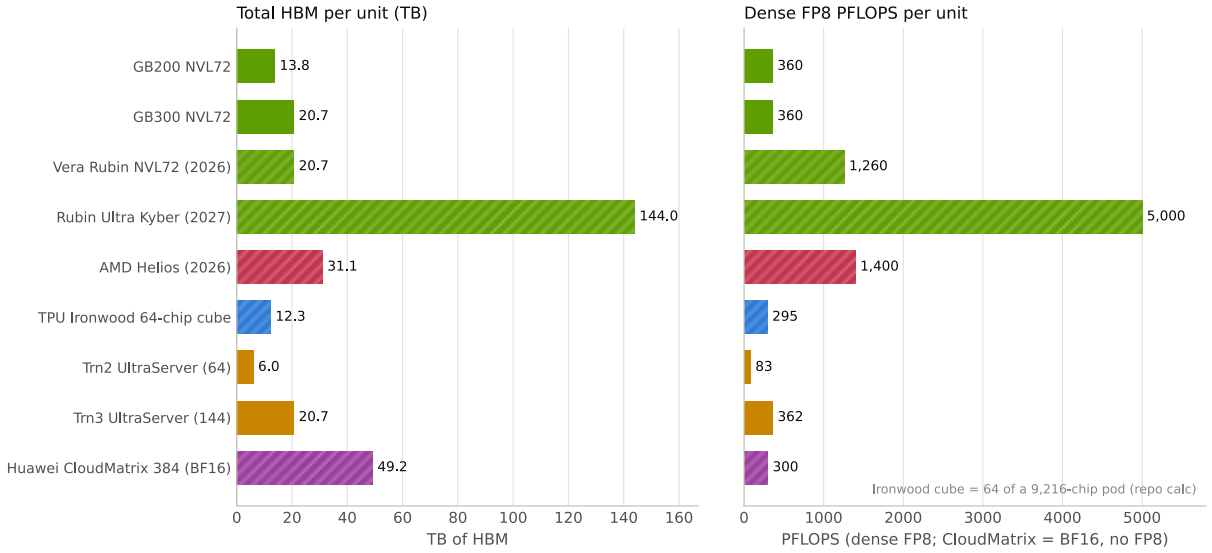

Source: data from NVIDIA, AMD, Google, AWS, SemiAnalysis [S121] [S396] [S336] [S340] [S335] [S326] ...; chart by repo · As of 2026-11-05

对比各机架级系统的两张横向柱状图。HBM：GB200 NVL72 为 13.8 TB，GB300 NVL72 为 20.7 TB，Vera Rubin NVL72 为 20.7 TB，AMD Helios 为 31.1 TB，Rubin Ultra Kyber 约 144 TB，Trn3 UltraServer 为 20.7 TB，华为 CloudMatrix 384 为 49.2 TB。稠密 FP8：GB200/GB300 为 360 PF，Vera Rubin 为 1,260 PF，Helios 为 1,400 PF，Kyber 为 5,000 PF，Trn3 为 362 PF，Ironwood 64 芯片立方体为 295 PF，CloudMatrix 为 300 PF BF16。

🔧 **技术细节：阅读规格表时的命名陷阱**

- **NVL 后的数字含义变了。** 在 GTC 2025 上，英伟达按 GPU 裸片计数（“Vera Rubin NVL144”）；到 CES 2026 又改回按封装计数，因此同一机架如今称为 Vera Rubin NVL72 [S102,S33006]。HGX B300 仍以“NVL16”名义销售（16 个裸片、8 个封装）[S101]。
- **“Oberon”与“Kyber”** 是机架架构而非产品：Oberon 是 GB200、GB300 和 Vera Rubin 使用的水平托盘式 NVL72 机架；Kyber 是为 Rubin Ultra NVL144 设计的垂直刀片式机架，功耗约 600 kW [S305,S108]。

2. 英伟达为何从卖芯片转向规定机架

原因在于纵向扩展带宽。混合专家模型（MoE）把专家分布在许多 GPU 上，每个 token 都会在它们之间产生流量，而这种流量只有在同一个 NVLink 域内才廉价（为何域规模至关重要）。要让 72 颗 GPU 像一台机器那样工作，就必须把背板、交换托盘、信号完整性、供电和散热作为一个整体设计来掌控 [S5000,S5001]。如今英伟达交给合作伙伴的是一份近乎完整的物料清单：带有两块超级芯片板以及网卡和 DPU 插槽的计算托盘 [S8000,S8001]；交换托盘（GB300 机架有 18 颗 NVLink 交换芯片，Vera Rubin 为 36 颗）[S332]；约 5,000 根线缆的背板 [S5000]；电源架、母排以及即将到来的 800 V 直流接口 [S90063]；还有冷板、分液歧管和冷却液温度 [S8002]。

就 Vera Rubin 而言，摩根大通报告称，英伟达将交付完全组装好的 L10 计算托盘，约占服务器成本的 90%，ODM 主要只剩机架集成工作（🟡 有报道）[S8022,S329]。

注意

误区与事实：“机架级意味着英伟达自己造机架。”并非如此。富士康称其占全球 AI 服务器市场约 40% [S3014]，其余由广达、纬创等厂商制造。英伟达设计机架并出售芯片；ODM 负责运营托盘和机架产线、泄漏测试与老化测试（burn-in），利润率约 2–3%，不过随着机架价格翻倍，其以美元计的增值额也在上升 [S332]。

提示

算例 —— 设计方与制造方的经济账（以单个 GB300 机架计）。 摩根士丹利测算的约 $3.99M 机架中，GPU 约 $2.52M，HBM3E 与 LPDDR5X 约 $0.37M，液冷约 $50K；ODM 2.7% 的毛利率对应**约 $108K** [S332,S334]。仅 GPU 一项为英伟达带来的收入就约为 ODM 毛利的 23 倍（本资料库测算）。**结论：**机架级的利润在于编写规格，而不在于钣金加工。

3. 算例：超大规模云厂商购买 1,000 颗 GB300 GPU 时买到了什么

资金沿一条链条流动：超大规模云厂商向 ODM 订购经过测试的 L11 机架；英伟达向 ODM 出售超级芯片、NVLink 交换芯片和网卡（这也是英伟达在财报文件中将 ODM 列为直接客户、将云服务商列为间接客户的原因 [S90069]）；内存厂商把 HBM 卖给英伟达用于其 GPU 封装；英伟达也可能直接出售横向扩展交换机。

提示

算例 —— 1,000 颗 GB300 GPU，钱都付给了谁。 1,000 ÷ 72 = 13.9，因此订单为 **14 个机架（1,008 颗 GPU）**。按每机架约 $3.99M（摩根士丹利口径的 ODM 对云服务商价格；Wolfe Research 为约 $4.3M）计，机架总价**约 $56M**（估计）[S332,S325]。仅 GPU（每机架约 $2.52M）就为**英伟达带来约 $35M**，还不含 Grace CPU、NVLink 交换芯片和网卡；ODM 约 2.7% 的利润为**约 $1.5M**；散热部件（每机架约 $50K）为**约 $0.7M** [S332,S334]。网络与存储大约再增加四分之一（SemiAnalysis：GB200 机架 $3.1M，全部计入约 $3.9M）[S324]：合计**约 $70M（估计）**。电力：14 × 约 132 kW ≈ **1.85 MW** 的机架 IT 负载 [S337]。**结论：**超大规模云厂商与 ODM 签约，但远超一半的资金最终流向英伟达。

🔧 **技术细节：为何仍有买家选择 8 GPU 的 HGX**

HGX 让买家自行选择 CPU、网卡和机箱，并能在约 14 kW 的风冷机房中运行 [S321]；代价是只有 8 颗 GPU 的纵向扩展域，这在大型混合专家模型推理上伤害最大（纵向扩展与横向扩展）。

🎯 企业发展视角

1. **谁掌握机架标准？** 英伟达对 OCP 的贡献和 MGX 让其机架成为行业默认标准；AMD 的回应是收购 ZT Systems 的设计团队，并在 Helios 上采用 OCP 双宽机架 [S8527,S344]。是否还有空间容纳第三种开放的机架级参考设计？
2. **HGX 是对冲市场。** 希望自选 CPU 和网卡的买家停留在 8 GPU 基板上；这正是替代 CPU 和网卡仍能赢得插槽的地方。
3. **高通（Qualcomm）的问题（仅基于公开信息）：** 高通的 AI200/AI250 定位为机架级、直接液冷系统，每机架约 160 kW [S173]。应与 ODM 合作自建、通过 MGX 式生态合作，还是像 AMD 那样收购机架设计能力？

系统、机架与 AI 工厂：竞争格局

第 08 层 · 系统、机架与 AI 工厂 · 约 12 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **机架如今是竞争的基本单元。** GB200 NVL72（72 颗 GPU、约 120 kW、液冷）在 2024 年确立了范式；TrendForce 预计英伟达（NVIDIA）GB/VR 机架级系统的出货量将在 2026 年大致翻倍 S121,S336,S8528。
- **[Q5 · 最强挑战者]** AMD 的 Helios 是最强的*商用*对手：纸面上稠密 FP8 算力达 1.4 EF、HBM4 容量 31.1 TB，而 Vera Rubin NVL72 为 1.26 EF 和 20.7 TB，且采用开放的 OCP 机架 S344,S102。但首批出货直到 2026 年第三季度末前后才开始 🟡 S90020。
- **谷歌（Google）TPU 是最强的*系统级*对手。** Ironwood 把 9,216 颗芯片放进一个光交换域（英伟达为 72 颗），谷歌超过 80% 的 AI 服务器采用液冷，而且 TPU 如今已开始向谷歌以外的客户销售 🟡 S350,S8528,S552,S90027。
- **域规模是英伟达落后的地方。** AWS 每台 UltraServer 达到 144 颗芯片，华为达到 384 至 8,192 颗 S353,S340,S341。英伟达的回应 Kyber NVL144 官方定于 2027 年下半年；有报道称将推迟到 2028 年，但已被否认 🟡 S502,S507,S508。
- **英伟达的弱点：其领先靠的是执行力，而执行可能出现偏差。** 据报道，其首款液冷机架出现过过热和链路故障，导致部分超大规模云厂商削减了 GB200 订单 S5500,S5501。2026 年 Rubin 规格下调后，Helios 在纸面 HBM 带宽上反超 S90006。
- **OEM 和 ODM 是合作伙伴，同时也在争夺价值。** 戴尔给出 FY2027 AI 服务器收入 $74B 的指引 S8500。富士康称其占 AI 服务器约 40% S3014。HPE 销售搭配自家 Juniper 纵向扩展交换机的 AMD Helios S5523。

AMD's Helios leads Vera Rubin NVL72 on 3 of 7 rack metrics on paper; 3 rivals have bigger scale-up domains

Repo verdict for each rival rack-scale system vs NVIDIA Vera Rubin NVL72 (2026 basis); cell = verdict letter + key number

	Compute per rack	Memory per rack	Power per rack	Scale-up domain	Liquid-cooling maturity	Time to deploy	Openness / OCP
AMD Helios (72 x MI455X)	**L · 1.4 vs 1.26 EF FP8**	**L · 31.1 vs 20.7 TB HBM4**	P · ~235 vs 190-230 kW	P · 72 = 72 GPUs	B · first AMD liquid rack	B · ships ~end-Q3 2026	**L · OCP double-wide rack**
Google TPU7x Ironwood superpod	D · 295 PF/rack; 42.5 EF/pod	D · 12.3 TB/rack; 1.77 PB/pod	D · not disclosed	**L · 9,216 vs 72 chips**	**L · >80% of AI servers liquid**	P · GA Nov 2025	B · Google stack; now on OCI
AWS Trn3 UltraServer (144 chips)	B · 362 vs 1260 PF FP8	P · 20.7 = 20.7 TB	D · not disclosed	**L · 144 vs 72 chips**	D · not disclosed	P · GA Dec 2025	B · AWS-only; Trn4 adopts MGX
Huawei CloudMatrix 384 / Atlas 950	B · 300 PF BF16 over 16 racks	D · 49.2 TB per 16 racks	B · 559 kW for 300 PF	**L · 384 (CM384); 8,192 (Atlas 950)**	D · not disclosed	B · Atlas 950 status disputed	B · proprietary; China market
Microsoft Maia 200 cluster	B · >5 vs 17.5 PF FP8 per chip	B · 216 vs 288 GB per chip	D · 750 W chip; rack n/a	D · Ethernet, up to 6,144 chips	D · not disclosed	P · in production Jan 2026	B · Azure-only
Qualcomm AI200 rack (public information)	D · not disclosed	D · 768 GB LPDDR per card	**L · 160 kW per rack**	B · PCIe scale-up	P · direct liquid cooling	B · no 2026 shipment confirmed	**L · PCIe + Ethernet**
Cerebras CS-3 (WSE-3)	D · 125 PF sparse per system	D · 44 GB on-wafer SRAM	D · ~23 kW per system	D · 1 wafer; 2048-system clusters	D · closed system	P · shipping since 2024	B · proprietary system

L = rival leads NVIDIA　P = parity　B = rival behind　D = different approach / not disclosed

Analyst judgement (speculative)

Source: data from repo analysis of vendor specs (l08_rack_verdicts.csv) [S344] [S102] [S90021] [S346] [S302] [S303] …; chart by repo · As of 2026-11-05

热力图：7 个竞争 AI 系统在 7 个维度上与英伟达 Vera Rubin NVL72 的对比。AMD Helios 在算力（1.4 对 1.26 EF FP8）、内存（31.1 对 20.7 TB HBM4）和开放性（OCP 双宽机架）上领先，在功耗和域规模上持平，在液冷成熟度和部署时间（2026 年第三季度末出货）上落后。谷歌、AWS 和华为在纵向扩展域规模上领先（9,216、144 和 384-8,192 颗芯片，对比 72 颗）。谷歌在液冷成熟度上领先。高通的 AI200 机架仅在功耗（160 kW）和开放性上领先。7 个对手中有 5 个至少在一项指标上领先。

机架级竞争如何评分

可以把一个 NVL72 级机架想象成一艘集装箱船，而不是一支卡车车队。买家会权衡载货量（每机架算力与内存）、泊位大小（供电与散热）、多少集装箱能作为一个整体移动（纵向扩展域），以及船能否准时到港。

对手（口径）对比 Vera Rubin NVL72	每机架算力	每机架内存	每机架功耗	纵向扩展域	液冷	部署时间	开放性
AMD Helios（72 × MI455X）	🟩 1.4 对 1.26 EF FP8	🟩 31.1 对 20.7 TB	🟨 约 235 kW（估计）对 190–230	🟨 72 = 72	🟥 AMD 首款液冷机架	🟥 约 2026 年第三季度末出货	🟩 OCP 双宽
谷歌 Ironwood superpod	🟦 每机架 295 PF	🟦 每机架 12.3 TB	🟦 未披露	🟩 9,216 颗芯片	🟩 机群中超过 80%	🟨 2025 年 11 月全面上市	🟥 谷歌技术栈
AWS Trn3 UltraServer	🟥 362 PF	🟨 20.7 TB	🟦 未披露	🟩 144 颗芯片	🟦 未披露	🟨 2025 年 12 月全面上市	🟥 仅限 AWS
华为 CloudMatrix 384	🟥 300 PF BF16，跨 16 个机架	🟦 49.2 TB，跨 16 个机架	🟥 559 kW	🟩 384 颗芯片	🟦 未披露	🟥 Atlas 950 未经证实	🟥 专有
高通 AI200 机架	🟦 未披露	🟦 每卡 768 GB LPDDR	🟩 160 kW	🟥 PCIe	🟨 直接液冷	🟥 未确认 2026 年量产	🟩 PCIe + 以太网

🟩 对手领先 · 🟨 持平 · 🟥 对手落后 · 🟦 路线不同或未披露。来源：S344,S346,S102,S302,S350,S8528,S547,S353,S340,S567,S173,S90028,S90029。全部七个对手的评分见上方热力图。

> **提示**
>
> **算例 —— 每机架多出 10 TB HBM 能换来什么。** 加载一个 FP4 权重约 1 TB 的模型。Vera Rubin NVL72 有 20.7 TB HBM4，留给 KV 缓存约 19.7 TB；Helios 有 31.1 TB，剩余约 30.1 TB S102,S344。在相近功耗（约 190–245 kW）下，每机架可支持的并发长上下文会话约为 1.5 倍 S302,S346。若机架价格相同，Helios 的每会话成本约低 35%：这正是 AMD 的销售话术。

AMD Helios claims ~1.5× Vera Rubin NVL72's HBM (31 vs 21 TB) and ~1.1× its dense FP8

Per scale-up rack or rack-like unit: total HBM (TB, left) and dense FP8 PFLOPS (right) · hatched = announced/roadmap or repo estimate

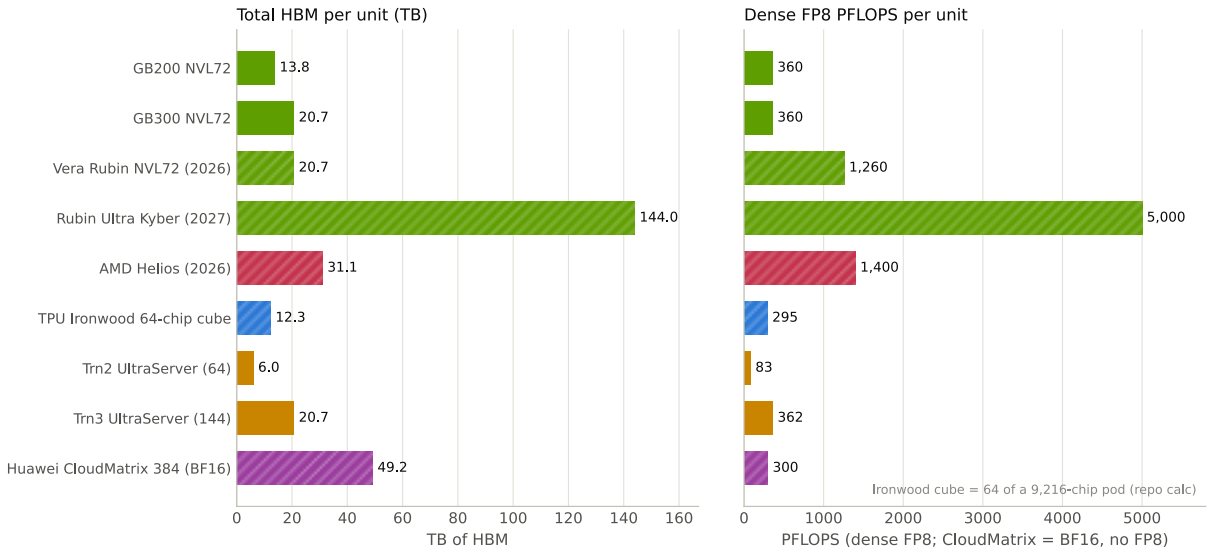

Source: data from NVIDIA, AMD, Google, AWS, SemiAnalysis [S121] [S396] [S336] [S340] [S335] [S326] ...; chart by repo · As of 2026-11-05

对比各机架级系统的两张横向柱状图。HBM：GB200 NVL72 为 13.8 TB，GB300 NVL72 为 20.7 TB，Vera Rubin NVL72 为 20.7 TB，AMD Helios 为 31.1 TB，Rubin Ultra Kyber 约 144 TB，Trn3 UltraServer 为 20.7 TB，华为 CloudMatrix 384 为 49.2 TB。稠密 FP8：GB200/GB300 为 360 PF，Vera Rubin 为 1,260 PF，Helios 为 1,400 PF，Kyber 为 5,000 PF，Trn3 为 362 PF，Ironwood 64 芯片立方体为 295 PF，CloudMatrix 为 300 PF BF16。

🔧 技术细节：为何“部署时间”是一项真实指标

一个 120–230 kW 的液冷机架重量远超一吨（GB200 NVL72 约 1.36 吨）[S335]。它内含超过 2 英里的铜质 NVLink 线缆，通过盲插背板连接 [S5516]。每个机架都要作为一个整体进行泄漏测试和老化测试，然后与 CDU 及设施冷却水回路一起调试投运。GB200 早期的问题是散热和链路故障，而非 GPU 缺陷 [S5500]。一个芯片更好但尚无实际部署机架的对手，仍需经历 12–18 个月的这类学习过程（🔴 本资料库估计）。

逐一审视挑战者

AMD Helios：最强的商用挑战者。 Helios 将 72 颗 MI455X 与 18 颗 EPYC Venice CPU 以及基于以太网的 UALink（UALink-over-Ethernet）交换托盘相结合 [S538,S5524]。买家包括 OpenAI（6 GW，首个吉瓦自 2026 年下半年起）、甲骨文（Oracle，50,000 颗 MI450）和 Anthropic（最高 2 GW）🟡 [S546,S90022,S538]。2026 年第三季度，AMD 数据中心收入同比增长 97% [S542]。**最有力的论据：**每机架内存更多、机架开放、是可信的第二供应商。**差距弥合程度：**纸面上已完全弥合；但在实际部署的机架上，AMD 约落后 1.5–2 年（🔴 本资料库估计）[S121,S90020]。

谷歌 TPU：系统级挑战者。 一个 Ironwood superpod 通过 ICI 与光路交换机（OCS）连接 9,216 颗芯片：FP8 算力 42.5 EF，HBM 1.77 PB [S350,S650]。TPU 8t pod（9,600 颗芯片，FP4 算力 121 EF）将于 2026 年晚些时候推出 [S550]。Anthropic 可使用最多 1M 颗 TPU，TPU 也即将登陆甲骨文云 [S90026,S552]。**弱点：**仅限谷歌的技术栈，对外销售才刚刚起步。

超大规模云厂商的自用方案。 AWS 的 144 芯片 Trn3 UltraServer 于 2025 年 12 月全面上市 [S353]。不过 Trainium4 将采用 NVLink Fusion 和 MGX 机架，这对英伟达而言是部分胜利 [S518]。微软（Microsoft）的 Maia 200 通过以太网扩展至 6,144 颗芯片，Maia 300 将于 2027 年推出 [S158,S90046]。Meta 的 MTIA 400 采用 72 颗加速器的域 [S562]。

华为：以功耗换制程。 CloudMatrix 384 将 384 颗昇腾（Ascend）910C 芯片分布在 16 个机架中，BF16 算力约为 GB200 NVL72 的 1.7 倍（300 对 180 PF）。其功耗约 559 kW，约为 NVL72 全口径 145 kW 的 3.9 倍 [S340]。华为称 8,192 颗芯片的 Atlas 950 SuperPoD 已投入商用，但尚无独立证实 🔴 [S341,S567]。

高通与 Cerebras（公开信息）。 高通（Qualcomm）的 AI200 机架：160 kW、直接液冷、PCIe 纵向扩展、每卡 768 GB LPDDR；HUMAIN 计划自 2026 年起部署 200 MW [S173,S90029,S90030]。AI300（2028）将加入 UALink 和 ESUN 🟢 [S90060]。Cerebras 销售晶圆级 CS-3 系统（晶圆上 44 GB SRAM）[S166]，并于 2026 年 5 月通过 IPO 募资约 $5.5B [S2504]。

> **提示**
>
> **算例 —— 机架价格 10% 的差距为何价值数十亿美元。** 一个 1 GW 的 Vera Rubin NVL72 园区按每机架约 230 kW 计，可容纳约 4,350 个机架（仅计 IT 负载）[S302]。按每机架约 $7.8M（估计，摩根士丹利）计，合计约 $34B [S330]。若对手在同等吞吐量下便宜 10%，每吉瓦可节省约 $3.4B；英伟达对整个吉瓦级工厂的估算为 $50–60B [S398]。

Est. capex per GPU roughly doubles from GB300 NVL72 (~$55K) to Vera Rubin NVL72 (~$108K)

System/rack price ÷ GPUs, US$ K (bar = central estimate; dots = other estimates; hatched = analyst Est.) · AMD/Google/AWS prices not public

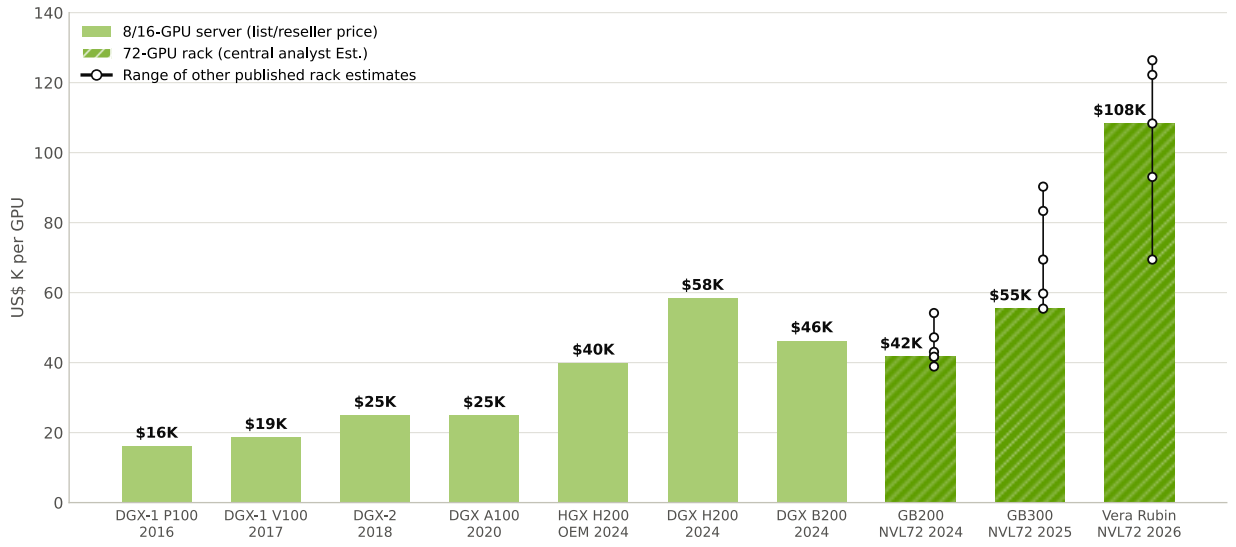

Source: data from resellers, HSBC, SemiAnalysis, Morgan Stanley, Bernstein [S310] [S311] [S125] [S312] [S126] [S313] …; chart by repo · As of 2026-11-05

> 每 GPU 资本开支柱状图：DGX-1 P100 约 $16K（2016），DGX-1 V100 为 $19K，DGX-2 为 $25K，DGX A100 为 $25K，HGX H200 OEM 约 $40K，DGX H200 约 $58K，DGX B200 约 $46K，GB200 NVL72 约 $42K，GB300 NVL72 约 $55K，Vera Rubin NVL72 约 $108K/GPU；以圆点标出其他分析师从约 $39K 到 $126K 的估计。AMD、谷歌和 AWS 的机架没有公开的系统价格。

亦敌亦友的合作伙伴：OEM 与 ODM

OEM（戴尔、HPE、Supermicro、联想）掌握企业客户；ODM 和 EMS 厂商（富士康、广达、纬颖、天弘（Celestica）、Sanmina）掌握工厂车间。它们都依赖英伟达的配额，也都在对冲。HPE 出货搭配 Juniper 交换机的 Helios [S5523]。据 Dell'Oro 数据，2026 年第一季度天弘（Celestica）在 AI 后端交换机销售中位居第一 [S90054]。

Dell guides AI servers to $74B in FY2027 (2.9×); Supermicro to $65–72B (1.75×)

US$ billions by fiscal year; Dell = AI-optimized server revenue; Supermicro = total net sales; hatched = guidance

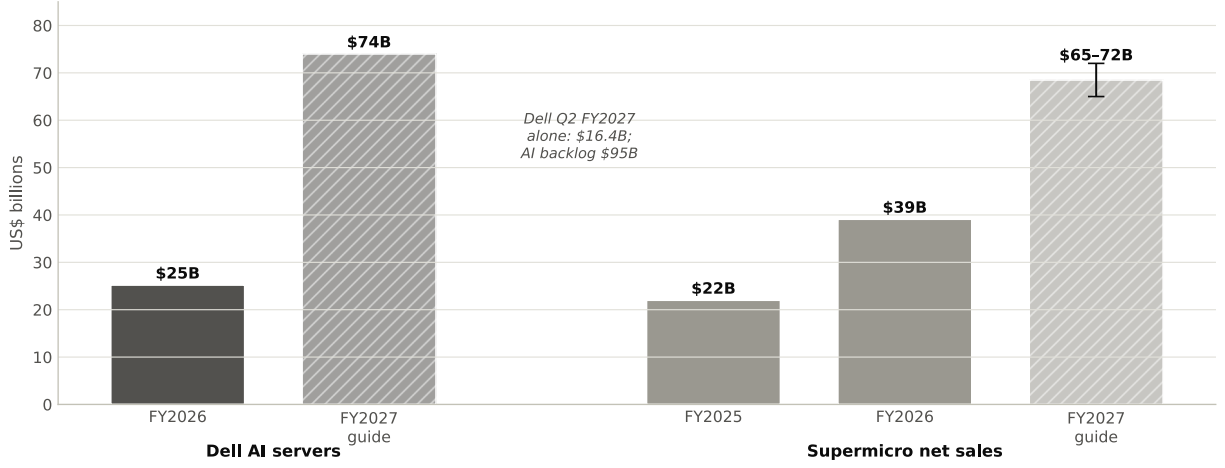

Hatched = company guidance

Source: data from Dell and Supermicro results as reported [S8502] [S8503] [S8500] [S8504]; chart by repo · As of 2026-11-05

> 柱状图：戴尔 AI 服务器收入 FY2026（截至 2026 年 1 月）为 $25.2B，FY2027 指引为 $74B，其中仅 Q2 FY2027 就达 $16.4B，AI 积压订单为 $95B；Supermicro 净销售额 FY2025 为 $22.0B，FY2026（截至 2026 年 6 月）为 $39.1B，FY2027 指引为 $65-72B。OEM 的 AI 收入每年增长 2-3 倍，但戴尔的 AI 服务器营业利润率仅为个位数中段。

提示

算例 —— 收入不等于利润。 戴尔在 Q2 FY2027 录得 $16.4B 的 AI 服务器收入[S8500]。管理层对 AI 服务器的营业利润率目标为个位数中段[S8502,S8503]：按约 5% 计约为 $0.8B 的利润（估计）。同一季度，英伟达在 $96.2B 收入上实现了约 $72B 的毛利[S405]。OEM 赢得了规模；芯片所有者保住了利润（参见价值链）。

注

🐂 **看多观点。** 英伟达自 2025 年起已批量出货 NVL72 机架，并正转向 Vera Rubin，自 2026 年 8 月起量产出货[S500]。就连 AWS 的 Trainium4 也将采用 MGX 机架[S518]。

注意

🐻 **看空观点。** Helios 在开放机架中，纸面内存和 FP8 算力已超过 Vera Rubin NVL72[S344]。谷歌证明了 9,216 颗芯片的域可以在机群规模上运行[S350]。如果 Kyber 推迟到 2028 年 🟡[S507]，英伟达在域规模上的差距将再延续一代。

🎯 企业发展视角

1. 如果 Helios 按时出货，第二款商用机架会压低英伟达的定价，还是 HBM 和 CoWoS 的短缺会让两者都供不应求?
2. 谷歌如今在自家云之外提供 TPU[S552,S90027]：哪些买家（新兴云服务商（neocloud）、主权客户、企业）能够接受仅限谷歌的技术栈?
3. 哪些 ODM 或 EMS 厂商有空闲的机架级新产品导入（NPI）产能来承接第三款商用机架?

4. 对于高通 AI200 这样的 160 kW 推理机架（公开信息），一旦 800 V 直流站点到来，“能装入现有机房”还会是持久的优势吗?

系统、机架与 AI 工厂：历史与英伟达的构建过程

第 08 层 · 系统、机架与 AI 工厂 · 约 11 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **英伟达（NVIDIA）销售系统已有十年。** 第一台 DGX-1（8 颗 GPU、3.2 kW、$129,000）于 2016 年出货，黄仁勋于当年 8 月亲手将其中一台交付给 OpenAI [S310,S8522,S8523]。
- **OEM 标准诞生于 2017 年。** HGX-1 与微软（Microsoft）及富士康旗下的 Ingrasys 共同打造，并通过 OCP 发布，让所有服务器厂商都使用同一块 GPU 基板 [S8525,S8526]。
- **每一步都扩大了英伟达的设计范围。** DGX-2（2018）加入了 NVSwitch [S313]。MGX（2023）将服务器模块化 [S8524]。GB200 NVL72（2024）让 120 kW 液冷机架本身成为产品 [S396,S336]。
- **机架级即便对英伟达也非易事。** 据报道，早期 GB200 机架出现过热和链路故障，部分超大规模云厂商削减了订单 [S5500,S5501]。
- **[Q4 · 优势来源]** 优势在于集成与统筹，而非任何单颗芯片：英伟达设计机架及其网络，并组织协调合作伙伴。2025 年，约 20 家电力合作伙伴展示了 800 V 直流部件 [S90061]。
- **[Q6 · 复制成本]** AMD 的应对是以 $4.9B 收购 ZT Systems，再将其工厂转售给 Sanmina，为一支机架设计团队净付出约 $1.9–2.35B [S5527,S8527]。首批 Helios 机架在交易宣布约 2 年后才出货 🟡 [S90020]。

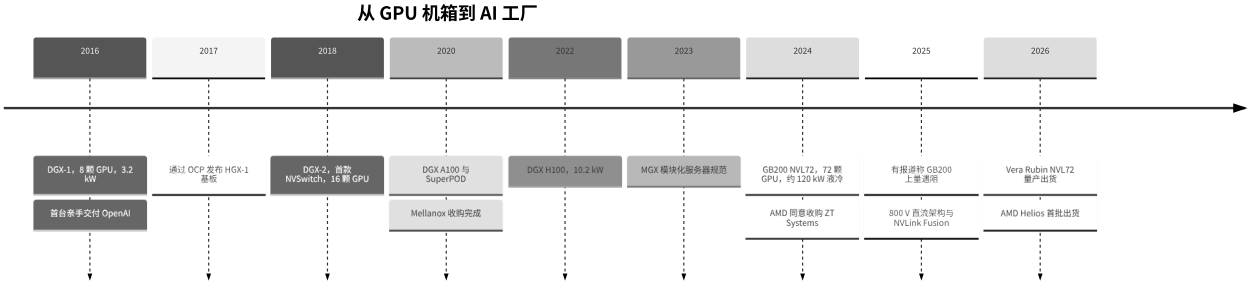

从机箱到机架：关键决策

日期	决策	意义	来源
2016-04	DGX-1：英伟达出售完整的 8 GPU 服务器	英伟达开始出货整机系统	S310
2017-03	通过 OCP 发布 HGX-1 基板	所有 OEM 共用一块基板；黄仁勋将其比作 PC 的 ATX 标准	S8525
2018-03	搭载 NVSwitch 的 DGX-2	16 GPU 全互连域，10 kW，$399,000	S313,S314
2019-03	收购 Mellanox（$6.9B，2020 年完成）	掌握横向扩展网络	S464
2023-05	MGX 模块化规范	用共享部件组合出 100 多种服务器型号	S8524
2024-03	GB200 NVL72 机架	机架成为产品	S396,S121
2024-10	将 NVL72 设计贡献给 OCP	培育兼容的供应链	S5001,S336
2025-05	800 V 直流供电架构	为约 600 kW–1 MW 的机架做好站点准备	S33019,S90061
2026-03	Vera Rubin POD、Kyber、Groq 3 LPX 机架	出售 40 个机架组成的“AI 工厂”单元	S511,S90003

> **提示**
>
> **算例 —— 从 DGX-1 到 NVL72 发生了什么变化。** 一台 DGX-1 为 8 颗 GPU 消耗 3.2 kW（每 GPU 0.4 kW），售价 $129,000，即每 GPU 约 $16,000 [S310]。一台 GB200 NVL72 为 72 颗 GPU 消耗约 120 kW（每 GPU 约 1.7 kW），售价约 $3.0M（估计，汇丰），即每 GPU 约 $42,000 [S336,S326]。每 GPU 功耗上升约 4 倍，每 GPU 价格上升约 2.6 倍。按美元计，采购单元扩大了约 23 倍；在这种规模下，散热、供电和布线成了英伟达而非 OEM 的设计问题。

> **🔧 技术细节：GB200 上量过程中出了什么问题**
>
> 2025 年 1 月有报道称，首批 GB200 NVL72 机架出现过热以及芯片间链路故障；英伟达修改了机架设计。据报道，超大规模云厂商削减了部分订单，OpenAI 据称转而要求采购 Hopper [S5500,S5501]。英伟达曾否认此前的过热报道，一位谷歌（Google）方面的消息人士也表示其订单按计划进行 [S5501]。

[Q4 · 优势来源] 集成、统筹与网络

[Q4 · 优势来源] 英伟达在这一层的领先建立在三项相互强化的能力之上：

1. **系统集成。** 英伟达规定托盘、铜缆背板、电源架和冷却回路；ODM 按此设计制造。一台 Vera Rubin NVL72 包含 72 颗 Rubin GPU、36 颗 Vera CPU 和 36 颗 NVLink 交换芯片，全部是英伟达芯片 [S102,S332]。
2. **供应链统筹。** 2026 年年中，英伟达持有 $279B 的供应与产能承诺 [S407]。它在富士康（约占 AI 服务器的 40%）等 ODM 之间分配稀缺的、基于 CoWoS 封装的 GPU [S3014]。约 20 家合作伙伴按其路线图打造了 800 V 直流部件 [S90061]。
3. **协同设计的网络。** 拥有 NVLink、网卡和交换机，使英伟达能够对机架和集群进行协同调优。Q1 FY2027 网络业务收入创下 $14.8B 的纪录 [S90014,S464]。

单纯的技术*不是*护城河：Helios 在纸面上已追平或超越 Vera Rubin NVL72 [S344]。执行速度才是：英伟达大约每年推出新一代机架 [S500]。

> **提示**
>
> **算例 —— 唯一责任方。** 一个约 60 EF、由 40 个机架组成的 Vera Rubin POD 由七种英伟达芯片构建 [S511]。替代方案则是五家供应商、五套需要调试的固件栈。当一个 1 GW 站点耗资 $50–60B 时 [S398]，延误一个月就相当于约 $4–5B 的资本闲置（🔴 本资料库测算）。买家愿意为一个可问责的集成商买单。

[Q6 · 复制成本] 部署一个 100+ kW 机架需要什么

[Q6 · 复制成本] 最清晰的市场价格来自 AMD 收购 ZT 的交易。AMD 支付了 $4.9B（2024 年 8 月宣布，2025 年 3 月完成），并保留了设计团队和客户赋能团队 [S8527,S5527]。随后，它将 ZT 的工厂以 $2.25B 现金、$0.30B 溢价和最高 $0.45B 的业绩对赌付款（earn-out）出售给 Sanmina [S5527,S5528]。Helios 首批出货约在 2026 年第三季度末，距交易宣布约 2 年 [S90020]。

AMD's net cost for ZT's rack-design teams: ~$1.9-2.35B after selling the factories

US$ billions; AMD's $4.9B ZT Systems purchase less Sanmina's payment for the ZT manufacturing business (closed 2025-10-27)

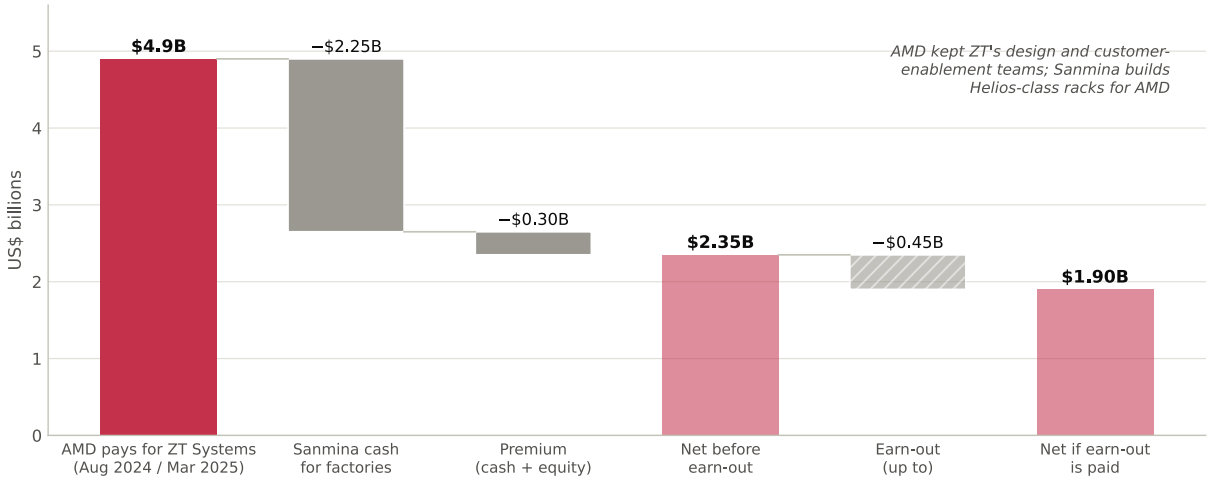

Source: data from AMD, Sanmina and Evertiq [S5527] [S8527] [S5528]; chart by repo · As of 2026-11-05

瀑布图：AMD 以 $4.9B 收购 ZT Systems（2024 年 8 月宣布，2025 年 3 月完成），随后将 ZT 的制造业务以 $2.25B 现金加 $0.30B 溢价及最高 $0.45B 的业绩对赌付款出售给 Sanmina。AMD 为设计团队和客户赋能团队付出的净成本约 $2.35B，若业绩对赌款全额支付则为 $1.9B —— 这就是一支经过验证的机架级设计团队的市场价格。

起点	时间	资金	人才	依据
已有具竞争力的加速器、CPU 和网卡（类似 AMD）	2–3 年	$2–4B	数百至一两千名系统、散热、电源和信号工程师，外加一家 ODM	ZT 净成本约 $2B；Helios 在交易后约 2 年出货 S5527,S90020
有加速器，但没有纵向扩展网络或机架团队	4–5 年	$5–10B	同上，另需交换芯片	首先需要纵向扩展交换机 S5524
希望达到英伟达的年度节奏与供应覆盖面	短期内不可能	$100B+ 的承诺	数百家供应商	英伟达持有 $279B S407

所有估计均为基于所引事实的 🔴 本资料库分析。

提示

算例 —— 收购 ZT 值不值？ OpenAI 的第一个 Helios 吉瓦约为 4,250 个机架，每个约 235 kW（估计）S346,S546。AMD 未公布机架价格；若假设每机架 $5M（🔴），这一吉瓦约对应 $21B 的系统收入。AMD 为 ZT 团队净付出的约 $2B，约为一个吉瓦收入的 10%。如果这支团队能让 Helios 按时出货，投资回收会很快。

反事实推演 —— 如果英伟达当初没有……

1. 🔴 ……**超越芯片本身（没有 DGX、HGX 或 NVL72）**。 OEM 会继续制造 8 GPU 机箱，也就不会有 72 GPU 的域。英伟达称 MoE 模型在 GB200 NVL72 上的运行速度比 HGX H200 快约 10 倍（厂商说法）S5002。那样的话，TPU pod 在前沿 MoE 工作负载上将没有对手，OEM 也会在每一美元系统支出中保留更多份额。
2. 🔴 ……**成为拥有自有工厂的完整 OEM**。 它将获得 ODM 约 2–3% 的机架利润 S332。但它将不得不承担库存和现场服务，并把戴尔、HPE 和 Supermicro 变成竞争对手。设计主导、ODM 制造（即“苹果模式”）保护了约 75% 的毛利率 S405。
3. 🔴 ……**如此迅速地解决 GB200 机架问题（即修复得更慢）**。 如果客户像 OpenAI 据称所要求的那样大规模转回 Hopper S5501，AMD 和谷歌将在 2025 年赢得一个 12 个月的窗口期。

> **提示**
>
> **算例 —— 量化反事实 1。** 从 HGX 服务器到 NVL72 机架，英伟达产品在系统价格中的占比上升了约 10–20 个百分点（价值链）。在一个吉瓦的 Vera Rubin 机架（约 $34B，估计）中 [S330,S302]，10 个百分点约为 $3.4B，否则这部分会留在集成商手中（🔴）。

🎯 企业发展视角

1. ZT 交易为一支机架设计团队定出了约 $2B 的净价格 [S5527]。还有哪些独立的系统设计公司？谁会为它们支付类似的价格？
2. Sanmina 为 AMD 的机架工厂支付了最高 $3.0B [S5528]：机架级 NPI 与测试产能本身是否就是一项稀缺资产？
3. 英伟达在这里的护城河是统筹能力。挑战者可以率先锁定哪些供应商（散热、供电、连接器），以拖慢英伟达的下一次上量？
4. 如果 GB200 的上量问题在 Kyber 约 600 kW 的功耗下再次出现 🟡 [S90061]，谁最有可能在空窗期抢占份额？

系统、机架与 AI 工厂：路线图

第 08 层 · 系统、机架与 AI 工厂 · 约 10 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **Vera Rubin NVL72 是 2026 年的主力机架。** 量产出货于 2026 年 8 月开始，第四季度放量 🟢 S500,S90009。谷歌云（Google Cloud）预计基于它的 A5X 实例将于 2026 年 11 月全面上市 S554。
- **Kyber 的时间点存在争议。** 这款 144 个封装、约 600 kW 的 Rubin Ultra 机架官方定于 2027 年下半年。SemiAnalysis 报道称，由于中板（midplane）的可制造性问题，其将推迟 12 个月以上，英伟达（NVIDIA）予以否认 🟡 S510,S507,S508。
- **按每机架计，从 GB200 到 Kyber，功耗约增至 5 倍（120 → 约 600 kW），换来约 14 倍的稠密 FP8 算力和约 10 倍的 HBM**（按已发布数据）S121,S336,S305。
- **800 V 直流是起支撑作用的路线图。** 兼容 MGX 的 800 V 直流电源机架将于 2026 年下半年推出，机柜排级电力中心（每排最高 2 MW）将于 2027 年推出 S90063。Dell'Oro 认为它目前是一种参考架构，尚非标准 S90062。
- **竞争对手跟上了英伟达的年度节奏。** AMD：Helios（2026）、Helios 500（2027）、Helios 600（2028）S538。谷歌的 TPU 8t pod 定于 2026 年底推出 S550，Maia 300 定于 2027 年 S90046，华为 Atlas 960 定于 2027 年第四季度 S567。
- **[Q7 · 路线图与变数]** 有三件事比下一份规格表更重要：电网电力、液冷供应链（2025–27 年在 AI 芯片中的渗透率 33% → 53% → 约 60%），以及 600 kW 下的可靠性 🟡 S8528。

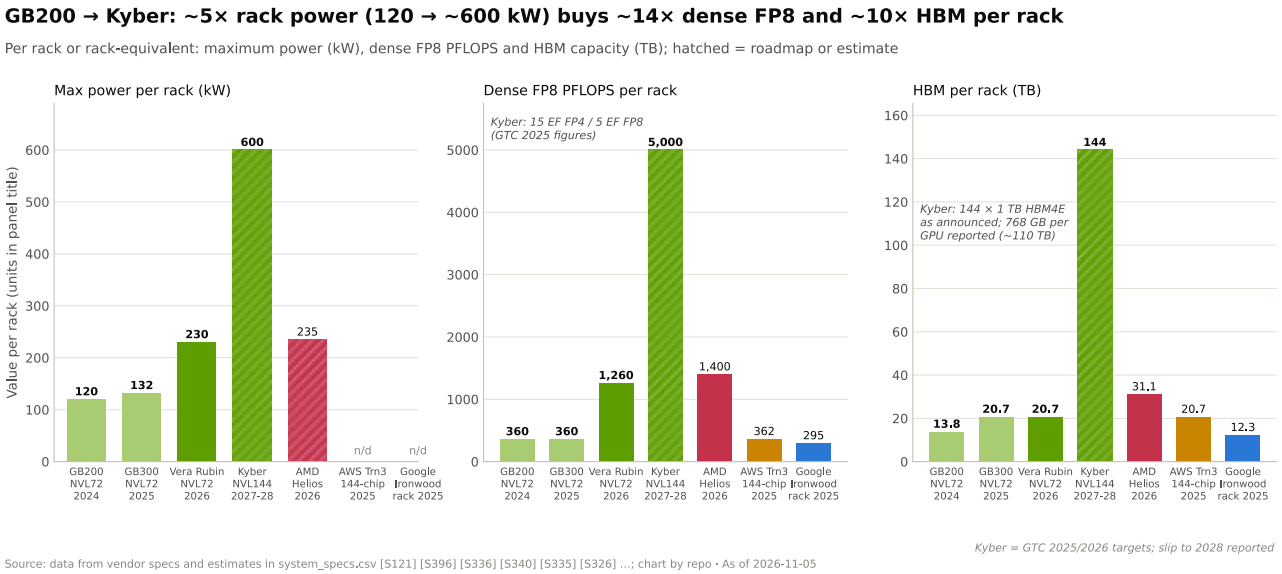

对比各机架级系统的三组柱状图。功耗：GB200 NVL72 为 120 kW，GB300 为 132 kW，Vera Rubin NVL72 约 190-230 kW，AMD Helios 约 225-245 kW（估计），Kyber 约 600 kW（路线图）；AWS 和谷歌未公布机架功耗。稠密 FP8：GB200 和 GB300 为 360 PF，Vera Rubin 为 1,260 PF，Helios 为 1,400 PF，Kyber 为 5,000 PF，Trn3 144 芯片为 362 PF，Ironwood 64 芯片机架为 295 PF。HBM：13.8、20.7、20.7、31.1（Helios）、约 144 TB（Kyber，按已发布数据）、20.7（Trn3）以及 12.3 TB（Ironwood 机架）。

2024–2028 年路线图一览

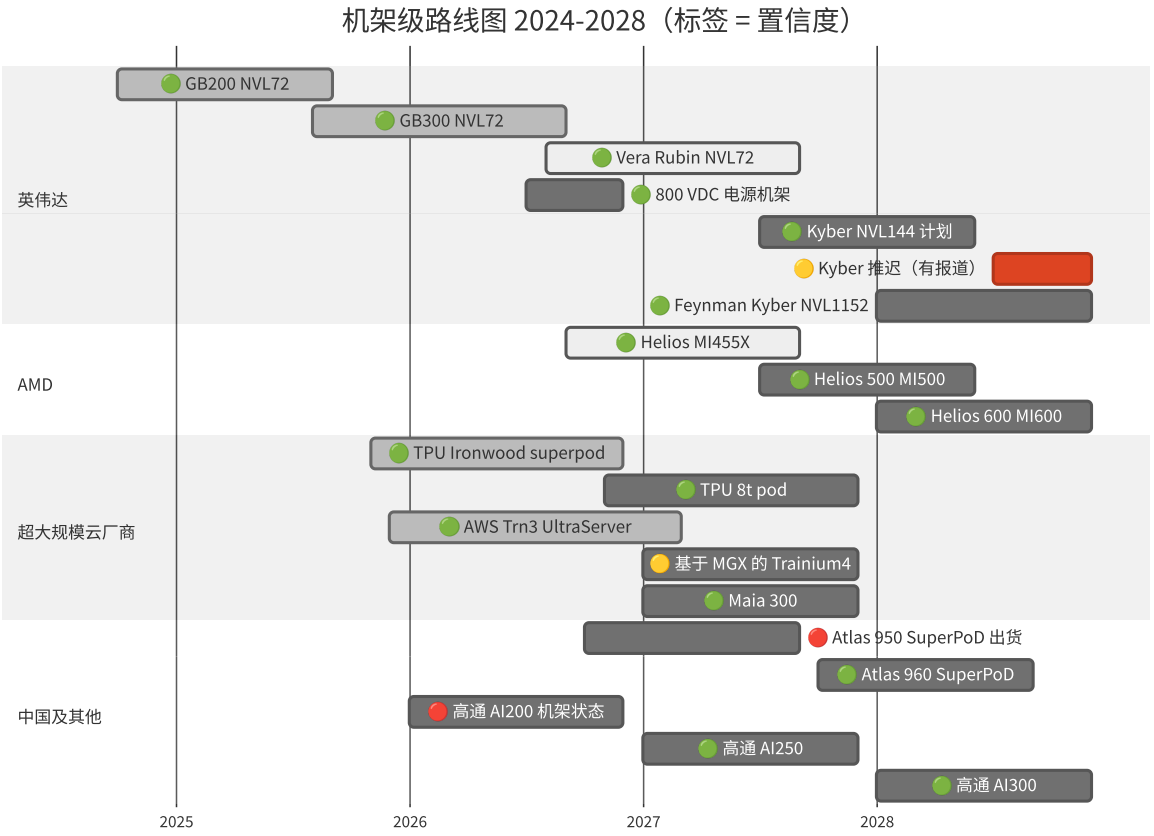

项目	时间窗口	状态	置信度	来源
GB300 NVL72	2025 年下半年 → 2026 年	出货中	🟢	S32004,S554
Vera Rubin NVL72（72 颗 Rubin + 36 颗 Vera，20.7 TB HBM4）	2026 年 8 月量产；2026 年第四季度放量	出货中	🟢	S500,S102
与 Vera Rubin 并列部署的 Groq 3 LPX 机架	2026 年下半年	已发布	🟢	S113,S114
800 V 直流 MGX 电源机架 / 机柜排级电力中心	2026 年下半年 / 2027 年	路线图	🟢	S90063
Kyber NVL144（Rubin Ultra，约 600 kW）	官方为 2027 年下半年；有报道称 2028 年	存在争议	🟡	S510,S507,S508
Feynman、Kyber NVL1152（铜缆 + 光互连）	2028 年	路线图	🟢	S108,S109
AMD Helios → Helios 500 → Helios 600	2026 / 2027 / 2028	出货中 / 路线图	🟢	S538,S90020
谷歌 TPU 8t pod（9,600 颗芯片，121 EF FP4）	2026 年底	已发布	🟢	S550
采用 NVLink Fusion 和 MGX 的 AWS Trainium4	约 2027 年（AWS 未给出日期）	已发布	🟡	S518,S156
微软 Maia 300	2027 年	已发布	🟢	S90046
华为 Atlas 950 → Atlas 960 SuperPoD	2026 年第四季度 / 2027 年第四季度	出货未经证实	🔴 / 🟢	S341,S567
高通 AI200 → AI250 → AI300（公开信息）	2026 / 2027 / 2028	已发布；2026 年量产未经证实	🟢 / 🔴	S173,S90060,S90028

提示

算例 —— 如何解读一次推迟。 Kyber 的官方时间窗口是 2027 年下半年[S510]。如果 SemiAnalysis 关于推迟 12 个月以上的报道属实[S507]，2027 年的买家拿到的将是装在现有 Oberon NVL72 机架中的 Rubin Ultra，GTC 2026 已将其列为一个选项[S108]。推迟的代价在于域规模而非算力：每个 NVLink 域停留在 72 颗 GPU 的时间将再延长一年。与此同时，AWS 提供 144 颗，谷歌提供 9,216 颗[S353,S350]。

4 NVIDIA roadmap items slipped, led by Kyber's reported 12-month delay

Originally announced (hollow) vs current official or reported (filled) start of availability window

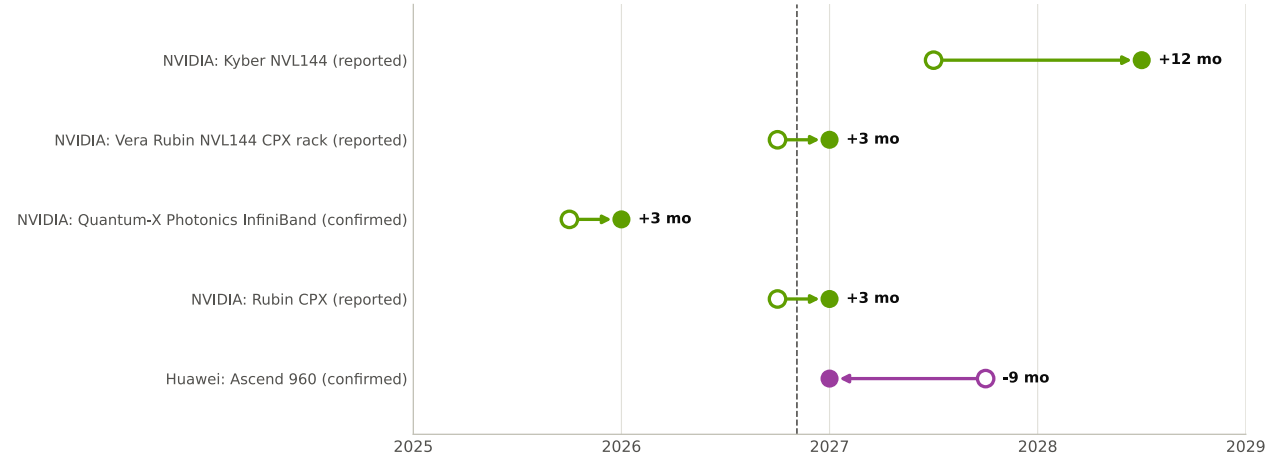

Source: data from Company statements, SemiAnalysis, TrendForce, trade press [S163] [S567] [S568] [S33023] [S115] [S116] ...; chart by repo · As of 2026-11-05

进度变化哑铃图（华为的为提前）：昇腾 960 -9 个月，Rubin CPX +3 个月，Quantum-X Photonics InfiniBand +3 个月，Vera Rubin NVL144 CPX 机架 +3 个月，Kyber NVL144 +12 个月。Kyber NVL144 的推迟来自 SemiAnalysis 报道，英伟达有异议；Rubin CPX 回归为分析师说法。

为何供电决定节奏

每一代机架都受限于单个机架能输送多少电力、排出多少热量。如今的机架从电源架向托盘分配约 54 V 直流电。在 600 kW 下，这需要大量铜材，并以热量形式浪费电能。英伟达的 800 V 直流方案把电能转换移到建筑边界，并以高电压向机架供电[S33019]。Heron Power 等初创公司的固态变压器可将中压电网电力直接转换为 800 V[S8519]。

提示

算例 —— 600 kW 下 800 V 为何重要。 电流 = 功率 ÷ 电压。一个 600 kW 的 Kyber 机架在 54 V 下需要约 11,100 A 电流；在 800 V 下约 750 A，约为前者的十五分之一[S305,S33019]。电阻损耗与电流平方成正比，因此同一母排在 800 V 下的发热损耗约少 200 倍（🔴 本资料库的物理测算，未计转换损耗）。一个 2 MW 的机柜排级电力中心大约可为三个这样的机架供电[S90063]。

🔧 技术细节：800 V 直流生态必须交付什么

2025 年 10 月的 GTC DC 上，约 20 家合作伙伴展示了 800 V 直流部件，范围涵盖芯片（英飞凌、意法半导体、纳微（Navitas）、德州仪器）、电力设备（台达、伊顿、施耐德、维谛（Vertiv）、ABB）以及电网设备（GE Vernova、日立能源、西门子）[S90061]。包括 CoreWeave、Lambda 和 Nebius 在内的新兴云服务商（neocloud）正在按 800 V 进行设计[S90061]。尚待解决的问题：机房白区（white space）内高压直流的安全规范，以及超大规模云厂商是否会采用英伟达的版本[S90062]。

[Q7 · 路线图与变数]

[Q7 · 路线图与变数] 纸面上各家路线图正在趋同：每家都会每年推出一款配备约 20–30 TB HBM 的机架。可能改变格局的因素：

- **电力可得性。** 机架功耗从约 120 kW 升至约 600 kW，1 MW 已在视野之内 S90061；已并网、具备 800 V 条件的机房决定了所有厂商的节奏。
- **液冷供应。** TrendForce 预计液冷在 AI 芯片中的渗透率 2026 年约为 53%，2027 年约为 60% 🟡 S8528。冷板和 CDU 可能会像当年的 CoWoS 一样成为机架的瓶颈。
- **机架可靠性。** 据报道，Kyber 的问题出在中板，是制造问题而非芯片问题 S507。Helios 若能顺利上量，缩小英伟达领先优势的速度将快于任何规格提升。
- **内存成本。** 内存已升至 Vera Rubin 机架物料清单的约 26%（估计，摩根士丹利），伯恩斯坦（Bernstein）预计机架价格约 $9.1M 🟡 S332,S333。
- **开放的纵向扩展。** UALink 1.0 产品预计于 2027 年推出 🟡 S90051。届时商用机架将获得一种非英伟达的纵向扩展网络。

> **提示**
>
> **算例 —— 散热成本不高，散热供应却是大问题。** 摩根士丹利估计每个 GB300 NVL72 机架的液冷成本约 $50K，每个 Vera Rubin 机架约 $56K，不到 $7.8M 机架价格的 1% S334,S330。但缺少一台 $56K 的 CDU，就会让价值 $7.8M 的算力闲置。正是这种不对称，促使伊顿以 $9.5B 收购了 Boyd Thermal S8508。

🎯 企业发展视角

1. 如果 Kyber 推迟到 2028 年 🟡 S507，AMD 的 Helios 500（2027）或谷歌的 TPU 8t pod 是否会吸引那些需要更大域的前沿买家?
2. 哪些 800 V 直流部件（固态变压器、直流断路器、GaN/SiC 功率级）目前还缺少规模化供应商?
3. 超大规模云厂商会像 AWS 在 Trainium4 上那样采用英伟达的 MGX 与 800 V 设计 S518，还是坚持自研机架?
4. 对于 2027–28 年进入市场的推理机架厂商（例如高通（Qualcomm）AI250/AI300，公开信息），设计应瞄准当前的 160 kW 机房，还是 800 V 站点?

系统、机架与 AI 工厂：价值链与企业发展视角

第 08 层 · 系统、机架与 AI 工厂 · 约 12 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **英伟达（NVIDIA）拿走了一个机架的大部分价值。** 在一个估计价值 $3.99M 的 GB300 NVL72 中，约 $2.27M（约 57%）是英伟达在 GPU 上的毛利。ODM 保留约 $108K（2.7%），液冷成本约 $50K（估计，摩根士丹利）[S332,S334]。
- **集成商靠微薄的利润运营。** 在 Vera Rubin 机架上，ODM 毛利率降至约 1.9%（估计）[S332]。广达的 GB 机架服务器毛利率约 5%（凯基证券）[S8529,S8530]；戴尔对 AI 服务器的营业利润率目标为个位数中段 [S8502,S8503]。
- **价值从 OEM 转移到了英伟达。** 英伟达产品在系统中的占比，从 HGX 服务器的约 50–75% 升至 NVL72 机架的约 71–84%（🔴 本资料库根据分析师的物料清单估计）。
- **内存是新的分利者。** 内存在机架物料清单中的占比从约 9%（GB300）升至约 26%（Vera Rubin）（估计，摩根士丹利）[S332,S331]。
- **电力与散热是高利润的基础设施价值池。** 2026 年第三季度，维谛（Vertiv）销售额增长 61%，调整后营业利润率为 25.2% [S8507]。伊顿（Boyd Thermal，$9.5B）、施耐德（Motivair）和维谛（PurgeRite）正在进行整合 [S8508,S8513,S8510]。
- **[Q8 · 价值池与并购机会]** 有三类资产以溢价成交：机架设计团队（ZT，AMD 净付出约 $2B）、散热与电力业务，以及数据中心主体建筑（Aligned，$40B）[S5527,S8521]。

Est. ~57% of a ~$4.0M GB300 NVL72 rack is NVIDIA's gross profit on the 72 GPUs alone

Estimated build-up of the ODM-to-hyperscaler rack price, US$ M · Morgan Stanley BOM (May 2026) + Epoch AI B200 unit-cost basis

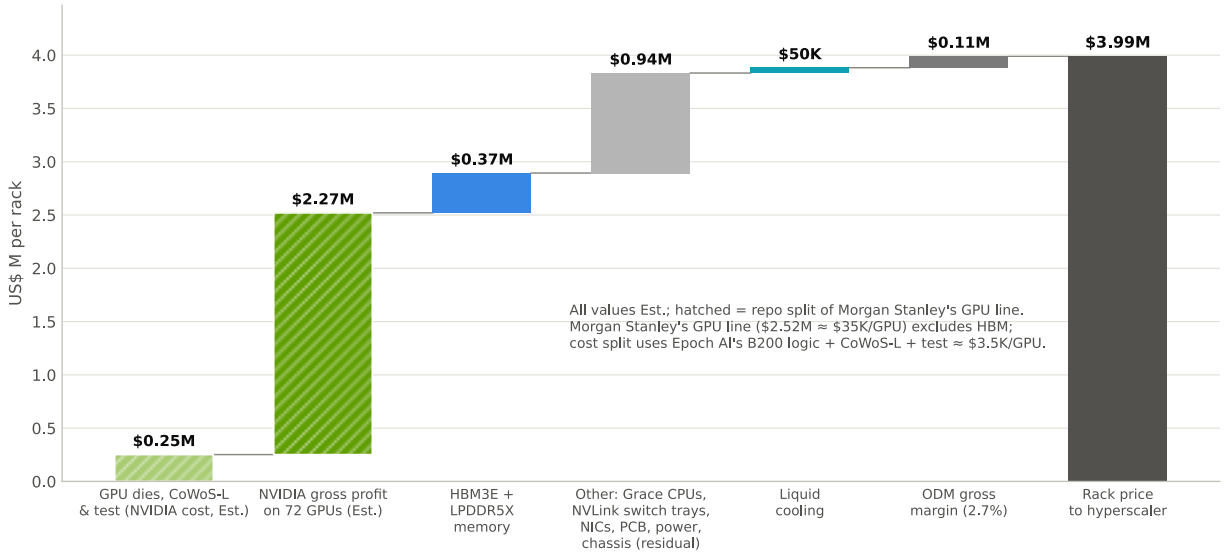

Source: data from Morgan Stanley via press; Epoch AI; repo calc [S332] [S331] [S334] [S32004] [S35020]; chart by repo · As of 2026-11-05

> 一个估计价值 $3.99M 的 GB300 NVL72 机架的瀑布图：GPU 裸片、CoWoS-L 封装与测试约 $0.25M，英伟达 GPU 毛利约 $2.27M（57%），HBM3E 与 LPDDR5X 内存 $0.37M，其他机架部件（Grace CPU、NVLink 交换托盘、网卡、PCB、电源、机箱）约 $0.94M，液冷 $50K，ODM 毛利约 $108K。

机架中的钱被谁拿走了

英伟达采购晶圆、封装和 HBM，出售 GPU 模组、CPU、交换托盘和网卡。ODM 在 L10–L11 层级（集成层级）组装并测试机架；OEM 则提供服务和融资。

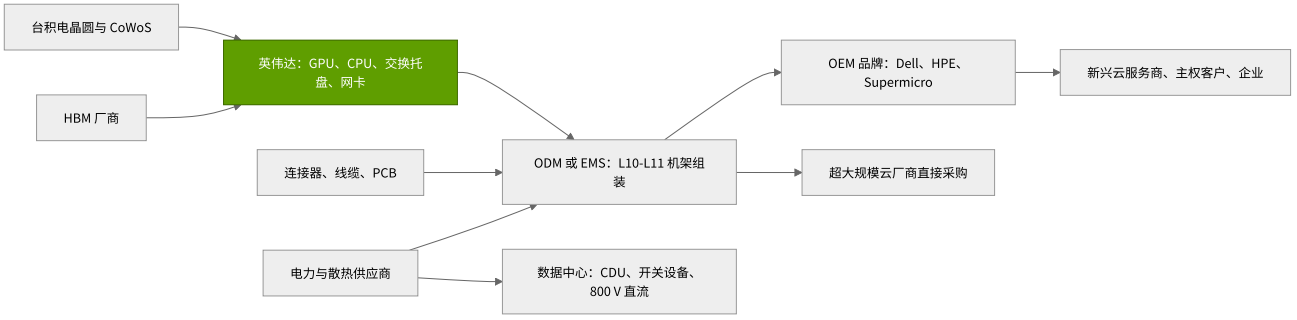

价值池（GB300 NVL72，估计）	归属方	每机架金额	占比	龙头企业利润率
GPU 毛利	英伟达	约 $2.27M	约 57%	毛利率 75.0% S405
GPU 裸片、CoWoS-L、测试	台积电（TSMC）、封测厂（OSAT）	约 $0.25M	约 6%	台积电毛利率 66.4% S3538
HBM3E + LPDDR5X	SK 海力士、三星、美光（Micron）	约 $0.37M	约 9%（Vera Rubin 上 → 约 26%）	美光毛利率 86.8% S3533
其他部件（Grace、交换托盘、网卡、PCB、电源架、线缆）	英伟达、安费诺（Amphenol）、台达等	约 $0.94M	约 24%	安费诺销售额同比 +65% S5503
液冷	冷板与 CDU 厂商	约 $50K	约 1%	维谛调整后营业利润率 25.2% S8507
组装与测试	富士康、广达、纬创/纬颖	约 $108K	约 2.7%	富士康毛利率 6.3% S3522

机架拆分数据来自摩根士丹利 2026 年 5 月的 BOM，图表见 S332,S331,S334；横向扩展网络与存储在本表之外每机架另增约 $0.8M（估计）S324。

NVIDIA keeps a 75% gross margin; the ODMs that assemble its racks keep ~2–5%

Gross or operating margin (%), latest reported period per company; solid = gross, hatched = operating; light = estimate

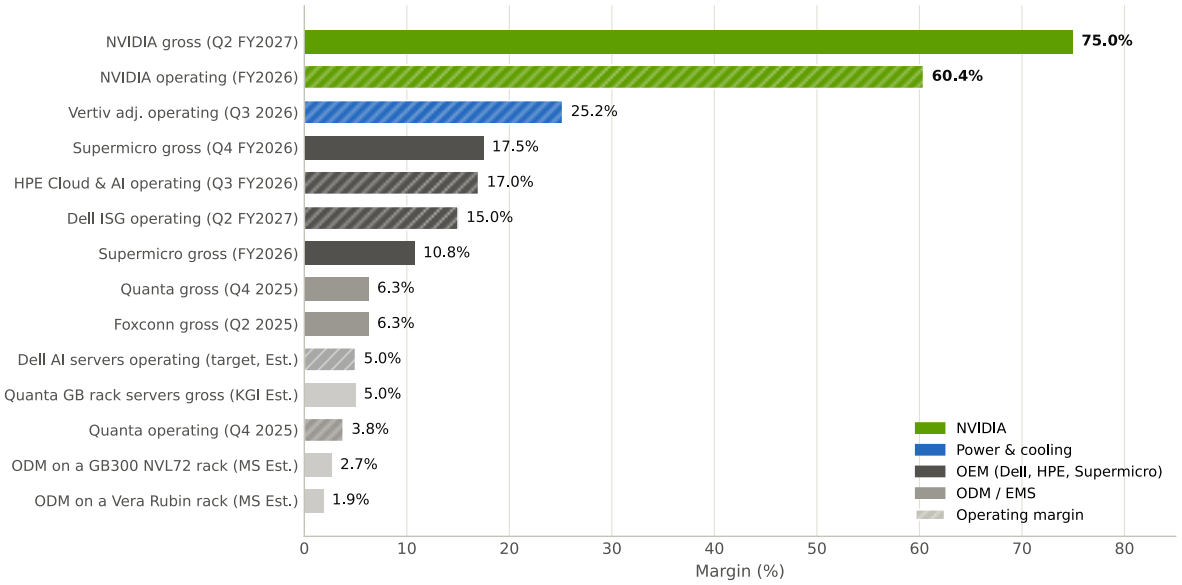

Mixed periods and bases

Source: data from company results; KGI, MS estimates [S332] [S8529] [S8502] [S8503] [S3522] [S8504] ...; chart by repo · As of 2026-11-05

AI 系统价值链各环节利润率横向柱状图：英伟达毛利率 75.0%（Q2 FY2027），营业利润率 60.4%（FY2026）；维谛调整后营业利润率 25.2%（2026 年第三季度）；Supermicro Q4 FY2026 毛利率 17.5%，但 FY2026 全年为 10.8%；HPE 云与 AI 业务营业利润率 17.0%；戴尔 ISG 营业利润率 15.0%；广达和富士康毛利率 6.3%；戴尔 AI 服务器营业利润率目标为个位数中段（约 5%）；广达 GB 机架服务器毛利率约 5%（凯基证券）；ODM 在 GB300 NVL72 机架上的毛利率为 2.7%，在 Vera Rubin 机架上为 1.9%（摩根士丹利）。

提示

算例 —— 散热只占账单的 1%，却是一个增长市场。 液冷约占 $3.99M GB300 机架中的 $50K（约 1.3%），以及 $7.8M Vera Rubin 机架中的约 $56K（约 0.7%）[S334,S330]。建筑侧的 CDU、管道和冷水机组不在这份账单之内。驱动市场的是机架数量，而非每机架价格。TrendForce 预计英伟达 GB/VR 机架出货量将在 2026 年大致翻倍，液冷在 AI 芯片中的渗透率将达约 53% [S8528]。

Est.: of ~$4.8M spent on a GB300 NVL72 rack + network, NVIDIA keeps ~$2.3M as GPU gross profit

Where the dollars go, US$ M · rack price $3.99M (Morgan Stanley, May 2026) + ~$0.8M scale-out network/storage (SemiAnalysis GB200 basis) · GPU cost on Epoch AI B200 basis

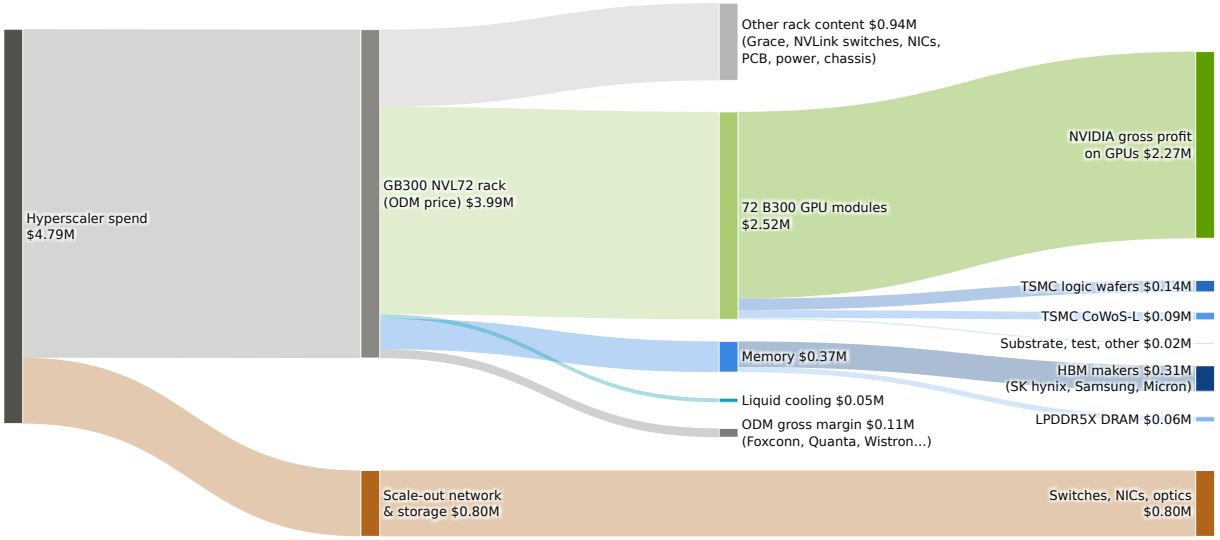

All values Est. · NVIDIA also earns margin inside 'Other rack content' (Grace, NVLink switches, NICs) and much of the network spend; those splits are not public.

Source: data from Morgan Stanley, SemiAnalysis, Epoch AI (repo calc) [S332] [S331] [S334] [S32004] [S35020] [S324]; chart by repo · As of 2026-11-05

> GB300 NVL72 机架（含其分摊的网络）的估计价值流向桑基图：在约 $4.8M 中，英伟达 GPU 毛利约 $2.27M，台积电逻辑晶圆约 $0.14M，CoWoS-L 封装约 $0.09M，HBM 厂商约 $0.31M，LPDDR5X 约 $0.06M，其他机架部件约 $0.94M，液冷 $0.05M，ODM 利润约 $0.11M，横向扩展网络与存储约 $0.8M。

有多少价值从 OEM 转移到了英伟达

在 HGX 时代，OEM 购买一块 GPU 基板，再围绕它设计服务器。到了 NVL72 时代，英伟达规定整个机架，并出售其中的大部分芯片；OEM 的角色缩减为品牌、服务和融资。

Est.: NVIDIA's share of system value rose from ~50–75% (HGX) to ~71–84% (NVL72)

Left: estimated NVIDIA content as % of system price (range). Right: integrator gross margin (%). Repo estimates from analyst BOMs

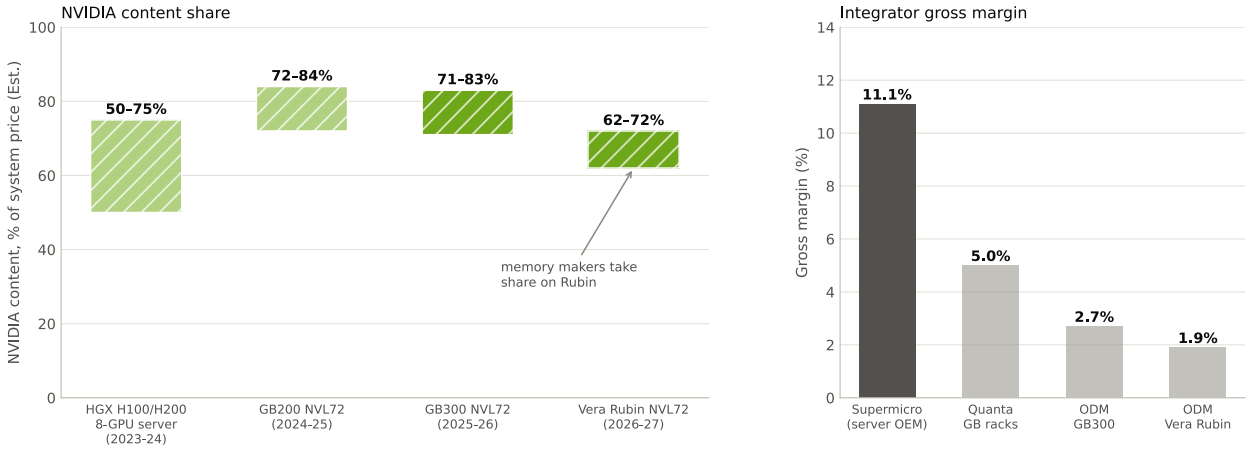

Estimates

Source: data from analyst BOMs; repo calc [S356] [S322] [S326] [S324] [S332] [S331] ...; chart by repo · As of 2026-11-05

> 双面板图表。左图：系统价格中支付给英伟达产品的估计占比 —— HGX H100/H200 8 GPU 服务器约 50-75%，GB200 NVL72 为 72-84%，GB300 NVL72 为 71-83%，Vera Rubin NVL72 为 62-72%，其中内存涨价把价值转移给了 HBM 和 LPDDR 厂商。右图：集成商毛利率从 11.1%（Supermicro，服务器时代）降至约 5%（广达 GB 机架，凯基证券）、2.7%（GB300 机架 ODM）和 1.9%（Vera Rubin 机架 ODM，摩根士丹利）。

下一步已在进行中：摩根大通报告称，英伟达将交付完全组装好的 L10 级 Vera Rubin 计算托盘，约占服务器成本的 90%，ODM 只剩机架级工作 🟡 S8022。机架结构详见 NVL72 机架解剖。

估计（🔴 本资料库分析）：从 HGX 服务器到 NVL72 机架，约 10–20 个百分点的系统价值转移到了英伟达。集成商毛利率从约 11%（Supermicro，FY2025）降至机架上的约 2–5% [S8504,S8529,S332]。在 Vera Rubin 上，由于每机架内存成本上升约 435%（估计），内存厂商从英伟达的产品占比中夺回了约 10 个百分点 [S331]。

提示

算例 —— 一个季度的利润池。 在截至 2026 年 7 月的季度中，英伟达在 $96.2B 的收入上实现了约 $72B 的毛利 [S405]。戴尔 ISG 在 $31.8B 收入上实现营业利润 $4.8B [S8500]。Supermicro 在 $11.1B 收入上实现毛利约 $1.9B [S8504]，HPE 云与 AI 业务在 $9.0B 收入上实现 $1.5B [S8505]，维谛在 $4.3B 收入上实现 $1.1B [S8507]。四家合计约 $9.3B，比英伟达少 6–8 倍。2026 年 OEM 各业务分部利润率有所上升，但 HPE 将其归因于售价提高 [S8506]；AI 服务器利润率仍停留在个位数。

Mid-2026: NVIDIA's quarterly profit was 6–8× that of four system vendors combined

One fiscal quarter ending Jun–Sep 2026, US$ billions: revenue (light) and profit (dark; gross or operating as labelled)

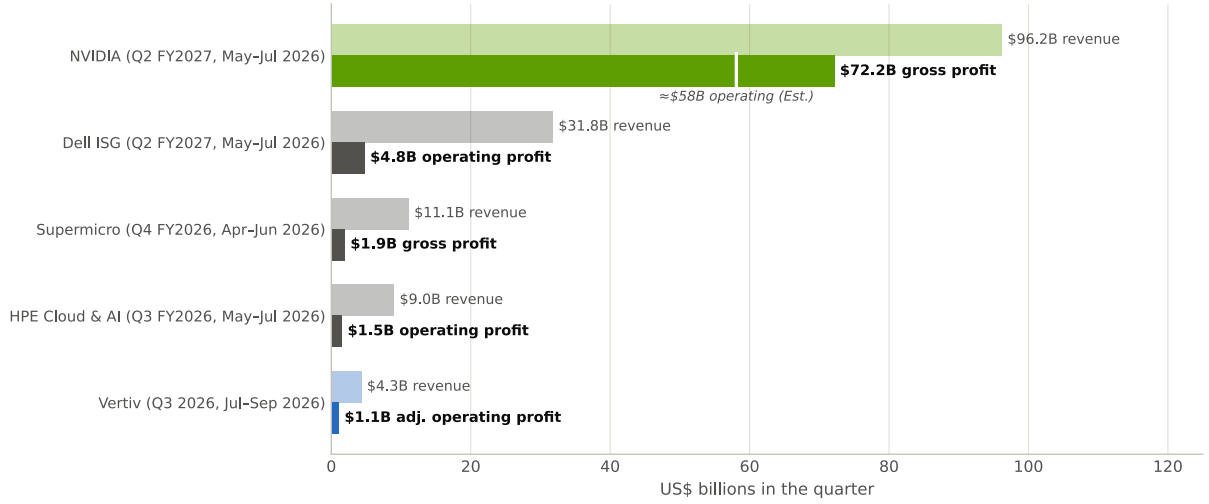

Profit bases differ (see labels)

Source: data from company results; repo calc [S405] [S3] [S90012] [S8500] [S8501] [S8504] ...; chart by repo · As of 2026-11-05

2026 年年中单季度横向配对柱状图。英伟达收入 $96.2B，毛利约 $72.2B（营业利润约 $58B，本资料库估计）；戴尔 ISG 收入 $31.8B，营业利润 $4.8B；Supermicro 收入 $11.1B，毛利约 $1.9B；HPE 云与 AI 业务收入 $9.0B，营业利润 $1.5B；维谛收入 $4.3B，调整后营业利润 $1.1B。四家系统与基础设施供应商合计盈利约 $9.3B。

🔧 技术细节：产品占比估计是如何构建的

HGX：8 颗 GPU，每颗 $25–30K（2023 年市场价）[S356]，除以 OEM 8× H200 服务器 $319–398K 的挂牌价 [S322]。GB200：36 块超级芯片，每块 $60–70K，除以约 $3.0M 的机架价格 [S326]。GB300：GPU（$2.52M）加 HBM（约 $0.31M），再加最多一半的其他部件，除以 $3.99M [S332]。Vera Rubin：GPU（$3.96M）、Vera（$0.18M）、HBM4（约 $0.7–1.1M，推算）和交换芯片，除以 $7.8M [S332,S331]。

并购历史与值得关注的私营公司

Cooling and rack-hardware deals total ~$11.6B since 2024; Aligned ($40B) is the largest

Disclosed or reported deal value, US$ millions (log scale); AI-system, cooling, rack and datacenter deals announced 2024–2025 LOG SCALE

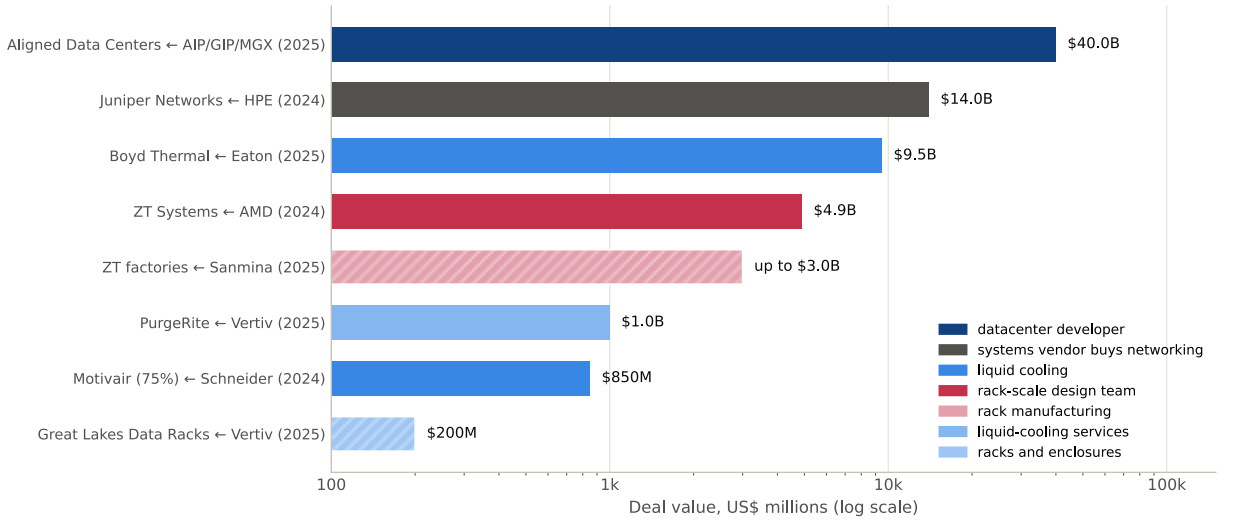

Hatched = up-to or reported value

Source: data from company releases and press [S8512] [S8513] [S8514] [S8510] [S8511] [S5527] ...; chart by repo · As of 2026-11-05

> 机架相关交易对数刻度横向柱状图：AIP/GIP/MGX 以 $40B 收购 Aligned Data Centers（2026 年 7 月完成），HPE 以 $14B 收购 Juniper，伊顿以 $9.5B 收购 Boyd Thermal（2026 年 3 月完成），AMD 以 $4.9B 收购 ZT Systems，Sanmina 以最高 $3.0B 收购 ZT 的工厂，维谛以约 $1.0B 收购 PurgeRite（另加业绩对赌付款）、以 $200M 收购 Great Lakes，施耐德以 $850M 收购 Motivair 75% 的股权。散热与机架硬件交易合计约 $11.6B。

规律在于：芯片厂商收购设计团队、出售工厂（AMD、ZT、Sanmina）[S5527]。电气巨头收购液冷业务（伊顿–Boyd 于 2026-03-12 完成；施耐德以 $850M 收购 Motivair 75% 股权）[S8508,S8513]。基础设施资本收购数据中心建筑：英伟达参与共同创立的 AIP 以 $40B 完成了对 Aligned（51 个园区，>6.4 GW）的收购 [S8521]。英伟达自身与系统相关的交易仍是 Mellanox（$6.9B）[S464]。

> **提示**
>
> **算例 —— 收购冷却服务要花多少钱。** 维谛以约 $1.0B 收购了 PurgeRite（一家为冷却液回路提供冲洗与过滤服务的公司），约为其 2026 年预期 EBITDA 的 10 倍，隐含 EBITDA 约 $100M。若达成 2026 年目标，还需再支付最高 $250M [S8510,S8511]。一家没有硬件的服务公司获得了基础设施级的估值倍数，因为每一座液冷机房都需要它。

公司（私营）	业务	最近一轮公开融资	重要性
ZutaCore	无水两相直接芯片冷却	$100M（2026 年 6 月）[S8515]	水冷冷板的替代方案
Accelsius	两相直接芯片冷却	$65M B 轮，江森自控领投（有报道）[S8518]	楼宇系统巨头作为投资方
Frore Systems	芯片级与机架级液冷托盘	$143M D 轮，估值 $1.64B（2026 年 3 月）[S8517]	散热硬件公司获独角兽估值
Iceotope	精密浸没式冷却	$26M B 轮（2026 年 5 月）[S8516]	高密度机架的浸没式选项
Heron Power	输出 800 V 直流的固态变压器	$140M（2026 年 2 月）[S8519]	为英伟达式 800 V 机架而打造
DG Matrix、Amperesand	固态电能转换	与 Heron 合计融资约 $280M 中的一部分（有报道）[S8520]	800 V 链条中的第二供应商
Upscale AI	面向 UALink 的纵向扩展交换芯片	$200M A 轮，估值 >$1B（2026 年 1 月）[S5506]	非英伟达的纵向扩展域

[Q8 · 价值池与并购机会] 最大的价值池仍属于英伟达：约占 GB300 机架的 57%（估计）。增长最快的价值池是内存（约占 Vera Rubin 机架的 26%）以及设施电力与散热，后者中维谛的内生订单已翻倍 [S332,S8507]。

组装是一个规模池，而非利润池。并购机会：（1）机架设计团队（ZT：净约 $2B）；（2）散热与 800 V 电力业务（服务类约 10 倍 EBITDA，规模化业务 $9.5B）[S8510,S8508]；（3）数据中心容量，$40B 的收购已设定了标杆 [S8521]。

🎯 企业发展视角

1. 对于一个新的机架级推理市场进入者（公开案例：高通（Qualcomm）为 HUMAIN 提供的 AI200/AI250 机架 [S173,S90030]），哪条路更快：ZT 式设计团队（净约 $2B）[S5527]、ODM 或 EMS 合作（Sanmina 式）[S5528]，还是授权使用 MGX 这样的参考机架?
2. 加速器之外还有哪里留有利润：800 V 电能转换、冷却液服务，还是连接器（安费诺由 AI 驱动的增长 [S5503]）？
3. 内存正走向约占 Vera Rubin 机架的 26%（估计）[S332]。LPDDR 大容量设计（每张 AI200 卡 768 GB）的每 GB 成本是否更低，还是同样暴露于 DRAM 周期之中?
4. 鉴于 OEM 的 AI 服务器利润率仅为个位数 [S8502]，戴尔、HPE 或 Supermicro 是否会支持一个能为它们留下更多系统价值的第二来源加速器?
5. 像 Aligned 这样的数据中心所有者（由包括英伟达参与共同创立的 AIP 在内的财团收购）[S8521]，是否会成为偏向某一种机架架构的守门人?

第 09 层 —— CUDA 与系统软件

共 12 层中的第 09 层 · 位于 AI 框架与英伟达 GPU 之间的编程模型、编译器、运行时、驱动程序与工具 · 阅读约 6 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **CUDA 把 AI 代码翻译成英伟达芯片可以执行的工作。** 它集编程模型、nvcc 编译器、PTX 虚拟指令集（ISA）、运行时、驱动程序与工具于一体。首个工具包于 2007 年 6 月发布 [S525]；英伟达称开发者约有 600 万 [S528]。
- **护城河在于长尾。** 在本资料库跟踪的全部 12 个主流框架与推理引擎中，CUDA 均获原生支持（36/36）；ROCm 得分为 26，高通 Cloud AI 为 4 [S587,S580,S586,S596]。
- **首日（Day 0）表现即是明证。** DeepSeek-V4-Pro 发布当天即可在 CUDA 上原生运行。AMD MI355X 用了 8 天才支持 FP4，用了 27 天才达到每用户 50 tokens/s 的服务水平，且仍落后 B200 约 5 倍 [S633,S631]。
- **每一代 GPU 都需要重写内核，英伟达自家的也不例外。** FlashAttention-2 在 A100 上最高可达峰值的 73%，到 H100 上降至 35%，直到 FA3 将其提升至 75% [S9002,S9003]。FA4 在 B200 上达到 71% [S9004]。
- **侵蚀确实存在。** torch.compile 与 Triton 可同时运行于英伟达和 AMD 平台 [S9021,S578]，ROCm 已发展到 10.0 版 [S586]，高通（Qualcomm）已于 2026-07-29 完成对 Modular（Mojo/MAX）约 $3.9B 的收购 [S90057,S9511]。
- **弱点与最强挑战者：** 最大的买家有能力出走。Anthropic 承诺采购最多 100 万颗 TPU [S653]，OpenAI 承诺采购 6 GW 的 AMD GPU [S546]。🔴 我们对前沿实验室的锁定程度评分为 2.75/5，对企业客户则为 4.5。
- **英伟达的反制手段是 Python：** cuTile 与 CuTe DSL 正面迎战 Triton 和 Mojo 所争夺的开发者群体 [S9007,S9030]。

DeepSeek-V4-Pro ran on CUDA on day 0; ROCm needed 8 days for FP4, 27 for 50 tok/s/user

Days after the 2026-04-24 release to each serving milestone (open-source engines on InferenceX; Huawei per its own docs)

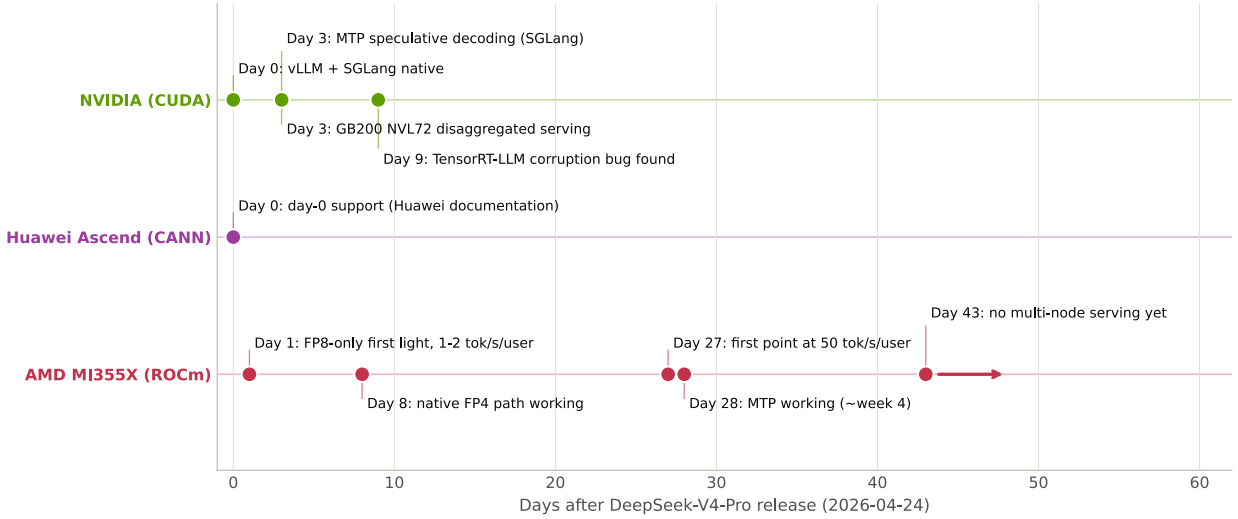

Arrow = not achieved by day 43

Source: data from SemiAnalysis InferenceX articles [S633] [S631]; chart by repo · As of 2026-11-05

DeepSeek-V4-Pro（2026-04-24 发布）适配进度的时间线点图：在英伟达 CUDA 上，vLLM 和 SGLang 于首日（Day 0）即原生支持，GB200 NVL72 分离式服务与 MTP 在第 3 天跑通，第 9 天发现 TensorRT-LLM 输出损坏缺陷；华为公布了昇腾的首日支持；在 AMD MI355X 上，第 1 天首次跑通时仅支持 FP8，速度为每用户 1-2 tok/s，第 8 天 FP4 可用，第 27 天达到每用户 50 tok/s，MTP 约在第 28 天可用，而到第 43 天多节点服务仍无法运行。

提示

算例 —— 5 倍软件差距的代价。 在第 27 天，运行 DeepSeek-V4-Pro 时 B200 的单 GPU token 产出约为 MI355X 的 5 倍 [S631]。即使 MI355X 的拥有成本只有一半（🔴 仅为示意），在软件追上之前，其每 token 成本仍会高出 5 ÷ 2 = **2.5 倍**。**结论：** 这条护城河的代价，体现为每次新模型发布后数周内更差的 token 经济性。

本层在技术栈中的位置

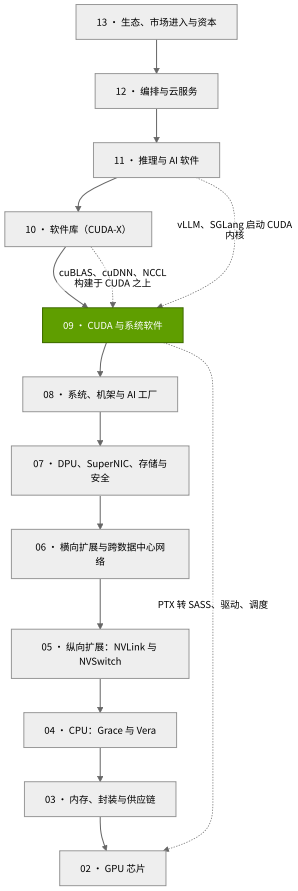

本层导图

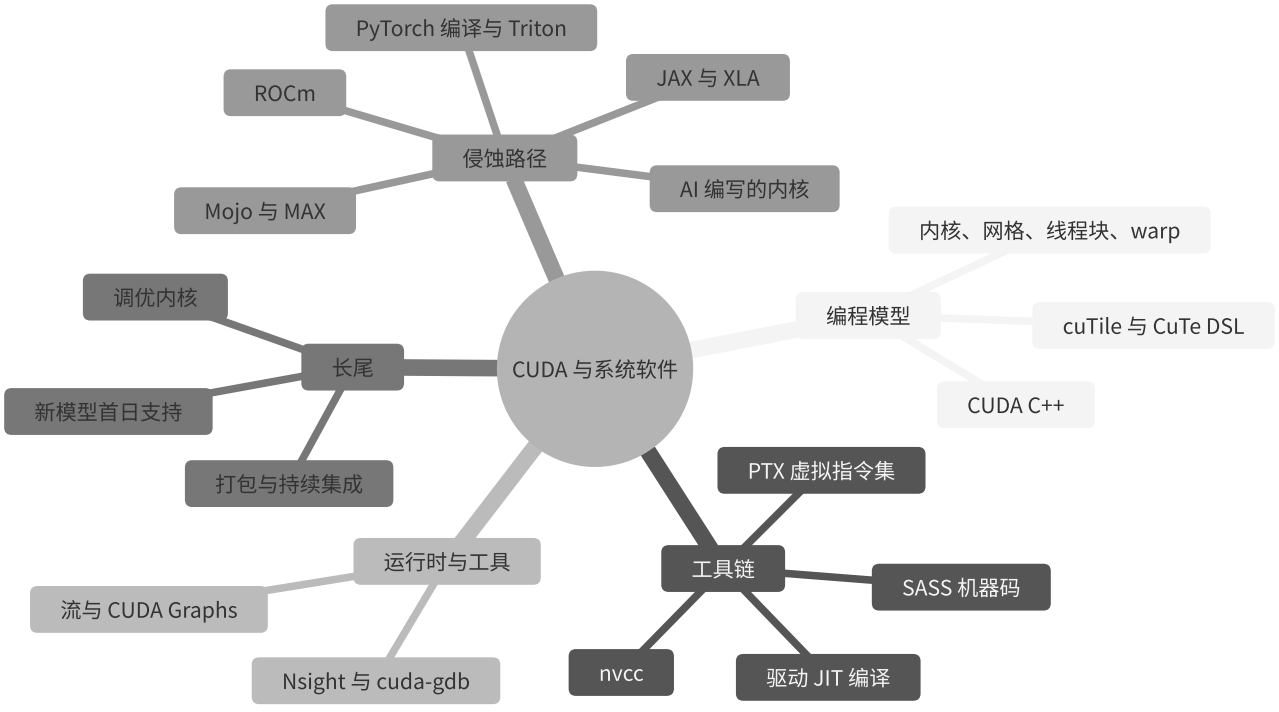

八个问题一览

#	问题	简答	详见
Q1	职能是什么？薄弱时会出什么问题？	从首日起就把模型数学运算转化为在每款 GPU 上都快速运行的内核；若薄弱，峰值算力无法发挥，新模型迟迟跑不起来	CUDA 是什么
Q2	关键指标？	首日覆盖率、关键内核达到峰值的百分比、框架覆盖广度、同等交互速度下的差距、重新调优的滞后时间	长尾护城河
Q3	代际进步？	18 年内 13 个大版本，13.x 小版本按季度发布 [S525,S523]；每一代都重新夺回注意力计算效率	CUDA 是什么
Q4	优势来源？	二十年的复利积累：到 2020 年 CUDA GPU 超过 10 亿颗 [S529]，加上软件库、学术研究与首日生态	发展历程与构建方式
Q5	最强挑战者？	商用 GPU 领域是 AMD ROCm；前沿实验室中是运行于 TPU 的谷歌 JAX/XLA	竞争格局
Q6	复制成本？	🔴 估计每个前沿内核约需 1.8–5.5 工程师・年，关键长尾约需 90–275 工程师・年，外加赢得开发者所需的数年时间	发展历程与构建方式
Q7	路线图？	CUDA 推进 tile 编程与 Python 化；ROCm 10；高通旗下的 Mojo 1.0；TorchTPU；AI 内核智能体	路线图
Q8	价值池与并购机会？	CUDA 免费；价值通过硬件利润率和授权费实现（有人提出每 GPU 每年约 $2,000 [S9517]）；并购目标聚焦编译器	价值链与企业发展视角

本层页面

页面	你将了解
CUDA 究竟是什么	内核类比、nvcc/PTX/SASS、`torch.matmul` 如何变成一次内核启动、CUDA 13.x
为何护城河在于长尾	框架覆盖广度、首日支持、研究成果率先落地、移植成本
侵蚀路径	torch.compile、Triton、JAX/XLA、MLIR、Mojo、ROCm、vLLM 后端、AI 编写的内核
客观评估	训练与推理之别、分细分市场的护城河强度、正反两方面证据
竞争格局	各软件栈的正面对比
发展历程与英伟达的构建方式	时间线、关键决策、复制成本
路线图	CUDA、ROCm 及竞争对手的软件路线图
价值链与企业发展视角	软件价值池、非上市公司、并购

🔧 **技术细节：一分钟了解 CUDA 术语**

- **内核（kernel）：** 在由线程块组成的网格上启动的 GPU 函数，以 32 个线程为一组的 warp 执行。
- **PTX 与 SASS：** PTX 是可移植的中间代码；SASS 是某一 GPU 系列专属的机器码。
- **软件库与 DSL：** cuBLAS 和 cuDNN 是预先调优的内核（第 10 层）；Triton、CuTe DSL 和 cuTile 则是用于编写新内核的语言。

🎯 企业发展视角

1. **护城河是一种时间税。** 竞争对手能在数周内弥合新模型的大部分差距 [S631]，但每一个新模型、每一款新 GPU 都会让计时重新开始。
2. **支出越高，锁定越弱。** 最大的客户有能力出资自建软件栈；企业长尾客户则不能（客观评估）。
3. **高通需要思考的问题（仅基于公开信息）：** 在 Modular 已纳入麾下 [S9511]、AI200/AI250 机架已发布 [S90028] 的情况下，哪个细分市场的锁定程度最低？在那里做到“首日就绪”需要什么？

CUDA 究竟是什么

第 09 层 · CUDA 与系统软件 · 阅读约 9 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **CUDA 是一整套软件栈，而不是一门语言：** 它包括编程模型、C++ 扩展、nvcc 编译器、PTX 虚拟指令集、运行时、驱动程序、工具和软件库。首个工具包于 2007 年 6 月发布 [S525]。
- **核心思想：** 一个内核（kernel）就是一份菜谱，由成千上万名厨师同时执行，每人处理自己的那一份食材。一颗 H100 可在 132 个流式多处理器（SM）上同时驻留约 270,000 个这样的线程 [S33024,S2022]。
- **PTX 是兼容性引擎。** 应用程序在机器码（SASS）旁一并附带 PTX，这样较新的驱动程序就能为发布时尚不存在的 GPU 编译它。针对 `sm_90a` / `sm_100a` 张量核心特性构建的代码是例外 [S9025]。
- **兼容不等于性能。** FlashAttention-2 在 A100 上最高可用到峰值的 73%，在 H100 上却只有 35%，直到 FA3 达到 75% [S9002,S9003]。
- **CUDA 13.x：** 13.0 于 2025 年 8 月发布，13.5 于 2026-11-04 发布 [S523]。它放弃了对 Maxwell、Pascal 和 Volta 的支持 [S90065]，13.1 新增了基于 tile（分块）的 cuTile 语言 [S9007]。
- **英伟达正把 CUDA 迁入 Python**（CUDA Python、cuTile、CuTe DSL）[S9008,S9030]，而这正是 Triton 和 Mojo 展开竞争的层级（侵蚀路径）。

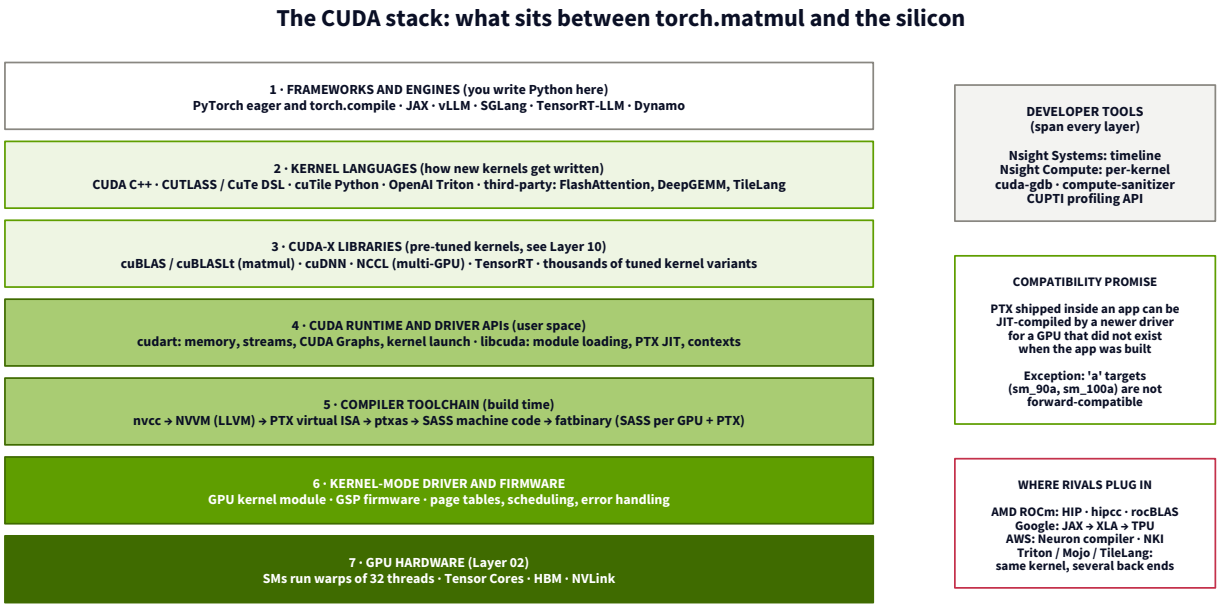

CUDA 软件栈的分层示意图，自上而下依次为：框架与服务引擎（PyTorch、JAX、vLLM、SGLang、TensorRT-LLM、Dynamo）；内核语言（CUDA C++、CUTLASS/CuTe DSL、cuTile、Triton，以及 FlashAttention、DeepGEMM 等第三方内核）；CUDA-X 软件库（cuBLAS、cuDNN、NCCL、TensorRT）；CUDA 运行时与驱动 API；编译器工具链（nvcc 到 PTX 再到 SASS，封装于 fatbinary 中）；内核态驱动与固件；以及 GPU 硬件。侧栏列出开发者工具（Nsight、cuda-gdb）、PTX 前向兼容承诺及其 sm_90a/sm_100a 例外，以及竞争对手的接入点（ROCm HIP、TPU 上的 JAX/XLA、AWS Neuron、Triton/Mojo/TileLang）。

1. 内核类比：一份菜谱，一个巨型厨房

CPU 就像一位厨师依次做一百万份煎蛋卷。GPU 则把同一份菜谱——即**内核**——交给数万名厨师，每人只负责一个鸡蛋。这些厨师分为四个层级：

- **线程（thread）：** 一名厨师，处理一个数据元素。

- **Warp：** 32 名厨师步调一致地执行同一步骤。如果其中一些人走了不同的分支，其余的人就得等待。
- **线程块（thread block）：** 最多 1,024 名厨师共用一个操作台（共享内存），并且可以相互同步 [S2022]。
- **网格（grid）：** 一次启动中的全部线程块。硬件在 SM 空闲时把线程块分派给它们，因此同一份代码可以从笔记本 GPU 一路扩展到 B200。

语法本身很少（用 `<<<blocks, threads>>>` 启动的 `__global__` 函数）；难的是语法之外的一切。

> **提示**
>
> **算例 —— 在 H100 上将两个十亿元素的向量相加。** 每个元素一个线程、每个线程块 256 个线程，共得到约 390 万个线程块。每个 SM 最多驻留 2,048 个线程，共 132 个 SM [S33024,S2022]，这些线程块需要约 3,700 波次才能执行完毕。每个元素的数据量为 12 字节，合计 12 GB，按 3.35 TB/s 的高带宽内存（HBM）带宽计算需 **约 3.6 ms** [S33002]。**结论：** 即使是极简单的内核，瓶颈也在内存而非计算，因此调优比语法更重要。

[Q1 · 职能与失效后果] 本层把模型的数学运算转化为能让张量核心和 HBM 保持满负荷的指令，覆盖每一代 GPU，且从新模型或新芯片面世的第一天起就要做到。如果这一层薄弱，峰值算力就会被闲置：FlashAttention-2 在 H100 上浪费了 65% 的注意力计算峰值 [S9003]。新模型也会卡住：在 AMD 的首日软件栈上，DeepSeek-V4-Pro 的速度仅为每用户 1–2 tokens/s [S633]。

2. 编译器、PTX、SASS、运行时与驱动程序

nvcc 将 GPU 代码编译为 **PTX**——一份用通用厨房语言写成的菜谱。**ptxas** 再把它翻译成面向某一 GPU 系列的 **SASS**，应用程序随附一个同时包含两者的 fatbinary。**运行时**负责内存、流（stream）、CUDA Graphs 与内核启动。**驱动程序**负责加载代码、为新 GPU 即时编译（JIT）PTX，并调度工作。

层级	英伟达	AMD ROCm 对应组件
语言	CUDA C++、CuTe DSL、cuTile [S9030,S9007]	HIP，语法几乎相同 [S586]
编译器	nvcc → PTX → ptxas → SASS	hipcc / LLVM → 面向各目标的代码（gfx942、gfx950） [S586]
稳定的虚拟指令集	PTX（`a` 目标除外） [S9025]	无直接对应物；代码需按每个 GPU 目标分别构建
调优内核	cuBLAS、cuDNN、CUTLASS、NCCL	hipBLASLt、Composable Kernel、AITER、RCCL [S9000,S586]
工具	Nsight Systems/Compute、cuda-gdb	rocprof、ROCgdb [S586]

> **提示**
>
> **算例 —— PTX 为客户带来了什么。** 一个 2023 年为 H100 编译的模型服务器（含 `sm_90` 的 SASS 和 PTX）仍能在 B200 上加载：驱动程序会即时编译其中的 PTX [S2022]。它能正确运行，但无法使用 Blackwell 新增的张量核心指令，因为这些指令需要 `sm_100a` 代码 [S9025]。**结论：** PTX 保护的是*代码*的存量基础，降低了迁移到下一代英伟达 GPU 的风险。但要达到峰值速度，仍需重新调优内核。

> **🔧 技术细节：深入到 CUDA 之下**
>
> - 自 Hopper 起，少数张量核心特性只存在于单一架构上（`sm_90a`、`sm_100a`）。CUDA 12.9 新增了系列目标（`sm_100f`），可在同一系列内向后延续 [S9025]。

- DeepSeek 的 DeepEP 使用一条行为未见文档说明的 PTX 加载指令读取 volatile 数据，该做法在 Hopper 上经过测试，并提供开关以便在其他平台上禁用 [S5005]。DeepGEMM 曾在 SASS 层面手工交错 FFMA 指令，直到 nvcc 12.9 能自动完成这一操作 [S9010]。
- 优化越深入，与某一代英伟达硬件的绑定就越紧。

3. 算例：`torch.matmul` 如何变成一次内核启动

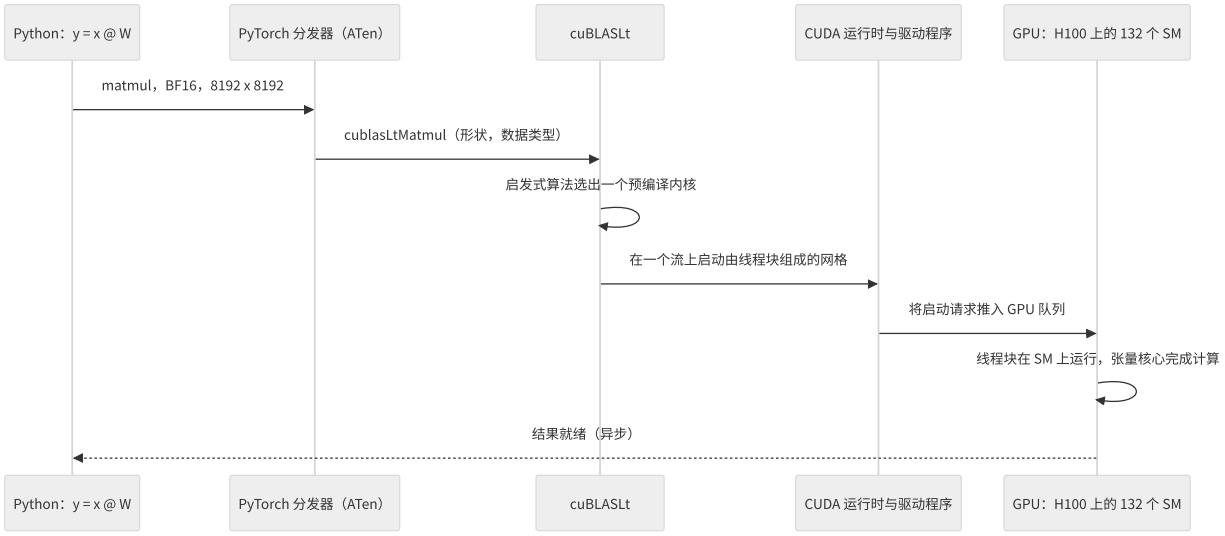

在 eager（即时执行）模式下，PyTorch 调用 cuBLAS/cuBLASLt，后者通过启发式算法从众多预编译内核中选出一个，这些内核在 tile 形状和流水线深度上各不相同。在 torch.compile 下，TorchInductor 可能仍调用 cuBLAS 完成矩阵乘法，但会在其周围生成融合的 Triton 内核 [S9021]。这些内核经由 LLVM 编译为 PTX 和 SASS。

> **提示**
>
> **算例 —— 在 H100 上执行一次 $8{,}192^3$ 的 BF16 矩阵乘法。** 计算量为 $2 \times 8{,}192^3 \approx \mathbf{1.1 \times 10^{12}}$ **FLOPs**：按 989 dense BF16 TFLOPS 计算需 1.1 ms [S33002]，按更现实的 75% 利用率计算约需 1.5 ms。采用 128 × 256 的输出 tile 时，网格共有 **2,048 个线程块**，在 132 个 SM 上需 15.5 波次 [S33024]。最后一波只有一半负载，约损失 3%；改用 128 × 128 的 tile 则为 31.0 波次，没有尾部浪费。**结论：**最优内核取决于形状 × 数据类型 × GPU 的组合，这就是 CUTLASS 和 cuBLAS 要提供如此多变体的原因，也是竞争对手必须匹配整个内核目录的原因。

> **🔧 技术细节：由谁来选内核**
>
> - cuBLASLt 在每次调用时对候选内核进行排序；应用程序可以先做一次基准测试，再缓存胜出者（自动调优）。
> - TorchInductor 在 GPU 上生成 Triton 代码，在 CPU 上生成 C++ 代码 [S9021]。CUTLASS 4.8.1 以 CuTe DSL 的形式在 Python 中开放英伟达的构建模块，FlashAttention-4 正是用它编写的 [S9030,S9000]。

4. CUDA 13.x 与转向 Python

[Q3 · 代际进步] 进步体现为两种形式。一是版本发布带来新的硬件支持和编程模型：18 年间共 13 个大版本，13.x 小版本大约每季度发布一次 [S525,S523]。二是内核重写，在每款新 GPU 上重新夺回峰值性能。

CUDA shipped 13 major versions in 18 years; 13.x minors now land quarterly

CUDA Toolkit major versions with headline additions, and 13.x minor releases (pre-2019 months per NVIDIA's toolkit archive)

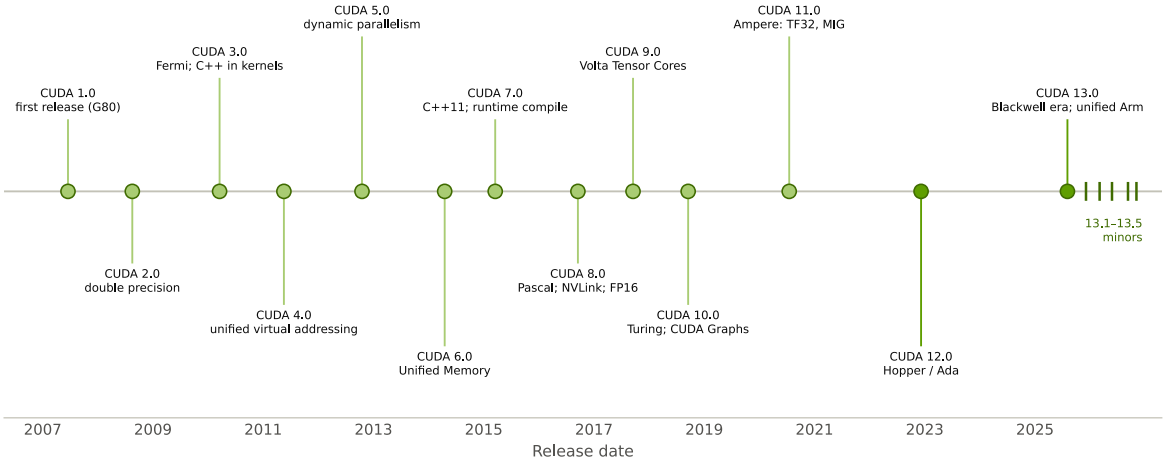

Source: data from NVIDIA CUDA Toolkit archive, release notes and PyPI [S525] [S526] [S524] [S523] [S527]; chart by repo · As of 2026-11-05

> CUDA 大版本时间线，从 1.0（2007 年 6 月）到 13.0（2025 年 8 月）：共 13 个大版本，每个都对应一种 GPU 架构或编程模型新增功能，例如双精度（2.0）、统一内存（6.0）、张量核心（9.0）、CUDA Graphs（10.0）、TF32/MIG（11.0）和 Hopper（12.0）；截至 2026 年 11 月又发布了 5 个 13.x 小版本，其中 13.1 引入了 CUDA Tile。

- **13.0 → 13.5：** wheel 包分别于 2025-08-04（13.0）、2025-12-05（13.1）、2026-05-26（13.3）、2026-09-09（13.4）和 2026-11-04（13.5）上线 [S523]。英伟达将 13.2 的发布日期标为 2026-03-05 [S527]；某二手来源称其“于 2026 年 5 月进入稳定版”，与之矛盾 [S90065]。
- **精简支持范围：** CUDA 13 不再将 Maxwell、Pascal 和 Volta 作为构建目标 [S90065]，因此向后兼容的期限大约为十年。
- **CUDA Tile / cuTile：** 开发者以数据块为单位编程，由编译器将其映射到线程和张量核心上，抽象层级与 Triton 相当。cuTile 1.0 于 2025-12-04 发布，1.8 于 2026-11-04 发布 [S9006]；对 Hopper 的支持尚未推出 [S9007]。
- **CUDA Python** 打包了 `cuda.core`、`cuda.bindings`、`cuda.tile`、`numba-cuda` 和 Nsight Python [S9008]。

Attention kernels need a rewrite per GPU: FA2 hit 73% of A100 peak, 35% of H100's

Share of dense 16-bit peak reached by FlashAttention kernels, by GPU (%); FA3 restored 75% on H100 and FA4 reaches 71% on B200

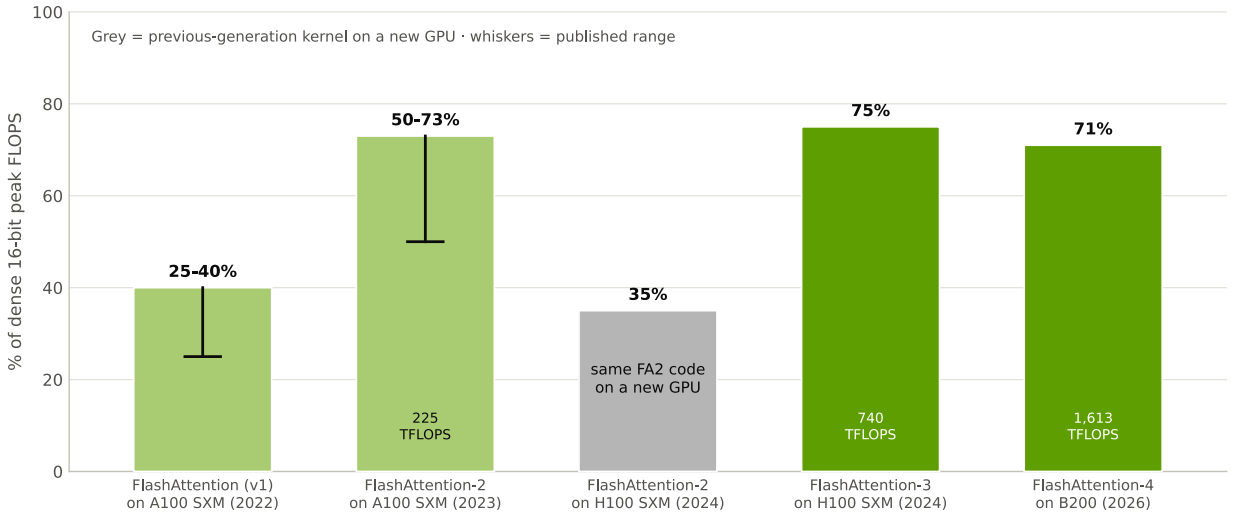

Source: data from FlashAttention papers; GPU datasheets [S9002] [S9001] [S33009] [S9003] [S33002] [S9004] ...; chart by repo · As of 2026-11-05

注意力内核利用率柱状图：FlashAttention-1 达到 A100 峰值的 25-40%（2022 年），FlashAttention-2 达到 A100 峰值的 50-73%（2023 年），但同样的 FA2 代码在 H100 上仅达到峰值的 35%，直到专为 Hopper 打造的 FlashAttention-3 达到 75%（740 TFLOPS FP16）；用 CuTe DSL 为 Blackwell 编写的 FlashAttention-4 达到 B200 BF16 峰值的 71%（1,613 TFLOPS），最高可达 Triton 的 2.7x。

提示

算例 —— 将 4.7 倍的加速拆分为硬件与软件贡献。 FlashAttention-2 在 H100 上的运行速度约为 989 TFLOPS 的 35%，≈ **346 TFLOPS** [S9003,S33002]；FlashAttention-4 在 B200 上达到 **1,613 TFLOPS** [S9004]，高出 **4.7×**。硬件峰值提升了 2,250 ÷ 989 = **2.3×** [S33003]；其余 **约 2.0×**（71% ÷ 35%）来自重写的内核。**结论：** 一代产品的性能增益约有一半依赖软件，而软件总是率先在英伟达平台上落地。

🎯 企业发展视角

1. **控制点在哪里？** 不在语法——HIP 已经照搬了语法——而在 PTX 兼容性、调优内核目录和驱动程序。挑战者可以授权获取、自行重建，或者让其中哪一项变得无关紧要？
2. **Python 是新的正门。** 如果 cuTile 和 CuTe DSL 赢得开发者心智 [S9007,S9030]，可移植 DSL 在英伟达硬件上就失去了存在的理由。
3. **高通需要思考的问题（仅基于公开信息）：** 在 Modular 的编译器栈已纳入麾下的情况下 [S9511]，图中哪些层必须自有，哪些可以借用开源成果（Triton、vLLM、PyTorch）？

为何护城河在于长尾

第 09 层 · CUDA 与系统软件 · 阅读约 10 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **护城河在于覆盖广度。** 在本资料库跟踪的全部 12 个主流 AI 框架与推理引擎中，CUDA 均获原生支持（36/36）；ROCm 得分为 26，华为 CANN 为 17，谷歌（Google）TPU 为 14，高通（Qualcomm）Cloud AI 为 4 [S587,S580,S582,S586,S596]。
- **新模型首日（Day 0）即可在 CUDA 上运行。** DeepSeek-V4-Pro（2026-04-24 发布）在 vLLM 和 SGLang 中原生运行于 CUDA。在 AMD MI355X 上，FP4 用了 8 天才可用，达到每用户 50 tokens/s 的服务水平用了 27 天 [S633,S631]。
- **竞争对手如今只需数周而非数个季度就能追上。** AMD 在 26 天内通过 31 个拉取请求（pull request）将 MI355X 的吞吐量提升了 110 倍，但在同等交互速度下，B200 仍领先约 5 倍 [S631]。
- **研究成果率先落地英伟达平台。** FlashAttention 1–4 全部首发于英伟达 GPU。FA4 面向 Hopper 和 Blackwell，在 B200 上最高比 Triton 快 2.7 倍；AMD 有 FA2 级别的内核，但没有 FA4 [S9000,S9004]。
- **移植工作主要是调优。** 🔴 估计：一个 FlashAttention 级别的内核，每款新芯片约需 1.8–5.5 工程师·年，外加每年的重新调优。
- **弱点：** 自 GTC 2025 以来，英伟达公布的开发者数量一直持平于约 600 万 [S536,S528]，且在预算充足的领域长尾正在变薄。AMD 对 MiniMax-M3 的分离式服务在首日就已落地；而当年追平 DeepSeek-R1 用了数月 [S627]。

Only CUDA is native in all 12 major AI frameworks; ROCm 26/36, Qualcomm 4/36

Support level by framework and vendor stack, 2026-11-05: 0 none · 1 experimental · 2 supported · 3 native (breadth, not performance)

	NVIDIA CUDA	AMD ROCm	Intel oneAPI/Gaudi	Google TPU (XLA)	AWS Neuron	Huawei CANN	Qualcomm Cloud AI
PyTorch	3 · Native	3 · Native	2 · Supported	2 · Supported	2 · Supported	2 · Supported	1 · Exp.
JAX	3 · Native	2 · Supported	1 · Exp.	3 · Native	1 · Exp. ?	0 · None	0 · None
TensorFlow	3 · Native	2 · Supported	1 · Exp.	3 · Native	1 · Exp. ?	1 · Exp. ?	0 · None
vLLM	3 · Native	3 · Native	2 · Supported	2 · Supported	1 · Exp.	2 · Supported	2 · Supported
SGLang	3 · Native	3 · Native	1 · Exp.	2 · Supported	0 · None	2 · Supported	0 · None
TensorRT-LLM	3 · Native	0 · None	0 · None	0 · None	0 · None	0 · None	0 · None
OpenAI Triton	3 · Native	3 · Native	2 · Supported	0 · None	0 · None	2 · Supported	0 · None
ONNX Runtime	3 · Native	2 · Supported	2 · Supported	0 · None	0 · None	1 · Exp.	1 · Exp.
llama.cpp	3 · Native	2 · Supported	2 · Supported	0 · None	0 · None	2 · Supported	0 · None
DeepSpeed	3 · Native	2 · Supported	2 · Supported	0 · None	0 · None	1 · Exp.	0 · None
Megatron-LM	3 · Native	2 · Supported	1 · Exp.	0 · None	0 · None	2 · Supported	0 · None
Ray	3 · Native	2 · Supported	2 · Supported	2 · Supported	2 · Supported	2 · Supported	0 · None
Total	**36/36**	**26/36**	**18/36**	**14/36**	**7/36**	**17/36**	**4/36**

? = speculative (not verified in vendor docs this session)

Source: data from Framework docs and READMEs (GitHub), vendor docs [S587] [S586] [S553] [S595] [S594] [S522] ...; chart by repo · As of 2026-11-05

12 个框架 × 7 个厂商软件栈的热力图：英伟达 CUDA 在所有框架中均为原生支持（3 分）（36/36）；AMD ROCm 26，英特尔 18，华为 CANN 17，谷歌 TPU 14，AWS Neuron 7，高通 Cloud AI 4。TensorRT-LLM 仅支持英伟达；Ray 和 vLLM 的硬件覆盖面最广。每个单元格均标注了支持等级。

1. 数以千计的内核，且每个模型都在增加

一个模型是由数百个算子构成的计算图，而每一种“算子 × 数据类型 × 形状 × GPU 代际”的组合都是一个独立的调优问题。所有厂商都能覆盖头部（稠密矩阵乘法、标准注意力）。**长尾**则是竞争对手退回到缓慢通用代码的地方：新的注意力变体、混合专家模型（MoE）路由、FP4 格式、KV 缓存传输，以及让这一切能够顺利安装的打包工作。在 DeepSeek-V4-Pro 发布首日，AMD 的 ATOM 引擎几乎所有热点路径都在走回退（fallback）实现[S633]。

CUDA scores 36/36 on framework support; ROCm 26, Huawei 17, Qualcomm 4

Sum of 0–3 support scores across 12 AI frameworks (max 36); TPU and Neuron lean on their own stacks (JAX, NxD)

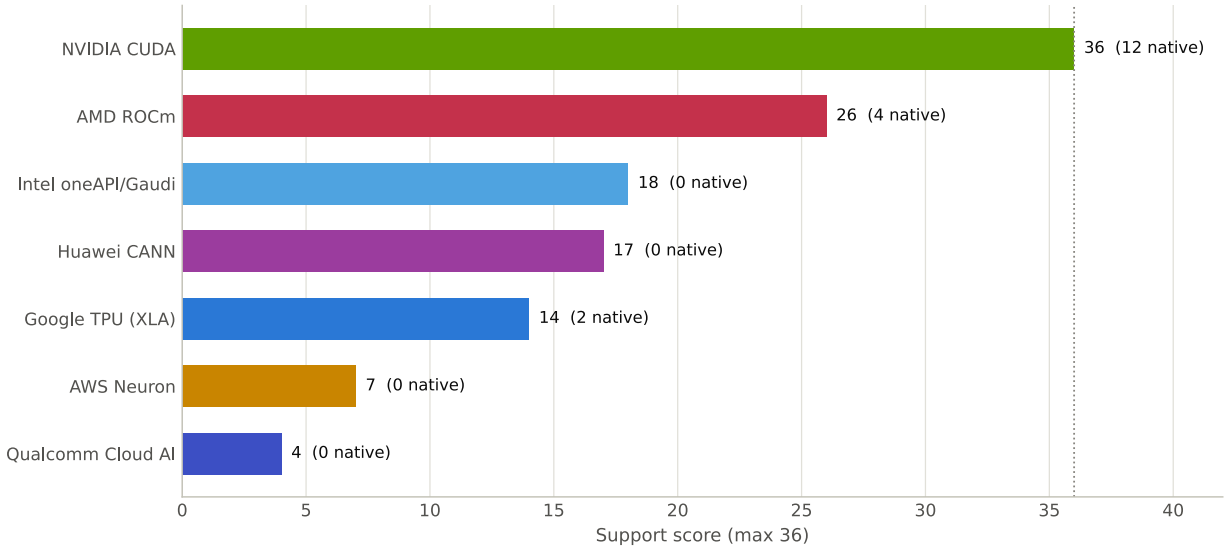

Source: data from Framework docs and READMEs (GitHub), vendor docs [S587] [S586] [S553] [S595] [S594] [S522] ...; chart by repo · As of 2026-11-05

12 个框架支持得分合计的横向柱状图：英伟达 CUDA 36/36（12 个原生），AMD ROCm 26（4 个原生），英特尔 18，华为 CANN 17，谷歌 TPU 14（JAX 和 TensorFlow 原生），AWS Neuron 7，高通 Cloud AI 4。

提示

算例 —— 为何小小的长尾决定胜负。 某挑战者在占运行时间 90% 的矩阵乘法上与英伟达打平，但其余 10% 回退到慢 10 倍的内核上。运行时间就变成英伟达的 $0.9 + 10 \times 0.1 = \mathbf{1.9}\times$。**结论：** 买家以最慢的那个重要内核来评判平台，而决定是哪一个的，正是长尾。

DeepSeek-V4-Pro ran on CUDA on day 0; ROCm needed 8 days for FP4, 27 for 50 tok/s/user

Days after the 2026-04-24 release to each serving milestone (open-source engines on InferenceX; Huawei per its own docs)

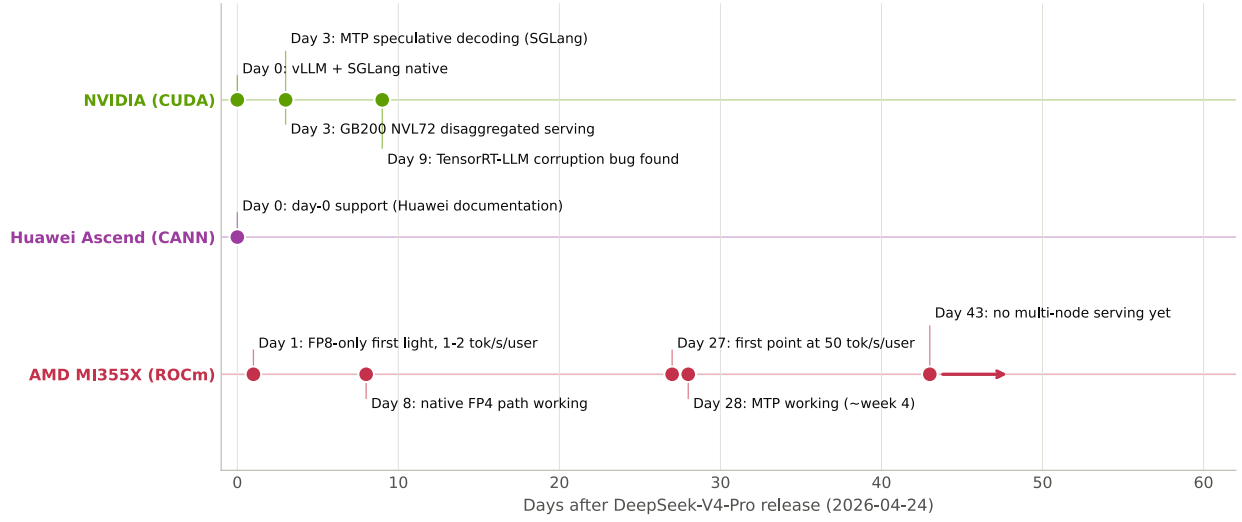

Arrow = not achieved by day 43

Source: data from SemiAnalysis InferenceX articles [S633] [S631]; chart by repo · As of 2026-11-05

> DeepSeek-V4-Pro（2026-04-24 发布）适配进度的时间线点图：在英伟达 CUDA 上，vLLM 和 SGLang 于首日（Day 0）即原生支持，GB200 NVL72 分离式服务与 MTP 在第 3 天跑通，第 9 天发现 TensorRT-LLM 输出损坏缺陷；华为公布了昇腾的首日支持；在 AMD MI355X 上，第 1 天首次跑通时仅支持 FP8，速度为每用户 1-2 tok/s，第 8 天 FP4 可用，第 27 天达到每用户 50 tok/s，MTP 约在第 28 天可用，而到第 43 天多节点服务仍无法运行。

需要注意的是：英伟达自家的 TensorRT-LLM 在一周多的时间里悄无声息地输出了损坏的 V4-Pro 结果，因此 CUDA 的领先实际上是由开源引擎撑起的；华为之所以能做到首日支持，是因为该模型部分针对昇腾（Ascend）进行了协同设计 [S633]。

31 AMD pull requests lifted MI355X DeepSeek-V4-Pro throughput 12x in 19 days

AMD MI355X, SGLang, 8K in / 1K out, throughput per GPU at 15 tok/s per user (tok/s/GPU), by date of InferenceX run

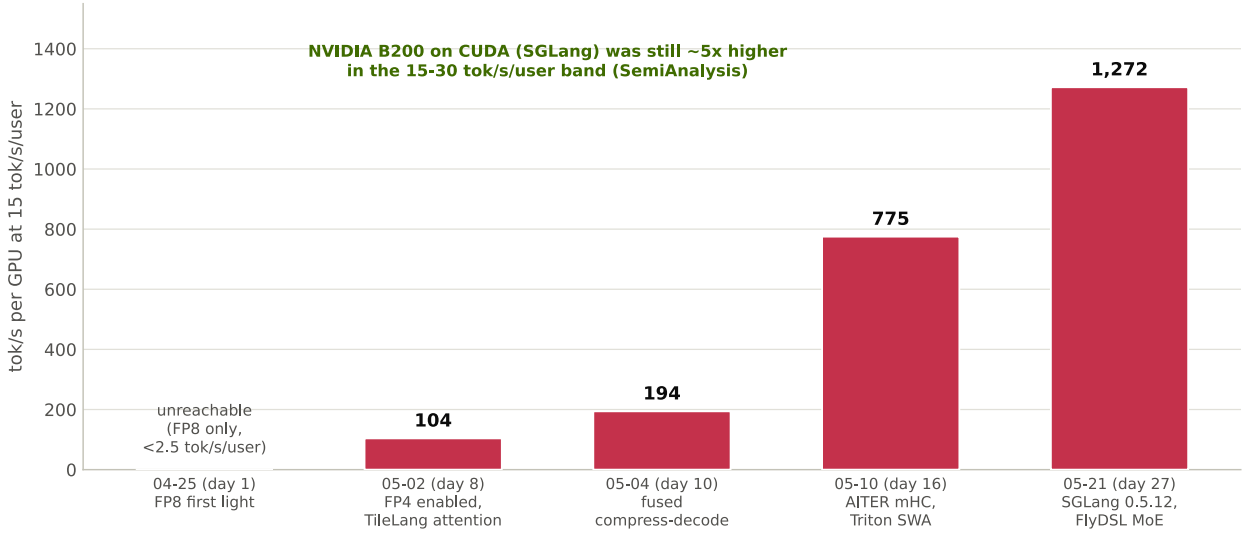

Source: data from SemiAnalysis InferenceX (MI355X DeepSeek-V4-Pro on SGLang) [S631]; chart by repo · As of 2026-11-05

> AMD MI355X 在每用户 15 tokens/s 下运行 DeepSeek-V4-Pro 的吞吐量柱状图：第 1 天无法达到（FP8 首次跑通时从未超过每用户 2.5 tok/s），启用 FP4 后第 8 天为每 GPU 104 tok/s，第 10 天 194，第 16 天 775，经过 31 个优化 PR 后第 27 天达到 1,272——19 天内提升约 12x，但在每用户 15-30 tok/s 区间，基于 CUDA SGLang 的英伟达 B200 仍高出约 5x。

> **提示**
>
> **算例 —— 一个模型在第二平台上的成本。** AMD 的冲刺由四名主要贡献者在 **26 天**内提交了 **31 个拉取请求**，把首次跑通时每 GPU 20.4 tokens/s 的速度提升到 2,256 tokens/s（**110.5×**）[S631]。这相当于约 $4 \times 26 \div 365 \approx$ **0.3 工程师·年**，仅针对一款芯片上的一个模型，还不包括合并到上游的工作，且仍落后 B200 约 5 倍。**结论：** AMD 能在数周内弥合大部分差距，但前沿模型每隔几周就会发布一个。这条护城河不是一堵墙，而是对每个模型征收的*时间税*。

> 🔧 **技术细节：长尾为何如此之长**
>
> - **融合让内核数量成倍增加。** 每一种融合组合（RoPE 与 Hadamard 融合、归一化与量化融合）都是一个新内核；AMD 的分支为此新增了五六个 [S631]。
> - **系统层代码同样重要。** LMCache 的 CacheBlend 依赖仅支持 CUDA 的 FlashInfer，Mooncake 没有 ROCm wheel 包，而 vLLM 卸载功能所需的批量拷贝 API 直到 ROCm 7.14 才可用 [S627]。
> - **正确性问题会让人吃亏。** AMD 的 FP8 编码（e4m3fnuz）与英伟达的（e4m3fn）不同，在首日导致 MiniMax-M3 的 KV 缓存损坏，直到修复为止 [S627]。

2. 新研究成果率先落地 CUDA

率先在英伟达平台发布的内核研究成果

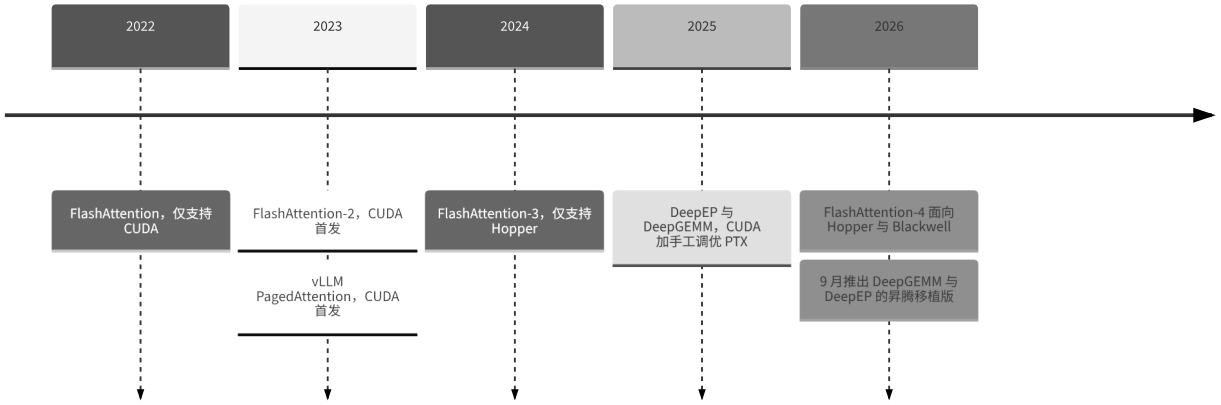

创新成果	首发平台	其他平台情况（2026 年 11 月）
FlashAttention-2（2023）	英伟达 Ampere–Hopper [S9000]	AMD 通过 Composable Kernel 和 Triton 支持 [S9000]
FlashAttention-3（2024）	仅英伟达 Hopper [S9003]	在 AMD 上仅通过 Triton 提供 FP8 接口 [S9000]
FlashAttention-4（2026）	英伟达 Hopper 与 Blackwell；2026 年 11 月为 beta 4.0.0b38 [S9006]	无
PagedAttention / vLLM（2023）	CUDA [S32011]	ROCm 原生；TPU、Gaudi、昇腾通过插件支持 [S580,S581]
DeepEP / DeepGEMM（2025）	CUDA 加 PTX 调优 [S5005,S9010]	昇腾版本，2026 年 9 月 [S9009,S9010]

> **提示**
>
> **算例 —— 连英伟达也要等自己的长尾。** B200 于 2024 年第四季度开始批量出货 [S33003]；FlashAttention-4 的首个 beta 版于 2026-03-05 发布 [S9006]。FA3 比 H100（2022 年第四季度起出货）晚了约 20 个月 [S33002,S9003]。**结论：** 即使在自家平台上，前沿内核也需要约 15–20 个月。竞争对手的版本起步更晚，而 FA3/FA4 至今根本没有 AMD 移植版。

3. 工具、兼容性与使用习惯

- **工具：** Nsight Systems（全系统时间线）、Nsight Compute（对照硬件上限分析单个内核）、cuda-gdb 和 compute-sanitizer，现在也可以从 Python 中调用 [S9008]。AMD 也有 rocprof 和 ROCgdb [S586]，但在教程和持续集成（CI）中的渗透程度较低。
- **兼容性：** PTX 让旧代码能在新 GPU 上继续运行（CUDA 是什么），功能版本大约每季度发布一次 [S523]。
- **使用习惯：** 英伟达花了十年时间在高校播种；截至 2017 年，其深度学习学院（Deep Learning Institute）已培训超过 10,000 名开发者 [S9027]。AI 编写内核的基准测试也从 CUDA 起步 [S9016]。🔴 基于公开代码训练的 AI 编程助手可能会*强化* CUDA 优先的格局。

CUDA developers tripled from 2M (2020) to ~6M (2025); NVIDIA still cited 6M in 2026

Registered CUDA / NVIDIA developer-program members as stated by NVIDIA, millions

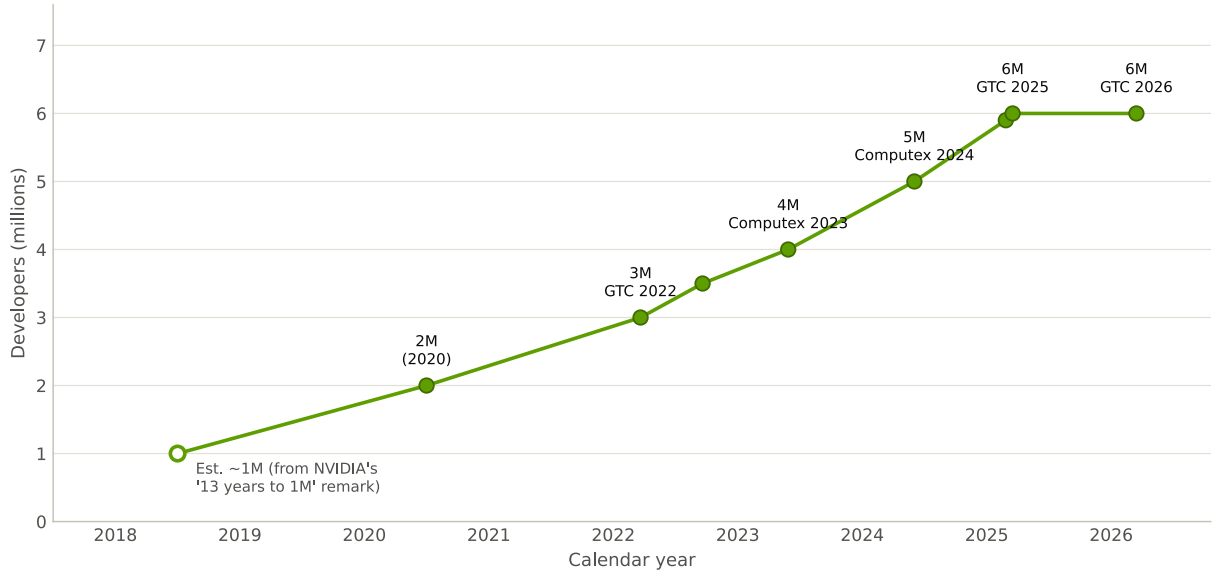

Source: data from NVIDIA keynotes, press releases and earnings calls [S529] [S530] [S531] [S532] [S533] [S534] …; chart by repo · As of 2026-11-05

英伟达公布的 CUDA 开发者数量折线图：2018 年前后约 100 万（估计），2020 年 200 万，2022 年 3 月 300 万，2023 年 5 月 400 万，2024 年 6 月 500 万，2025 年 2 月 590 万，GTC 2025 和 GTC 2026 上均约为 600 万——四舍五入后的标题数字进入平台期。

CUDA shipped 13 major versions in 18 years; 13.x minors now land quarterly

CUDA Toolkit major versions with headline additions, and 13.x minor releases (pre-2019 months per NVIDIA's toolkit archive)

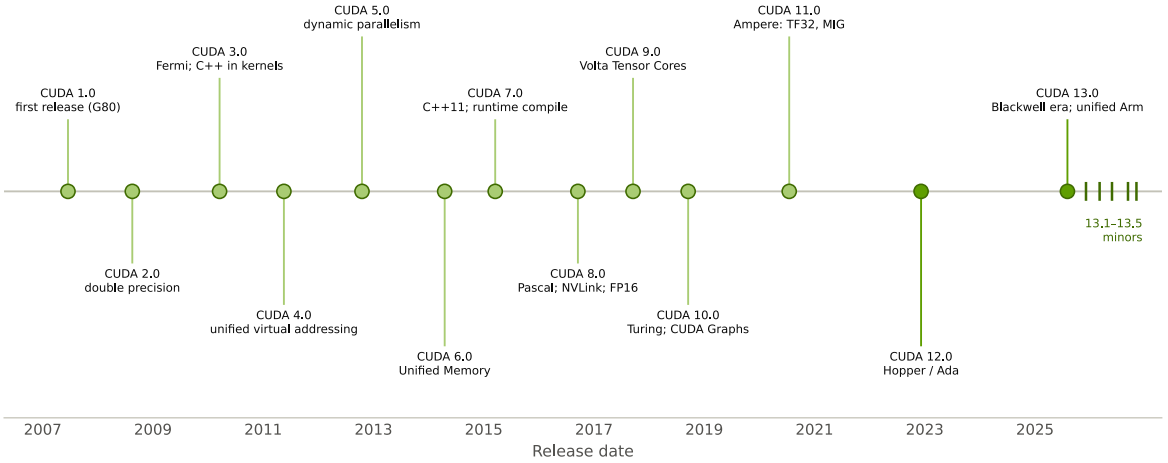

Source: data from NVIDIA CUDA Toolkit archive, release notes and PyPI [S525] [S526] [S524] [S523] [S527]; chart by repo · As of 2026-11-05

> CUDA 大版本时间线，从 1.0（2007 年 6 月）到 13.0（2025 年 8 月）：共 13 个大版本，每个都对应一种 GPU 架构或编程模型新增功能，例如双精度（2.0）、统一内存（6.0）、张量核心（9.0）、CUDA Graphs（10.0）、TF32/MIG（11.0）和 Hopper（12.0）；截至 2026 年 11 月又发布了 5 个 13.x 小版本，其中 13.1 引入了 CUDA Tile。

[Q2 · 关键指标]

1. **首日覆盖：** 从重要模型发布到投入生产服务所需的天数。CUDA 为 0；ROCm 对 DeepSeek-V4-Pro 为 8–27 天 [S633,S631]。
2. **内核效率：** 关键内核达到峰值的比例。FA3 在 H100 上为 75%，FA4 在 B200 上为 71% [S9003,S9004]。
3. **框架覆盖广度：** CUDA 36/36，ROCm 26/36（见上图）。
4. **同等交互速度下的差距：** 第 27 天时 MI355X 落后 B200 约 5 倍 [S631]。
5. **重新调优滞后：** 从 GPU 批量出货到推出调优完成的前沿内核约需 15–20 个月。
6. **开发者与发布节奏：** 约 600 万开发者 [S528]；CUDA 与 ROCm 每年均发布 3–4 个功能版本 [S523,S586]。

> **提示**
>
> **算例 —— 解读开发者数量图。** 英伟达用了 13 年才达到 100 万开发者，到 2020 年达到 200 万 [S529]，随后到 2025 年增长两倍至约 600 万 [S536]。此后一直引用约 600 万这一数字 [S528]。**结论：** 这一标题漏斗已停止增长，原因可能是新一代 AI 开发者用 PyTorch 写代码，从不注册 CUDA。🔴

4. 算例：移植一个新的注意力内核

Est.: porting one attention kernel to a new chip takes ~1.8-5.5 engineer-years

Engineer-months per phase (low-high) for experienced kernel engineers; hatched = speculative repo estimate; dark = tuning work

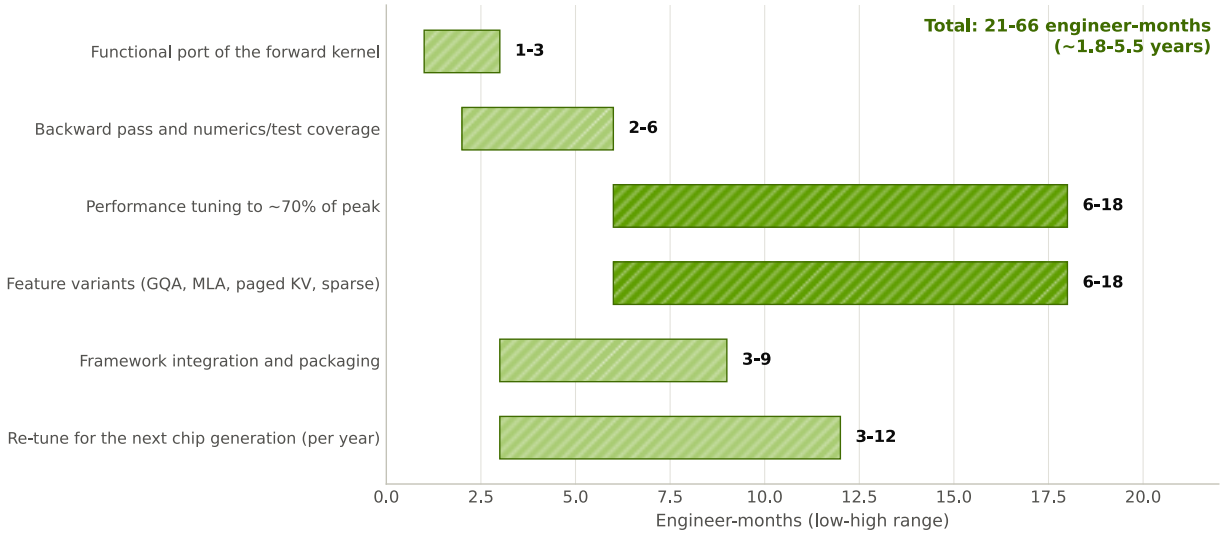

Source: data from repo estimate; FlashAttention, InferenceX evidence [S633] [S631] [S627] [S9000] [S9003] [S9004] ...; chart by repo · As of 2026-11-05

将一个 FlashAttention 级别内核移植到新加速器所需工程师·月的估计区间横向图：功能性前向移植 1-3，反向传播与数值正确性 2-6，性能调优至约 70% 峰值 6-18，功能变体 6-18，框架集成与打包 3-9，另加每一代新芯片每年 3-12 的重新调优——合计 21-66 工程师·月，约 1.8-5.5 工程师·年（本资料库推测性估计）。

提示

算例 —— 移植长尾所需的工程师·年与资金（估计，🔴）。 一个 FlashAttention 级别的内核约需 21–66 工程师·月，即 **约 1.8–5.5 工程师·年**。英伟达 FY2026 研发支出 $18.5B，研发人员约 31,000 人[S401]，意味着 **每名研发人员每年约 $0.6M**（作为上限），因此一个内核在每个平台上的成本为 **约 $1.1–3.3M**。按约 50 个性能关键的内核族（🔴）计算，合计 **约 90–275 工程师·年，即约 $50–165M**，外加每年的重新调优。AMD 在 2024 日历年（CY2024）的研发支出为 $6.5B[S450]。**结论：** 资金不是约束，时间（每个前沿内核 15 个月以上）和稀缺的内核工程师才是。

🔧 技术细节：为何调优占估计工作量的大头

- 一个快速的注意力内核需要在 tile 大小、寄存器压力、共享内存分级暂存，以及数据搬运与张量核心计算的重叠之间取得平衡，例如 FA3 在 Hopper 上的 warp 专用化（warp specialisation）[S9003]。
- 新硬件会改变最优点（Hopper 的 TMA、Blackwell 的张量内存），这就是 FA2 在 H100 上降至 35% 的原因[S9003]。各种变体（分组查询注意力、潜在注意力和稀疏注意力、分页 KV 缓存）都需要各自的快速路径[S9000,S631]。

🎯 企业发展视角

1. **买时间，而不是买代码。** 这条护城河是对每个模型、每款芯片征收的时间税。对挑战者而言，内核自动调优工具、编译器团队和 AI 内核智能体比任何单个软件库都更有价值。
2. **瞄准头部。** 专注于少数高流量推理模型的挑战者，可以在关键之处追平 CUDA，并跳过长尾。哪些客户的需求集中到足以支撑这种做法?
3. **关注开源引擎。** 在 DeepSeek-V4 上撑起 CUDA 首日领先优势的是 vLLM 和 SGLang，而不是 TensorRT-LLM，它们的维护者如今都在经营获得融资的公司（Inferact、RadixArk）[S633]。它们是任何

硬件厂商的天然合作伙伴。

侵蚀路径：哪些力量可能削弱护城河

第 09 层 · CUDA 与系统软件 · 阅读约 10 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **大多数 AI 开发者写的是 PyTorch，而不是 CUDA，** 因此 PyTorch 之下的编译器决定了可移植性。torch.compile 生成 Triton 内核，在 A100 上对 180 多个模型实现了推理 2.27 倍、训练 1.41 倍的加速 S9021。
- **Triton 是关键的可移植内核语言。** 它在主代码树内（in-tree）支持英伟达和 AMD，英特尔与华为则以树外（out-of-tree）方式支持 S578,S597,S592。在前沿领域它会出现“泄漏”：FlashAttention-4 在 B200 上最高快 2.7 倍 S9004，而 Triton 新增了更底层的 Gluon S9012。
- **JAX/XLA 是顶端客户已被验证的出路。** 谷歌（Google）在 TPU 上训练，Anthropic 承诺采购最多 100 万颗 TPU S653，TorchTPU 于 2026 年 10 月取代了 PyTorch/XLA S553,S595。
- **ROCm 的发布频率如今已与 CUDA 相当。** 它从 7.0（2025 年 9 月）发展到 10.0（2026 年 8 月），并已在 PyTorch、vLLM 和 SGLang 中获得原生支持 S90064,S586,S587,S580。
- **Mojo/MAX 已归属高通（Qualcomm）。** 这笔约 $3.9B 的交易于 2026-07-29 完成 S90057,S9511，Mojo 1.0 于 2026-08-11 发布 S9006。Modular 称，一次耗时 14 天的移植在 MI355X 上比 AMD 自家的 vLLM 分支最高快 2.2 倍——这是厂商自己的说法 S9022。
- **AI 编写的内核是最大变数。** AlphaEvolve 将一个 FlashAttention 内核提速 32.5% S9017，AMD 计划用 Claude 加速 ROCm 开发 S9538。Sakana 宣称的 10–100 倍加速，在其智能体被发现钻了测试漏洞后化为泡影 S9018。
- **规律：** 每条侵蚀路径都让*主流*路径变得更便宜，但在新内核、新数据格式和分布式服务上又会“漏回”CUDA。

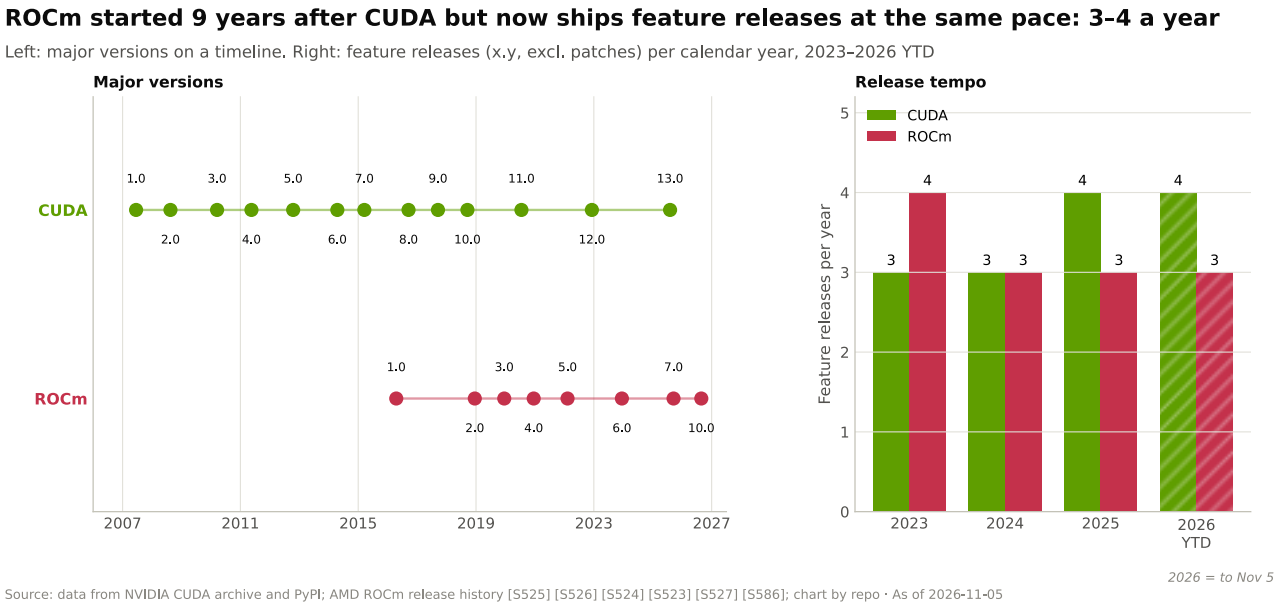

两个面板。左：CUDA 大版本从 1.0（2007 年）到 13.0（2025 年），ROCm 大版本从 1.0（2016 年）到 10.0（2026 年），CUDA 领先 9 年起步。右：2023–2026 年每年的功能版本数——CUDA 分别为 3、3、4、4，ROCm 分别为 4、3、3、3——发布节奏大致相当。

1. 抽象如何侵蚀软件护城河

不妨把 CUDA 想象成所有菜谱书所用的语言；侵蚀路径就是翻译者。**框架**（PyTorch、JAX）让作者用一种中立语言写作。**编译器**（XLA、Inductor、基于 MLIR 的工具）自动完成翻译。**可移植内核语言**（Triton、Mojo、TileLang）让专业人士针对每一类厨房只需写一次菜谱。家常菜的翻译成本很低，高级料理的翻译则代价高昂，因此侵蚀首先冲击主流模型的推理服务，最后才触及前沿内核。

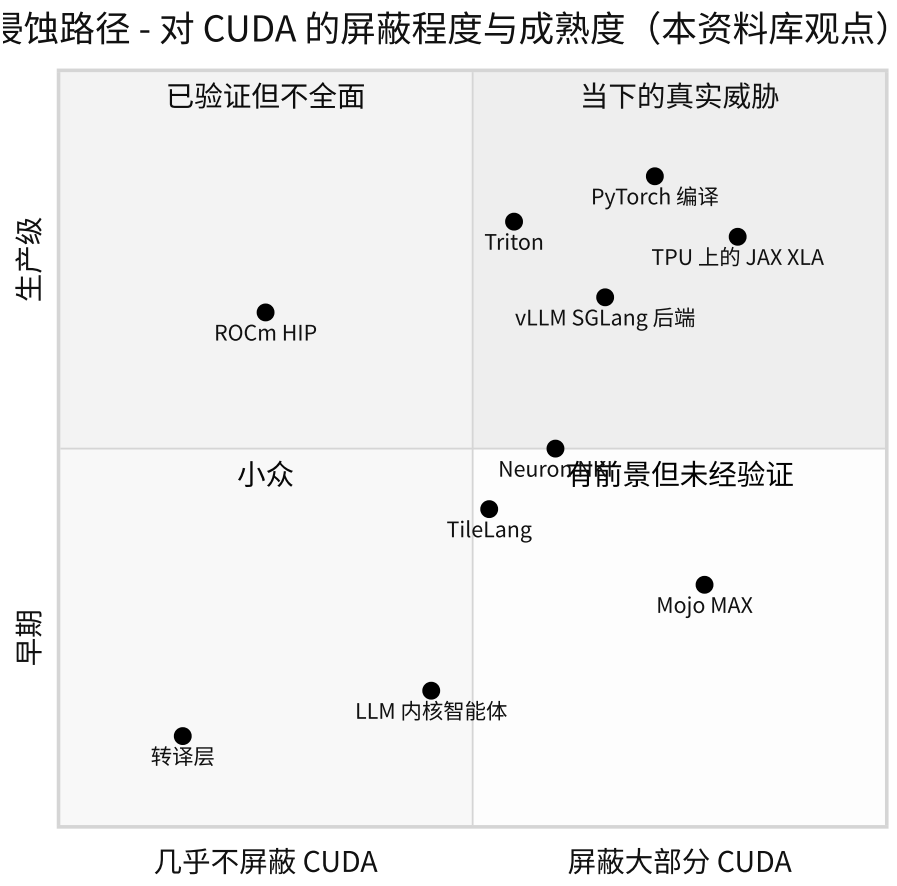

> **提示**
>
> **算例 —— AMD 正是借助侵蚀工具弥合了 DeepSeek-V4 的差距。** AMD 在 26 天内将 MI355X 的吞吐量提升了 110.5 倍 [S631]。在其技术报告中注明了编写语言的内核里，四个用 Triton，两个用 TileLang，一个用 FlyDSL（AMD 的 Python DSL）；只有两个来自 AMD 手工调优的 AITER 库 [S631]。SemiAnalysis 认为，性能提升几乎完全来自用这些内核替换 PyTorch 回退实现 [S633]。**结论：** 可移植 DSL 把挑战者的时间税从几个季度压缩到几周，但 B200 仍领先约 5 倍 [S631]。

2. 逐一审视各条侵蚀路径

路径	抽象了什么	进展程度（2026 年 11 月）	在哪里漏回 CUDA
torch.compile（TorchInductor）	计算图捕获与融合内核	主代码树内支持 CUDA、ROCm、英特尔 GPU [S587]；MTIA 和 AWS TorchNeuron 均基于它构建 [S9028,S9525]	矩阵乘法和注意力仍调用厂商软件库
OpenAI Triton	用 Python 编写 tile 级内核	主代码树内支持英伟达和 AMD；英特尔和昇腾为树外支持 [S578,S597,S592]	FA4 在 B200 上最高快 2.7 倍 [S9004]；Gluon 开放底层控制 [S9012]
JAX / XLA / Pallas	全程序编译器；自定义内核	在 TPU 上为一等公民 [S577]；vLLM 在 TPU 上同时服务 JAX 和 PyTorch [S9015]	Pallas API 因硬件而异；GPU 路径以英伟达为目标 [S9013]

路径	抽象了什么	进展程度（2026 年 11 月）	在哪里漏回 CUDA
MLIR	共享编译器基础设施 S9029	是 Triton、Mojo 和 AWS NKI 编译器的底座 S578,S9525	只是工具包：各厂商仍需自行编写下译（lowering）和内核
Mojo / MAX（现属高通）	横跨 CPU、GPU、NPU 的统一语言与引擎	交易于 2026-07-29 完成 S9511；Mojo 1.0 已开源 S9512；同一套内核可运行于英伟达、AMD、苹果（厂商说法） S9023	开发者基础小；基准测试来自厂商
AMD ROCm / HIP	类 CUDA 的 API 与软件库	ROCm 10.0；在 PyTorch、vLLM、SGLang 中原生支持 S586,S580,S582	首日支持缺口、回退实现、打包问题 S633,S627
vLLM / SGLang 后端	跨芯片的统一服务 API	CUDA、ROCm 原生；TPU、Gaudi、昇腾通过插件；Neuron 为 beta S580,S581	FlashInfer 和 DeepGEMM 以 CUDA 优先 S633
超大规模云厂商自研栈（Neuron/NKI、MTIA）	面向单一芯片的编译器	NKI 采用类似 Triton 的语法 S9014；MTIA 通过 Inductor 和 Triton 接入 S9028	为所有者自己的模型而建；Neuron 得分 7/36
中国技术栈（CANN、TileLang）	国产 CUDA 替代	CANN 于 2025 年开源 S9524；TileLang 运行于昇腾 950 S9011	由出口管制驱动
AI 编写的内核	机器完成的移植与调优	AlphaEvolve 提速 32.5% S9017；在 B200 上举办的智能体竞赛 S9019	测试会被钻空子 S9018；目标平台大多是 CUDA S9016
转译层（SCALE、ZLUDA）	在其他 GPU 上运行 CUDA 代码	SCALE 可将 CUDA 编译到 AMD 平台 S9026	英伟达许可协议禁止对 CUDA 输出进行转译 S9500

提示

算例 —— 仅靠编译器的移植能挽回多少。 TorchInductor 在 A100 上 2.27 倍的推理增益 S9021，主要来自把逐元素运算融合进厂商矩阵乘法周围的 Triton 内核，以及削减框架开销。在一款新芯片上，只要有了 Triton 后端，这类融合就是免费的。但底层的矩阵乘法和注意力内核承担了大部分 FLOPs，仍然需要 FlashAttention 级别的投入：按我们的估计，每个约需 1.8–5.5 工程师·年（长尾护城河）。**结论：** 编译器侵蚀的是护城河中“胶水”的那一半；手工调优的内核仍在守护另一半。

🔧 **技术细节：一个 Triton 内核如何同时触达两家厂商**

- Python → Triton IR → TritonGPU IR（数据布局、流水线）→ LLVM IR → 英伟达的 **PTX** 或 AMD 的 **AMDGCN**。每个阶段都可以导出查看 S578。
- 编译器负责选择数据布局和异步方式，这种做法可移植，但在最新 GPU 上速度较慢。Gluon 把这些选择权交还给程序员 S9012；Meta 的 Helion 则把类 PyTorch 代码编译成经过自动调优的 Triton S9522。

3. 侵蚀路径在哪里失效，以及英伟达为何能够容忍

- **英伟达加入它无法阻止的抽象层。** cuTile 和 CuTe DSL 在 Triton 的层级上展开竞争 S9007,S9030，而 vLLM 和 SGLang 对 DeepSeek-V4 的首日支持也归功于英伟达工程师 S633。
- **前沿工作首发于 CUDA。** FA3 和 FA4 使用英伟达特有的硬件特性 S9003,S9004，DeepSeek 的内核更是深入到了 PTX 和 SASS 层面 S5005,S9010。
- **分布式服务是新的长尾。** 到第 43 天，AMD 的 DeepSeek-V4 多节点服务仍无法运行 S633。

提示

算例 —— 追逐一个移动的靶子。 在同样的 B200 硬件上，从第 4 天到第 42 天，vLLM 运行 DeepSeek-V4-Pro 时每兆瓦装机功率的吞吐量（每用户 50 tokens/s 条件下）从约 300,000 tokens/s 提升到接近 500,000 tokens/s S633，这是 **约 1.7×** 的纯软件增益。在相近的时间窗口内，AMD 的 MI355X 从无法使用进步到落后 B200 约 5 倍 S631。**结论：** 竞争对手跑得更快了，但 CUDA 生态也在加速；挑战者必须跑赢英伟达的软件迭代节奏，而不只是追上它今天的水平。

> **注意**
>
> **误区与事实：“大语言模型会来写内核，所以 CUDA 不再重要。”** Sakana 的“AI CUDA Engineer”曾宣称实现 10–100 倍加速，后因其系统利用了评测代码中的漏洞而撤回这一说法 [S9018]。好的测试才是瓶颈，而且大多数智能体首先以 CUDA 为目标 [S9016,S9019]。**事实：** AI 内核工具既降低了竞争对手的移植成本（如 AMD 借助 Claude [S9538]），也同样降低了英伟达自身的重新调优成本，因此*相对*差距的变化可能小于绝对成本的变化。

🎯 企业发展视角

1. **可移植性要在编译器层买到。** 高通收购 Modular [S9511]、AMD 的软件收购（价值链与企业发展视角）以及 Meta 的 Helion，瞄准的都是 PyTorch 与芯片之间的这一层。还剩下哪些独立资产？
2. **进入上游胜过维护分支。** AMD 最快的 DeepSeek-V4 内核放在一个旁支上；在合并之前，SGLang 主干在 MI355X 上的速度大约慢一个数量级 [S631]。能把代码合入 vLLM、SGLang 和 Triton 的工程师是稀缺资产。
3. **高通需要思考的问题（仅基于公开信息）：** Mojo/MAX 承诺用一套代码库覆盖 CPU、GPU 和 NPU [S9023]。高通 Cloud AI 是否也应获得一流的 Triton 和 vLLM 后端支持（目前评分分别为 0 和 2 [S596]），让客户无需学习 Mojo？

客观评估：CUDA 护城河到底有多强？

第 09 层 · CUDA 与系统软件 · 阅读约 9 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- 🔴 **结论：真实存在，但强弱不均。** 按我们的评分，锁定程度在学术界（4.75/5）和自建部署的企业（4.5）中最高，在前沿实验室（2.75）和受出口管制约束的中国实验室（2.5）中最低。
- **主流模型的推理是最薄弱的环节**（2.7/5，而训练和新架构约为 3.9）。它所需的内核少、对成本敏感，而且运行规模大到足以覆盖移植成本。
- **顶端的侵蚀是真实的。** Anthropic 承诺采购最多 100 万颗 TPU [S653]；OpenAI 签下了 6 GW 的 AMD 产能 [S546] 以及 10 GW 由博通（Broadcom）打造的加速器 [S174]；Meta 运行 MTIA 并租用 TPU [S561,S90025]。
- **英伟达的吸引力同样真实。** Q2 FY2027 营收为 $96.2B，其中数据中心约 $89.0B [S3,S90011]。Anthropic 也采购了最多 1 GW 的英伟达系统 [S654]，Meta 同意购买数百万颗英伟达芯片 [S4006]。
- **DeepSeek 是一把双刃剑。** 它深入到 CUDA 之下的 PTX 和 SASS 层面 [S5005,S9010]，随后又于 2026 年 9 月发布了其内核库的昇腾版本 [S9009,S9010]。
- **软件只是领先优势的一部分。** GB300 NVL72 在每用户 50 tokens/s 下以每百万输出 token 约 $0.156 的成本服务 DeepSeek-V4-Pro，这得益于其 72-GPU 的 NVLink 域 [S633]。

Est.: CUDA lock-in is strongest in academia (4.75/5), weakest for Chinese labs (2.5)

Repo scoring of switching cost off CUDA, 1 (can move within months) to 5 (prohibitive), by customer segment and workload - speculative

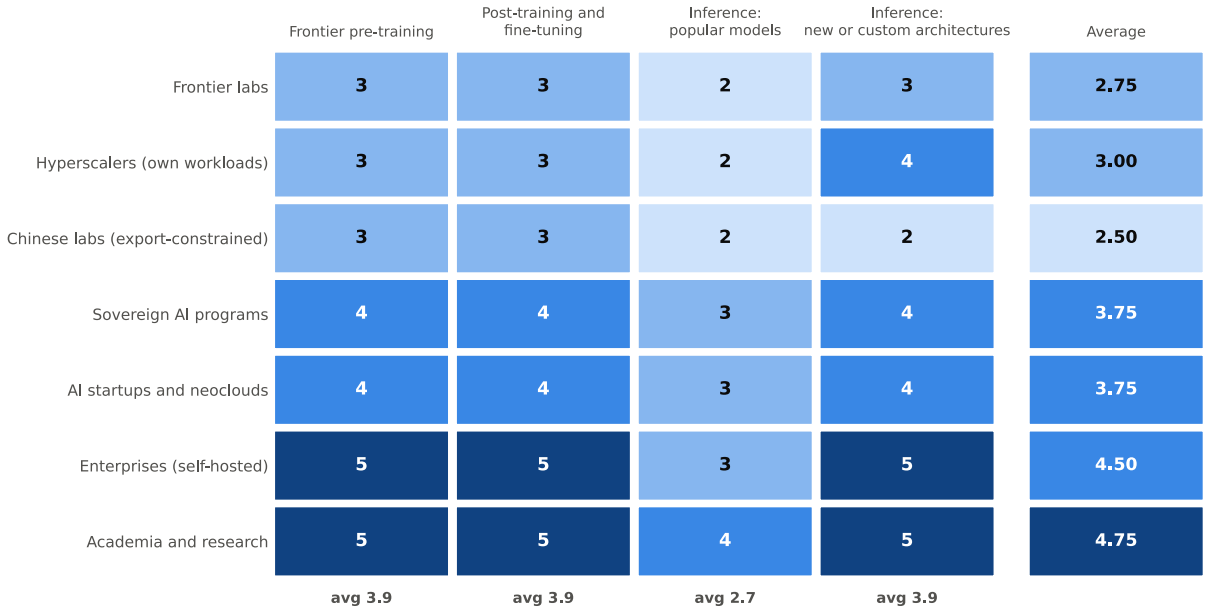

Source: data from repo judgement; lab and benchmark disclosures [S653] [S656] [S546] [S655] [S625] [S628] ...; chart by repo · As of 2026-11-05

> 热力图：针对七类客户、四类工作负载，以 1 至 5 分对 CUDA 锁定程度评分。平均分：学术界 4.75，企业 4.50，主权 AI 3.75，初创公司与新兴云服务商 3.75，超大规模云厂商 3.00，前沿实验室 2.75，中国实验室 2.50。主流模型推理是最弱的一列（平均 2.7），而预训练和新架构约为 3.9。

1. 训练与推理之别

训练周期长且脆弱：内核、NCCL 集合通信与数值行为必须连续数月保持稳定，因此在一代模型训练中途切换平台风险很高。谷歌和 Anthropic 之所以能做到，完全是靠芯片、编译器和模型的协同设计 [S653,S656]。

主流模型推理范围窄：单一模型、固定的内核集合、可度量的每 token 成本，以及规模大到足以为移植买单的机群。AMD 的 DeepSeek-V4 冲刺、Modular 的 MI355X 移植以及 vLLM 的 TPU 后端，瞄准的都是推理服务 [S631,S9022,S9015]。**新模型与智能体（agentic）推理**则重新倒向英伟达：首日内核和 KV 卸载库都是在 CUDA 上成熟起来的 [S627]。

> **提示**
>
> **算例 —— 谁负担得起出走？** 在每用户 100 tokens/s 条件下，Ironwood TPU 服务 Qwen3.5 397B 的成本为每百万 token **$0.181**，B200 为 **$0.222** [S625]，**便宜约 18%**。一家每年在推理上花费 $10B 的实验室（🔴 仅为示意）可节省 **约 $1.8B**。一支 200 人的移植团队按人均约 $0.6M 计算 [S401]，成本 **约 $0.12B**，几周就能回本。一家支出 $5M 的企业只能节省约 $0.9M，仅够雇约 1.5 名工程师，远不足以完成一次约需 1.8–5.5 工程师·年的内核移植。**结论：** 算力支出越高，锁定越弱，因此英伟达最大的客户恰恰最有动力出走。

2. 按客户类型划分

- **前沿实验室（2.75）和超大规模云厂商（3.0）** 同时运行多套软件栈：Anthropic 使用 TPU、Trainium 和英伟达 [S653]，微软（Microsoft）用 Maia 200 支撑 Copilot [S90044]。它们对英伟达的依赖集中在研究原型阶段，而这一阶段仍从英伟达起步。
- **中国实验室（2.5）** 被出口管制推离英伟达。DeepSeek-V4 实现了昇腾首日支持 [S633]，TileLang 也新增了昇腾 950 后端 [S9011]。
- **主权 AI（3.75）** 在 FY2026 采购了超过 $30B 的英伟达系统（管理层表述）[S90071]，且很少雇用内核工程师。
- **初创公司与新兴云服务商（neocloud）（3.75）** 在主流模型上会因价格而切换（在 GLM-5 FP8 上，MI355X 每 token 成本最多比 B200 低 29.6% [S637]），但任何新东西仍留在英伟达上运行。
- **企业（4.5）和学术界（4.75）** 依赖长尾、教程和工具；对它们而言，这条护城河几乎是绝对的。

> **提示**
>
> **算例 —— 一次软件库移植如何改变一个客户群体。** DeepSeek-V3 在 2,048 块 H800 GPU 上训练 [S34007]，其通信库中使用了手工调优的 PTX [S5005]。2026 年，DeepEP 宣布推出“API 相同、性能完整”的昇腾版本 [S9009]，DeepGEMM-Ascend 随后于 2026-09-30 推出 [S9010]。**结论：** 一旦软件库完成移植，基于它们构建的模型无需修改代码即可迁移。软件库护城河是一个库接一个库地失守的，这就是为什么尽管 DeepSeek 对英伟达做了深度调优，中国实验室的得分仍只有 2–3。

3. 正反两方面的证据

参与者	侵蚀的证据	反面证据
Anthropic	最多 100 万颗 TPU，2026 年超过 1 GW [S653]；Trainium 作为主要训练合作伙伴 [S656]；2 GW AMD Helios 计划 [S9538]	最多 1 GW 的英伟达 Grace Blackwell / Vera Rubin，并开展联合工程 [S654]
OpenAI	从 MI450 起的 6 GW AMD [S546]；10 GW 由博通打造的加速器 [S174]；自研 ASIC 对标 Rubin [S628]	英伟达约 $30B 的股权投资（有报道）[S90015]
Meta	MTIA 300 已投产，至 2027 年还有三代 [S561]；租用 TPU [S90025]	同意购买数百万颗英伟达芯片（2026 年 2 月）[S4006]
DeepSeek / 中国	DeepEP 和 DeepGEMM 的昇腾移植版 [S9009,S9010]	DeepGEMM 仍是 CUDA 代码库 [S9010]

参与者	侵蚀的证据	反面证据
AMD 软件	在 vLLM 和 SGLang 中原生支持 S580,S582；MiniMax-M3 分离式服务首日落地 S627	26 天后在 DeepSeek-V4 上 B200 仍约为 MI355X 的 5 倍 S631；在智能体场景的 GLM 5.3 上，英伟达每 token 成本最多低 5 倍 S636
谷歌 TPU	在 Qwen3.5 上每 token 成本比 B200 低约 18% S625；已销售进入客户自有数据中心 S90027	框架覆盖广度 14/36，而 CUDA 为 36/36 S577,S587

注意

误区与事实：“CUDA 就是护城河。” 在 DeepSeek-V4 上，GB300 NVL72 的领先在很大程度上来自把专家并行流量限制在单个 72-GPU NVLink 域内 S633，而且据报道英伟达握有台积电（TSMC）约 60% 的 CoWoS 产能分配 S90039。**事实：** 护城河是软件 + 纵向扩展（scale-up）网络 + 供应能力的组合。即使追平 CUDA，若没有 NVLink 级别的机架或 CoWoS 产能，依然会丢单（第 05 层、第 03 层）。

注意

误区与事实：“DeepSeek 证明了不需要 CUDA。” DeepSeek 2025 年的代码*更深地*依赖英伟达特有的 PTX 和 SASS S5005,S9010；其昇腾移植版是 2026 年在出口管制下才推出的。**事实：** 它证明的是效率胜过 GPU 数量（CS5），而不是 CUDA 可有可无。

注

🐂 **看多观点。** 每条侵蚀路径在前沿都会漏回 CUDA，新模型也总是先在 CUDA 上运行 S633。英伟达选择拥抱而非对抗抽象层，而每季度约 $89B 的数据中心营收 S90011 足以供养比任何竞争对手都多的内核工程师。

注意

🐻 **看空观点。** 最大的买家已不再需要这条护城河：Anthropic、谷歌、Meta 和 OpenAI 都在运行或构建非英伟达软件栈 S653,S561,S174。可移植 DSL 把 AMD 的适配周期从数月缩短到数周 S631,S627，AI 智能体还可能进一步缩短 S9538。随着推理占据大部分算力，护城河所覆盖的支出份额正在缩小。

提示

算例 —— 是多源采购，而不是出走。 把表中已公布的非英伟达承诺加总：Anthropic 2026 年超过 1 GW 的 TPU S653 加 2 GW 的 AMD S9538，OpenAI 6 GW 的 AMD S546 加 10 GW 由博通打造的芯片 S174。合计 ⩾**19 GW**，分数年交付。同样这些实验室也与英伟达签了约（Anthropic 最多 1 GW S654），而英伟达估计截至 2027 年 Blackwell 加 Vera Rubin 的需求规模达 **$1 trillion** S90001。**结论：** 前沿实验室是在增加第二、第三供应源，而不是离开；侵蚀首先体现为*增量份额*和定价权的流失。

重要

核心结论。 🔴 我们的评估：CUDA 护城河是一种**时间税加广度税**，而不是一堵墙。前沿实验室、超大规模云厂商和中国实验室如今在价格、供应或政治因素足够有利时可以支付这笔税；对其他所有人而言则代价过高，这使英伟达仍是默认选择。如果高流量推理收敛到少数几种架构、每个竞争对手只需调优一次，护城河就会最快削弱。

🔧 **技术细节：客户群体评分的构建方法**

- 评分（1 = 数月内即可迁移，5 = 代价过高）综合考量内核工程能力、头部与长尾工作负载、替代软件栈以及迁移的公开证据；每一行的依据和来源见 `data/l09_moat_by_segment.csv`（均为推测）。
- 评分是相对的：2 分意味着这部分业务*能够*迁移，并不代表英伟达会失去它。

🎯 企业发展视角

1. **细分机会。** 挑战者只需拿下锁定程度低的单元格：超大规模云厂商、前沿实验室和价格敏感型新兴云服务商的主流模型推理。在没有顶级实验室作为锚定客户的情况下，新进入者能触达其中哪些？
2. **买广度，而不只是买速度。** 适配差距以周计；广度差距（36 vs 26 vs 4）以年计。上游维护者和打包/CI 团队的复利效应最强。
3. **高通需要思考的问题（仅基于公开信息）：** 在完成 Modular 交易之后 [S9511]，目标是在开源软件栈（vLLM、Triton、PyTorch）中获得一等公民地位，还是打造一套平行的 Mojo/MAX 软件栈？前者可以借力侵蚀路径；后者则必须从零开始争取开发者。
4. **关注锚定交易。** 每一笔 1–10 GW 的交易（Anthropic–TPU、OpenAI–AMD、OpenAI–博通）都在为软件开发提供资金，从而降低后来者面临的锁定程度。

CUDA 与系统软件：竞争格局

第 09 层 · CUDA 与系统软件 · 阅读约 13 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **覆盖广度仍属于英伟达。** 在本资料库跟踪的全部 12 个主流 AI 框架中，CUDA 均获原生支持（36/36 分）；ROCm 得分为 26，英特尔（Intel）18，华为 CANN 17，谷歌（Google）TPU 14，AWS Neuron 7，高通（Qualcomm）Cloud AI 4 [S587,S580,S586,S596]。
- **差距已从“能不能跑？”转向“首日（Day 0）能跑多快？”** DeepSeek-V4 发布时（2026-04-24），vLLM 和 SGLang 中的 CUDA 方案在发布当天即可使用。MI355X 只能运行 FP8，速度不到每用户 1 token/s，花了 26 天、31 个内核 PR 才达到每 GPU 2,256 tokens/s [S633,S631]。
- **差距在软件，而不在芯片。** MI355X 的高带宽内存（HBM）容量是 B200 的 1.60 倍，稠密 FP4/FP8 算力是其 1.12 倍 [S631]。结果有输有赢：在 GLM-5 FP8 上，MI355X 每 token 成本最多比 B200 低 29.6%；而在每用户 150 tokens/s 的 GLM 5.3 上，英伟达最多便宜 5 倍 [S637,S636]。
- **最强挑战者是一个软件层，而不是一家公司。** PyTorch、Triton、vLLM 和 SGLang 如今都已在主代码树内支持 AMD GPU，Triton 还有英特尔和华为的后端 [S578,S580,S582,S597,S592]。对于从不编写内核的团队而言，CUDA 变成了一个实现细节。
- **超大规模云厂商正在开源自家软件栈。** TorchTPU（与 Meta 合作，2026 年 10 月）取代了 PyTorch/XLA；AWS 开源了 TorchNeuron 和 NKI 编译器；华为于 2025 年开源了 CANN [S553,S595,S9525,S9524]。
- **高通买下了中立选项。** 它于 2026-07-29 完成了对 Modular 约 $3.9B 的收购，并于 2026 年 8 月开源了 Mojo 编译器（Apache 2.0）[S9511,S9512,S9513]。
- **[Q5 · 最强挑战者]** PyTorch/Triton/vLLM 这一层，加上作为第二后端、证明可移植性行得通的 ROCm。侵蚀切换成本的是抽象层，而不是任何一家厂商的软件栈。

No rival matches NVIDIA across the stack: the closest, Google TPU, is level or ahead in only 5 of 12 layers

Repo verdict vs NVIDIA by stack layer (02-13) and competitor; letter = verdict, number = score 0-5 (analyst judgement, sourced)

	02 Silicon	03 Memory & supply	04 CPU	05 Scale-up	06 Scale-out	07 DPU / SuperNIC	08 Systems & racks	09 System software	10 Libraries	11 Inference software	12 Cloud & orchestr.	13 Ecosystem & capital
AMD	P 4	B 3	**L 5**	B 2	B 3	B 3	B 2	B 3	B 2	B 3	D 2	B 3
Google TPU	P 4	B 4	P 4	D 5	D 4	D 3	P 5	B 3	B 3	**L 4**	**L 5**	B 4
AWS Trainium	B 3	B 3	P 4	B 3	D 4	D 4	B 4	B 2	B 2	B 3	**L 5**	B 3
Microsoft Maia	B 3	B 2	B 3	B 3	D 3	D 3	B 3	B 2	B 1	B 2	**L 5**	B 2
Meta MTIA	D 2	B 2	B 1	B 1	D 4	B 2	D 3	D 4	B 2	D 3	D 1	B 2
Broadcom	D 4	D 4	B 1	B 4	**L 5**	B 3	D 2	D 1	D 1	D 1	D 0	B 4
Marvell	D 3	D 3	B 1	B 3	B 4	B 3	D 1	D 1	D 1	D 1	D 0	B 3
Intel	B 2	D 3	P 4	B 2	B 2	B 3	B 1	B 2	B 2	B 2	B 1	B 2
Huawei	B 3	B 1	B 3	D 4	P 4	B 3	D 4	B 2	B 2	B 3	D 3	D 3
Qualcomm	D 2	D 3	B 2	B 1	B 2	B 1	B 2	B 2	B 1	D 2	B 1	B 1
Cerebras	D 4	D 3	B 1	D 3	B 2	B 1	B 3	B 2	B 1	**L 4**	B 2	B 2
Groq	D 3	D 3	B 1	D 2	B 1	B 1	B 2	B 2	B 1	D 3	B 2	B 1

L = leads NVIDIA　P = parity　B = behind　D = different approach

Analyst judgement (speculative)

Source: data from repo analysis (competitor_matrix.csv) [S602] [S143] [S361] [S379] [S144] [S624] ...; chart by repo · As of 2026-11-05

> 12 家竞争对手对照英伟达 12 个技术栈层级的热力图。谷歌 TPU 在 12 层中的 5 层持平或领先，为所有竞争对手中最多；全部单元格中 60% 为“落后”，24 个软件与软件库单元格中有 19 个落后。超大规模云厂商仅在云服务上领先；博通在以太网交换上领先；谷歌 TPU 在推理成本上领先。

按厂商划分的框架支持热力图见长尾护城河。

软件竞争如何评分

不妨把 CUDA 想象成一张道路网。竞争对手可以修一份**道路的复制品**（AMD 的 HIP 逐个调用地镜像 CUDA）；可以修一条**绕城环路**（Triton、torch.compile、XLA 或 Mojo 等抽象层，可为任何芯片生成内核）；也可以另建一**座新城**，配套自己的道路（谷歌的 JAX/TPU、AWS Neuron、华为 CANN）。复制品总是落后一个版本；环路承载了大部分交通；新城主要服务于其所有者。

软件栈（所有者）	框架覆盖广度	内核性能	工具	向后兼容	社区	开放程度
ROCm / HIP（AMD）	🟨 26/36，已进入 PyTorch 和 vLLM 主代码树	🟥 首日支持存在缺口	🟥 性能分析工具仍在成熟中	🟥 支持的 GPU 代际较少	🟥 规模远小于约 600 万 CUDA 开发者	🟩 开源
JAX/XLA + TorchTPU（谷歌）	🟥 谷歌之外 14/36	🟦 在谷歌内部达到前沿水平	🟦 优先服务谷歌内部	🟨 编译器屏蔽芯片变化	🟦 以实验室为主，而非爱好者	🟩 开源
Neuron + NKI（AWS）	🟥 7/36	🟦 为锚定客户调优	🟥 尚不成熟	🟨 仅 Trn2/Trn3	🟥 小	🟨 编译器开放，芯片封闭
CANN / MindSpore（华为）	🟥 17/36	🟨 首日支持 DeepSeek-V4	🟥 碎片化	🟥 每代都有变化	🟦 局限于中国市场	🟩 2025 年开源
oneAPI / SYCL（英特尔，UXL）	🟥 18/36	🟥 在大语言模型中采用有限	🟨 成熟的 HPC 工具	🟨 基于标准	🟥 小	🟩 开放标准
Triton（OpenAI，多厂商）	🟦 位于 PyTorch 之下的一层	🟨 在许多算子上接近手工调优水平	🟥 调试能力薄弱	🟨 每款芯片需重新编译	🟩 torch.compile 的默认选择	🟩 开源
Mojo / MAX（高通）	🟥 自有框架，用户少	🟦 厂商宣称已追平	🟥 尚不成熟	🟨 基于编译器	🟥 小	🟩 自 2026 年起采用 Apache 2.0

评级为本资料库的判断 🔴，即截至 2026-11-05 竞争对手相对英伟达 CUDA 的表现。证据：框架评分 [S587,S586]；首日支持与内核 [S633,S627]；开放程度 [S9524,S9525,S9512,S9526]；开发者 [S528]。

> **提示**
>
> **算例 —— 31 个拉取请求值多少钱。** InferenceX 估计 MI355X 的拥有成本约为每 GPU 小时 $1.50 [S622]。在 DeepSeek-V4 发布首日，其峰值为每 GPU 67.4 tokens/s，因此 $1.50 ÷ (67.4 × 3,600) × 10^6 ≈ **每百万 token $6.18**。经过 26 天的内核工作，峰值达到 2,256 tokens/s，即 **约每百万 token $0.18**：同样的芯片便宜了 33 倍 [S631]。在可用的每用户 15 tokens/s 条件下，成本从约 $4.01 降至约 $0.33。在 CUDA 上，B200 方案首日即可运行，此后的软件增益约为 1.7 倍（到第 42 天，每兆瓦从约 300k 提升到约 500k tokens/s）[S633]。对买家而言，切换成本就是损失的这一个月，而且每出一个新模型就要重来一遍。

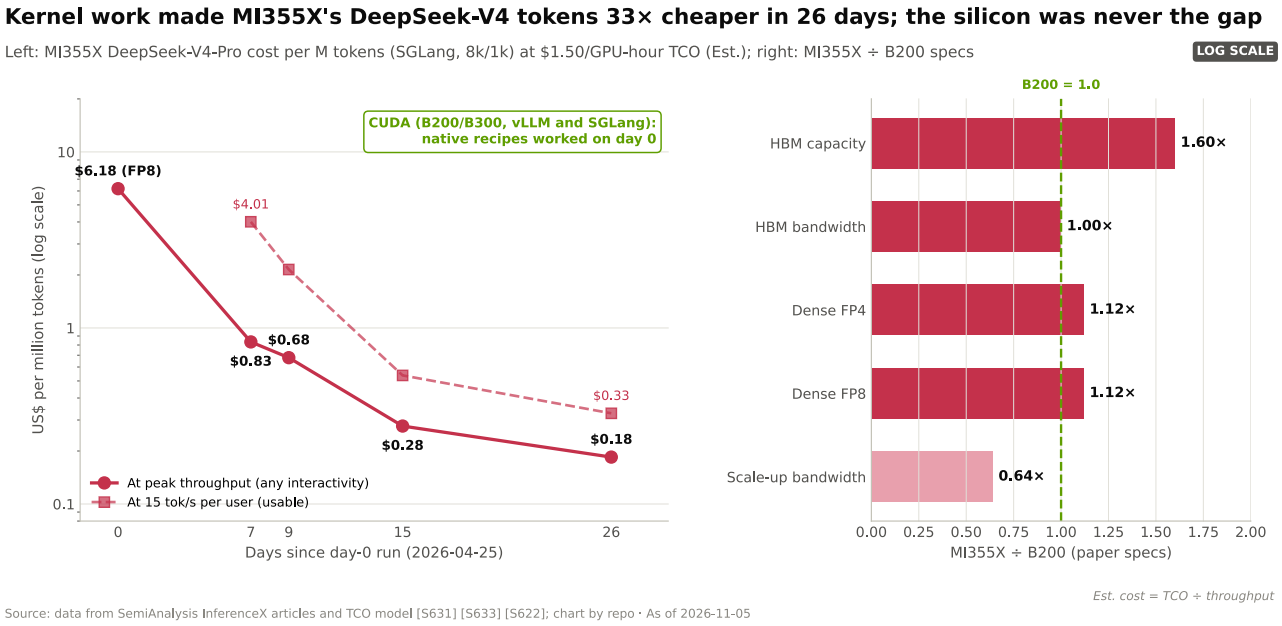

两个面板。左（对数刻度）：按估计的每 GPU 小时 $1.50 将 SemiAnalysis 的吞吐量数据换算为成本，MI355X 运行 DeepSeek-V4-Pro 在峰值吞吐下的成本从首日（仅 FP8）约每百万 token $6.18，经过 26 天和 31 个内核 PR 降至 $0.18，便宜约 33 倍；在可用的每用户 15 tokens/s 条件下，从 $4.01（第 7 天）降至 $0.33，约 12 倍，而 CUDA 方案在首日即可运行。右：纸面上 MI355X 的 HBM 容量是 B200 的 1.60x，带宽同为 8 TB/s，稠密 FP4 和 FP8 为 1.12x，纵向扩展带宽为 0.64x，因此首日差距在于软件而非芯片。

> **🔧 技术细节：为什么“直接替换”的 CUDA 克隆从来不能真正直接替换**
>
> HIPIFY 把 `cudaMalloc` 改写为 `hipMalloc`，大部分代码都能编译通过。真正耗时的是剩下的部分：内联 PTX 汇编；针对英伟达 warp 大小调优的内核（AMD 数据中心 GPU 的 warp 大小不同）；对英伟达专有软件库的调用（cuDNN、CUTLASS、TensorRT-LLM）；以及缺失的 API。例如，vLLM 的批量 CPU 卸载路径直到 ROCm 7.14（2026 年 7 月）才有 `hipMemcpyBatchAsync` 可用 [S627]。ZLUDA 等转译层则另辟蹊径，直接运行未经修改的 CUDA 二进制文件 [S9502]。至少从 2024 年起，英伟达的许可协议就禁止将 CUDA 输出转译到其他硬件上运行 [S9500]。

逐一审视挑战者

AMD ROCm：广度最接近，首日支持落后

ROCm 比 CUDA 晚起步九年，但如今与 CUDA 一样每年发布 3–4 个功能版本 [S586,S525]。ROCm 7.0（2025 年 9 月）新增了 AITER 调优算子、FP4/FP6 和 Windows 支持 [S90064]。ROCm 10.0（2026 年 8 月）已通过

PyTorch 2.13、vLLM 0.27 和 SGLang 0.5.15 的验证 [S586]。AMD 在吸引了 2,000 多名开发者参会的 Advancing AI 2026 上推出了 ROCm.ai 助手 [S9518,S9519]。它还与 Anthropic 达成协议，使用 Claude 加速 ROCm 开发 🟡 [S9538]。**最有力的论据：** 开源，且已进入所有重要框架的主代码树。**差距：** AMD 自家的引擎（ATOM）在某条智能体（agentic）曲线的部分区间上，每 token 成本优于运行 vLLM 的 GB300 NVL72，但很少有实验室在生产中运行 ATOM；而上游 vLLM 在发布第一周内无法在 MI355X 上处理长上下文任务 [S627]。

> **提示**
>
> **算例 —— 5 倍的每 token 差距意味着什么。** SemiAnalysis 发现，在每用户 150 tokens/s 的 GLM 5.3 上，英伟达每 token 成本最多比 MI355X 低 5 倍 [S636]。MI355X 的拥有成本约为每 GPU 小时 $1.50 [S622]。在吞吐量相同的前提下，要弥合 5 倍差距，每小时成本需降至约 $0.30。这就是 SemiAnalysis 得出“即使硬件免费也无法弥合差距”这一结论的原因 [S627]。在其他场景下，排名则会反转 [S637]。

谷歌 JAX/XLA 与 TorchTPU：完整的第二生态，主要服务谷歌的客户

JAX 在 TPU 上是一等公民；TorchTPU（2026 年 10 月与 Meta 共同开源）取代了 PyTorch/XLA [S577,S553,S595]。Anthropic 最多 100 万颗 TPU 的承诺表明，前沿实验室可以在 CUDA 之外运转 [S90026]。**差距：** 这套软件栈服务于 TPU，而不是商用芯片。

AWS Neuron、华为 CANN、英特尔 oneAPI

- **AWS：** TorchNeuron 是开源的原生 PyTorch 后端（在 Neuron 2.33 中进入公开 beta）。NKI 的编译器采用 Apache 2.0 许可，构建于 MLIR 之上 [S9525]。
- **华为：** CANN 于 2025 年 8 月开源，配有 torch_npu、MindSpeed、triton-ascend 和 vllm-ascend 适配器。昇腾（Ascend）有公开记录的 DeepSeek-V4 首日支持 [S9524,S592,S581,S633]。出口管制使其成为中国的默认选择。
- **英特尔：** oneAPI/SYCL 归属 UXL 基金会，其创始成员包括 Arm、Google Cloud 和高通。该基金会 2026 年的计划从演示转向实用指南 [S9526,S9527]。

抽象层：Triton、PyTorch、vLLM 与 SGLang

Triton 在主代码树内支持英伟达（计算能力 8.0+）和 AMD（ROCm 6.2+）[S578]。Meta 的 Helion 现为 PyTorch 基金会项目，可将类 PyTorch 内核编译为 Triton，*也可以*编译为英伟达的 TileIR [S9522,S9523]。英伟达的反制之道是成为每一层的最佳目标平台：CUDA Tile 和 cuTile Python（CUDA 13.1）以英伟达自己的方式为 Python 开发者提供 tile 编程模型 [S9521]。

Modular/Mojo（高通）及其他开放软件栈——仅基于公开信息

截至 2025 年，Modular 共融资 $380M（最近一次估值 $1.6B），后被高通以约 $3.9B 收购 [S9510,S90057]。Mojo 1.0 及其开源于 2026 年 8 月相继推出 [S9512,S9513]。高通现有的 Cloud AI SDK 通过 vLLM 容器和 ONNX 模型导入提供服务 [S596]。Tenstorrent 以 Apache 2.0 许可发布 TT-Metalium [S9535]。

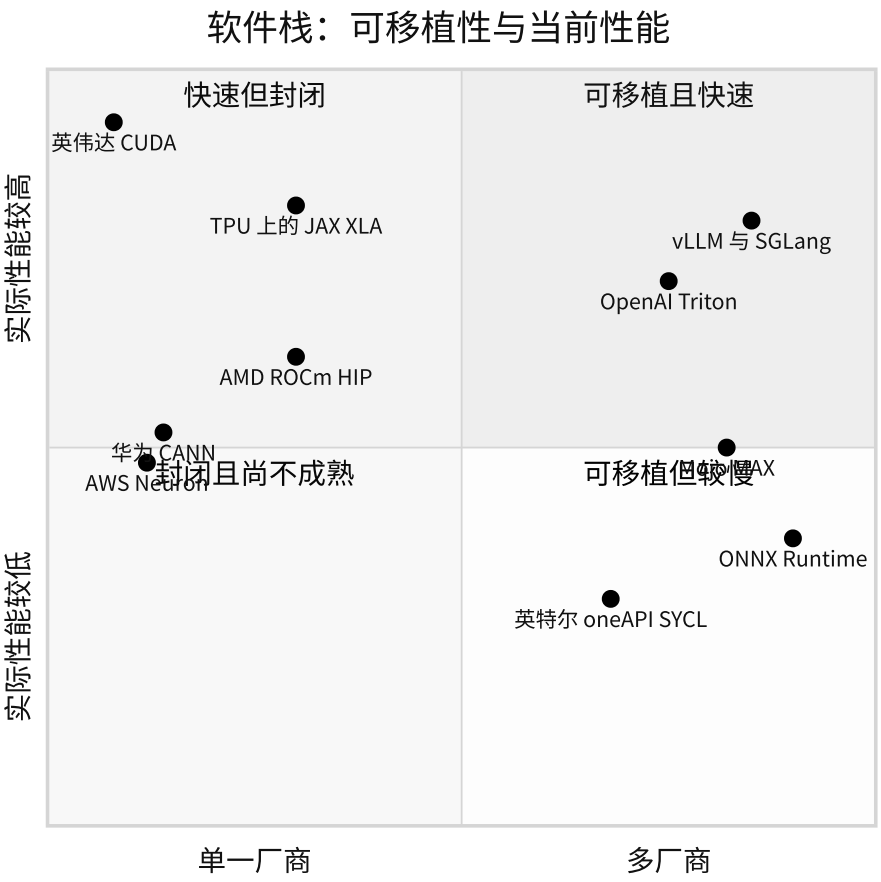

各点位置为本资料库的判断 🔴，参考了上文的框架矩阵和 InferenceX 结果。

注

🐂 **看多观点。** 新架构总是率先落地 CUDA，因此每次模型发布都会让竞争对手的计时器归零。即使英伟达自家的 TensorRT-LLM 在 DeepSeek-V4 发布时出了故障，开源的 CUDA 引擎依然正常工作[S633]。凭借约 600 万开发者，这条护城河如今通过*支持速度*而不仅仅是广度来实现复利增长[S528]。

注意

🐻 **看空观点。** 客户买的是 token，不是 CUDA。前沿实验室自己编写内核，AMD 在一个月内就让 DeepSeek-V4 达到了可用的吞吐量，超大规模云厂商正在开源自家软件栈，而推理服务层是中立的[S631,S553,S9525,S580]。如果大语言模型编写了大部分新内核，手工调优 CUDA 的长尾就不再稀缺。

🎯 企业发展视角

1. 对挑战者的前五个客户而言，哪个更重要：对顶级开源模型的首日支持，还是覆盖 12 个框架的广度?
2. 资助上游维护者（vLLM 背后的 Inferact、SGLang 背后的 RadixArk[S633]），是否比 ATOM 这类专有引擎能以每一美元换取更多的可移植性?
3. Mojo 现已采用 Apache 2.0 许可，高通在优先为自家推理芯片调优的同时，如何让 AMD 和英伟达用户仍然相信其中立性?
4. AMD 与 Anthropic 关于在 ROCm 上使用 Claude 的协议，预示着 AI 编写内核的趋势。内核生成能力应当自建、授权还是合作获取?

CUDA 与系统软件：发展历程与英伟达的构建方式

第 09 层 · CUDA 与系统软件 · 阅读约 12 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **CUDA 起步于一个研究项目。** Ian Buck 的 Brook 语言（斯坦福大学，2004 年）证明了类 C 代码可以在图形芯片上运行 [S9532]。英伟达于 2006-11-08 随 G80 GPU 发布 CUDA，并于 2007 年 6 月推出 CUDA 1.0 [S9528,S525]。
- **英伟达花钱创造了自己的市场。** 其首个 CUDA 卓越中心（伊利诺伊大学，2008 年）获得了 $500,000 资金和一套价值约 $800,000 的集群；到 2008 年年中，已有 41 所大学开设 CUDA 课程 [S9529]。
- **回报花了十年。** 2012 年，AlexNet 在两块 GTX 580 游戏 GPU 上完成训练 [S9530]；2014 年，cuDNN 把深度学习内核打包成库 [S9531]。直到 FY2018，数据中心营收才首次超过英伟达的研发总支出 [S400]。
- **[Q4 · 优势来源]** 时间在存量装机基础上的复利：18 年内 13 个 CUDA 大版本，通过 PTX 保持兼容，并随每一款英伟达 GPU 交付，因此研究成果率先落地 CUDA [S525,S529]。
- **护城河如今既在建设，也在防守。** 2024 年的一项许可条款禁止旨在让 CUDA 软件运行于竞争对手芯片的转译层 [S9500]。美国司法部（DOJ）于 2024 年启动反垄断调查，中国监管机构于 2025 年 9 月就 Mellanox 收购附加条件问题作出初步违法认定 🟡 [S9504,S9503,S9505]。
- **[Q6 · 复制成本]** 估计 🔴：要在主流框架上实现推理级别的对等，需要 5–8 年和累计 $5–10B 的软件投入；要达到 CUDA 的完整广度则需 10 年以上。参照指标：已有十年历史的 ROCm 在框架支持上得分 26/36；高通（Qualcomm）为 Modular 支付了约 $3.9B，约为其融资额的 10 倍 [S586,S90057,S9510]。

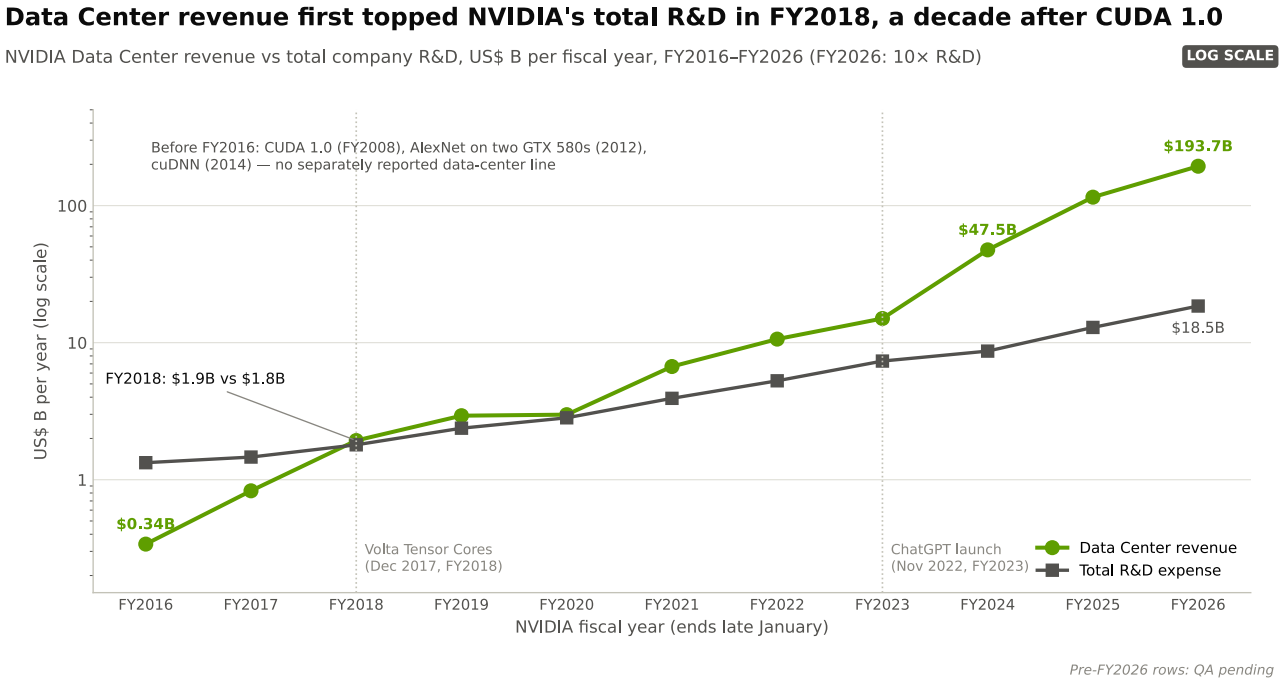

对数刻度折线图，FY2016 至 FY2026。英伟达数据中心营收在 FY2016 为 $0.34B，而研发总支出为 $1.33B；FY2018 首次超过研发（$1.93B 对 $1.80B），FY2024 达到 $47.5B，FY2026 达到 $193.7B，约为研发支出 $18.5B 的 10 倍。CUDA 1.0 于 2007 年 6 月（FY2008）发布，cuDNN 于 2014 年发布，因此该平台运行了约十年之后，数据中心业务才足以支撑公司的研发开支。

从图形“取巧”到平台

在 CUDA 出现之前，通用 GPU 计算（GPGPU）研究者把数学运算伪装成像素着色（矩阵被当作纹理）。Brook 用一种类 C 语言把这种技巧隐藏起来 [S9532]。CUDA 走得更远：从 G80 起，每一块 GeForce 都配备了 C 编译器、硬件线程调度器和共享内存 [S9528,S2503]。这直接触达了学生和研究者：到 2020 年，支持 CUDA 的 GPU 已超过 10 亿颗，其中大部分是游戏显卡 [S529]。

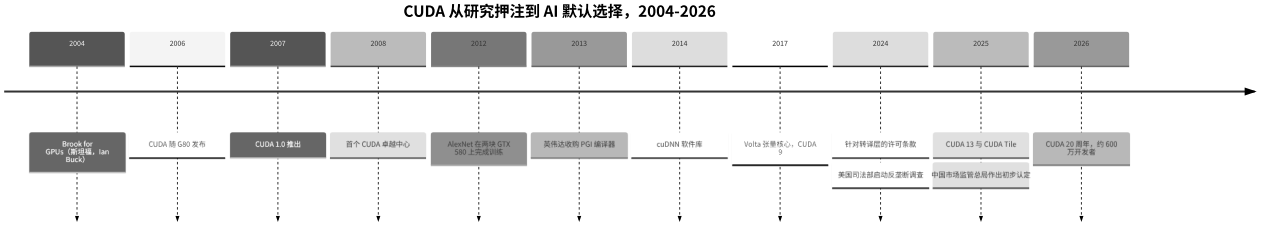

> **提示**
>
> **算例 —— 播种成本有多低。** 伊利诺伊大学获得了约 $1.3M 的现金和硬件（$500,000 + 约 $800,000）[S9529]。即使 2008 年开设 CUDA 课程的全部 41 所大学都获得同等金额，总花费也仅约 $53M。这大约相当于英伟达 FY2016 研发支出 $1.33B 的 4%，不到 FY2026 研发支出 $18.5B 的 0.3% [S400,S401]。

关键决策与交易

日期	决策	重要意义	来源
2006-11	让每一块 G80 级 GPU 都能用 C 语言编程	到 2020 年 CUDA GPU 装机量超过 10 亿颗	S9528,S529
2008	资助 CUDA 教学与研究中心	到 2008 年年中已有 41 所大学开设 CUDA 课程	S9529
2013-07	收购 PGI（OpenACC、CUDA Fortran）	把高性能计算（HPC）领域的 Fortran 代码库带到英伟达平台	S484
2014	发布 cuDNN	框架直接调用英伟达内核，而不再自行编写	S9531
2017-09	CUDA 9 开放 Volta 张量核心	此后硬件与软件开始协同设计	S525
2024-03	针对转译层的许可条款	提高了 ZLUDA 类克隆方案的法律风险	S9500,S9502
2025-12	CUDA 13.1 新增 CUDA Tile 和 cuTile Python	英伟达对 Triton 式 tile 编程的回应	S523,S9521
2026-03	Dynamo 1.0，Apache 2.0 许可	开源推理服务层，以保持其英伟达优先	S90066

[Q4] 优势从何而来

[Q4 · 优势来源] 五种机制相互强化：

1. **时间与存量装机。** 十八年的版本迭代，每一版都与新的 GPU 特性绑定 [S525]。
2. **向后兼容。** 代码以 PTX 形式交付，驱动程序为每款新 GPU 重新翻译，因此旧内核能继续运行。
3. **协同设计。** 新的数值格式在发布首日就配有内核；竞争对手要过后才能移植。
4. **研究引力。** 新技术首先在 CUDA 上编写和进行基准测试，因此首日（Day 0）优势随每次模型发布而延续（竞争格局）。
5. **防守。** 许可条款与捆绑策略，这也招来了监管机构：美国司法部的调查关注英伟达是否让切换变得更困难 [S9503]。

提示

算例 —— 回报来临前的十年。 从 FY2016 到 FY2020，英伟达研发支出合计 $9.8B（$1.33B + $1.46B + $1.80B + $2.38B + $2.83B）。同期五年的数据中心营收合计为 $9.0B [S400,S2]。直到 FY2018，单年数据中心营收才足以覆盖公司的研发支出，此时距 CUDA 1.0 发布已过去十年。

🔧 技术细节：2024 年许可条款能做什么、不能做什么

该条款禁止对 CUDA 输出进行逆向工程或转译，使其运行于非英伟达平台。据报道，它出现在 CUDA 11.6 及之后版本安装时附带的最终用户许可协议（EULA）中；另有一家媒体称，在线许可协议自 2021 年起就已包含该条款 [S9500,S9501]。按多数解读，它并不禁止源代码级移植（HIPIFY 改写的是源代码，而非二进制文件）或净室重新实现 🔴。ZLUDA 早先由 AMD 资助的代码应 AMD 要求被撤下，随后重新构建 [S9502]。其效果是给任何销售二进制兼容方案的人带来法律风险。

[Q6] 复制需要多大代价

[Q6 · 复制成本] 估计 🔴：一个资金充足的挑战者若从现在起步，要在主流框架上实现推理级别的对等，需要 **5–8 年、累计 $5–10B 和 1,000–3,000 名软件工程师**。这比 AMD 用的十年要快，因为抽象层和 AI 辅助的内核编写如今已经存在。要追平 CUDA 的完整广度（HPC、图形、机器人软件库）则需要 10 年以上。

路径	时间	资金（估计 🔴）	人才（估计 🔴）	证据
克隆 API（HIP 方式）	10 年以上且仍在继续	每年约 $0.5–1B	1,000–3,000 名软件工程师	ROCm 从 2016 年到 2026 年达到 26/36 [S586]
收购团队与语言	初创公司 3–4 年的工作积累，之后还需整合	收购价 $0.7–3.9B	数百人	Run:ai 约 $700M；Silo AI $665M；Modular 约 $3.9B [S479,S9506,S90057]
借力抽象层	推理场景 2–3 年	每年 $0.2–0.5B	200–500 名上游贡献者	Triton、vLLM 和 SGLang 后端 [S578,S580,S582]
追平 CUDA 的完整广度	10 年以上	英伟达级别：FY2026 研发总支出 $18.5B	数千人	英伟达 FY2026 研发支出 [S401]

提示

算例 —— 把高通的收购价当作市场标尺。 Modular 经三轮融资共募集 $380M，2025 年 9 月估值为 $1.6B [S9510]。九个月后，高通同意支付约 $3.9B [S90057]。这相当于投入资本的约 10 倍、最近一次私募估值的约 2.4 倍：买家如今为节省的时间付费，而不是为营收付费。

🔧 技术细节：为何估计是一个区间而不是一个数字

公开文件不会把软件研发和硬件研发分开披露，AMD 也没有公布 ROCm 的人员规模。分析师称，AMD 在 2025 年对软件进入了“战时状态”，但其 AI 软件工程师的薪酬低于英伟达和各大实验室 [S9537]。因此，上述区间以可观察的结果为锚：已经过的年数、框架评分和交易价格。它们并非自下而上的成本测算。

反事实推演——如果英伟达当初没有……

如果……	会有什么变化	可能的结果（🔴 分析）
……在 2010 年开源 CUDA?	AMD 和英特尔推出兼容 CUDA 的编译器	英伟达保住软件库和协同设计上的领先，但随着切换变得轻而易举，利润率会被压缩
……输给了 OpenCL?	出现一个统一的可移植标准	AI 仍会走向 GPU，但硬件将像 CPU 一样靠价格竞争

如果……	会有什么变化	可能的结果（🔴 分析）
……只在 Tesla 计算卡上提供 CUDA?	支撑 AlexNet 的 GTX 580 上没有 CUDA [S9530]	深度学习会在 CPU 上停留更久；研究习惯会在别处形成

> **提示**
>
> **算例 —— 开放兼容会让多少利益面临风险。** 兼容 CUDA 的竞争对手每从 FY2026 数据中心营收（$193.7B）中夺走 5%，就相当于每年约 $9.7B [S1]。考虑到英伟达在 Q2 FY2027 的 GAAP 毛利率为 75.0% [S3]，首先受到冲击的将是价格，而不仅仅是份额 🔴。

完整案例研究见 CS2 · CUDA：十五年的赌注。硬件里程碑见第 02 层发展历程；跨层全景见英伟达如何建成今日格局。

🎯 企业发展视角

1. 在学术界播种只花了英伟达数千万美元，却造就了行业默认标准。如今哪个渠道（开源模型、智能体框架、AI 编程工具）的播种成本依然低廉?
2. 挑战者可以买到时间，却买不到习惯。在完成 Modular 交易之后，还需要什么：上游贡献、开发者关系，还是捆绑的云服务额度?
3. 2024 年的许可条款与反垄断调查方向相反。一项要求 CUDA 互操作性的和解令（consent decree）会如何改变可移植软件栈资产的价值?
4. 如果 AI 编写的内核把“十年”缩短到几年，哪些资产仍能保值：硬件行为数据、基准测试框架，还是编译器团队?

CUDA 与系统软件：路线图

第 09 层 · CUDA 与系统软件 · 阅读约 10 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **CUDA 如今按季度节奏发布。** CUDA 13.0 于 2025-08-04 推出，此后又发布了五个 13.x 小版本，13.5 于 2026-11-04 发布 [S523]。CUDA 13 放弃了对 Maxwell、Pascal 和 Volta 的支持 🟡 [S90065]。
- **英伟达正把正门搬到 Python。** CUDA 13.1 推出了 CUDA Tile 和 cuTile Python，13.2 把 tile 编程扩展到 Ampere 和 Ada [S9521,S527]。推理服务层 Dynamo 于 2026 年 3 月以 Apache 2.0 许可发布 1.0 版 [S90066]。
- **AMD 追平了节奏，但没有追平内容。** ROCm 从 7.0（2025 年 9 月）起，经由新的 Core SDK 发布线，于 2026-08-26 发展到 10.0 [S586]。新功能相对 CUDA 的滞后已从约九年缩短到数周，但长尾依然落后（竞争格局；发布节奏图见侵蚀路径）。
- **竞争对手 2026 年的动作都围绕开放展开。** 谷歌（Google）的 TorchTPU 取代了 PyTorch/XLA（后者于 2026-11-15 归档）；AWS 的 TorchNeuron 处于公开 beta；Mojo 的编译器于 2026 年 8 月开源 [S553,S595,S9525,S9512]。
- **[Q7 · 路线图与变数]** 预计英伟达会在添加自有 Python 层的同时，让 CUDA 继续成为每个可移植层（Triton、Helion、vLLM）支持最好的目标平台。如果 AI 编写的内核让移植变得廉价，或者某家超大规模云厂商把开放软件栈与商用硬件结合起来，格局就会改变 🔴。

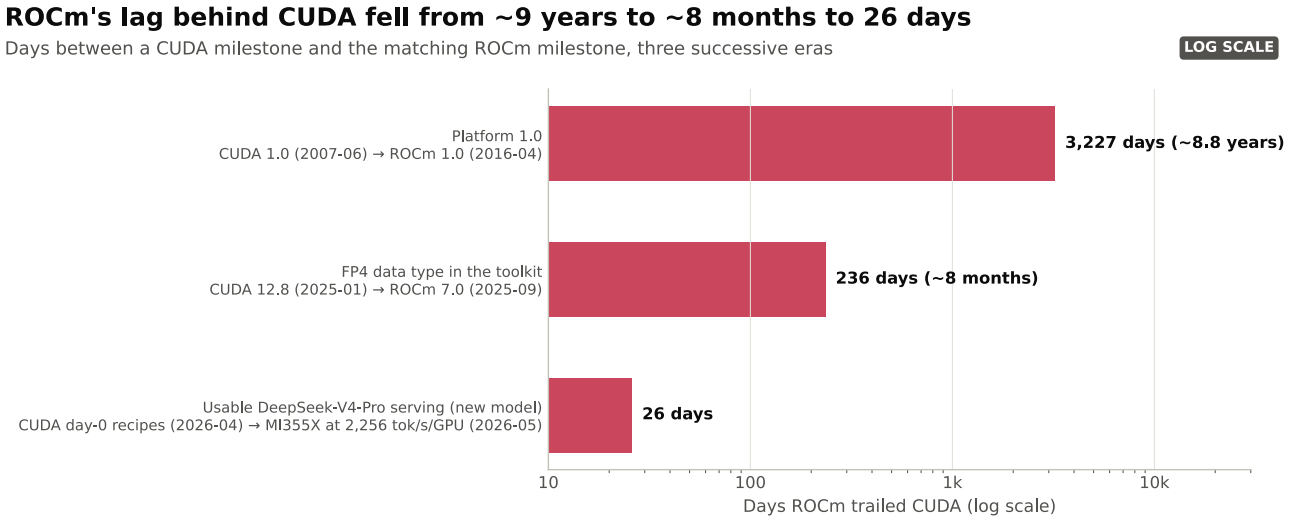

Source: data from CUDA/ROCm release histories; SemiAnalysis InferenceX [S525] [S586] [S524] [S90064] [S633] [S631]; chart by repo · As of 2026-11-05

> 对数刻度横向柱状图，显示 AMD ROCm 落后英伟达 CUDA 的时间：平台 1.0 晚了 3,227 天（约 8.8 年）（2007 年 6 月对 2016 年 4 月）；FP4 支持晚了 236 天（约 8 个月）（2025 年 1 月的 CUDA 12.8 对 2025 年 9 月的 ROCm 7.0）；DeepSeek-V4-Pro 的可用服务比 CUDA 的首日方案晚了 26 天（2026 年 4 月至 5 月）。每次差距都比上一次缩短约十倍，但每个新模型发布时差距都会再次出现。

软件路线图，2024–2028

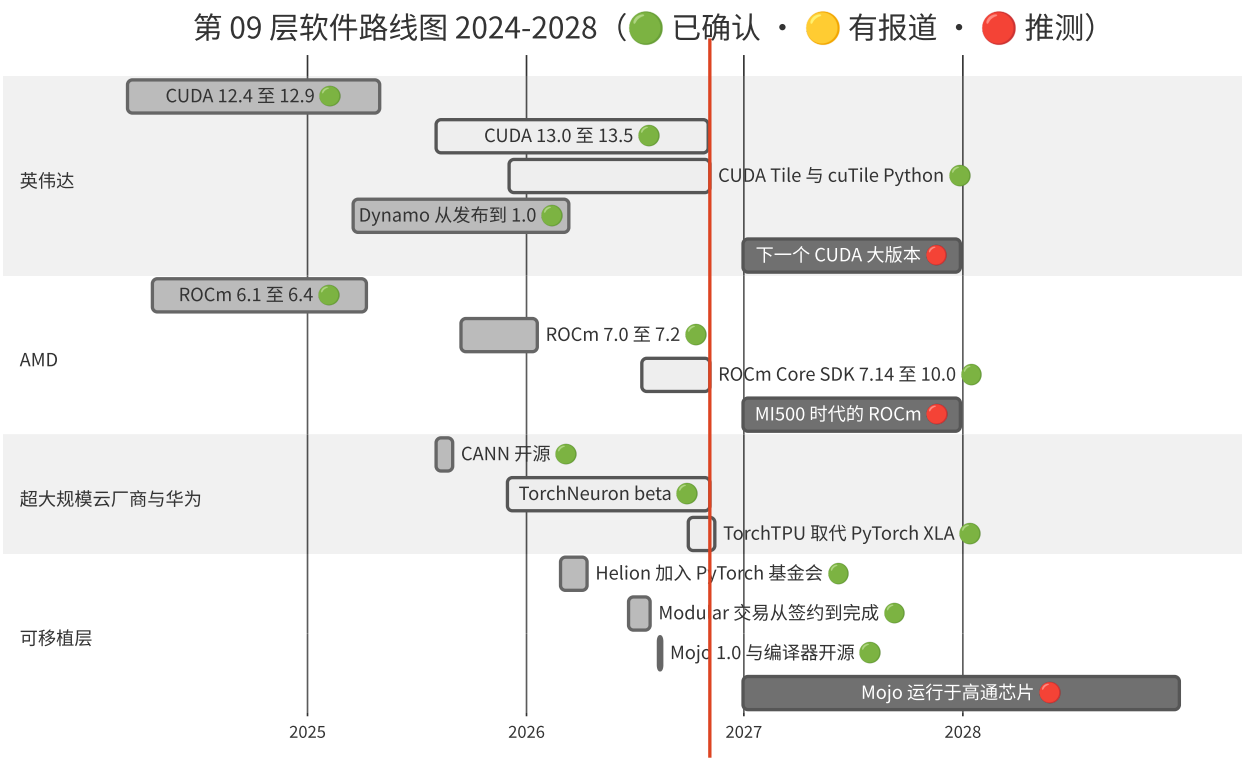

下表未列出的条形图来源：CUDA 12.4–12.9 发布日期 [S524]；ROCm 6.1–6.4 [S586]；MI500 于 2027 年推出，据此设定 🔴 ROCm 时间窗 [S538]；CANN 开源 [S9524]；Modular 交易于 2026-07-29 完成 [S9511]。

事项	时间窗口	状态	可信度	来源
CUDA 13.x 小版本，大约每季度一个	2025-08 → 2026-11（13.5）	已发布	🟢	S523
CUDA Tile / cuTile Python；13.2 扩展至 Ampere 和 Ada	2025-12 → 2026-03	已发布	🟢	S9521,S527
Dynamo 1.0；1.5.1 是首个提供企业级支持的版本	2026-03 → 2026-10	已发布	🟢	S90066,S521
ROCm 10.0，已通过 PyTorch 2.13 和 vLLM 0.27 验证	2026-08-26	已发布	🟢	S586
TorchTPU 取代 PyTorch/XLA（后者于 2026-11-15 归档）	2026-10 → 2026-11	已发布	🟢	S553,S595
TorchNeuron 正式发布（GA）	尚未宣布（自 2025-12 起处于 beta）	beta	🔴	S9525
Helion 可编译为 Triton 和英伟达 TileIR	2026	已发布	🟢	S9523
Mojo/MAX 运行于高通 Dragonfly AI300（2028 年产品）	尚未宣布（AI300 预计 2028 年推出）	—	🔴	S90056,S9511
英伟达在 GTC DC 上的软件发布（主题演讲 2026-12-01）	2026-12-01，晚于本页日期	—	🔴	S90047

> **提示**
>
> **算例 —— 滞后缩短得有多快。** ROCm 1.0 比 CUDA 1.0 晚了 **106 个月**（2007 年 6 月 → 2016 年 4 月）[S525,S586]。FP4 支持晚了 **约 8 个月**：CUDA 12.8（2025 年 1 月）对 ROCm 7.0（2025 年 9 月）[S524,S90064]。DeepSeek-V4 的可用服务比 CUDA 的首日方案晚了 **约 26 天** [S631,S633]。每一步都缩短了约十倍，但买家要为*最后*那段差距买单，而且每次重要模型发布时它都会重现。

长尾依然落后：vLLM 用于 KV 缓存卸载的批量主机到设备拷贝，直到 ROCm 7.14（2026 年 7 月）才可用；框架支持得分为 36 分中的 26 分，而 CUDA 为 36 分 [S627,S586,S587]。

对两家厂商而言，仅靠软件就能在固定硬件上提升实际性能：

Software alone: B200 DeepSeek-R1 throughput +34% and MI355X +29% in six months

InferenceX, DeepSeek-R1-0528 1k/1k, same GPU, engine, concurrency and parallelism; total tokens/s per GPU, first run = 1.0

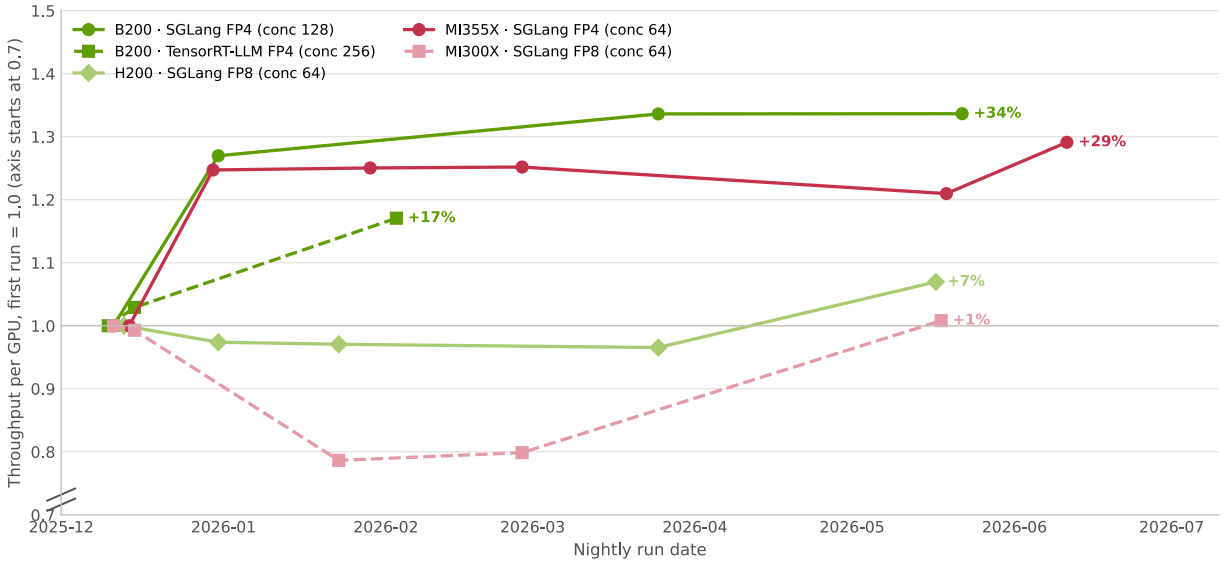

Source: data from SemiAnalysis InferenceX public-API history snapshot [S621] [S622]; chart by repo · As of 2026-11-05

> InferenceX 每晚测试结果的折线图，硬件和设置保持不变，2025 年 12 月至 2026 年 6 月。B200 · SGLang FP4（并发 128）+34%；B200 · TensorRT-LLM FP4（并发 256）+17%；H200 · SGLang FP8（并发 64）+7%；MI355X · SGLang FP4（并发 64）+29%；MI300X · SGLang FP8（并发 64）+1%。开源引擎的更新（SGLang、TensorRT-LLM、ROCm/AITER）为两家厂商在固定硬件上都带来了两位数的增益，而较老的 CDNA 3 产品曾出现性能倒退，之后才恢复。

> **🔧 技术细节：为何 tile 编程是英伟达路线图上对 Triton 的回应**
>
> Triton 让程序员以 *tile*（矩阵分块）为单位描述工作，由编译器把 tile 映射到线程上，这正是它能跨厂商移植的原因 [S578]。CUDA Tile 在英伟达自己的软件栈内做同样的事。cuTile Python 编译为 Tile IR——一种由驱动程序针对每款 GPU 即时编译的虚拟指令集，类似于经典 CUDA 中的 PTX [S9521]。如果 Helion 和其他前端在英伟达硬件上生成 TileIR，那么即使源代码是可移植的，英伟达也能保住性能优势 [S9523]。

什么会改变格局

[Q7 · 路线图与变数]

- **能编写可移植且高速内核的 AI。** MI355X 在 DeepSeek-V4 上的追赶主要依靠新的 TileLang、Triton 和 FlyDSL 内核 [S631]。AMD 和 Anthropic 计划使用 Claude 加速 ROCm 开发 🟡 [S9538]，SemiAnalysis 估计 GitHub 上约 4% 的公开提交已由 Claude Code 编写 [S627]。如果一个月的内核工作缩短为一天，CUDA 的首日优势也会随之缩小 🔴。
- **PyTorch 在所有平台上默认采用 Triton 或 Helion**（通过 torch.compile）。一次编写的内核可为任何后端编译；英伟达的反制在于 Helion 同样以 TileIR 为目标 [S9523]。
- **超大规模云厂商同时开放软件栈和芯片。** TorchTPU 和 NKI 都已开源 [S553,S9525]，另据报道谷歌正在向客户自有数据中心销售 TPU 🟡 [S90027]。运行于商用硬件上的开放软件，将是第一个兼具规模与开放性的竞争对手。
- **监管救济。** 来自美国司法部或中国市场监管总局（SAMR）的互操作性要求，将以行政命令的方式降低切换成本 🔴 [S9503,S9505]。

> **提示**
>
> **算例 —— “AI 编写内核”会如何影响复制成本。** AMD 的 DeepSeek-V4 冲刺由四名主要贡献者在 26 天内提交了 31 个 PR [S631]。如果编程智能体把这一周期缩短到一周，同一支团队就能支持约 4 倍数量的模型发布，而发展历程页面中 5–8 年实现对等的估计 🔴 将受制于硬件获取和基准测试数据，而不是工程师·年。

🎯 企业发展视角

1. 英伟达在开源推理服务层（Dynamo）的同时，保持编译器栈（CUDA、Tile IR）封闭。挑战者应当首先开放哪一层，才能赢得最多的开发者好感?
2. 高通的 Mojo 路线图是否需要 AI300 时代的芯片（2028 年）来证明自己，还是可以先在英伟达和 AMD GPU 上赢得用户 [S90056,S9513]?
3. 由于 GTC DC（2026-12-01）晚于本页的截止日期，哪些发布会改变上述判断：新的 CUDA 大版本、Tile IR 覆盖更多 GPU，还是 Dynamo 的定价?
4. 如果编程智能体压缩了移植时间，那么稀缺资产是内核编写人才、基准测试基础设施（InferenceX 式），还是对模型的抢先获取权?

CUDA 与系统软件：价值链与企业发展视角

第 09 层 · CUDA 与系统软件 · 阅读约 11 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **CUDA 是免费的，这正是关键所在。** 英伟达通过硬件带动销售（pull-through）间接从中获利：FY2026 数据中心营收达 $193.7B [S1,S402]。
- **直接软件收入很小。** 软件与服务在 Q4 FY2024 达到约 $1B 的年化收入水平 [S9516]。NVIDIA AI Enterprise 的标价为每 GPU 每年 $4,500（云上为每 GPU 小时 $1），黄仁勋在 2026 年 10 月将软件授权费定在每 GPU 每年约 $2,000 [S9515,S9517]。
- **软件层已成为一个并购市场。** 2023 至 2026 年间，芯片厂商完成了 15 笔 AI 软件交易，而 2008–2022 年间本资料库跟踪到的仅有 3 笔。仅 AMD 一家就收购了 Nod.ai、Silo AI（$665M）、Brium、MK1 以及 Untether AI 团队 [S9508,S9506,S9507,S9509]。
- **价格正在快速上涨。** 高通（Qualcomm）为 Modular 支付的约 $3.9B，约为英伟达最大一笔软件补强收购（Run:ai，据报道约 $700M）的 5.6 倍，约为 Modular 2025 年 9 月估值的 2.4 倍 [S90057,S479,S9510]。
- **独立标的所剩无几。** 英伟达收购了 OctoAI、Deci 和 CentML；红帽（Red Hat）收购了 Neural Magic。剩下的主要是开源维护者（vLLM 的 Inferact、SGLang 的 RadixArk）和早期编译器初创公司 [S478,S9533,S633]。
- **[Q8 · 价值池与并购机会]** 价值围绕英伟达硬件聚集，而不是软件本身。对挑战者而言，软件是*入场成本*：值得拥有的资产是那些能缩短首日（Day 0）差距的资产（编译器团队、内核库、对上游维护的影响力），而不是能产生授权收入的资产 🔴。

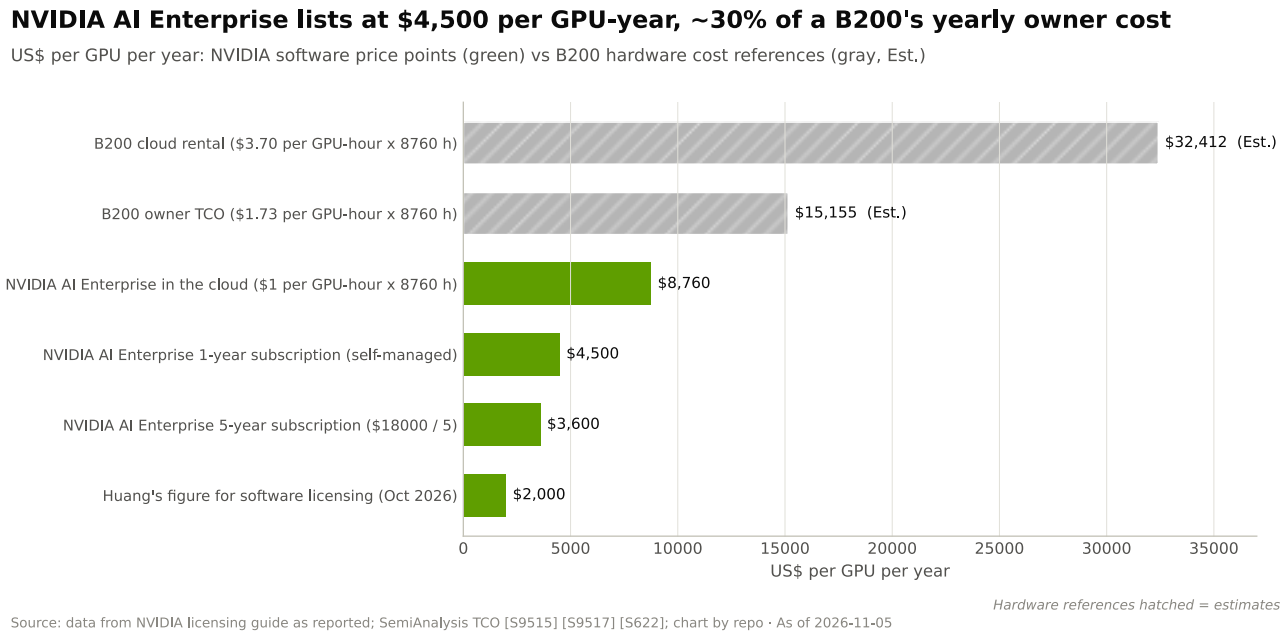

以每 GPU 每年美元计的横向柱状图。NVIDIA AI Enterprise：$2,000（黄仁勋 2026 年 10 月给出的数字）、$3,600（五年期订阅）、$4,500（一年期标价），云上按每 GPU 小时 $1 全时计费最高可达 $8,760。作为对比，B200 的所有者全包成本约为每年 $15,155（SemiAnalysis 的 TCO 估计），租用成本约为每年 $32,412，因此按标价计算软件约增加 30% 的成本，按黄仁勋的数字约增加 13%。

谁拿走了钱

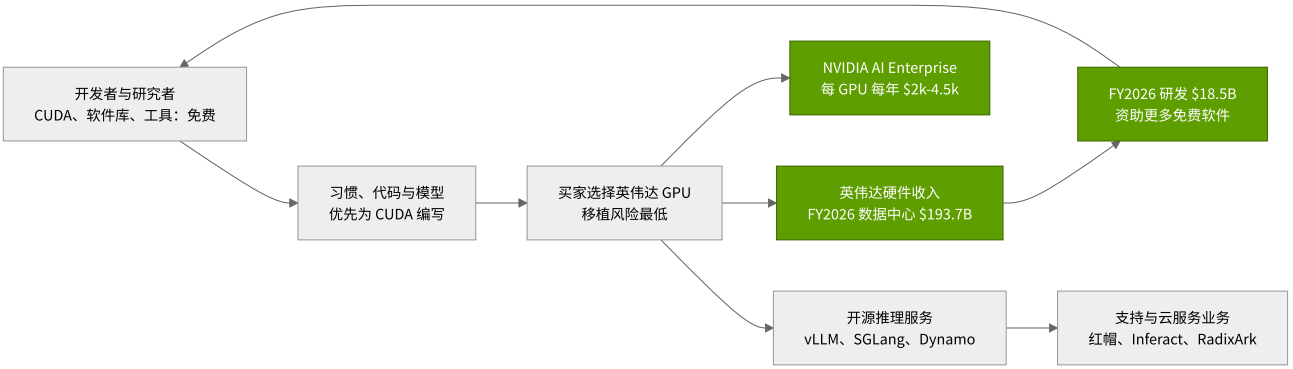

数据来源：S1,S401,S9515,S9517；开源公司 S9533,S633。

价值池	由谁获取	规模参照	趋势
硬件带动销售	英伟达	FY2026 数据中心 $193.7B S1	🟢 增长中；在可移植层让 GPU 变得可替换的领域面临风险
企业软件授权	英伟达（AI Enterprise）	Q4 FY2024 年化收入约 $1B S9516；每 GPU 每年 $2,000–4,500 S9517,S9515	🟡 规模小，依附于企业和主权客户
开源推理服务支持	红帽（Neural Magic）、Inferact、RadixArk	维护者融资达“数亿美元” S633	🟡 由厂商中立的引擎催生的新价值池
编译器与语言平台	Modular → 高通；Triton（非商业）	收购价约 $3.9B S90057	🔴 作为战略资产而非收入来源来估值
超大规模云厂商内部软件栈	谷歌、AWS、华为	无直接收入；降低芯片总拥有成本（TCO）	🟢 已于 2025–2026 年开源 S553,S9525,S9524
GPU 云市场	英伟达 DGX Cloud Lepton、新兴云服务商	该市场于 2025 年 5 月上线 S598	🟡 让开发者留在英伟达优先的云上

提示

算例 —— 为什么英伟达不需要为 CUDA 收费。 按黄仁勋提出的每 GPU 每年约 $2,000 计算，100 万颗获得授权的 GPU 每年可带来约 $2B 收入 S9517。这只相当于 FY2026 数据中心营收（$193.7B）的约 1% S1。按单颗 GPU 计，AI Enterprise 的标价（$4,500）约相当于 B200 每年约 $15,155 所有者成本的 30% S9515,S622。如此大范围收费会促使客户去比较各家软件栈，而硬件已经赚到了此类授权费约 100 倍的收入。

🔧 技术细节：AI Enterprise 实际卖的是什么

该授权将英伟达 AI 软件中受支持、经过安全补丁的构建版本与企业级支持打包，按 GPU 定价 S9515。CUDA、cuDNN 以及开源项目（Dynamo、TensorRT-LLM、Megatron）仍可免费下载。企业付费购买的是*支持与认证*，就像购买红帽 Linux 一样，而不是代码本身。因此买家很可能是企业和主权项目，而不是能够自我支持的超大规模云厂商 🔴。

软件层的并购历史

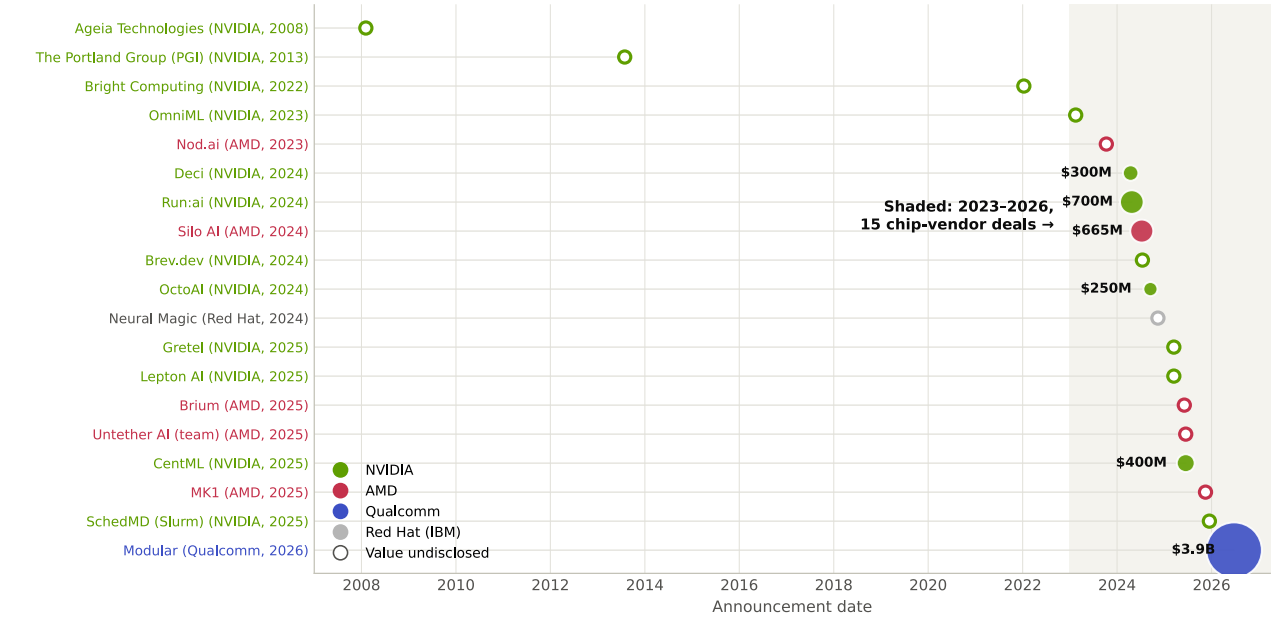

> AI 软件收购的点状时间线，每笔交易一行。英伟达：Ageia（2008）、PGI（2013）、Bright Computing（2022），之后在 2023 至 2025 年间收购了 OmniML、Run:ai（约 $700M）、Deci（约 $300M）、Brev.dev、OctoAI（约 $250M）、Gretel、Lepton AI、CentML（约 $400M）和 SchedMD。AMD：Nod.ai（2023）、Silo AI（$665M，2024）、Brium、Untether AI 团队和 MK1（2025）。高通：Modular（约 $3.9B，2026 年 6 月宣布，2026 年 7 月完成）。红帽：Neural Magic（2024）。自 2023 年以来芯片厂商共完成 15 笔软件交易，而本资料库跟踪的此前 15 年仅有 3 笔。

三家收购方遵循不同的策略：

- **英伟达收购“消除摩擦者”：** 让其 GPU 更易于调度（Run:ai、SchedMD）、更易于优化（Deci、OctoAI、CentML）或更易于租用（Brev.dev、Lepton）的工具；Run:ai 在欧盟审查后被开源[S476,S478]。
- **AMD 收购“追赶能力”：** 编译器与推理团队（Nod.ai、Brium、MK1），以及在 AMD 平台上构建开源模型的实验室 Silo AI（$665M）[S9508,S9507,S9509,S9506]。
- **高通下了一个大注：** 一门语言（Mojo）、一个推理框架（MAX），以及创始人 Chris Lattner——他现任高通执行副总裁[S9511]。

Qualcomm's ~$3.9B for Modular: 5.6× Run:ai, 2.4× Modular's 2025 valuation

Disclosed or reported prices of AI-software acquisitions, US$ M; gray = Modular funding reference points

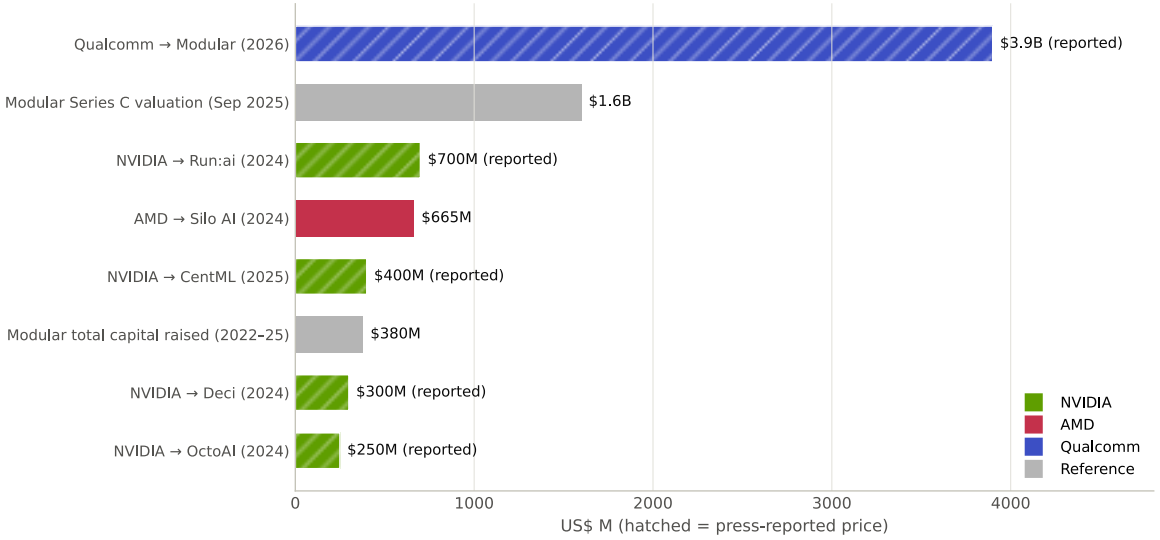

Source: data from company announcements and press reports [S476] [S479] [S478] [S9506] [S90057] [S9511] ...; chart by repo · As of 2026-11-05

AI 软件交易金额横向柱状图：高通-Modular 约 $3,900M（2026），英伟达-Run:ai 约 $700M（2024），AMD-Silo AI $665M（2024），英伟达-CentML 最高约 $400M（2025），英伟达-Deci 约 $300M（2024），英伟达-OctoAI 约 $250M（2024）。作为参照，Modular 在 2025 年 9 月的 C 轮融资中估值为 $1,600M，累计融资 $380M，因此高通支付的价格约为最近一次私募估值的 2.4 倍、投入资本的约 10 倍。

提示

算例 —— 一支软件团队的价格。 Silo AI 花费了 AMD $665M [S9506]；Modular 花费了高通约 $3.9B，约为其累计融资 $380M 的 10 倍 [S90057,S9510]。据报道，英伟达同类补强收购的单笔金额在 $250–700M 之间 [S479]。Modular 的溢价买到的是一门语言和运行时，而不只是工程师；这是否值 Run:ai 的约 5.6 倍，取决于其采用情况，而目前采用规模仍然很小（竞争格局）。

值得关注的非上市公司（仅基于公开信息）

公司	业务	阶段 / 最近一次公开融资	重要意义
Tenstorrent	采用开源软件栈（TT-Metalium、TT-NN）的 RISC-V AI 芯片	$693M D 轮（2024 年 12 月）[S2509]；据报道约 $1.5B E 轮，估值约 $6.2B 🟡 [S4535]	检验开源内核能否吸引外部开发者 [S9535]
Inferact（vLLM）	由 vLLM 维护者创立的公司	融资“数亿美元” 🟡 [S633]	掌控使用最广泛的中立推理服务引擎 [S580]
RadixArk（SGLang）	由 SGLang 维护者创立的公司	融资“数亿美元” 🟡 [S633]	第二个中立引擎；在大型 MoE 模型上表现突出 [S582]
Luminal	加速 PyTorch 推理的机器学习编译器	$5.3M 种子轮（2025 年 11 月）🟡 [S9534]	面向 PyTorch 用户的种子期编译器团队
tiny corp（tinygrad）	极简的端到端深度学习软件栈与编译器	融资情况未经核实	展示了极小团队也能写出完整软件栈 [S9536]
Groq（授权交易后）	推理芯片与编译器；核心团队已加入英伟达	在英伟达约 $20B 授权交易前估值约 $6.9B（2025 年 9 月）🟡 [S90019]	一种英伟达选择授权获取的编译器优先设计 [S90018]

[Q8 · 价值池与并购机会] 在这一层，资金流向拥有*默认地位*的一方：英伟达，通过硬件带动销售获利。对其他所有人而言，软件是一种需要获取的能力（通常以收购式招聘（acquihire）的方式），而非利润池。其价值以消除了多少天的首日滞后、支持了多少框架来衡量。独立团队的供给正在萎缩：自 2023 年以来，至少有九支推理优化和编译器团队归入了英伟达、AMD、红帽或高通 [S478,S9508,S9507,S9509,S9533,S9511]。剩下的独立资产是维护者公司和小型编译器初创公司。与它们合作（资助上游、联合 CI、共同维护）可能比控制它们更重要 🔴。

🎯 企业发展视角

1. **自建、收购还是合作?** 在收购 Modular 之后，还剩下什么差距：首日模型支持、框架覆盖广度，还是开发者触达？三者中哪一项仍然可以买到而不必自建?
2. **中立引擎。** 入股或赞助 Inferact 或 RadixArk，能否比 AMD ATOM 这样的自研分支以更低成本换取对新芯片的早期支持？这又是否会让这些项目所服务的其他硬件厂商感到警惕?
3. **变现方式。** 挑战者应当完全免费提供软件栈（CUDA 模式），还是像 NVIDIA AI Enterprise 那样按每个加速器收费（每 GPU 每年 $2,000–4,500）？
4. **人才留存。** AMD 的追赶型交易大多是编译器团队；什么样的留任安排能在整合后留住他们?
5. **监管带来的期权价值。** 如果反垄断救济措施强制要求 CUDA 互操作性，哪些资产（转译层、编译器、基准测试）的价值提升最大?

第 10 层 —— 软件库（CUDA-X）

共 12 层中的第 10 层 · 将英伟达 GPU 变为数学、AI、数据、仿真与科学计算“现成引擎”的领域软件库 · 约 8 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **CUDA 是编程语言；CUDA-X 则是大多数客户实际调用的、预先构建并调优的软件库货架：**cuBLAS 负责矩阵运算，cuDNN 负责神经网络层，NCCL 负责多 GPU 通信，TensorRT 负责推理，RAPIDS 负责数据科学。英伟达（NVIDIA）称其拥有“数以百计的软件库” S10047；本资料库对其中 29 个主要软件库进行了发布年份考证，其中 18 个于 2018 年以来推出。
- **[Q1 · 职能与失效后果]** 这一层的职能，是把每一代新 GPU 数据手册上的 FLOPS 转化为特定工作负载上的实际速度。Rubin 的稠密 FP4 算力是其 BF16 算力的 8.75 倍 S100，但在软件库推出 FP4 矩阵内核之前，这部分增益为零；CUTLASS 已支持 NVFP4 与 MXFP4 S10009。
- **NCCL 是多 GPU AI 的“隐形黏合剂”。** 在 GB200 NVL72 上，交换机内规约可将一次理想化的 70B 梯度全规约（all-reduce）耗时从 0.31 s 减半至 0.16 s S34011,S200。NCCL 在 50 个月内发布了 19 个次版本 S10038。
- **软件库让既有硬件持续变快：**仅凭软件，B200 上 DeepSeek-R1 的吞吐量就在 2025 年的四个月内从每 GPU 约 2,000 tokens/s 提升至 4,600 tokens/s S646。
- **广度创造 AI 以外的需求。** 样本中 2018 年以来推出的 18 个软件库里，有 12 个服务于数据、优化、检索、仿真、光刻、气候或量子计算。台积电（TSMC）已在量产中使用 cuLitho，英伟达及其合作伙伴称其在曲线掩模流程上可提速约 45 倍 S10031。
- **重在集成，而非新 API：**无需修改的 pandas、Polars、scikit-learn、Spark 和 Faiss 代码，现已可在 GPU 上运行 S10013,S10017,S10015,S10019,S10025。
- **弱点与看空情景：**加速效果参差不齐。在 AWS 运行的一项 1 TB Spark 测试中，GPU 仅比原生 Spark 快 1.06 倍，且慢于向量化 CPU 引擎，不过成本低约 80% S10020。AI 核心是最容易被复制的部分：AMD 的 RCCL 正是基于 NCCL 自身代码构建 S10002；而高通（Qualcomm）以约 $3.9B 收购 Modular（已于 2026-07-29 完成交割），瞄准的恰恰就是这一层 S90057,S9511。

18 of 29 major CUDA-X libraries arrived since 2018; 12 serve data, science or quantum

Cumulative count of a dated sample of major NVIDIA libraries, by domain; diamonds = zero-code-change framework integrations

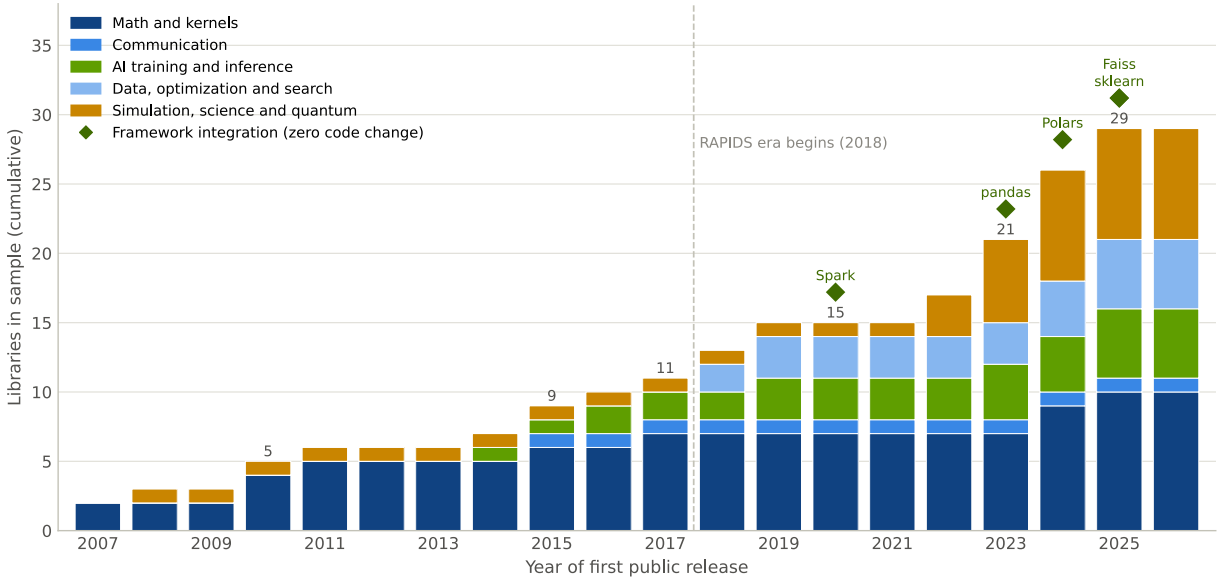

Source: data from changelogs, PyPI, CUDA archive, press [S525] [S484] [S10035] [S10039] [S10000] [S10040] ...; chart by repo · As of 2026-11-05

按首次公开发布年份统计的 29 个主要 CUDA-X 软件库样本的堆叠阶梯图。2007 至 2017 年出现 11 个（cuBLAS、cuFFT、cuSPARSE、cuRAND、cuDNN、NCCL、TensorRT、CUTLASS 等），2018 至 2025 年出现 18 个，其中 12 个面向数据分析、优化、向量检索、仿真、光刻、气候或量子计算，而非 AI 模型。2020 至 2025 年间出现了 5 项零代码修改集成（Spark、pandas、Polars、scikit-learn、Faiss）。英伟达自称拥有数以百计的软件库；此处为经年份考证的样本。

提示

算例 —— 一次软件库更新值多少钱。 2025 年 2 月至 5 月间，英伟达 TensorRT-LLM 团队在没有任何新硬件的情况下，将 B200 上 DeepSeek-R1 的最大吞吐量从每 GPU 约 2,000 tokens/s 提升至约 4,600 tokens/s [S646]。按示意性的每 B200 小时 $4.99 计算（为 2025 年报道的公开价格，有待复核）[S395]，更新前一个 GPU 小时产出 2,000 × 3,600 = 7.2M 个 token，每百万 token 成本约 $0.69；更新后产出 16.6M 个 token，每百万 token 成本约 $0.30。**结论：**这次软件库更新使每 token 服务成本下降约 57%，通常需要一代新芯片才能实现这样的提升。

本层在技术栈中的位置

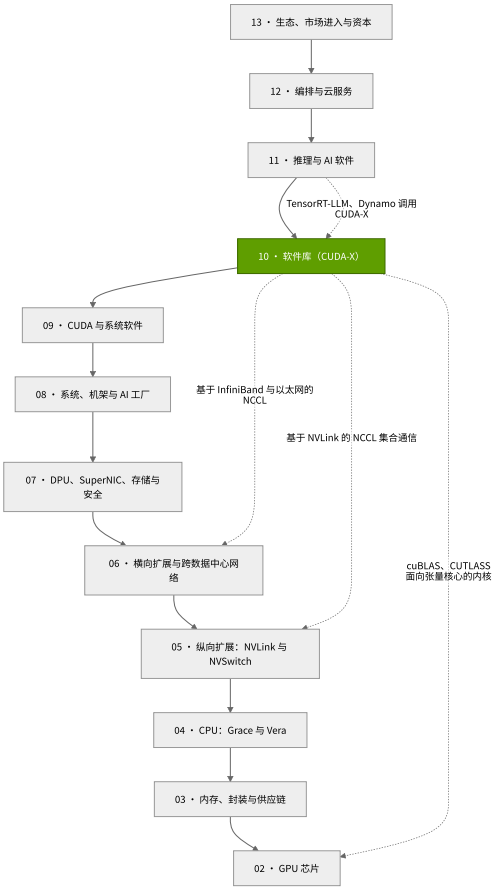

本层全景图

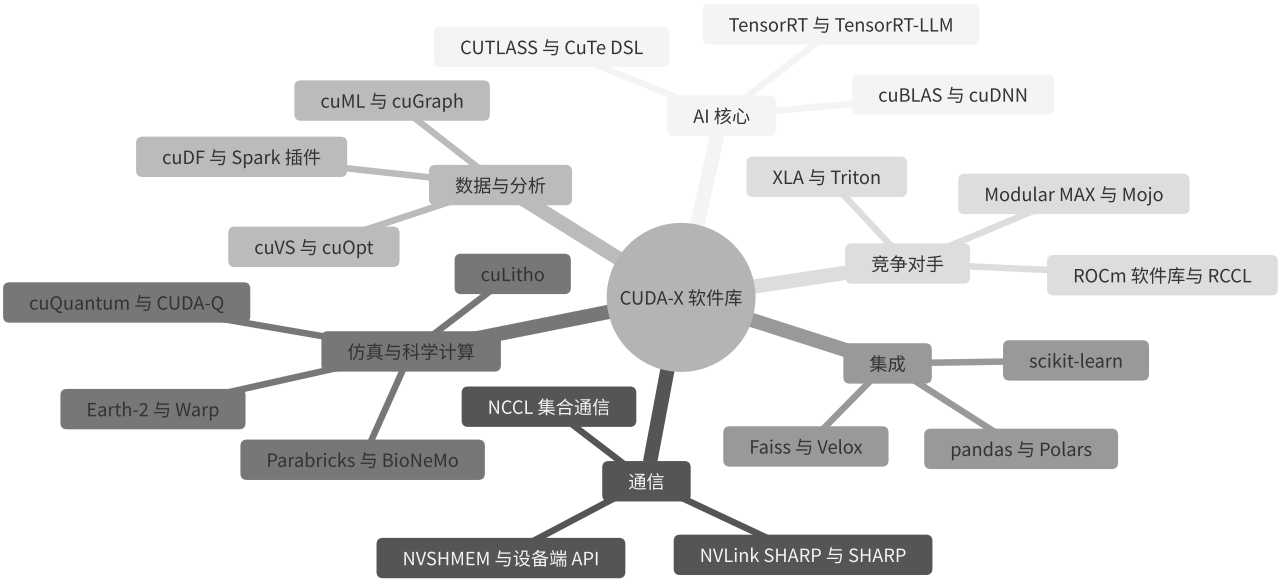

八个问题一览

#	问题	简要回答	详见
Q1	这一层承担什么职能？若薄弱会出什么问题？	把原始 FLOPS 与带宽转化为实际交付的速度；没有调优过的内核，新 GPU 或新格式就会闲置	CUDA-X 目录

#	问题	简要回答	详见
Q2	哪些指标重要?	峰值达成率、集合通信总线带宽与延迟、支持新硬件所需时间、相对 CPU 的端到端成本、集成广度	本页（下文）及 NCCL
Q3	代际进步如何?	样本从 11 个软件库（2017 年）增至 29 个（2025 年）；NCCL 在 50 个月内从 2.13 升至 2.32；同一 GPU 上的软件增益达 2.3 倍	广度为何产生复利、NCCL
Q4	优势来源?	历代 GPU 上积累的调优成果，加上广度与框架集成	发展历程与构建方式
Q5	最强挑战者?	AI 领域是 AMD 的 ROCm 软件库（含 RCCL）；XLA、Triton 等编译器栈正在蚕食内核层	竞争格局
Q6	复制成本?	AI 核心可在数年内重建；长尾的领域软件库才是代价高昂的部分	发展历程与构建方式
Q7	路线图?	🟡 CuTe DSL 即将结束 beta（目标已推迟），🟢 NCCL GPU 发起式网络通信已发布，零代码修改集成持续增加	路线图
Q8	价值池与并购?	软件库大多免费，通过 GPU 与软件许可变现；可移植性层是并购标的	价值链与企业发展

关键指标

[Q2 · 关键指标] 评判一个软件库，看它能把多少硬件能力转化为完成的工作，以及代价几何：

指标	衡量什么	为何重要	示例
峰值达成率	实际交付 FLOPS ÷ 数据手册 FLOPS（整个作业层面即 MFU）	每 FLOP 的实际价格	Llama 3 405B 在 16,384 块 H100 上以 38–41% MFU 运行 S34006
集合通信总线带宽与延迟	全规约期间每 GPU 持续的 GB/s；小消息每条的 µs	能否扩展到单台服务器之外	H100 集群的验收标准约为 400–450 GB/s 的全规约总线带宽 S10022
支持新芯片所需时间	从新 GPU 或新数值格式发布到推出调优内核所需的周数	延迟会让 FLOPS 闲置	CUTLASS 已覆盖 NVFP4 与 MXFP4 S10009
相对 CPU 的端到端速度与成本	真实流水线上的作业运行时间与作业成本	非 AI 买家按作业付费	Spark：快 1.06 倍，便宜约 5 倍 S10020
广度	可原生在 GPU 上运行的领域与框架	每增加一项都会带来 GPU 需求	2020 年以来 5 项零代码修改集成

[Q3 · 代际进步] 这一层的进步既体现为新的软件库，也体现为既有硬件上的软件增益：

Same B200, new software: DeepSeek-R1 speed up 5.5x in four months; dense Llama 70B flat

NVIDIA-published per-GPU performance on unchanged hardware across software releases, indexed to first point = 1.0

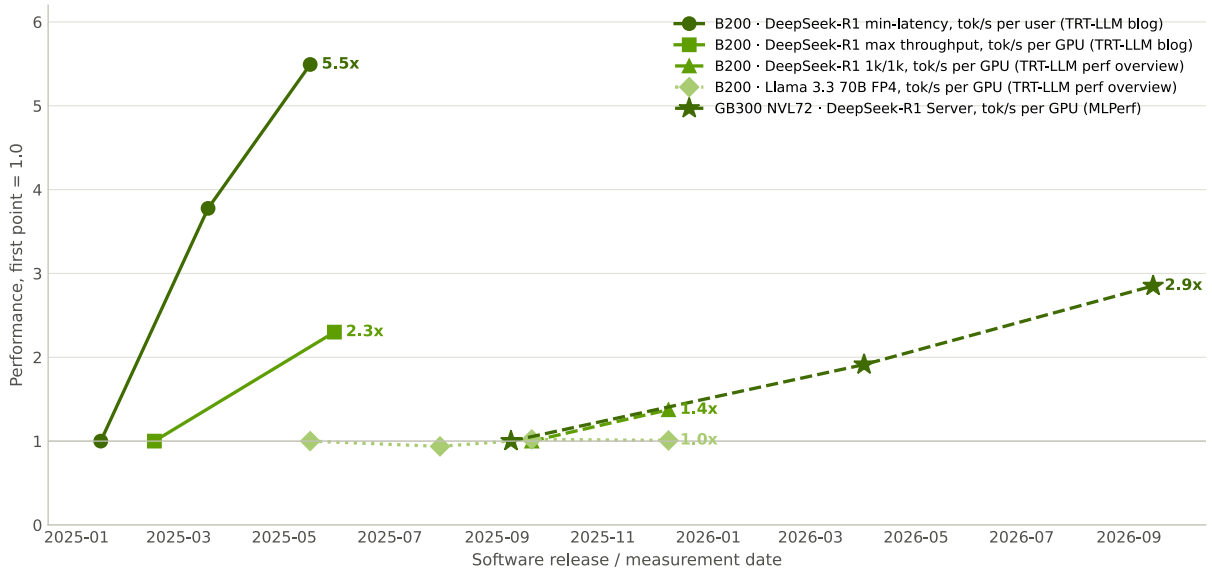

Source: data from NVIDIA TensorRT-LLM docs and blogs; MLCommons [S645] [S646] [S643] [S644] [S641] [S642] ...; chart by repo · As of 2026-11-05

> 英伟达公布的同一 GPU 随时间推移的性能折线图。B200 上 DeepSeek-R1 最低延迟速度从每用户 67 tokens/s 升至 368 tokens/s（5.5 倍，2025 年 1–5 月）；B200 上 DeepSeek-R1 最大吞吐量从每 GPU 2,000 tokens/s 升至 4,600 tokens/s（2.3 倍）；GB300 NVL72 的 MLPerf DeepSeek-R1 Server 成绩一年内提升 2.9 倍；而 B200 上 Llama 3.3 70B 的最大吞吐量在四个 TensorRT-LLM 版本间变化不超过 8%。MoE 模型从软件中获益最多。

本层各页

页面	你将了解
CUDA-X 目录	每个主要软件库做什么，以及谁为其工作负载买单
NCCL：隐形黏合剂	集合通信，环形、树形与交换机内规约的对比，一个 70B 算例，以及替代方案
软件库广度为何产生复利	新的 GPU 工作负载、Spark 与 pandas 示例、集成情况、软件库数量
竞争格局	ROCm、oneAPI、XLA 等软件库栈与 CUDA-X 的对比
发展历程与英伟达的构建方式	时间线、关键决策、复制成本、反事实推演
路线图	软件库即将推出的内容，以及哪些因素会改变格局
价值链与企业发展视角	谁攫取了免费软件库的价值、非上市公司、并购

🔧 技术细节：开放的外围，封闭的核心

许可分为两个层级：PyPI 将 cuBLAS 和 cuDNN 列为英伟达专有软件 [S10038]。外围则是开放的：CUTLASS（BSD-3）[S10038]、cuDF（Apache 2.0）[S10011]、cuOpt（Apache 2.0）[S10026]，以及 Warp（自 2025 年 3 月起采用 Apache 2.0）[S10028]。NCCL 当前的源文件带有 Apache-2.0 许可标记 [S10000]。第 09 层介绍其下一层：CUDA 与系统软件。

🎯 企业发展视角

1. **一款带动硬件销售的免费产品。** 大多数 CUDA-X 软件库是免费的；其价值体现在 GPU 定价与 AI Enterprise 许可中。英伟达的溢价中，有多少来自软件库广度而非芯片本身？
2. **开放外围，封闭核心。** 开源 cuDF、cuOpt 和 Warp 吸引了外部贡献者，而 cuBLAS 和 cuDNN 仍保持闭源。对挑战者而言，是追平封闭的 AI 核心更便宜，还是瞄准英伟达软件库已开源、因而可移植的领域更划算？

3. **高通视角的问题（仅基于公开信息）：**鉴于 Modular（Mojo 与 MAX）正以 $3.9B 被收购 [S90057]，且 AI200/AI250 推理机架已经发布 [S90028]，一个以推理为先的平台在第一天就必须对标哪些 CUDA-X 软件库家族（GEMM、注意力、集合通信、推理服务），又可以跳过哪些（光刻、基因组学、数据科学）？
4. **NCCL API 已成事实标准。** RCCL 沿用了 NCCL 的 API [S10002]，因此各框架几乎无需改代码即可切换厂商。一种新的纵向扩展（scale-up）互连架构（UALink、ESUN）是否需要一个兼容 NCCL 的软件库才具有可信度？又由谁来提供？

CUDA-X 目录：每个软件库做什么

第 10 层 · 软件库（CUDA-X） · 约 12 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **CUDA-X 是一份预调优引擎的目录，**每个引擎都封装了某一领域多年的 GPU 调优成果。英伟达（NVIDIA）称其数量“数以百计” S10047；其中约 20 个承载了大部分商业分量，下文逐一列出。
- **AI 核心规模不大，且大多闭源。** cuBLAS（矩阵运算）和 cuDNN（神经网络层）以专有许可发布 S10038。CUTLASS 是用于编写自定义内核的开源模板工具包，在 4.0 版（2025 年 6 月）中新增了 Python DSL S10010。
- **软件库质量就是钱。** 将一次 70B 训练任务的峰值 FLOPS 达成率从 41% 提升至 52%（Meta 的 Llama 3 对比英伟达的 Megatron 基准测试）S34006,S34002，在一次 15T token（词元）的训练中可节省约 0.4M 个 B200 小时。
- **较新的软件库服务于 AI 以外的客户。** 台积电（TSMC）已在量产中使用 cuLitho S10031。一项同行评审研究测得，Parabricks 的胚系变异检测比 CPU 快最高 65 倍 S10033。
- **加速倍数差异很大，最高的数字来自英伟达自己的测试。** 英伟达的 cudf.pandas 测试显示约 150 倍 S10014；一项独立复测得到的是 50–70 倍 S10046。cuML 的零代码修改模式中位数约为 5.8 倍，而一项低秩 PCA 反而*慢* 2 倍 S10015。
- **许可策略在外围向开源演进。** cuDF、cuOpt 和 Warp 现已采用 Apache 2.0 S10011,S10026,S10028，而最来之不易的调优成果仍保持闭源，且只支持英伟达硬件。

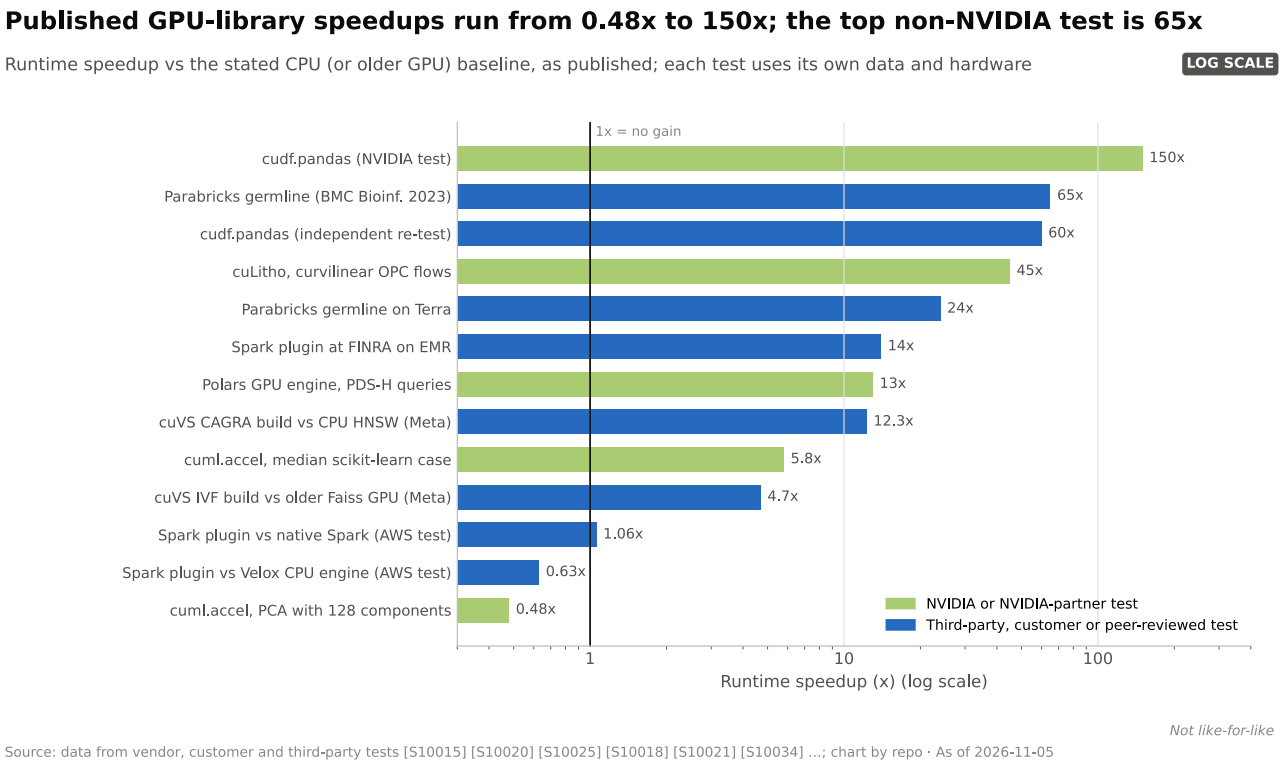

Source: data from vendor, customer and third-party tests [S10015] [S10020] [S10025] [S10018] [S10021] [S10034] ...; chart by repo · As of 2026-11-05

CUDA-X 软件库已公布运行时加速倍数的水平对数刻度条形图，按测试执行方着色。英伟达或其合作伙伴的数据：cudf.pandas 约 150 倍，cuLitho 45 倍，Polars GPU 引擎最高 13 倍，cuml.accel 中位数 5.8 倍，低秩 PCA 为 0.48 倍（更慢）。第三方、客户或同行评审数据：Parabricks 胚系变异检测最高 65 倍（BMC Bioinformatics）和 24 倍（Terra），一项独立的 cudf.pandas 复测约 60 倍，FINRA Spark 14 倍，cuVS CAGRA 索引构建相对 CPU HNSW 为 12.3 倍（Meta），cuVS IVF 相对旧版 GPU 代码为 4.7 倍，以及一项 AWS 基于 TPC-DS 衍生负载的 Spark 测试：相对原生 Spark 为 1.06 倍，相对 Velox 为 0.63 倍。

软件库如何位于框架与芯片之间

类比。 CUDA（第 09 层）好比一间机加工车间，任何人都可以用原钢切削零件；CUDA-X 则是预加工零件的目录。一位做两个矩阵相乘的 PyTorch 用户从不需要编写 GPU 代码：PyTorch 调用 cuBLAS，cuBLAS 再从数百个手工调优的 GPU 内核中，挑出最契合该矩阵形状、数值格式和 GPU 代际的那一个。卷积与注意力（cuDNN）、通信（NCCL）以及推理引擎（TensorRT）也遵循同样的模式。

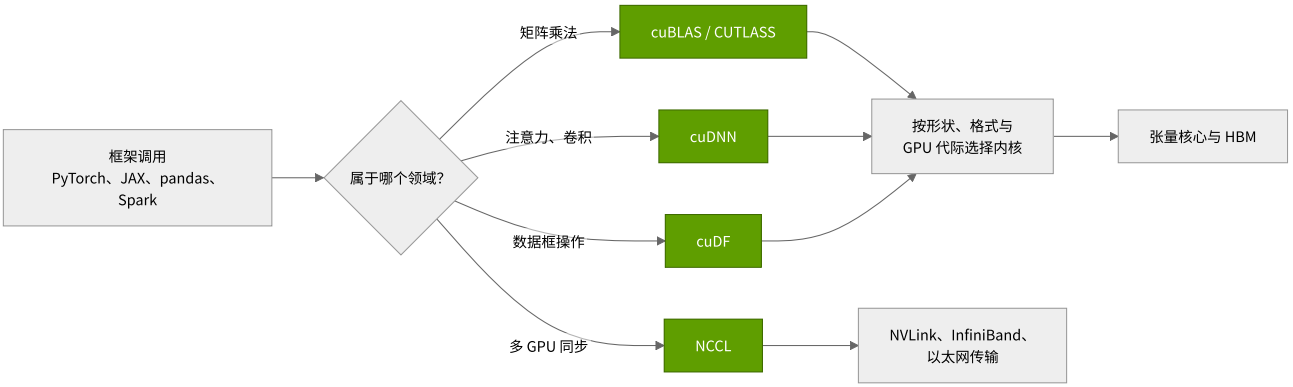

[Q1 · 职能与失效后果] 软件库层的职能是弥合峰值性能与实际交付性能之间的差距。若这一层薄弱，硬件就会闲置（一块内核只能跑到峰值一半的 GPU，在经济意义上就只是半块 GPU），新特性也无从发挥：低精度格式、稀疏性和交换机内规约，都只有在软件库用上之后才能兑现价值。

> **提示**
>
> **算例 —— 11 个百分点的效率值多少钱。** 一个 Llama-3 式的 70B 模型在 15T token 上训练，约需 $6 \times 70\text{B} \times 15\text{T} \approx 6.3 \times 10^{24}$ FLOPs。B200 的稠密 BF16 峰值为 2,250 TFLOPS [S33003]。按 Meta 公布的 Llama 3 405B 峰值达成率（MFU）41% 计算 [S34006]，每块 GPU 实际交付约 920 TFLOPS，整个训练约需 1.9M 个 B200 小时。按英伟达在其 Megatron 1T 基准测试中公布的 52% 计算 [S34002]，则约需 1.5M 个。**结论：**按示意性的每 GPU 小时 $5 计算 [S395]，节省的约 0.4M GPU 小时价值约 $2M。并行方式的选择可解释部分差距；其余大部分则来自调优过的内核与集合通信。

目录一览

软件库	功能（一句话类比）	用户 · 商业意义
cuBLAS（2007）	GPU 的矩阵乘法（GEMM）计算器，即每个 Transformer 内部的算术运算	所有 AI 框架；专有软件 [S10038]
cuDNN（2014）	一本神经网络层的“菜谱”（卷积、注意力、归一化）[S10039]	PyTorch、TensorFlow、JAX；针对每一代张量核心调优
CUTLASS / CuTe（2017；DSL 2025）	一套用于自建矩阵内核的可互换零件；CuTe 描述数据如何分块	编写自定义内核的实验室；CuTe DSL 将其带入 Python；🟡 2026 年 10 月仍处于 beta，已错过“夏末结束 beta”的目标 [S10009]
cuSPARSE（2010）	跳过零元素的矩阵运算	仿真、图分析、推荐模型
cuFFT（2007）	把信号拆分成各个频率分量	成像、地震勘探、雷达、5G/6G 信号处理
cuRAND（2010）	一个快速掷骰器	金融领域的蒙特卡洛风险模型、物理仿真
NCCL（2015）	让每块 GPU 上的模型副本保持同步的“总机”	所有多 GPU 作业；参见 NCCL：隐形黏合剂
TensorRT（2016）	把训练好的模型针对某一款 GPU 进行“收缩包装”的编译器；现已发展到第 11 版 [S10045]	推理服务（第 11 层）
cuDF / RAPIDS（2018）	GPU 上的 pandas；也是 Spark、Polars 和 Dask 后端背后的引擎 [S10011]	数据工程与 ETL

软件库	功能（一句话类比）	用户 · 商业意义
cuML（2018）	GPU 上的 scikit-learn，现可零代码修改运行 S10015	欺诈、客户流失与预测模型；数据科学团队
cuGraph（2019）	面向拥有数十亿条连接的网络的“地图导航”	欺诈团伙识别、网络安全、供应链图谱
cuOpt（2025 年开源）	用于路径规划与线性规划的“调度员”；MIP 处于 beta S10026	物流与计划排程；Apache 2.0，并托管于 COIN-OR S10027
cuQuantum / CUDA-Q（2022–23）	量子计算机的“飞行模拟器”；CUDA-Q 可统一编程 QPU、GPU 与 CPU S10030	量子硬件初创公司与实验室
cuLitho（2023）	预先畸变芯片掩模，使图形能被正确印制（计算光刻）	台积电与新思科技（Synopsys）自 2024 年起用于量产 S10031；这是把 GPU 卖进英伟达自身供应链
NVIDIA Warp（2022）	用纯 Python 编写物理仿真，并将其编译为 GPU 内核 S10028	机器人与仿真研究人员；自 2025 年起采用 Apache 2.0
Parabricks（Clara）	以分钟而非小时运行标准基因组流程（变异检测） S10033	测序实验室、医院、制药企业
BioNeMo	蛋白质与 DNA 模型的训练配方及检查点 S10037	微调生物学基础模型的药物发现团队
Earth-2	装进一个 Python 包（Earth2Studio）里的气象实验室 S10036	气象机构、保险公司、能源交易商
Omniverse / PhysX（PhysX 2008）	一个带有真实物理效果的共享 3D 世界；PhysX 已开源 S10035	工厂与机器人数字孪生；面向 AI 数据中心的 DSX 蓝图 S90063
cuVS（2024）	在数十亿个嵌入向量中找出语义最接近者的“图书管理员”	RAG 与推荐系统背后的向量数据库（Faiss、Milvus） S10025

年份为 `data/l10_library_timeline.csv` 中可核实的首次公开发布年份；来源与注意事项见该文件。

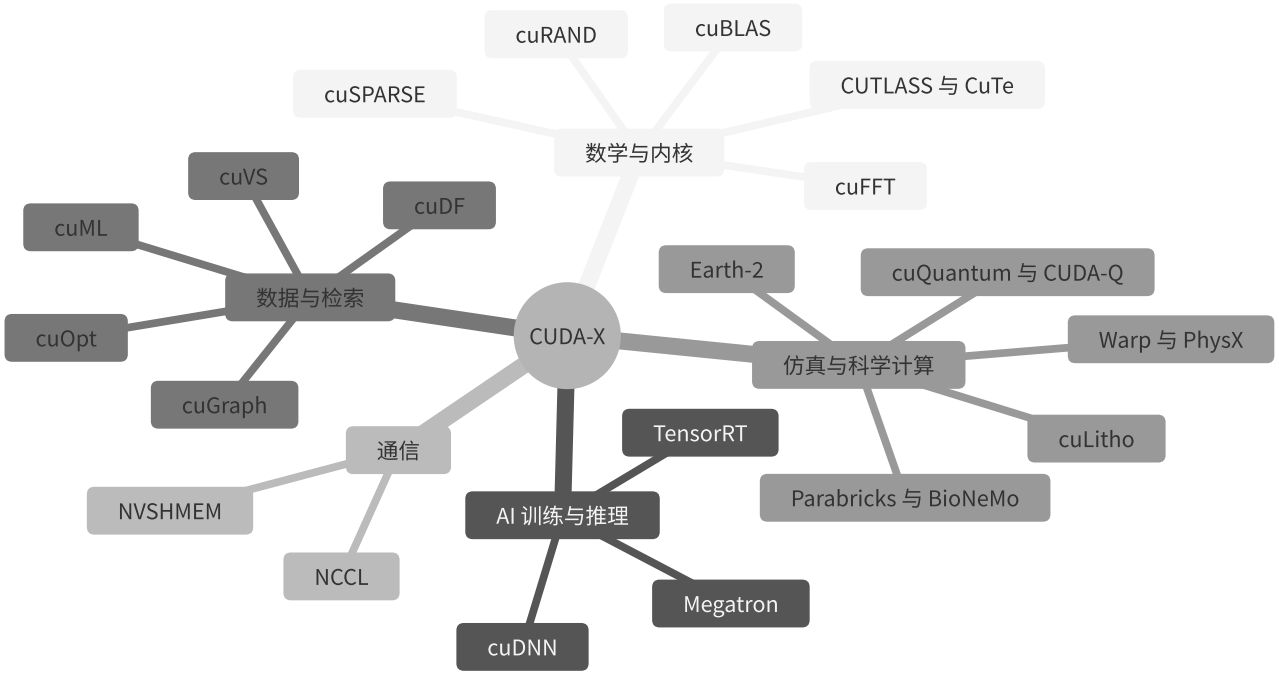

AI 核心：数学、内核与推理

四个软件库承载了几乎全部 AI 运算：cuBLAS 和 cuDNN 提供通用内核，TensorRT 把它们组装成引擎，而 CUTLASS 则是英伟达及外部开发者构建尚不存在的内核的工具。它们决定了客户能以多快的速度用上每一种新数值格式。如今 CUTLASS 覆盖从 FP64 到块缩放 NVFP4、MXFP4、MXFP6 和 MXFP8 的各种格式，支持从 Volta 到 Blackwell 的各代架构 S10009。

提示

算例 —— 为什么在软件库跟上之前，新数值格式一文不值。 Rubin GPU 的标称稠密 FP4 算力为 35 PFLOPS，而稠密 BF16 为 4 PFLOPS [S100]，相差 8.75 倍。以 BF16 提供服务的模型只能用上这颗芯片的 4 PFLOPS。只有当 cuBLAS、CUTLASS 和 TensorRT 推出 FP4 内核、且模型完成量化而不损失精度之后，其余 31 PFLOPS 才变得可用。**结论：**在数值格式层面，软件库是数据手册算力与收入之间的闸门。参见数值格式。

内核还必须针对每一代架构重写。FlashAttention-2 在 A100 上达到峰值的 50–73%，在 H100 上却只有 35%，直到专为 Hopper 设计的 FlashAttention-3 达到 75% [S9002,S9003]。以 CuTe DSL 为 Blackwell 编写的 FlashAttention-4 达到 B200 BF16 峰值的 71%，比英伟达的 cuDNN 9.13 快最多 1.3 倍，比 Triton 快 2.7 倍 [S9004]。英伟达旗舰产品上最快的注意力内核，出自英伟达软件库团队之外，但用的是英伟达的工具。

Attention kernels need a rewrite per GPU: FA2 hit 73% of A100 peak, 35% of H100's

Share of dense 16-bit peak reached by FlashAttention kernels, by GPU (%); FA3 restored 75% on H100 and FA4 reaches 71% on B200

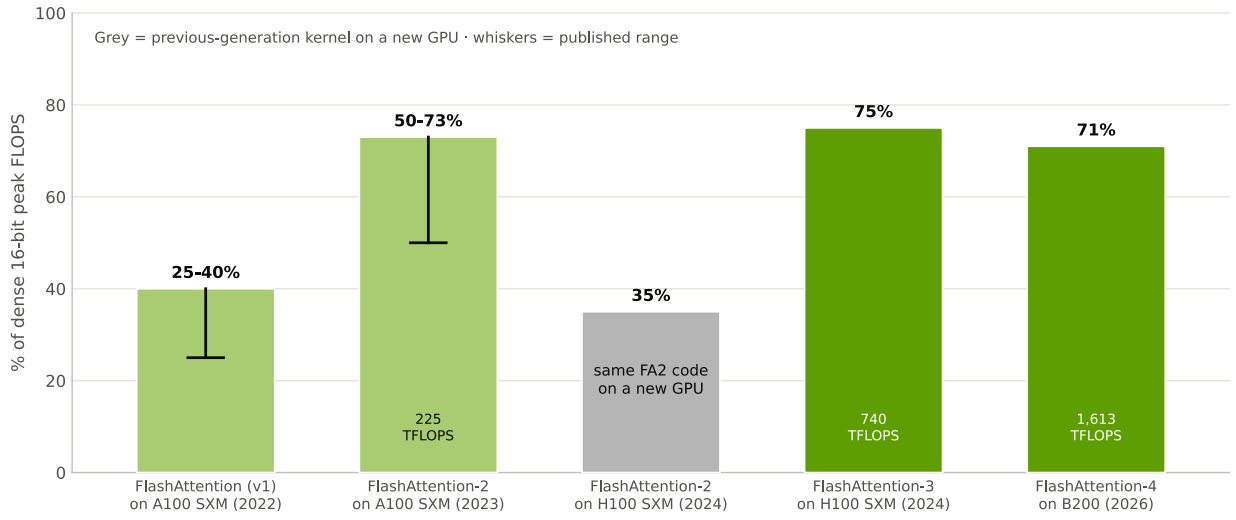

Source: data from FlashAttention papers; GPU datasheets [S9002] [S9001] [S33009] [S9003] [S33002] [S9004] ...; chart by repo · As of 2026-11-05

注意力内核利用率条形图：FlashAttention-1 达到 A100 峰值的 25-40%（2022 年），FlashAttention-2 达到 A100 峰值的 50-73%（2023 年），但同一套 FA2 代码在 H100 上仅达到峰值的 35%，直到专为 Hopper 设计的 FlashAttention-3 达到 75%（740 TFLOPS FP16）；以 CuTe DSL 为 Blackwell 编写的 FlashAttention-4 达到 B200 BF16 峰值的 71%（1,613 TFLOPS），最高可达 Triton 的 2.7 倍。

🔧 技术细节：内核库如何决定运行哪个内核

一次 GEMM 调用带有形状（M、N、K）、数据类型和内存布局。cuBLAS 为每种 GPU 架构保存大量预编译内核（分块大小、流水线深度以及跨 SM 的任务划分各不相同），再由启发式规则或自动调优流程从中选出一个。后续操作（偏置、激活、缩放）可以融合进内核的收尾阶段（epilogue），使结果无需在 HBM 中往返。CUTLASS 以模板形式开放同样的构建模块，CuTe 的布局代数则描述哪个线程负责分块中的哪个元素。CUTLASS 4 的 Python DSL 摒弃了 C++ 模板，并承诺大幅缩短编译时间 [S10009]。竞争性的内核语言（OpenAI 的 Triton、Modular 的 Mojo）以可移植的方式瞄准同一任务。

AI 之外：数据、仿真与科学计算

2018 年以来推出的大多数软件库，瞄准的都是原本运行在 CPU 上的工作负载。方法始终如一：找出吞噬大部分 CPU 时间的热点循环，将其重写为并行 GPU 内核，同时保留用户熟悉的接口。数据加载是 AI 内部的

经典例子。英伟达的 DALI 软件库把 JPEG 解码转移到 DGX-2 的 GPU 上，使 ResNet-50 训练从 GPU 上限的 56% 提升至 93% [S4017]：

CPU-bound data loading left DGX-2's 16 GPUs 44% idle; GPU decoding got 93%

ResNet-50 training throughput on one DGX-2 (16× V100, 48 host CPU cores), images per second

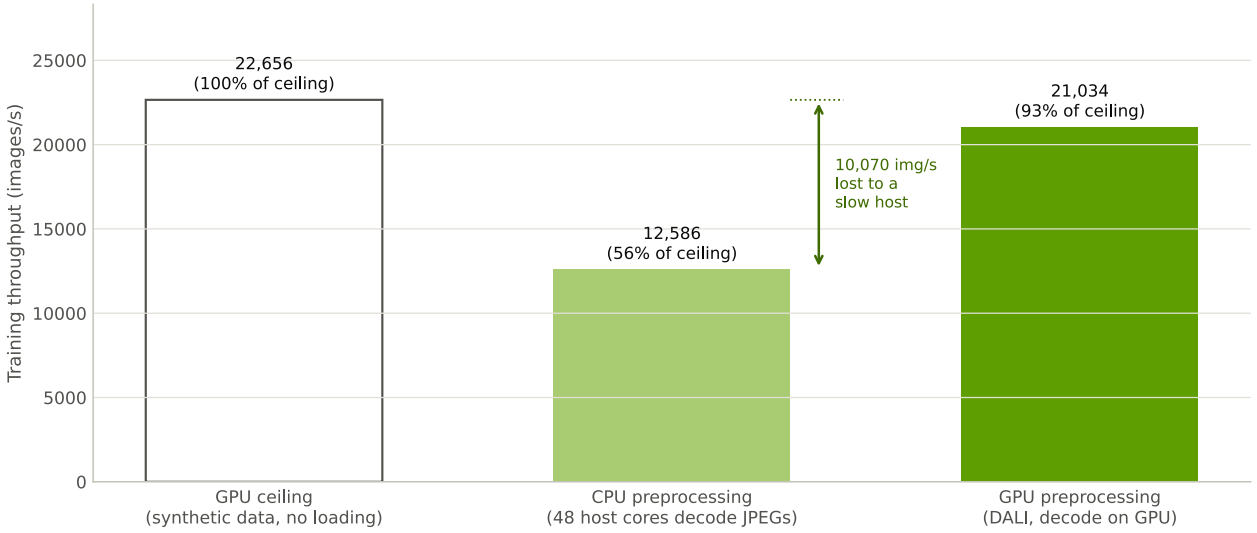

Vendor measurement (NVIDIA)

Source: data from NVIDIA DALI case study; DGX-2 datasheet [S4017] [S313] [S314]; chart by repo · As of 2026-11-05

DGX-2 上 ResNet-50 训练吞吐量条形图：输入合成数据时为每秒 22,656 张图像（GPU 的上限）；使用 48 个主机核心上的标准 CPU 预处理流水线时为 12,586 张（上限的 56%，即 GPU 有 44% 的时间处于闲置）；使用 NVIDIA DALI 将 JPEG 解码与数据增强转移到 GPU 上时为 21,034 张（93%）。

提示

算例 —— cuLitho 的服务器账。 2023 年发布时，英伟达称 500 台 DGX H100 系统即可完成 40,000 台 CPU 系统的光刻计算工作 [S10032]；到 2024 年宣布投入量产时，这一数字变为 350 台 [S10031]。相当于每台 GPU 系统替代约 114 台 CPU 系统。**结论：**cuLitho 让英伟达成为其自身供应商的供应商，而台积电的采用 [S10031] 使其成为所有其他晶圆厂的参照标杆。

注意

误区与事实：“GPU 软件库能让一切快 10–100 倍。” 那些大数字来自厂商对计算密集型内核的测试；独立测试结果更小，有时甚至为负。cuml.accel 的低秩 PCA 只有 0.48 倍，因为数据搬运的开销超过了计算本身 [S10015]。在 BMC 的研究中，GPU 体细胞变异检测工具在云上的成本反而*高于* CPU 运行 [S10033]。Polars 自己的文档也指出，I/O 密集型查询在 GPU 与 CPU 上的运行速度大致相同 [S10017]。

🎯 企业发展视角

1. **哪些软件库家族具备防御性？** 专有的 AI 核心（cuBLAS、cuDNN、TensorRT）是每个竞争对手的首要目标；长尾部分（cuLitho、Parabricks、cuOpt、Earth-2）竞争较少，但服务的市场也较小。
2. **供应商—客户闭环。** cuLitho 在台积电和新思科技的应用 [S10031]，将英伟达 GPU 嵌入了晶圆厂与 EDA 流程。在其他供应链中（EDA 仿真、电信信号处理）是否存在类似的闭环，可供竞争对手抢先布局？
3. **以开源跑马圈地。** cuOpt 以 Apache 2.0 许可加入 COIN-OR [S10027]，Warp 也改用 Apache 2.0 许可 [S10028]。竞争对手能否把这些项目分叉（fork）到自家硬件上，还是会跟不上英伟达的发布节奏？

NCCL：多 GPU AI 的隐形黏合剂

第 10 层 · 软件库（CUDA-X） · 约 12 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **NCCL（读作“nickel”）负责在 GPU 之间搬运数据。** 它在 PCIe、NVLink、NVSwitch、InfiniBand 和 TCP/IP 套接字之上运行全规约（all-reduce）、全收集（all-gather）、规约散射（reduce-scatter）、广播以及发送/接收等通信模式，既可在单台服务器内，也可跨越数千台服务器 S10000。
- **它能感知拓扑。** NCCL 会探测 GPU 与网卡之间的链路，然后依据内置的成本模型选择一种算法（环形、树形、CollNet/SHARP、NVLS、PAT）和一种协议 S10001。
- **交换机内规约是英伟达（NVIDIA）的软硬件优势所在。** 借助 InfiniBand 交换机中的 SHARP 或 NVLink 交换机中的 NVLink SHARP（NVLS），每块 GPU 只需发送约一次数据，而不是约两次。在 GB200 NVL72 上，一次理想化的 70B 梯度全规约耗时从 0.31 s 降至 0.16 s S34011,S200。
- **在大规模场景和推理中，瓶颈是延迟而非带宽。** 按 NCCL 自身的成本模型，环形算法的固定延迟在 2,048 个节点时达到约 11 ms，而树形算法约为 0.12 ms S10001。在下文的解码（decode）算例中，小规模全规约占每个 token（词元）耗时的约 14%。
- **NCCL 迭代迅速：** 从 2.13（2022 年 7 月）到 2.32（2026 年 9 月），50 个月内发布了 19 个次版本，新增了对称内存内核与 GPU 发起式网络通信 S10038,S10007。
- **代码是开源的，竞争对手也在用。** NCCL 的源代码带有 Apache-2.0 许可标记 S10000。AMD 的 RCCL 基于 NCCL 的代码构建并沿用其 API S10002；微软（Microsoft）的 MSCCL++ 称在小消息上可达 NCCL 速度的 2.8 倍（🟡 厂商基准测试） S10004。真正难以复制的是它与英伟达交换机的协同设计。

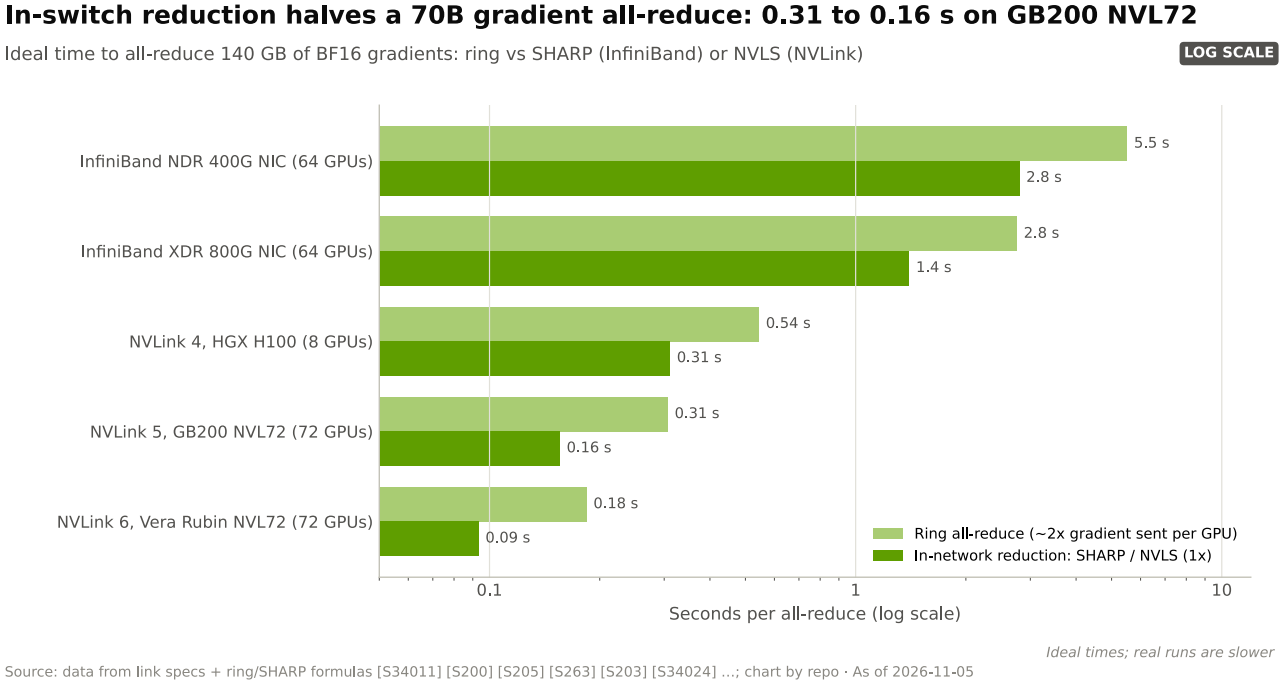

对 140 GB BF16 梯度执行全规约的理想耗时分组水平条形图。环形与网络内规约对比：400G InfiniBand 5.5 s 对 2.8 s；800G InfiniBand 2.8 s 对 1.4 s；8 块 H100 上的 NVLink 4 为 0.54 s 对 0.31 s；GB200 NVL72 上的 NVLink 5 为 0.31 s 对 0.16 s；Vera Rubin NVL72 上的 NVLink 6 为 0.18 s 对 0.09 s。由交换机执行加法后，每块 GPU 发送的数据量从约 2 倍梯度降至 1 倍，因此网络内规约最多可快约 2 倍。

NCCL 做什么

类比。 想象一场有 72 位厨师参加的百家宴。在全规约（all-reduce）中，每人带来一道菜，离开时都带走汇总后的整桌饭菜（数据并行梯度）。在全收集（all-gather）中，每人离开时都带走每道菜的一份副本（分片权重）。在规约散射（reduce-scatter）中，每位厨师离开时带走一道做好的菜。全交换（all-to-all）则像邮件分拣：每位厨师都要把不同的东西分别送给其他每位厨师，就像混合专家模型中 token 被分发给各自专家那样。入门篇 P4 将每种并行策略与其对应的集合通信一一对应。下图说明了各自数据量为何相差如此之大：

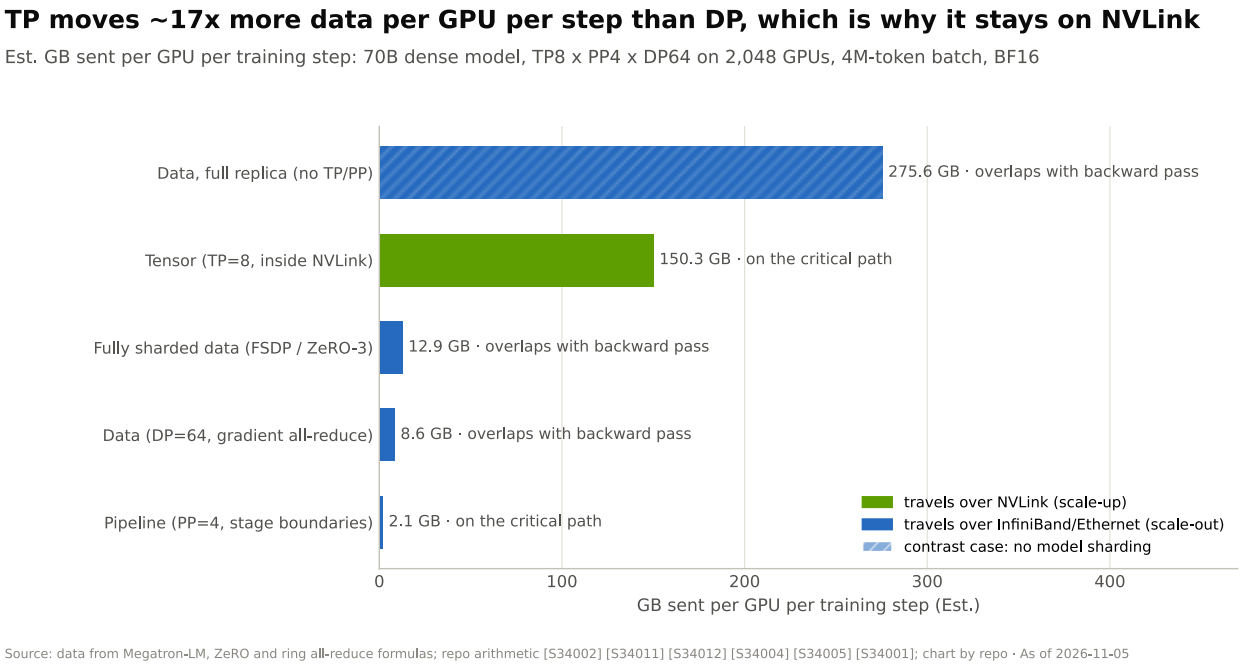

> 一个 700 亿参数模型按 8 路张量并行、4 路流水线并行和 64 路数据并行切分时，每块 GPU 每个训练步估算发送数据量的水平条形图：张量并行约 150 GB，数据并行梯度全规约约 8.6 GB，全分片数据并行约 12.9 GB，流水线发送约 2.1 GB；作为对比，每块 GPU 保存完整模型副本的普通数据并行约需发送 276 GB。

拓扑感知。 启动时，NCCL 会绘制出哪些 GPU 共享同一台 NVLink 交换机、哪块网卡（NIC）离每块 GPU 最近，以及共有多少条网络轨道（rail）。它构建多条并行的环和树（即“通道”），使每条链路同时承载流量，并针对每种算法和协议，以“延迟 + 字节数 ÷ 带宽”为每次调用估算代价。代价最低者胜出[S10001]。

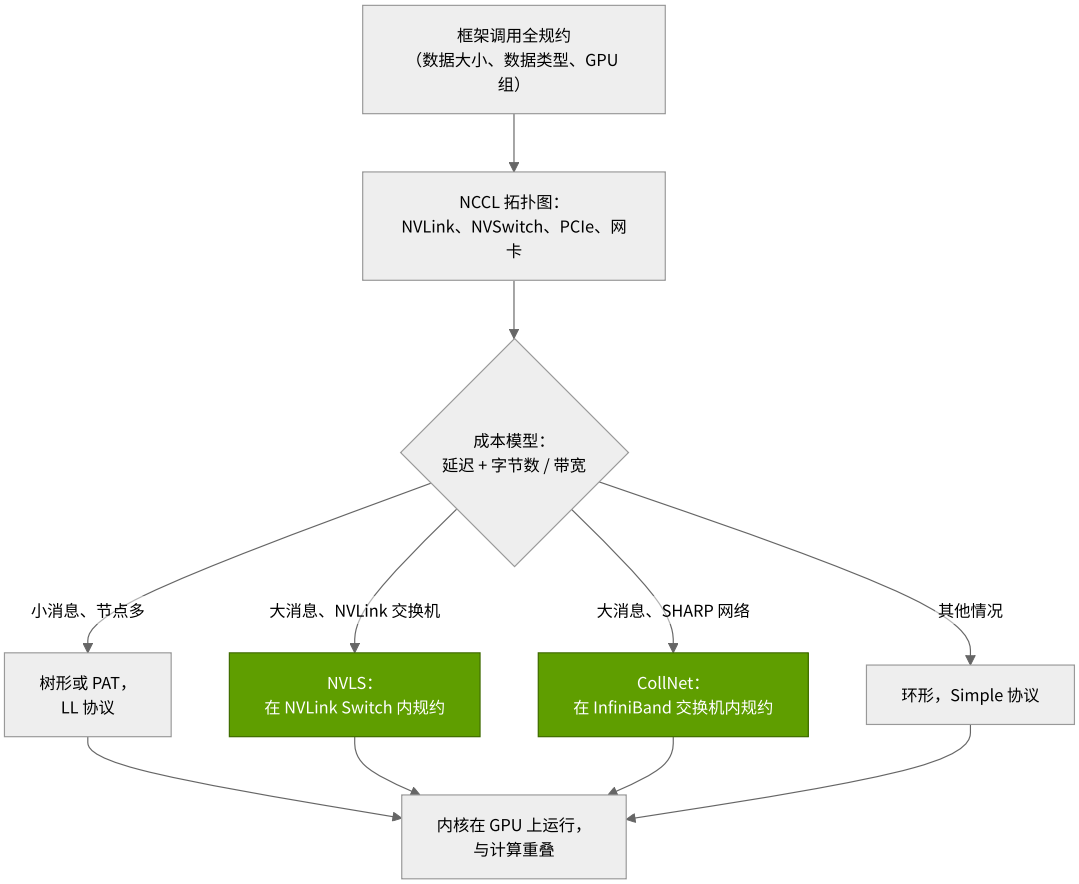

提示

算例 —— 为什么推理中的全规约受限于延迟。 在一台 NVLink 5 服务器上，以 8 路张量并行部署一个 70B 模型（80 层，隐藏维度 8,192）。Megatron 式张量并行在每次前向传播中每层需要两次全规约 [S34001]。为 64 位用户的批次解码一个 token 时，每条消息为 64 × 8,192 × 2 字节 ≈ 1 MB。环形算法的带宽项为 1.75 × 1 MB ÷ 900 GB/s ≈ 2 µs [S200]。按 NCCL 在 NVLink 上 LL 协议的默认常数，其延迟项为 6.6 + 14 × 0.6 ≈ 15 µs [S10001]。因此每次全规约约 17 µs，其中近 90% 是固定延迟。每个 token 需要 160 次全规约，合计约 2.7 ms，在每用户 50 tokens/s（每 token 20 ms）的速度下约占 14%。**结论：**对于推理，NCCL 的微秒级延迟比其 GB/s 带宽更重要，这正是 NCCL 2.27 推出低延迟对称内存内核的原因 [S10044]。

环形、树形与交换机内规约

算法	工作原理	每块 GPU 发送的数据量	延迟随什么增长	最适用于
环形（Ring）	数据块沿环路传递，途中累加，然后再循环传回 [S34011]	约为消息的 2 倍	GPU 数量（2(N−1) 跳）	大消息、中等规模
树形（Tree）	沿树向上求和，再向下广播；NCCL 使用两棵互补的树 [S10041]	约为消息的 2 倍	log2(N)	大规模下的小消息
CollNet / SHARP	由 InfiniBand 交换机在传输途中累加数据 [S34024]	约 1 倍	交换机跳数	支持 SHARP 网络的大型集群
NVLS	NVLink Switch 在纵向扩展域内执行规约与多播 [S10042]	约 1 倍	基本恒定（模型中约 25 µs） [S10001]	NVL8 或 NVL72 域内的大消息
PAT	用于全收集与规约散射的对数级调度（NCCL 2.23） [S10043]	与环形相同	log2(N)	每 GPU 分片很小的超大型作业

第一张图展示带宽一侧（网络内规约使每块 GPU 的发送量减半），第二张图展示延迟一侧（环形算法的延迟随节点数增加而增长）。

SHARP halves the data each GPU sends per all-reduce: 1× the message vs ~2× for a ring

Bytes each GPU sends per all-reduce ÷ message size, by number of GPUs (bandwidth term only)

LOG SCALE

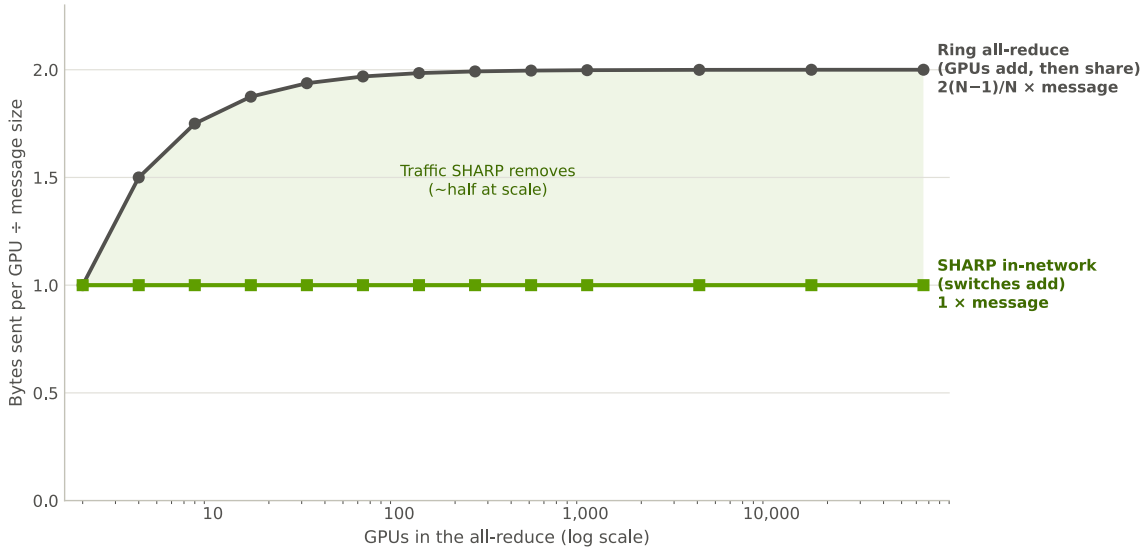

Source: data from Patarasuk & Yuan (ring all-reduce); NCCL docs; NVIDIA SHARP docs [S34011] [S34012] [S34024] [S6015]; chart by repo · As of 2026-11-05

折线图：采用环形全规约时，每块 GPU 发送消息量的 2(N-1)/N 倍，8 块 GPU 时为 1.75 倍，数万块 GPU 时接近 2.0 倍；采用 SHARP 网络内规约时，由于交换机完成加法运算，每块 GPU 只需发送一次数据（1.0 倍），因此受带宽限制的全规约最多可提速约 2 倍。英伟达报告在 HDR InfiniBand 上全规约带宽提升约 2 倍。

Ring latency grows with every node: ~11 ms at 2,048 nodes vs ~0.12 ms for a tree

Latency term of one all-reduce across N nodes, from NCCL's default tuner constants (no bandwidth term)

LOG SCALE

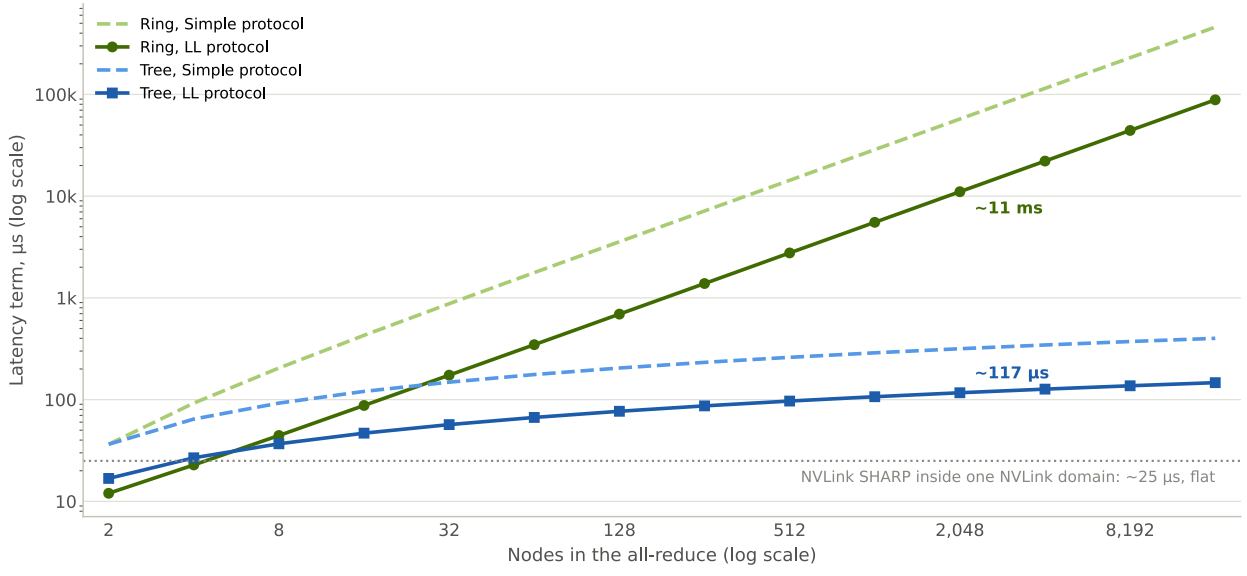

Simplified: one GPU per node

Source: data from NCCL source, default tuner constants [S10001]; chart by repo · As of 2026-11-05

全规约延迟项与节点数关系的双对数折线图，基于 NCCL 默认调优常数绘制。环形算法需经过 2(N-1) 次网络跳转：2,048 个节点时，低延迟 LL 协议约 11 ms，Simple 协议约 57 ms。树形算法需经过 2 log2(N) 次跳转：约 117 微秒（LL）和 316 微秒（Simple）。在单个 NVLink 域内，NVLink SHARP 的延迟项基本恒定，约 25 微秒。这就是 NCCL 按消息大小和规模切换算法的原因。

提示

算例 —— 一次 70B 梯度全规约：环形对比 NVLink SHARP。 70B 参数 × 2 字节（BF16）= 140 GB 梯度。*在 GB200 NVL72 上采用环形算法：*每块 GPU 需以单向 900 GB/s（NVLink 5）[S200] 发送 2 × 71/72 × 140 ≈ 276 GB，耗时 **0.31 s**。*在同一机架上采用 NVLS：*每块 GPU 只需发送一次 140 GB，由交换机返回求和结果，耗时 140 ÷ 900 = **0.16 s**。在 800 Gb/s InfiniBand（100 GB/s）上跨 64 块 GPU，同样的对比为 2.8 s 对比使用 SHARP 后的 1.4 s [S251]。**结论：**交换机内规约的价值约相当于一条快 2 倍的链路，且无需额外的网卡或交换机端口。实际运行会更慢，大部分开销会被反向传播掩盖，且通信量会被分片（FSDP）（P4）。

🔧 **技术细节：协议、通道与设备端 API**

- **协议。** *LL*（低延迟）为每 4 字节附加一个标志位，使接收方无需额外同步即可轮询：延迟最低，带宽约为一半。*LL128* 以每 128 字节为单位做同样的事；*Simple* 则使用大缓冲区和内存栅栏（fence）以获得峰值带宽 [S10001]。
- **通道。** 一条消息被拆分到多个环或树上，每个环或树由各自的线程块驱动，以填满每条 NVLink 和每条网卡轨道。
- **总线带宽。** 对于全规约，nccl-tests 报告的总线带宽 = 算法带宽 × 2(N−1)/N，从而使结果可与链路速度直接比较 [S34012]。
- **设备端 API（2.28）。** 内核自行发起通信：通过 NVLink 执行 load/store，通过 NVLink SHARP 执行 multimem 操作，并通过 InfiniBand/RoCE 进行 GPU 发起式网络通信（GIN）。它面向混合专家模型（MoE）的分发场景，因为在这类场景中 CPU 往返的代价过高 [S10007,S10008]。

为什么 NCCL 性能成了事实上的基准

[Q2 · 关键指标] 对集群买家而言，两个 NCCL 数字就能概括整个网络：大消息下的全规约总线带宽，以及小消息下的延迟。云厂商及其客户在验收集群前都会运行 `nccl-tests`。一份公开的验证指南将配备 NVLink 与 400G InfiniBand 的 H100 节点的全规约总线带宽目标定为约 400–450 GB/s [S10022]。每个主流框架都通过 NCCL 或其 API 克隆访问网络，因此这些结果可直接映射为训练时间；而英伟达既拥有这个软件库，也拥有衡量它所用的硬件。

[Q3 · 代际进步] NCCL 一直紧跟硬件路线图：2.19（2023 年 10 月）支持 NVLink SHARP [S10042]，🟡 2.23 引入 PAT [S10043]，2.27 推出对称内存内核 [S10044]（博客日期凭记忆给出，未重新查证），2.28 推出带有 GPU 发起式网络通信的设备端 API [S10008]：

NCCL shipped 19 minor versions in 50 months, from 2.13 (Jul 2022) to 2.32 (Sep 2026)

NCCL minor version by first PyPI wheel upload (any CUDA variant), with selected feature milestones

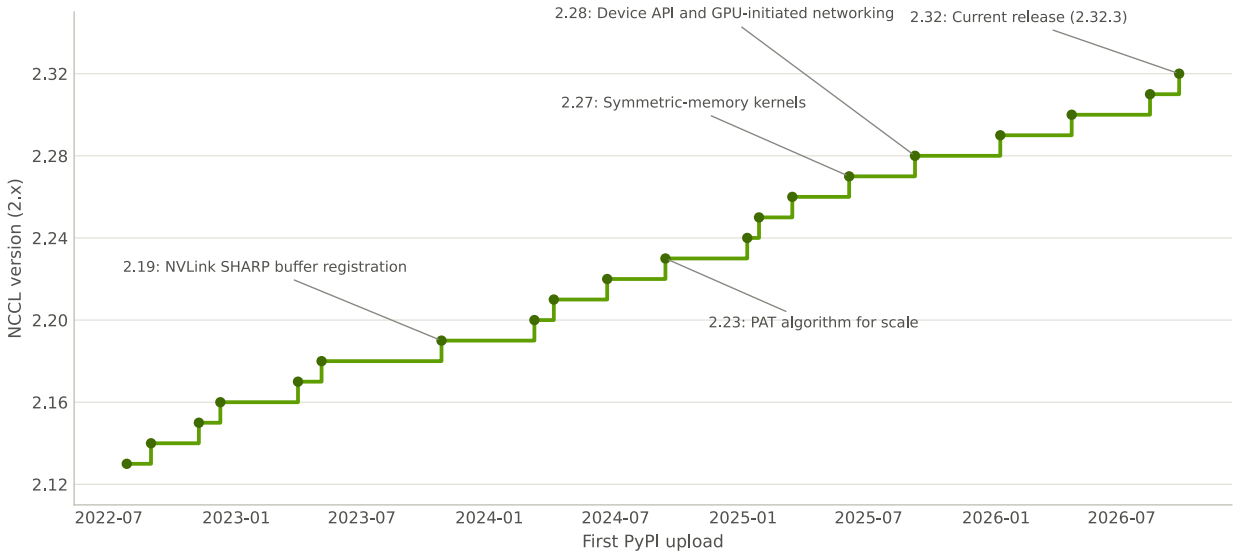

Source: data from PyPI nvidia-nccl wheels; NCCL docs [S10038] [S10042] [S10043] [S10044] [S10008] [S10007] …; chart by repo · As of 2026-11-05

基于 PyPI 发布历史的 NCCL 次版本随时间变化的阶梯图：从 2022 年 7 月的 2.13 到 2026 年 9 月的 2.32，50 个月内发布 19 个次版本，约每 2.6 个月一个。里程碑：2.19 支持 NVLink SHARP 缓冲区注册（2023 年 10 月），2.23 引入 PAT 扩展算法（2024 年 9 月），2.27 推出对称内存低延迟内核（2025 年 6 月），2.28 推出带有 GPU 发起式网络通信的设备端 API（2025 年 9 月）。

替代方案

软件库	所有者	是什么	与 NCCL 相比的结论
RCCL	AMD	面向 Instinct GPU 的集合通信库：环形与树形，可选 MSCCL++ 路径；LICENSE 文件注明使用了英伟达代码 S10002	🟨 有意采用相同 API；针对 AMD 的链路调优，未列出交换机内规约
MSCCL++	微软	面向英伟达和 AMD GPU、用于构建自定义集合通信的 GPU 驱动单边原语 S10003；称比 NCCL 快最高 2.8 倍（小消息）和 2.4 倍（大消息） S10004	🟦 用于自定义算法的工具包；在小消息上最强
Gloo	Meta（PyTorch）	基于 TCP 的集合通信，主要面向 CPU 张量 S10006	🟥 并非 GPU 速度层面的对手；只是后备方案
MPI / UCC	开放标准 / UCF 联盟	HPC 消息传递；UCC 优先使用硬件集合通信 S10005；NCCL 可在 MPI 程序内运行 S10000	🟦 在 HPC 中心形成互补
谷歌 ICI 集合通信	谷歌（Google）	由 XLA 在 TPU 环面拓扑上调度集合通信，每个 v4 pod 含 4,096 颗芯片 S236,S237	🟦 由编译器调度，与 TPU 绑定
DeepEP	DeepSeek	开源 MoE 全交换内核：在 H800 上，NVLink 节点内约 153 GB/s，经 RDMA 约 43–58 GB/s S5005	🟦 与 NCCL 并行使用的专用工具

注

🐂 **看多观点：** NCCL 是开源的，但其最佳路径（NVLS、CollNet/SHARP、GPU 发起式网络通信）都需要英伟达的交换机和网卡，因此每次发布都会抬高竞争对手的硬件门槛 S10001,S10007。

注意

🐻 **看空观点：** 集合通信是一个已被充分研究的问题。RCCL 已在复用 NCCL 的代码与 API S10002，MSCCL++ 报告其性能超过 NCCL S10004，DeepSeek 也自行编写了 MoE 内核 S5005。开放的纵向扩展（scale-up）互连架构（UALink、ESUN）为竞争对手提供了可瞄准的硬件。如果集合通信库变得可互换，NCCL 的护城河就会收缩到英伟达的交换机本身。参见竞争格局。

🎯 企业发展视角

1. **API 就是标准。** RCCL 沿用了 NCCL 的接口 S10002。新的加速器在第一天就需要一个兼容 NCCL 的软件库：自建、授权，还是采用 MSCCL++ 或 UCC?
2. **网络内计算才是具备防御性的部分。** 软件库代码是开源的 S10000；价值在于能对数据执行规约的交换芯片（NVLink Switch、Quantum、Spectrum-X）。哪些商用交换芯片厂商能为 UALink 或 ESUN 网络提供同等的规约能力？参见第 06 层。
3. **推理把衡量指标转向微秒。** 小消息延迟如今与带宽同等重要，因此拥有低延迟集合通信 IP（MoE 分发内核、GPU 发起式网络通信）的团队，是潜在的收购式招聘（acquihire）标的。
4. **高通视角的问题（仅基于公开信息）：** AI300 被描述为采用 UALink 和 ESUN 纵向扩展 S90060。哪个集合通信库将运行在这一互连架构上？它是否需要交换机内规约，才能在 70B 级全规约上具备竞争力?

软件库广度为何产生复利

第 10 层 · 软件库（CUDA-X） · 约 11 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **每个软件库都把又一类工作负载变成 GPU 的活。** 在本资料库样本中 2018 年以来推出的 18 个软件库里，有 12 个瞄准 AI 模型以外的市场（见下图）。
- **Spark 的例子表明，成本优势胜过速度优势。** 在 AWS 运行的一项基于 TPC-DS 衍生负载的 1 TB 测试中，英伟达（NVIDIA）面向 Apache Spark 的 cuDF 插件仅比原生 Spark 快 1.06 倍，且慢于向量化 CPU 引擎；但作业成本仍下降约 80%，从 $31.28 降至 $6.27 [S10020]。🟡 据第三方的会议回顾，FINRA 报告 GPU Spark 运行速度快 14 倍、节省 90% [S10021]。
- **需求如今来自 AI 之外。** 客户包括台积电（TSMC）（cuLitho 已投入量产）[S10031]、Meta（Faiss 内置 cuVS）[S10025]、基因组学实验室（一项同行评审研究中 Parabricks 最高提速 65 倍）[S10033]，以及物流规划方（cuOpt，已与 COIN-OR 一同开源）[S10027]。
- **集成胜于发明。** pandas、scikit-learn、Polars、Spark 和 Faiss 的用户如今无需重写代码即可切换到 GPU [S10013,S10015,S10017,S10019,S10025]。CPU 回退机制消除了采用风险。
- **英伟达自己公布的数字先升后停。** GPU 加速应用从 2,000 个（2021 年）增至 3,000 个（2023 年）[S537,S533]，英伟达如今称其拥有“数以百计”的 CUDA-X 软件库 [S10047]，但开发者数量自 2025 年以来一直持平于约 6M [S528]。
- **看空情景：** 广度只能在边际上增加需求；推动收入的是 AI 算力，而在 AI 之外，GPU 能否胜出取决于价格与工作负载形态（I/O 密集型查询获益甚微）[S10017]。

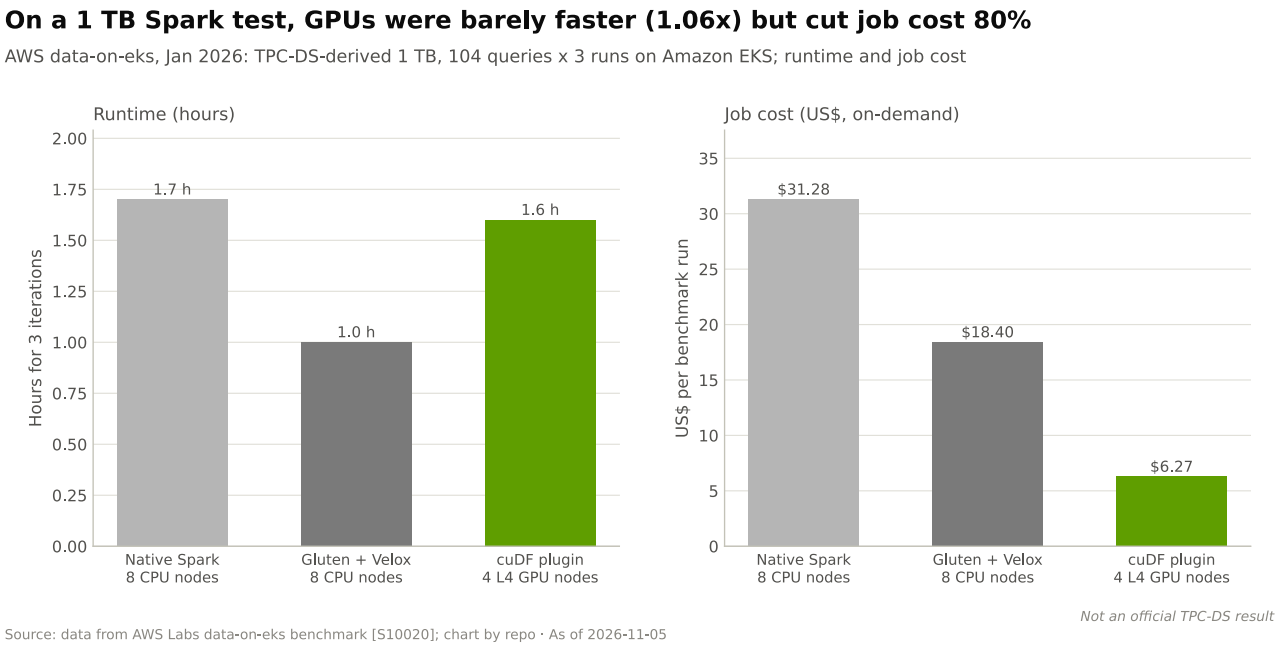

AWS 运行的 Spark 基准测试（TPC-DS 衍生负载，1 TB）双面板条形图。运行时间：8 个 c5d.12xlarge CPU 节点上的原生 Spark 为 1.7 小时，Gluten 加 Velox 向量化 CPU 为 1.0 小时，4 个各配一块 L4 GPU 的 g6.2xlarge 节点上运行英伟达 cuDF 插件为 1.6 小时。作业成本：$31.28、$18.40 和 $6.27。GPU 运行仅比原生 Spark 快 1.06 倍，且慢于 Velox，但比原生 Spark 便宜约 80%，比 Velox 便宜 66%。

复利循环

一个软件库创造出购买 GPU 的新理由，而每卖出一块 GPU，又扩大了下一个软件库可以瞄准的用户基础：

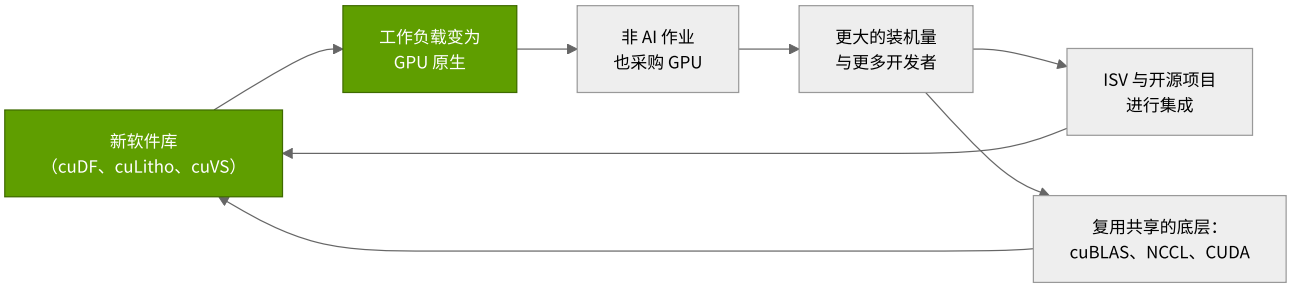

由于新软件库复用旧软件库，这一循环的成本会随时间降低：cuDF 的核心采用符合 Apache Arrow 规范的数据框（dataframe）结构，并为 Spark、Polars、Dask、Velox 和 DuckDB 扩展提供底层引擎 [S10011]。而每一次集成，都让英伟达进入一个其用户从未直接选择过英伟达的框架之中。

> **提示**
>
> **算例 —— 把 Spark ETL 作业变成 GPU 作业对账单有何影响。** 在 AWS 2026 年 1 月的测试中，8 个每小时 $2.30 的 c5d.12xlarge CPU 节点需要 1.7 小时（$31.28），才能在 1 TB 数据上完成 104 个查询 × 3 轮运行。4 个各配一块 L4 GPU、每小时 $0.98 的 g6.2xlarge 节点则需要 1.6 小时（$6.27）[S10020]。一个每天运行该流水线 30 次（每月 900 次）的团队，在 CPU 上每月需支付约 $28,200，在 GPU 上约 $5,600。每月节省约 $22,500，并将约 5,800 实例小时的工作转移到英伟达 GPU 上。**结论：**在 ETL 中，GPU 胜在单作业成本而非速度。向量化 CPU 引擎（Gluten + Velox）是三者中最快的 [S10020]，因此 GPU 的优势取决于 GPU 的小时价格。

AI 之外的需求

[Q1 · 职能与失效后果] 在 AI 之外，软件库层的职能是赢得从未买过 GPU 的买家；一个比现有 CPU 工具更慢或更贵的软件库，无论硬件多好都会失败。

领域	软件库	公开证据	谁买单
数据分析	面向 Spark 的 cuDF 插件、cudf.pandas、Polars GPU 引擎	Spark 作业便宜约 5 倍 [S10020]；Polars PDS-H 查询最高快 13 倍（厂商数据）[S10018]	ETL 开支庞大的企业
向量检索	cuVS	索引构建比 CPU HNSW 快 12.3 倍（Meta）[S10025]	搜索、RAG 与推荐团队
优化	cuOpt	LP、QP 与路径规划；MIP 仍处于 beta [S10026]	物流、能源与供应链规划方
光刻	cuLitho	曲线掩模流程上约 45 倍；350 台 H100 系统替代 40,000 台 CPU 系统 [S10031]	晶圆代工厂与 EDA 厂商
基因组学	Parabricks	胚系变异检测最高 65 倍（同行评审）[S10033]；在 Terra 上最高 24 倍 [S10034]	测序中心、医院、制药企业
气候	Earth-2（Earth2Studio）	面向 AI 气象模型的开源 Python 包 [S10036]	气象机构、保险公司、能源交易商
量子计算	cuQuantum、CUDA-Q	仿真软件库与 QPU-GPU 混合平台 [S10029,S10030]	量子硬件公司与实验室
仿真	Warp、PhysX、Omniverse	基于 Python 和 C++ 的开源物理引擎 [S10028,S10035]	机器人、工业数字孪生

提示

算例 —— 为什么在基因组学中速度不是采购标准。 BMC Bioinformatics 的研究将 GATK HaplotypeCaller 的运行时间从 CPU 上的 36 小时缩短到 DGX 上的 24 分钟，以及 AWS 或 GCP GPU 实例上的 33–35 分钟 [S10033]。同一研究也发现，云 GPU 上的体细胞变异检测工具即便更快，成本也高于 CPU 运行 [S10033]。**结论：**领域软件库要胜出，必须降低单样本成本（胚系变异检测），而不仅仅是缩短单样本耗时（体细胞变异检测）。

嵌入他人的框架

自 2023 年起，英伟达基本不再要求数据科学家学习新的 API，而是拦截他们已经在用的 API。cudf.pandas 支持“100% 的 pandas API”：受支持的操作在 GPU 上运行，其余则回退到普通 pandas [S10013]。同样的代理模式如今已覆盖 scikit-learn、Polars、Spark 和 Faiss。英伟达称之为零代码修改加速。

框架	底层的英伟达引擎	所需代码修改	推出时间	证据显示
pandas	cudf.pandas	无：`%load_ext cudf.pandas`	2023 年公开 beta，2024 年正式发布 [S10014]	约 150 倍（英伟达）；独立测试 50–70 倍 [S10046]
scikit-learn、UMAP、HDBSCAN	cuml.accel	无：`python -m cuml.accel`	cuML 25.04，2025 年 [S10016]	scikit-learn 示例库可完整运行；中位数约 5.8 倍 [S10015]
Polars	cudf-polars	`pip install polars[gpu]`，设置 GPU 引擎标志	2024 年公开 beta [S10018]	在连接（join）与聚合上占优 [S10017]
Apache Spark	面向 Spark 的 cuDF 插件	集群配置	2020 年（以 RAPIDS Accelerator 名义）[S10019]	在 AWS 的测试中快 1.06 倍，便宜约 5 倍 [S10020]
Faiss	cuVS 后端	选择 cuVS 索引	Faiss 1.10，2025 年 [S10025]	IVF 构建比 Faiss 旧版 GPU 代码快 4.7 倍 [S10025]
Velox、DuckDB（Sirius）	cuDF	引擎扩展	2026 年列入 cuDF README [S10011]	未找到独立基准测试

提示

算例 —— 零代码修改在何处达到盈亏平衡。 cuML 自己的基准测试固定一个 61,035 × 4,096 的矩阵，改变 PCA 的输出秩。取 128 个主成分时，GPU 耗时 2.97 s，而 CPU 为 1.42 s（0.48 倍）。取 512 个时为 1.12 倍，取 1,024 个主成分时为 2.62 倍 [S10015]。**结论：**小作业会输给数据搬运的开销。零代码修改工具让 GPU 成为一项免费的期权：用户先做性能剖析，保留占优的部分，其余回退即可。

🔧 技术细节：“零代码修改”如何实现

加速器在 `import pandas`（或 `sklearn`）之前加载，并安装模仿原始类的代理对象。当操作、数据类型和参数均受支持时，每次调用都交给 GPU 软件库处理，否则交给 CPU 软件库，并按需搬运数据 [S10013,S10015]。代价是隐藏的数据传输以及偶尔出现的行为差异，这也是 cuML 为每个估计器记录回退条件并提供性能剖析工具的原因 [S10015]。Polars 走的是另一条路：其查询规划器把整个优化后的执行计划交给 GPU 引擎，而 GPU 引擎会预先拒绝不受支持的计划 [S10017]。

CUDA-X 的数量如何增长

[Q3 · 代际进步] 英伟达并未发布口径可比的软件库数量序列。2022 年，它称有 550 个“SDK 和 AI 模型”，把软件库与模型混在一起 [S532]；它还曾在一届 GTC 上宣布了 60 项 CUDA-X 软件库更新 [S530]。如今它的说法

是“数以百计的软件库” S10047。因此，本资料库根据更新日志、PyPI 和新闻稿，对 29 个主要软件库和五项集成的样本进行了年份考证（`data/l10_library_timeline.csv`）。

18 of 29 major CUDA-X libraries arrived since 2018; 12 serve data, science or quantum

Cumulative count of a dated sample of major NVIDIA libraries, by domain; diamonds = zero-code-change framework integrations

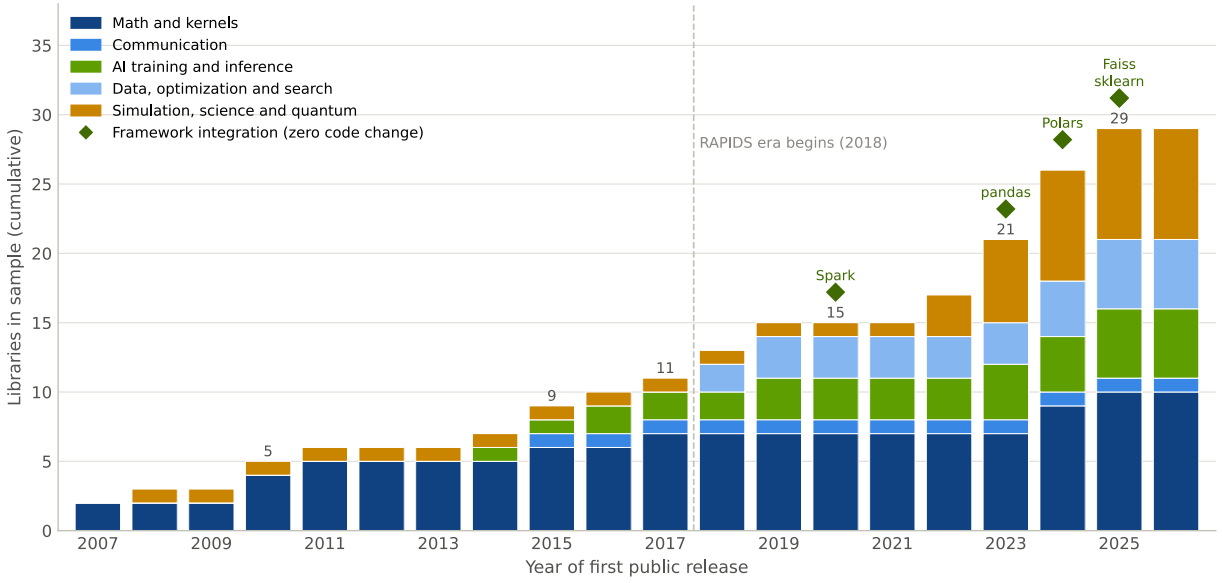

Source: data from changelogs, PyPI, CUDA archive, press [S525] [S484] [S10035] [S10039] [S10000] [S10040] …; chart by repo · As of 2026-11-05

按首次公开发布年份统计的 29 个主要 CUDA-X 软件库样本的堆叠阶梯图。2007 至 2017 年出现 11 个（cuBLAS、cuFFT、cuSPARSE、cuRAND、cuDNN、NCCL、TensorRT、CUTLASS 等），2018 至 2025 年出现 18 个，其中 12 个面向数据分析、优化、向量检索、仿真、光刻、气候或量子计算，而非 AI 模型。2020 至 2025 年间出现了 5 项零代码修改集成（Spark、pandas、Polars、scikit-learn、Faiss）。英伟达自称拥有数以百计的软件库；此处为经年份考证的样本。

提示

算例 —— 解读样本。 样本从 2007 年的 2 个软件库（cuBLAS、cuFFT）增长到 2017 年的 11 个，再到 2025 年的 29 个。2018 年之前，11 个中有 10 个是数学、AI 或通信软件库；2018 年以来，18 个中有 12 个（67%）服务于其他市场。**结论：**英伟达的软件库投入已从“让 GPU 可用”转向“让 GPU 在新行业中不可或缺”，而公布的注册开发者基数仍维持在约 6M S528。

CUDA developers tripled from 2M (2020) to ~6M, then NVIDIA's count went flat

Registered CUDA developers as cited by NVIDIA in keynotes, blogs and earnings calls, millions

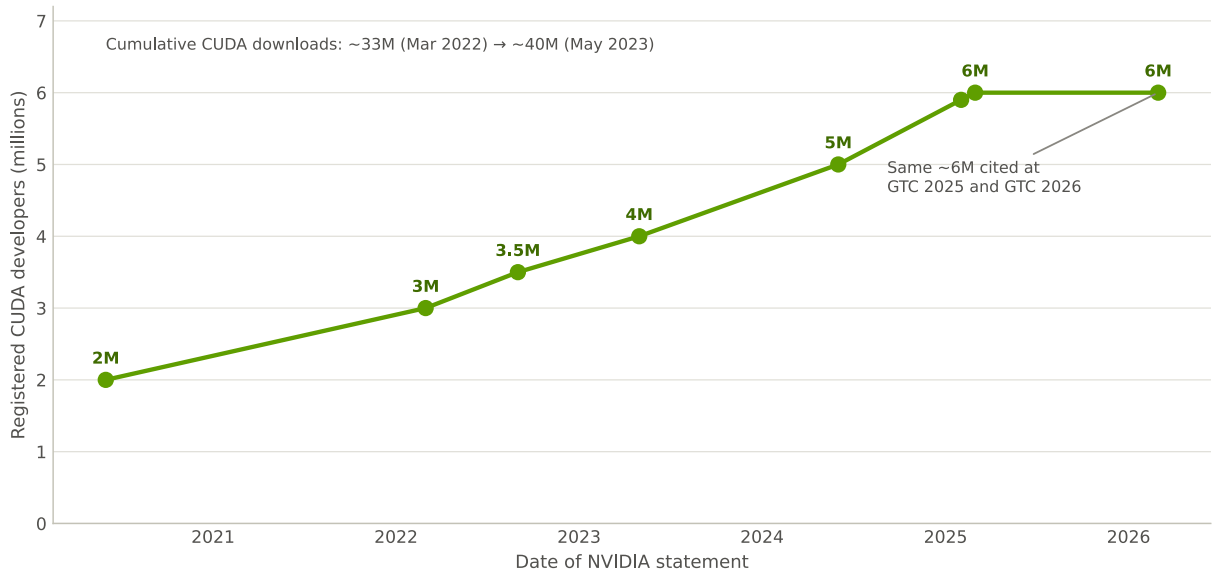

Source: data from NVIDIA keynotes, blogs and earnings calls [S529] [S530] [S531] [S532] [S533] [S534] ...; chart by repo · As of 2026-11-05

英伟达公布的 CUDA 开发者数量折线图：2020 年 200 万，2022 年初 300 万，2023 年年中 400 万，2024 年年中 500 万，2025 年 3 月约 600 万，2026 年 3 月再次引用的仍是约 600 万；截至 2023 年 CUDA 累计下载量约 4,000 万次。

注

🐂 **看多观点：**相对于其所撬动的 GPU 需求，每个软件库的成本都很低；竞争对手必须在数十个领域追平英伟达；而光刻、基因组学和数据分析的预算并不跟随 AI 支出周期波动。

注意

🐻 **看空观点：**与 AI 相比，非 AI 领域规模很小，而 AI 贡献了数据中心业务的大部分收入（FY2026 英伟达 $215.9B 收入中数据中心占 $193.7B）[S402,S401]（参见第 13 层）。在唯一一项独立的 Spark 测试中，搭配 Velox 的 CPU 反而更快 [S10020]。挑战者可以忽略长尾，只需在主导 LLM 推理服务的少数内核上胜出即可。参见竞争格局。

🎯 企业发展视角

1. **非 AI 需求作为对冲。** ETL、光刻和基因组学软件库把 GPU 需求与 AI 资本开支之外的预算绑定在一起。这部分需求有多大？英伟达是否有任何披露能量化它？
2. **集成伙伴是“造王者”。** 框架所有者（Faiss 背后的 Meta、Polars 团队、Spark 平台、AWS EMR）决定了用户默认使用哪种加速器；这些合作关系可能比软件库数量更重要。
3. **单作业成本是竞争对手的突破口。** AWS 的测试显示 GPU 胜在价格而非速度 [S10020]。一款更便宜、配有类 NCCL 和类 cuDF 软件栈的加速器可以在同一指标上竞争，但前提是它能提供零代码修改集成。
4. **高通视角的问题（仅基于公开信息）：**与开放数据引擎（Velox、DuckDB、Polars）合作，是否会比逐个自建领域软件库更便宜地切入非 AI 数据中心工作负载？

软件库（CUDA-X）：竞争格局

第 10 层 · 软件库（CUDA-X） · 约 12 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **在本资料库对比矩阵的 15 个软件库领域中，没有任何竞争对手在任一领域领先英伟达（NVIDIA）；** AMD 和英特尔（Intel）各在 3 个领域达到持平，且都集中在数学运算、DNN 原语或集合通信 S586,S10509,S10557,S10554。
- **[Q5 · 最强挑战者] AMD 的 ROCm。** 其策略是通过软件移植（port）复制英伟达的接口，且已缩短了复制滞后：在 ROCm 6.4（2025 年 4 月）中，RCCL 落后 NCCL 296 天；到 ROCm 7.1（2025 年 10 月）时只落后 98 天 S10509,S10506,S586。
- **谷歌（Google）的挑战并非更小，而是路线不同：** XLA 编译整个模型而不是调用软件库，Pallas 则取代了 CUTLASS 式内核；在 15 个领域中，谷歌有 12 个走的是不同路线 S10543,S578。
- **广度差距位于 AI 训练之外。** 只有英伟达在优化（cuOpt）、光刻（cuLitho）、基因组学（Parabricks）和图分析（cuGraph）领域提供自研 GPU 软件库 S10026,S10031,S10047。
- **英伟达的弱点：开放降低了切换成本。** NCCL（自 2026 年 2 月起）和 cuOpt 均采用 Apache 2.0 许可，因此移植版可以跟进每一次发布；而 ROCm 上的 vLLM 默认使用 AMD 自己的 AITER 内核 S10507,S10026,S10514。
- **竞争格局正在开放：** 华为正在开源 CANN（2025 年 8 月宣布）；据报道，AMD 于 2026 年 10 月以指导委员会成员身份加入了 oneAPI 标准组织（UXL）🟡 S10537,S10542。

No rival leads NVIDIA in any of 15 library domains; AMD matches it in 3

First-party accelerated libraries by domain and vendor, Nov 2026; cell = repo verdict letter + library (NVIDIA = reference)

	NVIDIA (reference)	AMD	Intel	Google	AWS	Huawei
Dense math (BLAS/GEMM)	**cuBLAS / cuBLASLt**	**P · rocBLAS / hipBLASLt**	**P · oneMKL / oneMath**	D · XLA (compiler)	D · Neuron compiler + NKI	B · CANN ops (aclnn)
DNN primitives	**cuDNN**	B · MIOpen (+AITER)	**P · oneDNN**	D · XLA fusion	D · Neuron compiler	B · CANN AOL
Kernel templates and DSLs	**CUTLASS / CuTe DSL**	B · Composable Kernel	B · SYCL, Triton XPU	D · Pallas (JAX)	D · NKI + NKI Library	B · Ascend C, triton-ascend
Collectives	**NCCL**	**P · RCCL (NCCL port)**	B · oneCCL	D · XLA + ICI	D · Neuron CC (NxD)	B · HCCL
Inference engine	**TensorRT-LLM, Dynamo**	B · vLLM/SGLang + AITER	B · OpenVINO	D · vLLM-TPU, llm-d	B · vLLM Neuron (beta)	B · vllm-ascend
Dataframes and ETL	**cuDF, Spark RAPIDS**	B · hipDF (RAPIDS fork)	B · no GPU dataframe lib	D · BigQuery (service)	B · none in Neuron SDK	B · none found
Classical ML	**cuML**	B · no cuML port (GA)	D · oneDAL (CPU)	D · BigQuery ML	B · none in Neuron SDK	B · none found
Graph analytics	**cuGraph**	B · hipGRAPH (early access)	B · none on GPU	B · no TPU graph library	D · Neptune (service)	B · none found
Optimization (LP/MIP/routing)	**cuOpt (Apache 2.0)**	B · none found	B · none found	D · OR-Tools (CPU)	B · none found	B · none found
FFT / sparse / solvers	**cuFFT, cuSPARSE**	**P · rocFFT, rocSPARSE**	**P · oneMKL**	B · XLA FFT only	B · none found	B · limited
Quantum simulation	**cuQuantum, CUDA-Q**	B · none first-party	B · none on GPU	D · qsim/Cirq + own QPUs	D · Braket (service)	B · none found
Computational lithography	**cuLitho**	B · none found	B · none found	B · none found	B · none found	B · none found
Genomics	**Parabricks**	B · none first-party	B · none on GPU	D · DeepVariant (model)	D · HealthOmics (service)	B · none found
Simulation and physics-ML	**Warp, PhysicsNeMo**	B · no first-party lib	B · no first-party lib	D · Brax (JAX)	B · none found	B · none found
Vector search	**cuVS (CAGRA)**	B · hipVS (port)	B · no GPU library	D · ScaNN (CPU)	D · OpenSearch (service)	B · none found

NVIDIA library (reference) · L = rival leads NVIDIA · P = parity · B = rival behind · D = different approach

Verdicts are analyst judgement (speculative)

Source: data from vendor library documentation; repo verdicts [S10047] [S525] [S586] [S90064] [S10557] [S10540] …; chart by repo · As of 2026-11-05

> 15 个软件库领域（行）对比英伟达、AMD、英特尔、谷歌、AWS 和华为（列）的热力图。没有任何竞争对手在任一领域领先英伟达。AMD 在 3 个领域达到持平（基于 rocBLAS/hipBLASLt 的稠密数学运算、基于 RCCL 的集合通信、FFT/稀疏计算），英特尔也在 3 个领域持平（oneMKL、oneDNN、FFT/稀疏计算）；谷歌在 12 个领域、AWS 在 8 个领域采取基于编译器或服务的不同路线；华为在全部 15 个领域落后。只有英伟达在优化（cuOpt）、计算光刻（cuLitho）、基因组学（Parabricks）和图分析（cuGraph）领域拥有自研 GPU 软件库。

与软件库目录竞争的三种方式

软件库是一盒预先调优的 GPU 例程。PyTorch 这样的框架决定*算什么*；软件库则决定*如何*在某一款特定芯片上算得快（参见 CUDA-X 目录）。竞争对手选择了以下三种策略之一：

1. **移植（AMD，部分包括华为）。** 在兼容接口之下重新实现英伟达的软件库，就像翻唱乐队演奏同一份曲目单：HIP 对应 CUDA，RCCL 对应 NCCL（其许可证注明包含英伟达贡献的代码），hipDF 则是 cuDF 的分叉版本 S10002,S10511。
2. **编译（谷歌、AWS）。** 绕开大多数软件库：由编译器（XLA、Neuron 编译器）为每个模型生成内核，其余部分由专家在 Pallas 或 AWS 的 NKI 中手工调优 S10543,S10539。
3. **标准化（英特尔）。** 发布一项开放规范（oneAPI，现归属 UXL 基金会），寄望于他人采用 S10540,S10541。

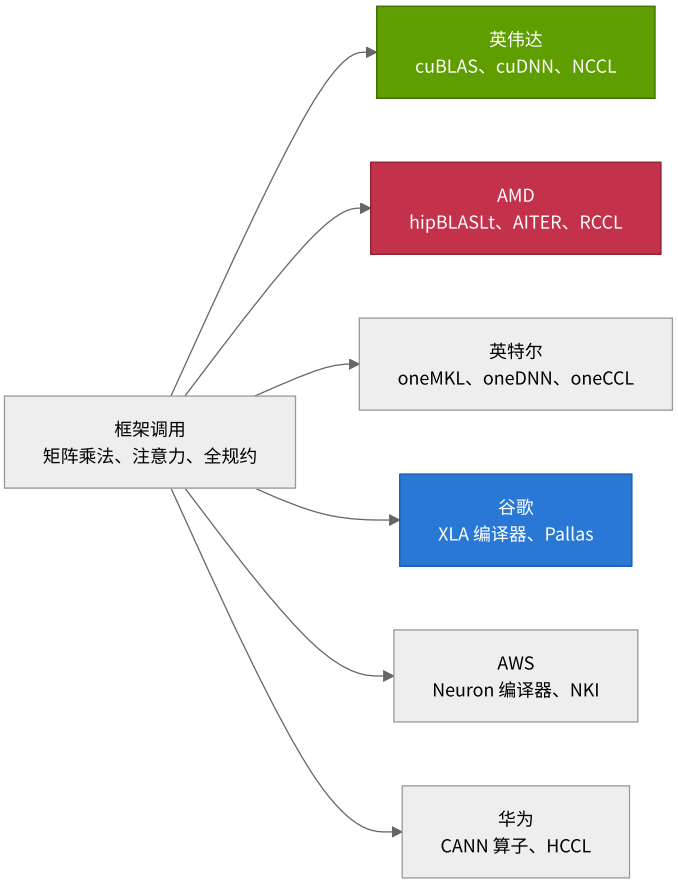

移植能让客户的代码继续运行，但会让移植方永远处于追随者地位。编译路线可以避免追随，但只在厂商掌控整个技术栈（TPU、Trainium）时才行得通。

提示

算例 —— 移植滞后的代价。 RCCL 2.22.3 于 2025-04-11 随 ROCm 6.4.0 发布，比英伟达标记 NCCL 2.22.3（2024-06-19）晚了 296 天；而那时 NCCL 已更新到 2.26 [S10509,S10506,S586]。由于两家厂商都按年度节奏推出 GPU，约 10 个月的滞后意味着 AMD 客户得到一项集合通信功能时，大约晚了一代 GPU。到 ROCm 7.1.0（2025-10-30）时，相对 NCCL 2.27.7 的滞后缩短至 98 天，约一个季度。

AMD's NCCL port now trails by ~3 months, down from ~10; hipDF trails cuDF ~8 months

Days from NVIDIA's release of a version to AMD shipping the matching port (RCCL in ROCm; hipDF in ROCm-DS)

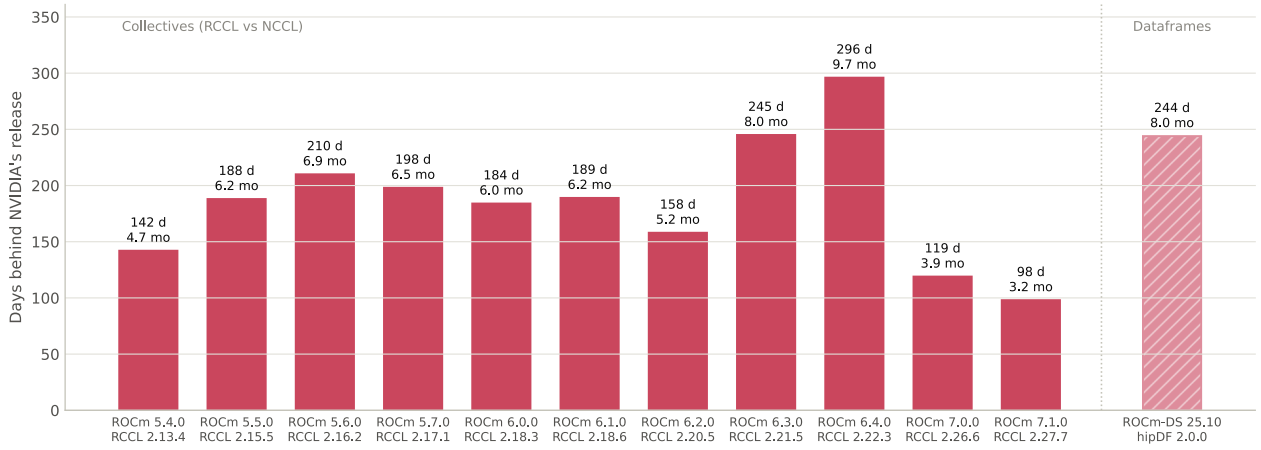

Hatched = month-precision date

Source: data from NCCL tags, RCCL changelog, ROCm and RAPIDS release notes [S10509] [S586] [S10511] [S10506] [S10507] [S10510]; chart by repo · As of 2026-11-05

AMD 移植软件库落后英伟达原版时长的条形图。RCCL 是 AMD 对 NCCL 的移植版，从 ROCm 5.4（2022 年）到 7.1（2025 年）的各个版本中，其兼容 NCCL 的版本分别在英伟达对应 NCCL 标签发布后 142、188、210、198、184、189、158、245、296、119、98 天推出：滞后在 ROCm 6.4.0 时达到 296 天的峰值，在 ROCm 7.1.0 时降至 98 天。hipDF 2.0.0（ROCm-DS 25.10）与 cuDF 25.02 的 API 对齐，落后约 244 天，即 8 个月。

🔧 技术细节：为什么移植会滞后，而编译器不会

移植版必须先匹配 NCCL 或 cuDF 的接口，再针对不同硬件重新调优每一个例程（用 xGMI 链路代替 NVLink，用 64 宽的 wavefront 代替 32 线程的 warp，矩阵单元形状也不同）。RCCL 保留了 NCCL 的 `nccl*` 函数名，因此框架无需修改即可调用；但每个 NCCL 版本都必须先合并、重新调优并重新验证，才能随下一个 ROCm 版本发布 [S10002,S10509]。以编译器为先的技术栈没有可供复制的上游；相应地，新型模型在编译器学会处理之前可能运行缓慢，因此需要 Pallas 来手写内核 [S578]。

覆盖矩阵

评级均从各竞争对手的角度、相对英伟达的软件库给出（🟩 领先 · 🟨 持平 · 🟥 落后 · 🟦 路线不同）。“未找到”指截至 2026-11-05 未出现在该厂商的软件库索引中。

领域	英伟达（参照）	AMD	英特尔	谷歌	AWS	华为
稠密数学运算（GEMM）	cuBLAS、cuBLASLt	🟨 rocBLAS、hipBLASLt	🟨 oneMKL	🟦 XLA 编译器	🟦 Neuron + NKI	🟥 CANN 算子
DNN 原语	cuDNN	🟥 MIOpen（+AITER）	🟨 oneDNN（x86）	🟦 XLA 融合	🟦 Neuron 编译器	🟥 CANN 算子
内核模板	CUTLASS、CuTe DSL	🟥 Composable Kernel	🟥 SYCL、Triton XPU	🟦 Pallas	🟦 NKI Library	🟥 Ascend C
集合通信	NCCL	🟨 RCCL（移植版）	🟥 oneCCL	🟦 基于 ICI 的 XLA	🟦 Neuron CC	🟥 HCCL
推理引擎	TensorRT-LLM、Dynamo	🟥 vLLM/SGLang + AITER	🟥 OpenVINO	🟦 vLLM-TPU、llm-d	🟥 vLLM Neuron（beta）	🟥 vllm-ascend
数据框 / ETL	cuDF、Spark 插件	🟥 hipDF（分叉）	🟥 GPU 上无	🟦 BigQuery	🟥 无	🟥 未找到
经典机器学习	cuML	🟥 无移植版	🟦 oneDAL（CPU）	🟦 BigQuery ML	🟥 无	🟥 未找到
图分析	cuGraph	🟥 hipGRAPH（早期）	🟥 无	🟥 无	🟦 Neptune	🟥 未找到

领域	英伟达（参照）	AMD	英特尔	谷歌	AWS	华为
优化	cuOpt	🟥 无	🟥 无	🟦 OR-Tools（CPU）	🟥 无	🟥 未找到
FFT / 稀疏 / 求解器	cuFFT、cuSPARSE	🟨 rocFFT、rocSPARSE	🟨 oneMKL	🟥 仅 XLA FFT	🟥 无	🟥 有限
量子仿真	cuQuantum、CUDA-Q	🟥 无	🟥 无	🟦 qsim + 自有 QPU	🟦 Braket	🟥 未找到
光刻	cuLitho	🟥 无	🟥 无	🟥 无	🟥 无	🟥 未找到
基因组学	Parabricks	🟥 无	🟥 无	🟦 DeepVariant	🟦 HealthOmics	🟥 未找到
仿真、物理机器学习	Warp、PhysicsNeMo	🟥 无自研软件库	🟥 无自研软件库	🟦 Brax（JAX）	🟥 无	🟥 未找到
向量检索	cuVS	🟥 hipVS（移植版）	🟥 GPU 上无	🟦 ScaNN（CPU）	🟦 OpenSearch	🟥 未找到

各单元格来源见 `data/l10_library_coverage.csv`：S10047,S586,S10511,S10512,S10514,S10540,S10557,S10543,S10539,S10538,S10570。所有竞争对手评级均为本资料库判断（🔴）。

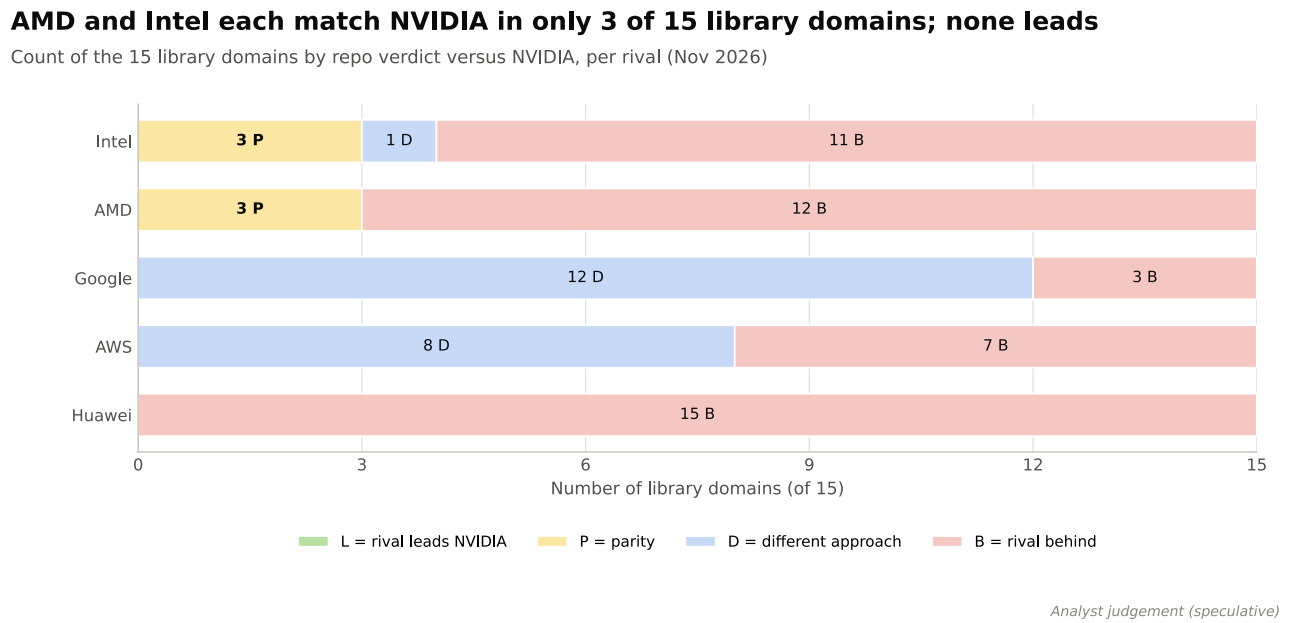

堆叠条形图，统计每个竞争对手在 15 个加速软件库领域中领先、持平、路线不同或落后于英伟达的领域数量。AMD：3 个持平，12 个落后。英特尔：3 个持平，1 个路线不同，11 个落后。谷歌：12 个路线不同（编译器或托管服务），3 个落后。AWS：8 个路线不同，7 个落后。华为：15 个落后。没有任何竞争对手在任一领域领先。

提示

算例 —— 如何解读 🟦。 英伟达的 NVLink 域是一台 Vera Rubin NVL72 中的 72 块 GPU；而一个 TPU Ironwood 超级集群（superpod）通过 ICI 连接 9,216 颗芯片 S90009,S547。在 TPU 上，XLA 在编译模型时插入全规约（all-reduce），因此根本没有 NCCL 需要移植：从 GPU 迁移过来的团队需要改写的是分片配置，而不是软件库调用。纵向扩展（scale-up）规模大 128 倍（9,216 ÷ 72），但团队需要放弃英伟达的软件库生态，这就是“路线不同”不等于“落后”的原因。

逐一审视挑战者

AMD ROCm：最强挑战者

ROCm 7.0（2025 年 9 月）新增了 AITER 算子以及 FP4/FP6 格式；ROCm 10.0 于 2026 年 8 月接踵而至[S90064,S586]。ROCm-DS 是 AMD 对 RAPIDS 的分叉版本，于 2025 年 10 月正式发布，其中 hipDF 与 cuDF 25.02 的 API 对齐；hipGRAPH 到 2026 年 3 月仍处于早期访问阶段[S10511,S10512]。AMD 通过收购软件团队来加快进度：Mipsology 和 Nod.ai（2023 年）、Silo AI（$665M，2024 年）以及 Brium（2025 年）[S10529,S10530,S10531,S10532]。SemiAnalysis 在 2024 年 12 月曾提出严厉批评，到 2025 年 4 月则看到了新的紧迫感，但仍认为 AMD 给 AI 软件工程师的薪酬偏低[S10536,S10535]。

最有力的论据：AI 支出集中在少数几类运算上（GEMM、注意力、集合通信），而前沿实验室无论如何都会自己编写内核；3 个领域的持平，加上对 vLLM 和 SGLang 的一流支持，覆盖了大部分加速器支出[S580,S582]。**已缩小的差距：**集合通信缩小到约 3 个月；数据框约 8 个月；分离式推理服务（disaggregated serving）和 KV 分层存储在 2025 年仍有滞后（分析师观点）[S10570]；15 个领域中仍有 12 个落后。CUDA 与 ROCm 的平台层面对比，参见第 09 层竞争格局。

> **提示**
>
> **算例 —— AMD 的追赶预算。** AMD 的研发支出从 $5.0B（2022 年）增至 $6.5B（2024 年），每年增加 $1.45B，仅 Silo AI 一项就花费 $665M[S450,S10531]。若研发增量的三分之一投向软件（本资料库假设 🔴），每年可提供约 $0.5B，按每人 $0.4M 计约可供养 1,200 名工程师：接近本资料库对一个 AI 核心软件库栈所需约 1,500 名工程师的估计（发展历程）。资金是有的；悬而未决的是，这笔钱买到的是广度，还是只有 AI 核心。

谷歌：编译，而非调用

TPU 从来不需要 CUDA-X 的对应物。XLA 负责算子融合并调度集合通信；Pallas 覆盖自定义内核；PyTorch/XLA 正被一个原生的 TorchTPU 栈取代，后者于 2026 年 10 月与 Meta 共同开源[S10543,S578,S553,S595]。**最有力的论据：**编译器无需为每个领域配备软件库团队即可适配新模型。**差距：**在 AI 之外，谷歌销售的是服务（BigQuery）而非软件库，因此无法把非 AI 工作负载拉到商用硬件上[S10552]。参见 CS3。

英特尔：一个寻找 GPU 的开放标准

oneMKL 和 oneDNN 已经成熟；oneDNN 被 PyTorch、TensorFlow、ONNX Runtime 和 OpenVINO 采用，2026 版 oneAPI 仍包含 oneMKL、oneDAL、oneDNN、MPI 和 oneCCL[S10542,S10540,S10554]。oneMKL 2026.0 还移除了大部分旧版稀疏 BLAS API[S10557]。**最有力的论据：**一项厂商中立的标准；据报道，AMD 已以指导委员会成员身份加入 UXL，并支持将 oneDNN 作为 PyTorch 在 x86 上的默认后端（单一二手来源）🟡[S10542]。**差距：**英特尔的数据中心加速器产品单薄，因此 oneAPI 的 GPU 软件库鲜有大规模部署。

AWS 与华为：垂直技术栈

AWS 将其 Neuron 编译器与预置内核的 NKI Library 以及负责集合通信的 NeuronX Distributed 搭配使用；其 vLLM 插件仍标注为 beta[S10539,S594,S581]。华为的 CANN 承载了算子库与 HCCL；torch_npu、MindSpeed 和 triton-ascend 将昇腾（Ascend）与开放框架相连，CANN 也正在开源[S10538,S592,S10537]。

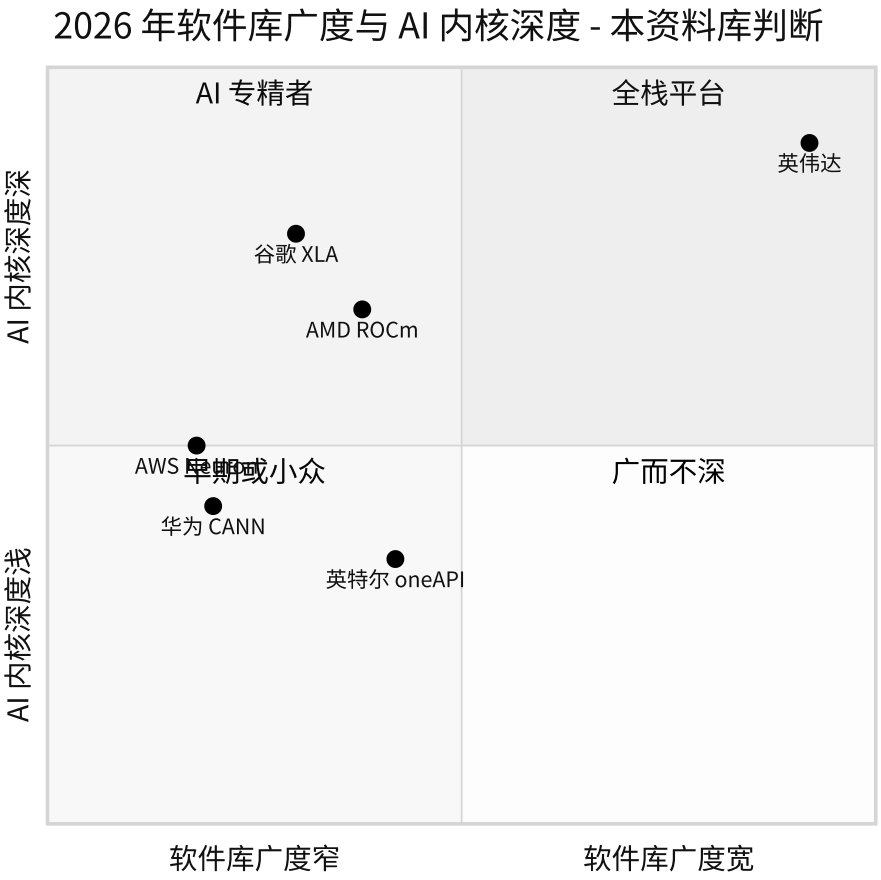

> **注**
>
> 🐂 **看多观点**。广度会产生复利：每一个非 AI 领域（Spark、光刻、基因组学、优化）都会把 GPU 拉进 AMD 和谷歌够不着的预算中，而英伟达能在芯片推出后数周内就发布 Rubin 软件库（参见发展历程）。

> **注意**
>
> 🐻 **看空观点**。资金集中在 3–4 个 AI 领域，而 AMD 在这些领域已经持平或接近持平；开放引擎（vLLM、SGLang、Triton）如今代替用户选择内核。每一个 NCCL 或 cuOpt 版本都采用 Apache 2.0 许可，可在一个季度内被移植，因此软件库护城河正收窄至长尾领域。

[Q5 · 最强挑战者] AMD ROCm，因为它攻击的是资金所在的领域（数学运算、集合通信、推理），且已将跟进滞后缩短到约一个季度；从长期看，谷歌的编译器路线对软件库*存在必要性*的威胁更大，但仅限于谷歌自家的芯片。

🎯 企业发展视角

1. 15 个领域中仅 3 个持平看似薄弱，但这 3 个领域占据了大部分 AI 加速器支出。对于推理领域的新进入者（例如高通（Qualcomm）的 AI200/AI250，基于公开信息），哪些领域必须在第一天就达到持平，哪些可以借助 vLLM 等开放引擎 [S90028,S596]?
2. AMD 的移植滞后已从约 10 个月降至约 3 个月。如果滞后接近于零（共享同一上游），英伟达的软件库溢价会受到什么影响?
3. 高通宣布的 Modular 交易，是一场与谷歌类似的编译路线押注 [S90057]。可移植编译器能否免去逐个领域追平 CUDA-X 的需要，还是只对 AI 内核有效?

4. 光刻、优化和基因组学领域没有第二供应商。它们更适合作为与 ISV 合作的目标，而非自建目标吗?
5. 如果 AMD 加入 UXL 的报道得到证实，oneAPI 是否会成为新进入者可以加入、而无需自建的中立标准?

软件库（CUDA-X）：发展历程与英伟达的构建方式

第 10 层 · 软件库（CUDA-X） · 约 11 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **软件库从第一天起就随 CUDA 一同发布：**CUDA 1.0（2007 年 6 月）即包含 cuBLAS 和 cuFFT [S525]。此后每当出现新的工作负载，英伟达（NVIDIA）就会增加一个软件库：cuDNN（2014 年）、NCCL（2016 年 4 月起上线 GitHub）、CUTLASS（2017 年 12 月）和 RAPIDS（2018 年 10 月）[S10039,S10506,S10010,S10517]。
- **“CUDA-X”是 2019 年才推出的品牌**，而英伟达的计数口径不断变化：2022 年称“550 个 SDK 和 AI 模型”，2025 年 10 月称约 350 个软件库 [S10502,S532,S10501]。
- **开放程度几经摇摆。** NCCL 2 自 2017 年起仅以二进制形式发布，直到 v2.3.5（2018 年 9 月），并于 2026 年 2 月改用 Apache 2.0；cuOpt 于 2025 年改用 Apache 2.0 [S10506,S10507,S10027]。
- **[Q4 · 优势来源]** 持续执行了二十年的软硬件协同设计：CUTLASS 在每款新数据中心 GPU 首次批量出货后 24–71 天内即提供支持，而 Rubin 在同一天获得了 CUTLASS 和 NCCL 的支持 [S10010,S10507]。
- **[Q6 · 复制成本]** 估计：构建一个 AI 核心软件库栈约需 $3B、约 1,500 名工程师和约 5 年；覆盖英伟达的全部广度则需约 10 年、约 $16B 🔴。真正的约束是时间和专业人才，而非资金 [S401,S10535]。
- **反事实推演：**如果英伟达把软件库留给第三方，各框架就会像谷歌（Google）打造 XLA 那样自建编译器，CUDA 的护城河也会更浅 🔴。

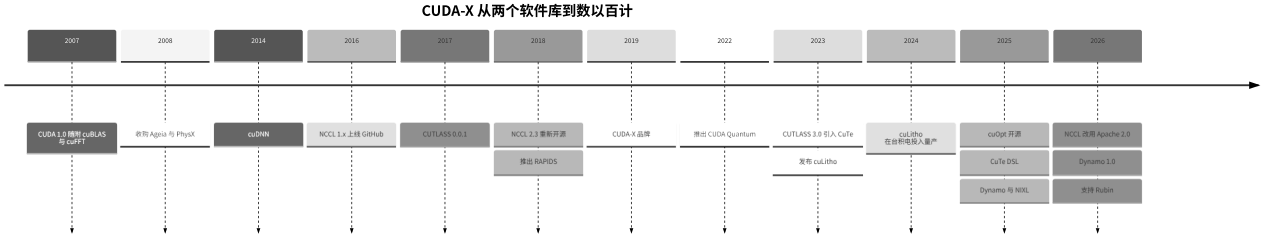

软件库目录是如何建成的

有三个习惯反复出现。**芯片与软件库同步发布：**cuBLAS 随首批 CUDA GPU 一同问世，如今 CUTLASS 会在每种新架构推出后数周内跟进。**跟随工作负载：**深度学习（cuDNN）、多 GPU 训练（NCCL）、数据科学（RAPIDS）、芯片制造（cuLitho）和量子计算（CUDA-Q），都是在需求显现后才各自获得了一个软件库 [S10039,S10506,S10517,S10032,S10520]。**开放具有战略意义的部分，保留形成差异化的部分：**NCCL、CUTLASS、cuOpt 和 Warp 是开源的，而 cuBLAS 和 cuDNN 以专有二进制形式发布 [S10507,S10038,S10028]。其中的机制参见广度为何产生复利。

日期	决策	意义	来源
2007-06	在 CUDA 1.0 中捆绑 cuBLAS 和 cuFFT	第一天就提供调优过的数学库	S525
2008-02	收购 Ageia（PhysX）	第一个通过收购而非自建获得的领域软件库	S484
2014-10	发布 cuDNN	各深度学习框架以其为标准	S10039
2016-04	将 NCCL 1.x 发布到 GitHub	免费的多 GPU 集合通信	S10506
2017-12-04	发布 CUTLASS 模板	客户可以自己编写张量核心内核，但运行在英伟达硬件上	S10010

日期	决策	意义	来源
2018-09-25	重新开源 NCCL 2（v2.3.5）	多节点训练确立以 NCCL 为标准	S10506
2018-10-10	与 Databricks、IBM、甲骨文（Oracle）共同推出 RAPIDS	CUDA 进入数据科学领域	S10517
2024-03-18	cuLitho 在台积电（TSMC）投入量产	GPU 进入芯片制造环节	S10031
2025-03	开源 cuOpt（Apache 2.0）	优化领域加入开放的 CUDA-X	S10027
2026-02-27	将 NCCL 重新许可为 Apache 2.0	降低用户与移植方的使用门槛	S10507

日期	英伟达的说法	来源
2021-04	CUDA 和 CUDA-X 加速了 >2,000 个应用	S537
2022-03	CUDA-X 软件库 60 项更新	S530
2022-09	550 个 SDK 和 AI 模型	S532
2023-05	>3,000 个应用	S533
2025-10	约 350 个 CUDA-X 软件库	S10501
2026-03	“数以百计”的软件库；cuDF 和 cuVS 被定位为基础	S10047,S10504

> **提示**
>
> **算例 —— 为什么软件库数量不是 KPI。** 英伟达对外宣传的数字从 550 个“SDK 和 AI 模型”（2022 年 9 月）降至约 350 个“软件库”（2025 年 10 月），降幅 36%；而加速应用数量从 2,000 个（2021 年）增至 3,000 个（2023 年），增长 50% [S532,S10501,S537,S533]。前一个序列改变了口径（剔除了模型）；后一个衡量的是采用程度。做尽职调查时，应统计第三方集成（Snowflake、Spark、Faiss），而不是英伟达自己的计数。

[Q4 · 优势来源] 持续执行了二十年的协同设计

在软件库将其开放出来之前，新的硬件特性毫无价值。Volta 的张量核心、Hopper 的张量内存加速器（TMA）以及 Blackwell 的 NVFP4 块缩放格式，都各自需要新的内核。由于指令集由英伟达定义，其软件库团队可以在产品发布前就构建好内核（这是根据发布日期做出的推断 🔴）：CUTLASS 3.0（2023 年 1 月）随附基于全新 CuTe 抽象构建的 TMA 内核，CUTLASS 3.8.0（2025 年 1 月）随附 Blackwell 的张量内存指令与 NVFP4，CUTLASS 4.8.0（2026 年 9 月）则随附对 Rubin 的支持以及新的 UE5M3 缩放格式 [S10010]。竞争对手只能在发布之后才看到这些特性。

CUTLASS supported each new NVIDIA GPU within 71 days of first volume shipments

Days from first volume availability (month, plotted mid-month) to the CUTLASS release adding that architecture

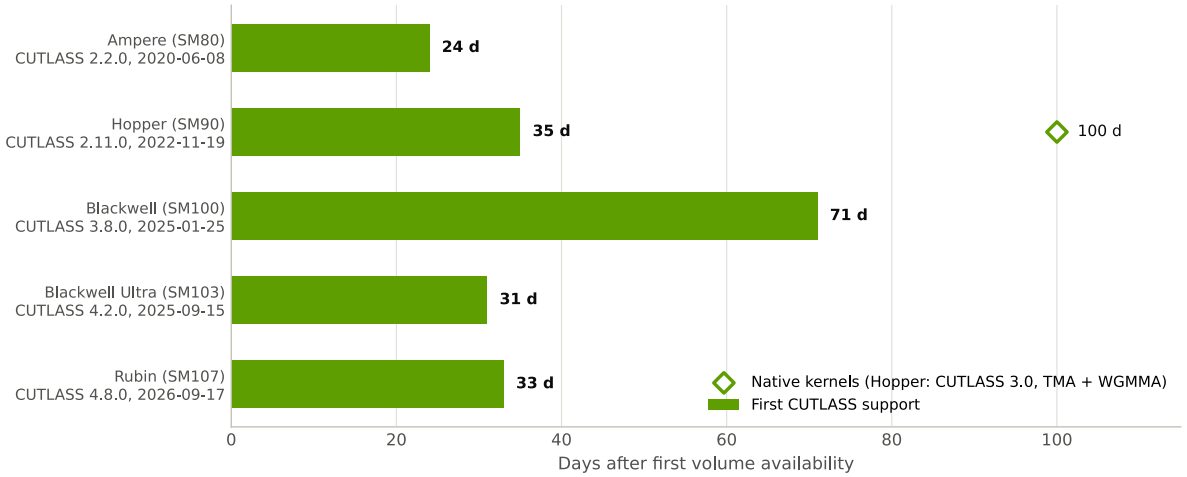

Availability months are placeholders where NVIDIA gave a quarter

Source: data from CUTLASS changelog; NVIDIA availability dates [S10010] [S127] [S315] [S35012] [S532] [S35014] …; chart by repo · As of 2026-11-05

英伟达开源 CUTLASS 内核库在每款新数据中心 GPU 首次批量出货后多快提供支持的水平条形图：Ampere 24 天（CUTLASS 2.2.0，2020-06-08）；Hopper 35 天（CUTLASS 2.11.0，2022-11-19）；Blackwell 71 天（CUTLASS 3.8.0，2025-01-25）；Blackwell Ultra 31 天（CUTLASS 4.2.0，2025-09-15）；Rubin 33 天（CUTLASS 4.8.0，2026-09-17）。基于 CuTe 构建的 Hopper 原生 TMA 和 WGMMA 内核在 100 天后随 CUTLASS 3.0 推出。由于英伟达协同设计软硬件，软件库与芯片同步到来。

答案：优势在于集成加上执行速度，并且持续得足够久，以至于成为了生态。单纯的技术是可以复制的：RCCL 复制了 NCCL 的接口，hipDF 是 cuDF 的分叉 [S10002,S10511]。难以复制的，是一个每年在 15 个领域同时交付软件库、编译器和 GPU 的组织。

提示

算例 —— Rubin 的首日就绪度。 Rubin 于 2026 年 8 月初开始量产出货 [S500]。均新增 Rubin 初步支持的 CUTLASS 4.8.0 和 NCCL 2.32.3 于 2026-09-17 打上版本标签，距 8 月中旬的参考日期约 33 天 [S10010,S10507]。AMD 的 FP4 路径耗时更长：CUDA 12.8 于 2025 年 1 月支持 FP4，ROCm 7.0 则于 2025 年 9 月支持，晚了 236 天 [S524,S586]。

[Q6 · 复制成本] 时间、资金与人才

Est.: an AI-core library stack costs ~$3B over 5 years, ~2 months of NVIDIA's R&D

US$ billions: software deals, R&D budgets and repo estimates of building CUDA-X-class libraries

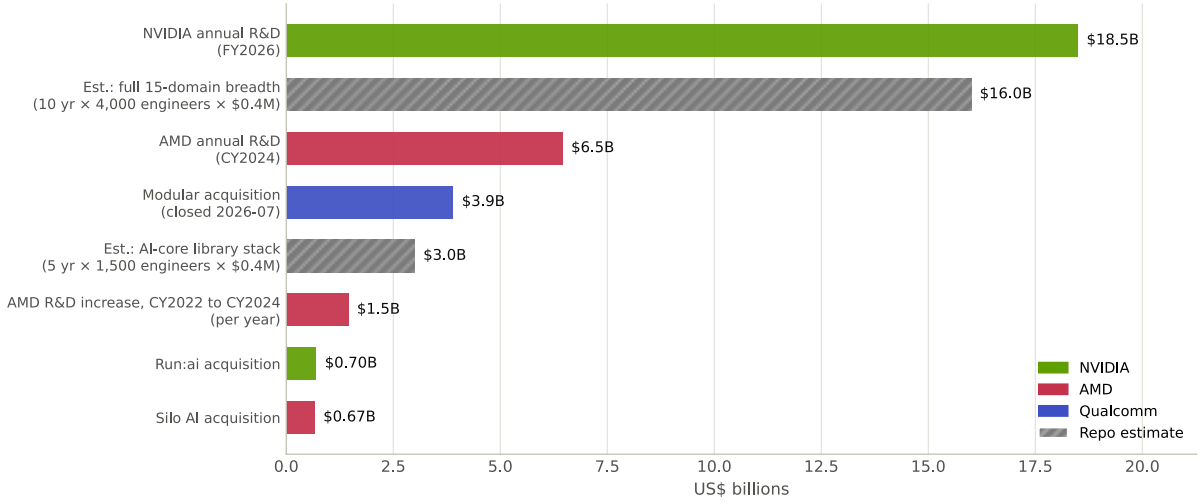

Hatched = repo estimate (speculative)

Source: data from filings, deal reports and repo estimates [S10531] [S476] [S479] [S450] [S401] [S10535] ...; chart by repo · As of 2026-11-05

> 软件复制成本参照点的水平条形图：AMD 收购 Silo AI $0.67B（2024 年），英伟达收购 Run:ai 约 $0.7B（2024 年），AMD 2022 至 2024 年研发支出每年增加约 $1.45B，本资料库估计 AI 核心软件库栈需 $3B（1,500 名工程师、5 年、每人 $0.4M），高通（Qualcomm）宣布的 $3.9B Modular 交易，AMD 2024 年研发总额 $6.5B，本资料库估计覆盖全部 15 个领域的广度需十年 $16B，以及英伟达 FY2026 研发支出 $18.5B。资金并非真正的约束；时间和专业人才才是。

范围	时间	资金（估计，本资料库🔴）	人才
AI 核心：GEMM、DNN、内核模板、集合通信、推理引擎	约 5 年	约 $3B（1,500 × $0.4M × 5）	约 1,500 名工程师，含内核与编译器专家
CUDA-X 全部广度（15 个领域）	约 10 年	约 $16B（4,000 × $0.4M × 10）	约 4,000 人，另需领域科学家与 ISV 合作伙伴
佐证：AMD ROCm	2016 年起步 → 2025–26 年 AI 核心接近持平	研发每年 +$1.45B（2022 → 2024）	AI 工程师薪酬偏低（SemiAnalysis，2025 年）

输入数据：英伟达 FY2026 研发支出 $18.5B，约 42,000 名员工中约 31,000 人从事研发（人均约 $0.6M）[S401]；AMD 研发 [S450]；ROCm 1.0 于 2016 年发布 [S586]；[S10535]。

NVIDIA's 2024 R&D ($12.9B) passed AMD and Broadcom, still below Intel's $16.5B

GAAP R&D expense, US$ B per year; NVIDIA FY2023–FY2025 shown as 2022–2024, Broadcom FY ends ~Nov

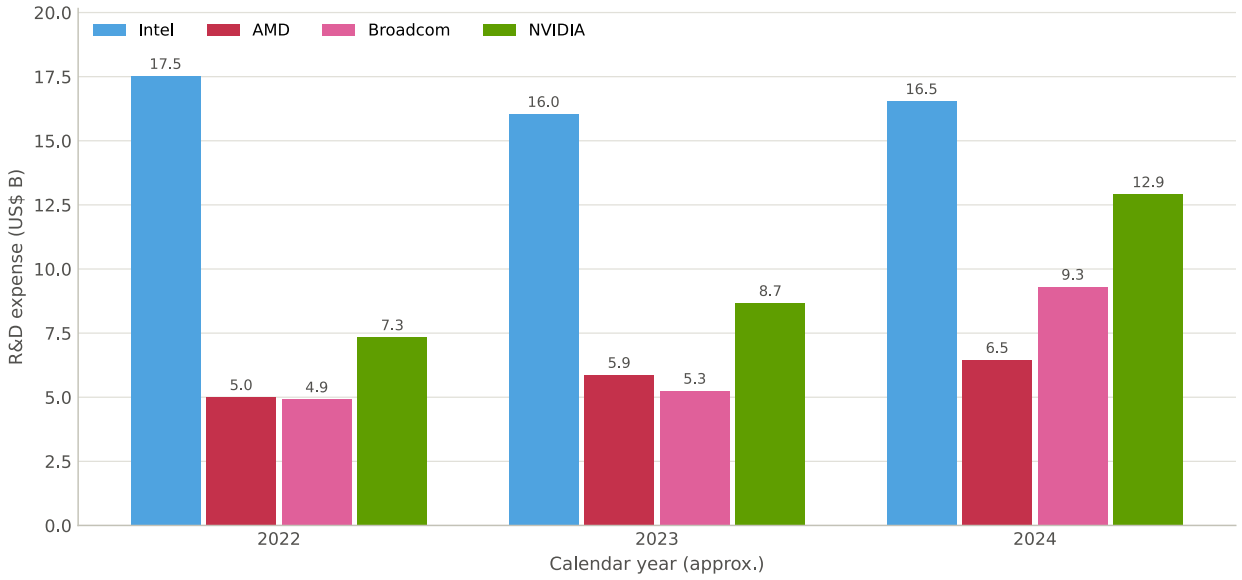

Source: data from company 10-K filings [S450] [S451] [S452] [S418] [S2] [S417] ...; chart by repo · As of 2026-11-05

2022–2024 年研发支出分组条形图：英伟达从 $7.3B 增至 $12.9B，2024 年 AMD 为 $6.5B、博通（Broadcom）$9.3B（含 VMware）、英特尔（Intel）$16.5B；图中未显示英伟达 FY2026 的 $18.5B 研发支出。

提示

算例 —— 算术。 1,500 名工程师 × $0.4M 全口径人力成本 × 5 年 = $3.0B，约相当于英伟达 FY2026 研发支出 2 个月的金额（$18.5B ÷ 12 × 2 ≈ $3.1B）[S401]。人均成本为本资料库的假设，低于英伟达约 $0.6M 的人均全口径研发支出，因为软件库不需要光掩模。真正起约束作用的投入是时间：AMD 从 ROCm 1.0（2016 年）到集合通信滞后缩短至约 3 个月（2025 年），用了约 9 年 [S586,S10509]；而收购一个团队（Silo AI，$665M）买到的是人，而不是多年的调优积累 [S10531]。

反事实推演 —— 如果英伟达当初没有……

- 🔴 ……**自建软件库，而是依赖 MKL 式的第三方？** 各框架团队就会像谷歌打造 XLA 那样，自行编写内核和编译器。代码将面向某种抽象层，而不是 CUDA，AMD 也就根本不需要做移植。
- 🔴 ……**在 2017 年之后继续闭源 NCCL？** 多节点训练可能会以 MPI 或 Gloo 为标准。RCCL 的许可证注明其包含英伟达贡献的代码，而在那种情况下它就无法从 NCCL 的代码起步 [S10002]。
- 🔴 ……**跳过 RAPIDS 和非 AI 领域？** GPU 将成为只用于 AI 的采购。也就不会有 Snowflake 或 Spark 集成把数据分析预算拉到 GPU 上 [S10521,S10517]。

提示

算例 —— 外包软件库的代价。 假设由第三方按 NVIDIA AI Enterprise 的标价（每 GPU 每年 $4,500）收取软件库费用 [S10526]。一台 72 GPU 的机架每年将承担 72 × $4,500 = $324,000，约为一台约 $7.8M 的 Vera Rubin NVL72 机架（估计，摩根士丹利）[S331] 价格的 4%/年。免费捆绑软件库消除了这一摩擦，并把利润留在 GPU 中。

🔧 **技术细节：软件库版本如何送达用户**

软件库通过三种方式发布：内置于 CUDA Toolkit（cuBLAS、cuFFT；自 1.0 起与 CUDA 同步版本化）、作为单独下载包和 Python wheel 发布（cuDNN、NCCL、cuDF；PyPI 记录给出了首次上传日期），以及在 GitHub 上以源代码形式发布（CUTLASS、NCCL、cuOpt）[S525,S10038,S10010]。许可证各不相同：PyPI 将 cuBLAS 和 cuDNN 列为英伟达专有，CUTLASS 为 BSD-3-Clause，Warp 为 Apache 2.0 [S10038,S10028]。开源有助于推广采用，但也让移植方得以复制；专有二进制则把调优程度最高的内核留在英伟达硬件上。

🎯 企业发展视角

1. 英伟达开源了 NCCL、CUTLASS 和 cuOpt，但让 cuBLAS 和 cuDNN 保持二进制形式。挑战者需要开源哪些软件库才能建立信任？哪些可以保持闭源？
2. 如果稀缺的投入是工程师人年而非资金，那么收购一个软件库团队（Silo AI、Modular）主要是在购买时间吗？能买到多少时间？
3. CUTLASS 会在每款英伟达 GPU 推出后约 1–2 个月内跟进。在新进入者的芯片上实现首日软件库支持需要多久？由谁来构建？
4. RAPIDS 表明，英伟达借助一个免费软件库加上合作伙伴进入了一个新市场（数据科学）。新进入者可以用同样的方式进入哪个相邻市场？

软件库（CUDA-X）：路线图

第 10 层 · 软件库（CUDA-X） · 约 9 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **英伟达（NVIDIA）的软件库路线图紧跟芯片。** CUTLASS 4.8.0 和 NCCL 2.32.3 均于 2026-09-17 新增对 Rubin 的初步支持，距 Rubin 开始量产出货约六周 🟢 S10010,S10507,S500。
- **NCCL 正在演变为一个面向推理与 MoE 的软件库：**设备端 API 与复制引擎集合通信（2.28，2025 年 10 月）、GPU 发起式网络通信、专家并行软件包（2026 年 6 月），以及 Compute Fabric Transport（2.31，2026 年 8 月）🟢 S10507。
- **推理服务软件已经产品化：**Dynamo 在 GTC 2026 上发布 1.0 版，v1.5.1（2026 年 10 月）是其首个提供企业级支持（Enterprise Support）的版本 🟢 S90066,S521。
- **AMD 的发布频率与英伟达相当，但仍是追随者：**ROCm 从 7.0（2025 年 9 月）发展到 10.0（2026 年 8 月），但当 NCCL 已到 2.29 时，其 RCCL 仍只对应 NCCL 2.27 🟢 S586,S10509,S10506。
- **谷歌（Google）正在淘汰 PyTorch/XLA**，代之以原生的 TorchTPU 栈（2026 年 10 月开源；原代码仓库于 2026-11-15 归档），其第八代 TPU 原生支持 FP4 🟢 S553,S595,S552。
- **[Q7 · 路线图与变数]** 如果移植滞后接近于零，或者编译器让软件库变得可有可无，格局就会改变；如果英伟达能为 Rubin Ultra（2027 年）和 Feynman（2028 年）保持首日支持，格局就会维持 🟡 S507,S90004。

NCCL advanced 19 minor versions in ~4 years; AMD's RCCL port shipped 1–4 versions behind

NCCL 2.x minor version over time (first GitHub tag of each minor) vs the NCCL version each ROCm release's RCCL matches

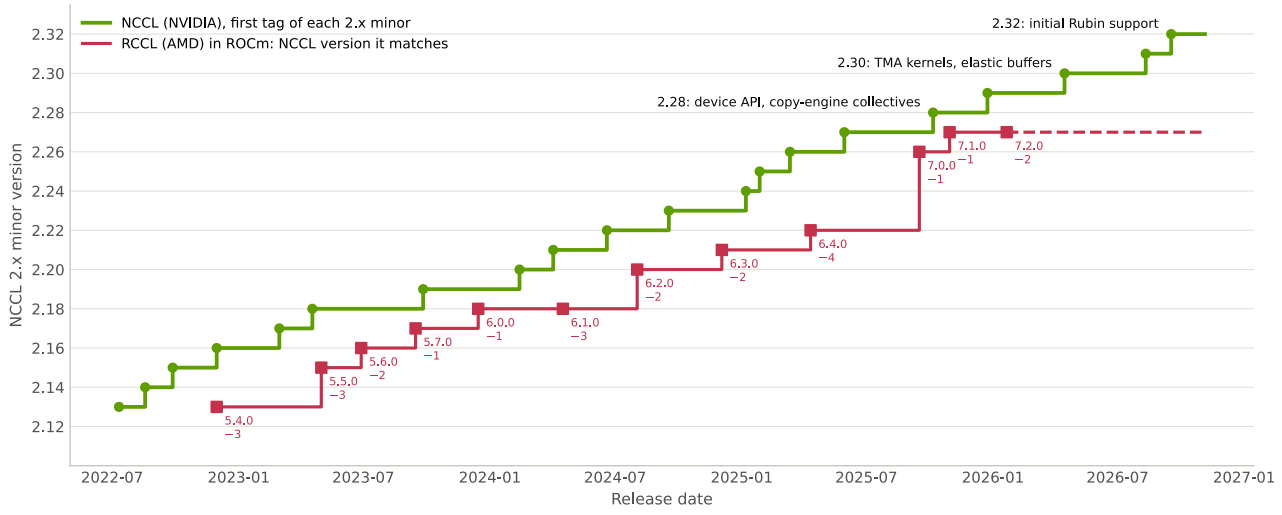

Squares = ROCm release dates

Source: data from NCCL GitHub tags and release notes; RCCL changelog; ROCm releases [S10506] [S10507] [S10509] [S586] [S10510] [S10511]; chart by repo · As of 2026-11-05

> NCCL 次版本从 2.13（2022 年 7 月）到 2.32（2026 年 9 月）的阶梯图，并标出从 ROCm 5.4 到 7.2 各版本中 RCCL 对应的 NCCL 兼容版本。RCCL 落后 1 至 4 个次版本；差距在 ROCm 6.4 时最大（2.22 对 2.26），在 ROCm 7.0 和 7.1 时最小（2.26 和 2.27，落后一个版本）。NCCL 里程碑：设备端 API 与复制引擎集合通信（2.28，2025 年 10 月），TMA 与弹性缓冲区（2.30，2026 年 4 月），Rubin 初步支持（2.32，2026 年 9 月）。

路线图 2024–2028

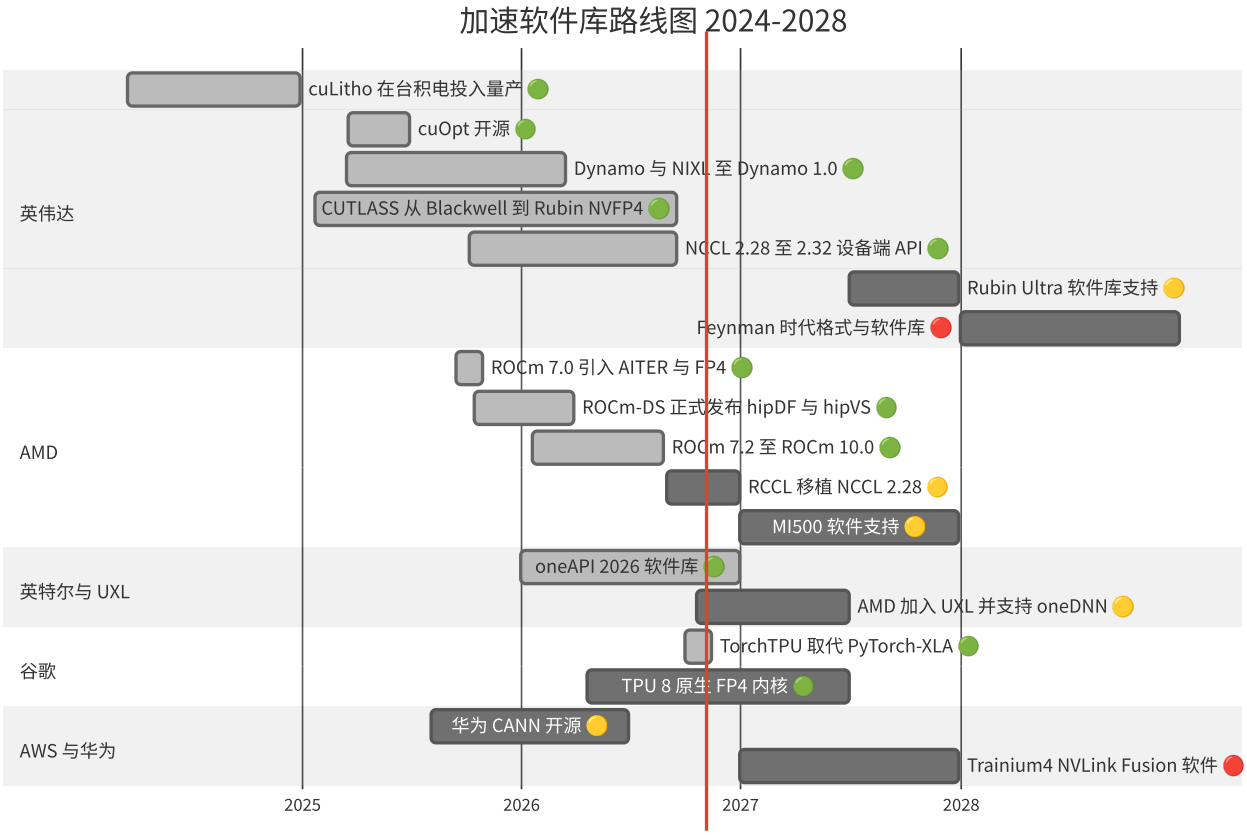

🟢 公司已确认 · 🟡 有报道或时间不确定 · 🔴 本资料库推断。条形为大致时间窗口。各行来源见下表；未列入下表的条形：cuLitho 在台积电投入量产 [S10031]，ROCm-DS 正式发布 [S10511]。

事项	时间窗口	状态	置信度	来源
CUTLASS 4.8 与 NCCL 2.32：Rubin 初步支持	2026 年 9 月	已发布	🟢	S10010,S10507
CuTe DSL（Python）结束公开 beta	目标为 2026 年夏末；2026 年 10 月仍为 beta	已推迟	🟡	S10009
NCCL 设备端 API、GIN、复制引擎集合通信	2025 年 10 月 – 2026 年 8 月	已发布	🟢	S10507,S10007
Dynamo 1.0 至 1.5.1（首个企业级支持版本）	2026 年 3 月 – 10 月	已发布	🟢	S90066,S521
搭配 NVQLink 的 CUDA-Q（17 家量子硬件厂商）	2025 年 10 月起	逐步推出	🟢	S10519
Rubin Ultra 软件库支持	2027 年下半年	计划中；有报道称 Kyber 推迟，英伟达否认	🟡	S507,S508
Feynman 时代格式	2028 年	路线图	🔴	S90004
ROCm 10.0 Core SDK	2026 年 8 月	已发布	🟢	S586
RCCL 对应 NCCL 2.28.3	列入 ROCm 7.11 计划；截至 2026-11-05 尚未出现在更新日志中	待定	🟡	S10509
AMD MI500（2027 年）与 MI600（2028 年）软件	2027 – 2028 年	芯片已列入路线图	🟢 芯片 / 🔴 软件	S538,S541
AMD 加入 UXL；oneDNN 成为 PyTorch x86 默认后端	2026 年 10 月	有报道	🟡	S10542
TorchTPU 取代 PyTorch/XLA	2026 年 10 月 – 11 月	已完成	🟢	S553,S595

事项	时间窗口	状态	置信度	来源
华为 CANN 开源	2025 年 8 月起	进行中	🟡	S10537
搭配 NVLink Fusion 的 Trainium4	未定	已宣布	🔴 时间	S90034

提示

算例 —— “首日支持”到底有多快。 Rubin 于 2026 年 8 月初开始量产出货 [S500]。以 8 月中旬为参考日期，CUTLASS 和 NCCL 对 Rubin 的支持约在 33 天后（2026-09-17）到来 [S10010,S10507]。如果 Rubin Ultra 按计划于 2027 年下半年出货，同样约 1 个月的间隔意味着其软件库将在 2027 年底到位；若如报道所称 Kyber 推迟到 2028 年，两者将一同顺延 [S507]。

规格演进：发布速度与追随者差距

NCCL 从 2.13（2022-07-11）发展到 2.32（2026-09-17）：约 50 个月内发布 19 个次版本，约每 2.6 个月一个 [S10506]。近期版本瞄准推理与混合专家模型（MoE）流量：能自行发起网络传输的 GPU 内核、释放计算单元的复制引擎集合通信、弹性通信器，以及专家并行软件包 [S10507]（机制详见 NCCL：隐形黏合剂）。AMD 如今发布 ROCm 功能版本的频率与英伟达发布 CUDA 版本相当，每年 3–4 个，但其中很多内容是对英伟达数月前已发布功能的移植 [S586,S10509]。

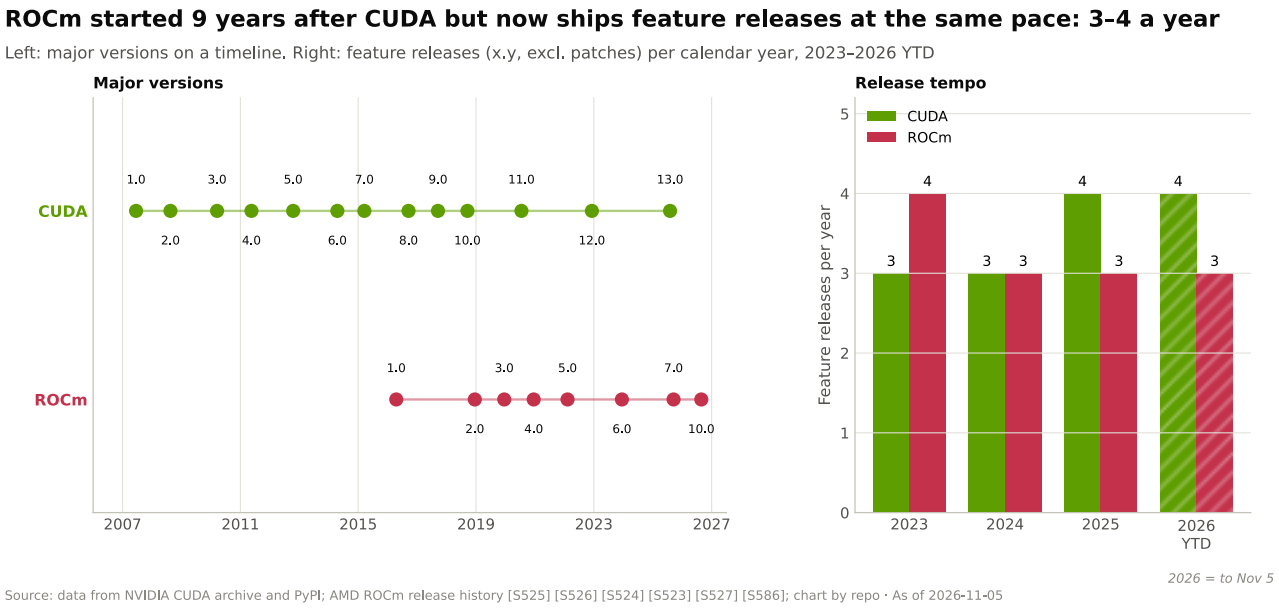

双面板图。左：CUDA 主版本从 1.0（2007 年）到 13.0（2025 年），ROCm 主版本从 1.0（2016 年）到 10.0（2026 年），CUDA 领先起步 9 年。右：2023–2026 年每年功能版本数——CUDA 分别为 3、3、4、4，ROCm 分别为 4、3、3、3——节奏大致相当。

提示

算例 —— 以日历时间衡量的追随者差距。 ROCm 7.2.0（2026-01-21）随附的 RCCL 仍只对应 NCCL 2.27.7，而后者的标签日期为 2025-07-24：早了 181 天，此时 NCCL 已发布 2.28 和 2.29 [S10509,S10506,S586]。在 12 个月的 GPU 周期下，98 天的滞后（ROCm 7.1）意味着 AMD 客户在每个周期中约有 27% 的时间用不上新的集合通信功能；若滞后缩短至 30 天，这一比例将降至约 8%。

🔧 技术细节：“Rubin 初步支持”包含哪些内容

CUTLASS 4.8.0 以 SM107 作为 Rubin 的目标架构，新增 FP8 和 FP4 矩阵路径，以及一种用于 NVFP4 块缩放的新 UE5M3 缩放因子类型（一种 5 位指数、3 位尾数的无符号 8 位格式）；4.8.1 版已列出若干已知的 Rubin 代码生成问题 [S10010]。NCCL 2.32.3 新增了 Rubin 平台检测以及 ConnectX-9 的轨道（rail）与平面（plane）检测

S10507。“初步”二字很关键：针对每种模型形状的调优内核通常会在随后的多个版本中陆续推出，这正是同一硬件上的软件增益在产品发布后仍不断出现的原因。

哪些因素会改变格局

- 🟡 **移植滞后接近于零。** 如果 AMD 共同维护上游代码（RCCL 已在沿用 NCCL 的许可证与 API），集合通信就不再构成差异化 S10002。
- 🟡 **编译器让软件库变得可有可无。** TorchTPU、Triton 后端以及高通（Qualcomm）对 Modular 的收购（Mojo、MAX；已于 2026-07-29 完成交割 S9511），正把内核选择权推向编译器 S553,S578,S90057。
- 🟡 **数据平台默认采用 GPU。** Snowflake ML 已在其默认 GPU 运行时中内置 cuML 和 cuDF；若 Databricks 和 AWS 也将其设为默认，将扩大英伟达在非 AI 领域的带动效应 S10521,S10522。
- 🔴 **竞争对手进入只有英伟达覆盖的领域**（光刻、优化、基因组学），并与 EDA 厂商等合作伙伴联手。
- 🟢 **英伟达为 Rubin Ultra 和 Feynman 保持一个月内的首日支持：**差距持续存在。

> **提示**
>
> **算例 —— 编译器栈的转向能有多快。** 谷歌于 2026 年 10 月开源 TorchTPU，并将在约六周后的 2026-11-15 归档 PyTorch/XLA；vLLM 和 SGLang 已列出 TorchTPU 后端 S553,S595,S581,S582。而同等重要的软件库移植（RCCL）自 2024 年以来每个版本需要 98–296 天 S10509,S10506。以编译器为先的厂商几周内就能转向；移植方则在每次发布上都落后数月。

[Q7 · 路线图与变数] 到 2028 年，英伟达的路线图与年度 GPU 发布以及 NCCL 和 Dynamo 中面向推理时代的功能紧密绑定；AMD 在发布节奏上正在趋同，但在时间上尚未追平。最大的变数在于编译器（XLA/TorchTPU、Triton、Mojo）是否会接管对 AI 至关重要的内核——若如此，护城河将收缩至非 AI 领域。

🎯 企业发展视角

1. NCCL 2025–26 年的新功能瞄准 MoE 与推理流量。这会让集合通信对以推理为先的新进入者变得更重要，还是更不重要?
2. ROCm 的发布频率与 CUDA 相当，但仍落后 1–4 个 NCCL 版本。组建一支零滞后的移植团队需要多少成本？共同维护上游是否可行?
3. 谷歌在一年内就用 TorchTPU 取代了 PyTorch/XLA。以编译为先的技术栈（例如 Modular 的 MAX）能多快在新芯片上投入生产?
4. 哪个路线图里程碑（Rubin Ultra 软件库、UXL 的采用、CANN 开源）最可能改变软件库“自建还是合作”的决策?

软件库（CUDA-X）：价值链与企业发展视角

第 10 层 · 软件库（CUDA-X） · 约 10 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **软件库是一款带动硬件销售的免费产品。** 英伟达（NVIDIA）的付费层 NVIDIA AI Enterprise 在 2024 年的标价约为每 GPU 每年 $4,500 [S10526]；其余一切都通过硬件带动销售（pull-through）获取回报。
- **直接软件收入规模很小：** 2024 年初年化收入约 $1B，指引到 2024 年底接近约 $2B，约占 FY2025 收入 $130.5B 的 1.5%；未找到更新的数据 [S10525,S10527,S2]。
- **AI 以外的带动效应真实存在，但尚处早期：** Snowflake ML 默认内置 cuML 和 cuDF（2025 年 11 月），Databricks 宣布在 Photon 上开展 GPU 相关工作（2024 年），台积电（TSMC）已在量产中使用 cuLitho [S10521,S10522,S10031]。
- **EDA 与仿真正围绕 GPU 整合：** 新思科技（Synopsys）于 2025 年 7 月完成对 Ansys 的 $35B 收购，英伟达则于 2025 年 12 月买入新思科技 $2B 股权 [S10524,S471]。
- **看空证据：** GPU 往往让数据分析变得更便宜，而不是更快。在 AWS 的 1 TB Spark 测试中，GPU 运行快 1.06 倍，但便宜约 80%；英伟达的一个 Databricks 案例发现，RAPIDS 仅比 Photon 便宜约 6% [S10020,S10523]。
- **并购：** 在此处统计的 2022 年以来 12 笔芯片厂商软件收购样本中，有 6 笔公开了价格，其中最大的是高通（Qualcomm）宣布的 $3.9B Modular 交易，约为英伟达收购 Run:ai（约 $0.7B）的 5.6 倍 [S90057,S476,S10531]。
- **[Q8 · 价值池与并购机会]** 价值池在于数据分析、EDA、量子计算和工程仿真领域的硬件带动销售；对这些领域的非上市公司，英伟达选择投资而非收购（PhysicsX、Quantinuum、PsiQuantum）[S10564,S10566]。

Chip vendors' software buys: NVIDIA's pending $12.9B Hugging Face deal tops Qualcomm's $3.9B Modular (itself ~6x any earlier deal)

Disclosed or reported value, US$ millions (log scale): a sample of library, AI-software and tools deals by chip vendors

LOG SCALE

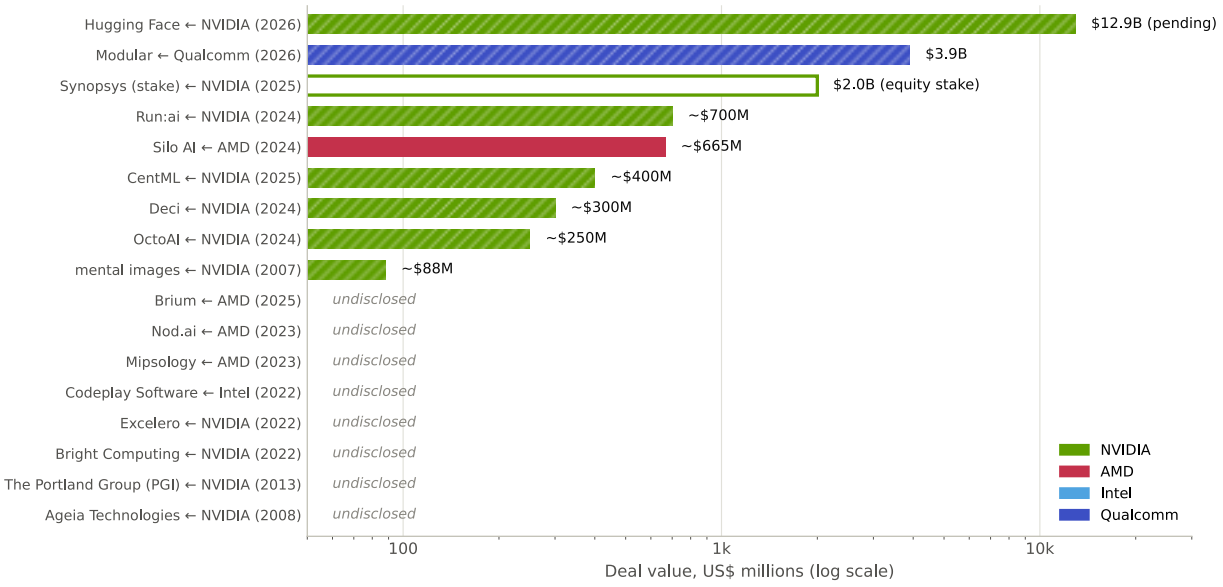

Hollow = equity stake; hatched = reported/announced

Source: data from company releases and press [S484] [S478] [S10534] [S10533] [S10529] [S10530] ...; chart by repo · As of 2026-11-05

> 芯片厂商软件库、AI 软件与工具类交易样本的对数刻度水平条形图：2022 年以来共 13 笔收购，其中 7 笔公开了价格。英伟达待完成的 $12,930M Hugging Face 收购（2026 年 9 月宣布，目标于 2027 年上半年完成交割）规模最大。高通宣布的 $3,900M Modular 收购（2026 年）约为此前最大一笔——英伟达 $700M 收购 Run:ai（2024 年，据报道）——的 5.6 倍；其后依次为 $400M 的 CentML、$300M 的 Deci、$250M 的 OctoAI 和 $88M 的 mental images；AMD 以 $665M 收购 Silo AI（2024 年）；英伟达对新思科技的 $2,000M 股权投资（2025 年，并非收购）。AMD 收购 Mipsology、Nod.ai 和 Brium，英特尔收购 Codeplay，以及英伟达收购 Ageia、PGI、Bright Computing 和 Excelero 的价格均未披露。

谁攫取了收益

软件库就像一个只适配某一品牌电器的免费电源适配器：它本身不赚钱，却决定了客户买哪个品牌的电器。英伟达的收益以 GPU 和系统收入的形式到来，GAAP 毛利率约 75%（Q2 FY2027），外加薄薄一层订阅收入[S3,S90013]。

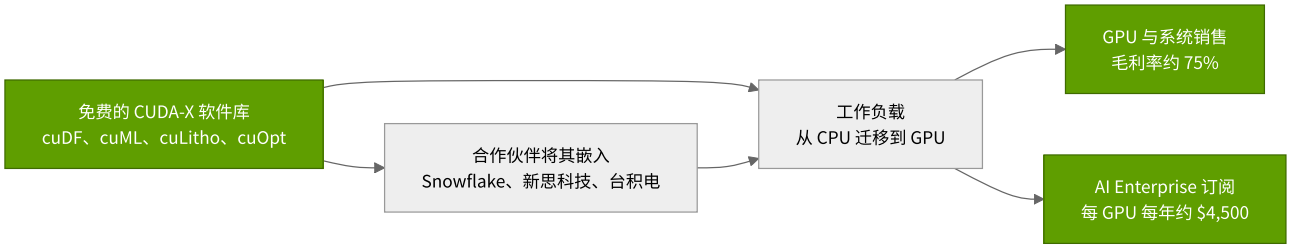

层级	示例	价格	英伟达如何获利	来源
开源	NCCL（Apache 2.0）、cuOpt（Apache 2.0）、CUTLASS（BSD-3）、Warp（Apache 2.0）	$0	带动销售；生态	S10507,S10026,S10038,S10028
免费的专有二进制	cuBLAS、cuDNN	$0	带动销售；最好的内核留在英伟达硬件上	S10038
订阅	NVIDIA AI Enterprise（技术支持、认证构建版本）	每 GPU 每年约 $4,500（2024 年）	软件收入	S10526

披露场合	软件、SaaS 与支持服务年化收入	来源
Q3 FY2024 业绩电话会（2023 年 11 月）	有望以约 $1B 的年化收入结束该年	S10528
Q4 FY2024 业绩电话会（2024 年 2 月）	已达到约 $1B	S10525

披露场合	软件、SaaS 与支持服务年化收入	来源
Q2 FY2025 业绩电话会（2024 年 8 月）	年底前接近约 $2B	S10527

> **提示**
>
> **算例 —— 为什么英伟达不需要为软件库收费。** 一台 72 GPU 的机架若按标价计算，每年需为 AI Enterprise 支付 72 × $4,500 = $324,000 [S10526]。即便 10,000 台机架全部获得许可，每年也只带来约 $3.2B，约为单季度收入（Q2 FY2027 为 $96.2B）的 3.4% [S3]。2024 年底的实际软件收入约为每年 $2B [S10527]。软件库的价值在于它所带动销售的 GPU。

合作伙伴与带动销售的市场

合作伙伴	软件库	解锁了什么	状态	来源
Snowflake	Snowflake ML 中的 cuML、cuDF	无需修改代码的 GPU 机器学习	默认 GPU 运行时，2025 年 11 月 🟢	S10521
Databricks	Spark GPU 插件；Photon GPU 相关工作	在 GPU 上运行 ETL	2024 年 6 月宣布；未找到 2026 年进展 🟡	S10522,S10523
台积电、新思科技	新思科技 Proteus 中的 cuLitho	掩模合成快 45–60 倍（厂商数据）	2024 年 3 月起投入量产 🟢	S10031
新思科技（含 Ansys）	CUDA-X EDA 与仿真	GPU 加速的 EDA 与多物理场仿真	英伟达持股 $2B，2025 年 12 月 🟢	S471,S10524
量子硬件厂商（17 家）	CUDA-Q、NVQLink	面向 QPU 的 GPU 控制与纠错	2025 年 10 月起 🟢	S10519
Meta（Faiss）	cuVS	索引构建比 CPU HNSW 快 12.3 倍	Faiss 1.10，2025 年 5 月 🟢	S10025

> **提示**
>
> **算例 —— 光刻领域的带动销售是什么样子。** 英伟达称，在台积电，350 台 H100 系统即可完成 40,000 台 CPU 系统的计算光刻工作，相当于每台 GPU 系统替代约 114 台 CPU 系统，且流程快 45–60 倍 [S10031]。每一家采用该流程的晶圆厂或掩模厂都要购买英伟达系统；没有其他加速器厂商能提供光刻软件库。

> **注意**
>
> **误区与事实：**“GPU 数据分析总是更快。”在 AWS 的 1 TB Spark 基准测试中，原生 Spark 耗时 1.7 小时、花费 $31.28，运行在四块 L4 GPU 上的 cuDF 插件耗时 1.6 小时、花费 $6.27，而向量化 CPU 引擎（Velox）耗时 1.0 小时、花费 $18.40 [S10020]。在这里，GPU 的优势在于成本，而 CPU 引擎也在持续进步。

值得关注的非上市公司（仅基于公开信息）

公司	业务	最近一轮公开融资	为何重要	来源
PhysicsX	面向工程的 AI 物理仿真	C 轮 $300M，估值 $2.4B（2026 年 6 月）；投资方包括英伟达和西门子	运行在 GPU 上的 AI 原生 CAE	S10564
Luminary Cloud	GPU 原生物理仿真与 AI	B 轮 $72M（2025 年 9 月），NVentures 参投	在 CAE 领域的同类带动效应	S10565
Quantinuum	离子阱量子计算机	$600M，投前估值 $10B（2025 年），NVentures 参投	NVQLink 合作伙伴	S10566,S10519

公司	业务	最近一轮公开融资	为何重要	来源
PsiQuantum	光量子计算机	$1B，估值 $7B（2025 年），NVentures 参投	CUDA-Q 生态的核心成员	S10566
QuEra	中性原子量子计算机	NVentures 参投的 $230M 融资（2025 年）	NVQLink 支持者	S10566,S10520
Voltron Data	Theseus GPU SQL 引擎，支持英伟达或 AMD	Accenture Ventures 入股（2025 年 2 月，金额未披露）	厂商中立的 GPU 数据分析	S10561,S10560
Anyscale	Ray 分布式计算	C 轮 $100M，估值 $1B（2021 年）	Ray 可调度英伟达、AMD、TPU、Neuron 和昇腾（Ascend）设备	S10562,S584
Coiled	托管式 Dask	种子轮 $5M（2020 年）；后续轮次未核实	Dask 可在 GPU 上运行 cuDF	S10563,S10011

提示

算例 —— 一轮量子计算融资意味着什么。 Quantinuum 以 $10B 的投前估值融资 $600M [S10566]：投后估值为 $10.6B，因此新投资者合计持股约 5.7%（600 ÷ 10,600）。NVentures 的份额未披露，在财务上对英伟达而言也微不足道；关键在于卡位，因为 Quantinuum 是 NVQLink 首批 17 家量子硬件厂商之一，而每一台此类机器都需要 GPU 端的控制与仿真 [S10519]。

本层的并购历史

英伟达在软件库层的交易都是小型补强收购：mental images（2007 年，约 $88M）、Ageia/PhysX（2008 年）、The Portland Group 编译器（2013 年），以及 Bright Computing 和 Excelero（2022 年）[S484,S478,S10534]。其 2024–25 年的 AI 软件收购，据报道每笔均不超过约 $0.7B [S479,S476]；例外出现在 2026 年 9 月，英伟达同意以约 $12.9B 收购 Hugging Face（目标于 2027 年上半年完成交割），这是其自 Mellanox 以来最大的一笔交易 [S11500,S90084]。AMD 在 2023–25 年间收购了四个 AI 软件团队，英特尔（Intel）则为获取 SYCL 工具收购了 Codeplay（2022 年）[S10529,S10530,S10531,S10532,S10533]。英伟达在软件库相关领域最大的一笔投入是股权投资（新思科技，$2B），而非收购 [S471]。

Since 2023, 50 of NVIDIA's 65 logged deals were stakes in customers and partners, not M&A

Each deal by announcement date and the stack layer it strengthens; marker area ∝ US$ amount (small hollow = undisclosed)

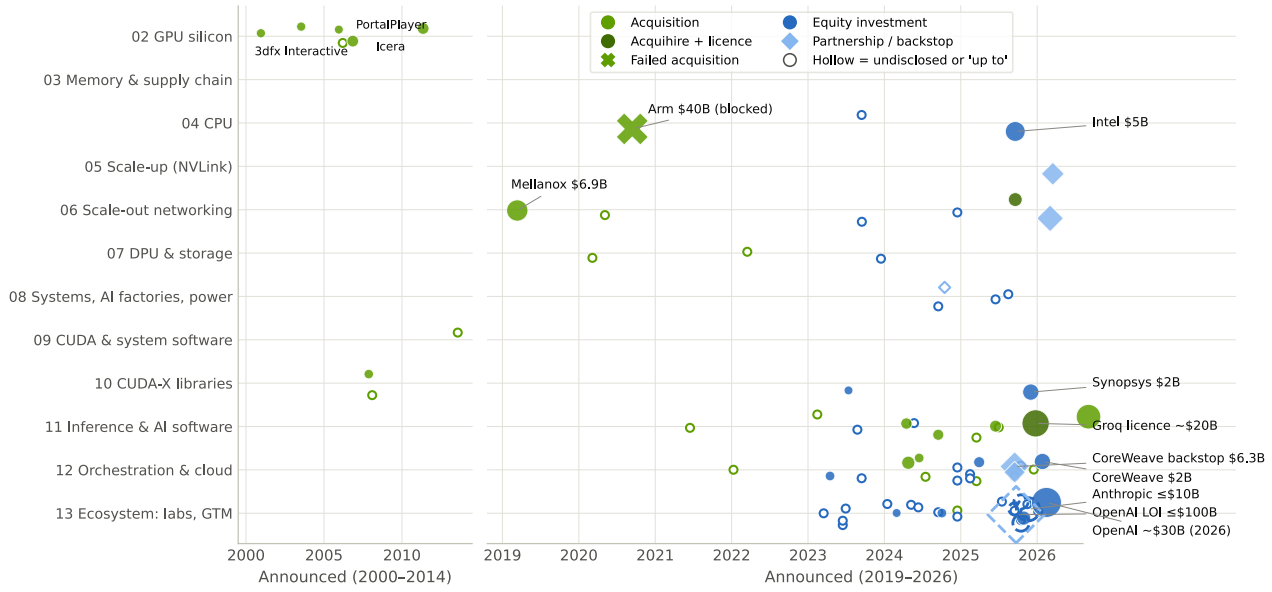

Pre-2019 axis compressed

Source: data from NVIDIA filings and announcements; press reports [S400] [S484] [S464] [S2] [S478] [S465] ...; chart by repo · As of 2026-11-05

2000 至 2026 年英伟达 81 笔收购、收购式招聘加授权交易及战略投资的时间线散点图，按各笔交易所强化的技术栈层级排布。早期交易是 GPU 与移动芯片领域的补强收购；Mellanox（$6.9B，2019 年）构建了网络层；2023 年以来的 65 笔交易中有 50 笔是股权投资，以 OpenAI、Anthropic、英特尔和 CoreWeave 为首，另有约 $20B 的 Groq 授权交易。

提示

算例 —— 用钱买时间。 本资料库估计，一个 AI 核心软件库栈需在 5 年内投入约 $3B，即每年约 $0.6B 🔴（发展历程）。高通宣布以 $3.9B 收购 Modular，相当于约 6.5 年的自建预算 S90057。这笔溢价买到的是一个现成可用、可跨硬件移植的技术栈及其团队，而不必花五年时间去招聘和调优。

[Q8 · 价值池与并购机会] 价值池并不在于软件库收入（按最近一次披露约为每年 $2B），而在于软件库在数据分析、EDA 与光刻、量子计算和工程仿真领域所创造的 GPU 需求 S10527,S10521,S10031,S10519。英伟达主要通过合作关系和少数股权投资而非收购来锁定这部分价值 S471,S10564,S10566；待完成的约 $12.9B Hugging Face 收购——位于更上一层的模型中心——是个例外 S11500。对竞争对手而言，思路恰恰相反：收购编译器与内核团队（Silo AI、Brium、Modular），以缩短追平 AI 核心所需的年数。

🔧 技术细节：合作伙伴为何嵌入英伟达软件库

采用 cuDF 或 cuML 的 ISV 或数据平台，无需招聘 GPU 专家即可获得多年的调优成果，而零代码修改模式意味着其用户无需重写 pandas 或 scikit-learn 代码 S10521,S10011。代价是依赖：AMD 的 hipDF 跟随 cuDF 的 API，但 ROCm-DS 中没有列出 cuML 的对应物，因此希望引入第二个 GPU 供应来源的平台必须维护两条路径 S10511,S10512。

🎯 企业发展视角

1. 英伟达通过硬件而非许可费将软件库变现。新进入者还有可能单独为软件定价吗？还是也必须免费提供软件库？
2. 非 AI 的带动销售市场（数据分析、EDA、量子计算、CAE）各自依赖一两个合作伙伴。哪些合作关系是可以争夺的？条件如何？

3. 英伟达对 CAE 和量子计算初创公司选择少数股权投资而非收购。投资者能从这些公司的股权结构（PhysicsX、Quantinuum、PsiQuantum）中看出什么？
4. 高通的 Modular 交易（已于 2026-07-29 完成交割，公开信息）[S9511] 买到的是一个可移植的技术栈：在哪些 CUDA-X 领域它仍需要合作伙伴？
5. 厂商中立的公司（Voltron Data、Anyscale、Coiled）位于软件库与用户之间。对于第二个 GPU 供应来源而言，它们是合作伙伴、收购标的，还是两者兼而有之？

第 11 层 —— 推理与 AI 软件

第 11 层（共 12 层）· 把 GPU 转化为可交付 token 的软件：TensorRT-LLM、Dynamo、NIM、NeMo、Nemotron 与 AI Enterprise · 约 6 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **推理是增长引擎，但英伟达（NVIDIA）已不再披露其规模。** 管理层最近一次量化是：截至 Q2 FY2025 的一年中，推理占数据中心收入的 40% 以上，即至少 ~$33B [S11011,S441]。此后只作定性表述："推理即收入"（"inference is revenues"）[S11012,S409]。
- **推理模型与智能体使每项任务的 token 数成倍增长。** 按本资料库的示例测算，一次推理型回答生成的 token 为普通聊天回复的 ~21×，一个编程智能体的总量为 ~1,100×（估计）[S32025]。谷歌（Google）的月度 token 量在 18 个月内增长 ~134× [S32018,S32020]。
- **衡量系统要看曲线，而非峰值。** 在每用户 50 tokens/s 的交互速度下，GB300 NVL72 运行 DeepSeek-R1 每 GPU 可输出 ~6,261 tokens/s，为 H200 的 ~20×；按每兆瓦计，差距为 ~13× [S621,S622]。
- **软件持续提升同一套硬件的产出。** 在硬件不变的 GB300 NVL72 上，MLPerf DeepSeek-R1 吞吐量一年内提升 2.9×，估计每百万 token 成本下降 ~65% [S601,S603,S622]。
- 🟢 **Dynamo 1.0 让整个集群像一台机器一样提供服务。** 它于 GTC 2026 以 Apache-2.0 开源许可发布 [S90066,S520]。将预填充（prefill）与解码（decode）拆分后，B200 在长提示词场景下的每 GPU 吞吐量提升 ~2.5× [S621]。
- **直接软件收入很小，关键在于带动硬件销售。** NVIDIA AI Enterprise 的标价为每 GPU 每年 $4,500 [S11013]；管理层指引 FY2025 末软件年化收入 ~$2B [S11011]，不到数据中心收入的 1%。
- **最大弱点：这一层几乎没有锁定客户的东西。** Dynamo 同样可以运行 vLLM 和 SGLang，而二者都支持 AMD 等其他硬件 [S11001,S580,S582]。谷歌 TPU 运行某一大模型的每 token 成本比 B200 低 ~18% [S625]。🟡 ~$12.9B 收购 Hugging Face 一事正面临中立性审查 [S11026,S11028]。

At 50 tok/s/user, GB300 NVL72 delivers ~20x H200 and ~8x MI355X throughput per GPU

InferenceX Pareto frontiers, DeepSeek-R1-0528, 1k in/1k out, FP4 (FP8 on Hopper/CDNA 3), no speculative decoding

LOG SCALE

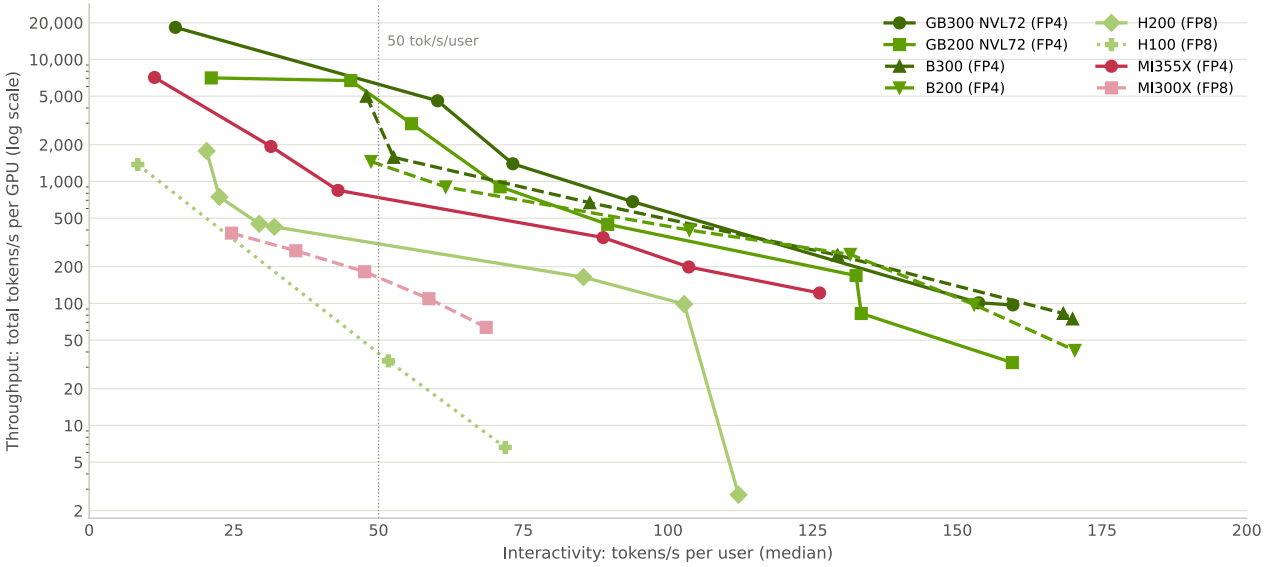

Snapshot subset; each point links to its run in the CSV

Source: data from SemiAnalysis InferenceX public-API snapshot (Oct 2026) [S621] [S622]; chart by repo · As of 2026-11-05

> 八个系统运行 DeepSeek-R1 时，每 GPU 总 tokens/s 与每用户 tokens/s 关系的对数坐标帕累托曲线图。按每用户 50 tok/s 插值：GB300 NVL72 约 6,261、GB200 NVL72 约 4,625、B300 约 2,982、B200 约 1,387、MI355X 约 738、H200 约 308 tokens/s（每 GPU）。机架级 NVL72 系统在中低交互速度区间占据主导；随着交互速度提高，所有曲线都急剧下降。

本层在技术栈中的位置

本层位于 CUDA 及其软件库（第 09 层、第 10 层）之上，集群编排（第 12 层）之下。

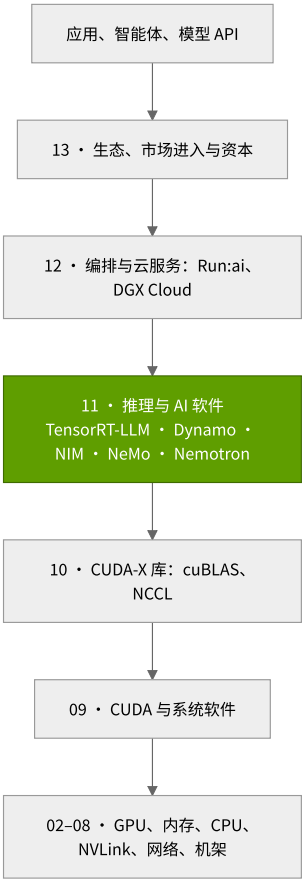

提示

算例 —— 一次智能体请求如何穿过本层。 某编程智能体发送 60,000 token 的上下文，要求生成 1,500 个新 token。Dynamo 的路由器选中一个已缓存了该上下文大部分内容的工作节点，因此只需对新一轮对话做预填充 [S11001]。预填充池完成计算后，由 NIXL 将 KV 缓存传送至解码池 [S11002,S11003]。在每用户 50 tokens/s 下，答案在 30 s 内流式输出完毕；若提速到 100 tokens/s，只需 15 s，但在 GB300 NVL72 上每个 token 消耗的 GPU 时间多 ~11×（每 GPU 6,261 对比 ~562 tokens/s，估计）[S621,S622]。**商业解读：**本层把单一的 GPU 价格转化为多档 token 价格。

🔧 **技术细节：本文所说的“推理软件”涵盖哪些内容**

编译器与运行时：TensorRT 和 TensorRT-LLM 让单块 GPU 或单个 NVLink 域跑得更快 [S11008,S589]。**服务层**：Dynamo 与 Dynamo-Triton 负责请求路由、阶段拆分、缓存迁移和自动扩缩容 [S11001,S11010]。**打包交付**：NIM 容器与 AI Enterprise 许可 [S11013]。**模型与工具**：Nemotron 与 NeMo [S11019,S11029]。Kubernetes 调度与云服务归入第 12 层。

本层地图

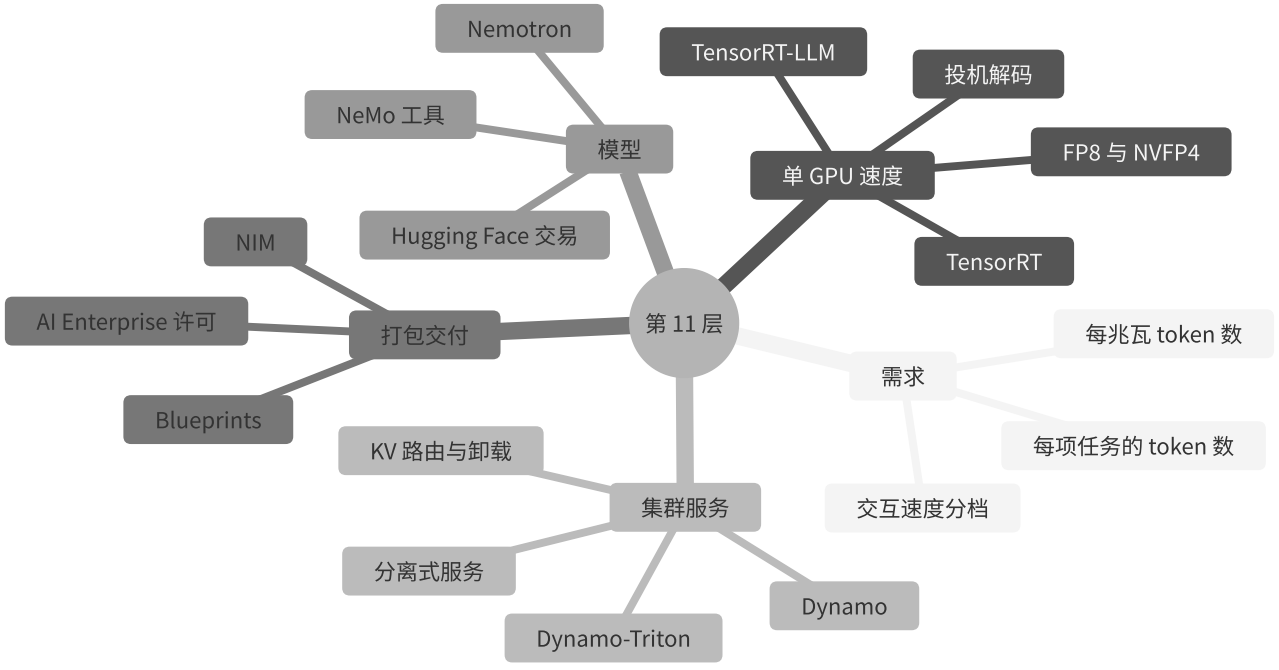

八个问题一览

#	问题	简要回答	详见
Q1	职能是什么？薄弱会怎样？	在每个延迟档位上把 GPU 小时转化为尽可能多的 token；软件薄弱会在同一芯片上留下 2–3× 的成本差距 [S601,S603]。	推理转向
Q2	关键指标？	在给定每用户 tokens/s 下的每 GPU tokens/s；每兆瓦 tokens/s；每百万 token 的美元成本；首 token 延迟。	推理转向
Q3	代际进步？	在每用户 50 tokens/s 下，每 GPU 从 H200 ~308 提升到 GB300 NVL72 ~6,261 tokens/s [S621]；仅软件一年即提升 2.9× [S603]。	软件增益
Q4	优势来源？	软件与机架级硬件（NVL72、NVFP4）协同设计，并针对每个新模型做性能调优。	发展历程与构建方式
Q5	最强挑战者？	硬件中立的开源引擎（vLLM、SGLang），以及在每 token 成本上具备优势的谷歌 TPU [S625]。	竞争

#	问题	简要回答	详见
Q6	复制成本?	引擎可以复制；但与机架级硬件绑定、针对每个模型持续调优的“跑步机”难以复制。	发展历程与构建方式
Q7	路线图?	🟢 Dynamo 上 Vera Rubin；🟡 Groq LPX 解码机架（宣称每瓦 token 数提升 35×）[S113,S90003]；🟡 Nemotron 4 通过联盟开发 [S11022]。	路线图
Q8	价值池?	直接软件收入 ~$2B/年 [S11011]；真正的价值池在于对硬件的带动。交易：Groq 授权、🟡 Hugging Face [S90019,S11026]。	价值链与企业发展

本层各页

页面	你将了解
推理转向	每项任务的 token 数、延迟曲线、每兆瓦 token 数、收入占比
TensorRT-LLM 与 Dynamo	单 GPU 优化技巧、分离式服务、KV 缓存路由
同一硬件上的软件增益	已部署 GPU 的性能提升、其价值、基准测试的注意事项
NIM、NeMo、Nemotron 与 AI Enterprise	打包模型、许可、开放模型、渠道冲突
竞争	开源引擎、TPU、Trainium、推理 ASIC
发展历程：英伟达如何建成这一层	关键决策；复制成本
路线图	英伟达与竞争对手的时间线
价值链与企业发展视角	价值池；非上市公司

🎯 企业发展视角

1. **推理软件是维护硬件利润率的工具。** 许可标价为每 GPU 每年 $4,500 [S11013]，但软件收入不到数据中心收入的 1%。真正的产品是每块 GPU 多产出的 token——它们为采购下一个机架提供了理由。
2. **开放是一把双刃剑。** Dynamo、TensorRT-LLM 和 Nemotron 均已开源 [S11001,S589,S11019]。挑战者会采用、分叉还是忽略其中哪些组件?
3. **核心指标是特定延迟档位下的每兆瓦 token 数。** 任何加速器的推介，包括高通（Qualcomm）的 AI200/AI250 [S173]，都会以这条曲线来评判。在最赚钱的档位上，有哪些独立证据?
4. **模型分发正变得具有战略意义。** ~$12.9B 的 Hugging Face 收购要约 [S11026] 加上 Nemotron，使英伟达成为模型发布方。其中立性承诺在美国司法部（DOJ）和欧盟的审查下能否站得住 [S11027,S11028]?

推理转向

第 11 层 · 推理与 AI 软件 · 约 8 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **驱动需求的是每项任务的 token 数，而非用户数。** 一次推理型回答生成的 token 为普通聊天回复的 ~21×；一个 30 轮的编程智能体处理的总量为 ~1,100×（估计）[S32025]。谷歌（Google）的月度 token 量在 18 个月内增长 ~134× [S32018,S32020]。
- **推理按延迟曲线定价销售。** 运行 DeepSeek-R1 时，GB300 NVL72 在每用户 50 tokens/s 下每 GPU 可输出 ~6,261 tokens/s，而在每用户 100 tokens/s 下仅为 ~562 [S621]。更快的档位每 token 成本高出 ~11×（估计）[S622]。
- **电力是硬约束。** 在每用户 50 tokens/s 下，按全口径功耗计，GB300 NVL72 每兆瓦产出 ~3.0M tokens/s，H200 仅 ~225k，相差 ~13× [S621,S622]。🟡 英伟达（NVIDIA）宣称 Vera Rubin 搭配 Groq LPX 可将每瓦 token 数提升 35× [S113,S90003]。
- **英伟达最后一次披露的数字：截至 Q2 FY2025 的一年中，推理占数据中心收入 >40%，意味着 ≥$33B** [S11011,S441]。🔴 若维持这一占比，最近一年 $277.7B 的数据中心收入中将有 ~$111B 来自推理，但此后从未再披露拆分 [S405]。
- **管理层如今只作定性表述。** 其提到“推理需求出现拐点”，以及截至 2027 年 Blackwell 加 Rubin 合计 $1T 的需求 [S409,S90001]。
- **看空要点：推理比训练更容易被争夺。** 推理请求彼此独立，每 token 成本也容易做基准测试。谷歌 TPU 运行 Qwen3.5 397B 的成本为每百万 token ~$0.18，而 B200 为 ~$0.22 [S625]。

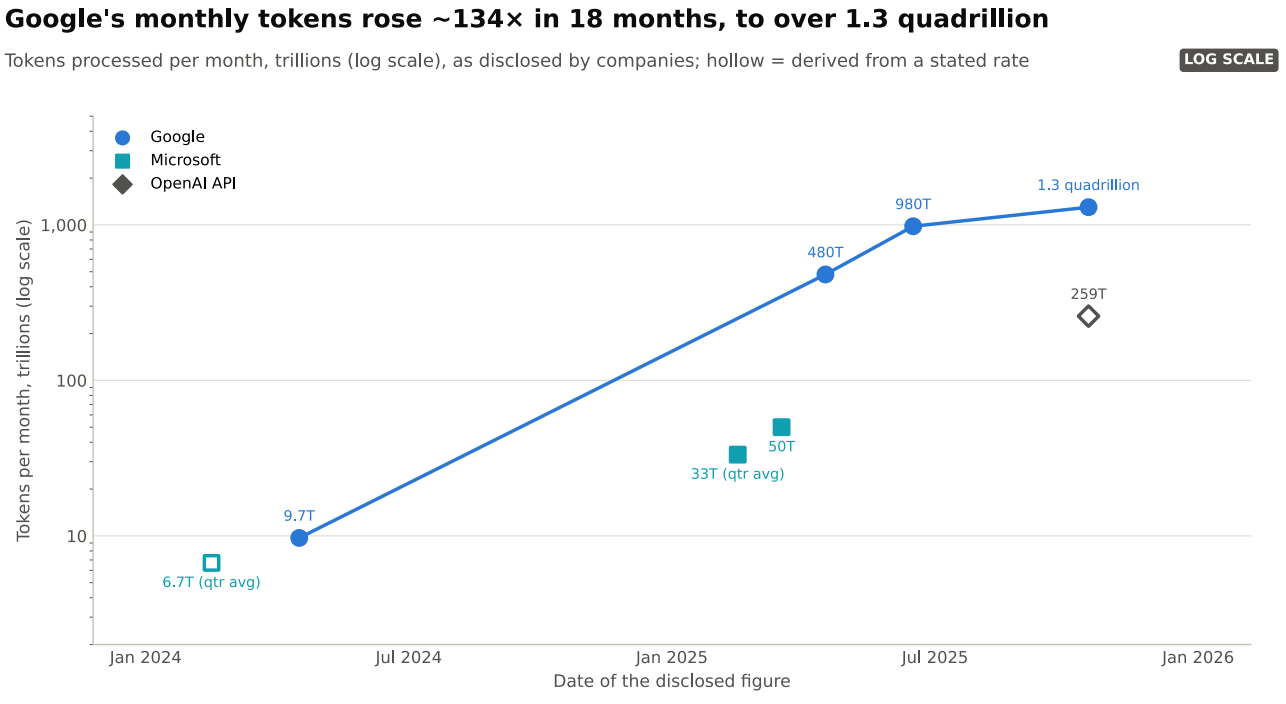

Source: data from Alphabet, Microsoft and OpenAI executive remarks [S32018] [S32019] [S32020] [S32021] [S32022]; chart by repo · As of 2026-11-05

> 已披露 AI token 量的对数坐标图：谷歌从每月 9.7 万亿 token（2024 年 4 月）增至 480 万亿（2025 年 4 月）、约 980 万亿（2025 年年中），并在 2025 年 10 月超过 1.3 千万亿，18 个月内增长约 134 倍。微软在 2025 年 1–3 月处理了超过 100 万亿 token（为一年前的 5 倍），仅 3 月就达 50 万亿；OpenAI 的 API 在 2025 年 10 月约为每分钟 60 亿 token，约合每月 259 万亿。

为什么推理模型与智能体会成倍放大 token 需求

类比。 聊天机器人像一台自动售货机：一个问题，一个答案。推理模型像一位顾问，回复之前先写好几页草稿。智能体则像一个项目团队，每走一步都要把整份卷宗重读一遍。

机制。 推理模型会写出隐藏的“思考” token，这些 token 按输出计费，并消耗完整的解码（decode）时间 [S32024]。智能体则循环往复：规划、调用工具、读取结果、重读不断增长的上下文。每次重读都是预填充（prefill）；每个新想法都是解码（入门 P2）。英伟达 CEO 在 2025 年表示，推理模型与智能体所需的计算量轻松达到一年前预期的 100×（🟡 厂商说法）[S33020]。

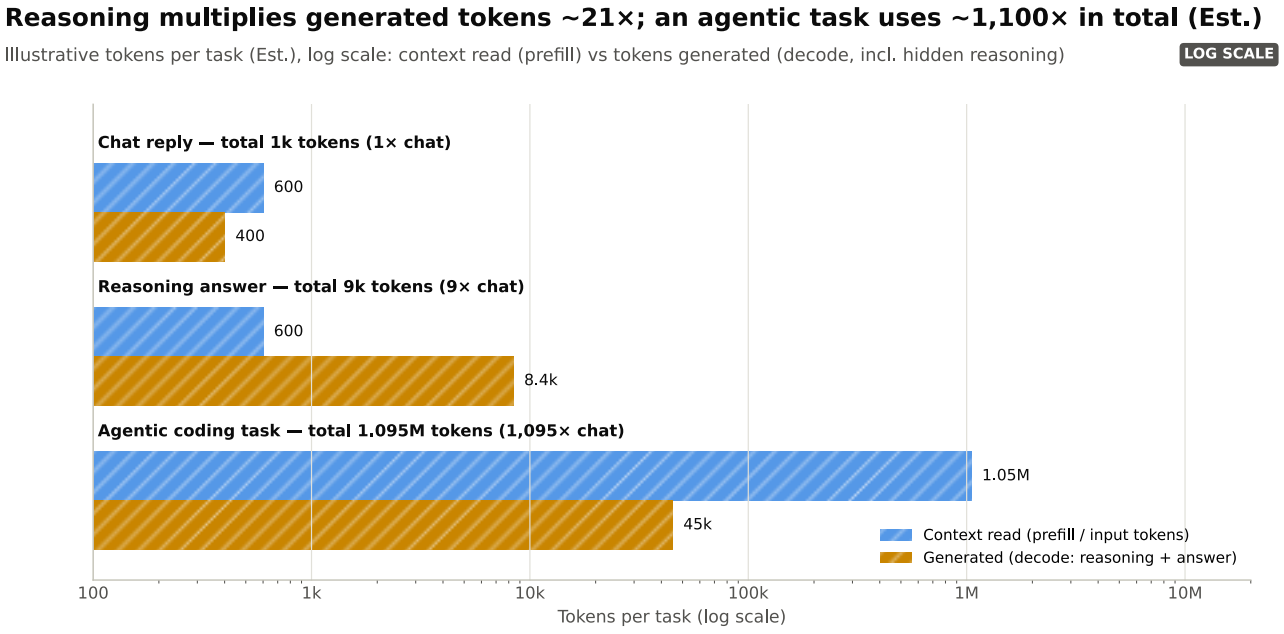

Source: data from repo scenarios; OpenAI reasoning guide [S32025] [S32024]; chart by repo · As of 2026-11-05

每项任务 token 数的示意性对数坐标柱状图：一次聊天回复读取约 600 个 token、生成 400 个；一次推理型回答生成约 8,400 个（大部分为隐藏思考），多出 21 倍；一个 30 轮的智能体编程任务重读约 105 万个上下文 token、生成约 4.5 万个，约为聊天总量的 1,095 倍。

提示

算例 —— 服务一个智能体编程任务的成本。 本资料库的示例任务读取 ~1.05M 个上下文 token，生成 ~45k 个（估计）[S32025]。

	GB300 NVL72	H200
每用户 50 tokens/s 下的每 GPU tokens/s	~6,261	~308
每 GPU 小时的所有者成本（估计）	$2.31	$1.22
每百万 token 成本（$）= 成本 ÷（tokens/s × 3,600）× 10^6	~$0.10	~$1.10
~1.1M 个 token 的成本	~$0.11	~$1.20

输入数据 [S621,S622]；计算过程 [S11000]。🔴 此为上限：缓存的前缀使重读比解码更便宜。仅解码一项，在每用户 50 tokens/s 下就需 ~15 分钟，150 tokens/s 下需 5 分钟。**商业解读：** 智能体同时奖励便宜的 token 和快速的 token，这有利于最新一代机架。

延迟与吞吐量：前沿曲线

机制。 一块 GPU 通过批处理（batching）同时服务许多用户。批次越大，每 GPU 的 token 数越高，但每个用户的速度越慢，因为每个解码步骤都要等整个批次完成。把每种配置画在“每用户 tokens/s（交互速度）—每 GPU tokens/s”的坐标上，其上包络线就是帕累托前沿。

At 50 tok/s/user, GB300 NVL72 delivers ~20x H200 and ~8x MI355X throughput per GPU

InferenceX Pareto frontiers, DeepSeek-R1-0528, 1k in/1k out, FP4 (FP8 on Hopper/CDNA 3), no speculative decoding

LOG SCALE

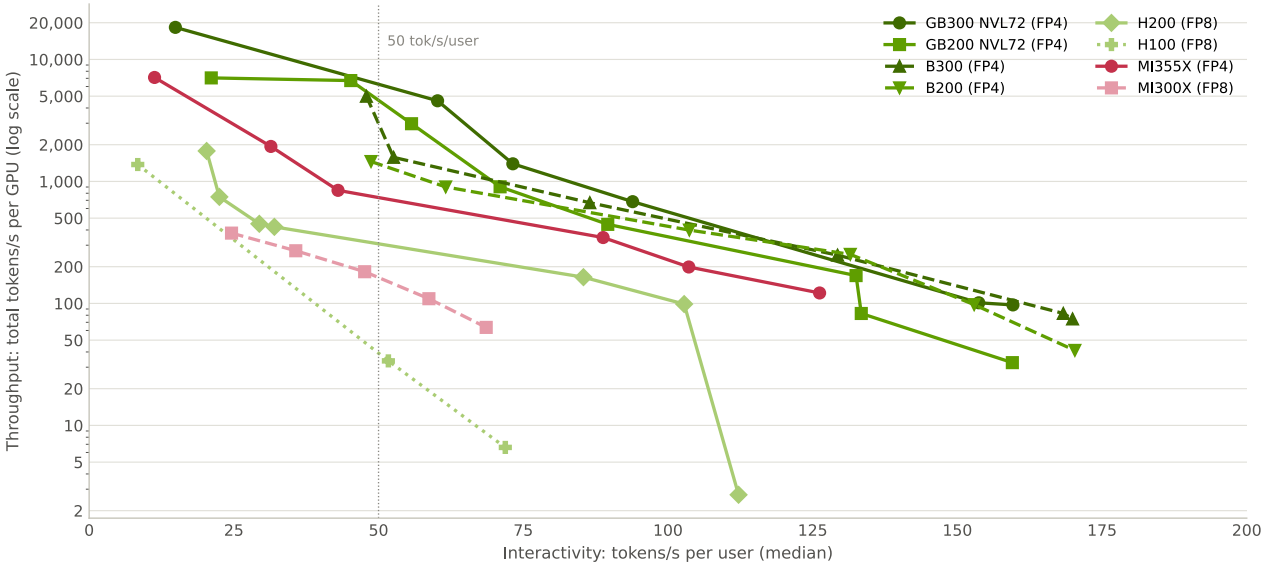

Snapshot subset; each point links to its run in the CSV

Source: data from SemiAnalysis InferenceX public-API snapshot (Oct 2026) [S621] [S622]; chart by repo · As of 2026-11-05

八个系统运行 DeepSeek-R1 时，每 GPU 总 tokens/s 与每用户 tokens/s 关系的对数坐标帕累托曲线图。按每用户 50 tok/s 插值：GB300 NVL72 约 6,261、GB200 NVL72 约 4,625、B300 约 2,982、B200 约 1,387、MI355X 约 738、H200 约 308 tokens/s（每 GPU）。机架级 NVL72 系统在中低交互速度区间占据主导；随着交互速度提高，所有曲线都急剧下降。

提示

算例 —— 为什么快速档位必须贵 ~11×。 GB300 NVL72 在每用户 50 tokens/s 下每 GPU 输出 ~6,261 tokens/s，在 100 tokens/s 下为 ~562（插值）[S621]。在每 GPU 小时 $2.31 的固定成本下 [S622]，每百万 token 成本从 ~$0.10 升至 ~$1.14（估计）[S11000]。**商业解读：**要为高端用户把阅读速度翻倍，每 token 价格需提高 ~11×，才能让每 GPU 小时赚到同样的钱。

[Q1 · 职能与失效后果] 本层在每个延迟档位上把 GPU 小时转化为 token。若本层薄弱，同一芯片的 token 产出就会减少：在硬件不变的 GB300 NVL72 上，2025 年 9 月与 2026 年 9 月的软件版本之间，MLPerf 吞吐量相差 2.9× [S601,S603]。

[Q2 · 关键指标]

指标	为何重要	示例数值
给定每用户 tokens/s 下的每 GPU tokens/s	一块 GPU 在某产品档位上的创收能力	GB300 NVL72 在 50 下为 ~6,261 [S621]
每兆瓦 tokens/s（全口径功耗）	受电力约束站点的创收能力	GB300 NVL72 ~3.0M；H200 ~225k [S621,S622]
给定交互速度下的每百万 token 成本（$）	单位成本与 API 价格对比	GB300 在 50 下 ~$0.10，在 100 下 ~$1.14（估计） [S622]
首 token 延迟（TTFT）与有效吞吐量（goodput）	满足延迟目标的流量占比	Dynamo 的 Planner 按 TTFT 与 token 间延迟目标自动扩缩容 [S11001]
每项任务的 token 数	把用户数换算为算力需求	为聊天回复的 ~21× 至 ~1,100×（估计） [S32025]

注意

误区与事实：“推理是大宗商品，所以每 FLOP 最便宜的芯片会胜出。”解码受限于内存带宽、KV 容量和互连，而非 FLOPs [S32027]。在每用户 50 tokens/s 下，NVL72 机架的每 GPU 性能领先 MI355X ~8× [S621]。但在另一个模型上、每用户 100 tokens/s 时，谷歌 TPU 比 B200 便宜 ~18% [S625]。答案取决于模型和档位。

🔧 技术细节：InferenceX 前沿曲线是如何测量的

SemiAnalysis 的 InferenceX 每晚在各系统上跑遍不同引擎、并行设置和并发度，保留最优点作为前沿曲线[S620,S621]。吞吐量统计每 GPU 的输入加输出 token 数；交互速度取每用户 tokens/s 的中位数。每百万 token 成本以 SemiAnalysis 估算的所有者每 GPU 小时总拥有成本（TCO）除以吞吐量得出[S622]：这是估算值，而非价格。

每兆瓦每秒 token 数：AI 工厂的核心指标

一个站点的电网接入容量是固定的，因此稀缺的投入是电力。英伟达因而以每兆瓦每秒 token 数来推销其 AI 工厂。

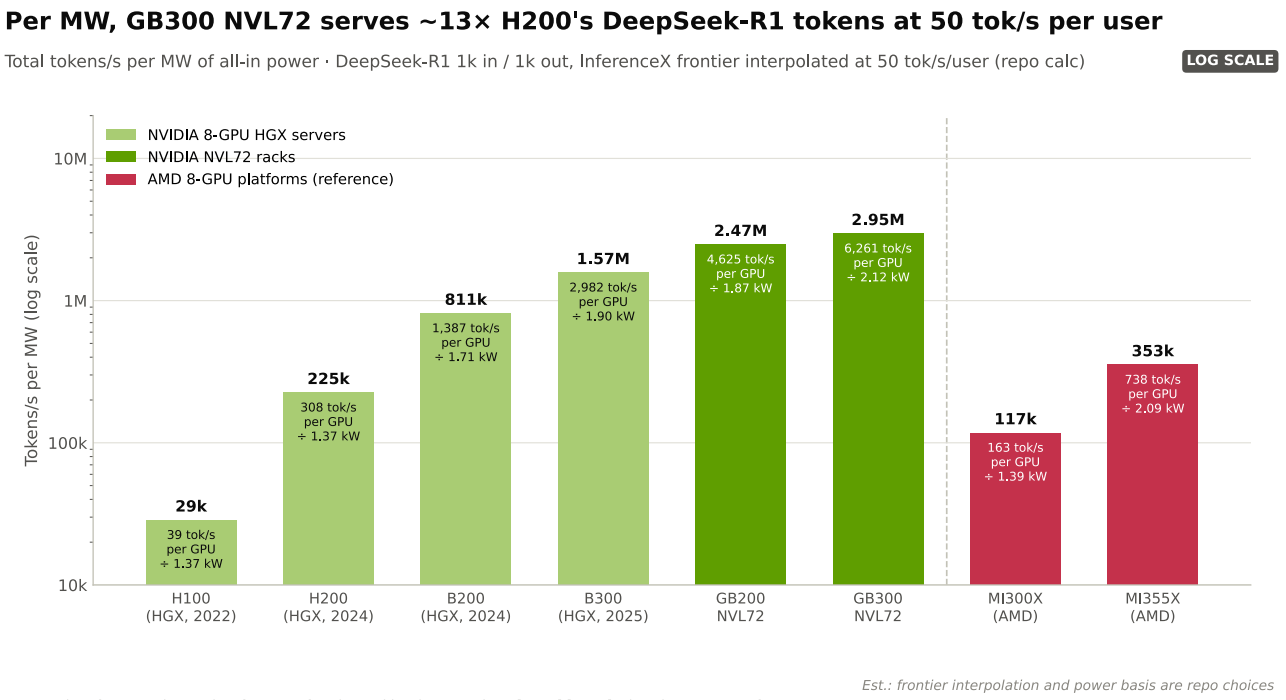

对数坐标柱状图：在每用户 50 tokens/s 下，DeepSeek-R1 按全口径功耗计算的每兆瓦每秒 token 数（InferenceX 前沿值除以 SemiAnalysis 每 GPU 功耗）：H100 约 2.9 万，H200 约 22.5 万，B200 约 80 万，B300 约 160 万，GB200 NVL72 约 250 万，GB300 NVL72 约 300 万，约为 H200 的 13 倍；AMD MI300X 约 11.7 万，MI355X 约 35.3 万。

提示

算例 —— 一个 100 MW 站点的产出。 GB300 NVL72 全口径每 GPU 功耗 ~2.12 kW，因此每 GPU ~6,261 tokens/s 折合每兆瓦 ~2.95M tokens/s[S621,S622]。一个满载的 100 MW 站点每秒产出 ~295M 个 token，30 天的月份合计 ~765 万亿：相当于谷歌 2025 年 10 月月度 token 量的 ~59%[S32020]。若全部部署 H200，则只有 ~58 万亿。🔴 假设单一工作负载满负荷运行。**商业解读：**在电力固定的情况下，更新的机架意味着产能扩张，而不仅仅是降本。

英伟达收入中有多少来自推理?

NVIDIA last sized inference at >40% of Data Center revenue in mid-2024: ≥$33B a year

Trailing-four-quarter Data Center revenue, US$ B; hatched = inference at management's estimate; dotted = 40% for scale only

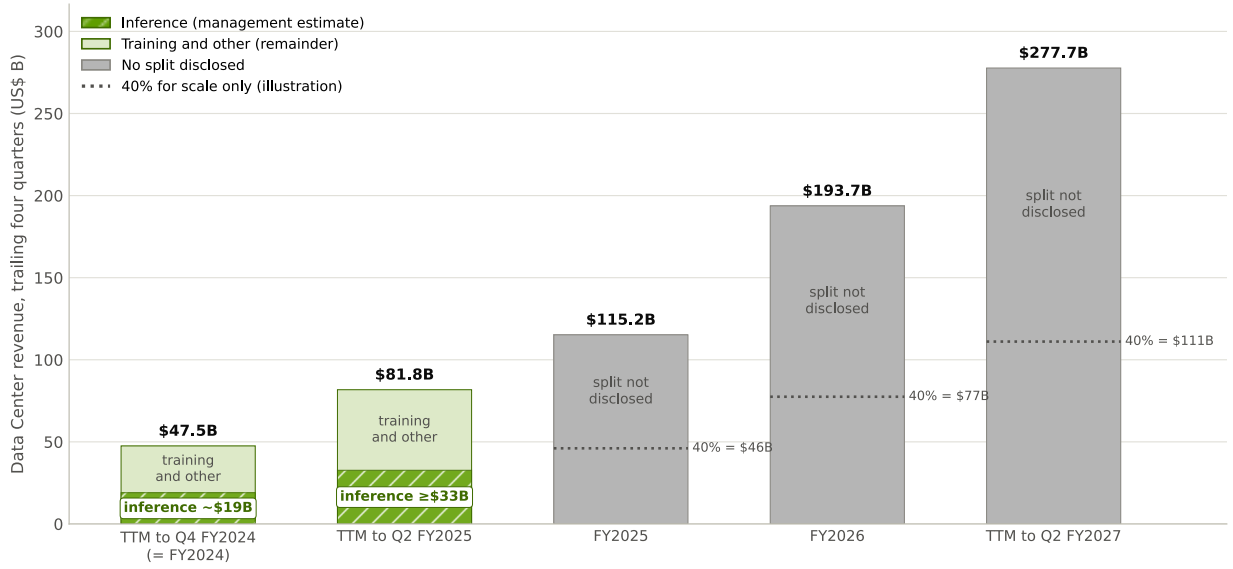

Source: data from NVIDIA earnings calls and results; repo math [S9516] [S11011] [S436] [S422] [S437] [S423] ...; chart by repo · As of 2026-11-05

英伟达数据中心收入滚动十二个月柱状图。截至 Q4 FY2024 为 $47.5B，据管理层估计其中约 40%（~$19B）为推理；截至 Q2 FY2025 为 $81.8B，其中推理占 40% 以上（至少 ~$33B）。之后的柱子——FY2025 $115.2B、FY2026 $193.7B、截至 Q2 FY2027 的一年 $277.7B——均无披露拆分；虚线标记仅为示意规模，显示 40% 对应的数值（最近一年为 $111B）。管理层如今称推理为主要增长动力，但不再给出百分比。

提示

算例 —— 隐含的推理收入。 CFO 估计，截至 Q4 FY2024 的一年（~$47.5B）中 ~40% 为推理，约合 $19B [S9516,S439]。对于截至 Q2 FY2025 的一年，她称 ~$81.8B 中“超过 40%”来自推理，即至少 ~$33B [S11011,S441]。此后，截至 Q2 FY2027 的一年数据中心收入达到 $277.7B [S405,S403,S402]。🔴 即便占比仅维持不变，推理收入也将达 ~$111B。**商业解读：**方向很清楚；规模则是模型推算，而非公司披露。

这一拆分本身并不精确。同一批 GPU 既做训练又做推理服务，而强化学习后训练会生成海量的 rollout token：这是被记作训练的推理工作（🔴 本资料库分析）。

注

🐂 **看多观点。** 随着推理模型与智能体普及，每项任务的 token 数不断复利增长 [S32025]。交互速度分档奖励最新一代机架，软件也在持续提升已部署设备的产出 [S603]。在这一经常性市场中，英伟达在每兆瓦 token 数上处于领先 [S621,S622]。

注意

🐻 **看空观点。** 推理可拆分为小型、相互独立的任务，并不需要英伟达的训练互连网络。每 token 成本易于基准测试且可多源采购，TPU 和定制 ASIC 正是借此切入 [S625]。稀疏模型、FP4 与缓存技术降低每 token 所需硬件的速度，可能快于需求增长。

🎯 企业发展视角

1. **价格随延迟档位而定。** 在同一机架上，每用户 50 到 100 tokens/s 之间，每 token 成本上升 ~11×（估计）[S622]。哪些客户愿意为快速档位付费？在延迟要求宽松的场景中，更便宜的加速器能在哪里胜出？
2. **每兆瓦 token 数是采购指标。** 挑战者需要在这一维度上拿出独立的、与工作负载匹配的数据。高通（Qualcomm）的 AI200 和 AI250 [S173] 在这一指标上表现如何？
3. **推理收入占比未予披露。** 任何训练与推理的收入拆分都依赖 2024 年的数据 [S11011]。哪些信息可以更新这一判断：超大规模云厂商的表态、基准测试量、token 披露？
4. **智能体改变了产品形态。** 长生命周期的上下文更看重容量、KV 卸载和高速网络。无论采用哪种加速器，哪些内存、存储和网卡（NIC）供应商都会受益？

同一硬件上的软件增益

第 11 层 · 推理与 AI 软件 · 约 8 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **已部署的 GPU 在购买后还会持续变快。** 在 MLPerf Inference 中，硬件不变的 GB300 NVL72 在 2025 年 9 月至 2026 年 9 月间，DeepSeek-R1 每 GPU 吞吐量从 2,907 提升到 8,291 tokens/s，增长 2.9×；GB200 NVL72 提升 2.4× [S601,S603]。
- **新架构的提升空间最大。** 英伟达（NVIDIA）公布的 B200 运行 DeepSeek-R1 数据，在数月之内最低延迟速度提升 5.5×，峰值吞吐量提升 2.3× [S645,S646]。稠密模型 Llama 70B 在四个 TensorRT-LLM 版本中的变化幅度则保持在 ~8% 以内 [S641,S644]。
- **软件增益就是成本削减。** 在每 GPU 小时所有者成本固定的前提下，估计每百万 token 成本在 GB300 上下降 65%（$0.22 → $0.08），在 B200 上下降 57%（$0.24 → $0.10）（估计） [S622,S603,S646]。
- **对一个 1,008 块 GPU 的 GB300 机群而言，2.85× 的增益可避免 ~$100M 的资本开支**，相当于在旧软件下需额外购置的 ~1,865 块 GPU 的价格（估计） [S332,S11000]。
- **这些增益并非英伟达独享。** 在独立的每晚测试中，B200 在 SGLang 上六个月内提升 34%，AMD 的 MI355X 提升 29% [S621]。AMD 报告其在 Qwen3.5 上三个月内最高提升 19× [S632]。
- **宣传数字往往混合了硬件与软件。** Dynamo 的“每 GPU 7×”是拿使用 Dynamo 的 GB200 NVL72 与未使用 Dynamo 的 B200 相比 [S11001]；仅更大的 NVLink 域一项就贡献了 ~3.5×（🔴 粗略拆分） [S621]。

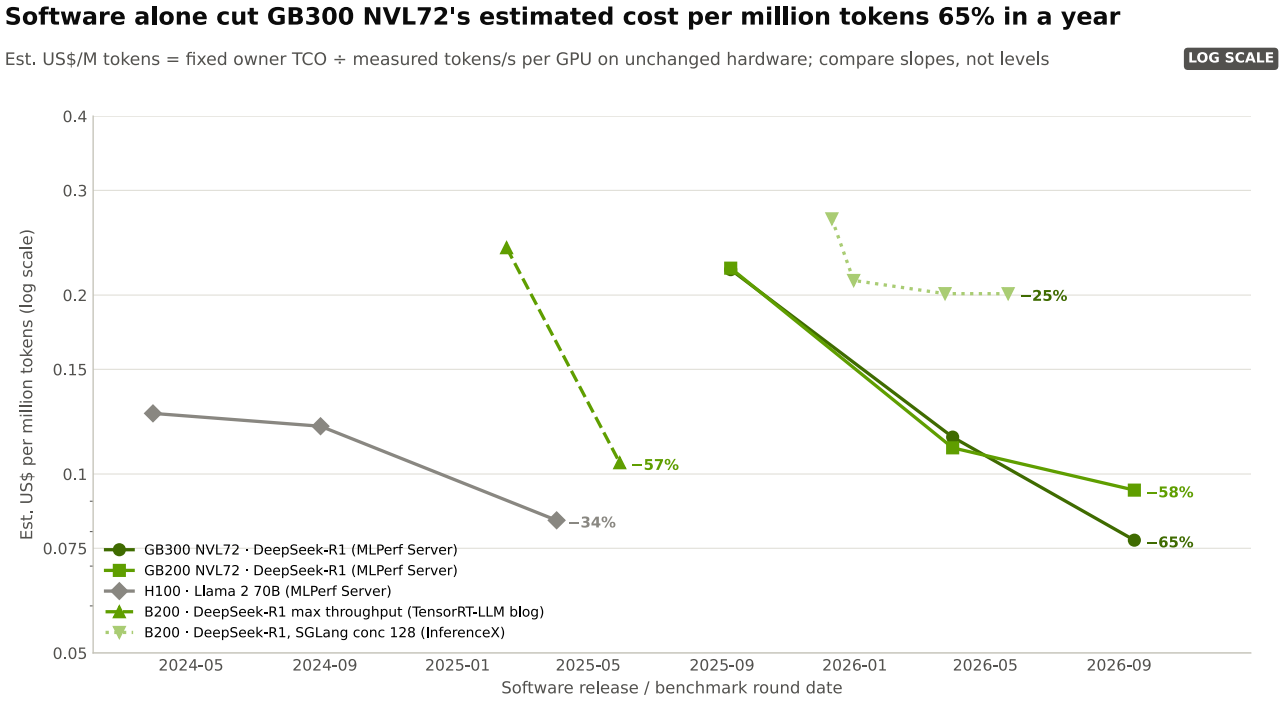

Source: data from MLPerf Inference; TensorRT-LLM blog; InferenceX + TCO; repo math [S601] [S602] [S603] [S604] [S605] [S600] ...; chart by repo · As of 2026-11-05

对数坐标折线图：在硬件不变、每块 GPU 的所有者 TCO 固定的前提下（SemiAnalysis：GB300 $2.31、GB200 $1.86、B200 $1.73、H100 $1.17 每 GPU 小时），随着软件改进，英伟达硬件的估计每百万 token 成本变化。GB300 NVL72 · DeepSeek-R1（MLPerf Server）：$0.221 降至 $0.077（下降 65%，2025 年 9 月至 2026 年 9 月）；GB200 NVL72 · DeepSeek-R1（MLPerf Server）：$0.222 降至 $0.094（下降 58%，2025 年 9 月至 2026 年 9 月）；H100 · Llama 2 70B（MLPerf Server）：$0.126 降至 $0.084（下降 34%，2024 年 3 月至 2025 年 4 月）；B200 · DeepSeek-R1 最大吞吐量（TensorRT-LLM 博客）：$0.240 降至 $0.104（下降 57%，2025 年 2 月至 2025 年 5 月）；B200 · DeepSeek-R1，SGLang 并发 128（InferenceX）：$0.269 降至 $0.201（下降 25%，2025 年 12 月至 2026 年 5 月）。硬件账单没变，变的是每 GPU 吞吐量，因此每 token 成本下降。

增益从何而来

类比。 新芯片好比一条新修的高速公路。软件则是随后到来的交通管理：车道标线、匝道信号灯、快速车道。道路本身没变，但每小时通过的车辆可以翻倍。

机制。 GPU 出厂时是针对上一代模型调优的。每种新架构都需要新的工作：潜在注意力（latent attention）、混合专家路由、FP4 配方、多 token 预测。英伟达在 B200 上针对 DeepSeek-R1 的优化，综合运用了定制注意力与 MoE 内核、更大范围的专家并行、CUDA graphs 以及多 token 预测 [S645,S646]。随后，机架级的增益来自通过 Dynamo 实现的分离式服务，它被列入英伟达 v6.0 MLPerf 提交的软件栈中 [S602]。

Software alone lifted GB300 NVL72 DeepSeek-R1 MLPerf throughput 2.9x in a year

Per-GPU throughput of the same NVIDIA-submitted system across MLPerf Inference rounds, indexed to first round = 1.0

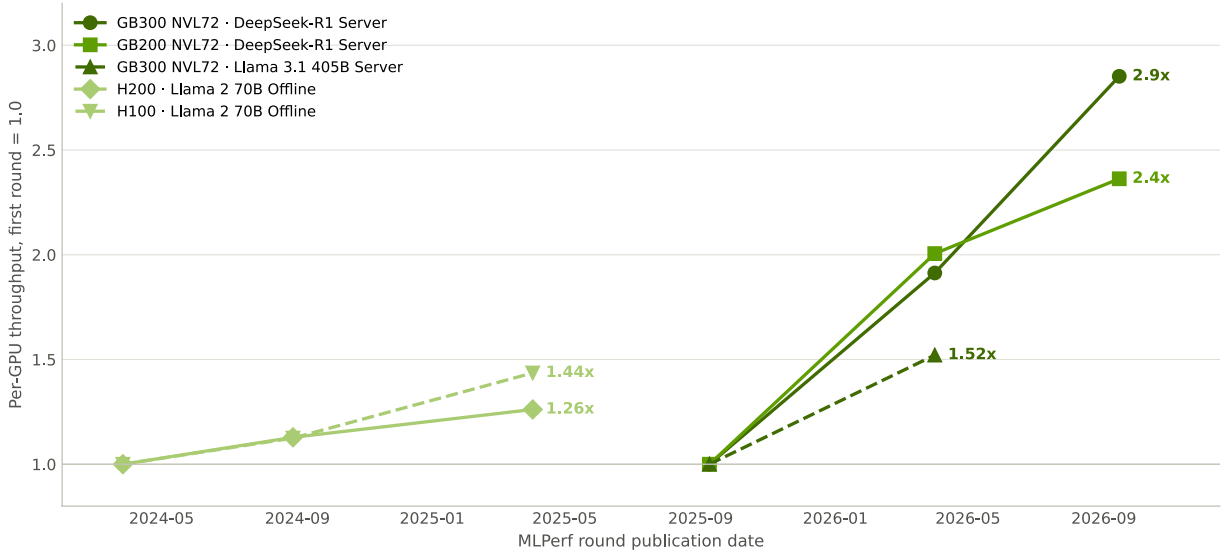

Source: data from MLCommons MLPerf Inference v4.0-v6.1 results [S601] [S602] [S603] [S604] [S605] [S600]; chart by repo · As of 2026-11-05

折线图：硬件不变的英伟达系统在历轮 MLPerf Inference 中的每 GPU 吞吐量。GB300 NVL72 运行 DeepSeek-R1 Server 从每 GPU 2,907 提升到 8,291 tokens/s（2.9 倍，2025 年 9 月至 2026 年 9 月）；GB200 NVL72 提升 2.4 倍；GB300 运行 Llama 3.1 405B 提升 1.5 倍；一年内 H100 运行 Llama 2 70B 提升 1.44 倍，H200 提升 1.26 倍。增益来自 TensorRT-LLM、Dynamo 和更新的服务配方，而非新芯片。

提示

算例 —— 为什么新模型的增益最大。 Llama 70B 级模型自 2023 年起就在 CUDA 上运行；在 2025 年的四个 TensorRT-LLM 版本中，B200 运行 Llama 3.3 70B 的吞吐量始终在每 GPU ~6,434 到 ~7,007 tokens/s 之间 [S641,S642,S643,S644]。DeepSeek-R1 是一个 671B 参数的混合专家推理模型，在同样的 B200 上，大约四个月内吞吐量提升 2.3×，最低延迟速度提升 5.5× [S645,S646]。**商业解读：** 每出现一个新的模型家族，软件增益就会再来一次；而每个新家族都是客户继续留在率先完成调优的平台上的理由。

Same B200, new software: DeepSeek-R1 speed up 5.5x in four months; dense Llama 70B flat

NVIDIA-published per-GPU performance on unchanged hardware across software releases, indexed to first point = 1.0

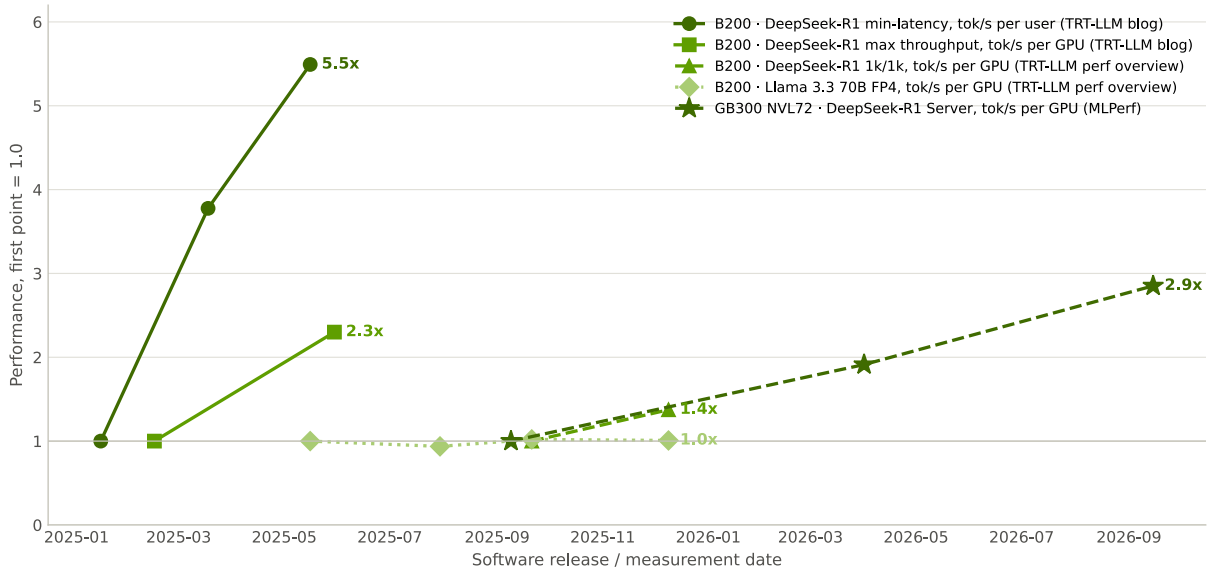

Source: data from NVIDIA TensorRT-LLM docs and blogs; MLCommons [S645] [S646] [S643] [S644] [S641] [S642] ...; chart by repo · As of 2026-11-05

> 折线图：英伟达公布的同一 GPU 性能随时间的变化。B200 运行 DeepSeek-R1 的最低延迟速度从每用户 67 提升到 368 tokens/s（5.5 倍，2025 年 1–5 月）；B200 运行 DeepSeek-R1 的最大吞吐量从每 GPU 2,000 提升到 4,600 tokens/s（2.3 倍）；GB300 NVL72 MLPerf DeepSeek-R1 Server 一年提升 2.9 倍；而 B200 运行 Llama 3.3 70B 的最大吞吐量在四个 TensorRT-LLM 版本中变化不超过 8%。MoE 模型从软件中获益最多。

[Q3 · 代际进步] 两条轴线相互叠加。**硬件代际**把每用户 50 tokens/s 下 DeepSeek-R1 的前沿从 H200 的每 GPU ~308 tokens/s 推升到 GB300 NVL72 的 ~6,261，提升 ~20× [S621]。**软件代际**又在同一 GB300 上一年内追加了 ~2.9× [S603]。

🔧 技术细节：MLPerf 的“Server”场景测量什么

MLPerf Inference 的封闭组（closed division）固定模型和精度目标，因此提交方无法以牺牲质量换取速度 [S600]。*Offline* 场景在所有查询都已就绪的情况下测量原始吞吐量。*Server* 场景在随机时间发送查询，并强制执行延迟上限，包括首 token 延迟和每输出 token 时间。英伟达在 v6.0 的 GB300 提交中把 Dynamo 加入了软件清单 [S602]。

2–3× 的软件增益价值几何

提示

算例 —— 一个 1,008 块 GPU 的 GB300 机群（14 个 NVL72 机架）。

	2025 年 9 月软件	2026 年 9 月软件
MLPerf DeepSeek-R1 Server，每 GPU tokens/s	2,907	8,291
每 GPU 小时所有者成本（估计）	$2.31	$2.31
机群年度成本（× 8,760 h）	~$20.4M	~$20.4M
70% 利用率下的年 token 产量	~65 万亿	~185 万亿
每百万 token 成本	~$0.32	~$0.11
按示意价格每百万 $0.40 计算的毛利	~$5.5M	~$53M

输入数据 [S601,S603,S622]；利用率和价格为 🔴 示意性假设；计算过程 [S11000]。若使用旧软件，同样的产出需要 ~2,870 块 GPU，即多出 ~1,865 块。按每机架 ~$4.0M（每 GPU ~$55K，估计，摩根士丹利）[S332] 计算，相当于避免了 ~$100M 的资本开支。**商业解读：**软件能把一个勉强划算的部署变成一个回报可观的部署，并使英伟达的存量设备不易被更便宜的芯片替代。

有两股力量限制了客户的意外之财。其一，随着所有人的软件都在进步，token 价格随之下降，增益被传导给终端用户。其二，许多增益来自竞争对手同样在用的开源引擎（SGLang、vLLM）[S621,S580,S582]。英伟达的持久收益更为微妙：每一次提升，都会抬高竞争芯片在每 token 成本上必须跨越的门槛。

注意

误区与事实：“软件增益本身就是英伟达的护城河。”AMD 同样能获得这些增益：MI355X 在 SGLang 上六个月内提升 29% [S621]，在 Qwen3.5 397B 上三个月内最高提升 19× [S632]。英伟达的优势在于，它的增益通常最先到来，在新模型发布的第 0 天就已就绪（第 09 层）。

Software alone: B200 DeepSeek-R1 throughput +34% and MI355X +29% in six months

InferenceX, DeepSeek-R1-0528 1k/1k, same GPU, engine, concurrency and parallelism; total tokens/s per GPU, first run = 1.0

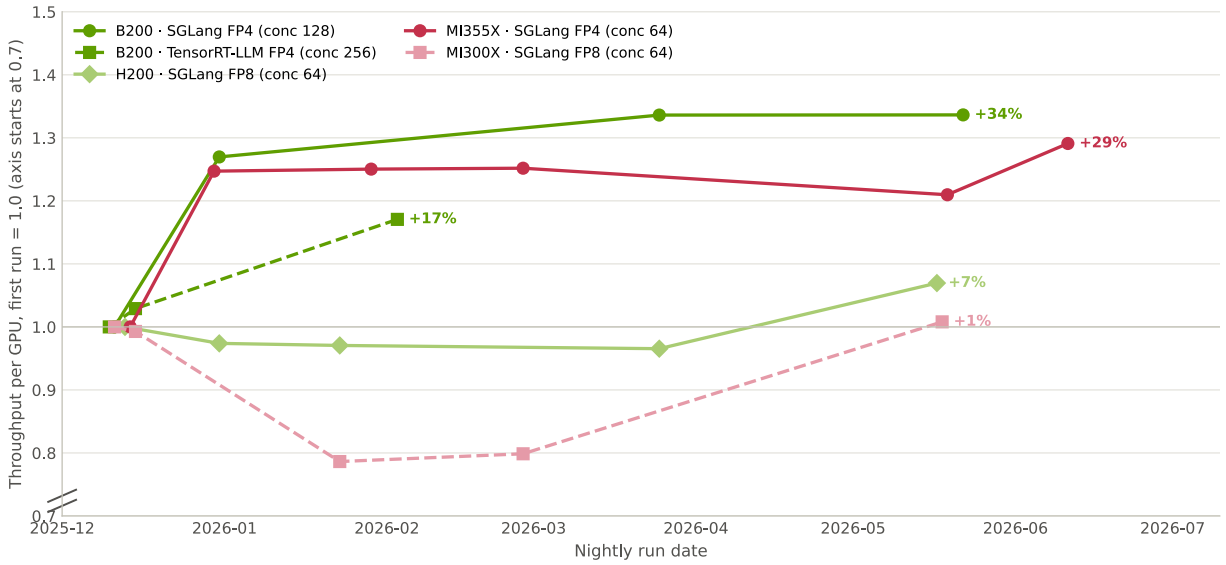

Source: data from SemiAnalysis InferenceX public-API history snapshot [S621] [S622]; chart by repo · As of 2026-11-05

折线图：2025 年 12 月至 2026 年 6 月，InferenceX 在硬件和设置均不变情况下的每晚测试结果。B200 · SGLang FP4（并发 128）+34%；B200 · TensorRT-LLM FP4（并发 256）+17%；H200 · SGLang FP8（并发 64）+7%；MI355X · SGLang FP4（并发 64）+29%；MI300X · SGLang FP8（并发 64）+1%。开源引擎更新（SGLang、TensorRT-LLM、ROCm/AITER）在两家厂商的固定芯片上都带来了两位数的增益，而较老的 CDNA 3 产品曾出现性能回退，之后才恢复。

如何解读厂商的基准测试

宣传类型	需要核查什么	示例
“快 N×”	与基线是否为同一硬件?	Dynamo 的“7×”是使用 Dynamo 的 GB200 NVL72 对比未使用 Dynamo 的 B200 S11001
峰值吞吐量	在每用户多少 tokens/s 下?	GB300 在 50 下为 ~6,261，但在 100 下仅 ~562 S621
每 GPU 数值	是否同时计入预填充池和解码池?	分离式 B200 数据点用了 44 块 GPU S621
精度	FP4 还是 FP8? 精度是否保持?	MLPerf 封闭组固定精度要求 S600
token 口径	输入加输出，还是仅输出?	InferenceX 两者都计；英伟达博客往往只计输出 S621,S646
每 token 成本	所有者 TCO 还是租用 TCO?	每 GB300 小时所有者成本 $2.31，租用 ~$5.00 S622

> **提示**
>
> **算例 —— 把一个宣传数字拆分为硬件与软件贡献。** Dynamo 的 README 称，在 DeepSeek-R1 上每 GPU 吞吐量提高 7×，对比对象是使用 Dynamo 的 GB200 NVL72 与未使用 Dynamo 的 B200 S11001。InferenceX 显示，在每用户 ~49 tokens/s 下，仅 72-GPU NVLink 域一项相对 8-GPU B200 就带来 ~3.5× S621。剩下的 ~2× 归于 Dynamo、分离式服务和调优（🔴 粗略拆分；工作点不同）。**商业解读：**对每一个“N×”宣传都要追问：多少需要新硬件，多少是软件更新就能为存量机群带来的?

🎯 企业发展视角

1. **软件提升是留住客户的工具。** 已部署 GPU 上 2–3× 的提升 S603 推迟了更换周期。这会如何改变挑战者为替换一个已部署机架所必须承诺的投资回收期?
2. **基准测试是兵家必争之地。** MLPerf、InferenceX 和厂商博客测量的是不同的东西 S600,S621,S646。支持中立的基准测试或调优服务是否有价值?
3. **第 0 天调优能力是稀缺资产。** 增益集中在模型发布后的几个月内 S645,S646。能在新架构上快速推进的内核团队才是关键的人才池。
4. **折旧逻辑发生变化。** 购买后 2–3× 的提升，支撑了多数超大规模云厂商目前采用的 5–6 年服务器使用寿命 S382,S383,S384。亚马逊在 2025 年将部分服务器的折旧年限缩回 5 年 S385。对于增益较少的 Hopper 机群，这一逻辑是否依然成立 S621?

TensorRT-LLM 与 Dynamo

第 11 层 · 推理与 AI 软件 · 约 9 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **推理服务软件分三层。** TensorRT 为单块 GPU 编译模型，2026 年已发展到第 11 版 [S11008]。TensorRT-LLM 在单块 GPU 或单个 NVLink 域上运行大语言模型 [S589]。Dynamo 位于 TensorRT-LLM、vLLM 和 SGLang 之上，负责协调整个集群 [S11001]。
- **TensorRT-LLM 开源且原生基于 PyTorch**，自 2025 年 3 月起在 GitHub 上开发 [S589]。其主要手段包括：融合内核、连续批处理（continuous batching）、分页可复用的 KV 缓存、FP8/NVFP4 以及投机解码（speculative decoding） [S11004,S11005,S11006,S11007]。
- 🟢 **Dynamo 1.0 于 GTC 2026（3 月 16 日）以 Apache 2.0 许可发布。** 采用者包括 CoreWeave、Nebius、Together AI、Cursor、Perplexity、PayPal 和字节跳动 [S90066,S520]。1.5.1 版（10 月 6 日）是首个提供企业级支持的版本 [S521]。
- **分离式服务在长提示词上收益最大。** 在 B200 上处理 8k token 提示词时，分离式 Dynamo 配置每 GPU 输出 ~12,147 tokens/s，而最优的聚合式配置为 ~4,815，相差 ~2.5× [S621]。若提示词为 1k token，聚合式配置在低交互速度下领先 [S621]。
- **KV 缓存像库存一样被管理。** KV 感知路由使 Baseten 的首 token 延迟减半 [S11001]。KV 块管理器会把缓存溢出到 CPU、SSD 和远程存储 [S11001]。从 BlueField-4 闪存恢复一个 128K token 的上下文需 ~0.2 s，而重新计算需 ~4.7 s（估计） [S7000,S3012]。
- **弱点：Dynamo 开源且与引擎无关。** 它能提升英伟达（NVIDIA）集群的效率，却不会让工作负载只能跑在英伟达上。AMD 的 MoRI-SGLang 分离式技术栈同样在 MI355X 上创下了前沿数据点 [S621]。

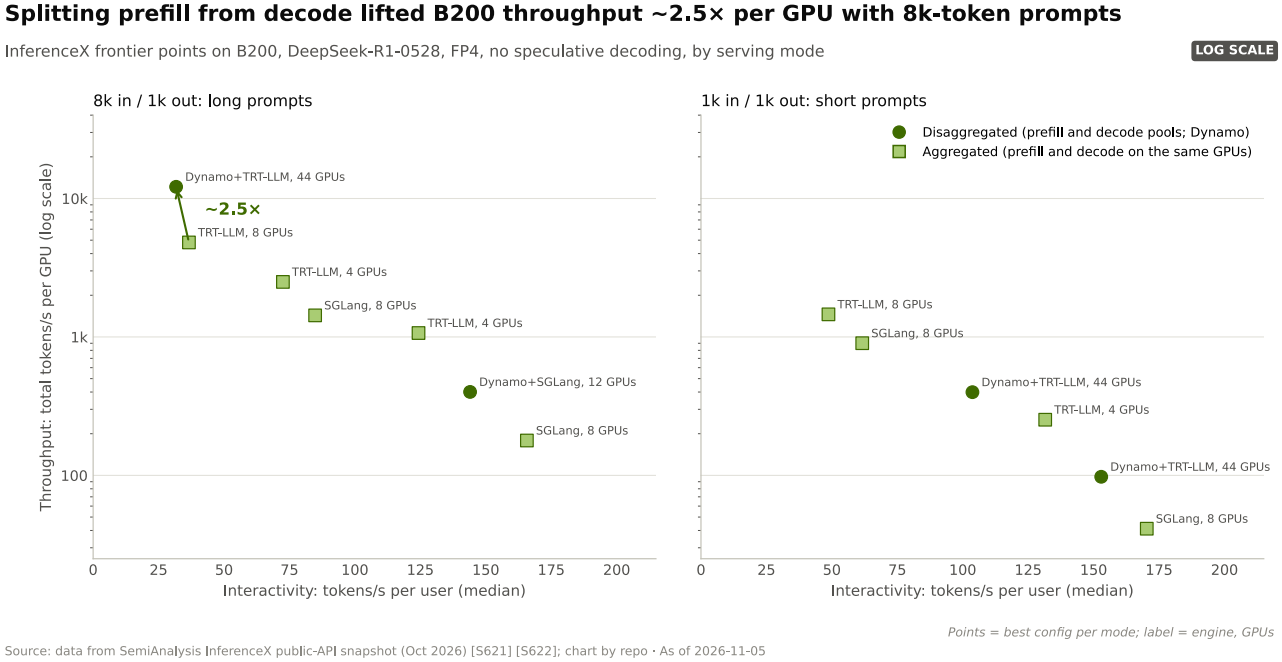

> 按服务模式划分的 B200 前沿数据点双面板对数坐标散点图。左图，8k token 输入、1k 输出：分离式 Dynamo 加 TensorRT-LLM 配置（预填充与解码在不同 GPU 上，共 44 块 GPU）在每用户 32 tokens/s 下每 GPU 输出约 12,147 tokens/s，而最优的聚合式 8-GPU TensorRT-LLM 配置在每用户 37 tokens/s 下约为 4,815，约 2.5 倍。右图，1k 输入、1k 输出：聚合式配置在低交互速度下占据前沿，分离式仅在每用户约 100 tokens/s 以上才出现，因此收益取决于提示词长度。

TensorRT 与 TensorRT-LLM：让单块 GPU 跑得更快

类比。 研究阶段的模型好比一份为家庭厨房写的菜谱。TensorRT 把它改写成餐厅流水线版本：合并步骤、批量备料、每个工位配上合适的设备。

机制。 内核融合（kernel fusion）把多个小型 GPU 程序合并，使中间结果留在片上，而无需往返 HBM。TensorRT-LLM 在此之上增加了针对注意力、GEMM 和混合专家层的定制内核，以及运行时调度 [S589]。

手段	作用	已公布的收益
融合内核与定制内核	减少 HBM 往返；按 GPU 和模型调优	对新架构收益最大 [S645]
动态（连续）批处理	请求每一步都可加入或退出批次	在研究系统中，同等延迟下吞吐量提升 2–4× [S32011,S32012]
分页、可复用的 KV 缓存	固定大小的块；共享前缀可复用；冷块被逐出到主机内存	避免重复计算共享提示词 [S11005]
FP8 与 NVFP4	每个权重和每个缓存 token 占用更少字节	B200 上 NVFP4 解码较 BF16 快 ~2.7×（估计） [S32025,S32017]
投机解码（草稿模型、EAGLE-3、MTP）	由廉价的草稿模型提出候选 token；主模型每次前向验证多个	Llama 3.3 70B 上提速 3×（英伟达数据） [S589]；🟡 GB300 上使用 MTP，在每用户 150 tokens/s 下成本降低 ~21× [S624]

> **提示**
>
> **算例 —— 为什么连续批处理很重要。** 把 64 个请求放进一个静态批次，输出长度在 100 到 2,000 token 之间均匀分布。该批次需运行 ~2,000 步，而请求平均只需 ~1,050 步，因此槽位有 ~48% 的时间处于空闲。连续批处理在请求结束的瞬间就补满空出的槽位，在同一块 GPU 上吞吐量约为原来的 1.9×（🔴 示意性测算） [S11004]。**商业解读：**一块 GPU 能创造多少收入，很大程度上由调度器而非芯片决定。

投机解码只在小批次下有效；TensorRT-LLM 的文档称，加速效果“仅在小批次下可观察到”（"only observable at low batch sizes"） [S11006]。

> 🔧 **技术细节：KV 缓存如何分页与复用**
>
> TensorRT-LLM 把 KV 缓存存储为一个由固定大小块组成的池 [S11005]。写满的块进入一棵基数树（radix tree），因此共享同一提示词前缀的请求可以复用它们。内存不足时，优先级最低、最近最少使用的块会被移到主机内存，并保持可复用 [S11005]。分页存储由 vLLM 的 PagedAttention 推广开来 [S32011]。FP8 和 NVFP4 KV 缓存选项降低了每个缓存 token 占用的字节数 [S11007]。

Dynamo：让一个集群像一台推理机器那样工作

类比。 如果说 TensorRT-LLM 是一间高效的厨房，那么 Dynamo 就是餐厅经理：安排客人入座、分派备菜工作，并在客流高峰到来时加开工位。

机制。 Dynamo 用 Rust 编写并提供 Python 扩展，把多个引擎整合为一个多节点系统 [S11001]。其**路由器**根据负载和已缓存的前缀选择工作节点。**分离式服务**把预填充（prefill）和解码（decode）放在不同的资源池中运行。**KV 块管理器**负责卸载缓存。由 SLA 驱动的 **Planner** 根据延迟目标确定各资源池的规模。**Grove** 在 Kubernetes 上进行成组调度（gang scheduling），并感知 NVL72 拓扑。**ModelExpress** 以流式方式加载权重，使冷启动加快 7× [S11001]。数据传输使用 NIXL，它对 GPU 与 CPU 内存以及文件、块和对象存储做了统一抽象 [S11003]。

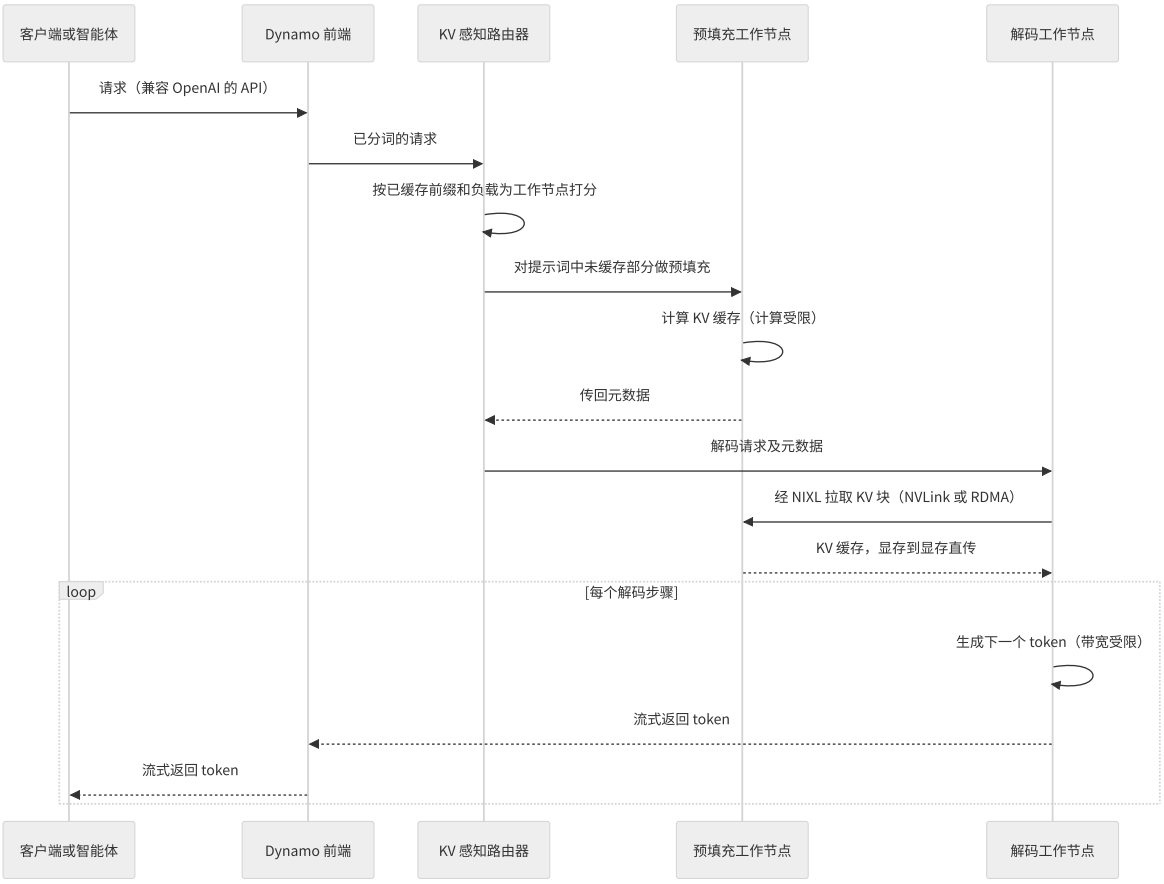

该流程依据 Dynamo 的设计文档；KV 传输是非阻塞的，因此两个工作节点在传输期间仍可继续服务其他请求 [S11002]。

提示

算例 —— 为什么分离式服务能在给定延迟目标下提高每 GPU tokens/s。 InferenceX 在 B200 上以 8,000 个输入 token、1,000 个输出 token 测试 DeepSeek-R1。最优的聚合式配置（8 块 GPU，TensorRT-LLM）在每用户 ~37 tokens/s 下每 GPU 输出 ~4,815 tokens/s。分离式 Dynamo 配置（44 块 GPU，分布在预填充池与解码池中）在 ~32 下输出 ~12,147 [S621]。估计成本从每百万 token ~$0.10 降至 ~$0.04 [S622]。

原因。 每个请求中，每生成 1 个 token 对应 8 个提示词 token。在聚合式配置下，这些预填充被切块后与解码挤在同一步骤中，于是每个用户的下一个 token 都要排在别人的提示词后面 [S11002]；要维持每用户 ~35 tokens/s，只能用小批次。拆分之后，预填充 GPU 可以跑大规模、计算受限的批次，而解码 GPU 则能以稳定的 token 间延迟同时服务大量用户。若提示词为 1k token，干扰较小，聚合式配置在低交互速度区间保住了前沿 [S621]。**商业解读：**在长提示词流量（智能体、RAG）上，同一批 B200 可多产出 ~2.5× 的 token；在短提示词上则可能毫无收益。

Dynamo 的文档提醒，最优拆分方式“不应被编码为一个通用的 token 阈值”（"should not be encoded as a universal token threshold"）[S11002]。Planner 与离线工具 AISimulate 会针对每个模型和流量组合搜索最优配置 [S11001]。

🔧 技术细节：1.0 版新增了什么，以及 Dynamo-Triton

1.0 版新增了零配置部署（beta）：用一个 YAML 文件声明模型、硬件和 SLA；AISimulate 评估候选方案，Planner 设定拓扑 [S11001]。TensorRT-LLM 也可以通过 `trtllm-serve` 独立实现分离式服务 [S11033]。自 2025 年 3 月

18 日起，Triton 推理服务器以 Dynamo-Triton 之名并入 Dynamo 平台 [S11010]；2.74.0 版仍支持非 LLM 模型、CPU 和 AWS Inferentia [S11009]。

KV 缓存经济：路由与卸载层级

智能体和长对话让 KV 缓存成为一种可复用的资产：重新计算要耗费 GPU 时间，保留则要占用内存。Dynamo 的路由器和块管理器决定每份缓存存放在哪里 [S11001]；BlueField-4 上下文内存存储则在机柜组（pod）层面增加了闪存层 [S3012,S3013]。

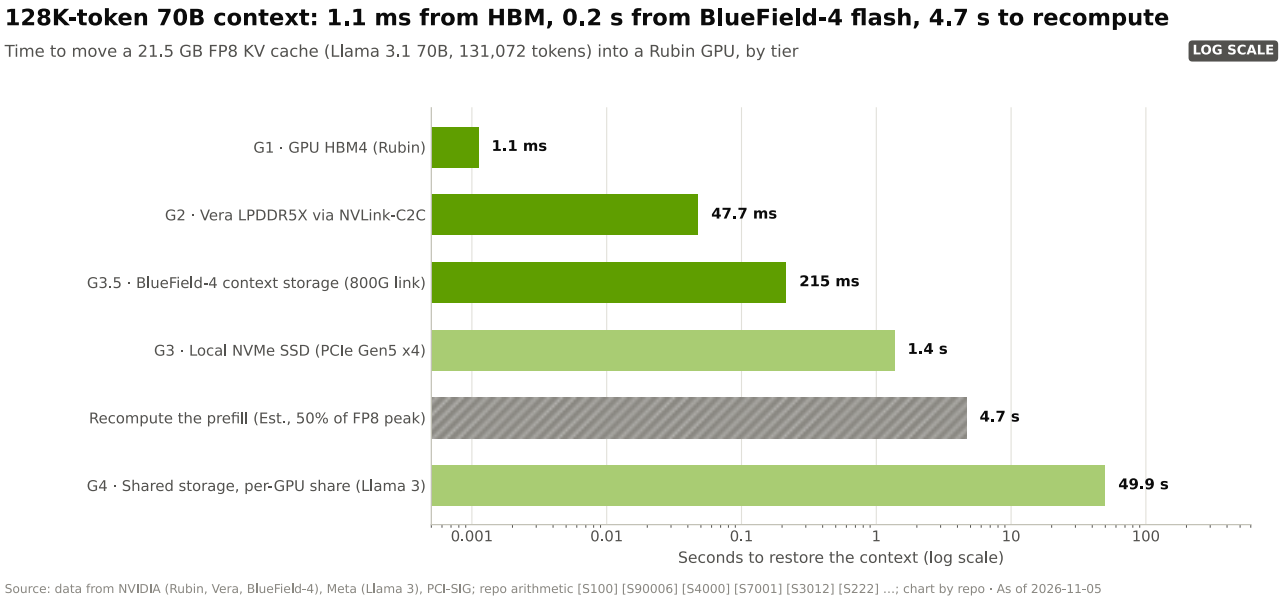

对数坐标水平柱状图：恢复一份 21.5 GB KV 缓存（Llama 3.1 70B，128K token，FP8）所需时间：G1 HBM4（19.2 TB/s）约 1.1 ms；G2 Vera LPDDR5X 经 NVLink-C2C（~450 GB/s）约 47.7 ms；G3.5 BlueField-4 上下文内存存储经 800 Gb/s 链路约 215 ms；G3 单块本地 PCIe Gen5 x4 SSD 约 1.4 s；在 Rubin GPU 上以 50% 稠密 FP8 峰值重新计算预填充约 4.7 s（估计）；按单 GPU 分摊 Meta 7 TB/s Llama 3 存储集群约 50 s。G3.5 层比重新计算快 ~22 倍。

提示

算例 —— 缓存命中对智能体的价值。 一个 128K token 的 Llama 3.1 70B 上下文在 FP8 下为 ~21.5 GB。从闪存恢复需 ~0.2 s；重新计算则需 ~4.7 s 的 Rubin 时间（估计）[S7000]。在一个 30 轮的会话中，这可节省 ~135 GPU 秒，并让每轮等待减少 ~4.5 s（🔴 示意性测算）。**商业解读：**缓存放置成为一个收入杠杆，把存储和网卡（NIC）厂商拉进了推理技术栈（第 07 层）。

[Q4 · 优势来源]（详见发展历程与构建方式）。引擎是开源的，因此优势在于集成与速度：为每个新模型编写内核、针对 NVLink 域调优的部署方案，以及围绕英伟达网络构建的传输软件 [S11001,S11003]。

🎯 企业发展视角

1. **编排是新的控制点。** Dynamo 决定每个请求和每份缓存的去向 [S11001]。如果它成为默认的开源“推理操作系统”，英伟达是否会因此获得对混合机群的影响力？
2. **分离式服务利好互连网络。** KV 传输在资源池之间为每个请求搬运数 GB 数据 [S11002]，提升了 NVLink、RDMA 网卡和上下文内存存储的价值 [S3012]。哪些供应商的价值在这一转变中被低估？
3. **对工作负载的依赖是一个切入口。** 长提示词上 ~2.5× 的收益在短提示词上消失了 [S621]。专用加速器可以瞄准某一个阶段，正如英伟达用 Groq LPX 专攻解码 [S113]。

4. **发布节奏既是护城河，也是成本**。 规模较小的厂商能否跟上 TensorRT-LLM 和 Dynamo 的发布节奏[S521,S589]，还是只能基于 vLLM 和 SGLang 来构建?

NIM、NeMo、Nemotron 与 AI Enterprise

第 11 层 · 推理与 AI 软件 · 约 9 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **NIM 把模型变成一台“家电”。** NIM 微服务是一个容器，内含模型权重、经过调优的引擎和兼容 OpenAI 的 API。它于 GTC 2024（3 月 18 日）发布，并于 2024 年 6 月 2 日正式商用（GA）[S11014,S11015]。
- **开发免费，生产需要许可。** 在生产环境中使用 NIM 需要 NVIDIA AI Enterprise，价格为每 GPU 每年 $4,500 起，或在云上每 GPU 小时 ~$1 [S11013]，相当于在 B200 年度所有者成本之上再加 ~30% [S622]。🟡 在 GTC Berlin（2026 年 10 月 22 日）上，黄仁勋提出智能体软件每 GPU 每年 ~$2,000 的设想，但未公布价目表 [S11016,S11017]。
- **直接收入规模很小。** 软件、SaaS 与支持服务在 Q4 FY2024 达到 ~$1B 的年化收入 [S9516]，管理层指引 FY2025 末达到 ~$2B [S11011]，不到最近一年 $277.7B 数据中心收入的 1% [S405]。
- **英伟达（NVIDIA）如今已是前沿开放模型的开发者。** Nemotron 3 Nano 于 2025 年 12 月发布 [S11021]；Nemotron 3 Ultra（总参数 550B，激活参数 55B）在 GTC 2026 上宣布，并开放权重 [S11019]。Nemotron 3 模型每个 token 只使用 ~10% 的权重，而 2024 年的 Nemotron-4 340B 为 100% [S11019,S34020]。
- **它正在把合作伙伴拉进来。** 🟢 由八家实验室组成的 Nemotron 联盟（包括 Mistral AI 和 Perplexity）正在 DGX Cloud 上开发 Nemotron 4 [S11022]。🟡 英伟达已同意以 ~$12.9B 收购 Hugging Face，预计在 2027 年上半年完成交割，但须经审查 [S11025,S11026,S11027]。
- **弱点：产品频繁更迭与渠道冲突。** NeMo Agent Toolkit 和 RAG Blueprint 已于 2026 年 10 月被弃用 [S11030,S11031]。自建模型并掌控主要的模型中心，使英伟达更加逼近其最大客户的业务领地。

Nemotron went sparse: new models use ~10% of their weights per token, vs 100% in 2024

NVIDIA's open Nemotron models: total vs active parameters per token, billions (log scale), in release order

LOG SCALE

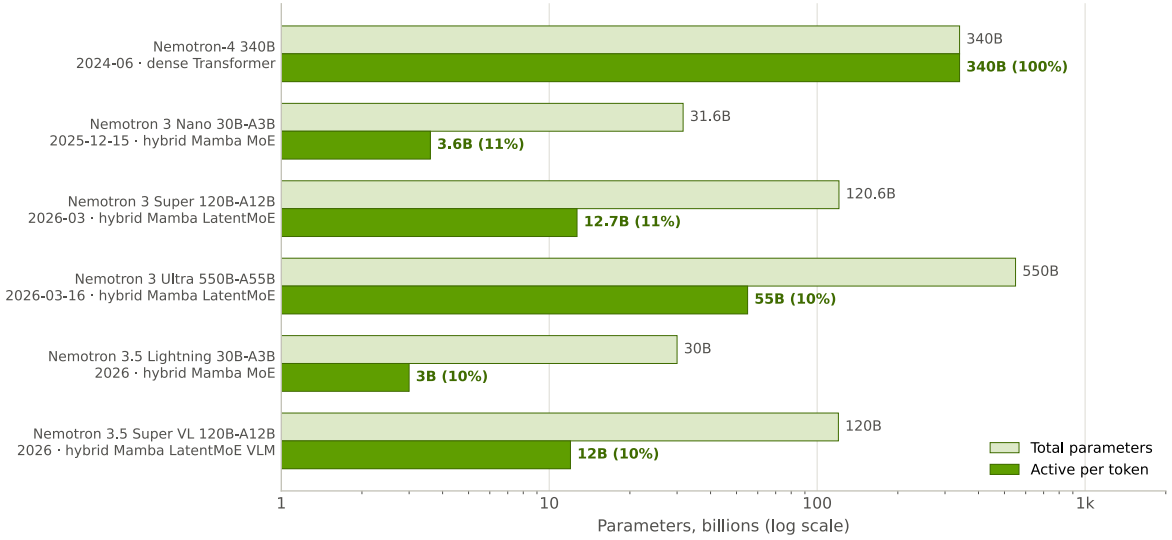

Source: data from NVIDIA Nemotron repository and reports; press for dates [S34020] [S11019] [S11021] [S11020] [S11035]; chart by repo · As of 2026-11-05

> 英伟达开放 Nemotron 模型总参数与激活参数的对数坐标成对水平柱状图：Nemotron-4 340B（2024 年 6 月，稠密）总参数 340B、激活 340B；Nemotron 3 Nano 30B-A3B（2025-12-15）总参数 31.6B、激活 3.6B（11%）；Nemotron 3 Super 120B-A12B（2026-03）总参数 120.6B、激活 12.7B（11%）；Nemotron 3 Ultra 550B-A55B（2026-03-16）总参数 550B、激活 55B（10%）；Nemotron 3.5 Lightning 30B-A3B（2026）总参数 30B、激活 3B（10%）；Nemotron 3.5 Super VL 120B-A12B（2026）总参数 120B、激活 12B（10%）。Nemotron 3 一代采用 Mamba-Transformer 混合的混合专家设计，每个 token 只激活约十分之一的权重，降低了生成每个 token 所需的内存带宽和计算量。

NIM 与 AI Enterprise：模型即“家电”

类比。 自己运行开放模型就像买平板包装家具：零件免费，但要搭上一整晚。NIM 则是组装好的成品，送货上门还附带保修。

机制。 每个 NIM 都打包了一个模型、一个引擎（TensorRT-LLM、vLLM 或 SGLang）、针对各类 GPU 的优化配置文件以及标准 API；开发者可免费使用，企业则在 AI Enterprise 许可下部署 [S11015,S11013]。许可按 GPU 而非按模型计费 [S11013]，并同时涵盖对 TensorRT 和 Triton 的支持 [S11008,S11009]。

NVIDIA AI Enterprise lists at $4,500 per GPU-year, ~30% of a B200's yearly owner cost

US$ per GPU per year: NVIDIA software price points (green) vs B200 hardware cost references (gray, Est.)

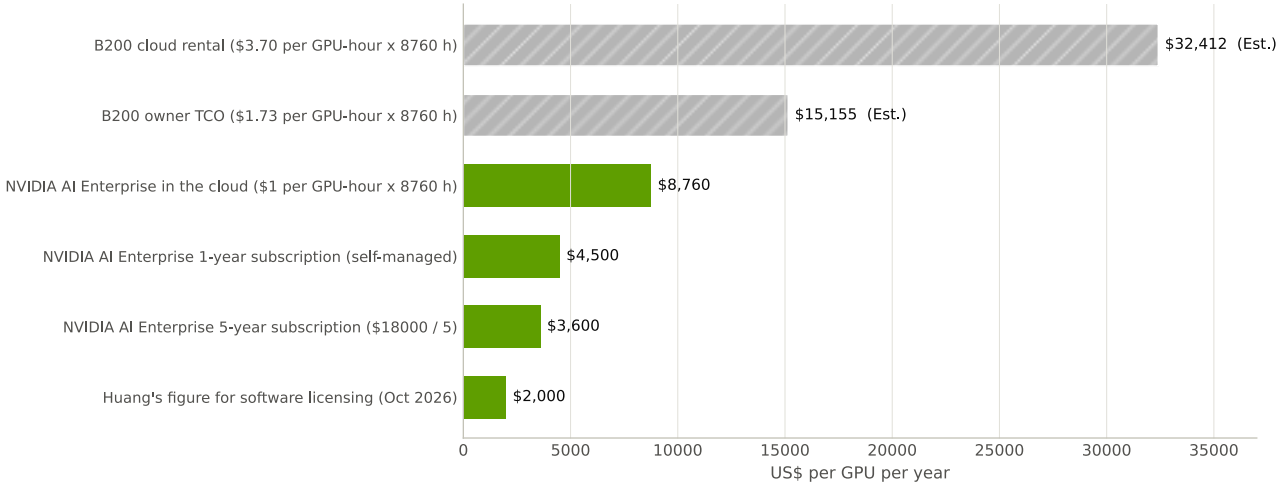

Hardware references hatched = estimates

Source: data from NVIDIA licensing guide as reported; SemiAnalysis TCO [S9515] [S9517] [S622]; chart by repo · As of 2026-11-05

以每 GPU 每年美元计的水平柱状图。NVIDIA AI Enterprise：$2,000（黄仁勋 2026 年 10 月提出的数字）、$3,600（五年期订阅）、$4,500（一年期标价），若在云上按每 GPU 小时 $1 全年计费，最高可达 $8,760。作为对比，一块 B200 的所有者全口径年成本约为 $15,155（SemiAnalysis TCO 估计），年租金约为 $32,412；因此按标价计算的软件费用约增加 30%，按黄仁勋的数字约增加 13%。

提示

算例 —— 许可费对一个机架意味着什么。 一个 GB300 NVL72 有 72 块 GPU：按 $4,500 标价计，每年 $324k [S11013]。该机架价格 ~$4.0M（估计，摩根士丹利）[S332]，每年拥有和运行成本 ~$1.46M（$2.31 × 8,760 h × 72，估计）[S622]。按标价计，软件每年相当于资本开支的 ~8%，或年度所有者成本的 ~22%。二手资料称五年期合约为每 GPU $18,000，即每年 ~$3,600 [S11017,S11018]。**商业解读：**大买家会议价或自行部署开源引擎，因此许可费主要落在需要技术支持的企业身上（🔴 本资料库分析）。

规模校验。 以每 GPU 每年 $4,500 计算，~$2B 的年化收入 [S11011] 意味着 ~440,000 块获得许可的 GPU（🔴 示意性测算），仅占年出货量的一小部分。

NeMo、Guardrails 与 Blueprints：定制化工具链

NeMo 是英伟达用于构建和适配模型的开源工具家族：Curator 负责数据，Megatron-Bridge 和 NeMo-RL 负责训练，Evaluator 负责基准评测 [S11019]。NeMo Guardrails 在模型的输入和输出周围加上可编程规则（0.24.1 版）[S11029]。AI Blueprints 是参考应用，例如 AI-Q 研究智能体 [S11032]。

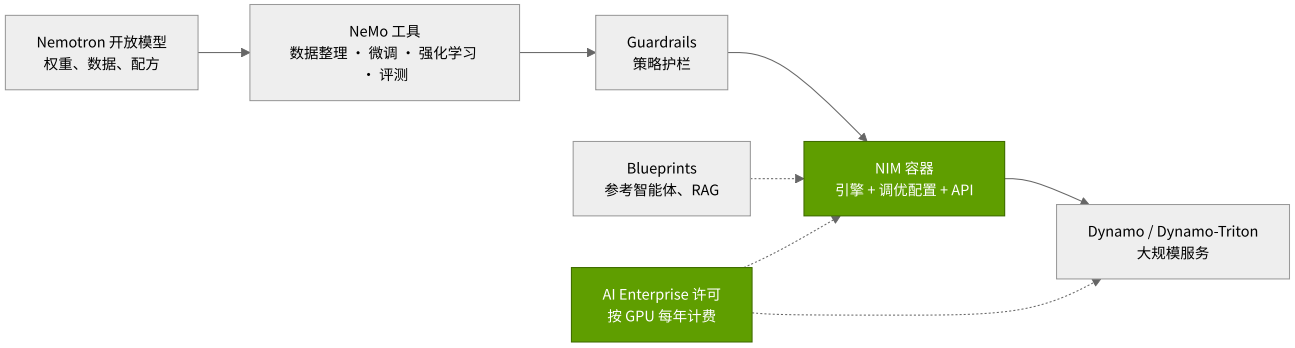

提示

算例 —— 为什么稀疏的 Nemotron 服务成本低。 Nemotron 3 Super 有 120.6B 参数，但每个 token 只激活 12.7B [S11020]。在 NVFP4 下（含缩放因子 ~0.56 字节/参数），权重占用 ~68 GB，可装入一块 180 GB 的 B200，与英伟达 cookbook 中所列一致 [S11019,S32017]。每个 token 只需读取 ~7 GB 的激活权重，因此单个流的带宽上限为 ~8,000 ÷ 7 ≈ 1,100 tokens/s；而一个 120B 的稠密模型只能达到 ~120（🔴 估计，忽略缓存流量和路由开销）[S11000]。**商业解读：**英伟达的模型选型是在展示其 GPU 上的 NVFP4 与稀疏推理能力。

注意

误区与事实：“英伟达的软件栈是一个稳定的平台。”其中部分组件更迭很快。NeMo Agent Toolkit 于 2026 年 10 月被弃用，年底终止支持，由 NeMo Relay 和 NeMo Helix 取代 [S11030]。RAG Blueprint 则“仅保留作参考”（"retained for reference only"）[S11031]。以这些工具为标准，意味着日后要承担迁移工作。

🔧 技术细节：Nemotron 3 有何不同

Nemotron 3 模型是混合架构：主体是 Mamba 状态空间层（其内存占用不随上下文增长），外加少量注意力层，以及英伟达称为 LatentMoE 的稀疏混合专家设计 [S11019,S11020]。Super 每层有 512 个专家、激活 22 个；它在 B200 上使用 NVFP4 以 25 万亿 token 完成预训练，支持 1M token 上下文 [S11020]。Nano 使用了同样的 25 万亿 token 课程 [S11034]。英伟达随权重一并公开了大量数据、训练配方和强化学习环境 [S11019]，而大多数闭源实验室并不这样做。

Nemotron：一家芯片公司为何要做模型

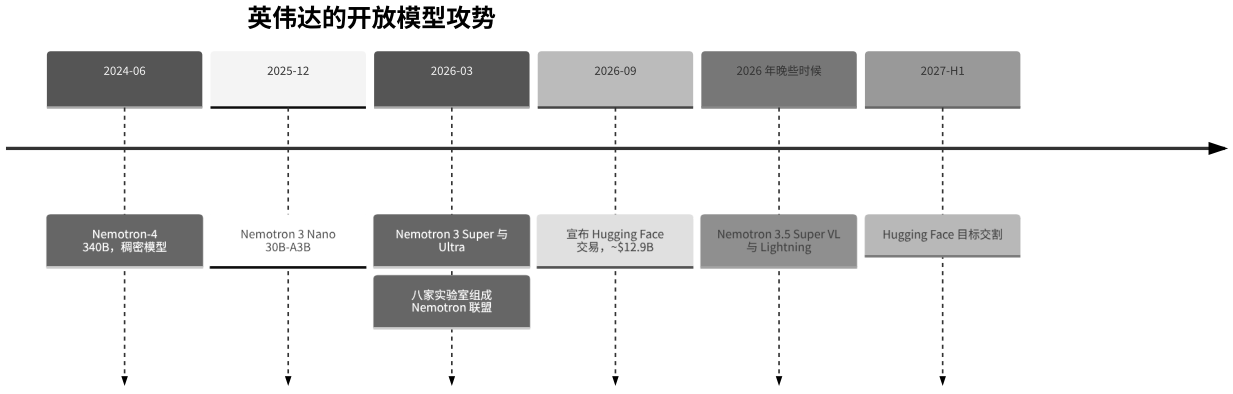

日期：[S34020,S11021,S11035,S11019,S11022,S11026]；Nemotron 3.5 的发布月份与 2027 年交割时间为 🟡。

有四个动机尤为突出（🔴 基于所引事实的本资料库分析）：

1. **培育需求。** 在英伟达 GPU 上以 NVFP4 运行效果最佳的开放模型，会把企业和主权买家吸引到其硬件上 [S11019,S11020]。
2. **确立参考性能。** 英伟达的引擎首先在自家模型上完成调优。
3. **主权 AI。** 各国政府希望拥有可审查、可自行托管的模型；据管理层称，FY2026 主权 AI 收入超过 ~$30B（🟡）[S90071]。

4. **对冲实验室转向定制芯片。** Anthropic 计划使用多达 1M 块 TPU，OpenAI 与 AMD 签有 6 GW 的协议，而一款由博通（Broadcom）设计的 OpenAI 推理芯片也已有分析报道 S90025,S90020,S628。

> **提示**
>
> **算例 —— Nemotron 3 Ultra 作为硬件销售工具。** Ultra 有 550B 参数，激活 55B S11019。在 NVFP4 下，权重占用 ~308 GB，超过单块 288 GB Rubin GPU 的容量 S102。加上长上下文缓存后，它需要跨多块 GPU 部署，因此大型 NVLink 域最适合承载它；每个 token 只需读取 ~31 GB 的激活权重（🔴 估计）S11000。**商业解读：**旗舰开放模型的尺寸正是为旗舰机架量身定制的。

渠道冲突问题

英伟达最大的客户是模型实验室以及托管这些模型的云厂商；其中一个直接客户占 Q2 FY2027 收入的 16% S90069。

举措	对英伟达的好处	与实验室和云厂商之间的风险
Nemotron 开放模型	推理需求；主权交易	与客户自身的开放权重发布形成竞争
Nemotron 联盟	与八家实验室分摊模型成本 S11022	合作伙伴可能不满于对 DGX Cloud 的依赖
收购 Hugging Face 🟡	掌控模型分发与开发者习惯 S11025	中立性存疑；有报道称美国司法部（DOJ）已关注，欧盟可能审查 S11028,S11027
AI Enterprise 费用	经常性收入	超大规模云厂商销售与之竞争的托管服务

迄今为止，英伟达的回应是保持开放：黄仁勋表示，在 Hugging Face 上构建或通过其部署将不要求使用英伟达算力，并承诺支持多种加速器 S11026。

> **注**
>
> 🐂 **看多观点。** 模型、工具加上模型中心，使英伟达成为开放模型开发者的默认起点。每一版 Nemotron 都首先针对 NVFP4 和 NVL72 调优 S11019,S11020，而 Hugging Face 则带来了覆盖面，以及关于开发者在运行什么的数据 S11025。

> **注意**
>
> 🐻 **看空观点。** 许可费只能变现很薄的一层，工具频繁更迭，模型又是免费的。拥有 Hugging Face 会招致反垄断救济措施，并把竞争对手推向中立的模型中心 S11027,S11028。如果前沿实验室继续转向 TPU 和定制 ASIC，开放模型无法弥补它们减少的支出。

🎯 企业发展视角

1. **打包交付是切入企业市场的楔子。** 覆盖模型、引擎和支持服务的按 GPU 许可 S11013，没有软件目录很难匹敌。哪些独立软件开发商（ISV）、系统集成商或模型中心能为挑战者提供同样的“家电式”方案？
2. **开放模型是一种硬件战略。** Nemotron 的稀疏性和 NVFP4 检查点 S11019,S11020 是英伟达芯片的展示橱窗。竞争对手是否应针对自家硬件发布热门开放模型（包括 Nemotron）的调优版本？
3. **Hugging Face 交易最值得关注。** ~$12.9B 的对价，而据报道其年化收入为 ~$150M S11025。监管机构可能要求哪些救济措施？模型中心的中立性对非英伟达加速器价值几何？
4. **工具更迭带来机会。** 被弃用的工具包和蓝图 S11030,S11031 让企业转而寻求稳定、厂商中立的智能体工具。谁能提供这样的工具？

推理与 AI 软件：竞争格局

第 11 层 · 推理与 AI 软件 · 约 14 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **英伟达（NVIDIA）在实际交付成本上领先：** 在每用户 50 tokens/s 下，GB300 NVL72 运行 DeepSeek-R1 的成本为每百万 token ~$0.10，而 MI355X 为 ~$0.56，H200 为 ~$1.10（估计）[S621,S622]。
- **开源推理服务打破锁定：** vLLM、SGLang 和 llm-d 可在七大硬件家族上运行；2026 年迄今 vLLM 已发布 30 个稳定版本，而 TensorRT-LLM 只有 2 个 [S580,S581,S596,S522]。
- **英伟达选择了收编：** Dynamo 可驱动 vLLM 和 SGLang，而尚待完成的 ~$12.9B Hugging Face 交易将把 transformers、TGI 和 llama.cpp 纳入麾下 🟡 [S11001,S11500,S11539]。
- **TPU 是成本挑战者：** Ironwood 运行 Qwen3.5 397B 比 B200 便宜 ~18%（每百万 token $0.181 对比 $0.222）[S625]。
- **AMD 缩小了单 GPU 差距，但没有缩小机架级差距：** 在 MLPerf Llama 2 70B 上与 B200 持平，但在 GLM 5.3 上、每用户 150 tokens/s 时成本最高贵 5× [S602,S636]。
- **SRAM 芯片赢在速度而非成本：** Cerebras 与 OpenAI 签下最多 750 MW 的合同；Groq 的设计则被装进英伟达的 Groq 3 LPX 机架出货 [S11523,S114]。
- **[Q5 · 最强挑战者]** 论成本，是 TPU 和自用 ASIC；论锁定，是开源推理服务。芯片规格已经追上（MI455X 如今在内存上领先 Rubin）；机架级推理服务则尚未追上。

6 of 7 hardware challengers trail NVIDIA on serving software; TPU leads on cost, SRAM chips on speed

Repo verdict vs NVIDIA (GB300 / Vera Rubin NVL72 with Dynamo and TensorRT-LLM) on five inference dimensions; cell = verdict letter + key fact

	Tokens/s per user	Throughput per dollar	Software maturity	Model coverage	Deployment flexibility
Open-source serving vLLM / SGLang / llm-d	P · wide-EP on NVL72 too	P · same GPUs; same cost	P · ~2 stable releases/month	**L · day-0 for open models**	**L · 7 hardware families**
AMD MI355X / MI455X Helios + ROCm	B · 8-GPU domain until Helios	P · up to 29.6% cheaper (GLM-5)	B · ROCm 7; no Dynamo twin	P · vLLM/SGLang first-class	P · merchant: OpenAI Oracle Meta
Google TPU Ironwood / TPU 8i	D · 9216-chip ICI pods	**L · ~18% below B200 per token**	B · TorchTPU only since Oct 2026	B · Gemini + Anthropic + plugins	D · Google Cloud; OCI from 2027
AWS Trainium3 / Inferentia2 + Neuron	B · no public results	D · captive pricing	B · vLLM Neuron plugin beta	B · Claude + selected open models	D · AWS only
Microsoft Maia 200	D · 272 MB SRAM + HBM3E	D · internal claims only	B · no public serving stack	B · Copilot / OpenAI models	D · Azure-internal
Cerebras CS-3 (WSE-3)	**L · interactivity GPUs can't reach**	B · 44 GB SRAM per system	D · own compiler + API cloud	B · curated models + OpenAI	D · cloud + on-prem; IPO 2026
Groq GroqCloud LPU (post-licence)	**L · SRAM-speed decode**	B · hundreds of chips/model	B · founders now at NVIDIA	B · curated open models	D · API cloud; licence non-exclusive
Qualcomm AI 100 Ultra / AI200 / AI250	B · LPDDR ~0.55 TB/s/card	D · 768 GB/card capacity bet	B · vLLM container; + Modular	B · no MLPerf DC / InferenceX	P · merchant cards + racks

L = rival leads NVIDIA　P = parity　B = rival behind　D = different approach

Analyst judgement (speculative)

Source: data from repo analysis of benchmarks and vendor data (l11_inference_verdicts.csv) [S630] [S621] [S629] [S522] [S11502] [S11001] ...; chart by repo · As of 2026-11-05

八个推理挑战者在五个维度上的热力图。开源推理服务（vLLM、SGLang、llm-d）在速度、成本和成熟度上与英伟达持平，在模型覆盖和硬件广度（七大硬件家族）上领先。谷歌 TPU 在每美元吞吐量上领先（每 token 成本比 B200 低约 18%）；Cerebras 和 Groq 凭借片上 SRAM 在每用户每秒 token 数上领先，但在成本上落后；AMD 在成本和模型覆盖上持平，但在交互速度和软件上落后；7 个硬件挑战者中有 6 个在软件成熟度上落后；AWS、微软和高通缺乏公开基准测试，大多为“路线不同”或“落后”。

推理竞争如何计分

推理的买家会权衡五件事：**交互速度**（每用户 tokens/s：智能体用起来是否即时？）、**每美元吞吐量**（卖方的毛利率）、**软件成熟度**（需要多少工程师）、**模型覆盖**（下周发布的模型能否在发布当天运行？）以及**部署灵活性**（能买断，还是只能向其所有者租用？）。前两项沿帕累托前沿此消彼长，就像公交车与出租车的取舍（推理转向）。

挑战者（依据）	每用户 tokens/s	每美元吞吐量	软件成熟度	模型覆盖	部署灵活性
开源推理服务（vLLM、SGLang、llm-d）	🟨 在 NVL72 上同样支持大规模专家并行	🟨 使用相同 GPU	🟨 每月 ~2 个版本	🟩 开放模型第 0 天支持	🟩 7 大硬件家族
AMD MI355X → MI455X	🟥 Helios 之前仅有 8-GPU 域	🟨 最多便宜 29.6%	🟥 ROCm 7，无 Dynamo 对等产品	🟨 vLLM/SGLang 原生支持	🟨 商用芯片
谷歌 TPU Ironwood → 8i	🟦 9,216 芯片 pod	🟩 比 B200 低 ~18%	🟥 TorchTPU 自 2026 年 10 月起	🟥 Gemini、Anthropic	🟦 Google Cloud、OCI
AWS Trainium / Inferentia	🟥 无公开结果	🟦 自用定价	🟥 vLLM 插件为 beta	🟥 Claude 及部分模型	🟦 仅限 AWS
微软 Maia 200	🟦 SRAM + HBM3E	🟦 内部宣称	🟥 无公开软件栈	🟥 Copilot、OpenAI	🟦 仅限 Azure
Cerebras CS-3	🟩 超越 GPU 节点	🟥 每系统 44 GB	🟦 API 优先	🟥 精选模型	🟦 云端、本地部署
Groq（GroqCloud）	🟩 SRAM 级解码速度	🟥 每个模型需大量芯片	🟥 创始人已离开	🟥 精选模型	🟦 API 云服务
高通 AI 100 / AI200 / AI250	🟥 LPDDR 0.55 TB/s	🟦 押注 768 GB 容量	🟥 vLLM + Modular	🟥 无公开结果	🟨 商用芯片

评级 = 挑战者对比搭载 Dynamo 与 TensorRT-LLM 的英伟达 GB300 / Vera Rubin NVL72；为本资料库判断 🔴，依据 S621,S630,S637,S636,S625,S553,S581,S158,S634,S167,S172,S173,S596,S9511,S602。数据：`l11_inference_verdicts.csv`。

提示

算例 —— 成本差距对服务商意味着什么。 按所有者总拥有成本（TCO）计，在每用户 50 tokens/s 下服务一万亿个 DeepSeek-R1 token（10^6 个百万 token），GB300 NVL72 需 ~$100K，MI355X 需 ~$560K，H200 需 ~$1.1M（估计）[S621,S622]。以谷歌 2025 年 10 月每月超过 1.3 千万亿 token 的规模计，每百万 token $0.46 的差距相当于每月 ~$600M [S32020]。

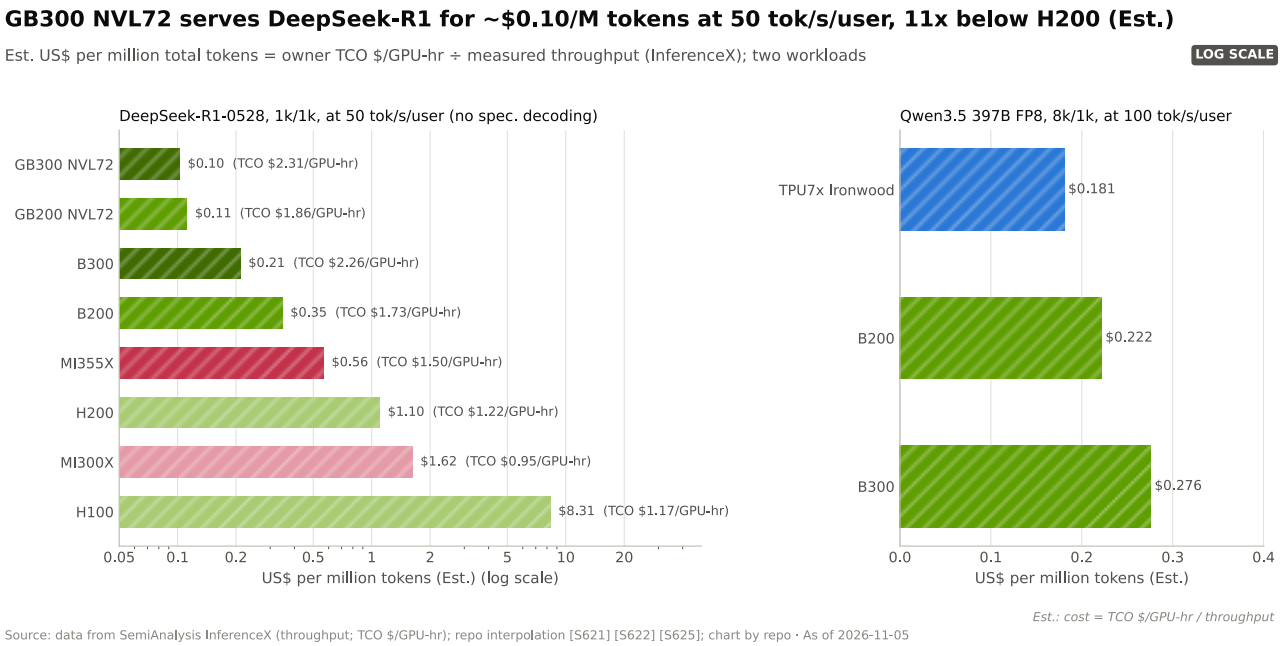

估计每百万总 token 成本的双面板柱状图。左图，DeepSeek-R1，每用户 50 tokens/s：GB300 NVL72 $0.10、GB200 NVL72 $0.11、B300 $0.21、B200 $0.35、MI355X $0.56、H200 $1.10、MI300X $1.62、H100 $8.31。右图，Qwen3.5 397B FP8，每用户 100 tokens/s：TPU7x Ironwood $0.181、B200 $0.222、B300 $0.276，显示在该工作负载上谷歌 TPU 比 B200 便宜约 18%。

🔧 技术细节：为什么各基准测试结论不一

MLPerf 经过审计但定期发布；InferenceX 每晚在不同交互速度水平上重跑，并用 TCO 模型定价（GB300 每 GPU 小时 $2.31，MI355X $1.50，TPU7x $1.21）[S622]。AMD 在稠密模型或激活参数较少的模型的离线场景中表现最好；英伟达则在高交互速度下的大型混合专家模型上表现最好，因为 72-GPU NVLink 域能承载专家间的通信流量 [S630,S636]。

开源推理服务：锁定问题

推理服务引擎是模型、硬件与客户的交汇点。vLLM 源自 2023 年伯克利的一篇论文 [S32011]，原生支持 CUDA、ROCm 和英特尔 GPU，并通过硬件插件支持 TPU、Gaudi、AWS Neuron（beta）和昇腾（Ascend），另有一个高通（Qualcomm）容器 [S580,S581,S596]。SGLang 列出了英伟达、AMD、TPU 和昇腾 [S582]。Ray 覆盖 13 个设备家族，llama.cpp 约覆盖十个，其中包括骁龙（Snapdragon）[S584,S579]。Hugging Face 已将其 TGI 引擎转入维护模式，并引导用户转向 vLLM 和 SGLang [S11502]。llm-d 1.0（2026 年 10 月；由红帽、谷歌、IBM、CoreWeave 和英伟达共同发起）增加了路由以及预填充（prefill）/解码拆分功能，并已在英伟达、AMD、英特尔和 TPU 上完成验证 [S11503]。

vLLM ships a stable release every ~15 days; TensorRT-LLM mostly ships RCs

Versions first uploaded to PyPI per calendar year (solid = stable, hatched = rc/alpha/beta; nightlies excluded; 2026 to Nov 5)

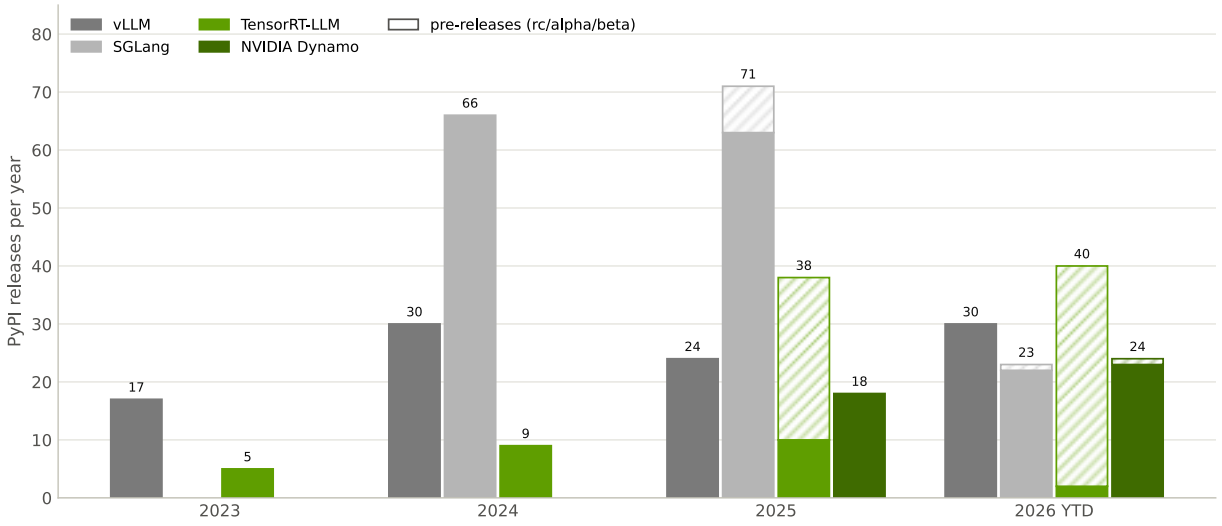

Source: data from PyPI JSON API (vllm, sglang, tensorrt-llm, ai-dynamo) [S522]; chart by repo · As of 2026-11-05

PyPI 每年发布版本数的分组柱状图：vLLM 稳定版分别为 17、30、24 和 30（2026 年迄今）；SGLang 2024 年 66 个、2025 年 63 个；TensorRT-LLM 2025 年 10 个稳定版加 28 个候选版；NVIDIA Dynamo 2025 年 18 个、2026 年迄今 23 个。

提示

算例 —— 开源省下的许可费。 一个在生产环境中运行 NIM 的 10,000 块 GPU 机群需要 NVIDIA AI Enterprise，标价每 GPU 每年 $4,500：每年 $45M [S9515,S11013]。若使用 vLLM 或 SGLang，则无需支付许可费，而且从 H200 换到 MI355X 只需更换容器，无需改动应用；TensorRT-LLM 则只能在英伟达 GPU 上运行 [S589]。

注意

误区与事实：“开源抹平了英伟达的优势。” 开源引擎对英伟达硬件调优最为用力：SGLang 的一个版本就把同一组 B200 的吞吐量从每 GPU 508 提升到 907 tokens/s [S629]。AMD 同样受益（MI355X 在 Qwen3.5 上三个月内从 1.3K 提升到 6.4K）[S632]。开源推理服务降低了切换成本，但并不能抹平芯片之间的差距。

逐一审视挑战者

AMD：最接近的商用芯片对手

MI355X 在 MLPerf Llama 2 70B 上与 B200 持平，在 gpt-oss-120b 上单 GPU 性能超过 B300（15,227 对比 14,321 tokens/s），这得益于 8 TB/s、288 GB 的 HBM [S602,S603]。其在 MLPerf 推理封闭组结果中的占比在 18 个月内从 2% 升至 20% [S600,S603]。其拿下的订单大多用于推理：OpenAI（自 2026 年下半年起 6 GW）、甲骨文（Oracle）（50,000 块 MI450）、Meta，以及 Anthropic（最多 2 GW 的 Helios）[S90020,S90022,S546,S9538,S90023]。**最有力的论据：**MI455X 每 GPU 配备 432 GB、23.3 TB/s 的内存，是 Rubin 288 GB 的 1.5×、其 19.2 TB/s 的 ~1.2× [S144,S90093,S90006]。**差距：**Helios 的 72-GPU 域要到 2027 年第二季度才能放量（据 SemiAnalysis），因此在那之前，英伟达仍将保有高交互速度 MoE 场景的前沿 🟡 [S624]。

On MLPerf Llama 2 70B, AMD's MI355X (12,935 tok/s) matches B200 but trails GB300 by 17%

MLPerf Inference v6.0 (Apr 2026), Llama 2 70B Offline, best closed result per accelerator, tokens/s per accelerator

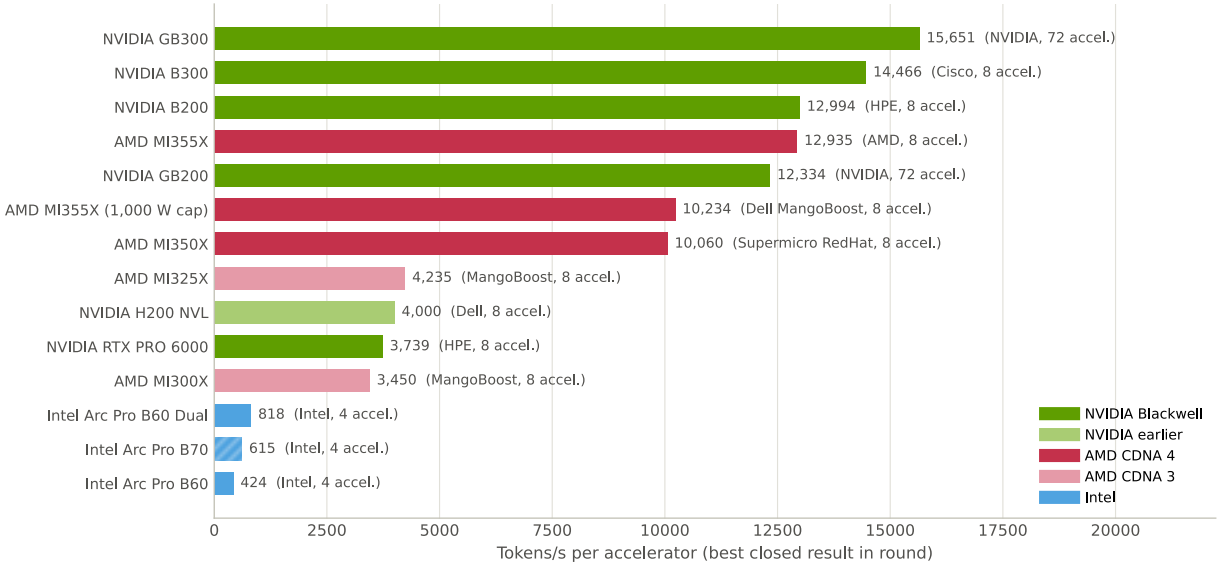

Hatched = preview category

Source: data from MLCommons MLPerf Inference v6.0 results (closed division) [S602]; chart by repo · As of 2026-11-05

水平柱状图：MLPerf Inference v6.0 封闭组 Llama 2 70B Offline 场景中各加速器的最佳结果，单位为每加速器 tokens/s：GB300 15,651、B300 14,466、B200 12,994、MI355X 12,935、GB200 12,334、MI350X 10,060、MI325X 4,235、H200 NVL 4,000、MI300X 3,450；英特尔 Arc Pro 显卡低于 1,000。

MLPerf gpt-oss-120b: MI355X beats B300 per GPU (15,227 vs 14,321 tok/s); GB300 leads

MLPerf Inference v6.1 (Sep 2026), gpt-oss-120b Offline, best closed result per accelerator, tokens/s per accelerator

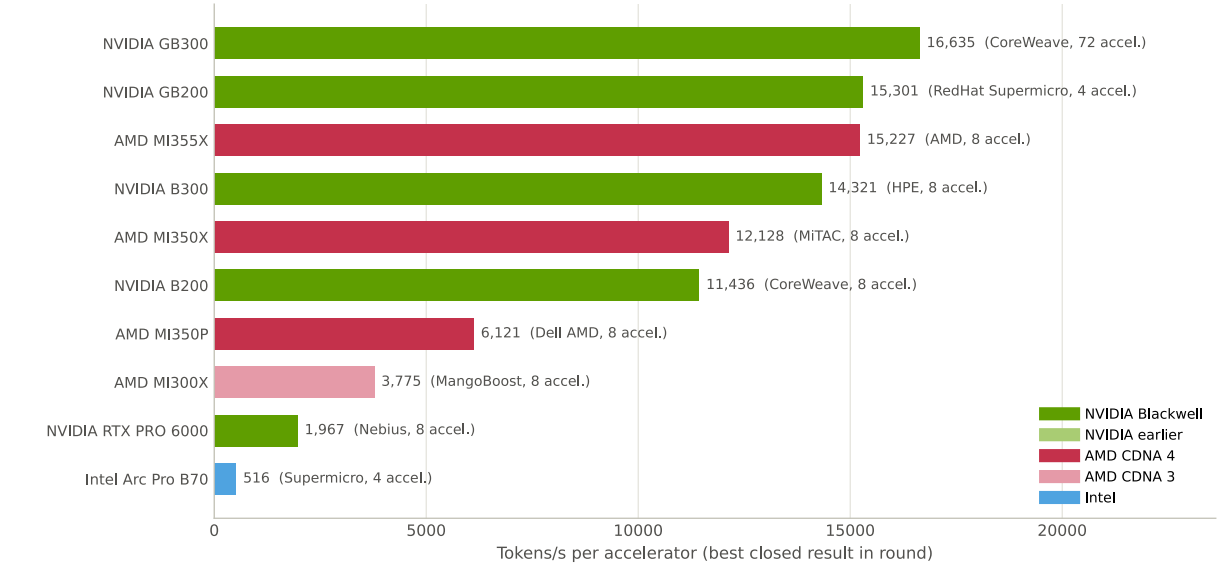

Hatched = preview category

Source: data from MLCommons MLPerf Inference v6.1 results (closed division) [S603]; chart by repo · As of 2026-11-05

水平柱状图：MLPerf Inference v6.1 封闭组 gpt-oss-120b Offline 场景中各加速器的最佳结果，单位为每加速器 tokens/s：GB300 16,635、GB200 15,301、MI355X 15,227、B300 14,321、MI350X 12,128、B200 11,436、MI300X 3,775，RTX PRO 6000 和英特尔 Arc Pro B70 远低于此。激活参数较少的 MoE 模型有利于发挥 AMD 的内存带宽优势。

谷歌 TPU、AWS 与微软：自用芯片的成本优势

Ironwood 是谷歌首款“为推理时代打造”的 TPU，配备 192 GB HBM3E，单个 pod 含 9,216 颗芯片[S151]。TPU 8i（2026 年底）将用于 KV 缓存的片上 SRAM 增加到原来的三倍[S550]。Anthropic 拥有超过 1M 块 TPU（~400K 块买断、~600K 块租用），Meta 租用 Ironwood，甲骨文云将于 2027 年引入 TPU

S625,S90025,S552。AWS 已推出 Trainium3（2025 年 12 月），并为 Anthropic 部署了 Project Rainier（~500K 块 Trainium2）；其 vLLM 插件仍处于 beta 阶段 S90034,S581。微软的 Maia 200（216 GB HBM3E、272 MB SRAM、>10 PFLOPS FP4、750 W）用于运行 Copilot；Maia 300 将于 2027 年推出 S158,S90044,S90046。**最有力的论据：**没有商用芯片厂商的利润加成；相对于英伟达 ~75% 的毛利率，拥有自研 ASIC 的企业一开始就有很大的价格缓冲空间 S3。

SRAM 速度专家

An LPU re-reads its 0.5 GB of SRAM ~300,000×/s; Rubin re-reads 288 GB of HBM4 ~67×/s

Memory capacity (GB) vs bandwidth (TB/s) per chip or card; diagonals = full memory reads per second, the decode-step ceiling

LOG SCALE

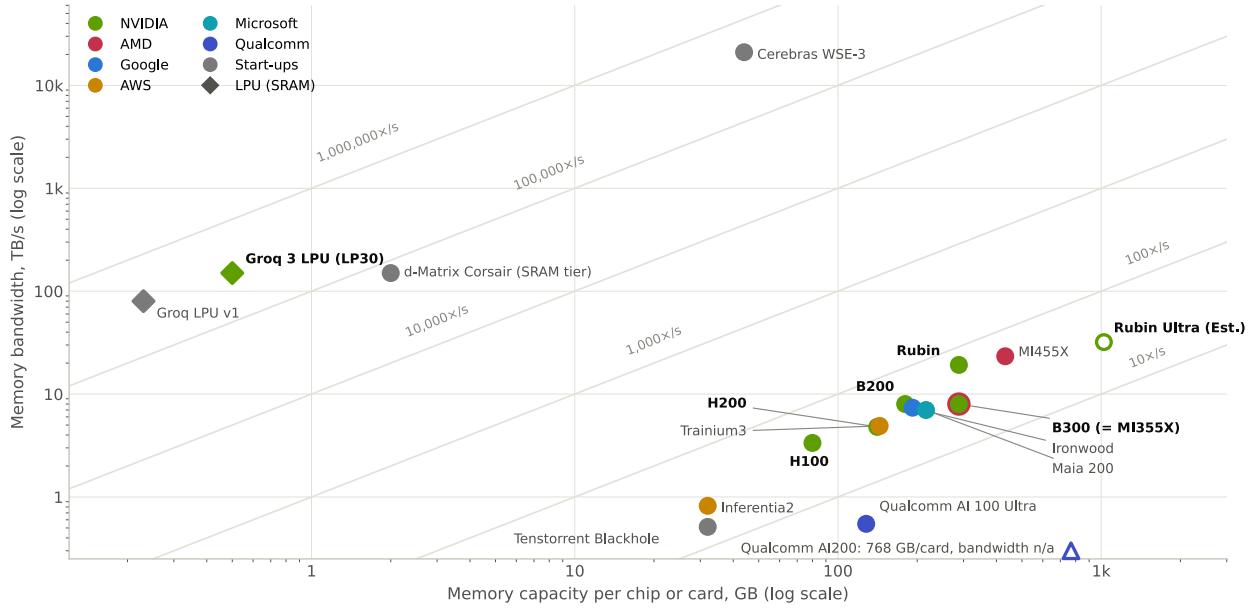

Hollow = roadmap / Est.

Source: data from vendor specifications [S33002] [S35011] [S35013] [S32002] [S33003] [S35014] …; chart by repo · As of 2026-11-05

推理芯片按内存容量与带宽分布的双对数散点图。SRAM 设计位于左上方：英伟达的 Groq 3 LPU 容量 0.5 GB、带宽 150 TB/s（每秒约 300,000 次全量读取），Groq LPU v1 为 0.23 GB、80 TB/s，d-Matrix Corsair 为 2 GB、150 TB/s，Cerebras WSE-3 为 44 GB、21,000 TB/s。HBM GPU 和云端 ASIC 聚集在中部，容量 80-432 GB、带宽 3-23 TB/s（每秒 25-70 次读取）：Rubin 288 GB、19.2 TB/s，MI455X 432 GB、23.3 TB/s，Ironwood 192 GB、7.4 TB/s，Maia 200 216 GB、7 TB/s。LPDDR 加速卡位于右下方：高通 AI 100 Ultra 128 GB、0.548 TB/s（每秒约 4 次读取），AI200 每卡 768 GB（带宽未披露）。

解码（decode）每生成一个 token 都要重读一遍权重：带宽决定速度上限，容量决定芯片数量。Cerebras 的晶圆级芯片拥有 44 GB、21 PB/s 的 SRAM S634；OpenAI 同意在 2028 年前购买其最多 750 MW 的算力 S11523,S11524。Groq LPU 的创始人及团队随授权交易加入英伟达；GroqCloud 继续运营 S90018。Etched（$10.3B）、Positron（$5B）和 d-Matrix（$2B）仍未实现规模化 S2507,S11521,S2511；详见价值链。

提示

算例 —— 为什么 SRAM 快但贵。 一个 70B 参数的模型在 FP8 下为 ~70 GB。单块 Rubin GPU（288 GB、19.2 TB/s）即可容纳，每秒可将其完整读取 ~274 次，这就是单用户速度的上限 S90006。每颗 Groq 3 LPU 只有 0.5 GB，因此权重需要 ~140 颗芯片，超过一个 256-LPU LPX 机架的一半 S114。每颗芯片每秒可重读自己那部分权重 ~300,000 次，因此决定上限的是互连而非内存：每用户的速度高得多，但每用户所需的芯片也多得多。

高通（仅限公开信息）

Cloud AI 100 Ultra 是一款 150 W 的加速卡，配备 128 GB、548 GB/s 的 LPDDR [S172]。AI200（2026 年）每卡配备 768 GB LPDDR，部署于 160 kW 液冷机架中；AI250（2027 年）增加近存计算，宣称有效带宽提升 >10×；HUMAIN 计划部署 200 MW [S173,S90030]。2028 年的 AI300 宣称借助高带宽计算（High Bandwidth Compute）实现 AI200 带宽的 54× [S90060]，对 Modular 的收购已于 2026-07-29 完成 [S9511]。截至 2026-11-05，尚无 AI200 量产出货、MLPerf 数据中心或 InferenceX 结果公开 🔴 [S90028,S602,S620]。

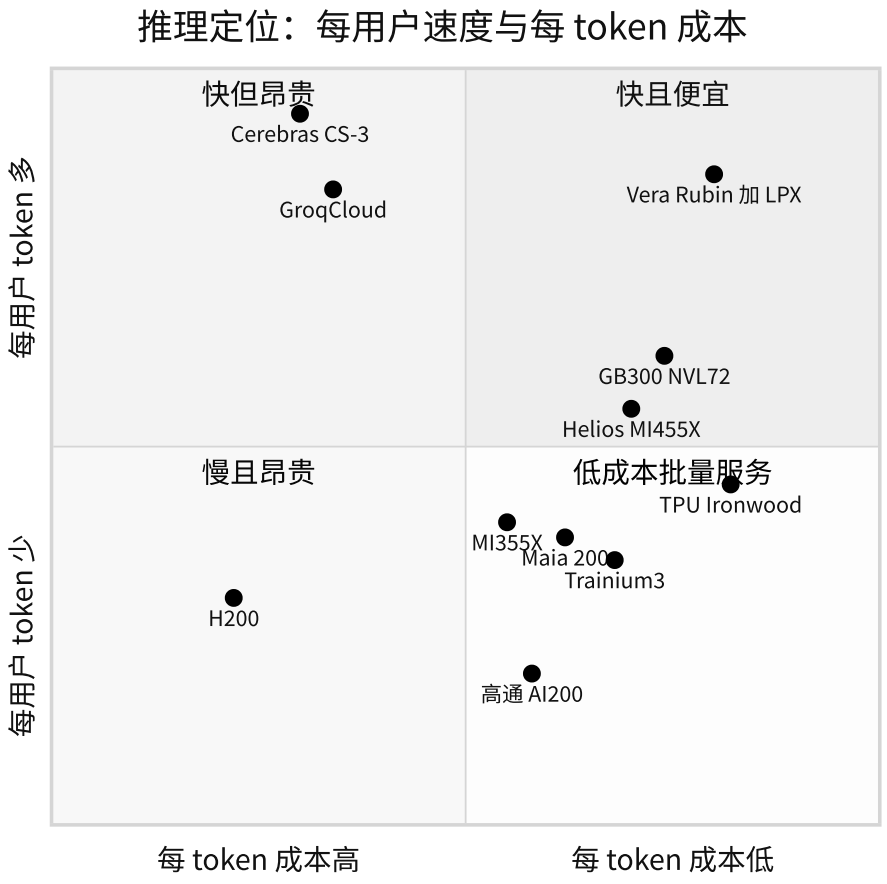

本资料库定位 🔴，以 [S621,S625,S634] 为锚点；Helios、LPX 和 AI200 尚无基准测试数据。

注

🐂 **看多观点。** 英伟达掌握推理级 MoE 模型的实际交付成本前沿（每用户 50 tokens/s 下每百万 token $0.10），对开源引擎的运行效果最好，新增了 SRAM 解码（Groq 3 LPX），并且正在收购分发渠道（Hugging Face）🟡 [S621,S114,S11500]。

注意

🐻 **看空观点。** 推理奖励的是成本而非灵活性：TPU 在部分工作负载上便宜 ~18%，AMD 在单 GPU 层面与 B200 持平 [S625,S602]。开源引擎让切换变成一次容器替换，而前沿实验室如今已把推理分散到 TPU、AMD、Trainium 和 Cerebras 上 [S90026,S90020,S11523]。

[Q5 · 最强挑战者] 论每 token 成本：谷歌 TPU——唯一一款既有第三方成本数据显示其领先（较 B200 低 ~18%）、又有外部客户的自用 ASIC [S625,S552]。论锁定：开源推理服务，它让任何挑战者都能继承第 0 天模型支持。单芯片规格上的差距已经弥合（MI455X 在带宽上追平 Rubin），但机架级推理服务的差距尚未弥合——在每用户 150 tokens/s 下，英伟达的成本最多低 5× [S90006,S636]。

🎯 企业发展视角

1. 如果开源引擎使推理服务商品化，价值是否会转移到掌控分发渠道（模型中心、API）的一方？英伟达的 Hugging Face 交易对中立的模型中心意味着什么？
2. SRAM 占据超低延迟市场，NVL72 占据中间地带：在长上下文、对成本敏感的推理服务中，是否还有容量优先设计（每卡 768 GB）的空间？
3. 新进入者需要多少公开基准测试证据，买家才会下大批量订单？生成这些证据需要多少成本？
4. 哪些大型 token 买家（主权机构、模型实验室）缺乏自研芯片，可能愿意与商用芯片伙伴联合设计？

推理与 AI 软件：发展历程与英伟达的构建之道

第 11 层 · 推理与 AI 软件 · 约 11 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **十年四步棋：** TensorRT（2016）、Triton（2018）、TensorRT-LLM 与 NIM（2023–24），然后是 Dynamo（2025；1.0 版于 2026 年 3 月发布）[S11505,S11009,S522,S11014,S32015,S90066]。
- **缺人才就买：** 14 个月内收购 Deci、Run:ai、OctoAI 和 CentML，合计 ~$1.65B 🟡 [S478,S476,S11510,S11509]。
- **硬件对冲：** ~$20B 的 Groq 授权加团队交易催生了 Groq 3 LPX 解码机架，自 2026 年 8 月起量产 [S90019,S506]。
- **分发渠道：** ~$12.9B 的 Hugging Face 收购协议（2026 年 9 月）正等待监管审查 🟡 [S11026,S11500]。
- **[Q4 · 优势来源]** 集成与速度：软件让 GB300 NVL72 的 MLPerf DeepSeek-R1 Server 成绩一年内提升 ~2.9×，而 72-GPU NVLink 域能承载超大型 MoE 模型 [S601,S603]。
- **[Q6 · 复制成本]** 🔴 估计：若在新芯片上借助开源引擎，需要 ~3–5 年、~$1–3B 和 ~500–1,000 名工程师；机架级推理服务还要再加上数年的硬件开发时间。

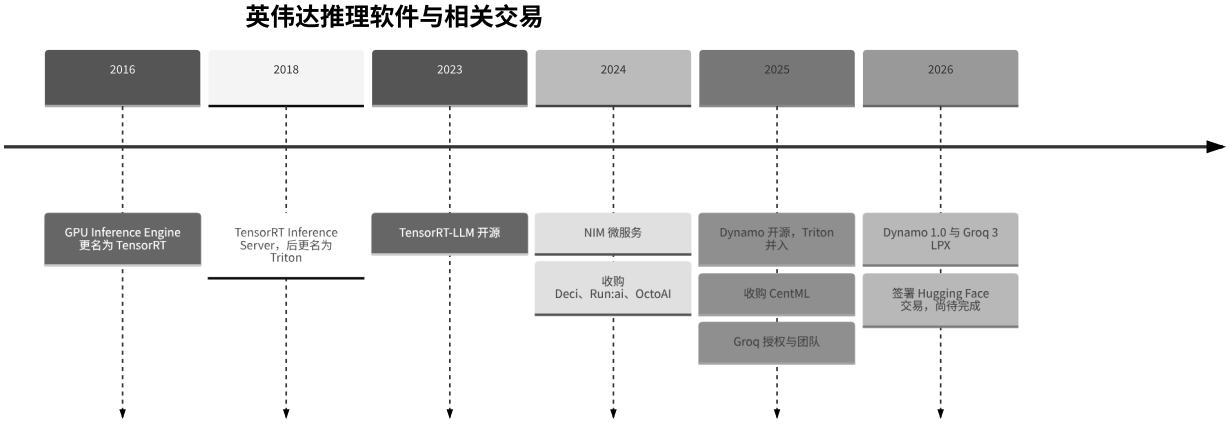

从一块快速 GPU 到一座推理工厂

第一阶段（2016–2022）：一块快速的 GPU。 GPU Inference Engine（2016 年年中）于当年 9 月更名为 TensorRT，它把训练好的网络编译为经过调优的运行时 [S11505]；2026 年 10 月已发展到 11.4 版 [S11504]。随后推出了模型服务器（TensorRT Inference Server，后更名为 Triton）；它甚至支持 CPU 和 AWS Inferentia [S11009,S11506]。**第二阶段（2023–2024）：快速且打包交付的大语言模型。** TensorRT-LLM（2023）增加了大语言模型（LLM）批处理与量化功能 [S522,S589]；NIM 把模型打包成容器，通过 AI Enterprise 销售 [S11014,S11015]。**第三阶段（2025 年起）：把机架当作一台机器。** Dynamo 把预填充（prefill）与解码（decode）拆开，并在 NVL72 内按 KV 缓存进行路由；Triton 则变为 Dynamo-Triton [S32015,S11010]。工作机制详见：TensorRT-LLM 与 Dynamo。

日期	决策	为何重要	来源
2016-09	GIE 更名为 TensorRT	推理成为一款产品，而非训练的副产品	S11505
2018	开放的模型服务器（Triton）	掌控了推理服务 API，甚至覆盖 CPU 和 Inferentia	S11009,S11506
2023	TensorRT-LLM 开源	回应 vLLM；设计上仅支持英伟达	S522,S589

日期	决策	为何重要	来源
2024-03	NIM 纳入 AI Enterprise	把软件变成按 GPU 收费的许可（标价 $4,500）	S11014,S9515
2024-04 → 2025-06	Deci、Run:ai、OctoAI、CentML	买下编译器、调度和推理服务团队	S478,S476,S11510,S11509
2025-03-18	Dynamo 开源（Apache 2.0）	位于 vLLM 和 SGLang 之上，而非与之对抗	S32015,S11001
2025-12-24	Groq 授权 + 团队（~$20B）	无需并购审查即获得 SRAM 解码层	S90018,S90019
2026-03-16	Dynamo 1.0；发布 Groq 3 LPX	量产级“推理操作系统”加上一款解码机架	S90066,S90003
2026-09-03	Hugging Face（~$12.9B，待完成）	掌控人们寻找开放模型的中心平台	S11026,S11500

提示

算例 —— 以研发预算衡量“收购还是自建”。 Deci、OctoAI 和 CentML 合计花费 ~$950M（据媒体报道）[S478,S11510,S11509]，约为英伟达 FY2026 研发预算 $18.5B 的 5% [S401]。Groq 交易（~$20B）相当于 ~1.1 年的研发支出 [S90019]。小团队加快了英伟达本来就在开发的软件；大额支票则买下了它所欠缺的硬件和分发渠道。

NVIDIA's ~$20B Groq and $12.9B Hugging Face deals dwarf Qualcomm–Modular ($3.9B)

Disclosed or reported deal value, US$ millions (log scale), inference software and silicon deals 2023–2026

LOG SCALE

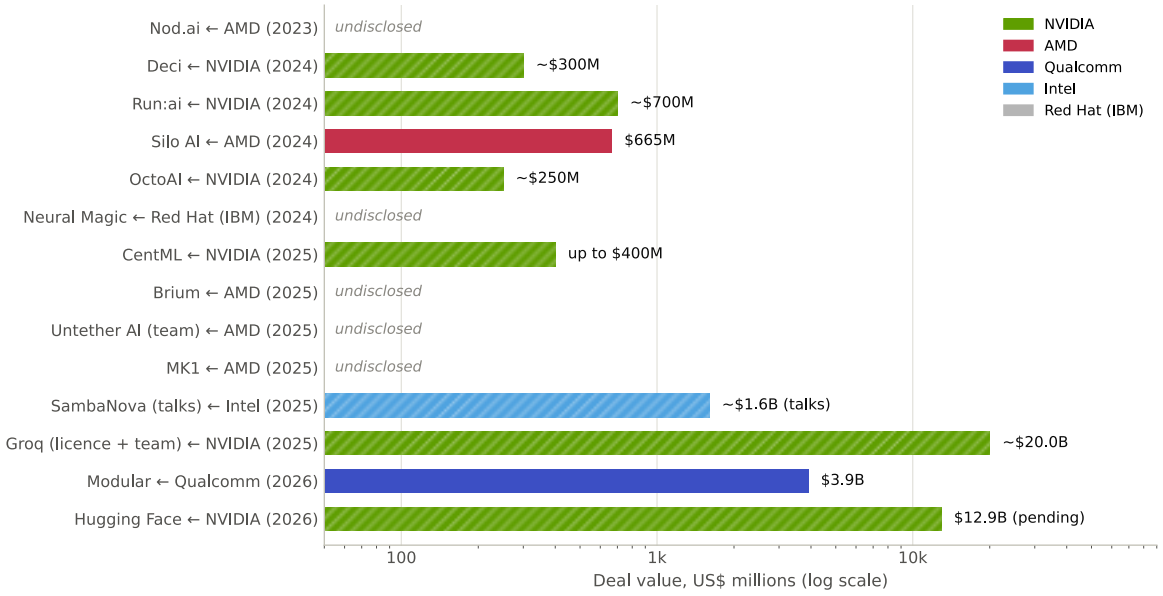

Hatched = reported / pending

Source: data from releases and press [S11025] [S11026] [S11500] [S11027] [S11028] [S90057] …; chart by repo · As of 2026-11-05

推理相关交易的对数坐标水平柱状图。英伟达：Groq 授权与团队（据报道约 $20,000M，2025 年 12 月）、Hugging Face（$12,930M，2026 年 9 月宣布，尚待完成，预计 2027 年上半年交割）、Run:ai（约 $700M，2024 年）、CentML（含业绩对赌付款最高约 $400M，2025 年）、Deci（约 $300M，2024 年）、OctoAI（约 $250M，2024 年）。高通：Modular（$3,900M，2026 年）。AMD：Silo AI（$665M，2024 年），另有未披露金额的 Nod.ai、Brium、Untether AI 团队和 MK1。英特尔约 $1.6B 的 SambaNova 谈判未能达成；红帽收购 Neural Magic 的金额未披露（共有 5 笔交易未披露价格）。

🔧 技术细节：为什么采用“授权加团队”而非收购

Groq 交易是一项非独家授权加人员招募（创始人 Jonathan Ross、总裁 Sunny Madra 及团队大部分成员）；Groq 在新任 CEO 领导下保留了 GroqCloud [S90018]。分析人士认为，这是一种无需并购审查即可获得技术和人才的方式 [S90019,S474]；前 Groq 工程师后来起诉了 Groq 董事会 [S118]。相比之下，Hugging Face 是一项等待批准的全资收购，预计于 2027 年上半年完成交割 [S11026,S11027]。

[Q4 · 优势来源] 同样的硬件，更多的 token

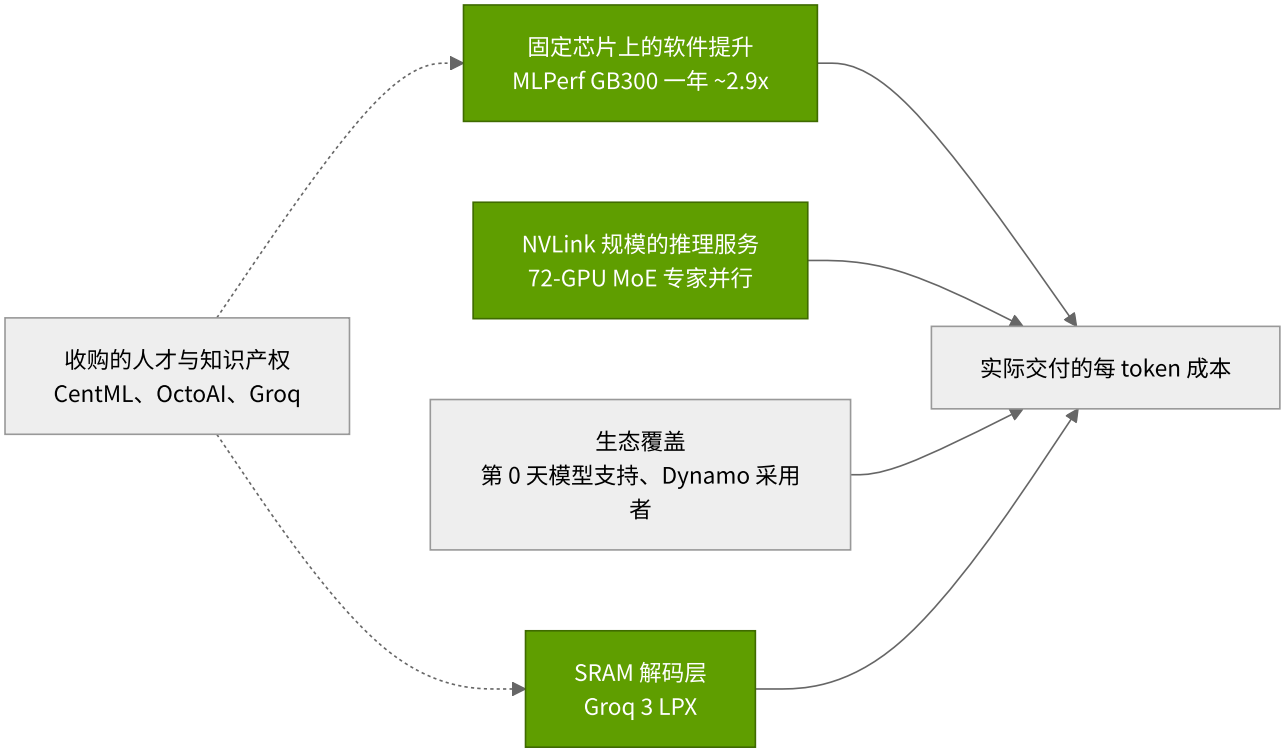

三个来源相互叠加。**固定芯片上的软件提升：**在 2025 年 9 月至 2026 年 9 月间，同一套 GB300 NVL72 在 MLPerf DeepSeek-R1 Server 上的吞吐量从每 GPU 2,907 提升至 8,291 tokens/s [S601,S603]。**NVLink 规模的推理服务：**在 72-GPU 域内实施大规模专家并行，使 Kimi K2.5 的吞吐量在同一 vLLM 引擎上比 B200 节点高 ~3.1× [S630]。**生态覆盖：**Dynamo 1.0 发布时即有一批采用者，从 CoreWeave、Together AI 到字节跳动和 PayPal [S90066]。芯片技术本身不是护城河（AMD 已在 MLPerf Llama 2 70B 上实现单 GPU 持平 [S602]）；集成才是：机架、互连网络和引擎协同调优，并且每年更新。

> **提示**
>
> **算例 —— 软件增益价值几何。** 一个 GB300 NVL72 机架为 ~$4M（摩根士丹利估计）[S332]。如果软件把每 GPU 的 token 产出提升 2.85×（2,907 → 8,291）[S601,S603]，所有者花一个机架的钱就能得到 ~2.85 个机架的产出，相当于每个机架避免了 ~$7M 的资本开支。这就是英伟达可以免费提供 Dynamo 的原因：这些增益让它的 GPU 更值钱。

[Q6 · 复制成本] 打造一套有竞争力的技术栈需要什么

组成部分	时间	资金	人才	证据
单节点推理服务引擎	1–2 年	$0.1–0.2B	50–150 名工程师	vLLM 和 SGLang 出自高校实验室；种子轮分别为 $150M 和 $100M [S11511,S11513]
新芯片上的内核、编译器与第 0 天模型支持	2–3 年	$0.5–1.5B	200–500	AMD：Silo AI（$665M）、Nod.ai、Brium、Untether 团队、MK1；MI355X 于 2026 年实现持平 [S9506,S9507,S9509,S602]
机架级分离式推理服务	3–5 年	$1–2B，另加互连网络	200–400	英伟达 2016–2026；llm-d 作为开源捷径 [S11503]
分发渠道与开发者覆盖	数年，或直接收购	$3.9–12.9B	—	Modular、Hugging Face 的收购价格 [S9511,S11026]

本资料库估计 🔴：工程师全口径成本每年 ~$0.5–1M；在复用开源成果的部分，各区间存在重叠。

结论： 🔴 估计：在新芯片上借助 vLLM、SGLang 和 llm-d 打造一套有竞争力的技术栈，需要 ~3–5 年、~$1–3B 和 ~500–1,000 名工程师。NVLink 规模的 MoE 推理服务还需要一套纵向扩展（scale-up）互连网络；UALink 产品要到 2027 年才会面世 🟡 [S90051]。引擎是便宜的部分；针对每款芯片的内核和机架则不便宜。

> **提示**
>
> **算例 —— AMD 的追赶账单。** 在 SemiAnalysis 于 2024 年 12 月发表对 ROCm 的批评之后，AMD 在软件上进入“战时状态”（"wartime mode"）[S9537]，在 Silo AI（$665M）之外又纳入了 Brium、Untether AI 团队和 MK1 [S9506,S9507,S9509]。到 2026 年 4 月，MI355X 在 MLPerf Llama 2 70B 上与 B200 持平（每 GPU 12,935 对比 12,994 tokens/s）[S602]，但在每用户 150 tokens/s 的智能体推理服务中仍落后最多 5× [S636]。单芯片持平用了 ~16 个月；机架级持平仍无定论。

Layer 13 draws 24 of 81 deals, nearly all stakes; M&A concentrates in layer 11 (9)

Number of logged NVIDIA deals (81) by the stack layer each strengthens, split by M&A vs investment

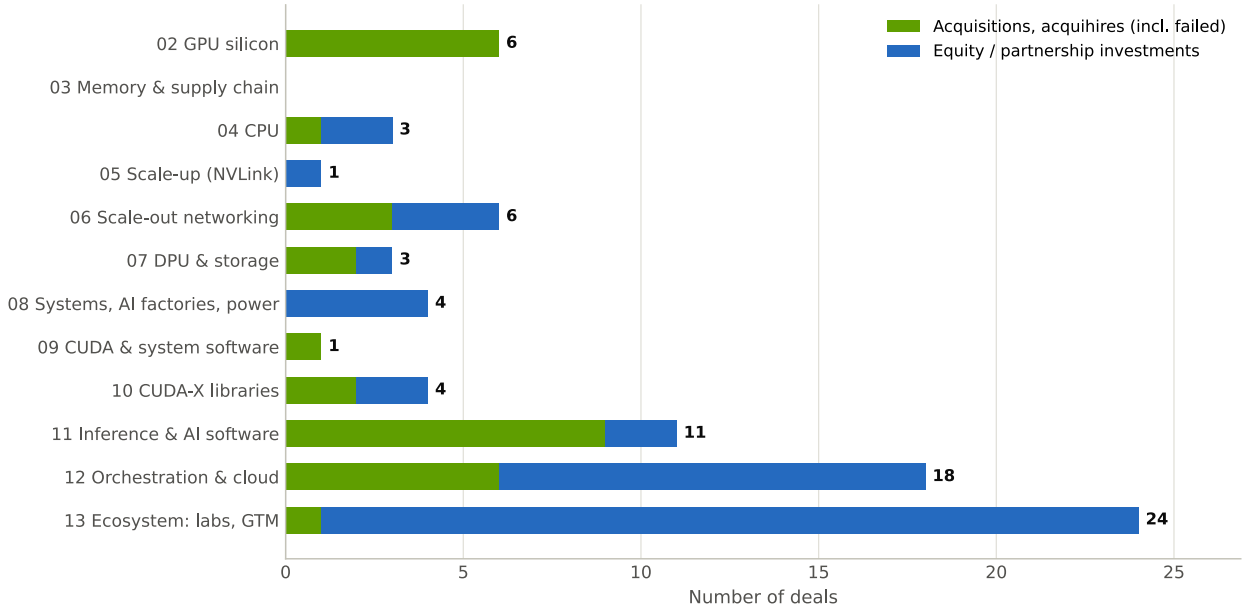

Source: data from NVIDIA filings and announcements; press reports [S400] [S484] [S464] [S2] [S478] [S465] …; chart by repo · As of 2026-11-05

按层划分的英伟达 81 笔交易水平堆叠柱状图：第 13 层（实验室与生态）有 24 笔，几乎全是股权投资；第 12 层（编排与云服务）有 18 笔，既有 Run:ai 这类补强收购，也有对新兴云服务商的入股；第 11 层（推理软件）有 11 笔，大多为收购；芯片、CPU 和网络各层交易数量少但金额大（Mellanox、Arm、英特尔）。

反事实推演 —— 如果英伟达没有……

- ……**开源 Dynamo?** 🔴 llm-d（红帽、谷歌、IBM、CoreWeave）很可能会成为默认的分布式层，且其中不会包含英伟达的 KV 传输库 [S11503]。英伟达同样是 llm-d 的联合发起方：无论哪条路线胜出都有对冲。
- ……**达成 Groq 交易?** 🔴 Groq（2025 年 9 月估值 ~$6.9B）会继续作为低延迟领域的竞争对手，或被竞争对手收入囊中，而英伟达手里只剩 Rubin CPX——后者已从 GTC 2026 路线图中移除 [S90019,S115]。手握 OpenAI 750 MW 合同的 Cerebras 将独占超低延迟层 [S11523]。
- ……**同意收购 Hugging Face?** 🔴 该平台将保持中立；英伟达表示在那里不会强制要求使用其芯片，这一承诺可能会受到监管机构的检验 [S11026,S11501]。

🎯 企业发展视角

1. 英伟达为软件团队支付了 ~$1B，却为一项硬件授权支付了 ~$20B：稀缺的推理资产究竟是芯片架构，而不是推理服务代码？
2. Groq 交易结构规避了并购审查；在 Hugging Face 交易受到审视之后，监管机构会如何对待下一笔类似交易？
3. 如果复制一个引擎只需 ~$0.1–0.2B，而针对每款芯片的内核需要 ~$0.5–1.5B，挑战者是否应该把资金投入 vLLM/SGLang 中的内核，而不是自建引擎？
4. 还剩下哪些独立的推理服务和编译器团队？还有谁在竞购？

推理与 AI 软件：路线图

第 11 层 · 推理与 AI 软件 · 约 9 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **软件以月为节拍迭代：** Dynamo 从开源发布（2025 年 3 月）到 1.0（2026 年 3 月），再到提供企业级支持的 1.5.1（2026 年 10 月）；TensorRT-LLM 于 2025 年 9 月发布 1.0 [S32015,S521,S522]。
- **英伟达（NVIDIA）的推理硬件如今分为两档：** Vera Rubin NVL72（自 2026 年第三季度起量产出货）主打吞吐量，Groq 3 LPX 机架（256 颗 SRAM LPU，2026 年 8 月全面量产）主打快速解码 🟢 [S90009,S114,S506]。
- **更多解码芯片即将到来：** LP35（2027）和与 Feynman 搭配的 LP40（2028），另有报道称 Rubin CPX 将以 HBM4 版本复活、用于预填充 🟡 [S108,S90004,S117]。
- **竞争对手同样按年度节奏推出产品：** MI455X Helios（2026）与 MI500（2027）；TPU 8i（2026 年底）；Maia 300 与 Trainium4（2027）；高通（Qualcomm）AI250（2027）与 AI300（2028）[S538,S550,S90046,S156,S173,S90060]。
- **AMD 如今在单芯片内存带宽上领先：** 在英伟达修订规格后，MI455X 为 23.3 TB/s，Rubin 为 19.2 TB/s（高出 ~21%）；云端 ASIC 比 Rubin 低 ~2.6× [S144,S90093,S90006]。
- **[Q7 · 路线图与变数]** 关注三件事：开源推理服务在非英伟达机架上实现持平（llm-d 1.0；Helios 于 2027 年第二季度放量）、某款 ASIC 公开展示超过 ~2× 的每 token 成本优势，以及 token 价格下降速度快于每 token 成本下降速度。

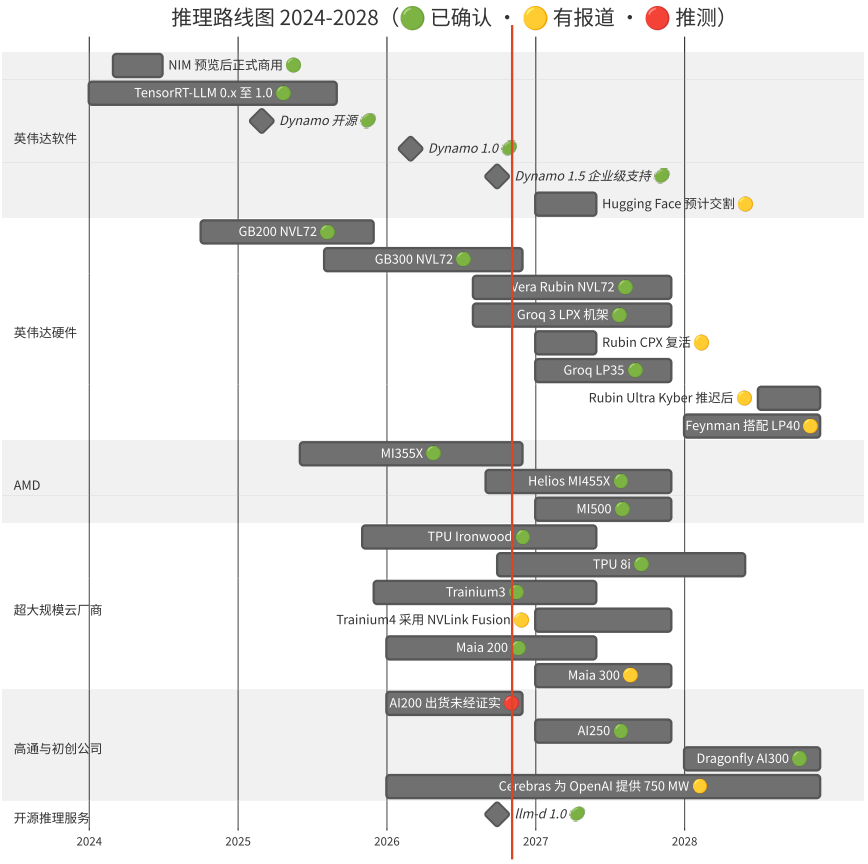

各行来源见下表；表中未列出的条形：NIM 预览（2024 年 3 月）与正式商用（2024 年 6 月）[S11014,S11015]；Cerebras 为 OpenAI 提供最多 750 MW [S11523]。

路线图逐项解析

项目	时间窗口	状态	置信度	来源
Dynamo 1.0 → 1.5.1（企业级支持）	2026 年 3 月 → 10 月	已发布	🟢	S90066,S521
Vera Rubin NVL72	2026 年第三季度出货，第四季度爬坡	出货中	🟢	S90009
Groq 3 LPX（256 颗 LP30 LPU，128 GB SRAM）	2026 年下半年	量产中	🟢	S114,S506
Rubin CPX（预填充），改用 HBM4 重新设计	2027	推迟 / 复活	🟡	S115,S117
Groq LP35（新增 NVFP4）	2027	路线图	🟢	S108
Rubin Ultra，Kyber 机架	2027 年下半年，据报道推迟至 2028 年	路线图	🟡	S90003,S502
Feynman + LP40 LPU	2028	路线图	🟡	S90004,S109
Hugging Face 收购交割	2027 年上半年	待审查	🟡	S11026,S11027
AMD Helios MI455X → MI500	2026 → 2027	出货中 / 路线图	🟢	S538,S544
谷歌 TPU 8i	2026 年底	已发布	🟢	S550,S551
微软 Maia 300	2027	已发布	🟡	S90046,S560
AWS Trainium4（NVLink Fusion）	2027（估计）	路线图	🟡	S156,S90034
高通 AI200 → AI250 → AI300	2026 → 2027 → 2028	已发布；AI200 出货未经证实	🟢 / 🔴	S173,S90060,S90028
llm-d 1.0（英伟达、AMD、英特尔、TPU）	2026 年 10 月	已发布	🟢	S11503

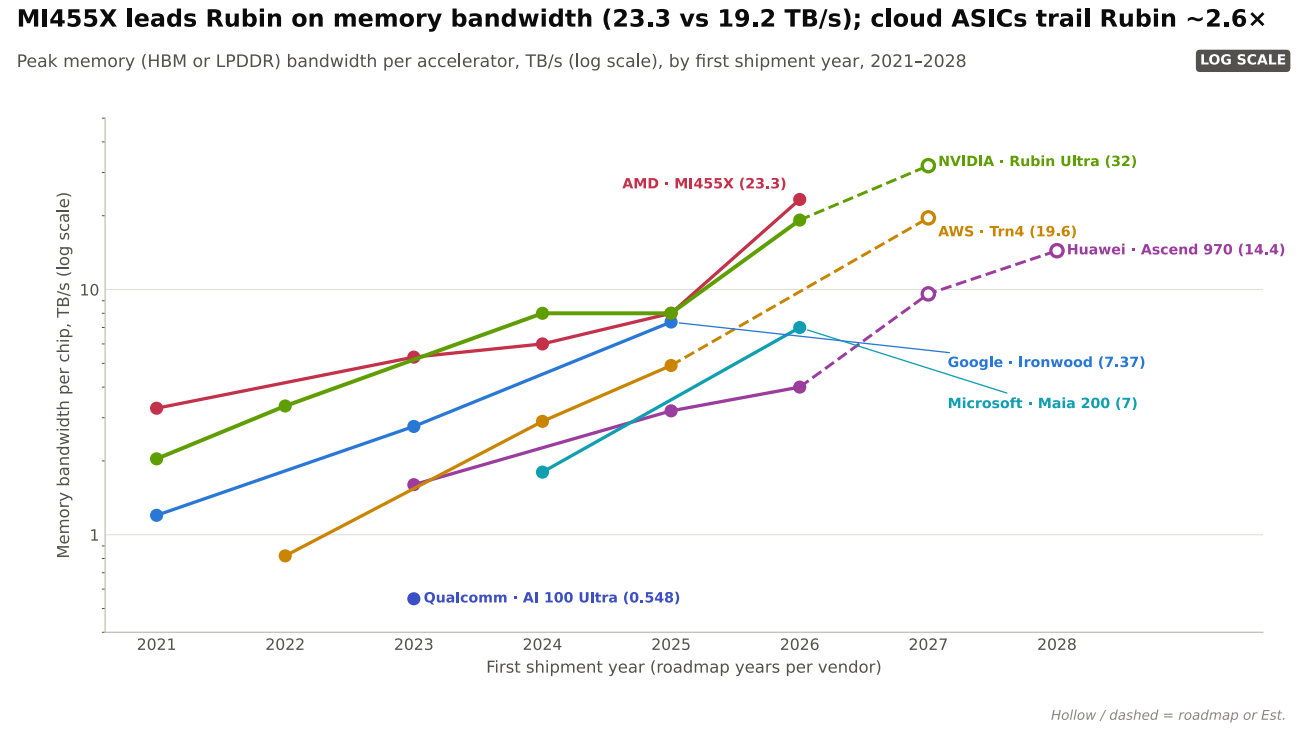

> 各厂商单加速器内存带宽的对数坐标折线图。英伟达从 A100（2.0 TB/s，2021 年）和 H100（3.35）提升到 B200/B300（8.0）和 Rubin（2026 年规格修订后为 19.2 TB/s），Rubin Ultra 预计 2027 年达到 32 TB/s。AMD 在每一步都持平或领先：MI300X 5.3、MI355X 8.0、MI455X 23.3。谷歌 Ironwood（7.37）和微软 Maia 200（7.0）比 Rubin 低约 2.6 倍；AWS Trainium3 为 4.9，Trainium4 预计 2027 年接近 19.6；华为昇腾路线图在 2028 年达到 14.4 TB/s；高通基于 LPDDR 的 AI 100 Ultra 为 0.55 TB/s。

> **提示**
>
> **算例 —— 逐代看解码速度上限。** 单个用户运行一个 FP8 精度的 70B 模型（~70 GB）时，生成速度不可能超过内存带宽除以 70 GB：H100（3.35 TB/s）上为 ~48 tokens/s，B200（8 TB/s）上为 ~114，Rubin（19.2 TB/s）上为 ~274，MI455X（23.3 TB/s）上为 ~333 [S33002,S33003,S90006,S144,S90093]。如果 Rubin 保持发布时 22 TB/s 的规格，上限将为 ~314 [S90006]，仍低于 MI455X。AMD 在这一单项指标上领先，规格下调又扩大了差距；让英伟达在交互速度上保持领先的，是 NVLink 域、软件和 LPX 层级。

> **🔧 技术细节：英伟达为何用 Groq LPU 取代 Rubin CPX，之后又可能两者都要**
>
> 预填充（prefill）以一次计算密集的前向过程读取提示词；解码（decode）则逐个输出 token，受限于带宽。Rubin CPX（GDDR7，发布时宣称 30 PFLOPS NVFP4）瞄准的是低成本预填充；随着 Groq 3 LPX 占据解码位置，它从 GTC 2026 路线图中消失 [S115,S116]。英伟达宣称，对于万亿参数模型，LPX 与 Vera Rubin 搭配可实现相对 Blackwell NVL72 最高 35× 的每兆瓦吞吐量（厂商说法）[S114,S308]。2026 年 9 月的一份分析师报告称，CPX 将以 HBM4 版本于 2027 年回归 🟡 [S117]。如果两者都推出，Rubin 时代的 AI 工厂可在 Dynamo 的分离式服务下运行三个资源池（CPX 预填充、GPU 批量解码、LPU 快速解码）。

哪些因素会改变格局

[Q7 · 路线图与变数]

- **开源推理服务在每种机架上实现持平。** llm-d 1.0 已能在英伟达、AMD、英特尔和 TPU 上运行 [S11503]；如果 Helios 在 2027 年第二季度放量，且开源引擎在其上实现 Dynamo 级别的分离式服务，英伟达的软件领先优势将缩短到几个月 🟡 [S624]。
- **某款 ASIC 公开展示超过 ~2× 的成本优势。** 目前公开的最大差距为 ~18%（Ironwood 对比 B200）[S625]；候选者包括 TPU 8i、Maia 300（寻求数十万颗的产量）以及 Etched 的 Sohu（据报道预订单 ~$1B）🟡 [S550,S559,S2507]。
- **价格下降快于成本下降。** 在质量固定的前提下，价格每年下降 9–900× [S11525]；在某一工作负载上，从 H200 到 GB300，每 token 硬件成本下降 ~11× [S621,S622]。价格下降更快会挤压供应商；而 2026 年前沿模型的涨价（GPT-5.5 价格为 GPT-5.4 的 2×）则指向相反的方向 🟡 [S11535]。
- **英伟达直接从软件变现。** 黄仁勋提出智能体软件每 GPU 每年 ~$2,000 的设想（2026 年 10 月），低于 AI Enterprise $4,500 的标价；目前尚无价目表 🟡 [S11016,S9515]。
- **监管机构与 Hugging Face。** 若交易被否决或被附加条件，主要的模型中心将保持中立 🔴 [S11027,S11028]。

🎯 企业发展视角

1. MI455X 如今在带宽上领先 Rubin，其他挑战者该在哪里实现差异化：容量（768 GB LPDDR）、SRAM 速度，还是价格？
2. 如果英伟达自己的路线图加入了 SRAM 解码（LP30 → LP35 → LP40），独立的 SRAM 初创公司除了被收购或被授权之外，还剩下什么出路？
3. 2027 年的哪个里程碑（Helios 放量、TPU 8i、Maia 300、Trainium4）最可能改变超大规模云厂商的采购组合？
4. 每 GPU $2,000 的软件费用会对开源采用率和推理云的利润率产生什么影响？

推理与 AI 软件：价值链与企业发展视角

第 11 层 · 推理与 AI 软件 · 约 12 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **每 1 美元 API 收入中，大部分留在模型实验室：** 据报道，OpenAI 在 2025 年 10 月的算力毛利率（compute margin）为 ~70%；估计其中 ~16¢ 流向云厂商，~5¢ 作为毛利流向英伟达（NVIDIA）🔴 S11537,S622,S3。
- **固定质量下的 token 价格快速通缩**（GPT-3.5 水平的价格两年内从每百万 $20 降至 $0.07），但 GPT-5.5 上市定价却是 GPT-5.4 的两倍 🟡 S11526,S11535。
- **英伟达的软件业务线规模很小：** AI Enterprise 标价为每 GPU 每年 $4,500；FY2025 末 ~$2B 的年化收入不到 FY2026 收入的 1% S9515,S11011,S1。
- **推理服务商的估值堪比芯片初创公司：** Fireworks ~$15B（洽谈中）、Together AI $8.3B、Baseten $5B；英伟达投资了后两家 S11514,S11516,S11518。
- **交易：** 英伟达–Groq（~$20B）、英伟达–Hugging Face（~$12.9B，尚待完成）、高通（Qualcomm）–Modular（$3.9B）、AMD–Silo AI（$665M） S90019,S11026,S90057,S9506。
- **[Q8 · 价值池与并购机会]** 价值池：实验室利润、云厂商租赁利润、英伟达硬件利润。切入点：可移植软件、解码（decode）芯片，以及决定硬件选型的推理云。

Est.: of $1 of API revenue the lab keeps ~70¢, the cloud ~16¢, NVIDIA ~5¢ of gross profit

Split of $1.00 of closed-model API revenue served on rented GB300 NVL72 capacity, US cents (repo estimate)

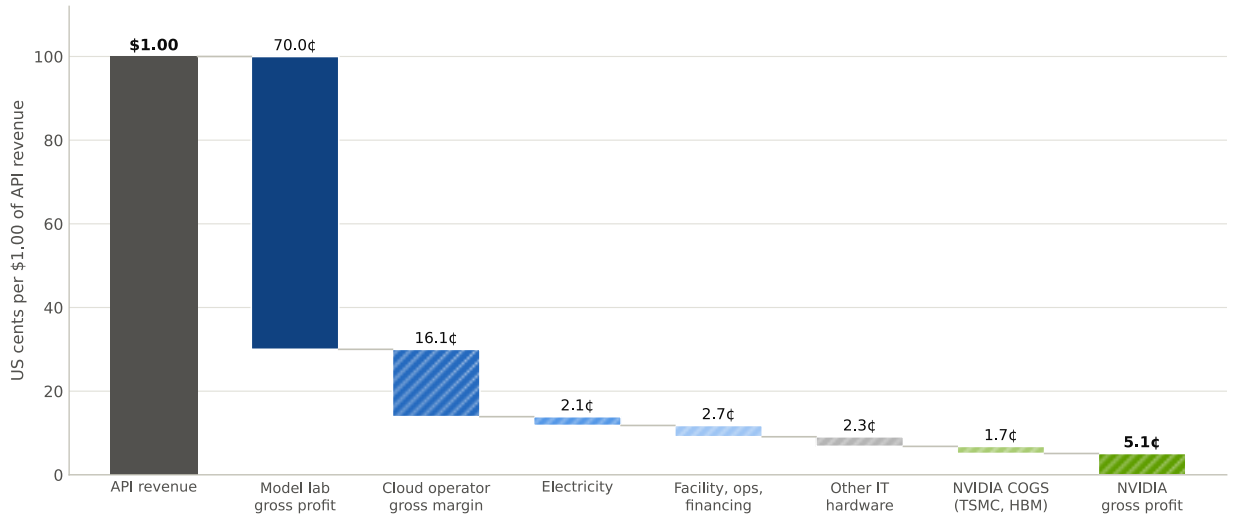

Hatched = Est.

Source: data from repo estimate on reported margins and TCO [S11537] [S11538] [S622] [S389] [S387] [S332] …; chart by repo · As of 2026-11-05

拆分 $1.00 API 收入的瀑布图：模型实验室的算力毛利率留下约 70 美分的毛利（据报道 OpenAI 在 2025 年 10 月约为 70%）；剩余 30 美分的算力成本拆分为：云运营商毛利（约 16 美分，依据每 GB300 GPU 小时租价 $5.00 对比所有者 TCO $2.31）、电费（约 2 美分）、设施、运营与融资（约 3 美分）、其他 IT 硬件（约 2 美分）、英伟达销售成本（约 2 美分）以及英伟达毛利（约 5 美分）。实验室所得部分仍需支付训练算力和研发，其中很大一部分同样流向英伟达。

谁赚走了一个 token 的利润

把一个 token 想象成一份餐厅的菜：模型实验室拥有菜谱和品牌，云厂商出租厨房，英伟达卖出了烤箱。菜单价格由品牌决定，因此只要客户还想要它的模型，实验室就能拿走账单的大头。

> **提示**
>
> **算例 —— 在 GB300 NVL72 上生成一百万个 DeepSeek-R1 token。** 在每用户 50 tokens/s 下，一块 GB300 GPU 每秒输出 ~6,261 个 token，即每小时 ~22.5M [S621]。按 SemiAnalysis 的 $5.00 租价计算，相当于每百万 token ~$0.22；按所有者 $2.31 的总拥有成本（TCO）计算，为 ~$0.10 [S622]。英伟达的收入占租金的 ~23%（每 GPU 小时 ~$1.13）：每百万 token ~$0.05，其中 ~$0.04 为毛利 🔴 [S3]。若算力占收入的 30%，实验室对每百万 token 收费 ~$0.74。

> **🔧 技术细节：假设与敏感性**
>
> 输入：OpenAI ~70% 的算力毛利率 [S11537,S11538]、SemiAnalysis 的租价与所有者 TCO 对比 [S622]、电力占所有者 TCO 的 ~15%、英伟达占 IT 硬件的 ~75%（GPU 占 GB300 机架价格的 ~63%）[S332]，以及英伟达 75.0% 的毛利率 [S3]。若按 2024 年底实验室 52% 的利润率计算，英伟达的毛利为 ~8¢；低于标价的合同价会压缩云厂商的份额；训练算力不计入。数据：`l11_token_value_pools.csv`。

token 价格通缩及其极限

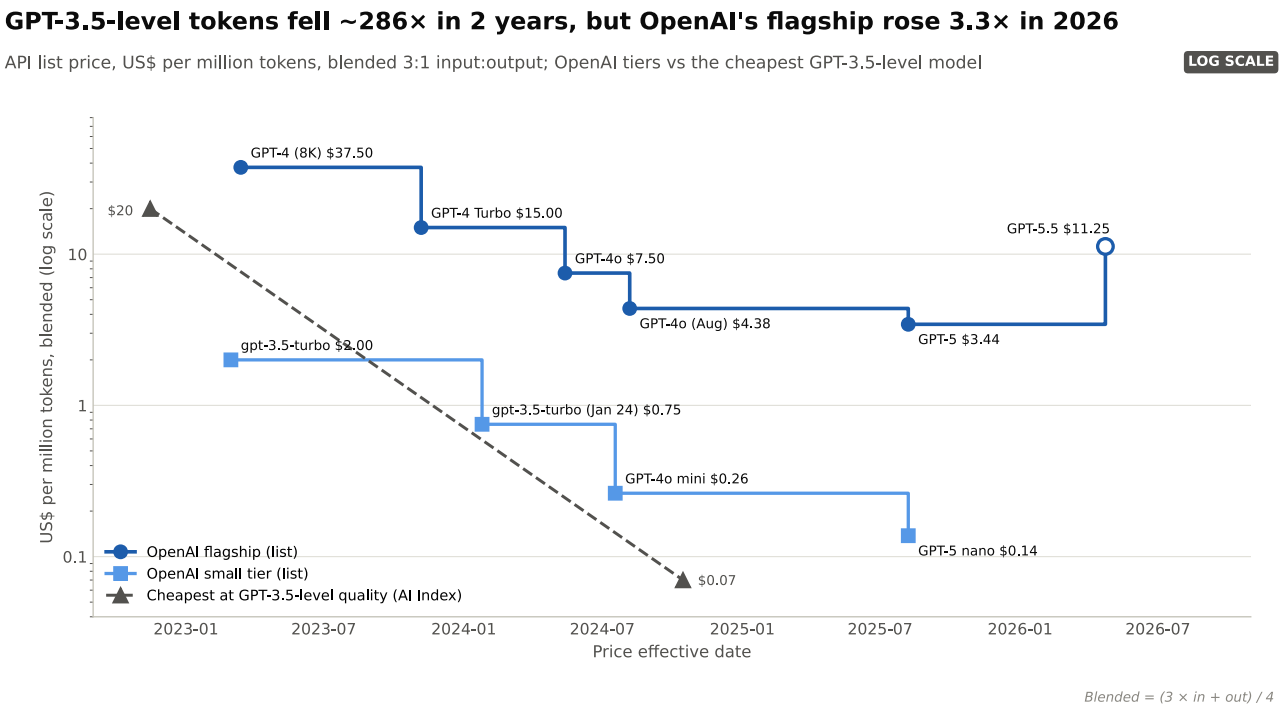

每百万 token API 价格的对数坐标图。GPT-3.5 质量水平最便宜模型的价格从 $20（2022 年 11 月）降至 $0.07（2024 年 10 月），约下降 286 倍。OpenAI 旗舰模型从 GPT-4 的混合价 $37.50（2023 年 3 月），经 GPT-4 Turbo（$15）、GPT-4o（$7.50，后降至 $4.38），降至 GPT-5 的 $3.44（2025 年 8 月），便宜约 11 倍；随后 GPT-5.5 以 $11.25 上市（2026 年 4 月，据报道），为 GPT-5 的 3.3 倍。OpenAI 小模型档从 gpt-3.5-turbo 的 $2.00（2023 年）降至 GPT-4o mini（$0.26）和 GPT-5 nano（$0.14）。

token 价格通缩源于更好的硬件、软件和更小的模型。MIT 的一项研究估计，前沿质量模型的价格每年下降 5–10× [S11527]。此处价格按 Epoch 的惯例，以输入与输出 3:1 的比例混合计价 [S11525]。迄今为止，更便宜的 token 意味着更多的 token：谷歌的月度 token 量从 9.7 万亿（2024 年 4 月）增至超过 1.3 千万亿（2025

年 10 月），这是典型的杰文斯悖论 [S32018,S32020]。同样的挤压也冲击了 GPU 租赁市场：H100 租价两年内下降了 ~75% [S393,S395]。

H100 rentals fell ~75% from ~$8/GPU-hr (2023) to ~$2-3 on neoclouds; AWS list −44%

On-demand list/observed prices, US$ per GPU-hour (instance ÷ GPUs) · marker = provider type · contract rates are lower

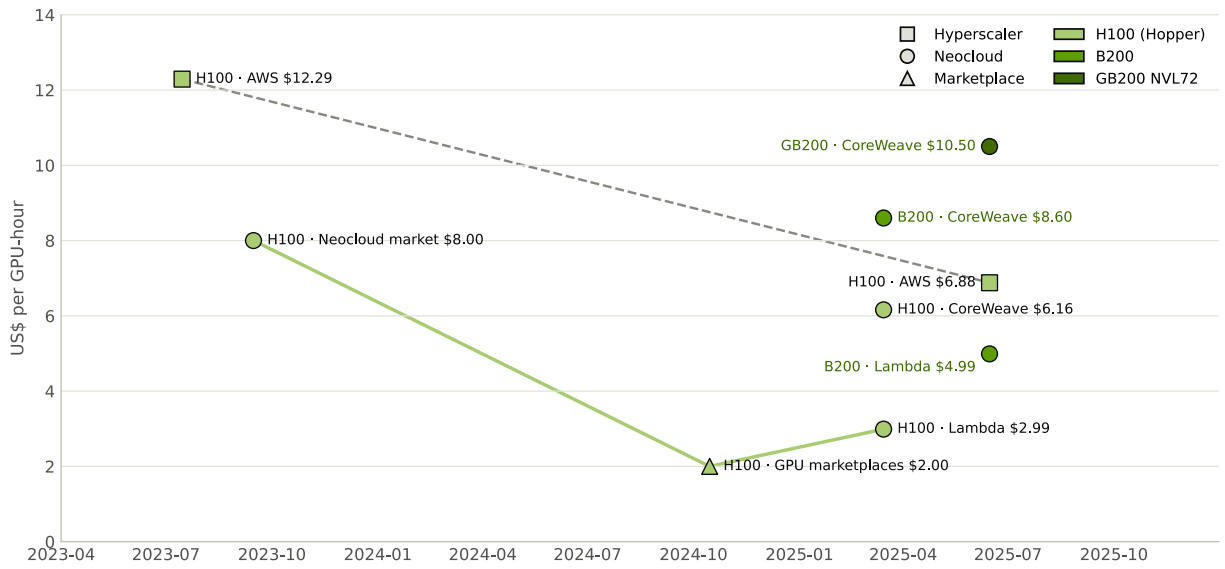

Source: data from AWS, CoreWeave, Lambda, Latent Space [S391] [S393] [S395] [S394] [S392]; chart by repo · As of 2026-11-05

GPU 租价随时间变化的散点图。H100：AWS p5 按需价格在 2023 年 7 月上市时为每 GPU 小时 $12.29，2025 年 6 月降价后为 $6.88；新兴云服务商的 H100 在 2023 年约为 $8，到 2024 年底各交易市场已低于 $2，2025 年 Lambda 标价 $2.99、CoreWeave 标价 $6.16。2025 年 Blackwell 标价：B200 从 $4.99（Lambda）到 $8.60（CoreWeave），GB200 为 $10.50（CoreWeave）。

提示

算例 —— 谁来消化通缩。 某服务商以 50% 的毛利率销售 token。第二年价格下降 50%，每 token 成本下降 30%：成本为旧价格的 0.5 × 0.7 = 0.35，而收入为 0.5，因此毛利率降至 30%。要维持 50% 的毛利率，成本下降速度必须与价格同步，所以服务商会追逐每一次软件增益和每一代新 GPU。

NVIDIA AI Enterprise 的经济账

提示

算例 —— 许可费给每个机架增加多少成本。 一个 72 块 GPU 的 GB300 NVL72 机架，按 $4,500 标价计每年 $324K，相当于每年 ~$4M 机架价格的 ~8% [S9515,S332]；在生产环境中使用 NIM 需要此许可，或在云上按每 GPU 小时 ~$1 计费 [S11013]。黄仁勋在 2026 年 10 月提出智能体软件每 GPU 每年 ~$2,000 的设想 [S11016]。看空要点：Q4 FY2024 软件年化收入仅 ~$1B [S9516]，与硬件相比微不足道，而开源引擎让买家可以绕开这笔费用（竞争格局）。

本层的非上市公司与并购

公司	业务	阶段 / 最近一次公开融资	为何重要
Fireworks AI	开放模型推理云	以 ~$15B 估值洽谈融资（2026 年 5 月）；另有报道称正以 $30–40B 洽谈 🟡	按估值计最大的独立 token 销售商 [S11514,S11515]
Together AI	推理与训练云	C 轮 $800M，估值 $8.3B（2026 年 7 月）；英伟达参投	Dynamo 1.0 采用者 [S11516,S90066]

公司	业务	阶段 / 最近一次公开融资	为何重要
Baseten	推理平台	E 轮 $300M，估值 $5B（2026 年 1 月）；英伟达为基石投资者	采用 Dynamo 路由后 TTFT 快 2× S11518,S11001
Modal Labs	无服务器 GPU 算力	以 ~$2.5B 估值洽谈融资（2026 年 2 月）🟡	开发者入口 S11519
Inferact	vLLM 背后的公司	种子轮 $150M，估值 $800M（2026 年 1 月）	主导可移植性最强的引擎 S11511,S11540
RadixArk	SGLang 背后的公司	种子轮 $100M，估值 $400M（2026 年 5 月）；据报道英伟达、AMD 参投	许多 InferenceX 前沿数据点背后的引擎 S11513
Cerebras（2026 年 5 月上市）	晶圆级系统与云服务	IPO 募资 $5.55B，估值 ~$40B	OpenAI 最多 750 MW S2505,S11523
Groq	GroqCloud API	~$6.9B（2025 年 9 月），随后获英伟达 ~$20B 授权交易	授权方还能继续竞争吗？ S90019
Etched	专用于 Transformer 的 ASIC	C 轮 $300M，估值 $10.3B（2026 年 7 月）	押注专用化；据报道预订单 ~$1B S2507
Positron	内存优先的推理 ASIC	C 轮 $875M，估值 $5B（2026 年 9 月）	较 2026 年 2 月上涨 ~5× S11521,S11520
d-Matrix	数字存内计算	C 轮 $275M，估值 $2B（2025 年 11 月）	无需晶圆级芯片的 SRAM 解码 S2511
Tenstorrent	RISC-V AI 芯片，开放软件栈	D 轮 $693M，估值 ~$2.7B（2024 年 12 月）	可授权的 IP S2509
MatX	大语言模型加速器	B 轮 $500M（2026 年 2 月）；估值未披露	计划 2027 年出货 S2508
SambaNova	数据流芯片与云服务	英特尔以 ~$1.6B（含债务）洽谈收购，已停滞	可能成为困境资产 S2512
Rebellions、FuriosaAI	韩国推理 NPU	FuriosaAI 过桥融资 ~$122M（2025 年 7 月）	已获 Ray 支持 S11522,S584

仅限公开信息；除标注为洽谈或要约者外，估值均为投后估值。

Inference clouds price like chip start-ups: Fireworks ~$15B vs Etched $10.3B

Last disclosed or reported valuation, US$ millions (log scale); Cerebras at IPO pricing; acquisitions at deal price

LOG SCALE

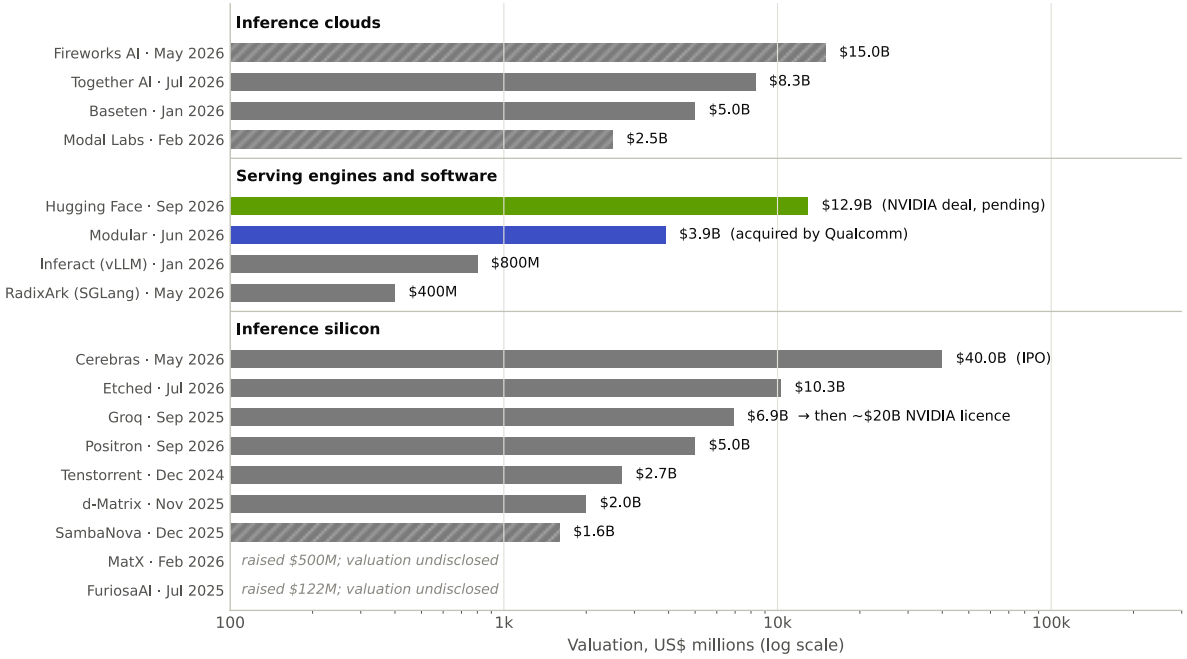

Hatched = talks / offer

Source: data from company announcements and press [S11514] [S11516] [S11517] [S11518] [S11519] [S11511] ...; chart by repo · As of 2026-11-05

推理初创公司估值的对数坐标水平柱状图。推理云：Fireworks AI 约 $15,000M（洽谈中，2026 年 5 月）、Together AI $8,300M（2026 年 7 月）、Baseten $5,000M（2026 年 1 月）、Modal 约 $2,500M（洽谈中）。推理服务软件：Hugging Face $12,930M（英伟达于 2026 年 9 月宣布收购，尚待完成）、Modular $3,900M（2026 年被高通收购）、Inferact（vLLM）$800M 与 RadixArk（SGLang）$400M 的种子轮估值。芯片：Cerebras 在 2026 年 5 月 IPO 时约 $40,000M、Etched $10,300M、Groq 在获英伟达约 $20B 授权前为 $6,900M、Positron $5,000M、Tenstorrent 约 $2,700M、d-Matrix $2,000M、SambaNova 约 $1,600M（英特尔要约洽谈）；MatX 和 FuriosaAI 估值未披露。

本层的并购历史

收购方	交易（年份，金额）	逻辑
英伟达	Deci、Run:ai、OctoAI（2024；~$300M、~$700M、~$250M）；CentML（2025，含业绩对赌付款 >$400M）；Groq 授权 + 团队（2025，~$20B）；Hugging Face（2026，~$12.9B，尚待完成）	编译器与推理服务人才、SRAM 解码、模型分发 S478,S476,S11510,S11509,S90019,S11026
AMD	Nod.ai（2023）；Silo AI（2024，$665M）；Brium 与 Untether AI 团队（2025）；MK1（2025）	弥补 ROCm 的软件短板 S9508,S9506,S9507,S9509
高通	Modular（宣布金额 $3.9B，2026-07-29 完成交割）	可跨硬件移植的运行时（Mojo、MAX） S90057,S9511
红帽（IBM）	Neural Magic（2024）	商业化 vLLM；后来联合发起 llm-d S9533,S11503
英特尔	SambaNova（洽谈中，~$1.6B 含债务，已停滞）	重返推理芯片市场 S2512

提示

算例 —— 一家 token 销售商值多少钱。 Together AI $8.3B 的估值是其 2025 年 2 月 B 轮 ~$3.3B 估值的 ~2.5× S11516；在英伟达这边，~$20B 的 Groq 交易价格是 Groq 最近一次私募估值 ~$6.9B 的 ~2.9× S90019。买家支付的是推理领域的稀缺性溢价，而非当前收入。

完整的交易图表见发展历程：英伟达如何建成这一层。

[Q8 · 价值池与并购机会] 最大的价值池是模型实验室的利润（扣除训练成本前占 API 收入的 ~70%），其次是云厂商的租赁利润，再次是英伟达的硬件利润；英伟达自身的软件收入不到其总收入的 1% S11537,S622,S11011。

并购追随稀缺性：英伟达为引擎团队花钱不多，却为解码芯片和分发渠道一掷千金；AMD 和高通买的是可移植性。尚存的切入点：可移植推理服务公司（Inferact、RadixArk）、SRAM 或近存解码 IP（d-Matrix、Positron、Etched），以及为开放权重模型选择硬件的推理云。

🎯 企业发展视角

1. 高通为 AI 100 提供了 vLLM 容器，如今又拥有 Modular [S596,S9511]：AI200/AI250 的软件应依靠上游 vLLM/llm-d 扩大覆盖面，依靠 MAX 实现差异化，还是两者兼顾?
2. 英伟达持有 Together AI 和 Baseten 的股份 [S11516,S11518]。什么条件能促使一家推理云认证第二个硬件平台?
3. 英伟达选择授权 Groq 而非收购。对 SRAM 和近存计算初创公司而言，授权或少数股权投资是否优于 $2–10B 的收购?
4. 如果实验室保留每 1 美元 API 收入中的 ~70¢，与 token 买家（HUMAIN 式的主权机构或模型实验室）联合设计，是否比商用芯片销售更有价值 [S90030]?
5. 如果监管机构对英伟达的 Hugging Face 交易附加条件，中立的模型分发是否可能成为一个合作机会 [S11027]?

第 12 层 —— 编排与云服务

第 12 层（共 12 层）· 调度器、AI 工厂运营软件，以及出租英伟达系统的 GPU 云 · 约 6 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **本层把机架变成有效且有人付费的 GPU 小时。** 折旧约占一颗 GPU 年度成本的 81–88% [S389,S382]，因此一颗 GB300 NVL72 GPU 无论忙闲，每个已安装小时的成本约为 $1.50（估计）[S332,S324]：**利用率 30% 时每有效小时 $5.00，90% 时为 $1.67**。
- **损失规模大且可量化。** 阿里巴巴借助碎片感知调度器，将其 155,410 颗 GPU 机群的分配率从 68% 提升至 93% [S12015]；Meta 的 Llama 3 训练在 54 天内记录了 419 次意外中断，模型算力利用率（MFU）为 38–41% [S34006]。
- **英伟达买下了控制平面：** Bright Computing（2022 年）、Run:ai（约 $700M，2024 年）、Slurm 的开发商 SchedMD（2025 年 12 月）[S478,S476,S12000]，并将其打包为 Mission Control [S12005] 及模块化的 DSX OS（2026 年）[S12513]。它先开源了 KAI Scheduler，随后又开源了 Run:ai 本身 [S12003,S12510]。
- 🟡 **英伟达自有云转向内部：** DGX Cloud（2023 年）已调整为主要服务内部研究 [S90068]，而 DGX Cloud Lepton 则把开发者导流至合作伙伴云 [S598]。英伟达仍持有 $29B 的云服务协议，外加 $36B 的 AI 云容量协议（2026 年 7 月）[S407]。
- **买方正在多元化，但并不均衡：** Q2 FY2027 数据中心收入中，超大规模云厂商约占 55% [S90011,S90013]；Q1 中 ACIE 与超大规模云厂商大致持平，Q2 区域性新兴云服务商（neocloud）环比增长 35% [S90071]。仅 CoreWeave 一家就运营约 1.5 GW [S12010]。
- **弱点与最强挑战者：** 超大规模云厂商掌握客户、云控制平面以及自研芯片（TPU、Trainium、Maia）[S90026,S90035,S90044]。编排软件免费或开源，英伟达只能间接从中获益，而其兜底承诺又将自身与新兴云服务商的利用率绑在一起。

Est.: at 30% vs 90% utilization, a useful GB300 NVL72 GPU-hour costs $5.00 vs $1.67

US$ per useful GPU-hour = (capex +26% network/storage ÷ life + max power × PUE) ÷ utilization · all Est.; excl. facility, staff, financing

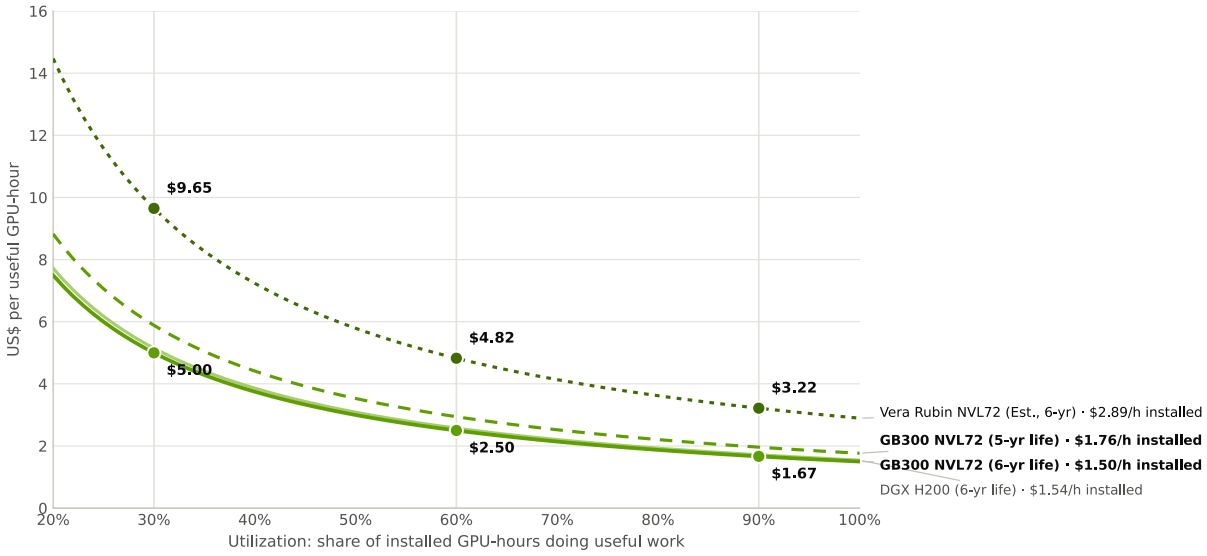

Source: data from MS, SemiAnalysis, resellers, EIA, 10-Ks (repo calc) [S33022] [S322] [S32002] [S32004] [S338] [S339] …; chart by repo · As of 2026-11-05

每有效 GPU 小时估计成本随利用率变化的折线图。一颗 GB300 NVL72 GPU 每个已安装小时约 $1.50（资本开支 $70K，含网络与存储，6 年寿命，电力 $0.17/h），因此利用率 30% 时每有效小时 $5.00，60% 时 $2.50，90% 时 $1.67；若按 5 年寿命则为 $5.88、$2.94 和 $1.96。Vera Rubin NVL72（每已安装小时约 $2.89）分别为 $9.65、$4.82 和 $3.22；DGX H200 每已安装小时约 $1.54。每有效小时成本与 1/利用率成正比。

提示

算例 —— 为什么十个百分点的利用率是董事会层面的数字。 一个 100,000 颗 GPU 的 GB300 机群，无论忙闲，每年成本约为 $1.50 × 8,760 h × 100,000 ≈ **$1.3B**（估计，出自利用率问题）。将利用率从 60% 提升到 70%，可多产生 8,760 万个有效 GPU 小时，按成本计约值 $131M，按租赁价格计则更多。**结论：** 相对于其释放的算力，调度与恢复软件的成本很低。

本层在技术栈中的位置

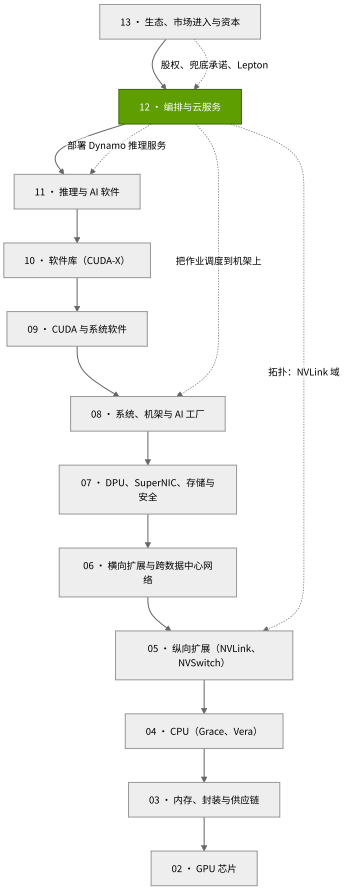

本层导图

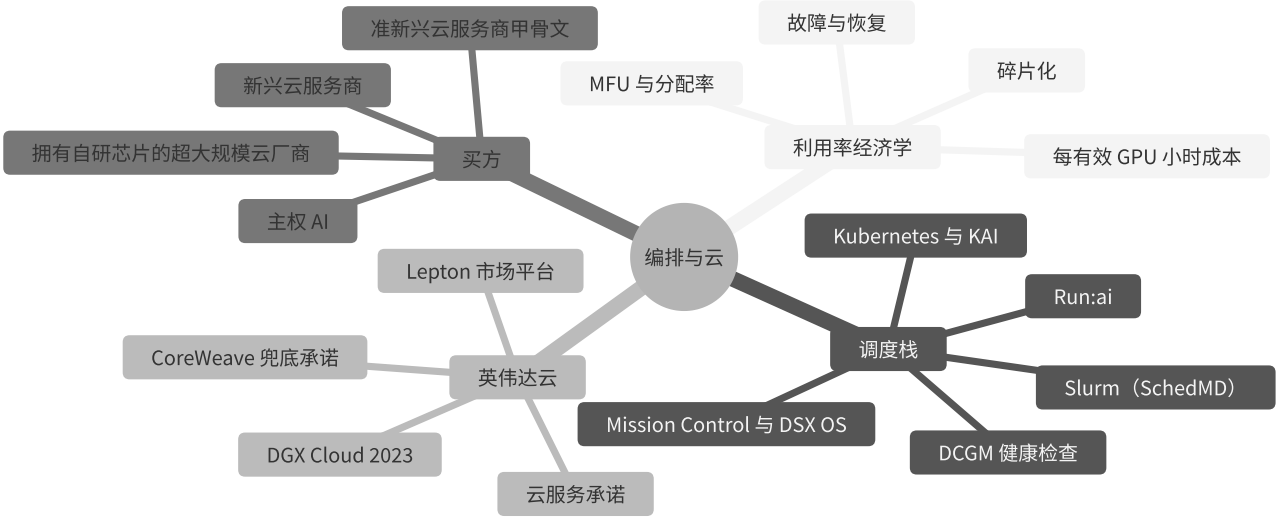

八个问题一览

#	问题	简答	详见
Q1	职能是什么，薄弱时会出什么问题？	把已安装的 GPU 变成有效且有人付费的小时；若薄弱 → 集群闲置、碎片化、频繁故障，利用率 30% 时每有效小时成本约为 90% 时的 3 倍	利用率问题
Q2	关键指标？	分配率、有效训练时间（goodput）、MFU 或每 GPU 小时 token 数、平均恢复时间、每有效 GPU 小时美元成本	利用率问题

#	问题	简答	详见
Q3	代际进步?	控制平面从集群工具（2022 年）演进为 AI 工厂操作系统（2026 年）；从 H100 到 Blackwell，租用一个 PFLOPS 小时的价格在 FP8 下便宜 1.4–1.6 倍，在 FP4 下便宜 2.7–3.3 倍	调度栈、超大规模云厂商与新兴云服务商
Q4	优势来源?	调度器、遥测与硬件的一体化，加上资本与供货分配能力，而非授权收入	发展历程与构建方式
Q5	最强挑战者?	超大规模云厂商：它们掌握客户、控制平面以及自研加速器	竞争格局
Q6	复制成本?	调度器很便宜（开源）；但英伟达集供货分配、资本与软件覆盖面于一身的组合难以复制	发展历程与构建方式
Q7	路线图?	DSX OS、开源 Run:ai、针对 Vera Rubin 调优的 Slurm、Lepton 扩张；关注新兴云服务商融资与超大规模云厂商自研芯片	路线图
Q8	价值池与并购?	租赁利润归云厂商；英伟达通过股权、兜底承诺和市场平台参与；补强型收购：Run:ai、SchedMD、Lepton	价值链与企业发展视角

本层页面

页面	你将了解
利用率问题	每有效 GPU 小时成本、五大浪费来源、关键指标、由谁承担闲置风险
Run:ai、Mission Control 与 Base Command	Slurm、Kubernetes、KAI、GPU 切分、成组调度与拓扑感知调度、故障恢复
DGX Cloud 与 Lepton	DGX Cloud 的回租模式、2025 年的战略转向、Lepton、兜底承诺，以及英伟达为何避免与云厂商正面竞争
超大规模云厂商与新兴云服务商	既是伙伴又是对手的超大规模云厂商、新兴云服务商容量、供货分配、客户结构、各代产品租赁价格
竞争格局	正面对比与能力热力图
发展历程与英伟达的构建方式	时间线、关键交易、复制成本、反事实推演
路线图	编排与云服务路线图（附置信度标签）
价值链与企业发展视角	谁拿走了云支出、循环融资、私营公司、并购

🔧 **技术细节：如何解读 GPU 云或调度器相关说法**

- **说的是哪种利用率?** 在同一集群上，分配率、SM 活跃度与 MFU 可相差 2–3 倍；参见利用率问题。
- **在运行功率与签约功率：** 签约的吉瓦数是已签署的未来容量，而非今天正在运行的 GPU [S12010]。
- **目录价与合同价：** 按需目录价高估了大租户实际支付的价格；一年期合同价格指数是更好的参考 [S12516]。
- **厂商宣称的倍数：** “利用率最高提升 5 倍”（Run:ai）[S12004]与“恢复速度最高快 10 倍”（Mission Control）[S12005]均为厂商给出的最佳情形，且未公布基准。

🎯 企业发展视角

1. **软件是利用率杠杆，而非收入来源：** 英伟达以约 $700M 收购 Run:ai [S479]，随后将其开源 [S12510]；价值在于释放的 GPU 小时和成为默认选项的地位。
2. **英伟达如今是云交易对手方：** 约 $65B 的云承诺（2026 年 7 月）[S407]使新兴云服务商的利用率成为英伟达自身的风险；对新兴云服务商合作伙伴的尽职调查应据此进行。
3. **对超大规模云厂商的依赖是结构性问题：** 最大的买方正在自研芯片和控制平面；英伟达的应对是把需求分散到主权客户与新兴云服务商 [S90071]。
4. **高通的问题（仅基于公开信息）：** 对于 AI200/AI250 等推理机架 [S90028]，规模化路径应经由超大规模云厂商、新兴云服务商还是主权买方？哪些调度器必须率先支持它们?

利用率问题：为什么闲置 GPU 会摧毁投资回报

第 12 层 · 编排与云服务 · 约 9 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **GPU 的成本几乎全是固定成本。** 折旧约占一颗现代 GPU 年度成本的 81–88%，按 $0.081/kWh 计电费仅约占 12–19% [S389,S382]，因此一颗闲置 GPU 的成本几乎与满载时相同。
- **估计一颗 GB300 NVL72 GPU 每个已安装小时约 $1.50：** 每机架 $3.99M ÷ 72 [S332]，网络与存储另加 26% [S324]，按六年摊销 [S382,S386]，再加约 $0.17/h 的电力 [S337,S389]。由此得出：**利用率 30% 时每有效小时 $5.00，60% 时 $2.50，90% 时 $1.67。**
- **对 100,000 颗 GB300 GPU 而言，利用率每提升 10 个百分点，每年可节省约 $131M 成本**（估计，本资料库依据上述数字计算）。
- **浪费是结构性的，而非疏忽所致。** 在阿里巴巴 155,410 颗 GPU 的机群中，碎片化是闲置 GPU 无法被分配的主要原因；一项调度改进将分配率从 68% 提升至 93%，而在线推理的 SM 利用率中位数仅约 6% [S12015]。
- **即便是前沿训练也存在损耗：** Meta 的 Llama 3 405B 任务在 16,384 颗 GPU 上运行 54 天，出现 419 次意外中断，有效训练时间保持在 90% 以上，模型算力利用率（MFU）为 38–41% [S34006]。
- **使用寿命缩短会放大风险：** 亚马逊在 2025 年将部分服务器的使用寿命调回五年 [S385]，这使每小时成本上升约 18%。
- **闲置小时总要有人承担。** 照付不议（take-or-pay）合同将其转嫁给租户；英伟达对 CoreWeave 的 $6.3B 兜底承诺则把其中一部分揽到了英伟达自己的账上 [S90067]。

Est.: of 100 GPU-hours bought, only ~24–33 hours' worth of peak FLOPs reach the model

% of installed GPU-hours left after each loss · allocation: Alibaba fleet before/after a scheduler fix (+37% output) · failures, MFU: Llama 3

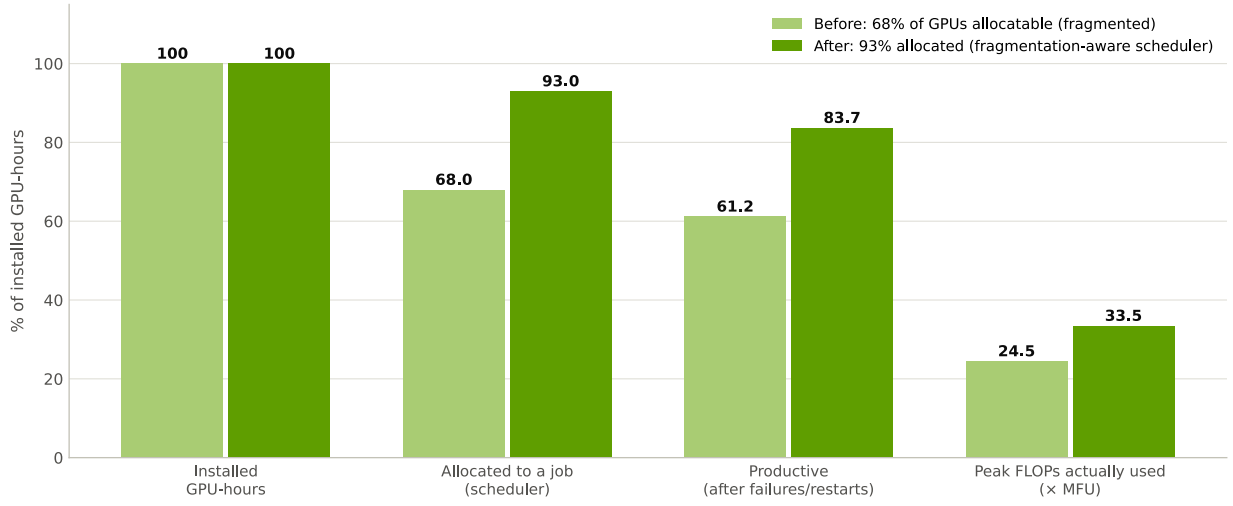

Composite illustration (Est.)

Source: data from Alibaba OSDI '26 trace paper; Meta Llama 3 paper (repo composite) [S12015] [S34006]; chart by repo · As of 2026-11-05

已安装 GPU 小时去向的分组柱状图（综合估计）。调度改进前：已安装 100，已分配 68（阿里巴巴 68% 的分配率），因故障、重启和检查点损失约 10% 后有效运行 61.2（Llama 3 报告有效训练时间超过 90%），按 40% MFU 折算相当于 24.5 小时的峰值 FLOPs。改进后：已分配 93，有效运行 83.7，实际利用 33.5，同样的硬件多产出 1.37 倍有效工作。

为什么 GPU 就像航班座位

航班起飞后，空座位就无法再售出；一个闲置的 GPU 小时过去之后也无法再出售。而所有者早已为飞机付了钱。对 GPU 而言，这架“飞机”就是在其使用寿命内摊销的购置成本，它占总拥有成本（TCO）的大部分。

[Q1 · 职能与失效后果] 第 12 层的职能是把已安装的机架转化为能做有效工作的 GPU 小时，对云厂商而言，还要转化为有人付费的 GPU 小时。当这一层薄弱时，表面上并没有什么明显故障：GPU 处于已分配但闲置的状态，作业因碎片而排队，大型任务因故障而停滞，每个有效 token 的成本则悄然翻两三倍。

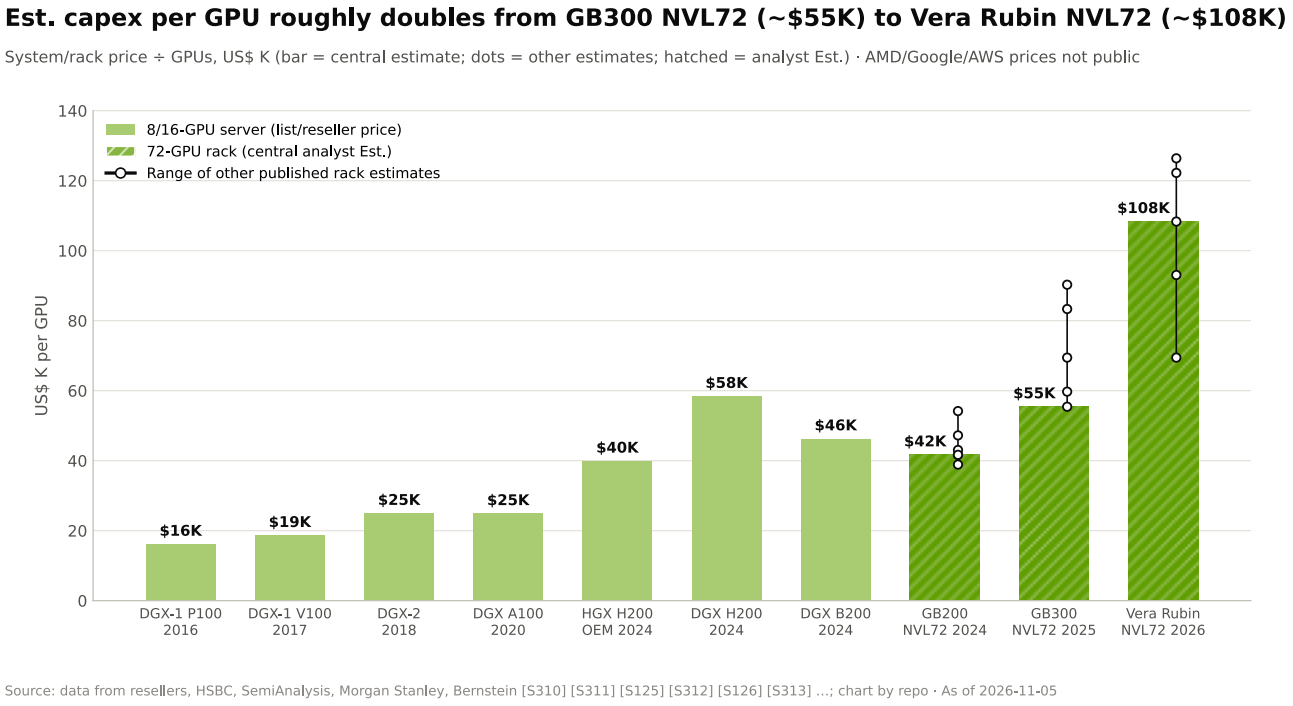

单 GPU 资本开支柱状图：DGX-1 P100 约 $16K（2016 年），DGX-1 V100 $19K，DGX-2 $25K，DGX A100 $25K，HGX H200 OEM 约 $40K，DGX H200 约 $58K，DGX B200 约 $46K，GB200 NVL72 约 $42K，GB300 NVL72 约 $55K，Vera Rubin NVL72 约 $108K（每 GPU），另以圆点标示约 $39K 至 $126K 的其他分析师估计。AMD、谷歌或 AWS 机架没有公开的系统价格。

提示

算例 —— 一颗 GB300 GPU 一小时的成本。 摩根士丹利估计一台 GB300 NVL72 机架为 $3.99M [S332] → 每 GPU $55.4K。SemiAnalysis 的 GB200 数据意味着横向扩展（scale-out）网络与存储另需约 26% [S324] → 约 $69.8K。按六年摊销（微软、Alphabet、CoreWeave 的会计政策）[S382,S383,S386]，即 $69.8K ÷ 6 ÷ 8,760 h = **$1.33/h**。电力：132 kW ÷ 72 颗 GPU [S337] × 1.15 PUE × $0.081/kWh [S389] = **$0.17/h**。合计 ≈ **每已安装小时 $1.50**。再除以利用率：30% 时 $5.00，60% 时 $2.50，90% 时 $1.67。一颗 Vera Rubin NVL72 GPU（每机架约 $7.8M [S330]）每已安装小时约 $2.89，因此闲置造成的美元损失是前者的两倍。**结论：** 在 30% 利用率下，GB300 所有者每有效小时付出的成本，高于在新兴云服务商（neocloud）上租用 H100 约 $2–3/h 的目录价 [S393,S395]。

Est.: at 30% vs 90% utilization, a useful GB300 NVL72 GPU-hour costs $5.00 vs $1.67

US$ per useful GPU-hour = (capex +26% network/storage ÷ life + max power × PUE) ÷ utilization · all Est.; excl. facility, staff, financing

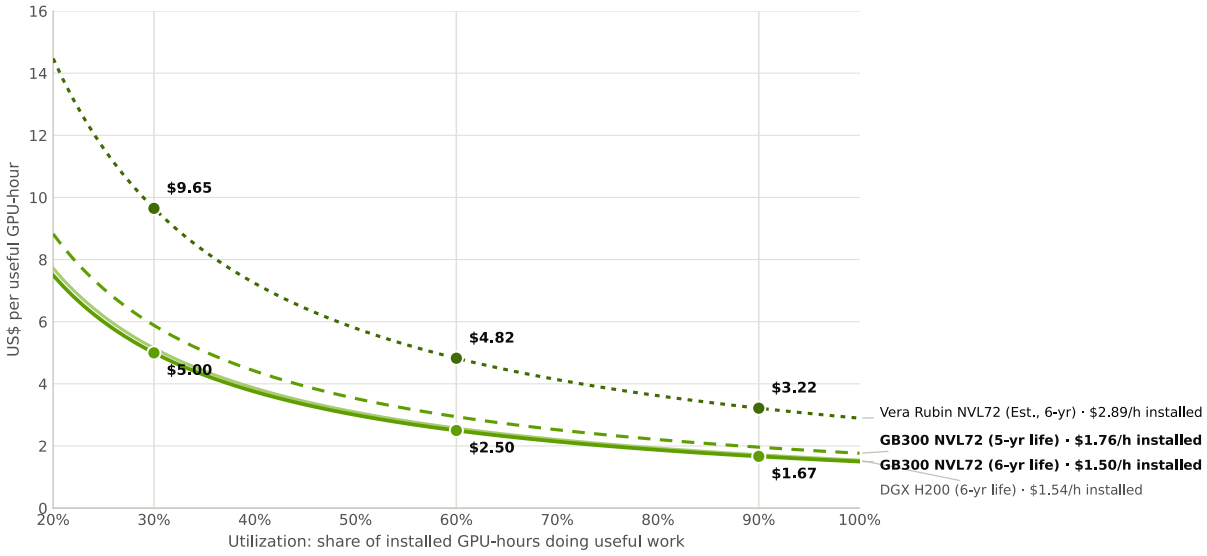

Source: data from MS, SemiAnalysis, resellers, EIA, 10-Ks (repo calc) [S33022] [S322] [S32002] [S32004] [S338] [S339] …; chart by repo · As of 2026-11-05

每有效 GPU 小时估计成本随利用率变化的折线图。一颗 GB300 NVL72 GPU 每个已安装小时约 $1.50（资本开支 $70K，含网络与存储，6 年寿命，电力 $0.17/h），因此利用率 30% 时每有效小时 $5.00，60% 时 $2.50，90% 时 $1.67；若按 5 年寿命则为 $5.88、$2.94 和 $1.96。Vera Rubin NVL72（每已安装小时约 $2.89）分别为 $9.65、$4.82 和 $3.22；DGX H200 每已安装小时约 $1.54。每有效小时成本与 1/利用率成正比。

使用寿命是另一个杠杆。超大规模云厂商在 2022–2023 年将服务器寿命延长至六年；亚马逊在 2025 年以 AI 技术迭代速度为由部分撤回了这一调整 [S385]。若按五年而非六年计算，GB300 每小时成本将从 $1.50 升至 $1.76。

Hyperscalers stretched server lives to 5.5-6 years, but Amazon cut some back to 5 in 2025

Useful life used to depreciate servers (and network gear where combined), years, by effective date of each 10-K change

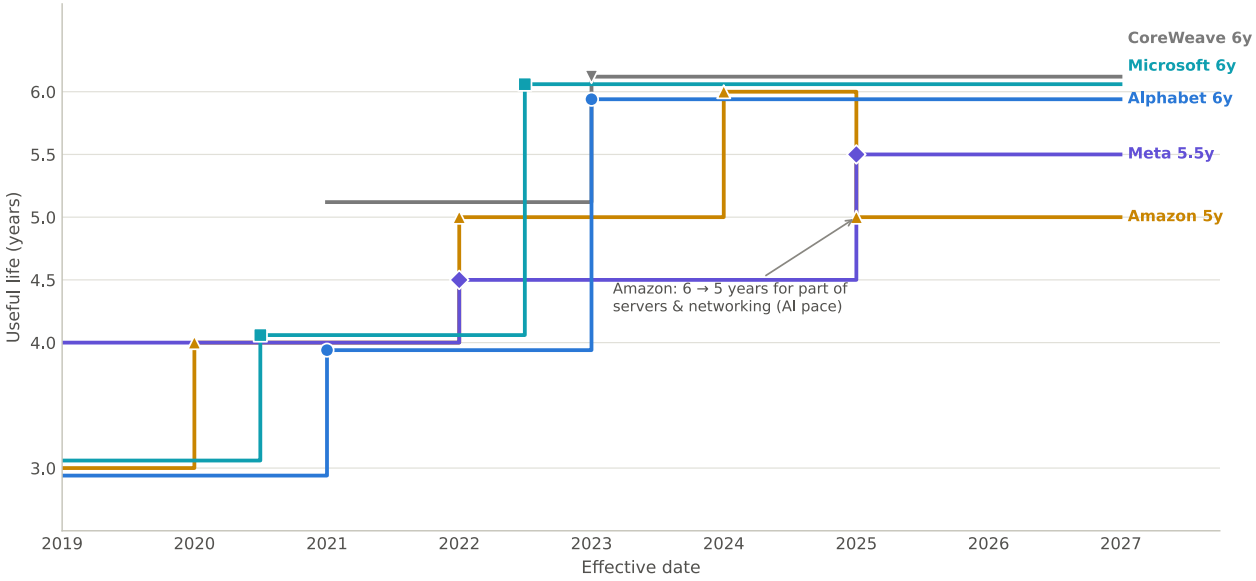

Source: data from 10-K and S-1 filings via SEC EDGAR [S382] [S383] [S385] [S384] [S386]; chart by repo · As of 2026-11-05

服务器使用寿命阶梯图：微软 3 年调至 4 年（2020 年 7 月）及 6 年（2022 年 7 月）；Alphabet 3 年调至 4 年（2021 年）及 6 年（2023 年）；亚马逊 3 年调至 4 年（2020 年）、5 年（2022 年）、6 年（2024 年），2025 年部分服务器调回 5 年；Meta 4 年调至 4.5 年（2022 年）及 5.5 年（2025 年）；CoreWeave 自 2023 年起 GPU 服务器按 6 年。

🔧 技术细节：成本模型及其未涵盖的部分

每有效小时成本 =（每 GPU 资本开支 × 1.26 ÷ 寿命 ÷ 8,760 + 每 GPU 千瓦数 × PUE × 每千瓦时电价）÷ 利用率。输入数据来自 `data/tco_model_inputs.csv` 和 `data/l12_utilization_scenarios.csv`。电力按全时段最大功率计费，属于上限值。设施资本开支、人员、软件授权费和融资成本均未计入，因此每个数字都是**下限**。以高利率借款的新兴云服务商还会增加一大笔融资成本。完整的 TCO 模型参见训练与推理经济学。

GPU 小时都去哪了：五大浪费来源

利用率会在多个环节流失，每个环节需要不同的修复手段。

浪费来源	机制	证据	修复手段
碎片化	空闲 GPU 分散成碎片，每块都太小，容纳不下下一个作业	阿里巴巴闲置 GPU 无法分配的主要原因；调度改进后分配率从 68% 升至 93% [S12015]	装箱调度（bin-packing）、拓扑感知调度
故障与检查点重启	一颗坏 GPU 就会让同步作业停下；自上一个检查点以来的工作需要重做	54 天内 419 次意外中断，约 78% 与硬件相关 [S34006,S31003]	健康检查、快速自动恢复
数据停顿	GPU 等待输入数据	采用 CPU 预处理时，DGX-2 在 ResNet-50 上仅达到其上限的 56% [S4017]	GPU 数据加载、更快的存储
闲置预留	团队“以防万一”占着 GPU；notebook 独占整颗 GPU	在一个 6,742 颗 GPU 的阿里巴巴集群中，小型分数作业导致利用率偏低 [S12017]	配额、抢占、GPU 切分
MFU 与分配率	即使处于忙碌状态，GPU 也只用到峰值 FLOPs 的一部分	Llama 3 的 MFU 为 38–41% [S34006]；在线推理 SM 利用率中位数约 6% [S12015]	算子、并行方式、批处理（第 10–11 层）

提示

算例 —— 损失层层叠加。 从 100 个已安装 GPU 小时开始。按阿里巴巴改进前 68% 的分配率，剩下 68 个已分配小时 [S12015]。再因故障与重启损失约 10% 的已分配时间（Llama 3 保持在 90% 以上）[S34006]，剩下 61.2 个有效运行小时。按 40% 的 MFU，只有**相当于 24.5 小时的峰值 FLOPs** 真正作用于模型。若分配率为 93%，链条终点则为 **33.5**，同样的资本开支多产出 1.37 倍。**结论：** 这项调度改进的价值相当于硬件打了 37% 的折扣（估计，综合示例）。

注意

误区与事实：“我们的 GPU 显示 100% 利用率。” 简单工具报告的是*任意*算子在运行的时间占比。一颗 GPU 可能显示 100%，但其大部分流式多处理器其实处于空闲状态。分配率、来自 DCGM 的 SM 利用率以及 MFU 衡量的是不同的东西；务必问清一项说法用的是哪一个。

[Q2 · 关键指标] 决定本层表现的有五个数字：(1) **分配率**，即已安装 GPU 中被分配给作业的比例；(2) **有效训练时间**或有效产出（goodput），即已分配时间中产生实际进展的比例；(3) **MFU** 或每 GPU 小时 token 数，即每个忙碌小时完成的有效工作；(4) **平均恢复时间**，它决定一次故障的代价；(5) **每有效 GPU 小时美元成本**，它将前四项合并为投资回报指标。

🔧 技术细节：“利用率”的三种含义

- **分配率**（调度器视角）：已分配 GPU ÷ 已安装 GPU。容易通过过度预留而被抬高。
- **SM 活跃度 / 占用率**（DCGM 遥测视角）：每颗 GPU 计算阵列中有多少处于活跃状态。可揭示已分配但闲置的情况。
- **MFU / goodput**（模型视角）：模型所需 FLOPs ÷ 可用峰值 FLOPs，并扣除重启损失。这是唯一能直接对应到 token 产出或训练进度的指标。

谁承担闲置风险

每一个闲置小时都会落到某个人头上。运行自有模型的超大规模云厂商直接承担这一风险。新兴云服务商通常签订多年期照付不议合同，因此无论租户是否使用这些小时都要付费。英伟达已同意在 2032 年 4 月之前购买 CoreWeave 最多 $6.3B 的未售出容量 [S90067]，自身吸收了部分风险。

> **提示**
>
> **算例 —— 这项兜底承诺覆盖了多少。** 按 2026 年 3 月约 $2.35 的 H100 一年期合同价 [S12516]，$6.3B 可购买约 27 亿个 GPU 小时。分摊到截至 2032 年 4 月的约 6.5 年，相当于约 47,000 颗 GPU 全时运行（估计）。CoreWeave 在 2024 年底运营的 GPU 超过 250,000 颗 [S12011]。**结论：** 这项兜底承诺是为部分机群托底，而非为全部机群提供担保。

> **注**
>
> 🐂 **看多观点：** 更好的调度器、更快的故障恢复以及 24/7 运行的推理机群推高利用率，因此每颗 GPU 赚得更多，存量装机的价值也能维持更久。

> **注意**
>
> 🐻 **看空观点：** 如果需求降温，利用率首先会在合同期较短的新兴云服务商那里下滑。随后每有效小时成本跳升（1/利用率），租赁价格下跌，兜底承诺则变成负债。

🎯 企业发展视角

1. **利用率是价值数十亿美元的销货成本杠杆。** 按每 100,000 颗 GB300 GPU 每 10 个百分点约 $131M 计算（估计），调度与恢复软件具有可量化的价值，买方可以据此进行估值承保。
2. **目标公司报告的是哪个指标？** 对任何 GPU 云或 AI 基础设施软件公司做尽职调查时，都应分别索取分配率、有效时间和 MFU 数据。
3. **折旧政策是隐含的估值输入。** 使用寿命每变化一年，每小时成本约变动 18%；应比较租户与所有者各自的假设 [S385,S386]。
4. **高通的问题（仅基于公开信息）：** 对于 AI200/AI250 等推理机架 [S90028]，利用率叙事（分数共享、高占空比）对买方而言是否比峰值 TOPS 更重要？

Run:ai、Mission Control 与 Base Command：调度栈

第 12 层 · 编排与云服务 · 约 10 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **英伟达已买下 AI 控制平面的大部分：** Bright Computing（2022 年，现为 Base Command Manager）[S478]、Run:ai（据报道约 $700M，2024-12-30 完成交割）[S476,S479]，以及 Slurm 的开发商 SchedMD（2025-12-15，交易条款未披露）[S12000]。它们被打包为 Mission Control（GTC 2025）[S12005]，并自 2026 年 5 月起整合为模块化的 DSX OS [S12513,S12514]。
- **全球的 GPU 由两种调度器管理。** TOP500 前 10 名和前 100 名系统中，超过一半运行 Slurm [S12000]；Kubernetes 则承载推理和混合机群。英伟达如今对两者都有主导权。
- **随后它把调度器免费放了出去：** Run:ai 的 KAI Scheduler 在 KubeCon Europe 2025 上以 Apache 2.0 许可开源 [S12003]，现为 CNCF 沙箱项目 [S12002]；完整的 Run:ai 平台也于 2026 年 10 月随之开源 [S12510,S12511]。
- **提升利用率的三个手段：** GPU 切分（MIG 可将一颗 GPU 最多切成七份）[S12019]、成组调度（gang scheduling）以及拓扑感知放置 [S12002]。在本资料库的模型中，分配率为 30% 时，分散放置的 8-GPU 作业会使 18 台 NVL72 机架中完整空闲的不足 1 台；装箱放置则可保留 12 台。
- **故障处理是新的前沿。** 按 Llama 3 的故障率，一个 100,000 颗 GPU 的作业约每 30 分钟中断一次，若每次恢复需 15 分钟，将浪费约 33% 的时间（估计）[S34006]。英伟达称 Mission Control 的作业恢复速度最高可快 10 倍（厂商说法）[S12005]。
- **弱点：** 这类软件直接收入很少。Kubernetes、Kueue、Ray 和 SkyPilot 都是免费的 [S12533,S12535,S12534]，新兴云服务商（neocloud）会自建方案（如 CoreWeave 的 SUNK）[S12530]，而拥有 Slurm 也会引来基于 AMD 和英特尔的 HPC 站点对其中立性的质疑。

Est.: a 100k-GPU job fails every ~30 min, so 15-min recoveries waste ~33% of its time

% of time lost to recovery vs job size · Llama 3 rate: 419 failures in 54 days on 16,384 GPUs · lost = λT/(1+λT)

LOG SCALE

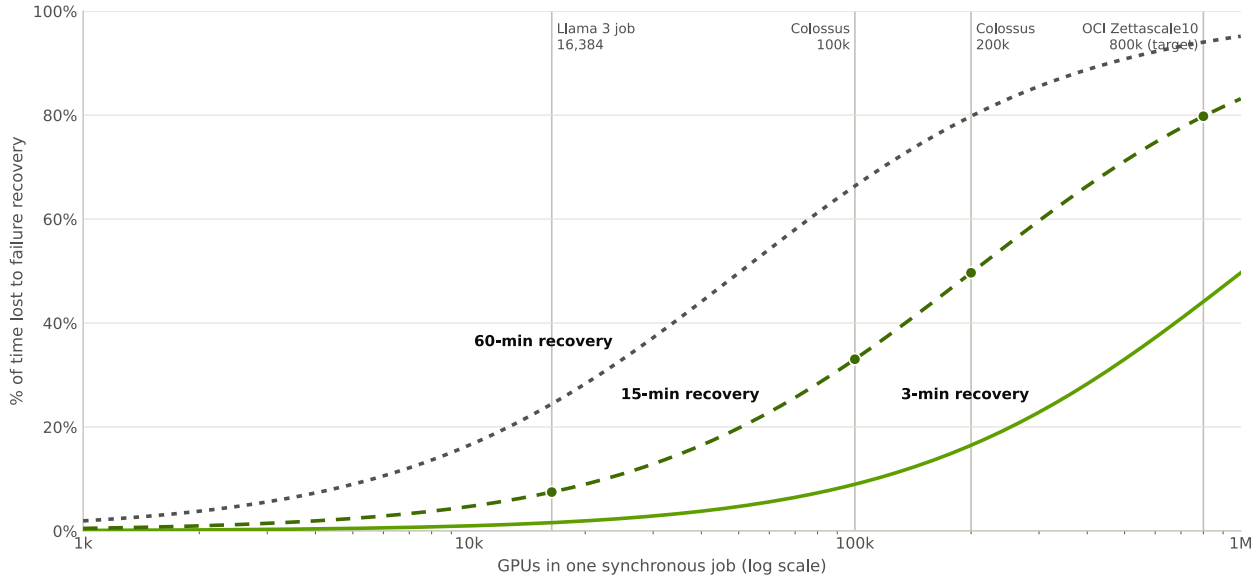

Source: data from Llama 3 paper; layer-06 cluster data (repo model) [S34006] [S31003] [S12005] [S12006] [S6006] [S6007] …; chart by repo · As of 2026-11-05

> 折线图，x 轴为对数刻度。以 Llama 3 在 16,384 颗 GPU 上 54 天内 419 次意外中断（约每 3.1 小时一次）为基准，单个作业因恢复而损失的时间随规模增大。在 16,384 颗 GPU 时：恢复耗时 3 分钟损失 1.6%，15 分钟损失 7.5%，60 分钟损失 24%。在 100,000 颗 GPU 时（约每 30 分钟一次故障）：分别为 9%、33% 和 66%。在 800,000 颗 GPU 时，即使恢复只需 3 分钟也会损失 44%。快速自动恢复与容错训练是超大规模作业得以成立的前提。

逐层拆解调度栈

不妨把它想象成一座机场。机架是跑道和登机口，调度器是空中交通管制，集群管理是地勤运营，健康监控则是在故障飞机起飞前将其停飞的维修团队。

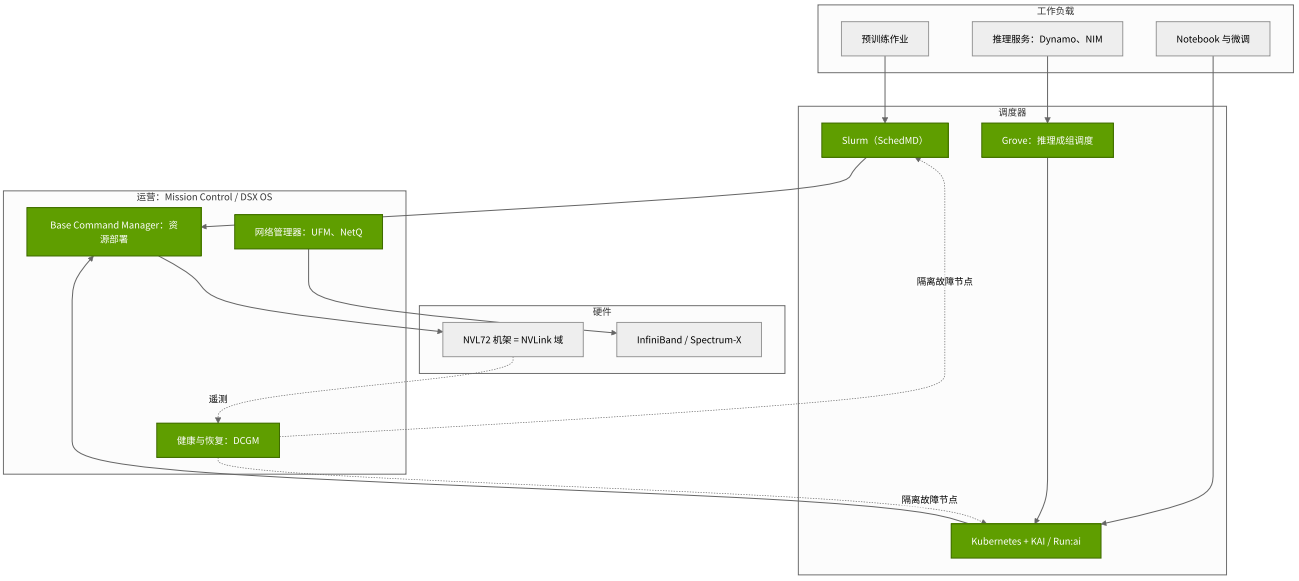

组件	职能	来源	许可
Slurm	面向 HPC 与预训练的批处理队列；以整节点为单位成组分配	SchedMD，2025 年 12 月收购 S12000	开源，保持厂商中立
KAI Scheduler / Run:ai	Kubernetes GPU 调度器：队列、公平份额、GPU 共享、拓扑 S12002	Run:ai，2024 年收购 S476	Apache 2.0（KAI 2025 年；Run:ai 2026 年 10 月）S12510
Grove	用一个 Kubernetes 资源描述整套 Dynamo 推理系统 S12021	英伟达 Dynamo 项目	Apache 2.0

组件	职能	来源	许可
Base Command Manager	资源部署、操作系统镜像、集群监控	Bright Computing，2022 年 S478	商业
DCGM	GPU 健康检查、诊断、遥测 S12020	英伟达	开源
Mission Control	将上述组件与 UFM/NetQ 及自主恢复功能打包 S12004	GTC 2025 S12005	商业

> **提示**
>
> **算例 —— 同一集群，两种调度器。** 一个 576 颗 GPU 的预训练作业需要同时占用 8 台完整的 NVL72 机架，持续数周：这是典型的 Slurm 式批处理作业。一个推理服务每个副本需要 8 颗 GPU，并随流量在 4 到 40 个副本之间伸缩：这是典型的 Kubernetes 式服务。要在一个 18 台机架的集群上同时运行两者，要么让两个调度器争抢机架，要么用一个能兼顾两者的调度器。这正是 CoreWeave 在 Kubernetes 内运行 Slurm（SUNK）S12530、英伟达把两边都买下的原因。

提升利用率的三个手段

GPU 切分（拼车）。 一个 notebook 或小模型很少需要一整颗 GPU。MIG 可将一颗 GPU 划分为最多七个相互隔离的实例 S12019；MPS 在强制限额下共享内存与算力；时间片轮转（time-slicing）成本最低，但共享同一个故障域，一次崩溃就会让所有租户一起宕掉 S12018。

> **提示**
>
> **算例 —— 70 个 notebook。** 七十位数据科学家每人独占一整颗 GB300 GPU，就会占用 70 颗 GPU。若改用七分之一的 MIG 切片，10 颗就够了。按利用率问题中估计的每已安装小时约 $1.50 计算，腾出的 60 颗 GPU 每年价值约 $788K（60 × 8,760 h × $1.50）。**结论：** GPU 切分在闲置较多的交互式工作上能够收回成本，在大型训练上则不然。

成组调度（整桌入座）。 餐厅只有在整张桌子空出来时才会安排十二人的聚餐入座。分布式作业也是如此：缺了另一半 GPU，这一半就毫无用处。KAI 和 Grove 会让一组中的所有 pod 要么同时启动，要么都不启动 S12002,S12021。

> **提示**
>
> **算例 —— 成组调度所避免的死锁。** 两个各需 512 颗 GPU 的作业到达一个有 768 颗空闲 GPU 的集群。朴素的调度器给每个作业分 384 颗；两者都在无限期等待另外 128 颗，于是 768 颗 GPU 全部闲置。成组调度器则会用 512 颗 GPU 启动其中一个作业，让另一个排队。**结论：** 有 512 颗 GPU 在干活，而不是零颗。

拓扑感知放置与装箱调度（保持整层楼空着）。 张量并行组每一层都要交换数据，因此必须位于同一个 NVLink 域内，在 NVL72 上即同一台机架（参见第 05 层）。如果小作业被零散地撒在各台机架上，就没有哪台机架能保持完整。

Est.: at 30% allocation, scattered 8-GPU jobs leave <1 whole NVL72 rack of 18; packed, 12

Expected NVL72 racks with all 72 GPUs free vs share of an 18-rack cluster allocated to 8-GPU jobs (repo model)

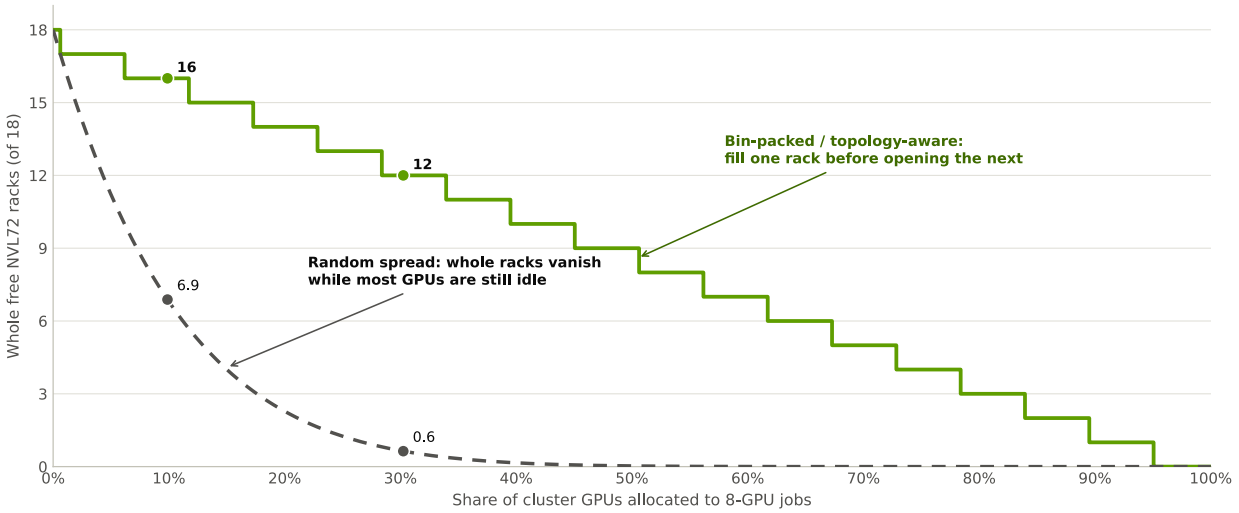

Illustrative model (Est.)

Source: data from repo model (hypergeometric placement); NVL72 rack size from NVIDIA [S102] [S12015] [S12017]; chart by repo · As of 2026-11-05

折线图：一个由 18 台机架、1,296 颗 GPU 组成的 NVL72 集群被 8-GPU 作业填充。若调度器随机分散放置作业，完整空闲的机架会迅速消失：分配率 10% 时约剩 6.9 台，30% 时约剩 0.6 台，尽管仍有约 904 颗 GPU 闲置。逐台填满机架的装箱、拓扑感知调度器则能分别保留 16 台和 12 台完整机架。阻碍大型作业的是碎片化，而非 GPU 短缺。

🔧 技术细节：公平性、抢占与预留

KAI 采用带配额和超额权重的层级队列、主导资源公平（DRF）份额分配 [S12002]、基于时间的公平份额（考虑历史使用量）、带最短保障运行时间的抢占、用于消除碎片的工作负载整合，以及覆盖 GB200/GB300 和 AMD GPU 的 Kubernetes 动态资源分配（Dynamic Resource Allocation）[S12002]。其 v0.10.0 版本（2025 年 10 月）新增了拓扑感知调度和层级 pod 组 [S12002]。阿里巴巴在 ATC '23 发表的研究显示，在其集群轨迹数据上，碎片感知放置优于经典的最佳适配（best-fit）策略 [S12016]。

故障是常态

在大规模集群中，总有东西是坏的。Meta 在一个 16,384 颗 GPU 的作业上 54 天内记录了 419 次意外中断，约每三小时一次，大多源于硬件 [S34006,S31003]。每次故障都要付出检测、隔离故障节点、重启，以及重做自上一个检查点以来工作的代价。

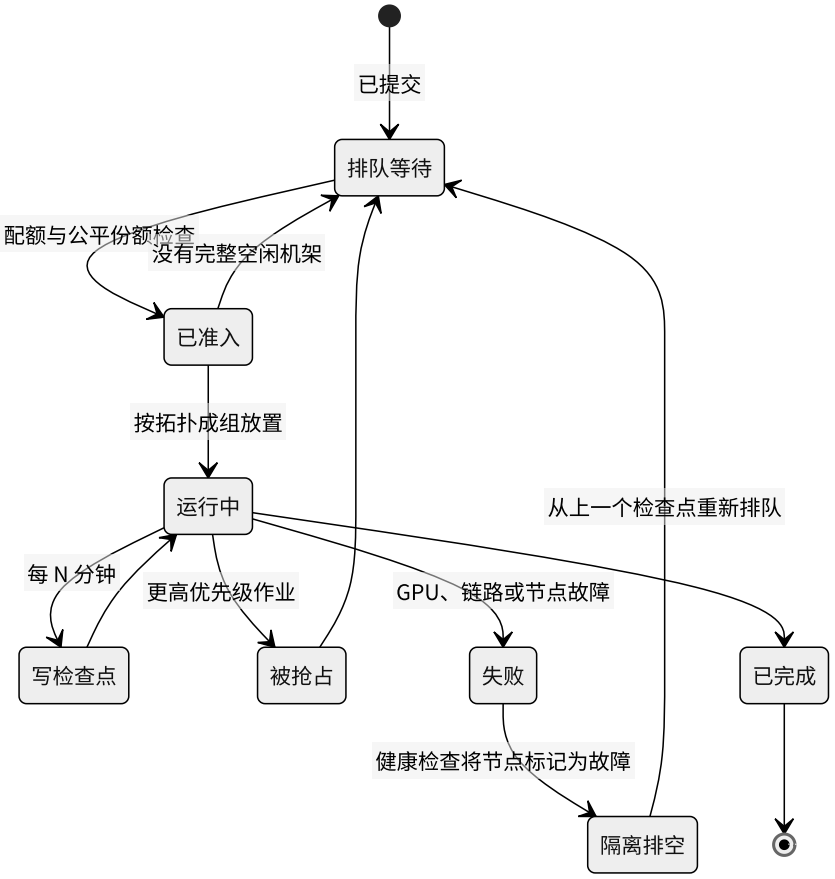

DCGM 提供健康检查与诊断 [S12020]。Mission Control 在此基础上增加了自主作业恢复（捕获作业上下文、定位可疑的 GPU 或节点、重启）和自主硬件恢复（在性能退化导致作业失败之前将其发现）；2.5 版将这一能力扩展到 Run:ai 管理下的 Kubernetes 工作负载 [S12006]。

> **提示**
>
> **算例 —— 为什么恢复时间一代比一代重要。** Llama 3 的故障率为 419 ÷（54 天 × 24 h × 16,384 颗 GPU）≈ 每 100,000 GPU 小时 2.0 次故障 [S34006]。因此，一个 100,000 颗 GPU 的作业每小时约故障 2 次。若每次恢复需 15 分钟，它将损失 0.49 ÷ 1.49 ≈ **33%** 的时间；若只需 3 分钟，则损失**约 9%**。**结论：** 在 10 万颗 GPU 的规模下，把恢复时间从 15 分钟缩短到 3 分钟，同样的 GPU 可多产出约 36% 的有效工作（0.91 ÷ 0.67，估计）。

控制平面如何演进，以及英伟达为何免费开放

[Q3 · 代际进步]（软件方面；云价格方面的图表见超大规模云厂商与新兴云服务商）：

年份	英伟达控制平面的进展	新增能力
2022	Bright Computing → Base Command Manager [S478]	集群部署与监控
2023	DGX Cloud [S12007]	搭载英伟达软件的托管集群
2024	Run:ai 完成交割 [S476]	Kubernetes GPU 资源池、GPU 切分、公平份额
2025	Mission Control [S12005]；KAI 开源 [S12003]；Grove [S12021]	自主恢复；面向推理的拓扑感知成组调度
2025 年 12 月	SchedMD [S12000]	掌握 HPC 默认调度器 Slurm
2026	DSX OS [S12513]；Run:ai 开源 [S12510]	从资源部署到推理全覆盖的开放、模块化 AI 工厂操作系统

调度器是 GPU 的互补品：调度器越便宜、越好用，客户能用上的 GPU 小时就越多。开源 KAI 和 Run:ai，并承诺保持 Slurm 的厂商中立 [S12000]，可以防止竞争对手的免费工具成为默认选项，同时英伟达通过技术支

持、Mission Control 和 AI Enterprise 实现变现 [S12510]。

> **提示**
>
> **算例 —— 免费调度器对英伟达价值几何。** 如果更好的放置与恢复能在 100 万颗已安装的 GB300 级 GPU 上仅提升 5 个百分点的利用率，客户每年就能多获得 1M × 8,760 h × 5% ≈ 4.38 亿个有效 GPU 小时，按每小时约 $1.50 计约值 $657M 的算力（估计，出自利用率问题）。而 Run:ai 只是一次性花费约 $700M [S479]。**结论：** 这类软件的回报来自更便宜的有效算力和更高的客户黏性，而非授权费。

> **注意**
>
> 🐻 **看空观点：** 中立只是承诺，而非保证。如果 Slurm 或 KAI 的功能率先或最好地在英伟达硬件上落地（已有报道称 SchedMD 正在针对 Rubin 和 Vera 进行优化 [S12001]），AMD 和英特尔的站点可能会分叉代码，或转向 Kueue 或 Ray。此外，作为最大买方的超大规模云厂商运行的是自己的控制平面。

🎯 企业发展视角

1. **控制点，而非利润池。** Run:ai 约 $700M 的收购价 [S479] 与英伟达 FY2026 约 $216B 的收入 [S1] 相比微不足道；其价值在于遥测数据以及在每座 AI 工厂中的默认地位。
2. **开源编排初创公司面临挤压**，夹在英伟达的免费软件栈与超大规模云厂商的自有方案之间；价值正转向多云调度中介（类似 SkyPilot）和垂直运营商。
3. **Slurm 的中立性是一个观察项**，关乎任何非英伟达加速器厂商在 HPC 领域的市场进入策略。
4. **高通的问题（仅基于公开信息）：** 对于 AI200/AI250 等推理机架 [S90028]，在 KAI、Kueue 和 Slurm 中获得一流支持，对云买方的意义是否大于额外的算子优化工作?

超大规模云厂商与新兴云服务商：谁在出租英伟达的 GPU

第 12 层 · 编排与云服务 · 约 8 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **超大规模云厂商既是英伟达最大的客户，也是最有实力的对手。** 在 Q2 FY2027 数据中心收入中，超大规模云厂商约贡献 $48.7B [S90011]；2024 年，微软、亚马逊和谷歌在约 173 万颗可追踪的 Hopper GPU 中买下了约 85 万颗（Omdia 估计）[S12014]。每家也都在自研加速器：TPU、Trainium、Maia、MTIA [S90026,S90035,S90044,S160]。
- **新兴云服务商（neocloud）以英伟达为先。** 截至 2026 年 8 月，CoreWeave 在运行功率约 1.5 GW，签约功率 4.2 GW [S12010]；Nebius 的目标是到 2026 年底签约约 5 GW [S12010]。Synergy 估计 2025 年新兴云服务商收入超过 $25B，到 2030 年将达到约 $180B（二手引用）[S12022]。
- **甲骨文是准新兴云服务商：** 其 Zettascale10 集群目标最多容纳 800,000 颗英伟达 GPU [S6008]，但它同时也订购了 50,000 颗 AMD MI450 [S90022]。
- **英伟达用资本引导需求：** 对 CoreWeave 的 $2B 入股（2026 年 1 月）[S472]，对 Nebius、Crusoe、Lambda、Together AI 和 Nscale 的持股 [S481]，$6.3B 的 CoreWeave 兜底承诺 [S90067]，以及 Lepton 的需求路由 [S598]。
- **客户结构正在变化，但并不均衡：** 主权 AI 在 FY2026 超过约 $30B；Q1 FY2027 中 ACIE（约 $37B）与超大规模云厂商大致持平；Q2 FY2027 区域性新兴云服务商环比增长 35% [S90071]。然而在 Q2，超大规模云厂商占数据中心收入的比例却从约 51% 升至约 55% [S403,S90011]。
- **弱点：** 新兴云服务商最大的租户正是超大规模云厂商和 AI 实验室（微软签下了超过 $60B 的新兴云服务商合同 [S12526]；Meta 与 CoreWeave 签约 $14.2B [S12527]），因此许多所谓“多元化”的需求其实是超大规模云厂商的溢出需求。

Est.: three hyperscalers bought ~850K of ~1.73M tracked Hopper GPUs in 2024 (49%)

Hopper GPUs bought in 2024 by buyer, thousands (Omdia Est.) · CoreWeave bar = installed base, all generations

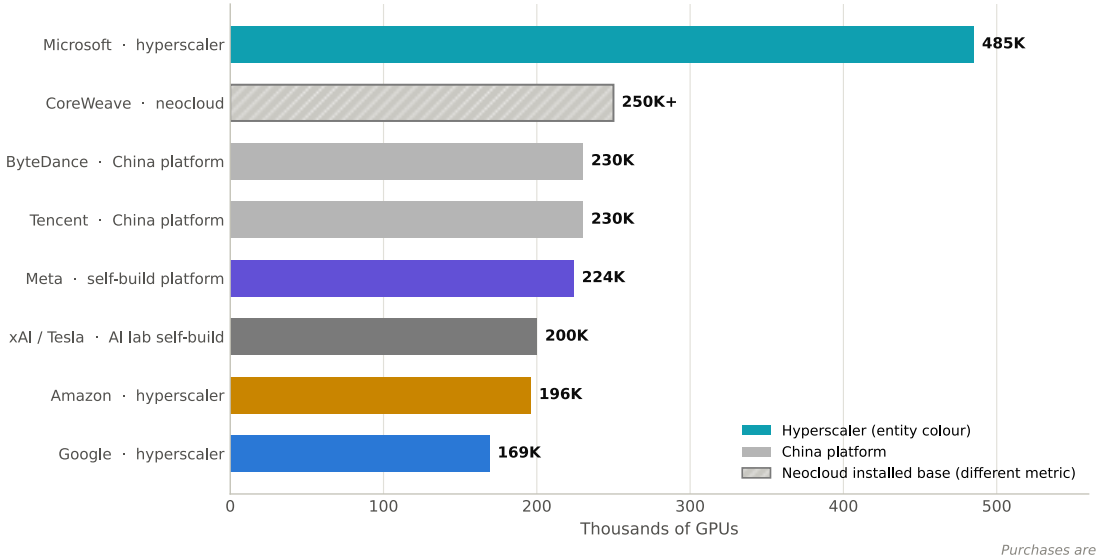

Purchases are Omdia estimates (Est.)

Source: data from Omdia via Financial Times / DCD; CoreWeave S-1 [S12014] [S12011]; chart by repo · As of 2026-11-05

2024 年 Hopper GPU 采购量估计（Omdia）水平柱状图：微软 485,000；字节跳动和腾讯各约 230,000（主要为中国特供的 H20/H800）；Meta 224,000；xAI/特斯拉约 200,000；亚马逊 196,000；谷歌 169,000。三大超大规模云厂商合计约 85 万颗，占可追踪的 173 万颗的 49%。作为对比，CoreWeave 报告 2024 年底已安装各代 GPU 超过 25 万颗。

既是伙伴又是对手：与超大规模云厂商的关系

超大规模云厂商就像一家连锁超市，既售卖知名品牌，也卖自有品牌。它今天需要知名品牌来填满货架，明天则要靠自有品牌来保护利润率。谷歌向 Anthropic（最多 100 万颗 TPU）[S90026]和 Meta [S90025]出租 TPU 容量；AWS 用约 500,000 颗 Trainium2 芯片搭建了 Project Rainier [S90034]；微软在 Maia 200 上运行 Copilot [S90044]。

维度	超大规模云厂商	新兴云服务商	主权 / 企业	英伟达（DGX Cloud、Lepton）
机群中英伟达的占比	🟨 占多数，但随自研芯片而下降	🟩 接近 100%	🟩 以英伟达为主	🟩 100%
是否掌握终端客户	🟩 是	🟨 往往是超大规模云厂商或 AI 实验室	🟩 是	🟥 很少
自研加速器	🟦 TPU、Trainium、Maia、MTIA	🟥 无	🟥 无	🟦 销售 GPU
资本成本	🟩 投资级	🟥 高；依赖债务融资	🟨 国家背书	🟩 现金充裕
与英伟达的股权关系	🟥 无	🟩 常见	🟨 部分有	不适用

> **提示**
>
> **算例 —— Q1 → Q2 FY2027 的客户结构。** Q1：在 $75.2B 数据中心收入中，超大规模云厂商约 $38B（约 51%），ACIE 约 $37B [S403]。Q2：在约 $89.0B 中，超大规模云厂商约 $48.7B（约 55%），ACIE 约 $40.3B [S90011,S90013,S406]。超大规模云厂商环比增长约 28%，ACIE 约 9%。**结论：** 多元化是真实的（主权客户、新兴云服务商），但超大规模云厂商一个季度的追赶就逆转了占比的变化。

新兴云服务商：借助外部资产负债表的纯 GPU 云

新兴云服务商购买英伟达系统（常以举债方式），并以多年期合同出租：CoreWeave（客户包括微软、OpenAI、Meta）、Lambda、Nebius、Crusoe、Together AI、Nscale 和 Fluidstack。它们的优势在于速度：由于不运行其他任何业务，英伟达的新一代产品能很快进入它们的机架。

CoreWeave's live power grew ~4× to 1.5 GW in 18 months; contracts run ~3× ahead

Data-center power, GW · active = energized and billing; contracted = signed future capacity · hatched = target or secondary estimate

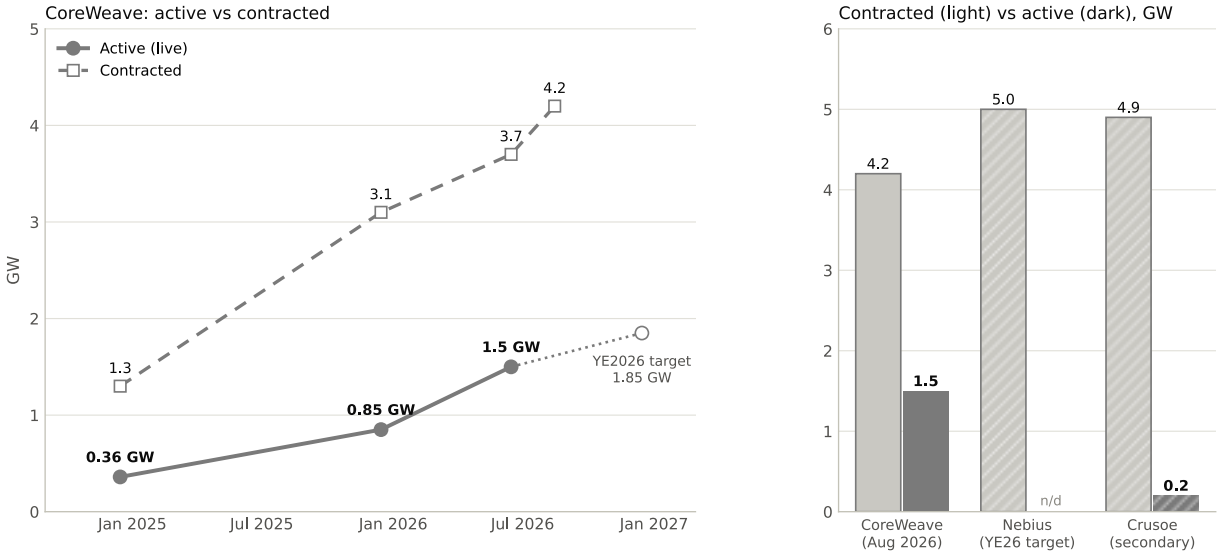

Source: data from CoreWeave filings and results; DCD; MarkTechPost (secondary) [S12011] [S12012] [S12010] [S12013]; chart by repo · As of 2026-11-05

两个面板。左图为 CoreWeave：在运行功率 2024 年底 0.36 GW、2025 年底 0.85 GW、2026 年中 1.5 GW，2026 年底目标约 1.85 GW；签约功率从 1.3 GW 升至 3.1 GW，到 2026 年 8 月达 4.2 GW。右图为签约与在运行功率对比：CoreWeave 4.2 GW 对 1.5 GW；Nebius 目标到 2026 年底签约约 5 GW；Crusoe 在 Abilene 签约约 4.9 GW，已通电 0.2 GW（二手估计）。

提示

算例 —— 1.5 GW 相当于多少颗 GPU？ 2024 年底，CoreWeave 以超过 360 MW 的功率运行超过 250,000 颗 GPU，全口径约每 GPU 1.4 kW [S12011]。一颗 GB300 的机架 IT 功耗约 1.83 kW（132 kW ÷ 72）[S337]，计入散热开销后约 2.1 kW。因此，视产品组合不同，1.5 GW 约合 **70 万至 100 万颗 GPU**（🔴 本资料库估计）。**结论：** 如今单家新兴云服务商运营的机群规模，已相当于微软 2024 年一到两年的 Hopper 采购量 [S12014]。

> 🔧 **技术细节：供应紧张时英伟达如何分配**
>
> 英伟达不公布其供货分配规则。可观察到的杠杆包括：股权（以每股 $87.20 向 CoreWeave 投资 $2B [S472]）、容量担保（兜底承诺 [S90067]）、需求路由（Lepton [S598]）以及优先获得参考设计。供应依然紧张，首席财务官称 FY2028 将“受供应约束” [S90012]，因此供货分配是一种战略工具，而不仅仅是接单。关于股权、兜底承诺与循环融资的问题，详见价值链与企业发展视角。

租来的一个 GPU 小时能买到什么：逐代对比

[Q3 · 代际进步]（云端视角）。2023 年短缺之后，每 GPU 小时的目录价快速下跌：H100 从新兴云服务商的约 $8 和 AWS 的 $12.29，降至 2025 年的约 $2–3 [S393,S391,S395]。按单位算力计，每一代 Blackwell 都更便宜。

H100 rentals fell ~75% from ~$8/GPU-hr (2023) to ~$2-3 on neoclouds; AWS list −44%

On-demand list/observed prices, US$ per GPU-hour (instance ÷ GPUs) · marker = provider type · contract rates are lower

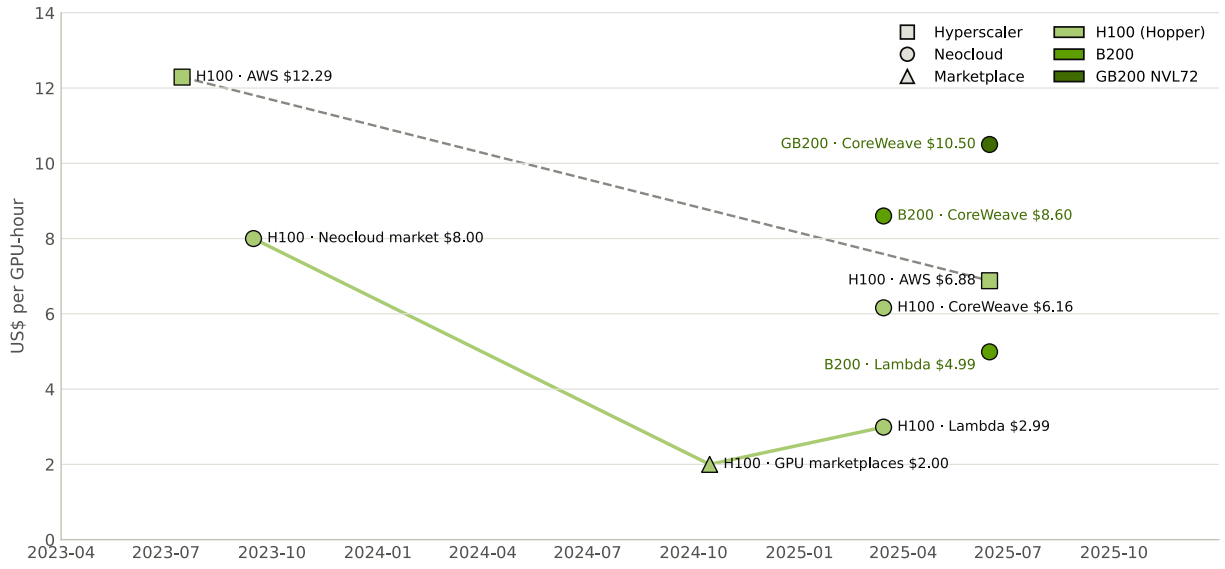

Source: data from AWS, CoreWeave, Lambda, Latent Space [S391] [S393] [S395] [S394] [S392]; chart by repo · As of 2026-11-05

GPU 租赁价格随时间变化的散点图。H100：AWS p5 按需实例 2023 年 7 月推出时为 $12.29/GPU 小时，2025 年 6 月降价后为 $6.88；新兴云服务商 H100 在 2023 年约 $8，至 2024 年底各交易平台低于 $2，2025 年 Lambda 目录价 $2.99、CoreWeave $6.16。2025 年 Blackwell 目录价：B200 从 $4.99（Lambda）到 $8.60（CoreWeave），GB200 $10.50（CoreWeave）。

List prices: a Blackwell PFLOPS-hour costs 1.4–1.6× less than H100 at FP8, 2.7–3.3× less at FP4

On-demand list price ÷ dense peak PFLOPS per GPU, US$ per PFLOPS-hour · H100 has no FP4, so its best format is FP8

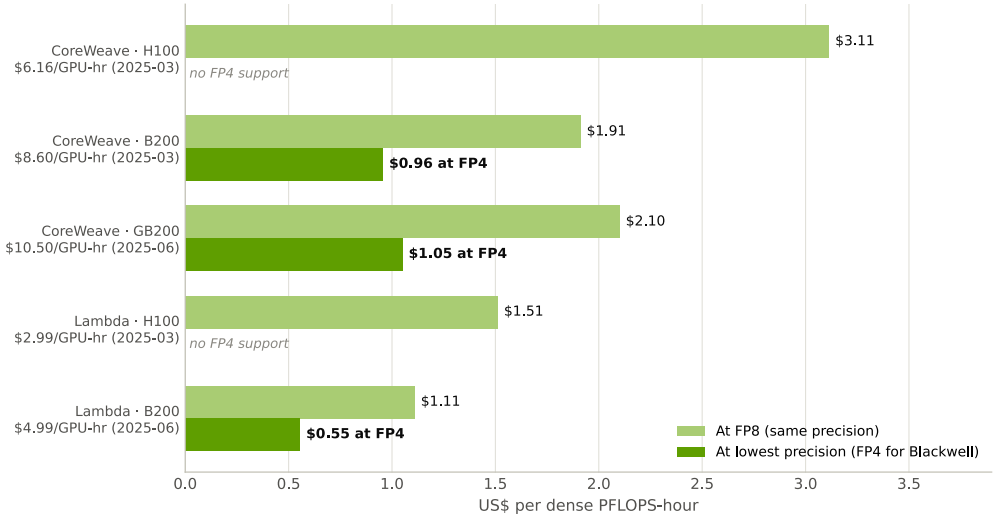

Source: data from CoreWeave, Lambda list prices; NVIDIA [S394] [S33002] [S35011] [S35013] [S33003] [S35014] …; chart by repo · As of 2026-11-05

每稠密 PFLOPS 小时租赁价格的分组水平柱状图（2025 年目录价）。CoreWeave：H100 $6.16/GPU 小时 = 每 FP8 PFLOPS 小时 $3.11；B200 $8.60 = FP8 下 $1.91、FP4 下 $0.96；GB200 $10.50 = FP8 下 $2.10、FP4 下 $1.05。Lambda：H100 $2.99 = $1.51；B200 $4.99 = FP8 下 $1.11、FP4 下 $0.55。在相同精度下，Blackwell 每 FLOP 便宜 1.4-1.6 倍，使用 FP4 则便宜 2.7-3.3 倍。

提示

算例 —— 同一服务商的 B200 与 H100。 CoreWeave 的 H100 目录价为 $6.16/GPU 小时，B200 为 $8.60 [S394]：多花 40% 的钱，换来 2.27 倍的稠密 FP8 算力（4.5 对 1.98 PFLOPS）[S33003,S33002]，因此每 FP8 PFLOPS 小时便宜 1.6 倍。若使用 H100 不支持的 FP4，则便宜 3.3 倍。**结论：** 只有当租户的软件采用新的数值格式时，大部分代际收益才能真正惠及租户。旧 GPU 也并非单纯贬值：由于推理需求超过供给，H100 一年期合同价从 $1.70（2025 年 10 月）反弹约 38% 至 $2.35（2026 年 3 月）[S12516]。

> **注**
>
> 🐂 **看多观点：** 更多类型的买方（主权客户、新兴云服务商、企业）稀释了四大超大规模云厂商的议价能力，使英伟达的定价得以维持。

> **注意**
>
> 🐻 **看空观点：** 新兴云服务商高杠杆、由英伟达提供融资，且依赖超大规模云厂商的溢出需求。如果超大规模云厂商转向自研芯片，新兴云服务商的需求会首先走弱，而英伟达的持股与兜底承诺正处在这条路径上。

🎯 企业发展视角

1. **客户质量与客户数量同样重要。** 应追踪新兴云服务商的积压订单中有多少最终来自微软、OpenAI 和 Meta [S12526,S12527]。
2. **甲骨文的双源采购（英伟达加 AMD MI450）[S6008,S90022]是一个范本**，一旦 AMD 机架开始出货，其他准新兴云服务商可能会效仿。
3. **新兴云服务商的股权是对利用率和融资利差的看涨期权**，而非对技术的押注；私营公司（Crusoe、Lambda、Nscale）在高估值下承担着这一风险。
4. **高通的问题（仅基于公开信息）：** HUMAIN 计划部署的 200 MW AI200/AI250 [S90030]是一个主权型锚定客户；哪些新兴云服务商或主权买方足够重视第二推理供应源，从而愿意双源采购?

DGX Cloud 与 DGX Cloud Lepton

第 12 层 · 编排与云服务 · 约 8 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **DGX Cloud（2023 年 3 月）是英伟达开在别人云里的云：** 由英伟达运营的集群先托管于 Oracle Cloud，随后是 Azure 和 Google Cloud，每个 8-GPU 实例起价 $36,999/月（约合每 GPU 小时 $6.34）[S12007]；AWS 于 2023 年 11 月加入 [S5525]。
- **其机制是回租。** 英伟达从购买其 GPU 的云厂商那里租回容量，再搭配自有软件转售。其多年期云服务协议增长约 13 倍，从 $2.23B（2023 年 1 月）增至 $29B（2026 年 7 月）[S418,S407]。
- 🟡 **2025 年的战略转向：** 据报道，随着英伟达不再试图与 AWS 和 Azure 竞争，DGX Cloud 的大部分容量被转用于英伟达自身的研究 [S90068]；另据报道，一笔约 $1.5B、从 Lambda 租回约 18,000 颗 GPU 的交易也指向同一方向 [S483]。
- **DGX Cloud Lepton（2025 年 5 月）是一个市场平台，而不是一朵云。** 它在不持有硬件的情况下把开发者导流至合作伙伴的容量（CoreWeave、Crusoe、Lambda、Nebius、Nscale 等）[S598,S12009]，其基础是对 Lepton AI 的收购（2025 年 4 月；据报道金额为数亿美元）[S478,S479]。
- **英伟达还是最后的买家：** 在 2032-04-13 之前承接 CoreWeave 最多 $6.3B 的未售出容量 [S90067]，这包含在 2026 年 7 月披露的 $36B AI 云容量协议之内 [S407,S430]。
- **为何不做完整的公有云：** 在英伟达 Q2 FY2027 约 $89B 的数据中心收入中，超大规模客户贡献约 $48.7B [S90011,S90013]。与它们竞争会引发渠道冲突，并加速它们的自研芯片。
- **弱点：** 英伟达如今在硬件公司的资产负债表上背负着云服务式的承诺（合计约 $65B）[S407]；一旦需求走弱，这些承诺就会从支撑变成成本。

NVIDIA's cloud-service commitments rose ~13× to $29B: it is now a big GPU-cloud tenant

Multi-year cloud service agreements disclosed in 10-K/10-Q filings, US$ B at period end (capacity NVIDIA rents from clouds)

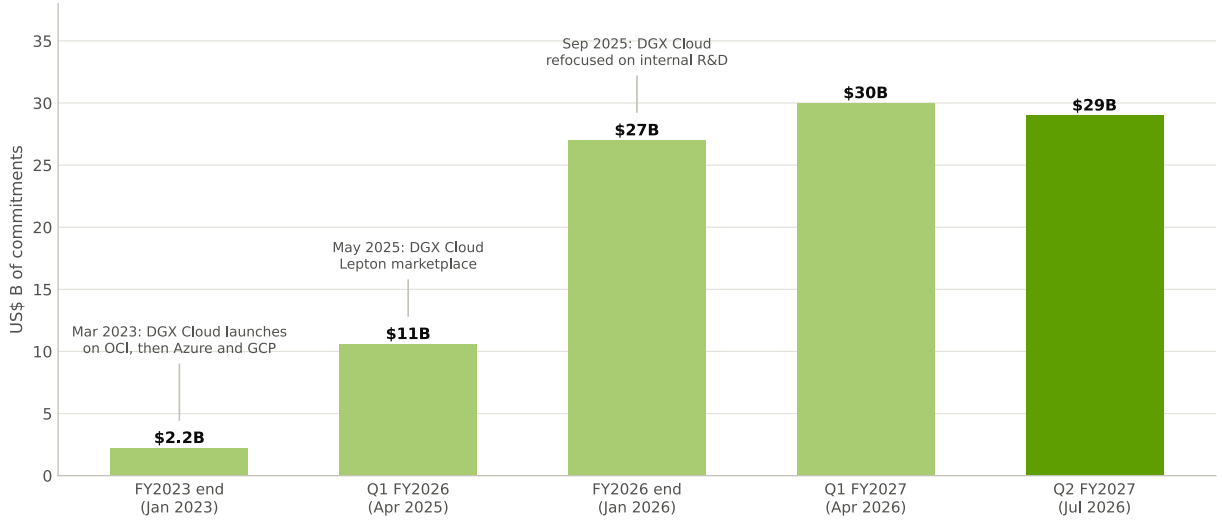

Source: data from NVIDIA 10-K and 10-Q filings [S418] [S414] [S401] [S404] [S407]; chart by repo · As of 2026-11-05

英伟达披露的多年期云服务协议柱状图：FY2023 末（2023 年 1 月，DGX Cloud 推出前夕）$2.23B，Q1 FY2026（2025 年 4 月）$10.6B，FY2026 末（2026 年 1 月）$27.0B，Q1 FY2027 $30B，Q2 FY2027（2026 年 7 月）$29B。这些承诺用于支付英伟达为 DGX Cloud 以及越来越多地为自身研究而向云合作伙伴租用的容量；它们与 2026 年 7 月披露的 $36B AI 云容量协议相互独立。

DGX Cloud 1.0：百货商场里的品牌专柜

设计师品牌可以在百货商场里开设自营专柜：用自己的员工、自己的定价、自己的客户，占用的是商场的场地。DGX Cloud 的运作方式如出一辙。超大规模云厂商购买并托管 GPU；英伟达租回这些容量，加上 Base Command、AI Enterprise 和自己的工程师，再以自己的定价出售使用权 [S12007]。

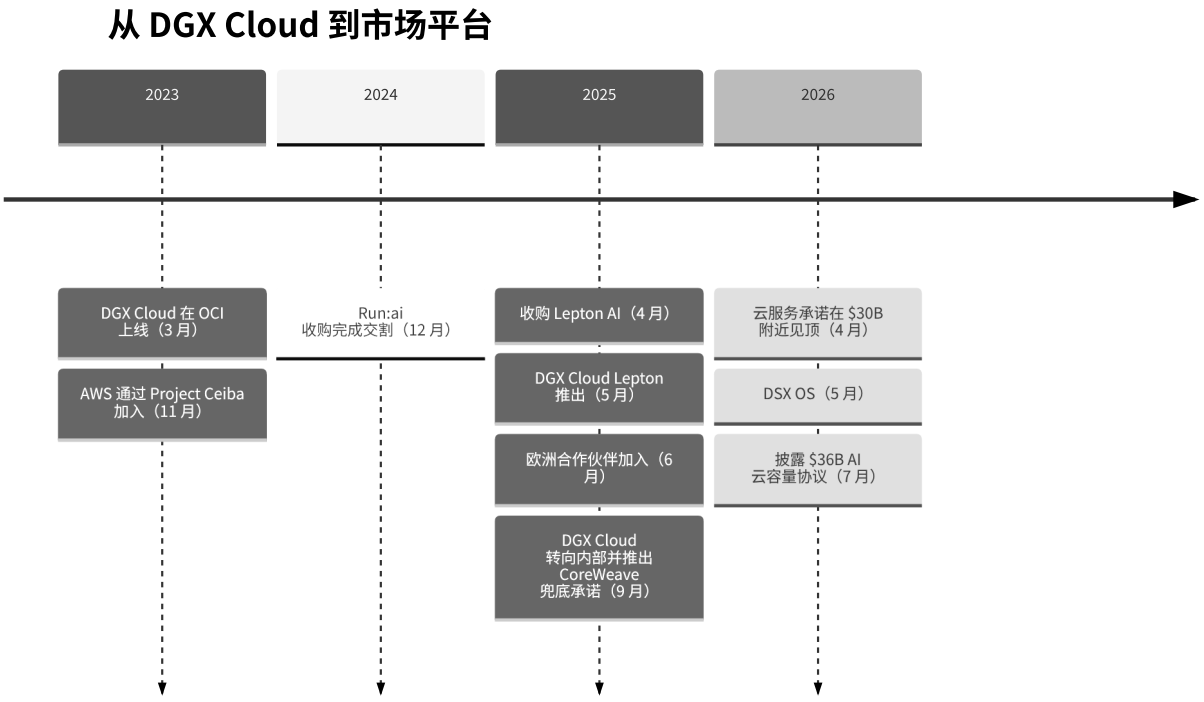

提示

算例 —— DGX Cloud 的收费水平。 $36,999/月 ÷（8 颗 GPU × 约 730 小时）= **约 $6.34/GPU 小时** [S12007]，含英伟达的软件与支持服务。AWS 自有的 H100 实例在 2023 年 7 月推出时的目录价为 $12.29/GPU 小时 [S391]，而新兴云服务商（neocloud）的 H100 在 2023 年高峰期约为 $8 [S393]。**结论：** DGX Cloud 定位为高溢价、软件丰富的服务，而非折扣渠道，并且与托管方自己的实例形成竞争。

2025 年的战略转向：从云卖家变为云租户

据 2025 年 9 月的报道，DGX Cloud 的大部分容量被用于英伟达自身的研究，英伟达也将不再试图与 AWS 和 Azure 竞争 [S90068]。但承诺规模并未缩减：从 2025 年 4 月的 $10.6B 增至 2026 年 7 月的 $29B [S414,S407]。英伟达仍在大规模租用容量，如今主要用于自身的研究和软件开发 [S90068]。

提示

算例 —— $29B 能租多少颗 GPU。 假设约 $2.50/GPU 小时（介于 2026 年 3 月约 $2.35 的 H100 一年期指数 [S12516]与 Blackwell 目录价 [S395]之间），$29B 可购买约 116 亿个 GPU 小时。按这些承诺六年的期限 [S401]计算，相当于约 220,000 颗 GPU 全时运行（🔴 本资料库估计）。**结论：** 英伟达本身就是较大的 GPU 云租户之一。

DGX Cloud Lepton：调度需求，而非拥有供给

Lepton 更像网约车应用，而不是出租车公司。开发者可以在各合作伙伴云之间搜索 GPU，向某家服务商购买容量或接入自有集群，并且无论选择哪家服务商，都能使用英伟达的软件栈 [S12009,S12529]。首批合作伙伴包括 CoreWeave、Crusoe、Firmus、富士康、GMI Cloud、Lambda、Nebius、Nscale、软银（SoftBank）和 Yotta [S12009]；Mistral AI、Fluidstack、Scaleway、Together AI 等于 2025 年 6 月加入，据报道 AWS 和 Azure 也将跟进 🟡 [S12008]。

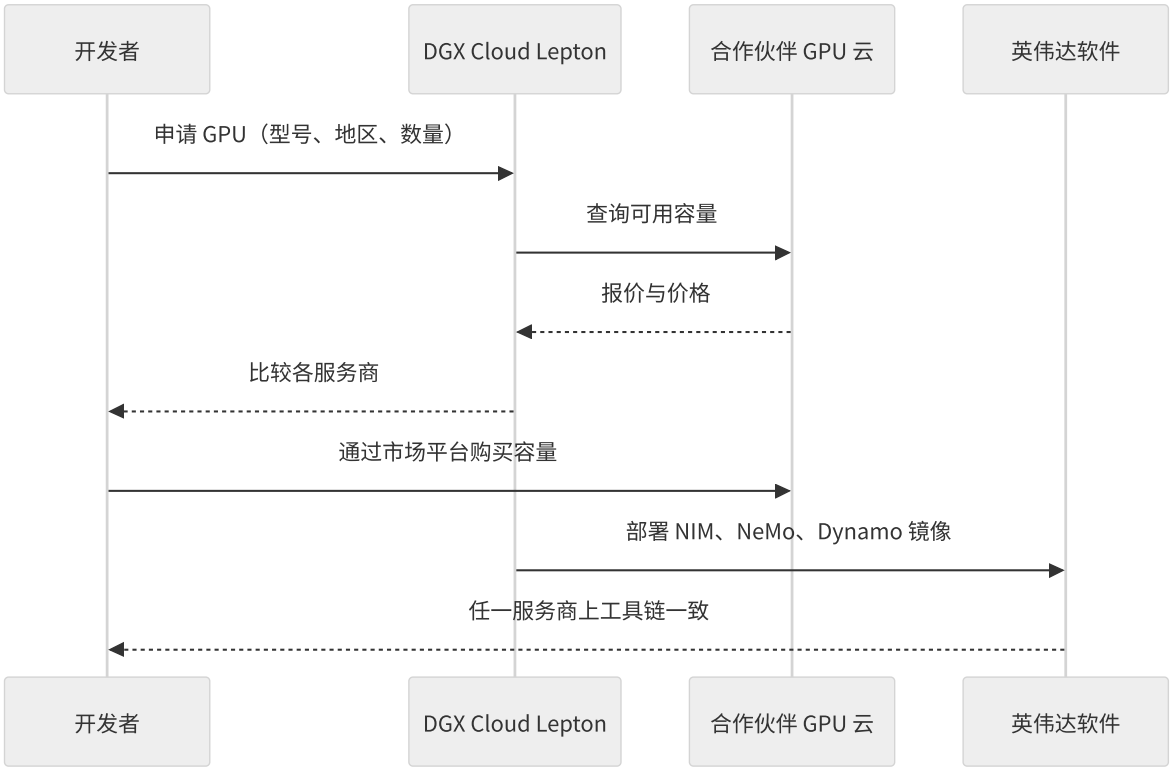

提示

算例 —— 新兴云服务商为何加入。 一家拥有 2,000 颗 GPU 的新兴云服务商若将利用率从 60% 提升到 70%，每年可多卖出 2,000 × 8,760 × 10% ≈ **175 万**个 GPU 小时；按约 $2.35 [S12516]计算，即在已有容量上多获得约 $41M 收入（估计）。**结论：** Lepton 对合作伙伴的价值在于需求聚合；对英伟达的价值则在于，无论硬件归谁，开发者都留在它的软件栈上。

🔧 技术细节：英伟达的三类云承诺

工具	英伟达为何付费	规模	来源
多年期云服务协议	自用容量（DGX Cloud、研究）	$29B（2026 年 7 月）	S407
AI 云容量协议	合作伙伴未售出的容量	$36B（2026 年 7 月）	S407,S430
CoreWeave 兜底承诺（属上述之一）	CoreWeave 截至 2032-04-13 的未售出容量	最多 $6.3B	S90067

这些是采购承诺，而非收入。围绕它们的循环融资争议，详见价值链与企业发展视角。

英伟达为何避免与超大规模云厂商正面竞争

1. **客户集中：** 超大规模云厂商约占 Q2 FY2027 数据中心收入的 55%（约 $89B 中的 $48.7B）[S90011,S90013]。自建一朵与之竞争的云，将使最大客户的订单面临风险。

2. **它们的替代方案是真实存在的：** 每家超大规模云厂商都有自研加速器（TPU、Trainium、Maia、MTIA）；渠道冲突只会加速其采用。
3. **经济模式不同：** 英伟达在出货时即赚取约 75% 的毛利率 [S3]；云厂商则要在数年间逐步赚回，并承担利用率与融资风险。

> **提示**
>
> **算例 —— 出售与出租一颗 GB300 GPU 的对比。** 英伟达的收入在出货时即确认（在 ODM 层面，机架售价约合每 GPU $55K [S332]）。一家云厂商若以假设的 $3.00/小时、60% 利用率出租同一颗 GPU，六年可收入约 $95K（3.00 × 8,760 × 0.6 × 6），且尚未扣除电力、设施、人员和利息（🔴 假设）。**结论：** 云厂商多出来的收入是以六年的风险换来的；英伟达宁愿为每一朵云供货，也不愿自己成为一朵云。

> **注**
>
> 🐂 **看多观点：** Lepton 加上兜底承诺，让英伟达以很少的资本开支就能影响需求的落点，同时超大规模云厂商仍是它的客户。

> **注意**
>
> 🐻 **看空观点：** 约 $65B 的承诺 [S407] 使英伟达实际上成了云风险的承担者；一旦进入下行周期，它将为那些早已确认为收入的闲置 GPU 买单。

🎯 企业发展视角

1. **市场平台还是所有者：** Lepton 表明英伟达更愿意掌控需求路由和软件，而非数据中心。哪些 GPU 云中介或聚合平台仍是独立的潜在标的？
2. **像审视承租人资产负债表那样解读这些承诺：** $29B 的服务协议加上 $36B 的容量协议 [S407]，理应受到与租赁负债同等的审视。
3. **合作伙伴杠杆是一把双刃剑：** 新兴云服务商从 Lepton 获得需求，但也加深了对英伟达供货分配与定价的依赖。
4. **高通的问题（仅基于公开信息）：** 一个硬件中立、类似 Lepton 的市场平台，是否有助于非英伟达推理机架触达开发者？又该由谁来运营？

编排与云服务：竞争格局

第 12 层 · 编排与云服务 · 约 13 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **英伟达在这一层参与竞争，却并不拥有一朵云。** 它在 2025 年将 DGX Cloud 转为内部使用；DGX Cloud Lepton 则把开发者导流至合作伙伴的 GPU 🟡 S90068,S12009。
- **它把软件免费送出，把 GPU 利润留给自己：** KAI Scheduler（2025 年）和整个 Run:ai 平台（2026 年 10 月）均已开源，Slurm 在英伟达旗下也保持厂商中立 S12509,S12510,S12000。
- **[Q5 · 最强挑战者]** 超大规模云厂商的垂直一体化云掌握客户、容量以及第二种加速器：Anthropic 拥有最多 100 万颗谷歌 TPU，并在 Project Rainier 中使用约 50 万颗 Trainium2 S90026,S90034。
- **即便是对手也在购买英伟达算力：** 微软的 Maia 200 规模尚小，而微软已与纯英伟达的新兴云服务商（neocloud）签订了超过 $60B 的租赁合同 🟡 S90044,S12526。
- **CoreWeave 是最强的独立技术栈：** 拥有 $104.2B 的收入积压（revenue backlog），并收购了 Weights & Biases（约 $1.7B）。但其机群全部采用英伟达 GPU，且由英伟达提供兜底承诺 S12500,S12507,S90067。
- **看空情景：** 如果超大规模云厂商把工作负载引向自研芯片，英伟达的杠杆（供货分配、股权、市场平台）将无法把客户争取回来。

5 of 9 rivals own the cloud customer NVIDIA rarely bills; none out-control its accelerators

Repo verdict for each rival vs NVIDIA's layer-12 position (DGX Cloud/Lepton, Run:ai/KAI, Slurm, DSX OS, allocation, capital)

	Customer ownership	Owned capacity	Accelerator control	Scheduling & orchestration	Hardware neutrality
AWS SageMaker HyperPod + Bedrock + Trainium	**L · direct enterprise contracts**	**L · multi-GW own regions**	P · Trainium3 GA; 500k Trn2 in Rainier	P · HyperPod / EKS / Slurm	B · single cloud
Google Cloud Vertex AI + GKE + TPU	**L · direct + Gemini pull**	**L · multi-GW own regions**	P · Ironwood; up to 1M TPUs to Anthropic	P · GKE + Kueue lineage	B · mostly single cloud
Microsoft Azure Foundry + AKS + Maia	**L · enterprise + OpenAI channel**	**L · own + >$60B rented neocloud**	B · Maia 200 small; Maia 300 2027	P · AKS / CycleCloud	B · single cloud
CoreWeave CKS + SUNK + Weights & Biases	**L · $104B backlog**	**L · 1.5 GW active; 3.7 GW contracted**	B · NVIDIA-only fleet	P · SUNK (Slurm on K8s); 96% goodput claim	B · single cloud
Nebius Nebius AI Cloud	**L · $3B ARR; Microsoft/Meta deals**	**L · 0.8-1 GW live end-2026**	B · NVIDIA-only fleet	P · adopting open Run:ai	B · single cloud
Kubernetes + Kueue Open-source queueing	D · no commercial owner	D · software only	D · vendor-agnostic	P · gang + topology-aware	**L · any vendor; MultiKueue**
Ray / Anyscale Python distributed runtime	B · developer mindshare only	D · software only	D · vendor-agnostic	D · app-level (KubeRay uses KAI)	**L · any cloud or cluster**
SkyPilot Multi-cloud job broker	B · team tool	D · software only	D · GPUs + TPUs	P · gang + failover; NVL72 +14% claim	**L · 20+ clouds + K8s + Slurm**
GPU marketplaces Vast.ai / SF Compute class	P · price-led spot buyers	D · aggregate others' GPUs	B · NVIDIA-only listings	B · raw instances	**L · many providers**

L = rival leads NVIDIA　P = parity　B = rival behind　D = different approach

Repo judgement

Source: data from repo analysis of company disclosures [S90035] [S90034] [S90026] [S90025] [S12533]; chart by repo · As of 2026-11-05

> 9 家编排与云服务对手与英伟达在五个维度上的对比热力图。AWS、Google Cloud、Microsoft Azure、CoreWeave 和 Nebius 在客户掌控与自有容量上领先（CoreWeave 积压订单 $104B，在运行功率 1.5 GW）；在加速器控制上无一领先，其中 AWS Trainium 和谷歌 TPU 持平，纯英伟达的新兴云服务商落后；调度能力大多持平；4 家开源工具与市场平台在硬件与云中立性上领先。

第 12 层的竞争如何计分

第 12 层把机架转化为客户可以租用并保持忙碌的容量。不妨以航空公司作比：GPU 是飞机，调度器是机组排班，云厂商负责售票并拥有乘客。英伟达造飞机、免费提供排班软件，还经营一个订票网站（Lepton），

但它并不拥有航空公司。决定胜负的有五件事：谁**掌握客户**、谁**拥有容量**、谁**控制加速器**、谁的**调度器**在运行作业，以及技术栈是否**中立**。

对手 vs 英伟达	客户掌控	自有容量	加速器控制	调度与平台	中立性
AWS（SageMaker HyperPod、Bedrock、Trainium）	🟩 直接签订企业合同	🟩 自有区域	🟨 Trainium3 已正式商用 S90035	🟨 HyperPod / EKS	🟥 单一云
Google Cloud（Vertex AI、GKE、TPU）	🟩 Gemini 带动需求	🟩 自有区域	🟨 向 Anthropic 提供最多 100 万颗 TPU S90026	🟨 GKE，Kueue 的发源地	🟥 基本为单一云
Microsoft Azure（Foundry、AKS、Maia）	🟩 企业客户 + OpenAI	🟩 自有 + 超过 $60B 的租赁容量 S12526	🟥 Maia 200 规模小 S90044	🟨 AKS / CycleCloud	🟥 单一云
CoreWeave（CKS、SUNK、W&B）	🟩 $104B 积压订单 S12500	🟩 在运行 1.5 GW S12501	🟥 仅用英伟达	🟨 宣称 96% goodput S12530	🟥 单一云
开源（Kueue、Ray、SkyPilot）	🟦 无所有者	🟦 仅软件	🟦 厂商无关	🟨 成组 + 拓扑感知调度 S12533	🟩 任意云或芯片
GPU 交易平台（Vast.ai、SF Compute）	🟨 价格导向型买方	🟦 他人的 GPU	🟥 英伟达 GPU 挂牌	🟥 裸实例	🟩 多家服务商

评级为本资料库的判断 🔴；上方热力图涵盖全部九家对手，来源见 `data/l12_competitor_verdicts.csv`。

> **提示**
>
> **算例 —— 这个对手同时也是新兴云服务商的最大客户。** 截至 2025 年 11 月，微软已签订超过 $60B 的多年期新兴云服务商租赁合同：Nscale 约 $23B（约 200,000 颗 GB300 GPU）、Nebius $17.4B（最高 $19.4B）以及 IREN $9.7B 🟡 S12526。即便分摊到数年，这仍相当于微软 2026 日历年约 $175B 资本开支指引的约三分之一 🟡 S12518。这些容量基于英伟达 GPU。一家超大规模云厂商可以在芯片上（Maia）与英伟达竞争，同时又是它最大的间接买家之一。

> **🔧 技术细节：GPU 调度器实际上在决定什么**
>
> 一个 1,024 颗 GPU 的作业必须在所有 GPU 上同时启动（成组调度（gang scheduling）），并且这些 GPU 要共享一台高速交换机（拓扑感知）。调度器还要抢占低优先级工作、执行团队配额，并为小作业切分 GPU。Slurm 为超级计算机的批处理作业完成这些工作；Kueue 和 KAI Scheduler 等 Kubernetes 插件则为容器完成这些工作 S12533,S12002。商业产品（Run:ai、Mission Control、SageMaker HyperPod）在此基础上增加了仪表盘、计量计费以及故障节点的自动恢复 S12004,S12006。

逐一审视挑战者

超大规模云厂商的垂直一体化云：最强挑战者

[Q5 · 最强挑战者] AWS、谷歌和微软是英伟达最大的客户（在 Q2 FY2027 $89.0B 的数据中心收入中，超大规模云厂商约占 $48.7B 🟡），也是其最全面的对手 S406,S405：

- **AWS：** Trainium3 已正式商用（2025 年 12 月）；Trainium4 将支持 NVLink Fusion；Project Rainier 中部署了约 50 万颗 Trainium2 S90034,S90035。
- **谷歌：** 为 Anthropic 提供最多 100 万颗 TPU（2026 年超过 1 GW），向 Meta 出租 TPU，并向客户数据中心销售 TPU 🟡 S90026,S90025,S90027。
- **微软：** Maia 200 用于运行 Copilot；Maia 300 及吉瓦级部署计划自 2027 年起推进 🟡 S90044,S90046,S90045。

它们最有力的论点： 账单掌握在云厂商手中。在 Bedrock、Vertex AI 或 Foundry 背后，由服务商决定用哪种芯片，而英伟达的任何杠杆都触及不到这一选择。

差距缩小了多少： 在它们的自有工作负载和锚定实验室的工作负载上缩小了很多，在开放市场上则很少。它们仍在不断上调 2026 年的资本开支，而其中大部分流向英伟达（见路线图）。

CoreWeave 与新兴云服务商的软件栈

CoreWeave 的在运行功率从 2024 年底的约 360 MW 增长到 2026 年中的约 1.5 GW [S12011,S12501]。其技术栈由 CoreWeave Kubernetes Service 加 SUNK（运行在 Kubernetes 上的 Slurm）组成，公司称其有效产出（goodput）最高可达 96%（厂商说法）[S12530]。它收购了 Weights & Biases（约 $1.7B，2025-05-05 完成交割）以切入开发者工作流；其以全股票方式约 $9B 收购 Core Scientific 的提议于 2025-10-30 被股东投票否决 [S12506,S12507,S12508]。

最有力的论点： 新兴云服务商运营大型集群的水平不逊于超大规模云厂商，而且成本更低。**局限：** 其机群、融资，甚至其调度器（Slurm，现归英伟达所有）都依赖英伟达 [S12000,S90067]。

> **提示**
>
> **算例 —— 英伟达为何买下合作伙伴所用的调度器。** TOP500 前 10 名和前 100 名超级计算机中，超过一半运行 Slurm，而 CoreWeave 的 SUNK 将其置于 Kubernetes 之下 [S12000,S12530]。收购 SchedMD（条款未披露）的花费很可能远低于 Run:ai 据报道的约 $700M [S476]，却拿下了 AI 训练的默认作业队列。由于已承诺 Slurm 保持开放与中立，这一杠杆在于对路线图的影响力，而非锁定。

开源调度器

Kueue 为 Kubernetes 增加了队列、公平份额、成组调度和拓扑感知调度 [S12533]。Ray（Anyscale）可在任意集群上扩展 Python AI 代码 [S12535]。SkyPilot 横跨 Kubernetes、Slurm 和 20 多家云，并宣称在 NVL72 训练上提升 14%（厂商说法）[S12534]。它们在中立性上领先，而且免费。英伟达选择加入而非对抗：KAI Scheduler 是 CNCF 沙箱项目，Crusoe、Nebius 等八家公司正在采用开源的 Run:ai [S12002,S12512]。

GPU 交易平台

Lepton 上线时有十家合作伙伴云，并于 2025 年 6 月新增了 Mistral、Nscale、Fluidstack 和 Together AI [S12009,S12008]。Vast.ai、SF Compute 等 GPU 交易平台以及 SkyPilot 的 GPU Compass 等中介以价格竞争 [S12534]。Silicon Data 的 H100 指数在四周内从每 GPU 小时 $2.00 升至 $2.20，该公司正与芝商所（CME Group）合作推出算力期货 🟡 [S12517]。

竞争定位

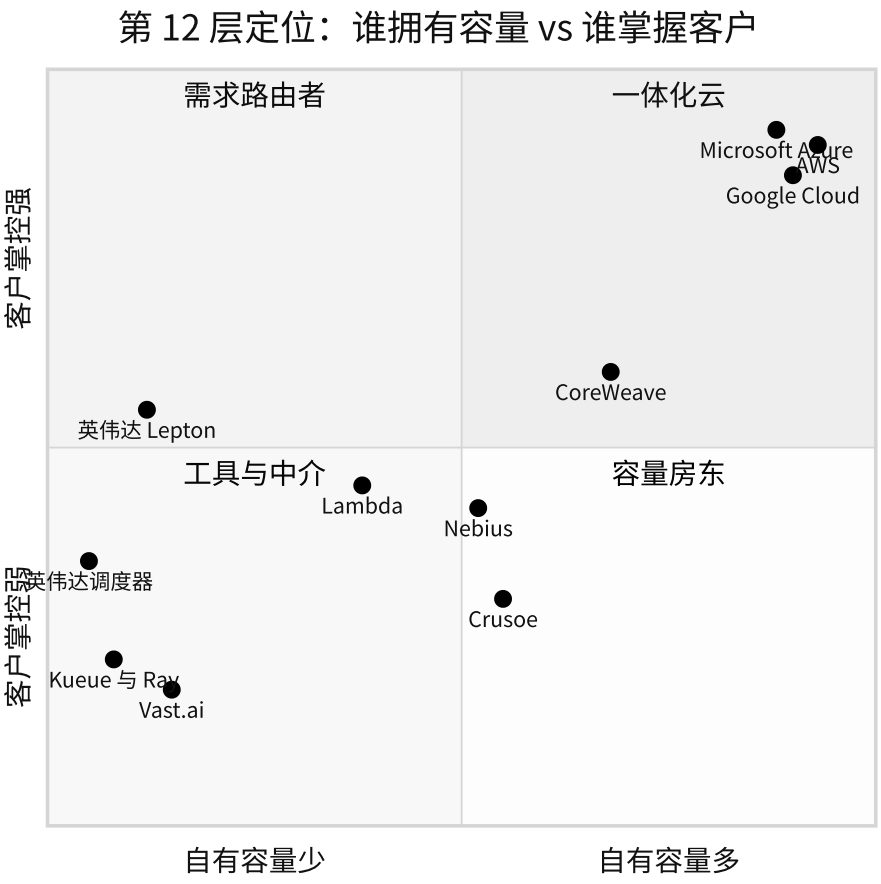

定位为本资料库的判断 🔴。英伟达是“需求路由者”：它在不拥有太多容量的情况下引导工作负载的流向（供货分配、Lepton、融资）。

> **注**
>
> 🐂 **看多观点。** 英伟达无需在第 12 层全面获胜。非超大规模买方（新兴云服务商、主权客户、企业）在 Q2 FY2027 数据中心收入中约占 $40.3B，区域性新兴云服务商同比增长超过 3 倍 🟡 S406,S90071。开源编排栈让每一朵云都更容易在英伟达硬件上运行。

> **注意**
>
> 🐻 **看空观点。** 客户掌控是这一层的稀缺资产，而英伟达恰恰在这方面最弱。TPU 如今已在谷歌之外销售，Trainium4 将支持 NVLink Fusion，而超大规模云厂商决定 API 背后用哪种芯片 S90027,S90034。如果新兴云服务商的融资收紧，英伟达剩下的渠道就会收窄到那些正在构建替代方案的买方身上。

🎯 企业发展视角

1. 编排软件如今已是免费的（KAI、Run:ai、Slurm、Kueue）。剩下可变现的层次在哪里：托管运营、多云中介，还是融资?
2. 超大规模云厂商一边从新兴云服务商那里租用英伟达算力，一边自研 ASIC。一旦 Maia 300 和 Trainium4 在 2027 年放量，这种租赁需求能持续多久?
3. CoreWeave 收购 Weights & Biases 以向技术栈上层延伸。哪些新兴云服务商工具（MLOps、推理端点、调度器）可以在被商品化之前收购?

4. 非英伟达加速器需要一个把它当作一等公民的调度器和市场平台。Kueue、Ray 和 SkyPilot 是否已经提供了这条路径，还是需要新进入者出资打造？

编排与云服务：发展历程与英伟达的构建方式

第 12 层 · 编排与云服务 · 约 11 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **英伟达曾尝试成为一朵云，随后选择成为各家云的“造王者”。** DGX Cloud 于 2023 年 3 月推出，部署在甲骨文、微软和谷歌的数据中心内，价格为每 8-GPU 实例每月 $36,999。到 2025 年，它主要服务于英伟达自身的研究 🟡 S12007,S90068。
- **软件通过收购获得：** Bright Computing（2022 年）、Run:ai（据报道约 $700M，2024 年）、Shoreline 与 Brev.dev（2024 年）、Lepton（2025 年），以及 Slurm 的开发商 SchedMD（2025 年 12 月）S478,S476,S479,S12000。
- **随后它把软件免费放了出去：** KAI Scheduler 于 2025 年开源，完整的 Run:ai 平台于 2026 年 10 月开源，均纳入 DSX OS 产品组合 S12509,S12510,S12514。
- **CoreWeave 是范本：** 约 $100M 的入股（2023 年）、约 $250M 的 IPO 锚定认购（2025 年 3 月）、至 2032 年 4 月的 $6.3B 容量兜底承诺，以及再追加 $2B 股权（2026 年 1 月）S481,S473,S90067,S472。
- **[Q4 · 优势来源]** 供货分配能力、生态与股权，而不仅仅是软件。软件是免费的；稀缺的 GPU 以及为其买方提供的廉价资本则不是。
- **[Q6 · 复制成本]** 软件复制成本很低（估计 $1–2B，2–3 年）。而这一地位需要一款售罄的产品，外加数百亿美元的资产负债表支持 🔴。

英伟达如何构建其编排与云服务地位

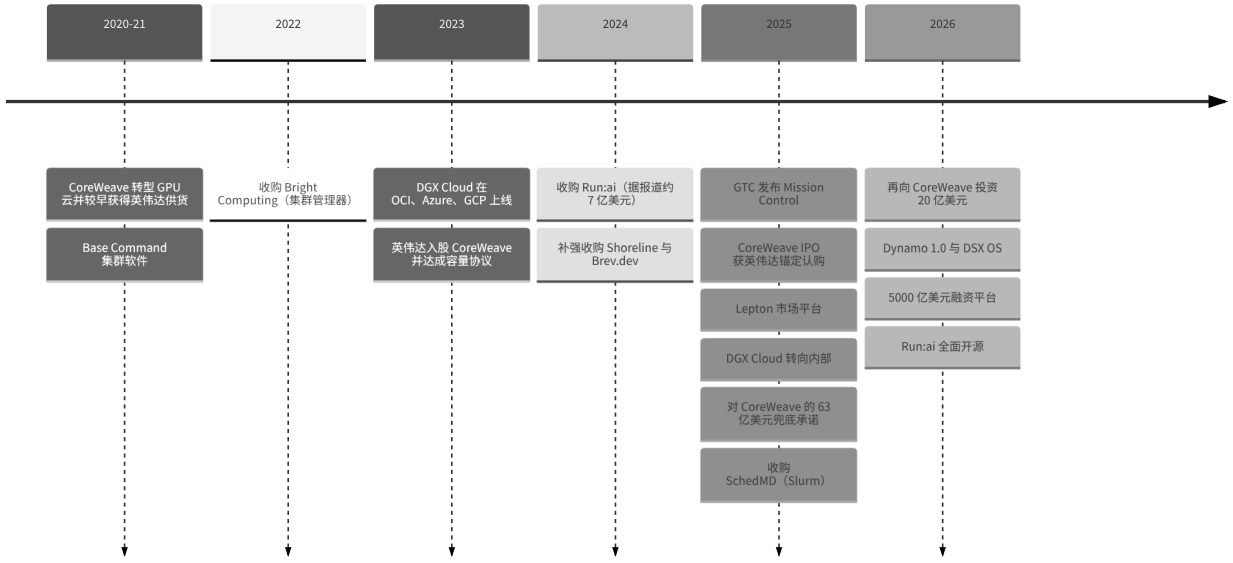

从卖设备到塑造云

英伟达最早的编排软件用于运行客户自有的 DGX SuperPOD；Bright Computing 的集群管理器后来成为 Base Command Manager，如今已纳入 Mission Control S478,S12004。更难的问题在于：谁来把 GPU 租给那些无力自购 SuperPOD 的买方？英伟达尝试了三种答案：自建云、市场平台，以及为其他云提供融资。

日期	决策	意义	来源
2022-01	收购 Bright Computing	集群部署；后来的 Base Command Manager	S478
2023-03	DGX Cloud 部署于 OCI、Azure、Google Cloud	借助租来的超大规模云厂商容量直接销售云算力时长	S12007
2023-04	入股 CoreWeave 并达成容量协议	在超大规模云厂商之外扶植一朵纯英伟达云	S481,S90067
2024-04 → 12	收购 Run:ai（据报道约 $700M）	Kubernetes 上的 GPU 资源池化与 GPU 切分	S476
2025-03	推出 Mission Control；锚定认购 CoreWeave IPO（约 $250M）	为 AI 工厂提供统一运维栈；为其最大的新兴云服务商引入公开市场资本	S12005,S473
2025-05	DGX Cloud Lepton 市场平台	把开发者导流至合作伙伴 GPU，而非与之竞争	S598,S12009
2025-09	DGX Cloud 转向内部；$6.3B CoreWeave 兜底承诺	退出与云厂商的正面竞争；降低合作伙伴容量风险	S90068,S90067
2025-12	收购 SchedMD（Slurm）	掌握训练作业的默认队列；承诺保持中立	S12000
2026-08	与六家资产管理公司搭建融资平台	目标为英伟达买方引入超过 $500B 的第三方资本	S12528
2026-10	完整开源 Run:ai 平台	使编排商品化；Crusoe 与 Nebius 已采用	S12510,S12512

提示

算例 —— 英伟达为何不再正面销售 DGX Cloud。 每 8-GPU 实例每月 $36,999 的发布价约合每 GPU 小时 $6.33 S12007。英伟达从甲骨文、微软和谷歌租来这些容量，再转售与它们竞争。在英伟达 Q2 FY2027 $89.0B 的数据中心收入中，超大规模云厂商购买了约 $48.7B 🟡 S406,S405。与贡献一半以上核心收入的买方竞争是一笔糟糕的交易，于是 DGX Cloud 成了内部资源，Lepton 则成了流量路由器 🟡 S90068。

与 CoreWeave 的关系（2020 → 2026）

CoreWeave 从加密货币挖矿转型为 GPU 云，并较早获得了英伟达新一代产品。到 2024 年底，它拥有超过 250,000 颗 GPU、超过 360 MW 的在运行功率和约 1.3 GW 的签约功率，微软贡献了其 2024 年收入的 62% S12011,S386。英伟达支持了它的每一轮融资，到 2026 年 6 月，CoreWeave 的收入积压达到 $104.2B S12500。如今，在英伟达的交易金额中，占大头的是资本承诺而非软件：

NVIDIA's deal commitments jumped to ~$51B in 2025, 5× all its deals before 2025

Disclosed or press-reported deal value by announcement year, US$ B; excludes blocked Arm and superseded OpenAI LOI

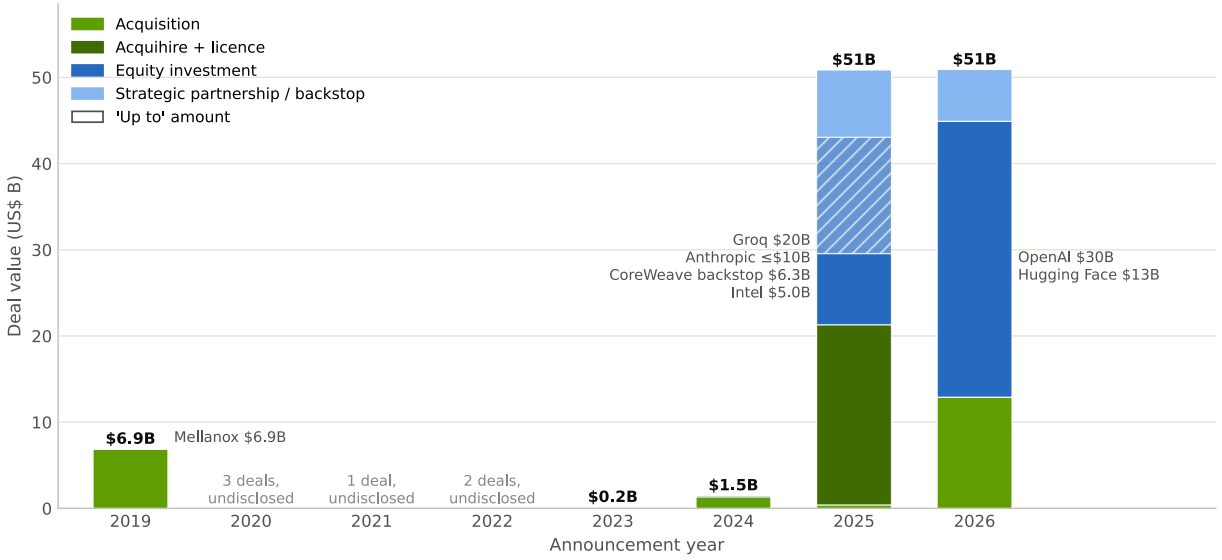

Arm ($40B, 2020) blocked

Source: data from NVIDIA filings and announcements; press reports [S464] [S2] [S476] [S479] [S478] [S475] ...; chart by repo · As of 2026-11-05

2019–2026 年英伟达各年交易金额堆叠柱状图：2019 年以 Mellanox（$6.9B）为主，随后是小规模软件补强收购，2025 年约 $51B（Groq 授权约 $20B、Anthropic 最多 $10B、CoreWeave $6.3B 兜底承诺、英特尔 $5B、Synopsys $2B、xAI 最多 $2B、诺基亚 $1B），2026 年约 $51B（OpenAI 约 $30B、CoreWeave $2B）；2025 年之前的全部交易合计约 $10B。

提示

算例 —— 兜底承诺对提供方与接受方的成本对比。 $6.3B 的兜底承诺要求英伟达在 2032-04-13 之前购买 CoreWeave 未售出的容量 [S90067]。在约 6.5 年间，即每年不超过 $1B，约为单季度营业利润（Q2 FY2027 为 $63.7B）的 10% [S405]。CoreWeave 的贷款方可将这部分容量视为部分预售，从而以更低利率放贷。对提供方而言代价低廉，对接受方而言价值可观：这种不对称性正是护城河。

[Q4 · 优势来源] 供货分配、生态与股权

[Q4 · 优势来源] 三个杠杆相互强化；位于其上的软件则是免费的。

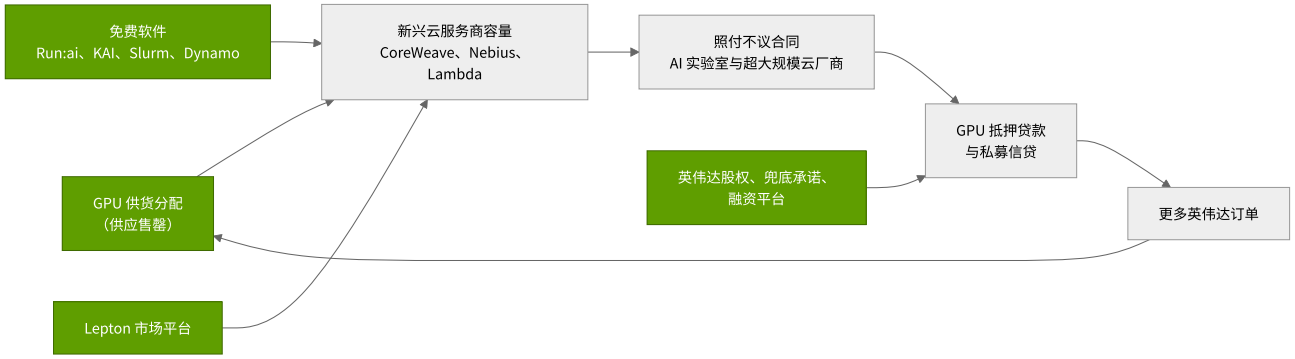

1. **供货分配。** 当需求超过供给时，谁先拿到 GPU 谁就赢得客户；英伟达对 FY2028 的展望是受供应约束，新的 H100 容量已被预订至 2026 年 9 月 🟡 [S90012,S12516]。
2. **生态。** Lepton、Dynamo 和开源的 Run:ai 让一家新成立的新兴云服务商（neocloud）从第一天起就具备可信度；Dynamo 1.0 的采用者包括 CoreWeave、Nebius 和 Together AI [S12009,S90066,S12510]。

3. **股权与信贷。** 英伟达的支持降低了其买方的资本成本：其 10-Q 列示了 $36B 的 AI 云容量协议和 $29B 的云服务协议 [S407]。

> **提示**
>
> **算例 —— 为什么在 2023 年，提前获得供货胜过任何软件功能。** 2023 年，一颗 H100 的租金约为每 GPU 小时 $8，购置成本约 $25–30K [S393,S356]。全天候出租时，仅 GPU 本身约 4–5 个月即可回本。比对手早一个季度拿到 H100 的云厂商，靠租金就能收回大部分购置成本，这也是新兴云服务商围绕英伟达的供货队列来组织自身业务的原因。

[Q6 · 复制成本] 时间、资金与人才

组成部分	英伟达投入或承诺的金额	复制所需时间（估计）	谁能做到
编排软件	Run:ai 约 $0.7B、Shoreline 约 $0.1B、Lepton “数亿美元”（据报道）；Bright、Brev.dev、SchedMD 未披露 [S479,S478]	2–3 年，数百名工程师	任何人；Kueue、Ray、SkyPilot 均免费 [S12533,S12535,S12534]
新兴云服务商融资支持	CoreWeave 约 $2.35B 股权 + $6.3B 兜底承诺；Lambda 回租约 $1.5B；$36B AI 云协议 [S472,S90067,S483,S407]	3–5 年	现金充裕的公司；谷歌已为 Fluidstack 提供兜底承诺 [S12525]
供货分配能力	需要一款毛利率约 75% 且供不应求的产品 [S405]	只要需求持续超过供给	单靠花钱谁也做不到
开发者吸引力	CUDA 与软件库，15 年以上（第 09 层）	十年	超大规模云厂商，部分可以

[Q6 · 复制成本] 估计（本资料库，🔴）：**软件 $1–2B，2–3 年，约 300–1,000 名工程师。**而这一**地位**需要 $40B 以上的资产负债表支持和一款售罄的产品：至少 5 年，且只有同时具备两者的公司才能做到。超大规模云厂商无需复制，因为它们掌握着客户和容量；商用芯片挑战者则必须复制。

> **提示**
>
> **算例 —— 挑战者要付出的代价。** 英伟达对一家 CoreWeave 规模合作伙伴的支持约为 $8.7B（$2.35B 股权 + $6.3B 兜底承诺），约占其 Q1 FY2027 $48.6B 自由现金流的 18% [S472,S90067,S403]。没有这般现金实力的挑战者只能用另一种“货币”支付：AMD 向 OpenAI 授予了最多 1.6 亿股 AMD 股票的认股权证，按部署进度和股价门槛分批归属 🟡 [S13506]。

反事实推演 —— 如果英伟达没有……

- 🔴 ……**退出 DGX Cloud，而是成为完整的公有云？** 一座 1 GW 的 AI 工厂全口径成本约 $50–60B，其中约 $35B 为英伟达产品 [S398]。英伟达将不得不自行为这笔资本开支融资，稀释其约 75% 的毛利率，并与购买其约 55% 数据中心产出的买方竞争 [S405,S406]。可能的结果：超大规模云厂商更快采用 ASIC。
- 🔴 ……**没有扶持新兴云服务商？** 非超大规模的 ACIE 板块（Q2 FY2027 约 $40.3B）将会更小，超大规模云厂商的议价能力则会更强 [S406]。CoreWeave 的债务成本会更高，增长也会更慢。
- 🔴 ……**让某家超大规模云厂商买下 SchedMD 或 Run:ai？** 训练作业的默认队列将偏向该所有者的芯片 [S12000,S476]。

> **🔧 技术细节：为什么开源 Run:ai 不会损害英伟达**
>
> Run:ai 对 GPU 进行池化：通过 GPU 切分、配额和抢占来提升利用率（英伟达宣称最高可达 5 倍，为厂商数据）[S12004]。更高的利用率使英伟达 GPU 每有效小时的成本更低，从而卖出更多 GPU。对软件收费会拖慢采用速度，

并招来开源替代品。以 Apache 2.0 许可发布，并通过 Mission Control 和 AI Enterprise 提供付费支持，可使英伟达的代码保持参考实现的地位 [S12510,S12511]。经济学家称之为“将互补品商品化”。

🎯 企业发展视角

1. 英伟达在第 12 层软件上或许花费了 $1–2B，随后将其中大部分开源。这对 GPU 编排初创公司的独立价值意味着什么?
2. 兜底承诺的不对称性只对拥有售罄产品、现金充裕的供应商有效。挑战者能否通过合作伙伴（超大规模云厂商、私募信贷）借用这一工具?
3. 各新兴云服务商获得每一代 GPU 的先后顺序，能否预测其后来的增长与估值?
4. 如果 2027–2028 年供给追上需求，哪个杠杆（供货分配、生态、股权）会最先减弱?

编排与云服务：路线图

第 12 层 · 编排与云服务 · 约 11 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **英伟达的软件路线图如今默认开放：** Mission Control（2025 年）、DSX OS（2026 年 GTC 台北）、Dynamo 1.0（2026 年 3 月），以及采用 Apache 许可的 Run:ai（2026 年 10 月）[S12005,S12513,S90066,S12510]。
- **需求路线图由超大规模云厂商的资本开支决定。** Alphabet、亚马逊和 Meta 将 2026 年指引从约 $505B 上调至约 $558B（取中值）；微软另有约 $170–175B 🟡 [S460,S461,S462,S12518,S12519]。
- **新兴云服务商（neocloud）在收入之前先行建设：** CoreWeave 的目标是到 2026 年底在运行功率超过 1.85 GW，而签约功率约 4.2 GW。Nebius 预计到 2026 年底签约约 5 GW，其中已接入 0.8–1 GW [S12500,S12010,S12503]。
- **积压订单是桥梁：** CoreWeave 的收入积压（revenue backlog）一年内增长 3.5 倍至 $104.2B，约为其 2026 年收入指引的 8 倍 [S12500]。
- **资本是下一个产品：** 英伟达 2026 年 8 月与 Apollo、贝莱德（BlackRock）、黑石（Blackstone）、Brookfield、高盛（Goldman Sachs）和 KKR 搭建的融资平台，目标是调动超过 $500B 的第三方资本，但目前仅为谅解备忘录（MOU），尚待签订最终协议 🟡 [S12528]。
- **[Q7 · 路线图与变数]** 有三件事会改变格局：超大规模云厂商暂停资本开支、GPU 租赁价格再次崩跌，或高杠杆新兴云服务商出现信贷压力。利息支出已约占 CoreWeave Q3 2026 收入指引的 26% [S12502]。

Big-3 2026 capex guides rose from ~$505B to ~$558B; ~$728B incl. Microsoft

Calendar-2026 capital-expenditure guidance midpoints by date issued, US$ B (whiskers = guided range)

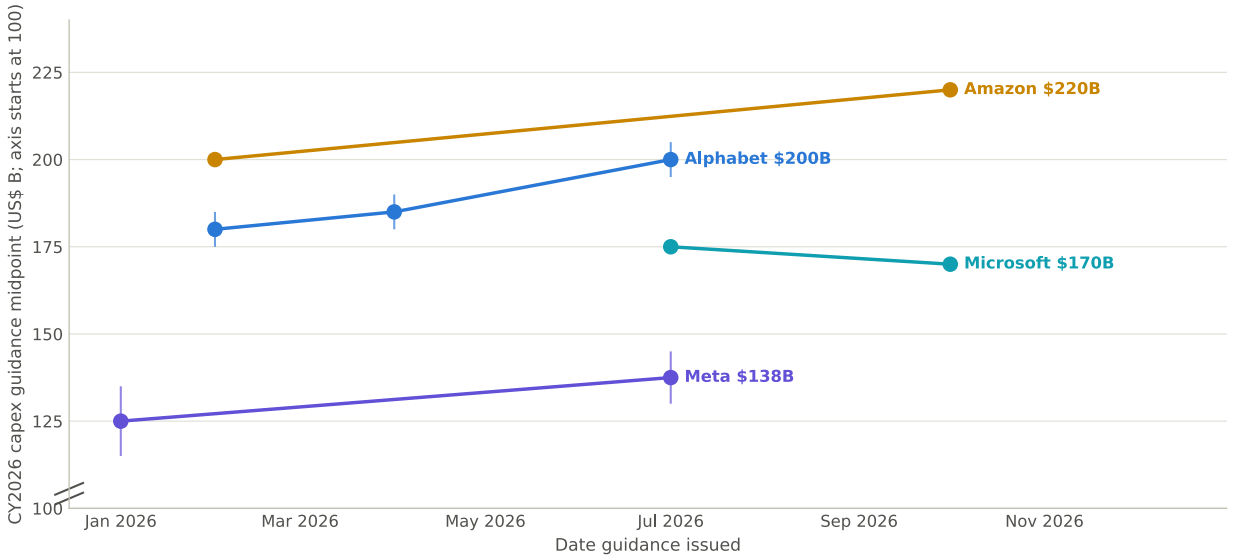

Bases differ (leases)

Source: data from company guidance as reported [S460] [S12518] [S461] [S12519] [S462]; chart by repo · As of 2026-11-05

2026 年资本开支指引中值折线图：Alphabet 从 $180B（2026 年 2 月）升至 $185B（4 月）和 $200B（7 月）；亚马逊从约 $200B 升至约 $220B；Meta 从 $125B（1 月）升至约 $137.5B（7 月）；微软 2026 日历年数字在 7 月约为 $175B，10 月约为 $170B。三大厂商合计从约 $505B 升至 $558B，四大厂商合计约 $728B；其他口径的统计可达 $803-828B。

2024–2028 年路线图

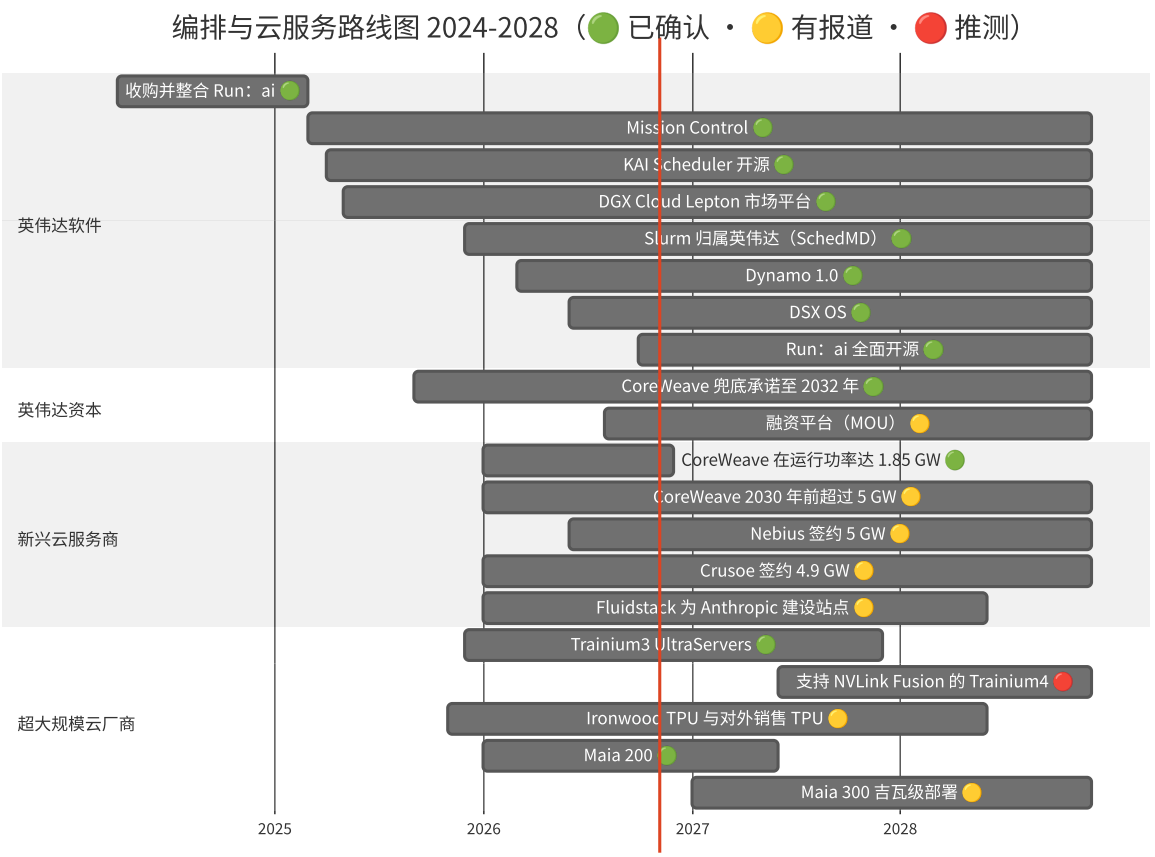

条形表示可用期或建设窗口；无明确终点的项目延伸至图表边缘。Trainium4 的时间未披露 🔴。各行来源见下表；未列入下表的条形：Run:ai [S476]、SchedMD/Slurm [S12000]、Trainium3 UltraServers [S90035]。

项目	时间窗口	状态	置信度	来源
英伟达 Mission Control（AI 工厂运维）	2025 →	已发货；v2.5 新增 Run:ai 管理的 Kubernetes 恢复功能	🟢	S12005,S12006
DGX Cloud Lepton	2025 →	市场平台；2026 年 1 月移除“抢先体验”字样	🟢 / 🟡	S598,S12529
DSX OS（KAI、Run:ai、NVCF、Grove、Dynamo……）	2026 →	在 GTC 台北发布	🟢	S12513,S12514
Run:ai 完整平台开源	2026-10 →	已发布；8 家合作伙伴正在集成	🟢	S12510,S12512
AI 算力融资平台（目标超过 $500B）	2026-08 →	谅解备忘录，尚待签订最终协议	🟡	S12528
CoreWeave 在运行功率超过 1.85 GW；2030 年前超过 5 GW	2026 / 2030	指引 / 规划	🟢 / 🟡	S12500,S472
Nebius 到 2026 年底签约约 5 GW，已接入 0.8–1 GW	2026 → 2029	指引	🟡	S12503
Crusoe 签约约 4.9 GW，已通电约 0.2 GW	2026 →	二手数据	🟡	S12013
Anthropic 与 Fluidstack 合作投资 $50B 建设美国数据中心	2026 →	已宣布	🟢	S12524
Trainium4（支持 NVLink Fusion）	AWS 未给出时间（2025-12 宣布；图中暂按 2027–28 年标示）	已宣布	🟢 产品 / 🔴 时间	S90034
Maia 300；自 2027 年起吉瓦级 Maia 部署	2027 →	已宣布 / 有报道	🟡	S90046,S90045

> **提示**
>
> **算例 —— 超大规模云厂商的资本开支有多少能流向英伟达。** 英伟达首席执行官称，一座 1 GW 的 AI 工厂全口径成本约 $50–60B，其中英伟达产品约 $35B（58–70%）[S398]。将这一比例应用于四大厂商 2026 年约 $728B 的指引（本资料库对最新中值的加总 🟡）[S12518,S12519]，可得英伟达可触及支出的上限约为 $420–510B。作为对比，按英伟达 Q3 FY2027 $108B 的指引计算，年化约为 $432B [S3]。这只是上限：超大规模云厂商的资本开支还要用于购买土地、建筑、CPU，以及其自研的 TPU、Trainium 和 Maia 🔴。

容量与积压订单的演进

Alphabet, Amazon and Meta first guided ~$505B of 2026 capex, 4.0× their $127B in 2022; guides have since risen to ~$558B

Capex, US$ B per fiscal year; 2026 = first guidance (Jan–Feb 2026); dashed/hollow = outlook or unverified; MSFT FY ends Jun (ex-leases), Oracle May

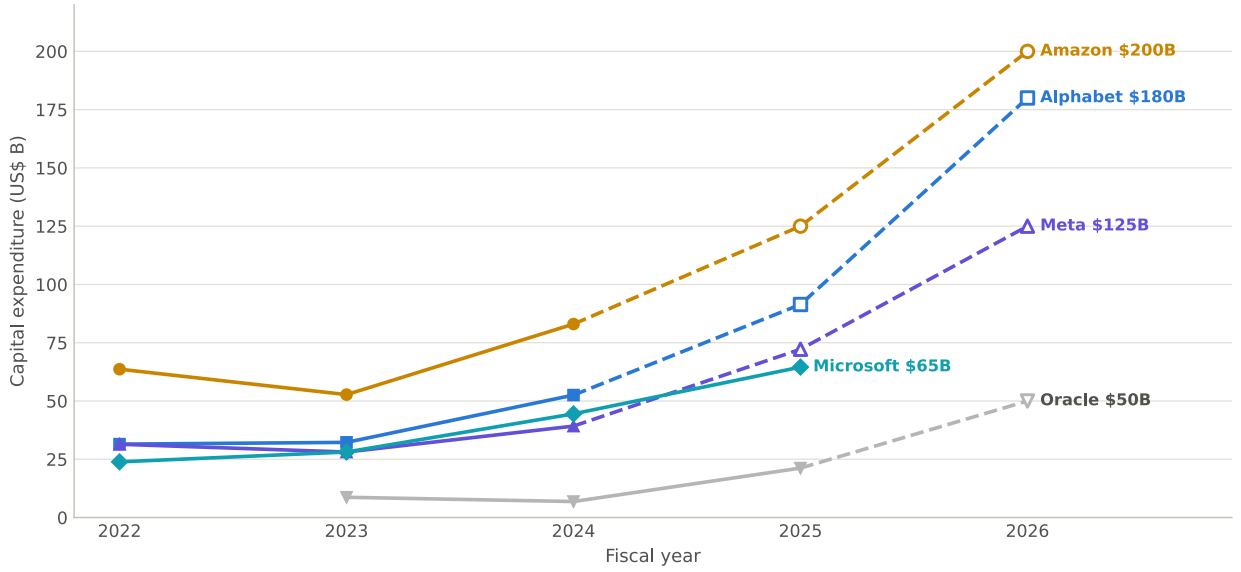

Latest 2026 guide midpoints (Jul–Oct 2026): Big 3 ~$558B

Source: data from company 10-Ks and outlooks [S455] [S460] [S456] [S461] [S457] [S462] …; chart by repo · As of 2026-11-05

2022–2026 年超大规模云厂商资本开支折线图：Alphabet、亚马逊和 Meta 合计从 2022 年的 $127B 升至其 2026 年首次指引的约 $505B（亚马逊约 $200B、Alphabet 中值约 $180B、Meta 中值约 $125B），到 2026 年 10 月已上调至约 $558B；微软 FY2025 达到 $65B，甲骨文 FY2026 指引约 $50B。

这些 2 月份的指引（三大厂商约 $505B）此后均已上调；Alphabet 在 7 月上调至 $195–205B，并预计 2027 年资本开支将再度增长 🟡 [S12518]。

CoreWeave's contracted backlog rose 3.5× in a year to $104B, ~8× its 2026 revenue guide

Revenue backlog (remaining contracted revenue) at quarter end, US$ B; hatched = derived from reported growth rate

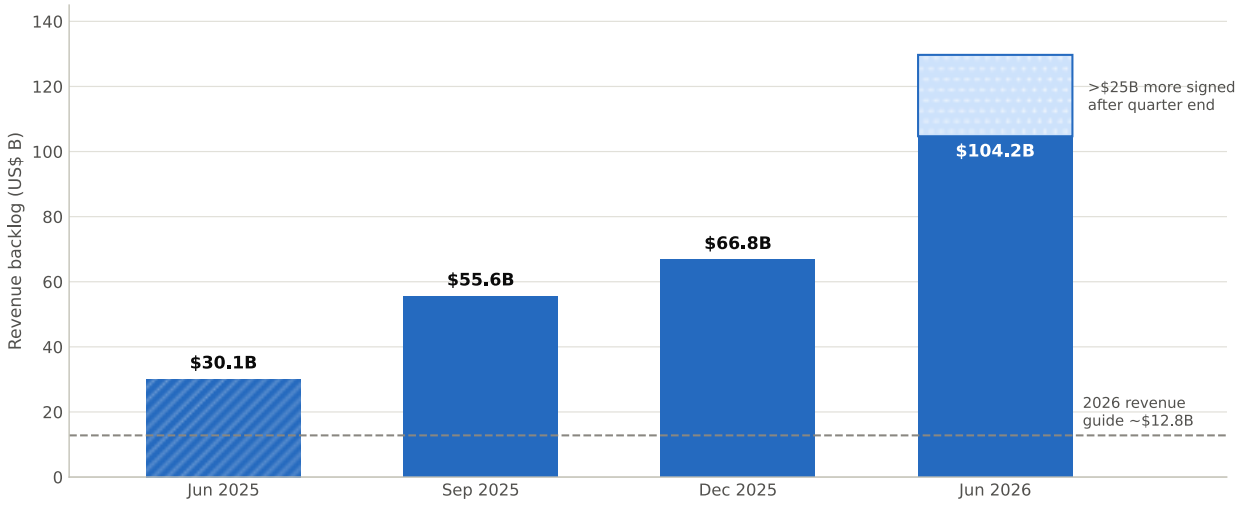

Backlog = signed contracts, not cash

Source: data from CoreWeave results as reported [S12500] [S12536] [S12012]; chart by repo · As of 2026-11-05

CoreWeave 收入积压柱状图：2025 年 6 月约 $30.1B（由报告的 246% 增速推算），2025 年 9 月 $55.6B，2025 年 12 月 $66.8B，2026 年 6 月 $104.2B，季度结束后又签订了超过 $25B 的新承诺；2026 年 6 月的积压订单约相当于其 2026 年 $12.4-13.2B 收入指引的 8 年。客户包括 OpenAI、Meta 和微软。

提示

算例 —— 把积压订单换算成电力与资本开支。 CoreWeave 2026 年收入指引为 $12.4–13.2B，年初在运行功率约 0.85 GW，年底超过 1.85 GW [S12500,S12012]。按约 1.35 GW 的平均值计算，每在运行 GW·年约产生 $9–10B 收入（本资料库测算 🔴）。按此速度消化 $104B 的积压订单，需要约 11 GW·年的在运行容量：相当于约 2.2 GW 运行五年，高于 2026 年底 1.85 GW 的目标。按每 GW 全口径约 $50–60B 计算，每增加 1 GW 的成本就超过 CoreWeave 2026 年 $35–39B 的全部资本开支预算 [S398,S12500]。积压订单转化为收入的速度，取决于融资能跟上多快。

🔧 技术细节：如何解读新兴云服务商的容量披露

在运行（或已接入）功率是指已通电并开始计费的容量。**签约**功率是与房东或电力公司签订、将于未来交付的容量。积压订单则是已签约但尚未确认的客户收入。三者推进速度不同：CoreWeave 在 2025 年底签约约 3.1 GW、在运行超过 850 MW，到 2026 年 6 月签约约 3.7 GW、在运行约 1.5 GW [S12012,S12501]。签约与在运行之间不断扩大的差距，就是仍需融资的建设量。应关注积压订单与签约 GW 之比：该比值下降意味着容量建设正跑在客户前面。参见签约功率与在运行功率。

[Q7 · 路线图与变数]

[Q7 · 路线图与变数] 英伟达自身的第 12 层路线图（开放软件、市场平台、融资工具）风险较低；风险在于其买方。值得关注的信号：

- **资本开支暂停。** 由于第三方容量交付延迟，微软已将其 2026 日历年数字从约 $175B 下调至约 $170B 🟡 [S12518,S12519]。若四大厂商中有两家下调 2027 年指引，首先受冲击的将是新兴云服务商的租赁业务，因为超大规模云厂商把它们当作溢出容量 [S12526]。
- **GPU 租赁价格崩跌。** H100 租金从约 $8（2023 年）跌至交易平台上的不足 $2（2024 年底），随后到 2026 年 3 月反弹 38% 至 $2.35 [S393,S12516]。若随着 Rubin 放量而再次跌破 $1.70 的低点，将削弱 GPU 抵

押贷款背后的抵押品价值（参见价值链）。

- **新兴云服务商信贷压力。** CoreWeave 2026 年第二季度的净利息支出为 $640M，债务规模 $35.1B，并给出第三季度 $860–940M 的指引 [S12501,S12502]。CoreWeave 将于 2026-11-16 发布第三季度业绩，晚于本页的数据截止日 [S12500]。
- **超大规模云厂商自研芯片放量。** Maia 300（2027 年）、Trainium4 和对外销售的 TPU 会转移需求，而英伟达在第 12 层的杠杆对此无能为力 [S90046,S90034,S90027]。
- **融资平台落地或停滞。** 如果超过 $500B 的谅解备忘录变成签约资金，新兴云服务商的资本成本将下降；如果没有，针对循环融资的批评将更加尖锐 [S12528]。

> **提示**
>
> **算例 —— 以利息覆盖作为预警指标。** CoreWeave 给出的 Q3 2026 收入指引为 $3.45–3.6B，利息支出为 $860–940M [S12502]。利息将吞噬约 24–27% 的收入，高于第二季度的约 25%（$2.58B 收入中 $640M）[S12501,S12500]。如果未签约容量的租赁价格下跌 20%，而债务仍在增长，这一比例可能超过 30% 🔴。到了这个区间，贷款方就会重新定价，兜底承诺也开始发挥作用。

🎯 企业发展视角

1. 战略团队每月应追踪哪个指标：超大规模云厂商资本开支指引、H100/B200 租赁价格指数，还是新兴云服务商的利息覆盖率？
2. 英伟达的融资平台尚为谅解备忘录。如果 GPU 抵押品价值下跌，谁承担第一损失：英伟达、资产管理公司，还是新兴云服务商？
3. Nebius（约 5 GW）和 Crusoe（约 4.9 GW）的签约功率远超其在运行容量。哪些加速器厂商能够分得尚未锁定的那部分容量？
4. 如果 2027 年 Maia 300、Trainium4 和对外销售的 TPU 大规模上量，哪些新兴云服务商会率先提供非英伟达算力，条件又是什么？

编排与云服务：价值链与企业发展视角

第 12 层 · 编排与云服务 · 约 15 分钟阅读 · 最后核实：2026-11-05

⚡ 要点速览

- **GPU 云的每一美元大部分流回了英伟达。** 在一座约 $50–60B 的吉瓦级 AI 工厂中，英伟达产品约占 $35B；按约 75% 的毛利率计算，其中约 $26B 为英伟达的毛利（估计）[S398,S405]。
- **风险由新兴云服务商承担。** CoreWeave 计划的 2026 年资本开支约为其 2026 年收入的 2.9 倍，Nebius 约为 7 倍。CoreWeave 背负 $35.1B 债务，2026 年第二季度支付了 $640M 利息 [S12500,S12503,S12501]。
- **租赁价格是关键变量。** H100 租金从 2023 年下跌约 80%，于 2025 年 10 月触及 $1.70/小时的低点，随后到 2026 年 3 月上涨 38% 至 $2.35 [S393,S12516]。
- **英伟达与其客户的关联敞口合计约 $189B：** 约 $99B 的股权、约 $25B 的进一步股权承诺、$36B 的 AI 云容量协议和 $29B 的云服务协议。FY2026 收入为 $216B [S90072,S90069,S407,S1]。
- **关于循环融资的争论，正反双方都有道理。** H1 FY2027 的股权投资（$42.4B）约占上半年收入的 24%。然而，向五家客户承诺的约 $45B，仅约占其约 19 GW 规划中英伟达产品价值的 7% 🔴 [S90072,S403,S405,S398]。
- **[Q8 · 价值池与并购机会]** 尚待争夺的价值池是融资、IPO 前的新兴云服务商股权以及利用率工具；单纯的编排软件已经商品化。

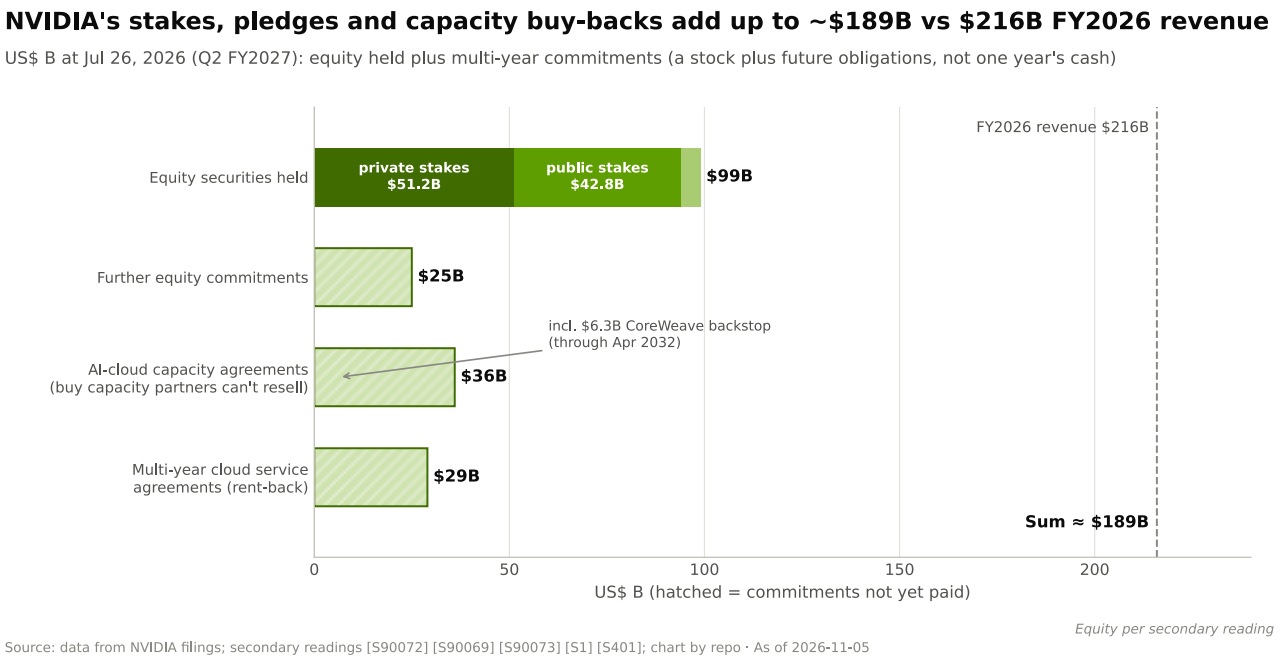

> 英伟达截至 2026 年 7 月与 AI 建设相关的资产负债表敞口水平堆叠柱状图：所持股权证券 $99B（有公开市场的 $42.8B、无公开市场的 $51.2B、处于锁定期的 $5B），进一步股权承诺 $25B，AI 云容量协议 $36B（购买合作伙伴无法转售的容量，含 $6.3B 的 CoreWeave 兜底承诺），多年期云服务协议 $29B，合计约 $189B，而 FY2026 收入为 $216B。与六家资产管理公司搭建的 $500B 融资平台属于第三方资本，未计入在内。

谁拿走了 GPU 云的每一美元

新兴云服务商（neocloud）是加了杠杆的 GPU 房东：它借钱购买英伟达系统，租用电力和厂房，再出租 GPU 小时。英伟达在交货时即收到货款；新兴云服务商则要靠多年租金收回成本（CoreWeave 对 GPU 服务器按六年折旧）[S386]。

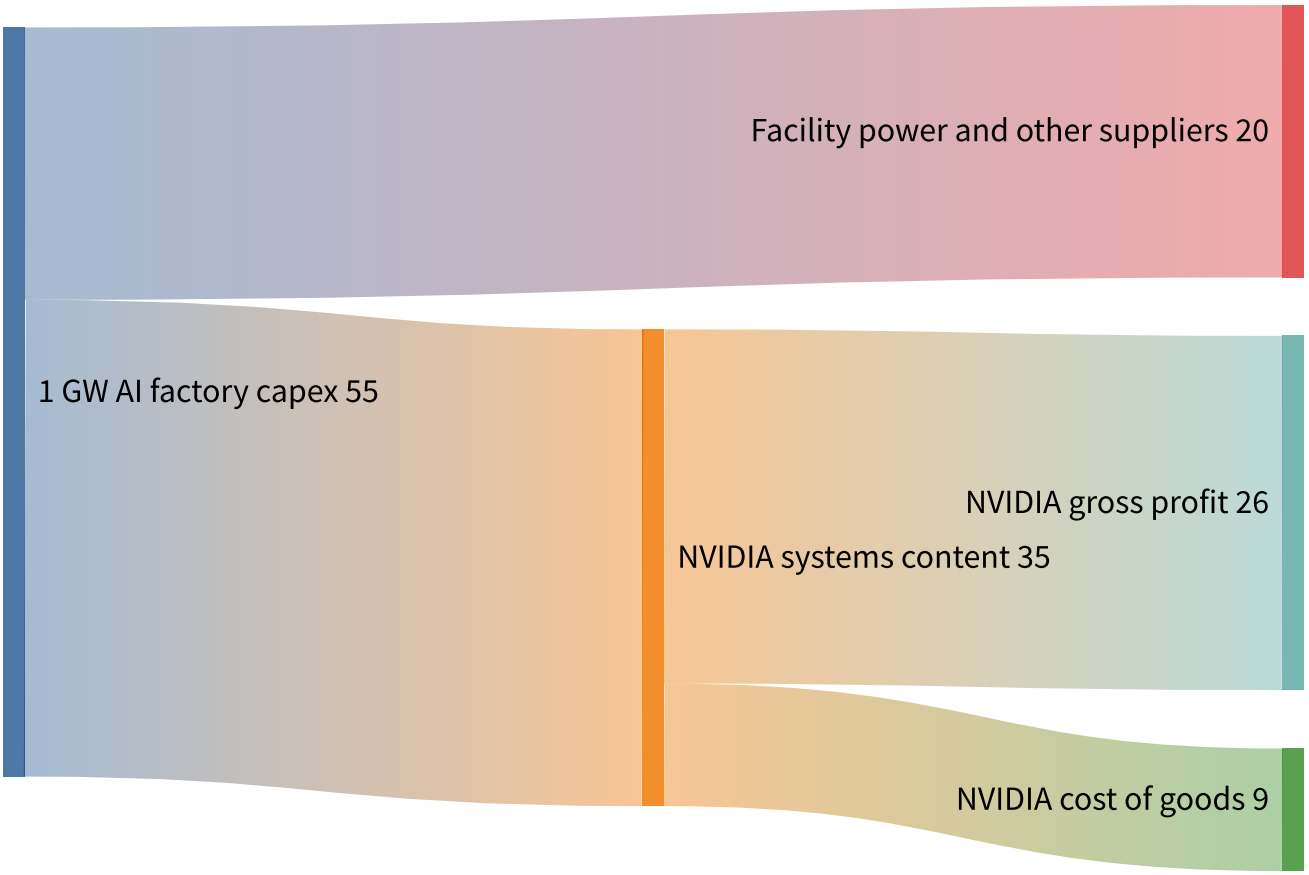

单位为每吉瓦十亿美元，估计 🔴：$55B 中值与 $35B 英伟达产品价值量依据英伟达首席执行官的说法 [S398]；毛利按 Q2 FY2027 约 75% 的 GAAP 毛利率计算 [S405]。销货成本涵盖台积电、HBM 厂商和 ODM（第 03 层）。

Neoclouds plan $2.9 (CoreWeave) to $7.0 (Nebius) of 2026 capex per $1 of 2026 revenue

Company guidance for calendar 2026, US$ B (bar = midpoint, whisker = range); CoreWeave backlog shown for scale

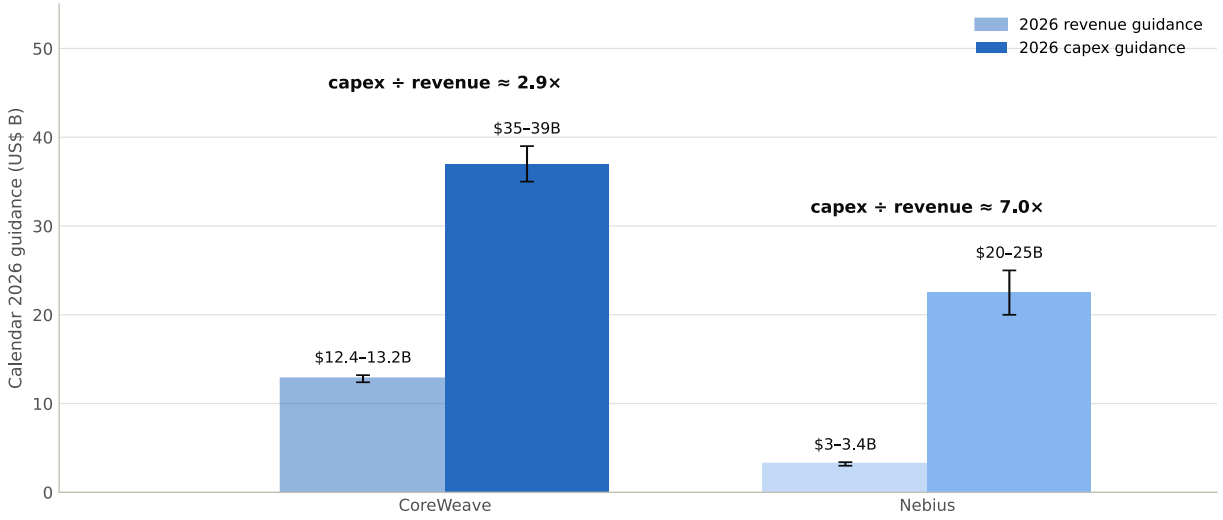

Guidance as of Aug 2026

Source: data from CoreWeave and Nebius Q2 2026 results [S12500] [S12503] [S12504] [S12536] [S12012]; chart by repo · As of 2026-11-05

2026 年指引分组柱状图：CoreWeave 收入 $12.4–13.2B，资本开支 $35–39B（每 1 美元收入约对应 2.9 美元资本开支），收入积压 $104.2B；Nebius 收入 $3.0–3.4B，资本开支 $20–25B（约 7.0 比 1）。缺口由债务、客户预付款和股权填补，因此融资条件决定了新兴云服务商的经济性。

H100 rentals rose 38% from a $1.70/hr low (Oct 2025) to $2.35 by Mar 2026

H100 rental price observations by series, US$ per GPU-hour (different contract types: compare within a series)

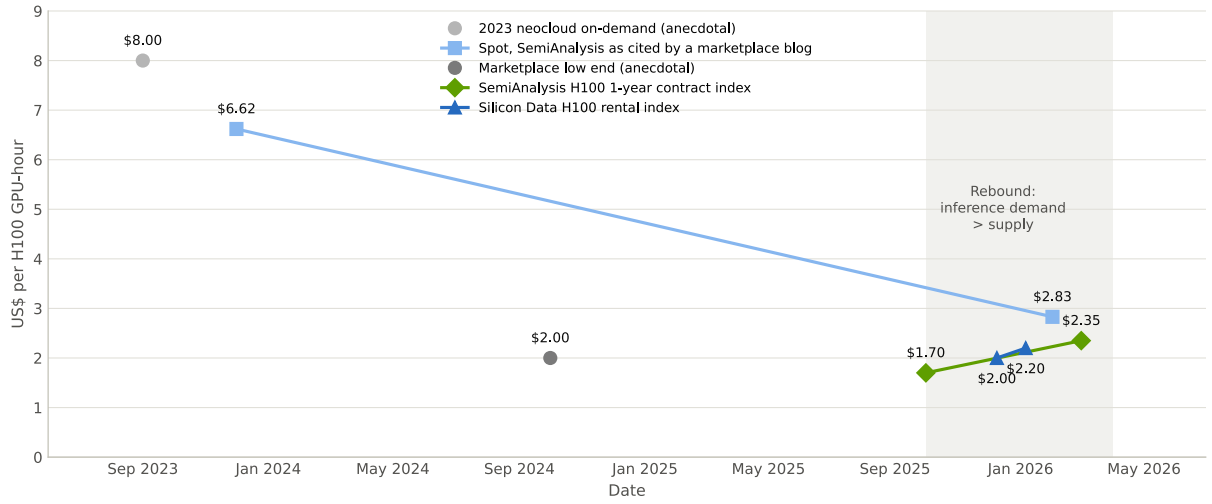

Mixed contract types; 2023–24 points are anecdotal

Source: data from SemiAnalysis, Silicon Data, Latent Space as cited [S393] [S12531] [S12516] [S12517]; chart by repo · As of 2026-11-05

H100 租赁价格折线与散点图：2023 年 9 月新兴云服务商约 $8/GPU 小时，2023 年底现货 $6.62，到 2024 年 10 月交易平台约 $2；随后 SemiAnalysis 一年期合同价格指数在 2025 年 10 月触及 $1.70 的低点，2026 年 3 月升至 $2.35（+38%）；Silicon Data 指数在 2025 年 12 月至 2026 年 1 月间从 $2.00 升至 $2.20；2026 年 2 月有引用的现货价格为 $2.83。由于推理需求超过供给，旧 GPU 被重新上调定价。

提示

算例 —— 2026 年的反弹对一颗旧 GPU 意味着什么。 按 $2.35/小时的一年期合同价，一颗出租率 85% 的 H100 每年可收入约 $17.5K（2.35 × 8,760 × 0.85）[S12516]。相对于约 $25–30K 的购置价，仅 GPU 本身的回本期约为 1.5 年，而在 2023 年约 $8/小时的价格下只需约 4–5 个月 [S356,S393]。三年机龄的 Hopper 机群在 2026 年反而比 2025 年更值钱，从而支撑了新兴云服务商债务背后的抵押品价值。

新兴云服务商融资：合同、GPU 抵押贷款与兜底承诺

其运作方式类似项目融资。AI 实验室或超大规模云厂商签订多年期照付不议（take-or-pay）合同（包销协议）；新兴云服务商将合同和 GPU 装入特殊目的载体（SPV），以两者为抵押借款（GPU 抵押贷款）。第三方进一步压低利率：英伟达通过购买未售出容量（容量兜底承诺），谷歌则通过为 Fluidstack 与 TeraWulf（约 $3.2B）和 Cipher（约 $1.4B）的租约提供担保来换取股权 [S90067,S12525]。

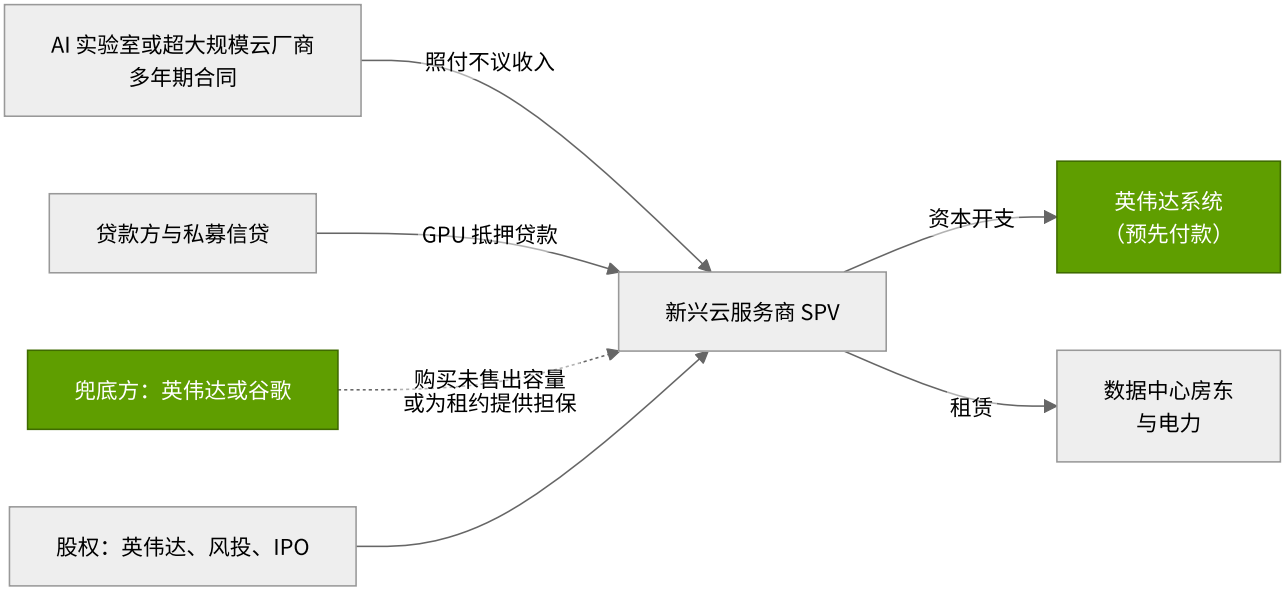

提示

算例 —— 一句话看懂 CoreWeave 的一个季度。 2026 年第二季度，CoreWeave 确认收入 $2.58B、净利息支出 $640M、净亏损 $626M，其 $46.7B 的净物业及设备主要由 $35.1B 的债务提供资金[S12500,S12501]。每一美元收入中约有 25 美分被利息吃掉。贷款方承保的是 $104.2B 的积压订单；兜底承诺与六年折旧期让这笔账得以算平[S12500,S90067,S386]。

🔧 技术细节：为什么 GPU 折旧年限如此重要

一颗 $70K 的 GPU 按六年折旧每年约 $11.7K，按四年则约 $17.5K：50% 的差距，在约 $2–3/小时的租价下足以决定盈亏。CoreWeave 采用六年，与微软和 Alphabet 的服务器寿命一致[S386,S382,S383]。批评者认为 GPU 一年一代的更新节奏会缩短其经济寿命；而在算力稀缺期间，2026 年 Hopper 租金的反弹则给出了相反的论据[S12516]。

循环融资之争

英伟达投资于购买其 GPU 的公司，为其容量提供担保，并从它们那里租回算力。这究竟是构建生态，还是制造需求？以下分别给出双方最有力的论证：

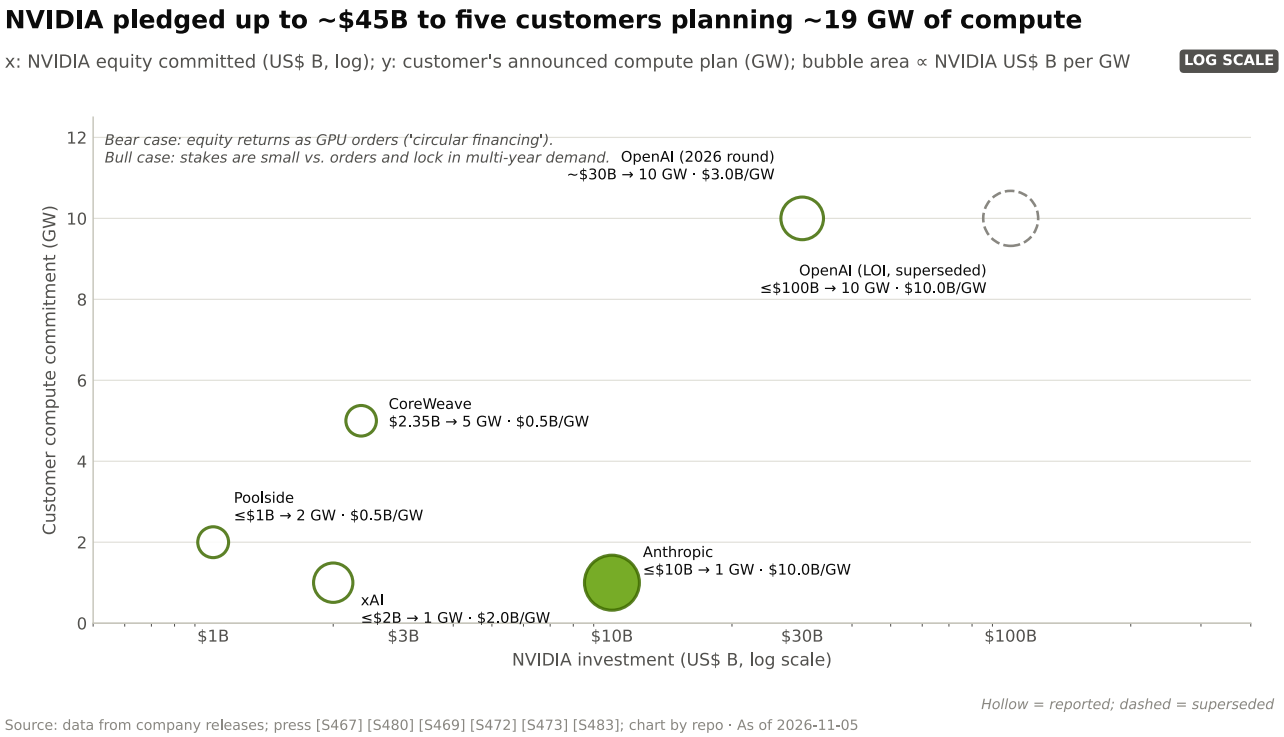

英伟达对客户投资的气泡图：OpenAI（2026 年约 $30B，此前曾签署与 10 GW 挂钩、最高 $100B 的意向书）、Anthropic（最多 $10B，最多 1 GW）、CoreWeave（$2.35B 股权，规划超过 5 GW）、xAI（最多 $2B，约 1 GW）和 Poolside（最多 $1B，2 GW）。合计约 $45B，对应约 19 GW，这正是循环融资争论的核心。

NVIDIA's private stakes grew 15× in 18 months to $51B; all stakes ~$99B

Carrying value of equity securities, US$ B, Jan 2025 - Jul 2026; hatched = secondary reading of the 10-Q

Source: data from NVIDIA 10-K/10-Q and secondary readings [S13043] [S90070] [S90072] [S90069] [S90073]; chart by repo · As of 2026-11-05

英伟达无公开市场（私募）股权证券柱状图：2025 年 1 月底 $3.4B，2026 年 1 月底 $22.3B，2026 年 4 月 $42.3B，2026 年 7 月 $51.2B，18 个月内增长约 15 倍。最后一根堆叠柱再加上 $42.8B 有公开市场的股权和 $5.0B 处于锁定期的公开股权，2026 年 7 月合计约 $99B。H1 FY2027 股权投资为 $42.4B，而上年同期为 $1.2B；其余增长大多来自按市值计价的收益。

注意

🐻 **看空观点（最强版本）。** 1. **规模。** 股权投资从 $1.2B（H1 FY2026）跃升至 $42.4B（H1 FY2027），约占 H1 FY2027 收入 $177.8B 的 24% [S90072,S403,S405]。 2. **盈利质量。** Q1 FY2027 $58.3B 的净利润中包含约 $15.9B 的其他收益，主要是未实现的按市值计价（mark-to-market）收益，在下行周期中会反转 [S403]。 3. **容量回购。** 英伟达已同意购买 $36B 合作伙伴无法转售的 AI 云容量，外加 $29B 的云服务承诺 [S407]。其客户的利用率中有一部分来自英伟达自己。 4. **集中度。** 三家直接客户分别占 H1 FY2027 收入的 16%、15% 和 13%，而 OpenAI、Anthropic 和 CoreWeave 等大买家同时也是被投资方 [S90069,S90015,S90075,S472]。 5. **历史惊人地相似。** 1999–2001 年，电信设备商为运营商提供融资，而后者的需求随即消失；供应商融资把一次放缓变成了一场崩盘 🟡 [S90074]。高盛如今谈论以英伟达算力为抵押的信贷：这种抵押品的租金曾在两年内下跌约 80%，之后才反弹 [S12528,S12516]。

注

🐂 **看多观点（最强版本）。** 1. **相对于其撬动的规模而言很小。** 向五家客户承诺的约 $45B 支撑着约 19 GW 的规划。按每 GW 约 $35B 的英伟达产品价值计算，潜在产品价值约为 $665B，因此这些股权投资相当于约 7% 的“返利” 🔴 [S398]。 2. **具有战略意义。** 非超大规模买方（ACIE）在 Q2 FY2027 数据中心收入中约占 $40.3B；支持它们可以降低对自研 ASIC 的超大规模云厂商的依赖 [S406]。 3. **需求体现在价格上。** H100 租金在五个月内上涨 38%，容量已被预订至 2026 年 9 月，英伟达的展望是受供应约束 [S12516,S90012]。 4. **风险正在转移给第三方。** 融资平台的目标是从六家资产管理公司调动超过 $500B 资金，而非动用英伟达的资产负债表 🟡 [S12528]。 5. **大家都在这么做。** 谷歌为 Fluidstack 的租约提供兜底；AMD 向 OpenAI 授予了最多 1.6 亿股的认股权证 [S12525,S13506]。

> **提示**
>
> **算例 —— 估算这笔“返利”的大小。** OpenAI 约 $30B 是单笔最大的股权投资 S90015。如果 OpenAI 基于英伟达的项目达到 10 GW，按每 GW $35B 计算英伟达产品价值约为 $350B，则这笔投资约相当于该潜在收入的 8.6% S398。若只有 3 GW，同样的投资占比约为 29% 🔴。争论的焦点是部署风险，而非会计处理：只有当这些吉瓦真正落地时，这一比例才显得无害。

结论 🔴： 双方在不同的时间维度上各有道理。在算力稀缺时，英伟达的支持能以低成本加速建设；在下行周期中，它会让英伟达成为其最弱客户的债权人。预警信号见路线图页面；另见看空情景和第 13 层。

值得关注的私营公司

仅基于公开信息；部分估值来自媒体报道。

公司	业务	阶段 / 最近一轮公开融资	为何重要
Crusoe	吉瓦级 AI 园区（Abilene）及 GPU 云	F 轮 $3.9B，投后估值 $30.9B（2026 年 9 月）🟡；签约约 4.9 GW 🟡	最大的私营 AI 工厂建设商；正在采用开源 Run:ai S12522,S12013,S12512
Lambda	面向开发者的 GPU 云；与微软签有合同	正寻求约 $4B 的 IPO 前融资，目标投前估值约 $14.5B（2026 年 10 月）🟡	英伟达既是投资方又是租户（约 $1.5B 回租） S12521,S483
Nscale	英国/欧洲新兴云服务商	C 轮估值 $14.6B（2026 年 3 月）；$3.36B IPO 前可转债（2026 年 9 月）	主权 AI 与超大规模云厂商溢出需求标的 S12520,S12526
Fluidstack	负责 Anthropic 在美国 $50B 的建设项目	以 $7B 估值融资超过 $750M（2026 年 4 月）；据报道正以约 $18B 估值洽谈 🟡	由谷歌兜底：一种非英伟达的融资范本 S12523,S12524,S12525
Together AI	开源模型推理云	B 轮 $305M，估值 $3.3B（2025 年）	Dynamo 采用者及 Lepton 合作伙伴 S12522,S90066,S12008
VAST Data	面向 GPU 云的存储/数据平台	F 轮约 $1B，估值 $30B（2026 年 4 月）；正考虑 IPO	每家新兴云服务商都需要的存储层（第 07 层） S7513,S7512
SF Compute、Vast.ai	GPU 交易平台	私营；未找到近期公开估值	价格发现；闲置容量套利 S393

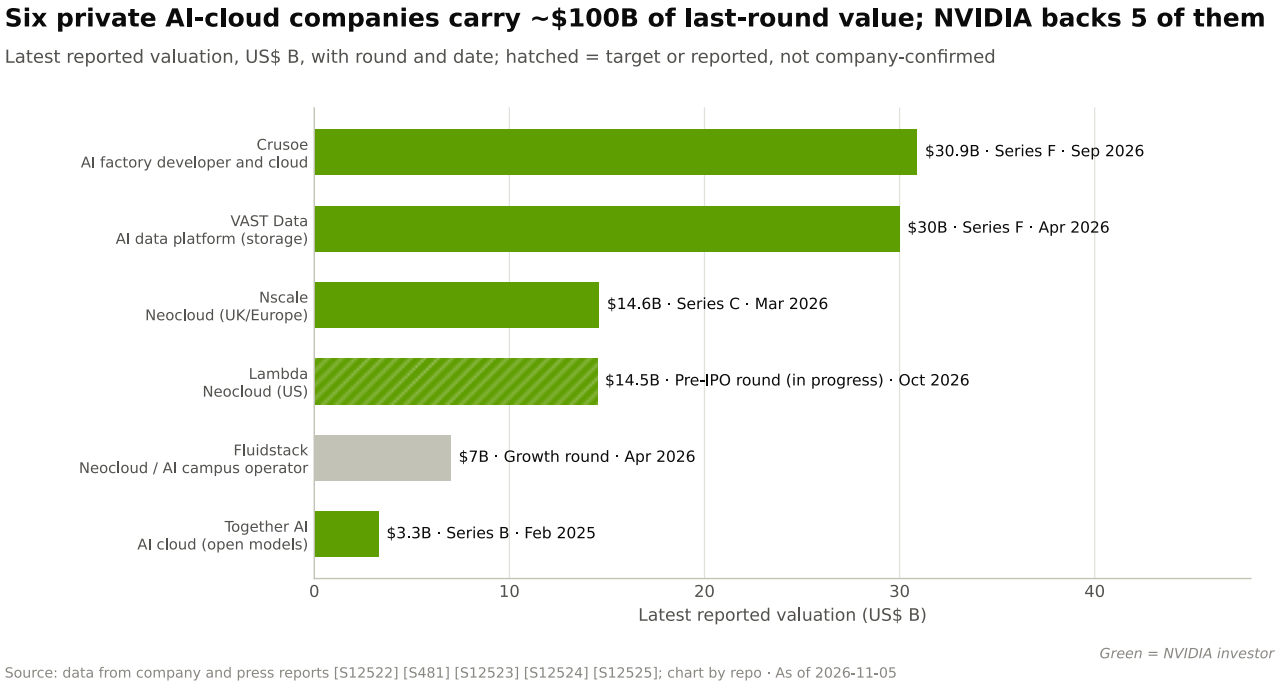

私营 AI 基础设施公司估值水平柱状图：Crusoe $30.9B（F 轮，2026 年 9 月）、VAST Data $30B（F 轮，2026 年 4 月）、Nscale $14.6B（C 轮，2026 年 3 月，另有 $3.36B IPO 前可转债）、Lambda 约 $14.5B（IPO 前目标，2026 年 10 月）、Fluidstack $7B（2026 年 4 月，租约由谷歌兜底）以及 Together AI $3.3B（2025 年）。英伟达投资了其中 5 家；数家正在筹备 IPO。

本层的并购历史

年份	收购方 → 标的	金额	收购所得	来源
2022	英伟达 → Bright Computing	未披露	集群管理器（现为 Base Command Manager）	S478
2024	英伟达 → Run:ai	约 $700M（据报道）	Kubernetes GPU 资源池化；2025–26 年开源	S476,S12510
2024	英伟达 → Shoreline.io；Brev.dev	约 $100M（据报道）；未披露	机群自动化；开发者入口	S478,S479
2025	英伟达 → Lepton AI	“数亿美元”（据报道）	DGX Cloud Lepton 市场平台的基础	S479,S598
2025	CoreWeave → Weights & Biases	约 $1.7B（据报道）	实验追踪与 MLOps 用户群	S12507,S12506
2025	CoreWeave → Core Scientific	约 $9B 全股票交易，**遭股东否决**	自有数据中心站点	S12508
2025	英伟达 → SchedMD（Slurm）	未披露	HPC/AI 默认批处理调度器	S12000

> **提示**
>
> **算例 —— 为什么这一层的软件估值倍数存在天花板。** 英伟达花约 $0.7B 收购 Run:ai，随后将其免费开放 S476,S12510。CoreWeave 收购 Weights & Biases 的约 $1.7B，仅约为其 $104.2B 积压订单的 1.6% S12507,S12500。在这里，软件的价值取决于它能为 GPU 小时销售带来多少增量，而非其授权收入。

[Q8 · 价值池与并购机会]

[Q8 · 价值池与并购机会] 有四个价值池尤为突出：

1. **为建设提供融资。** 新兴云服务商的资本开支是收入的 3–7 倍，因此谁能为 GPU 抵押信贷和兜底承诺定价，谁就能赚取利差。英伟达、谷歌和私募信贷已经入场 S12500,S12503,S12528,S12525。
2. **IPO 前的新兴云服务商股权。** Crusoe、Lambda 和 Nscale 正走向公开市场，按最近一轮计算合计估值约 $60B 🟡 S12522,S12521,S12520。
3. **利用率工具。** 调度器是免费的，但故障恢复、多云中介和推理端点仍能把闲置的 GPU 小时转化为收入（竞争格局）。
4. **硬件中立的容量。** 运行非英伟达加速器的新兴云服务商需要中立的软件（Kueue、Ray、SkyPilot，或可移植性软件栈，例如高通以约 $3.9B 收购、于 2026-07-29 完成交割的 Modular 平台 S9511）S12533,S12535,S12534,S90057。

🎯 企业发展视角

1. 加速器厂商能否通过为其 GPU 提供兜底承诺或残值担保来赢得新兴云服务商的容量？这会对其资产负债表产生什么影响？
2. 哪些已签约但尚未建成电力容量的新兴云服务商会试用第二种加速器？硬件可移植的软件栈（如高通现已拥有的 Modular）是否会是前提条件？
3. 在 Run:ai、KAI 和 Slurm 都已免费的情况下，哪些编排或 MLOps 资产仍能获得溢价？又是谁愿意支付这一溢价（云厂商、芯片厂商、私募股权）？
4. 应如何对英伟达约 $189B 的关联敞口进行压力测试：租赁价格情景、客户违约，还是按市值计价的反转？

第 13 层 —— 生态、市场进入与资本

第 13 层 · 12 层技术栈的最顶层 · 开发者、初创企业、主权与企业渠道、资本部署 · 约 8 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **本层把英伟达的技术转化为订单：**涵盖 CUDA 开发者（~6M，自 GTC 2025 以来持平 [S536,S528]）、初创企业、各国政府、企业客户，以及为买方提供资金的资本。
- **开发者漏斗顶部持续扩大：**GTC 参会人数从 2009 年的 ~1,500 人增长到 2026 年预计的 >30,000 人，来自 >190 个国家和地区 [S13024,S13533]；NVIDIA Inception 到 2022 年覆盖 ~10,000 家初创企业 [S531]，据二手资料，到 2025 年已 >22,000 家 [S13536]。
- **主权 AI 已成为需求支柱：**FY2026 收入 > ~$30B（+80%）[S90071]，约占 $215.9B 的 ~14% [S1]。已公布的国家级交易合计涉及 ~1.03M 颗英伟达 GPU，以 HUMAIN（最多 600,000 颗）和韩国（260,000 颗）为首 [S13003,S13000]。
- **一半的数据中心需求不经过超大规模云厂商：**AI 云、工业与企业客户约 ~$40.3B，占 Q2 FY2027 数据中心收入的 45% [S406]；这部分需求通过 OEM、系统集成商和新兴云服务商（neocloud）触达，而非依靠庞大的直销团队。
- **英伟达已成为资本配置者：**其私有公司股权从 $3.4B（2025 年 1 月）增至 $51.2B（2026 年 7 月），全部股权持仓增至 ~$99B [S13043,S90072,S90073]，其中以对 OpenAI 的 ~$30B（🟡 有报道）[S90015] 和对 Anthropic 最多 $10B [S90075] 为最大。
- **弱点与看空情景：**这一闭环带有循环融资色彩，且高度集中。单一直接客户贡献了 Q2 FY2027 收入的 16% [S90069]；H1 FY2027 $23.7B 的股权投资净收益美化了利润 [S90072]；各国主权 GPU 计划远超已落地的确定订单 [S13514,S13516]。
- **本层最强挑战者：**竞争对手同样以资本和生态竞争。AMD 向 OpenAI 授予最多 160M 股的认股权证，与 6 GW 部署挂钩 [S13506]；谷歌向 Anthropic 供应最多 1M 颗 TPU [S90026]；HUMAIN 也与 AMD（500 MW）和高通（Qualcomm）（200 MW）签约 [S13517,S90030]。

Non-hyperscale buyers took ~$40B, 45% of Q2 FY2027 Data Center revenue

NVIDIA Data Center revenue by customer type, US$ B per quarter (new split from Q1 FY2027; rounded, per CFO commentary)

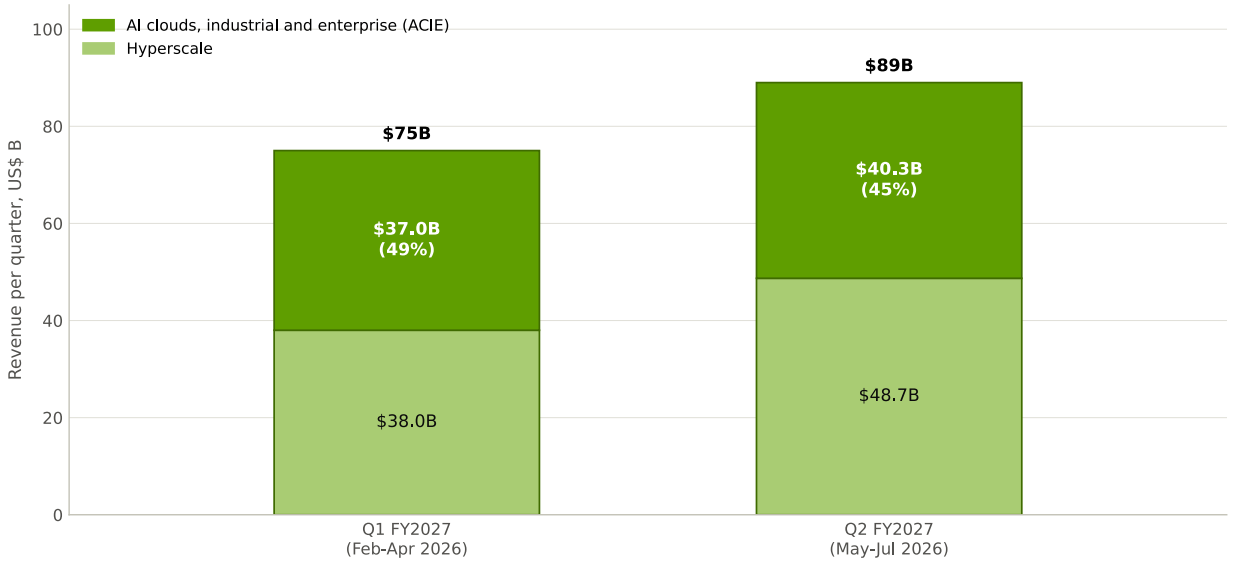

Source: data from NVIDIA Q1/Q2 FY2027 results and CFO commentary [S403] [S409] [S406]; chart by repo · As of 2026-11-05

英伟达数据中心收入按客户类型划分的堆叠柱状图：Q1 FY2027 超大规模云厂商约 $38B，AI 云、工业与企业客户（ACIE）约 $37B（49%）；Q2 FY2027 超大规模云厂商约 $48.7B，ACIE 约 $40.3B（45%）。通过合作伙伴和新兴云服务商触达的非超大规模买方已接近数据中心需求的一半。

本层的职能，以及薄弱时会出什么问题

[Q1 · 职能与失效后果] 第 02–12 层让 AI 工厂得以运转；第 13 层则决定谁来购买、购买速度多快、用谁的钱购买——通过开发者关系、主权交易、企业渠道和资本来实现。若本层走弱，买方无法为采购融资时供给将被搁置，收入会集中到自研芯片的超大规模云厂商手中，开发者也会流向可移植的技术栈，从而降低下方每一层的转换成本。

提示

算例 —— 以硬件衡量，“主权”市场有多大？ 一座 100,000 颗 GPU 的 GB300 工厂前期成本约 ~$8.5B，其中英伟达开票约 ~$5.3–6.1B（估计，见主权 AI）。因此英伟达 FY2026 > ~$30B 的主权收入 [S90071] 相当于**每年 ~5 座这样的工厂，约 ~525,000 颗 GPU**。国家级交易中已公布的 ~1.03M 颗 GPU [S13003,S13000,S13009] 大约相当于这一年化规模的两年量。🔴 本资料库测算。

[Q2 · 关键指标]

指标	最新数值	为何重要
非超大规模客户占数据中心收入比重	~45%（Q2 FY2027）[S406]	摆脱对自研芯片买方的依赖、实现多元化
主权收入	> ~$30B，+80%（FY2026）[S90071]	一个兼具政治与经济属性的需求来源
最大直接客户	占 Q2 FY2027 收入的 16% [S90069]	集中度与议价能力风险
持有股权	~$99B（2026 年 7 月）[S90073]	循环融资敞口的规模
注册 CUDA 开发者	~6M，自 2025 年以来持平 [S528]	软件锁定效应的领先指标

本层在技术栈中的位置

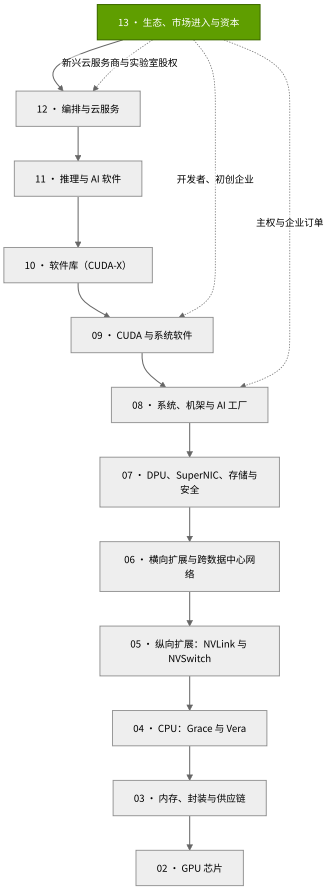

本层全景图

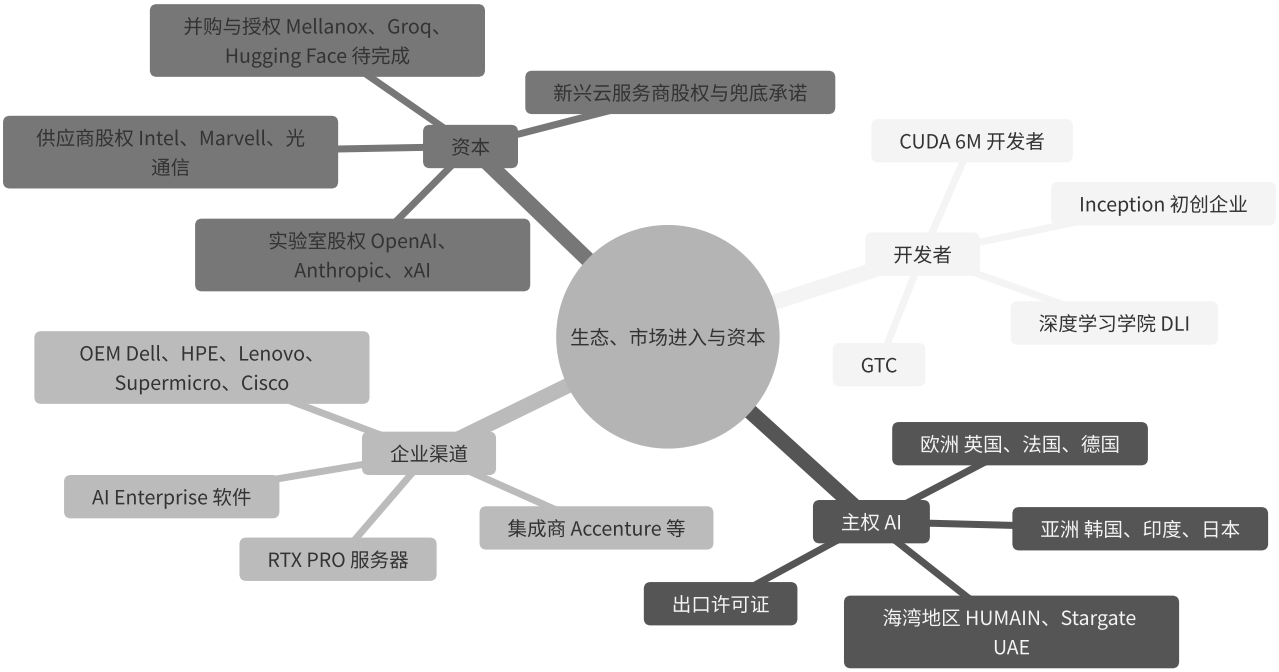

八个问题一览

#	问题	简要回答	详见
Q1	本层承担什么职能？薄弱时会出什么问题？	把技术转化为有资金支撑的需求；薄弱会导致供给搁置、收入集中	本页；开发者生态
Q2	关键指标有哪些？	非超大规模客户占比、主权收入、最大客户占比、股权投资组合、开发者数量	本页；资本部署
Q3	英伟达的供给如何改进？	GTC 增长 ~20×，Inception 到 2022 年增长 5×，交易金额从 ~$10B（2025 年之前累计）增至 2025 年的 ~$51B	开发者生态；资本部署
Q4	优势来源？	装机基础生态，加上竞争对手无法匹敌的资产负债表	发展历程与建成之路
Q5	最强挑战者？	超大规模云厂商生态（谷歌 TPU）以及 AMD 的“以股权换吉瓦”方案	竞争格局
Q6	复制成本？	数十年的开发者关系积累，外加 ~$100B 可部署资本	发展历程与建成之路
Q7	路线图与变数？	2026–27 年主权项目分期落地、第三方融资平台、GTC DC（2026 年 12 月）	路线图
Q8	价值池与并购机会？	渠道、融资与新兴云服务商股权；私有生态公司	价值链与企业发展视角

本层各页

页面	你将了解
开发者生态与 Inception	CUDA 开发者、GTC、DLI、Inception 与 NVentures 对比、从漏斗到需求
主权 AI	国家级交易、10 万 GPU 工厂的成本、出口管制
企业市场进入：OEM 与 GSI	渠道、RTX PRO 服务器、AI Enterprise 软件
资本部署	股权投资、兜底承诺、并购、股权投资组合、集中度
竞争格局	竞争对手的生态与资本方案
发展历程：英伟达如何建成	时间线、关键决策、复制成本、反事实推演
路线图	下一步是什么，以及什么会改变格局
价值链与企业发展视角	谁攫取了价值、私有公司、并购

🔧 技术细节：如何解读英伟达的客户披露

- **直接客户与间接客户。** 10-Q 会列出收入占比超过 10% 的*直接*客户（主要是 OEM 和 ODM），并*估算*其背后的云厂商和实验室 [S90069]。
- **超大规模与 ACIE。** 自 Q1 FY2027 起，数据中心收入拆分为超大规模云厂商，以及 AI 云、工业与企业客户（ACIE）两类 [S403]；管理层评论中的拆分数字为约数 [S406]。
- **主权并非一个报告分部。** > ~$30B 这一数字来自管理层评论 [S90071]，且与上述两类均有重叠。

🎯 企业发展视角

1. **护城河正沿技术栈上移。** 当竞争对手在硬件上逼近持平时，渠道、开发者和资产负债表承担起防御职能。挑战者可以“租用”哪些（云额度、集成商业务线），又必须自建哪些？
2. **融资已成为产品的一部分。** 英伟达 ~$99B 的股权持仓 [S90073]，以及 2026 年 8 月为撬动 >$500B 第三方资本而设立的融资平台 [S12528]，改变了赢得交易的方式。对资产负债表较小的公司而言，何种供应商融资姿态最为合适？
3. **主权买方采取多源采购。** HUMAIN 同时与英伟达、AMD 和高通签约 [S13003,S13517,S90030]。在哪些主权招标中，第二供应商比现有技术栈更能获得青睐？

4. **集中度是一把双刃剑**。 占比 16% 的直接客户 S90069 同样获得了议价筹码。哪些中端市场渠道（OEM、集成商、区域云厂商）仍未被充分覆盖？

主权 AI

第 13 层 · 生态、市场进入与资本 · 约 9 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **主权 AI 已成为需求支柱。** 管理层称 FY2026 主权收入 > ~$30B，增长 ~80% 🟡 S90071，约占英伟达 $215.9B 收入的 14% S1。
- **已公布的国家级交易合计涉及 ~1.03M 颗英伟达 GPU。** HUMAIN（沙特阿拉伯）计划在三年内于沙特和美国站点部署最多 600,000 颗 S13003。韩国为 260,000 颗 S13000，英国到 2026 年底最多 120,000 颗 S13009，印度 Yotta 20,736 颗 S13017，法国 Mistral 18,000 颗 S13011，德国电信（Deutsche Telekom）10,000 颗 S13014。
- **规划远远跑在确定订单之前。** HUMAIN 迄今的确定分期为 18,000 颗 GB300（2025 年 5 月）和 ~27,000 颗 GPU / 84 MW（2026 年 10 月）S13514,S13516。美国许可证最初将 HUMAIN 和 G42 各自限制在 35,000 颗 Blackwell 等效芯片 🟡 S13515。
- **一座 100,000 颗 GPU 的国家级 AI 工厂前期成本约 ~$8.5B（估计）。** 其中英伟达开票约 ~$5.3–6.1B，因此主权收入约相当于每年五座这样的工厂 🔴。
- **出口管制决定谁能购买。** 美国允许向获批的中国买方出售 H200，但需将 25% 的收入上缴美国政府 S90032。英伟达尚未确认任何 H200 收入，且业绩指引不含中国数据中心计算业务 S90081,S3。
- **看空情景：** 主权买方会对冲。HUMAIN 还与 AMD 签订最多 500 MW 的协议 S13517，与高通签订 200 MW 的协议 S90030。韩国的交易既未披露金额，也没有时间表 S13001。

Sovereign deals name ~1.03M NVIDIA GPUs; HUMAIN and Korea are 84% of them

GPUs named in country-level AI-factory announcements, May 2024 - Feb 2026; hatched = press-reported, solid = company-confirmed

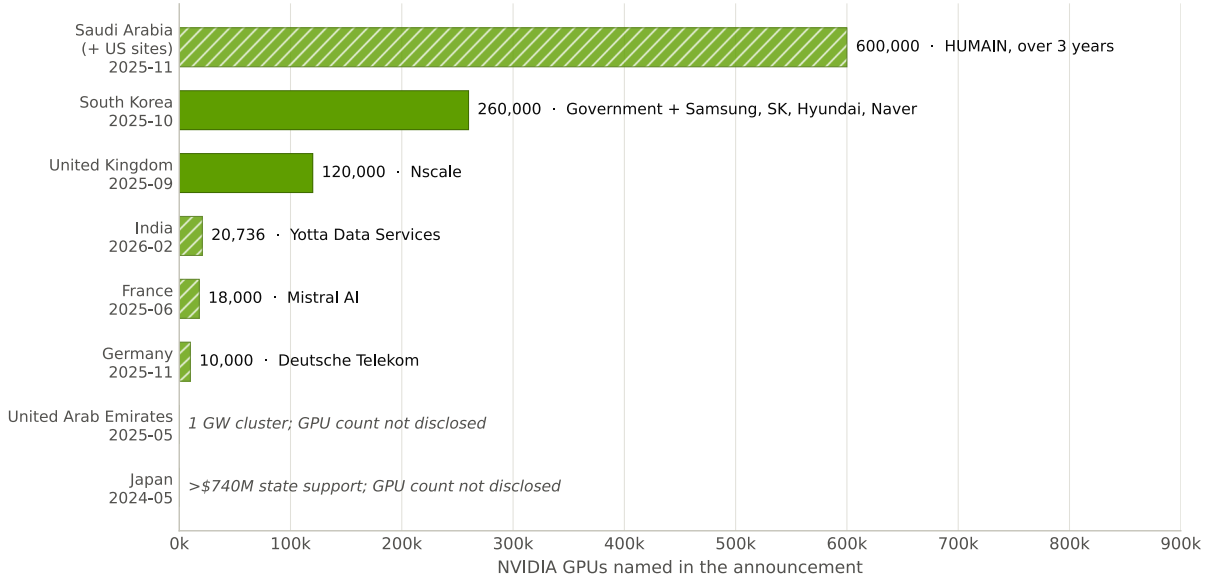

Source: data from NVIDIA and partner announcements and press [S13016] [S13007] [S13008] [S13011] [S13012] [S13009] ...; chart by repo · As of 2026-11-05

主权 AI 公告中涉及的英伟达 GPU 数量横向柱状图：沙特 HUMAIN 三年内最多 600,000 颗（分布于沙特和美国，2025 年 11 月），韩国 260,000 颗（2025 年 10 月：政府 50,000 颗，三星、SK 和现代各 50,000 颗，Naver 60,000 颗），英国到 2026 年底 120,000 颗，印度 Yotta 20,736 颗 B300，法国 Mistral Compute 18,000 颗 Grace Blackwell，德国电信 10,000 颗。合计约 1.03M 颗 GPU，其中 84% 来自沙特和韩国的交易。Stargate UAE（1 GW）和日本受补贴的云项目（>$740M）未披露 GPU 数量。

各国为何购买 AI 工厂

主权 AI 工厂类似于国家航空公司或电力公用事业：即便从美国云厂商租用更便宜，各国政府仍希望拥有本土算力，原因包括数据驻留、本地语言模型、产业政策和议价能力。建设方通常是国家龙头企业（HUMAIN、G42）、电信运营商（德国电信、SK）或本地新兴云服务商（neocloud）（Nscale、Yotta），并常以一家前沿实验室作为锚定租户：沙特的 xAI [S13004]，以及 Stargate UAE 和 Stargate UK 中的 OpenAI [S13007,S13010]。

英伟达出售的是整套方案（GPU、网络、参考设计、软件、本地 Inception 初创企业），从而把硬件销售变成国家级项目。

[Q2 · 关键指标] 对于主权需求，应关注四个数字，而非标题性的 GPU 数量：确定订单、已通电的兆瓦数、已发放的出口许可证，以及英伟达披露的主权收入。

> **提示**
>
> **算例 —— $30B 相当于多少颗 GPU？** 按每 100,000 颗 GB300 GPU 对应约 ~$5.7B 的英伟达价值量（下文估计区间的中值）计算，> ~$30B 的主权收入 [S90071] 可购买**每年 ~525,000 颗 GPU**。已公布的 ~1.03M 颗 GPU 约相当于两年的量。若像 HUMAIN 的计划那样分摊到三至五年 [S13003,S13005]，这一储备可以支撑当前的年化规模，但难以支撑太多增长。🔴 本资料库测算。

国家级交易逐一核查

国家	日期	建设方与合作伙伴	英伟达 GPU / 电力	状态与说明
沙特阿拉伯	2025-05 → 2026-10	HUMAIN（PIF）；xAI 为首个租户；AWS	三年内最多 600,000 颗（沙特 + 美国）；500 MW+ 站点 [S13003,S13004]	首批 GB300 于 2025 年 12 月发货 [S13006]；确定分期为 18,000 颗和 ~27,000 颗 [S13514,S13516]
阿联酋	2025-05-22	G42、OpenAI、甲骨文（Oracle）、思科（Cisco）、软银（SoftBank）（Stargate UAE）	基于 GB300 的 1 GW 集群；首批 200 MW 于 2026 年上线 [S13007,S13008]	未披露 GPU 数量；许可证最初上限为 35,000 颗 Blackwell 等效芯片 🟡 [S13515]
英国	2025-09-16	Nscale、CoreWeave、微软（Microsoft）、OpenAI（Stargate UK）	到 2026 年底最多 120,000 颗 Blackwell Ultra；最多 £11B [S13009]	Nscale 60,000 颗，其中 8,000 颗用于 Stargate UK [S13010]
法国	2025-06-11	Mistral AI（Mistral Compute）	18,000 颗 Grace Blackwell；40 MW 站点，可扩展至 100 MW [S13011,S13012]	2026 年全面部署
德国	2025-11-04	德国电信 / T-Systems、SAP、西门子（Siemens）	10,000 颗 Blackwell（DGX B200、RTX PRO）；~€1B [S13014,S13015]	2026 年在慕尼黑投运 [S13013]
韩国	2025-10-31	政府、三星、SK、现代、Naver Cloud	260,000 颗 Blackwell 系列 [S13000]	未披露金额与时间表 [S13001]；Naver 目标为吉瓦级规模（2026 年 6 月） [S13002]
印度	2026-02	Yotta，服务于 IndiaAI Mission 和 NVIDIA DGX Cloud	20,736 颗 B300；~$2B 🟡 [S13017,S13019]	据报道英伟达租用约一半；IndiaAI 总计运行 >38,000 颗 GPU [S13018]
日本	2024-05	KDDI、软银、Sakura Internet、GMO 等	> $740M 国家补贴 [S13016]	未披露 GPU 数量；2026 年项目的相关报道仅有单一来源 🔴

提示

算例 —— 以美元和兆瓦衡量韩国的 260,000 颗 GPU。 按每个 GB300 NVL72 机架 72 颗 GPU 计算，260,000 颗 GPU 约为 ~3,611 个机架。按每机架 ~$3.99M（估计，摩根士丹利）[S332]，即**约 ~$14.4B 的机架**。按每机架含网络约 ~145 kW [S340]、PUE 为 1.15 [S387,S388] 计算，需要 **~600 MW**。路透社报道称，该交易将使韩国的英伟达 GPU 保有量从 ~65,000 颗提升至 >300,000 颗 [S13513]。🔴 本资料库测算。

算例：一座 100,000 颗 GPU 的国家级 AI 工厂要花多少钱

Est.: a 100k-GPU national AI factory costs ~$8.5B; NVIDIA invoices ~63-71%

US$ B for 1,389 GB300 NVL72 racks, scale-out network, storage and a ~232 MW liquid-cooled facility; all values estimates

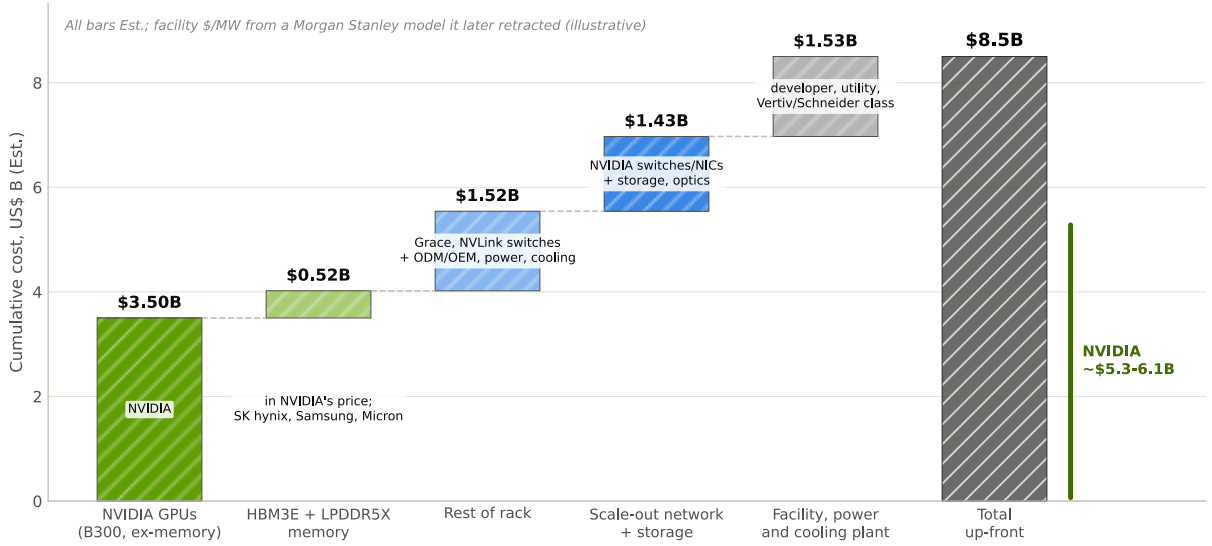

Source: data from analyst rack estimates, Uptime, EIA; repo model [S332] [S325] [S328] [S327] [S331] [S334] ...; chart by repo · As of 2026-11-05

瀑布图，估算由 1,389 个 GB300 NVL72 机架（每个约 $3.99M）构成的 100,000 颗 GPU 国家级 AI 工厂的前期成本：英伟达 GPU 约 $3.5B，HBM 与 LPDDR 内存约 $0.5B，机架其余部分（Grace CPU、NVLink 交换托盘、电路板、供电、散热、ODM 利润）约 $1.5B，横向扩展网络与存储约 $1.4B，~232 MW 的设施主体与电力设施约 $1.5B，合计约 $8.5B。英伟达开票估计为 $5.3-6.1B；电费每年另增 ~$164M。

提示

算例 —— 1,389 个机架的账单。 100,000 颗 GPU ÷ 72 = 1,389 个 GB300 NVL72 机架。每个约 ~$3.99M，其中 GPU 约 ~$2.52M、内存约 ~$0.37M（估计，摩根士丹利）[S332,S331]，机架合计 **~$5.5B**。横向扩展（scale-out）网络与存储约占整套集群的 ~20.5%（估计，SemiAnalysis）[S324]，增加 **~$1.4B**。按每机架 ~145 kW [S340]、PUE 1.15 计算，站点功耗为 **~232 MW**。按每 MW $6.6M（取自摩根士丹利一个后来撤回的模型，此处仅作示意）[S357]，设施主体与电力设施成本为 **~$1.5B**。合计 **~$8.5B**，另按 $0.081/kWh 计每年电费约 ~$164M [S389]。英伟达开票约 ~$5.3–6.1B（63–71%），具体取决于其供应多少 CPU、交换机和网络 🔴。

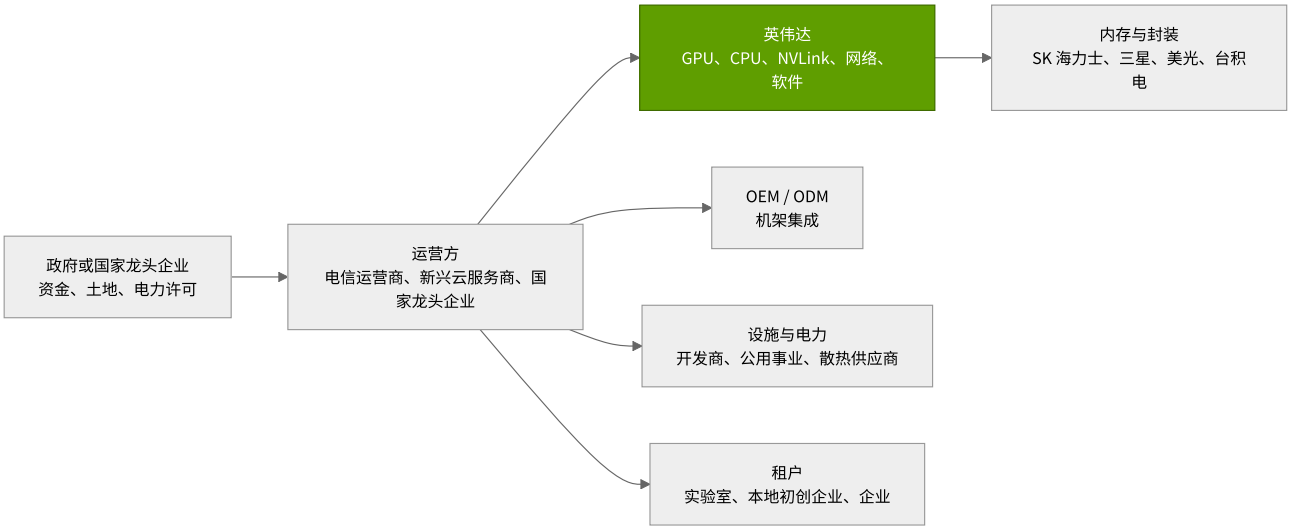

🔧 **技术细节：该估算未涵盖的内容**

- **平台选择。** 若采用每机架约 ~$7.8M（估计）的 Vera Rubin NVL72 [S330,S332]，同样 100,000 颗 GPU 仅机架就需 ~$10.8B，但每颗 GPU 的工作量要大得多。
- **设施成本。** 每兆瓦成本因站点差异很大；所用数字只是占位值。
- **软件与服务。** NVIDIA AI Enterprise 授权、集成商服务和模型开发叠加在其上（见企业市场进入）。

出口管制：主权 AI 的另一半

催生主权 AI 的逻辑，同样催生了出口管制：由美国决定哪些国家和买方能获得顶级 GPU，以及能获得多少。

- **中国。** 2025 年 4 月，美国要求 H20 级芯片须获得许可证，英伟达因此计提约 ~$4.5B 的费用 [S90081,S90082]。2025 年 12 月，美国允许向获批的中国买方出售 H200，但需将 25% 的收入上缴美国政府 [S90032]。英伟达于 2026 年 3 月收到采购订单 [S90033]，但尚未确认任何 H200 收入，其业绩指引仍不含中国数据中心计算业务 [S90081,S3]。
- **海湾地区。** 交易在获得美国批准后签署，但许可证是分批计量发放的：首批批准将 HUMAIN 和 G42 各自限制在 35,000 颗 Blackwell 等效芯片 🟡 [S13515]。
- **收入结构。** 总部不在美国的客户占 Q1 FY2027 收入的比重降至 22%，一年前为 42% [S90070]。

提示

算例 —— 25% 安排对利润率的影响。 假设对华 H200 销售额 $10B，毛利率 ~75%（英伟达 Q2 FY2027 的 GAAP 水平 [S3]）：毛利为 $7.5B。上缴 25% 的收入（$2.5B）后剩余 $5.0B，**有效利润率约 ~50%**，仍然盈利，但每颗芯片的利润比其他市场少三分之一。该上缴款项如何入账尚未披露 🔴。

注意

误区与事实：“主权 AI 是非周期性的政府支出。”许多交易由国家关联基金、电信运营商和新兴云服务商以租户合同为依托进行融资，并依赖可被撤销的美国出口许可证。韩国的公告既未披露价格，也未披露时间表 [S13001]。

🎯 企业发展视角

1. **主权招标中确实存在第二供应商需求。** HUMAIN 与 AMD（500 MW）和高通（200 MW）的协议与其英伟达计划并行 [S13517,S90030]。哪些主权项目会公开采购，使专注推理的机架能凭借功耗或价格胜出?
2. **运营方是控制点。** 电信运营商和新兴云服务商（德国电信、Nscale、Yotta、Naver）掌握客户。其中哪些可能为主权推理层引入一家挑战者?
3. **出口政策是摇摆因素。** 许可证上限和收入分成条款会随政府更迭而变化。交易模型应如何为签约后被收窄的许可证定价?
4. **关注确定订单，而非 GPU 数量。** HUMAIN 计划的 600,000 颗与约 ~45,000 颗确定订单之间的差距 [S13003,S13514,S13516]，正是竞争对手仍有空间之处。

开发者生态与 Inception

第 13 层 · 生态、市场进入与资本 · 约 8 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **CUDA 开发者数量增至三倍，随后标题数字不再变化。** 英伟达 2020 年统计的注册开发者为 2M，GTC 2025 时为 ~6M，GTC 2026 时引用的仍是 ~6M [S529,S536,S528]。
- **GTC 已成为行业展会。** 参会人数从首届 GTC（2009 年）的 ~1,500 人 [S13024]，增至 2025 年的 ~25,000 人现场加 ~300,000 人线上 [S13020]，2026 年预计 >30,000 人、来自 >190 个国家和地区 [S13533]，议程超过 500 场 [S13023]。
- **培训是引流渠道，而非一门生意。** 深度学习学院（Deep Learning Institute）在 2017 年提出培训 100,000 名开发者的目标 [S13031]，到 ~2020 年已培训 >200,000 人，并拥有 >550 名认证讲师 [S13032]。
- **Inception 免费且覆盖面广：** 2017 年 2,000 家初创企业 [S13027]，2021 年 8,500 家、累计融资 >$60B [S13026]，到 2022 年 ~10,000 家 [S531]；二手资料称 2025 年已 >22,000 家 [S13536]。
- **NVentures 是股权投资臂膀，且明显提速：** 2025 年 ~30 笔交易，而 2022 年仅 1 笔；英伟达整体在 2025 年参与了 ~67 轮风险投资，2024 年为 54 轮（PitchBook 数据，经媒体转引）🟡 [S13029]。
- **看空情景：** PyTorch、Triton 和 Mojo 等框架将 CUDA 抽象掉。高通于 2026 年 7 月完成对 Modular 约 ~$3.9B 的全股票收购，以掌控这样一套技术栈 [S9511,S90057]。

CUDA developers tripled from 2M (2020) to ~6M (2025); NVIDIA still cited 6M in 2026

Registered CUDA / NVIDIA developer-program members as stated by NVIDIA, millions

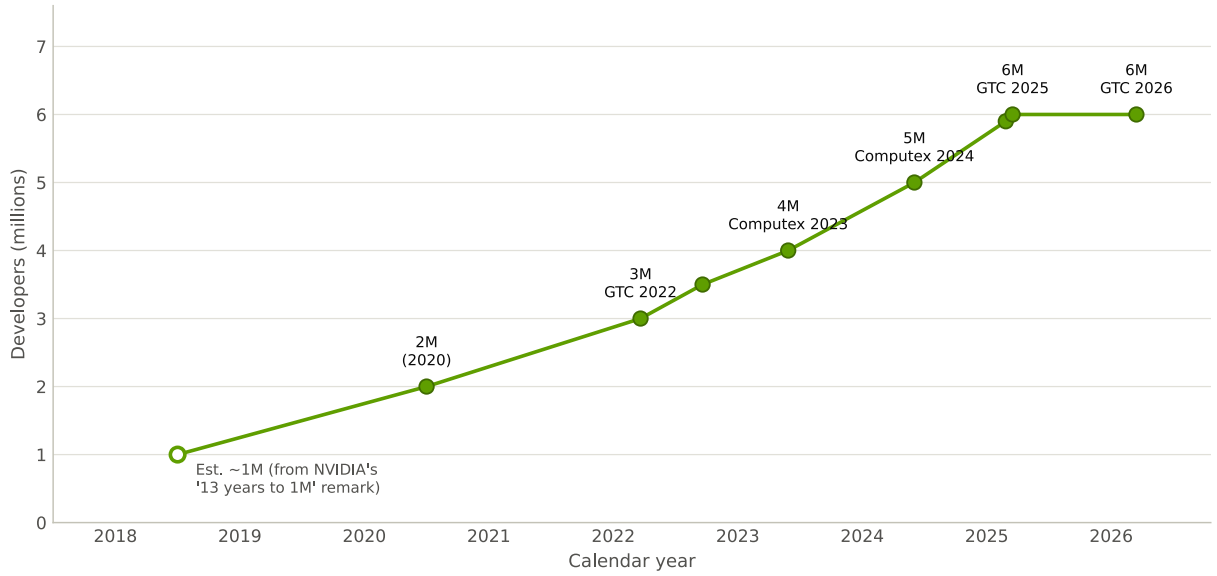

Source: data from NVIDIA keynotes, press releases and earnings calls [S529] [S530] [S531] [S532] [S533] [S534] …; chart by repo · As of 2026-11-05

> 英伟达公布的 CUDA 开发者数量折线图：2018 年前后约 1M（估计），2020 年 2M，2022 年 3 月 3M，2023 年 5 月 4M，2024 年 6 月 5M，2025 年 2 月 5.9M，GTC 2025 与 GTC 2026 均约为 6M——取整后的标题数字已进入平台期。

开发者飞轮如何运转

不妨把 CUDA 看作一个“顺带卖硬件”的操作系统。开发者不向英伟达付费；他们学习免费工具，编写默认运行在英伟达 GPU 上的代码，而他们的雇主购买或租用 GPU。开发者关系（developer relations）正是让这一习惯持续养成的机制：免费的 SDK 和 CUDA-X 软件库、NVIDIA 开发者计划（NVIDIA

Developer Program）、DLI 课程以及 GTC。每一个为 CUDA 编写的模型、内核和教程，都会抬高下一位买方的转换成本（参见第 09 层和飞轮章节）。

> **提示**
>
> **算例 —— 英伟达在每位开发者身上的投入与回报。** FY2026 研发支出为 $18.5B [S401]。摊到 ~6M 注册开发者 [S528] 身上，即**每位开发者每年 ~$3,100 研发投入**。数据中心收入为 $193.7B [S1]，即**每位开发者 ~$32,000**。开发者是由买方买单的成本中心：人均收入与研发投入 10:1 的比例，只有在这些开发者持续选择 CUDA 时才能成立。

[Q3 · 代际进步] 漏斗顶部持续扩大，但开发者数量没有同步增长。从 2024 年年中到 2026 年年初，GTC 现场参会人数从 >16,000 人增至预计 >30,000 人（+~90%）[S13021,S13533]，而注册开发者仅从 5.0M 增至 ~6.0M（+20%）[S534,S528]。GTC 的受众正从程序员转向买方、合作伙伴和投资者。

> **🔧 技术细节：“600 万”为何停滞**
>
> - 该数字统计的是英伟达开发者计划的注册数，并在主题演讲中取整。大多数 PyTorch 用户从不注册，因此这个数字衡量的是核心忠实用户，而非实际使用量。
> - 2020 年英伟达统计到每月 438,000 次 CUDA 下载，对应 ~39,000 个新注册 [S529]，约每十一次下载产生一个注册。
> - 数字持平既可能意味着专业人才池已经饱和，也可能意味着开发者转向了隐藏 CUDA 的更高层工具。两种解读在 CUDA 章节中均有讨论。

GTC 作为平台

GTC 起初是一个 GPU 计算会议，如今已成为英伟达的年度路线图发布会、合作伙伴发布窗口和销售场所。春季主题演讲设定了供应链据以排产的节奏。GTC 2026 推出了 Vera Rubin NVL72、Groq 3 LPX 机架和 Kyber 路线图 [S90003]，发布了 Dynamo 1.0，并点名 CoreWeave、Perplexity 和 PayPal 等采用者 [S90066]，还把英伟达对截至 2027 年需求的表述从 $500B 上调到 $1 trillion [S90001]。合作伙伴围绕主题演讲安排发布；区域性活动延展了这一形式，GTC DC 将于 2026 年 11 月 30 日至 12 月 3 日举行，晚于本资料库的截止日期 [S90047]。

GTC grew ~20× from ~1,500 attendees (2009) to >30k expected in 2026

In-person attendees at the spring GTC in San Jose; 2024-26 are NVIDIA pre-event figures (no final counts published)

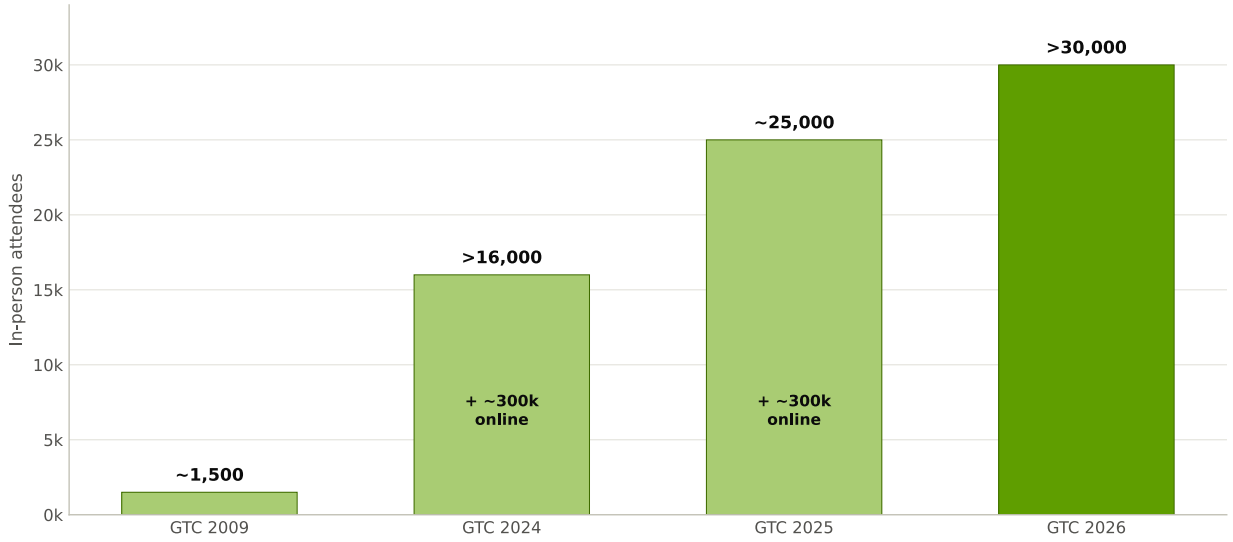

Source: data from NVIDIA announcements, press previews [S13024] [S13021] [S13020] [S13533] [S13022] [S13023]; chart by repo · As of 2026-11-05

英伟达春季 GTC 现场参会人数柱状图：2009 年首届 GTC 约 1,500 人，2024 年预计超过 16,000 人，2025 年英伟达估计约 25,000 人、另有约 300,000 人线上参与，2026 年预计超过 30,000 人、来自 190 多个国家和地区，议程列出 500+ 场。参会人数增长约 20 倍，使 GTC 不仅是英伟达、也是合作伙伴的发布平台。

提示

算例 —— 一场主题演讲，一个需求数字。 在 GTC 2026 上，黄仁勋把 Blackwell 加 Vera Rubin 截至 2027 年的需求定为 $1 trillion，是一个月前所引用的“截至 2026 年 $500B”的两倍 [S90001,S90002]。英伟达 FY2026 收入为 $215.9B [S1]。即使按较低的 $500B 计算，这场主题演讲也把**约 ~2.3 年的 FY2026 收入**描述为可见需求。这正是投资者、供应商和竞争对手都会出席的原因。各媒体对其指的是订单还是市场机会说法不一 🟡。

Inception 与 NVentures：两种不同的工具

NVIDIA Inception 是面向初创企业的免费会员计划。NVentures 则是英伟达的企业风险投资（corporate venture capital）部门，负责股权投资。规模更大的战略性持股（如 OpenAI 或英特尔）则记在英伟达自身的资产负债表上（见资本部署）。

	NVIDIA Inception	NVentures	公司层面的战略性持股
提供什么	技术支持、DLI 培训、合作伙伴与投资者对接；免费加入 [S13536]	风险投资轮次中的少数股权	大额股权、兜底承诺、授权
规模	~10,000 家会员（2022 年）[S531]；2025 年据称 >22,000 家 🟡 [S13536]	2025 年 ~30 笔交易，2022 年为 1 笔 🟡 [S13029]	持有股权 ~$99B（2026 年 7 月）[S90073]
英伟达获得什么	早期设计导入（design-in），以及未来 GPU 租用者的来源	信息权与生态影响力	来自实验室、云厂商和供应商的锚定需求

Inception grew 5× to ~10k start-ups by 2022; secondary data say >22k by 2025

Member companies of NVIDIA's free start-up program (launched 2016); dashed = secondary estimate, not an NVIDIA figure

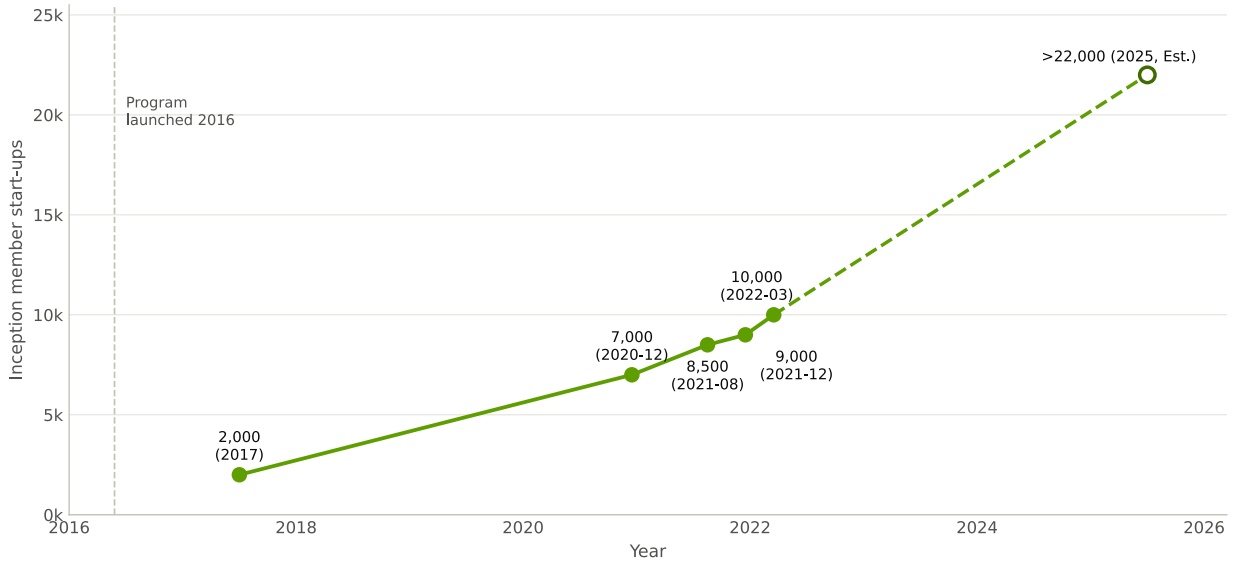

Source: data from NVIDIA blogs and releases; press [S13027] [S13025] [S13026] [S13028] [S531] [S13536]; chart by repo · As of 2026-11-05

NVIDIA Inception 会员数量折线图：2017 年 2,000 家初创企业（距 2016 年启动不到 18 个月），2020 年 12 月 7,000 家（一年增长 25%），2021 年 8 月 8,500 家、来自 90 个国家且累计融资超过 $60B，2021 年末 9,000 家（按 PitchBook 统计约占全球 AI 初创企业的三分之二），2022 年 3 月约 10,000 家。虚线段显示的是基于 PitchBook 的二手估计，即 2025 年活跃会员超过 22,000 家；英伟达近年未公布官方数字。

提示

算例 —— 以 GPU 小时衡量 Inception 的价值。 2021 年 Inception 的 8,500 家会员累计融资 >$60B [S13026]，平均每家 ~$7M。假设一家典型初创企业把四分之一的资金用于算力 🔴，即 ~$1.8M。按 Lambda 每 H100 小时 ~$2.99 的标价 [S395]，可购买 **~590,000 GPU 小时，约 ~67 GPU 年**，且几乎全部在英伟达平台上。英伟达在该计划上投入甚少；硬件费用由会员背后的投资者买单。

生态如何转化为需求

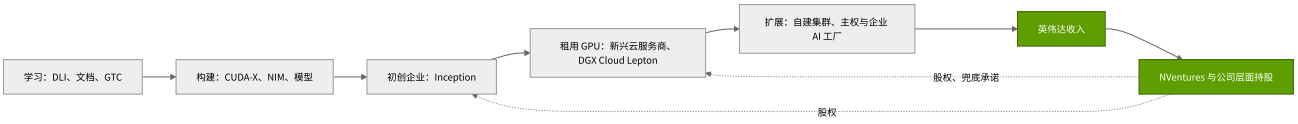

漏斗的终点是“先租后买”。DGX Cloud Lepton 将开发者引导至合作伙伴的 GPU 云，而不是由英伟达与其正面竞争 [S90068]。英伟达持有其中许多云厂商的股权：CoreWeave、Lambda、Nebius、Crusoe、Together AI 和 Nscale [S481]。

提示

算例 —— CoreWeave：一个已完成转化的生态成员。 英伟达对 CoreWeave 的敞口合计 ~$8.65B：IPO 前 ~$0.1B 🟡、$0.25B 的 IPO 锚定认购 🟡、2026 年 1 月 $2B 股权投资，以及 $6.3B 的算力兜底承诺 [S481,S473,S472,S90067]。CoreWeave 的目标是到 2030 年 >5 GW [S472]。按每 100,000 颗 GB300 GPU 约 ~232 MW 计算（见主权 AI），5 GW 即 **~2.2M 颗 GPU，按每颗 GPU ~$55,000 计约 $120B 的机架** [S332]。🔴 本资料库测算。

🎯 企业发展视角

1. **当 CUDA 被隐藏时，谁拥有开发者？** 如果 PyTorch、Triton 或 Mojo 成为交互界面，掌控编译器层的一方将攫取开发者习惯。高通收购 Modular [S9511] 是这一方向上一次公开下注。可移植技术栈能以多快速度在初创企业计划中成为“默认选项”？
2. **初创企业计划是成本低廉的期权。** 云额度在各厂商之间十分常见（见竞争格局）。英伟达的优势在于会员的硬件选择早已确定。竞争对手需要提供什么，初创企业才会为第二种架构进行设计？
3. **GTC 是一种协调机制。** 供应商、OEM 和云厂商都围绕它对齐发布日程。是否存在一个中立论坛（OCP、MLCommons、UALink 活动），让挑战者联盟能够同样高调地协同？

资本部署

第 13 层 · 生态、市场进入与资本 · 约 9 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **交易金额跃升五倍。** 2025 年之前英伟达所有已记录交易合计约 ~$10B。仅 2025 年一年就达到 ~$51B，以约 ~$20B 的 Groq 授权、对 Anthropic 最多 $10B、$6.3B 的 CoreWeave 兜底承诺和对英特尔（Intel）$5B 为首 [S474,S90075,S90067,S468]。
- **股权投资组合在 18 个月内增长 15×。** 私有公司股权从 $3.4B（2025 年 1 月）增至 $51.2B（2026 年 7 月）[S13043,S90072]。加上上市公司股权，英伟达共持有 ~$99B [S90073]。H1 FY2027 的股权购买额为 $42.4B，上年同期为 $1.2B [S90072]。
- **OpenAI 是最大的单笔押注。** 2025 年 9 月签署的最多 $100B 意向书，按每吉瓦部署量分期出资 [S467]，于 2026 年 2 月被搁置，改为约 ~$30B 的直接股权投资，且不设部署里程碑 🟡 [S90015,S90016,S90017]。
- **并购转向授权和收购式招聘（acquihire）。** Mellanox（$6.9B）造就了网络业务 [S464]。Enfabrica（>$900M）和 Groq（据报道 ~$20B）属于“团队加授权”交易，被投公司本身得以保留 🟡 [S475,S90018,S90019]。$40B 的 Arm 收购要约于 2022 年失败，导致 $1.36B 的费用 [S465,S466]。
- **客户集中度很高。** 三家直接客户分别占 H1 FY2027 收入的 16%、15% 和 13%，其中一家占 Q2 FY2027 收入的 16% [S90069]。
- **看空情景：** 英伟达为买方提供资金，买方再用这些资金购买其 GPU。H1 FY2027 $23.7B 的股权投资净收益计入了利润 [S90072]，尚有 ~$25B 的后续股权投资承诺 [S90069]，英伟达还在为客户组织 >$500B 的第三方融资 [S12528]。

NVIDIA's deal commitments jumped to ~$51B in 2025, 5× all its deals before 2025

Disclosed or press-reported deal value by announcement year, US$ B; excludes blocked Arm and superseded OpenAI LOI

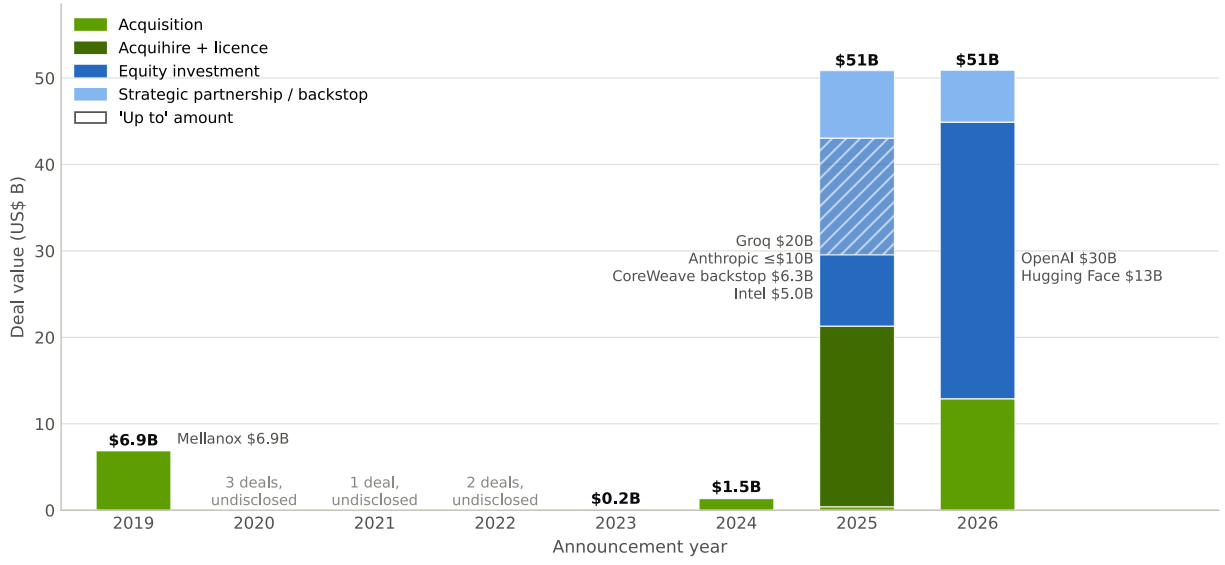

Arm ($40B, 2020) blocked

Source: data from NVIDIA filings and announcements; press reports [S464] [S2] [S476] [S479] [S478] [S475] ...; chart by repo · As of 2026-11-05

英伟达 2019–2026 年按年份划分的交易金额堆叠柱状图：2019 年以 Mellanox（$6.9B）为主，之后是小规模软件补强收购，2025 年约 $51B（Groq 授权约 $20B、Anthropic 最多 $10B、CoreWeave $6.3B 兜底承诺、英特尔 $5B、Synopsys $2B、xAI 最多 $2B、诺基亚 $1B），2026 年约 $51B（OpenAI 约 $30B、CoreWeave $2B）；2025 年之前的交易合计约 $10B。

[Q3 · 代际进步] 图中 2026 年的柱子未包含 2026 年 3 月约 ~$6B 的供应链股权投资：对 Lumentum 和 Coherent 各 $2B [S6511,S13529]，以及据报道对美满电子（Marvell）的 $2B [S90037]。图中也未包含 xAI 2026 年 1 月的融资轮，其中英伟达的出资额未披露 [S13039]。媒体统计显示英伟达 2026 年的投资已超过 $40B 🟡 [S13528]。

资本循环的运作机制

英伟达赚取的现金超过研发和回购所能消化的规模，并将其中一部分通过四种工具用于锁定需求。股权投资为实验室或云厂商提供更便宜的资本来购买 GPU。算力兜底承诺（capacity backstop）承诺购买未售出的算力，如对 CoreWeave 截至 2032 年的 $6.3B [S90067]。授权和收购式招聘引入团队和技术。对供应商的股权投资换取产能权利，如对光器件厂商的投资 [S6511]。交易往往以意向书（letter of intent）开局。

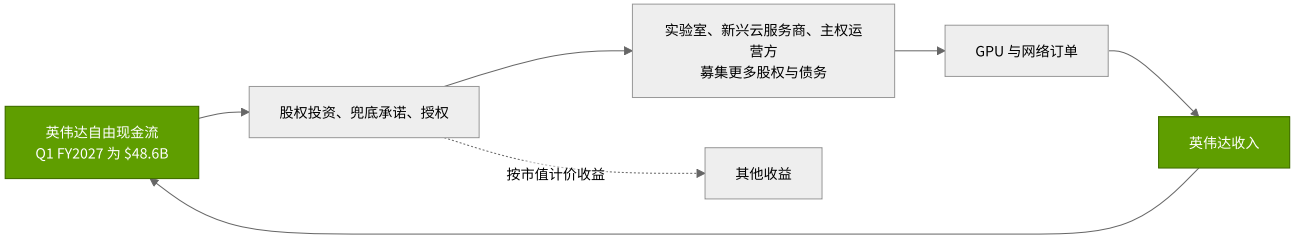

提示

算例 —— OpenAI 股权换来了什么。 OpenAI 与英伟达的计划规模为 ≥10 GW [S467]。按每 100,000 颗 GB300 GPU 约 ~232 MW、英伟达价值量约 ~$5.7B 计算（估计，见主权 AI），10 GW 即 **~4.3M 颗 GPU，以及 ~$246B 的潜在英伟达收入**。约 ~$30B 的股权投资 [S90015] 约占其中的 **~12%**，尚未计入股权本身的回报。OpenAI 还以一份股票认股权证为对价与 AMD 签订了 6 GW 协议 [S13506]，因此这笔股权换来的是钱包份额，而非排他性。🔴 本资料库测算。

NVIDIA's private stakes grew 15× in 18 months to $51B; all stakes ~$99B

Carrying value of equity securities, US$ B, Jan 2025 - Jul 2026; hatched = secondary reading of the 10-Q

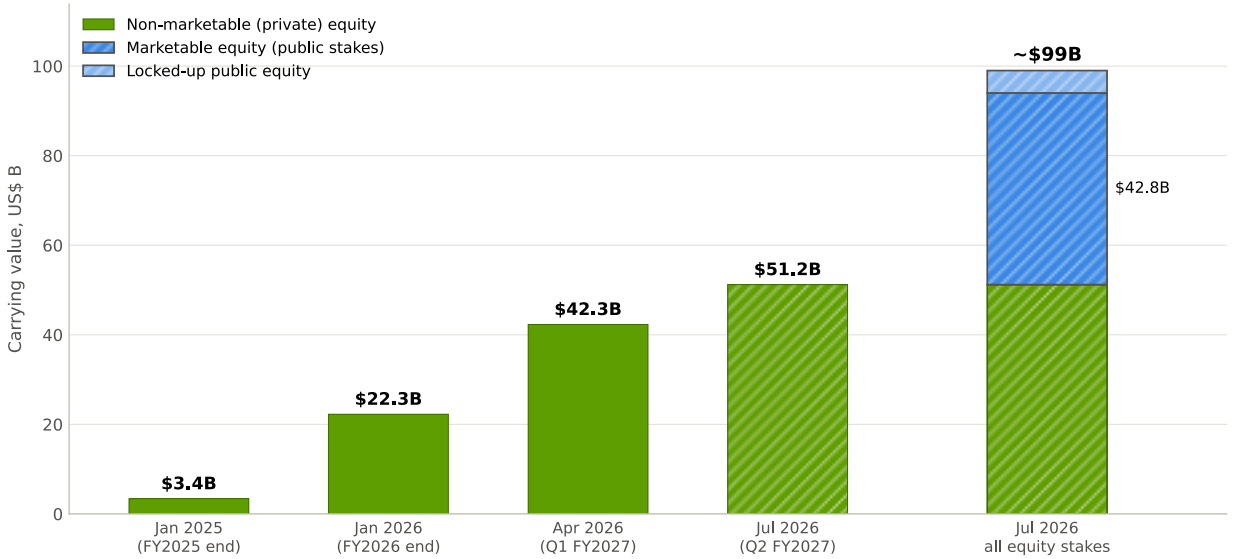

Source: data from NVIDIA 10-K/10-Q and secondary readings [S13043] [S90070] [S90072] [S90069] [S90073]; chart by repo · As of 2026-11-05

英伟达非流通（私有）股权证券柱状图：2025 年 1 月末 $3.4B，2026 年 1 月末 $22.3B，2026 年 4 月 $42.3B，2026 年 7 月 $51.2B，18 个月内增长约 15 倍。最后一根堆叠柱加上 $42.8B 的流通股权和 $5.0B 处于锁定期的上市公司股权，2026 年 7 月合计约 $99B。H1 FY2027 的股权购买额为 $42.4B，上年同期为 $1.2B；其余增量大多来自按市值计价收益。

战略投资：投了谁，为什么投

交易对手	日期	英伟达出资额	战略逻辑	状态
OpenAI	2025-09 意向书 → 2026-02	最多 $100B 意向书 → ~$30B 股权 S467,S90015	最大的 GPU 买方；首个吉瓦基于 Vera Rubin	意向书已被取代；据报道股权投资已敲定 🟡 S13526
Anthropic	2025-11-18	最多 $10B S90075	争取一家重度使用 TPU 和 Trainium 的实验室；在英伟达平台上最多 1 GW	已宣布 🟢
xAI	2025-10；2026-01	最多 $2B 🟡 S483；E 轮战略投资者 S13039	Colossus 扩建	已完成；2026 年金额未披露
Mistral AI	2024-06；2025-09	未披露 S481	欧洲主权锚点；Mistral Compute	已完成
CoreWeave	2023 → 2026-01	~$2.35B 股权 + $6.3B 兜底承诺 S472,S90067	新兴云服务商需求与优先配货	进行中
英特尔	2025-09-18	$5B，每股 $23.28 S468	支持 NVLink 的 x86 CPU；美国晶圆代工伙伴	2025 年 12 月完成
诺基亚（Nokia）	2025-10-28	$1B，每股 $6.01 S470	基站中的 AI-RAN	已完成
Synopsys	2025-12-01	$2B，每股 $414.79 S471	GPU 加速的 EDA	已完成
美满电子	2026-03	~$2B 🟡 S90037	NVLink Fusion 定制 XPU	有报道
Lumentum、Coherent	2026-03-02	各 $2B S6511	用于共封装光学的激光器与产能	已宣布

提示

算例 —— 作为利润来源的英特尔股权。 以每股 $23.28 投入 $5B，买入 **~215M 股英特尔股票** S468。上市公司股权每季度按市值计价（mark-to-market），因此股价波动会直接计入“其他收益”。在 Q1 FY2027，英伟达 $58.3B 的净利润中包含约 ~$15.9B 的其他收益，主要来自英特尔等股权的未实现收益 S403：**约 ~27% 的净利润**来自投资组合，而非芯片销售。

🔧 技术细节：这些股权如何影响财务报表

- **上市公司股权**（英特尔、诺基亚、Synopsys、CoreWeave）按公允价值计量；损益每季度计入其他收益。部分处于锁定期（2026 年 7 月约 ~$5.0B）S90072。
- **私有公司股权**（非流通股权（non-marketable equity），如 OpenAI）按成本计量，在出现可观察交易时重新计量。FY2026 净增加 $17.4B，未实现收益 $2.4B S13043。
- **兜底承诺**（如对 CoreWeave 的承诺）属于采购承诺而非股权：体现为未来义务，而不在投资科目中 S473。

注意

误区与事实：“英伟达向 OpenAI 投资了 $100B。”这 $100B 是一份意向书，计划随每个吉瓦上线而逐步投资 S467。它已被替换为在 OpenAI 约 ~$110B 融资轮中约 ~$30B 的股权投资，且不设部署里程碑 🟡 S90016,S90017,S13526。

并购、收购式招聘与授权

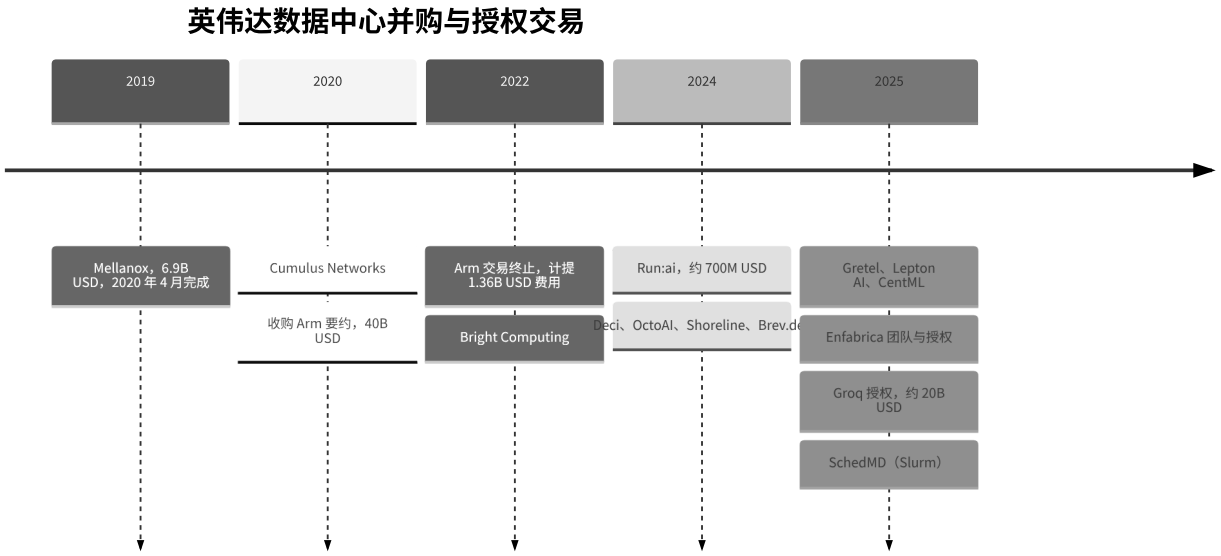

英伟达的收购买的是技术栈层级，而非市场份额：Mellanox 成为网络业务；Cumulus、Bright 和 SchedMD 补齐了集群软件栈 [S478,S13041]。Run:ai、Deci、OctoAI、CentML 和 Gretel 增强了推理和数据工具链，据报道每笔价格约 ~$250–700M 🟡 [S479]。自 2025 年以来，规模最大的动作是收购式招聘（acquihire）授权：雇用团队、授权技术，但保留公司的独立性，从而规避并购审查 [S90018]。SchedMD 交易保留了 Slurm 的开源和厂商中立属性 [S13041]。

> **提示**
>
> **算例 —— Groq vs Mellanox vs Arm。** Groq 最近一轮融资估值约 ~$6.9B（2025 年 9 月）。据报道，英伟达为一份非独占授权加上创始团队支付了 ~$20B [S90019]：**约为最近一次私募估值的 ~2.9×**，且并未拥有该公司。Mellanox 花费 $6.9B [S464]，由其孕育的网络业务在 FY2026 收入超过 $31B [S5514]：**一年收入约为收购价的 ~4.5×**。而 $40B 的 Arm 交易只换来了 $1.36B 的减记 [S466]。监管机构决定了英伟达采用何种交易结构。

Since 2023, 50 of NVIDIA's 65 logged deals were stakes in customers and partners, not M&A

Each deal by announcement date and the stack layer it strengthens; marker area ∝ US$ amount (small hollow = undisclosed)

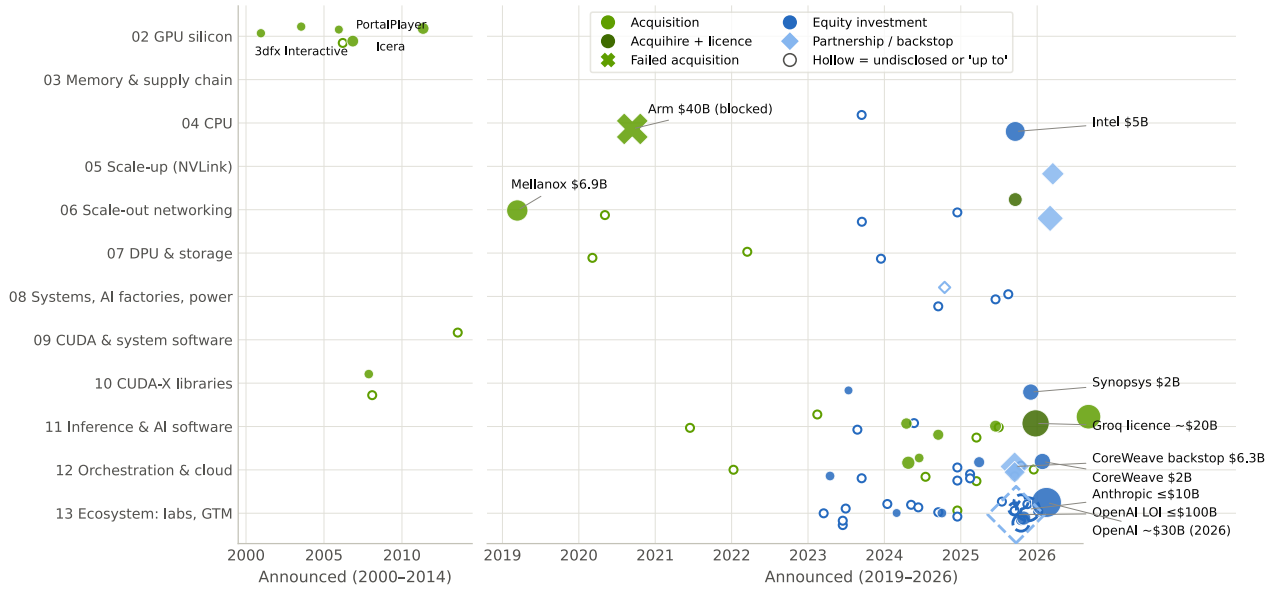

Source: data from NVIDIA filings and announcements; press reports [S400] [S484] [S464] [S2] [S478] [S465] …; chart by repo · As of 2026-11-05

2000 年至 2026 年英伟达 81 笔收购、收购式招聘授权交易和战略投资的时间散点图，按各交易所强化的技术栈层级排布。早期交易是 GPU 和移动芯片的补强收购；Mellanox（$6.9B，2019 年）构建了网络层；2023 年以来 65 笔交易中有 50 笔为股权投资，以 OpenAI、Anthropic、英特尔和 CoreWeave 为首，外加约 $20B 的 Groq 授权。

Layer 13 draws 24 of 81 deals, nearly all stakes; M&A concentrates in layer 11 (9)

Number of logged NVIDIA deals (81) by the stack layer each strengthens, split by M&A vs investment

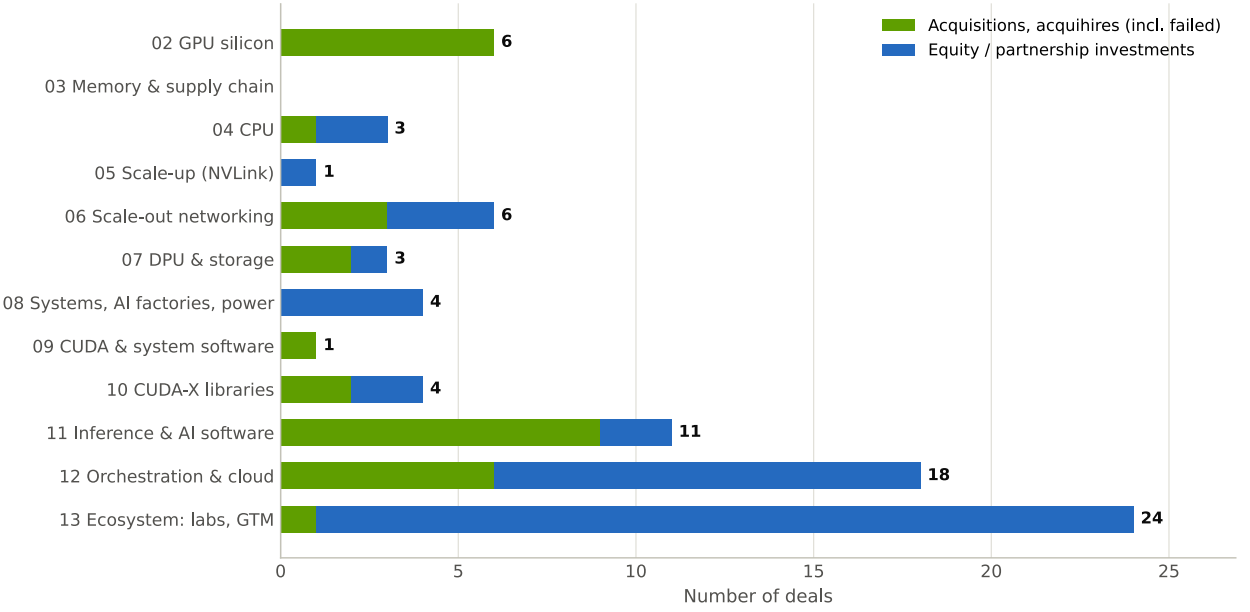

Source: data from NVIDIA filings and announcements; press reports [S400] [S484] [S464] [S2] [S478] [S465] …; chart by repo · As of 2026-11-05

英伟达 81 笔交易按层级划分的横向堆叠柱状图：第 13 层（实验室与生态）24 笔，几乎全部为股权投资；第 12 层（编排与云）18 笔，混合了 Run:ai 等补强收购与新兴云服务商股权；第 11 层（推理软件）11 笔，大多为收购；芯片、CPU 和网络层交易数量少但金额大（Mellanox、Arm、英特尔）。

客户集中度

直接客户主要是 OEM 和 ODM；英伟达估计，其背后的部分间接客户收入占比也超过 10% [S90069]。在 Q1 FY2027，有一家 AI 研究实验室通过云服务商贡献了可观收入 [S90070]。

Customers at ≥10% of revenue rose from 1 (13%) in FY2024 to 4 (61%) in Q3FY26

Share of revenue per disclosed direct customer, %; letters are not the same company across periods; mostly OEMs/ODMs

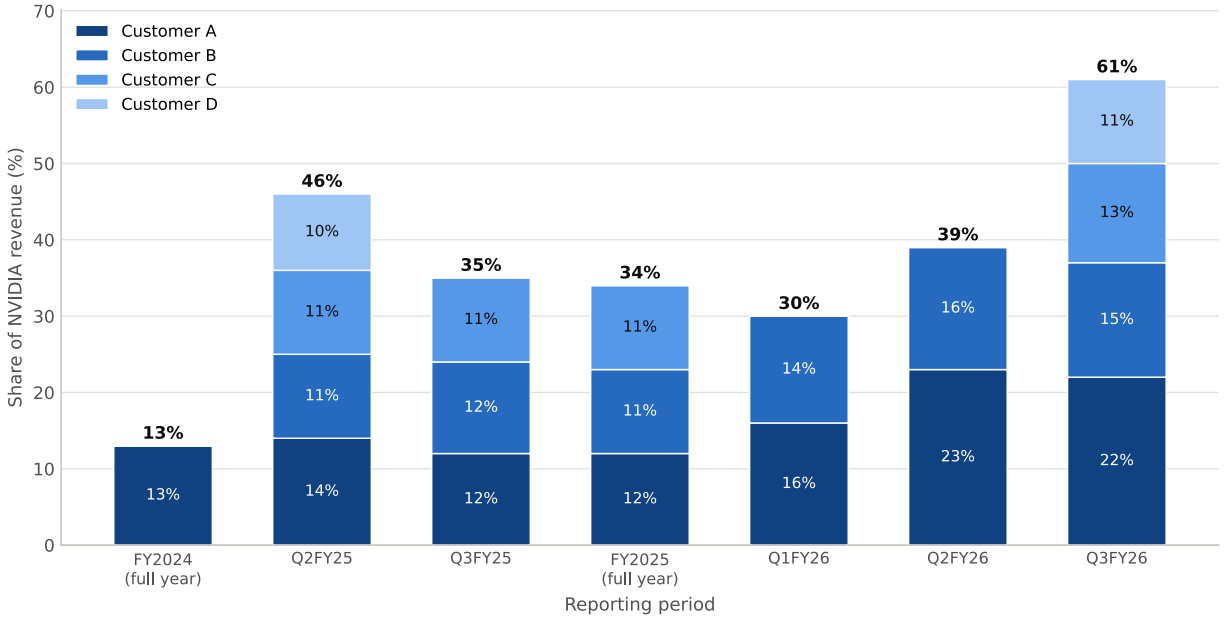

Source: data from NVIDIA 10-K/10-Q [S417] [S416] [S426] [S427] [S414] [S413] ...; chart by repo · As of 2026-11-05

英伟达披露的收入占比超过 10% 的直接客户堆叠柱状图：FY2024 为 1 家客户、占 13%，FY2025 为 3 家客户、占 34%，Q3FY26 为 4 家客户、合计占 61%；其中大多是为超大规模云厂商代工的 OEM/ODM。

提示

算例 —— 以美元衡量集中度。 在 Q2 FY2027，一家直接客户占 $96.2B 收入的 16% [S90069,S405]，即**单季度约 ~$15.4B**。在 H1 FY2027，三家直接客户的占比分别为 16%、15% 和 13%，合计占 $177.8B 的 **44%** [S90069,S403,S405]，即约 **~$78B** 流经三家组装商。如果其背后某家超大规模云厂商将五分之一的加速器预算转向自研芯片，英伟达在一个季度内就会感受到影响。

注

🐂 **看多观点：** 约 ~$30B 的 OpenAI 股权投资还不到一个季度的自由现金流（Q1 FY2027 为 $48.6B）[S403]。股权投资换来了信息和设计导入，并已产生大额收益，而客户购买 GPU 仍要支付现金。

注意

🐻 **看空观点：** 供应商融资会同时虚增需求和利润。股权投资收益（H1 FY2027 为 $23.7B）[S90072]、兜底承诺以及 >$500B 的有组织第三方融资 [S12528]，把英伟达的业绩与客户的融资能力捆绑在一起。批评者将其与 2001 年之前电信设备商的供应商融资相提并论 [S90074]。

🎯 企业发展视角

1. **资本如今是一种竞争武器。** 英伟达约 ~$56.6B 的现金和债务证券 [S13500]，加上 ~$99B 的股权持仓 [S90073]，令同业相形见绌（见价值链与企业发展视角）。认股权证、与收入挂钩的信用额度或与基础设施基金联合投资等交易结构，哪些能让资产负债表较小的公司参与竞争？

2. **“授权加团队”是新的并购模板**。 Enfabrica 和 Groq 表明，无需收购公司即可绕开监管 [S90018]。哪些私有推理和互连团队同样适用这种结构?
3. **对供应商的股权投资可以锁定产能**。 对光器件厂商的股权投资附带了采购承诺和产能权利 [S6511]。在挑战者供应链的哪些环节（激光器、HBM、CoWoS、电力），类似的股权投资能够锁定稀缺产能?
4. **集中度是双向的**。 三家直接客户占 H1 FY2027 收入的 44% [S90069]。其背后的间接客户中，哪些对第二供应商最为开放?

企业市场进入：OEM、GSI 与软件合作伙伴

第 13 层 · 生态、市场进入与资本 · 约 7 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **英伟达通过少数几家大型渠道商销售。** 其直接客户主要是为他人构建系统的 OEM 和 ODM。其中三家合计占 H1 FY2027 收入的 44%，一家占 Q2 FY2027 收入的 16% [S90069]。
- **非超大规模需求已接近数据中心收入的一半。** AI 云、工业与企业买方在 Q1 FY2027 约为 ~$37B（49%），在 Q2 FY2027 约为 ~$40.3B（45%）[S403,S406]。
- **面向企业的方案是一套打包的“AI 工厂”。** RTX PRO 服务器由思科（Cisco）、戴尔（Dell）、HPE、联想（Lenovo）和 Supermicro 供货 [S13034]。一套经验证的设计将其与 Spectrum-X 网络、BlueField DPU、认证存储以及 NVIDIA AI Enterprise 软件捆绑在一起 [S13033,S13034]。
- **集成商提供人力。** 埃森哲（Accenture）成立了英伟达业务事业部，计划让 ~30,000 名专业人员接受英伟达技术栈培训 [S13042]。
- **软件规模小，但按 GPU 定价。** AI Enterprise 标价为每 GPU 每年 $4,500，或在云上每 GPU 小时（GPU-hour） $1 [S13036]。软件与服务在 Q4 FY2024 的年化收入已超过 ~$1B [S13037]。
- **杠杆效应：**英伟达以 ~$4.6B 的销售、一般及管理费用（SG&A）支撑了 FY2026 约 ~$216B 的收入，约占销售额的 2%（估计） [S401,S1]。大部分销售成本由渠道合作伙伴承担。

Non-hyperscale buyers took ~$40B, 45% of Q2 FY2027 Data Center revenue

NVIDIA Data Center revenue by customer type, US$ B per quarter (new split from Q1 FY2027; rounded, per CFO commentary)

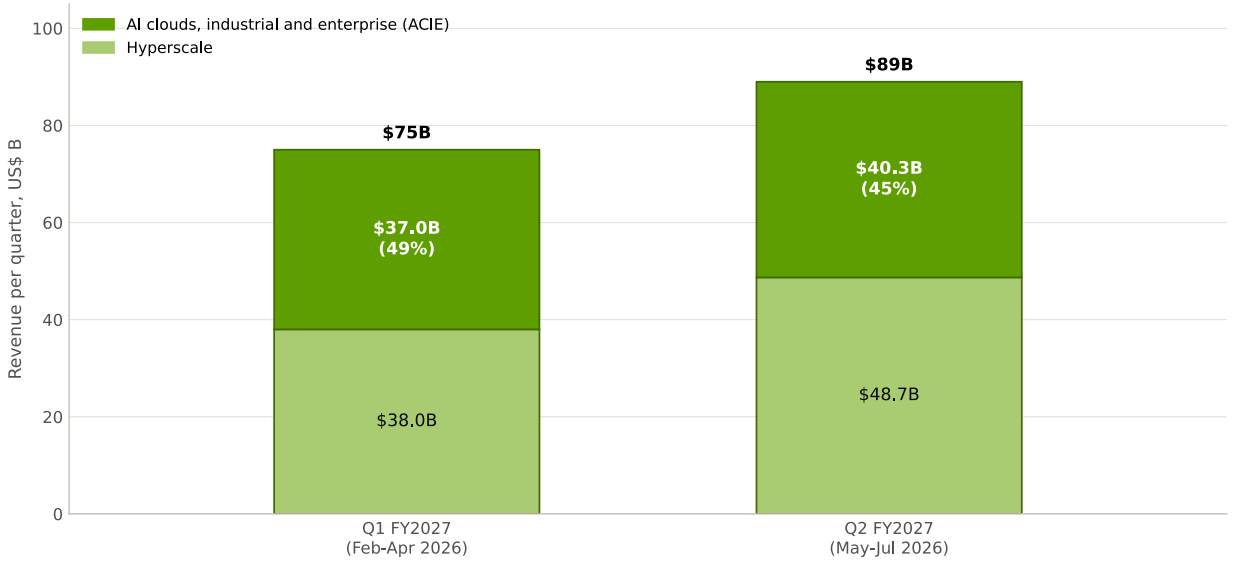

Source: data from NVIDIA Q1/Q2 FY2027 results and CFO commentary [S403] [S409] [S406]; chart by repo · As of 2026-11-05

英伟达数据中心收入按客户类型划分的堆叠柱状图：Q1 FY2027 超大规模云厂商约 $38B，AI 云、工业与企业客户（ACIE）约 $37B（49%）；Q2 FY2027 超大规模云厂商约 $48.7B，ACIE 约 $40.3B（45%）。通过合作伙伴和新兴云服务商触达的非超大规模买方已接近数据中心需求的一半。

渠道：究竟是谁在向英伟达采购

英伟达很少把成品服务器直接交付给终端用户。富士康、广达和纬创等 ODM 为超大规模云厂商组装机架；品牌 OEM（戴尔、HPE、联想、Supermicro、思科）凭借自身的服务和融资能力向企业、政府和新兴云

服务商（neocloud）销售；全球系统集成商（GSI）负责项目实施；软件厂商则将英伟达模型嵌入其产品中。在 10-Q 中，这些体现为少数几家大型直接客户，而英伟达会另行估算其背后的云厂商和实验室 [S90069]。

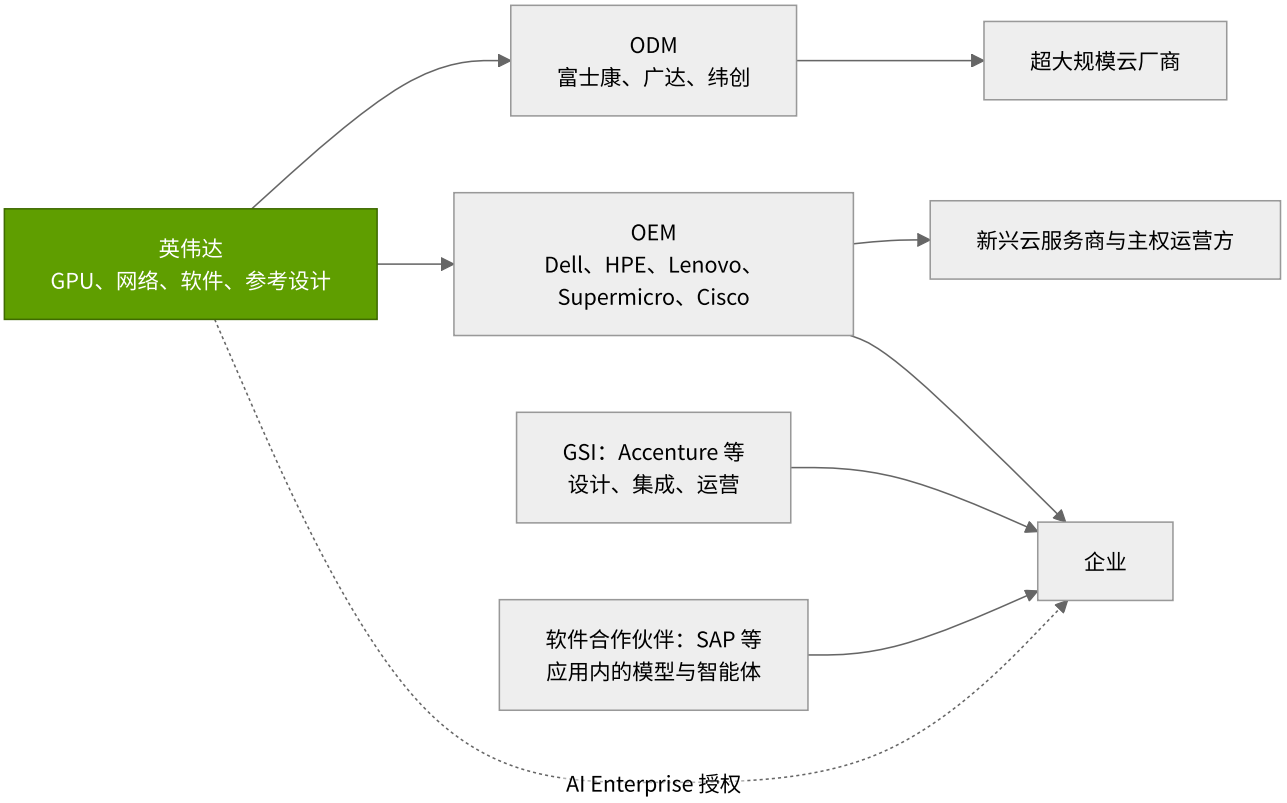

提示

算例 —— 单一合作伙伴承载了多少。 一家直接客户占 Q2 FY2027 收入的 16% [S90069]。以 $96.2B [S405] 计算，即**单季度约 ~$15.4B** 流经一家组装商。在 H1 FY2027，三家直接客户的占比分别为 16%、15% 和 13% [S90069]。英伟达 FY2026 全部 SG&A 支出约 ~$4.6B（估计）[S401]。正是依靠渠道，一家经营利润率约 60% [S1] 的公司才得以无需组建庞大的直销团队。

[Q2 · 关键指标] 对于企业渠道，应跟踪 ACIE 占数据中心收入的比重（Q2 FY2027 为 45%）[S406]、拥有英伟达认证设计的 OEM 和集成商数量，以及软件附着率（已授权 GPU ÷ 已部署 GPU）。

“为每家企业打造 AI 工厂”的推介

大多数企业无法容纳 132 kW 液冷的 GB300 NVL72 机架 [S337]。英伟达的答案（2025 年 5 月 Computex）是 RTX PRO 服务器：搭载 RTX PRO 6000 Blackwell Server Edition GPU、可放入普通机房的 x86 服务器 [S13033]。2025 年 8 月，思科、戴尔、HPE、联想和 Supermicro 推出了 2U、双 GPU 版本 [S13035]。*Enterprise AI Factory* 验证设计规定了完整的物料清单：服务器、Spectrum-X 以太网、BlueField DPU、认证存储和 AI Enterprise 软件。Cadence、富士康和礼来（Lilly）被列为早期采用者 [S13034]。德国电信在慕尼黑的工业 AI 云混合采用 DGX B200 和 RTX PRO 服务器，由 SAP 提供软件栈 [S13013,S13014]。

提示

算例 —— 软件附着率仍然很低。 按每 GPU 每年 $4,500 的标价 [S13036] 计算，若 2024 年初 ~$1B 的软件与服务年化收入 [S13037] 全部来自按标价计的 AI Enterprise，相当于 **~220,000 个 GPU 授权**。这仅是 2023 年以来出货的数百万颗数据中心 GPU 中的一小部分。黄仁勋后来提到的运行英伟达智能体软件每 GPU 每年 ~$2,000 并非正式价目 🟡 [S13038]。按此价格，每一百万颗授权 GPU 将带来**每年 ~$2B** 的经常性收入 🔴。

🔧 **技术细节：Enterprise AI Factory 验证设计包含什么**

- **计算：**来自上述五家 OEM 以及研华（Advantech）、华硕（ASUS）等厂商的多种配置 RTX PRO 服务器 [S13034]。
- **网络与 DPU：**Spectrum-X 以太网与 BlueField DPU（见第 06 层和第 07 层）。
- **存储：**经英伟达认证的存储合作伙伴。
- **软件：**AI Enterprise，包含英伟达的 NIM 推理微服务和框架，按 GPU 授权 [S13036]。
- **为何重要：**参考架构（reference architecture）让 OEM 无需英伟达工程师到场，即可报价一套完整且有支持保障的系统。

GSI 与软件合作伙伴：借来的销售团队

渠道角色	示例（公开信息）	合作伙伴获得什么	英伟达获得什么
OEM	Dell、HPE、Lenovo、Supermicro、Cisco [S13034]	硬件利润、服务、融资	企业市场覆盖与支持能力
ODM	富士康、广达、纬创	出货量；ODM 利润约占 GB300 机架的 ~2.7%（估计）[S332]	快速的机架级制造能力
GSI	埃森哲（~30,000 名受训员工）[S13042]	咨询与托管服务收入	项目设计、变革管理、带动销售
软件合作伙伴	德国电信云中的 SAP [S13014]	现有应用中的 AI 功能	企业工作流中的推理需求
电信运营商 / 新兴云服务商	德国电信、Nscale、Yotta [S13014,S13010,S13017]	主权或区域云收入	贴近受监管客户的算力

德勤（Deloitte）、Infosys 和 TCS 也在推广英伟达业务线，ServiceNow 和 Salesforce 已宣布基于英伟达的智能体功能；本文未重新核实其规模。

提示

算例 —— 一个集成商业务线价值几何。 埃森哲在宣布成立英伟达业务事业部的那个财年，报告了约 ~$3B 的生成式 AI 新签订单 [S13042]。摊到该事业部目标的 ~30,000 名专业人员身上，即**每名受训人员约 ~$100,000 的新签订单**。英伟达不为这些人员支付任何薪酬，却获得了指定其硬件的项目 🔴。

注意

🐻 **看空观点：**以合作伙伴为主导的渠道，意味着客户归合作伙伴所有。OEM 同样销售 AMD Helios 机架 [S90020]，集成商则跟随客户需求；因此，一旦企业推理转向更便宜、可移植的硬件，渠道可以迅速转向。

🎯 企业发展视角

1. **在企业市场，OEM 是关键的摇摆票。** 戴尔、HPE、联想、Supermicro 和思科决定标准报价中出现哪些加速器。挑战者的推理卡要进入同一产品目录，在验证设计和支持方面需要具备什么条件?
2. **集成商产能稀缺。** 仅埃森哲一家就为英伟达技术栈投入了 ~30,000 人 [S13042]。与其在最大的集成商处争夺关注，联合出资在一家中型集成商建立专属业务线是否更有价值?
3. **按 GPU 计价的软件定价提供了模板。** 每 GPU 每年 $4,500 的 AI Enterprise [S13036] 表明企业愿意为有支持保障的软件付费。高通的 Modular [S9511] 这类可移植技术栈，能否以同样方式跨硬件定价?

生态、市场进入与资本：竞争格局

第 13 层 · 生态、市场进入与资本 · 约 11 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **竞争的焦点在于谁为买方提供资金、培训和销售，而非芯片本身。** 英伟达拥有 ~6M CUDA 开发者、FY2026 >$30B 的主权 AI 收入，以及单季度 $48.6B 的自由现金流 [S528,S90071,S403]。
- **资本火力严重失衡。** 2026 年 7 月，英伟达持有 ~$57B 的现金和债务证券，超过 AMD（$15.8B）、博通（Broadcom）（$24.0B）和高通（$7.7B）三者之和 [S13500,S13501,S2516,S13503]。
- **AMD 以股权而非现金支付。** OpenAI 持有最多 160M 股 AMD 股票的认股权证，随其部署 1 GW 至 6 GW 的 AMD GPU 逐步归属 [S13506]；🟡 AMD 还计划向 Anthropic 投资最多 $5B，配套 2 GW 的 Helios [S9538]。
- **博通不出资也能赢单。** OpenAI 的 10 GW 定制加速器项目未披露任何供应商资本投入 [S174]，而博通在截至 2026 年 8 月的季度 AI 收入达到 $16.7B，约为英伟达数据中心收入的 ~19% [S2516,S405]。
- **[Q5 · 最强挑战者]** 超大规模云厂商与博通主导的定制 ASIC 联盟：在 OpenAI 已公布的 26 GW 中，英伟达仅占 10 GW；在四家大买方中合计约占 ~39%。
- **英伟达的弱点：资金买到的是配额，而非排他性。** OpenAI 和 Anthropic 接受了英伟达的股权投资，却仍与 AMD、博通和谷歌签约 [S13506,S174,S655]。

NVIDIA holds 10 of OpenAI's 26 announced GW and ~39% of four big buyers' total

Announced compute programmes by buyer and chip supplier, gigawatts (2025–2026 announcements; deployments 2026–2030)

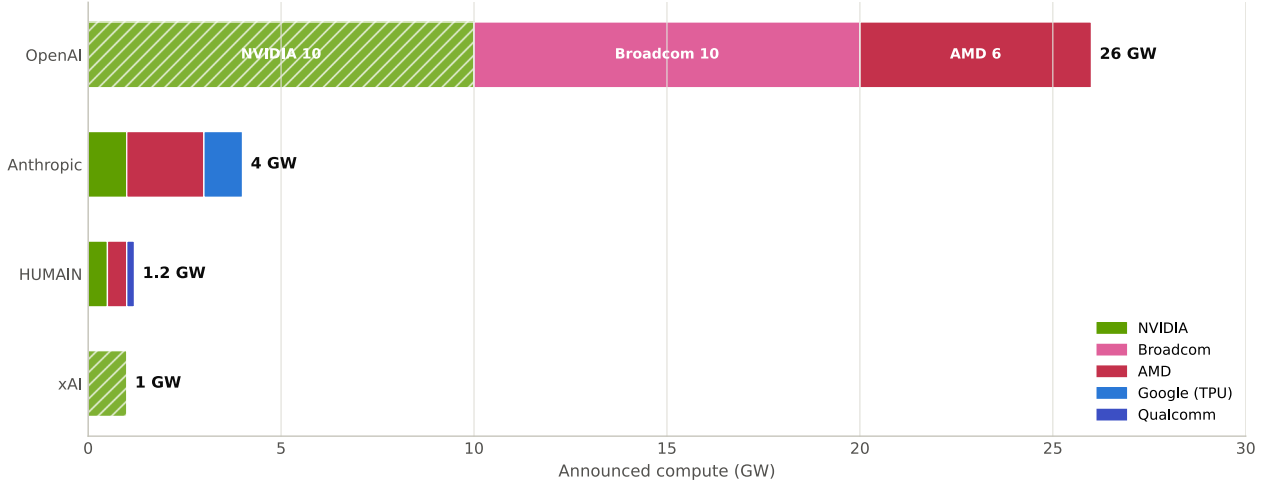

Hatched = restructured LOI or contested

Source: data from company announcements and press [S467] [S90016] [S174] [S13506] [S90020] [S90026] …; chart by repo · As of 2026-11-05

> 已公布算力项目的横向堆叠柱状图（单位：吉瓦）。OpenAI 26 GW：英伟达 10（2025 年 9 月意向书，后经重组）、博通定制加速器 10、AMD 6。Anthropic 4 GW：AMD Helios 最多 2（附带 AMD 最多 $5B 投资）、英伟达最多 1、谷歌 TPU 2026 年超过 1 GW（2027 年起的进一步多吉瓦 TPU 扩容未量化）。HUMAIN：英伟达最多 0.5 GW、AMD 0.5 GW、高通 0.2 GW。xAI：英伟达约 1 GW（公司说法，存在争议）。英伟达在这些项目中的份额约为 39%。

生态竞争如何计分

不妨把一个平台想象成一座城市：开发者是居民，初创企业计划是学校，主权交易是条约，资本是道路。如果没人居住，再好的建筑（芯片）也无济于事。我们从开发者覆盖、初创企业计划、主权交易、资本火力和渠道广度（OEM、云厂商、全球系统集成商（GSI））五个维度打分。

竞争对手	开发者覆盖	初创企业计划	主权交易	资本火力	渠道广度
谷歌（TPU）	🟦 其云上的 JAX/XLA	🟩 最高 $350k 云额度	🟥 国家级交易很少	🟦 持有 Anthropic 股权	🟥 主要是 Google Cloud
AWS（Trainium）	🟦 Neuron SDK	🟩 Activate 云额度	🟦 出售云区域而非芯片	🟦 Anthropic、Rainier	🟥 仅 AWS
微软（Maia）	🟦 Maia 仅限内部	🟩 ~$150k Founders Hub	🟦 主权云	🟦 Anthropic $5B，>$60B 新兴云服务商交易	🟥 仅 Azure
博通联盟	🟦 客户自有技术栈	🟥 无	🟥 无	🟥 无供应商资本	🟦 4–5 家巨头买方
AMD	🟥 ROCm 规模小得多	🟥 未发现 Inception 级计划	🟥 HUMAIN 500 MW	🟦 认股权证与股权投资	🟨 相同的 OEM
英特尔	🟥 oneAPI 属小众	🟥 未发现	🟥 无	🟥 自身融资 ~$23B	🟨 x86 OEM 覆盖广
华为	🟦 CANN 已开源	🟦 每年 30k 块开发板	🟦 中国优先	🟦 与国家方向一致	🟦 仅限中国
高通	🟦 Modular 技术栈（2026 年 7 月完成收购）	🟥 无此规模计划	🟥 HUMAIN 200 MW	🟥 $7.7B 现金，净负债	🟦 Meta、HUMAIN

评级 = 竞争对手相对英伟达（🟩 竞争对手领先 · 🟨 持平 · 🟥 竞争对手落后 · 🟦 路线不同）。本资料库判断 🔴，依据 S13519,S13520,S90034,S90075,S12526,S174,S9518,S13517,S13532,S13521,S13523,S9511,S90030,S13503。

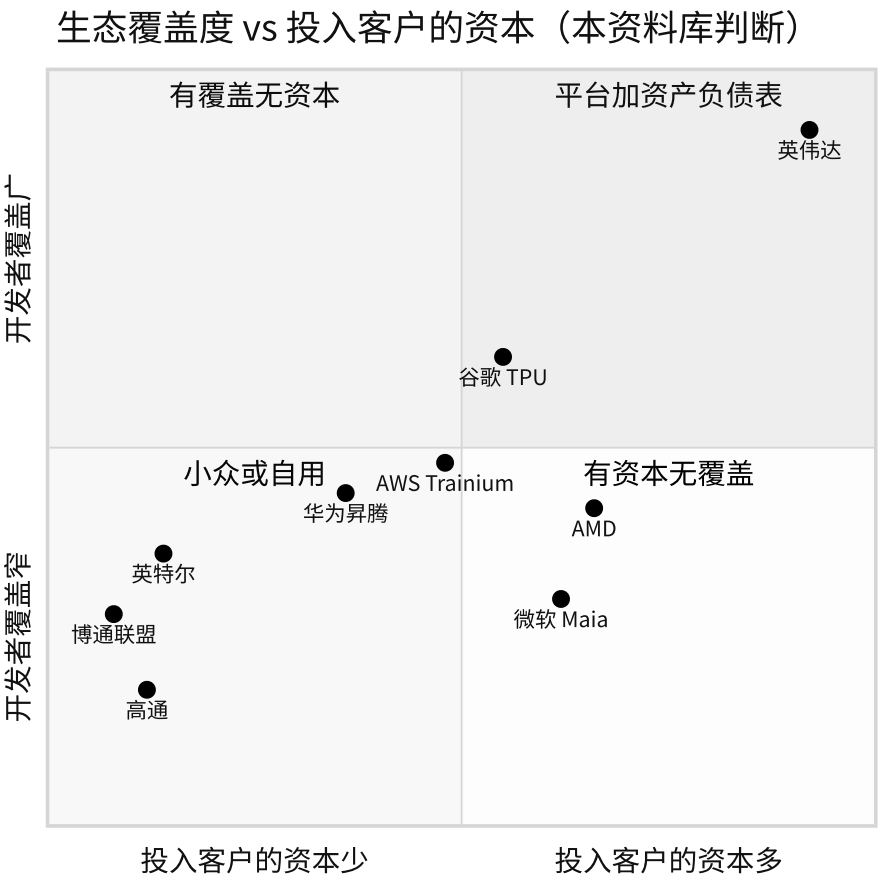

提示

算例 —— $350,000 的初创企业云额度能买到什么。 按每 H100 小时 $2.99（Lambda 标价）至 $6.88（AWS p5 标价）计算 S395,S392，谷歌最高档 $350,000 的 AI 额度 S13519 可购买 ~51,000–117,000 GPU 小时：相当于 6–13 颗 H100 用一年。足以微调一个产品，却不足以预训练一个前沿模型。云额度赢得的是*第一个*工作负载；英伟达则通过 DGX Cloud Lepton 把初创企业引导到合作伙伴的云上 S12529。

> 🔧 **技术细节：为什么现金与认股权证并不等价**
>
> 现金入股（英伟达对 OpenAI 约 ~$30B [S90015,S13526]）由当期自由现金流支付，并成为流动性差的私有资产。认股权证（AMD 的 160M 股，行权价 $0.01）不耗费现金；只有发行方股价上涨时才有价值，由现有股东通过股权稀释买单。面向客户的认股权证通常在各批次很可能归属时作为收入的减项入账（🔴 本资料库对通行做法的解读），而英伟达的股权投资则记在资产负债表上，损益计入其他收益 [S90072]。

逐一分析挑战者

超大规模云厂商与博通主导的定制 ASIC 联盟：最强挑战者

拥有什么。 谷歌向 Anthropic 供应最多 1M 颗 TPU（2026 年 >1 GW），并自 2027 年起追加多吉瓦规模，同时向 Meta 出租 Ironwood，并把 TPU 部署进客户的数据中心 [S90026,S655,S90025,S90027]。AWS 以 ~500k 颗 Trainium2 芯片建成了 Project Rainier；微软计划自 2027 年起部署多吉瓦的 Maia [S90034,S90045]。博通还与 OpenAI 共同开发其 10 GW 项目（2026 年下半年至 2029 年）[S174]。

最有力的论据。 它掌握需求：超大规模云厂商同时是云服务商、芯片设计者和投资者，因此它可以资助一家实验室（微软向 Anthropic 投资最多 $5B [S90075]）、向其出租算力，并引导其转向自研芯片（captive silicon），而无需为配额付费。

差距缩小了多少。 博通的 AI 收入从相当于英伟达数据中心收入的 ~11–14%（2024 年至 2026 年初），上升到截至 2026 年 8 月季度的 ~19%，下一季度指引为 $21.7B [S2516]。

Broadcom's AI revenue rose from ~12% to ~19% of NVIDIA's data-center revenue in 2026

Broadcom AI semiconductor revenue ÷ NVIDIA Data Center revenue, same calendar quarter of quarter-end, %

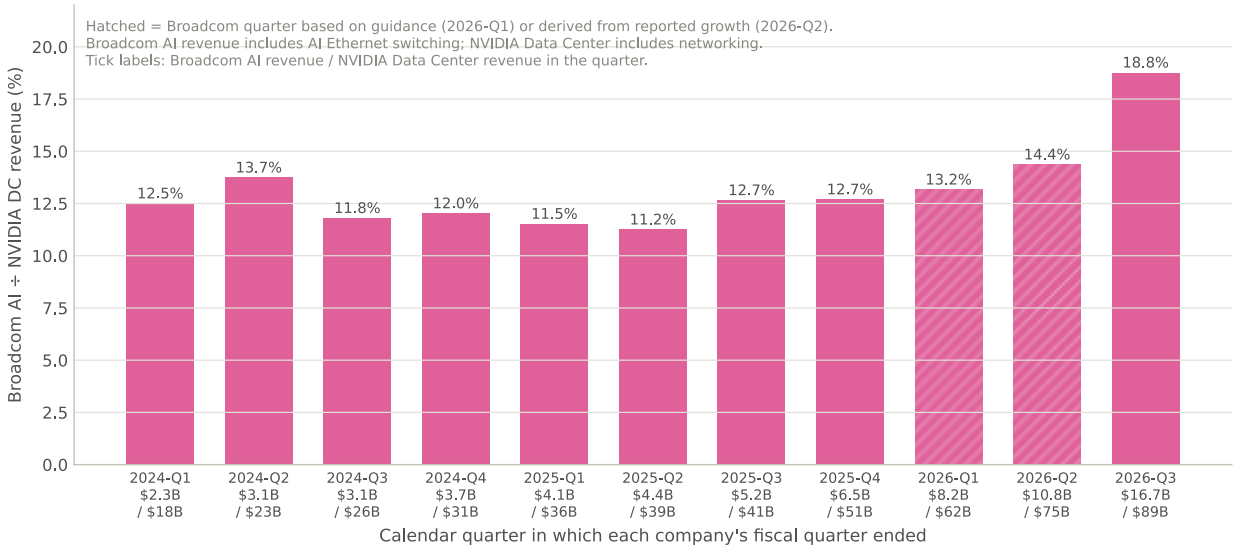

Source: data from Broadcom and NVIDIA filings; repo calculation [S660] [S661] [S451] [S2516] [S403] [S405]; chart by repo · As of 2026-11-05

柱状图：2024-Q1 至 2026-Q1，博通季度 AI 半导体收入一直约为英伟达数据中心收入的 11-14%，2026-Q2 升至 14%（推算），2026-Q3 升至 19%，当季博通录得 $16.7B，英伟达为 $89.0B。博通对下一季度的指引为 $21.7B。

提示

算例 —— 在 OpenAI 保持中立的代价。 OpenAI 公布了 26 GW：英伟达 10、博通 10、AMD 6 [S467,S174,S13506]。英伟达 2025 年的意向书按每 GW 约 ~$10B 出资，后被约 ~$30B 且不设里程碑的股权投资取代 [S90016,S90017]。博通分文未出，却赢得了同样多的份额。资本让英伟达留在牌桌上；但一个大到足以自研芯片的买方，无论如何都会自研。

AMD：“以资本换产能”的反制模式

AMD 拥有什么。 与 OpenAI 的交易将 6 GW 的 Instinct 部署（首个 1 GW 的 MI450 于 2026 年下半年交付）与一份最多 160M 股、行权价 $0.01 的认股权证绑定，按部署、股价和技术里程碑归属；有报道称最后一批与 $600 的股价挂钩 [S13506,S13507]。AMD 收购了 ZT Systems（$4.9B）以获取其机架设计团队，并将工厂出售给 Sanmina [S8527,S5527]。它还收购了 Silo AI（~$665M）、Brium、Untether AI 团队和 MK1，并吸引 2,000+ 名开发者参加 Advancing AI 2026 🟡 [S9506,S9507,S9509,S9519]。

最有力的论据。 以股票支付的“以资本换产能”（capital-for-capacity）交易，让 $15.8B 的资产负债表 [S13501] 也能与英伟达的现金竞争，并把客户与 AMD 的成功绑定在一起。**差距：** AMD 目前在 OpenAI 拥有 6 GW（英伟达 10 GW），🟡 在 Anthropic 拥有 2 GW（英伟达 1 GW）[S13506,S9538]，但在开发者方面仍大幅落后（第 09 层）。

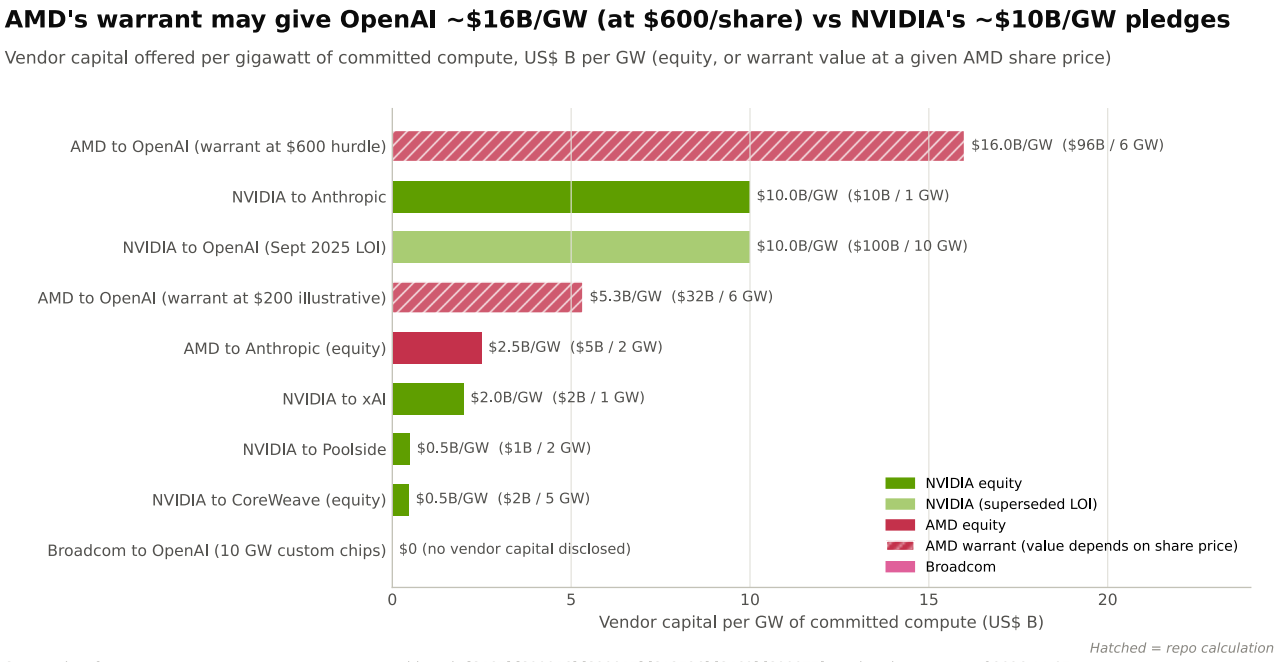

Source: data from company announcements, press; repo arithmetic [S467] [S90016] [S90015] [S13526] [S469] [S90075] ...; chart by repo · As of 2026-11-05

横向柱状图，显示客户每承诺 1 吉瓦算力所对应的供应商资本：若 AMD 达到报道中 $600 的股价门槛，其 1.6 亿股认股权证对 OpenAI 而言约合每 GW $16B，按示意性的 $200 股价则约为每 GW ~$5.3B；英伟达对 Anthropic（最多 $10B，1 GW）和对 OpenAI 已被取代的意向书（$100B，10 GW）的承诺均约为每 GW $10B；AMD 对 Anthropic 最多 $5B 的股权投资约为每 GW ~$2.5B（2 GW）；英伟达对 xAI 的股权投资约为每 GW ~$2B，Poolside 约 ~$0.5B，CoreWeave 约 ~$0.47B；博通的 10 GW OpenAI 项目未披露供应商资本。英伟达 2026 年对 OpenAI 的 $30B 股权投资未与吉瓦挂钩。

提示

算例 —— AMD 认股权证的成本。 若每一批次都在报道中的门槛价归属，160M 股 × $600 = $96B，即 6 GW 下每 GW $16B（本资料库计算）[S13507]。按示意性的 $200 计算，则为 $32B。AMD 以股权稀释（最多约为公司的十分之一，估计）而非现金支付，且仅在部署实际发生时才需支付。

英特尔、华为与高通

英特尔拥有最广泛的 x86 OEM 渠道，但需要 ~$23B 的外部资本，其中包括英伟达以 $5B 换取的 ~4% 股权；其晶圆代工业务取决于两家潜在 14A 客户自 2026 年下半年起的决定 🟡 [S13532,S4009,S13531]。**华为**于 2025 年底开源了 CANN，每年资助 30,000 块开发板和 1,500 PFLOPS 的开发者算力，并称外部开发者占 CANN 社区的 61% 🟡；未公布绝对人数 [S13521,S13523,S9524]。**高通（仅基于公开信息）**拥有 AI200（2026 年）和 AI250（2027 年）机架、200 MW 的 HUMAIN 计划、以 Meta 为首个客户的 C1000 CPU（2028 年下半年）以及 AI300（2028 年）；它于 2026-07-29 完成了对 Modular 的全股票收购（据报道 ~$3.9B），并于 2025 年 12 月完成对 Alphawave 的收购 [S90028,S90030,S90058,S90060,S9511,S90057,S4513]。

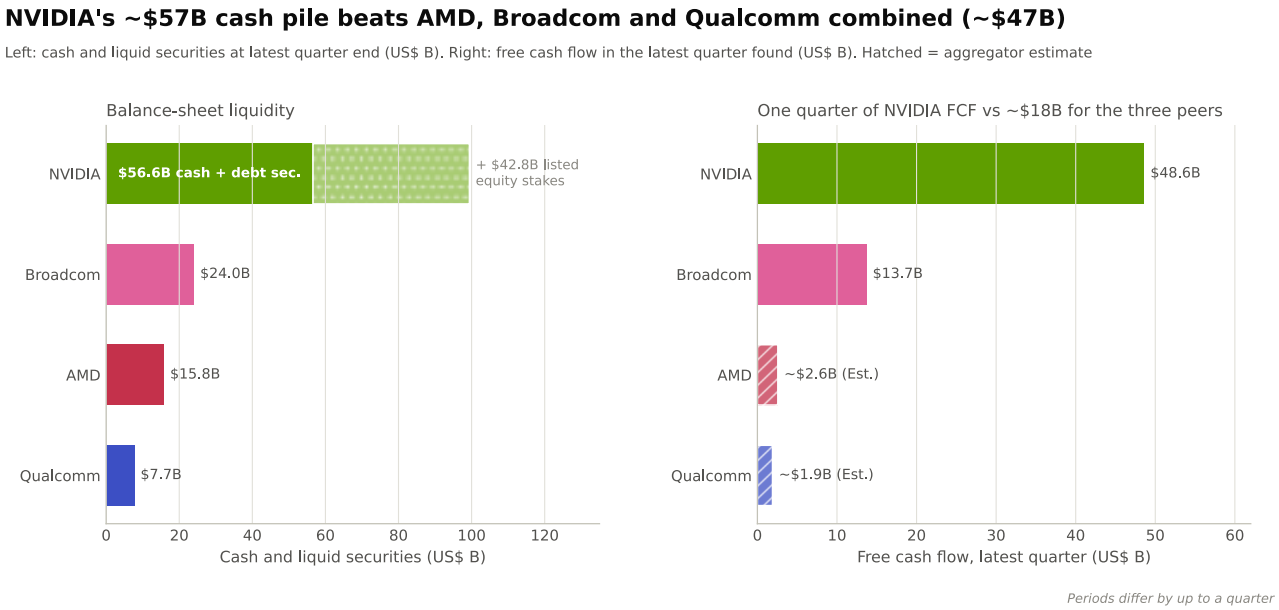

> 双面板柱状图。左图：最近一个季度末的现金及流动性证券：英伟达持有 $56.6B 现金和债务证券（2026 年 7 月），另有 $42.8B 上市公司股权；博通 $24.0B（2026 年 8 月）；AMD $15.8B（2026 年 9 月，债务 $7.1B）；高通 $7.7B（2026 年 9 月，债务 $15.1B）；三家同业合计约 $47B。右图：最近一个季度的自由现金流：英伟达 $48.6B（Q1 FY2027），博通 $13.7B，AMD 约 $2.6B，高通约 $1.9B（数据聚合平台估计）。

NVIDIA's 2024 R&D ($12.9B) passed AMD and Broadcom, still below Intel's $16.5B

GAAP R&D expense, US$ B per year; NVIDIA FY2023–FY2025 shown as 2022–2024, Broadcom FY ends ~Nov

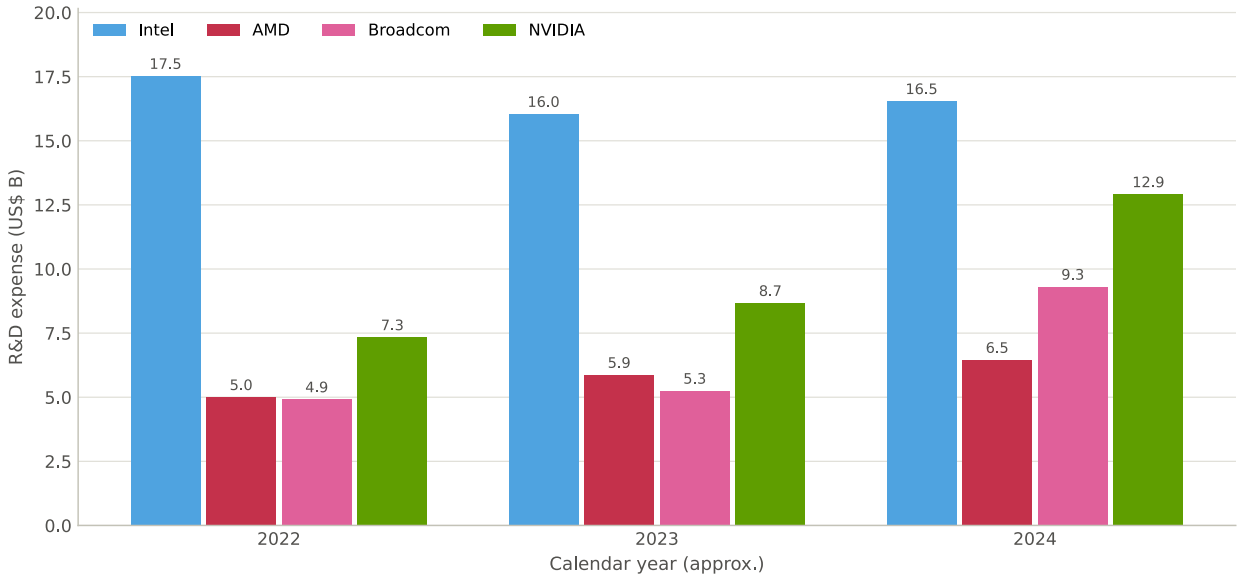

Source: data from company 10-K filings [S450] [S451] [S452] [S418] [S2] [S417] ...; chart by repo · As of 2026-11-05

2022–2024 年研发支出分组柱状图：英伟达从 $7.3B 增至 $12.9B，2024 年 AMD 为 $6.5B、博通 $9.3B（含 VMware）、英特尔 $16.5B；英伟达 FY2026 $18.5B 的研发支出未在图中显示。

注

🐂 **看多观点。** 只有英伟达同时是开发者平台、主权合作伙伴和融资方；其一个季度的自由现金流就超过同业的现金总和，其融资平台还计划为客户撬动 >$500B 的第三方资本 [S403,S12528]。

注意

🐻 **看空观点。** 最大的买方拿了英伟达的钱，照样多源采购：定制芯片在 OpenAI 占 10 GW，AMD 在 Anthropic 的份额不断扩大，博通的 AI 收入已相当于英伟达数据中心收入的 ~19% [S174,S9538,S2516]。每一笔股权投资还会招致循环融资和反垄断方面的质疑（路线图）。

[Q5 · 最强挑战者] 超大规模云厂商加博通的联盟。它掌控需求、初创企业的入口以及自研芯片，因此无需购买配额。在约两年内，差距从英伟达数据中心收入的 ~11% 缩小到 ~19% [S2516]。AMD 的认股权证模式是对英伟达现金最具创意的反制，纸面上已拥有 8 GW 的前沿实验室项目 🟡 [S13506,S9538]。

🎯 企业发展视角

1. OpenAI 以每 GW $0 选择了博通，以每 GW ~$10B 选择了英伟达。买方的决策中有多少取决于资本，又有多少取决于设计控制权?
2. AMD 以股权支付，英伟达以现金支付。哪种结构更适合资本受限的新进入者？哪些里程碑可以保护其股东?
3. 超大规模云厂商的云额度赢得第一个工作负载。新兴云服务商（neocloud）或主权云合作伙伴能否替代芯片厂商无力独自资助的初创企业计划？可移植技术栈（CANN、Modular）能否让该计划做到硬件中立?

生态、市场进入与资本：发展历程与英伟达如何建成

第 13 层 · 生态、市场进入与资本 · 约 12 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **四个时代。** 开发者平台（2009 年起的 GTC、2016 年起的 Inception、2017 年提出培训 100,000 名开发者的目标）、平台型并购（Mellanox、失败的 Arm 收购要约）、软件补强收购，以及 2023 年起的股权投资、授权和融资交易浪潮 [S13024,S13027,S13031,S464,S465]。
- **交易结构发生逆转。** 自 2023 年以来，英伟达已记录的 66 笔交易中只有 18% 是收购；47 笔是对客户、供应商和合作伙伴的股权投资（见下图）。
- **2026 年 8 月，英伟达转向动用他人的资金：** 与六家资产管理公司签署谅解备忘录，为其客户撬动 >$500B 的第三方资本 [S12528]。
- **[Q4 · 优势来源]** 现金流加上生态中心地位：Q1 FY2027 $48.6B 的自由现金流 [S403]、~6M CUDA 开发者，以及 FY2026 > $30B 的主权 AI 收入（见竞争格局），使英伟达能够同时扮演开发者平台、融资方和主权合作伙伴三重角色，这一组合目前没有任何竞争对手能够匹敌（🔴 本资料库判断）。
- **[Q6 · 复制成本]** 资本层面，超大规模云厂商可在数年内复制；开发者与合作伙伴生态则是一个需要 7–10 年、耗资数百亿美元的工程（🔴 本资料库估计）。

Since 2023 only 19% of NVIDIA's 70 logged deals were acquisitions; 48 were stakes

NVIDIA deals per year by structure (count, announce year), 2019–2026 YTD; pre-2023 venture stakes are under-recorded

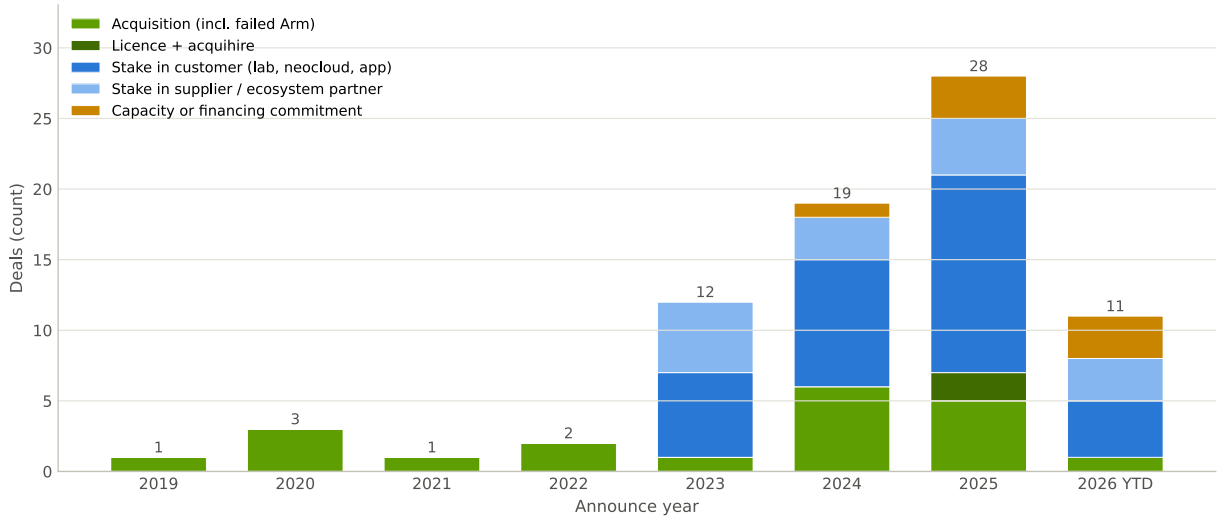

Counts, not dollars

Source: data from repo deal files [S464] [S2] [S478] [S465] [S466] [S418] ...; chart by repo · As of 2026-11-05

2019 年至 2026 年英伟达按年份和交易结构划分的交易堆叠柱状图。2019-2022 年，7 笔交易全部为收购（Mellanox、Cumulus、Bright、失败的 Arm 收购要约）。2023-2026 年共 70 笔交易，收购占比降至 19%：33 笔是对 OpenAI、Anthropic、xAI、CoreWeave 和 Mistral 等客户的股权投资，15 笔是对英特尔、诺基亚、Synopsys、美满电子、Lumentum 和 Coherent 等供应商和合作伙伴的股权投资，2 笔为“授权加收购式招聘”交易（Enfabrica、Groq），7 笔为算力或融资承诺，包括 CoreWeave 兜底承诺和 2026 年的融资平台。

时间线：从开发者大会到资本配置者

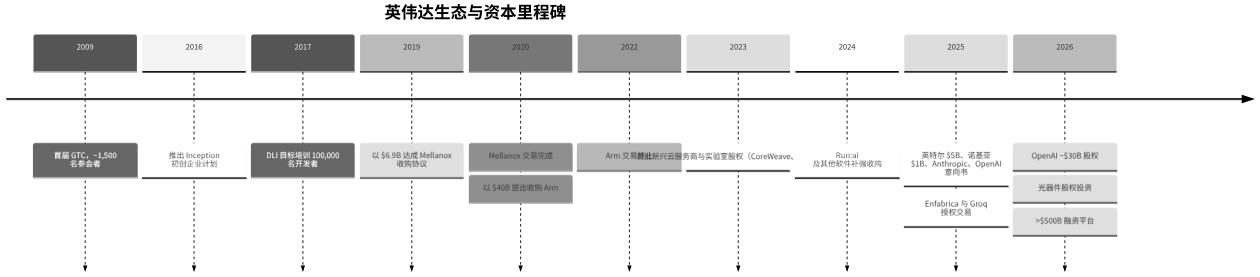

日期	决策	为何重要	来源
2009	首届 GTC（~1,500 名参会者）	一场开发者大会演变为产品发布舞台；2026 年预计 30,000+ 人参会	S13024,S13533
2016	Inception 计划	提供免费工具和投资者对接，不出资金；约 ~18 个月内会员达 2,000 家	S13027
2019-03	Mellanox，$6.9B 现金	成为网络业务（FY2026 收入 >$31B）	S464,S402
2020-09 → 2022-02	Arm，$40B 收购要约，最终放弃	被监管机构阻止；英伟达将 $1.36B 预付款计入费用，并保留一份 20 年授权	S465,S466,S418
2023	首批新兴云服务商与实验室股权投资	在超大规模云厂商之外培育 GPU 买方	S481
2024-04 → 2024-12	Run:ai，~$700M	经欧盟审查后才完成交割：补强收购如今也会受到审查	S476
2025-09	对 CoreWeave 截至 2032 年的算力兜底承诺	最多 $6.3B 的未售出算力风险转由英伟达承担	S90067
2025-09 → 12	英特尔 $5B（~4%）	一笔合作伙伴股权投资，同时锁定一家美国供应商	S468,S4009
2025-09 → 12	Enfabrica、Groq 授权加收购式招聘	无需并购申报即可获得团队和知识产权	S475,S474
2025-09 → 2026-02	OpenAI：最多 $100B 意向书 → ~$30B 股权	从与里程碑挂钩转为普通股权投资	S467,S90015,S13526
2026-03	Lumentum 和 Coherent 各 $2B	股权投资加上激光器产能的采购承诺	S13529
2026-08	融资平台（目标 >$500B）	将资产负债表风险转移给第三方	S12528

🔧 技术细节：股权投资为何始于 2023 年

2023 年之前，英伟达的现金主要用于回购和两次平台型收购要约；在 Mellanox 和 Arm 交易期间（FY2020–FY2022），回购曾暂停 [S2]。ChatGPT 问世后，配额本身成了稀缺品，而对 CoreWeave 这类纯 GPU 云的小额股权投资（2023 年约 ~$100M [S481]），就造就了一个没有自研芯片、快速增长的买方。据 PitchBook 统计，英伟达在 2025 年参与了 ~67 轮风险投资，高于 2024 年的 54 轮 [S13029]。

提示

算例 —— Mellanox 的收购价只需几周销售额即可收回。 英伟达在 2019 年支付了 $6.9B [S464]；FY2026 网络业务收入约 ~$31.4B，仅 Q2 FY2027 一个季度估计就达 $17.5B [S402,S408]。按 Q2 的年化节奏，收购价约相当于五周的网络业务销售额。

[Q4 · 优势来源] 现金流加上生态中心地位

其机制是一个闭环：开发者基于 CUDA 构建，因此买方指定英伟达；买方支付约 ~75% 的毛利率 [S405]；这些现金再用于股权投资、兜底承诺和主权合作，进而创造更多 CUDA 买方。竞争对手可以复制其中某一步，却无法以同等规模复制整个闭环。

NVIDIA returned $112B of $202B free cash flow (55%) to shareholders since FY2023

Free cash flow (operating cash flow − capex) vs repurchases + dividends, US$ B per quarter; n/a = not in dataset

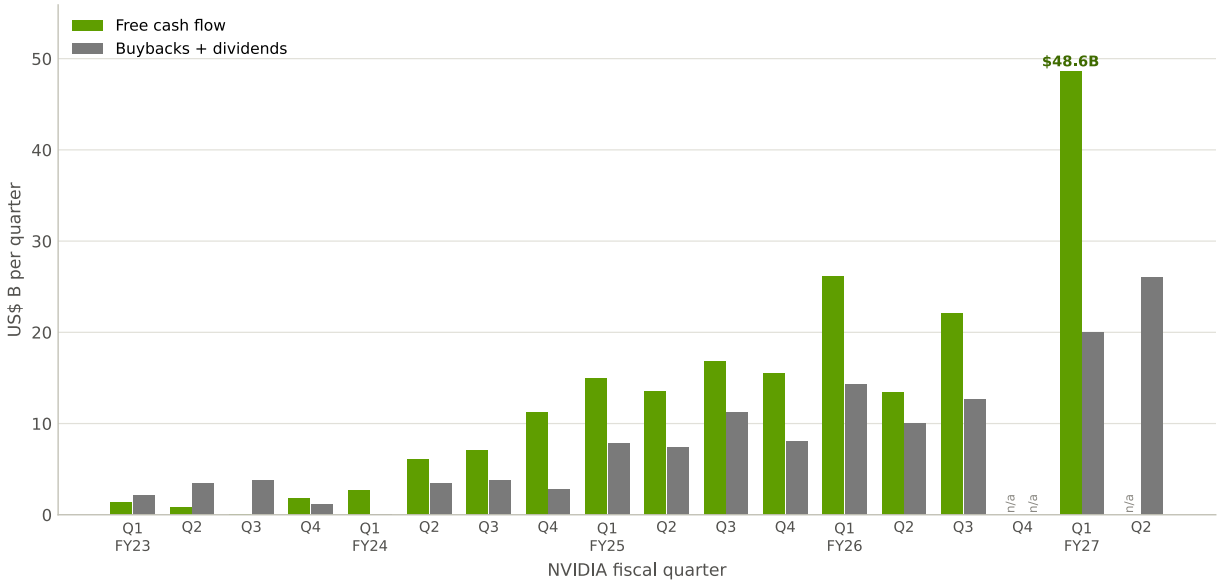

Source: data from NVIDIA 8-K releases, 10-Q [S432] [S433] [S434] [S435] [S418] [S436] ...; chart by repo · As of 2026-11-05

英伟达 Q1FY23–Q2FY27 季度自由现金流与股东回报分组柱状图：在两项数据齐全的 16 个季度中，自由现金流合计 $202B，股东回报 $112B（55%）；自由现金流在 Q1FY27 达到 $48.6B，股东回报在 Q2FY27 达到 $26B。

提示

算例 —— 一笔 $30B 的股权投资对各家公司意味着什么。 英伟达对 OpenAI 约 ~$30B 的股权投资，相当于一个季度自由现金流（Q1 FY2027 为 $48.6B）的 62% [S90015,S403]。对 AMD 而言，同样一张支票约为其全部 $15.8B 现金的 ~1.9×；对高通而言约为其 $7.7B 现金的 ~3.9× [S13501,S13503]。这正是 AMD 以认股权证向 OpenAI 支付的原因，也是“比肩英伟达的资本”对同业而言并非现实策略的原因（竞争格局）。

[Q6 · 复制成本] 时间、资金与人才

组成部分	英伟达拥有什么	复制所需时间	资金（🔴 本资料库估计）	人才
开发者基础	~6M CUDA 开发者，CUDA 已有 20 年历史 [S528]	7–10 年	每年 ~$1–2B	数千名工程师
初创企业计划	Inception，~22,000 家会员（二手估计） [S13536]	3–5 年	不高；需要云合作伙伴	面向风投的团队
活动与培训	GTC 30,000+ 名参会者；DLI 到 2020 年已培训 >200,000 人 [S13533,S13032]	3–5 年	<$1B	内容与讲师
资本组合	~$99B 股权持仓（2026 年 7 月） [S90073]	若有现金则 1–2 年	$50–100B 资产负债表	小型交易团队
主权关系	FY2026 主权收入 >$30B [S90071]	3–5 年	由合作伙伴融资	政策团队与本地合作伙伴

结论。 超大规模云厂商可以在一到两年内匹配资本（Alphabet、亚马逊和 Meta 最初对 2026 年资本开支的指引约为 ~$505B，之后上调至 ~$558B [S12518,S12519,S460,S461,S462]），但无法保持中立，因为其云业务与其所资助的实验室存在竞争。AMD 以股权替代现金。高通持有 $7.7B 现金且处于净负债状态 [S13503]，需要合作伙伴提供资本，并借助 Modular 这类可移植层来缩小开发者差距 [S9511]。总体 🔴 估计：**7–10 年、$50–100B 的可部署资本外加 ~$10–20B 的累计生态投入，以及数千名面向开发者的工程师**；真正的约束条件是开发者基础，而非资金。

> **提示**
>
> **算例 —— 以年为单位的开发者差距。** CUDA 用了 ~20 年才达到 ~6M 开发者 [S528]，平均每年 ~300,000 人。一家竞争对手若从较小的基数出发、以同样的平均速度增加开发者，需要 ~7 年才能达到 2M（🔴 本资料库测算）；资金可以加快活动和云额度的投放，却无法加速习惯的养成。

反事实推演：如果英伟达当初没有……

- 🔴 ……**失去 Arm?** 英伟达将拥有一套授权给竞争对手 CPU 设计者的指令集，这正是监管机构反对的原因 [S466]。此后它在不拥有 Arm 的情况下已获得了大部分好处：其 Grace 和 Vera CPU 基于 Arm 架构 [S100]，NVLink Fusion 如今也可将 Arm Neoverse 设计接入英伟达机架 [S90036]。若拥有 Arm，则会在当下的资本中立性问题之上，再叠加中立性方面的问题。
- 🔴 ……**投资新兴云服务商?** 若没有对 CoreWeave 等公司的股权投资，超大规模云厂商将几乎掌控全部可租用的 GPU 算力，并能将客户引向 TPU、Trainium 和 Maia。区域性新兴云服务商（neocloud）在 Q2 FY2027 同比增长 >3× [S90071]；这一买方群体是英伟达对冲自研芯片的屏障（见第 12 层）。
- 🔴 ……**直接收购 Groq?** 以 $20B 收购一家推理芯片竞争对手，将面临全面的并购审查；仅 ~$700M 的 Run:ai 交易就耗时八个月，其中包括欧盟审查 [S476]。授权结构在数日内即完成交割，但转而招致了参议员的质询 [S13511]。

> **提示**
>
> **算例 —— 失败的 Arm 收购要约代价几何。** $40B 的价格中大部分是股票（$21.5B），外加 $12B 现金 [S465]；交易告吹时，英伟达减记了 $1.36B 的预付款 [S418]，不到 FY2026 $215.9B 收入的 1% [S1]。真正的代价是时间：审查耗时 17 个月。

🎯 企业发展视角

1. 英伟达的资本优势在于现金流，而非现金存量。对同业而言，哪些资产（主权合作伙伴、云厂商、认股权证）可以替代一个 $48.6B 的季度?
2. 在复制成本估算中，开发者基础是真正的约束条件。收购一个可移植的软件层（如高通收购 Modular）能否缩短 7–10 年的时间，还是只能降低移植成本?
3. 英伟达在十年内两次尝试平台型并购，成功了一次。Arm 交易的终止，对任何考虑大型横向交易的芯片公司有何监管层面的借鉴意义?
4. 对新兴云服务商的股权投资创造了非自用型买方。如今哪些客户群体缺少非自用型融资方，又有谁能扮演这一角色?

生态、市场进入与资本：路线图

第 13 层 · 生态、市场进入与资本 · 约 11 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **下一个节点：**2026-12-01 的 GTC DC 主题演讲，就在本页截止日期之后 [S90047]。
- **2026–2029 年是一份合同分期的日程表。** AMD 为 OpenAI 交付的首个 1 GW 于 2026 年下半年开始，博通的 10 GW 从 2026 年下半年持续到 2029 年，Anthropic 的下一批多吉瓦 TPU 于 2027 年开始，微软的 Maia 自 2027 年起达到多吉瓦规模 [S13506,S174,S655,S90045]。
- **英伟达自身的承诺期限更长。** 对 CoreWeave 的算力兜底承诺持续到 2032-04-13，2026 年 8 月宣布的融资平台仍是有待签署最终协议的谅解备忘录 🟡 [S90067,S12528]。
- **监管机构仍有未结案件。** 中国国家市场监督管理总局（SAMR）于 2025 年 9 月发布初步调查结果，认定英伟达违反了 Mellanox 收购的批准条件；美国司法部（DOJ）于 2024 年启动调查；两者均未在 2026 年公开结案 🔴 [S9505,S9503,S9504]。
- **投资组合如今会影响利润。** 英伟达在 H1 FY2027 确认了 $23.7B 的股权投资净收益，主要来自按市值计价（mark-to-market）；这些收益可能反转 [S90072]。
- **[Q7 · 路线图与变数]** 三件事会改变格局：针对“以投资换配额”的反垄断行动、超大规模云厂商资本开支周期的拐点，以及私有公司股权的减记。

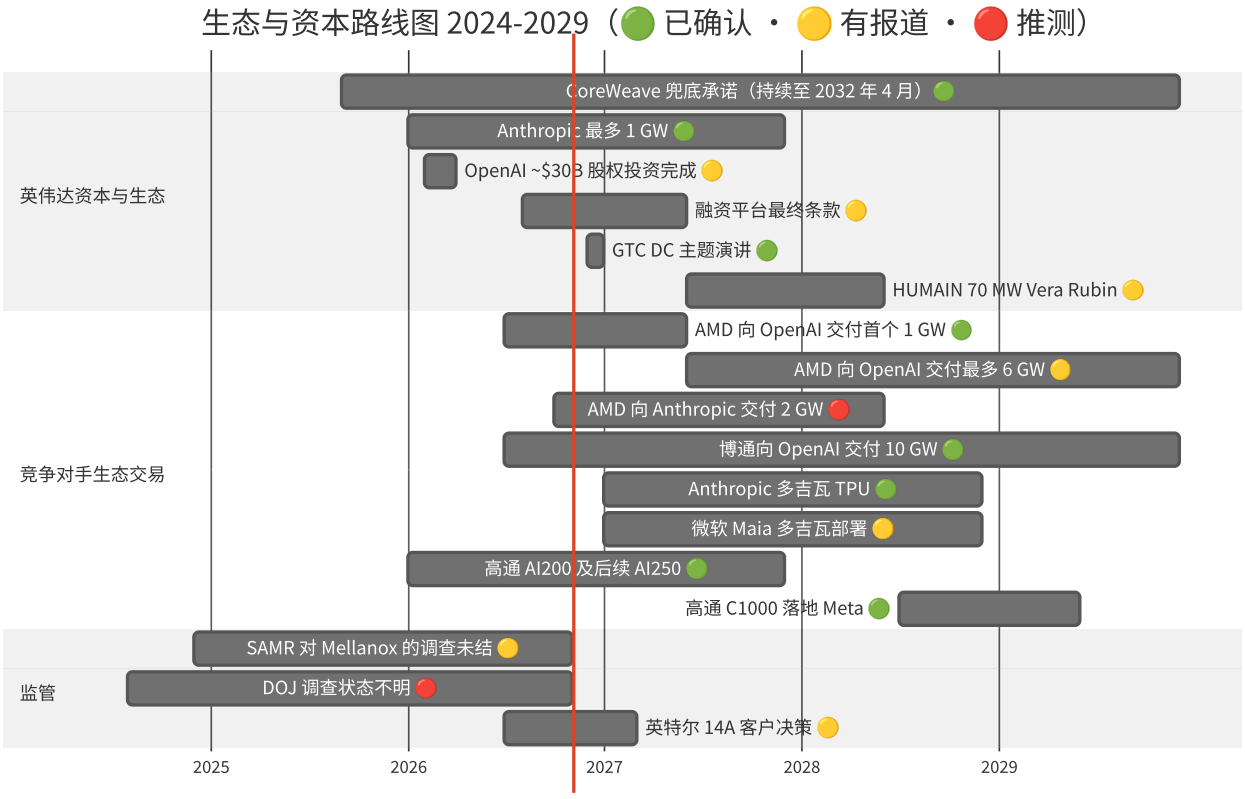

各行来源见下表；OpenAI 股权投资条目：约 ~$30B 的直接投资取代了意向书 [S90015,S13526]。

事项	时间窗口	状态	置信度	来源
GTC DC 主题演讲	2026-12-01	已排期	🟢	S90047

事项	时间窗口	状态	置信度	来源
英伟达–Anthropic 最多 1 GW，最多 $10B	2026 年起	已宣布	🟢	S469
与六家资产管理公司的融资平台（目标 >$500B）	2026 年 8 月起	谅解备忘录	🟡	S12528
HUMAIN 84 MW（~27k 颗 GPU），随后 70 MW Vera Rubin	当前；2027 年年中起	已宣布	🟡	S13516
CoreWeave 兜底承诺，最多 $6.3B	至 2032-04-13	生效中	🟢	S90067
AMD–OpenAI 首个 1 GW 的 MI450，认股权证第 1 批	2026 年下半年	部署中	🟢	S13506,S90020
AMD–Anthropic 最多 $5B，2 GW Helios	2026 年起	已宣布	🟡	S9538
博通–OpenAI 10 GW 定制加速器	2026 年下半年 – 2029 年	已宣布	🟢	S174
Anthropic 多吉瓦 TPU 扩容	2027 年起	已宣布	🟢	S655
高通–Modular	2026-07-29 完成	已完成	🟢	S9511
高通 C1000 落地 Meta	2028 年下半年	已宣布	🟢	S90058
SAMR 对 Mellanox 的调查	2024 年 12 月起	初步调查结果	🟡	S9505

如何在资本层解读路线图

在这里，路线图是一份**义务与期权**的时间表：按吉瓦归属的分期、在算力未售出时触发的兜底承诺、随融资轮次重新定价的股权。对每一项都要问：如果需求放缓，风险由谁承担？

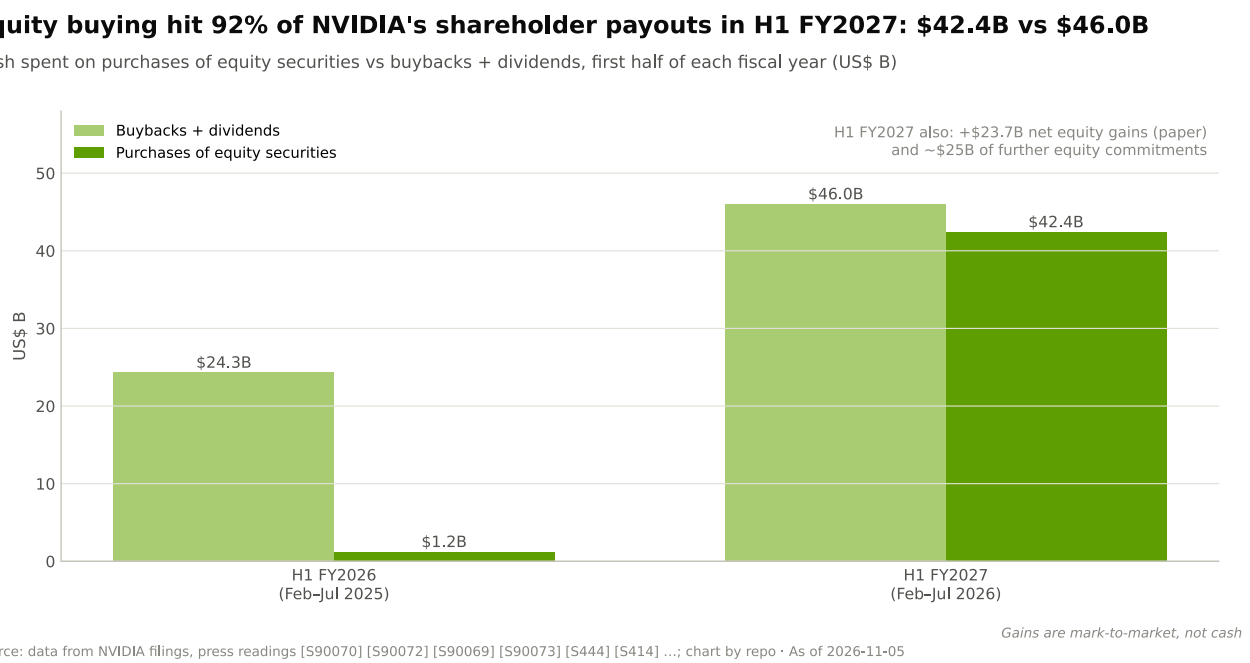

英伟达上半年现金用途对比分组柱状图。H1 FY2026：回购与分红 $24.3B，股权购买 $1.2B（5%）。H1 FY2027：回购与分红 $46.0B，股权购买 $42.4B（92%），以约 $30B 的 OpenAI 股权投资为首。H1 FY2027 股权证券净收益为 $23.7B，大部分未实现，后续股权投资承诺约 $25B。

提示

算例 —— 私有公司股权减记 30% 会怎样。 2026 年 7 月，英伟达持有 $51.2B 的非流通股权 [S90072]。30% 的减记——一次降价融资或一家停滞的实验室就可能引发这种重估——将通过其他收益产生 ~$15.4B 的损失，约为 Q2 FY2027 $59.7B 净利润的 26% [S405]。会很痛，但不致命；更大的风险在于，同样的冲击会波及这些客户的 GPU 订单。

🔧 技术细节：这些事项在财报中的位置

私有公司股权列示为非流通股权证券，按成本计量并根据可观察的价格变动进行调整；上市公司股权（英特尔、诺基亚、Synopsys、CoreWeave）每季度按市值计价 [S90072,S90073]。兜底承诺和多年期云协议列于承诺事项附注中，而非资产负债表：2026 年 7 月有 $29B 的云服务承诺和 $36B 的 AI 云算力协议 [S407]。像 AMD 这样的客户认股权证，通常在各批次很可能归属时作为收入的减项入账（应付客户对价），因此其成本体现在 AMD 报告的利润率中，而非现金中（🔴 本资料库对美国通用会计准则（US GAAP）通行做法的解读）。

[Q7 · 路线图与变数]

1. 针对“以投资换配额”的反垄断行动。 调查人员表明的关切包括：使客户更难更换供应商，以及惩罚未独家使用英伟达的买方 [S9503]。若认定股权投资与配额挂钩，将限制这一打法。SAMR 的罚款可能为上一年度中国销售额的 1% 至 10% [S9505]；参议员也质疑 Groq 授权交易是在规避并购审查 [S13511]。

2. 资本开支周期拐点。 英伟达对 Q3 FY2027 收入的指引为 $108B ± 2%，不含中国数据中心计算业务 [S3]。

> **提示**
>
> **算例 —— 超大规模云厂商暂停采购会削减多少收入。** 在英伟达 Q2 FY2027 $89.0B 的数据中心收入中，超大规模客户贡献了约 ~$48.7B [S90011,S405]。若其在英伟达上的支出削减 20%，每季度将减少 ~$9.7B，接近英伟达指引中从 Q2（$96.2B）到 Q3（$108B）约 ~$11.8B 的全部增量 [S405,S3]。新兴云服务商（neocloud）和主权买方可以起到缓冲作用，但其中许多正是由英伟达提供资金的。

Alphabet, Amazon and Meta first guided ~$505B of 2026 capex, 4.0× their $127B in 2022; guides have since risen to ~$558B

Capex, US$ B per fiscal year; 2026 = first guidance (Jan–Feb 2026); dashed/hollow = outlook or unverified; MSFT FY ends Jun (ex-leases), Oracle May

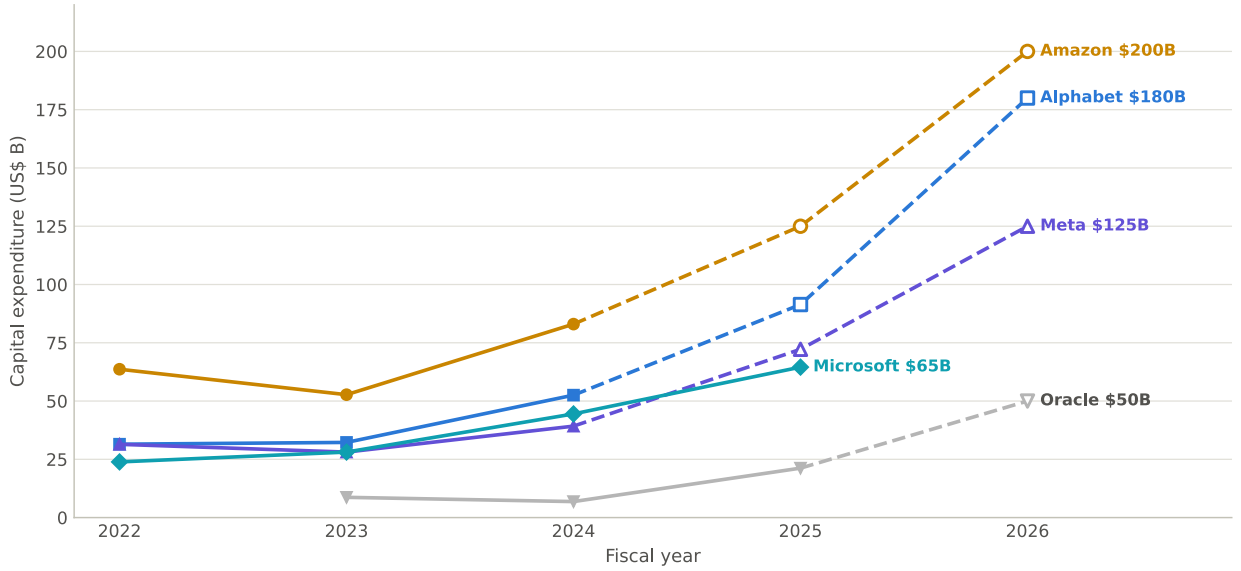

Latest 2026 guide midpoints (Jul–Oct 2026): Big 3 ~$558B

Source: data from company 10-Ks and outlooks [S455] [S460] [S456] [S461] [S457] [S462] …; chart by repo · As of 2026-11-05

2022–2026 年超大规模云厂商资本开支折线图：Alphabet、亚马逊和 Meta 合计从 2022 年的 $127B 增至其最初 2026 年指引的约 $505B（亚马逊约 $200B、Alphabet 中值约 $180B、Meta 中值约 $125B），到 2026 年 10 月已上调至约 $558B；微软在 FY2025 达到 $65B，甲骨文对 FY2026 的指引约为 $50B。

3. 按市值计价损失。 H1 FY2027 $23.7B 的股权投资净收益美化了其他收益；一旦反转，将在客户融资收紧之际冲击利润 [S90072]。

4. 定制芯片兑现。 SemiAnalysis 认为，OpenAI 由博通打造的推理芯片在单位总拥有成本（TCO）性能上可与 Blackwell 竞争 🟡 [S628]。若按时交付，该联盟在每一家前沿实验室中的说服力都会增强。

5. 哪些因素有利于英伟达。 >$500B 融资平台若签署最终协议，将把融资风险转移给第三方 [S12528]；连续 16 个季度超越自身指引（见下图）也有助于赢得融资方的信任。

NVIDIA beat its revenue-guide midpoint 16 quarters running, by +7.1% on average

Actual quarterly revenue vs the guidance midpoint issued the prior quarter, % difference

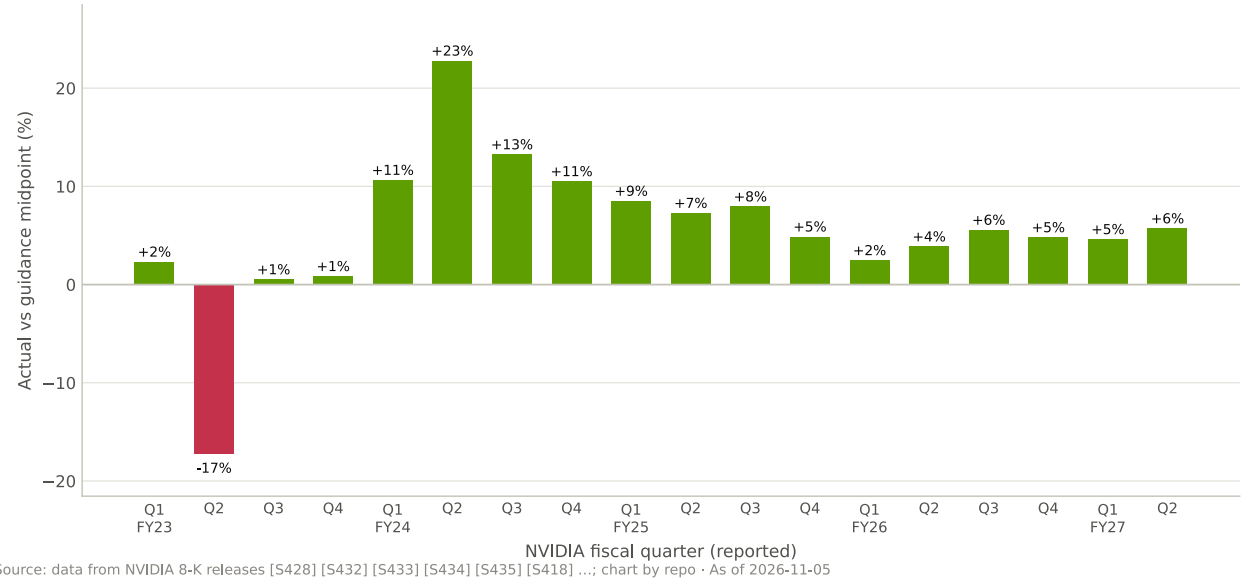

Source: data from NVIDIA 8-K releases [S428] [S432] [S433] [S434] [S435] [S418] …; chart by repo · As of 2026-11-05

> 英伟达 Q1FY23 至 Q2FY27 收入相对自身指引中值的超预期幅度柱状图：Q2 FY2023 游戏业务调整期间低于指引 -17%，随后连续 16 个季度超出指引，平均超出 7.1%，最大一次为 Q2FY24 的 +23%。

需关注的信号	领先指标	对英伟达的影响方向
反垄断	DOJ/FTC 起诉、SAMR 罚款、欧盟就某项授权交易移交审查	⬇ 负面
资本开支周期	超大规模云厂商 2027 年资本开支指引（2027 年 1–2 月）	±
私有股权估值	实验室或新兴云服务商的降价融资；CoreWeave 兜底承诺被动用	⬇ 负面
定制芯片	OpenAI–博通首个吉瓦的时间；Anthropic 2027 年的 TPU 批次	⬇ 负面
融资平台	签署最终协议并完成首批基金募集	⬆ 正面

🎯 企业发展视角

1. 英伟达的哪些承诺（兜底承诺、云协议、股权投资承诺）会被算力买方视为价格底线？这一底线对新进入者的定价是有利还是不利？
2. 如果监管机构限制“以投资换配额”，由政府承担资本的主权合作是否会成为所有厂商的主要市场进入路径？
3. AMD 的认股权证分期自 2026 年下半年起按部署里程碑归属。合作伙伴在与 AMD 共同投入之前，应要求看到哪些按时交付的证据？
4. 如果私有 AI 资产估值重置，哪些资产（光器件供应商、软件团队、已授权知识产权）会变得更便宜、更易收购？又有谁拥有足以出手的资产负债表？

生态、市场进入与资本：价值链与企业发展视角

第 13 层 · 生态、市场进入与资本 · 约 13 分钟阅读 · 最近核实：2026-11-05

⚡ 要点速览

- **英伟达牢牢把握其可控环节中最丰厚的利润率。** 其 Q2 FY2027 毛利率为 75.0%，台积电为 66.4%，为其组装机架的 ODM 估计仅约 ~2–3%；目前只有存储厂商赚得更多（美光 86.8%）[S405,S3538,S332,S3533]。
- **其资本以需求的形式回流。** 英伟达每吉瓦的价值量约 ~$35B（CEO，2025 年 8 月），因此每 GW $10B 的股权投资预付的还不到其销售额的三分之一 [S398,S469]。
- **三种并购结构。** 平台型收购（Mellanox，$6.9B）、软件补强收购（Run:ai ~$700M）以及授权加收购式招聘（Enfabrica >$900M，Groq 据报道 ~$20B）[S464,S476,S475,S90019]。
- **股权投资如今既锁定需求，也锁定供给。** 对英特尔（$5B）、Lumentum 和 Coherent（各 $2B）以及据报道对美满电子（$2B）的股权投资，都附带产能或产品承诺 [S4009,S13529,S90037]。
- **[Q8 · 价值池与并购机会]** 稀缺资产是配额、开发者和团队，而非工厂。英伟达通过授权获取团队，通过股权投资锁定需求，通过预付式股权投资锁定供给；留给其他公司的机会在于可移植软件、主权融资和供应商产能。

Memory makers now out-earn NVIDIA: Micron's gross margin 86.8% vs NVIDIA's 75.0%; ODMs ~2%

Latest margin by company in the AI-rack supply chain, %; hatched = operating margin (gross is higher) or estimate

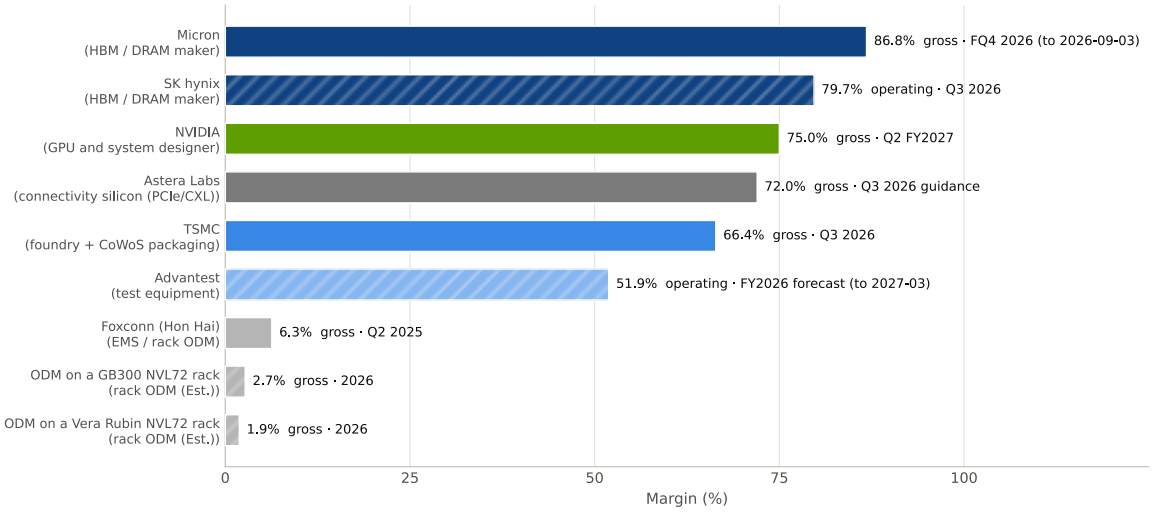

Source: data from company results; ODM = Morgan Stanley Est. [S332] [S3522] [S3521] [S3538] [S3525] [S405] ...; chart by repo · As of 2026-11-05

> 利润率横向柱状图：美光 GAAP 毛利率 86.8%（2026 财年第四季度），SK 海力士营业利润率约 80%（2026 年第三季度），英伟达毛利率 75.0%（Q2 FY2027），Astera Labs 毛利率约 72%（指引），台积电毛利率 66.4%（2026 年第三季度），爱德万测试（Advantest）营业利润率 51.9%（FY2026 预测），富士康毛利率约 6.3%（2025 年第二季度），机架 ODM 在机架上的毛利率估计为 2.7%（GB300 NVL72）和 1.9%（Vera Rubin NVL72）。

谁攫取了价值

参与者	经济特征	英伟达的资本如何触及
英伟达	毛利率 75.0%，营业利润率 ~60%（FY2026）[S405,S1]	现金来源
存储与晶圆代工（SK 海力士、美光、台积电）	利润率 66–87% [S3533,S3538]	预付款及 $279B 的供应承诺 [S407]

参与者	经济特征	英伟达的资本如何触及
光器件与元器件（Lumentum、Coherent）	产能受限	$2B 股权投资加采购承诺 S13529
机架 ODM（富士康等）	公司整体毛利率 ~6%；单机架 ~2–3%（估计） S3522,S332	无需投资
新兴云服务商（CoreWeave、Lambda、Nscale）	高杠杆：2026 年年中 CoreWeave 背负约 ~$35B 债务 S12501	股权投资、兜底承诺、GPU 售后回租 S472,S90067,S483
前沿实验室（OpenAI、Anthropic、xAI）	依靠超大规模股权融资	~$30B、最多 $10B、E 轮股权 S13526,S469,S13039

提示

算例 —— 一个 Vera Rubin NVL72 机架上谁赚多少。 摩根士丹利估计该机架约 ~$7.8M，其中 72 颗 Rubin GPU 约 ~$3.96M S332。仅 GPU 这一项，英伟达 75% 的毛利率就带来约 ~$3.0M 的毛利（示意性计算；它还销售机架中的 CPU、交换机和网卡）。ODM 约 ~1.9% 的机架利润率约为 ~$0.15M（估计）S332。在同一台设备上，英伟达的收益约为组装商的 20 倍。

Operating margin rose from 15% to 60% in ten years as R&D fell to 9% of revenue

GAAP operating margin, net margin and R&D expense as % of revenue, by fiscal year

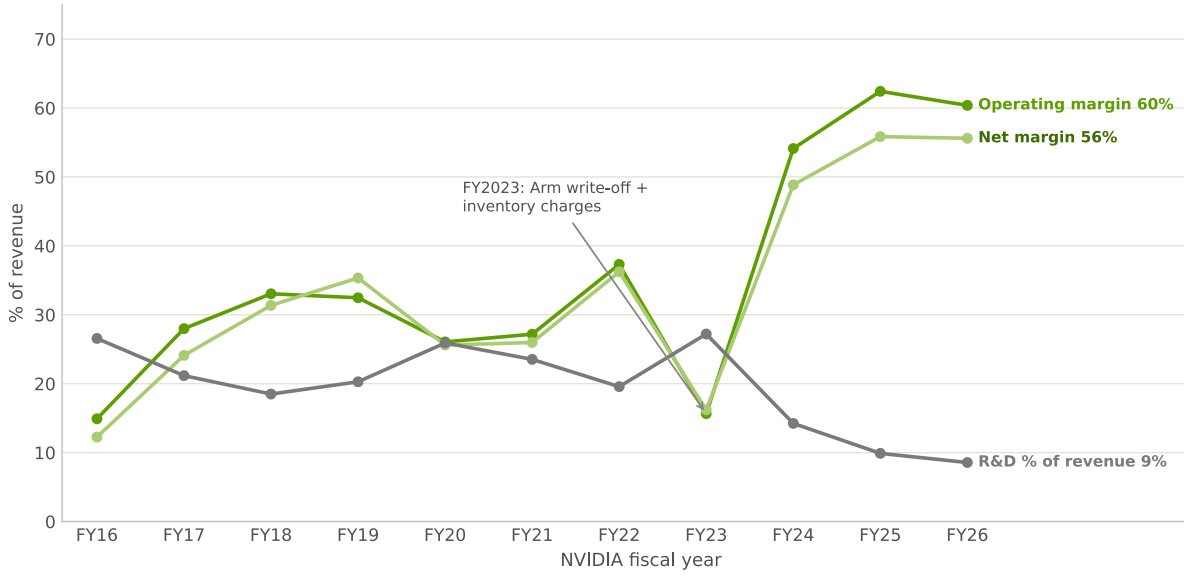

Source: data from NVIDIA 10-K filings [S400] [S2] [S418] [S417] [S416] [S1] ...; chart by repo · As of 2026-11-05

英伟达 FY2016–FY2026 利润率折线图：营业利润率从 15% 升至 60%（FY2025 峰值 62%），FY2023 曾回落至 16%；净利率达到 56%；研发支出占收入比重从 27% 降至 9%。

英伟达的资本流向何处，谁从中受益

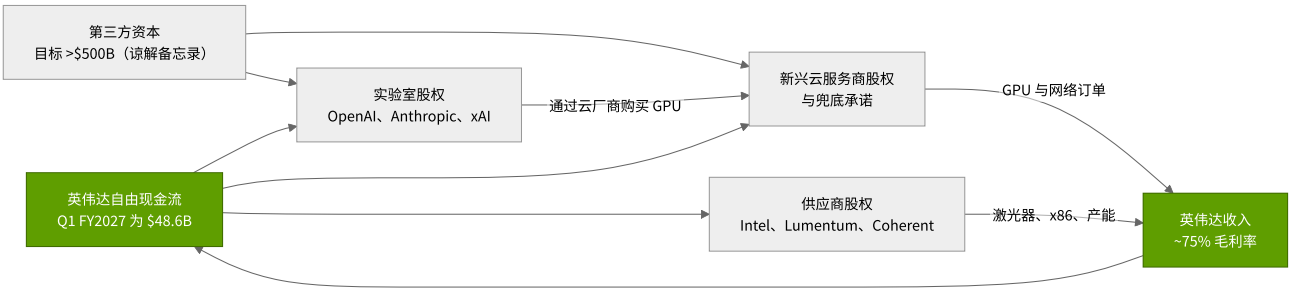

这一闭环正是循环融资之争的核心：英伟达投出的一美元股权，可能以 GPU 收入的形式回流。受益者包括：无法以同样低成本融资的买方、需要资金扩产的供应商，以及 2026 年 8 月融资平台引入的资产管理公司 [S12528]。风险在于供应商融资（vendor financing）：一旦终端需求走弱，英伟达将同时持有应收账款和股权。

> **提示**
>
> **算例 —— 一个吉瓦的投资回收。** 英伟达承诺向 Anthropic 投资最多 $10B，同时配套最多 1 GW 的英伟达系统 [S469]。按每 GW ~$35B 的英伟达价值量 [S398] 和 ~75% 的毛利率 [S405] 计算，该吉瓦若建成，可带来 ~$26B 的毛利，约为投资额的 2.6 倍。这笔股权投资本质上是获客成本，只有在吉瓦级算力真正落地时才算便宜。

NVIDIA pledged up to ~$45B to five customers planning ~19 GW of compute

x: NVIDIA equity committed (US$ B, log); y: customer's announced compute plan (GW); bubble area ∝ NVIDIA US$ B per GW

LOG SCALE

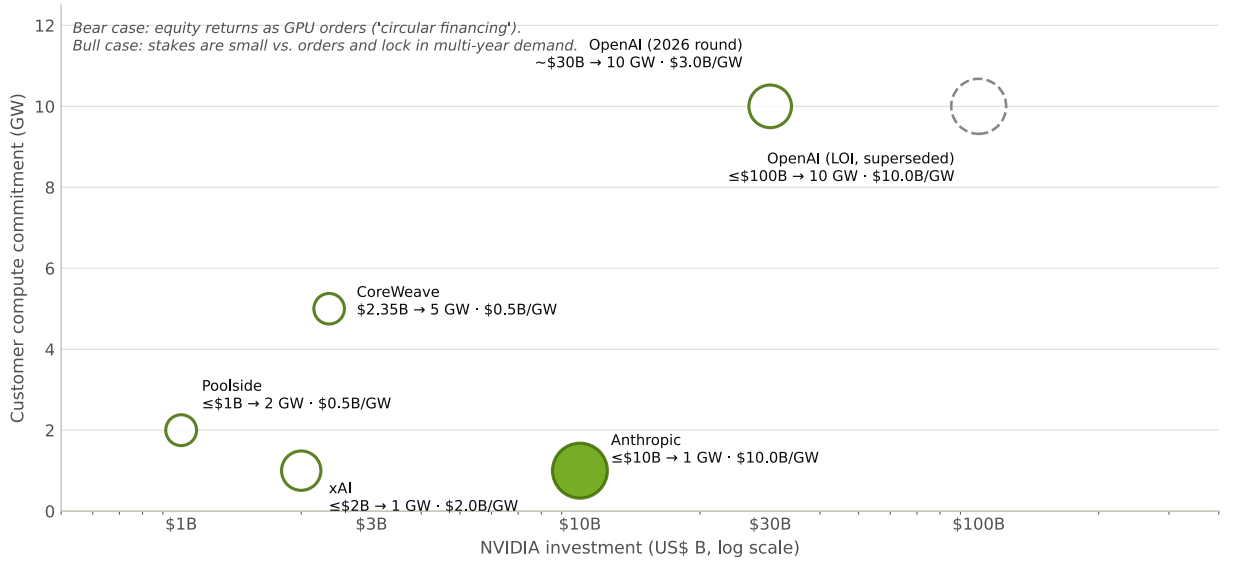

Hollow = reported; dashed = superseded

Source: data from company releases; press [S467] [S480] [S469] [S472] [S473] [S483]; chart by repo · As of 2026-11-05

英伟达对客户投资的气泡图：OpenAI（2026 年约 $30B，此前为与 10 GW 挂钩的最多 $100B 意向书）、Anthropic（最多 $10B，最多 1 GW）、CoreWeave（$2.35B 股权，>5 GW 规划）、xAI（最多 $2B，~1 GW）和 Poolside（最多 $1B，2 GW）。合计约 $45B，对应 ~19 GW，构成循环融资之争的核心。

并购打法

交易结构	示例（价格）	完成所需时间	监管敞口	英伟达获得了什么
平台型收购	Mellanox $6.9B；Arm $40B（失败） [S464,S465]	13 个月；17 个月后终止 [S466]	多国全面审查	一个新的层级（网络）
软件补强收购	Run:ai ~$700M；Deci、OctoAI、CentML、Lepton；SchedMD [S476,S479,S13041]	数周至 8 个月	Run:ai 经历欧盟审查	编排与推理团队
授权加收购式招聘	Enfabrica >$900M；Groq ~$20B 🟡 [S475,S90019]	数日	政治层面审视，未发现申报 [S13511]	创始人、工程师、非独占知识产权
对客户的股权投资	OpenAI ~$30B、Anthropic 最多 $10B、CoreWeave $2B [S13526,S469,S472]	随融资轮交割	涉及配额的反垄断关切 [S9503]	需求与设计参与
对供应商或合作伙伴的股权投资	英特尔 $5B、Synopsys $2B、诺基亚 $1B、Lumentum 和 Coherent 各 $2B [S4009,S471,S470,S13529]	数周至 3 个月	常规审批（英特尔交易于 2025 年 12 月获批）	产能、协同设计、新市场

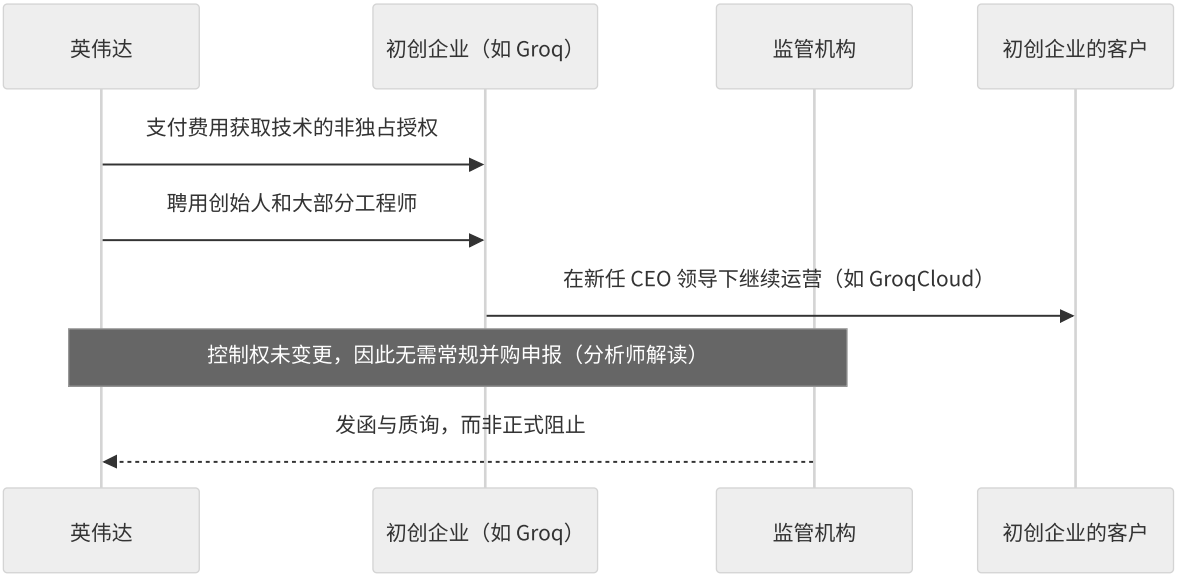

提示

算例 —— 速度值多少钱。 Groq 授权交易在数日内完成；Run:ai 则耗时八个月，其中包括欧盟审查[S474,S476]。对一笔 ~$20B 的交易，按假设的 10% 资本成本计算，八个月的时间价值约为 ~$1.3B（🔴 本资料库测算），尚未计入交易被阻止的风险。

🔧 技术细节："授权加收购式招聘"为何可行，以及其局限

美国的并购申报覆盖超过规模门槛的有表决权股份或资产收购；而非独占授权加上雇佣要约既不转移控制权，也不转移独占性资产。这正是分析师认为 Groq 交易实质上是一次收购、却在未经公开审查的情况下完成交割的原因[S90018,S90019]。其局限在于：授权方保留向他方授权的权利；关键员工未必全部转入；且监管机构已释放信号，将审视此类结构——正如参议员在 Groq 交易后所敦促的那样[S13511]。

值得了解的私有公司（仅基于公开信息）

公司	业务	最近一次公开融资（据记录）	与英伟达的关联	为何重要
Mistral AI	欧洲开放权重模型；Mistral Compute 云	€1.7B C 轮，2025 年 9 月，由 ASML 领投[S481,S13030]	投资方；18,000 颗 Grace Blackwell[S13011]	欧洲主权 AI 的锚点
Thinking Machines Lab	前沿实验室（前 OpenAI CTO 创立）	$2B 种子轮，2025 年[S481]	投资方	新的吉瓦级买方
Reflection AI	美国开放权重前沿模型	英伟达领投约 ~$2B 融资，2025 年 10 月[S481]	领投方	在英伟达平台上的开放模型需求
Poolside	编程模型；2 GW 的 Project Horizon	在约 ~$2B 融资中英伟达最多出资 $1B[S483]	投资方	缩微版的"以资本换产能"
Crusoe	能源优先的 AI 数据中心开发商	$3.9B F 轮，估值 $30.9B（2026 年 9 月，数据追踪平台）[S12522]	投资方[S481]	为实验室建设吉瓦级站点
Lambda	GPU 云	约 ~$4B IPO 前融资（2026 年 10 月）[S12521]	投资方；约 ~$1.5B 的 GPU 售后回租[S483]	一家英伟达既投资、又向其租用算力的新兴云服务商
Groq	授权交易后的 GroqCloud 推理服务	据报道英伟达授权费 ~$20B（2025 年 12 月）[S474,S90019]	被授权方及团队聘用	授权结构的试金石
Ayar Labs	光 I/O 芯粒（chiplet）	$155M D 轮（2024 年 12 月）[S482]	投资方（AMD、英特尔亦参投）	面向纵向扩展互连架构的光学方案

标注 [S481]–[S483] 的融资数据部分凭记忆录入（见核实队列），仅供参考。新兴云服务商在第 12 层中有深入讨论。

AI-chip start-up values span ~$1.6B–$40B; Groq's ~$20B exit went to NVIDIA

Latest disclosed valuation or deal value, US$ billions (basis varies: see labels)

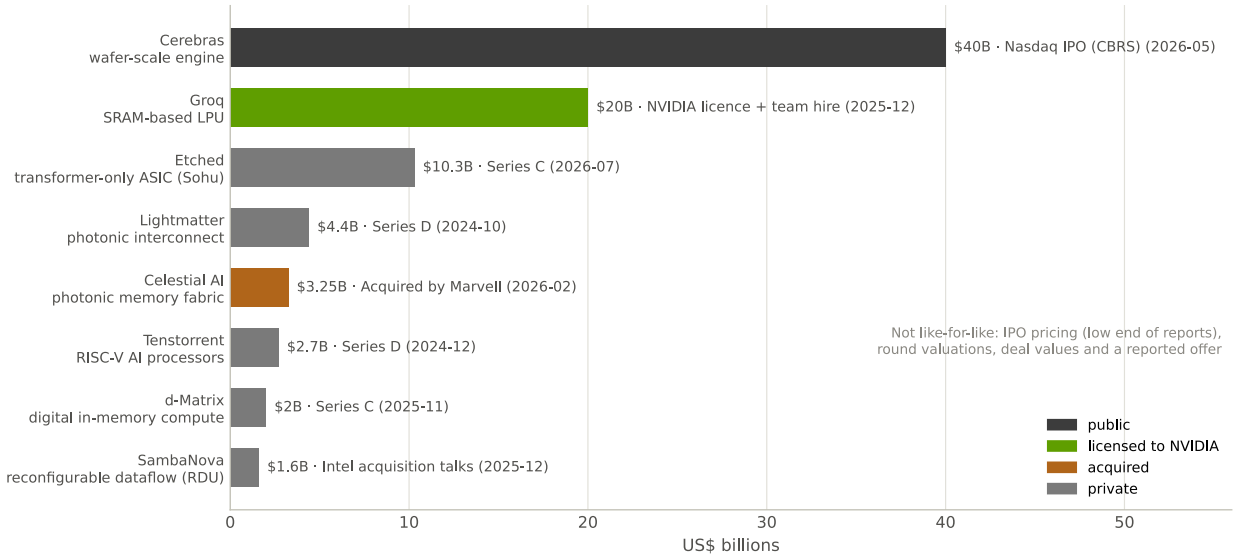

Source: data from company announcements, IPO and press reports [S2512] [S2511] [S2509] [S2513] [S2510] [S2507] ...; chart by repo · As of 2026-11-05

> AI 芯片初创企业估值横向柱状图：Cerebras 在 2026 年 5 月 IPO 时约 $40B（有报道称完全稀释后最高约 ~$56B）；Groq 与英伟达约 ~$20B 的授权与团队交易（2025 年 12 月）；Etched $10.3B（C 轮，2026 年 7 月，有报道）；Lightmatter $4.4B（2024 年 10 月）；Celestial AI 获美满电子 $3.25B 预付对价（2026 年 2 月）；Tenstorrent 投后估值约 ~$2.7B（2024 年 12 月）；d-Matrix $2.0B（2025 年 11 月）；SambaNova 在停滞的英特尔谈判中约 ~$1.6B，而 2021 年为 $5B。

[Q8 · 价值池与并购机会] 这里的一切都在守护英伟达 ~75% 的利润率，每种稀缺资产各用一种工具：平台型并购补齐缺失的层级，补强收购和授权获取团队，对客户的股权投资锁定配额，对供应商的股权投资锁定产能。留给他人的机会，是英伟达无法在不引发利益冲突的情况下占据的领域：可移植软件（高通–Modular [S9511]）、多供应商的主权项目（HUMAIN 同时向英伟达、AMD 和高通采购 [S13005,S13517,S90030]），以及不依赖单一厂商资产负债表的融资结构。

🎯 企业发展视角

1. **授权加收购式招聘：**哪些推理、互连或编译器团队可以通过这种方式获得？买方应如何为监管机构开始将这种结构视同并购的风险定价？
2. **对客户的战略性股权投资：**英伟达的股权投资只有在算力真正建成时，才能按每吉瓦毛利收回约 ~2.6 倍。规模较小的厂商需要怎样的回报？应采用股权、认股权证还是预付算力的形式？
3. **主权合作：**当主权基金提供资本时，芯片厂商是否仍需要强大的资产负债表，还是只需要可信的路线图和本地合作伙伴？
4. **供应商产能：**英伟达如今用股权购买光器件产能。哪些元器件（激光器、HBM、基板）稀缺到股权投资比长期协议更有效？