# 英伟达全栈深度研究

NVIDIA 如何在 AI 训练与推理中变得不可或缺 —— 逐层解析

## 卷四 · 跨层专题

第 14–19 章：经济学、竞争格局、发展史、路线图、看空情景、对高通的启示

简体中文参考译文 · 仅供参考，如有出入以英文原文为准
数据与图表截至 2026-11-05 · 仅使用公开信息
英文原版：github.com/FrankHuang94/nvidia_deep_dive_claude

## 阅读说明

本册为英文研究资料库《NVIDIA Full-Stack Deep Dive》的**简体中文参考译文**，仅供参考；如与英文原文存在任何出入，以英文原文为准。全书共五册，可分册打印。

- **图表**：数据图表与架构图保留英文原版（由仓库中的 CSV 数据生成）；每张图下方的灰色文字为中文图注，概括该图的结论与关键数字。Mermaid 示意图已译为中文。
- **引用**：正文中的灰色上标（如 [S2031]）为来源编号，完整书目见卷五附录“参考文献”（保留英文原题）。
- **可信度标记**：🟢 已确认（公司官方公布）· 🟡 有报道（可信媒体或分析机构）· 🔴 推测（推断、传闻或本资料库的分析）；“估计”表示估算值。
- **对比标记**：🟩 领先 · 🟨 持平 · 🟥 落后 · 🟦 路线不同。
- **三层阅读深度**：每页以“⚡ 要点速览”开篇；正文“原理解析”含“算例”；虚线框为“🔧 技术细节”；页末“🎯 企业发展视角”列出供企业发展团队思考的问题。
- **时效**：数据截至 2026-11-05；英伟达 2027 财年第三季度财报（2026-11-17）与 GTC DC 大会（2026-12-01）晚于此日期。
- **公开信息**：本资料库仅使用公开信息；涉及高通的内容均以问题与选项的形式呈现，不构成建议。

# 目录

**14 —— 训练与推理经济学** 4

**15 —— 竞争格局** 30

AMD —— 商用挑战者 46

定制 ASIC 设计服务商：博通、美满电子、世芯、创意电子与联发科 57

推理芯片初创公司：Cerebras、Groq、SambaNova、Tenstorrent、d-Matrix、Etched 及其他 66

高通：第二次进军数据中心，对照英伟达的全景图 75

中国：华为昇腾、寒武纪与受保护的国内市场 83

谷歌 TPU —— 可信的替代方案，如今已对外销售 92

AWS Trainium —— 最大云平台内部的成本优势 102

微软 Maia —— 为 Copilot 打造的推理引擎 109

Meta MTIA —— 英伟达最大自建型客户的自研对冲 116

英特尔：既是竞争对手，也是供应商和合作伙伴 123

**16 —— 英伟达如何建成今日格局（时间线）** 130

**17 —— 路线图 2025–2028** 148

**18 —— 弱点与看空情景** 169

**19 —— 对高通的启示** 197

# 14 —— 训练与推理经济学

跨层专题 14 · 总拥有成本（TCO）模型、每 token 成本与每兆瓦 token 产出 · 约 35 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **训练是一项资本项目；推理是一座工厂。** 一次训练运行只为模型付费一次。推理则按小时出售 token（词元），对应某一速度档位，并取决于利用率。这使推理成为持续性且竞争更激烈的支出：英伟达（NVIDIA）最近一次给出的口径（2024 年年中）是推理占数据中心收入的 40% 以上 [S11011]（P1、P2）。
- **拥有一块 GB300 GPU 的全口径成本约为每装机小时 $2.46（估计）。** 其中包括一台 $3.99M 的机架 [S332]，外加网络、设施、电力与运维，按 8% 资金成本、六年期融资 [S14000]。SemiAnalysis 的测算为 $2.31 [S622]。资本性费用占成本的 ~70%；电费仅占 ~6%。
- **在聊天速度下，GB300 NVL72 产出的 token 是所有已出货系统中最便宜的：** 在每用户 50 tokens/s 下，每百万 DeepSeek-R1 token 成本 ~$0.16（估计，P10–P90 区间 $0.13–0.23）[S14000,S621]。这比 TPU v7 低 ~3.4 倍，比 MI355X 低 ~6 倍（🔴 TPU 为模型推算）。原因在于吞吐量：在该速度下，其 72-GPU NVLink 域输出的 token 是 B200 的 ~4.5 倍。
- **英伟达 ~75% 的毛利率 [S405] 仅占 GB300 每 token 成本的 ~24%**（若计入相应的融资成本则为 ~32%）（估计）[S14000]。不同平台的每兆瓦 token 产出相差最多 ~30 倍，因此吞吐量的影响远大于毛利率。在每用户 50 tokens/s 下，即便免费获得 MI355X、TPU v7 或 Trainium3，其 token 成本仍高于付费购买的 GB300（🔴 本资料库模型）。
- **领先是有条件的。** 在每用户 100 tokens/s 下，GB300（~$1.74/M）与 TPU v7（$1.46–1.72）和 Trainium3（$1.77）基本持平（🔴 模型推算）。仅推测解码（speculative decoding）一项就可使实测成本变动 2–20 倍 [S621,S624]。要在该档位追平谷歌（Google）内部的 TPU 成本，GB300 需降价 ~20%，这将使英伟达毛利率降至 ~66%（🔴）。
- **训练对英伟达的有利程度不及推理。** 在同等效率下，一次 $10^{27}$ FLOP 的训练运行在 GB300 上成本 ~$515M，在 TPU v7 上为 ~$293M（估计）[S14000,S31007]。英伟达在训练上的卖点是速度与实际交付的利用率：Vera Rubin 用 100,000 块 GPU ~26 天即可完成（🔴）。
- **看空观点：** 利用率、使用寿命和租赁价格对每 token 成本的影响大于芯片价格。H100 租金较 2023 年峰值下跌 ~75%，随后在 2026 年反弹 ~38% [S393,S12516]。若将 GB300 的寿命从六年缩短为四年，每个有效使用小时的成本将从 $3.51 升至 $4.49，逼近其 ~$5.00 的租赁价格（估计）[S622]。

**Est.: at 50 tok/s/user a GB300 token costs ~$0.16/M, 3.4× below TPU v7, 6× below MI355X**

Owner cost per million total tokens, US$ (log scale) · bar = base case, whisker = Monte Carlo P10–P90 · hatched = modelled throughput LOG SCALE

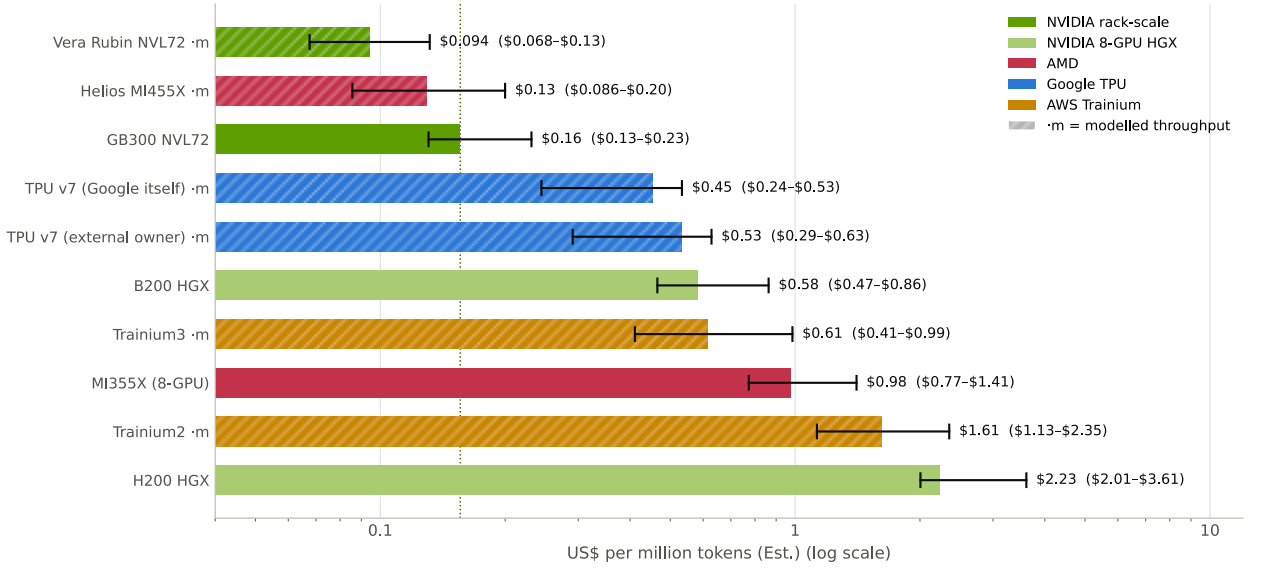


*Est.: repo TCO model (scripts/tco); hatched = modelled throughput*

Source: data from repo TCO model on InferenceX throughput [S14000] [S621] [S622] [S332] [S625] [S626] ...; chart by repo · As of 2026-11-05

对数刻度水平条形图：每用户 50 tokens/s 下每百万 DeepSeek-R1 token 的估计所有者成本，基准情景及 P10 至 P90 区间：Vera Rubin NVL72 $0.094（$0.068–$0.13），模型推算；Helios MI455X $0.129（$0.086–$0.20），模型推算；GB300 NVL72 $0.156（$0.13–$0.23）；TPU v7（谷歌自用）$0.452（$0.24–$0.53），模型推算；TPU v7（外部所有者）$0.532（$0.29–$0.63），模型推算；B200 HGX $0.583（$0.47–$0.86）；Trainium3 $0.615（$0.41–$0.99），模型推算；MI355X（8-GPU）$0.978（$0.77–$1.41）；Trainium2 $1.612（$1.13–$2.35），模型推算；H200 HGX $2.233（$2.01–$3.61）。在该运行点上，英伟达机架级系统领先；在每用户 100 tokens/s 下，TPU 与 Trainium3 的估计值与 GB300 持平。

**重要**

**模型输出的所有数字均为估计值（标注“估计”）。** 吞吐量仅对 H200、B200、GB300 和 MI355X 为实测值（SemiAnalysis InferenceX）。Vera Rubin、AMD Helios、谷歌 TPU v7 和 AWS Trainium 均基于锚点与乘数**模型推算**，并标注 🔴。AMD、谷歌和 AWS 系统的价格均未公开。诚实的输出应是区间，而非点估计。模型、输入与输出见 `scripts/tco/`。

## 1. 同一芯片上的两门生意：训练与推理的经济学为何不同

不妨以石油公司作比。勘探是一项资本项目：一次性投入、时间紧迫，回报是一座油藏。炼油则是一座工厂：装置每小时都在运转，利润是每桶售价减去每桶成本。训练与推理使用同样的机架，但它们恰恰是这两门生意。

**训练**是一项庞大的同步作业（P1）。总计算量由模型和数据决定，约为 6 × 参数量 × token 数。Meta 的 Llama 3.1 405B 需要 $3.8 \times 10^{25}$ FLOPs [S34006] 和 30.84M H100 GPU 小时 [S31002]。Epoch AI 估计 Grok 4 约需 ~$5 \times 10^{26}$ FLOPs，合 ~246M H100 等效小时（估计）[S31008]。前沿算力每年增长 ~4–5 倍 [S31007]。买方关心的是每*有效* FLOP 的成本和完成训练所需的天数。有效 FLOPs 取决于 MFU（Llama 3 为 38–41%）以及能否扛过故障（54 天内发生 419 次意外中断）[S34006]。产出是一个模型，只需付费一次。

**推理**是数以百万计的小型独立请求（P2）。每个请求都包含计算受限的预填充（prefill）和内存受限的解码（decode）。服务器需沿着帕累托前沿在每用户速度（交互速度）与总吞吐量之间权衡。买方关心的是在指定运行点下的每百万 token 成本，以及能售出多少小时（利用率）。产出是源源不断的 token，且需求呈复利增长：谷歌的月度 token 量在 18 个月内增长了 ~134 倍 [S32018,S32020]。

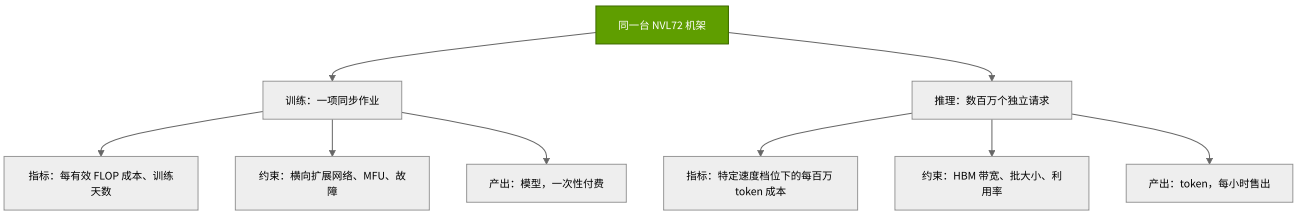


| 维度 | 训练 | 推理 |
|---|---|---|
| 价值单位 | 训练好的模型（一项资产） | 一百万 token（一种产品） |
| 成本驱动因素 | FLOPs ÷（峰值 × MFU × 有效产出率（goodput）） | 所有者每小时成本 ÷ 每小时 token 数 |
| 约束因素 | 横向扩展网络、可靠性、MFU | HBM 带宽、KV 缓存、批大小、利用率 |
| 买方优化目标 | 训练时长与每有效 FLOP 成本 | 特定延迟档位下的每 token 成本；每兆瓦 token 产出 |
| 可分割性 | 一项作业需同时占用整个集群 | 请求可发往任何空闲芯片 |
| 竞争者多寡 | 少：需要能在 10,000+ 芯片规模上运行的成熟软件 | 多：TPU、Trainium、AMD、推理 ASIC |

最后一行才是商业要点。一项训练作业若因网络薄弱或集合通信库存在缺陷而停滞，整个集群都会被浪费，因此买方愿为经过验证的技术栈付费。推理则可拆分到任何能以合适速度服务该模型的硬件上，因此它是挑战者最先发起进攻的领域（第 11 层）。

> **提示**
>
> **算例 —— 训练运行只付一次，推理集群年年要付。** 下文模型对一次假设的 $10^{27}$-FLOP 训练运行在 GB300 NVL72 上的定价为 ~$515M（估计）[S14000]。一个 100 MW 的 GB300 推理站点（~41,000 块 GPU）每年的持有与运营成本为 ~$0.88B，在其六年寿命内年年如此（估计）[S14000]。一次前沿训练运行约相当于一个中型推理站点一年成本的一半，及其六年总成本的十分之一。**结论：** 一旦模型大规模部署，持续性的推理支出将远超一次性的训练支出，而每 token 成本正是买方施压最狠的地方。

> **🔧 技术细节：为何运行点决定一切**
>
> 解码时每生成一个新 token，都要从高带宽内存（HBM）读取全部激活权重。服务器将这次读取摊销到一批用户上，因此批越大，每块 GPU 产出的 token 越多，但每用户获得 token 的速度越慢。混合专家模型（MoE）又增加了一层变化：其专家可分布在多块 GPU 上（宽专家并行），从而腾出内存以支持更大的批，但需要高速的全交换（all-to-all）链路。NVL72 机架可在单个 72-GPU NVLink 域内完成这一点；8-GPU 服务器则做不到。这就是为什么根据 InferenceX 数据，在每用户 50 tokens/s 下，GB200 NVL72 的 DeepSeek-R1 吞吐量是 B200 的 ~3.3 倍 [S621]，而在每用户 100 tokens/s、批很小时，差距收窄甚至反转。参见为何域规模至关重要。

## 2. 成本栈：一个加速器小时对所有者而言的成本

模型对每个平台只问一个问题：一个已装机加速器小时的全口径所有者成本是多少？这一所有者 TCO 包含七项。四项为资本性：加速器系统、计入其售价的供应商毛利、横向扩展网络与存储，以及资本成本。三项为运营性：设施资本开支（建筑外壳、电气设备、冷却）、电费与运维。资本通过资本回收系数转化为每年等额的费用，即类似按揭的还款额，在资产的使用寿命内偿还资产本身及其融资成本。除以小时数得到每小时美元成本；除以 token 数得到每百万 token 美元成本；将 token 数除以设施兆瓦数，则得到每兆瓦 token 产出。

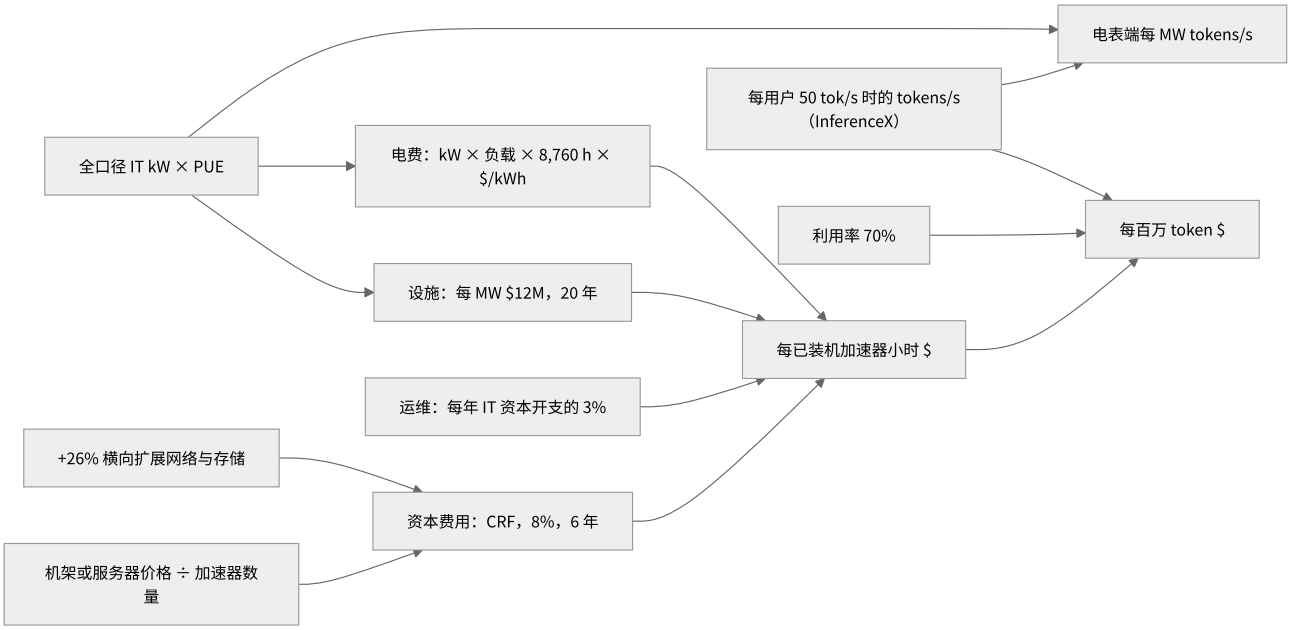


全局假设如下。每一项都是 `data/x14_tco_scenarios.csv` 中的一行，附有来源、置信度标签以及敏感性分析所用的高低区间。

| 假设 | 基准值 | 测试区间 | 依据 |
|---|---|---|---|
| 已装机小时利用率 | 70% | 40–90% | 阿里巴巴将分配率从 68% 提升至 93% S12015；Meta 为 ~89%（11% 为热备） S27010 |
| 电价 | $0.081/kWh | $0.05–0.10 | 2024 年美国工业平均电价 S389；购电协议（PPA）报价 S390 |
| PUE | 1.15 | 1.09–1.40 | 新建液冷机房；谷歌全机队 1.09 S388；行业 ~1.54 S8007 |
| 资本成本 | 8% | 0–12% | 超大规模云厂商与高杠杆新兴云服务商（neocloud）之对比（CoreWeave 的利息负担） S12501 |
| IT 设备使用寿命 | 6 年 | 4–7 | 微软（Microsoft）、Alphabet、CoreWeave 的会计政策 S382,S383,S386 |
| 设施资本开支 | 每 MW $12M | $6.6–13M | 每 GW $11–13B（CS7） S6025；摩根士丹利已撤回的 100 MW 模型 S357 |
| 网络与存储 | 0.26 × 系统价格 | 0.20–0.32 | SemiAnalysis 的 GB200 全口径成本与机架价格之比 S324；AMCompute S6026 |
| 运维 | 每年 IT 资本开支的 3% | 2–5% | 本资料库假设 🔴 S14000 |
| 参考工作负载 | DeepSeek-R1-0528，1k 输入 / 1k 输出，每用户 50 tokens/s | 35–100 | InferenceX 前沿，未使用推测解码 S621 |

**提示**

**算例 —— 拆解一个 GB300 GPU 小时。** 摩根士丹利估计一台 GB300 NVL72 机架为 $3.99M S332，即每块 GPU $55.4K。加上 26% 的横向扩展网络与存储 S324：$69.8K。按 8%、六年计算，资本回收系数为 0.216，因此资本成本为每年 $15.1K，其中 $11.6K 为直线折旧，$3.5K 为融资成本。每块 GPU 全口径功耗 2.12 kW S622，按 PUE 1.15 折算到电表端为 2.44 kW。设施按每 MW $12M 计为每块 GPU $29.3K，按 20 年摊销即每年 $3.0K。电费为 2.44 kW × 0.79 平均负载 × 8,760 h × $0.081 = $1.4K。运维再加 $2.1K。合计**每年 $21.5K，即每装机小时 $2.46**（估计） S14000。SemiAnalysis 的所有者 TCO 为 $2.31 S622。**结论：** 第 12 层中每小时 $1.50 的底价仅包括折旧与电力。加上融资（+$0.40）、设施（+$0.34）、运维（+$0.24）以及小幅的电力调整后，升至 $2.46。

**Est.: a GB300 NVL72 token costs ~$0.16/M; NVIDIA's margin is ~24%, electricity only ~6%**

Owner cost per million total tokens, DeepSeek-R1 1k/1k at 50 tok/s/user, 70% utilization, 6-yr life, 8% cost of capital, $0.081/kWh, PUE 1.15

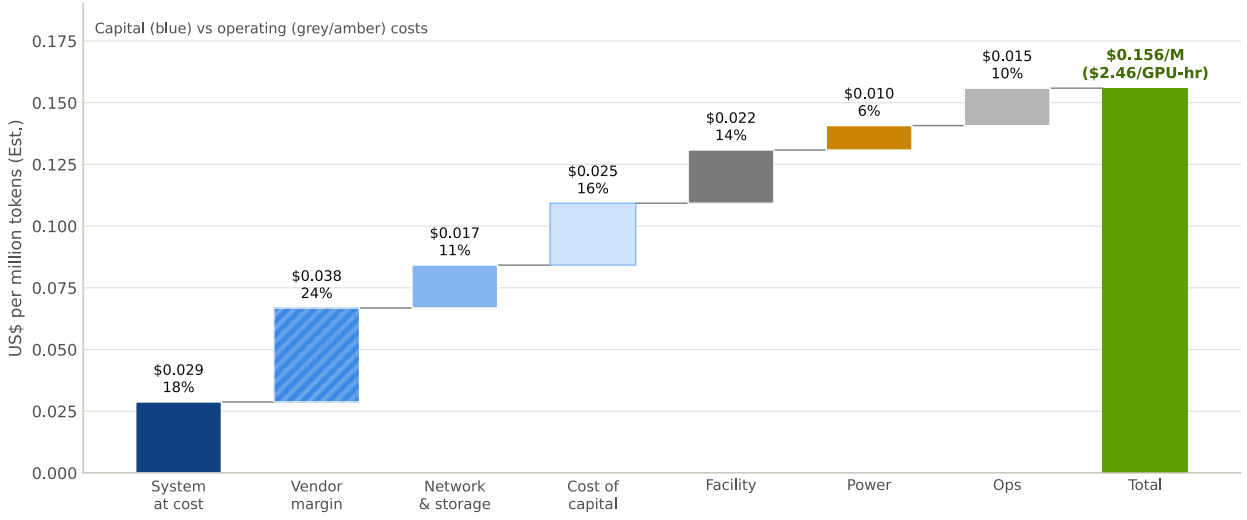


*Est.: repo TCO model (scripts/tco); hatched = vendor gross margin inside the price*

Source: data from repo TCO model on InferenceX throughput and analyst rack prices [S14000] [S621] [S622] [S332] [S625] [S626] …; chart by repo · As of 2026-11-05

> 瀑布图：拆解 GB300 NVL72 每百万 token 约 $0.156 的估计成本：按英伟达及供应商成本计的机架硬件 $0.029，计入价格的英伟达毛利 $0.038（24%），横向扩展网络与存储 $0.017，资本成本 $0.025，设施 $0.022，电费 $0.010（6%），运维 $0.015。资本性项目占总额的 70%；每个 GPU 小时的装机成本约为 $2.46。

在 70% 利用率和每 GPU 6,261 tokens/s [S621] 的条件下，一块 GB300 GPU 每年产出 ~138 billion（约 1,380 亿）个 token。$21.5K ÷ 138 billion = **每百万 token $0.156**。瀑布图将其拆分为七项。有两点值得注意：电费是最小的一项，仅占 ~6%，因此“廉价电力”是选址优势，而非每 token 成本优势；英伟达的毛利（图中阴影条）占成本的 ~24%。

机架价格本身存在不确定性。已公开的 GB300 估计在 $3.99M 至 $5.0M 之间，媒体报价最高达 $6.5M；Vera Rubin 的估计则在 $5.0M 至 $9.1M 之间 [S332,S328,S327,S333]。本模型以摩根士丹利自下而上的测算为基准，与第 08 层和第 12 层保持一致，并对其余数值进行测试。

**NVL72 rack estimates: $2.8–3.9M GB200, $4–6.5M GB300, $5–9.1M Vera Rubin**

Each published estimate of price per rack, US$ M · ◆ = analyst/BOM estimate, ○ = end of a quoted media range · all Est.

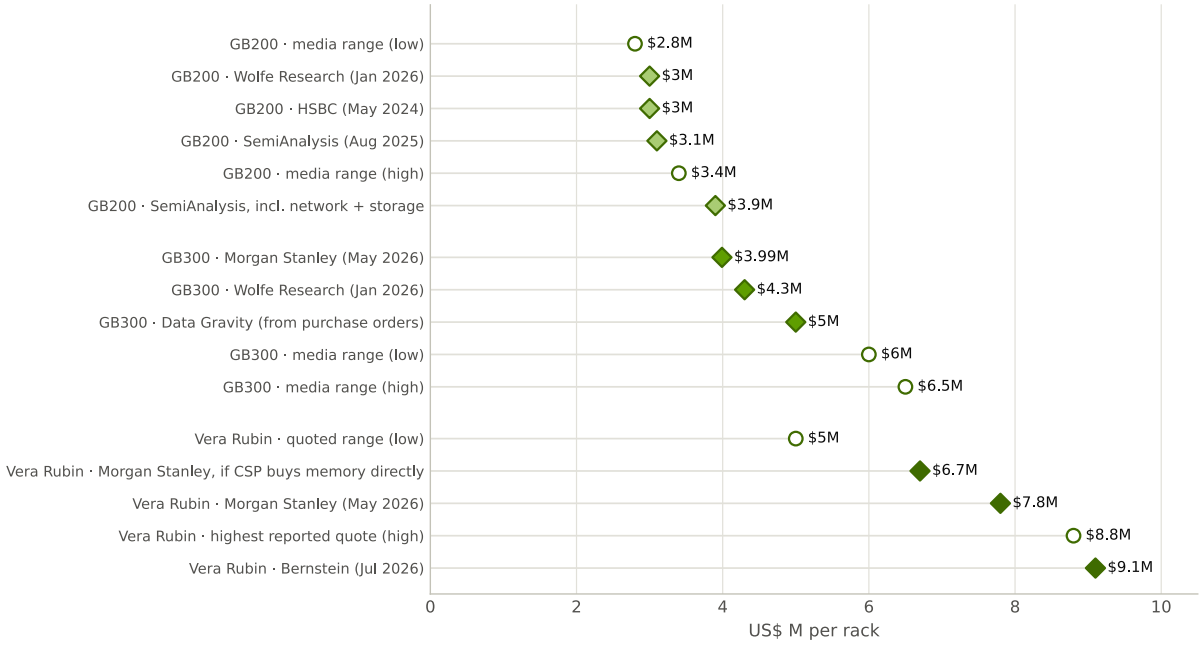


Source: data from HSBC, SemiAnalysis, Wolfe, Morgan Stanley, Bernstein, press [S326] [S324] [S325] [S327] [S332] [S328] …; chart by repo · As of 2026-11-05

NVL72 机架价格估计点图。GB200 NVL72：含网络与存储 $2.8M 至 $3.9M（汇丰 $3.0M，SemiAnalysis $3.1M）。GB300 NVL72：摩根士丹利 $3.99M，Wolfe $4.3M，Data Gravity $5.0M，媒体 $6.0-6.5M。Vera Rubin NVL72：报价自 $5.0M 起，摩根士丹利 $7.8M（若云服务商直接采购内存则为 $6.7M），有报道最高达 $8.8M，Bernstein $9.1M。

### 🔧 技术细节：公式及模型未涵盖的内容

每个加速器每年：资本 = $(C + N) \times \mathrm{CRF}(r, \text{life})$，其中 $C$ 为系统资本开支，$N = 0.26\ C$，$\mathrm{CRF}(r, n) = r \div (1 - (1 + r)^{-n})$。模型将直线折旧与超出部分的融资成本分别列示。“供应商毛利”是对折旧项的*拆分*（系统价格中属于加速器供应商毛利的份额），而非额外成本。设施 = kW × PUE × $/MW × $\mathrm{CRF}(r, 20)$。电费 = kW × PUE × [floor + (1 − floor) × utilization] × 8,760 × $/kWh，其中空闲功耗下限（floor）为 30%（与 CS7 中相同的负载系数规则）。运维 = IT 资本开支的 3%。token 指总 token 数（输入 + 输出）；1k/1k 工作负载中一半为输出。

未涵盖：超出运维预算的软件许可（NVIDIA AI Enterprise 标价为每 GPU 每年 $4,500，大客户很少按此支付 S11013）、税费与保险、残值、批量折扣及与股权挂钩的交易。4,000 次抽样的蒙特卡洛模拟给出 P10–P90 区间；它显示的是合理区间的宽度，而非经过校准的概率。

## 3. 模型结果：每小时成本、每 token 成本与每兆瓦 token 产出

各系统的输入是比较的核心。实测吞吐量来自 InferenceX 在参考运行点的数据 S621。若无实测数据，模型会对某个已实测的锚点进行缩放，表中注明了缩放方法。

| 系统 | 每加速器资本开支 | 全口径 IT kW | 每加速器 tokens/s | 吞吐量依据 | 置信度 |
|---|---|---|---|---|---|
| H200 HGX | $39.9K（OEM 标价） S322 | 1.37 S622 | 308 | 实测，FP8 S621 | 🟡 |
| B200 HGX | $46.3K（经销商价，估计） S320 | 1.71 S622 | 1,387 | 实测，FP4 S621 | 🟡 |
| GB300 NVL72 | $55.4K（摩根士丹利） S332 | 2.12 S622 | 6,261 | 实测，FP4 S621 | 🟡 |
| Vera Rubin NVL72 | $108.3K（摩根士丹利） S330 | 3.30 S622 | ~19,400 | GB300 × 3.1：每兆瓦 token 产出 ~2 倍 S626 | 🔴 |

| 系统 | 每加速器资本开支 | 全口径 IT kW | 每加速器 tokens/s | 吞吐量依据 | 置信度 |
|---|---|---|---|---|---|
| MI355X (8-GPU) | $37.5K（本资料库根据 ~$25K ASP 估计） S14001 | 2.09 S622 | 738 | 实测，FP4 S621 | 🟡 |
| Helios (MI455X) | $72.9K（Futurum：机架 $5.0–5.5M） S14002 | ~3.8（机架估计） S346 | ~10,700 | Vera Rubin × 0.55（0.3–0.9） | 🔴 |
| TPU v7 Ironwood | $28.4K（校准值） S622 | 1.21 S622 | ~960 | B200 × 0.95（同等精度） S625 × 0.73（FP8 对 FP4） | 🔴 |
| Trainium2 | $12K（本资料库估计） | ~0.75（估计） S14004 | ~150 | H200 × 0.60（HBM 带宽）× 0.8 | 🔴 |
| Trainium3 | $20K（本资料库估计） | ~1.05（估计） S14005 | ~620 | H200 × 2.0（1.0–3.4） S242 | 🔴 |

谷歌和 AWS 均未公布芯片价格，AWS 也未公布 Trainium 的功耗 S14003。因此 TPU 的资本开支为*校准值*：通过反推求解，使 TPU 相对于 GB300 的每小时成本与 SemiAnalysis 的所有者 TCO 比率一致（外部所有者为 $1.21 ÷ $2.31；谷歌自用为 $1.03 ÷ $2.31） S622。Trainium 价格是在 Epoch AI 的 B200 成本拆解 S35020 基础上，加上设计合作伙伴利润与服务器分摊而得出的自下而上推测。Futurum 估计 Helios 每台机架 $5.0–5.5M；但同一报告中 Rubin 机架“$3.5–4M”的数字与所有基于物料清单（BOM）的估计相冲突，因此模型对 Rubin 仍沿用 $7.8M S14002,S330,S333。

**Est.: an installed GB300 GPU-hour costs ~$2.46, Vera Rubin ~$4.61, a TPU v7 ~$1.29**

Owner cost per installed accelerator-hour by component, US$ · ◆ = SemiAnalysis owner TCO (cross-check) · base case

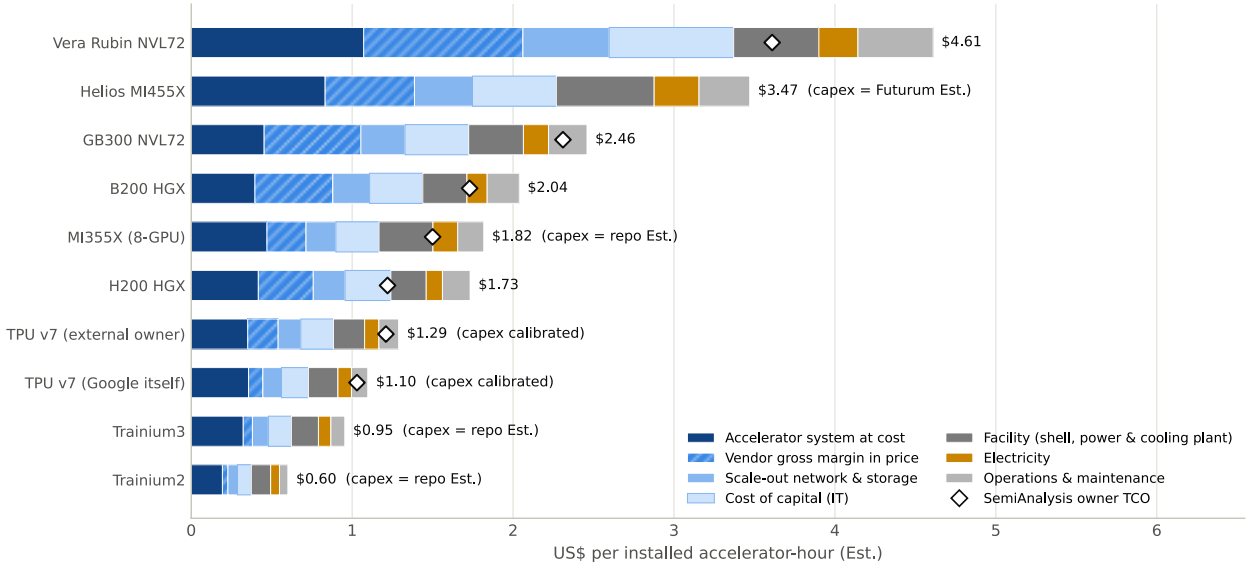


*Est.: repo TCO model (scripts/tco); hatched = vendor gross margin inside the price*

Source: data from repo TCO model; SemiAnalysis owner TCO [S14000] [S621] [S622] [S332] [S625] [S626] ...; chart by repo · As of 2026-11-05

> 每已装机加速器小时估计所有者成本的堆叠水平条形图：Trainium2 $0.60，Trainium3 $0.95，TPU v7（谷歌自用）$1.10，TPU v7（外部所有者）$1.29，H200 HGX $1.73，MI355X（8-GPU）$1.82，B200 HGX $2.04，GB300 NVL72 $2.46，Helios MI455X $3.47，Vera Rubin NVL72 $4.61。SemiAnalysis 的所有者 TCO 数据在 GB300 NVL72 上与之接近（$2.31），在 H200（$1.22）和 MI355X（$1.50）上更低。资本费用在每根条形中均占大头；TPU 资本开支按 SemiAnalysis 的 TPU 与 GB300 之比校准，Trainium 资本开支为本资料库估计。

按小时计，排名大致与价目表一致：Trainium 和 TPU 的小时成本最低，Rubin 最高。模型对 GB300 的结果与 SemiAnalysis 相差不到 6%，但对 8-GPU 服务器则高出 20–40%，这表明 SemiAnalysis 假设的服务器价格更低；应将 H200 和 MI355X 的小时成本视为上限。而按 token 计，排名发生反转：

| 系统 | 每装机小时 $ | 每百万 token $（P10–P90） | 电表端每 MW tokens/s | 供应商毛利占 token 成本比例 |
|---|---|---|---|---|
| Vera Rubin NVL72 🔴 | $4.61 | $0.094（$0.068–0.13） | 5.1M | 21% |
| Helios (MI455X) 🔴 | $3.47 | $0.13（$0.086–0.20） | 2.4M | 16% |

| 系统 | 每装机小时 $ | 每百万 token $（P10–P90） | 电表端每 MW tokens/s | 供应商毛利占 token 成本比例 |
|---|---|---|---|---|
| GB300 NVL72 | $2.46 | $0.16（$0.13–0.23） | 2.6M | 24% |
| TPU v7（谷歌自用）🔴 | $1.10 | $0.45（$0.24–0.53） | 0.73M | 8% |
| TPU v7（外部所有者）🔴 | $1.29 | $0.53（$0.29–0.63） | 0.69M | 15% |
| B200 HGX | $2.04 | $0.58（$0.47–0.86） | 0.71M | 24% |
| Trainium3 🔴 | $0.95 | $0.61（$0.41–0.99） | 0.51M | 6% |
| MI355X (8-GPU) | $1.82 | $0.98（$0.77–1.41） | 0.31M | 13% |
| Trainium2 🔴 | $0.60 | $1.61（$1.13–2.35） | 0.17M | 6% |
| H200 HGX | $1.73 | $2.23（$2.01–3.61） | 0.20M | 20% |

所有数值均为估计 [S14000]；运行点为 DeepSeek-R1 1k/1k、每用户 50 tokens/s、未使用推测解码 [S621]。

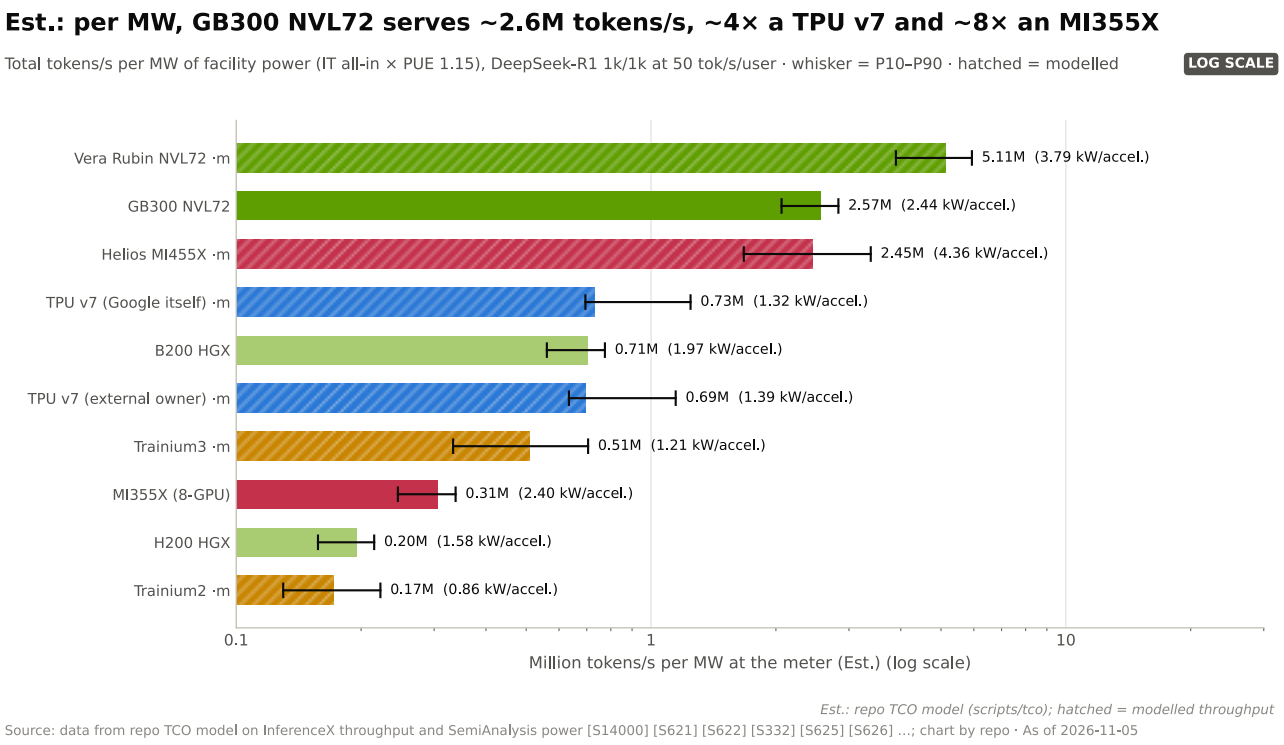


> 电表端每兆瓦每秒 token 数估计值的对数刻度水平条形图：Vera Rubin NVL72 5.11 million（模型推算）；GB300 NVL72 2.57 million；Helios MI455X 2.45 million（模型推算）；TPU v7（谷歌自用）0.73 million（模型推算）；B200 HGX 0.71 million；TPU v7（外部所有者）0.69 million（模型推算）；Trainium3 0.51 million（模型推算）；MI355X（8-GPU）0.31 million；H200 HGX 0.20 million；Trainium2 0.17 million（模型推算）。这些数值低于图表 08-tokens-per-mw-by-system，因为本模型计入了 PUE；排名一致。

这些每兆瓦 token 数据按电表端计量，因此比第 08 层的图表（以 IT 功耗为分母）低 ~13%；排名相同。在蒙特卡洛模拟中，在该运行点上，GB300 在每一次抽样中的每 token 成本均低于 TPU v7、MI355X 和 Trainium3，而 Helios 在 ~86% 的抽样中低于 GB300（🔴，因为 Helios 吞吐量为模型推算）[S14000]。

**提示**

**算例 —— 更便宜的小时，更昂贵的 token。** MI355X 每小时成本 ~$1.82，比 GB300 的 $2.46 低 26%（估计）[S14000]。但在每用户 50 tokens/s 下，MI355X 每秒输出 738 个 DeepSeek-R1 token，GB300 则输出 6,261 个 [S621]，是前者的 8.5 倍。每 token 成本 =（每小时成本 ÷ 每小时 token 数）：$1.82 ÷ 738 对比 $2.46 ÷ 6,261，因此 MI355X 的 token 成本**高出 ~6.3 倍**。**结论：** 26% 的小时折扣无法抵消 8.5 倍的吞吐量差距；只有在关键运行点上实现吞吐量持平，更便宜的加速器才真正更便宜。

**Est.: vendor margin is 6–24% of each token's cost; throughput, not margin, sets the 24× spread**

Cost stack per million tokens by system (own y-scale per panel) · DeepSeek-R1 1k/1k, 50 tok/s/user, base case

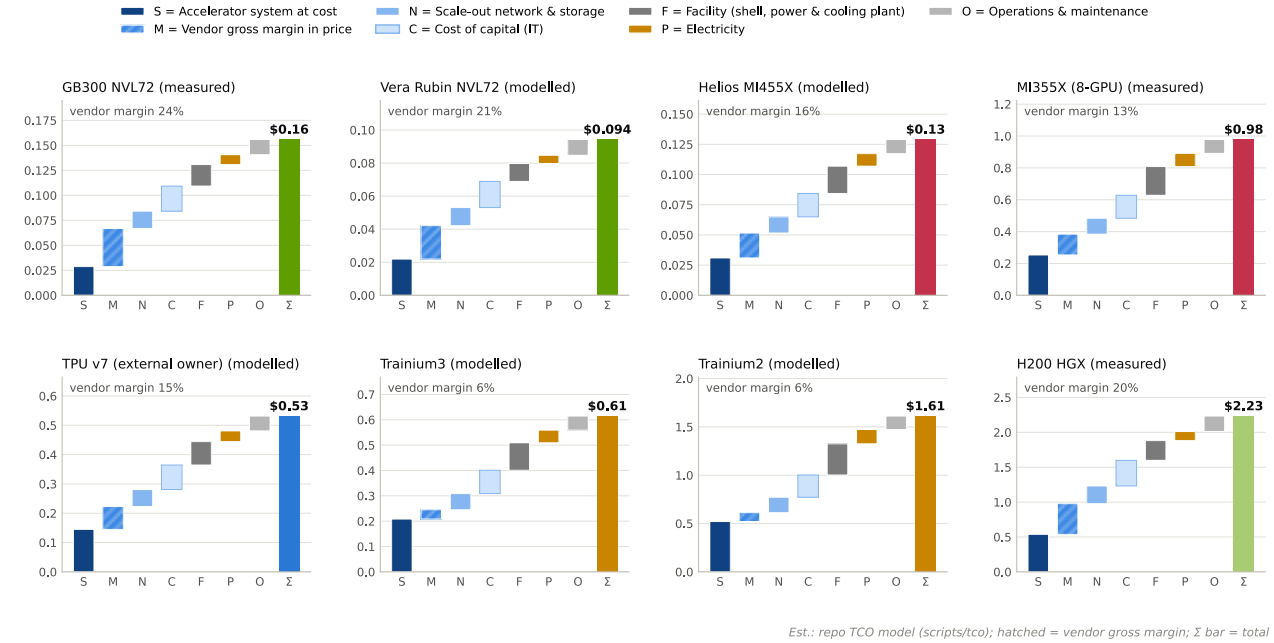


*Est.: repo TCO model (scripts/tco); hatched = vendor gross margin; Σ bar = total*

Source: data from repo TCO model [S14000] [S621] [S622] [S332] [S625] [S626] …; chart by repo · As of 2026-11-05

八个小型瀑布图，展示每百万 token 估计成本：GB300 NVL72 $0.156，供应商毛利占 24%；Vera Rubin NVL72 $0.094，供应商毛利占 21%；Helios MI455X $0.129，供应商毛利占 16%；MI355X（8-GPU）$0.978，供应商毛利占 13%；TPU v7（外部所有者）$0.532，供应商毛利占 15%；Trainium3 $0.615，供应商毛利占 6%；Trainium2 $1.612，供应商毛利占 6%；H200 HGX $2.233，供应商毛利占 20%。供应商毛利在每个成本栈中都只占少数；总额差异主要源于每加速器 token 产出不同，且 Vera Rubin、Helios、TPU 和 Trainium 的吞吐量为模型推算而非实测。

**注意**

**误区与事实：“定制芯片更便宜，因为没有英伟达的毛利。”** 毛利确实存在：在基准情景中，它占 GB300 每 token 成本的 ~24%，占 Trainium 的 ~6%（估计）[S14000]。但上述各成本栈的总额相差最多 ~24 倍，几乎完全是因为每加速器 token 产出不同。去掉 24% 的一块并不能弥合 3–6 倍的吞吐量差距；只有追平吞吐量才能做到。

**🔧 技术细节：模型推算的吞吐量如何构建**

- **Vera Rubin：** SemiAnalysis 发现，在 DeepSeek-R1 上、每用户 100 tokens/s 以内，其每兆瓦 token 产出约为 GB300 的 ~2 倍 [S626]。考虑到每 GPU 功耗为 3.30 kW 对 2.12 kW [S622]，折合每 GPU ~3.1 倍。低情景 2.3 倍（Rubin 的 HBM 带宽下调至 19.2 TB/s 后的带宽比 [S90006]）；高情景 4.0 倍，接近英伟达“最高 5 倍”的宣称 [S33006]。
- **Helios：** 纸面上 MI455X 胜过 Rubin（23.3 对 19.2 TB/s，~1.21 倍；HBM4 容量 432 对 288 GB）[S144,S90093]。低情景假设当前的软件差距持续存在：在同为 8 TB/s 带宽下，MI355X 的吞吐量仅为 B300 的 ~0.25 倍 [S621]。高情景采用 AMD 的宣称：在机架价格低 ~33% 的情况下，每美元 token 产出比 Vera Rubin 最多高 30%，折合 ~0.87 倍 [S14002]。基准 0.55 倍。
- **TPU v7：** SemiAnalysis 实测 Ironwood 在每用户 20 tokens/s 下每芯片 token 产出为 B200 的 1.05 倍，在 100 tokens/s 下为 ~0.86 倍（推算），均为 FP8 [S625]。Ironwood 不支持 FP4，因此模型乘以 0.73（本资料库的 FP8 对 NVFP4 解码比率 [S2021]）。最高 2 倍的上行系数用于反映跨 9,216 芯片 pod 的宽专家并行。
- **Trainium：** 目前没有公开的 tokens/s 基准测试。Trainium2 = H200 × HBM 带宽比（2.9 对 4.8 TB/s）[S154,S32002] × 0.8（软件折扣）。Trainium3 = H200 × 2.0，介于带宽持平（1.0 倍）与 AWS 宣称的每兆瓦 token 产出超过 Trainium2 的 5 倍（3.4 倍）之间 [S242]。

## 4. 运行点与软件决定排名

参考运行点（每用户 50 tokens/s）非常适合 NVL72：大批量分布在 72 块 GPU 上。改变运行点，排名就会变化。本资料库中的 InferenceX 前沿数据可直接用于观察已实测系统；TPU 曲线为模型推算。

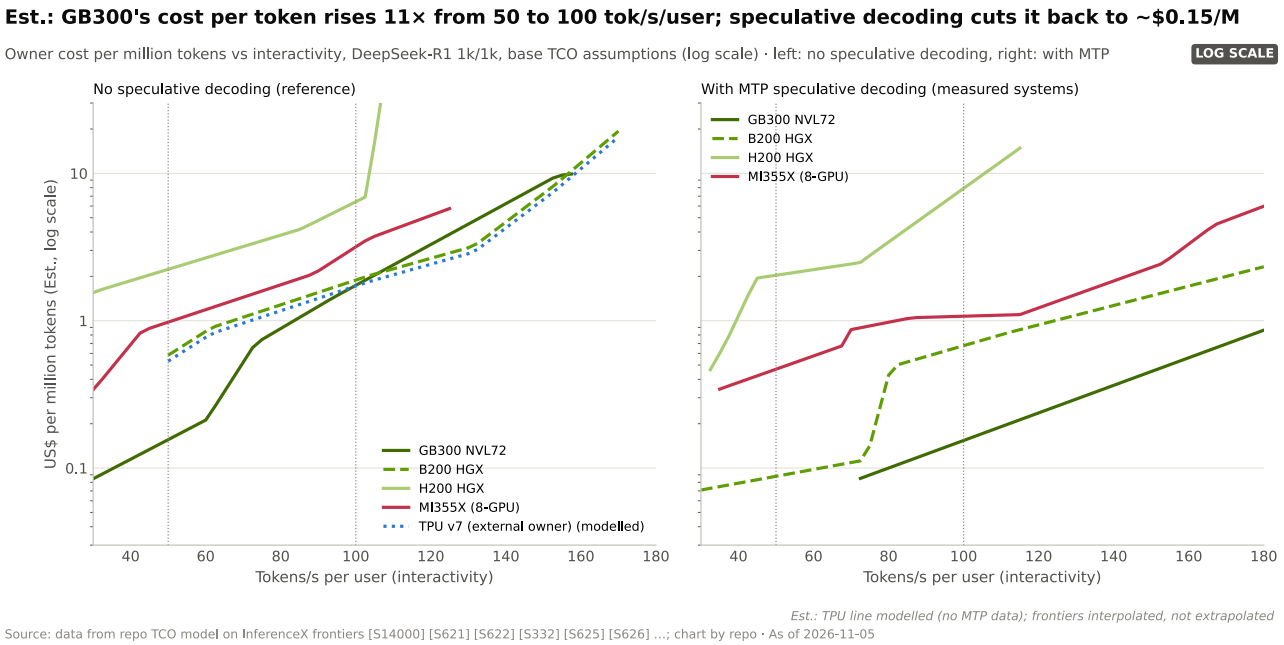


双面板对数刻度折线图：每百万 token 估计成本与每用户每秒 token 数的关系。未使用推测解码时，GB300 NVL72 在每用户 50 tokens/s 下约 $0.16，在 100 tokens/s 下约 $1.74，此时模型推算的 TPU v7 约为 $1.72，接近持平；H200 和 MI355X 均高于二者。使用 MTP 推测解码后，实测成本下降数倍：B200 在每用户 50 tokens/s 下约 $0.09，GB300 在 100 tokens/s 下约 $0.15。运行点与软件配置对每 token 成本的影响不亚于硬件选择。

| 系统 | 每用户 35 tok/s | 50 | 75 | 100 |
|---|---|---|---|---|
| GB300 NVL72 | $0.10 | $0.16 | $0.75 | $1.74 |
| Vera Rubin NVL72 🔴 | $0.06 | $0.09 | $0.45 | $1.05 |
| TPU v7（谷歌自用）🔴 | — | $0.45 | $0.90 | $1.46 |
| TPU v7（外部所有者）🔴 | — | $0.53 | $1.06 | $1.72 |
| Trainium3 🔴 | $0.47 | $0.61 | $0.96 | $1.77 |
| MI355X (8-GPU) | $0.48 | $0.98 | $1.59 | $3.17 |

单位为每百万 token 美元成本，估计 S14000,S621；“—”表示超出锚点系统的实测前沿范围。模型推算的系统在其他运行点沿用其在 50 tokens/s 下的乘数。

从每用户 50 到 100 tokens/s，GB300 的每 token 成本上升 ~11 倍，而 B200 仅上升 ~3 倍。NVL72 的优势来自分布在整个机架上的大批量；在每用户高速下，批会缩小，该优势随之消退。在每用户 100 tokens/s 下，TPU v7 和 Trainium3 与 GB300 在模型误差范围内持平。

软件对曲线的影响不亚于硬件。多 token 预测（MTP）是 DeepSeek 内置的一种推测解码形式，每一步可草拟多个 token。SemiAnalysis 发现，它将 GB300 在每用户 150 tokens/s 下的成本从每百万 token ~$2.35 降至 ~$0.11 S624。在 MTP 前沿上，B200 在每用户 50 tokens/s 下成本为 ~$0.09（估计），*低于*未使用 MTP 的 GB300。不考虑软件配置的排名，算不上排名。

> **提示**
>
> **算例 —— 同一台 GB300，三种价格。** 在每用户 50 tokens/s、未使用 MTP 时，GB300 每百万 token 成本为 ~$0.16。在 100 tokens/s 下升至 ~$1.74，上涨 11 倍，因为每 GPU 吞吐量从 6,261 降至 562 tokens/s [S621]。在 100 tokens/s 下开启 MTP，吞吐量回升至 ~6,340，成本随之回落至 ~$0.15（估计）[S14000]。**结论：** 供应商宣称“每 token 成本降低 X 倍”，若不说明模型、每用户速度和服务配置，便毫无意义；三者都要问清楚。

SemiAnalysis 对 TPU 的直接测量从另一侧印证了同一观点。在 Qwen3.5 397B、FP8、每用户 100 tokens/s 下，Ironwood 每百万 token 成本为 $0.181，B200 为 $0.222，B300 为 $0.276，比 B200 低 ~18% [S625]。该测试未包含 GB300 NVL72。

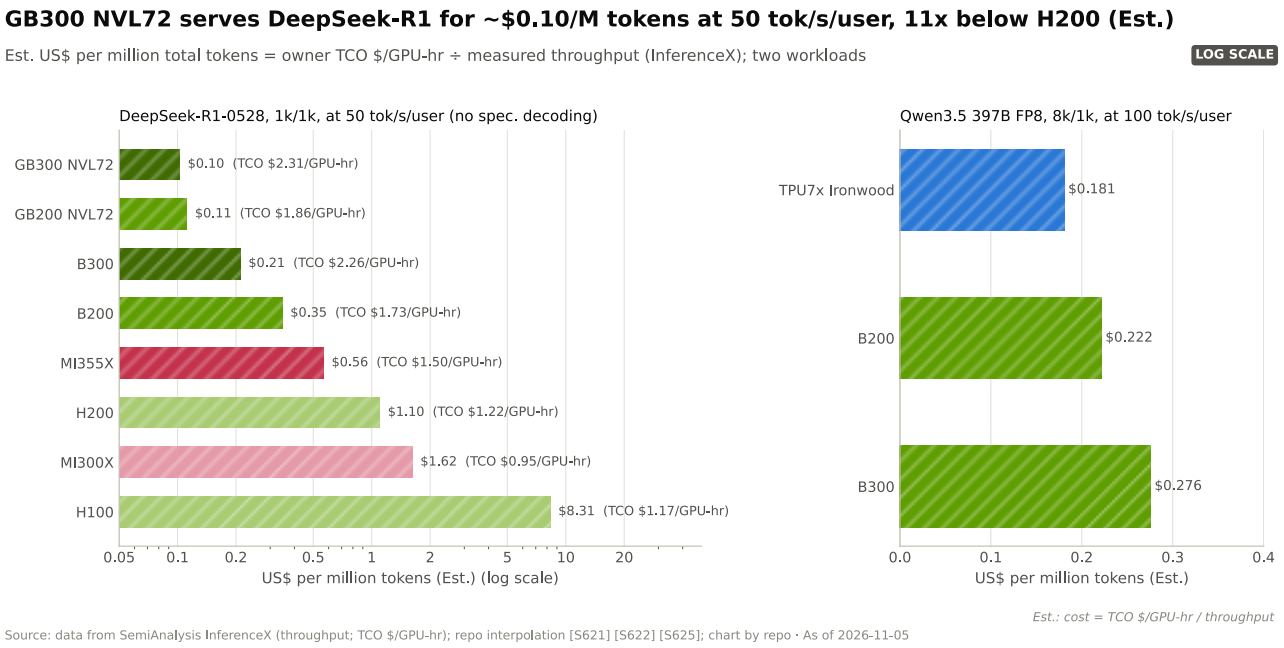


两个条形面板，展示每百万总 token 估计成本。左：DeepSeek-R1，每用户 50 tokens/s：GB300 NVL72 $0.10，GB200 NVL72 $0.11，B300 $0.21，B200 $0.35，MI355X $0.56，H200 $1.10，MI300X $1.62，H100 $8.31。右：Qwen3.5 397B FP8，每用户 100 tokens/s：TPU7x Ironwood $0.181，B200 $0.222，B300 $0.276，表明在该工作负载上谷歌 TPU 比 B200 便宜约 18%。

该图假设 100% 利用率并采用 SemiAnalysis 的小时成本，因此其 GB300 数值（$0.10）低于本模型在 70% 利用率下的 $0.16；但比率相近。

## 5. 敏感性分析：哪些假设至关重要

龙卷风图每次只在高低值之间变动一个输入，并按各输入对结果的影响幅度排序。

**Est.: utilization moves GB300's $0.16/M token cost from $0.12 to $0.27; power price barely matters**

One-at-a-time sensitivity of GB300 NVL72 US$ per million tokens · label = input value → result · blue = cheaper, red = dearer

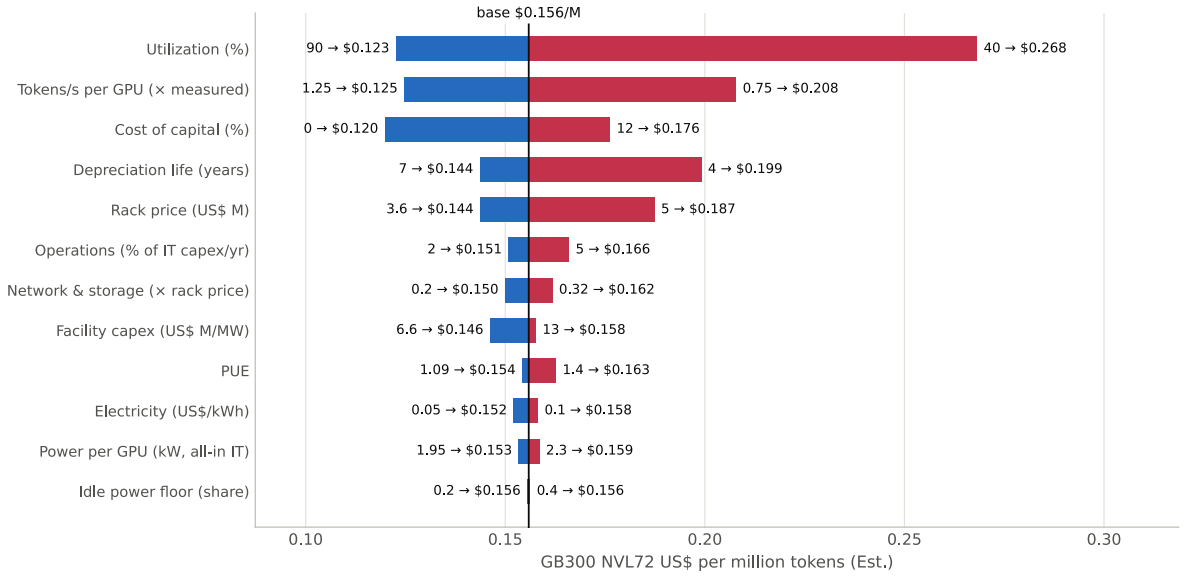


*Est.: repo TCO model (scripts/tco)*

Source: data from repo TCO model [S14000] [S621] [S622] [S332] [S625] [S626] ...; chart by repo · As of 2026-11-05

GB300 NVL72 每百万 token 估计成本的龙卷风图，基准值 $0.156：利用率（%）40 至 90 对应 $0.268 至 $0.123；每 GPU tokens/s（× 实测值）0.75 至 1.25 对应 $0.208 至 $0.125；资本成本（%）0 至 12 对应 $0.120 至 $0.176；折旧年限（年）4 至 7 对应 $0.199 至 $0.144；机架价格（US$ M）3.6 至 5 对应 $0.144 至 $0.187；运维（占 IT 资本开支 %/年）2 至 5 对应 $0.151 至 $0.166；网络与存储（× 机架价格）0.2 至 0.32 对应 $0.150 至 $0.162；设施资本开支（US$ M/MW）6.6 至 13 对应 $0.146 至 $0.158；PUE 1.09 至 1.4 对应 $0.154 至 $0.163；电价（US$/kWh）0.05 至 0.1 对应 $0.152 至 $0.158；每 GPU 功耗（kW，全口径 IT）1.95 至 2.3 对应 $0.153 至 $0.159；空闲功耗下限（占比）0.2 至 0.4 对应 $0.156 至 $0.156。电价从每 kWh $0.05 升至 $0.10，对结果的影响不到每百万 token 一美分。

三点发现。第一，利用率影响最大：40% 而非 70% 的利用率会使每 token 成本上升 ~72%。第二，吞吐量（软件）次之：tokens/s 变动 ±25%，成本变动 −20% 至 +33%。第三，人们最常争论的财务与物理输入——机架价格、电价和 PUE——影响最小。电价翻倍仅使 GB300 的成本变动不到每百万 token 一美分。

**提示**

**算例 —— 闲置的机架与昂贵的机架。** 在 70% 利用率下，GB300 每百万 token 成本为 ~$0.156。利用率降至 40% 则升至 ~$0.268（+72%）。而以 $5.0M 而非 $3.99M 购入机架，成本仅升至 ~$0.187（+20%）（估计）[S14000]。**结论：** 买方若谈下机架 20% 的折扣，但利用率只有 40% 而非 70%，仍然得不偿失；调度、故障恢复与需求填充的价值高于价格谈判（第 12 层）。

对竞争而言真正重要的比较是一个比率：TPU 的 token 比 GB300 的 token 贵多少?

**Est.: throughput assumptions, not finance, decide GB300 vs TPU; base TPU cost 3.4× GB300's, ~1.0× at 100 tok/s/user**

One-at-a-time sensitivity of (TPU v7 external $/M tokens) ÷ (GB300 NVL72 $/M tokens) at 50 tok/s/user · >1 = GB300 cheaper

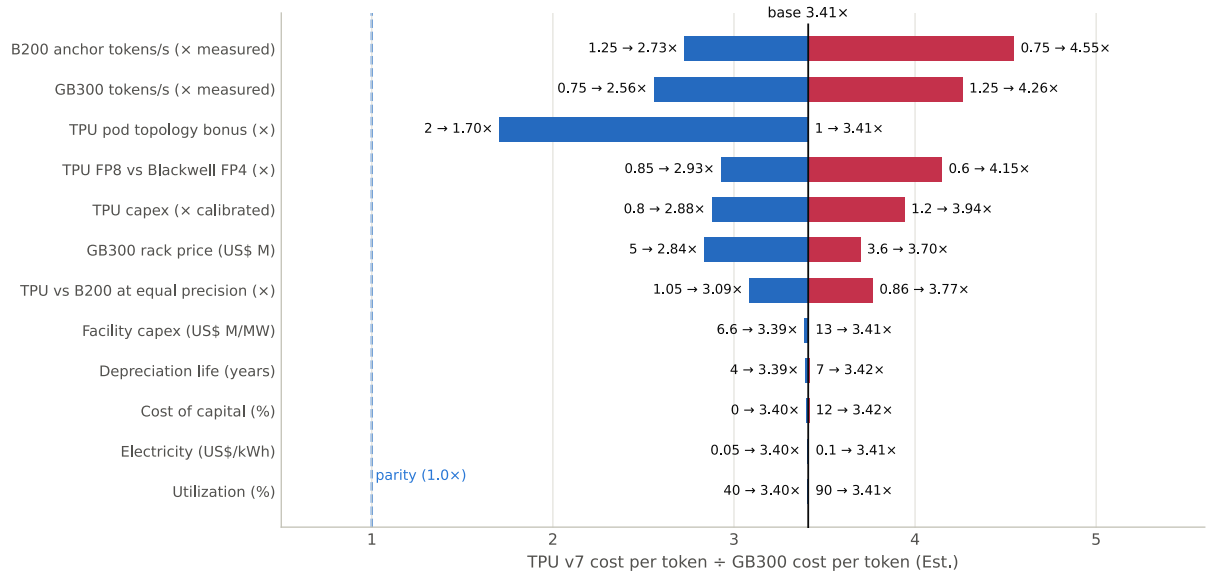


*Est.: TPU throughput is modelled from SemiAnalysis's TPU-vs-B200 result*

Source: data from repo TCO model; SemiAnalysis TPU vs Blackwell [S14000] [S621] [S622] [S332] [S625] [S626] ...; chart by repo · As of 2026-11-05

> TPU v7 与 GB300 NVL72 每 token 估计成本之比的龙卷风图，基准值 3.41：B200 锚点 tokens/s（× 实测值）对应 4.55 至 2.73；GB300 tokens/s（× 实测值）对应 2.56 至 4.26；TPU pod 拓扑加成（×）对应 3.41 至 1.70；TPU FP8 对 Blackwell FP4（×）对应 4.15 至 2.93；TPU 资本开支（× 校准值）对应 2.88 至 3.94；GB300 机架价格（US$ M）对应 3.70 至 2.84；同等精度下 TPU 对 B200（×）对应 3.77 至 3.09；设施资本开支（US$ M/MW）对应 3.39 至 3.41；折旧年限（年）对应 3.39 至 3.42；资本成本（%）对应 3.40 至 3.42；电价（US$/kWh）对应 3.40 至 3.41；利用率（%）对应 3.40 至 3.41。财务输入（资本成本、寿命、电价、利用率、设施）使该比率变动不到 0.02；在每用户 100 tokens/s 下，该比率约为 0.99，接近持平。

财务假设对该比率的影响不到 0.02，因为它们对两个平台的作用相同。每一根有分量的条形都是吞吐量假设：即每款芯片以该速度服务该模型的能力。在每用户 50 tokens/s 下，没有任何单一输入能翻转排名，但将运行点移至 100 则可以。这才是对任何加速器开展尽职调查时真正要问的问题：*在买方运行点上实测的每秒 token 数*。

**🔧 技术细节：敏感性网格与排名概率**

`scripts/tco/outputs/x14_tco_sensitivity_grid.csv` 在利用率 30–90%、电价 $0.05–0.15/kWh、寿命 3–7 年、资本成本 0/8/12% 的组合下对每个系统重新运行（共 4,200 行）。`x14_tco_ranking_probability.csv` 报告在蒙特卡洛抽样中，一个平台的每 token 成本低于另一平台的频率。在每用户 50 tokens/s 下：Vera Rubin 在 ~91% 的抽样中胜过 Helios，Helios 在 ~86% 的抽样中胜过 GB300，Trainium3 与 B200 大致各半（~50/50），Trainium3 在 ~15% 的抽样中胜过 TPU v7（外部所有者）（均为 🔴，因为多个吞吐量为模型推算）[S14000]。

## 6. 关键洞见：~75% 的毛利率为何能与最低 TCO 并存

英伟达在 Q2 FY2027 实现了 75.0% 的 GAAP 毛利率 [S405]。天真的解读是，其客户支付的价格是芯片成本的三到四倍。模型显示了为何许多客户仍能获得最低的每 token 成本。共有五种机制在起作用。

**Gross margin climbed from 43.5% to ~75%, broken only by the H20 write-down**

GAAP and non-GAAP gross margin, % of revenue, Q1 FY23–Q2 FY27; from Q1 FY2027 non-GAAP includes stock-based comp

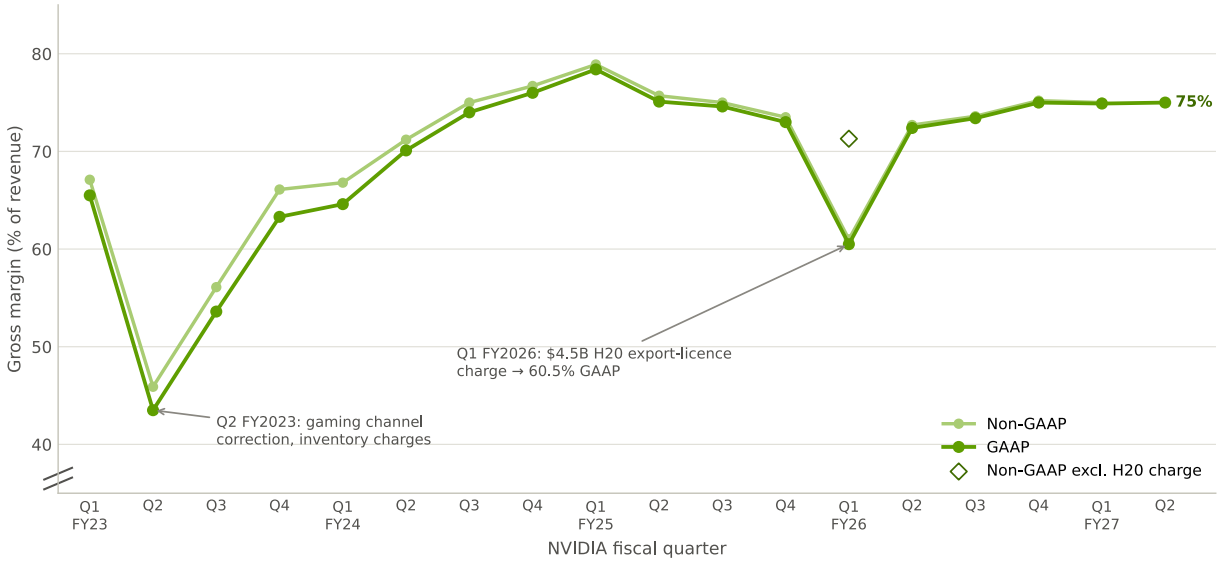


*Axis starts at 35% (break marked)*

Source: data from NVIDIA 8-K releases [S432] [S433] [S434] [S435] [S418] [S436] …; chart by repo · As of 2026-11-05

英伟达季度毛利率折线图：GAAP 毛利率在 Q2FY23 触底至 43.5%（游戏业务库存减值），在 Hopper 放量期间升至 75% 以上，在 Q1 FY2026 因 $4.5B 的 H20 出口管制费用降至 60.5%（剔除该项后非 GAAP 为 71.3%），在 Q2FY27 约为 75%。

**1 · 毛利只占 token 成本的少数。** ~75% 的毛利率只适用于英伟达自身的内容。在 GB300 机架中，英伟达在 GPU 上获得的毛利约占机架价格的 ~57%（估计）[S332,S35020]。计入网络、设施、电力、运维和融资后，机架约占 token 成本的 ~60%。净结果：token 成本中 ~24% 为英伟达毛利（计入相应融资则为 ~32%）。即便英伟达将毛利减半，GB300 的每 token 成本也只会下降 ~18%（估计）[S14000]。

**2 · 每瓦与每机架性能。** 每 token 最大的几项成本（资本、设施、电力）都随加速器数量或兆瓦数线性增减。而每加速器与每兆瓦的 token 产出差异要大得多：在参考运行点上，GB300 每兆瓦每秒输出 ~2.6M token，TPU v7 为 ~0.7M，MI355X 为 ~0.3M（估计）[S14000]。一个在相同电力和占地面积下输出 3–8 倍 token 的系统，即便背负高毛利也照样胜出。

**3 · 已装机硬件上的软件增益。** 已装机硬件在购买后还会变得更快。在未作改动的 GB300 NVL72 上，MLPerf DeepSeek-R1 吞吐量一年内提升 2.9 倍，使每百万 token 估计成本下降 ~65% [S601,S603]。TensorRT-LLM 在 2025 年的四个月内将 B200 从每 GPU ~2,000 tokens/s 提升至 4,600 tokens/s [S646]。AMD 的提升同样陡峭，但起步更晚：MI355X 在 DeepSeek-V4-Pro 上 26 天内从每 GPU 20 tokens/s 提升至 2,256 tokens/s [S631]。参见同一硬件上的软件增益。

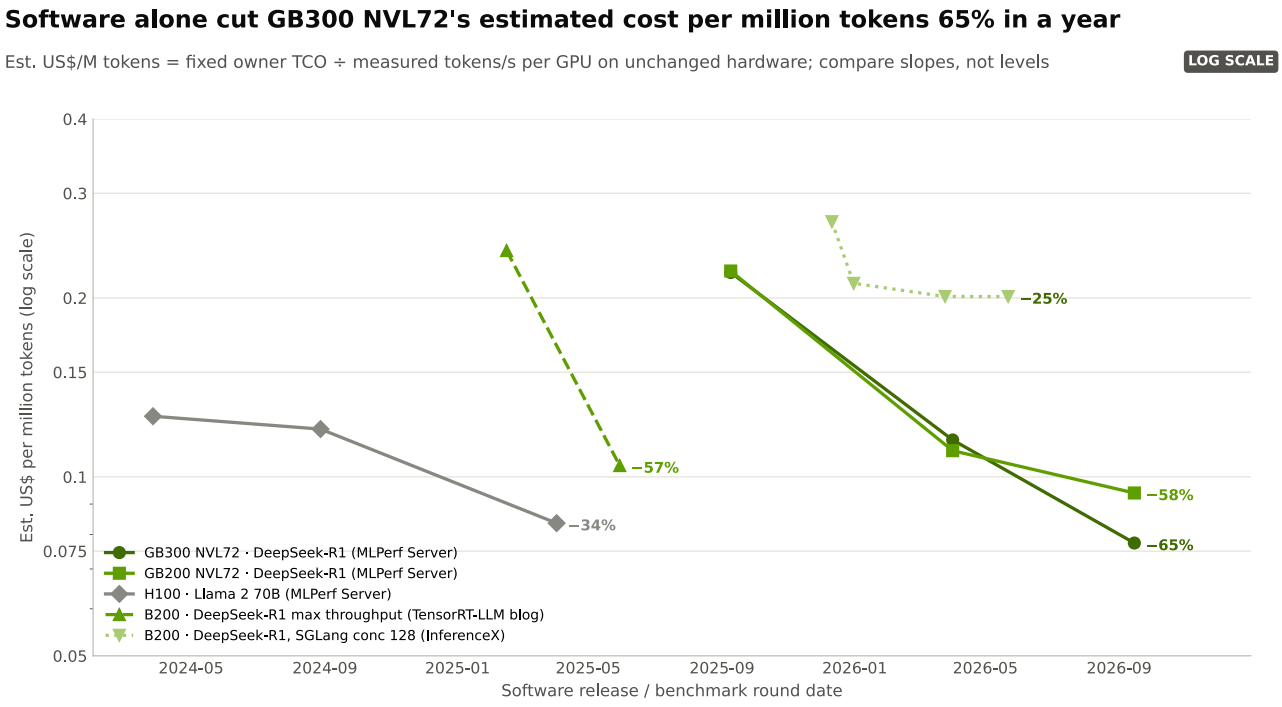


Source: data from MLPerf Inference; TensorRT-LLM blog; InferenceX + TCO; repo math [S601] [S602] [S603] [S604] [S605] [S600] ...; chart by repo · As of 2026-11-05

对数刻度折线图：在英伟达硬件不变、各 GPU 所有者 TCO 保持不变（SemiAnalysis：GB300 $2.31，GB200 $1.86，B200 $1.73，H100 $1.17/GPU 小时）的情况下，随着软件改进，每百万 token 估计成本的变化。GB300 NVL72 · DeepSeek-R1（MLPerf Server）：$0.221 降至 $0.077（降低 65%，2025 年 9 月至 2026 年 9 月）；GB200 NVL72 · DeepSeek-R1（MLPerf Server）：$0.222 降至 $0.094（降低 58%，2025 年 9 月至 2026 年 9 月）；H100 · Llama 2 70B（MLPerf Server）：$0.126 降至 $0.084（降低 34%，2024 年 3 月至 2025 年 4 月）；B200 · DeepSeek-R1 最大吞吐量（TensorRT-LLM 博客）：$0.240 降至 $0.104（降低 57%，2025 年 2 月至 2025 年 5 月）；B200 · DeepSeek-R1，SGLang 并发 128（InferenceX）：$0.269 降至 $0.201（降低 25%，2025 年 12 月至 2026 年 5 月）。硬件支出没有变化，变化的是每 GPU 吞吐量，因此每 token 成本下降。

**4 · 利用率与部署时间。** 利用率是最大的单一杠杆（第 5 节），一个能以全速运行首日（day-0）模型的平台能更快填满其可售小时。部署时间同样重要：无论是否在提供服务，一块 GB300 GPU 每年的持有成本都在 ~$21.5K（估计）[S14000]，因此一台因软件或供应问题而空等六个月的机架会白白烧掉 ~$0.8M。AMD 的 Helios 约在 2026 年第三季度末开始出货，据报道将于 2027 年第二季度放量 [S90020,S624]；英伟达的机架如今已在批量出货。

**5 · 电力受限站点与时间的机会成本。** 当稀缺的投入是电网电力而非资金时，问题就变成了每兆瓦能赚多少钱。美国新增发电项目在并网排队中需等待四年以上 [S8009]。在一个固定站点上，年度成本几乎与平台无关，但 token 产出却与平台密切相关（见下方算例）。对前沿实验室而言，时间是另一项稀缺投入：早几个月发布的模型，其价值可能超过全部算力支出（第 8 节）。

**提示**

**算例 —— 一个 100 MW 站点，五个平台。** 按电表端计算，100 MW 可容纳 ~41,000 块 GB300 GPU、~72,000 颗 TPU v7 芯片或 ~41,600 块 MI355X GPU。年度所有者成本相近：分别为 ~$0.88B、~$0.81B 和 ~$0.66B。而在 70% 利用率下的年度 token 产出差异巨大：分别为 ~5.7、~1.5 和 ~0.7 quadrillion（千万亿）。Vera Rubin 将以 ~$1.06B 产出 ~11.3 quadrillion，Helios 以 ~$0.70B 产出 ~5.4 quadrillion（🔴 模型推算）（均为估计）[S14000]。按示例价格每百万 token $0.50 计算，GB300 站点每年收入 ~$2.8B，成本为 $0.88B，而 TPU 和 MI355X 站点则无法覆盖成本。**结论：** 在电力成为约束时，买方愿为更高的每兆瓦 token 产出支付高得多的单 GPU 价格，这正是英伟达定价权的来源。

这一论点最尖锐的版本来自英伟达自己。其 CEO 在 2024 年表示，英伟达的芯片好到“即使竞争对手的芯片免费，也不够便宜”[S14006]。模型可以通过免费芯片测试来检验这一说法：将竞争对手的加速器系统免费送

出，但仍需支付网络、设施、电力和运维费用，然后进行比较。

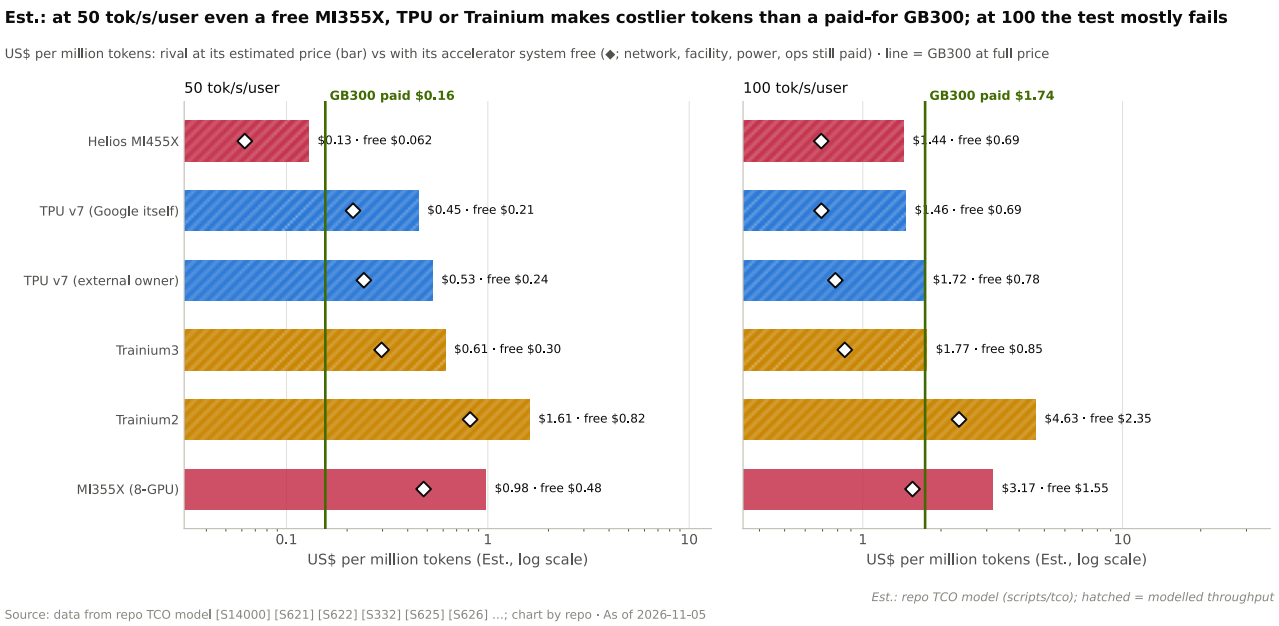


> 双面板水平条形图。在每用户 50 tokens/s 下，按全价计算的 GB300 NVL72 每百万 token 成本约 $0.156，而在加速器系统免费的情况下，竞争对手的成本为：MI355X（8-GPU）$0.480，Trainium2 $0.817，Trainium3 $0.297，TPU v7（外部所有者）$0.242，TPU v7（谷歌自用）$0.214，Helios MI455X $0.062；只有免费的 Helios MI455X 能胜过 GB300。在每用户 100 tokens/s 下，GB300 成本约 $1.74，除 Trainium2 外，所有免费版本的成本都低于它（TPU v7 外部所有者免费时为 $0.78）。“免费也不够便宜”的论点仅在英伟达机架级吞吐量领先幅度较大时成立。

在每用户 50 tokens/s 下，这一说法对模型中所有已出货的竞争对手都成立。在每用户 100 tokens/s 下，除 Trainium2 外，它对所有对手都不成立。当 72-GPU 域的吞吐量领先幅度较大时，该说法成立；反之则不成立。

| 买方情境 | 英伟达机架级方案 | AMD（MI355X / Helios） | 谷歌 TPU | AWS Trainium |
|---|---|---|---|---|
| 电力受限站点、聊天速度的 MoE 服务 | 🟩 领先：每 MW ~2.6M tokens/s，对手 ≤0.7M（估计） | 🟨 Helios 纸面上接近持平（🔴）；MI355X 落后 | 🟥 在该运行点每 MW ~0.7M tokens/s（🔴） | 🟥 ~0.5M（🔴） |
| 高交互速度服务（≥100 tok/s/用户） | 🟨 持平；MTP 与 Rubin 可恢复领先 | 🟨 Helios 具竞争力（🔴） | 🟨 持平，谷歌自用时更优（🔴） | 🟨 持平（🔴） |
| 前沿训练运行 | 🟨 Rubin 单芯片最快；每 FLOP 并非最便宜 | 🟨 FLOPs 便宜，但大规模验证较少 | 🟩 同等 MFU 下每 FLOP 最便宜（估计） | 🟥 单芯片慢；训练周期长 |
| 无编译器团队的企业或主权买方 | 🟩 首日（day-0）软件支持，支持面广 | 🟨 快速改善中 | 🟦 主要在谷歌云内租用 | 🟦 仅限 AWS 内部 |
| 拥有大规模自研芯片的超大规模云厂商 | 🟨 议价锚 | 🟨 第二供应商 | 🟦 自有经济性，无商用芯片毛利 | 🟦 自有经济性 |

评级为基于模型估计的本资料库分析（🔴）[S14000]。

### 🔧 技术细节：降价测试

对于每一个在某个运行点上每 token 成本低于 GB300 的竞争对手，模型求解能与之持平的 GB300 价格，假设英伟达承担全部降价，并重新计算英伟达在其内容上的毛利率（内容 = 毛利份额 ÷ 75%）。在每用户 100 tokens/s 下对比谷歌内部 TPU，GB300 需降价 ~20%，这将使英伟达毛利率降至 ~66%。在每用户 50 tokens/s 下对比 Helios（🔴），需降价 ~22%，毛利率 ~65%（估计）[S14000]。这与 CS3 对 B200 与 TPU 价格战所估计的 ~62% 相符 [S23010]。英伟达有赢得价格战的空间；每一个拥有可信替代方案的大买家都能从这 ~10 个百分点的缓冲中分走一部分。

## 7. 当它不成立时：超大规模定制芯片与 TPU 的自有经济性

共存论点有其局限，而这些局限在商业上是本章最重要的部分。

**自有经济性。** 谷歌在自家 TPU 上既无需支付商用 GPU 的毛利，也无需支付云服务加价。SemiAnalysis 估计谷歌自用的成本为每芯片小时 ~$1.03，外部所有者为 $1.21，GB300 为 $2.31 [S622]。在 TPU 吞吐量接近 Blackwell 的场景下，例如实测的 Qwen3.5 工作负载（比 B200 便宜 ~18% [S625]），或本模型中每用户 100 tokens/s 的情形，谷歌的 token 更便宜。仅 Anthropic 一家就将使用 ~1M 颗芯片 [S653]，节省额以每年数十亿美元计。

**Est.: an owned Ironwood chip-hour costs ~$1.21, about half a GB300's $2.31**

All-in owner cost per accelerator-hour (capex amortisation, power, hosting), US$, SemiAnalysis model, July 2026

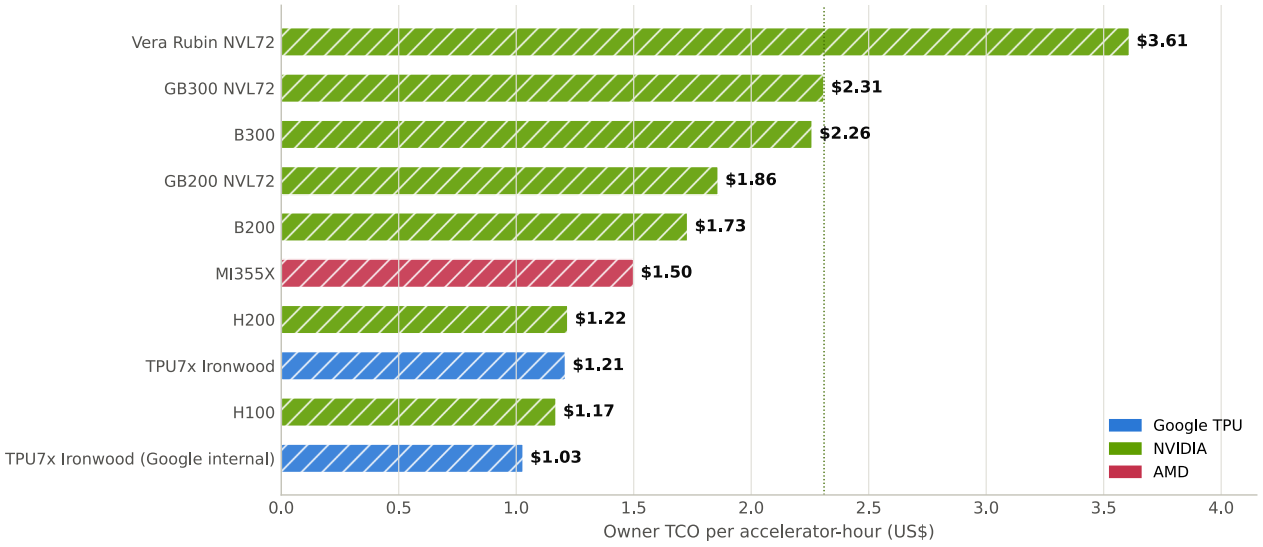


*Est. · per chip, not per token*

Source: data from SemiAnalysis InferenceX TCO registry [S622]; chart by repo · As of 2026-11-05

每加速器小时估计所有者 TCO 的水平条形图：TPU7x Ironwood 谷歌自用 $1.03、外部所有者 $1.21，H100 $1.17，H200 $1.22，AMD MI355X $1.50，B200 $1.73，GB200 NVL72 $1.86，B300 $2.26，GB300 NVL72 $2.31，Vera Rubin NVL72 $3.61。这些是按芯片而非按工作量计算的：Ironwood 的小时成本比 B200 低 30%，但在 SemiAnalysis 的一项工作负载中，其每 token 成本仅低约 18%，因为各芯片的吞吐量不同。

**提示**

**算例 —— 自有经济性在吉瓦规模下价值几何。** 在每用户 100 tokens/s 下，谷歌内部 TPU 生产每百万 token 的成本为 ~$1.46，GB300 为 ~$1.74，低 16%（🔴 估计）[S14000]。在模型中，一支 1 GW 的 TPU 集群每年的持有与运营成本为 ~$7.3B；在 GB300 上产出同样的 token 则需 ~$8.7B。即在该运行点上每吉瓦每年节省 **~$1.4B**。在每用户 50 tokens/s 下，结论反转：GB300 的 token 便宜 ~2.9 倍，除非 TPU pod 能像 NVL72 一样从宽专家并行中获益。**结论：** TPU 的优势在为针对 TPU 优化的模型提供延迟敏感型服务时最强，在为大型 MoE 模型提供大批量服务时最弱。

**超大规模定制 ASIC。** 设计合作伙伴模式（与 ASIC 设计合作伙伴共同打造的自用芯片）在价格中包含的毛利更小：在模型中占 Trainium 每 token 成本的 ~6%，而 GB300 为 ~24%（🔴）。CS3 估计，一个自研项目在每代 ~130,000 颗芯片时达到盈亏平衡（🔴）[S23010]。AWS 在 Rainier 项目（Project Rainier）中为 Anthropic 运行 ~500,000 颗 Trainium2 芯片 [S27011]。据报道，OpenAI 由博通（Broadcom）打造的推理芯片单颗裸片（die）可提供 13.4 PFLOPS MXFP4，而每颗 Rubin 裸片为 17.5 🟡 [S628]。这些买家已跨过门槛，即便其芯片更慢，也获得了议价能力。

**无需机架级系统的工作负载**。稠密模型、离线批处理作业以及长提示、短回答的服务，几乎无法从 72-GPU NVLink 域中获益。SemiAnalysis 发现，在每用户 225 tokens/s 以下，MI355X 在 gpt-oss-120b 上使用 vLLM 的每 token 成本低于 B200 [S623]；在一项智能体基准测试的部分场景中，搭载 AMD ATOM 服务引擎的 MI355X 在每美元性能上胜过运行 vLLM 的 GB300 [S627]。在这些场景中，最便宜的小时往往胜出，而一块已折旧、一年期合约每小时 ~$2.35 [S12516] 的 H100 是难缠的竞争者。

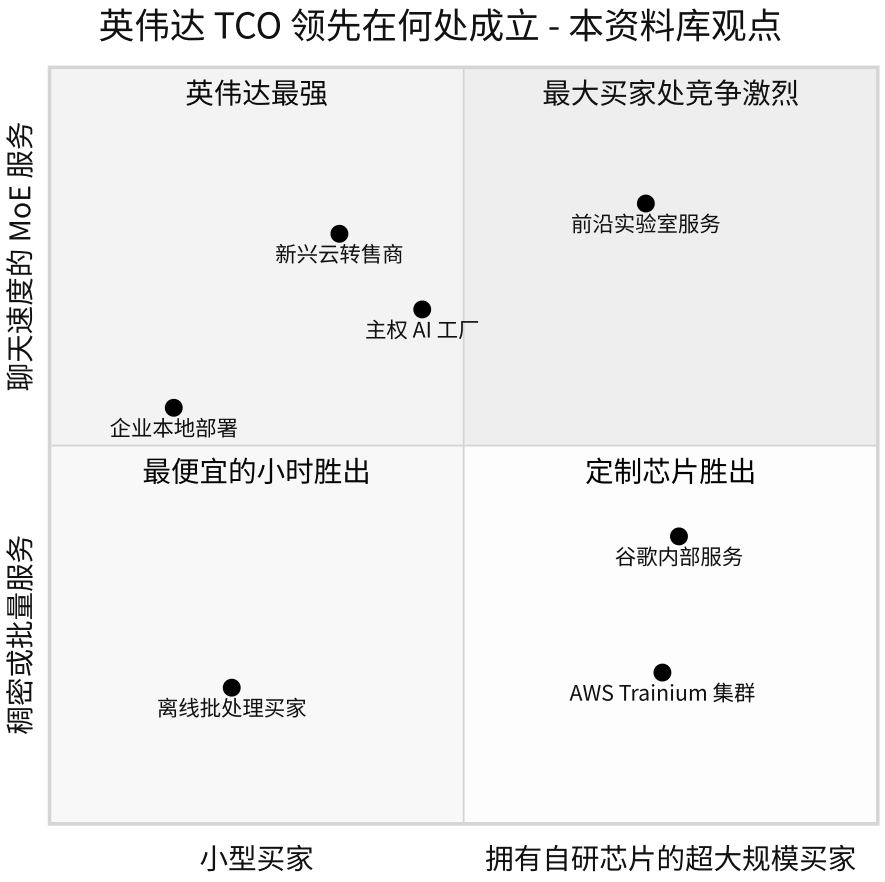

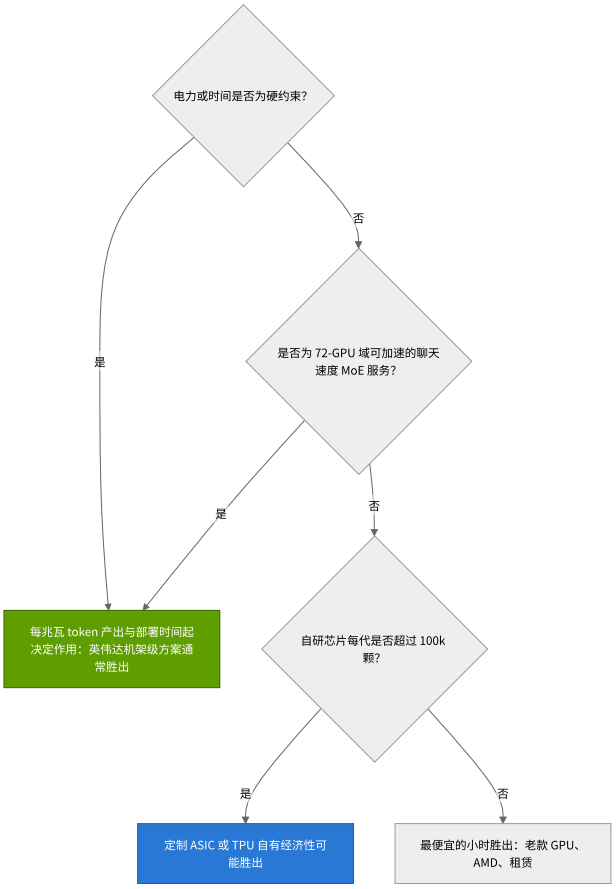


> **注**
>
> 🐂 **看多观点（定制芯片）：** 最大的买家掌握着需求、模型和数据中心。英伟达每一代产品都会留下几个季度的窗口期，在此期间，一款针对单一模型系列、单一运行点调优的 ASIC 能在每 token 成本上胜过商用 GPU。它们只需赢下自己的工作负载，而非所有人的工作负载 [S625,S653]。

> **注意**
>
> 🐻 **看空观点（定制芯片）：** 模型的区间恰恰在 TPU 和 Trainium 上最宽（P10–P90 跨度达 ~2 倍），因为没有人在公开基准测试上发布其吞吐量；Ironwood 缺席了 MLPerf Inference 6.0 [S613]。在一个运行点上胜出的芯片会在另一个运行点上落败，而一次模型变更就可能使其沦为搁浅资产。参见第 09 层的客观评估。

## 8. 训练经济学：一次前沿训练运行在各平台上的成本

对于训练，模型将 FLOPs 换算为加速器小时：FLOPs ÷（稠密 FP8 峰值 × MFU × 90% 有效产出率（goodput））[S34006]，再按满功率对每小时计费。这次训练运行假设为 $10^{27}$ FLOPs，约为 Epoch AI 对 Grok 4 估计值的两倍（🔴 情景）[S31007,S31008]。MFU 设定为：英伟达和谷歌为 FP8 峰值的 30%，新一代 Rubin 为 28%，AMD 和 AWS 为 22–24%，均为本资料库假设（🔴）。

**Est.: a $10^{27}$-FLOP run costs ~$0.51B on GB300 vs ~$0.29B on TPU v7, but Rubin finishes in ~26 days**

Hypothetical 1e27-FLOP training run: owner cost (US$ M, whisker = P10–P90) and calendar days on 100,000 accelerators · FP8, base MFU, 90% goodput

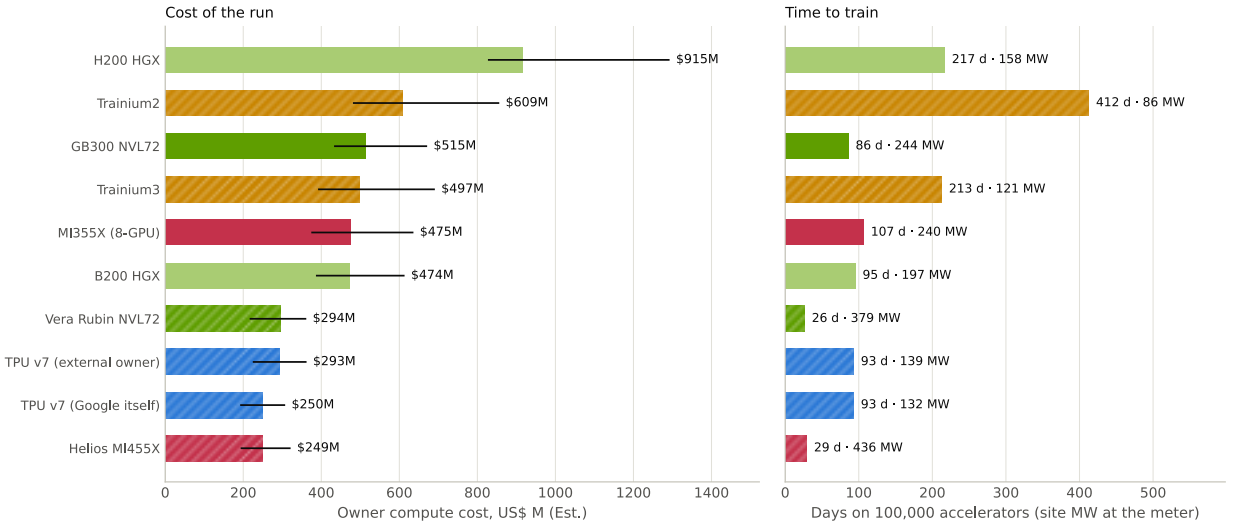


*Est.: equal-MFU assumptions favour less mature platforms; MI455X FP8 may be a sparse figure*

Source: data from repo TCO model; Epoch AI scenario [S14000] [S621] [S622] [S332] [S625] [S626] ...; chart by repo · As of 2026-11-05

> 假设 10 的 27 次方 FLOP 训练运行的双面板条形图。估计所有者算力成本：Helios MI455X $249M，TPU v7（谷歌自用）$250M，TPU v7（外部所有者）$293M，Vera Rubin NVL72 $294M，B200 HGX $474M，MI355X（8-GPU）$475M，Trainium3 $497M，GB300 NVL72 $515M，Trainium2 $609M，H200 HGX $915M。在 100,000 个加速器上所需天数：Helios MI455X 29，TPU v7（谷歌自用）93，TPU v7（外部所有者）93，Vera Rubin NVL72 26，B200 HGX 95，MI355X（8-GPU）107，Trainium3 213，GB300 NVL72 86，Trainium2 412，H200 HGX 217。按每 FLOP 计，英伟达并非最便宜；其训练优势在于训练时长与实际交付的利用率。

训练的图景与推理恰恰相反。按每 FLOP 计，GB300 是较贵的平台之一。其 FP8 算力（5 PFLOPS）较 B200 的 4.5 几乎没有提升 [S32004,S33003]，而机架成本却更高。TPU v7 完成同一训练运行的成本为 ~$293M，低 ~43%（估计）[S14000]。Helios 看起来最便宜，为 ~$249M，但 AMD 尚未说明其 20 PFLOPS FP8 数据是稠密还是稀疏算力 [S144]；若为稀疏，其成本将翻倍。

> **提示**
>
> **算例 —— 在 GB300 上运行一次 $10^{27}$-FLOP 训练。** 每 GPU 有效算力 = 5.0 PFLOPS × 30% MFU × 90% goodput = 1.35 PFLOPS。$10^{27} \div 1.35 \times 10^{15} \div 3{,}600$ = **~206M GPU 小时**。按满功率下每小时 ~$2.50 计算，该训练运行成本 ~$515M（P10–P90 $435–669M）。在 100,000 块 GPU 上需 ~86 天，以及一个 ~244 MW 的站点（估计）[S14000]。Vera Rubin 可在 ~26 天内完成，成本 ~$294M，功耗 ~380 MW（🔴）。按每 100 MW 电力计，Rubin 需 ~100 天完成，TPU v7 需 ~129 天，GB300 需 ~209 天。**结论：** 英伟达在训练上的卖点不是每 FLOP 价格，而是训练时长，以及训练运行能够达到预期 MFU 的确定性。

为何前沿实验室仍主要在英伟达平台上训练？第一，在 10,000+ 芯片规模上实际交付的 MFU 才是难点：NCCL、网络和故障恢复决定了 30% 是否会变成 20%（第 10 层）。第二，时间是有价格的。对于一个下一代模型可能带来数十亿美元收入的实验室而言，提早一个月完成的训练运行，其价值超过硬件上的节省。第三，同一集群随后可用于推理，第 6 节所述优势在此适用。反面证据也确实存在：谷歌在 TPU 上训练 Gemini [S23005]，Anthropic 则将工作负载分布在 TPU、Trainium 和英伟达 GPU 上 [S653]。

**Frontier final-run bills span ~88×: $5.6M (DeepSeek-V3) to ~$0.5B (Grok 4, Est.)**

GPU-hours × $2/GPU-hour (DeepSeek's rental assumption), US$ M (log scale); hatched = estimate

LOG SCALE

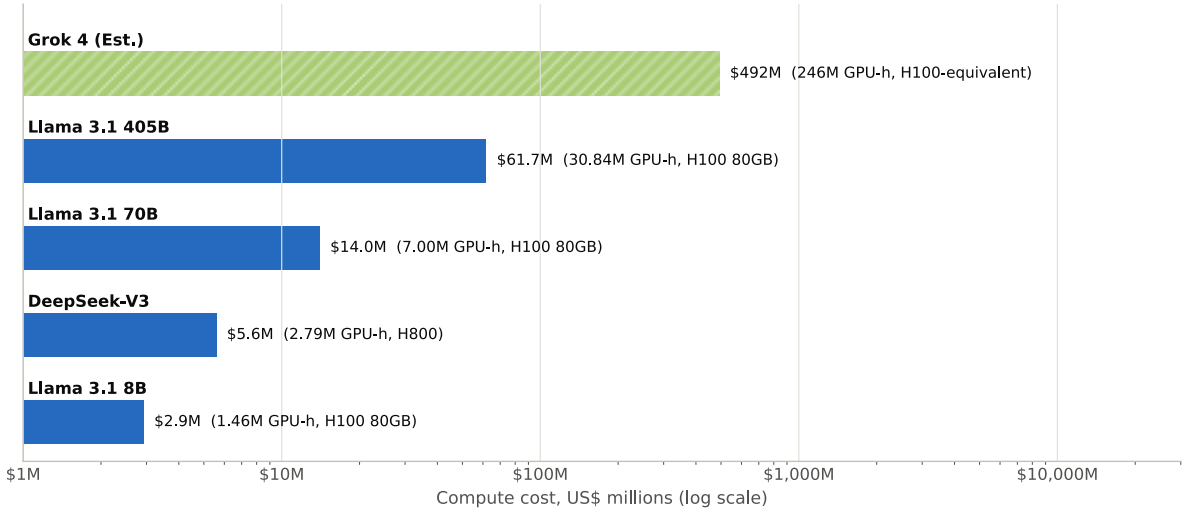


Source: data from Meta model card, DeepSeek-V3 report, Epoch AI [S31002] [S34007] [S34006] [S31008]; chart by repo · As of 2026-11-05

> 按每 GPU 小时 $2 计算的租赁等价算力成本对数刻度水平条形图：Llama 3.1 8B 约 $2.9M（1.46M GPU 小时），DeepSeek-V3 $5.6M（2.788M H800 小时），Llama 3.1 70B $14M，Llama 3.1 405B 约 $62M（30.84M H100 小时），Grok 4 约 $492M（Epoch AI 估计 246M H100 小时）。

**🔧 技术细节：为何同等 MFU 的假设有利于挑战者**

英伟达 30% 的 MFU 源自 Meta 在 Llama 3 上实现的 38–41% BF16 MFU [S34006]，并针对 FP8 翻倍的峰值进行了调整。AMD 或 Trainium 几乎没有公开的大规模 MFU 数据，因此模型给它们设定 24%，并采用较宽区间（15–32%）。同等 MFU 的假设意味着它们的集合通信、编译器和故障处理同样能良好扩展，而公开证据尚未证明这一点。FP4 训练（NVFP4）将使英伟达的峰值再翻一倍左右，模型并未计入这一点。应将训练图表理解为“若各平台都能像英伟达一样高效运行，其成本可能是多少”，而非预测。

## 9. 折旧年限假设改变了什么

加速器的大部分成本是资本费用，因此其分摊期限至关重要。2020 至 2025 年间，超大规模云厂商将服务器寿命从三或四年延长至五年半或六年 [S382,S383,S384,S385]。仅微软 2022 年的那次延长，就被披露为对 FY2023 营业利润带来 ~$3.7B 的提振 [S382]。亚马逊率先转向，于 2025 年以 AI 技术迭代速度为由，将部分服务器和网络设备的寿命缩回五年 [S385]。这些日期所依据的申报文件信息系凭记忆录入，已排队等待重新核实。

**Hyperscalers stretched server lives to 5.5–6 years, but Amazon cut some back to 5 in 2025**

Useful life used to depreciate servers (and network gear where combined), years, by effective date of each 10-K change

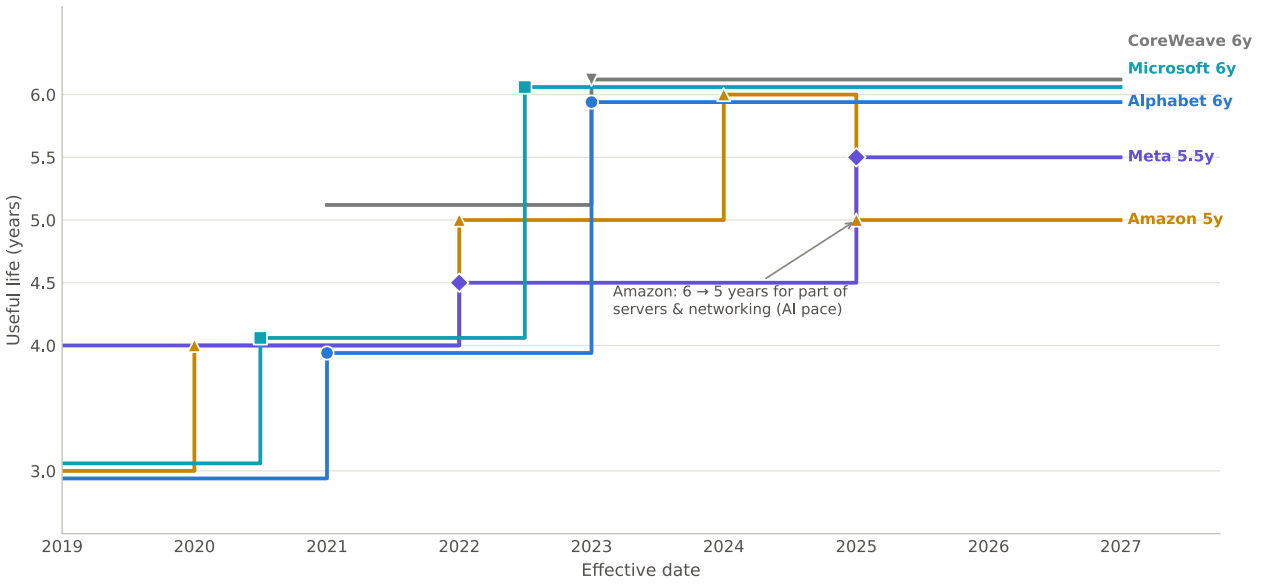


Source: data from 10-K and S-1 filings via SEC EDGAR [S382] [S383] [S385] [S384] [S386]; chart by repo · As of 2026-11-05

> 服务器使用寿命阶梯图：微软由 3 年延至 4 年（2020 年 7 月）及 6 年（2022 年 7 月）；Alphabet 由 3 年延至 4 年（2021）及 6 年（2023）；亚马逊由 3 年延至 4 年（2020）、5 年（2022）、6 年（2024），并于 2025 年将部分服务器缩回 5 年；Meta 由 4 年延至 4.5 年（2022）及 5.5 年（2025）；CoreWeave 自 2023 年起 GPU 服务器为 6 年。

会计上的使用寿命与经济寿命是两回事。会计寿命是一项政策；经济寿命则是 GPU 收入高于其现金成本的持续时间。英伟达的年度迭代节奏缩短了经济寿命：英伟达宣称 Vera Rubin 将每 token 成本较 Blackwell 降低 10 倍 S33006（供应商宣称），而本模型显示，在参考运行点上 Rubin 的每 token 成本比 GB300 低 ~40%（🔴）。每一代新品都会压低旧算力小时的可售价格。

| GB300 使用寿命 | 每装机小时 $ | 每有效小时 $（70%） | 每百万 token $ |
|---|---|---|---|
| 3 年 | $3.83 | $5.47 | $0.24 |
| 4 年 | $3.14 | $4.49 | $0.20 |
| 5 年（亚马逊，部分） | $2.73 | $3.90 | $0.17 |
| 6 年（微软、Alphabet、CoreWeave） | $2.46 | $3.51 | $0.16 |
| 7 年 | $2.27 | $3.24 | $0.14 |

资本成本 8%；估计 S14000。

**Est.: cutting GB300's life from 6 to 4 years lifts a useful GPU-hour from $3.51 to $4.49, close to its $5.00 rental price**

Owner cost per useful accelerator-hour (70% utilization) vs useful life · solid = 8% cost of capital, dashed = 0% · dotted = July 2026 rental price

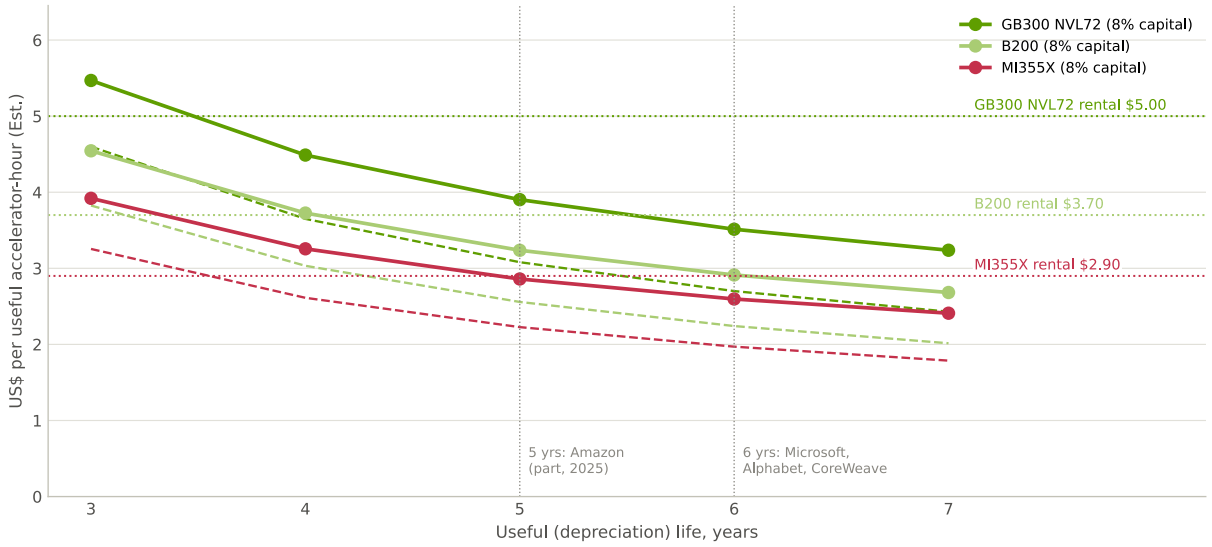


*Est.: repo TCO model; rental = SemiAnalysis July 2026 survey (S622)*

Source: data from repo TCO model; SemiAnalysis rental survey [S14000] [S621] [S622] [S332] [S625] [S626] …; chart by repo · As of 2026-11-05

估计每有效小时所有者成本随折旧年限（3 至 7 年）变化的折线图。GB300 NVL72，资本成本 8%：3 年约 $5.47，4 年 $4.49，6 年 $3.51，对比 SemiAnalysis 2026 年 7 月租赁价格 $5.00；B200 在 6 年时约 $2.91，租赁价 $3.70；MI355X 约 $2.60，租赁价 $2.90。寿命越短，租赁方利润越受挤压；若不计资本成本，每条曲线约下降 10-20%。

**提示**

**算例 —— 折旧年限从六年改为四年对 GPU 云意味着什么。** SemiAnalysis 2026 年 7 月的调查显示，GB300 租赁价格为每 GPU 小时 ~$5.00 [S622]。按六年寿命、70% 利用率计算，所有者每售出小时成本为 ~$3.51，扣除间接费用前利润率 ~30%。按四年计算为 ~$4.49，利润率 ~10%；按三年计算为 ~$5.47，即出现亏损（估计）[S14000]。**结论：** 对新兴云服务商而言，折旧政策不是会计细节。它决定 GPU 租赁能否覆盖资本成本，并体现在GPU 抵押贷款的贷款条款中。

对于使用自有 GPU 的超大规模云厂商，影响相同，只是体现在不同的科目上：寿命缩短会降低当期报告的营业利润；寿命延长则推迟成本确认，并增加日后若经济寿命被证明更短时需计提减值的风险。

## 10. 看空观点：GPU 租赁价格通缩

最有力的看空论点并不需要任何竞争对手胜出，只需要英伟达持续胜出。每一代产品都会降低每 token 成本，因此旧加速器小时的市场价格会向某一水平回落：在该水平上，其 token 成本与最新芯片相同，即其 token 平价租金。若价格下跌快于折旧计划的假设，所有者将面临亏损和减值，而建立在 GPU 抵押品之上的循环融资也将被削弱（第 18 章）。

**H100 rentals fell ~75% from ~$8/GPU-hr (2023) to ~$2-3 on neoclouds; AWS list −44%**

On-demand list/observed prices, US$ per GPU-hour (instance ÷ GPUs) · marker = provider type · contract rates are lower

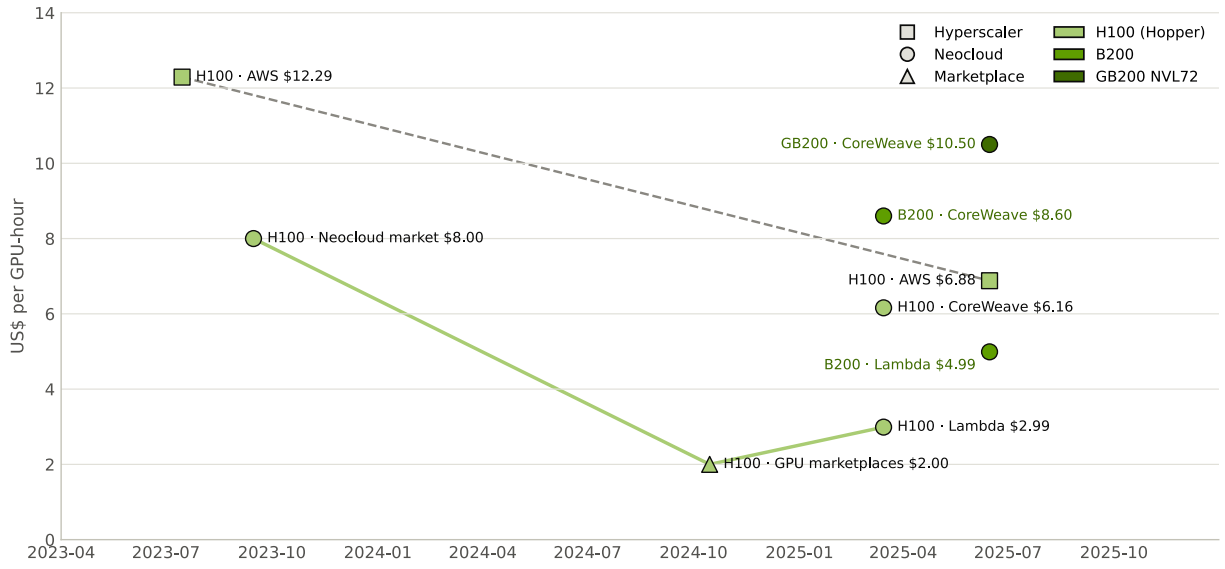


Source: data from AWS, CoreWeave, Lambda, Latent Space [S391] [S393] [S395] [S394] [S392]; chart by repo · As of 2026-11-05

> GPU 租赁价格随时间变化的散点图。H100：AWS p5 按需价格在 2023 年 7 月发布时为每 GPU 小时 $12.29，2025 年 6 月降价后为 $6.88；新兴云服务商 H100 在 2023 年约 $8，到 2024 年末交易平台价格低于 $2，2025 年 Lambda 标价 $2.99、CoreWeave 标价 $6.16。2025 年 Blackwell 标价：B200 $4.99（Lambda）至 $8.60（CoreWeave），GB200 $10.50（CoreWeave）。

历史确有其事。H100 租金从 2023 年每小时 ~$8 跌至 2024 年末交易平台上的不足 $2 [S393]，AWS 在 2025 年 6 月将 H100 标价下调 ~44% [S392]。这些租赁数据同样系凭记忆录入，已排队等待重新核实。

> **提示**
>
> **算例 —— Vera Rubin 对一个 GB300 小时的冲击。** 在参考运行点上，一块 GB300 GPU 每个繁忙小时产出 ~22.5M token [S621]。若 Vera Rubin 生产每百万 token 的成本为 ~$0.094（🔴 估计）[S14000]，那么一旦 Rubin 供应充足，买方最多只愿为一个 GB300 小时支付 ~22.5 × $0.094 ≈ **$2.12**。而 GB300 所有者每售出小时的成本为 ~$3.51。按同样的算法，在该工作负载上相对于 GB300，一个 H200 小时的价格不到 $0.20。**结论：** 在供应不受限的市场中，英伟达每一代产品令上一代贬值的速度都快于六年折旧的假设；只有在需求超过供应时，已装机存量才能保值。

迄今为止需求一直超过供应。H100 一年期合约价格在 2025 年 10 月触底于 ~$1.70，随后随着推理需求增长，到 2026 年 3 月上涨 ~38% 至 ~$2.35 [S12516,S12517]。老款 GPU 在其“够用”的工作负载上仍能赚钱：较小的稠密模型、微调和批处理作业。SemiAnalysis 对 H100 的所有者 TCO 估计为每小时 ~$1.17 [S622]，因此一块已完全折旧、以 $2.35 出租的 H100 仍然有利可图。

**H100 rentals rose 38% from a $1.70/hr low (Oct 2025) to $2.35 by Mar 2026**

H100 rental price observations by series, US$ per GPU-hour (different contract types: compare within a series)

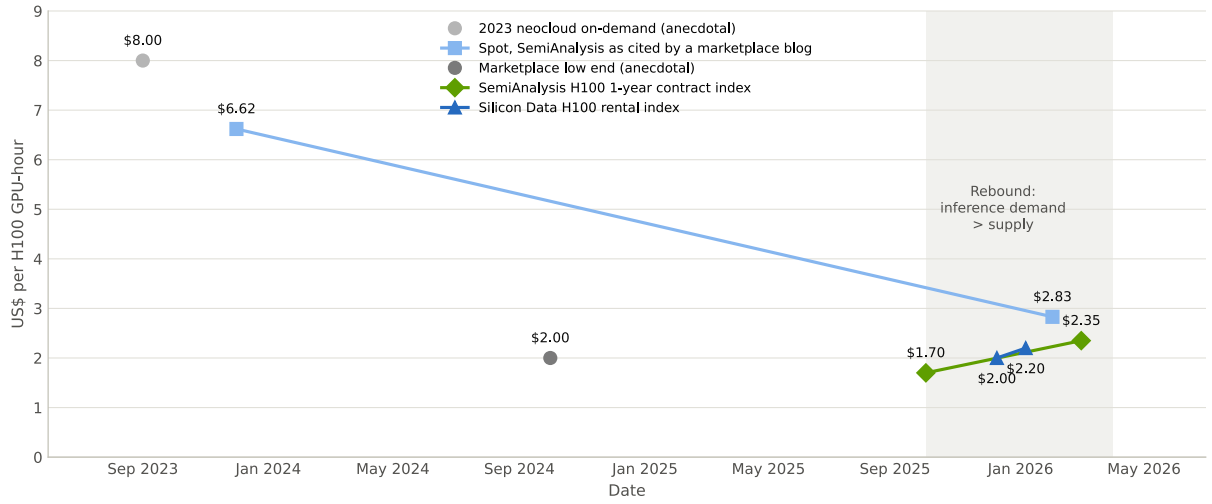


*Mixed contract types; 2023–24 points are anecdotal*

Source: data from SemiAnalysis, Silicon Data, Latent Space as cited [S393] [S12531] [S12516] [S12517]; chart by repo · As of 2026-11-05

H100 租赁价格折线与散点图：2023 年 9 月新兴云服务商价格约为每 GPU 小时 $8，2023 年末现货价 $6.62，到 2024 年 10 月交易平台价格约 $2；随后 SemiAnalysis 一年期合约指数在 2025 年 10 月触及 $1.70 低点，到 2026 年 3 月升至 $2.35（+38%）；Silicon Data 指数在 2025 年 12 月至 2026 年 1 月间从 $2.00 升至 $2.20；2026 年 2 月引用的现货价格为 $2.83。随着推理需求超过供应，老款 GPU 价格被上调。

**注**

🐂 **看多观点：** token 需求的复合增长速度快于每 token 成本的下降速度（谷歌的 token 量在 18 个月内增长 ~134 倍 [S32018,S32020]），因此每一代产品的产能都会被消化。软件持续提升老款 GPU 的吞吐量 [S601,S603]，且英伟达为合作伙伴的部分未售出产能提供兜底，例如截至 2032 年在 CoreWeave 的 $6.3B [S90067]。

**注意**

🐻 **看空观点：** 只有当 token 需求的价格弹性保持在 1 以上时，支出才会增长（CS5）。若供应追上需求——无论是通过吉瓦级扩建 [S398] 还是高效模型——租赁价格将跌至 token 平价水平，六年寿命将变成减值。届时，支撑英伟达毛利率的同一吞吐量优势，反而会摧毁其自身已装机存量的残值。首当其冲的是贷款方、新兴云服务商以及英伟达的兜底安排。

## 🎯 企业发展视角

1. **制胜指标是在指定运行点下实测的每兆瓦每秒 token 数。** 更便宜的加速器小时并不足够：模型显示，26% 的小时折扣会输给 8.5 倍的吞吐量差距。对于任何推理挑战者，包括高通（Qualcomm）的 AI200/AI250 和 Dragonfly AI300（仅基于公开公告）[S90028,S90060]，哪些运行点和模型（稠密、长提示、批处理、高交互速度）对 NVL72 最不利？什么样的公开证据能让每 token 成本的宣称具有可信度？
2. **英伟达的毛利率可守，但并非不可撼动。** ~20% 的降价即可追平最强的自有运营替代方案，且仍保留 ~66% 的毛利率（🔴）。预计英伟达将通过捆绑销售、融资和路线图时机来防守，而非下调标价。这给以价格取胜的第二供应商留下了多少空间？
3. **电力是稀缺投入，因此已通电的站点是战略资产。** 在一个固定的 100 MW 站点上，各平台的年度成本相近，而已出货系统之间的 token 产出相差最多 ~15 倍（估计）。与站点所有者、电力公司和 800 VDC 供应商的合作，其价值可能高于芯片性能的增量提升（第 08 层）。

4. **软件对每 token 成本的杠杆作用与硬件同样大**。 MTP、宽专家并行和服务引擎可在硬件不变的情况下使成本变动 2–20 倍 [S624,S631]。掌控或影响服务栈（Dynamo、vLLM、SGLang，或高通的 Modular/Mojo [S9511]），每美元的价值可能高于芯片功能。在新模型上实现首日（day-0）性能的最低成本路径是什么?
5. **残值风险存在于融资链条中**。 折旧年限、利用率和 token 平价租金决定了 GPU 抵押贷款、新兴云租约和供应商兜底能否站得住。任何涉及 GPU 产能的合作或投资，都应围绕其假设的寿命、利用率和租金曲线开展尽职调查，而非着眼于芯片规格。

# 15 —— 竞争格局

跨层专题 15 · 谁在与英伟达竞争、在哪些层级竞争、竞争强度如何 · 约 22 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **市场规模翻了两番，份额几乎未变。** 2025 年英伟达（NVIDIA）占 AI 数据中心芯片收入的约 87%，2023 年约为 90%；同期市场规模从约 $53B 增至约 $224B（估计，本资料库测算）[S416,S1,S660,S661,S663]。定制 ASIC 约占收入的 10%，但 TrendForce 估计基于 ASIC 的服务器将占 2026 年 AI 服务器出货量的约 27.8% [S2517]。
- **没有任何对手能匹敌其全栈布局。** 最接近的谷歌（Google）TPU 在英伟达 12 个层级中的 5 个持平或领先；在本资料库的评分矩阵中，所有“对手×层级”单元格中有 60% 被评为“落后” [S15014]。
- **AMD 已弥合芯片差距。** MI455X 标称 432 GB HBM4、23.3 TB/s 带宽和 20 PFLOPS FP8，而 Rubin 为 288 GB、19.2 TB/s 和 17.5 PFLOPS [S144,S90093,S33005,S90006]。在 MLPerf Llama 2 70B 测试中，MI355X 单卡性能与 B200 持平（12,935 vs 12,994 tokens/s） [S602]。
- **超大规模云厂商的自研芯片单芯片性能落后，但成本占优。** 自有 Ironwood 的每芯片小时成本约为 $1.21，而 GB300 约为 $2.31（估计，SemiAnalysis） [S622]。但 Rubin 的 HBM4 重新拉开了硬件差距：2026 年超大规模云厂商芯片的内存带宽仅为 Rubin 的 32–45%（本资料库测算） [S15014]。
- **最大的买家如今采用组合采购。** OpenAI：6 GW 的 AMD、10 GW 由博通（Broadcom）打造的加速器，以及自 2027 年起约 2 GW 的 Trainium [S24000,S174,S15000]。Anthropic：最多 1M 颗 TPU 和最多 5 GW 的 Trainium [S653,S15000]。Meta：6 GW 的 AMD，外加租用的 TPU [S24004,S90025]。
- **收入数据仍显示英伟达一家独大。** 其 FY2026 约 $194B 的数据中心收入约为 AMD 数据中心分部的 12×、博通 AI 收入的约 10× [S1,S450,S451]。博通是攀升最快的对手：其 Q3 FY2026 的 AI 收入为 $16.7B，同比增长 221% [S2516]。
- 🔴 **本资料库判断：** 英伟达的领先如今是平台与迭代节奏的领先，而非芯片本身的领先。竞争对手在动摇其出货量之前，早已先压制其在最大买家处的定价权。

**No rival matches NVIDIA across the stack: the closest, Google TPU, is level or ahead in only 5 of 12 layers**

Repo verdict vs NVIDIA by stack layer (02-13) and competitor; letter = verdict, number = score 0-5 (analyst judgement, sourced)

| | 02 Silicon | 03 Memory & supply | 04 CPU | 05 Scale-up | 06 Scale-out | 07 DPU / SuperNIC | 08 Systems & racks | 09 System software | 10 Libraries | 11 Inference software | 12 Cloud & orchestr. | 13 Ecosystem & capital |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| AMD | P 4 | B 3 | **L 5** | B 2 | B 3 | B 3 | B 2 | B 3 | B 2 | B 3 | D 2 | B 3 |
| Google TPU | P 4 | B 4 | P 4 | D 5 | D 4 | D 3 | P 5 | B 3 | B 3 | **L 4** | **L 5** | B 4 |
| AWS Trainium | B 3 | B 3 | P 4 | B 3 | D 4 | D 4 | B 4 | B 2 | B 2 | B 3 | **L 5** | B 3 |
| Microsoft Maia | B 3 | B 2 | B 3 | B 3 | D 3 | D 3 | B 3 | B 2 | B 1 | B 2 | **L 5** | B 2 |
| Meta MTIA | D 2 | B 2 | B 1 | B 1 | D 4 | B 2 | D 3 | D 4 | B 2 | D 3 | D 1 | B 2 |
| Broadcom | D 4 | D 4 | B 1 | B 4 | **L 5** | B 3 | D 2 | D 1 | D 1 | D 1 | D 0 | B 4 |
| Marvell | D 3 | D 3 | B 1 | B 3 | B 4 | B 3 | D 1 | D 1 | D 1 | D 1 | D 0 | B 3 |
| Intel | B 2 | D 3 | P 4 | B 2 | B 2 | B 3 | B 1 | B 2 | B 2 | B 2 | B 1 | B 2 |
| Huawei | B 3 | B 1 | B 3 | D 4 | P 4 | B 3 | D 4 | B 2 | B 2 | B 3 | D 3 | D 3 |
| Qualcomm | D 2 | D 3 | B 2 | B 1 | B 2 | B 1 | B 2 | B 2 | B 1 | D 2 | B 1 | B 1 |
| Cerebras | D 4 | D 3 | B 1 | D 3 | B 2 | B 1 | B 3 | B 2 | B 1 | **L 4** | B 2 | B 2 |
| Groq | D 3 | D 3 | B 1 | D 2 | B 1 | B 1 | B 2 | B 2 | B 1 | D 3 | B 2 | B 1 |

L = leads NVIDIA · P = parity · B = behind · D = different approach

*Analyst judgement (speculative)*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S143] [S361] [S379] [S144] [S624] ...; chart by repo · As of 2026-11-05

12 家竞争对手在英伟达 12 个技术栈层级上的热力图。谷歌 TPU 在 12 个层级中的 5 个持平或领先，为所有对手中最多；全部单元格中有 60% 为“落后”，软件与软件库的 24 个单元格中有 19 个落后。超大规模云厂商仅在云服务上领先；博通在以太网交换上领先；谷歌 TPU 在推理成本上领先。

## 市场份额：商用 GPU 与定制 ASIC

两类卖方在相互竞争。商用芯片厂商（英伟达、AMD、英特尔（Intel）及初创公司）向所有客户销售芯片和系统。定制 ASIC 为单一买家设计，通常与博通或美满电子（Marvell）等 ASIC 设计合作伙伴合作开发，从不在公开市场销售。份额很难衡量：定制芯片的“价格”是设计合作伙伴的收入，而非买家原本需要付给英伟达的金额。

**NVIDIA kept ~87% of AI silicon revenue in 2025 while the pool grew 4.2x from 2023**

Share of vendor-reported AI data-center revenue (NVIDIA DC, AMD Instinct, Broadcom AI, Marvell AI), %; labels = pool US$ B

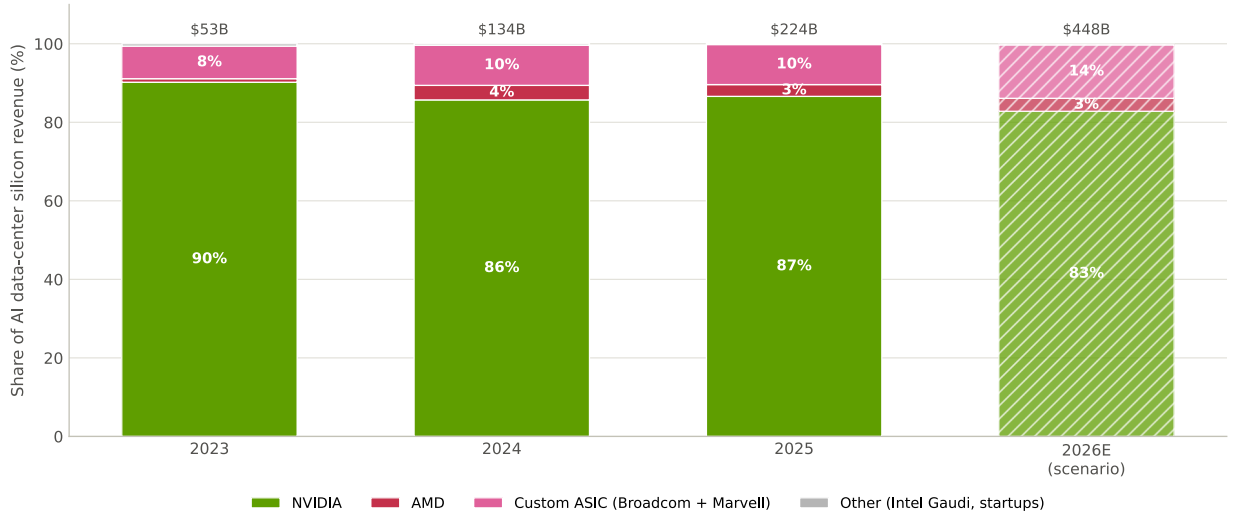


*Est.; hatched = 2026E scenario*

Source: data from vendor filings; repo calculation [S416] [S417] [S1] [S403] [S405] [S660] ...; chart by repo · As of 2026-11-05

按厂商划分的 AI 数据中心芯片收入份额 100% 堆叠柱状图。英伟达 2023 年为 90%，2025 年为 87%；定制 ASIC 合作伙伴（博通和美满电子）2025 年约为 10%；AMD 为 1-4%。市场规模从 2023 年的约 $53B 增至 2025 年的 $224B，2026 年估计为 $448B（阴影部分）。

| 年份 | 市场规模（US$ B，估计） | 英伟达 | AMD | 定制 ASIC（博通 + 美满电子） | 其他 |
|---|---|---|---|---|---|
| 2023 | ~53 | 90.2% | 0.9% | 8.3% | 0.6% |
| 2024 | ~134 | 85.7% | 3.7% | 10.2% | 0.4% |
| 2025 | ~224 | 86.6% | 3.0% | 10.2% | 0.2% |
| 2026E | ~448 | 82.8% | 3.3% | 13.6% | 0.2% |

本资料库基于公司财报在 `data/market_share.csv` 中测算 [S416,S417,S1,S660,S661,S662,S663]；不含中国本土市场（华为昇腾）；2026E 为 🔴 推测。

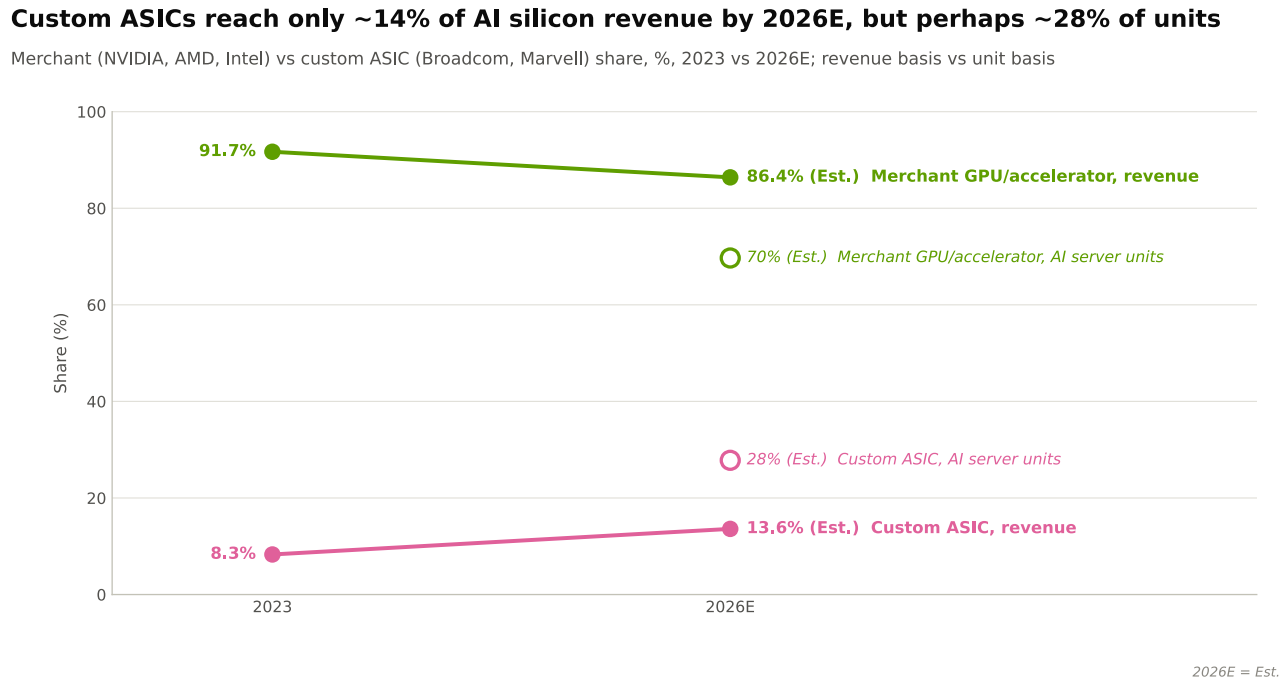


斜率图：2023 年至 2026E，商用 GPU 和加速器占 AI 数据中心芯片收入的比例从 92% 降至约 86%，定制 ASIC 则从 8% 升至约 14%。按出货量计，TrendForce 类估计显示基于 ASIC 的服务器占 2026 年 AI 服务器出货量近 28%，原因是定制芯片的单价低得多。

**提示**

**算例 —— 为何 ASIC 按金额约占 14%，按出货量却约占 28%。** TrendForce 估计基于 ASIC 的服务器占 2026 年 AI 服务器出货量的约 27.8%，基于 GPU 的服务器约占 69.7% [S2517,S666]。收入占比约为 14% 对 86%（估计，已将博通 FY2026 更新为约 $57B）[S15014]。因此，ASIC 相对于 GPU 的单位收入为 (14 ÷ 27.8) ÷ (86 ÷ 69.7) ≈ 0.50 ÷ 1.23 ≈ **0.41**。一台定制 ASIC 服务器为其供应商带来的收入，约为一台 GPU 服务器为英伟达及其合作伙伴带来收入的 40 %。**结论：** 出货量份额夸大了对英伟达收入的威胁，但它衡量的是对其*出货量*和定价权的威胁。（口径不同：服务器与芯片；🔴 本资料库测算。）

定制 ASIC 的收入体现在设计合作伙伴身上。博通的 AI 收入（既包括 AI 以太网，也包括定制 XPU）从 2023 年的约 $3.8B 增至 2025 财年的约 $20.2B [S660,S661]，随后单季度（Q3 FY2026）即达 $16.7B，并指引 Q4 为 $21.7B [S2516]。图表现采用约 $57B 作为博通的 FY2026 数据——即已报告季度与指引季度之和 [S2516]。

**Broadcom's AI revenue rose 2.8x in two years to $6.5B a quarter and tracks ~$57B for FY2026; Marvell's is ~1/8 the size**

Left: Broadcom AI semiconductor revenue by fiscal quarter (US$ B). Right: annual AI revenue, Broadcom vs Marvell (US$ B)

*Hatched = guidance or Est.*

Source: data from Broadcom, Marvell earnings releases [S660] [S661] [S451] [S2516] [S662] [S453] ...; chart by repo · As of 2026-11-05

两个面板。左：博通季度 AI 半导体收入从 2024 财年 Q1 的 $2.3B 攀升至 2025 财年 Q4 的 $6.5B，2026 年 Q1 指引为 $8.2B（阴影）。右：年度 AI 收入，博通约为 $3.8B（2023）、$12.2B（2024）、$20.2B（2025），FY2026 约 $57B（Q1 和 Q4 为指引，Q2 为推算，Q3 为已报告）；美满电子分别为 $0.55B、$1.5B、$2.5B 和约 $3.5B（2026E）。博通的数据既包括 AI 以太网网络，也包括谷歌 TPU 等定制 XPU。

**超大规模云厂商的钱包。** 厂商市场份额掩盖了买家的整体支出规模。四大超大规模云厂商对 2026 年资本开支的指引约为 $728B（取中值）[S12518,S12519]。英伟达来自超大规模客户的数据中心收入年化约 $173B，约占其四分之一 [S403,S406]。大部分资本开支流向建筑、电力、网络和内存。

**Est.: NVIDIA's ~$173B hyperscale run-rate equals ~24% of the Big-4's ~$728B 2026 capex**

US$ B per year, 2026: Big-4 capex guidance (midpoints) vs annualized supplier run-rates; scopes differ (see notes): an order-of-magnitude view of who captures the hyperscaler AI dollar

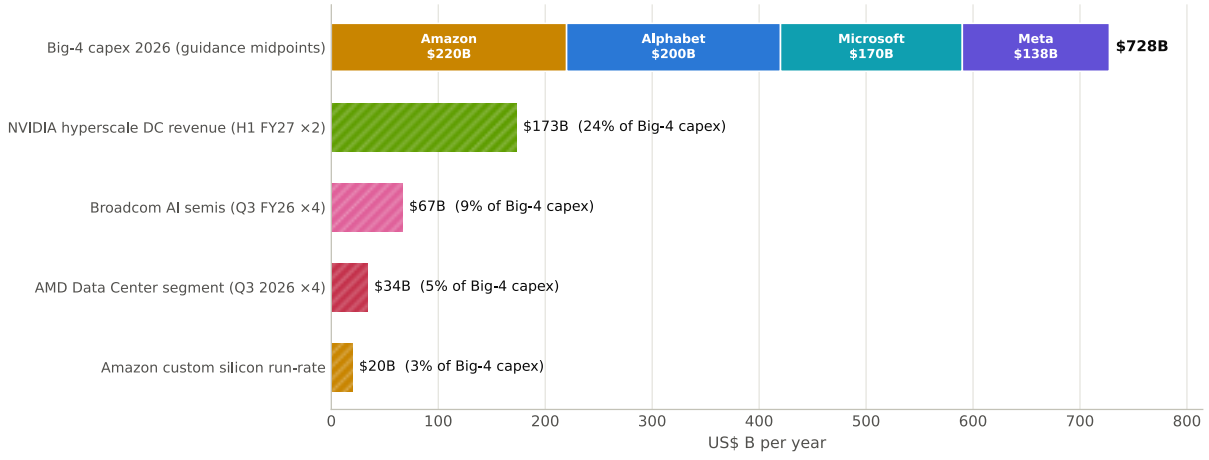


*Est.: run-rates annualized by repo; scopes not identical*

Source: data from company guidance and filings; repo annualization [S12518] [S12519] [S403] [S406] [S90011] [S2516] ...; chart by repo · As of 2026-11-05

水平柱状图。四家最大的超大规模云厂商对 2026 年资本开支的指引约为 $728B（亚马逊约 $220B、Alphabet 约 $200B、微软约 $170B、Meta 约 $138B，取中值）。相比之下，英伟达来自超大规模客户的数据中心收入年化约 $173B（FY2027 上半年乘以二），约占资本开支的 24%；博通 AI 半导体收入年化约 $67B（Q3 FY2026 乘以四，含网络及非超大规模客户）；亚马逊自有定制芯片业务的年化收入已超过 $20B；AMD 整个数据中心分部年化约 $34B。大部分资本开支流向建筑、电力、网络和内存，而非加速器。

### 🔧 技术细节：份额数据包含什么、遗漏什么

- **英伟达**按数据中心收入衡量，其中包括网络（FY2026 约 $31B）、CPU 和系统，因此高估了“GPU”份额 [S402]。
- **定制 ASIC** 按博通和美满电子的 AI 收入计算，其中包括 AI 以太网以及 OpenAI 等非超大规模客户，但不含超大规模云厂商自身的设计成本。
- **AMD** 为 Instinct 估计值（AMD 未披露）；其数据中心分部还包含 EPYC CPU [S663,S450]。

- **中国**未计入：华为昇腾收入未公开，而英伟达在出口管制后对华数据中心销售接近于零 S90011。
- 没有公开来源提供“买家的加速器成本”这一更合适的分母，因此所有份额数据都应视为存在 ±3 个百分点的误差。

## 各对手的竞争领域：层级、广度与深度

顶部的热力图对 12 家对手在英伟达 12 个技术栈层级（从第 02 层芯片到第 13 层生态与资本）上逐一评分。每个单元格都有 🟩🟨🟥🟦 判定及附出处的理由，见 `data/competitor_matrix.csv`。技术栈广度统计对手得分至少 3 分（满分 5 分）的层级数；深度为其得分最高的三个层级的平均分。

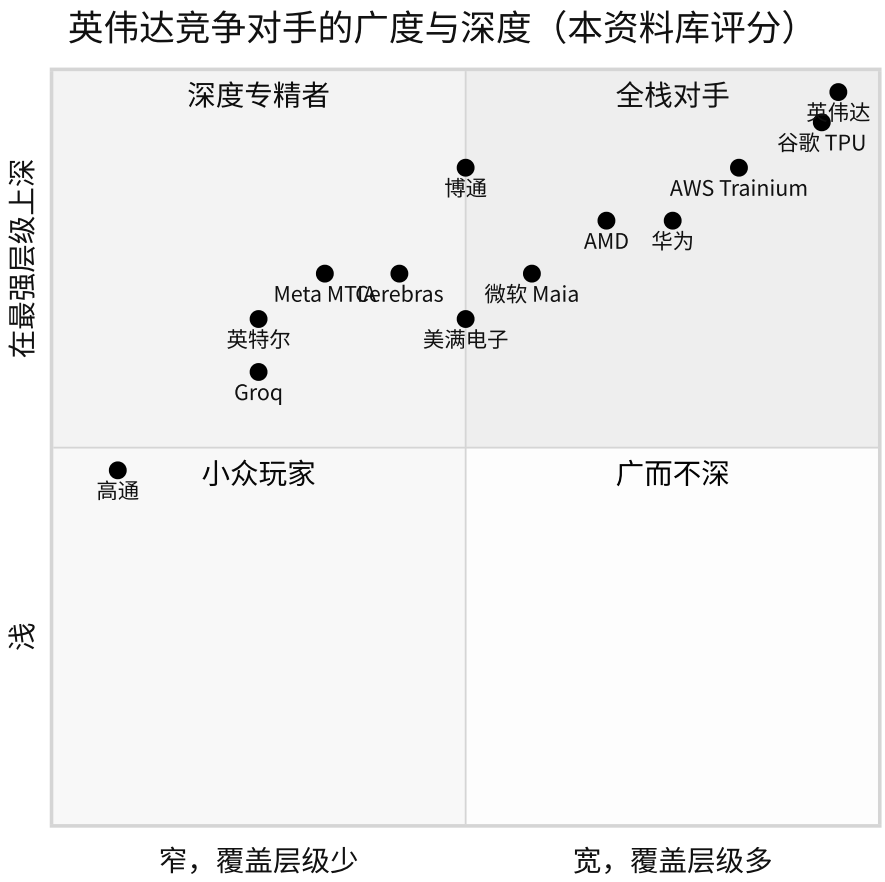


x = 得分 ⩾ 3（满分 5）的层级数除以 12；y = 得分最高的三个层级的平均分除以 5。英伟达和谷歌 TPU 均覆盖 12 个层级且得分为 5.0，为便于辨认已将二者错开。本资料库分析师判断（🔴）S15014。

有三个规律十分突出。

1. **只有垂直整合的超大规模云厂商覆盖面广。** 谷歌和 AWS 在 10–12 个层级上得分，因为它们拥有云、网络、CPU 和芯片，但这种广度只存在于其自有数据中心内部。
2. **AMD 是唯一覆盖面广的商用厂商。** 它覆盖 8 个层级，并在其中一个层级（EPYC 主机 CPU）领先，但在软件、机架和纵向扩展（scale-up）上落后。
3. **大多数对手只是单点方案。** 12 家中有 7 家覆盖六个或更少的层级。博通深度最高：它在以太网交换上领先，同时*向*超大规模云厂商销售芯片。

**Only Google's in-house TPU stack rivals NVIDIA's breadth; AMD covers 8 of 12 layers**

Breadth = layers (02-13) scored 3 or more of 5; depth = average layer score; repo analyst judgement

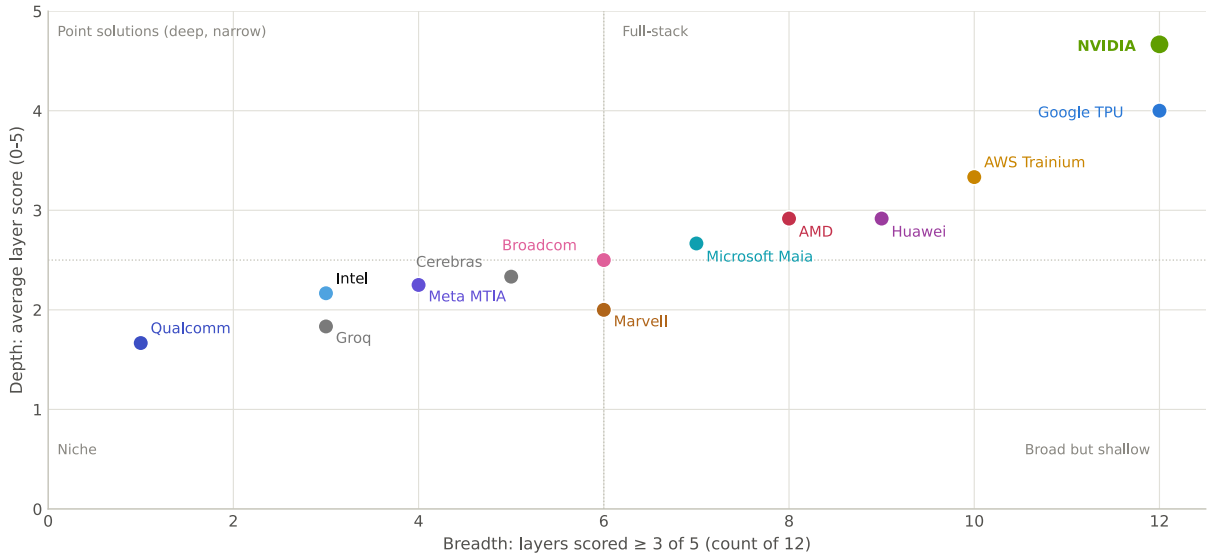


*Analyst judgement (speculative)*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S379] [S412] [S468] [S630] ...; chart by repo · As of 2026-11-05

技术栈广度与平均深度的散点图。英伟达在 12 个层级中全部得分 3 分或以上，平均 4.7；谷歌 TPU 同样覆盖 12 个层级（平均 4.0），但仅限谷歌内部；AMD 覆盖 8 个（平均 2.9）；12 家对手中有 7 家覆盖六个或更少的层级，即单点方案。

**提示**

**算例 —— 解读谷歌的“12 中占 5”。** 谷歌的 TPU 技术栈在推理成本和云分发上为 🟩，在芯片、CPU 和机架上为 🟨，在纵向扩展、横向扩展（scale-out）和卸载（offload）上为 🟦（自研设计，不对外销售），在内存供应、系统软件、软件库和生态上为 🟥 S15014。因此 12 个单元格中有 5 个为 🟩 或 🟨。若各层级等权，谷歌的平均分为 4.0，英伟达为 4.7。这 0.7 分的差距几乎全部来自软件以及对外销售能力。**结论：** 谷歌若开放其技术栈，可以弥合大部分差距；2025–26 年的举措（向 Anthropic、Meta 和甲骨文（Oracle）提供 TPU）正是朝这一方向迈出的一步。

雷达图在九个能力维度上讲述了同样的故事：每个对手都在软件上落后，多数在机架级系统上落后，而领先之处则零散分布（AMD 在内存，谷歌在纵向扩展域规模和成本，博通在以太网交换）。

### Google TPU is the strongest all-round challenger, averaging 4.0 of 5 vs NVIDIA's 4.7

Capability scores 0-5 on nine axes; competitor (filled) vs NVIDIA reference (dashed green); analyst judgement, sourced

Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S143] [S361] [S630] [S402] ...; chart by repo · As of 2026-11-05

六张雷达图，在九个能力维度上将 AMD、谷歌 TPU、AWS Trainium、微软 Maia、Meta MTIA 和英特尔与英伟达对比。平均得分：AMD 3.3；谷歌 TPU 4.0；AWS Trainium 3.0；微软 Maia 2.6；Meta MTIA 2.4；英特尔 2.3；英伟达为 4.7。AMD 在内存容量上领先；谷歌 TPU 在纵向扩展域规模和成本上领先；每个对手都在软件生态和机架级系统上落后。

**ASIC partners, China and start-ups attack one or two axes each; none averages above 3.2 of 5**

Capability scores 0-5 on nine axes; competitor (filled) vs NVIDIA reference (dashed green); analyst judgement, sourced

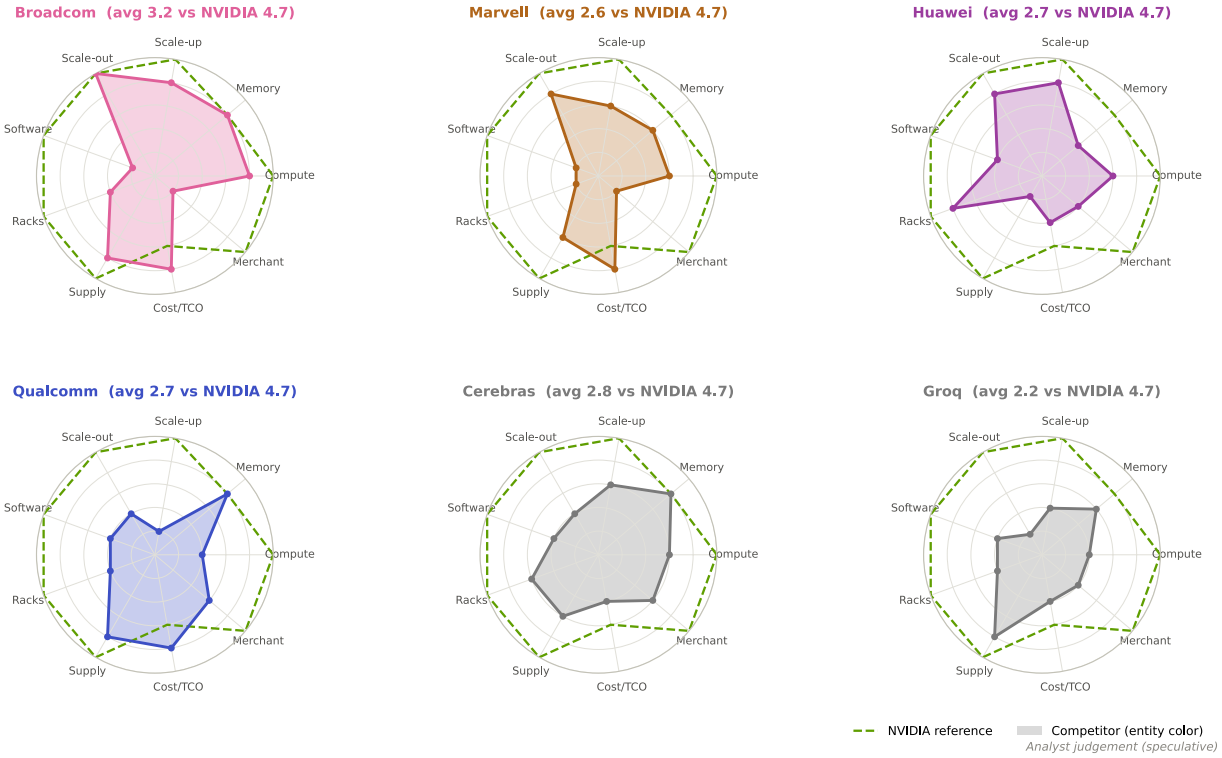


Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S143] [S361] [S630] [S402] ...; chart by repo · As of 2026-11-05

六张雷达图，在九个能力维度上将博通、美满电子、华为、高通、Cerebras 和 Groq 与英伟达对比。平均得分：博通 3.2；美满电子 2.6；华为 2.7；高通 2.7；Cerebras 2.8；Groq 2.2；英伟达为 4.7。博通在横向扩展以太网交换上领先，华为在纵向扩展域规模上持平但受供应制约，高通、Cerebras 和 Groq 则以不同的内存设计规避 HBM 供应限制。

## 战略原型

竞争对手以五种方式挑战英伟达，每种方式都有其自身的经济引擎和失败模式。

| 原型 | 代表厂商 | 经济引擎 | 对英伟达构成的最佳情形 | 典型失败模式 |
|---|---|---|---|---|
| 全栈商用厂商 | 英伟达；AMD（建设中）；英特尔（重新进入） | 向所有客户销售芯片、机架和软件 | 规格相同、价格更低的第二供应商（AMD） | 软件和机架成熟度滞后；数据中心收入少约 13×，难以支撑迭代节奏 S405,S450 |
| 超大规模云厂商自研（自用芯片） | 谷歌 TPU、AWS Trainium、微软 Maia、Meta MTIA | 在自有工作负载上消除商用厂商的利润 | 在一个 TPU 工作负载上每 token 成本低约 18% S625 | 每代需要约 130,000 颗芯片才能回本（🔴） S23010；仅限内部使用 |
| 设计服务公司 | 博通、美满电子、联发科（MediaTek）、世芯（Alchip）、创意电子（GUC） | 就设计、SerDes、封装和供应收费 | 把每个大买家都变成潜在的 XPU 客户（定制 ASIC 设计公司） | 客户集中于少数几家；依赖台积电（TSMC）和 HBM 配额 |
| 推理专精厂商 | Cerebras、SambaNova、Etched、d-Matrix、Tenstorrent；高通（Qualcomm）AI200/AI250 | 重构内存架构，以提升 token 速度或降低成本 | 随推理需求增长赢得延迟或成本细分市场（推理初创公司、高通） | 软件覆盖面窄；Groq 的技术已被英伟达以约 $20B 获得授权（🟡） S90018 |
| 国家冠军企业 | 华为昇腾、寒武纪（Cambricon） | 出口管制保护下的本土市场 | 在英伟达被排除在外的情况下主导中国市场（中国） | 制程节点和 HBM 受限；SuperPoD 出货未经证实（🔴） S90042 |

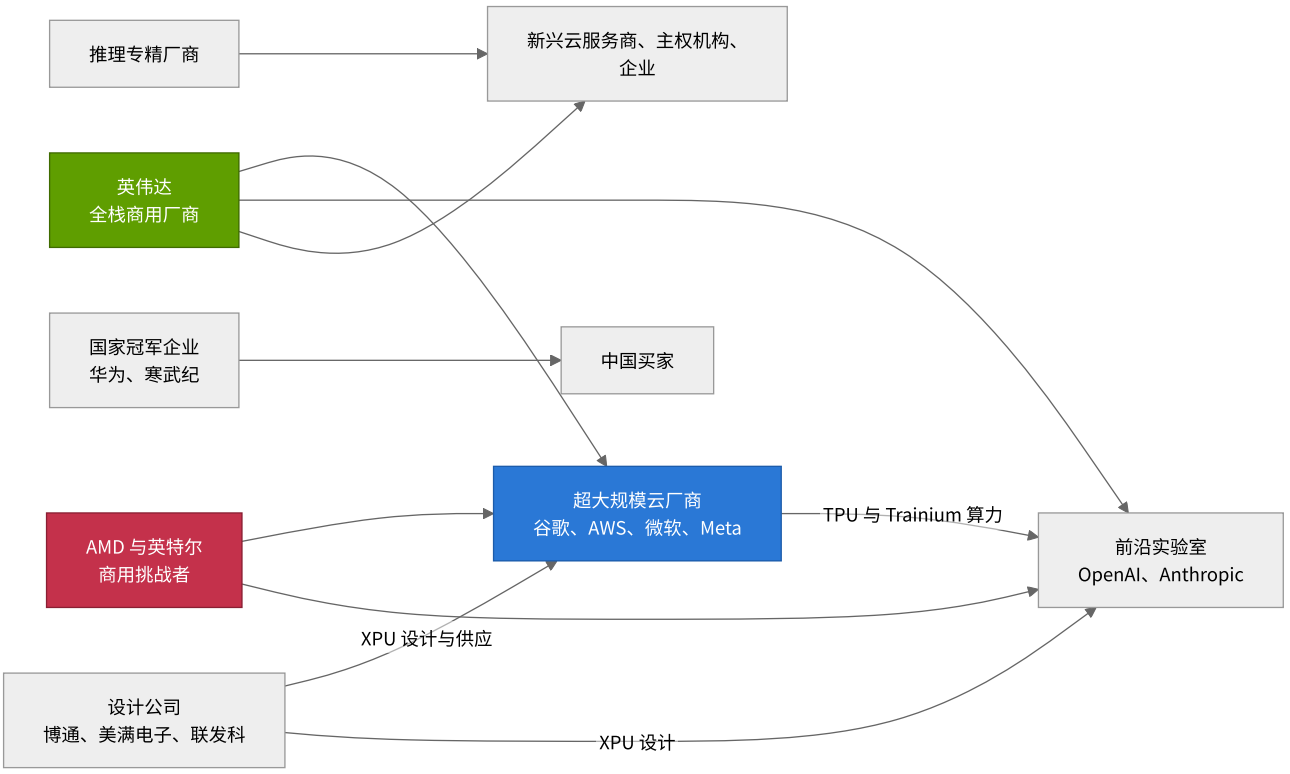


2025–26 年的转变：超大规模云厂商成为前沿实验室的*供应商*。谷歌向 Anthropic 和 Meta 出租并出售 TPU [S653,S90025]；AWS 向 Anthropic 和 OpenAI 供应 Trainium [S15000]。而这些公司仍是英伟达最大的客户。

> **提示**
>
> **算例 —— 自研芯片的盈亏平衡点。** 一个前沿制程芯片项目的设计成本约为 $0.6–0.7B；若将软件和系统成本计入、翻倍至约 $1.4B（🔴）[S2500,S2501]。如果自研芯片能节省 B200 每小时约 $1.73 自有成本的约 18%，则每芯片年可节省约 $2,700 [S625,S622]。盈亏平衡点约为 520,000 芯片年，即在四年内每代约 130,000 颗芯片（🔴 本资料库测算，来自 CS3）[S23010]。**结论：** 只有四大超大规模云厂商和两三家前沿实验室能跨过这一门槛。其他所有买家要么购买商用芯片，要么租用他人的 ASIC。

## 差距缩小了多少？

下图比较每个挑战者的最新芯片与同年出货的英伟达旗舰（同年旗舰）在内存带宽和稠密 FP8 算力上的相对水平。带宽对推理最为关键，因为每生成一个 token 都要从高带宽内存（HBM）中重新读取一遍模型权重。

**Rubin reset the gap: 2026 hyperscaler chips have 32–45% of its bandwidth; only AMD is ahead (121%)**

Challenger chip as % of the NVIDIA flagship shipping the same year (100% = parity); left: HBM/DRAM bandwidth per chip; right: dense FP8 per chip; vendor peak figures

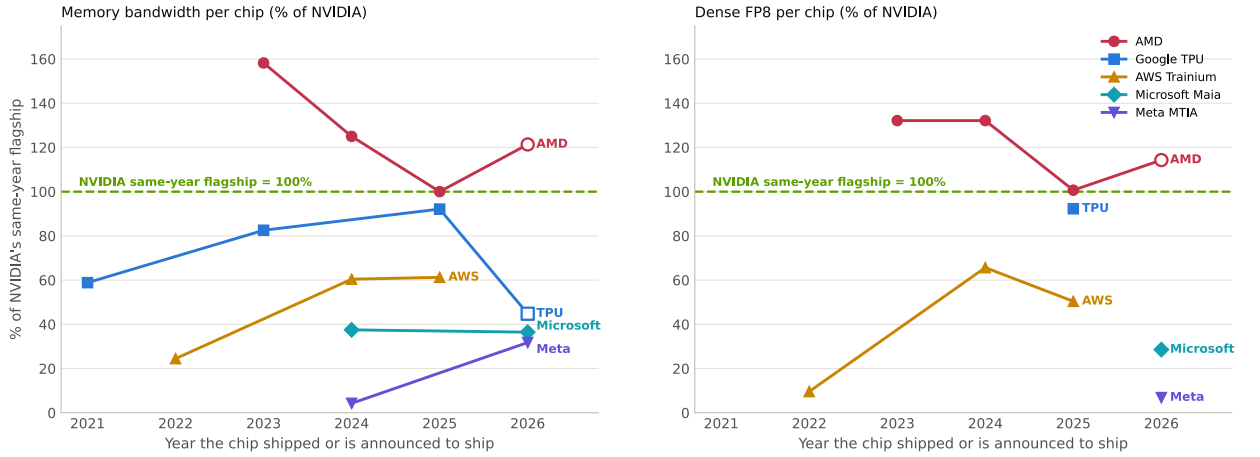


*Repo calculation; hollow markers = announced, not yet shipping*

Source: data from vendor specifications; repo ratios [S141] [S142] [S143] [S144] [S145] [S90093] …; chart by repo · As of 2026-11-05

两个折线面板，显示挑战者芯片相对于英伟达同年旗舰的百分比。内存带宽：AMD 为 158%（MI300X vs H100，2023）、125%、100% 和 121%（MI455X vs Rubin，2026）；谷歌 TPU 从 59%（v4，2021）升至 92%（Ironwood vs GB300，2025），随后降至约 45%（TPU 8i vs Rubin，2026）；AWS Trainium 为 24%、60% 和 61%（2022-2025）；微软 Maia 为 38%（2024）和 36%（2026）；Meta MTIA 为 4%（v2，2024）和 32%（MTIA 300，2026）。稠密 FP8：AMD 为 101-132%；Ironwood 为 92%；Trainium 为 10%、66% 和 50%；Maia 200 为 29%；MTIA 300 为 7%。Rubin 的 HBM4 跃升重新拉开了定制芯片在 2025 年几乎弥合的差距。

| 挑战者 | 2023–24 年位置（占英伟达带宽的 %） | 2025 | 2026 | 方向 |
|---|---|---|---|---|
| AMD Instinct | 158%（MI300X vs H100） | 100%（MI355X vs GB300） | 121%（MI455X vs Rubin） | 🟩 重新领先 |
| 谷歌 TPU | 83%（v5p vs H100） | 92%（Ironwood vs GB300） | 约 45%（TPU 8i vs Rubin） | 🟥 被 HBM4 重新拉开 |
| AWS Trainium | 60%（Trn2 vs H200） | 61%（Trn3 vs GB300） | —（Trn4 尚未定档） | 🟥 落后，保持稳定 |
| 微软 Maia | 38%（Maia 100 vs H200） | — | 36%（Maia 200 vs Rubin） | 🟥 落后，保持稳定 |
| Meta MTIA | 4%（v2 vs H200） | — | 32%（MTIA 300 vs Rubin） | 🟥 从低位快速追赶 |

本资料库根据厂商峰值规格测算 S141,S143,S144,S90093,S151,S154,S155,S157,S158,S15010,S15002,S33005,S90006,S15014。

**提示**

**算例 —— “Rubin 带宽的 45%”在解码（decode）阶段意味着什么。** 对一个 70B 参数的 FP8 模型，每个解码步骤需重新读取约 70 GB 的权重。以 19.2 TB/s 计，一颗 Rubin GPU 每秒可完成约 274 次；以 8.6 TB/s 计，一颗 TPU 8i 约 123 次 S90006,S15010。这意味着在批处理之前，单流速度上限约为 274 对 123 tokens/s。要达到 Rubin 的每秒 token 数，TPU 集群需要约 2.2× 的芯片，因此每 TPU 芯片小时的成本须低于 Rubin 芯片小时的约 45%。SemiAnalysis 估计自有 Ironwood 的芯片小时成本（$1.21）约为 Vera Rubin（$3.61）的 34%（估计）S622；如果 TPU 8i 的成本与 Ironwood 相当，即可跨过这一门槛。**结论：** 成本优势可以在带宽差距下勉强保住；它依靠的是价格，而非芯片本身。

下方散点图加入了所有公开数据加速器的算力与内存容量。Rubin 和 MI455X 独占右上角；已出货的定制 ASIC 大致聚集在 GB300 的水平。

**Rubin and MI455X claim 17.5–20 PFLOPS FP8; shipping custom ASICs sit at 2.5–5**

Dense FP8 PFLOPS (x) vs memory bandwidth TB/s (y) per accelerator; bubble area = memory GB (log–log) LOG SCALE

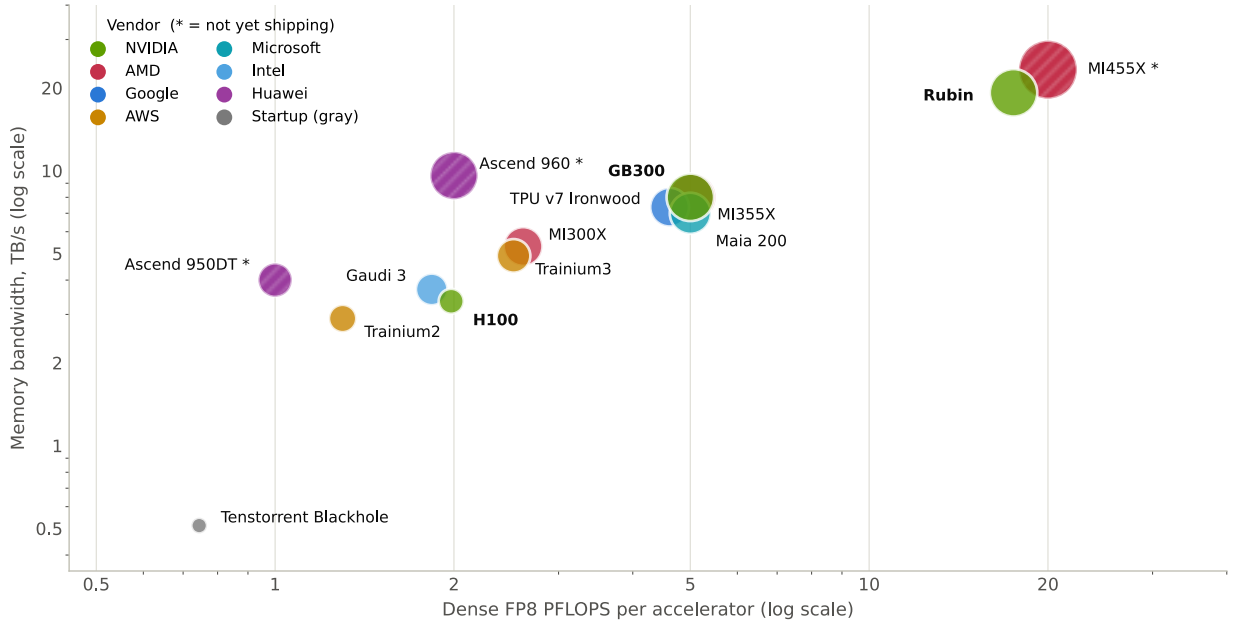


*Hatched = not yet shipping*

Source: data from vendor specs [S33002] [S35011] [S35013] [S32004] [S123] [S100] …; chart by repo · As of 2026-11-05

> AI 加速器的双对数气泡图：英伟达 Rubin（17.5 PFLOPS 稠密 FP8、19.2 TB/s、288 GB）和 AMD 已发布的 MI455X（20 PFLOPS、23.3 TB/s、432 GB）远在右上方；已出货的定制 ASIC——谷歌 Ironwood、AWS Trainium3 和微软 Maia 200——聚集在 2.5-5 PFLOPS 和 4.9-7.4 TB/s，与 GB300 和 MI355X 持平；华为 Ascend 950DT 和英特尔 Gaudi 3 落后。

## MLPerf 证据：独立基准测试显示了什么

MLPerf 是唯一经过审计的跨厂商基准测试。它有两大局限：厂商自行决定是否提交，而超大规模云厂商的 ASIC 大多不提交。谷歌仅在 Inference v5.0 以及 Training v5.0 及之前的轮次中提交过 TPU 结果；Trainium、Maia 和 MTIA 没有封闭组（closed division）结果[S601,S602,S603,S613]。

### On MLPerf Llama 2 70B, AMD's MI355X (12,935 tok/s) matches B200 but trails GB300 by 17%

MLPerf Inference v6.0 (Apr 2026), Llama 2 70B Offline, best closed result per accelerator, tokens/s per accelerator

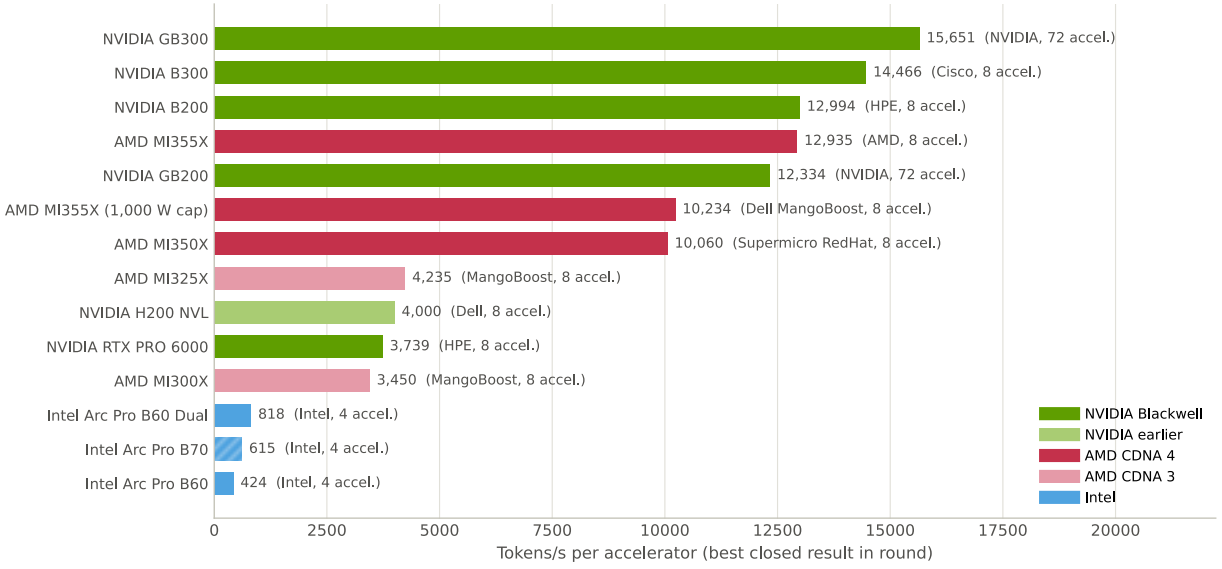


*Hatched = preview category*

Source: data from MLCommons MLPerf Inference v6.0 results (closed division) [S602]; chart by repo · As of 2026-11-05

水平柱状图，展示 MLPerf Inference v6.0 封闭组 Llama 2 70B Offline 场景下各加速器的最佳结果，单位为每加速器 tokens/s：GB300 15,651、B300 14,466、B200 12,994、MI355X 12,935、GB200 12,334、MI350X 10,060、MI325X 4,235、H200 NVL 4,000、MI300X 3,450；英特尔 Arc Pro 显卡低于 1,000。

### MLPerf gpt-oss-120b: MI355X beats B300 per GPU (15,227 vs 14,321 tok/s); GB300 leads

MLPerf Inference v6.1 (Sep 2026), gpt-oss-120b Offline, best closed result per accelerator, tokens/s per accelerator

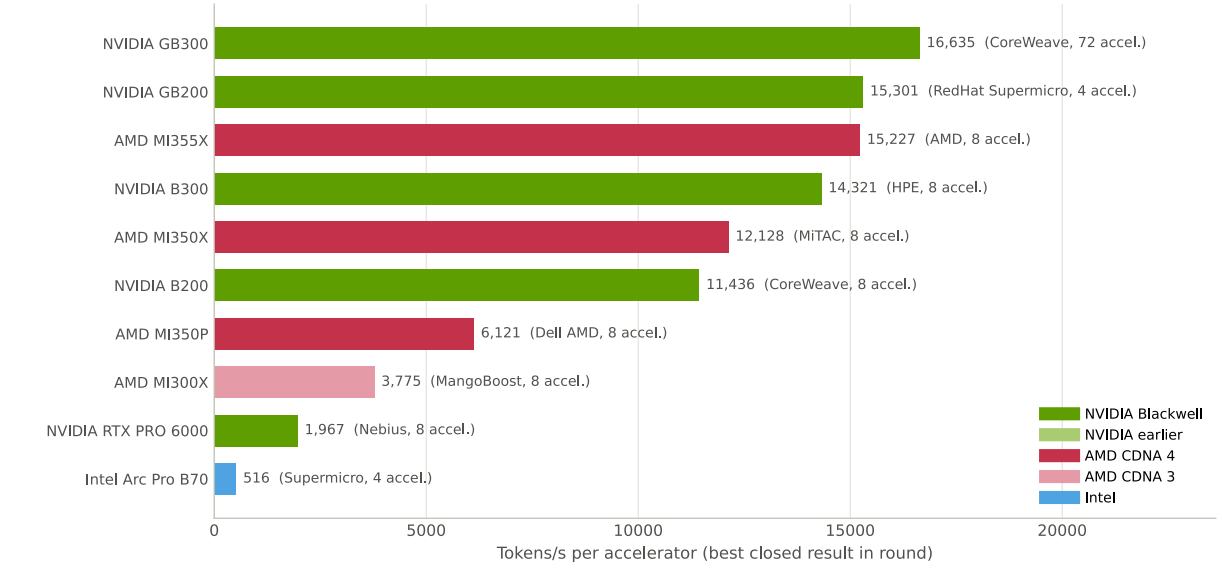


*Hatched = preview category*

Source: data from MLCommons MLPerf Inference v6.1 results (closed division) [S603]; chart by repo · As of 2026-11-05

水平柱状图，展示 MLPerf Inference v6.1 封闭组 gpt-oss-120b Offline 场景下各加速器的最佳结果，单位为每加速器 tokens/s：GB300 16,635、GB200 15,301、MI355X 15,227、B300 14,321、MI350X 12,128、B200 11,436、MI300X 3,775，RTX PRO 6000 和英特尔 Arc Pro B70 远低于此。激活参数较少的 MoE 模型有利于发挥 AMD 的内存带宽优势。

在单节点推理上，AMD 已缩小差距：MI355X 在 Llama 2 70B 上与 B200 持平，并在 gpt-oss-120b 上击败 B300——后者是一个奖励内存带宽的混合专家模型（MoE）[S602,S603]。英伟达的领先在机架规模上重新显现。GB300 NVL72 在两张图中均居首位；在每用户 50 tokens/s 的交互速度下，SemiAnalysis 的 InferenceX 测得 GB300 NVL72 每 GPU 约 6,261 tokens/s，而 MI355X 约为 738 [S621,S622]。

**AMD's share of closed MLPerf inference results rose from 2% to 20% in 18 months; NVIDIA still 67%**

Closed-division performance results by accelerator vendor per round (count); labels = submitting organisations

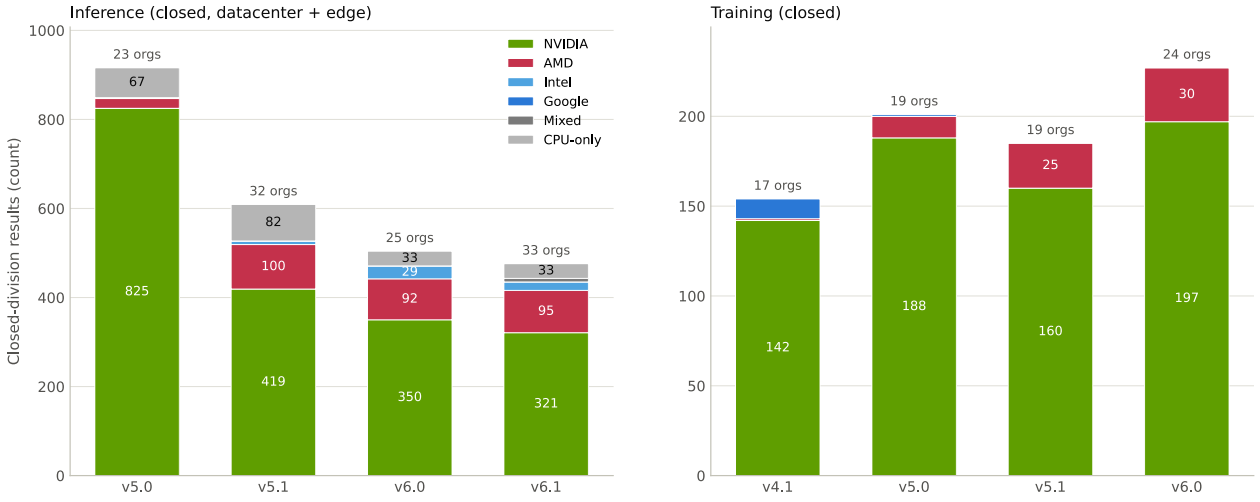


Source: data from MLCommons results repositories (repo count) [S600] [S601] [S602] [S603] [S606] [S607] …; chart by repo · As of 2026-11-05

两个堆叠柱状面板。推理轮次 v5.0 至 v6.1：基于 AMD 的结果占封闭组性能结果的比例从 2% 升至 20%，基于英伟达的结果降至 67%；谷歌仅在 v5.0 提交过 TPU，英特尔新增了 Arc Pro 显卡。训练轮次 v4.1 至 v6.0：英伟达占结果的 87-93%，AMD 从 1 个结果增至 30 个，谷歌 TPU 结果在 v5.0 之后消失。

**提示**

**算例 —— 基于 MLPerf 结果的每美元 token 数。** 在 Llama 2 70B Offline 上，MI355X 为 12,935 tokens/s，GB300 为 15,651 [S602]。按 SemiAnalysis 估计的每 GPU 小时自有成本约 $1.50 和约 $2.31 计算 [S622]，即每美元小时约 8,600 对约 6,800 tokens/s：在该测试中 **AMD 领先约 27%**（估计）。在 DeepSeek-R1 上以每用户 50 tokens/s 测算时排名逆转：6,261 ÷ 2.31 ≈ 2,710 对 738 ÷ 1.50 ≈ 490，**GB300 NVL72 领先约 5.5×** [S621,S622]。**结论：** 哪家厂商“胜出”取决于工作负载的交互速度目标。批处理和离线任务青睐便宜且内存充裕的 GPU；交互式推理则青睐英伟达的机架级 NVLink 域。

训练方面的对比更为悬殊。在 8-GPU 微调上，MI355X（8.3 分钟）介于 B200（7.9）和 GB200（9.6）之间 [S609]。但没有任何非英伟达加速器提交过 Llama 3.1 405B 预训练基准测试，而英伟达系统在该测试上已扩展至 8,192 颗 GPU [S607,S609]。

### MI355X fine-tunes Llama 2 70B on 8 GPUs in 8.3 min, 1.5x GB300's 5.6 min and close to B200

MLPerf Training, Llama 2 70B LoRA, best 8-accelerator closed result per accelerator and round (minutes, lower is better)

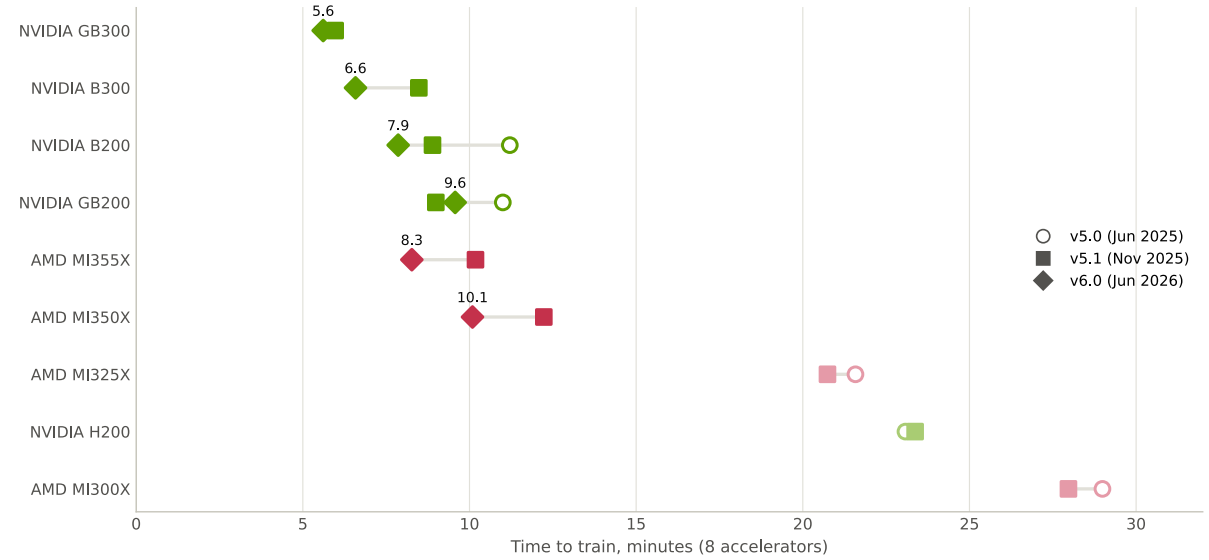


Source: data from MLCommons MLPerf Training v5.0-v6.0 (repo-computed scores) [S607] [S611] [S608] [S609]; chart by repo · As of 2026-11-05

8-GPU MLPerf Training LoRA 微调时间点图。在 v6.0 中：GB300 5.6 分钟、B300 6.6、B200 7.9、MI355X 8.3、GB200 9.6、MI350X 10.1。AMD 的 MI325X 在 2025 年约需 21-22 分钟，MI300X 约需 28-29 分钟；因此 AMD 借助 CDNA 4 弥合了大部分单节点差距，而英伟达在机架规模上的领先依然存在。

### MLPerf Llama 3.1 405B training: 27 min on 2,496 GB200s (2025) → 7 min on 8,192 (2026)

MLPerf Training time-to-train vs cluster size, Llama 3.1 405B, closed division (minutes; both axes log scale) LOG SCALE

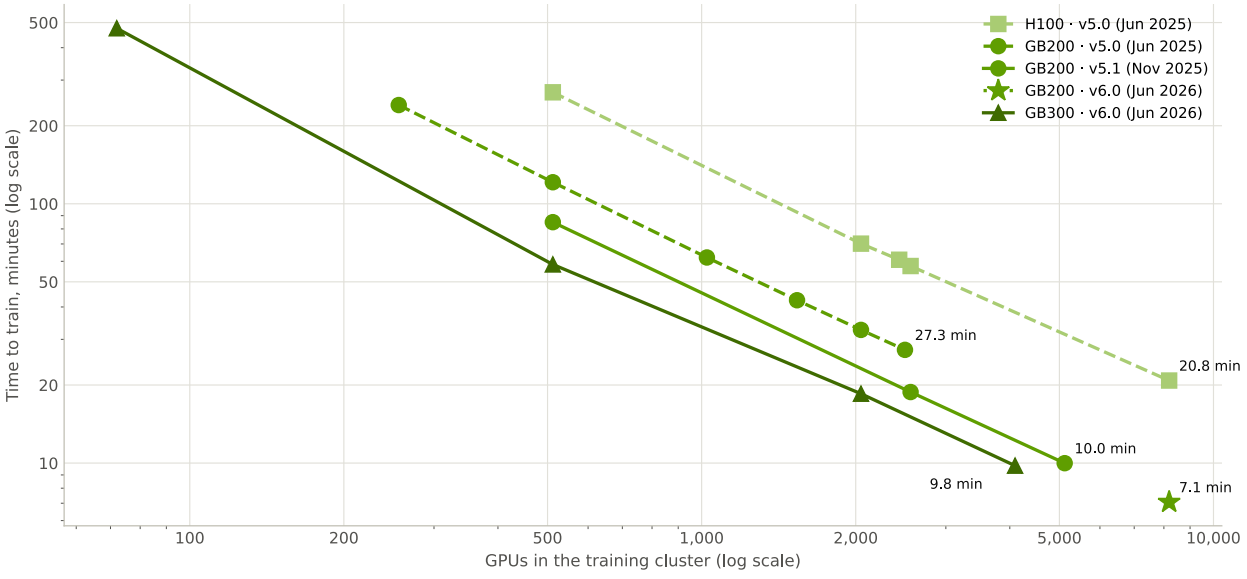


Source: data from MLCommons MLPerf Training v5.0-v6.0 (repo-computed scores) [S607] [S611] [S608] [S609]; chart by repo · As of 2026-11-05

Llama 3.1 405B 的 MLPerf Training 训练时间与 GPU 数量双对数图。在 v5.0（2025 年 6 月）中，2,496 颗 GB200 GPU 用时 27.3 分钟，8,192 颗 H100 用时 20.8 分钟；在 v5.1 中，5,120 颗 GB200 用时 10.0 分钟；在 v6.0 中，8,192 颗 GB200（Azure）用时 7.1 分钟，4,096 颗 GB300 用时 9.8 分钟。没有任何非英伟达加速器提交过该基准测试。

**🔧 技术细节：如何解读 MLPerf 而不被误导**

- **封闭组与开放组。** 封闭组要求使用参考模型并达到精度目标；开放组允许改动（量化、剪枝）。只应比较封闭组结果。
- **Offline 与 Server 场景。** Offline 在所有查询一次性就绪时衡量原始吞吐量；Server 为每个查询增加了延迟约束。交互式产品关心的是后者，而英伟达的机架级优势在此更为突出。

- **按单加速器归一化**掩盖了系统成本：一个 NVL72 机架包含 36 颗 Grace CPU 和 NVLink 交换托盘，而 8-GPU 的 AMD 节点没有这些。
- **缺席本身就是信息。** 自 TPU 在 v5.0 之后退出 MLPerf，买家只能依赖谷歌和分析师提供的数据 S613。

## 十个竞争对手页面

| 页面 | 原型 | 其最有力的论据 | 对英伟达的威胁（🔴 本资料库观点） |
|---|---|---|---|
| AMD | 全栈商用厂商（挑战者） | 规格持平或高于 Rubin、开放机架、14 GW 承诺 S144,S24000,S24004 | 🟥 在前沿实验室处高；其他领域中等 |
| 谷歌 TPU | 超大规模云厂商自研，现已对外销售 | 实测每 token 成本最低；9,216 芯片 pod S625,S151 | 🟥 价格层面高；商用出货量层面低 |
| AWS Trainium | 超大规模云厂商自研 | 超过 $225B 的 Trainium 承诺；以 Anthropic 和 OpenAI 为锚定客户 S15000 | 🟨 中等；受软件制约 |
| 微软 Maia | 超大规模云厂商自研 | Copilot 推理每美元性能提升约 30%（厂商说法） S15007 | 🟨 2027 年起为中等 |
| Meta MTIA | 超大规模云厂商自研 | 两年推出四代；掌控 PyTorch S15003,S9028 | 🟨 低到中等；Meta 同时也是英伟达的头部买家 |
| 定制 ASIC 设计公司 | 设计服务 | 博通单季度 AI 收入 $16.7B S2516 | 🟥 高：它们为每一家超大规模云厂商提供武器 |
| 英特尔 | 商用厂商（重新进入） | x86 在位优势；英伟达自身的 $5B 入股及 NVLink x86 CPU S4009 | 🟩 作为加速器对手威胁低 |
| 高通 | 推理专精厂商 | 每卡 768 GB LPDDR，用于低成本推理（公开信息） S90028 | 🟩 目前低；尚无已确认的 2026 年出货（🔴） |
| 推理初创公司 | 推理专精厂商 | 以 SRAM 和晶圆级设计追求速度；OpenAI–Cerebras 最多 750 MW S11523 | 🟨 小众；英伟达已吸收 Groq 的技术 S90018 |
| 中国 | 国家冠军企业 | 受保护的市场；计划推出 8,192 芯片的 Atlas 950 SuperPoD S90042 | 🟥 在中国高，其他地区低 |

## 总体判断

2026 年 11 月的英伟达**覆盖面广，但在任何单一层级上都已不再无人挑战**。AMD 在纸面上持平或领先（在 HBM 容量和带宽上领先） S144,S90093，在单节点基准测试中也很接近；谷歌 TPU 在已测工作负载上的每 token 成本更低；基于博通的以太网赢得了后端网络之争 S90053。但没有任何对手拥有这样的组合：一款商用产品，在各处销售，每年更新，并为每个新模型提供首日（day-zero）软件支持。正是这一组合使其份额保持在 85–90% 附近，同时价格维持了约 75% 的毛利率 S405。

因此，竞争首先冲击的是**价格**，其次是**在最大买家处的份额**，最后才是出货量。CS3 的测算表明，英伟达可以把每 token 成本降至与 TPU 相当，同时仍保有约 62% 的毛利率（🔴） S23010。与此同时，由新兴云服务商（neocloud）、主权机构和企业组成的长尾客户——在 Q2 FY2027 占数据中心收入的约 45% S406——几乎没有现实的替代方案。

> **提示**
>
> **算例 —— 份额与利润率。** 在约 $436B 的 2026E 市场中，每一个百分点约值 $4.4B S15014。若在约 $371B 的数据中心年度（FY2027E）上同时失去五个百分点的份额*和*五个百分点的毛利率 S403,S405，英伟达将损失约 $22B 的收入，以及剩余收入上约 $17B 的毛利（🔴 本资料库测算）。**结论：** 英伟达所保留的 80% 以上份额所承受的利润率压力，与份额流失同样重要。

> **注**
>
> 🐂 **看多观点。** 三年来对手一直在*规格*上与英伟达看齐，但在市场规模翻两番的同时，其份额仅下降约 3 个百分点 [S15014]。每个挑战者都在软件和机架上落后——这恰恰是最难复制的两项——而英伟达每年都推出新平台（2026 年 Rubin、2027 年 Rubin Ultra、2028 年 Feynman）[S90003,S90004]。超大规模云厂商仍在持续采购：即便在自研 MTIA 的同时，Meta 仍承诺采购“数百万颗” Blackwell 和 Rubin GPU [S4006]。

> **注意**
>
> 🐻 **看空观点。** 四家最大的买家都有自研芯片，其中两家如今还将这些芯片卖给英伟达的其他大客户。据 TrendForce 预测，定制 ASIC 的出货量份额将在 2026 年达到约 28%，到 2030 年约 40% [S2517]。一旦某个模型系列能在 TPU 或 Trainium 上良好运行，下一个模型的迁移成本就会下降。一家商用对手（AMD）已在内存规格上超越 Rubin，其“股权换产能”交易将 14 GW 的前沿需求放到了非英伟达的路线图上 [S24000,S24004,S9538]。

| 值得关注的信号（2027 年） | 利好英伟达的情形 | 利空的情形 |
|---|---|---|
| OpenAI 的首个 AMD 吉瓦（MI450） | 爬坡延迟，或主要用于承接溢出的推理需求 | 前沿模型训练在 Helios 上大规模运行 |
| 谷歌云之外的 TPU 销售 | 仍局限于 Anthropic 和 Meta | 甲骨文等厂商广泛转售 TPU [S552] |
| 超大规模云厂商参与 MLPerf | ASIC 持续缺席 | Trainium 或 Maia 发布经审计的胜出结果 |
| 博通 AI 收入 | 增速放缓至低于英伟达 | 超过英伟达数据中心收入的约 25% |
| 英伟达毛利率 | 维持在约 75% | 在超大规模客户处滑向 60% 出头 |

## 🎯 企业发展视角

1. **份额究竟在向哪里转移？** 收入份额显示英伟达约占 87%；出货量份额显示 ASIC 接近约 28%。挑战者的商业论证应采用哪个指标？对新的商用进入者而言，哪些买家（前沿实验室、超大规模云厂商、主权机构）真正可以争取？
2. **设计服务价值池。** 博通 AI 收入的增速快于英伟达 [S2516]。哪些能力使设计公司不可或缺（SerDes、封装、HBM 供应、机架集成）？新进入者可以通过自建、收购或合作获得其中哪些能力？
3. **软件是共同短板。** 每张雷达图的软件轴都处于落后。高通公开收购 Modular（约 $3.9B，Mojo/MAX），瞄准硬件可移植的 AI 软件 [S90057]。什么证据（首日模型支持、MLPerf 提交）能表明此类软件栈正在为任一挑战者缩小差距？
4. **推理是各类原型的交汇点。** TPU、Trainium、Maia 和 MTIA 如今都以推理为优先，初创公司以及高通公开的 AI200/AI250 计划亦然 [S90028]。一旦超大规模云厂商将自研 ASIC 出租给外部客户，商用推理专精厂商还有生存空间吗？
5. **与英伟达合作还是竞争。** AWS 在 Trainium4 上采用了 NVLink Fusion；英特尔在打造 NVLink x86 CPU [S90034,S4009]。何时接入英伟达的互连架构比与之对抗更划算？

# AMD —— 商用挑战者

跨层专题 15 · 竞争格局 · AMD Instinct、ROCm、Helios · 约 16 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **纸面上 AMD 已经追平。** 自 MI300X 以来，每款 Instinct GPU 在 HBM 容量和稠密 FP8 上都持平或超过英伟达（NVIDIA）的同年旗舰（本资料库对比）[S15014]。MI455X 标称 432 GB HBM4、23.3 TB/s 带宽和 20 PFLOPS FP8（口径未说明），而 Rubin 为 288 GB、19.2 TB/s 和 17.5 PFLOPS [S144,S90093,S33005,S90006]。
- **AMD 如今卖的是机架，而不只是 GPU。** Helios 将 72 颗 MI455X 与 EPYC “Venice” CPU 和 Pensando 网卡整合在一起：2.9 EF FP4、1.4 EF FP8 和 31 TB HBM4。它已投入生产，首批出货约从 2026 年 Q3 末开始（🟢/🟡）[S90021,S90020]。其设计团队来自 ZT Systems（$4.9B，2025 年 3 月完成交割）[S8527]。
- **前沿买家承诺了最多 14 GW。** OpenAI（6 GW）和 Meta（6 GW）的部分对价以 AMD 认股权证支付；Anthropic 追加了最多 2 GW [S24000,S24004,S9538]。按每 GW $10–20B 的硬件计算，未来数年合计约 $140–280B（估计）[S15014]。
- **收入增长迅速，但差距反而更大。** 数据中心收入在 2026 年 Q2 同比增长 107%，Q3 同比增长 97% [S543,S542]。然而，英伟达的数据中心收入从 2023 年初为 AMD 的 3.3× 扩大到 2026 年年中的约 13×（本资料库测算）[S450,S405]。
- **软件是关键约束。** ROCm 从 7.0（2025 年 9 月）升级到 10.0（2026 年 8 月）[S586]。即便如此，DeepSeek-V4-Pro 在 MI355X 上用了 27 天才能有效提供服务，而在 CUDA 上首日即可 [S633]。
- **最大弱点：** 缺乏机架级的实战记录。英伟达已推出第三代 NVL72；Helios 是 AMD 的第一代产品，有分析师预计 MI455X 机架要到 2027 年 Q2 才会产出首批生产级 token（🟡）[S624]。

**On paper every Instinct since MI300X matched or beat NVIDIA's same-year flagship: 432 vs 288 GB in 2026**

Per GPU: dense FP8 PFLOPS, HBM capacity (GB) and HBM bandwidth (TB/s); AMD vs the NVIDIA flagship shipping that year; MI455X announced, FP8 basis unstated

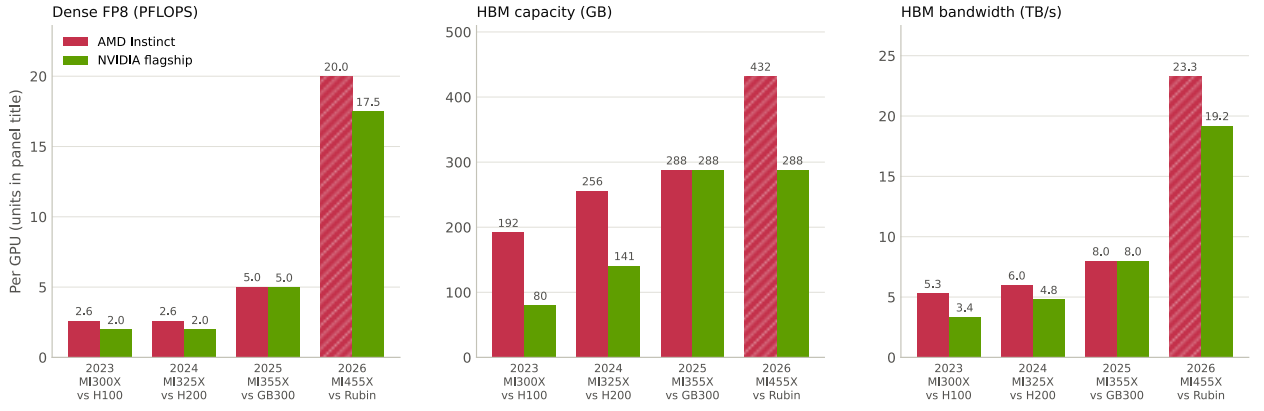


*Hatched = announced, not yet shipping in volume*

Source: data from AMD and NVIDIA specifications [S141] [S142] [S143] [S144] [S145] [S90093] ...; chart by repo · As of 2026-11-05

三个分组柱状面板，将 AMD Instinct GPU 与英伟达同年旗舰对比。稠密 FP8：MI300X 2.6 vs H100 2.0 PFLOPS（2023），MI325X 2.6 vs H200 2.0（2024），MI355X 5.0 vs GB300 5.0（2025），MI455X 20 vs Rubin 17.5（2026，AMD 口径未说明）。HBM 容量：192 vs 80 GB、256 vs 141、288 vs 288 和 432 vs 288。HBM 带宽：5.3 vs 3.35 TB/s、6.0 vs 4.8、8.0 vs 8.0，以及英伟达 2026 年 Rubin 规格修订后的 23.3 vs 19.2。因此，AMD 与英伟达的差距不在规格表上，而在软件、机架和收入上。

## Instinct 路线图：MI300X → MI355X → MI450 → MI500

AMD 的数据中心 GPU 采用 CDNA 架构和小芯片（chiplet）设计。计算裸片（XCD）堆叠在 I/O 裸片之上，因此 AMD 可以混用不同的制程节点和分档。MI355X 采用台积电（TSMC）N3P 计算裸片和 N6 I/O 裸片 [S2020]。其迭代节奏现已变为一年一代 [S545]，最近三款 Instinct 旗舰均与英伟达旗舰在同一季度推出（见下图）[S142,S143,S539]。

| GPU | 发布时间 | HBM | 带宽 | 稠密 FP8 | 稠密 FP4 | 纵向扩展 | 状态 | 来源 |
|---|---|---|---|---|---|---|---|---|
| MI300X | 2023 年 12 月 | 192 GB HBM3 | 5.3 TB/s | 2.6 PF | — | 8 颗 GPU，Infinity Fabric | 🟢 已出货 | S141 |
| MI325X | 2024 年 10 月 | 256 GB HBM3E | 6.0 TB/s | 2.6 PF | — | 8 颗 GPU | 🟢 已出货 | S142 |
| MI355X | 2025 年 6 月 | 288 GB HBM3E | 8.0 TB/s | 5.0 PF | 10.1 PF | 8 颗 GPU，1,075 GB/s | 🟢 已出货 | S143,S229 |
| MI455X（MI450 系列） | 2026 年 7 月 | 432 GB HBM4 | 23.3 TB/s | 20 PF（口径未说明） | 40 PF | 72 颗 GPU，每颗 3.6 TB/s | 🟢 已量产 | S144,S90093,S538,S5522 |
| MI500（CDNA 6） | 2027 | HBM4E（有报道） | n/a | n/a | n/a | Helios 500 机架 | 🟢 已发布 | S541,S538 |
| MI600 | 2028 | n/a | n/a | n/a | n/a | Helios 600 机架 | 🟢 已发布 | S538 |

MI450 系列包括 MI455X（Helios）、MI440X（8-GPU 服务器）和 MI430X（FP64 高性能计算）[S544]。Meta 的首个吉瓦采用一款基于 MI450 的定制部件 [S24004]。AMD 宣称 MI500 的 AI 性能最高可达 MI300X 的 1,000× [S544]，这是一项混合了精度与系统层面增益的厂商说法。

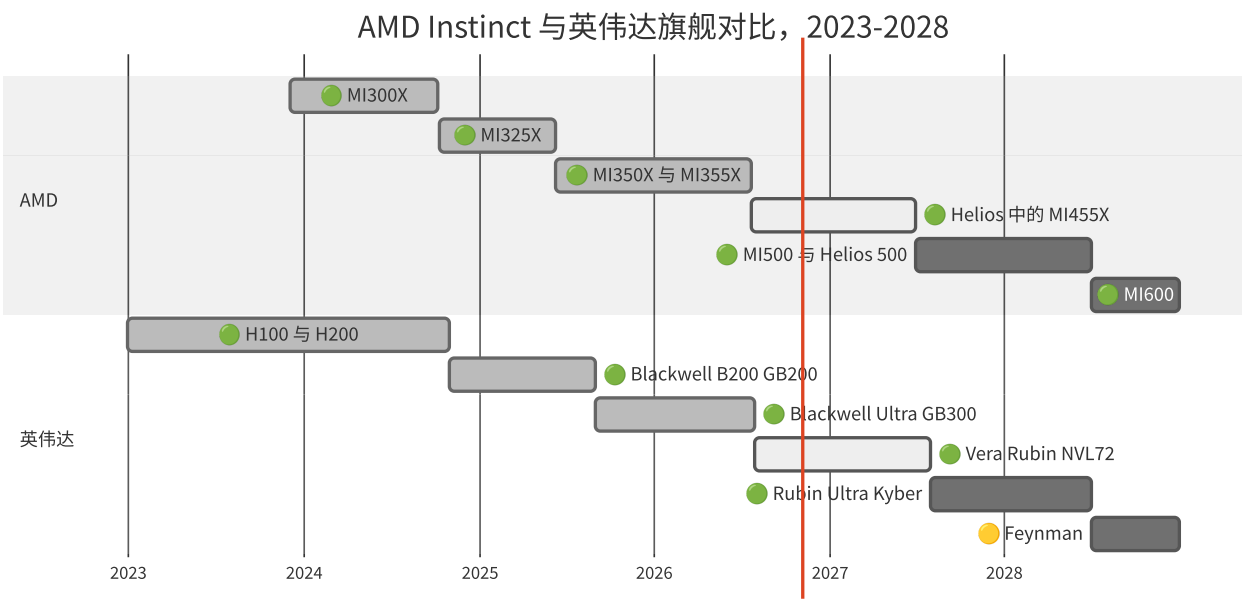


来源：AMD 产品发布 [S141,S142,S143,S538,S541]；英伟达平台 [S90009,S90003,S90004]。条形表示各部件作为当期旗舰的时间段，而非出货量。

**NVIDIA and AMD launched flagships in the same quarter 3 years running**

Start of availability window for each vendor's flagship AI accelerator; both publish annual roadmaps to 2028

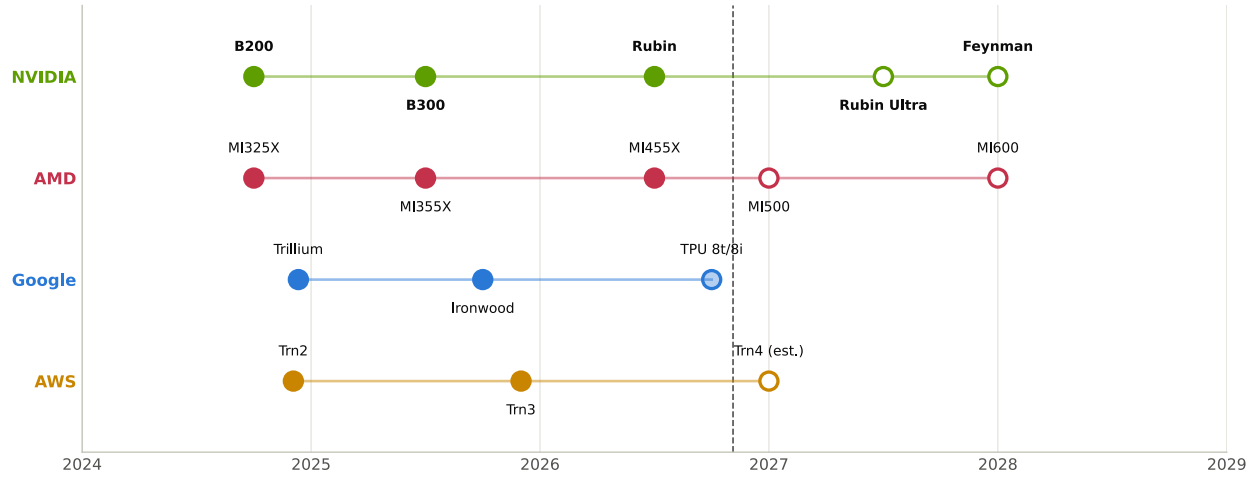


*Hollow = roadmap · pale = not yet GA*

Source: data from Company announcements [S35014] [S121] [S32004] [S123] [S33020] [S554] ...; chart by repo · As of 2026-11-05

旗舰加速器时间线：英伟达 B200（2024 年 Q4）、B300（2025 年 Q3）、Rubin（2026 年 Q3）、Rubin Ultra（2027 年下半年）、Feynman（2028）；AMD MI325X、MI355X 和 MI455X 均在同一季度推出（三年中三年如此），并计划推出 MI500（2027）和 MI600（2028）；谷歌 Trillium、Ironwood 和 TPU 8t/8i 均在每年 12 月至 Q4 推出；AWS Trn2 和 Trn3 均在 12 月推出，Trn4 估计在 2027 年。

**提示**

**算例 —— 432 GB 能带来什么。** 一个 4050 亿参数的 FP8 模型仅权重就需要约 405 GB。一颗 MI455X（432 GB）即可容纳，并为 KV 缓存留出约 27 GB [S144]。在 Rubin（288 GB）上，同一模型需要两颗 GPU（576 GB），可为 KV 缓存留出约 171 GB [S33005]。按单 GPU 计，AMD 可容纳约 1 个模型副本，英伟达约 0.5 个，但英伟达这一对 GPU 可用于并发用户的空余内存约为前者的 6×。**结论：** 容量优势让 AMD 能用更少的 GPU 服务大模型，这在 8-GPU 服务器中是实实在在的优势。而在 72-GPU 的 NVLink 域内，将模型拆分到多颗 GPU 上的代价很低，这一优势随之缩小。

**🔧 技术细节：为什么 MI455X 的“口径未说明”很重要**

AMD 通常将稀疏算力单列为 2× 的一行；上文的 MI355X 数据为稠密值 [S143]。对于 MI455X，AMD 2025 年 6 月公布的数据（40 PFLOPS FP4、20 PFLOPS FP8）并未说明是稠密还是稀疏 [S144]。Rubin 的 17.5 PFLOPS FP8 为稠密值，其 50 PFLOPS NVFP4 “推理”数据依赖自适应压缩 [S100]。如果 AMD 的数据是稀疏值，MI455X 的稠密 FP8 将只有 Rubin 的一半左右；内存数据则毫无歧义。AMD 在一份不具约束力的谅解备忘录（MOU）下，指定三星为 MI455X 的主要 HBM4 供应商 [S3511]。

## ROCm：逐个模型缩小软件差距

ROCm 是 AMD 对标 CUDA 的方案：包括编译器、HIP 编程接口、数学库、RCCL 集合通信库以及框架插件。它比 CUDA 晚九年起步。此后，每个里程碑的发布滞后大约缩短了十倍：平台 1.0 滞后约 8.8 年，FP4 支持滞后约 8 个月，可用的 DeepSeek-V4-Pro 服务滞后约 26 天 [S586,S90064,S633]。

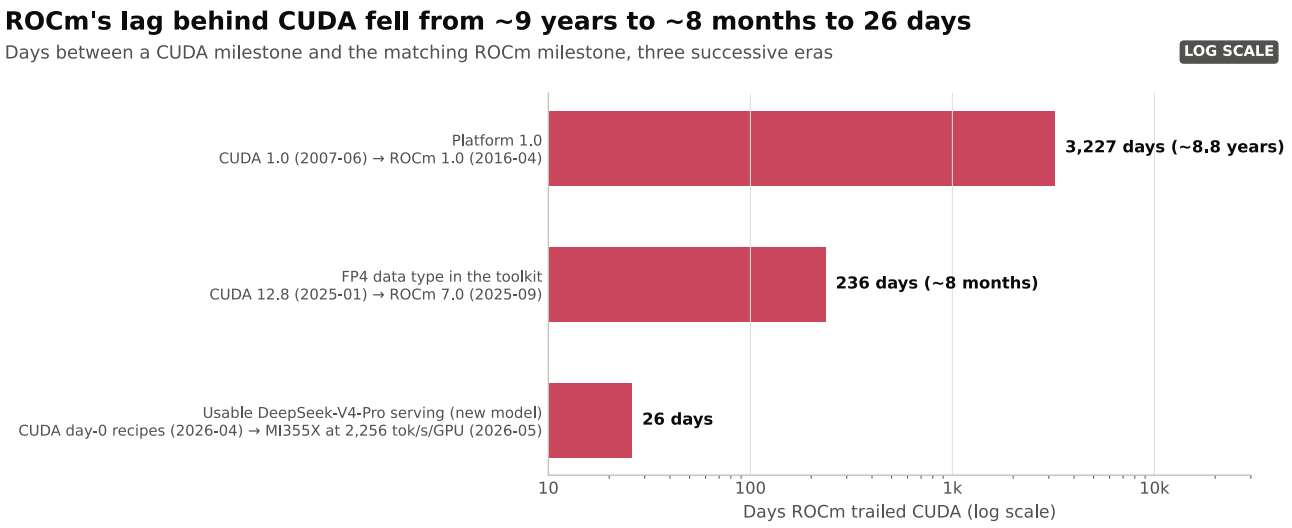


Source: data from CUDA/ROCm release histories; SemiAnalysis InferenceX [S525] [S586] [S524] [S90064] [S633] [S631]; chart by repo · As of 2026-11-05

> 水平对数刻度柱状图，显示 AMD ROCm 落后英伟达 CUDA 的程度：平台 1.0 晚了 3,227 天（约 8.8 年）（2007 年 6 月 vs 2016 年 4 月）；FP4 支持晚了 236 天（约 8 个月）（2025 年 1 月的 CUDA 12.8 vs 2025 年 9 月的 ROCm 7.0）；DeepSeek-V4-Pro 的可用服务比 CUDA 的首日方案晚了 26 天（2026 年 4 月至 5 月）。每次差距大约都比上一次缩短十倍，但每个新模型都会再次出现差距。

剩余差距在于覆盖广度和首日支持。在本资料库的框架指数中，ROCm 得分 26/36（CUDA：36）[S586,S580]。AMD 的 AITER 算子库现已成为 AMD 平台上 vLLM 的默认注意力后端 [S10514]。ROCm.ai（2026 年 7 月）新增了一个 AI 助手，用于安装、调优和调试工作负载 [S9518]。Anthropic 2026 年的交易包括使用 Claude 加速 ROCm 开发 [S9538]。

> **提示**
>
> **算例 —— 27 天的代价。** 在 DeepSeek-V4-Pro 发布后的第 27 天，B200 的单 GPU token 产出仍约为 MI355X 的 5× [S631]。SemiAnalysis 估计自有成本为每 B200 小时约 $1.73、每 MI355X 小时约 $1.50 [S622]。因此当天 MI355X 的每 token 成本为 (1.50 ÷ 1) ÷ (1.73 ÷ 5) ≈ **B200 的 4.3×**。随后的内核优化在几周内将 MI355X 的每 token 成本降低了约 33× [S631]。**结论：** AMD 硬件一旦调优到位就具备成本竞争力。但每个新模型发布后的数周内，买家都要支付“软件税”，因此 AMD 更适合稳定、大规模的工作负载，而非最新的前沿模型。

## Helios 与 ZT Systems：AMD 的第一款机架

客户如今购买的是机架。英伟达的 NVL72 证明，在混合专家模型（MoE）推理中，72 颗 GPU 共享一个内存语义互连架构，胜过 8-GPU 服务器。Helios 是一款双宽 Open Rack 设计，通过基于博通（Broadcom）Tomahawk 6 的交换托盘，以 UALink over Ethernet 连接 72 颗 MI455X GPU [S226,S5522]。

| 机架（2026） | AMD Helios | 英伟达 Vera Rubin NVL72 | 对 AMD 的判定 |
|---|---|---|---|
| 每个纵向扩展域的 GPU 数 | 72 颗 MI455X | 72 颗 Rubin | 🟨 规模相同 [S344,S102] |
| HBM4 容量 | 约 31 TB | 20.7 TB | 🟩 约 1.5× [S90021,S102] |
| HBM 带宽 | 约 1,678 TB/s | 1,400 TB/s（修订后） | 🟩 约 1.2×；也高于 1,580 的发布规格 [S90093,S90006] |
| 稠密 FP8 | 1.4 EF | 约 1.26 EF | 🟩 纸面领先 [S90021,S33005] |
| 每 GPU 纵向扩展带宽 | 3.6 TB/s（开放的 UALink-over-Ethernet） | 3.0 TB/s NVLink 6（修订后） | 🟦 开放 vs 专有 [S5522,S90007] |
| 每 GPU 横向扩展带宽 | 2.4 Tb/s（Pensando Vulcano） | 1.6 Tb/s（ConnectX-9） | 🟩 [S228,S7500,S33004] |

| 机架（2026） | AMD Helios | 英伟达 Vera Rubin NVL72 | 对 AMD 的判定 |
|---|---|---|---|
| 实战记录 | 第一代 | 第三代 NVL72 | S8527,S5501 |

**Helios leads Vera Rubin NVL72 on rack HBM bandwidth (1,678 vs 1,400 TB/s, ~1.2x) and capacity (1.5x)**

HBM bandwidth (TB/s) and capacity (TB) per rack-scale system; outline = Vera Rubin launch target (CES 2026)

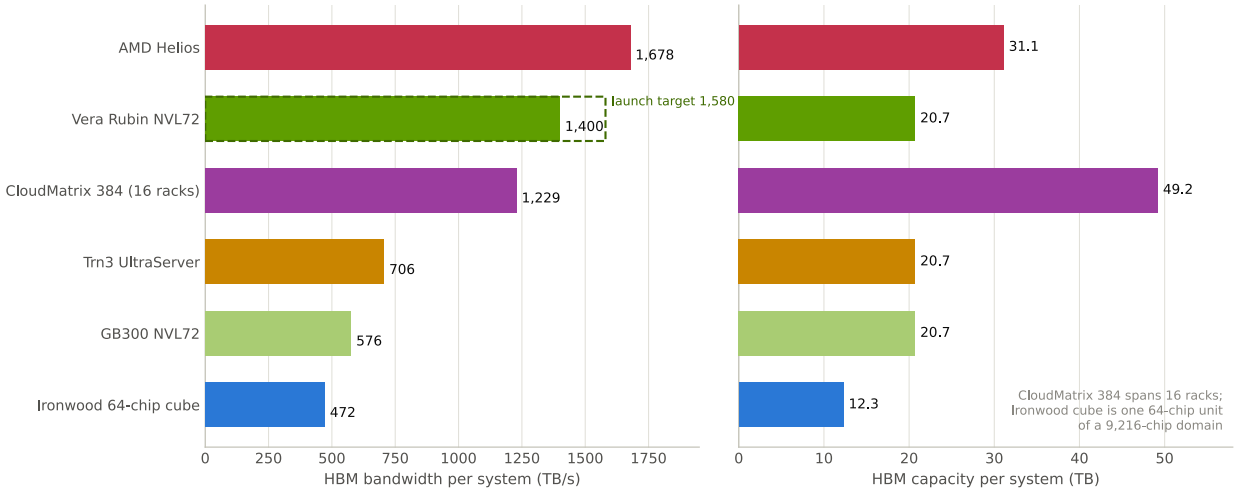


Source: data from vendor specifications; per-chip x count where marked (repo calc) [S32004] [S123] [S102] [S33006] [S90006] [S104] ...; chart by repo · As of 2026-11-05

> 两张水平柱状图，展示各机架级系统的 HBM。带宽：AMD Helios 1,678 TB/s（72 x 23.3 TB/s），2026 年 9-10 月修订后的 Vera Rubin NVL72 为 1,400 TB/s（发布目标为 1,580），华为 CloudMatrix 384 跨 16 个机架约 1,229 TB/s，AWS Trn3 UltraServer 706，GB300 NVL72 576，谷歌 Ironwood 64 芯片立方体 472 TB/s。容量：CloudMatrix 49.2 TB，Helios 31.1 TB，Vera Rubin、Trn3 和 GB300 各 20.7 TB，Ironwood 立方体 12.3 TB。

ZT Systems 提供了机架设计能力。AMD 支付 $4.9B，于 2025-03-31 完成交割，并保留了设计和客户赋能团队 [S8527]。随后它以 $2.25B 现金加 $0.3B 溢价及最多 $0.45B 的或有对价（earn-out），将工厂出售给 Sanmina [S5527,S5528]。

**AMD's net cost for ZT's rack-design teams: ~$1.9–2.35B after selling the factories**

US$ billions; AMD's $4.9B ZT Systems purchase less Sanmina's payment for the ZT manufacturing business (closed 2025-10-27)

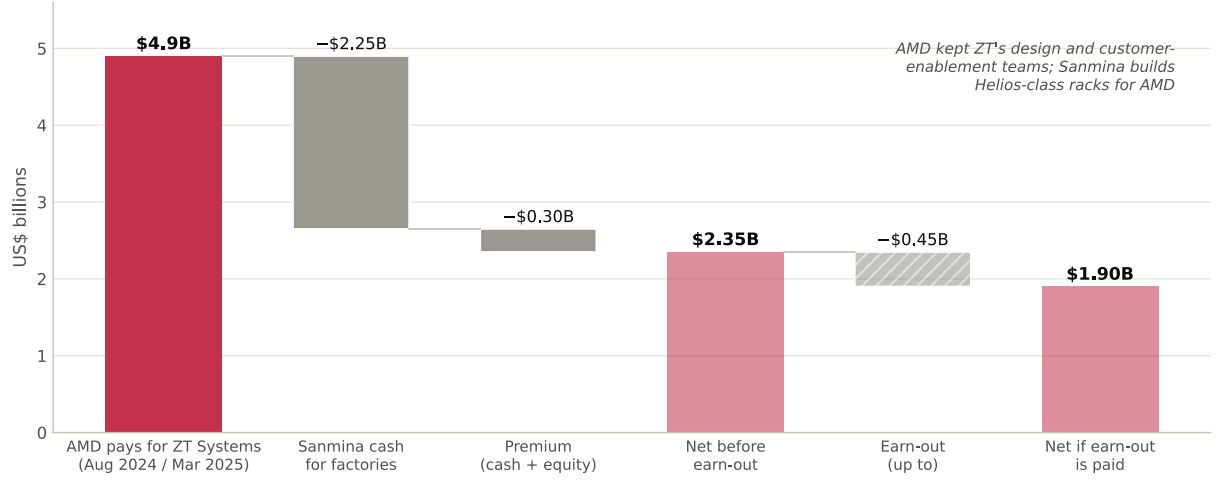


Source: data from AMD, Sanmina and Evertiq [S5527] [S8527] [S5528]; chart by repo · As of 2026-11-05

> 瀑布图：AMD 为 ZT Systems 支付 $4.9B（2024 年 8 月宣布，2025 年 3 月完成交割），随后以 $2.25B 现金加 $0.30B 溢价及最多 $0.45B 的或有对价，将 ZT 的制造业务出售给 Sanmina。AMD 获得设计和客户赋能团队的净成本约为 $2.35B，若或有对价兑付则为 $1.9B——这就是一个经过验证的机架级设计组织的市场价格。

> **提示**
>
> **算例 —— AMD 为机架技术诀窍付出了多少。** 净成本 = $4.9B − $2.25B − $0.3B = **$2.35B**；若或有对价全额支付，则为 $1.9B [S5527]。这约为 AMD 约 $34B 年化数据中心收入（2026 年 Q3，估计）的 7% [S15014]。它支撑了最多 14 GW 的承诺，未来数年价值约 $140–280B（估计）[S15014]。**结论：** 对挑战者而言，一支经过验证的机架集成团队的价值远超其资产价值——英伟达收购 Mellanox 时就确立了这一模式（CS1）。

时间进度仍是悬而未决的问题。AMD 表示 Helios 已投入生产，约从 2026 年 Q3 末开始出货，OpenAI 的大规模部署自 2026 年 Q4 开始 [S90020,S90021]。AMD 否认了 2026 年 2 月关于 MI455X 延期的报道 [S2521,S2524]。SemiAnalysis 预计首批生产级 token 要到 2027 年 Q2 才会出现（🟡）[S624]。本资料库将 Helios 的规模化出货视为 2027 年的事件。

## OpenAI 与 Meta 的认股权证交易

AMD 的商业突破来自一种股权换产能结构。OpenAI 承诺自 2026 年下半年起部署最多 6 GW 的 Instinct GPU，并获得以每股 $0.01 认购最多 160M 股 AMD 股票的认股权证，其归属与部署进度及股价门槛挂钩，据报道最高门槛为 $600 [S24000,S13507]。Meta 于 2026 年 2 月以相同结构签署了另外 6 GW [S24004]。两份认股权证合计覆盖 320M 股，约为交易前股本的 20% [S24003]。AMD 股价于 2026-09-21 首次收于 $600 上方 [S24005]。完整分析见 CS4 · AMD、OpenAI 与第二供应商。

| 客户（日期） | 算力规模 | 对价 | 状态 | 来源 |
|---|---|---|---|---|
| OpenAI（2025-10-06） | 最多 6 GW，自 2026 年下半年起采用 MI450 | 认股权证，160M 股 | 🟢 自 2026 年 Q4 起爬坡 | S24000,S90021 |
| 甲骨文（Oracle）（2025-10） | 50,000 颗 MI450 | 采购 | 🟢 自 2026 年起 | S90022 |
| Meta（2026-02-24） | 最多 6 GW，首批为定制 MI450 | 认股权证，160M 股 | 🟢 首个 GW 在 2026 年下半年 | S24004 |
| Anthropic（2026） | 最多 2 GW 的 Helios | AMD 投资最多 $5B | 🟡 有报道 | S9538,S538 |
| 微软（Microsoft）Azure | 首个大型 Helios 部署 | — | 🟡 有报道 | S90024 |

### Est.: AMD's 14 GW of commitments imply ~$140–280B of hardware, 4–8× its ~$34B DC run-rate

Left: committed GW by customer (maximums). Right: implied hardware value at $10/15/20B per GW (repo scenarios) vs AMD Data Center segment, Q3 2026 annualized (incl. EPYC)

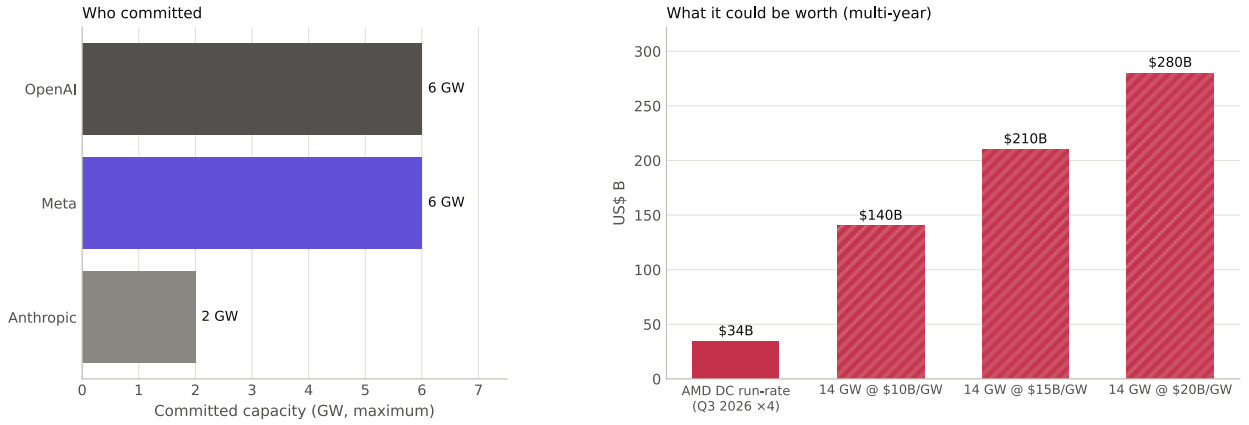


*All values Est. or maximums; hatched = scenario*

Source: data from AMD and customer announcements; repo scenarios [S24000] [S24004] [S538] [S9538] [S24010] [S24006] ...; chart by repo · As of 2026-11-05

两个面板。左：AMD 已公布的吉瓦级承诺为 OpenAI 6 GW（2025 年 10 月）、Meta 6 GW（2026 年 2 月）和 Anthropic 最多 2 GW（2026），合计 14 GW，均为与部署挂钩的上限。右：在本资料库每 GW 对应 $10B、$15B 或 $20B AMD 硬件的情景下，14 GW 意味着未来数年约 $140B、$210B 或 $280B 的收入，而 AMD 数据中心分部的年化收入约为 $34B（2026 年 Q3 年化，含服务器 CPU）：约相当于当前业务规模的 4 到 8 年。

**提示**

**算例 —— 每吉瓦的厂商资本投入。** 在 $600 的股价门槛下，OpenAI 完全归属的认股权证价值为 160M × $600 = $96B，即每承诺 GW 约 $16B。英伟达的可比承诺约为每 GW $10B（向 OpenAI 承诺 10 GW 最多 $100B，后被约 $30B 的股权投资取代；向 Anthropic 承诺 1 GW 最多 $10B）[S24005,S90015,S90075]。**结论：** 纸面上 AMD 的出价高于英伟达，但用的是自家股票，且只有在部署和股价双双兑现时才成立；成本以股权稀释的形式落在 AMD 现有股东身上。

### AMD's warrant may give OpenAI ~$16B/GW (at $600/share) vs NVIDIA's ~$10B/GW pledges

Vendor capital offered per gigawatt of committed compute, US$ B per GW (equity, or warrant value at a given AMD share price)

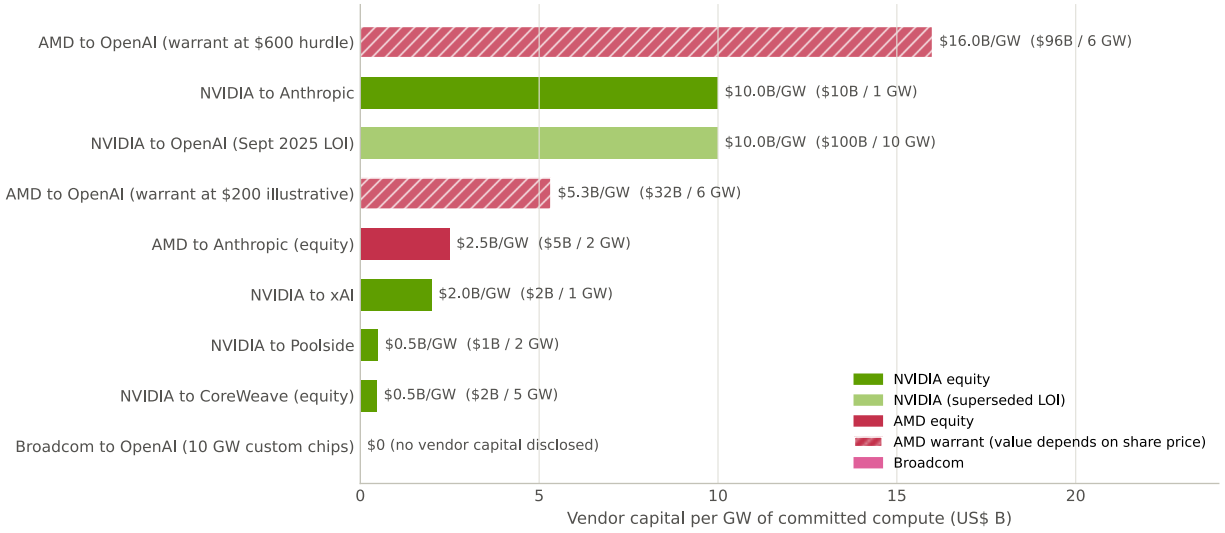


*Hatched = repo calculation*

Source: data from company announcements, press; repo arithmetic [S467] [S90016] [S90015] [S13526] [S469] [S90075] ...; chart by repo · As of 2026-11-05

水平柱状图，展示客户每承诺一吉瓦算力所对应的厂商资本投入：若 AMD 股价达到据报道的 $600 门槛，其 160M 股认股权证对 OpenAI 而言约值每 GW $16B，按 $200 的示意股价则约为每 GW $5.3B；英伟达对 Anthropic（最多 $10B，1 GW）以及对 OpenAI 已被取代的意向书（$100B，10 GW）的承诺均约为每 GW $10B；AMD 对 Anthropic 最多 $5B 的入股约为每 GW $2.5B（2 GW）；英伟达对 xAI 的入股约为每 GW $2B，对 Poolside 约 $0.5B，对 CoreWeave 约 $0.47B；博通 10 GW 的 OpenAI 项目没有披露厂商资本投入。英伟达 2026 年对 OpenAI 的 $30B 股权投资未与 GW 挂钩。

## 财务：增长迅速，但美元差距进一步拉大

AMD 数据中心分部（包括 EPYC CPU 和 Pensando 网卡）的收入从 2023 年的 $6.5B 增至 2024 年的 $12.6B 和 2025 年的约 $16.7B [S450]。2026 年，Q1 为 $5.8B（+57%），Q2 为 $6.7B（+107%），Q3 增长 97%（约 $8.55B，本资料库根据增速估算）[S24009,S543,S542]。AMD 不披露 Instinct 收入；它曾表示 2024 年数据中心 GPU 收入超过 $5B [S663]。

**AMD's data-center revenue rose ~6.6× since 2023, but NVIDIA's lead widened from 3.3× to 13×**

Quarterly data-center revenue (US$ B) and NVIDIA ÷ AMD; AMD's segment includes EPYC CPUs; calendar quarters

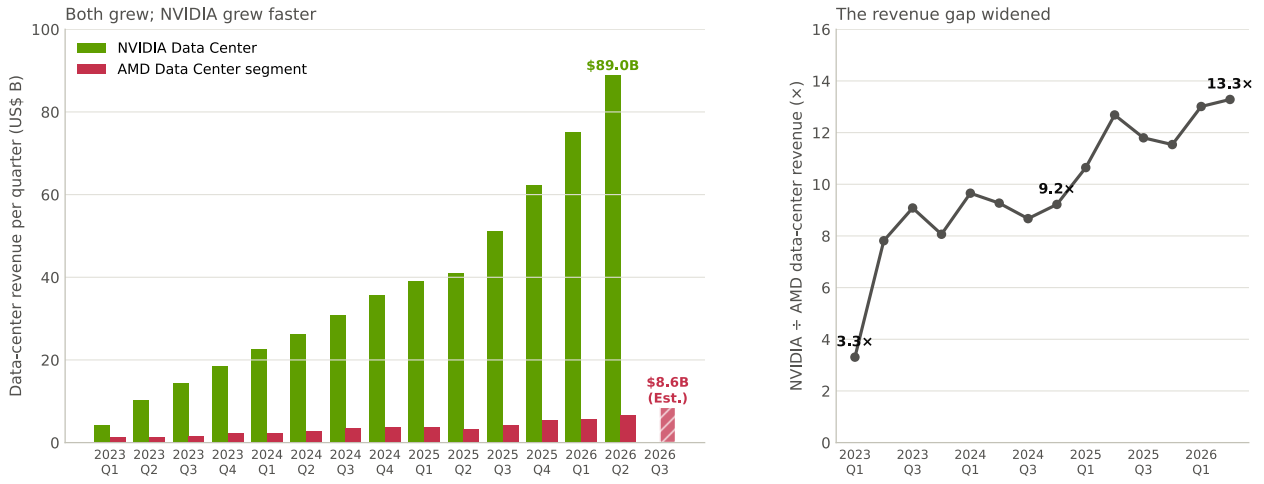


*Hatched = repo estimate*

Source: data from AMD and NVIDIA quarterly results [S1] [S24009] [S402] [S403] [S405] [S412] ...; chart by repo · As of 2026-11-05

双面板图，时间跨度为自然年 2023-Q1 至 2026-Q3。左：AMD 数据中心分部季度收入从 $1.3B 增至 $8.6B（2026-Q3 为本资料库根据 AMD 同比 +97% 估算），约增长 6.6 倍；同期英伟达数据中心收入从 $4.3B 增至 $89.0B（2026-Q2）。右：英伟达数据中心收入在 2023-Q1 为 AMD 的 3.3 倍，2024-Q4 为 9.2 倍，2026-Q2 为 13.3 倍：第二供应商尚未缩小收入差距。AMD 的数据包含 EPYC 服务器 CPU，因此仅就 GPU 而言差距更大。

**NVIDIA's data-center revenue ($194B) is ~12× AMD's and ~10× Broadcom's AI revenue**

Data-center / AI revenue, US$ B per year (NVIDIA and Marvell FY mapped to prior calendar year; Intel scope changed 2024)

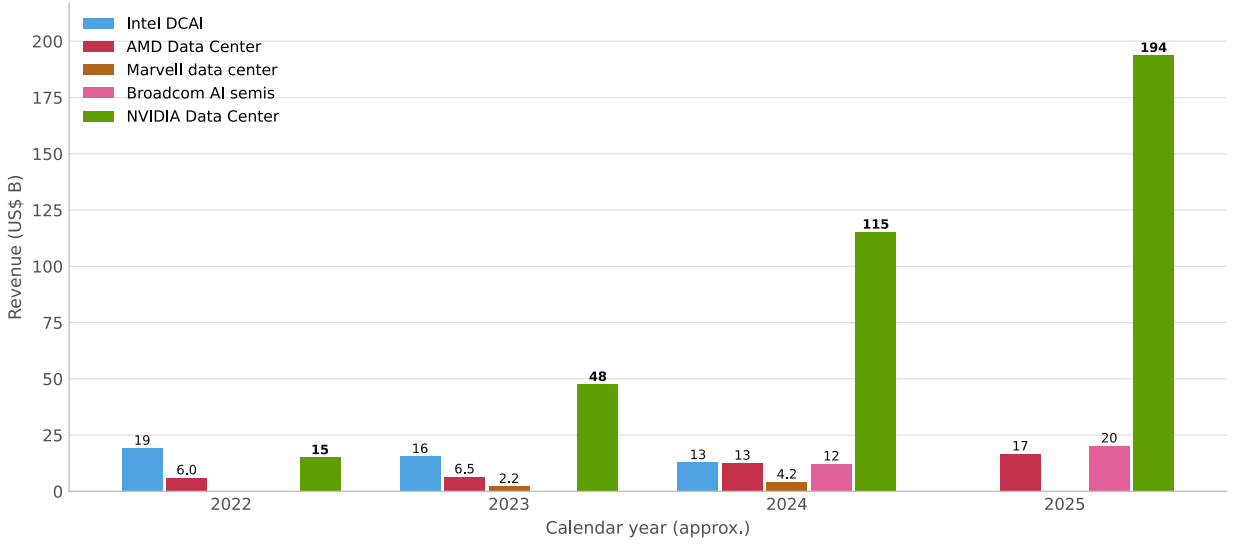


*Intel DCAI = mostly Xeon CPUs*

Source: data from company filings [S418] [S2] [S417] [S90090] [S416] [S1] ...; chart by repo · As of 2026-11-05

2022–2025 年数据中心收入分组柱状图：英伟达从 $15B 增至 $194B；AMD 数据中心从 $6.0B 增至 $16.7B；博通 AI 半导体达到 $20.2B；英特尔 DCAI 从 $19.2B 降至 $12.8B（部分源于分部重新划分）；美满电子数据中心 $4.2B。

在 2025 年 11 月的金融分析师日上，AMD 设定了三到五年的目标：数据中心 AI 收入年增速超过 80%，数据中心收入年增速超过 60%，每股收益（EPS）超过 $20 [S15012]。

> **提示**
>
> **算例 —— 80% 的年复合增长率意味着什么。** 以 2025 年约 $6.7B 的 Instinct 收入为起点（本资料库估计）[S450]。按每年 80% 增长，2028 年将达到 $6.7 \times 1.8^3 \approx$ **$39B**，2030 年将达到 $6.7 \times 1.8^5 \approx$ **$127B** [S15012]。英伟达 FY2026 数据中心收入约为 $194B [S1]。**结论：** 即便按 AMD 自己的目标，在 2030 年前后之前它仍低于英伟达的*当前*规模。其押注在于 AI 市场持续扩大，使 AMD 无需英伟达收缩即可赢得份额。

## 分层级的优势与劣势

### AMD averages 3.3 of 5 vs NVIDIA's 4.7, ahead only on Memory and Cost/TCO

Capability scores 0-5; AMD (filled) vs NVIDIA reference (dashed green); analyst judgement with sourced rationale

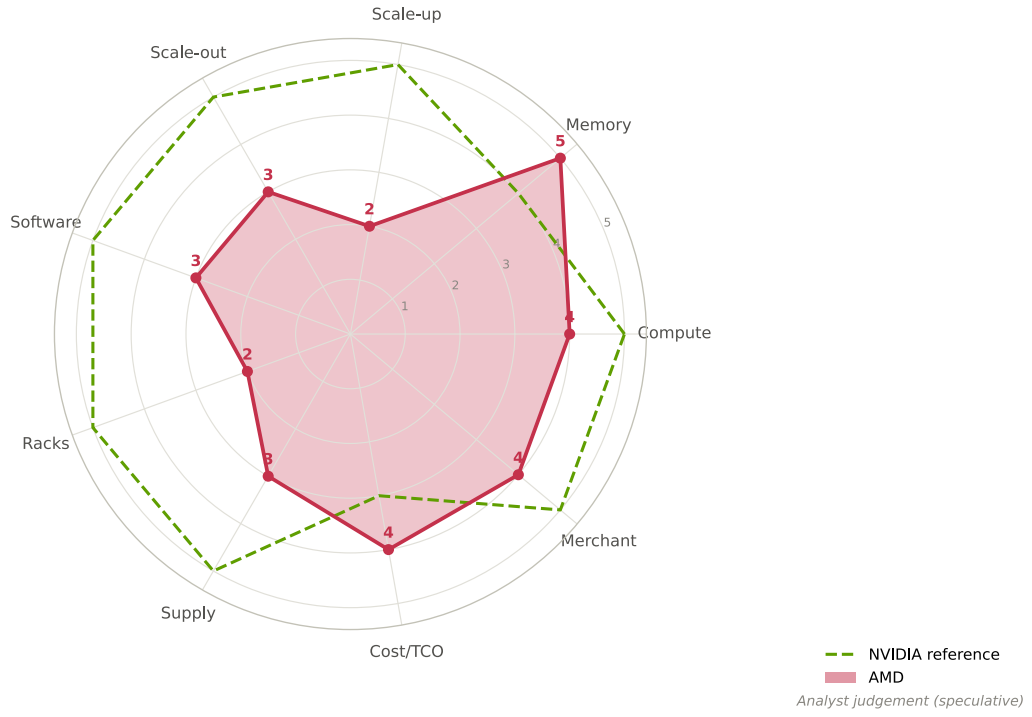


Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S143] [S361] [S630] [S402] ...; chart by repo · As of 2026-11-05

AMD 与英伟达在九个能力维度上的雷达图，按 0-5 分评分（本资料库分析师判断）：算力 4 vs 5；内存 5 vs 4；纵向扩展 2 vs 5；横向扩展 3 vs 5；软件 3 vs 5；机架 2 vs 5；供应 3 vs 5；成本/TCO 4 vs 3；商用可得性 4 vs 5。平均 3.3 vs 4.7。AMD 仅在内存上领先，在算力、成本和商用可得性上接近；在 Helios 爬坡之前，其最弱的维度是纵向扩展互连和机架级系统（各 2 分）。

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 02 GPU 芯片 | 🟨 持平 | MI355X 在 MLPerf Llama 2 70B 上与 B200 持平（12,935 vs 12,994 tokens/s） [S602] |
| 03 内存、封装与供应 | 🟥 落后 | 单 GPU HBM 领先，但 CoWoS 和 HBM 配额小得多 [S379] |
| 04 CPU | 🟩 领先 | EPYC（Venice，最多 256 核）是最常见的 x86 AI 主机 CPU [S4028] |
| 05 纵向扩展 | 🟥 目前落后（纸面上 🟦） | Helios 之前为 8-GPU Infinity Fabric；纸面上每 GPU 3.6 vs 3.0 TB/s [S5522,S90007] |
| 06 横向扩展 | 🟥 落后 | 有 Pensando 网卡，但没有自研交换芯片 [S7500] |
| 07 DPU、SuperNIC、存储 | 🟥 落后 | Salina DPU 的部署量远低于 BlueField 或 Nitro [S289] |
| 08 系统与机架 | 🟥 落后 | Helios 是第一代产品 [S8527] |

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 09 系统软件 | 🟥 落后 | ROCm 框架指数 26/36；存在首日支持缺口 S586,S633 |
| 10 软件库 | 🟥 落后 | RCCL 落后 NCCL 约 3 个月；FP4 推理内核滞后 S10509,S624 |
| 11 推理软件 | 🟥 落后 | 在部分每美元性能指标上胜出（GLM-5 比 B200 最多便宜 29.6%），但在每用户 150 tokens/s 下成本最高可达 5× S637,S636 |
| 12 编排与云 | 🟦 路线不同 | 没有自营云；通过甲骨文、Azure 和新兴云服务商销售 S90022,S90024 |
| 13 生态与资本 | 🟥 落后 | 认股权证赢得了 12 GW，但现金约 $15.8B，远低于英伟达 S13501 |

判定依据 `data/competitor_matrix.csv`（本资料库分析师判断，🔴）S15014。本页将第 05 层标为“目前落后、纸面上路线不同”，比矩阵中单一的“落后”更为细分。

**提示**

**算例 —— AMD 能承受多少新模型流量。** 在调优后的基准测试中，MI355X 的每美元 token 数比 GB300 高约 27%，即每 token 成本约为后者的 0.73×（估计）S602,S622。在新模型发布后的头几周，其成本可能高出约 4.3×（见上文 DeepSeek-V4 示例）。若某集群的 token 中有比例 $x$ 来自此类新模型，则当 $0.73 \times (1 - x) + 4.3 \times x = 1$ 时 AMD 达到盈亏平衡，即 $x \approx 8\%$（🔴 本资料库测算）。**结论：** AMD 在稳定、成熟的工作负载上具有成本优势，但只要超过约 8% 的 token 来自刚发布的模型就会落败——这正是首日软件支持比峰值规格更重要的原因。

**其最有力的论据。** “相同规格、开放互连、第二供应商。”AMD 提供的商用 GPU 每年都在纸面上持平或超越英伟达。其机架基于开放的、以以太网为基础的 UALink，而非专有的 NVLink；买家借此获得针对英伟达约 75% 毛利率的议价筹码 S405。三家前沿实验室已为其押注了数吉瓦的算力。

**差距缩小了多少。**

| 指标 | 过去 | 现在（2026 年 11 月） | 来源 |
|---|---|---|---|
| 单 GPU HBM 对比英伟达旗舰 | 192 vs 80 GB（2023） | 432 vs 288 GB | S141,S144,S33005 |
| 单节点微调，8 颗 GPU | MI300X 约 28–29 分钟（2025）vs GB300 约 5.6 分钟 | MI355X 8.3 vs 5.6 分钟：1.5× | S609 |
| 新模型的软件滞后 | 数年 | 26 天（DeepSeek-V4-Pro） | S633 |
| 纵向扩展域 | 8 颗 GPU | 72 颗 GPU（Helios） | S226 |
| AI 芯片收入份额 | 约 0.9%（2023，估计） | 约 3%（2025，估计） | S15014 |
| 英伟达 ÷ AMD 数据中心收入 | 3.3×（2023-Q1） | 约 13×（2026-Q2） | S450,S405 |

硬件差距已经弥合；软件差距已从数年缩短到数周；收入差距则在扩大。

**注**

🐂 **看多观点（对 AMD 而言）。** AMD 是唯一同时拥有商用 GPU、机架、CPU 和网卡的对手，且如今已跟上英伟达一年一代的节奏。凭借 14 GW 的承诺和 HBM 领先优势，它只需在约 $436B 的市场（2026E）中拿下几个百分点，即可让其 AI 业务翻倍：每个百分点约值 $4.4B（估计）S15014。若实现其金融分析师日（FAD）提出的年增速 >80% 目标，Instinct 收入将在 2030 年前超过约 $100B（本资料库测算）S15012。

> **注意**
>
> 🐻 **看空观点（对 AMD 而言）。** 规格不等于部署。Helios 尚未经过规模化验证，ROCm 在每个新模型上仍要落后数周，与英伟达的收入差距扩大到约 13× [S633,S405]。认股权证交易将 2027–28 年的收入与两家客户的融资能力绑定，并使现有股东最多被稀释约 20% [S24003]。如果 MI450 表现不及预期，OpenAI 和 Meta 完全可以少部署几个吉瓦。

## 🎯 企业发展视角

1. **机架集成作为一类资产。** AMD 为 ZT 的设计团队净付出约 $2B [S5527]。挑战者还可以收购哪些机架级、液冷或供电团队？相对于它们所能撬动的吉瓦级承诺，这些团队价值几何？
2. **以开放的纵向扩展（scale-up）作为切入点。** Helios 基于博通交换机上的 UALink over Ethernet [S5522]。开放的纵向扩展生态，是否为第三方 CPU、网卡或加速器创造了 NVLink Fusion 所不具备的空间？
3. **股权换产能具有反身性。** AMD 的认股权证之所以奏效，是因为其股价从约 $165 涨至约 $612 [S24001,S24005]。哪些结构（预付款、返利、站点共同投资）能让市值较小的挑战者提供类似条件？
4. **首日软件支持是稀缺要素。** ROCm 的滞后已降至 26 天 [S633]。要将其降至零，需要在人员、工具或收购上投入什么？还有谁（Modular、Triton、PyTorch 编译器）可以为任何非英伟达芯片提供这种能力？
5. **客户集中度。** OpenAI 和 Meta 合计可能吸收最多 12 GW 的 AMD 产能 [S24000,S24004]。合作伙伴应如何结合这种集中度，为 AMD 2027–28 年的执行风险定价？

# 定制 ASIC 设计服务商：博通、美满电子、世芯、创意电子与联发科

跨层专题 15 · 竞争格局 · 阅读约 16 分钟 · 最后核实：2026-11-05

## ⚡ 要点速览

- **博通（Broadcom）已成为仅次于英伟达（NVIDIA）的第二大 AI 芯片供应商。** 截至 2026-08-02 的季度，其 AI 半导体收入达 $16.7B（同比 +221%），约相当于英伟达当季 $89.0B 数据中心收入的 19% [S2516,S405]。管理层预计 FY2026 为 ~$58B，高于 FY2025 的 $20.2B [S15501,S661]。
- **前瞻表述更为激进。** 博通称已锁定足以支撑 FY2027 ~$115B AI 收入的供应，并对 FY2028 ~$230B 具备“清晰可见度”（line of sight）（🟡 管理层目标，并非已签约收入）[S15501]。
- **客户名单即前沿阵营。** 谷歌（Google）的 TPU、Meta 的 MTIA、OpenAI 的 10 GW 项目（2026 年下半年至 2029 年）以及 Anthropic （$10B 订单，其后又追加 $11B 基于 TPU 的机架）均经由博通实现 [S15552,S174,S15500]。预计 Anthropic 将在 2027 年 成为其最大的 XPU 客户 🟡 [S15501]。
- **美满电子（Marvell）是远远落后的第二名。** 其 Q2 FY2027 季度数据中心收入为 $2.17B（+46%），约为 博通 AI 收入年化水平的七分之一 [S15504]。据报道，英伟达于 2026 年 3 月向美满电子投资 $2B，以将其绑定于 NVLink Fusion 🟡 [S90037]。
- **围绕台积电（TSMC）的台湾第二梯队正在成长。** 世芯电子（Alchip，承接 3 nm 的 AWS Trainium3）、创意电子（GUC）和联发科（MediaTek，2026 年 AI ASIC 目标 $2B；有报道称承接谷歌 TPU 相关工作）的年收入各在 $1–2B 左右 [S2517,S15506,S15508,S2518,S23008]。
- **其经济性只在超大规模下成立。** 本资料库模型测算，每个项目的盈亏平衡点为 ~87k 个 GPU 等效算力单位；若该芯片只能完成 GPU 一半的有效工作量，则升至 ~237k（🔴 估计）[S2501,S35026]。
- **对英伟达意味着什么：** 按设计合作方价格计，2025 年定制芯片约占 AI 加速器*收入*的 ~10%（估计）[S416,S661]，但 TrendForce 预计 2026 年基于 ASIC 的服务器将占 AI 服务器*出货量*的 27.8% [S2517]。金额份额低估了 出货量的迁移，而且正在转向的恰恰是最大的买家。

**Broadcom's AI revenue rose ~15× to ~$58B; its FY2027 goal is ~59% of NVIDIA's FY2026 DC**

US$ B per fiscal year, aligned by calendar year (Broadcom FY ends ~Nov; NVIDIA FY ends late Jan, so NVIDIA FY2026 ≈ CY2025)

*Hatched = management target / aspiration, not reported revenue*

Source: data from Broadcom and NVIDIA filings and calls [S660] [S451] [S661] [S15501] [S2516] [S417] ...; chart by repo · As of 2026-11-05

> 按日历年对齐的分组柱状图。博通 AI 半导体收入：$3.8B（FY2023）、$12.2B（FY2024）、$20.2B（FY2025），FY2026 约 $58B（Q4 为指引值），FY2027 管理层目标约 $115B，FY2028 具备“清晰可见度”的约 $230B（斜线填充）。英伟达数据中心收入：$47.5B（FY2024）、$115.2B（FY2025）和 $193.7B（FY2026）；仅 FY2027 上半年英伟达就确认了 $164B。博通的 FY2027 目标约相当于英伟达 FY2026 数据中心收入的 59%。

## 定制 ASIC 业务如何运作

想要自有加速器的超大规模云厂商很少会独立完成整颗芯片。其架构师决定计算引擎的形态（矩阵单元、数值格式、片上存储），因为这正是其工作负载知识所在。ASIC 设计合作方则提供其余一切：用于芯片间互连的高速 SerDes、HBM 接口、封装、物理设计，以及在台积电产能队列中的位置。不妨以盖楼作比：业主的建筑师画平面图，总承包商负责打地基、布线并办理各项许可。

合作方有两笔收入。第一笔是设计阶段的 NRE（一次性工程费用）。第二笔规模大得多：每颗出货芯片的单价，其中包含合作方对其代为采购的晶圆、HBM 和封装所赚取的利润。合同形式有两种。在交钥匙 ASIC（turnkey ASIC）模式下，合作方出售成品芯片；在客户自有工具（COT）模式下，客户购买服务或 IP，并自行与晶圆代工厂签约，从而压缩合作方的单颗收入。博通与 Anthropic 的交易属于交钥匙模式的极端情形：其 CEO 称之为整系统销售，由博通对机架负责 [S15500]。

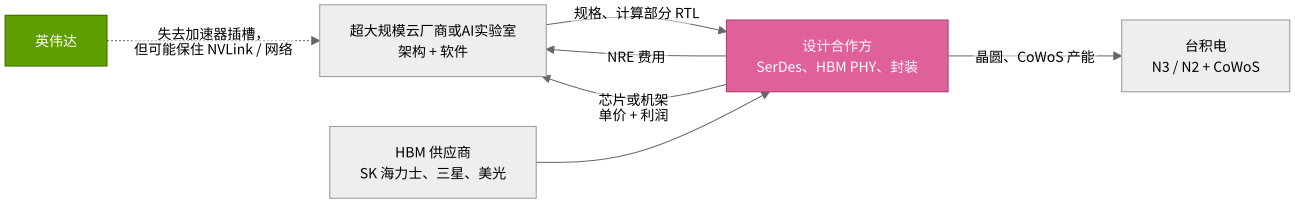


时间维度对交易分析很重要。OpenAI 于 2025 年 10 月宣布与博通的合作项目，部署期为 2026 年下半年至 2029 年 [S174]；据报道，其首款芯片（代号 Jalapeño）已在博通 Q3 FY2026 季度出货 🟡 [S15552]。因此，一个项目从架构设计到最后一批量产出货大约跨越 3–5 年（🔴 本资料库分析），而买家如今会同时推进多代重叠的产品：Meta 规划了截至 2027 年的四代 MTIA，节奏约为每 ~6 个月一代 [S561]。

**提示**

**算例 —— 从博通单季业绩推算出货量。** 博通 Q3 FY2026 确认 AI 收入 $16.7B，并 表示其中 73% 来自 XPU，即单季定制加速器收入 ~$12.2B（本资料库测算）[S2516,S15501]。若 每颗 XPU 售价 ~$10–15K（🔴 假设，低于商用 GPU 的 $30–40K [S35026]），则每季 ~0.8–1.2M 颗芯片。 作为参照，仅 Anthropic 一家就计划使用多达 1M 颗 TPU [S653]。定制芯片是一门以较低单价换取大规模出货的生意， 这正是收入份额低估出货份额的原因。

**🔧 技术细节：为何 SerDes 与封装是设计合作方的护城河**

2026 年的加速器每秒需在芯片外传输数 TB 数据：据报道，Jalapeño 的 HBM4 带宽达 15.4 TB/s [S628]，而 纵向扩展（scale-up）链路采用 200G 级通道。要设计出在功耗预算内实现每通道 200 Gb/s 的 SerDes，以及能通过内存厂商认证的 HBM PHY，需要多年的芯片迭代。博通还销售 这些链路所接入的交换机（Tomahawk），因此能够对两端进行协同设计；本资料库评估博通在 横向扩展（scale-out）以太网交换领域领先英伟达 [S274]。封装则构成另一道供应护城河：TrendForce 一类的估计显示，在 2026 年 ~1,000k 片 CoWoS 晶圆中，博通占 ~150k，仅次于英伟达的 ~595k（估计）[S379]。超大规模云厂商可以招聘计算架构师， 却很难“招聘”到十年积累的 SerDes 测试芯片和 CoWoS 产能配额。

## 谁为谁设计

下表梳理了已公开的客户–合作方配对关系。其中若干为报道而非确认；设计合作方很少公开点名 客户。

| 客户项目 | 主要设计合作方 | 其他合作方（有报道） | 状态 | 来源 |
|---|---|---|---|---|
| 谷歌 TPU（Ironwood、TPU 8） | 博通 | 联发科负责 v7e/v8e 变体 🟡 | 已出货；Anthropic 采购，Meta 租用 | S15552,S23008,S90025 |
| Meta MTIA | 博通 | — | 已出货；规划至 2027 年共 4 代 | S15551,S561 |
| OpenAI “Jalapeño”（10 GW） | 博通（芯片 + 以太网机架） | — | Q3 FY2026 首批出货 🟡 | S174,S15552 |
| Anthropic（TPU 机架） | 博通（系统销售） | 谷歌（TPU 设计） | $10B + $11B 订单 | S15500,S655 |
| AWS Trainium | 自研（Annapurna） | 美满电子（早期代次）、世芯（Trainium3）🟡 | Trn3 自 2026 年第二季度起量产 | S2517,S90034 |
| 微软（Microsoft）Maia | 自研 | 美满电子 🟡；可使用 OpenAI 由博通打造芯片的 IP | Maia 200 已部署；Maia 300 于 2027 年推出 | S15008,S662,S90044,S90046 |
| AWS 定制推理芯片 + 1.6T 光学器件 | 高通（Qualcomm） | — | 多代合作；自 2027 财年第一季度起贡献收入 🟢 | S15510,S15509 |

AWS Trainium、 谷歌 TPU、 微软 Maia 与 Meta MTIA 各页从客户角度介绍了上述各项目。

## 博通：规模型玩家

博通的论据建立在三个数字之上。收入：FY2026 AI 半导体收入 ~$58B；此前 Q3 总收入为 $29.6B（+86%），其中 AI 占 $16.7B [S15501,S15502]。前沿客户集中度： 谷歌、Meta、OpenAI 与 Anthropic 均为其公开点名的客户，其 XPU 客户总数为六家 [S15551,S15552]。 在手订单：陈福阳（Hock Tan）表示，FY2027 翻倍至 ~$115B 已有供应保障，并预计 OpenAI 将部署超过 5 GW 的 Jalapeño 及其后继产品 🟡 [S15501]。

**Broadcom's AI revenue rose from ~12% to ~19% of NVIDIA's data-center revenue in 2026**

Broadcom AI semiconductor revenue ÷ NVIDIA Data Center revenue, same calendar quarter of quarter-end, %

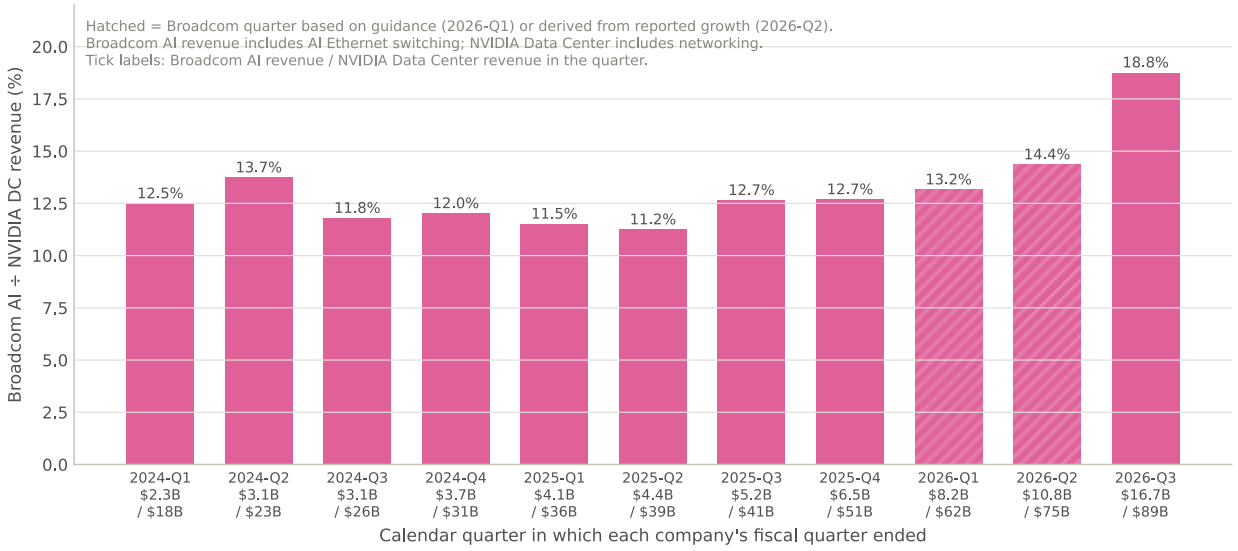


Source: data from Broadcom and NVIDIA filings; repo calculation [S660] [S661] [S451] [S2516] [S403] [S405]; chart by repo · As of 2026-11-05

> 柱状图：2024 年第一季度至 2026 年第一季度，博通季度 AI 半导体收入一直维持在英伟达数据中心收入的约 11–14%，随后在 2026 年第二季度升至 14%（推算），并在 2026 年第三季度升至 19%，当季博通确认 $16.7B，而英伟达为 $89.0B。博通对下一季度的指引为 $21.7B。

该图中的比率是衡量定制芯片相对英伟达态势最简洁的单一指标。它在两年间稳定于 11–14%，并在 2026 年第三日历季度跃升至 19% [S2516,S405]。本资料库此前对博通 FY2026 ~$45B 的情景假设被证明过于保守：指引加上已公布的 各季度数据，目前合计 ~$57B（下图即采用此数），而博通 CEO 引用的数字为 ~$58B [S2516,S15501]（GPU 芯片竞争）。

**Broadcom's AI revenue rose 2.8x in two years to $6.5B a quarter and tracks ~$57B for FY2026; Marvell's is ~1/8 the size**

Left: Broadcom AI semiconductor revenue by fiscal quarter (US$ B). Right: annual AI revenue, Broadcom vs Marvell (US$ B)

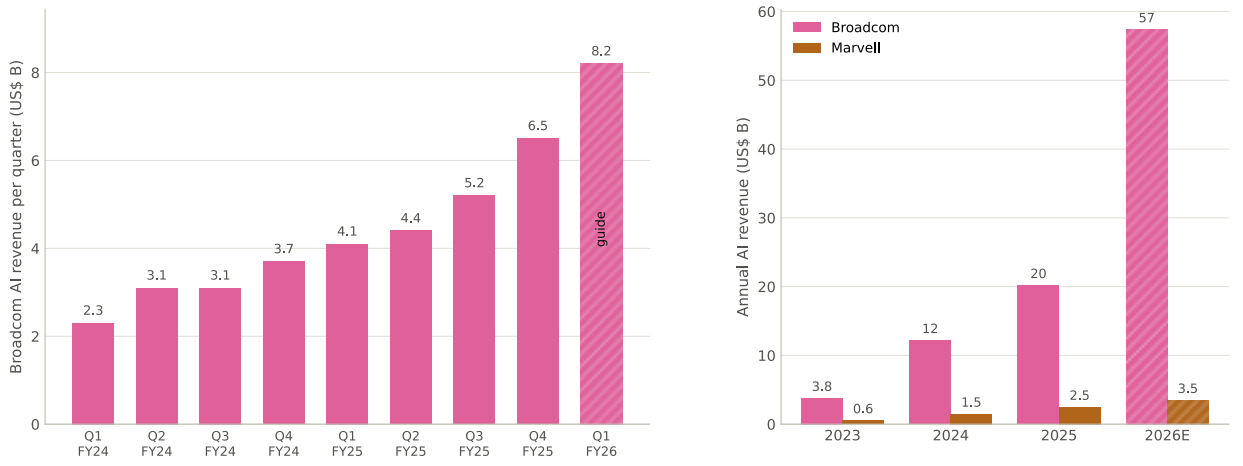


*Hatched = guidance or Est.*

Source: data from Broadcom, Marvell earnings releases [S660] [S661] [S451] [S2516] [S662] [S453] ...; chart by repo · As of 2026-11-05

> 两幅子图。左：博通季度 AI 半导体收入从 2024 财年第一季度的 $2.3B 攀升至 2025 财年第四季度的 $6.5B，2026 财年第一季度指引 $8.2B 以斜线标示。右：年度 AI 收入，博通约 $3.8B（2023）、$12.2B（2024）、$20.2B（2025），FY2026 ~$57B（Q1 与 Q4 为指引值，Q2 为推算值，Q3 为已公布值）；美满电子为 $0.55B、$1.5B、$2.5B、 ~$3.5B（2026E）。博通的数字既包括 AI 以太网网络业务，也包括谷歌 TPU 等定制 XPU。

> **提示**
>
> **算例 —— 将 FY2027 目标与英伟达对照。** 博通 FY2027 ~$115B 的目标约为英伟达 FY2026 数据中心收入 $193.7B 的 ~59% [S15501,S1]。但英伟达仅在 FY2027 上半年就确认了 $164.2B 的数据中心收入 [S403,S405]，年化 ~$330B。以这一速度衡量，博通的目标仅 ~35%。方向已很清晰；但“定制芯片超越商用芯片”的叙事尚未体现在数字中。

## 美满电子、世芯、创意电子与联发科：第二梯队

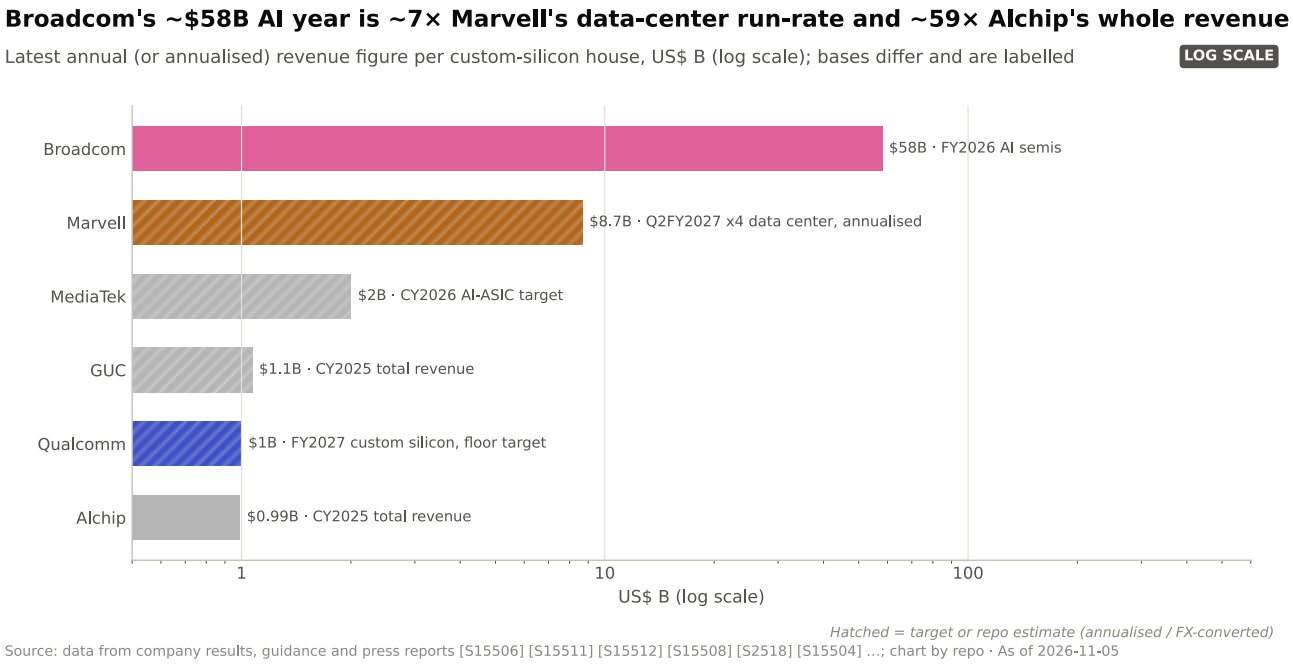


> 定制芯片收入规模的水平对数坐标柱状图：博通 FY2026 AI 半导体收入约 $58B（其中定制 XPU 约占 73%）；美满电子按 Q2 FY2027 季度年化的数据中心收入约 $8.7B；联发科 2026 年 AI ASIC 收入目标 $2B；创意电子 2025 年总收入约 $1.07B（由 NT$34.1B 换算）；世芯 2025 年总收入 $0.99B；高通来自两家超大规模云厂商的 FY2027 定制芯片收入至少 $1B（目标）。博通约为美满电子的七倍、世芯的近 60 倍。

**美满电子**销售定制 XPU、光通信 DSP 和交换机。其 Q2 FY2027 季度收入为 $2.739B（+37%），其中数据中心占 ~79%；公司预计定制业务收入将在 FY2028 增长一倍以上，另据报道其 FY2027 指引为 ~$12B [S15504,S15505]。其弱点在于客户集中：AWS 看来对 Trainium 采取双供应商策略，而世芯拿下了 3 nm 的 Trainium3 [S2517]。据报道英伟达持有的 $2B 股份（2026 年 3 月）使美满电子成为与英伟达关系最紧密的设计服务商：它是 NVLink Fusion 设计合作方，因此由美满电子打造的 XPU 可以置于英伟达机架之内 [S90037,S131]。美满电子还于 2026 年 2 月以 $3.25B 预付对价收购了 Celestial AI（光子内存互连架构）[S2513]。

**世芯与创意电子**是隶属台积电生态的台湾设计服务公司。随着 5 nm 项目退坡，世芯 2025 年收入从 ~$1.6B 降至 ~$992M；2026 年第二季度起量产的 Trainium3 是其反弹的契机 [S15506,S15507,S2517]。创意电子 作为台积电的关联企业，2025 年收入为 NT$34.1B（~$1.07B）[S15508]。它们的模式更接近 COT：单颗芯片利润率更低，客户锁定程度也更弱。

**联发科**带来了手机 SoC 公司的能力（能效、SerDes、大规模量产执行力）。公司将 2026 年 AI ASIC 目标从 $1B 上调至 $2B，据报道还拿下了谷歌 TPU v7e/v8e 的相关工作，可能负责的是 I/O 裸片 而非计算裸片 🟡 [S15503,S2518,S23008]。它也是 NVLink Fusion 的首发合作伙伴 [S90031]。

> **提示**
>
> **算例 —— 定制芯片市场内部的差距。** 博通 FY2026 ~$58B 的 AI 收入约为美满电子年化 $8.7B 数据中心收入的 ~6.7 倍，世芯 2025 年收入的 ~59 倍 [S15501,S15504,S15506]。即使联发科的谷歌业务 在其 $2B 目标基础上增长十倍，也仍只有博通 FY2026 的三分之一。定制芯片并非一个碎片化的 市场；它是博通加上一条长尾。

## 超大规模云厂商为何选择它们，代价几何

动机在于利润率。英伟达 Q2 FY2027 公司整体毛利率为 75.0% [S405]；Epoch AI 估计一颗 B200 的制造成本约 ~$6.4K，而售价为 $30–40K [S35020,S35026]。部署数十万颗加速器的买家即便支付了合作方的利润 和自身的工程费用，只要芯片完成足够多的有效工作，仍然可以胜出。

**Est.: a custom ASIC repays ~$1.2B of fixed cost after ~87k GPU-equivalents; at half a GPU's speed it needs ~237k**

Repo model: cumulative cost (US$ B) to deploy N GPU-equivalents of capacity, merchant GPU vs custom ASIC (NRE + team + unit cost)

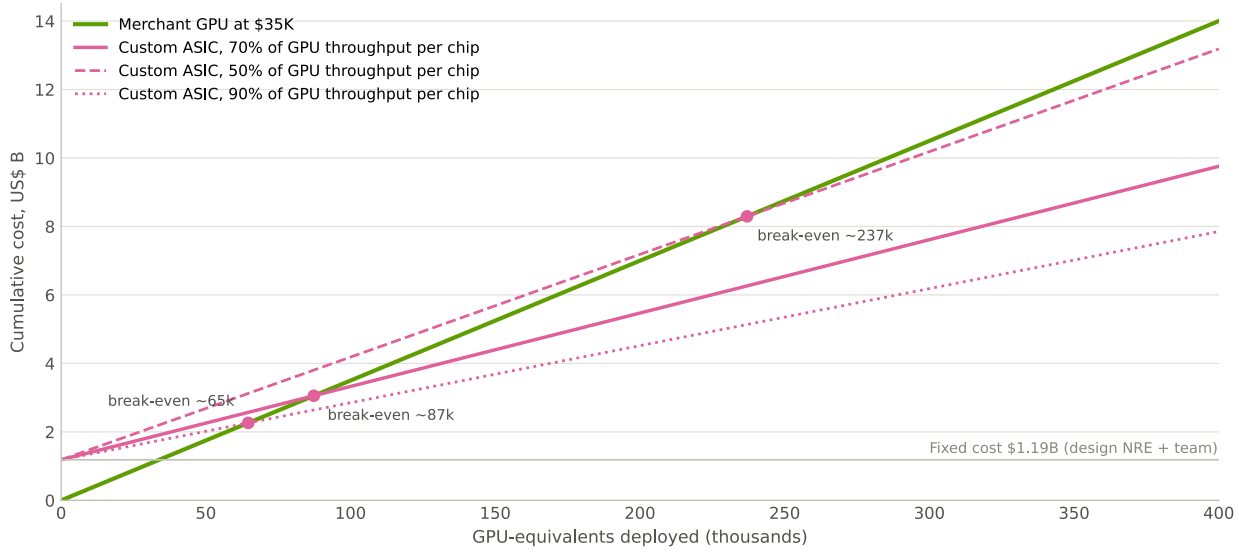


*Illustrative model (speculative inputs); excludes power, networking and opportunity cost*

Source: data from repo model; inputs from Epoch AI, NVIDIA CEO remarks, IBS/Silicon Analysts [S35026] [S35020] [S625] [S628] [S2501] [S401] ...; chart by repo · As of 2026-11-05

本资料库盈亏平衡模型的折线图。采购商用 GPU 每颗 $35K，因此成本从零开始呈直线上升。定制 ASIC 起始固定成本为 $1.19B（约 $0.59B 的 3 nm 设计费用和约 $0.6B 的软件与系统团队成本），每颗芯片成本 $15K。若每颗芯片完成 GPU 有效工作量的 70%，两条线在约 87k 个 GPU 等效单位处相交；若为 50%，交点移至约 237k；若为 90%，则降至约 65k。只有部署数十万颗加速器的买家才能轻松越过门槛。

> **提示**
>
> **算例 —— 盈亏平衡点。** 固定成本：3 nm 设计 ~$0.59B [S2501]，加上一支 500 人的 软件与系统团队三年 ~$0.6B（按每人年 ~$0.4M 计，🔴 假设）[S10535]：合计 ~$1.19B。单位成本： 每颗定制芯片 $15K（🔴），而每颗 GPU 为 $35K [S35026]。若吞吐量为 GPU 的 70%，则定制芯片折合每个 GPU 等效单位的成本为 $15K ÷ 0.7 ≈ $21.4K，每个节省 ~$13.6K。$1.19B ÷ $13.6K ≈ 87k 个 GPU 等效单位。一个 1 GW 的项目需要 数十万颗加速器，因此前沿实验室能够越过门槛；一家部署 20k 颗 GPU 的企业则不能。

该模型遗漏了实际决策中最困难的部分：软件。谷歌 TPU 之所以具备经济性，是因为 XLA 和 JAX 已经存在；SemiAnalysis 在某一工作负载上测得 Ironwood 的单 token 成本比 B200 低 ~18%，主要源于更便宜的 芯片时租价格，而非更快的芯片 [S625]。缺乏这套软件栈的新 XPU 可能需要数年才能达到其纸面吞吐量（参见 CUDA 竞争）。

## 分层评判：博通类定制芯片 vs 英伟达

| 层 | 评判 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟦 路线不同 | 客户自定义 XPU；Jalapeño 每裸片 ~13.4 PFLOPS MXFP4（SemiAnalysis） S628 |
| 03 内存、封装与供应 | 🟥 落后 | 2026 年 CoWoS 晶圆 ~150k，英伟达 ~595k（估计） S379 |
| 04 CPU | 🟥 落后 | 无 CPU；客户自带 Arm 或 x86 主机 |
| 05 纵向扩展互连 | 🟥 落后 | 以太网纵向扩展（SUE、ESUN）在已部署域规模上落后于 NVLink S90052,S576 |
| 06 横向扩展网络 | 🟩 领先 | Tomahawk 6 率先达到 102.4 Tb/s；以太网约占 AI 后端交换的三分之二 S274,S90054 |
| 08 系统与机架 | 🟦 路线不同 | 仅为特定客户（OpenAI、Anthropic）提供机架 S174,S15500 |
| 09–11 软件 | 🟦 路线不同 | 客户自有软件栈（JAX/XLA、PyTorch 后端） |
| 13 生态与资本 | 🟥 落后 | 六家 XPU 客户，对比英伟达的广泛渠道；未披露供应商融资 S15551 |

本资料库的全局评分见竞争格局索引。

## 它们最有力的论据，以及差距缩小了多少

**最有力的论据：** 四家最大的 AI 支出方已经决定自有部分芯片，而博通以远低于英伟达向买家收取的毛利率承接了这一决定。每一个转向定制芯片的 GW 都是英伟达卖不出去的 GW，各家的 GW 规划也印证了这一点：在 OpenAI 已宣布的 26 GW 中，10 GW 为博通定制加速器，另有 10 GW 归英伟达（一份此后已重组的意向书）、6 GW 归 AMD S174,S90016,S13506。

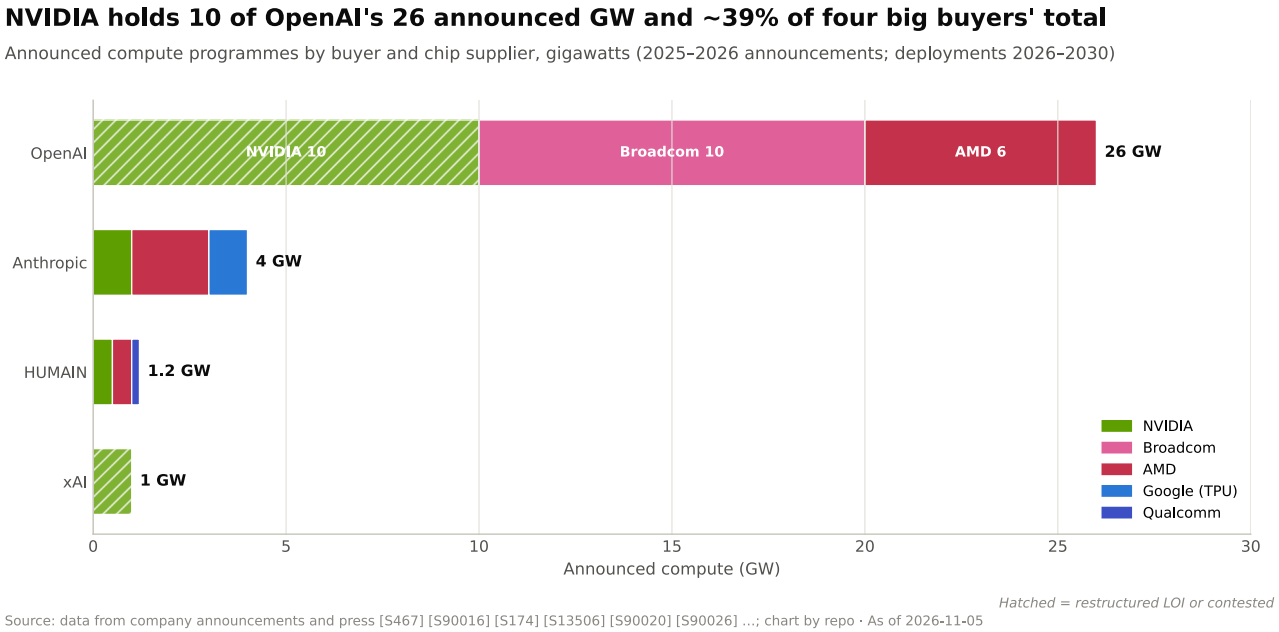


已宣布算力项目的堆叠水平柱状图，单位为吉瓦。OpenAI 26 GW：英伟达 10（2025 年 9 月意向书，此后已重组）、博通定制加速器 10、AMD 6。Anthropic 4 GW：AMD Helios 最多 2（附带 AMD 最多 $5B 的投资）、英伟达最多 1、谷歌 TPU 2026 年逾 1 GW（2027 年起另有数 GW 的 TPU 扩容，未量化）。HUMAIN：英伟达最多 0.5 GW、AMD 0.5 GW、高通 0.2 GW。xAI：约 1 GW 采用英伟达（公司口径，存在争议）。英伟达在上述项目中的份额约为 39%。

**差距缩小了多少：** 按收入计，定制芯片从 2023 年约占 AI 芯片总盘子的 ~8% 升至本资料库 2026 年估计的 ~11%（鉴于博通的收入增速，该估计可能偏低） S660,S661；按博通对英伟达数据中心收入之比计，单季从 ~12% 升至 ~19% S2516,S405；按出货量计，差距缩小得更多（占 2026 年 AI 服务器的 27.8%） S2517。

**Custom ASICs reach only ~14% of AI silicon revenue by 2026E, but perhaps ~28% of units**

Merchant (NVIDIA, AMD, Intel) vs custom ASIC (Broadcom, Marvell) share, %, 2023 vs 2026E; revenue basis vs unit basis

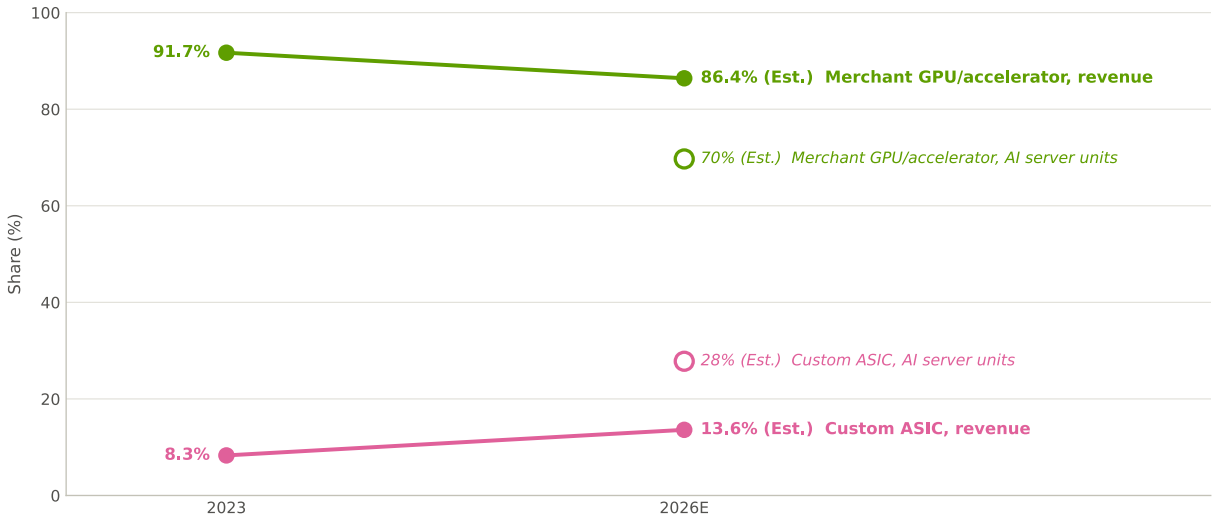


*2026E = Est.*

Source: data from vendor filings; TrendForce (as recalled) [S416] [S1] [S403] [S405] [S663] [S660] ...; chart by repo · As of 2026-11-05

斜率图：2023 年至 2026E，商用 GPU 与加速器占 AI 数据中心芯片收入的比重从 92% 降至约 86%，而定制 ASIC 从 8% 升至约 14%。按出货量计，TrendForce 一类的估计显示，基于 ASIC 的服务器约占 2026 年 AI 服务器出货量的 28%，原因是定制芯片的单价要低得多。

**注**

🐂 **看多观点（对英伟达而言）。** 定制芯片项目仍让英伟达留在机架之中：Trainium4 将采用 NVLink Fusion 和 MGX， 而美满电子、联发科和世芯都是 Fusion 合作伙伴，因此即便英伟达丢掉了加速器，仍能销售交换机和 CPU [S518,S90031]。FY2027 上半年，英伟达自身数据中心收入的美元增量超过了博通整条 AI 业务线 [S403,S405]。

**注意**

🐻 **看空观点（对英伟达而言）。** 仅博通 FY2027 的目标就为 ~$115B [S15501]，而其最大客户正是 英伟达同样倚重的实验室。若 Anthropic、OpenAI、谷歌和 Meta 将其 2027–28 年增量中哪怕一半转向定制芯片， 英伟达的超大规模云业务板块（每季 ~$49B）将在需求见顶之前很早就碰到出货量天花板 [S90011]。

## 对英伟达份额意味着什么

英伟达的防御有三重：年度迭代节奏（2024 年设计的定制芯片在 2026 年要面对 Rubin）、设计合作方只向少数客户销售的 机架级系统，以及通过 NVLink Fusion 进行的收编（NVLink Fusion）。 风险高度集中：能够越过上述盈亏平衡门槛的买家，恰恰是英伟达最大的直接客户， 其中三家分别占 FY2027 上半年收入的 16%、15% 和 13% [S90069]。

**提示**

**算例 —— 前三大客户转移意味着什么。** 三家直接客户分别占 FY2027 上半年收入的 16%、15% 和 13%， 合计 44% [S90069]。若这三家将其英伟达支出中的十个百分点转向定制 芯片，英伟达将损失 ~4.4% 的收入（🔴 本资料库测算）——还不到 Q2 FY2027 单季环比增幅（环比 +18%）[S405]。威胁针对的是增长率与定价权，而非 2026 年的收入基数。

## 🎯 企业发展视角

1. 博通的护城河在于 SerDes、封装产能配额和系统集成，而非计算架构。其中哪些是 新进入者可以买到的（IP 授权、OSAT 产能、收购 Alphawave 一类的标的），哪些需要十年才能建成?
2. 第二梯队（世芯、创意电子、联发科）凭借成本和贴近台积电胜出，却缺乏客户锁定。对于一家已具备 SerDes 和封装 能力的买家而言，一项设计服务资产价值几何？在博通的六家客户之外，还有哪些锚定客户 尚未落定?
3. 英伟达对美满电子的 $2B 投资以及 Fusion 授权，把竞争对手变成了供应商。“英伟达机架内的定制加速器” 是一个可持续的中间形态，还是 UALink/ESUN 机架于 2027 年成熟之前的过渡状态?
4. 收入份额（~11%）与出货份额（~28%）讲述的是不同的故事。企业发展模型应采用哪一指标来测算 定制芯片市场规模？该测算对 XPU 定价的敏感度如何?
5. 盈亏平衡点有利于数十万颗量级的买家。是否存在“轻定制”（custom-lite，共享基础裸片、 客户专属小芯片）的市场，从而为二线云厂商和主权买家降低门槛?

# 推理芯片初创公司：Cerebras、Groq、SambaNova、Tenstorrent、d-Matrix、Etched 及其他

跨层专题 15 · 竞争格局 · 阅读约 15 分钟 · 最后核实：2026-11-05

## ⚡ 要点速览

- **资本回归，估值走高。** Cerebras 于 2026 年 5 月在纳斯达克上市，以 ~$40B 估值（完全摊薄口径最高达 ~$56B）募资 $5.55B [S2504,S2505]；Tenstorrent 以 $6.2B 估值募资 $1.5B（2026 年 10 月），Etched 估值达 $10.3B，Positron 达 $5B [S15516,S2507,S11521]。
- **规模最大的退出是一笔授权交易，而非收购。** 据报道，英伟达（NVIDIA）支付 ~$20B，获得 Groq 技术的非独家授权，并吸纳其创始人和团队；Groq 继续运营 GroqCloud [S90018,S90019]。该设计如今已纳入 英伟达路线图，以 Groq 3 LPX 机架（256 颗 LPU）的形式出货 🟢 [S90003,S114]。
- **估值远远领先于收入。** Cerebras 2026 年第二季度 GAAP 收入为 $180.1M（+74%），全年指引 ~$880–890M；上市时 ~$40B 的估值约为该指引的 ~45 倍 [S15514,S2505]。
- **速度是突破口。** 解码受限于内存带宽，因此将权重存放在 SRAM 或整片 晶圆上的芯片，可以为每个用户提供更高的每秒 token 数；OpenAI 同意在 2028 年前采购最多 750 MW 的 Cerebras 算力 （据报道 >$10B） [S11523,S634]。
- **结局已两极分化。** Graphcore 以 ~$0.6B 出售给软银，而其 2020 年估值为 $2.77B [S15519]；SambaNova 曾与英特尔（Intel）以含债务 ~$1.6B 的价格洽谈，随后据报道以 ~$11B 估值融资（报道相互矛盾）🟡 [S2512,S15518]。
- **生存几率偏向拥有锚定客户或身处英伟达未覆盖细分市场的公司。** 英伟达与 Groq 的交易表明，它会买下 对其构成威胁的细分市场，这限制了下一家 SRAM 新进入者的上行空间（🔴 本资料库分析）。

**AI-chip start-up marks re-rated 2–5× in 2026; Graphcore's exit came at ~1/5 of its 2020 value**

Disclosed or reported valuation marks per company, US$ B (log scale); lines join marks of the same company

LOG SCALE

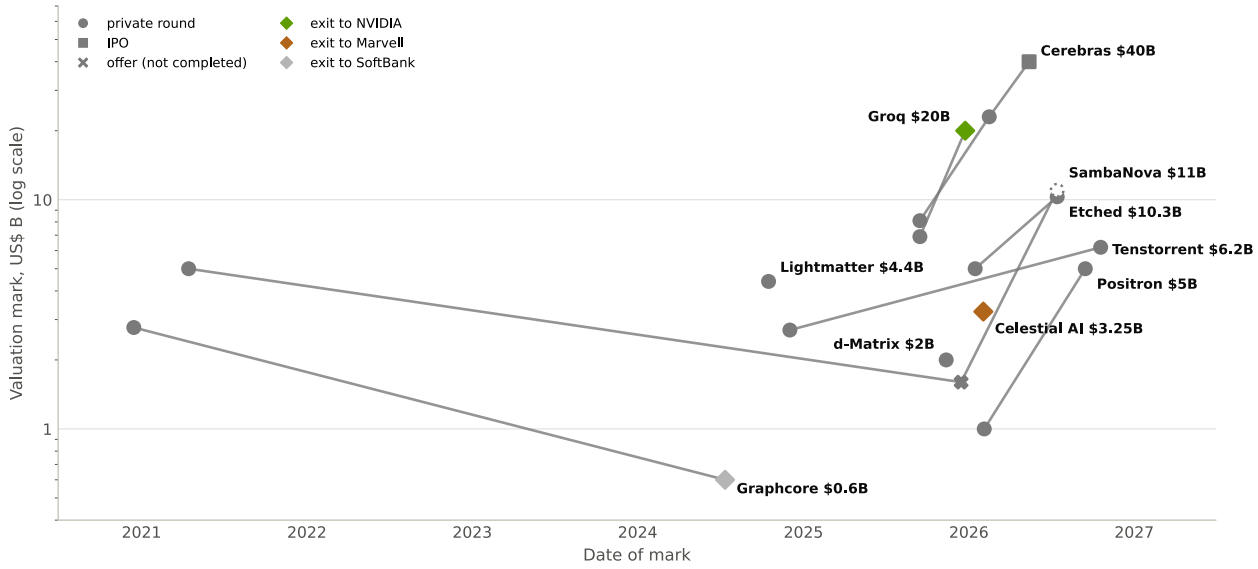


*Marks are not like-for-like (round, IPO, deal, offer); dotted marker = conflicting report*

Source: data from funding announcements, IPO filings and press reports [S2505] [S2504] [S90019] [S90018] [S2506] [S2507] ...; chart by repo · As of 2026-11-05

> AI 芯片初创公司估值节点的对数坐标时间线。Cerebras：$8.1B（2025 年 9 月）、~$23B（2026 年 2 月），2026 年 5 月上市时 ~$40B；Groq：$6.9B（2025 年 9 月），随后与英伟达达成 ~$20B 的授权加团队交易（2025 年 12 月）；Etched：>$5B（2026 年 1 月），随后 $10.3B（2026 年 7 月）；Tenstorrent：~$2.7B（2024 年 12 月），随后 $6.2B（2026 年 10 月）；Positron：~$1B（2026 年 2 月），随后 $5B（2026 年 9 月）；SambaNova：$5B（2021 年），英特尔含债务 ~$1.6B 的报价（2025 年 12 月，已搁置），以及据报道 ~$11B 的 F 轮（2026 年 7 月，报道相互矛盾）；d-Matrix：$2B（2025 年 11 月）；Lightmatter：$4.4B（2024 年 10 月）；Graphcore：$2.77B（2020 年），以 ~$0.6B 出售给软银（2024 年）；Celestial AI：被美满电子以 $3.25B 预付对价收购（2026 年 2 月）。

## 技术押注详解

生成一个 token（解码（decode））需要把每个模型权重重新读取一遍。单个用户的速度大致等于 内存带宽除以权重字节数。GPU 将权重存放在高带宽内存（HBM）中：容量大（Rubin 为 288 GB），但带宽 “只有” 19.2 TB/s [S90006]。初创公司从不同方向挑战这一比率。

| 公司 | 押注方向 | 每芯片 / 每系统内存 | 带宽 | 状态（2026 年） | 最新估值 | 来源 |
|---|---|---|---|---|---|---|
| Cerebras | 晶圆级引擎 | 44 GB 片上 SRAM | ~21 PB/s | 已上市（CBRS）；云服务 + 系统 | ~$40B IPO | S166,S2505 |
| Groq | SRAM LPU，编译器静态调度 | 230 MB（v1）；500 MB（Groq 3，英伟达） | 80 / 150 TB/s | 已授权给英伟达；GroqCloud 继续运营 | ~$20B 交易 | S167,S114,S90019 |
| SambaNova | 数据流 RDU，三级内存 | 520 MB SRAM + 64 GB HBM + 最多 1.5 TB DDR | 未披露 | 获 Vista 和英特尔投资（2026 年 2 月） | 据报道 ~$11B 🟡 | S168,S15517,S15518 |
| Tenstorrent | RISC-V + Tensix 核心，以太网横向扩展，开放软件 | 32 GB GDDR6 | 0.512 TB/s | E 轮 | $6.2B | S169,S15516 |
| d-Matrix | 数字存内计算 | 2 GB SRAM + 256 GB LPDDR5 | 150 TB/s（SRAM） | Corsair 已出货 | $2.0B | S170,S2511 |
| Etched | 模型专用 ASIC（仅支持 Transformer） | 144 GB HBM3E | 未披露 | 据报道预订单 ~$1B | $10.3B | S171,S2507 |
| MatX | LLM 专用加速器 | 未披露 | 未披露 | 计划 2027 年出货 | 未披露（融资 $500M） | S2508 |
| Positron | 内存优先的推理芯片 | 未披露 | 未披露 | C 轮 | $5B | S11521 |
| Lightmatter | 光子互连 | — | — | 据报道接入 NVLink Fusion 🟡 | $4.4B（2024 年） | S2510,S5022 |

**6 of 7 hardware challengers trail NVIDIA on serving software; TPU leads on cost, SRAM chips on speed**

Repo verdict vs NVIDIA (GB300 / Vera Rubin NVL72 with Dynamo and TensorRT-LLM) on five inference dimensions; cell = verdict letter + key fact

| | Tokens/s per user | Throughput per dollar | Software maturity | Model coverage | Deployment flexibility |
|---|---|---|---|---|---|
| Open-source serving vLLM / SGLang / llm-d | P · wide-EP on NVL72 too | P · same GPUs; same cost | P · ~2 stable releases/month | **L · day-0 for open models** | **L · 7 hardware families** |
| AMD MI355X / MI455X Helios + ROCm | B · 8-GPU domain until Helios | P · up to 29.6% cheaper (GLM-5) | B · ROCm 7; no Dynamo twin | P · vLLM/SGLang first-class | P · merchant: OpenAI Oracle Meta |
| Google TPU Ironwood / TPU 8i | D · 9216-chip ICI pods | **L · ~18% below B200 per token** | B · TorchTPU only since Oct 2026 | B · Gemini + Anthropic + plugins | D · Google Cloud; OCI from 2027 |
| AWS Trainium3 / Inferentia2 + Neuron | B · no public results | D · captive pricing | B · vLLM Neuron plugin beta | B · Claude + selected open models | D · AWS only |
| Microsoft Maia 200 | D · 272 MB SRAM + HBM3E | D · internal claims only | B · no public serving stack | B · Copilot / OpenAI models | D · Azure-internal |
| Cerebras CS-3 (WSE-3) | **L · interactivity GPUs can't reach** | B · 44 GB SRAM per system | D · own compiler + API cloud | B · curated models + OpenAI | D · cloud + on-prem; IPO 2026 |
| Groq GroqCloud LPU (post-licence) | **L · SRAM-speed decode** | B · hundreds of chips/model | B · founders now at NVIDIA | B · curated open models | D · API cloud; licence non-exclusive |
| Qualcomm AI 100 Ultra / AI200 / AI250 | B · LPDDR ~0.55 TB/s/card | D · 768 GB/card capacity bet | B · vLLM container; + Modular | B · no MLPerf DC / InferenceX | P · merchant cards + racks |

L = rival leads NVIDIA · P = parity · B = rival behind · D = different approach

*Analyst judgement (speculative)*

Source: data from repo analysis of benchmarks and vendor data (l11_inference_verdicts.csv) [S630] [S621] [S629] [S522] [S11502] [S11001] …; chart by repo · As of 2026-11-05

八家推理挑战者在五个维度上的热力图。开源推理服务框架（vLLM、SGLang、llm-d）在速度、成本和成熟度上与英伟达持平，在模型覆盖和硬件广度（七个硬件家族）上领先。谷歌 TPU 在每美元吞吐量上领先（单 token 成本比 B200 低约 18%）；Cerebras 和 Groq 凭借片上 SRAM 在每用户每秒 token 数上领先，但在成本上落后；AMD 在成本和模型覆盖上持平，但在交互速度和软件上落后；7 家硬件挑战者中有 6 家在软件成熟度上落后；AWS、微软和高通缺乏公开基准测试，大多被评为“路线不同”或“落后”。

**提示**

**算例 —— 为何 SRAM 既快又贵。** 一个 FP8 精度的 70B 参数模型 ~70 GB。一颗 Rubin GPU 就能容纳它， 且每秒可完整读取 ~274 次（19.2 TB/s ÷ 70 GB）[S90006]。一颗 Groq 3 LPU 仅容纳 0.5 GB，因此光是权重 就需要 ~140 颗芯片，超过一个 256-LPU LPX 机架的一半；每颗芯片每秒可重新读取其分片 ~300,000 次（150 TB/s ÷ 0.5 GB）[S114]。Cerebras 的 44 GB 晶圆需要两片才能装下 FP8 权重 [S166]。每用户速度优势是真实的；而 每个模型所需的芯片数量就是代价。这正是本资料库将 SRAM 芯片评为交互速度领先、成本落后的原因 （推理竞争）。

**🔧 技术细节：每种押注各自牺牲了什么**

- **晶圆级（Cerebras）：** 一整块 46,225 mm²、拥有 900,000 个核心的硅片，完全避免了芯片间互连 [S166]，但需要定制封装、每套系统 ~23 kW 的功耗，以及容忍缺陷的冗余设计。超出片上 SRAM 容量的模型需从外部 MemoryX 流式读取权重。
- **编译器调度的 SRAM（Groq）：** 每个操作都在编译时排定执行时刻，因此延迟是确定性的，但 任何模型变更都意味着要在数百颗芯片上重新编译 [S167]。
- **分级数据流（SambaNova）：** SRAM 存放热张量，HBM 存放权重，DDR 提供容量 [S168]；灵活性的代价是 编译器复杂度。
- **存内计算（d-Matrix）：** 运算单元紧邻 SRAM 阵列以减少数据搬运；4-bit 块格式提升了 峰值吞吐量，但需要对模型进行量化 [S170]。
- **模型专用（Etched）：** 将 Transformer 硬化到电路中，消除了通用计算的开销；但模型 架构一旦转变（状态空间模型或混合模型），芯片就可能被闲置 [S171]。

## 逐家分析

**Cerebras** 是唯一一家登陆公开市场的独立公司。除 IPO 外，其锚定客户是 OpenAI：以云服务形式提供最多 750 MW 推理算力，分批交付至 2028 年 [S11523,S11524]。2026 年第二季度核心云业务收入增长 287% 至 $127.7M，公司报告已签约 ~600 MW 数据中心容量 [S15514,S15515]。客户集中度和 利润率是需要关注的指标：公司第二季度核心毛利率为 ~41% 🟡 [S15514]。

**Groq** 展示了英伟达如何化解一个细分市场的威胁。2025 年 12 月的交易以非独家方式授权了 LPU，并将创始人 Jonathan Ross、总裁 Sunny Madra 及团队转入英伟达；Groq 在 CEO Simon Edwards 领导下继续运营 [S90018,S474]。英伟达 GTC 2026 路线图将 256-LPU 的 Groq 3 LPX 机架与 Vera Rubin 并列，另据报道 Feynman（2028 年）将搭配 LP40 LPU 🟡 [S90003,S90004]。Groq 前员工已就该交易起诉董事会 [S118]。

**SambaNova** 说明了估值有多么波动：2021 年 $5B，在已搁置的英特尔谈判中含债务 ~$1.6B（2025 年 12 月）， 随后是 Vista 领投、英特尔参投的 ~$350M 融资（2026 年 2 月），以及据报道估值 ~$11B 的 ~$1B F 轮（2026 年 7 月）—— 但另一家媒体给出的数字要低得多 🟡 [S2512,S15517,S15518]。英特尔 CEO 担任其董事长 [S2512]。

**Tenstorrent** 主打开放：RISC-V CPU 和 Tensix AI 核心、芯片间以太网互连，以及 Apache-2.0 软件栈（tt-metal）[S169,S9535]。其 2026 年 10 月的 E 轮融资（$1.5B，估值 $6.2B）用于资助量产和 Galaxy 系统 [S15516]。IP 授权为其带来了纯芯片初创公司所没有的收入。

**d-Matrix、Etched、MatX 和 Positron** 尚未形成规模。d-Matrix 已出货 Corsair 加速卡（2 GB SRAM，带宽 150 TB/s，外加 256 GB LPDDR5）[S170]。Etched 报告 Sohu 预订单 ~$1B，但尚无经核实的出货 [S2507,S171]。MatX 募资 $500M， 计划 2027 年出货 [S2508]。Positron 的估值在 2026 年内从 ~$1B 升至 $5B [S11520,S11521]。

**光子**领域已一分为二：Lightmatter（$4.4B，2024 年）销售光互连，据报道正加入 NVLink Fusion 🟡 [S2510,S5022]；Celestial AI 的光子内存互连架构则以 $3.25B 预付对价归入美满电子（Marvell）[S2513]。

> **提示**
>
> **算例 —— Cerebras 与 OpenAI 的合同相对 Cerebras 自身有多大？** OpenAI 可能在 2028 年前采购最多 750 MW 算力，据报道金额超过 $10B [S11523]。按约三年摊分，每年 ~$3.3B， 约为 Cerebras 2026 年 ~$885M 收入指引的 3.8 倍 [S15514]。按每套 CS-3 系统 ~23 kW 计算 [S166]，750 MW 的 IT 负载 对应 ~32,600 套系统，每套都是一整片晶圆（🔴 上限估计；设施电力并非全部是 IT 负载）。因此，单一客户 就可能在未来数年内决定 Cerebras 的收入、其对台积电（TSMC）晶圆的需求以及其客户集中度风险。

**AI-chip start-up values span ~$1.6B–$40B; Groq's ~$20B exit went to NVIDIA**

Latest disclosed valuation or deal value, US$ billions (basis varies: see labels)

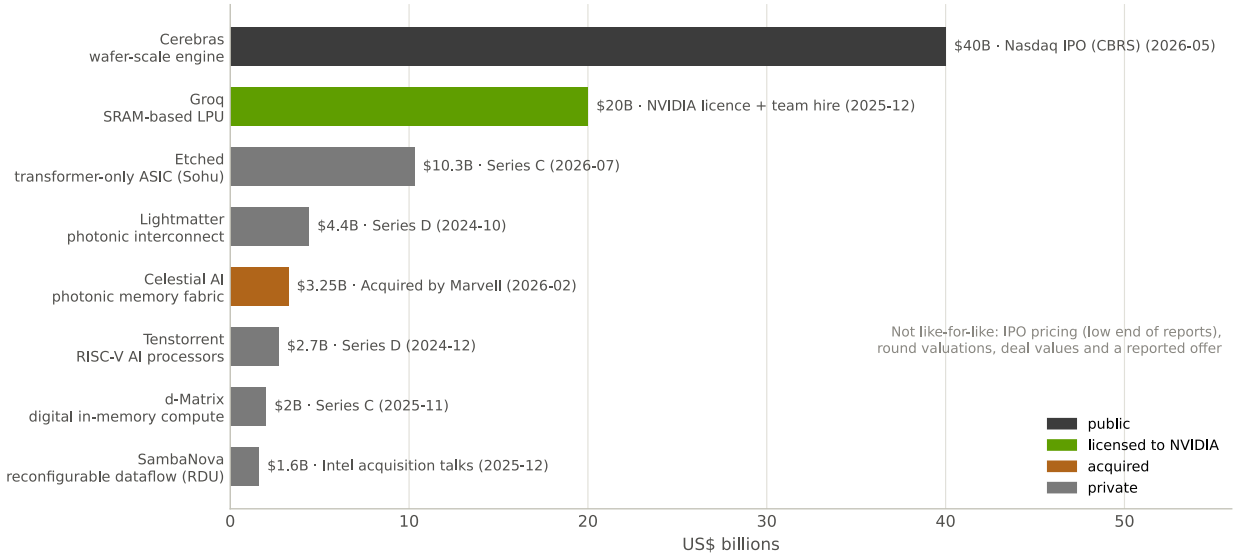


Source: data from company announcements, IPO and press reports [S2512] [S2511] [S2509] [S2513] [S2510] [S2507] ...; chart by repo · As of 2026-11-05

AI 芯片初创公司价值水平柱状图：Cerebras 2026 年 5 月上市时约 $40B（有报道称完全摊薄口径最高 ~$56B）；Groq 与英伟达 ~$20B 的授权加团队交易（2025 年 12 月）；Etched $10.3B（C 轮，2026 年 7 月，有报道）；Lightmatter $4.4B（2024 年 10 月）；Celestial AI 获美满电子 $3.25B 预付对价（2026 年 2 月）；Tenstorrent 投后 ~$2.7B（2024 年 12 月）；d-Matrix $2.0B（2025 年 11 月）；SambaNova 在已搁置的英特尔谈判中 ~$1.6B，而 2021 年为 $5B。

## 融资与收入对比

**提示**

**算例 —— 市场为 Cerebras 每一美元收入支付多少。** IPO 估值 ~$40B ÷ 2026 年收入指引 ~$885M（中值）≈ 45 倍市销率 [S2505,S15514]。英伟达 FY2026 收入为 $215.9B [S1]；以 ~$5.76T 市值（2026-10-05）计，为 ~27 倍历史市销率 [S18005]。投资者对 Cerebras 的定价，相当于假设其收入将增长 数倍，而这取决于 OpenAI 的 750 MW 分批交付能否按时到位 [S11523]。Groq ~$20B 的交易价约为其三个月前 $6.9B 融资估值的 ~2.9 倍 [S90019]：决定最高价格的是战略买家，而非风险投资市场。

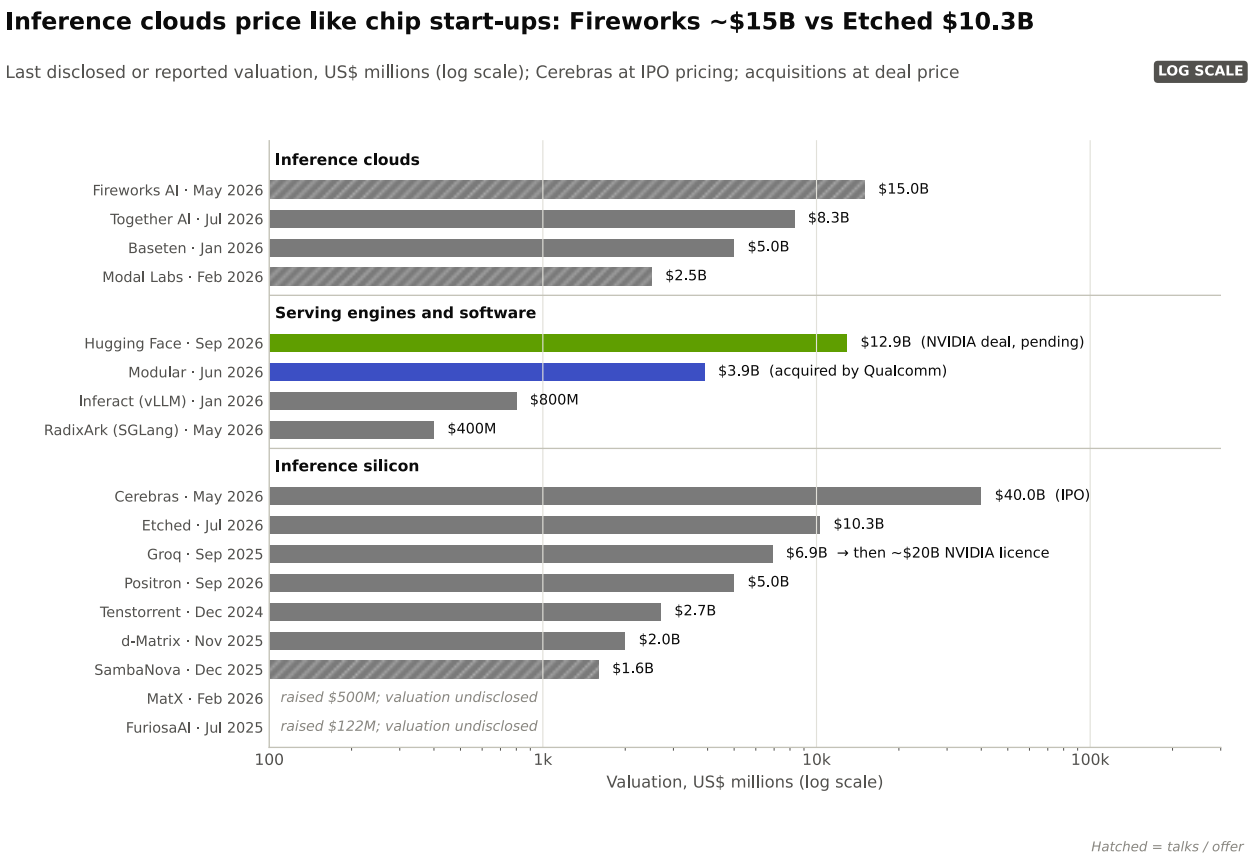


> 推理初创公司估值的对数坐标水平柱状图。推理云：Fireworks AI ~$15,000M（洽谈中，2026 年 5 月）、Together AI $8,300M（2026 年 7 月）、Baseten $5,000M（2026 年 1 月）、Modal ~$2,500M（洽谈中）。推理服务软件：Hugging Face $12,930M（英伟达于 2026 年 9 月宣布收购，待完成）、Modular $3,900M（2026 年被高通收购）、Inferact（vLLM）$800M 和 RadixArk（SGLang）$400M 种子轮估值。芯片：Cerebras 2026 年 5 月上市时 ~$40,000M、Etched $10,300M、Groq 在与英伟达达成 ~$20B 授权前为 $6,900M、Positron $5,000M、Tenstorrent ~$2,700M、d-Matrix $2,000M、SambaNova ~$1,600M（英特尔报价洽谈）；MatX 和 FuriosaAI 估值未披露。

上图还说明了第二点：推理云（Fireworks、Together、Baseten）的估值如今已与芯片初创公司相当，因为它们无需承担芯片风险即可获取 token 收入[S11514,S11516]。芯片初创公司除了卖芯片之外的另一条路，就是自营云服务，Cerebras 和 Groq 都是这样做的。

## 迄今的退出案例

| 年份 | 公司 | 退出方式 | 价值 | 买方获得了什么 | 来源 |
|---|---|---|---|---|---|
| 2019 | Habana Labs | 被英特尔收购 | ~$2B | Gaudi 产品线（后来未达目标） | S2514,S668 |
| 2024 | Graphcore | 被软银收购 | 据报道 ~$0.6B | IPU 团队；低于 ~$700M 的累计融资 | S15519,S15520 |
| 2025 | Enfabrica | 英伟达收购式招聘 + 授权 | >$0.9B | CEO、团队、内存互连技术 | S475 |
| 2025 | Untether AI | 团队被 AMD 招募 | 未披露 | 工程师，而非公司本身 | S9507 |
| 2025 | Rivos | 被 Meta 收购 | 未披露 | RISC-V CPU/加速器团队 | S4518 |
| 2025 | Groq | 英伟达授权 + 团队 | 据报道 ~$20B | LPU 技术与创始人 | S90018,S90019 |
| 2026 | Celestial AI | 被美满电子收购 | $3.25B 预付 + 对赌付款（earn-out） | 光子内存互连架构 | S2513 |
| 2026 | Cerebras | 纳斯达克 IPO | 募资 $5.55B | 公开市场股票（收购货币） | S2504,S2505 |

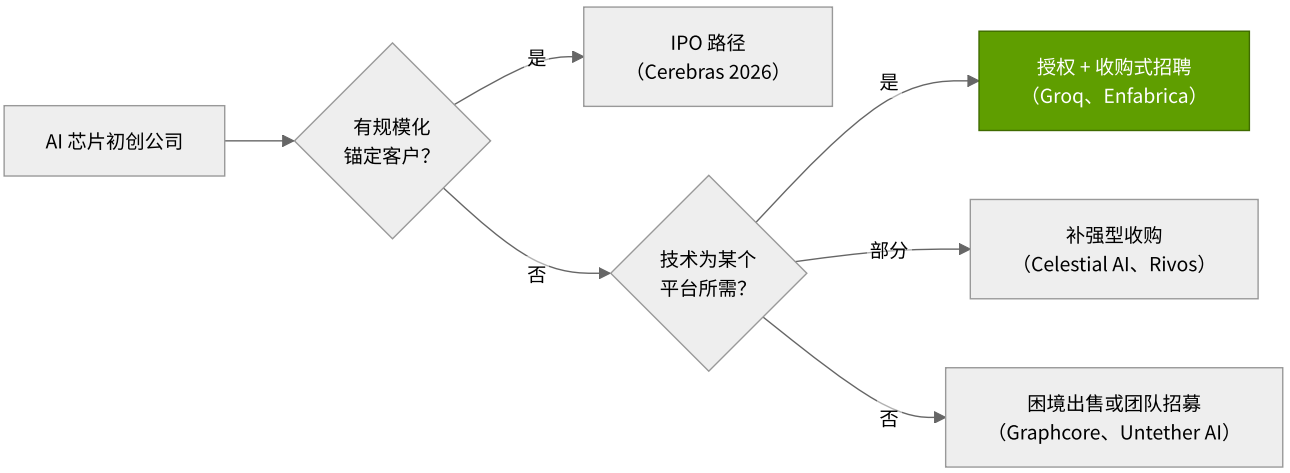


**注意**

**误区与事实：“英伟达会收购每一个威胁。”** 英伟达在这一领域的两笔最大动作，一是非独家授权（Groq），二是附带授权的收购式招聘（Enfabrica）[S90018,S475]；两者都无需对整家公司进行并购审查。大多数退出的买方是其他公司（英特尔、软银、美满电子、Meta、AMD）。真正新颖的是交易结构，而非交易频率，而且这种结构正在法庭上受到挑战[S118]。

**提示**

**算例 —— 退出案例的资本回报。** Graphcore 累计融资 ~$700M，出售价 ~$600M，约为投入资本的 ~0.86 倍，仅为其 2020 年 $2.77B 估值的 ~22%[S15519]。Celestial AI 从美满电子获得的 $3.25B 预付对价不含对赌付款[S2513]。据报道 Groq ~$20B 的交易价约为其三个月前融资估值的 ~2.9 倍[S90019]。最好与最差结局之间的价值差距 超过 30 倍，其驱动因素与其说是芯片规格，不如说是某个平台方是否急需这支团队。

## 生存几率

上图定位属于 🔴 本资料库判断，依据是上文所列的公开融资和客户披露信息。最有可能长期存续的独立公司， 要么有实验室或超大规模云厂商以吉瓦级规模采购（Cerebras–OpenAI），要么其业务不依赖于在每美元 token 数上击败 英伟达（Tenstorrent 的 IP 授权）。创始人离开后，GroqCloud 的资金跑道最不明朗。

## 分层评判：初创公司（作为整体）vs 英伟达

| 层 | 评判 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟦 路线不同 | SRAM、晶圆级、数据流和模型专用设计 S166,S168,S171 |
| 03 内存与供应 | 🟦 路线不同 | 多数避开 HBM/CoWoS；代价是每芯片容量 S167,S170 |
| 05–06 纵向扩展 / 横向扩展 | 🟥 落后 | 专有或以太网链路；没有 NVLink 级别的互连域（Groq 的 LPX 如今归英伟达所有） S114 |
| 08 系统与机架 | 🟥 落后 | CS-3 系统和小型集群；机架级部署很少 S166 |
| 09–10 软件与库 | 🟥 落后 | 厂商自有编译器；精选的模型清单 S634 |
| 11 推理服务 | 🟩 领先（速度） | 每用户每秒 token 数超越 GPU 节点（Cerebras、Groq） S634 |
| 12 云 | 🟦 路线不同 | 以 API 云（Cerebras、GroqCloud）为主，而非硬件销售 S11523 |
| 13 生态与资本 | 🟥 落后 | 客户集中；~$40B 已是独立公司中的最高估值 S2505 |

## 它们最有力的论据，以及差距缩小了多少

**最有力的论据：** 推理正在成为更大的工作负载，而用户愿意为智能体和编程工具中的速度付费；在 这一维度上，SRAM 和晶圆级设计如今胜过 GPU 节点 S634。OpenAI 与 Cerebras 的 750 MW 交易证明， 前沿实验室愿意为此买单 S11523。

**差距缩小了多少：** 在交互速度上，已完全追平；在单 token 成本和软件广度上，收窄有限；在规模上，Cerebras 已签约的 ~600 MW 颇具意义，但只是英伟达出货量的一小部分 [S15515]。本资料库的评估矩阵给 Cerebras 打 2.8 分、Groq 打 2.2 分（满分 5），英伟达为 4.7（索引）。

> **注**
>
> 🐂 **看多观点（对英伟达而言）。** 英伟达买下了最好的 SRAM 设计，并在一年内以 LPX 形式出货；Rubin NVL72 加 LPX 覆盖了批处理和超低延迟两个层级，留给初创公司的细分市场正在收缩 [S90003,S114]。

> **注意**
>
> 🐻 **看空观点（对英伟达而言）。** 初创公司的资金比 2021 年以来任何时候都更充裕，已上市的 Cerebras 可随时 进行股权融资，而开源推理服务引擎（vLLM、SGLang）可运行于七个硬件家族，因此 推理的切换成本持续下降 [S2504,S15516,S580]。

## 🎯 企业发展视角

1. Groq 以授权加团队的形式，按其最近一轮估值 ~2.9 倍的价格出售 [S90019]；Graphcore 的售价则低于累计融资额 [S15519]。两者 的分野在于什么：一个有付费用户的成熟云服务、一项平台所需的技术，还是时机？
2. 2026 年估值上涨 2–5 倍，而收入依然很小（Cerebras 约为 2026 年销售额的 ~45 倍）。战略收购方应如何权衡 收购一家初创公司的设计，与像英伟达那样获取授权或招募其团队这两种选择？
3. 哪些押注仍独立于英伟达的路线图之外？晶圆级和存内计算不在其中；SRAM 解码如今已在其中 （LPX）[S90003]。
4. Tenstorrent 在销售芯片的同时授权 RISC-V 和 AI IP [S169,S15516]。对推理初创公司而言，IP 授权是否是比芯片 更具防御性的业务？天然的被授权方是谁？
5. 授权加收购式招聘的交易避开了全面的并购审查，却招致员工诉讼 [S118]。监管机构和 法院会如何对待下一笔此类交易？这是否会改变交易结构的选择？

# 高通：第二次进军数据中心，对照英伟达的全景图

跨层专题 15 · 竞争格局 · 阅读约 16 分钟 · 最后核实：2026-11-05

> **重要**
>
> **仅基于公开信息。** 本页所有内容均来自高通（Qualcomm）的公开公告、监管文件和媒体 报道，并已逐条标注出处。本页陈述事实与待解问题；不提供任何建议，也未使用任何内部 信息。

## ⚡ 要点速览

- **这是高通第二次进军数据中心。** 48 核的 Centriq 2400 于 2017 年 11 月发布；约一年之内， 该部门人员即从 ~1,000 人削减至 ~50 人 [S4542,S4543,S4544]。
- **此次重建主要依靠收购。** 收购 NUVIA（$1.4B， 2021 年）获取 CPU 核心；收购 Alphawave（~$2.4B，2025-12-18 完成交割）获取 SerDes 与互连能力；收购 Ventana（RISC-V，2025 年 12 月，金额未披露）；收购 Modular（$3.9B， 2026-07-29 完成交割）获取可跨硬件移植的 AI 软件 [S4538,S4513,S4514,S4512,S9511]。
- **加速器押注内存容量，而非 HBM。** AI200（2026 年）每张卡配备 768 GB LPDDR，部署于 160 kW 液冷机架；AI250（2027 年）加入近存计算；Dragonfly AI300 （2028 年）宣称内存带宽为 AI200 的 54 倍，并采用 UALink 和 ESUN 纵向扩展（scale-up） [S173,S90060]。截至 2026-11-05，尚无 AI200 批量出货的 公开信息 🔴 [S90028]。
- **CPU 既是与英伟达（NVIDIA）的合作棋，也是独立棋。** 高通于 2025 年 5 月以服务器 CPU 身份加入 NVLink Fusion [S90031]；Dragonfly C1000（>250 个 Oryon 核心）的首个客户是 Meta，自 2028 年下半年起部署 [S90056,S90058]。
- **客户如今已落在纸面上。** HUMAIN 规划了 200 MW [S90030]。AWS 签署了一项多代合作协议，涵盖定制推理 芯片和 1.6T 光学器件，并附带一份最多可认购 25M 股高通股票的认股权证，随着 AWS 在 ~10 年内最多采购 $60B 而逐步归属 🟢 [S15510,S15509]。两份超大规模云厂商定制芯片合同的金额各超过 $1B [S15511]。
- **目标是 FY2027 实现 $5B 数据中心收入，FY2029 达到 $15B** [S15512,S90059]。FY2029 目标约为 英伟达 FY2026 数据中心收入的 ~8% [S1]。
- **相对英伟达的定位图谱：** 在 CPU 上是合作伙伴（NVLink Fusion），在推理加速器和纵向扩展标准上是竞争对手 （UALink/ESUN），在互连 IP 和可移植软件上是互补者。

**Qualcomm's datacenter push: 11 public moves since May 2025; accelerator volume is a 2026–28 target**

Public announcements only, by lane; filled = shipped / closed / signed, hollow = announced roadmap, × = exit

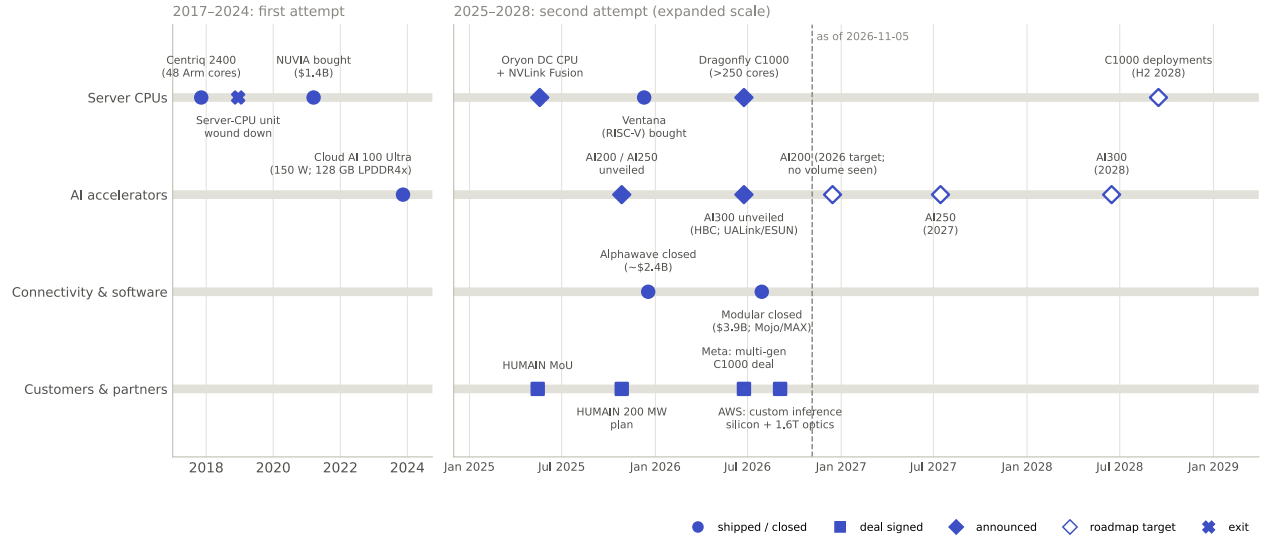


*Public information only; dates of roadmap items are company targets*

Source: data from Qualcomm releases, filings and press coverage (public information only) [S4542] [S4543] [S4544] [S4538] [S172] [S90031] …; chart by repo · As of 2026-11-05

> 高通公开数据中心动作的时间线，分为四条泳道。2025 年之前：Centriq 2400 服务器 CPU（2017 年 11 月），该部门收缩（2018 年），以 $1.4B 收购 NUVIA（2021 年），以及 Cloud AI 100 Ultra 加速卡（2023 年）。2025 年 5 月以来：NVLink Fusion CPU 合作与 HUMAIN 谅解备忘录（2025 年 5 月）；发布 AI200 和 AI250，同时公布 HUMAIN 200 MW 规划（2025 年 10 月）；收购 Ventana（RISC-V）和 Alphawave（~$2.4B）（2025 年 12 月）；投资者日发布面向 Meta 的 Dragonfly C1000 CPU、AI300 加速器以及 Modular 交易（2026 年 6 月）；Modular 以 $3.9B 完成交割（2026 年 7 月）；与 AWS 达成多代定制推理芯片及 1.6T 光学器件协议，并以 $4B 认股权证作为支撑（2026 年 9 月）。路线图：AI200 于 2026 年推出（截至 2026 年 11 月未确认批量出货），AI250 于 2027 年推出，AI300 和 C1000 于 2028 年部署。

## 第一次尝试的启示（Centriq，2017–2018）

Centriq 2400 是一款可信的芯片：采用三星 10 nm 工艺、48 个定制 Arm 核心，发布价 $1,995 [S4542]。它进入 市场时恰逢高通削减 ~$1B 成本，而据报道退出决定是在发布约七个月后作出的 [S4543]。该 部门从 ~1,000 人缩减至 ~50 人，相关 IP 则在一家中国合资企业中得以延续 [S4544]。

> **提示**
>
> **算例 —— 历史记录对尽职调查的启示。** 从发布（2017-11-08）到有报道的退出决定 （2018 年 5 月）~6–7 个月 [S4542,S4543]；员工从 ~1,000 人削减至 ~50 人，降幅 95% [S4544]。服务器 CPU 需要在云客户处经历多年 认证，因此一个以季度计的项目很难走到量产。此次公开可见的不同之处在于：量产之前即有锚定客户（HUMAIN、Meta、AWS），以收购获得 IP 而非仅靠内部自研，以及明确公布的 多年期目标 [S90030,S90058,S15510,S15512]。这些差异能否经受住下行周期的考验，是历史记录提出的问题， 而非它能回答的问题。

## 加速器产品线：从 AI 100 到 AI300

高通的推理加速器以牺牲内存带宽为代价换取内存容量和能效，与英伟达的 HBM GPU 处于相反的象限（内存墙）。

| 产品 | 年份 | 内存 | 带宽 | 功耗 / 散热 | 纵向扩展 | 状态 | 来源 |
|---|---|---|---|---|---|---|---|
| Cloud AI 100 Ultra | 2023 | 128 GB LPDDR4x | 0.548 TB/s | 150 W 加速卡 | PCIe | 已出货 | S172 |
| AI200 | 2026 | 每卡 768 GB LPDDR | 未披露 | 160 kW 机架，直接液冷 | PCIe；以太网横向扩展 | 🔴 未见批量出货 | S173,S90029 |

| 产品 | 年份 | 内存 | 带宽 | 功耗 / 散热 | 纵向扩展 | 状态 | 来源 |
|---|---|---|---|---|---|---|---|
| AI250 | 2027 | LPDDR + 近存计算 | 有效带宽较 AI200 提升“>10×”（宣称） | 机架级 | PCIe；以太网 | 路线图 | S173 |
| Dragonfly AI300 | 2028 | High Bandwidth Compute 第二代 | AI200 的“54×”（宣称） | 机架级 | UALink、ESUN | 路线图 | S90060 |
| NVIDIA Rubin（参照） | 2026 | 288 GB HBM4 | 19.2 TB/s | 液冷 NVL72 机架 | NVLink 6，72 个封装 | 爬坡中 | S90006,S90009 |

**提示**

**算例 —— 以一个模型看容量与带宽。** 一个 FP8 精度的 70B 参数模型需要 ~70 GB 权重。 解码（decode）时每生成一个 token 都要重新读取全部权重，因此单用户速度上限为带宽 ÷ 权重：Cloud AI 100 Ultra 上为 0.548 TB/s ÷ 70 GB ≈ 8 tokens/s，而 Rubin GPU 上为 19.2 TB/s ÷ 70 GB ≈ 274 [S172,S90006]。批处理多个用户可以分摊 每次权重读取，因此单卡总吞吐量在低功耗下仍可相当可观；LPDDR 买不到的是每用户的高速度。 每张 AI200 卡的 768 GB 可容纳一个 ~600B 参数的 FP8 模型，并为 KV 缓存留出 ~170 GB， 这是任何单颗 HBM GPU 都做不到的（Rubin 为 288 GB）。悬而未决的问题是 AI200 的带宽——高通尚未披露，因此 AI300 宣称的 54 倍 目前还无法换算成 TB/s。

**An LPU re-reads its 0.5 GB of SRAM ~300,000×/s; Rubin re-reads 288 GB of HBM4 ~67×/s**

Memory capacity (GB) vs bandwidth (TB/s) per chip or card; diagonals = full memory reads per second, the decode-step ceiling

LOG SCALE

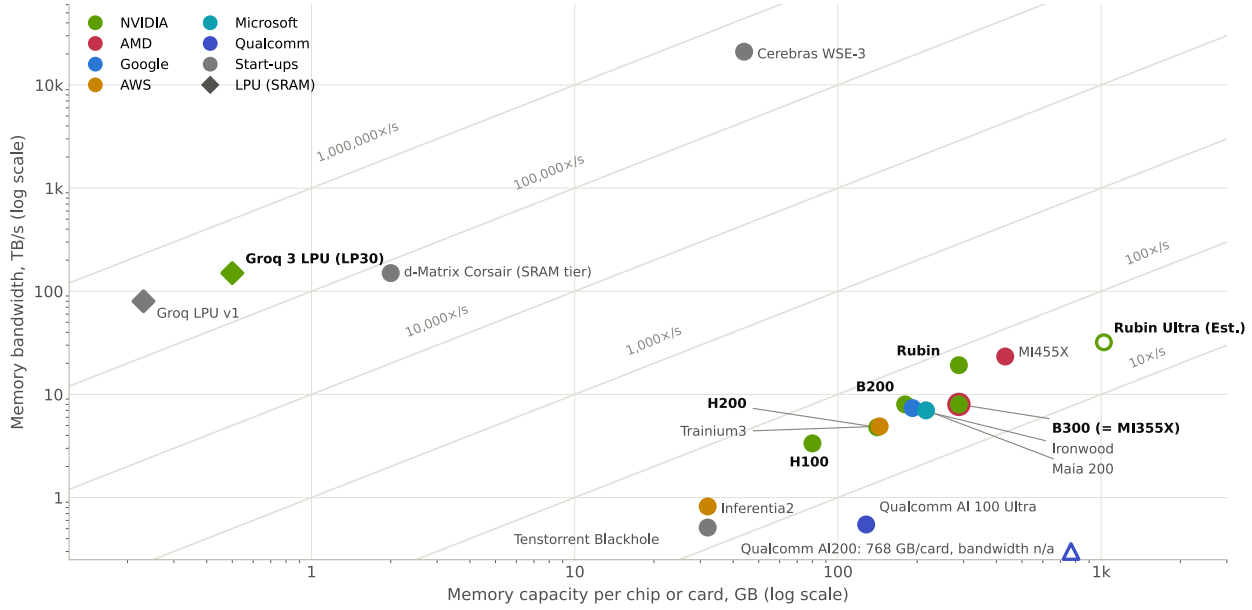


*Hollow = roadmap / Est.*

Source: data from vendor specifications [S33002] [S35011] [S35013] [S32002] [S33003] [S35014] ...; chart by repo · As of 2026-11-05

推理芯片按内存容量与带宽分布的双对数散点图。SRAM 设计位于左上方：英伟达的 Groq 3 LPU 为 0.5 GB、150 TB/s（每秒约 300,000 次全量读取），Groq LPU v1 为 0.23 GB、80 TB/s，d-Matrix Corsair 为 2 GB、150 TB/s，Cerebras WSE-3 为 44 GB、21,000 TB/s。HBM GPU 与云厂商 ASIC 集中在中部，容量 80–432 GB、带宽 3–23 TB/s（每秒 25–70 次读取）：Rubin 288 GB、19.2 TB/s，MI455X 432 GB、23.3 TB/s，Ironwood 192 GB、7.4 TB/s，Maia 200 216 GB、7 TB/s。LPDDR 加速卡位于右下方：高通 AI 100 Ultra 128 GB、0.548 TB/s（每秒约 4 次读取），以及每卡 768 GB 的 AI200（带宽未披露）。

**🔧 技术细节：为何选择 LPDDR，以及“近存计算”和 HBC 改变了什么**

LPDDR 是手机和笔记本电脑使用的内存：每 GB 成本低、功耗低，由多家厂商大规模生产，而且不需要 CoWoS 中介层。它通过较窄的通道连接处理器，因此每 GB 带宽较低。HBM 则将 DRAM 裸片堆叠起来， 以数千个硅通孔连接并紧邻 GPU 放置：Rubin 的 19.2 TB/s 约为 AI 100 Ultra 0.548 TB/s 的 ~35 倍 [S90006,S172]，但 HBM 供应紧张且价格昂贵（HBM 详解）。高通的 AI250 将部分 计算移到内存旁边，从而减少经由窄通道传输的数据量，这也是它报出的是*有效*带宽提升的原因 [S173]。AI300 中的高带宽计算（High Bandwidth Compute）是高通沿这条

路径迈出的下一步 S90060。正因如此，本资料库在内存与供应维度上将高通评为“路线不同”：它绕开了 HBM 和 CoWoS 的配额之争，而英伟达在 2026 年 CoWoS 晶圆中占 ~60%（估计）S379。

## CPU 产品线：从 Centriq 到 Dragonfly C1000

两条 CPU 路线并行推进。第一条是合作路线：基于 Oryon 的服务器 CPU 通过 NVLink Fusion 连接英伟达 GPU，于 Computex 2025 宣布 S90031,S4516。第二条是独立路线： Dragonfly C1000，一款拥有 250 个以上核心的小芯片（chiplet）CPU，目标主频 >5 GHz，支持 PCIe Gen 7 和 CXL，定位为面向智能体（agentic）工作负载的 AI 头节点；Meta 是首个公开点名的客户，自 2028 年下半年起部署 S90056,S90058。此前一则未经证实的报道描述了一款支持 NVLink Fusion 的 80 核产品 S4515。作为参照， 英伟达的 Vera 有 88 个核心，AMD 的 EPYC Venice 最多 256 个 S100,S144；来自 Ventana 的 RISC-V 工作与 Oryon 并行推进 S4512（CPU 竞争）。

> **提示**
>
> **算例 —— 核心数与时间表。** 250 个以上核心约为 Vera 88 核的 ~2.8 倍，与 EPYC Venice 的 256 核持平 S100,S144。Venice 约从 2026 年第三季度起随 AMD 的 Helios 机架出货，Vera 则从 2026 年第三季度起随 Vera Rubin NVL72 出货 S90020,S90009；C1000 自 2028 年下半年起部署 S90058，因此它将面对这些厂商的下一代产品。核心数能让一颗 CPU 进入评估；而决定头节点胜负的是每核内存带宽、GPU 链路和软件生态 （AI 为何需要 CPU）。

## 互连、软件与定制芯片：Alphawave、Modular、AWS

**Alphawave** 带来了 SerDes、小芯片和光互连 IP，这正是定制 ASIC 设计服务商视为 护城河的能力（定制 ASIC 设计服务商）S4514。**Modular** 带来了 Mojo 和 MAX 推理引擎，这是一套可跨硬件移植的软件栈；Mojo 已于 2026 年 8 月以 Apache 2.0 协议开源 S9511,S9512。本资料库第 09 层的分析将可移植软件视为侵蚀 CUDA 的主要途径之一 （CUDA 竞争）。

**Qualcomm's ~$3.9B for Modular: 5.6× Run:ai, 2.4× Modular's 2025 valuation**

Disclosed or reported prices of AI-software acquisitions, US$ M; gray = Modular funding reference points

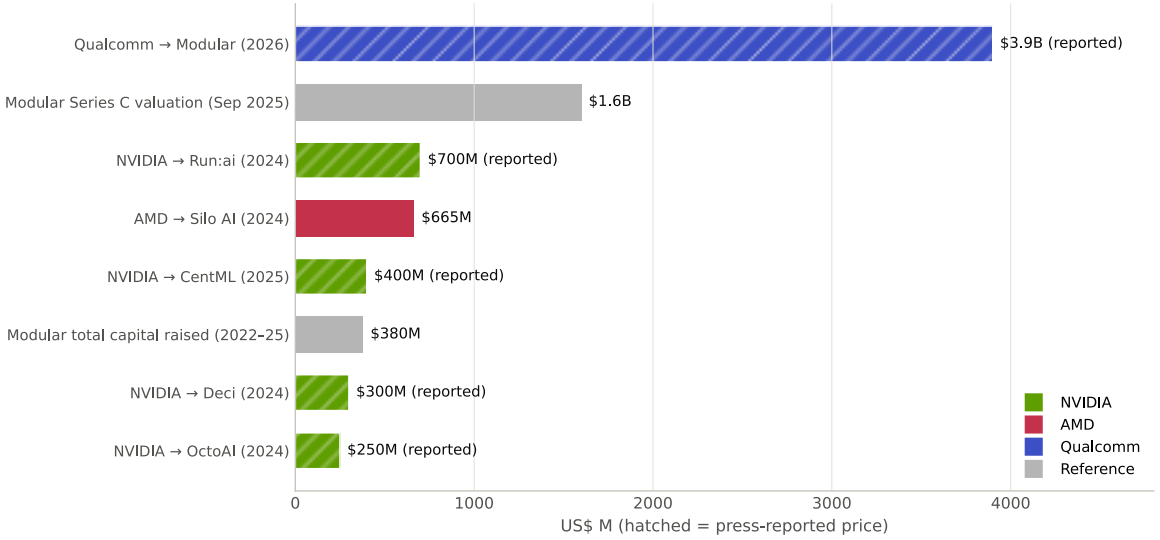


Source: data from company announcements and press reports [S476] [S479] [S478] [S9506] [S90057] [S9511] ...; chart by repo · As of 2026-11-05

AI 软件交易金额水平柱状图：高通-Modular 约 $3,900M（2026 年）、英伟达-Run:ai 约 $700M（2024 年）、AMD-Silo AI $665M（2024 年）、英伟达-CentML 最多约 $400M（2025 年）、英伟达-Deci 约 $300M（2024 年）以及英伟达-OctoAI 约 $250M（2024 年）。作为参照，Modular 在 2025 年 9 月的 C 轮融资中估值为 $1,600M，累计融资 $380M，因此高通支付的价格约为其最近一轮私募估值的 2.4 倍、投入资本的约 10 倍。

**AWS** 是最重要的公开客户信号。高通与 AWS 同意跨代共同开发定制 AI 推理芯片， 以及最高 1.6T 的光互连，预计从高通 2027 财年第一季度起产生收入 [S15509,S15510]。

**提示**

**算例 —— 解读按采购额归属的认股权证。** 该认股权证涵盖最多 25M 股，行权价 $161.26，对应行权总值 ~$4.0B， 随亚马逊在 2036 年前最多采购 $60B 产品而逐步归属；其中 3.75M 股已因初始承诺而归属 [S15510]。即 $60B ÷ 25M = 每归属一股对应 $2,400 采购额。若股价高于行权价 $40， 则每股对亚马逊价值 $40，约为对应采购额的 ~1.7%（🔴 示意性股价）。若归属是线性的 （未披露），3.75M 股对应的初始承诺为 ~$9B（🔴 本资料库测算）。从结构上看，这是一种以股权支付的 批量返利，类似 AMD 给 OpenAI 的认股权证，但行权价为正值 [S13506] （按采购额归属的认股权证）。

## 逐层图谱：合作、竞争、互补

| 英伟达技术栈层 | 高通的公开布局 | 与英伟达的关系 | 相对英伟达的评判 | 来源 |
|---|---|---|---|---|
| 02 加速器芯片 | Cloud AI 100 Ultra；AI200/AI250/AI300 | 竞争（推理） | 🟦 路线不同：LPDDR 推理 NPU | S172,S173,S90060 |
| 03 内存与供应 | 以 LPDDR 替代 HBM/CoWoS | 竞争（供应独立） | 🟦 路线不同：每卡 768 GB，带宽低 | S173 |
| 04 CPU | 通过 NVLink Fusion 的 Oryon CPU；Dragonfly C1000 | 合作兼竞争 | 🟥 落后：2028 年前不出货 | S90031,S90056 |
| 05 纵向扩展 | AI300 采用 UALink 和 ESUN | 竞争（对立标准） | 🟥 落后：目前为 PCIe | S90060,S173 |
| 06 横向扩展与光学 | Alphawave IP；AWS 1.6T 光学器件 | 互补（向多方销售） | 🟥 交换领域落后；🔴 IP 供应商角色 | S4514,S15509 |
| 08 系统与机架 | 160 kW AI200 机架 | 竞争 | 🟥 落后：首批机架为 2026 年目标 | S173 |

| 英伟达技术栈层 | 高通的公开布局 | 与英伟达的关系 | 相对英伟达的评判 | 来源 |
|---|---|---|---|---|
| 09–11 软件 | 集成 vLLM 的 Cloud AI SDK；Modular（Mojo/MAX） | 互补（可移植性） | 🟦 路线不同：可移植软件栈 | S596,S9511 |
| 12 云 | 无云服务 | — | 🟥 落后 | S173 |
| 13 生态与资本 | HUMAIN、Meta、AWS；$5B / $15B 目标 | 争夺超大规模云厂商预算 | 🟥 落后：早期客户 | S90030,S90058,S15512 |

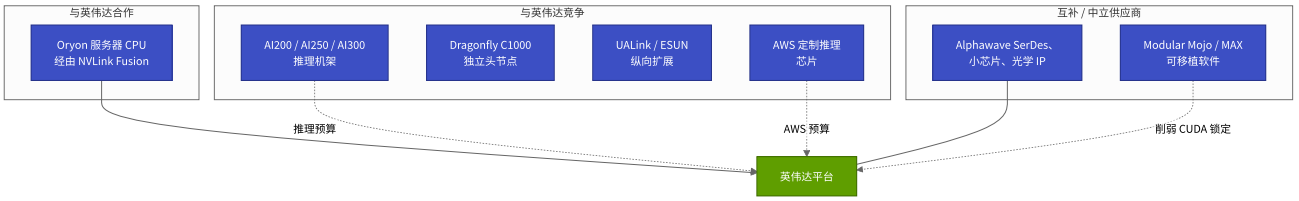


### Qualcomm averages 2.7 of 5 vs NVIDIA's 4.7; it out-scores NVIDIA only on claimed cost per token

Repo scores 0-5 (analyst judgement, sourced): capability radar (left) and per-layer score with verdict vs NVIDIA (right)

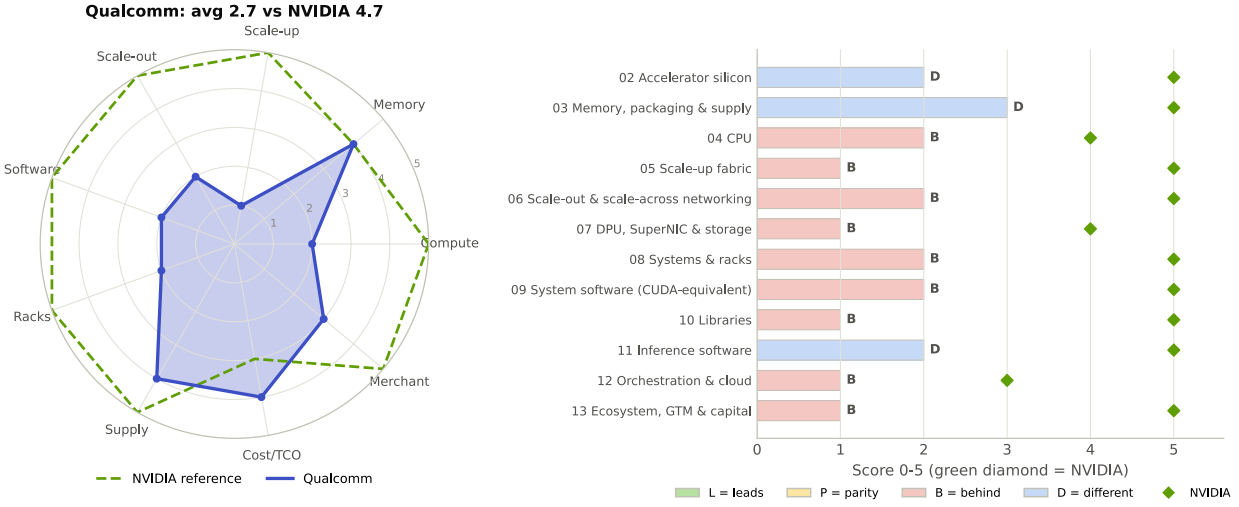


*Analyst judgement (speculative); L/P/B/D = leads / parity / behind / different approach*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S379] [S412] [S468] [S630] ...; chart by repo · As of 2026-11-05

> 双子图。左：高通与英伟达在九个能力维度上的雷达图，平均得分分别为 2.7 和 4.7（满分 5）（计算 2 对 5；内存 4 对 4；纵向扩展 1 对 5；横向扩展 2 对 5；软件 2 对 5；机架 2 对 5；供应 4 对 5；成本/TCO 4 对 3；商用化 3 对 5）。右：高通在英伟达 12 个技术栈层级中各层的得分及评判：落后 9 层、路线不同 3 层。仅基于公开信息：高通基于 LPDDR 的设计在内存容量以及摆脱 CoWoS 和 HBM 依赖方面得分，其成本优势为厂商宣称，纵向扩展、软件和机架尚处早期。

## 放在大背景下看目标

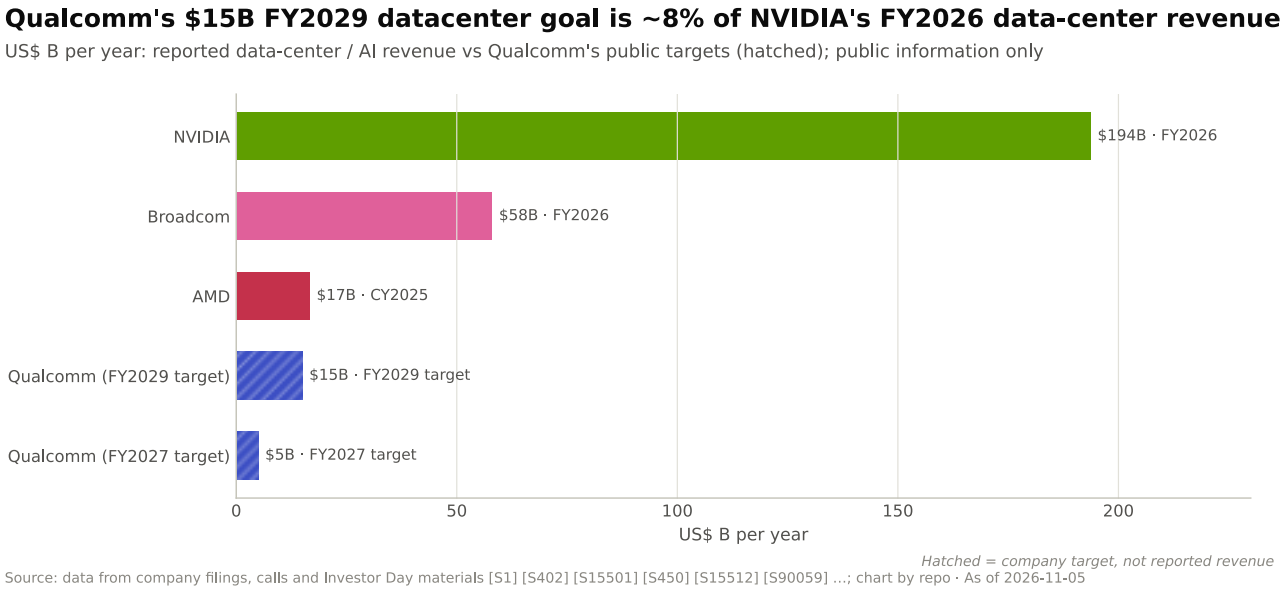


水平柱状图：英伟达 FY2026 数据中心收入 $193.7B；博通 FY2026 AI 半导体收入约 $58B；AMD 2025 年数据中心收入约 $16.7B；高通公开目标为 FY2029 数据中心收入 $15B、FY2027 为 $5B（斜线填充）。FY2029 目标约相当于英伟达 FY2026 数据中心收入的 8%。

**提示**

**算例 —— 衡量 $15B 目标的体量。** 高通 FY2026 收入为 $43.1B [S15513]。若到 FY2029 数据中心业务线达到 $15B， 将相当于该基数的 ~35%、英伟达 FY2026 数据中心收入（$193.7B）的 ~7.7%，并大致相当于 AMD 2025 年 数据中心收入（~$16.7B）[S1,S450]。FY2027 阶段目标（$5B）中至少有 $1B 来自两家超大规模云厂商 定制芯片客户 [S15511]，因此近期目标中商用加速器的占比低于 标题数字所显示的水平。

## 它们最有力的论据，以及差距缩小了多少

**最有力的公开论据**在于：推理对成本和功耗的重视程度高于峰值速度，而高通的 LPDDR 设计、 150 W 级的产品积淀以及不依赖 HBM 和 CoWoS 的供应独立性，正是瞄准了这一点 [S172,S173]。与 AWS 和 Meta 的 协议表明超大规模买家已经参与进来 [S15510,S90058]。

**差距缩小了多少：** 就已出货的数据中心加速器而言，迄今收窄有限；截至 2026-11-05，尚无 AI200 批量出货、MLPerf 数据中心成绩或 InferenceX 成绩的公开信息 🔴 [S90028,S602,S620]。就客户与 IP 而言，则比 2018 年以来任何时候都更进一步（见上方时间线）。本资料库的评估矩阵给高通的评分为 2.7（满分 5），英伟达为 4.7（🔴 分析师判断；见上方能力图）。

**注**

🐂 **看多观点（对英伟达而言）。** 高通的 CPU 接入 NVLink Fusion，因此其部分努力扩展的是英伟达的机架， 而非取而代之 [S90031]；英伟达自身的推理产品线如今已涵盖 HBM GPU 和基于 SRAM 的 Groq 3 LPX 机架，覆盖了成本和延迟两个层级 [S114,S90003]。

**注意**

🐻 **看空观点（对英伟达而言）。** 一家 FY2026 收入达 $43.1B 的公司 [S15513] 如今已拥有超大规模云厂商定制芯片协议（AWS）、 CPU 协议（Meta）、可移植软件（Modular）以及 UALink/ESUN 纵向扩展，全部瞄准推理预算——而这正是 英伟达软件优势最不重要的领域 [S15510,S90058,S9511,S90060]。

## 企业发展团队会问的问题

| 问题 | 为何重要 | 迄今的公开证据 |
|---|---|---|
| AI200 何时批量出货？除 HUMAIN 外还会出货给谁？ | 关系到 FY2027 $5B 目标的收入确认时点 | 2026 年目标；尚无出货确认 S173,S90028 |
| AI200 的内存带宽和实测 tokens/s 是多少？ | 决定其能服务哪些模型和延迟层级 | 未披露；无 MLPerf/InferenceX 成绩 S602,S620 |
| AWS 的 $60B 上限中有多少会转化为确定订单？ | 认股权证只随采购而归属 | 25M 股中已有 3.75M 股因初始承诺而归属 S15510 |
| NVLink Fusion CPU 会先于 C1000 出货吗？ | 合作路线与独立路线的优先级 | 尚无公开出货日期 S90031,S90056 |
| Modular 的工具如何覆盖高通芯片以及竞争对手的芯片？ | 可移植性惠及所有人，包括竞争对手 | Mojo 于 2026 年 8 月开源 S9512 |
| UALink/ESUN 的时间表与 2028 年的 AI300 如何衔接？ | 纵向扩展标准的成熟度 | UALink 产品预计 2027 年推出 S90051 |

## 🎯 企业发展视角

1. 高通同时是合作伙伴（NVLink Fusion CPU）、竞争对手（AI200–AI300、C1000、AWS 芯片）和中立供应商 （Alphawave IP、Mojo）。哪些公开证据能表明到 FY2029 哪种角色贡献的收入最多？
2. 定制芯片合同（两家超大规模云厂商，各超过 $1B）和 AWS 协议与博通的模式相似。按公开数据，NRE、 单颗利润率和认股权证摊薄与商用 AI200 产品线相比如何？
3. LPDDR 容量路线如今与英特尔的 Crescent Island 以及初创公司的 SRAM/HBM 混合方案形成交集。在这一细分市场中， 靠什么建立持久地位：内存、软件、功耗还是客户渠道？
4. Modular 的收购价为 $3.9B，约为其 $1.6B C 轮估值的 ~2.4 倍 S9511,S9510。哪些里程碑（框架采用率、第三方 硬件支持、开发者数量）能够表明该软件正在推动工作负载迁移？
5. Centriq 在发布后 ~6 个月即告退出 S4543。哪些公开披露（出货量、客户数量、分部 报告）将表明此次尝试是否越过了上一次止步的阶段？

# 中国：华为昇腾、寒武纪与受保护的国内市场

跨层专题 15 · 竞争格局 · 阅读约 16 分钟 · 最后核实：2026-11-05

## ⚡ 要点速览

- **对英伟达（NVIDIA）而言，中国如今已是一个独立的市场。** 中国占英伟达收入的比重从 FY2022 的 26.4% 降至 FY2026 的 9.1%， FY2027 各季度为 5.6–8.2%；公司指引已剔除中国数据中心计算业务，而据报道，在缴纳 25% 分成的许可证下销售的 H200 不到 Q2 FY2027 数据中心收入的 1% 🟡 S2,S401,S90070,S90069,S90032,S26009。
- **华为是主要受益者。** 华为预计 2026 年 AI 芯片收入 ~$12B，较 2025 年的 ~$7.5B 增长 ~60%， 并计划今年出货 ~750k 颗昇腾（Ascend）950PR 芯片 🟡 S15527。
- **按单芯片计，华为仍然落后。** 昇腾 950 标称 1 PFLOPS FP8，是中国此前可采购的 H20 的 ~3.4 倍，但只有 获许可的 H200 的一半左右；即便是 2028 年的昇腾 970（4 PFLOPS），也仍落后于 2026 年的 Rubin（17.5）~4.4 倍 S163,S26003,S90006。
- **华为以规模和电力作为应对。** CloudMatrix 384 提供 ~300 PF 稠密 BF16 算力，而 GB200 NVL72 为 ~180 PF， 但功耗为 559 kW 对 145 kW（估计， SemiAnalysis） S340；8,192 芯片的 Atlas 950 SuperPoD（8 EF FP8）计划于 2026 年第四季度推出，华为 称其已大规模商用；但缺乏独立证实 🔴 S341,S567,S90042。
- **供应是硬约束。** 据估计，中芯国际（SMIC）7 nm 级产能为每月 ~45–60k 片晶圆（SemiAnalysis），实际产出不足 20k 片（日经），而国产高带宽内存（HBM）（长鑫存储 CXMT 的 HBM3E）仅处于小规模阶段，目标在 2027 年上量 S15528,S15529,S3516。
- **国内上市阵营正快速成长。** 2026 年上半年，寒武纪（Cambricon）收入增长 108% 至 6.0B 元，摩尔线程（Moore Threads）增长 147% 至 1.7B 元，海光（Hygon）增长 67% 至 9.1B 元（含 CPU）；壁仞（Biren）、沐曦（MetaX）和摩尔线程已于 2025–26 年上市， 百度旗下的昆仑芯（Kunlunxin）正在筹备 IPO S15522,S15523,S15525,S15541,S15540,S15537。
- **围绕昇腾的软件生态正在成形：** DeepSeek V4（2026 年 4 月）在 V4-Flash 的部分训练中使用了昇腾，并针对推理适配了 昇腾超节点（SuperNode） S90079,S90080；华为于 2025 年 8 月开源了 CANN S10537。

**Ascend 950: ~3.4× an H20's FP8 compute, ~half an H200's; Ascend 970 (2028) trails Rubin ~4.4×**

Per chip: dense TFLOPS (FP8; FP16 where no FP8, log scale), memory bandwidth (TB/s) and capacity (GB); hatched = not yet shipping

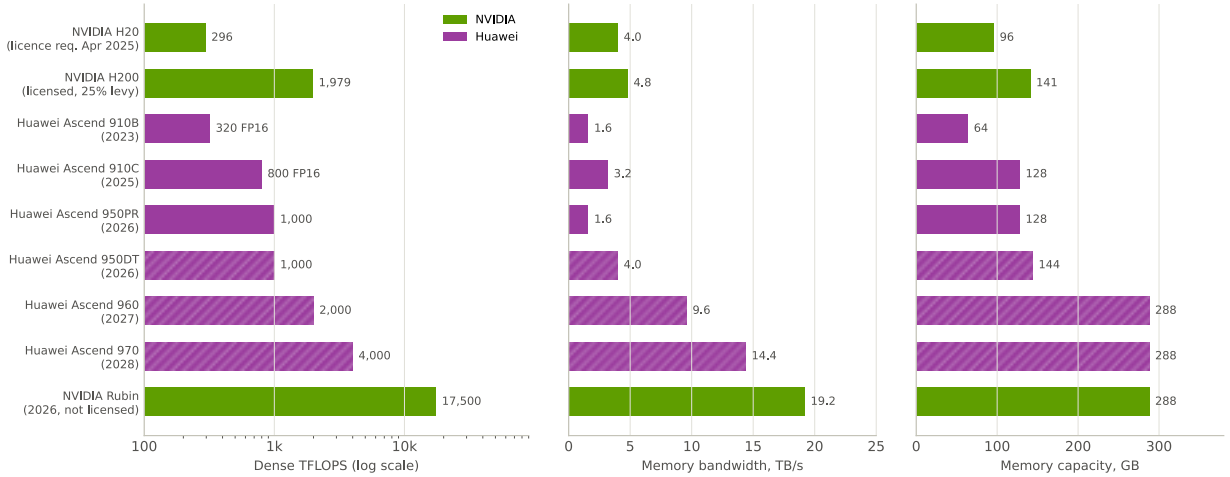


*Hatched = announced / roadmap; Ascend dense-vs-sparse basis not always stated by Huawei*

Source: data from Huawei Connect 2025 roadmap, NVIDIA specs, SemiAnalysis H20 leak [S163] [S164] [S26003] [S32002] [S90006] [S90042]; chart by repo · As of 2026-11-05

> 三幅子图的柱状图，将华为昇腾芯片与中国可以或曾经可以采购的英伟达产品进行比较。稠密算力：H20 296 TFLOPS FP8，H200 1979，昇腾 910B 320 FP16，910C 800 FP16，950PR 与 950DT 1000 FP8，960 2000，970 4000（2028 年），Rubin 17500。内存带宽：H20 4.0 TB/s，H200 4.8，910C 3.2，950PR 1.6，950DT 4.0，960 9.6，970 14.4，Rubin 19.2。容量：H20 96 GB，H200 141，950PR 128，950DT 144，960 与 970 288，Rubin 288。华为的路线图到 2027 年弥合了容量差距，但未能弥合算力或带宽差距。

## 为何中国是一个独立的市场

这堵墙是两国政府共同筑起的。华盛顿设定了 TPP 门槛，限制了英伟达可销售的产品；而当这些受限产品进入市场后，北京又引导买家转向国产芯片。完整的历史以及对英伟达收入的 影响，见 CS6 · 中国出口管制：H20 及之后。

**出口管制的演变，2022-2026**

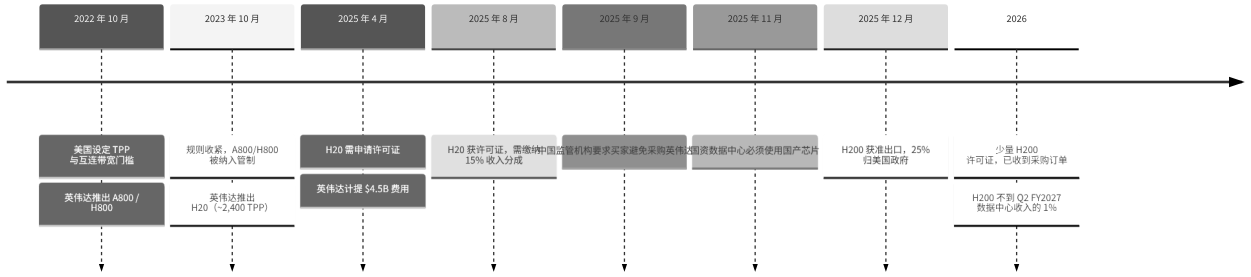

### H20 was cut to ~2,400 TPP, half the 4,800 licence line and 1/7 of H200, but kept 4 TB/s HBM

TPP (dense TFLOPS × bit width) per package; label = TPP · HBM bandwidth · China status; hatched = reported/leaked

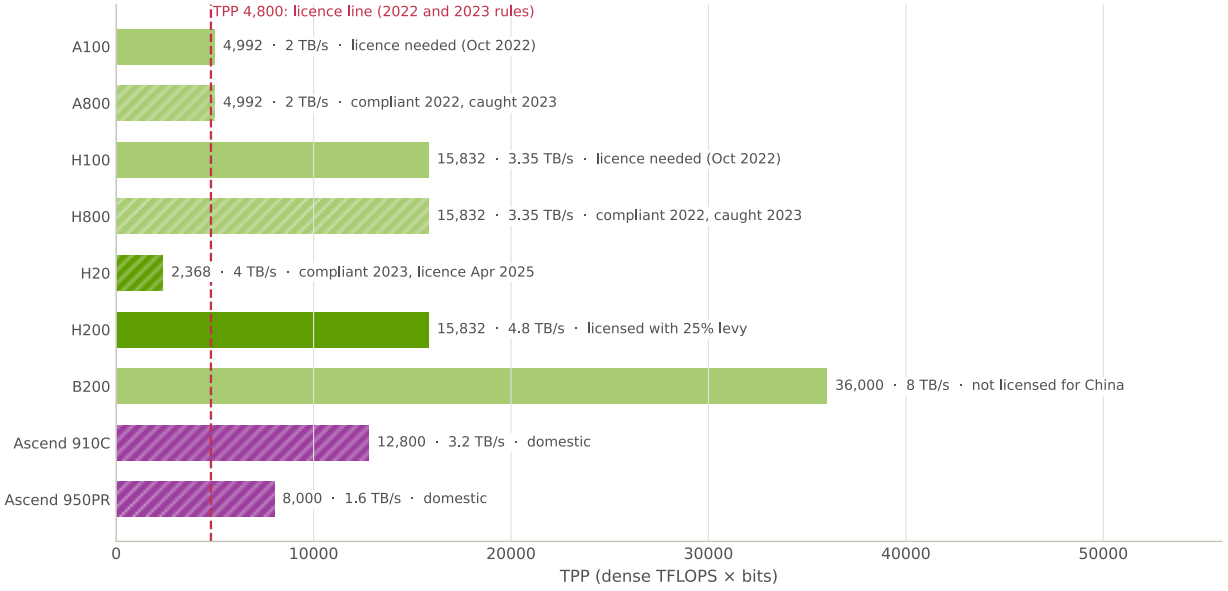


Source: data from NVIDIA datasheets, SemiAnalysis (H20 leak), Huawei, BIS [S33009] [S26002] [S26001] [S33002] [S34007] [S26003] ...; chart by repo · As of 2026-11-05

各加速器 TPP（美国出口管制指标）的水平柱状图，虚线标出 4,800 的许可证门槛。英伟达 B200 36,000；H200 15,832；H800 15,832（NVLink 降至 400 GB/s）；H100 15,832；A800 4,992（NVLink 400 GB/s）；A100 4,992；H20 2,368，配备 96 GB、4.0 TB/s 的 HBM；华为昇腾 910C 纸面约 12,800（FP16），昇腾 950PR 约 8,000（FP8）。H20 的算力远低于门槛线，但保留了比 H100 更高的内存带宽。

**提示**

**算例 —— 2026 年一位中国买家的选择。** 获许可的 H200 拥有 1,979 TFLOPS 稠密 FP8 算力和 4.8 TB/s 的 HBM3E [S32002]；昇腾 950PR 拥有 ~1,000 TFLOPS FP8 算力（未说明是稠密还是稀疏）和 1.6 TB/s 带宽 [S163]。按单芯片计， H200 的算力约为其 ~2 倍，带宽约为其 ~3 倍。但 H200 需向美国政府缴纳 25% 的收入分成 [S90032]， 国资项目必须使用国产芯片 [S26007]，而且供应随时可能被任一方再次切断。对于一位 更看重连续性而非峰值速度的买家而言，用两颗昇腾芯片替代一颗 H200 可能是理性选择，而华为的 SuperPoD 让 “更多芯片”成为一种架构，而非一种惩罚。

**China fell from ~26% of NVIDIA revenue (FY2022) to ~9% (FY2026) and 6–8% in FY2027**

China incl. Hong Kong as % of total revenue; left: fiscal years (two reporting bases); right: quarters, customer-HQ basis (hatched = secondary reading of the 10-Q)

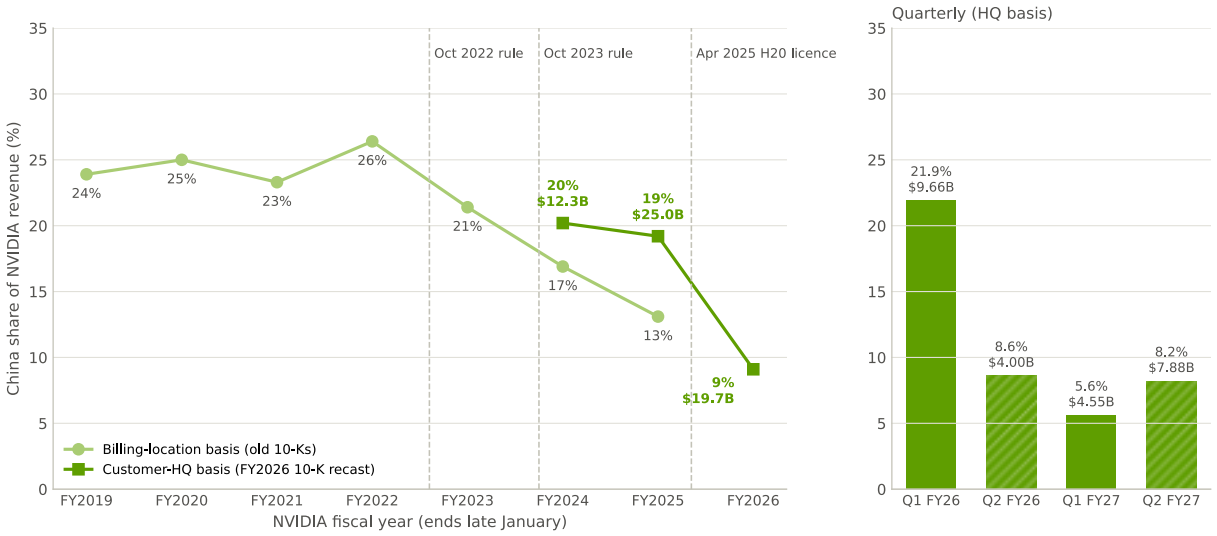


Source: data from NVIDIA 10-K and 10-Q geographic revenue notes [S400] [S2] [S418] [S417] [S416] [S26013] …; chart by repo · As of 2026-11-05

> 中国占英伟达收入比重的双子图。左：按财年，旧口径（按开票地）：FY2019 23.9%、FY2020 25.0%、FY2021 23.3%、FY2022 26.4%、FY2023 21.4%、FY2024 16.9%、FY2025 13.1%；新口径（按客户总部所在地）：FY2024 20.2%、FY2025 19.2%（$25.0B，美元金额峰值）、FY2026 9.1%（$19.7B）。右：按季度，总部口径：Q1 FY2026 为 21.9%，H20 许可证要求出台后 Q2 FY2026 为 8.6%，Q1 FY2027 为 5.6%，Q2 FY2027 为 8.2%（全部平台，含游戏）。

## 华为昇腾：芯片、超节点与“蛮力”规模

华为的策略是接受较弱的单芯片，并在系统层面加以弥补：更多芯片、基于光互连（灵衢（UnifiedBus））的更大 纵向扩展（scale-up）域，以及更多电力。它掌控 整个技术栈：NPU、鲲鹏（Kunpeng）CPU、自研 HBM、交换机、CANN 软件和华为云 [S163,S4031]。

| 系统或芯片 | 时间 | 规模 | 算力 | 内存 | 互连 | 状态 | 来源 |
|---|---|---|---|---|---|---|---|
| 昇腾 910B | 2023 | 芯片 | ~320 TFLOPS FP16 | 64 GB HBM2e，1.6 TB/s | HCCS，每节点 8 颗 | 已出货 | S164 |
| 昇腾 910C | 2025 | 芯片（2 颗裸片） | ~800 TFLOPS FP16 | 128 GB，3.2 TB/s | UB（CloudMatrix） | 已出货 | S163,S164 |
| CloudMatrix 384 | 2025 年 4 月 | 384 × 910C | ~300 PF BF16 | 49.2 TB HBM | 光互连 UB | 已出货 | S340,S248 |
| 昇腾 950PR | 2026 年第一季度 | 芯片 | 1 PF FP8，2 PF FP4 | 128 GB HiBL 1.0，1.6 TB/s | UB，2 TB/s | 据报道已量产 🟡 | S163,S15527 |
| 昇腾 950DT | 2026 年第四季度 | 芯片 | 1 PF FP8 | 144 GB HiZQ 2.0，4.0 TB/s | UB，2 TB/s | 已发布 | S163,S90042 |
| Atlas 950 SuperPoD | 2026 年第四季度 | 8,192 × 950DT | 8 EF FP8 / 16 EF FP4 | — | 全光互连 UB 2.0 | 🔴 出货未经证实 | S341,S250,S567 |
| 昇腾 960 / 960DT | 2027 年第四季度 → 2027 年第一季度 | 芯片 | 2 PF FP8 | 288 GB，9.6 TB/s | UB，2.2 TB/s | 提前 3 个季度 🟡 | S163,S567 |
| Atlas 960 SuperPoD | 2027 年第四季度 | 15,488 颗芯片 | 30 EF FP8 / 60 EF FP4 | 4,460 TB | UB | 路线图 | S342 |
| 昇腾 970 | 2028 年第四季度 | 芯片 | 4 PF FP8 | 288 GB，14.4 TB/s | UB，4 TB/s | 路线图 | S163 |
| *NVIDIA Vera Rubin NVL72（参照）* | 2026 | 72 个封装 | 3.6 EF NVFP4（推理） | 每 GPU 288 GB HBM4 | NVLink 6 | 爬坡中 | S90003,S90006 |

**提示**

**算例 —— “蛮力”的代价。** SemiAnalysis 估计 CloudMatrix 384 的稠密 BF16 算力为 ~300 PF，而 GB200 NVL72 为 ~180 PF，算力为其 1.7 倍，但功耗为 559 kW 对 ~145 kW，是其 3.9 倍 [S340]。按每千瓦计，分别为 ~0.54 PF 和 ~1.24 PF，因此华为每单位算力需要 ~2.3 倍的能耗。以示意性的每 kWh $0.08 计（🔴），额外的 ~414 kW 全年运行，每套系统每年成本 ~$0.29M：不可忽视，但与硬件成本相比很小。电力是 华为最便宜的投入；尖端晶圆和 HBM 才是其最稀缺的资源。

**NVIDIA's 72-GPU NVLink domain trails AWS (144), Huawei (384) and Google TPU pods (9,216) in size**

Accelerators per scale-up domain, shipping vs announced. Topologies differ (box): bigger is not automatically better

LOG SCALE

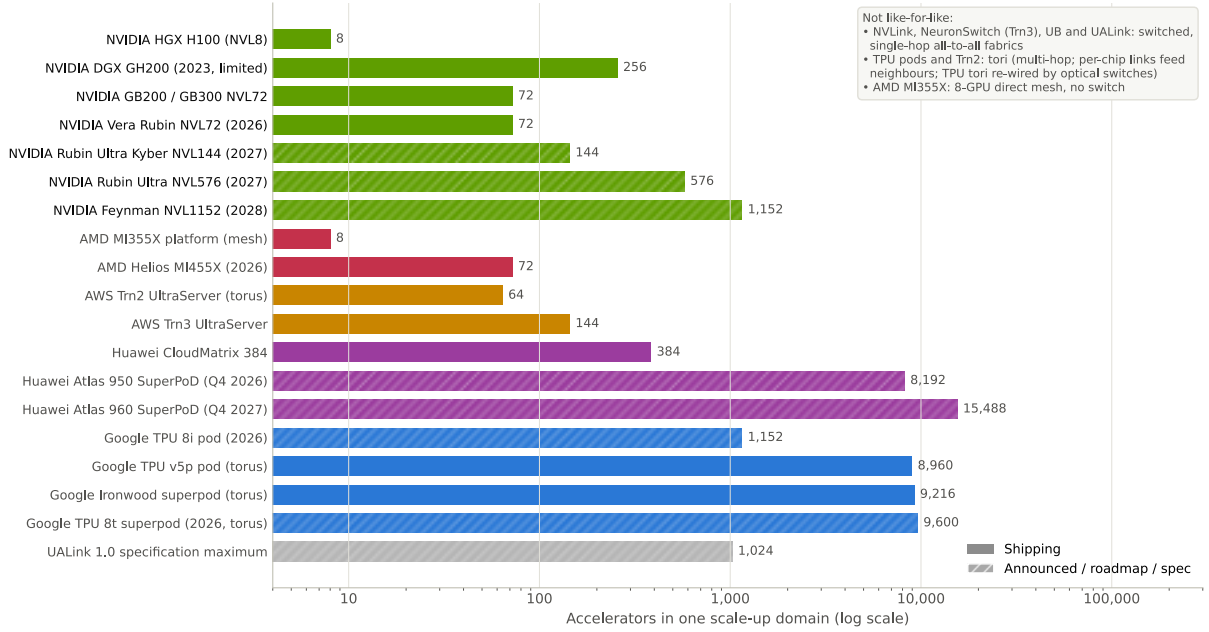


Source: data from NVIDIA, AMD, AWS, Google, Huawei, UALink; analysts [S200] [S205] [S262] [S263] [S201] [S202] ...; chart by repo · As of 2026-11-05

纵向扩展域规模的水平对数坐标柱状图：英伟达 NVL72 目前为 72 颗 GPU，Kyber NVL144 和 NVL576 于 2027 年、NVL1152 于 2028 年推出（路线图）；AMD Helios 72；AWS Trn3 UltraServer 144；华为 CloudMatrix 384 和 Atlas 950 8,192（2026 年第四季度）；谷歌 Ironwood 9,216 颗、TPU 8t 9,600 颗芯片，但 TPU pod 是多跳环面拓扑，而非交换式全互连；UALink 1.0 支持 1,024。

**🔧 技术细节：没有 EUV 如何制造 7 nm 级芯片**

中芯国际无法购买 EUV 光刻机，因此它使用深紫外光刻设备，对每一层进行多次曝光来制造 7 nm 级图层（DUV 多重图形化）。每增加一次曝光都会增加工序、生产周期和缺陷风险，因此大尺寸 AI 裸片的 良率落后于台积电（TSMC）[S15531]。据报道，昇腾 950PR 采用中芯国际的 N+3 工艺 [S15531]，而摩根士丹利 因良率问题大幅下调了其对中芯国际来自华为 AI 业务收入的估计 [S15530]。华为的自研 HBM（HiBL 1.0、HiZQ 2.0） 替代了其已无法进口的 HBM 堆栈 [S163]；中国的长鑫存储于 2026 年开始小规模生产 HBM3E [S3516]。华为、 中芯国际和若干 GPU 设计公司已被列入美国实体清单，无法获得美国的设备和 IP； 2023 年 10 月的规则还将多家中国 GPU 开发商列入其中 [S26001]。

# 供应：中芯国际产能与国产 HBM

**2027 estimates of China's 7 nm-class capacity: ~18k–100k wafers a month; Ascend needs ≤20k**

Thousand wafers per month: SMIC advanced-node capacity or output by estimator and year (targets hollow)

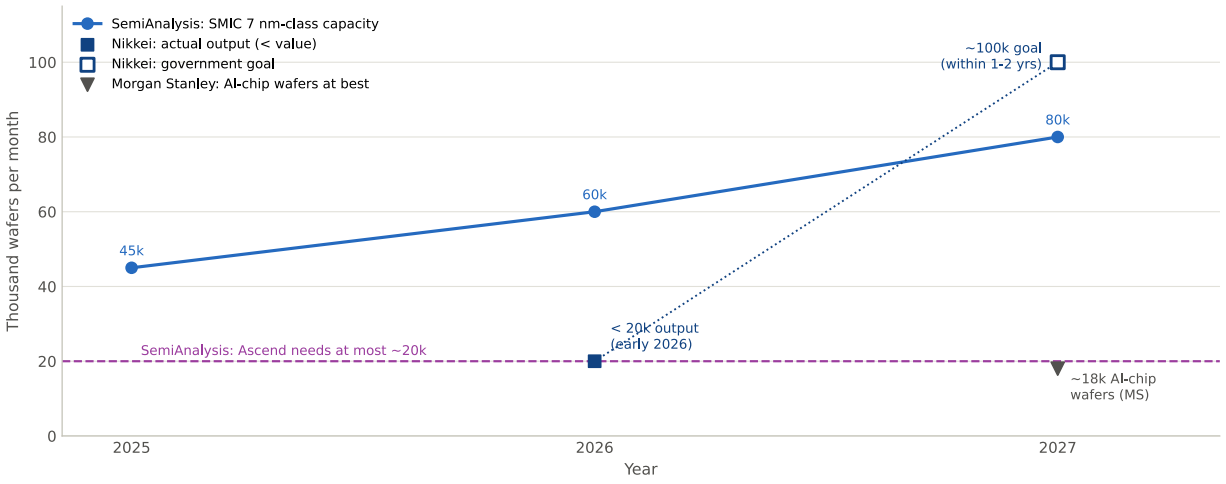


*Estimates use different scopes (total capacity, output, AI-chip wafers); not additive*

Source: data from SemiAnalysis, Nikkei via TrendForce, Morgan Stanley via Wccftech [S15528] [S15529] [S15530]; chart by repo · As of 2026-11-05

中国 7 nm 级晶圆产能估计的点线图。SemiAnalysis（保守估计）：中芯国际 7 nm 及以下产能 2025 年底约每月 45k 片，2026 年 60k，2027 年 80k，华为昇腾所需最多约 20k。日经（经 TrendForce 转引）：2026 年初产出不足每月 20k 片，政府目标是在一到两年内达到约 100k（空心标记）。摩根士丹利：由于良率较低，到 2027 年 AI 芯片晶圆最多约每月 18k 片。晶圆厂产能并非唯一约束：HBM 供应会率先成为瓶颈。

**提示**

**算例 —— 受约束条件下的每片晶圆裸片数。** 据报道，华为 2026 年的目标是最多生产 ~1.6M 颗昇腾裸片 [S15532]。SemiAnalysis 称昇腾最多需要每月 ~20k 片晶圆 [S15528]，即每年 ≤240k 片。1.6M 颗裸片 ÷ 240k 片晶圆 ≈ 在该上限下每片晶圆 7 颗良品裸片（🔴 本资料库测算）：对于大尺寸裸片、良率一般的情况而言是合理的， 这也说明晶圆本身并不是昇腾的上限。真正的上限是 HBM：每颗 950DT 需要 144 GB HBM [S163]，而国产 HBM3E 仍处于小规模阶段 [S3516]。作为对比，2026 年第二季度中芯国际占全球晶圆代工收入的 5.4%，而台积电为 72.5% [S35035]。

# 其余阵营：寒武纪、海光、摩尔线程、沐曦、壁仞、平头哥、昆仑芯

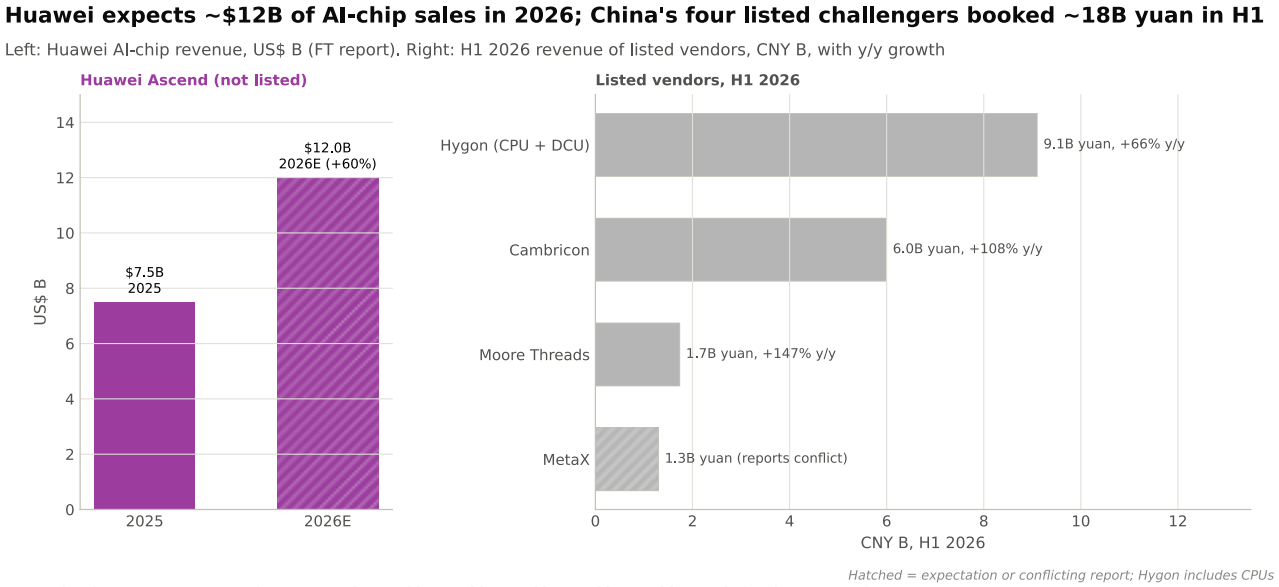


双子图柱状图。左：华为 AI 芯片收入 2025 年约 $7.5B，公司预计 2026 年约 $12B（+60%，斜线填充，据英国《金融时报》报道）。右：中国上市 AI 芯片厂商 2026 年上半年收入：海光 9.1B 元（+67%，CPU 与 DCU 加速器合计）、寒武纪 6.0B 元（+108%）、摩尔线程 1.7B 元（+147%）以及沐曦约 1.3B 元（报道不一，另一来源为 0.95B），合计约 18B 元。

| 公司 | 产品 | 2026 年数据点 | 资本市场 | 来源 |
|---|---|---|---|---|
| 寒武纪 | 思元（MLU）训练与推理加速器 | 上半年收入 6.0B 元（+108%），净利润 2.3B 元；存货 8.25B 元 | 科创板上市 | S15522,S15521,S165 |
| 海光 | x86 授权 CPU 和 DCU 加速器 | 上半年收入 9.1B 元（+67%） | 科创板上市；与中科曙光（Sugon）的合并于 2025 年 12 月终止 | S15525,S15526 |
| 摩尔线程 | GPU（图形 + AI） | 上半年收入 1.7B 元（+147%） | 2025 年 12 月科创板 IPO（募资 ~$1.1B） | S15523,S15539 |
| 沐曦 | 面向 AI 和 HPC 的 GPU | 上半年盈利；收入报道不一 | 2025 年 12 月科创板 IPO（募资 ~4.2B 元） | S15524,S15540 |
| 壁仞 | 面向 AI 的 GPU | — | 2026-01-02 于香港上市 | S15541 |
| 阿里巴巴平头哥（T-Head） | PPU / 真武 810E（96 GB HBM2e，400 W） | 出货 >560k 颗（公司口径，有报道）；中国联通西宁部署 16,384 颗 | 内部自用，有分拆报道 | S15533,S15534,S15535 |
| 百度昆仑芯 | 昆仑 AI 芯片 | 估值 ~21B 元（2025 年 12 月）；据报道 IPO 目标估值 $14.7B–$50B 🟡 | 自 2026 年 5 月起推进港股 + 科创板上市程序 | S15536,S15537,S15538 |

**提示**

**算例 —— 仅华为一家就能替代英伟达多少原有的中国业务。** 英伟达在中国的收入于 FY2025 达到峰值 $25.0B（客户总部口径，全部平台）[S401]。华为预计 2026 年 AI 芯片收入 ~$12B [S15527]，相当于该峰值的 ~48%，这还未计入寒武纪、海光和 GPU 初创公司（2026 年上半年 ~18B 元，按 ~7.1 元兑 1 美元计约合 $2.5B，🔴 汇率假设）[S15522,S15525,S15523]。国内阵营有望在 H20 许可证要求出台后的两年内 填补大部分缺口。

## DeepSeek V4 在昇腾上运行与软件问题

DeepSeek 的 V4 预览版（2026-04-24）以开放权重形式发布了 V4-Pro（~1.6T 参数）和 V4-Flash（284B）；V4-Flash 的部分训练 使用了华为昇腾，并针对推理适配了昇腾超节点 [S90079]。V4-Pro 的 定价为每百万输出 token ~$3.48，DeepSeek 表示，在 950PR 超节点于 2026 年下半年大规模出货之前，吞吐量

仍将受限 S90080。SemiAnalysis 从第 0 天起就跟踪了 V4 在华为硬件上与 GB300 NVL72 上的服务表现 S633（CS5 · DeepSeek 时刻与效率冲击）。

软件栈虽较单薄，但是开放的：CANN 已于 2025 年 8 月开源 S10537；华为称外部开发者 占 CANN 社区的 61%（公司口径） S13523；PyTorch（torch_npu）、vLLM（vllm-ascend）和 llama.cpp 均支持 昇腾 S592,S581,S579。

> **提示**
>
> **算例 —— V4 的定价与服务成本。** DeepSeek 对 V4-Pro 的定价为每百万输出 token ~$3.48 S90080。 在对 V4 从第 0 天到第 43 天的跟踪中，SemiAnalysis 测得运行 SGLang 的 GB300 NVL72 在每用户 50 tokens/s 下， 每百万输出 token 成本为 ~$0.156 S633。标价为该服务成本的 ~22 倍，因此中国服务商即便在昇腾上承受较大的硬件 效率差距，仍可盈利地提供 V4 服务。DeepSeek 所提及的约束是产能，而非单位成本 S90080。

## 分层评判：华为 vs 英伟达

| 层 | 评判 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟥 落后 | 950：1 PF FP8，Rubin 为 17.5 S163,S90006 |
| 03 内存、封装与供应 | 🟥 落后 | 中芯国际 DUV 工艺；自研 HBM 产量低 S15528,S3516 |
| 04 CPU | 🟥 落后 | 鲲鹏 950（192 核，2026 年），缺乏 NVLink-C2C 级别的紧耦合 S4031 |
| 05 纵向扩展互连 | 🟦 路线不同 | 384 至 8,192 芯片的光互连 UB 域，对比 72 封装的 NVLink S340,S341 |
| 06 横向扩展网络 | 🟨 持平 | 在中国境内采用自研交换与光学器件 S341 |
| 08 系统与机架 | 🟦 路线不同 | 超节点以电力换规模 S340 |
| 09–11 软件 | 🟥 落后 | CANN/MindSpore 开放但较单薄；V4 可在昇腾上运行 S10537,S90079 |
| 12–13 云与生态 | 🟦 路线不同 | 华为云加上受保护的本土市场 S26007 |

## 它们最有力的论据，以及差距缩小了多少

**最有力的论据：** 在中国，华为无需击败 Rubin。它只需要做到可获得、有政策支持、在系统层面 够用——而在这三点上它都领先于英伟达：英伟达获准销售的最佳产品需缴纳 25% 的分成，且其 买家被要求避免采购 S90032,S26006,S26007。

**差距缩小了多少：** 在中国市场，已缩小了大半（华为 2026 年的预期约为英伟达 FY2025 中国收入峰值的一半） S15527,S401。在中国以外，几乎没有缩小：华为芯片并未在海外大规模销售，且 单芯片 FP8 算力与 Rubin 相差 ~17 倍 S163,S90006。本资料库的评估矩阵给华为的评分为 2.7（满分 5），英伟达为 4.7 （索引）。

> **注**
>
> 🐂 **看多观点（对英伟达而言）。** 中国占比已降至收入的十分之一以下，而 FY2026 总收入增长了 65% S401,S1； 在供应受限的市场中，中国腾出的产能已流向其他买家（见 CS6 情景分析）。华为面临的 约束（晶圆、HBM、良率）使其局限于中国境内 S15528,S15530。

> **注意**
>
> 🐻 **看空观点（对英伟达而言）**。 出口管制催生了一个资金充裕、受到保护、拥有完整技术栈的对手，有针对其硬件调优的前沿模型 （DeepSeek V4），还有五家正在融资的上市同业；如果中芯国际实现每月 ~100k 片晶圆的目标、 国产 HBM 在 2027 年上量，同样的超节点就可以出口到英伟达所服务的市场 S15529,S3516,S90079。

## 🎯 企业发展视角

1. 中国国内 AI 芯片收入（华为预计 ~$12B，上市同业上半年 ~$2.5B）如今是英伟达无法触及的市场。 华为或寒武纪最先可能出口到哪些中国以外的市场？时间表如何？
2. 华为证明了较弱的芯片加上大规模光互连纵向扩展域可以在系统层面参与竞争。竞争者 应如何相对于单芯片 FLOPS 来评估纵向扩展互连和光学器件的价值？
3. 与中国 AI 芯片公司的合作受到同样的管制（实体清单）约束。对于非美国企业而言，还有哪些合作 （如果有的话）仍然可行？规则变化的速度有多快？
4. 中国上市 AI 芯片公司的估值（摩尔线程、沐曦）意味着投资者预期国产替代将持续。 哪些政策变化（无分成的 H200 级许可证，或北京放松其指导意见）会对此构成检验？
5. HBM 是中国的硬约束。长鑫存储能以多快速度扩大 HBM3E 产能？国产 HBM 是否会为世界其他地区提供一个新的、非韩国、非美国的供应商？

# 谷歌 TPU —— 可信的替代方案，如今已对外销售

跨层专题 15 · 竞争格局 · 从 TPU v1 到 TPU 8t/8i、ICI 与光交换机、JAX/XLA、对外销售 · 约 15 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **十年，八代。** 第一代 TPU 于 2015 年承担谷歌（Google）的推理任务，速度是同期 CPU 和 GPU 的 15–30× [S23001]。Ironwood（v7，2025 年 11 月正式商用）每颗芯片提供 4,614 TFLOPS 稠密 FP8 算力和 192 GB HBM3E，pod 规模为 9,216 颗芯片 [S151,S547]。
- **2026 年产品线一分为二。** TPU 8t（训练）宣称在 9,600 芯片的 pod 中提供 12.6 PFLOPS 的 FP4 算力；TPU 8i（推理）则将 10.1 PFLOPS 与 288 GB HBM 及 384 MB 片上 SRAM 相结合（🟢 已发布；内存数据 🟡 来自媒体报道）[S552,S239,S15010]。
- **纵向扩展（scale-up）是谷歌的招牌。** ICI 链路构成 3D 环面（torus）拓扑，并由光路交换机重新布线，使一个 pod 的规模达到 NVL72 机架的 128×，尽管单芯片带宽较低 [S232,S237]。
- **TPU 如今已对谷歌以外的客户销售。** Anthropic 可使用最多 1M 颗 TPU（2026 年超过 1 GW）[S653]；Meta 租用 Ironwood，并已讨论为自有数据中心采购 TPU（🟡）[S90025]；甲骨文（Oracle）将自 2027 年起托管 TPU [S552]。
- **经济性才是威胁所在。** SemiAnalysis 估计自有 Ironwood 的每芯片小时成本约为 $1.21，而 B200 约为 $1.73、GB300 约为 $2.31；在一项 FP8 工作负载上，其每 token 成本比 B200 低约 18%（估计）[S622,S625]。
- **弱点：** 在谷歌之外，其软件生态尚不成熟（本资料库框架指数得分 14/36，CUDA 为 36），且自 v5.0 以来 TPU 一直缺席 MLPerf [S580,S613]。Rubin 的 HBM4 也重新拉开了硬件差距：TPU 8i 的内存带宽约为 Rubin 的 45% [S15014]。

**TPU 8i's 8.6 TB/s is ~7× TPU v4's, but only ~45% of Rubin's 19.2 TB/s**

HBM bandwidth (TB/s) and capacity (GB) per chip by TPU generation; green dots = NVIDIA flagship shipping the same year; hatched = announced

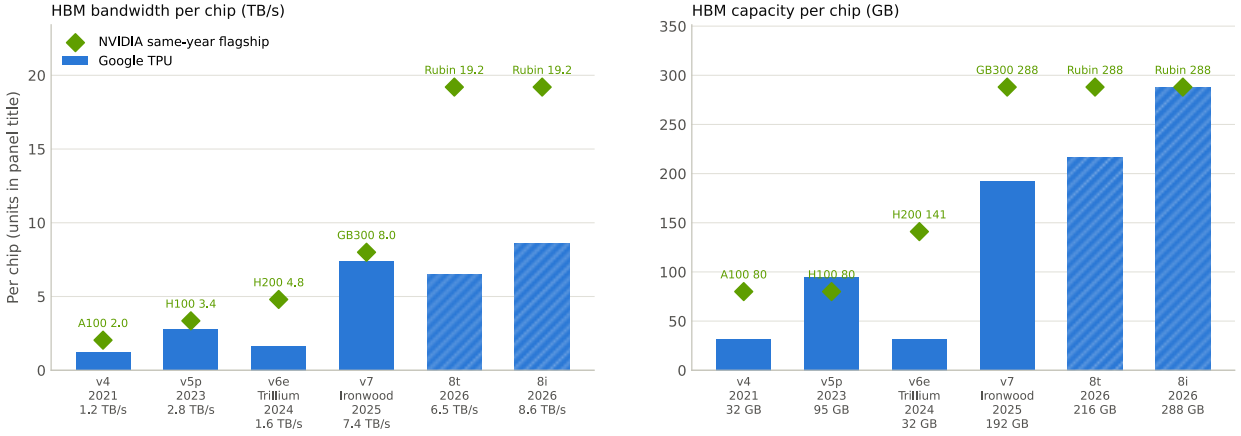


*TPU 8t/8i memory figures are press-reported*

Source: data from Google Cloud docs, press deep dives, NVIDIA specs [S146] [S147] [S149] [S150] [S151] [S15010] ...; chart by repo · As of 2026-11-05

两个柱状面板，展示谷歌 TPU 的单芯片内存，并以绿色圆点标出英伟达同年旗舰。带宽：v4 1.2 TB/s（2021，A100 为 2.0），v5p 2.77（2023，H100 为 3.35），Trillium 1.64（2024，H200 为 4.8），Ironwood 7.37（2025，GB300 为 8.0，达 92%），TPU 8t 6.5 和 TPU 8i 8.6（2026，Rubin 为 19.2）。容量：32、95、32、192、216 和 288 GB，对比 80、80、141、288 和 288 GB。Ironwood 在 2025 年几乎弥合了带宽差距；Rubin 的 HBM4 将差距重新拉大到约 2.2 倍，而 TPU 8i 在容量上与 Rubin 的 288 GB 持平。

## 历代产品：从推理卡到双芯片家族

谷歌负责架构、编译器和系统设计；博通（Broadcom）一直是其长期的 ASIC 设计合作伙伴，联发科（MediaTek）则加入负责部分型号（🟡）[S23007,S23008]。媒体深度报道称，8t 裸片由博通设计，8i 由联发科设计 [S15010]。

| 代际 | 年份 | 定位 | 单芯片峰值 | 单芯片 HBM | 最大 pod | 来源 |
|---|---|---|---|---|---|---|
| v1 | 2015 | 推理 | 92 TOPS INT8 | 28 MiB 片上 + DDR3 | — | S23002 |
| v4 | 2021 | 训练 | 275 TFLOPS BF16 | 32 GB，1.2 TB/s | 4,096 | S146,S237 |
| v5p | 2023 | 训练 | 459 TFLOPS BF16 | 95 GB，2.77 TB/s | 8,960 | S149 |
| v6e Trillium | 2024 | 能效 | 918 TFLOPS BF16 | 32 GB，1.64 TB/s | 256 | S150 |
| v7 Ironwood | 2025 | 推理优先 | 4,614 TFLOPS FP8 | 192 GB，7.37 TB/s | 9,216 | S151,S650 |
| 8t | 2026（🟢 已发布） | 训练 | 12.6 PFLOPS FP4 | 216 GB，约 6.5 TB/s（🟡） | 9,600 | S552,S15010 |
| 8i | 2026（🟢 预览） | 推理 | 10.1 PFLOPS FP4 | 288 GB，约 8.6 TB/s（🟡） | 1,152（🟡） | S15011,S239 |

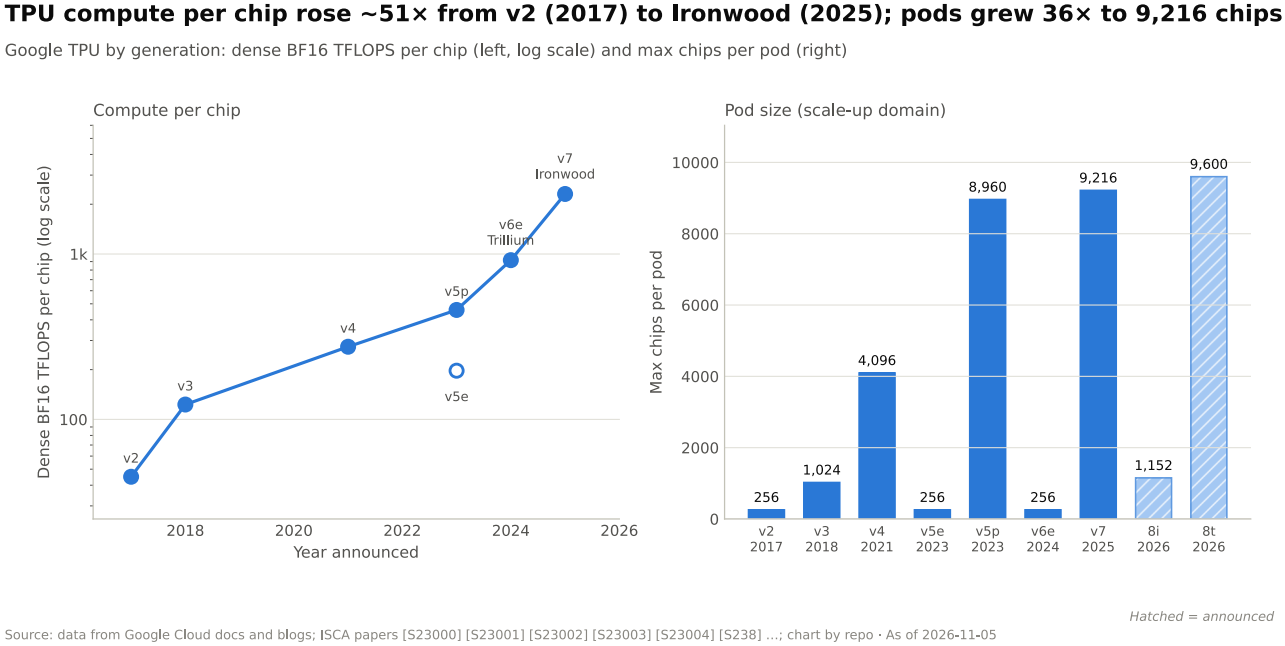


谷歌 TPU 历代产品双面板图。左（对数刻度）：单芯片稠密 BF16 TFLOPS 从 45（TPU v2，2017）增至 123（v3，2018）、275（v4，2021）、459（v5p，2023）、918（v6e Trillium，2024）以及约 2,307（v7 Ironwood，2025；BF16 按其 4,614 FP8 的一半计），八年约增长 51 倍；成本优化型 v5e 为 197。右：单 pod 最大芯片数从 256（v2）增至 1,024（v3）、4,096（v4）、8,960（v5p）和 9,216（Ironwood），2026 年发布的 TPU 8t 为 9,600；能效型 v5e 和 Trillium 保持 256 芯片 pod。TPU v1（2015）是一款 92 TOPS 的 INT8 推理卡，没有 pod。

这种拆分与英伟达（NVIDIA）自身的方向如出一辙：Vera Rubin 用于通用工作负载，旁边配以 Groq 3 LPX 推理机架 [S90003]。训练需要原始 FLOPS 和尽可能大的互连规模；推理需要内存容量以及用于 KV 缓存的片上 SRAM。据报道，8t 以比 Ironwood 低约 11.5% 的带宽，换取 12.5% 的容量提升和更低的成本，目的是提高良率 [S15010]。

**提示**

**算例 —— 一个 TPU 8t pod 有多大？** 9,600 颗芯片 × 12.6 PFLOPS = **约 121 EF 的 FP4** [S239,S550]。一个 Vera Rubin NVL72 机架的训练 NVFP4 算力标称 2.52 EF [S102]。一个 8t pod 相当于约 48 个 NVL72 机架的峰值训练算力，而且处于同一个纵向扩展域内，而不是 48 个通过网络连接的机架。**结论：** 谷歌在域规模上竞争，英伟达则在单芯片速度和全交换（all-to-all）带宽上竞争。

### 🔧 技术细节：脉动阵列，以及编译器为何重要

TPU 的矩阵单元是脉动阵列（systolic array）：由乘累加单元组成的网格，将操作数传递给相邻单元，因此从内存取出的每个数都会被复用数百次。Ironwood 拥有四个 256 × 256 阵列，并新增了原生 FP8 支持 [S2016]。更大的阵列能节省带宽，但在处理小型或形状不规则的矩阵时会闲置，因此 XLA 编译器会对整个计算图进行融合和重塑，以保持阵列满载。因此，与 GPU 相比，TPU 的性能更依赖于编译器的成熟度。

设计合作伙伴也分享了上行收益：博通的 AI 收入（包括 TPU 和 AI 以太网）在其 Q3 FY2026 达到 $16.7B [S2516]，而 Anthropic 自 2027 年起的下一批数吉瓦 TPU 订单正是与博通联合宣布的 [S655]。完整的历史和经济性分析见 CS3 · 谷歌 TPU：可信的替代方案；设计公司相关内容见定制 ASIC 设计公司。

## ICI 与光交换机：为何 pod 能容纳 9,216 颗芯片

每颗 Ironwood 芯片有六条 200 GB/s 的 ICI 链路（合计 1.2 TB/s），分别连接 3D 环面中的每个相邻芯片 [S232]。64 颗芯片在一个机架中组成 4 × 4 × 4 的立方体；立方体之间通过光路交换机相连——这种交换机用镜面在光纤之间引导光信号，而无需将其转换为电信号。TPU v4 使用了 48 台光路交换机，将 64 个立方体连接成一台 4,096 芯片的机器 [S237]。通过重新调整光路指向，谷歌可以灵活划分切片，并绕开故障立方体。其 Jupiter 数据中心网络也基于同样的理念 [S293]。

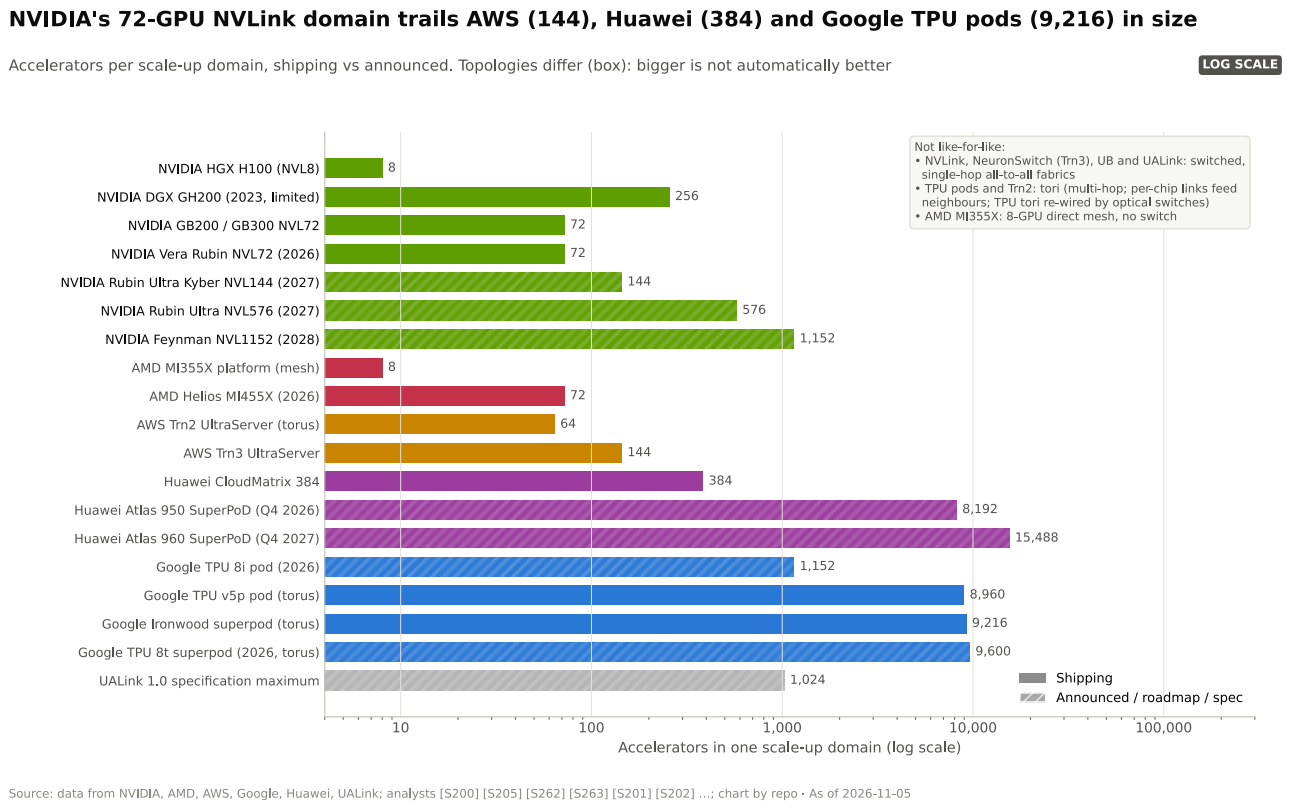


Source: data from NVIDIA, AMD, AWS, Google, Huawei, UALink; analysts [S200] [S205] [S262] [S263] [S201] [S202] …; chart by repo · As of 2026-11-05

纵向扩展域规模的水平对数刻度柱状图：英伟达 NVL72 目前为 72 颗 GPU，2027 年的 Kyber NVL144 和 NVL576 以及 2028 年的 NVL1152（路线图）；AMD Helios 为 72；AWS Trn3 UltraServer 为 144；华为 CloudMatrix 384 和 Atlas 950 为 8,192（2026 年 Q4）；谷歌 Ironwood 为 9,216 颗芯片、TPU 8t 为 9,600 颗芯片，但 TPU pod 是多跳环面而非交换式全互连；UALink 1.0 允许 1,024。

**Est.: all-to-all bandwidth per chip is 900 GB/s in NVL72, ~200 in a 64-chip TPU cube**

Uniform all-to-all GB/s per chip per direction vs chips exchanging; bandwidth-only repo model

LOG SCALE

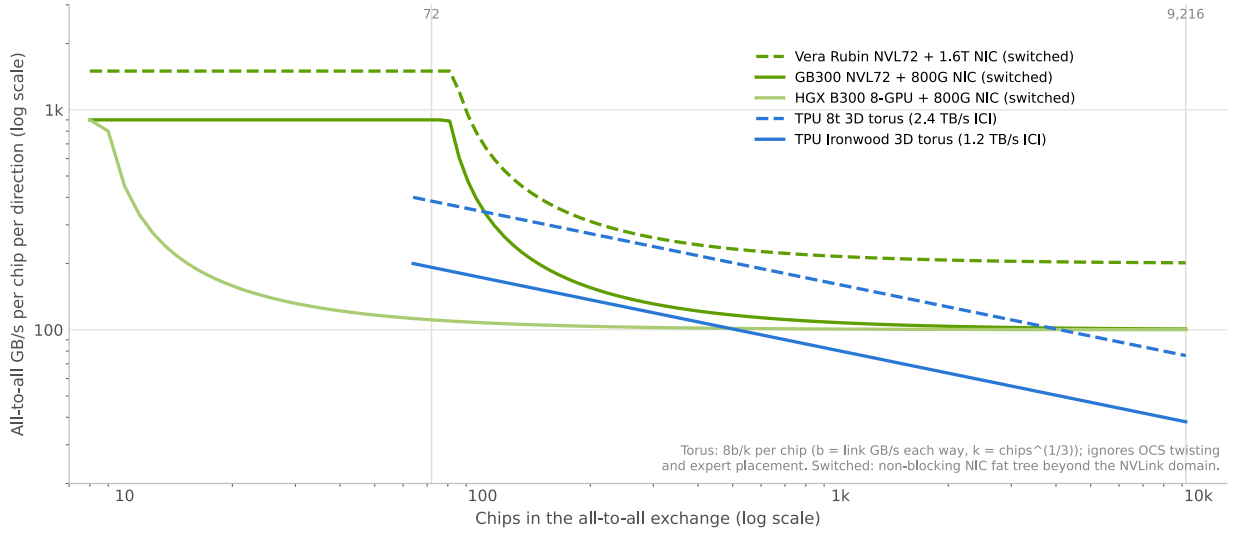


Source: data from NVIDIA, Google Cloud, IEEE specs; repo model [S200] [S262] [S263] [S201] [S202] [S33004] ...; chart by repo · As of 2026-11-05

单芯片全交换带宽建模的双对数折线图。交换式 GB300 级 NVL72 在 72 颗 GPU 以内为每颗 GPU 提供每方向 900 GB/s，此后降至 800G 网卡的约 100 GB/s（9,216 颗 GPU 时为 101 GB/s）；8-GPU HGX 节点在超过 8 颗 GPU 后降至约 100 GB/s；Vera Rubin NVL72 起点为 1,500，配合 1.6T 网卡后稳定在约 200。TPU Ironwood 3D 环面（六条链路共 1.2 TB/s）在 64 芯片立方体中提供约 200 GB/s，随芯片数的立方根下降，在 9,216 颗时约为 38；TPU 8t 将其翻倍。环面链路需承载多跳流量，而交换式架构可避免这一问题。

**提示**

**算例 —— 混合专家层中的环面与交换架构对比。** 在混合专家模型（MoE）中，每个 token 都会被发送到其他芯片上的少数几个专家：这是一次全交换（all-to-all）。在 NVL72 内部，每颗 GPU 以约 900 GB/s 的速度访问其他每颗 GPU；在 64 芯片的 TPU 立方体中，多跳路由使每颗芯片仅剩约 200 GB/s（本资料库模型）[S232]。对于 64 颗芯片的专家组，英伟达传输同样流量的速度约快 4.5×。超过 72 颗 GPU 后，英伟达回落到通过 800G 网卡每 GPU 约 100 GB/s，而环面在约 500 颗芯片以内仍能提供约 100–200 GB/s。**结论：** NVL72 在机架内胜出；对于必须把一个紧耦合步骤分散到数百颗芯片上的任务，TPU pod 胜出。

## JAX、XLA 与 PyTorch 桥接

在谷歌内部，模型用 JAX 编写并由 XLA 编译；Gemini 1.0 即以这种方式在 TPU v4 和 v5e 集群上训练 [S23005]，据报道 Gemini 3 也是在 TPU 上训练的（🟡）[S23006]。在谷歌之外，大多数开发者使用 PyTorch，而这条路径一直较弱。PyTorch/XLA 现已被弃用，取而代之的是 2026 年 10 月与 Meta 联合开源的 TorchTPU [S595,S553]。vLLM 的 TPU 后端已迁移至 JAX 实现，PyTorch 原生的 TPU 推理服务则由一个独立插件提供 [S581]。

**CUDA scores 36/36 on framework support; ROCm 26, Huawei 17, Qualcomm 4**

Sum of 0–3 support scores across 12 AI frameworks (max 36); TPU and Neuron lean on their own stacks (JAX, NxD)

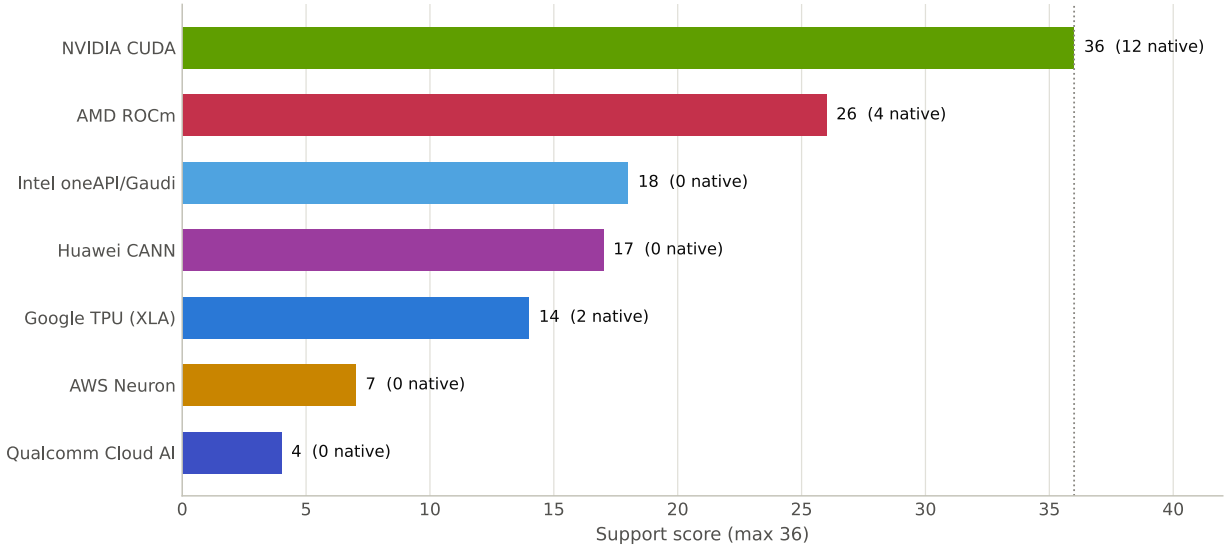


Source: data from Framework docs and READMEs (GitHub), vendor docs [S587] [S586] [S553] [S595] [S594] [S522] ...; chart by repo · As of 2026-11-05

12 个框架支持得分加总的水平柱状图：英伟达 CUDA 为 36/36（12 个均原生支持），AMD ROCm 为 26（4 个原生支持），英特尔为 18，华为 CANN 为 17，谷歌 TPU 为 14（JAX 和 TensorFlow 原生支持），AWS Neuron 为 7，高通 Cloud AI 为 4。

**提示**

**算例 —— 14/36 对买家意味着什么。** 本资料库的框架指数检查 12 个主要框架和推理服务引擎，看其是原生支持、插件支持还是不支持 [S580,S577]。TPU 得分 14/36；CUDA 为 36。一个用 JAX 训练、用谷歌自有技术栈提供服务的实验室，可能只会用到这十二个中的三个左右，因此差距几乎无关紧要。而一家使用 PyTorch、vLLM、SGLang 和 TensorRT 类工具的企业会用到八个或更多，每个不受支持的工具都意味着一个移植项目。**结论：** TPU 适合少数技术实力雄厚的买家（Anthropic、Meta、谷歌自身）；对于长尾客户，软件仍是壁垒。

## 对外供应：从云租用到商用芯片

十年来，TPU 只能通过谷歌云租用。2025–26 年，谷歌同时开放了多个渠道。

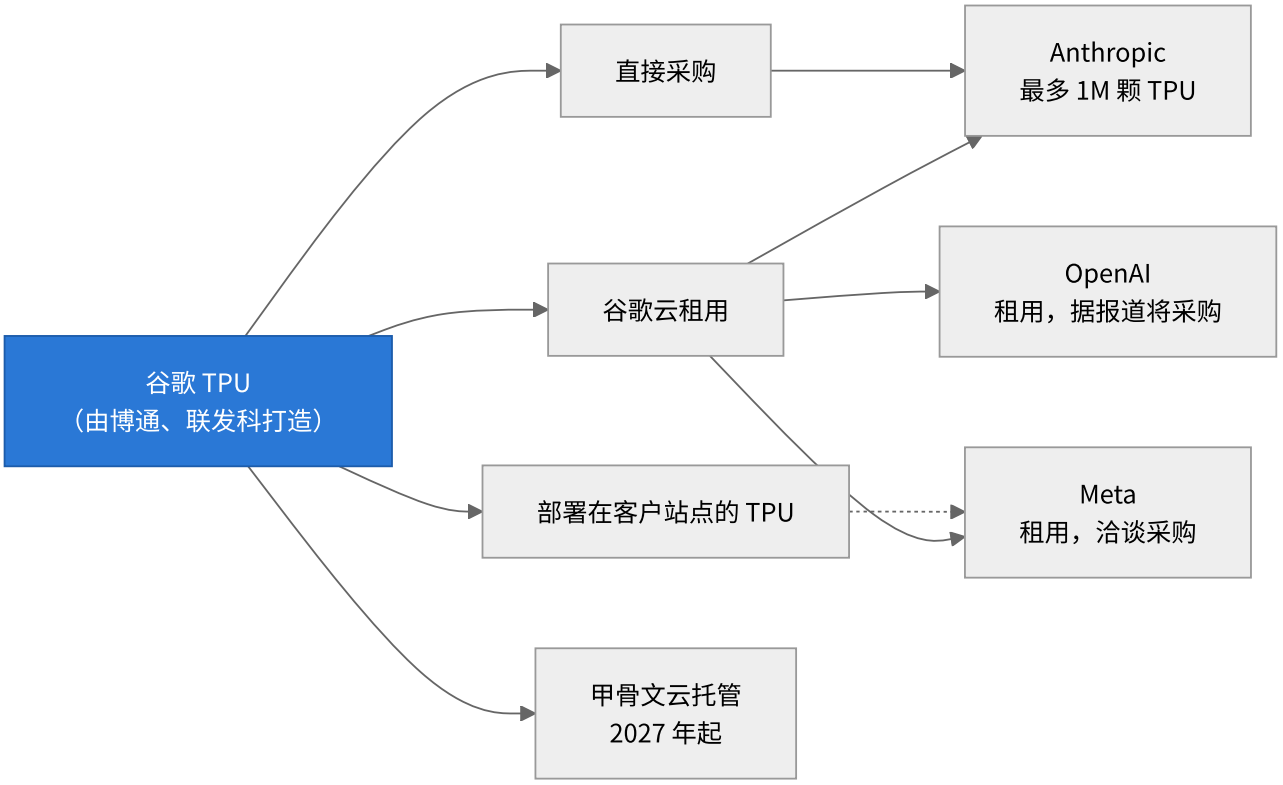


Anthropic [S653,S625]；Meta（🟡）[S90025]；客户站点销售 [S90027]；甲骨文 [S552]；OpenAI 采购洽谈（🔴 单一来源）[S24008]。

| 客户 | 内容 | 状态 | 来源 |
|---|---|---|---|
| Anthropic | 最多 1M 颗 TPU，2026 年超过 1 GW，“数百亿美元”；约 400k 颗采购、约 600k 颗租用（估计） | 🟢 / 🟡 分项 | S653,S625 |
| Anthropic | 自 2027 年起数吉瓦的下一代 TPU 算力，与博通合作 | 🟢 | S655 |
| Meta | 数十亿美元的 Ironwood 租用；洽谈为自有数据中心采购 TPU | 🟡 | S90025 |
| 甲骨文（OCI） | 自 2027 年起托管 TPU 算力 | 🟢 | S552 |
| OpenAI | 自 2025 年起租用；据报道计划采购 | 🔴 单一来源 | S24008 |

市场已经注意到这一点。2025 年 11 月一则关于 Meta 正洽谈使用 TPU 的报道，令英伟达股价盘中一度下跌多达 7.1% [S23009]。

**Est.: an owned Ironwood chip-hour costs ~$1.21, about half a GB300's $2.31**

All-in owner cost per accelerator-hour (capex amortisation, power, hosting), US$, SemiAnalysis model, July 2026

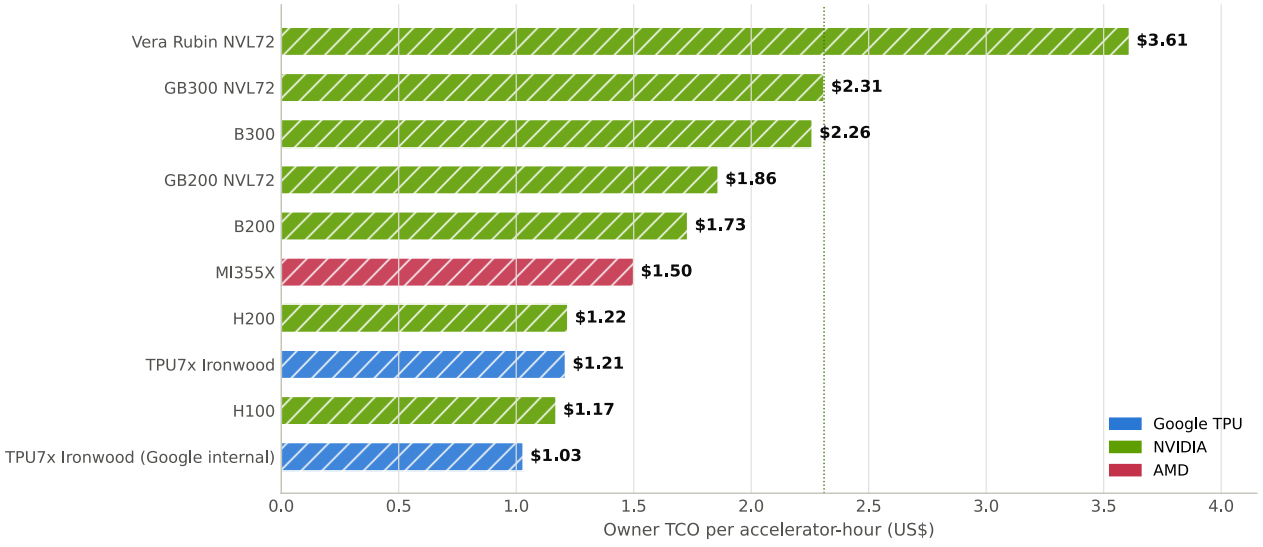


*Est. · per chip, not per token*

Source: data from SemiAnalysis InferenceX TCO registry [S622]; chart by repo · As of 2026-11-05

各加速器每小时自有总拥有成本（TCO）估计的水平柱状图：TPU7x Ironwood 对谷歌自身为 $1.03，对外部持有者为 $1.21，H100 $1.17，H200 $1.22，AMD MI355X $1.50，B200 $1.73，GB200 NVL72 $1.86，B300 $2.26，GB300 NVL72 $2.31，Vera Rubin NVL72 $3.61。这些是按芯片计算的成本，而非按单位工作量：Ironwood 每小时比 B200 便宜 30%，但在 SemiAnalysis 的一项工作负载上，其每 token 成本仅低约 18%，因为各芯片的吞吐量不同。

**提示**

**算例 —— Anthropic 的 TPU 能节省多少。** 一百万颗 Ironwood 级芯片，按每芯片小时约 $1.21 计算，每年的持有和运营成本约为 1,000,000 × $1.21 × 8,760 ≈ **$10.6B**（估计）[S622]。如果 TPU 的每 token 成本比 B200 低约 18% [S625]，那么在 B200 上产出同样的 token 将花费约 $10.6B ÷ 0.82 ≈ $12.9B：**每年节省约 $2.3B。结论：** 节省是真实的，但它是约 18% 的每 token 折扣，而非芯片小时价格所暗示的约 45%，因为 B200 每小时完成的工作更多。这一差距正是买家如今对英伟达握有的价格筹码。

### GB300 NVL72 serves DeepSeek-R1 for ~$0.10/M tokens at 50 tok/s/user, 11x below H200 (Est.)

Est. US$ per million total tokens = owner TCO $/GPU-hr ÷ measured throughput (InferenceX); two workloads

LOG SCALE

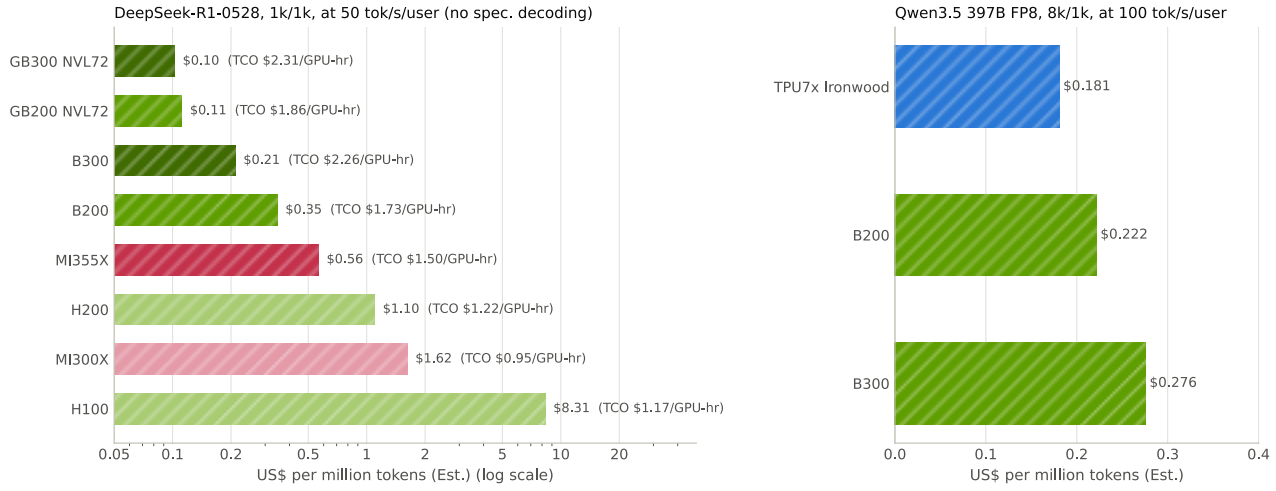


*Est.: cost = TCO $/GPU-hr / throughput*

Source: data from SemiAnalysis InferenceX (throughput; TCO $/GPU-hr); repo interpolation [S621] [S622] [S625]; chart by repo · As of 2026-11-05

两个柱状面板，展示每百万 token（总计）的成本估计。左，DeepSeek-R1，每用户 50 tokens/s：GB300 NVL72 $0.10，GB200 NVL72 $0.11，B300 $0.21，B200 $0.35，MI355X $0.56，H200 $1.10，MI300X $1.62，H100 $8.31。右，Qwen3.5 397B FP8，每用户 100 tokens/s：TPU7x Ironwood $0.181，B200 $0.222，B300 $0.276，显示在该工作负载上谷歌 TPU 比 B200 便宜约 18%。

## 分层级判定

### Google TPU averages 4.0 of 5 vs NVIDIA's 4.7, ahead only on Cost/TCO

Capability scores 0-5; Google TPU (filled) vs NVIDIA reference (dashed green); analyst judgement with sourced rationale

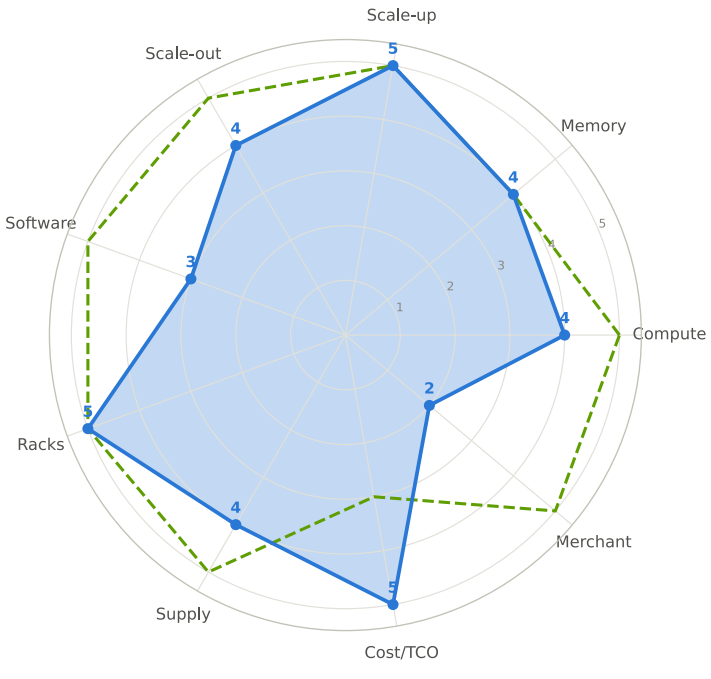


*Analyst judgement (speculative)*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S143] [S361] [S630] [S402] ...; chart by repo · As of 2026-11-05

谷歌 TPU 与英伟达在九个能力维度上的雷达图，按 0-5 分评分（本资料库分析师判断）：算力 4 vs 5；内存 4 vs 4；纵向扩展 5 vs 5；横向扩展 4 vs 5；软件 3 vs 5；机架 5 vs 5；供应 4 vs 5；成本/TCO 5 vs 3；商用可得性 2 vs 5。平均 4.0 vs 4.7。谷歌 TPU 在纵向扩展域规模和成本上领先，但商用可得性仅得 2 分，谷歌以外的软件生态得 3 分。

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟨 持平 | Ironwood 单芯片约 4.6 PFLOPS FP8，与 B200/B300 的稠密 FP8 相当；TPU 8t 为 12.6 PFLOPS FP4 S151,S552 |
| 03 内存、封装与供应 | 🟥 落后 | 通过博通成为 CoWoS 第二大用户，仅次于英伟达；数吉瓦订单令供应吃紧 S379,S655 |
| 04 CPU | 🟨 持平 | 有 Axion Arm CPU，但没有类似 NVLink-C2C 的一致性 CPU-TPU 链路 S547 |
| 05 纵向扩展 | 🟦 路线不同 | 9,216 芯片环面 vs 72-GPU 交换域 S232,S650 |
| 06 横向扩展 | 🟦 路线不同 | Jupiter 光网络，仅限内部使用 S293 |
| 07 DPU 与卸载 | 🟦 路线不同 | Titanium 卸载，内部使用 S547 |
| 08 系统与机架 | 🟨 持平 | 从液冷立方体到 9,216 芯片超级 pod，配备 1.77 PB HBM S650 |
| 09 系统软件 | 🟥 落后 | JAX/XLA 在谷歌内部已成熟；TorchTPU 仅推出数月 S553,S595 |
| 10 软件库 | 🟥 落后 | XLA、Pallas 和 MaxText 覆盖大语言模型；长尾覆盖弱于 CUDA-X S650 |
| 11 推理软件 | 🟩 领先 | 在 Qwen3.5 FP8 上每 token 成本比 B200 低约 18%（估计） S625 |
| 12 编排与云 | 🟩 领先 | 谷歌云分发渠道；自 2027 年起 TPU 上线 OCI S552 |
| 13 生态与资本 | 🟥 落后 | 赢得 Anthropic 和 Meta，但合作伙伴基础仅为英伟达的一小部分 S653,S90025 |

本资料库分析师判断，依据 `data/competitor_matrix.csv`（🔴） S15014。

> **提示**
>
> **算例 —— 英伟达要追平 TPU 需付出什么代价。** 要追平 Ironwood 约 18% 的每 token 成本优势，B200 持有者的成本须下降 18.5% S625。若英伟达的发票金额约占该持有成本的 55%（🔴），英伟达的价格须下降约 34%。在 75% 的毛利率下，单位成本为原价的 25%，因此新的毛利率为 (66 − 25) ÷ 66 ≈ **62%**（🔴 本资料库测算，来自 CS3） S23010。**结论：** 英伟达可以赢得与 TPU 的价格战，但每个手握 TPU 报价的买家都能分走约 13 个百分点毛利率缓冲中的一部分。

**其最有力的论据。** “以最大规模提供最便宜的 token，并已在前沿模型上得到验证。”TPU 是唯一一个拥有完整技术栈、量产十年、已训练出前沿模型并拥有吉瓦级外部客户的替代方案 S653,S23005。

**差距缩小了多少。**

| 指标 | 过去 | 现在（2026 年 11 月） | 来源 |
|---|---|---|---|
| 内存带宽对比英伟达旗舰 | 59%（v4 vs A100，2021） | 92%（Ironwood vs GB300，2025）→ 约 45%（8i vs Rubin，2026） | S15014 |
| HBM 容量对比英伟达旗舰 | 40%（v4 vs A100） | 100%（8i 288 GB vs Rubin 288 GB） | S15010,S33005 |
| 每芯片小时自有成本对比 GB300 | n/a | 约 52%（$1.21 vs $2.31，估计） | S622 |
| 外部客户 | 仅谷歌云租户 | Anthropic、Meta、甲骨文、OpenAI（有报道） | S653,S90025,S552,S24008 |
| 框架支持指数 | n/a | 14/36，CUDA 为 36 | S580 |

> **注**
>
> 🐂 **看多观点（对谷歌而言）。** TPU 兼具实测最低的每 token 成本、最大的纵向扩展域，以及 AI 领域两家要求最严苛的客户。谷歌通过自有云、客户站点以及如今的甲骨文销售 TPU，因此单笔吉瓦级交易不再需要谷歌云合同 S552,S90027。

> **注意**
>
> 🐻 **看空观点（对谷歌而言）。** 按单芯片计，Ironwood 的稠密 FP8 约为 Rubin 的四分之一，TPU 8i 的内存带宽约为 Rubin 的 45% [S151,S15014]。PyTorch 路径才推出数月，MLPerf 结果在 v5.0 之后中断，而且每颗芯片中都包含博通的利润。向 Meta 等对手销售 TPU，也是在武装谷歌在 AI 领域的竞争者。

## 🎯 企业发展视角

1. **商用 TPU 的经济性。** 如果谷歌将 TPU 销售到客户站点 [S90027]，它就成为一家以博通和联发科为合同设计方的商用厂商。这将如何改变设计公司以及 HBM 和 CoWoS 供应商的议价能力？
2. **价格，而非份额。** 在一项工作负载上，每 token 节省约 18% [S625]。一份可信的 TPU 报价能为吉瓦级买家换来英伟达几个百分点的价格让步？这部分价值由谁获取？
3. **PyTorch 桥接。** TorchTPU（与 Meta 合作）和 vLLM 的 JAX 后端是外部用户的入口 [S553,S581]。可移植编译器和推理服务运行时资产（开源或可收购的）是否是任何非英伟达加速器的关键赋能因素？
4. **推理专用芯片。** TPU 8i 的 384 MB SRAM 和 288 GB HBM 瞄准的是 KV 缓存密集型的推理服务 [S15011]。8t/8i 的拆分是否验证了纯推理加速器市场的存在？内存与算力的配比应为多少？

# AWS Trainium —— 最大云平台内部的成本优势

跨层专题 15 · 竞争格局 · Trainium1–4、Neuron SDK、UltraServer、Project Rainier、Annapurna Labs · 约 14 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **四年四代。** Trainium 的单芯片稠密 FP8 算力从 0.19 PFLOPS（Trn1，2022）提升到 2.52 PFLOPS（Trn3，2025 年 12 月正式商用），约 13× [S152,S353]。AWS 表示 Trainium4 的 FP8 算力将至少为 Trn3 的 3×、FP4 为 6×、内存带宽为 4×，但未给出发布日期 [S90034]。
- **AWS 追平的是英伟达的机架，而非芯片。** 一台 Trn3 UltraServer 连接 144 颗芯片，提供约 362 PFLOPS FP8 和 20.7 TB HBM3E [S353]，与一个 GB300 NVL72 机架大致相当，但芯片数量是其两倍（本资料库对比）[S15014]。
- **Trainium4 将接入英伟达的互连架构。** AWS 为 Trainium4 选择了 NVLink Fusion 和英伟达（NVIDIA）的 MGX 机架设计，是迄今为止该计划中唯一的超大规模云厂商加速器 [S518,S90034]。
- **两大锚定租户。** Project Rainier 于 2025 年为 Anthropic 投入了约 500,000 颗 Trainium2 芯片 [S27011]。此后 Anthropic 承诺使用最多 5 GW 的 Trainium，OpenAI 自 2027 年起使用约 2 GW；AWS 称 Trainium 收入承诺超过 $225B [S15000,S15001]。
- **它已经是一项大业务。** 亚马逊的定制芯片（Graviton、Trainium、Nitro）在 2026 年 Q1 的年化收入已超过 $20B；亚马逊 CEO 表示，若作为独立业务出售，其规模约为 $50B [S15000]。
- **弱点：** 软件与透明度。Neuron SDK 在本资料库的框架指数中得分 7/36 [S594]，Trainium 没有 MLPerf 结果，且仅以 AWS 算力的形式出售。AWS 还签署了一项约 $38B 的协议，向 OpenAI 提供英伟达 GB200/GB300 算力 [S15013]。

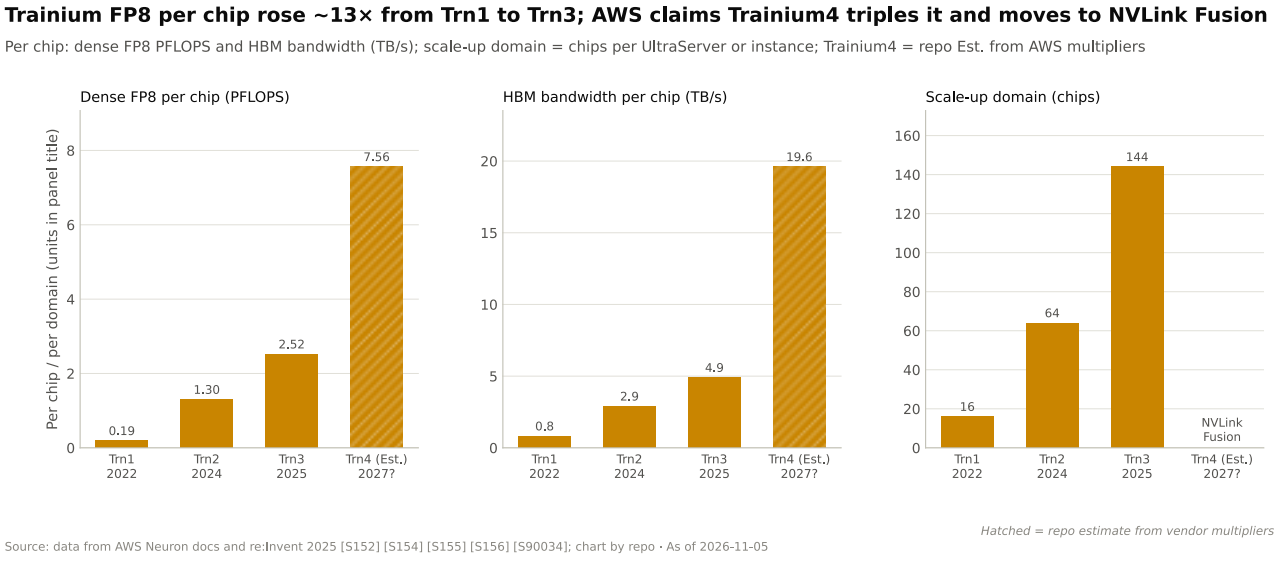


三个柱状面板，展示 AWS Trainium 历代产品。单芯片稠密 FP8：Trn1 0.19 PFLOPS（2022）、Trn2 1.3（2024）、Trn3 2.52（2025），三年约增长 13 倍；根据 AWS 所称至少为 Trn3 的 3 倍，Trainium4 估计约为 7.6。HBM 带宽：0.82、2.9 和 4.9 TB/s，根据 AWS 所称的 4 倍，Trainium4 估计约为 19.6 TB/s。纵向扩展域：每个 Trn1 实例 16 颗芯片，每台 Trn2 UltraServer 64 颗，每台 Trn3 UltraServer 144 颗；Trainium4 将采用英伟达 NVLink Fusion，因此其域规模尚未确定。

## 从 Annapurna Labs 到 Trainium4

AWS 的芯片来自 Annapurna Labs，这是一家以色列初创公司，亚马逊于 2015 年以据报道约 $350–370M 的价格将其收购 [S4540]。Annapurna 先打造了 Nitro 卸载卡，随后推出 Graviton Arm CPU（2018）、Inferentia 推理芯片和 Trainium [S4541,S7533]。Graviton5（2026）拥有 192 个核心 [S4526]。外部设计合作伙伴协助完成物理设计；TrendForce 报道称世芯（Alchip）获得了 Trainium3 订单，自 2026 年 Q2 起量产 [S2517]。

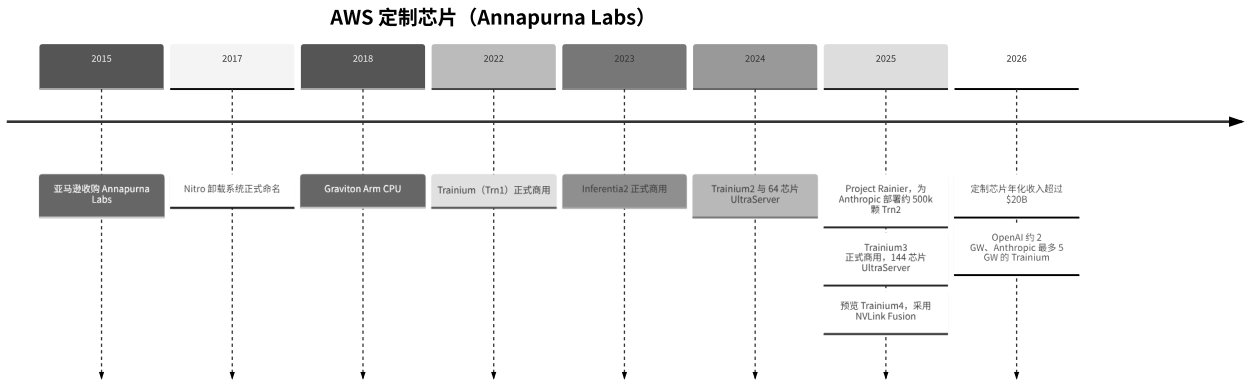


来源：[S4540,S7533,S4541,S152,S153,S352,S27011,S353,S90034,S15000]。

| 代际 | 正式商用 | 单芯片稠密 FP8 | 单芯片 HBM | 纵向扩展域 | 来源 |
|---|---|---|---|---|---|
| Trainium（Trn1） | 2022 年 10 月 | 0.19 PF | 32 GB，0.82 TB/s | 每实例 16 颗芯片 | S152 |
| Trainium2 | 2024 年 12 月 | 1.3 PF | 96 GB，2.9 TB/s | 64 芯片 UltraServer，3D 环面 | S154,S352,S245 |
| Trainium3（3 nm） | 2025 年 12 月 | 2.52 PF | 144 GB HBM3E，4.9 TB/s | 144 芯片 UltraServer，NeuronSwitch | S353,S242 |
| Trainium4 | 未定档 | ≥ Trn3 的 3×（≥ 约 7.6 PF，估计） | 容量 2×、带宽 4×（估计约 288 GB、约 19.6 TB/s） | NVLink Fusion，MGX 机架 | S90034,S518 |

**提示**

**算例 —— 同样的机架，两倍的芯片。** 一台 Trn3 UltraServer 提供 144 × 2.52 ≈ **362 PFLOPS** 稠密 FP8 和 144 × 144 GB ≈ **20.7 TB** HBM3E [S353]。一个 GB300 NVL72 机架提供 72 × 5.0 = **360 PFLOPS** 和 72 × 288 GB = **20.7 TB** [S32004,S123]。在 HBM 总带宽上 AWS 甚至略胜一筹：706 vs 576 TB/s。**结论：** AWS 需要两倍数量的芯片（以及芯片间的链路）才能达到同样的机架水平。其押注在于：由于无需支付商用厂商利润，每颗 Trn3 对 AWS 的成本远低于其采购 GB300 所需价格的一半。

### 🔧 技术细节：NeuronLink、NeuronSwitch 与转向 NVLink

Trainium2 UltraServer 将 64 颗芯片跨两个机架连接成 4 × 4 × 4 环面：实例内每芯片约 1 TB/s，实例间 256 GB/s [S244,S245]。Trainium3 新增了 NeuronSwitch-v1，这是一种全交换式互连架构，配合 NeuronLink-v4，每芯片约 2 TB/s（有分析师称最高 2.5 TB/s）[S242,S247]。这使 AWS 向英伟达的交换式 NVL72 设计靠拢，而远离谷歌（Google）的环面拓扑。Trainium4 转向 NVLink Fusion 则更进一步：它采用英伟达的 NVLink 6 协议和 MGX 机架，而不是继续扩展 AWS 的自有方案 [S518]。据报道，NVLink Fusion 系统必须包含部分英伟达芯片，例如英伟达 CPU 或 NVLink 交换芯片（🟡）[S5020]。

### NVLink Fusion: 8 launch partners, 13 by June 2026, one hyperscale XPU

Publicly announced NVLink Fusion partners by category and announcement date (filled = company-confirmed, hollow = reported)

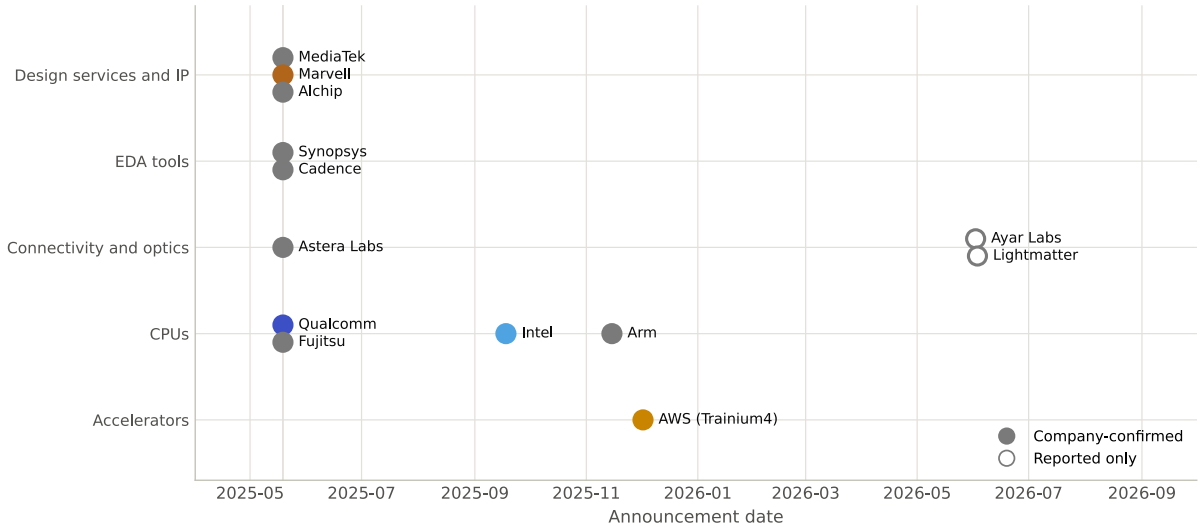


Source: data from NVIDIA; partner and press reports [S131] [S216] [S90037] [S4516] [S90031] [S4529] ...; chart by repo · As of 2026-11-05

> NVLink Fusion 合作伙伴时间线点图。2025 年 5 月 19 日发布时：联发科、美满电子和世芯（设计服务），Synopsys 和 Cadence（EDA），Astera Labs（连接），高通和富士通（CPU）。此后：英特尔 x86 CPU（2025 年 9 月）、Arm Neoverse（2025 年 11 月）、AWS Trainium4（2025 年 12 月，唯一的超大规模云厂商加速器），以及有报道但未经证实的光学领域的 Ayar Labs 和 Lightmatter（2026 年 6 月）。AMD、博通和谷歌缺席。

### Vera Rubin gives each GPU 88 host threads, 3× DGX H100; a Trainium3 gets 16

Host CPU hardware threads (vCPUs) per accelerator; labels add physical cores where known; hatched = announced

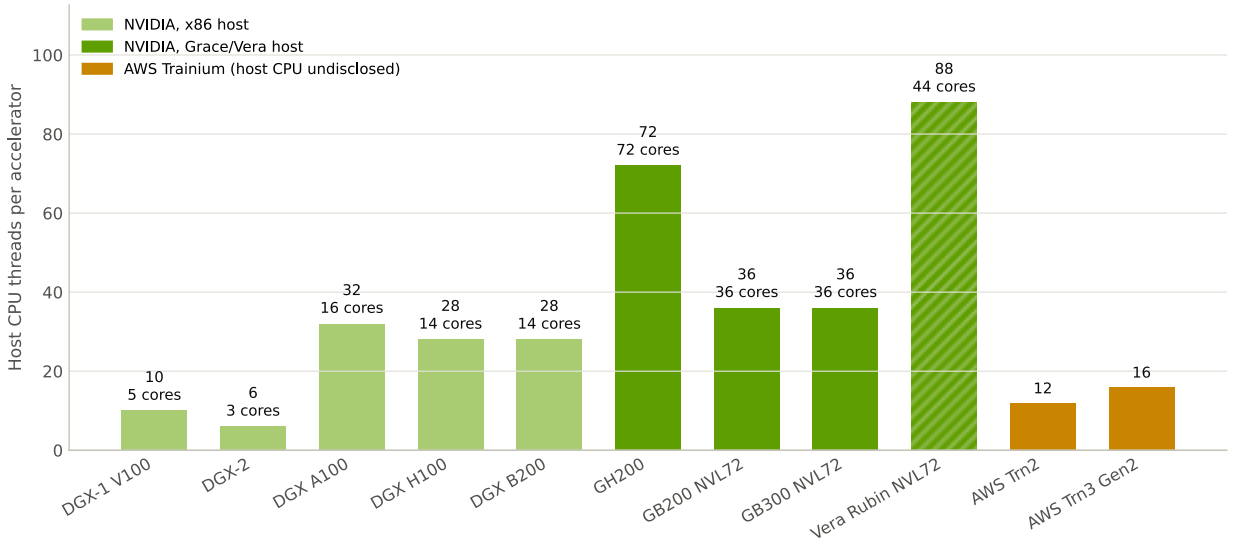


Source: data from NVIDIA DGX datasheets; NVIDIA Grace/Vera; AWS Neuron docs [S189] [S312] [S222] [S313] [S314] [S188] ...; chart by repo · As of 2026-11-05

> 每个加速器所配主机 CPU 线程数柱状图：DGX-1 V100 为 10，DGX-2 为 6，DGX A100 为 32，DGX H100 为 28，DGX B200 为 28，GH200 为 72（72 个 Grace 核心，无 SMT），GB200 和 GB300 NVL72 为 36，Vera Rubin NVL72 为 88（44 个 Olympus 核心，每核两个线程）；AWS Trn2 实例每颗 Trainium2 配 12 个主机 vCPU，Trn3 Gen2 UltraServer 每颗 Trainium3 配 16 个，因此英伟达的机架设计中每个加速器配备的主机算力是其数倍。

第二张图显示了一个相关的取舍：每颗 Trainium3 约分得 16 个主机 CPU 线程，而 Vera Rubin 中每颗 GPU 有 88 个。原因在于 AWS 让每台主机挂载大量加速器，而英伟达则按照依赖 CPU 的智能体（agentic）工作负载来配置 Vera（见第 04 层）[S4021,S354]。

## Neuron SDK：软件差距

Neuron SDK 为 Trainium 编译 PyTorch 和 JAX 计算图 [S9014]。自定义内核使用 Python 内核语言 NKI 编写，AWS 也提供预构建的 NKI 内核 [S9014,S10539]。2026 年，AWS 新增了 TorchNeuron——一个支持 eager 模式和 torch.compile 的原生 PyTorch 后端 [S9525]——以及用于大模型并行的 NeuronX Distributed [S594]。

> **提示**
>
> **算例 —— 为何 7/36 对 AWS 来说仍然够用。** 在本资料库的框架指数中，Neuron 得分 7/36，CUDA 为 36 [S594,S580]。一家使用十几种工具的企业将面临大量移植项目。而 Anthropic 只以超大规模运行少数几个模型系列，并有工程师参与共同开发 Trainium [S656]。若移植每年需要约 $100M 的工程投入（🔴 示意），而 Anthropic 的 Trainium 集群每年花费约 $10B，那么 10% 的成本优势足以十倍覆盖移植成本。**结论：** Trainium 的软件只需对少数巨型租户足够好即可，这正是它在覆盖广度上落后、却仍能赢得吉瓦级订单的原因。

## Project Rainier、Anthropic 与 OpenAI：需求侧

AWS 于 2025 年 10 月启用了 Project Rainier：在印第安纳州部署了近 500,000 颗 Trainium2 芯片，专为 Anthropic 打造 [S27011]。亚马逊已向 Anthropic 投资 $8B，后者将 AWS 指定为其主要训练合作伙伴 [S656]。2026 年 4 月，亚马逊披露 Anthropic 将获得最多 5 GW 的当前及未来各代 Trainium，OpenAI 将自 2027 年起使用约 2 GW 的 Trainium [S15000]。AWS 称 Trainium 收入承诺超过 $225B [S15001]。

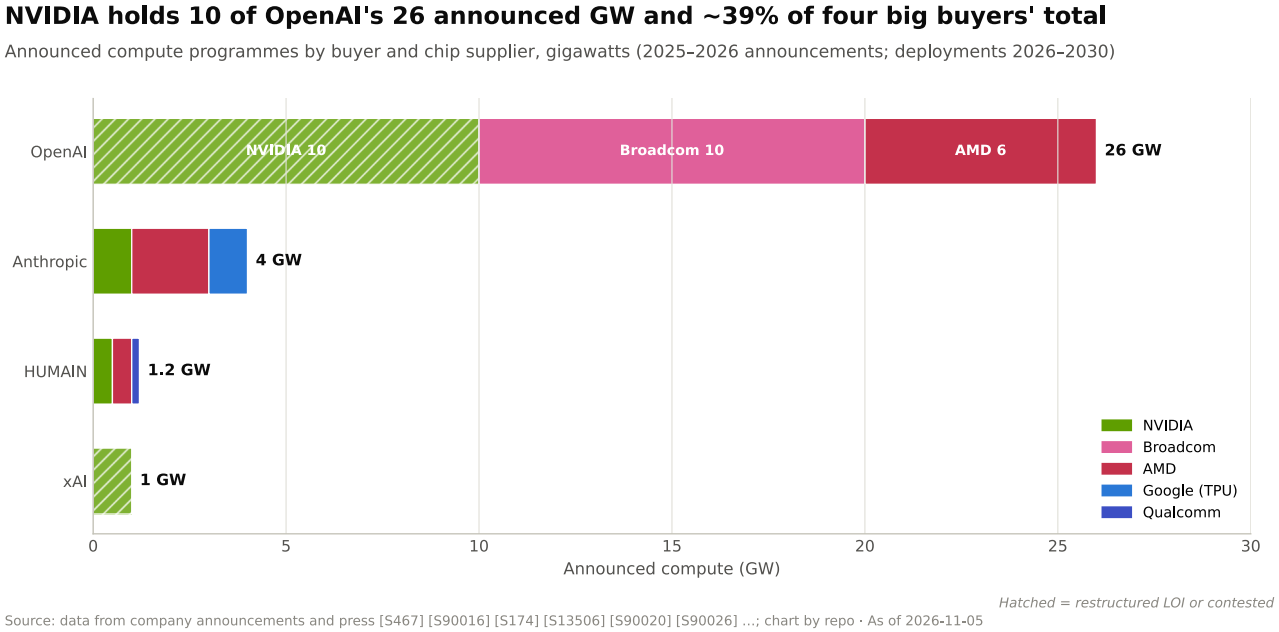


已公布算力项目（按吉瓦计）的堆叠水平柱状图。OpenAI 26 GW：英伟达 10（2025 年 9 月意向书，此后已重组）、博通定制加速器 10、AMD 6。Anthropic 4 GW：AMD Helios 最多 2（附带 AMD 最多 $5B 的投资）、英伟达最多 1、谷歌 TPU 2026 年超过 1 GW（2027 年起进一步的数吉瓦 TPU 扩容尚未量化）。HUMAIN：英伟达最多 0.5 GW、AMD 0.5 GW、高通 0.2 GW。xAI：约 1 GW 英伟达（公司说法，存在争议）。英伟达在这些项目中的份额约为 39%。

AWS 两头下注。2025 年 11 月，它签署了一项为期七年、约 $38B 的协议，为 OpenAI 托管英伟达 GB200 和 GB300 算力 [S15013]。它在 2024 年估计采购了 196,000 颗 Hopper GPU [S12014]。其 2026 年资本开支指引约为 $220B [S12519]。

**提示**

**算例 —— $225B 对应 7 GW 意味着什么。** $225B ÷ (5 + 2) GW ≈ **每 GW 约 $32B 的 Trainium 收入承诺** [S15000,S15001]。英伟达 CEO 称，在一座 1 GW 的 AI 工厂中英伟达的价值含量约为 $35B [S398]。两者口径并不完全可比（多年期云收入 vs 硬件销售，且为“最多”上限），但处于同一数量级。**结论：** 每一个 Trainium 吉瓦，大致就是一个流向别处的英伟达吉瓦；全部建成时，Trainium 的承诺约相当于英伟达 FY2026 一年的数据中心收入（约 $194B）[S1]。

## AWS 内部与英伟达的经济性对比

AWS 对 Trainium 的定价低于同类 GPU 实例，但未公布每 token 基准测试；Trainium 缺席 MLPerf 和 InferenceX [S620]。最清晰的公开信号是亚马逊自己对其芯片业务的表述。

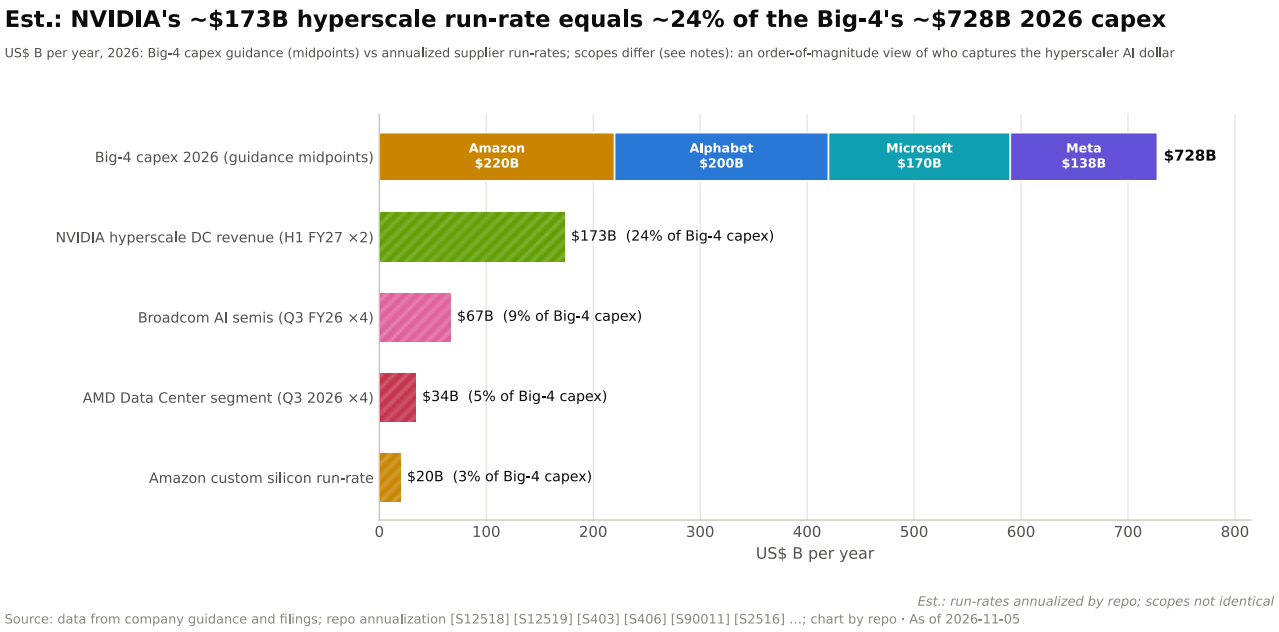


水平柱状图。四家最大的超大规模云厂商对 2026 年资本开支的指引约为 $728B（亚马逊约 $220B、Alphabet 约 $200B、微软约 $170B、Meta 约 $138B，取中值）。相比之下，英伟达来自超大规模客户的数据中心收入年化约 $173B（FY2027 上半年乘以二），约占资本开支的 24%；博通 AI 半导体收入年化约 $67B（Q3 FY2026 乘以四，含网络及非超大规模客户）；亚马逊自有定制芯片业务的年化收入已超过 $20B；AMD 整个数据中心分部年化约 $34B。大部分资本开支流向建筑、电力、网络和内存，而非加速器。

**提示**

**算例 —— 解读 Jassy 的“$20B vs $50B”。** 亚马逊表示其定制芯片业务年化收入超过 $20B，若作为独立业务出售则约为每年 $50B [S15000]。两者之比 20 ÷ 50 = **0.4**，表明 AWS 内部对其芯片的估值约为商用等价价格的 40%：其余约 60% 大致相当于商用厂商会收取的利润（🔴 本资料库对一个假设情形的解读）。英伟达约 75% 的毛利率意味着其成本约为售价的 25% [S405]。**结论：** 自研芯片收回了大部分（而非全部）商用厂商利润，因为 AWS 仍需按市场价向设计合作伙伴、台积电和 HBM 供应商付款。

**🔧 技术细节：AWS 为何仍需要英伟达**

许多 AWS 客户需要 CUDA，前沿实验室也会先在英伟达平台上训练新架构。因此 AWS 采取双轨策略：一边销售英伟达算力（包括与 OpenAI 的交易 [S15013]），一边引导自家大租户使用 Trainium。借助 Trainium4 上的 NVLink Fusion [S518]，AWS 获得了英伟达成熟的互连架构和机架，同时保留自有计算裸片；英伟达则在每个机架中保有一份收入。

# 分层级判定

### AWS Trainium averages 3.0 of 5 vs NVIDIA's 4.7, ahead only on Cost/TCO

Capability scores 0-5; AWS Trainium (filled) vs NVIDIA reference (dashed green); analyst judgement with sourced rationale

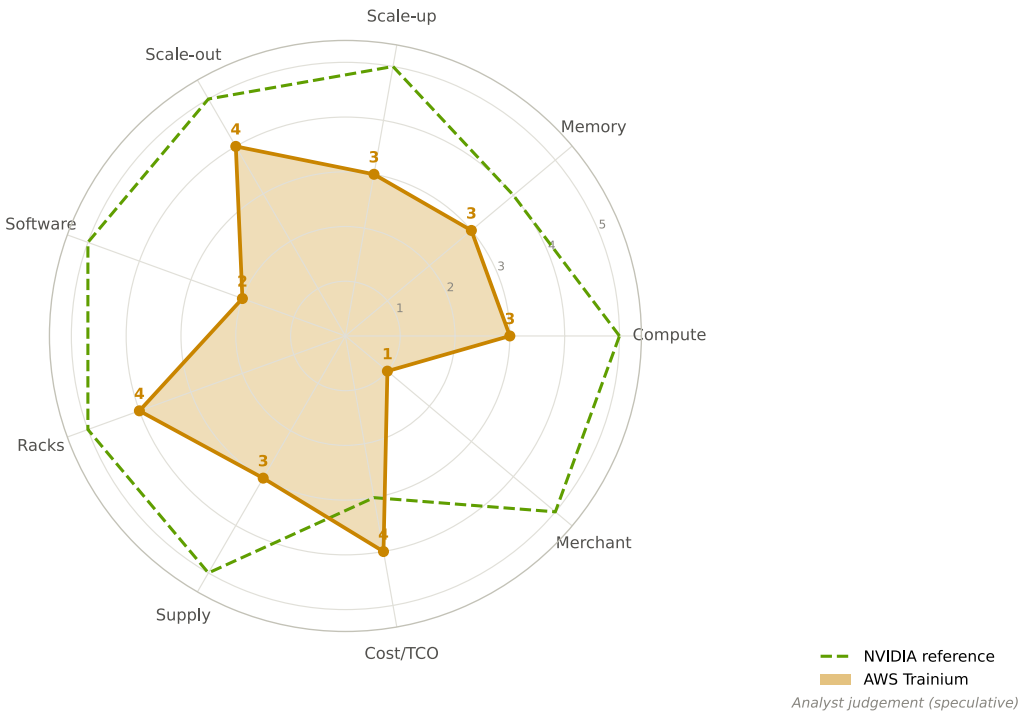


Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S143] [S361] [S630] [S402] ...; chart by repo · As of 2026-11-05

AWS Trainium 与英伟达在九个能力维度上的雷达图，按 0-5 分评分（本资料库分析师判断）：算力 3 vs 5；内存 3 vs 4；纵向扩展 3 vs 5；横向扩展 4 vs 5；软件 2 vs 5；机架 4 vs 5；供应 3 vs 5；成本/TCO 4 vs 3；商用可得性 1 vs 5。平均 3.0 vs 4.7。Trainium 是为 AWS 内部的成本而生：成本和机架强，软件（2 分）和商用可得性（1 分，仅限 AWS）弱。

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟥 落后 | Trn3 单芯片 2.52 PFLOPS FP8、144 GB，约为 GB300 的一半 S353 |
| 03 内存、封装与供应 | 🟥 落后 | 设计合作伙伴争夺 CoWoS 产能时排在英伟达和谷歌之后 S2517 |
| 04 CPU | 🟨 持平 | Graviton5（192 核）是成熟的 Arm 服务器 CPU S4526 |
| 05 纵向扩展 | 🟥 落后 | 144 芯片 NeuronSwitch 域；Trainium4 转向 NVLink Fusion S242,S518 |
| 06 横向扩展 | 🟦 路线不同 | 基于自研以太网架构的 EFA，不对外销售 S352 |
| 07 DPU 与卸载 | 🟦 路线不同 | Nitro，在 AWS 内部成熟且无处不在 S7533 |
| 08 系统与机架 | 🟥 落后 | UltraServer 已达到 Rainier 规模，但仅限 AWS 内部 S27011 |
| 09 系统软件 | 🟥 落后 | Neuron 在框架指数中得分 7/36 S594 |
| 10 软件库 | 🟥 落后 | NKI 库覆盖面窄且尚不成熟 S10539 |
| 11 推理软件 | 🟥 落后 | 大规模为 Claude 提供服务；无 MLPerf 或 InferenceX 结果 S620 |
| 12 编排与云 | 🟩 领先 | AWS 是最大的云平台；Trainium 仅以服务形式出售 S15000 |
| 13 生态与资本 | 🟥 落后 | 两大锚定租户，外部吸引力有限 S656,S15000 |

本资料库分析师判断，依据 `data/competitor_matrix.csv`（🔴） S15014。

> **提示**
>
> **算例 —— 纸面上的 Trainium4 与 Rubin 对比。** 将 AWS 公布的倍数应用于 Trainium3，可得单芯片 ≥ 约 7.6 PFLOPS FP8 和约 19.6 TB/s HBM 带宽（估计）[S90034,S353]。Rubin 标称 17.5 PFLOPS 和 19.2 TB/s [S33005,S90006]。**结论：** Trainium4 将在内存带宽上与当前的 Rubin 持平（约 102%），算力约为其 43%——这是推理优先芯片的典型特征；但如果它在 2027 年出货，面对的将是 Rubin Ultra 而非 Rubin。

**其最有力的论据。** “够用、更便宜、已经在你的云里。”AWS 能以低于英伟达实例的价格出售 Trainium，因为它获取了商用厂商的利润，而且其两大 AI 租户已承诺了吉瓦级算力。它无需在单芯片上击败英伟达，只需让自家机架的每 token 成本更低。

**差距缩小了多少。**

| 指标 | 过去 | 现在（2026 年 11 月） | 来源 |
|---|---|---|---|
| 单芯片稠密 FP8 对比英伟达旗舰 | 10%（Trn1 vs H100，2022） | 50%（Trn3 vs GB300，2025） | S15014 |
| 内存带宽对比英伟达旗舰 | 24%（Trn1） | 61%（Trn3） | S15014 |
| 纵向扩展域 | 16 颗芯片 | 144 颗芯片（NVL72：72） | S152,S353 |
| 已承诺需求 | 内部及小型租户 | Anthropic 最多 5 GW，OpenAI 约 2 GW，超过 $225B | S15000,S15001 |
| 独立基准测试 | 无 | 无 | S613,S620 |

> **注**
>
> 🐂 **看多观点（对 AWS 而言）。** 在所有超大规模云厂商芯片中，Trainium 拥有最大的已承诺外部需求，并享有掌控整个云平台的经济性。Trainium4 的 4× 带宽跃升将使其在纸面上接近 Rubin 的 19.2 TB/s，而 NVLink Fusion 则补上了 AWS 最薄弱的层级——纵向扩展（scale-up）[S90034,S518]。

> **注意**
>
> 🐻 **看空观点（对 AWS 而言）。** 采用 NVLink Fusion 等于承认 AWS 自有的互连架构不够用，并让英伟达在每个 Trainium4 机架上收取“过路费”。Trainium 没有经过审计的基准测试。其需求依赖于两家同时采购英伟达、AMD 和 TPU 的实验室，而其软件得分仅为 7/36 [S594]。

## 🎯 企业发展视角

1. **NVLink Fusion 作为一种商业模式。** AWS 选择将 Trainium4 接入英伟达的互连架构，而不是自建或采用 UALink [S518]。这对构建有竞争力的纵向扩展互连所需的成本和时间释放了什么信号？还有谁可能跟进？
2. **锚定租户模式。** Trainium 的软件只需服务少数巨型租户。商用挑战者能否通过与一家实验室结盟来复制这一模式？这需要怎样的股权或算力条款（可对比 AMD 的认股权证）？
3. **设计合作伙伴的风险敞口。** 据报道，世芯和美满电子（Marvell）负责打造各代 Trainium [S2517]。每家设计公司的收入对单一超大规模云厂商的集中度有多高？这种地位能否跨代延续？
4. **定制芯片作为一个可报告的业务分部。** 亚马逊如今像谈论一条产品线一样谈论其芯片业务（年化 $20B）[S15000]。如果 AWS 像谷歌如今对待 TPU 那样在 AWS 之外销售 Trainium，商用加速器市场将如何变化？

# 微软 Maia —— 为 Copilot 打造的推理引擎

跨层专题 15 · 竞争格局 · Maia 100/200/300、Cobalt CPU、与 OpenAI 的关系 · 约 13 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **起步晚，跟进快。** Maia 100（2023 年发布，2024 年公布细节）仅在内部有限使用 [S157]。Maia 200 于 2026 年 1 月发布，已部署在美国、欧洲和澳大利亚，并运行 Microsoft 365 Copilot [S158,S90044]。
- **纯推理设计。** Maia 200 将超过 10 PFLOPS 的 FP4 和超过 5 PFLOPS 的 FP8 算力，与 216 GB、约 7 TB/s 的 HBM3E 以及 272 MB 片上 SRAM 相结合，功耗为 750 W [S158]。微软（Microsoft）宣称其每美元性能比其集群中的最新硬件高约 30% [S15007]。
- **Maia 300 瞄准 Rubin 级内存。** 该芯片于 2026-10-12 发布，标称 288 GB HBM4、18 TB/s 带宽和最高 13.8 PFLOPS FP4，功耗 950 W，采用 96 芯片机架，计划 2027 年量产（🟢 已发布，厂商数据）[S15005,S15006,S90046]。
- **数吉瓦级的雄心。** 微软计划自 2027 年起进行数吉瓦级的 Maia 部署，据报道正就超过 300,000 颗 Maia 300 与台积电（TSMC）洽谈产能（🟡）[S90045,S559]。
- **OpenAI 的芯片工作反哺 Maia。** 微软可获取 OpenAI 与博通（Broadcom）联合开发的系统级芯片 IP，并表示将在此基础上开发 Maia [S15008]。
- **弱点：** 微软是 2024 年英伟达（NVIDIA）Hopper 的最大买家（约 485,000 颗，估计），目前仍以英伟达为主 [S12014]。Maia 200 的内存带宽约为 Rubin 的 36%，没有公开基准测试，软件也仅为自有模型打造 [S15014]。

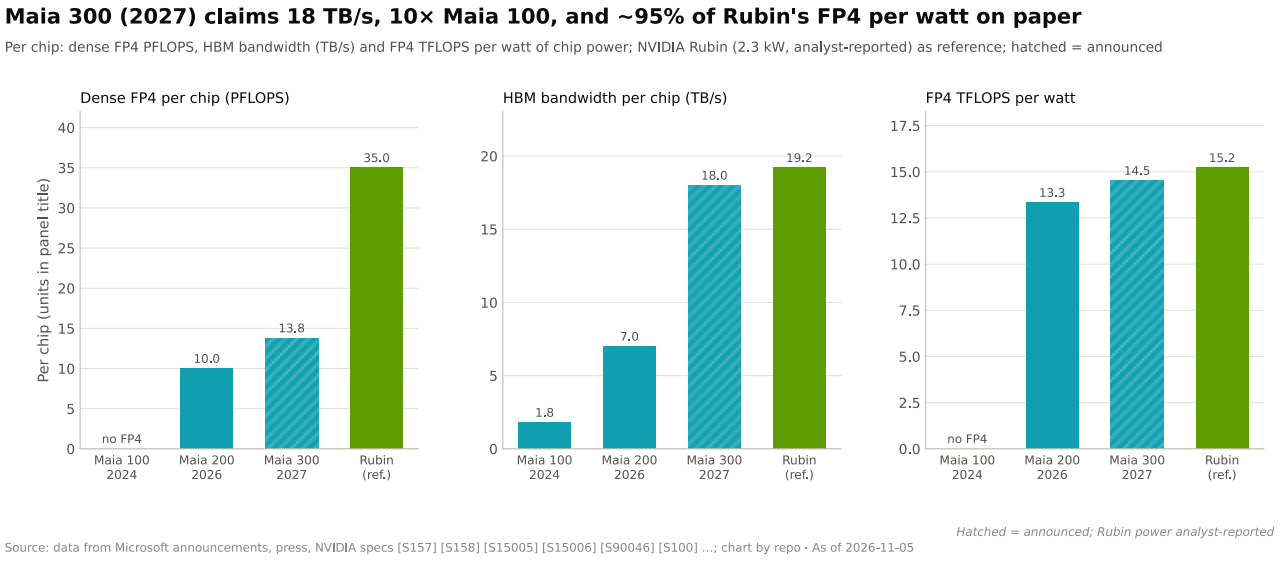


> 三个柱状面板，展示微软 Maia 历代产品，并以英伟达 Rubin 为参照。稠密 FP4：Maia 100 不支持 FP4，Maia 200 至少 10 PFLOPS（2026），Maia 300 最高 13.8（2027），Rubin 为 35。HBM 带宽：1.8、7.0 和 18 TB/s，Rubin 为 19.2。每瓦 FP4：Maia 200 在 750 W 下约 13.3 TFLOPS/W，Maia 300 在 950 W 下约 14.5，Rubin 在据报道的 2.3 kW 下约 15.2。Maia 在纯推理设计中以峰值算力换取能效；Maia 300 的所有数据均为微软说法。

## Maia 100 → 200 → 300

| 代际 | 发布时间 | 工艺 | 内存 | 峰值算力 | 功耗 | 部署 | 来源 |
|---|---|---|---|---|---|---|---|
| Maia 100 | 2023 年 11 月 | 台积电 N5，约 820 mm² | 64 GB HBM2E，1.8 TB/s | 约 0.8 PFLOPS BF16 | 配置功耗 500 W | 有限，内部使用 | S157 |

| 代际 | 发布时间 | 工艺 | 内存 | 峰值算力 | 功耗 | 部署 | 来源 |
|---|---|---|---|---|---|---|---|
| Maia 200 | 2026 年 1 月 | 台积电 N3，超过 140B 个晶体管 | 216 GB HBM3E，约 7 TB/s；272 MB SRAM | >10 PFLOPS FP4，>5 FP8 | 750 W | 🟢 美国、欧洲、澳大利亚；运行 Copilot | S158,S90044 |
| Maia 300 | 2026 年 10 月 | 台积电 N2P 计算裸片 + 2 个 I/O 裸片 | 288 GB HBM4，18 TB/s | 最高 13.8 PFLOPS FP4 | 950 W | 🟢 已发布；2027 年量产 | S15005,S15006 |

Maia 300 是微软首款小芯片（chiplet）设计：一个 N2P 计算裸片、两个 I/O 裸片和八个 HBM4 堆栈[S15005]。一个机架在 167 kW 的功率包络内容纳 96 个加速器。微软宣称其每兆瓦 token 数比“领先的基于 GPU 的系统”高约 40%，单机架吞吐量是 Maia 200 的 7×。两者均为未经验证的设计目标[S15005]。

**提示**

**算例 —— “数吉瓦”换算成芯片是多少。** 一个 Maia 300 机架为 96 颗芯片耗电 167 kW：含机架开销，**每颗芯片约 1.74 kW**[S15005]。据报道的 300,000 颗芯片将消耗 300,000 × 1.74 kW ≈ 520 MW 的 IT 负载，按 1.15 的 PUE 计约为 600 MW（🔴 本资料库测算）[S559]。**结论：** 首批 Maia 300 订单大约相当于半个吉瓦。“自 2027 年起数吉瓦”[S90045] 意味着跨代累计远超一百万颗 Maia 芯片——其集群规模可与微软 2024 年采购的约 485,000 颗 Hopper GPU 相比，但单颗功耗为其数倍[S12014]。

**🔧 技术细节：为什么推理芯片可以更简单**

推理时每个 token 只需一次前向传播；训练还需要反向传播、优化器状态和高精度累加。放弃训练能力后，芯片可以缩减或去除 FP64/FP32 单元，缩小纵向扩展（scale-up）互连（Maia 200 每芯片提供 2.8 TB/s 双向带宽[S158]），并把芯片面积用于 SRAM 和低精度运算。Maia 200 的 272 MB SRAM 将热点权重和 KV 缓存块保存在靠近计算单元的位置。微软还与其他 OCP 成员共同定义了微缩放（microscaling）（MX）格式，通过每 32 个元素块共享一个缩放因子，使 4 位和 6 位数值保持精度[S2007]。

## 能效：ASIC 的取舍

与大多数超大规模云厂商不同，微软会公布芯片功耗。纸面上，Maia 以峰值算力换取能效。

**Rubin leads FP8 per watt (~7.6 TFLOPS/W); Maia 200 is next at ~6.7**

Dense FP8 TFLOPS per watt of chip/module power vs memory per chip; bubble area = memory bandwidth (TB/s)

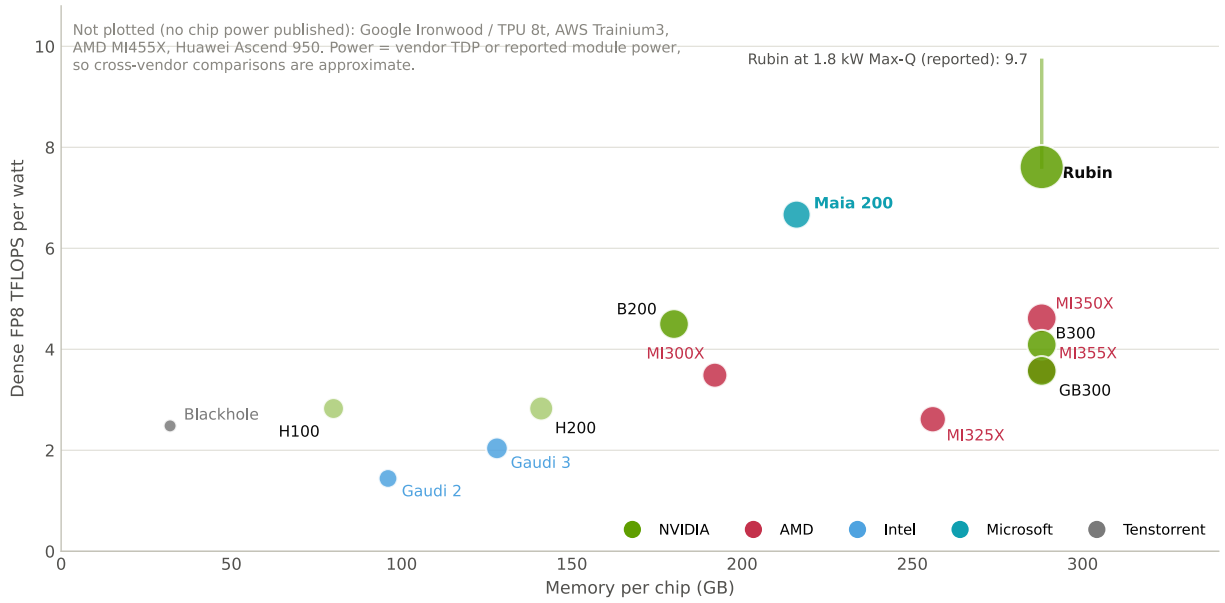


Source: data from vendor specifications (power partly reported) [S33002] [S35011] [S35013] [S32002] [S33003] [S35014] …; chart by repo · As of 2026-11-05

每瓦稠密 FP8 TFLOPS 与单芯片内存的散点图。英伟达 Rubin 在据报道的 2.3 kW 下约为 7.6 TFLOPS/W（1.8 kW 下约 9.7），内存 288 GB；微软 Maia 200 约为 6.7，内存 216 GB；AMD 最佳的 MI350X 约为 4.6，内存 288 GB；B200 为 4.5，GB300 为 3.6，MI355X 为 3.6，H100 为 2.8，Gaudi 3 为 2.0。谷歌 TPU、AWS Trainium、AMD MI455X 和华为 Ascend 950 未绘出，因为其芯片功耗未公布。

**提示**

**算例 —— 每兆瓦芯片功耗的 FP4 算力。** 1 MW 可供约 1,333 颗 750 W 的 Maia 200（≥ 13.3 EF FP4），或约 435 颗据报道功耗 2.3 kW 的 Rubin GPU（约 15.2 EF 稠密 FP4）[S158,S106,S33005]。950 W 的 Maia 300 可达每瓦约 14.5 TFLOPS，纸面上约为 Rubin 的 95% [S15005]。**结论：** 纯推理 ASIC 通过放弃通用性，使每瓦算力接近英伟达。悬而未决的是实际利用率和软件，而这些在规格表上看不出来。

## Cobalt 与微软的其他芯片

Maia 是微软三款自研芯片之一。Azure Cobalt 100（128 个 Arm Neoverse N2 核心）于 2024 年 10 月正式商用 [S183]；Cobalt 200（基于台积电 3 nm 的 132 个 Neoverse V3 核心）于 2025 年 11 月推出，同时发布了新的 Azure Boost 卸载卡 [S184,S4024]。三者合力，使微软能够打造一个 CPU、卸载卡和加速器均为自研的机架。不过它仍从英伟达采购大部分 AI 算力，且据报道是 AMD Helios 的首个大型部署方（🟡）[S90024]。

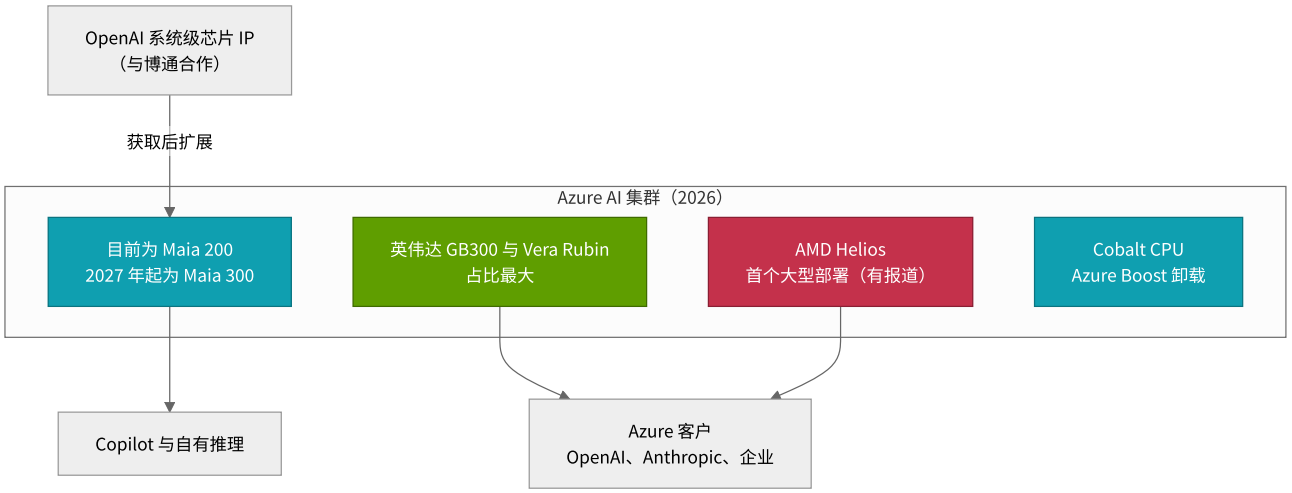


来源：S12014,S90024,S15005,S183,S184,S15008,S90044,S90075。

**Est.: three hyperscalers bought ~850K of ~1.73M tracked Hopper GPUs in 2024 (49%)**

Hopper GPUs bought in 2024 by buyer, thousands (Omdia Est.) · CoreWeave bar = installed base, all generations

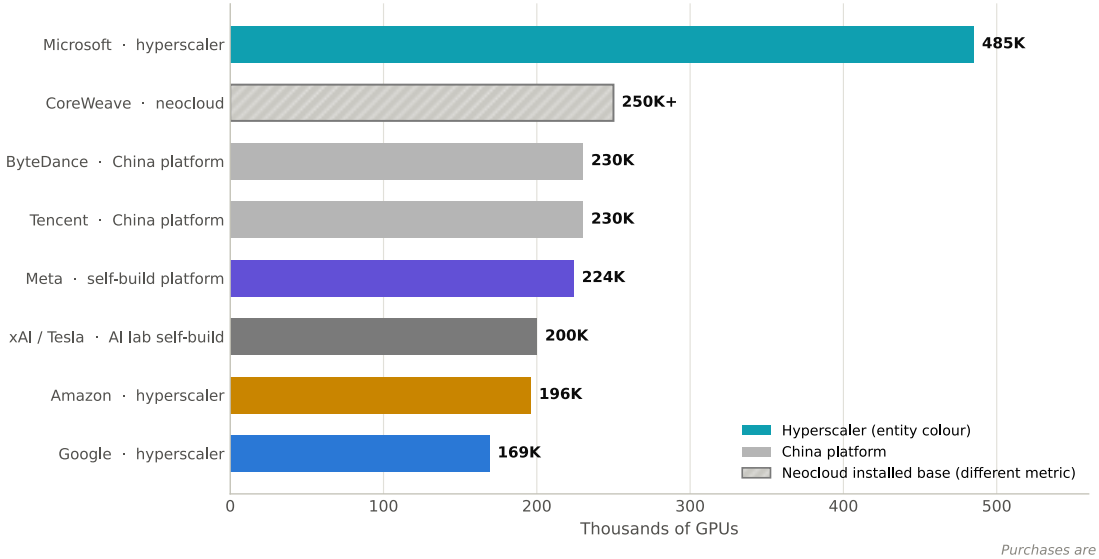


*Purchases are Omdia estimates (Est.)*

Source: data from Omdia via Financial Times / DCD; CoreWeave S-1 [S12014] [S12011]; chart by repo · As of 2026-11-05

> 按买家划分的 2024 年 Hopper GPU 采购量估计（Omdia）水平柱状图：微软 485,000；字节跳动和腾讯各约 230,000（主要为中国特供版 H20/H800）；Meta 224,000；xAI/特斯拉约 200,000；亚马逊 196,000；谷歌 169,000。三家超大规模云厂商合计约 850K，占所追踪的约 1.73M 颗的 49%。作为对比，CoreWeave 报告称截至 2024 年底已部署超过 250K 颗各代 GPU。

> **提示**
>
> **算例 —— 如果 CPU 只占机架成本约 2%，为何还要自研？** 摩根士丹利估计，一个约 $7.8M 的 Vera Rubin 机架中 36 颗 Vera CPU 价值约 $180k，约占其成本的 2.3% [S331]。用 Cobalt 替换它们节省不了多少硬件开支。**结论：** Cobalt 的价值在于掌控力：微软可以决定 Maia 机架的主机软件、卸载方案（Azure Boost）和配比，并把这一层排除在英伟达的物料清单之外。

## 与 OpenAI 的关系

微软的芯片战略与 OpenAI 紧密交织。在 2025 年 10 月的重组中，OpenAI 承诺额外采购 $250B 的 Azure 服务，微软放弃了作为 OpenAI 算力供应商的优先购买权，并保留了该公司约 27% 的股份 [S15009]。一个月后，微软 CEO 表示，微软可获取 OpenAI 与博通联合开发的系统级芯片成果，并将先加以实现、再进一步

扩展 [S15008]。微软还承诺向 Anthropic 投资最多 $5B，而 Anthropic 则承诺采购 $30B 基于英伟达系统的 Azure 算力 [S90075]。

> **提示**
>
> **算例 —— OpenAI 的芯片能为 Maia 带来什么。** SemiAnalysis 报道称，OpenAI 由博通打造的推理 ASIC 在单个 N3P 裸片上提供 13.4 PFLOPS 的 MXFP4 算力，配备 15.4 TB/s 的 HBM4（🟡）[S628]。Maia 300 标称最高 13.8 PFLOPS FP4 和 18 TB/s [S15005]。**结论：** 两款设计处于同一级别，因此这项 IP 权利的意义与其说是获得一款更好的芯片，不如说是在无需额外研发成本的情况下获得第二支设计团队，以及博通的封装和供应链。无论内部哪款设计胜出，这都降低了微软留在定制芯片竞赛中的成本。

## 分层级判定

### Microsoft Maia averages 2.6 of 5 vs NVIDIA's 4.7 and is ahead on no axis

Capability scores 0-5; Microsoft Maia (filled) vs NVIDIA reference (dashed green); analyst judgement with sourced rationale

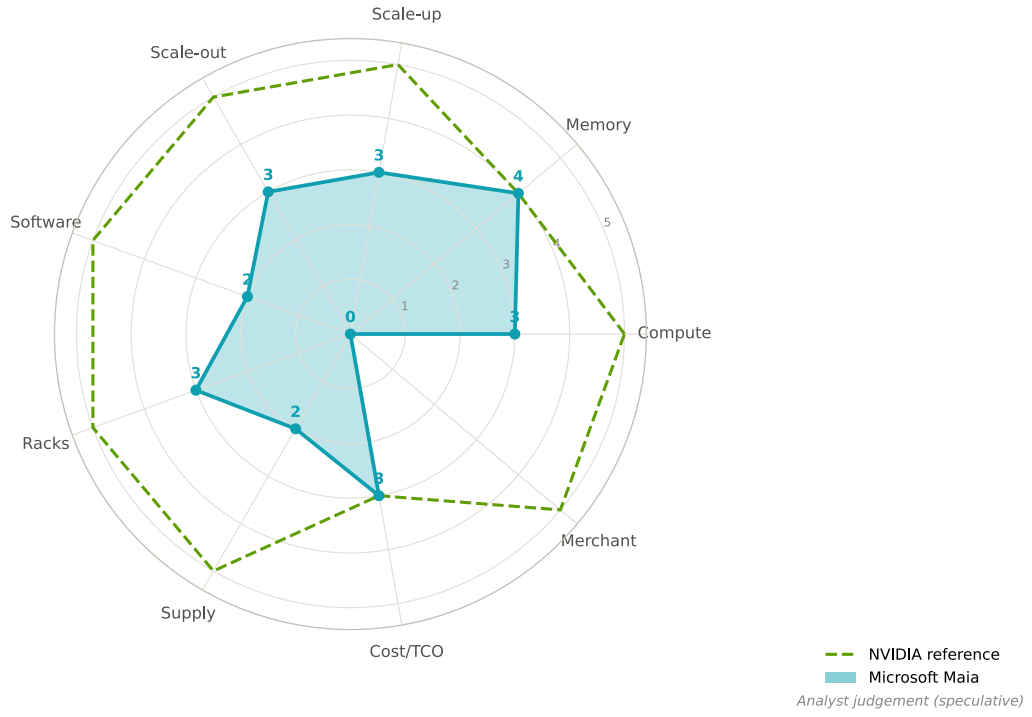


Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S143] [S361] [S630] [S402] ...; chart by repo · As of 2026-11-05

微软 Maia 与英伟达在九个能力维度上的雷达图，按 0-5 分评分（本资料库分析师判断）：算力 3 vs 5；内存 4 vs 4；纵向扩展 3 vs 5；横向扩展 3 vs 5；软件 2 vs 5；机架 3 vs 5；供应 2 vs 5；成本/TCO 3 vs 3；商用可得性 0 vs 5。平均 2.6 vs 4.7。Maia 是一个内部推理项目：芯片处于中游水平，软件和供应较弱，商用可得性为零。

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟥 落后 | Maia 200 >5 PFLOPS FP8 vs Rubin 17.5；Maia 300 要到 2027 年 [S158,S33005] |
| 03 内存、封装与供应 | 🟥 落后 | 仍在为 Maia 300 洽谈台积电产能 [S559] |
| 04 CPU | 🟥 落后 | Cobalt 处于早期部署阶段；没有一致性 CPU-加速器链路 [S184] |
| 05 纵向扩展 | 🟥 落后 | 基于以太网每芯片 2.8 TB/s，集群最多 6,144 颗芯片 [S158] |
| 06 横向扩展 | 🟦 路线不同 | Azure 以太网架构，不对外销售 [S6005] |
| 07 DPU 与卸载 | 🟦 路线不同 | Azure Boost，内部使用 [S4024] |
| 08 系统与机架 | 🟥 落后 | 相比 Azure 的英伟达资产，集群规模较小；96 芯片 Maia 300 机架于 2027 年推出 [S15005] |
| 09 系统软件 | 🟥 落后 | Maia SDK（基于 Triton）仅用于自有模型 [S158] |

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 10 软件库 | 🟥 落后 | 软件库生态极为有限 S158 |
| 11 推理软件 | 🟥 落后 | 运行 Copilot；无公开基准测试 S90044 |
| 12 编排与云 | 🟩 领先 | Azure 位列前两大云平台；OpenAI 承诺 $250B S15009 |
| 13 生态与资本 | 🟥 落后 | 内部项目；微软仍是英伟达的头部客户 S12014 |

本资料库分析师判断，依据 `data/competitor_matrix.csv`（🔴）S15014。

> **提示**
>
> **算例 —— “每美元性能提升 30%”值多少钱。** 每美元多完成 30% 的工作，意味着完成同样工作的成本为 1 ÷ 1.3 ≈ 77%，即节省 23% S15007。若微软自有推理每年使用约 $5B 的加速器算力（🔴 示意），在全面采用的情况下 Maia 每年可节省约 $1.2B。**结论：** 对于一家公司自身的流量而言，这笔收益很可观，但它随 Maia 在微软集群中的占比而扩大，而目前这一占比仍然很小。

**其最有力的论据。** “我们自己的 token，按我们自己的成本。”Copilot 和 Azure 的自有服务产生了巨大且可预测的推理需求。一款只针对这一需求调优、每美元性能提升约 30% 的芯片 S15007，可以在微软为自己提供的每一个 token 上省钱，而无需赢得外部开发者。

**差距缩小了多少。**

| 指标 | 过去 | 现在（2026 年 11 月） | 来源 |
|---|---|---|---|
| 内存带宽对比英伟达旗舰 | 38%（Maia 100 vs H200，2024） | 36%（Maia 200 vs Rubin）；Maia 300 宣称 2027 年达到当前 Rubin 的 94% | S15014,S15005 |
| HBM 容量 | 64 GB | 216 GB（Maia 200），288 GB（Maia 300） | S157,S158,S15005 |
| 部署 | 内部有限使用 | 在三个地区量产部署；计划自 2027 年起达到数吉瓦 | S90044,S90045 |
| 公开基准测试 | 无 | 无 | S613 |

> **注**
>
> 🐂 **看多观点（对微软而言）。** Maia 300 的 18 TB/s 和 288 GB 在内存上与当前的 Rubin 相当，其宣称的每兆瓦 token 数 40% 优势瞄准的正是功率受限数据中心最看重的指标，而 OpenAI 的 IP 权利为微软带来了第二支设计团队 S15005,S15008。

> **注意**
>
> 🐻 **看空观点（对微软而言）。** Maia 每次都晚到一代：Maia 300 于 2027 年出货时，英伟达已转向 Rubin Ultra S90003。所有性能说法都是厂商数据。微软仍是英伟达最大的客户之一，Azure 也必须继续提供英伟达产品才能赢得外部工作负载 S12014。

## 🎯 企业发展视角

1. **自用推理需求。** Maia 的立论基础是自有工作负载（Copilot、Foundry）S15007。还有哪些公司拥有足够的自有推理需求来支撑一款推理 ASIC？商用推理厂商能否以低于定制项目的成本为它们提供服务？
2. **IP 共享作为一种新的交易形式。** 微软获取 OpenAI 芯片 IP 的权利 S15008 是一种合作结构，而非收购。类似的“授权 + 联合开发”交易，能否让其他公司无需组建完整的设计团队就进入定制芯片领域？
3. **每兆瓦 token 数成为主战场。** Maia 300 的核心宣传点是每 MW token 数比 GPU 高 40% S15005。如果买家采用这一指标，什么样的验证能让挑战者的说法令人信服：MLPerf Power、InferenceX 还是客户披露？

4. **第二供应商带来的议价筹码**。 微软采购英伟达、部署 AMD Helios（🟡）并自研 Maia [S90024]。Maia 的价值有多少来自芯片本身，又有多少来自它为 Azure 在与英伟达谈判时提供的价格筹码？

# Meta MTIA —— 英伟达最大自建型客户的自研对冲

跨层专题 15 · 竞争格局 · 从 MTIA v1 到 MTIA 500、Rivos、Meta 与 AMD、TPU 和英伟达的交易 · 约 13 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **MTIA 起步于推荐芯片。** MTIA v1（2023）和 v2（2024）是采用 LPDDR5 内存的小型低功耗芯片，用于广告和信息流排序：v2 在 90 W 功耗下提供 177 TFLOPS BF16 算力，内存 128 GB、带宽约 0.2 TB/s [S159,S160]。
- **2026 年它转型为 HBM 级推理产品线。** Meta 宣布以约六个月的节奏推出四代产品：MTIA 300（已量产）、400、450 和 500（2027）。MTIA 500 标称最高 27.6 TB/s 的 HBM 带宽和 10 PFLOPS FP8 算力（🟢 已发布；🟡 媒体规格表）[S15003,S15002,S561]。
- **Meta 在收购芯片人才。** 它收购了 RISC-V 初创公司 Rivos（2025 年 10 月，条款未披露，据报道估值约 $2B），以加速 MTIA 开发（🟡）[S15004,S4518]。
- **Meta 同时也是其他所有厂商的头部买家。** 2026 年，它承诺采购“数百万颗”英伟达（NVIDIA）Blackwell 和 Rubin GPU 以及 Grace CPU [S4006]，最多 6 GW 的 AMD Instinct（附 160M 股认股权证）[S24004]，以及数十亿美元的谷歌（Google）TPU 租用（🟡）[S90025]。其 2026 年资本开支指引为 $130–145B [S12518]。
- **它掌控着其他对手所缺乏的软件层。** Meta 创建了 PyTorch；MTIA 的编译器基于 TorchInductor、Triton 和 MLIR 构建，Meta 还与谷歌联合开发了 TorchTPU [S9028,S553]。
- **弱点：** MTIA 仅限内部使用，相比 Meta 的 GPU 集群规模仍然较小；MTIA 300 的内存带宽约为 Rubin 的 32%，稠密 FP8 约为其 7%（本资料库测算）[S15014]。

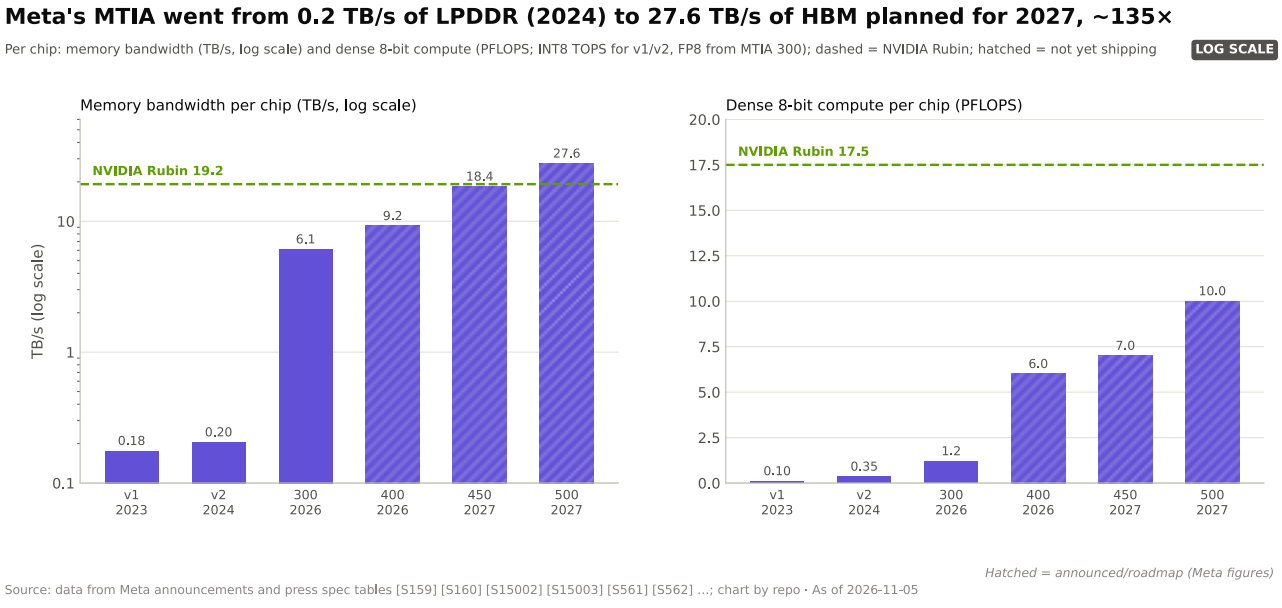


Source: data from Meta announcements and press spec tables [S159] [S160] [S15002] [S15003] [S561] [S562] ...; chart by repo · As of 2026-11-05

两个柱状面板，展示 Meta MTIA 历代产品。单芯片内存带宽（对数刻度）：MTIA v1 为 0.18 TB/s、v2 为 0.20 TB/s 的 LPDDR5（2023-24），随后转向 HBM：MTIA 300 为 6.1 TB/s（2026 年量产），MTIA 400 为 9.2，MTIA 450 为 18.4，MTIA 500 为 27.6（2027），约为 v2 的 135 倍，纸面上超过 Rubin 的 19.2 TB/s。稠密 8 位算力：v1 和 v2 分别为 0.10 和 0.35 POPS INT8，随后为 1.2、6、7 和 10 PFLOPS FP8，Rubin 为 17.5。Meta 将 MTIA 从小型推荐芯片转向以六个月为周期迭代的 HBM 级生成式 AI 推理芯片。

## MTIA 历代产品：从排序到生成式 AI

| 代际 | 年份 | 内存 | 带宽 | 稠密 8 位算力 | 功耗 | 状态 | 来源 |
|---|---|---|---|---|---|---|---|
| MTIA v1 | 2023 | 128 GB LPDDR5 | 0.18 TB/s | 102 TOPS INT8 | 25 W | 🟢 已出货 | S159 |
| MTIA v2 | 2024 | 128 GB LPDDR5 + 256 MB SRAM | 0.20 TB/s | 354 TOPS INT8 | 90 W | 🟢 已出货 | S160 |
| MTIA 300 | 2026 | 216 GB HBM | 6.1 TB/s | 约 1.2 PFLOPS FP8 | 800 W | 🟢 已量产 | S15002,S561 |
| MTIA 400 | 2026 | 288 GB HBM | 9.2 TB/s | 6 PFLOPS FP8（12 MX4） | 1,200 W | 🟡 发布时处于实验室测试阶段 | S15002,S562 |
| MTIA 450 | 2027 | 288 GB HBM | 18.4 TB/s | 7 PFLOPS FP8（21 MX4） | 1,400 W | 🟡 路线图 | S15002,S15003 |
| MTIA 500 | 2027 | 384–512 GB HBM | 27.6 TB/s | 10 PFLOPS FP8（30 MX4） | 1,700 W | 🟡 路线图 | S15002,S15003 |

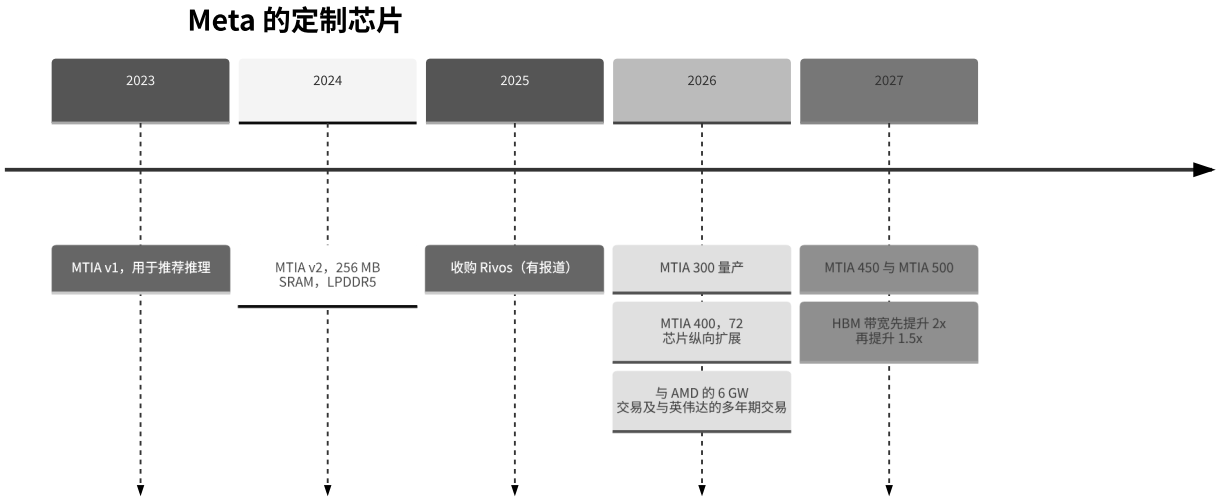


来源：S159,S160,S4518,S561,S562,S24004,S4006,S15003。

为何转型？推荐模型每次查询只需在庞大的嵌入表中查找少数几行，因此需要的是*容量*，便宜的 LPDDR 即可满足。大语言模型每生成一个 token 都要重新读取全部权重，因此需要的是*带宽*，而只有 HBM 能够提供。

> **提示**
>
> **算例 —— 为何 MTIA v2 无法服务大语言模型（LLM）。** 一个 70B 参数的 FP8 模型约有 70 GB 权重，每个解码（decode）步骤都要重新读取一遍。以 MTIA v2 的 0.2 TB/s 计算，单芯片单流速度上限约为 3 tokens/s；以 MTIA 400 的 9.2 TB/s 计约为 131 tokens/s；以 MTIA 500 的 27.6 TB/s 计约为 394 S160,S15002。**结论：** 正是向 HBM 的跃升，让 MTIA 从排序加速器转变为生成式 AI 推理芯片。纸面上 MTIA 500 的带宽（27.6 TB/s）超过 Rubin 的 19.2 TB/s，尽管它要晚一年推出 S90006。

> **🔧 技术细节：六个月的迭代节奏与共享机架**
>
> Meta 表示 MTIA 400、450 和 500 共用同一套机箱和机架设计，因此每款新芯片都能直接装入现有基础设施 S561。这正是 Meta 能够大约每六个月推出一款芯片的原因——是英伟达一年一代节奏的两倍：机架、供电和散热保持不变，只更换芯片。MTIA 400 引入了 72 个加速器的纵向扩展（scale-up）域，与 NVL72 规模相同 S562。

根据 Meta 的数据，MTIA 500 的每瓦带宽约为 16 GB/s（1,700 W 下 27.6 TB/s），而 Rubin 约为每瓦 8 GB/s（据报道 2.3 kW 下 19.2 TB/s）[S15002,S106]。软件栈为 PyTorch 原生，通过 torch.compile 和 torch.export 支持 eager 模式和图模式，编译器基于 TorchInductor、Triton、MLIR 和 LLVM 构建 [S9028]。

## Meta 的芯片战略：部分自研，大部分外购

Meta 运营着公有云之外最大的 AI 集群。其 2026 年资本开支指引为 $130–145B（含融资租赁）[S12518]。它正在建设 Prometheus（俄亥俄州，2026 年超过 1 GW，目标约 1M 颗 GPU）和 Hyperion（路易斯安那州，将扩展至 5 GW）[S27007,S27009]。MTIA 是这一扩建中的对冲手段，而非替代方案。

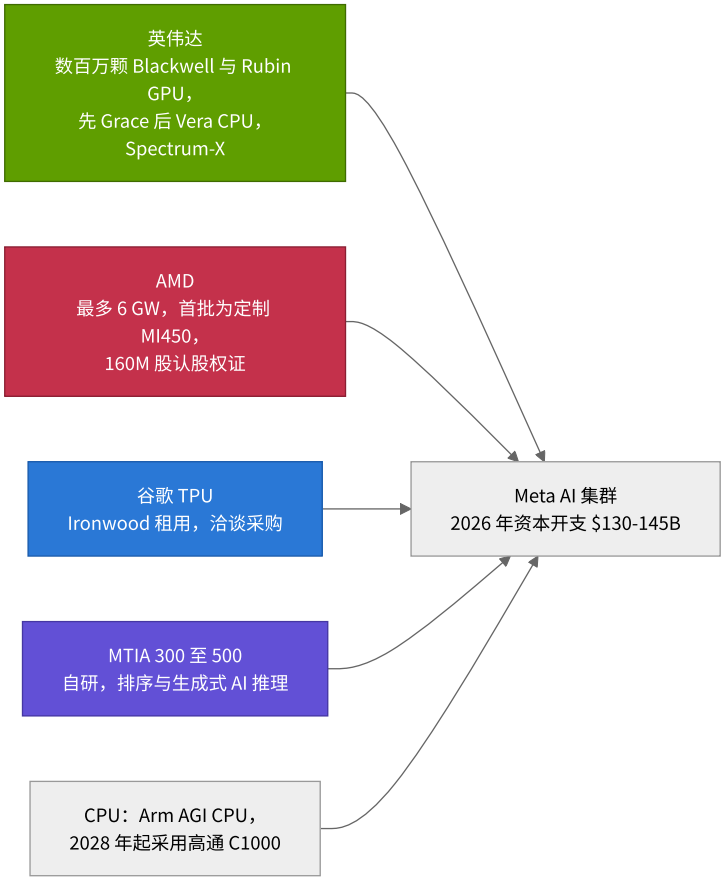


来源：[S4006,S6009,S24004,S90025,S15003,S4510,S90058,S12518]。

| 供应商 | Meta 的承诺内容 | 状态 | 来源 |
|---|---|---|---|
| 英伟达 | 多年期：数百万颗 Blackwell 和 Rubin GPU；大规模采用独立 Grace CPU，随后为 Vera；Spectrum-X 以太网 | 🟢 | S4006,S4519,S6009 |
| AMD | 最多 6 GW 的 Instinct，首批为基于 MI450 的定制部件；最多 160M 股的认股权证 | 🟢 | S24004 |
| 谷歌 | 数十亿美元的 Ironwood 租用；洽谈为自有站点采购 TPU | 🟡 | S90025 |
| CoreWeave | 截至 2031 年 $14.2B 的算力 | 🟢 | S12527 |
| Arm | Arm 自研 AGI CPU 的首个客户 | 🟢 | S4510 |
| 高通（Qualcomm）（公开信息） | Dragonfly C1000 服务器 CPU 的首个具名客户，2028 年下半年起量产 | 🟢 | S90058 |

**Alphabet, Amazon and Meta first guided ~$505B of 2026 capex, 4.0× their $127B in 2022; guides have since risen to ~$558B**

Capex, US$ B per fiscal year; 2026 = first guidance (Jan–Feb 2026); dashed/hollow = outlook or unverified; MSFT FY ends Jun (ex-leases), Oracle May

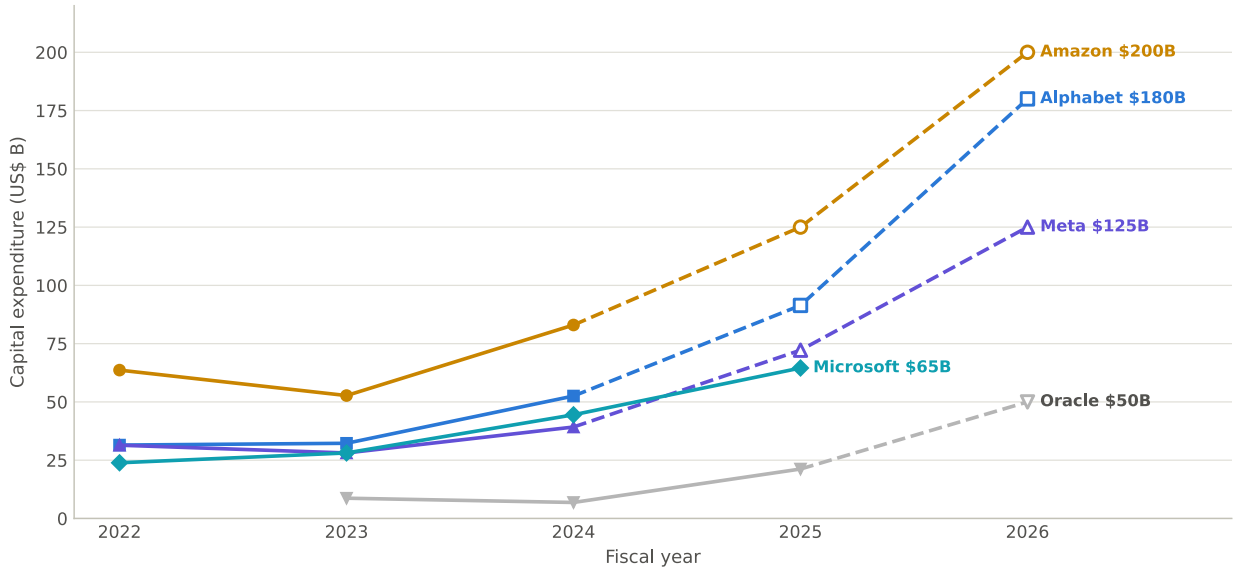


*Latest 2026 guide midpoints (Jul–Oct 2026): Big 3 ~$558B*

Source: data from company 10-Ks and outlooks [S455] [S460] [S456] [S461] [S457] [S462] ...; chart by repo · As of 2026-11-05

2022–2026 年超大规模云厂商资本开支折线图：Alphabet、亚马逊和 Meta 合计从 2022 年的 $127B 增至其 2026 年首次指引的约 $505B（亚马逊约 $200B、Alphabet 中值约 $180B、Meta 中值约 $125B），到 2026 年 10 月已上调至约 $558B；微软 FY2025 达到 $65B，甲骨文 FY2026 指引约 $50B。

## Big-3 2026 capex guides rose from ~$505B to ~$558B; ~$728B incl. Microsoft

Calendar-2026 capital-expenditure guidance midpoints by date issued, US$ B (whiskers = guided range)

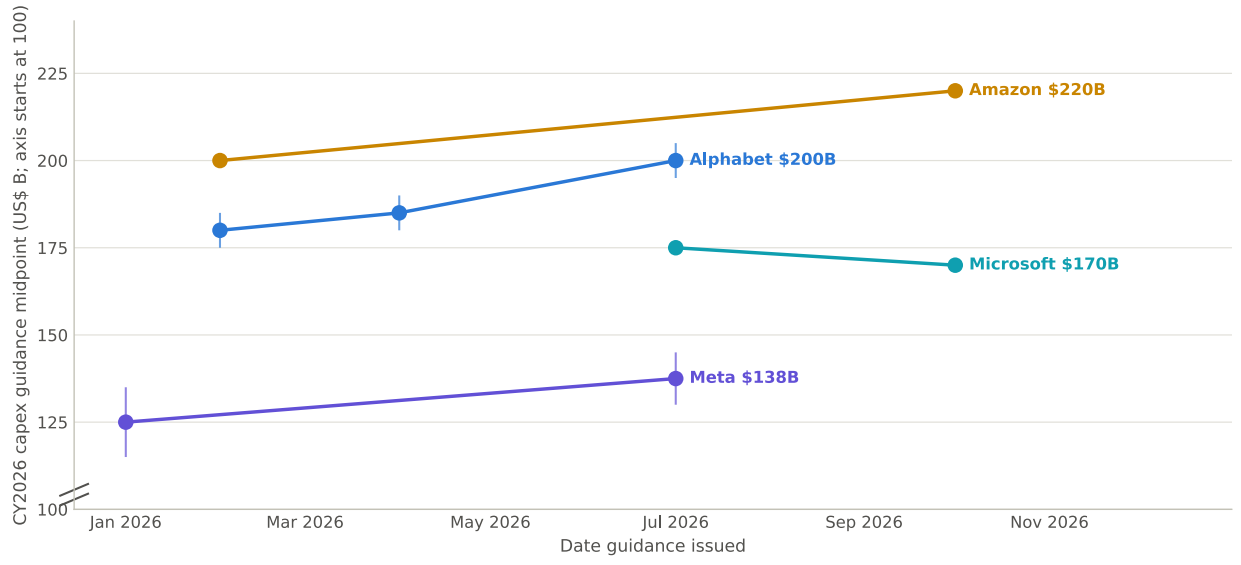


*Bases differ (leases)*

Source: data from company guidance as reported [S460] [S12518] [S461] [S12519] [S462]; chart by repo · As of 2026-11-05

2026 年资本开支指引中值折线图：Alphabet 从 $180B（2026 年 2 月）升至 $185B（4 月）和 $200B（7 月）；亚马逊从约 $200B 升至约 $220B；Meta 从 $125B（1 月）升至约 $137.5B（7 月）；微软自然年 2026 年的数据在 7 月约为 $175B，10 月约为 $170B。三大厂商合计从约 $505B 升至 $558B，四大厂商合计约 $728B；其他口径的统计达到 $803-828B。

> **提示**
>
> **算例 —— Meta 对英伟达承诺的规模。** 摩根士丹利估计一个 Vera Rubin NVL72 机架约 $7.8M，即每颗 GPU 约 $108K（估计）[S330]。一百万颗 Rubin 级 GPU——“数百万颗”的下限 [S4006]——对应约 $108B 的系统，约为 Meta 2026 年资本开支中值（$137.5B）的 80% [S12518]。AMD 的 6 GW 按每 GW $10–15B 计算，未来数年将再增加约 $60–90B（估计）[S24004]。**结论：** 与这些商用采购承诺相比，MTIA 的产出很小。其主要任务是降低 Meta 自身排序和推理流量的成本，并在与英伟达和 AMD 谈判时为 Meta 提供可信的备选方案。

## 分层级判定

### Meta MTIA averages 2.4 of 5 vs NVIDIA's 4.7, ahead only on Cost/TCO

Capability scores 0-5; Meta MTIA (filled) vs NVIDIA reference (dashed green); analyst judgement with sourced rationale

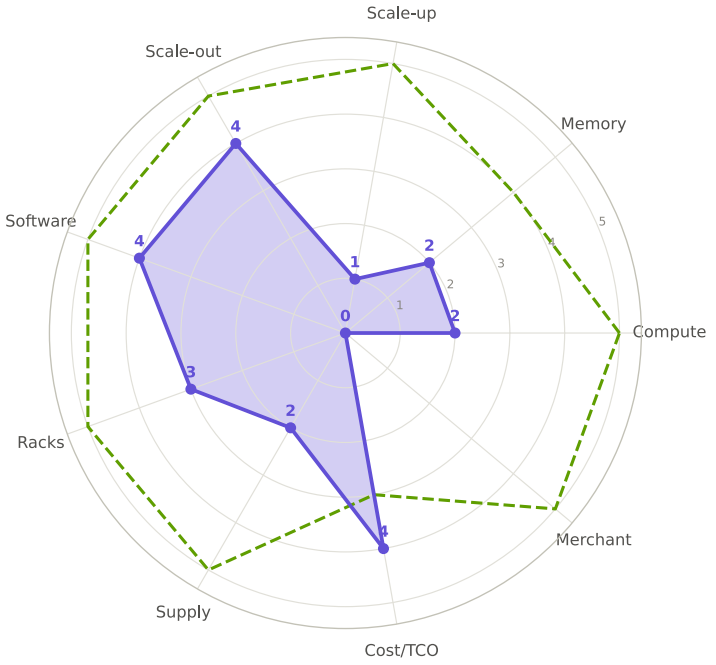


*Analyst judgement (speculative)*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S143] [S361] [S630] [S402] ...; chart by repo · As of 2026-11-05

Meta MTIA 与英伟达在九个能力维度上的雷达图，按 0-5 分评分（本资料库分析师判断）：算力 2 vs 5；内存 2 vs 4；纵向扩展 1 vs 5；横向扩展 4 vs 5；软件 4 vs 5；机架 3 vs 5；供应 2 vs 5；成本/TCO 4 vs 3；商用可得性 0 vs 5。平均 2.4 vs 4.7。MTIA 走的是不同路线：在 PyTorch 软件和 Meta 自建以太网上较强，在纵向扩展和供应上较弱，商用可得性为零。

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟦 路线不同（本页：生成式 AI 方面为 🟥） | 矩阵将 MTIA v2 作为排序芯片评分；MTIA 300 的稠密 FP8 约为 Rubin 的 7% [S160,S15014] |
| 03 内存、封装与供应 | 🟥 落后 | 出货量小；自 MTIA 300 起才采用 HBM [S561] |
| 04 CPU | 🟥 落后 | 没有 CPU 项目；采购 Grace、Arm AGI 及（2028 年起）高通 CPU [S4006,S4510,S90058] |
| 05 纵向扩展 | 🟥 落后 | 自 MTIA 400 起才有 72 芯片域 [S562] |
| 06 横向扩展 | 🟦 路线不同 | 超大规模的自建 RoCE 以太网集群 [S34022] |
| 07 DPU 与网卡 | 🟥 落后 | 与美满电子（Marvell）合作的定制 FBNIC 前端网卡；后端网卡外购 [S7525] |
| 08 系统与机架 | 🟦 路线不同 | OCP 机架设计；同时也部署 GB200/GB300 机架 [S4006] |
| 09 系统软件 | 🟦 路线不同 | 掌控 PyTorch；MTIA 为 PyTorch 原生 [S9028] |

| 层级 | 相对英伟达的判定 | 理由 |
|---|---|---|
| 10 软件库 | 🟥 落后 | MTIA 专用软件库很少 S9028 |
| 11 推理软件 | 🟦 路线不同 | 服务 Meta 的排序推理；大语言模型主要运行在 GPU 上 S15003 |
| 12 编排与云 | 🟦 路线不同 | 仅限内部 |
| 13 生态与资本 | 🟥 落后 | Meta 的影响力在于作为买家，而非卖家 S24004,S90025 |

本资料库分析师判断，依据 `data/competitor_matrix.csv`（🔴）S15014。**存在分歧：** 矩阵按 MTIA v2 对芯片和纵向扩展评分；鉴于 MTIA 400–500 已发布，本页在生成式 AI 方面将芯片视为 🟥 落后，并记录 MTIA 400 的 72 芯片域，同时保留矩阵对纵向扩展的 🟥 评分。

> **提示**
>
> **算例 —— 快速迭代 vs 移动靶。** 到 2027 年底，Meta 计划推出四代 MTIA；英伟达届时将推出两代（Rubin，然后是 Rubin Ultra）S561,S90003。MTIA 500 的 10 PFLOPS FP8 和 27.6 TB/s，对比 Rubin Ultra 估计的每封装约 34.7 PFLOPS 和约 32 TB/s（估计）S15002,S35018：算力约为其 29%，带宽约为其 86%。**结论：** 快速迭代缩小内存差距的速度快于缩小算力差距，这更适合推理而非训练。

**其最有力的论据。** “我们掌控框架，也掌控工作负载。”Meta 掌控 PyTorch 及其自有的排序和生成式 AI 服务，因此 MTIA 不需要外部开发者；六个月的迭代节奏使其每年可以两次把新芯片装入同一机架 S9028,S561。

**差距缩小了多少。**

| 指标 | 过去 | 现在（2026 年 11 月） | 来源 |
|---|---|---|---|
| 内存带宽对比英伟达旗舰 | 4%（MTIA v2 vs H200，2024） | 32%（MTIA 300 vs Rubin）；MTIA 500 宣称 2027 年达到 27.6 TB/s | S15014,S15002 |
| 稠密 8 位算力对比英伟达旗舰 | 约 18%（v2 INT8 vs H200 FP8） | 约 7%（MTIA 300）；纸面上 MTIA 500 为 Rubin 的 57% | S15014 |
| 内存类型 | LPDDR5 | HBM | S160,S561 |
| 纵向扩展域 | 无 | 72 颗芯片（MTIA 400） | S562 |
| 迭代节奏 | 约每年 1 款芯片 | 约每年 2 款芯片 | S561 |

> **注**
>
> 🐂 **看多观点（对 Meta 而言）。** 在 MTIA v2 之后两年内，MTIA 500 的纸面规格在带宽和容量上已接近 Rubin。PyTorch 原生软件栈、固定的机架以及 Rivos 团队，有望让 Meta 在推理——其最大的 AI 工作负载——上实现自给自足 S15002,S9028,S15004。

> **注意**
>
> 🐻 **看空观点（对 Meta 而言）。** Meta 不断与英伟达和 AMD 签下创纪录的交易并租用 TPU：这是 MTIA 尚无法承担前沿工作的最明显信号 S4006,S24004,S90025。其最新芯片仍停留在纸面规格，Rivos 的整合尚未得到证实，而六个月的迭代节奏会成倍放大执行风险。

## 🎯 企业发展视角

1. **买家即造王者。** Meta 是 AMD 定制 MI450、Arm AGI CPU 以及高通公开的 C1000 路线图的首个客户 S24004,S4510,S90058。供应商应如何权衡赢得 Meta 这一标杆客户的价值，与 Meta 已表现出的多源采购和自研意愿？

2. **收购式招聘（acquihire）芯片团队**。 收购 Rivos（据报道约 $2B）为 Meta 带来了一支全栈芯片团队[S15004]。还有哪些独立设计团队可供收购？Meta 此举对它们的估值意味着什么？
3. **固定机架，快速芯片**。 Meta 为 MTIA 400–500 共用机箱[S561]，使芯片迭代节奏与数据中心设计脱钩。机架级标准化（OCP、MGX、Open Rack Wide）是否才是定制芯片的真正赋能因素？由谁来提供？
4. **推荐推理 vs 生成式推理**。 MTIA 起源于排序。鉴于超大规模云厂商自行满足自身需求，推荐和排序模型是否是商用厂商尚未充分服务的加速器市场？

# 英特尔：既是竞争对手，也是供应商和合作伙伴

跨层专题 15 · 竞争格局 · 阅读约 13 分钟 · 最后核实：2026-11-05

## ⚡ 要点速览

- **作为加速器竞争对手，英特尔（Intel）至今未能形成实质威胁。** 它先后收购了 Nervana（2016 年）和 Habana（~$2B，2019 年）[S2514]，未能实现 2024 年 $500M 的 Gaudi 收入目标 [S668]，并于 2025 年 1 月取消了 Falcon Shores 的产品化 [S15546,S564]。
- **重启路线是先做推理 GPU，后做机架。** Crescent Island（Xe3P，160 GB LPDDR5X，风冷）将于 2026 年下半年送样，并在 OCP 2026 上更名为 GPU D-Series；机架级产品 Jaguar Shores（SK 海力士 HBM4、硅光子）尚无确定日期，2027 年前推出的可能性不大 🟡 [S162,S15543,S15544,S15545]。
- **其数据中心业务本质上是 CPU 业务，且已恢复增长。** 数据中心与 AI 事业部 2026 年第三季度收入 ~$7.3B（同比 +78%），约为英伟达（NVIDIA）最近一个季度数据中心收入的 8% [S15543,S405]。按出货量计，英特尔仍占服务器 CPU 的 54.9%，但按收入计，AMD 已占 x86 服务器市场的 ~46% [S4503,S4505]。
- **英伟达持有其 ~4% 股份。** 英伟达 $5B 的入股（以 $23.28 认购 ~214.7M 股）已于 2025-12-26 完成交割，用于资助通过 NVLink 连接的定制 x86 CPU，以及 x86 RTX PC 芯片；数据中心产品尚无公开日期 🔴 [S4009,S15547,S130]。
- **供应商角色在于封装。** 英特尔的 EMIB-T 是大型 AI 封装绕开台积电（TSMC）的主要路径；据报道谷歌（Google）和亚马逊正在洽谈 🟡；估计显示，2027 年 EMIB-T 产能约为每月 ~15–20k 片 CoWoS 等效晶圆，而台积电 2026 年底的 CoWoS 产能为 ~130k（估计）[S3532,S3002]。
- **在纵向扩展（scale-up）之争中，英特尔两边下注：** 它既是 UALink 董事会成员，又是通过 NVLink 连接的 x86 合作伙伴 [S573,S130]。美国政府（9.9%）、软银（$2B）和英伟达如今都是其股东 [S15550,S15547]。
- **本资料库判断 🔴：** 作为加速器供应商威胁较低；但作为英伟达的 x86 合作伙伴，以及西方唯一的 先进封装第二供应来源，其重要性正在上升。

**Intel's data-center segment ($7.3B a quarter) is ~8% of NVIDIA's and under half of Broadcom's AI revenue**

Latest reported quarter of data-center (or AI) revenue per vendor, US$ B; segment definitions differ and are labelled

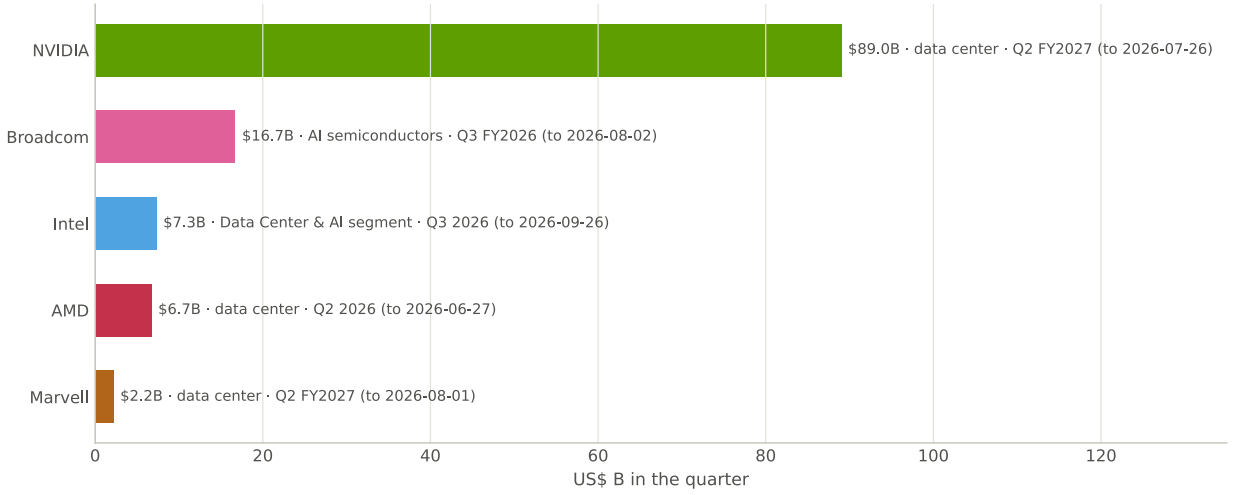


Source: data from company results [S15504] [S543] [S15543] [S15542] [S2516] [S405] ...; chart by repo · As of 2026-11-05

> 最近一个已公布季度的水平柱状图：英伟达数据中心 $89.0B（Q2 FY2027，截至 2026 年 7 月）；博通 AI 半导体 $16.7B（Q3 FY2026，截至 2026 年 8 月）；英特尔数据中心与 AI 事业部 $7.3B（2026 年第三季度，截至 2026 年 9 月，主要为 Xeon CPU，同比 +78%）；AMD 数据中心 $6.7B（2026 年第二季度，EPYC 加 Instinct）；美满电子数据中心 $2.2B（Q2 FY2027）。英特尔该事业部收入约为英伟达的 8%。

## 一家公司，三种角色

英特尔同时以三种方式触及英伟达的技术栈，而每种角色的方向各不相同。

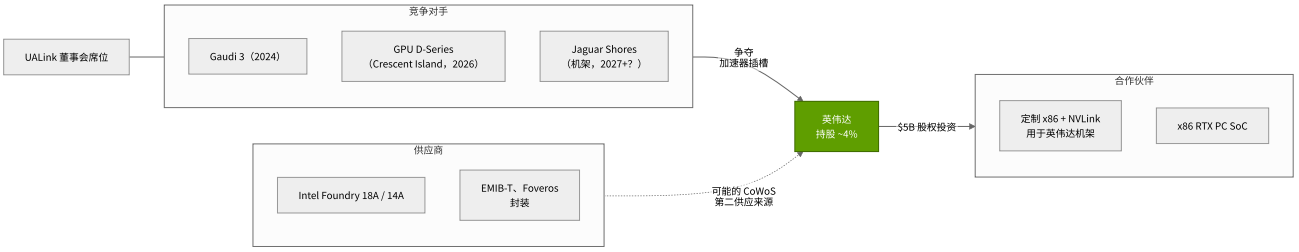


本页其余部分依次讨论这三种角色。CPU 细节见 CPU 竞争；封装细节见 CoWoS 与先进封装。

## 作为竞争对手的英特尔：Gaudi 的结局与 GPU 重启

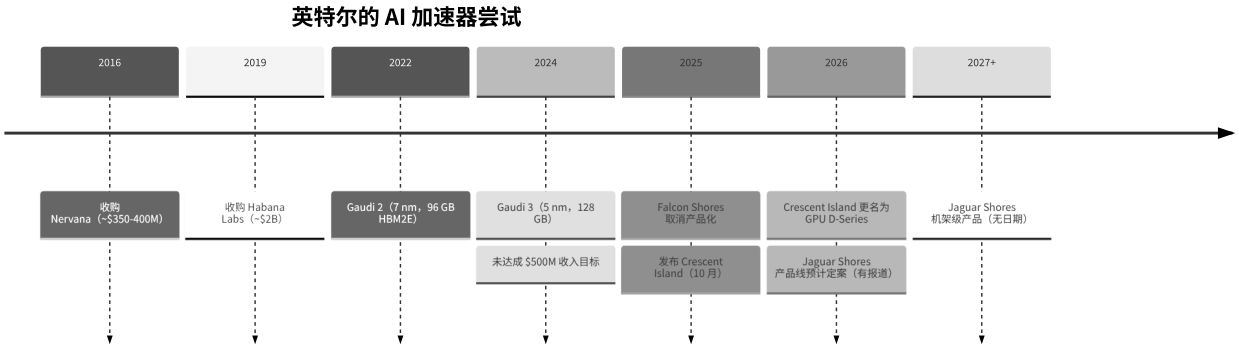


纸面上，Gaudi 3 与其发布时对标的 GPU 相比颇具竞争力。它在 900 W 模组中提供 1,835 TFLOPS 稠密 BF16/FP8 算力和 128 GB HBM2e（带宽 3.7 TB/s）[S161]，而 H100 为 80 GB、3.35 TB/s [S33002]。但它卖不动。原因 正是本资料库反复发现的那些：软件（大多数模型首先适配 CUDA）、纵向扩展（Gaudi 使用 24 个 200 GbE 端口， 其中 21 个用于 8 芯片全交换（all-to-all），因此不存在机架级互连域）[S296]，以及路线图可信度（先是 Gaudi，然后是 Falcon Shores，再到 Jaguar Shores）[S2515]。

| 加速器 | 年份 | 内存 | 带宽 | 稠密 FP8 | 纵向扩展 | 状态 | 来源 |
|---|---|---|---|---|---|---|---|
| Intel Gaudi 2 | 2022 | 96 GB HBM2E | 2.45 TB/s | 865 TFLOPS | 24 × 100 GbE，8 芯片 | 已出货 | S161 |
| Intel Gaudi 3 | 2024 | 128 GB HBM2e | 3.7 TB/s | 1,835 TFLOPS | 24 × 200 GbE，8 芯片 | 已出货 | S161,S296 |
| Intel GPU D-Series（Crescent Island） | 2026 | 160 GB LPDDR5X | 未披露 | 未披露 | 未披露 | 2026 年下半年送样 | S162,S15543 |
| Intel Jaguar Shores | 2027+ | HBM4（SK 海力士） | 未披露 | 未披露 | 机架级，光子互连 | 🟡 无日期 | S15544,S564 |
| NVIDIA H100 | 2022 | 80 GB HBM3 | 3.35 TB/s | 1,979 TFLOPS | NVLink 4，8 GPU | 已出货 | S33002 |
| NVIDIA Rubin | 2026 | 288 GB HBM4 | 19.2 TB/s | 17,500 TFLOPS | NVLink 6，72 个封装 | 爬坡中 | S90006,S90009 |

> **提示**
>
> **算例 —— 为何出色的规格没有转化为收入。** Gaudi 3 在稠密 FP8 上与 H100 相当，在内存上更胜一筹（128 GB 对 80 GB）[S161,S33002]，但 2024 年 Gaudi 收入仍低于 $500M [S668]，而英伟达 FY2025 数据中心收入为 $115.2B [S416]。以一台 8 芯片的 Gaudi 3 节点为例：其纵向扩展域为 8 颗芯片，而一台 GB200 NVL72 可将 72 颗 GPU 连入同一个 NVLink 域。对于把专家分布在数十颗芯片上的混合专家模型（MoE）而言，决定吞吐量的是节点边界，而不是单颗芯片（为何互连域规模至关重要）。规格让英特尔进入了评估环节；系统与软件上的差距则把它挡在了部署之外。

2026 年的计划收窄了目标。Crescent Island 是一款风冷推理卡，配备 160 GB LPDDR5X [S162]：这与 高通（Qualcomm）每张 AI200 卡配备 768 GB LPDDR 的“以容量换带宽”取舍如出一辙（高通）。它瞄准的是液冷和高带宽内存（HBM）成本构成门槛的企业推理服务器，而非前沿训练。

### 🔧 技术细节：“机架级 + 硅光子”对 Jaguar Shores 意味着什么

英特尔将 Jaguar Shores 描述为一款采用光互连和 SK 海力士 HBM4 的机架级设计；堆叠层数 和制程尚未确认（TrendForce 的图片显示为 18A）[S15544,S564]。机架级意味着英特尔必须交付 英伟达 NVL72 和 AMD Helios 已在出货的那一整套：交换式纵向扩展互连、液冷托盘、电源架，以及能够 把 72 颗以上芯片当作一个整体来调度的软件栈。光链路以激光器功耗和成本为代价，突破了铜缆的距离限制（约一个机架）。英特尔的 UALink 成员身份 [S573] 暗示了其纵向扩展协议的选择，但 UALink 产品预计要到 2027 年才会推出 [S90051]。若 Jaguar Shores 于 2027 年推出，其对手将是 Rubin Ultra（2027 年下半年）[S90003]。

**Intel trails NVIDIA in 10 of 12 layers; only its CPU is at parity and its packaging is a different route**

Repo scores 0-5 (analyst judgement, sourced): capability radar (left) and per-layer score with verdict vs NVIDIA (right)

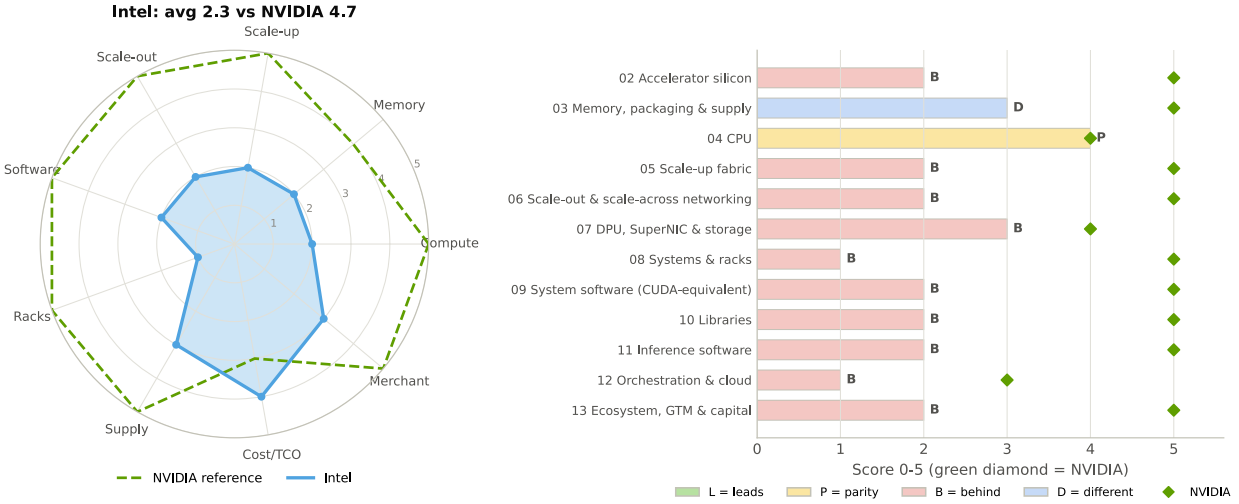


*Analyst judgement (speculative); L/P/B/D = leads / parity / behind / different approach*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S379] [S412] [S468] [S630] ...; chart by repo · As of 2026-11-05

双子图。左：英特尔与英伟达在九个能力维度上的雷达图，平均得分分别为 2.3 和 4.7（满分 5）（计算 2 对 5；内存 2 对 4；纵向扩展 2 对 5；横向扩展 2 对 5；软件 2 对 5；机架 1 对 5；供应 3 对 5；成本/TCO 4 对 3；商用化 3 对 5）。右：英特尔在英伟达 12 个技术栈层级中各层的得分及评判：落后 10 层、路线不同 1 层、持平 1 层。英特尔唯一持平的层是 CPU（作为 AI 主机的 Xeon），其封装（EMIB、Foveros）被评为路线不同；加速器、纵向扩展、机架和软件均落后。

## 作为合作伙伴的英特尔：Xeon 主机与 NVLink x86 协议

每一颗英伟达 GPU 都需要一颗主机 CPU。在英伟达自家的 GB 系列机架中，主机是 Grace 或 Vera；而在规模大得多的 x86 服务器世界里，主机是 Xeon 或 EPYC。2025 年 9 月的协议使英特尔成为定制 x86 CPU

的供应商，由英伟达 通过 NVLink 将其集成到自家平台中，同时还包括集成 RTX 小芯片的 x86 PC SoC [S130,S468]。英特尔也被列为 NVLink Fusion 的 CPU 合作伙伴之一 [S90031]。

**NVLink Fusion: 8 launch partners, 13 by June 2026, one hyperscale XPU**

Publicly announced NVLink Fusion partners by category and announcement date (filled = company-confirmed, hollow = reported)

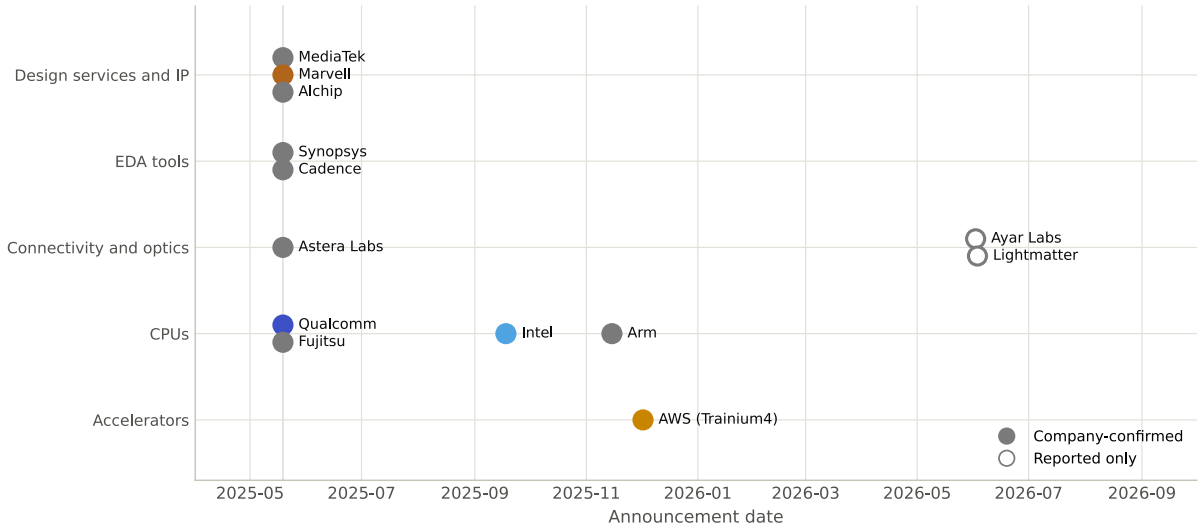


Source: data from NVIDIA; partner and press reports [S131] [S216] [S90037] [S4516] [S90031] [S4529] ...; chart by repo · As of 2026-11-05

NVLink Fusion 合作伙伴的时间线点图。2025 年 5 月 19 日发布时：联发科、美满电子和世芯（设计服务），Synopsys 和 Cadence（EDA），Astera Labs（互连），高通和富士通（CPU）。此后：英特尔 x86 CPU（2025 年 9 月）、Arm Neoverse（2025 年 11 月）、AWS Trainium4（2025 年 12 月，唯一的超大规模云厂商加速器），以及有报道但未确认的光学领域 Ayar Labs 和 Lightmatter（2026 年 6 月）。AMD、博通和谷歌缺席。

**提示**

**算例 —— NVLink 对 x86 主机为何重要。** 一条 PCIe Gen6 x16 主机链路带宽 ~256 GB/s；Vera 的 NVLink-C2C 为 1.8 TB/s，约高出 7 倍 [S100,S144]。对于将 KV 缓存溢出到 CPU 内存的推理而言，主机链路决定了上下文重新加载的速度。通过 NVLink 连接的 Xeon 可让只用 x86 的企业在不转向 Arm 的情况下获得英伟达的一致性 CPU–GPU 通路，这也是为什么这项协议保护的是 英伟达的机架，而非英特尔的加速器。

合作伙伴角色对英特尔自身的 CPU 业务也有代价。2026 年第二季度，AMD 在 x86 服务器中的出货份额达到 34.5%，按收入计为 ~46% [S4505,S4503]；而在英伟达设计的机架中，CPU 插槽归属 Grace 或 Vera。

**AMD rose to 34.5% of x86 server CPU units by Q2 2026, ~46% by value**

AMD share of x86 server CPUs (%), Mercury Research as reported; light bar = revenue or like-for-like value share

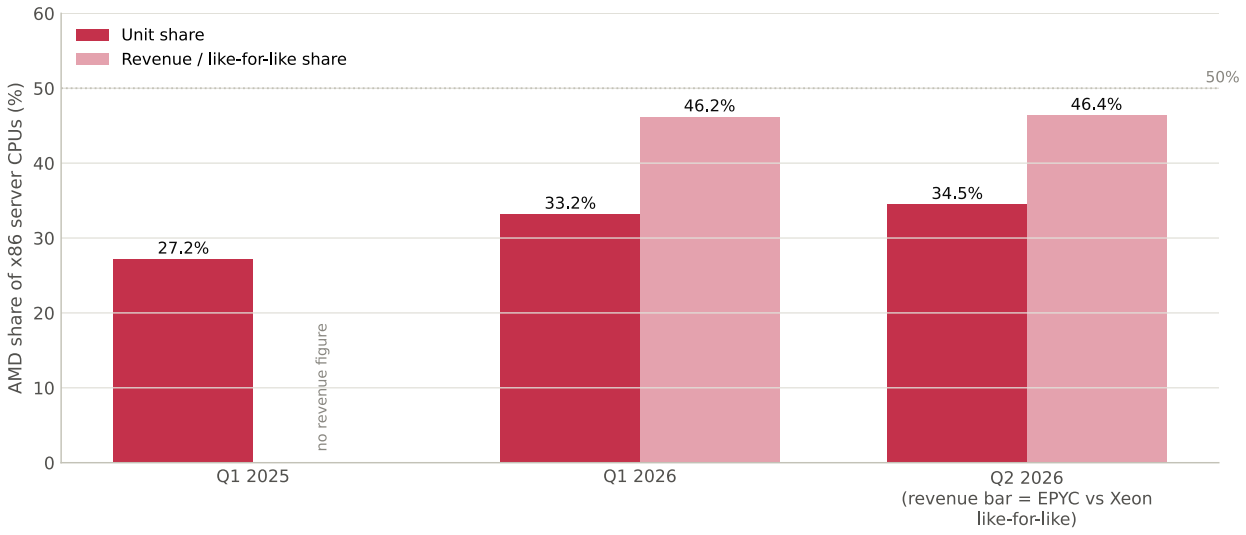


*Excludes Arm*

Source: data from Mercury Research via press [S4504] [S4503] [S4505]; chart by repo · As of 2026-11-05

根据 Mercury Research 数据绘制的 AMD x86 服务器 CPU 份额分组柱状图：按出货量，2025 年第一季度 27.2%、2026 年第一季度 33.2%、2026 年第二季度 34.5%；按收入，2026 年第一季度 46.2%，按 EPYC 对 Xeon 归一化口径 2026 年第二季度为 46.4%——x86 的在位之争如今是两家厂商的较量，英特尔在出货量上仍然领先。

## 作为供应商的英特尔：18A 以及作为 CoWoS 替代方案的 EMIB

台积电的 CoWoS 将所有裸片放在一块大型硅中介层上，好比把整个庭院都铺平，让每条 路径都平整顺畅。英特尔的 EMIB 则只在两颗裸片相接之处，于有机基板中嵌入小块硅桥， 好比只在道路交叉处架设人行天桥。用硅更少，意味着可以以更低成本做出更大的封装；EMIB-T 增加了 硅通孔（TSV），使 HBM 堆栈可以经由硅桥获得供电和信号 [S15548]。 Foveros 则将裸片垂直堆叠。英特尔将 EMIB-T 定位为一种只需极少重新设计即可让方案脱离 CoWoS 的途径， 这样计算裸片仍可由台积电制造 [S15548]。

**Est.: TSMC CoWoS capacity grew ~8× from 2023 to 2026, and NVIDIA booked ~60% of 2026 wafers**

Left: year-end CoWoS run-rate, k wafers/month (midpoint of press-reported ranges) · Right: 2026 CoWoS bookings by customer, k wafers

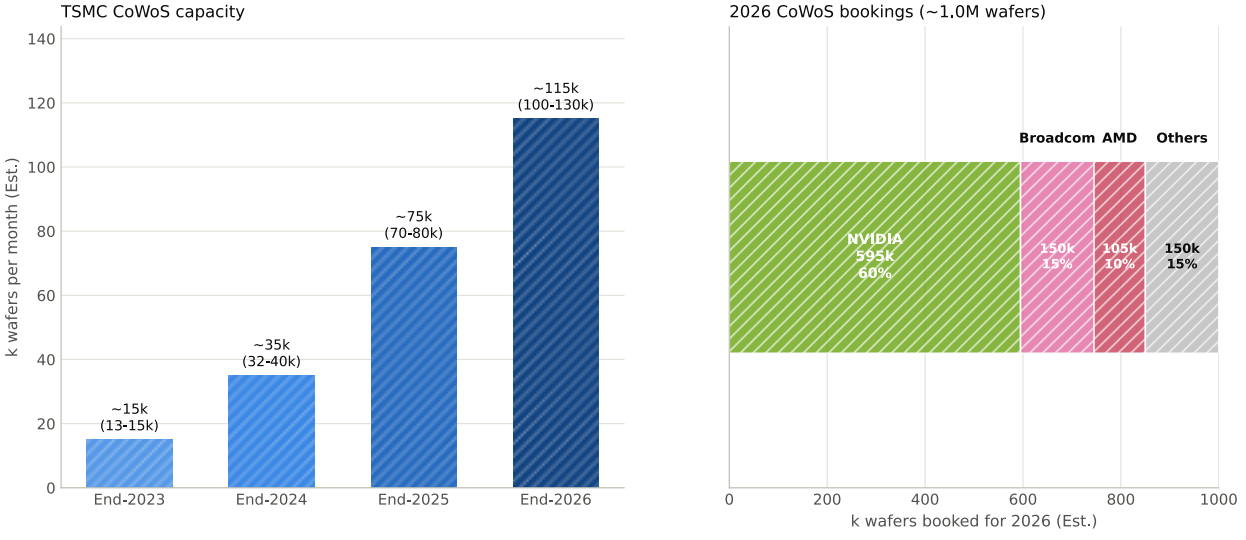


*All values Est. (TSMC does not disclose CoWoS wafers)*

Source: data from TrendForce, Morgan Stanley via trade press, TSMC [S379] [S378]; chart by repo · As of 2026-11-05

估计值双子图。左：台积电 CoWoS 产能 2023 年底约每月 15k 片晶圆，2024 年 35k，2025 年 75k，2026 年约 115k，增长约 8 倍。右：在 2026 年约 1,000k 片的 CoWoS 需求中，英伟达约 595k（60%），博通 150k，AMD 105k，其他约 150k。

提示

**算例 —— EMIB-T 作为第二供应来源有多大体量？** 机构估计，EMIB-T 在 2027 年约为每月 ~15–20k 片 CoWoS 等效晶圆，2028 年 ~40–45k；相比之下，台积电 CoWoS 在 2026 年底 ~130k，到 2028 年底将达 ~260k （估计）[S3002]。按 2027 年区间中值计，17.5k ÷ 130k ≈ 台积电 2026 年底基数的 13%。这足以拯救 一个排在英伟达 ~60% CoWoS 配额之后的 ASIC 项目 [S379]，但不足以改变英伟达自身的供应地位。

客户是悬而未决的问题。据报道谷歌和亚马逊正在洽谈封装合作；英特尔 CEO 表示，客户 愿意协助预付基板供应商的款项 🟡 [S3532]。DIGITIMES 将英伟达列为有报道的订单来源之一（未确认 🔴），并预计 EMIB 将从 2026 年下半年起产生客户收入 [S15549]。晶圆方面，Intel 18A 已投产（Clearwater Forest Xeon，288 个 E 核）[S4525]；对于 14A，英特尔称有两家潜在客户，预计在 2026 年下半年至 2027 年初作出决定 [S13531]。Intel Foundry 2026 年第三季度收入 ~$6.7B，主要来自英特尔自身 [S15543]。

## 分层评判：英特尔 vs 英伟达

| 层 | 评判 | 理由 |
|---|---|---|
| 02 加速器芯片 | 🟥 落后 | Gaudi 3（1.8 PFLOPS FP8）未达目标；D-Series 仅面向推理 [S161,S668] |
| 03 内存、封装与供应 | 🟦 路线不同 | 自有晶圆厂和 EMIB/Foveros：可能成为 CoWoS 第二供应来源 [S3002] |
| 04 CPU | 🟨 持平 | Xeon 仍是主流 AI 主机；NVLink x86 协议 [S468,S4503] |
| 05 纵向扩展互连 | 🟥 落后 | 目前为 8 芯片以太网节点；UALink 产品 2027 年推出 [S296,S90051] |
| 06–07 网络、DPU | 🟥 落后 | 有网卡和 IPU；没有 AI 交换机业务 [S452] |
| 08 系统与机架 | 🟥 落后 | 尚无机架级 AI 系统出货 [S162] |
| 09–11 软件 | 🟥 落后 | 有 oneAPI、OpenVINO 和 vLLM-Gaudi，但采用率很低 [S10540,S581] |
| 13 生态与资本 | 🟥 落后 | 处于转型重整期；政府、软银和英伟达入股 [S15550,S15547] |

本页与各层页面的差异：评判结论上没有差异。第 04 层页面将作为主机的 Xeon 评为持平；本页 同意这一结论，并补充指出，NVLink 协议使英特尔的主机角色部分依赖于英伟达。

## 它们最有力的论据，以及差距缩小了多少

**英特尔最有力的论据：** 它是唯一一家同时拥有尖端逻辑晶圆厂、先进封装和 x86 装机基础的西方公司。如果 CoWoS 持续是瓶颈、且各国政府希望采购美国制造的 AI 芯片，英特尔就是默认的第二 供应来源，而英伟达已经花了 $5B 把它留在身边 [S15547,S15550]。

**差距缩小了多少：** 作为加速器供应商，丝毫没有缩小；英特尔在 2026 年 MLPerf 中的身影是 Arc Pro 工作站显卡 [S602]。作为 CPU 供应商，其数据中心业务已重回增长（同比 +78%）[S15543]。作为封装 供应商，它尚处于产生收入之前的阶段，客户虽被点名但未经确认 [S15549]。

注

🐂 **看多观点（对英伟达而言）。** 英特尔如今更像合作伙伴而非对手：英伟达持有其 ~4% 股份，x86 主机将通过 NVLink 连接，而 EMIB-T 可以增加英伟达无需自掏腰包的封装供应 [S15547,S130,S3002]。

> **注意**
>
> 🐻 **看空观点（对英伟达而言）。** 一个健康的 Intel Foundry 加上 EMIB-T，将缓解 CoWoS 瓶颈——正是这一瓶颈让定制 ASIC 在台积电的排队中位于英伟达之后[S379,S3002]；而且英特尔是 UALink 董事会成员[S573]，因此 2027 年的 Jaguar Shores 加上 UALink，将在 NVLink 体系之外新增一款商用机架。

## 🎯 企业发展视角

1. 英伟达的 $5B 买到的是一个合作伙伴，而非控制权（没有特殊治理权利）[S15547]。少数股权能换来多大的路线图影响力？其他方能否获得 CPU 或封装供应商的可比股权？
2. EMIB-T 的价值取决于客户将设计迁离 CoWoS。哪些加速器项目（定制 ASIC、推理 卡、主权项目）能从非台积电封装中获益最多？认证周期需要多长？
3. Crescent Island 与高通的 AI200 押注的是同一个 LPDDR 容量逻辑。企业推理市场能否容纳 两家或更多基于 LPDDR 的商用芯片供应商？每家需要怎样的软件覆盖面？
4. 英特尔（通过其 CEO）担任 SambaNova 的董事长并对其投资，还差点将其收购[S2512,S15517]。英特尔是更可能 收购 AI 能力而非自建？哪些标的契合其“封装 + x86”的定位？
5. 在美国政府持股 9.9% 的情况下[S15550]，监管机构会如何看待外国或战略买家收购英特尔任何 涉及 AI 或先进封装的业务单元？

# 16 —— 英伟达如何建成今日格局（时间线）

跨层专题 16 · 从 1993 年的一张餐馆卡座到市值 ~$5T 的公司 · 约 28 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **起步几近失败。** 英伟达（NVIDIA）于 1993 年 4 月在加利福尼亚州注册成立 [S401]，创始人为黄仁勋（Jensen Huang，时任职于 LSI Logic），以及来自 Sun Microsystems 的 Chris Malachowsky 和 Curtis Priem，三人在圣何塞的一家 Denny's 餐厅里谋划了公司的创立 [S16002]。其第一款芯片 NV1（1995）押注于一种业界最终未采用的 3D 技术路线；兼容 Direct3D 的 RIVA 128（1997）挽救了公司 [S16000,S16001]。
- **四个阶段，一条复利曲线。** 营收从 IPO 当年 FY1999 的 $158M 增长至 2026 财年（FY2026）的 $215.9B，增长 ~1,365 倍 [S16015,S1]。其中 88% 的美元增量仅来自 FY2024–FY2026 这三年（本资料库测算）[S16016]。
- **决定性的押注既耐心又昂贵。** 自 2006–07 年起，CUDA 随每一块 GPU 出货 [S9528,S525]，而毛利率则从 45.6%（FY2008）降至 34.3%（FY2009）[S22000]。回报来自外部：2012 年，AlexNet 在两块游戏 GPU 上完成训练 [S9530]。直到 FY2018，数据中心收入才首次超过公司研发总支出 [S400]。
- **自建来不及的，英伟达就买。** 它以 $70M 外加股票收购了 3dfx 的资产（2000–01）[S16005]，以 $6.9B 收购了 Mellanox（2019–20）[S464]；网络业务在 FY2026 达到 ~$31.4B [S402]。其失败案例同样是交易：Icera 调制解调器（$367M，2015 年关停）[S16009]，以及 $40B 的 Arm 收购要约（2022 年终止，计提 ~$1.36B 费用）[S465,S466]。
- **十二次押注中的规律：** 成功者需要 2–11 年才见回报；失败者在 1.4–4 年内即被砍掉（🔴 本资料库分析）[S16016]。
- **产品形态不断扩大：** 从一颗芯片，到售价 $129K 的 DGX-1 服务器（2016）[S310]，到 72-GPU 的 GB200 NVL72 机架（2024）[S396]，再到自 2026 年 8 月起出货的 Vera Rubin [S500]。产品迭代如今约每年一代，此前为 ~29 个月 [S33020,S17003]。
- **市值随之而来：** 英伟达于 2025-10-29 成为首家市值达 $5T 的公司 [S25010]，并在 2026 年 10 月初接近 ~$5.8T 🟡 [S16012,S18005]。
- **持平而论：** 决定性的需求转变（深度学习）来自英伟达的计划之外，而大多数偏离核心业务的举措（游戏主机、手机、Arm）都令人失望。2025–26 年的押注——~$20B 的 Groq 授权交易和 $12.9B 的 Hugging Face 收购——规模庞大且尚未得到验证 🟡 [S90019,S11500]。

**Revenue rose ~1,365× since FY1999, but 88% of the dollar gain came in the last three years**

NVIDIA total revenue by fiscal year, US$ B (log scale), FY1999–FY2026, shaded by era; labels mark the key bets

LOG SCALE

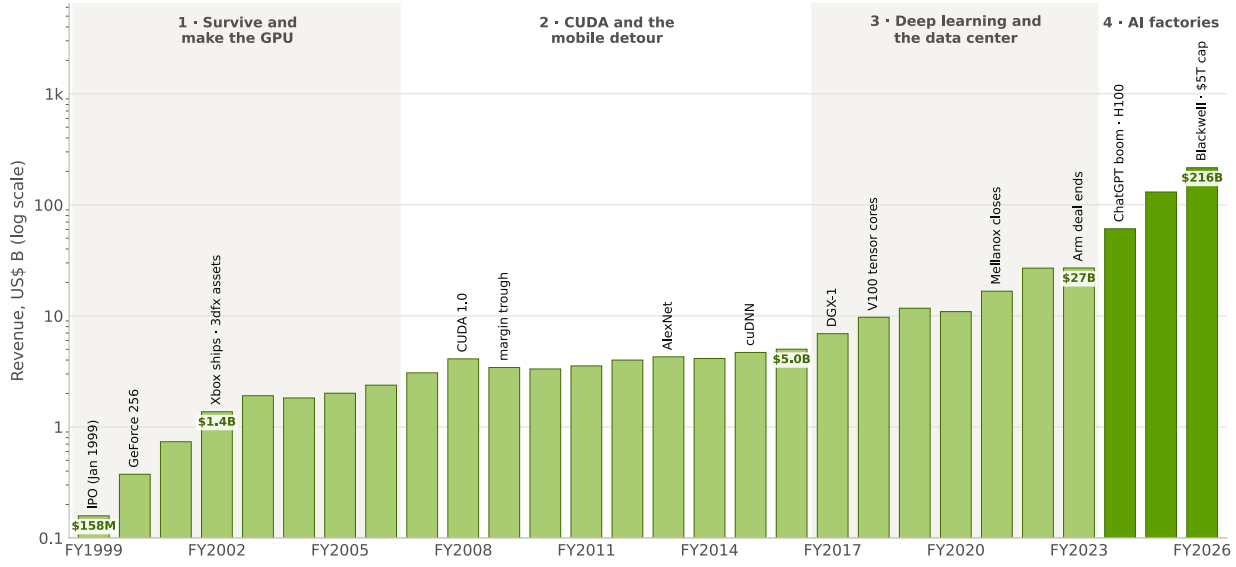


Source: data from NVIDIA 10-K/10-K405 filings and FY2026 results [S16015] [S16006] [S16007] [S22000] [S22004] [S400] …; chart by repo · As of 2026-11-05

英伟达年度营收对数刻度条形图，从 FY1999（$158M，IPO 当年）到 FY2026（$216B），增长约 1,365 倍，分为四个阴影阶段：求生存，造出 GPU（FY1999–FY2006，增至 $2.4B）；CUDA 与移动业务弯路（FY2007–FY2016，营收停滞在 $3.3–5.0B）；深度学习与数据中心（FY2017–FY2023，增至 $27B）；AI 工厂（FY2024–FY2026）。图中标注了 IPO、GeForce 256、Xbox、CUDA 1.0、AlexNet、cuDNN、DGX-1、张量核心、Mellanox、Arm 交易终止、ChatGPT 和 Blackwell；全部美元增量中有 88% 来自 FY2023 之后。

## 四个阶段一览

英伟达的历史最好按四个阶段来理解。每个阶段的产品、客户和利润结构各不相同，且每个阶段都以一次为下一阶段奠定基础的押注收尾。下表是本页其余部分的导览图；具体机制在所链接的各层页面中阐述。

| 阶段 | 年份 | 英伟达销售的产品 | 阶段末营收 | 决定性押注 | 濒危时刻或挫折 |
|---|---|---|---|---|---|
| 1 · 求生存，造出 GPU | 1993–2005 | PC 图形芯片、Xbox GPU、芯片组 | $2.4B（FY2006）S16007 | 跟随 Direct3D；定义 GPU | NV1 失败（1995–96）S16000 |
| 2 · CUDA 与移动业务弯路 | 2006–2015 | GeForce、Quadro、Tesla 板卡、Tegra | $5.0B（FY2016）S400 | 每块 GPU 都搭载 CUDA | FY2009–FY2010 毛利率低谷 S22000；退出 Icera S16009 |
| 3 · 深度学习与数据中心 | 2016–2022 | V100/A100、DGX、InfiniBand | $27.0B（FY2023）S2 | 张量核心；Mellanox | Arm 交易受阻 S466；FY2023 库存危机 S418 |
| 4 · AI 工厂 | 2023–2026 | Hopper、Blackwell 和 Rubin 机架、网络、资本 | $215.9B（FY2026）S1 | 年度迭代节奏；以机架为产品 | GB200 量产爬坡问题 S5500；H20 禁令 S90081 |

**阶段之间如何交接。** 每一次过渡都遵循相同的顺序。一台现金引擎（先是 PC 图形，然后是游戏，再到数据中心 GPU）为一项当时看来并不经济的平台押注提供资金。随后，一个外部事件为该平台创造了需求：Direct3D 游戏、深度学习、ChatGPT。最后，英伟达收购或自建任何成为下一个瓶颈的环节：着色器、软件库、网络、机架。毛利率底线每次都在抬升，原因在于下一代产品承载了更多英伟达自身的设计与软件，而非芯片的制造成本降低了。

### Each era raised the margin floor: average gross margin went 35% → 47% → 61% → 73%

NVIDIA by era: revenue CAGR (from the prior era's last year), average GAAP gross margin and average R&D as % of revenue

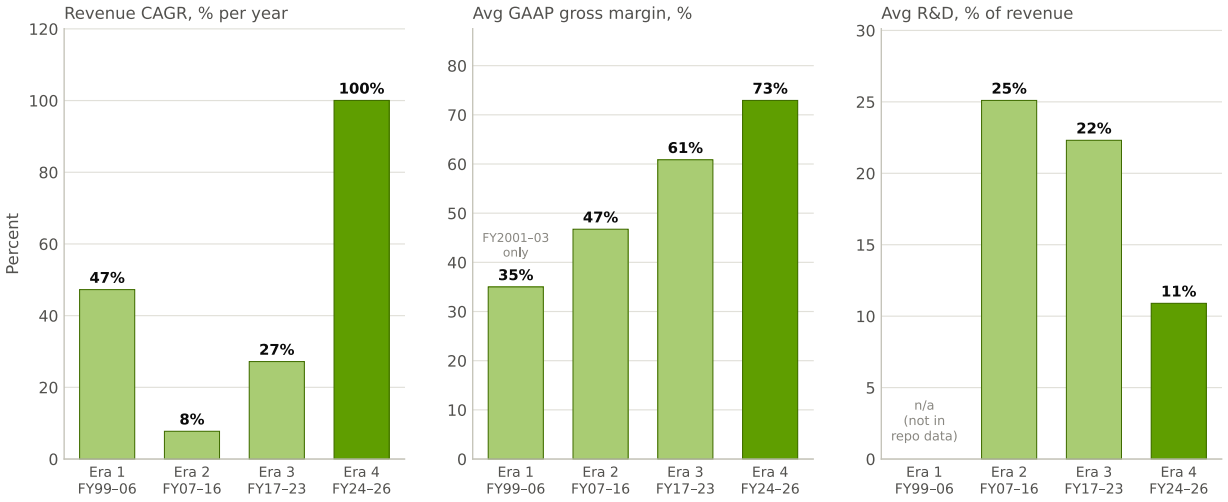


Source: data from NVIDIA 10-K filings; repo era arithmetic [S16015] [S16006] [S16008] [S22000] [S22001] [S22003] ...; chart by repo · As of 2026-11-05

英伟达四个阶段的三面板条形图。年均营收增速：47%（FY1999–FY2006）、8%（FY2006–FY2016）、27%（FY2016–FY2023）和 100%（FY2023–FY2026）。平均 GAAP 毛利率：35%（仅 FY2001–FY2003）、47%、61% 和 73%。平均研发强度：第一阶段在本资料库数据中缺失，CUDA 阶段 25%，深度学习阶段 22%，AI 工厂阶段 11%：CUDA 阶段是低增长、高研发的投入期，后续阶段则收获其成果。

**提示**

**算例 —— 漫长的中期付出了什么代价。** 英伟达从创立到首个营收达 $1B 的财年（FY2002）用了 ~9 年，此后又用了 17 年才突破 $10B（FY2019）[S16006,S400]。从 FY2006（$2.4B）到 FY2016（$5.0B），营收年均增速仅 ~8% [S16007,S400]，而研发支出平均占营收的 ~25%（见上图）。一家年增速 8%、研发占比 25% 的同业公司，会被市场按成熟硬件公司估值。**结论：** 带来后来 ~100% 年增速的平台，恰恰是在一个投资者很容易将其解读为停滞的十年里建成的。

### NVIDIA took 9 years to reach $1B of revenue, 17 more to reach $10B, then 6 to pass $100B

Years from founding (April 1993) to the end of the first fiscal year above each annual-revenue threshold

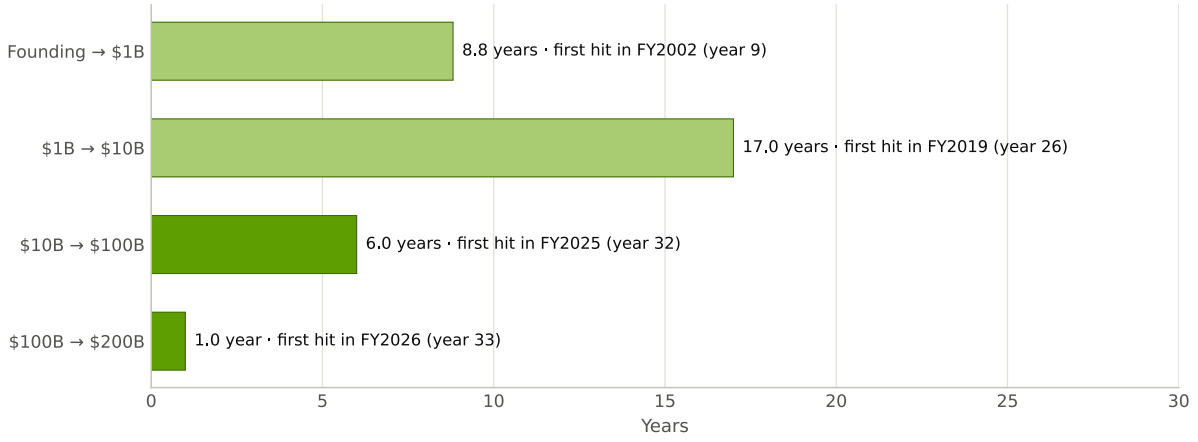


Source: data from NVIDIA 10-K filings and FY2026 results; repo arithmetic [S16006] [S400] [S2] [S1] [S16002] [S16003]; chart by repo · As of 2026-11-05

营收里程碑间隔时间的水平条形图。自 1993 年 4 月创立起，英伟达用了 8.8 年实现首个 $1B 财年（FY2002），又用了 17.0 年突破 $10B（FY2019），6.0 年突破 $100B（FY2025），1.0 年突破 $200B（FY2026）。漫长的中间阶段涵盖了 CUDA 与移动业务的那些年。

# 第一阶段 —— 求生存，造出 GPU（1993–2005）

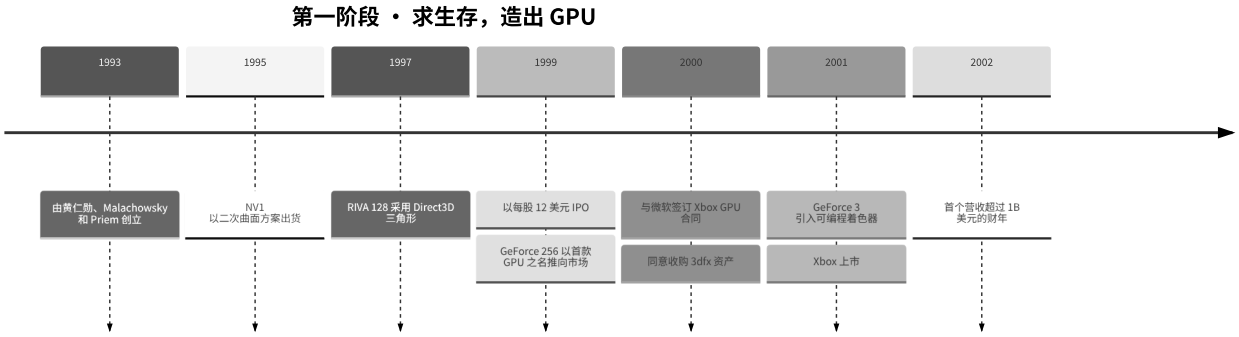


**创业押注**是：PC 将需要专用的 3D 图形芯片，由一家无晶圆厂（fabless）公司打造——即自行设计芯片、交由代工厂制造。**第一款产品几乎要了公司的命。** NV1（1995）用弯曲的二次曲面绘制 3D 场景，并捆绑了音频功能。随后微软（Microsoft）的 Direct3D 以三角形为标准，使 NV1 与开发者正在编写的软件不兼容 S16000。原计划为世嘉（Sega）开发的一款游戏机芯片也被放弃 🟡 S16000。

**转型用了大约两年。** 在客户寥寥、人员缩编的情况下，英伟达围绕三角形和 Direct3D 重建产品，并于 1997 年上半年推出 RIVA 128 S16001。据一位分析师估计，到 1997 年底英伟达在高性能图形市场的份额为 ~24% 🟡 S16003。公司于 1999 年 1 月以每股 $12 上市，发行 3.5M 股外加超额配售，净募资 ~$43.3M S16004。

**随后它为这一品类命名。** 英伟达将 GeForce 256（1999）作为首款“GPU”推向市场，因为它把变换与光照从 CPU 上卸载了下来 S2502。紧接着是两笔交易。2000 年 3 月，微软选择英伟达为 Xbox 提供 GPU，并支付了 $200M 的采购预付款 S16005。2000 年 12 月，英伟达同意以 $70M 现金和 1M 股收购已经陨落的前市场领导者 3dfx 的专利、品牌和库存，交易于 2001 年 4 月完成 S16005,S484。GeForce 3（2001）加入了可编程着色器 S16011，正是这一特性后来使通用 GPU 计算成为可能。

> **提示**
>
> **算例 —— Xbox 的取舍。** Xbox 处理器占营收的比例从 FY2002 的 9% 升至 FY2003 的 23%，毛利率则从 38% 降至 30% S16008。以 FY2003 营收 $1.91B S16006 计算，八个百分点的毛利率约合 ~$150M 毛利，不过 ~$21M 的库存减记也有一定影响 S16008。**结论：** 游戏主机让英伟达变得更大，却没有变得更赚钱。后来的手机押注也印证了同样的教训：按客户的定价走量，建不起护城河。

### 🔧 技术细节：从固定功能到可编程图形

早期的 3D 芯片采用固定功能流水线：每个阶段（变换、光照、纹理、混合）都是只有少量可调设置的硬连线电路。GeForce 256 将变换与光照从 CPU 移入此类硬件 S2502。GeForce 3 则用小程序替换了流水线的部分环节，这些小程序针对每个顶点或每个像素各运行一次 S16011。一颗能并行运行成千上万个小程序的芯片就是一台并行处理器，这正是研究人员开始把数学运算伪装成像素着色的原因（斯坦福大学的 Brook，2004）S9532。G80（2006）随后使每个着色器核心完全相同，即统一着色器架构，并通过 CUDA 将其开放 S2503。

# 第二阶段 —— CUDA 与移动业务弯路（2006–2015）

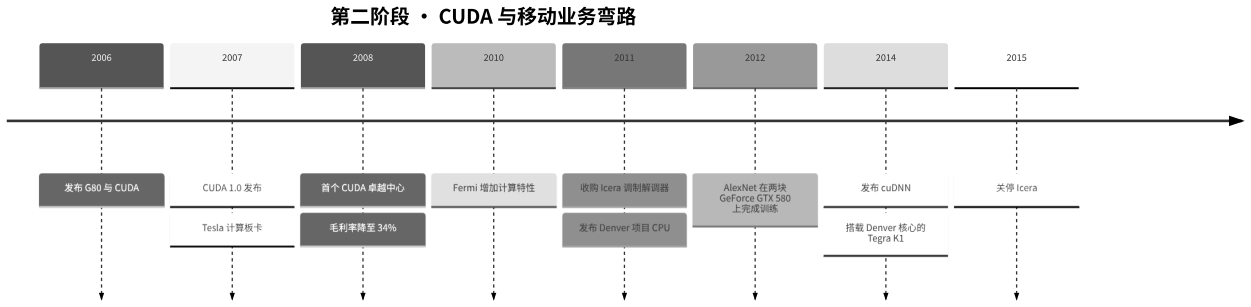


**CUDA 是对一个尚不存在的市场的押注。** 英伟达于 2006-11-08 随 G80 发布 CUDA，并于 2007 年 6 月推出 CUDA 1.0 [S9528,S525]。它把这项能力放进每一块 GeForce 显卡，因此任何拥有游戏 PC 的学生都拥有了一台并行计算机（见 CS2）。随后它出资让大学教授 CUDA：首个 CUDA 卓越中心（伊利诺伊大学，2008）获得了 $500,000 资金外加一套集群 [S9529]。黄仁勋曾回忆，在英伟达毛利率为 ~35% 的时候，CUDA 使产品成本增加了 ~50% 🟡 [S22005,S22006]。

**代价体现在利润表上。** 毛利率从 FY2008 的 45.6% 降至 FY2009 的 34.3%（其中包括一笔因裸片与封装材料组合存在缺陷而计提的 $196M 费用），FY2010 为 35.4% [S22000]。研发支出占营收的比例从 17% 升至 FY2009–FY2015 的 24–32% [S22001,S22003]，而营收始终徘徊在 $3.3B 至 $4.7B 之间 [S22000,S22004]。

**与此同时，英伟达在追逐手机市场。** Tegra 系统级芯片（SoC）需要调制解调器才能与高通（Qualcomm）竞争，因此英伟达于 2011 年以 ~$367M 收购了 Icera。Icera 的软件基带调制解调器只打入了少数手机，2015 年 5 月英伟达宣布将关停该业务，若找不到买家将计提 $100–125M 费用 [S16009,S16010]。其定制 Arm CPU 项目 Denver（2011 年发布）自 2014 年起仅用于 Tegra 产品 [S4536]。

**回报来自外部。** 2012 年，Krizhevsky、Sutskever 和 Hinton 在两块 GeForce GTX 580 游戏 GPU 上训练了 AlexNet [S9530]。英伟达随即于 2014 年将深度学习内核打包为 cuDNN [S9531]。在 CUDA 1.0 发布十年后的 FY2018，数据中心收入才首次超过英伟达的研发总支出 [S400]。

## Gross margin fell from 45.6% to 34.3% after CUDA 1.0 and took until FY2012 to recover

NVIDIA GAAP gross margin and R&D as % of revenue by fiscal year, FY2007–FY2026, with CUDA milestones

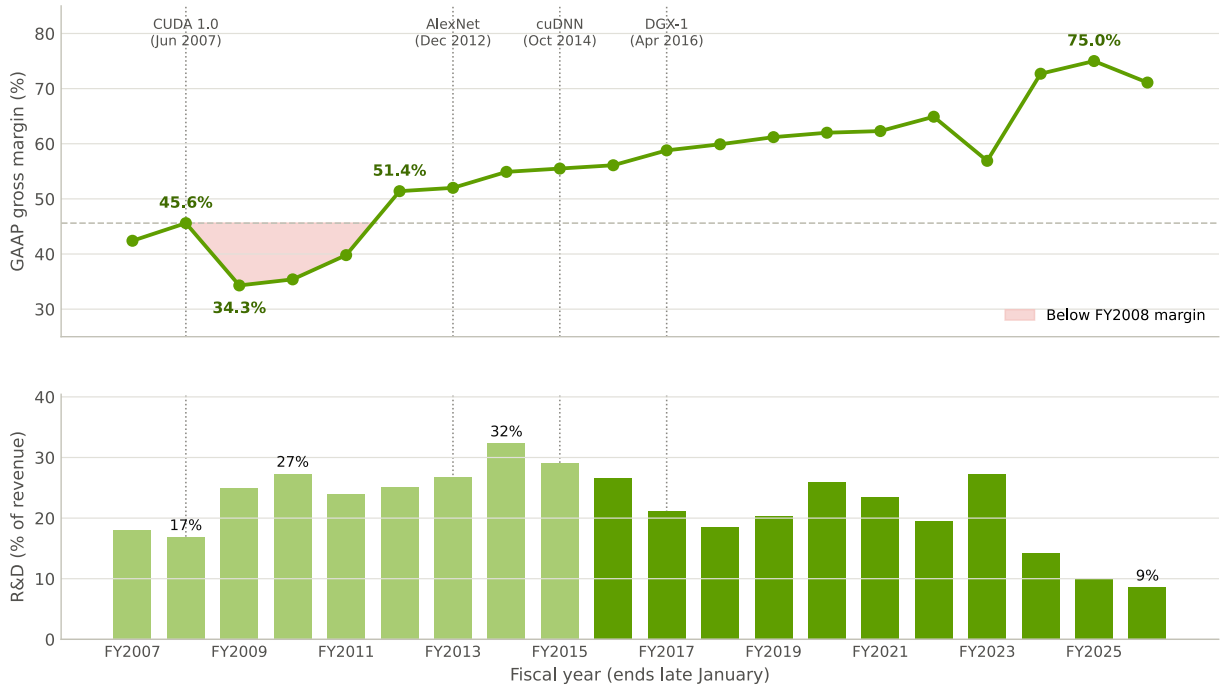


*Some FY2007–15 values recalled*

Source: data from NVIDIA 10-Ks [S400] [S22001] [S22000] [S22002] [S22003] [S22004] …; chart by repo · As of 2026-11-05

双面板折线图，FY2007 至 FY2026。上：英伟达 GAAP 毛利率在 FY2007 为 42.4%，在 CUDA 1.0 发布的 FY2008 为 45.6%，随后在 FY2009 降至 34.3%（包括一笔 $196M 的封装缺陷费用及经济衰退影响），FY2010 为 35.4%，直到 FY2012 才恢复至 FY2008 的水平（51.4%），并在 FY2025 达到 75.0%。下：研发支出占营收比例从 FY2008 的 17% 升至 FY2010 的 27%，并在 FY2014 达到 32% 的峰值，之后由于营收增速超过支出，在 FY2026 降至 9%。标注的里程碑：CUDA 1.0（FY2008）、AlexNet（FY2013）、cuDNN（FY2015）、DGX-1（FY2017）。

**提示**

**算例 —— 同一个十年里的两次押注。** 案例研究 CS2 估计 CUDA 的“期权费”（FY2009–FY2015 期间高于 FY2008 研发强度的那部分研发支出）为 ~$2.8B（🔴 本资料库估计）[S22009]。移动调制解调器押注的成本为收购 Icera 的 ~$367M 加上 $100–125M 的退出费用 [S16009,S16010]：约 $0.5B。两者都是对新市场的押注。一个滋养了英伟达所售每一块 GPU 构成的装机基础；另一个则闯入了高通和联发科（MediaTek）早已在销售集成调制解调器的市场。**结论：** 成本较低的押注之所以失败，是因为它挑战的是在位者的平台；成本较高的押注之所以成功，是因为它延伸的是英伟达自己的平台。

**Data Center revenue first topped NVIDIA's total R&D in FY2018, a decade after CUDA 1.0**

NVIDIA Data Center revenue vs total company R&D, US$ B per fiscal year, FY2016–FY2026 (FY2026: 10× R&D)

LOG SCALE

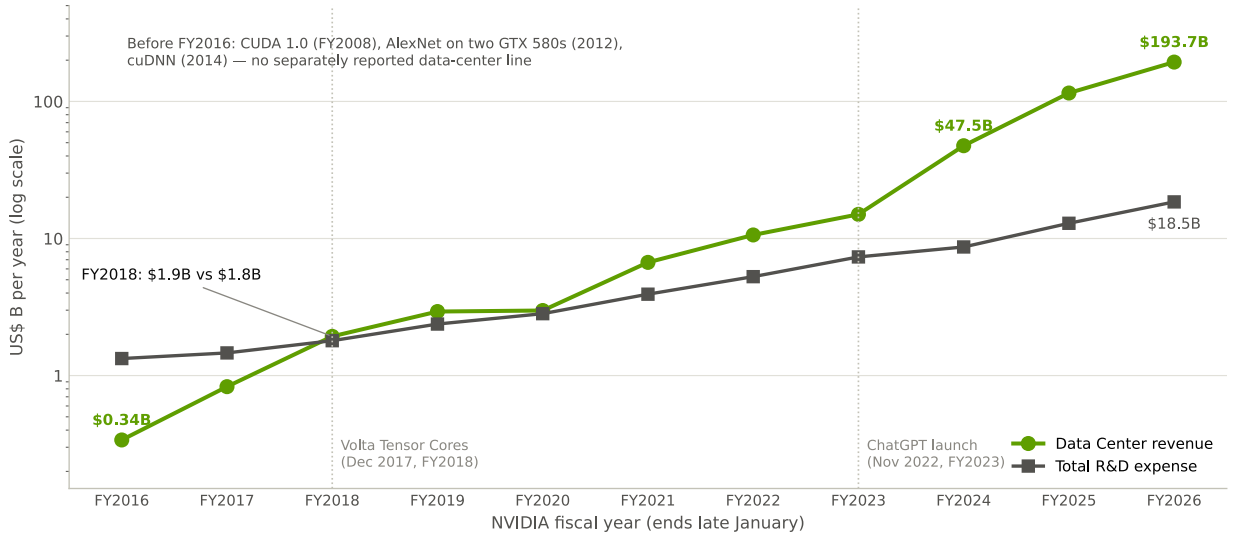


*Pre-FY2026 rows: QA pending*

Source: data from NVIDIA 10-Ks (financials.csv) [S400] [S2] [S418] [S417] [S90090] [S416] ...; chart by repo · As of 2026-11-05

对数刻度折线图，FY2016 至 FY2026。英伟达数据中心收入在 FY2016 为 $0.34B，而研发总支出为 $1.33B；在 FY2018 超过研发支出（$1.93B 对 $1.80B），在 FY2024 达到 $47.5B，在 FY2026 达到 $193.7B，约为 $18.5B 研发支出的 10 倍。CUDA 1.0 于 2007 年 6 月（FY2008）发布，cuDNN 于 2014 年发布，因此该平台运行了约十年，数据中心业务才足以支付公司的研发开支。

**🔧 技术细节：为何“每块 GeForce 都搭载 CUDA”比编译器更重要**

开发者平台需要让大量开发者手中都有廉价硬件。通过在消费级显卡中搭载支持 CUDA 的芯片，英伟达让研究人员可以在游戏 PC 上做原型，再用同一套代码部署到数据中心板卡上。PTX 虚拟指令集使旧程序能在新 GPU 上继续运行，因此十年的研究代码都积累在同一个目标平台上（见第 09 层历史）。Fermi（2010）及其后续架构又加入了超级计算机所需的特性，例如纠错内存和更快的双精度运算 [S2503]。

## 第三阶段 —— 深度学习与数据中心（2016–2022）

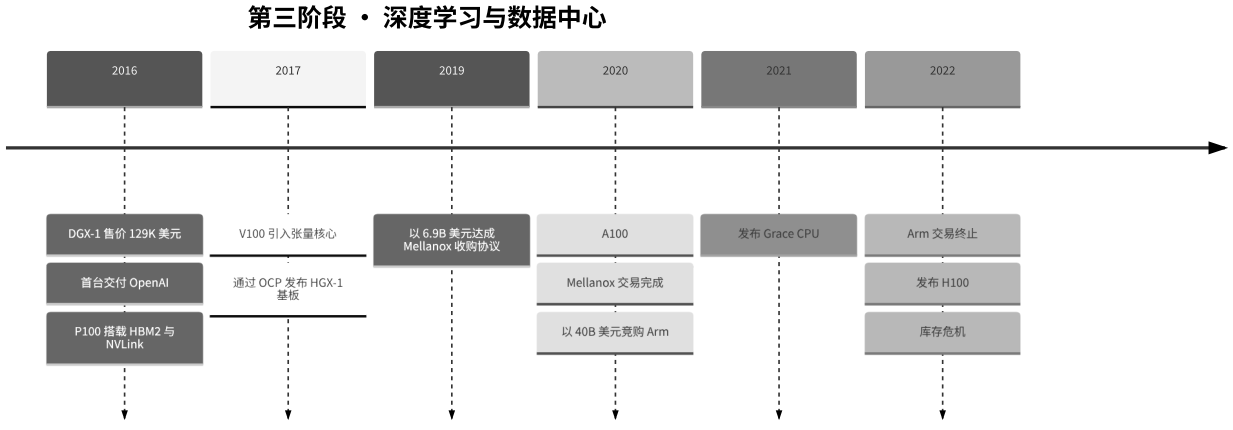


**英伟达开始销售计算机，而不仅仅是芯片。** DGX-1（2016 年 4 月）将八块 P100 GPU 装进一台售价 $129,000、功耗 3.2 kW 的机箱 [S310]；同年 8 月，黄仁勋亲手将第一台交付给 OpenAI [S8522]。P100 也是英伟达首款采用 HBM 和 NVLink 的 GPU [S125]。2017 年，与微软一起通过 OCP 发布的 HGX-1 基板，让每一家服务器厂商都能采用同一设计 [S8525]。

**硬件转向矩阵运算。** V100（2017）加入了张量核心：FP16 矩阵运算达 125 TFLOPS，而通用 FP32 运算为 15.7 TFLOPS [S126,S33010]。A100（2020）随后推出 [S127]。

**随后英伟达买下了网络，并试图买下 CPU。** 它于 2019-03-11 同意以 $6.9B 现金收购 Mellanox，击败了据报道出价 ~$6B 的英特尔（Intel），并在获得中国批准后于 2020-04-27 完成交易 [S464,S6509,S21005]。2020 年 9 月，它以 $40B 竞购 Arm；由于监管机构反对，该交易于 2022-02-08 告吹，英伟达计提了 ~$1.36B 费用 [S465,S466]。英伟达转而自建 CPU：2021 年 4 月发布采用授权 Arm 核心的 Grace [S537]（见第 04 层历史）。

**它还围绕硬件构建了生态。** NCCL 通信库于 2016 年 4 月出现在 GitHub 上，RAPIDS 则于 2018 年 10 月将 GPU 引入数据科学 [S10506,S10517]。GTC 首届（2009 年）吸引了 ~1,500 名参会者 [S13024]，后来成为每年发布路线图的舞台。注册 CUDA 开发者达到 1M 用了 13 年；第二个 1M 只用了约两年 [S529]。这些就是第 10 层和第 13 层所描述的护城河资产。

**这一阶段以一场危机收尾。** FY2023 营收持平于 $27.0B [S2]，毛利率降至 56.9% [S418]，英伟达计提了 ~$2.17B 的存货准备 [S418]。而 2022 年 3 月发布的 H100 [S35012]，已为随后到来的需求做好了准备。

**Networking revenue rose ~24× from Mellanox's $1.33B (2019) to ~$31.4B in FY2026**

Annual revenue, US$ B: Mellanox as a standalone company (CY2018–19) vs NVIDIA's networking line after the deal

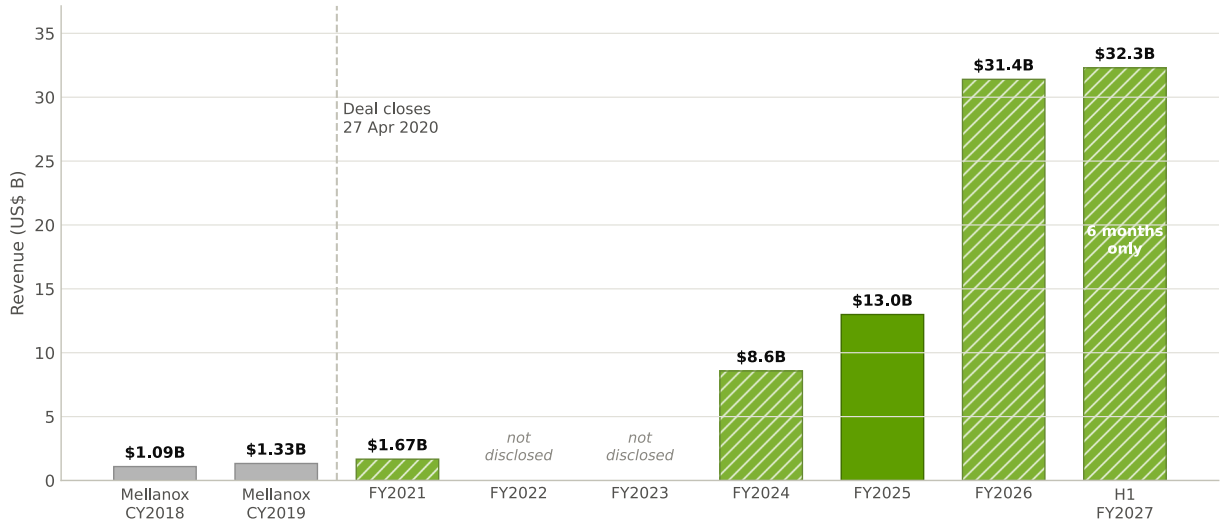


*Hatched = Est.*

Source: data from Mellanox 10-K; NVIDIA filings [S21000] [S21001] [S418] [S2] [S416] [S443] ...; chart by repo · As of 2026-11-05

网络业务收入条形图。Mellanox 单独在 2018 年收入 $1.09B，2019 年 $1.33B。2020 年 4 月交易完成后，英伟达网络业务在 FY2021 约为 $1.67B（估计：约 9 个月、约占营收 ~10%），FY2022-FY2023 未披露，随后在 FY2024 达到约 $8.6B（估计），FY2025 为 $13.0B，FY2026 约为 $31.4B，约为 Mellanox 2019 年收入的 24 倍；仅 FY2027 上半年就带来约 $32.3B。该业务线如今还包括 Mellanox 从未销售过的 NVLink 交换机。

**提示**

**算例 —— 同一管理层，两笔交易，结局相反。** Mellanox 花费 $6.9B [S464]；按案例研究中的严苛假设（将一半网络业务归功于 Mellanox，毛利率按 65% 计），它在 FY2025 前已收回成本（🔴 本资料库模型）[S21014]。Arm 本需花费 $40B，最终以 ~$1.36B 的减记告终 [S465,S466]。Mellanox 只向部分竞争对手供货；而 Arm 几乎向所有竞争对手授权，包括高通和超大规模云厂商自己的 CPU 团队 [S4517,S4022,S4024,S4026]（见 CS1）。**结论：** 收购一家向竞争对手供货的供应商，与监管机构尚可谈判；收购所有人都依赖的中立标准，则没有谈判余地。

**🔧 技术细节：张量核心改变了什么**

通用 GPU 核心每条指令执行一次乘加运算。张量核心则在一步内将两个小矩阵相乘并加上第三个矩阵，因此一条指令可完成数十次乘加。神经网络的主体是矩阵乘法，因此 V100 的张量核心在此类运算上提供了其 FP32 速率的 8 倍 [S126]。此后每一代都在同一思路上加入了更低精度的格式（2022 年的 FP8、2025 年的 NVFP4）[S35011,S32017]；见 GPU 芯片历史。

## 第四阶段 —— AI 工厂（2023–2026）

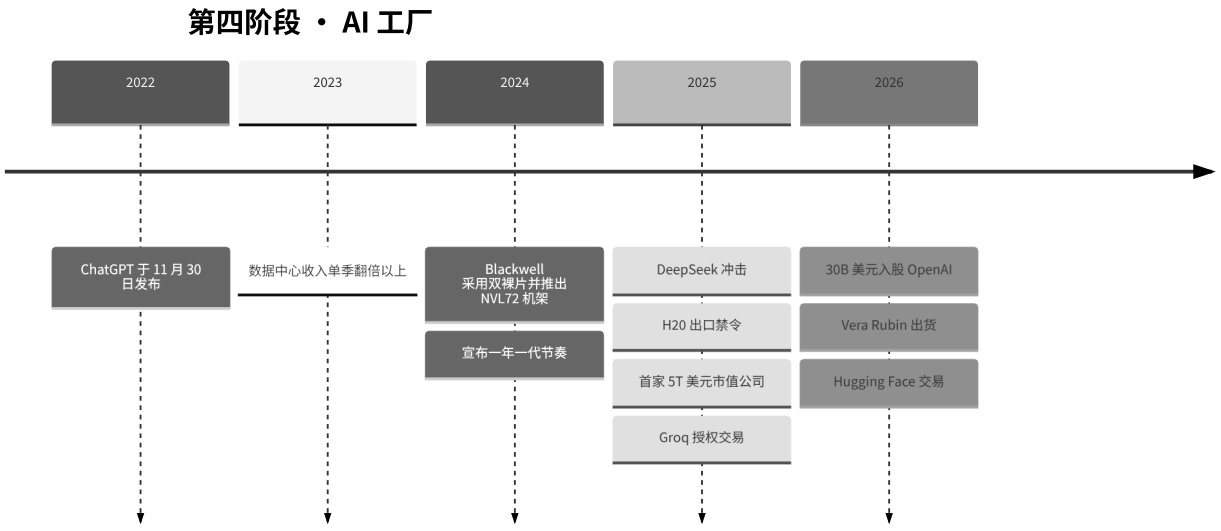


**需求骤然而至。** OpenAI 于 2022-11-30 发布 ChatGPT [S16014]。两个季度后，英伟达数据中心收入从 $4.3B 跃升至 $10.3B（Q2 FY2024）[S436,S437]。营收从 FY2024 的 $60.9B 增至 FY2025 的 $130.5B 和 FY2026 的 $215.9B [S2,S1]。

**英伟达用现金来提速。** 在 Computex 2024 上，它宣布数据中心产品转向“一年一代的节奏” [S17003]。Blackwell（2024）将两颗光罩尺寸极限大小的裸片（die）合为一个 GPU [S35014]，开发成本 ~$10B [S35028]。NVL72 机架使 72 块 GPU 构成一个 NVLink 域 [S396]（见第 08 层历史）。Vera Rubin 于 2026 年 8 月初开始量产出货 [S500]。

**冲击确实存在，但并未打断增长曲线。** 据报道，早期 GB200 机架出现过热，部分客户削减了订单 🟡 [S5500]。DeepSeek 的发布在一天之内（2025-01-27）抹去了 $589B 市值 [S25001]。2025 年 4 月的 H20 许可要求带来了 ~$4.5B 的费用 [S90081]。Rubin 的内存与 NVLink 带宽在发布后被下调 [S90006]。英伟达仍于 2025-10-29 成为首家市值 $5T 的公司 [S25010]。到 Q2 FY2027，季度营收为 $96.2B，GAAP 毛利率 75.0%，Q3 指引为 $108B ±2% [S405,S3]。

**它还成为了一个资本配置者。** 英伟达以据报道的 ~$20B 获得了 Groq 的技术授权并招揽其团队（2025 年 12 月）[S90018,S90019]，搁置了对 OpenAI 的 $100B 意向书，转而入股 ~$30B（2026 年 2 月）🟡 [S90015,S90016]，并同意以 $12.9B 收购 Hugging Face（2026 年 9 月）[S11500]。其股权投资总额 ~$99B（🟡 对 2026 年 7 月 10-Q 的二手解读）[S90073]（见资本部署）。

**商业模式随规模而改变。** 截至 Q2 FY2027，供应与产能承诺达 $279B [S407]，单一直接客户占季度营收的 16% [S90069]，FY2027 上半年 $23.7B 的股权投资净收益（主要为按市值计价的收益）计入了盈利 [S90072]。这一阶段始于一家芯片公司，终于一家预购供应商产能、为客户提供融资并持有大量股权投资组合的公司：其风险特征比 2016 年的 GPU 供应商复杂得多（见第 18 章）。

## Data Center grew from 7% of NVIDIA revenue in FY2016 to 90% in FY2026

Revenue by market platform, US$ B per fiscal year (FY ends late Jan); FY2026 gaming/other = sum of quarters

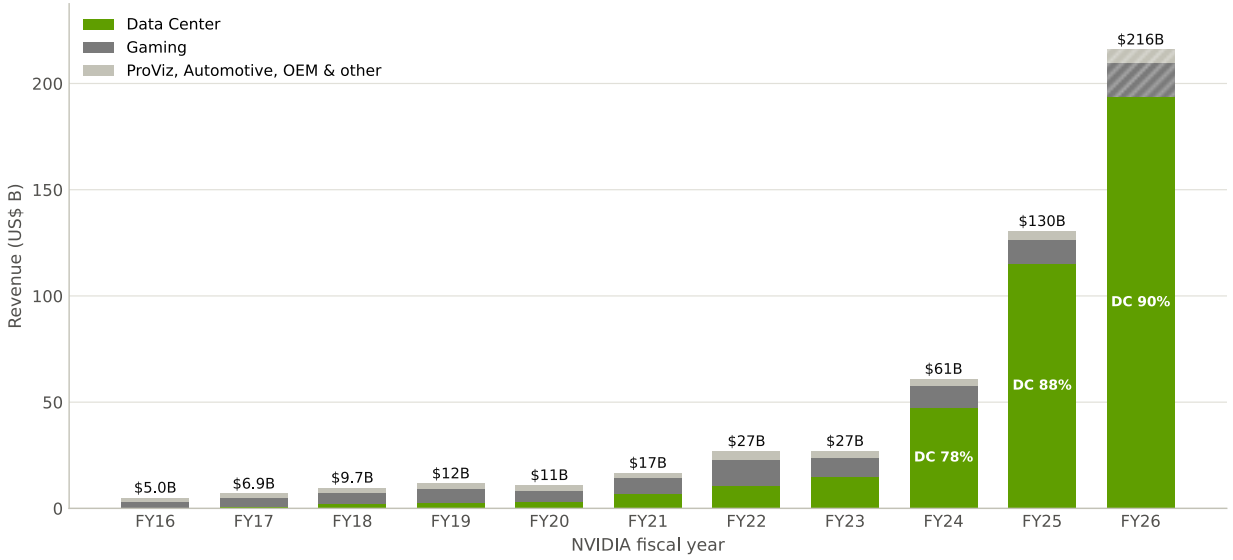


*Hatched = estimate*

Source: data from NVIDIA 10-K filings [S400] [S2] [S418] [S417] [S90090] [S416] …; chart by repo · As of 2026-11-05

英伟达 FY2016–FY2026 按业务分部的年度营收堆叠条形图：数据中心从 $0.34B（7%）增至 $193.7B（90%），游戏从 $2.8B 增至约 $16B；总营收从 $5.0B 增至 $216B。

## Gross margin climbed from 43.5% to ~75%, broken only by the H20 write-down

GAAP and non-GAAP gross margin, % of revenue, Q1 FY23–Q2 FY27; from Q1 FY2027 non-GAAP includes stock-based comp

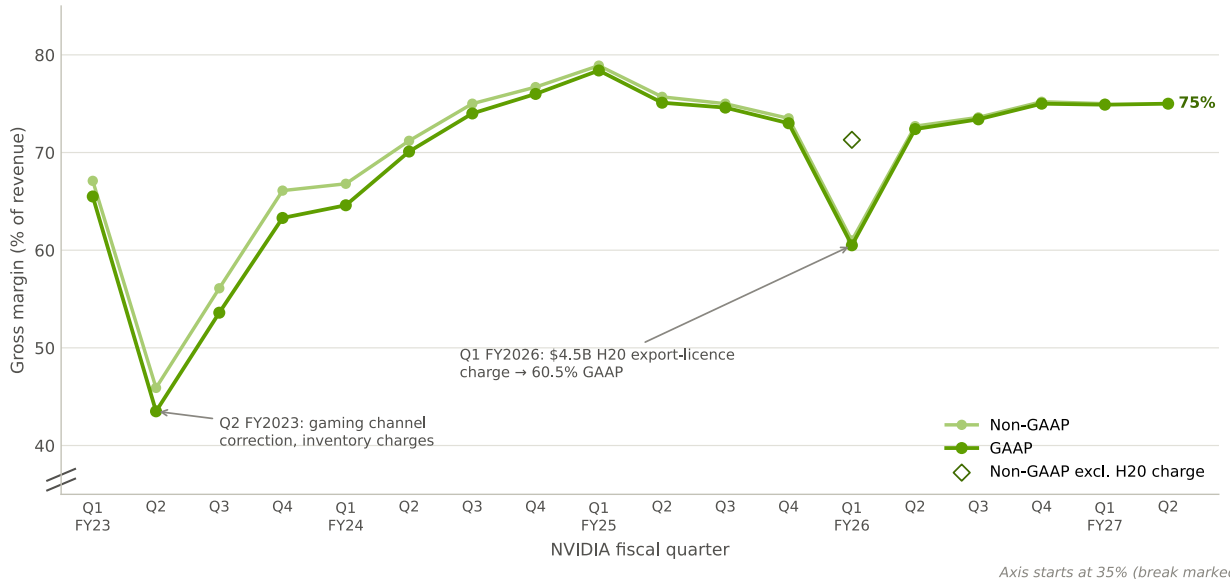


*Axis starts at 35% (break marked)*

Source: data from NVIDIA 8-K releases [S432] [S433] [S434] [S435] [S418] [S436] …; chart by repo · As of 2026-11-05

英伟达季度毛利率折线图：GAAP 毛利率在 Q2FY23 触底至 43.5%（游戏业务库存减值），在 Hopper 放量期间升至 75% 以上，在 Q1 FY2026 因 $4.5B 的 H20 出口管制费用降至 60.5%（剔除该项后非 GAAP 为 71.3%），在 Q2FY27 约为 75%。

### R&D spend rose 14× to $18.5B (FY2026) while falling to 9% of revenue

Left: GAAP research and development expense, US$ B per fiscal year. Right: R&D as % of revenue

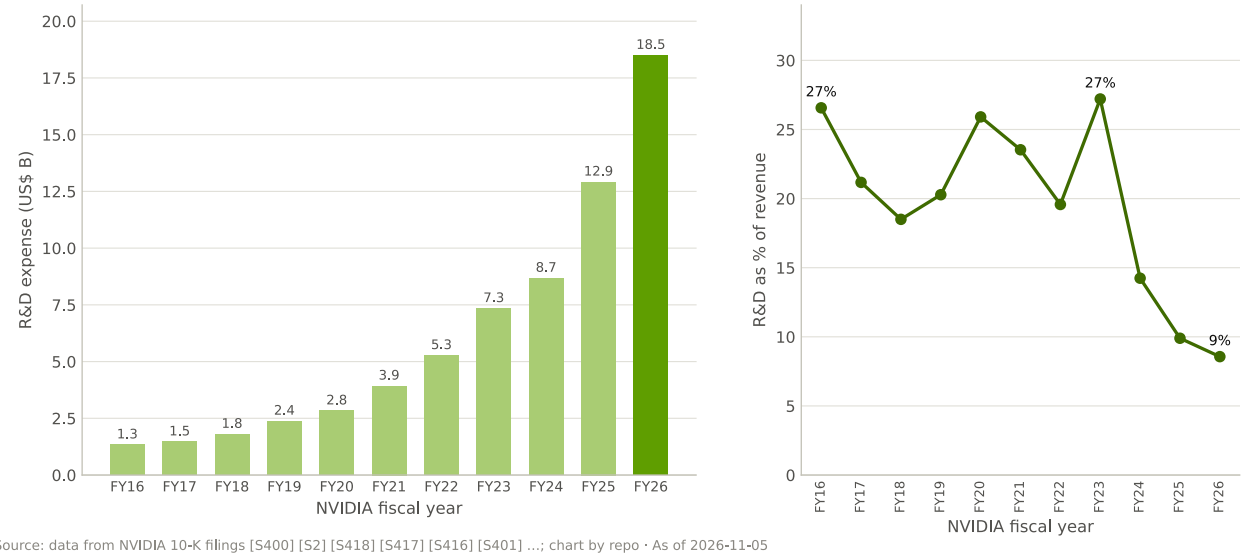


Source: data from NVIDIA 10-K filings [S400] [S2] [S418] [S417] [S416] [S401] ...; chart by repo · As of 2026-11-05

英伟达研发支出双面板图。左：研发支出从 FY2016 的 $1.33B 增至 FY2026 的 $18.5B，约 14 倍。右：由于营收增长更快，研发强度从营收的 27% 降至 8.6%。

**提示**

**算例 —— 为何研发强度下降并非弱点。** 英伟达 FY2026 研发支出 $18.5B，仅占营收的 ~8.6%，但约为 FY2016 $1.33B 的 ~14 倍 [S401,S400]。AMD 2024 年所有产品的研发总支出为 ~$6.5B [S450]。仅 Blackwell 一款产品就在数年间耗费了 ~$10B 开发成本 [S35028]：相当于英伟达 FY2026 研发预算的 ~54%，却是 AMD 2024 年全部研发预算的 ~1.5 倍。**结论：** 在大得多的基数上，较低的百分比所买到的绝对工程投入超过任何竞争对手，而这正是维持年度迭代节奏的基础。

### NVIDIA's GPU cadence sped up from ~29 months per generation to ~11 (annual)

Months between first volume availability of successive NVIDIA data-center GPU architectures, Volta → Feynman

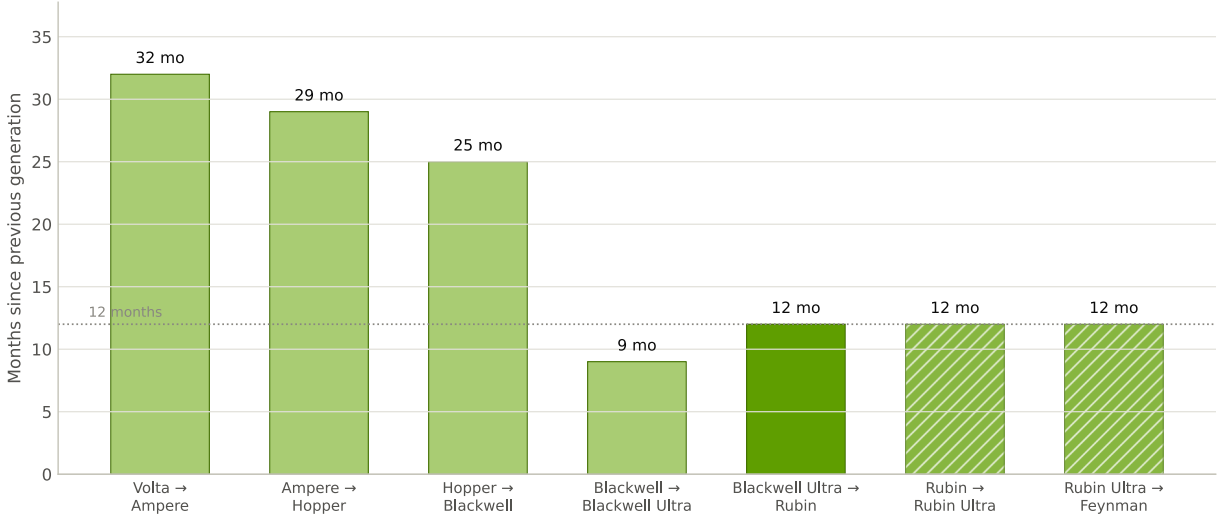


*Hatched = planned (roadmap)*

Source: data from NVIDIA keynotes and launch coverage [S126] [S312] [S127] [S315] [S35012] [S532] ...; chart by repo · As of 2026-11-05

英伟达 GPU 代际间隔月数条形图：Volta→Ampere、Ampere→Hopper 和 Hopper→Blackwell 平均约 29 个月；Blackwell→Blackwell Ultra 和 Blackwell Ultra→Rubin 平均约 11 个月；计划中的 Rubin Ultra（2H 2027）和 Feynman（2028）保持 ~12 个月的节奏，不过据报道 Kyber 机架将推迟至 2028 年。

**🔧 技术细节：为何产品越做越大**

每一步都把一个瓶颈移入英伟达自己的设计之中：DGX 将八块 GPU 放在一块板上，NVSwitch（2018）连接了十六块，NVL72（2024）则通过一个机架内的铜缆背板连接了七十二块 [S310,S396]。当大部分数据都留在一个 NVLink 域内时，谁设计这个域，谁就决定物料清单（BOM）并攫取利润。同样的逻辑也解释了 Mellanox（机架之间的网络）、Grace 与 Vera（主机 CPU）以及 BlueField（数据通路）；见飞轮一章。

## 濒危时刻与英伟达的应对

英伟达自身的文化倾向于认为公司始终处于失败边缘。而历史记录支持的是一个更窄的结论：它至少经历过八次严重挫折，且在其中大多数情况下都保住了研发投入并持续出货。下表列出了这些挫折及每次冲击的规模。

| 时间 | 事件 | 冲击规模 | 应对 | 来源 |
|---|---|---|---|---|
| 1996–97 | NV1 建立在错误的 3D 标准之上 | 客户寥寥，人员缩编 | ~2 年内推出 RIVA 128 | S16000,S16001 |
| FY2003 | Xbox 带来的产品结构变化与库存减记 | 毛利率 38% → 30% | 保持 PC GPU 产品线增长；营收达到 $1.91B | S16008,S16006 |
| FY2009–FY2010 | 封装缺陷与 2008 年经济衰退 | 毛利率 45.6% → 34.3%；$196M 费用 | 研发占营收比例从 17% 升至 27% | S22000,S22001 |
| 2015 | Icera 调制解调器失败 | 预计 $100–125M 费用 | 退出手机基带；重新聚焦 GPU、汽车和数据中心 | S16009,S16010 |
| FY2023 | 游戏与渠道库存危机 | 季度营收在两个季度内 −28%；Q2 毛利率 43.5% | 研发 +39%；H100 放量 | S432,S434,S2 |
| 2025 年 1 月 | DeepSeek 效率冲击 | 单日市值蒸发 −$589B | FY2026 营收仍增至 $215.9B | S25001,S1 |
| 2025 | H20 出口许可要求 | ~$4.5B 费用 | 从业绩指引中剔除中国数据中心计算业务 | S90081,S3 |
| 2026 | Rubin 规格在发布后修订 | 每 GPU HBM 带宽 22 → 19.2 TB/s | 规格重新表述为量产值 | S90006,S104 |

**提示**

**算例 —— 在 FY2023 危机中坚持投入。** 季度营收从 $8.29B（Q1 FY2023）降至 $5.93B（Q3 FY2023），两个季度内 −28% [S432,S434]，全年营收持平于 $27.0B [S2]。英伟达仍将研发支出从 FY2022 的 $5.27B 提升至 FY2023 的 $7.34B，+39% [S2]，同时推出了 2022 年 3 月发布的 H100 [S35012]。当需求随 ChatGPT 到来时，产品已经就绪：数据中心收入在单个季度内增长 ~2.4 倍 [S436,S437]。**结论：** 若在那次下行周期中削减研发，可节省 ~$2B，却会错失整个 Hopper 周期。

## 关键押注的决策树

每张图展示一个决策、英伟达选择的分支（绿色）、未选择的分支（虚线）以及随后的结果。反事实结果为本资料库的分析（🔴）。

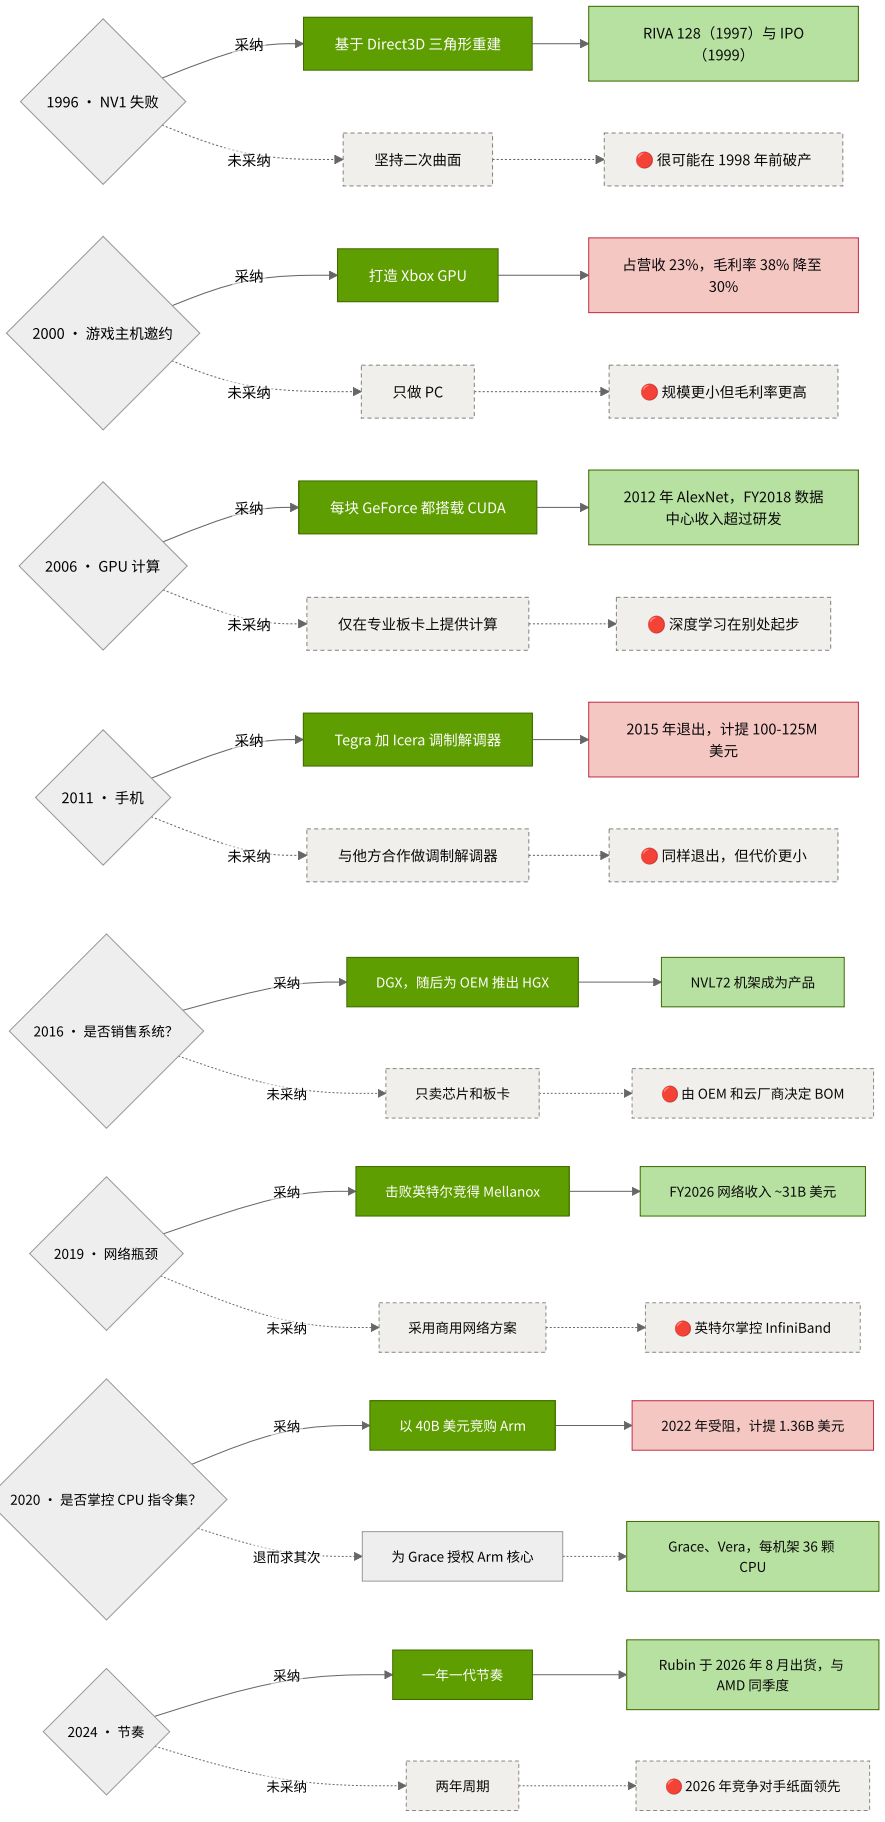


| 日期 | 决策 | 未采纳的选项 | 重要性 | 来源 |
|---|---|---|---|---|
| 1996–97 | 围绕 Direct3D 三角形重建 | 坚持 NV1 的二次曲面 | 得以存活；RIVA 128 恢复了销售 | S16000,S16001 |

| 日期 | 决策 | 未采纳的选项 | 重要性 | 来源 |
|---|---|---|---|---|
| 1999 | 将 GeForce 256 作为“GPU”推向市场 | 继续做加速卡供应商 | 命名了英伟达至今仍在销售的品类 | S2502 |
| 2000 | 接下 Xbox 合同；收购 3dfx 资产 | 只做 PC；任由 3dfx 资产落入他人之手 | 获得规模与 $200M 预付款，但毛利率更低 | S16005,S16008 |
| 2006–07 | 每块 GPU 都搭载 CUDA | 仅在高端板卡上提供计算 | 到 2026 年开发者达 ~6M | S9528,S528 |
| 2011–15 | 推出搭载 Icera 调制解调器的 Tegra 手机方案，随后退出 | 不进入手机市场 | 挑战在位平台的 ~$0.5B 教训 | S16009,S16010 |
| 2016–17 | 销售 DGX 系统和 HGX 基板 | 只卖芯片，由 OEM 设计 | 促成机架成为销售单位 | S310,S8525 |
| 2017 | V100 引入张量核心 | 仅用通用核心 | 矩阵运算达 FP32 的 8 倍 | S126 |
| 2019–20 | 以 $6.9B 收购 Mellanox | 采用商用网络方案 | FY2026 网络收入 ~$31.4B | S464,S402 |
| 2020–22 | 以 $40B 竞购 Arm；退而采用授权 | 从一开始就用授权核心自建 CPU | Grace 与 Vera 照样推出 | S465,S466,S537 |
| 2024 | 一年一代节奏 | 两年周期 | 竞争对手不得不跟进 | S17003,S17007 |
| 2025–26 | Groq 授权（~$20B）；Hugging Face（$12.9B） | 自建 SRAM 解码芯片；不涉足模型托管 | 尚待验证；考验英伟达作为大规模收购方的能力 | S90019,S11500 |

**NVIDIA's winning bets took 2–11 years to pay off; it cut its failed bets within 4**

Years from each key bet to its payoff milestone (or to the exit), 1995–2027; milestones defined in data/x16_key_bets.csv

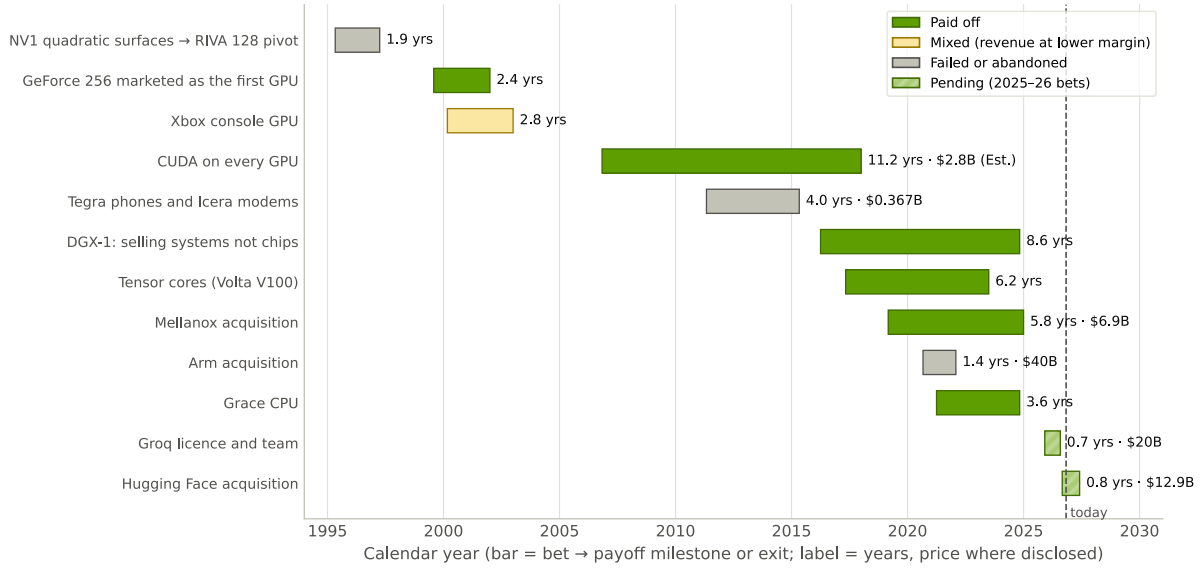


Source: data from NVIDIA filings and press releases, trade press, repo case studies [S16000] [S16001] [S2502] [S16006] [S16005] [S16008] ...; chart by repo · As of 2026-11-05

英伟达十二次押注的甘特式条形图。成功：GeForce 256 至首个 $1B 财年用时 2.4 年，CUDA 至数据中心收入超过研发用时 11.2 年，DGX-1 至 NVL72 机架 8.6 年，张量核心至 Hopper 爆发 6.2 年，Mellanox 至收回成本 5.8 年，Grace 至 GB200 3.6 年。失败：NV1 的二次曲面（约 2 年后转向 RIVA 128）、Tegra 手机方案与 Icera 调制解调器（4 年）以及 $40B 的 Arm 竞购（1.4 年）。好坏参半：Xbox。尚待验证：~$20B 的 Groq 授权和 $12.9B 的 Hugging Face 收购。

**提示**

**算例 —— 把押注账本当作投资组合来看。** 六次押注获得回报，用时 2.4 至 11.2 年（中位数 ~6 年）[S16016]。三次失败，英伟达在 1.4 至 4.0 年后将其砍掉。按披露的价格衡量，失败案例（Icera ~$0.37B、Arm ~$1.36B 费用）合计成本 ~$1.7B [S16009,S466]。而仅一次成功——Mellanox——就在一年内带来 ~$31.4B 的网络收入 [S402]。**结论：** 这一组合之所以奏效，是因为亏损被迅速止住，而赢家被持有长达十年——这是上市公司内部的经典风险投资模式。

**Since 2023, 50 of NVIDIA's 65 logged deals were stakes in customers and partners, not M&A**

Each deal by announcement date and the stack layer it strengthens; marker area ∝ US$ amount (small hollow = undisclosed)

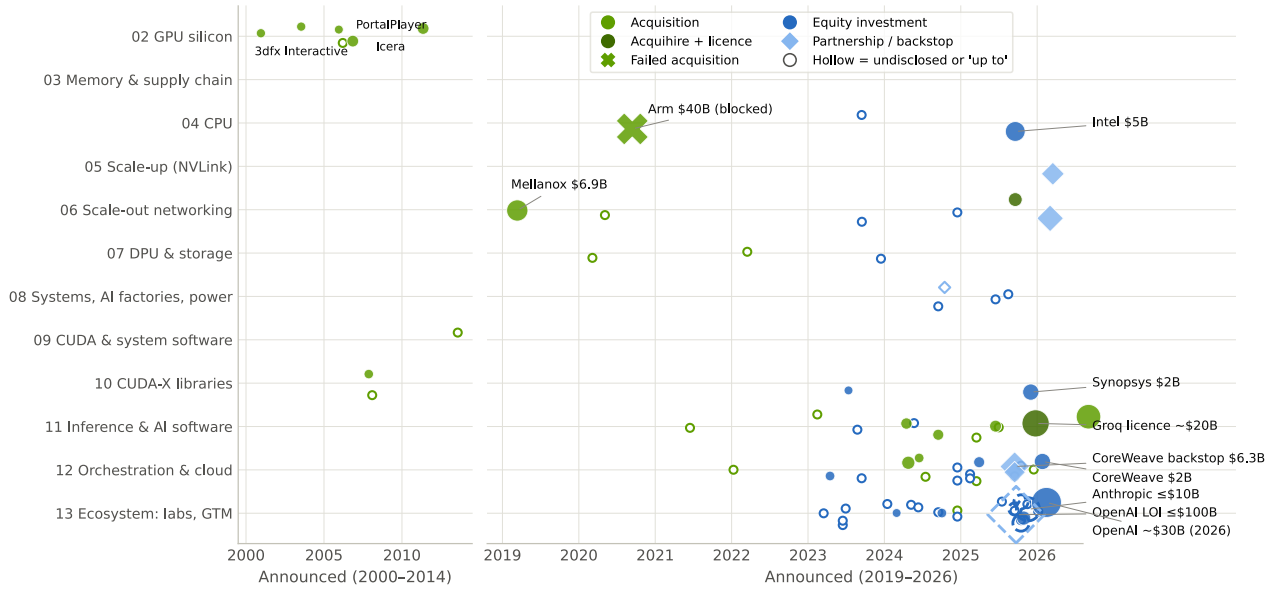


*Pre-2019 axis compressed*

Source: data from NVIDIA filings and announcements; press reports [S400] [S484] [S464] [S2] [S478] [S465] …; chart by repo · As of 2026-11-05

> 时间线散点图：2000 至 2026 年英伟达的 81 笔收购、收购式招聘加授权交易以及战略投资，按各自强化的技术栈层级排列。早期交易是 GPU 和移动芯片领域的补强型收购；Mellanox（$6.9B，2019）构建了网络层；自 2023 年以来，65 笔交易中有 50 笔为股权投资，以 OpenAI、Anthropic、英特尔和 CoreWeave 为首，外加 ~$20B 的 Groq 授权交易。

## 反事实分析

全部六个反事实均为本资料库的分析（🔴 推测）。每一个都阐明了推理过程，以及它对英伟达及其竞争对手意味着什么。各层的反事实分析见 GPU 芯片、网络和 CUDA 的历史页面。

| # | 假如英伟达当初…… | 🔴 最可能的结果 | 意味着什么 |
|---|---|---|---|
| 1 | ……在 Direct3D 选择三角形之后仍坚持 NV1 的二次曲面 | 到 ~1998 年耗尽现金 | PC 图形市场向 3dfx 和 ATI 集中；没有 GeForce，也没有 CUDA |
| 2 | ……只在高端计算板卡上提供 CUDA | AlexNet 运行在 CPU 或其他厂商的硬件上 | 深度学习的默认技术栈在别处形成，可能围绕谷歌的 TPU |
| 3 | ……让英特尔抢走 Mellanox | 英特尔掌控 InfiniBand 和 ConnectX | 英伟达没有网络业务线（FY2026 ~$31.4B）；从 NVL72 到集群的叙事更弱 |
| 4 | ……完成 $40B 的 Arm 交易 | 行为性救济措施；被授权方转向 RISC-V 和 x86 对冲 | 英伟达拥有一家其客户并不信任的“中立”授权方 |
| 5 | ……维持两年周期 | Rubin 在 ~2027 年才推出 | AMD MI455X 和 TPU 8t 在整个 2026 年规格领先英伟达 |
| 6 | ……将 DGX Cloud 推进为完整的公有云 | 与其最大客户公开发生渠道冲突 | 超大规模云厂商加速推进 TPU、Trainium 和 Maia；新兴云服务商失去其供应商兼合作伙伴 |

**1. 若没有 RIVA 128 转型。** NV1 在技术上颇有新意，但与游戏开发者采用的基于三角形的 Direct3D 不兼容 [S16000]。在推出 RIVA 128 之前，公司客户寥寥，人员缩编 [S16001]。若在错误的标准上再坚持一年，很可能已将公司耗尽。*意味着什么：* PC 3D 图形市场将向 3dfx 和 ATI 集中。而实际情况是，英伟达在 2000–01 年以 $70M 外加股票收购了 3dfx 的资产 [S16005]。

**2. CUDA 仅用于高端板卡。** 这是最微妙的一个。AlexNet 是在两块消费级 GTX 580 上训练的 [S9530]，而该平台的覆盖面正来自在游戏显卡上搭载 CUDA [S22006]。若计算能力仅限于昂贵的 Tesla 板卡，学术研究将停留在 CPU 上，或转向当时最便宜的任何硬件。谷歌到 2015 年已在其数据中心运行 TPU [S23000]。*意味着什么：* 框

架生态（在本资料库的矩阵中，如今 36/36 原生支持 CUDA [S580]）可能会围绕某家超大规模云厂商的编译器形成，正如后来 XLA 之于 TPU。

**3. 英特尔赢得 Mellanox。** 据报道英特尔出价 ~$6B，共有七家竞购方参与 [S6509,S6508]。*意味着什么：* 英特尔将掌控连接大多数 AI 集群的 InfiniBand 交换机和 ConnectX 网卡（NIC），从而获得英伟达如今所拥有的话语权。Spectrum-X 在 Q2 FY2027 同比增长 2.6 倍 [S408]，若无 Mellanox 团队便无从打造。英伟达的网络业务线（FY2026 ~$31.4B [S402]）和 Spectrum-X 都不会以现有形态存在。英伟达很可能会基于博通（Broadcom）的以太网芯片来构建。

**4. Arm 交易完成。** $40B 的价格 [S465] 将买下高通服务器 CPU 以及 AWS、谷歌和微软自研 CPU 背后的指令集 [S4517,S4022,S4026,S4024]。监管机构很可能会施加中立性条件，正如中国对 Mellanox 交易所做的那样 [S21002]。*意味着什么：* 客户会更早转向 RISC-V 或 x86 进行对冲；英伟达将拥有一笔无法用于战略目的的授权费收入。而 Grace 和 Vera 本来就是基于授权核心打造的 [S537]。

**5. 没有年度迭代节奏。** 按照过去 ~29 个月的节奏 [S33020]，Rubin 将在 ~2027 年才推出，而 AMD 的 MI455X（432 GB HBM4）和谷歌的 TPU 8t 均在 2026 年推出 [S144,S550]。纸面上 MI455X 已在 HBM 带宽（23.3 对 19.2 TB/s，~21%）和容量（432 对 288 GB）上领先 Rubin [S144,S90093,S90006]；若对比 Blackwell Ultra 的 288 GB、8 TB/s [S32004]，带宽差距将达 ~2.9 倍。*意味着什么：* 竞争对手将在整整一年里在所有标志性规格上领先——第 17 章表明，英伟达的路线图正是为了不给对手这种可乘之机而设计的。

**6. 英伟达成为一家完整的云厂商。** DGX Cloud 于 2023 年 3 月推出，每个 8-GPU 实例每月 $36,999，托管于甲骨文（Oracle）、微软和谷歌的数据中心内 [S12007]。据报道，到 2025 年其大部分算力已转用于英伟达自身的研究，而 DGX Cloud Lepton 则开始将开发者导向合作伙伴云 🟡 [S90068]。若英伟达继续推进，它将与当时最大的买家——超大规模云厂商——争夺终端客户（仅一家直接客户就占 Q2 FY2027 营收的 16% [S90069]）。*意味着什么：* 超大规模云厂商将作为防御性回应加快对 TPU、Trainium 和 Maia 的投入，新兴云服务商渠道也将被削弱。这次收缩是英伟达选择不掌控某一层的罕见案例。

> **注意**
>
> **误区与事实：“英伟达预见了 AI 热潮。”** 历史记录显示的是一家构建了通用平台然后耐心等待的公司。英伟达并未预见深度学习：AlexNet 出自大学研究人员之手 [S9530]，数据中心收入直到 FY2018 都低于研发支出 [S400]。英伟达所做的，是让试验变得廉价，然后在需求出现时迅速行动：AlexNet 之后两年内推出 cuDNN [S9531]，四年内推出 DGX [S310]。

> **🔧 技术细节：如何评判这些反事实**
>
> 每个反事实只改变一项决策，并保持外部世界的其他条件不变（竞争对手路线图、深度学习的到来、监管机构的行为）。其合理性基于有据可查的替代方案：英特尔据报道对 Mellanox 的出价 [S6509]、被放弃的世嘉芯片 [S16000]、2015 年退出 Icera [S16009] 以及 AMD 2026 年的规格 [S144]。变化与结果之间的跨度越大，置信度越低；第 2 个反事实最不确定，因为它取决于研究人员当时会如何行事。

## 经验教训

下面的象限图按各押注对 GPU 平台的延伸程度及其回报进行定位；这是本资料库的判断（🔴），但规律十分鲜明：右上角的每一项押注都延伸了平台，而每一次明确的亏损都偏离了平台。

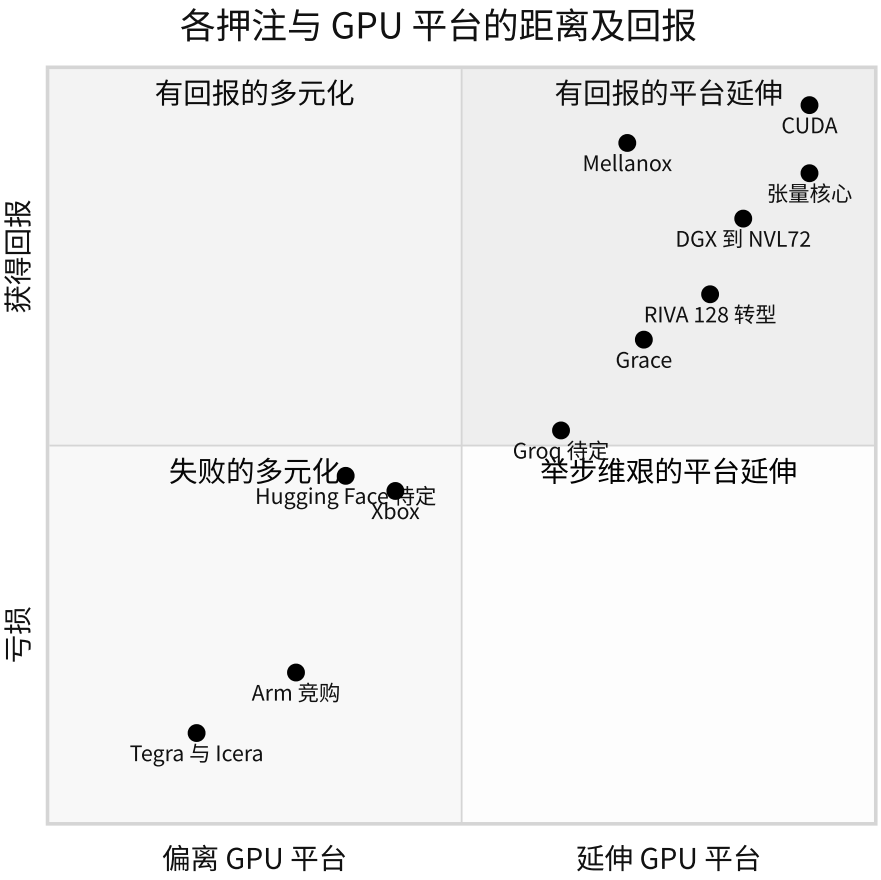


| # | 经验 | 证据 | 对挑战者的启示 |
|---|---|---|---|
| 1 | 在市场形成之前构建平台，但要用现金引擎为其提供资金 | CUDA 运行了 ~11 年，数据中心收入才覆盖研发支出 S9528,S400；游戏业务为其买单 | 平台押注需要一个盈利的核心业务，以及一个能容忍十年投入的董事会 |
| 2 | 当标准对你不利时，迅速采纳 | NV1 → RIVA 128 用时 ~2 年 S16000,S16001 | 标准之争若要输，就早输，别慢慢输 |
| 3 | 在相邻瓶颈显而易见之前将其收入囊中 | Mellanox $6.9B → FY2026 网络收入 ~$31.4B S464,S402 | 今天的对应物可能是光学、电源或内存接口 |
| 4 | 不要收购所有人都依赖的中立层 | Arm 交易受阻；~$1.36B 费用 S466 | 监管风险随依赖该资产的竞争对手数量而上升 |
| 5 | 偏离平台的举措往往令人失望 | Xbox 毛利率 S16008、Icera S16009 | 通过延伸平台实现多元化，而非进入他人的市场 |
| 6 | 销售系统，掌控物料清单 | DGX → NVL72 S310,S396 | 谁制定机架规格，谁就保住利润 |
| 7 | 速度本身就是战略 | 每代 ~29 → ~11 个月 S33020 | 跟上这一节奏如今已是入场门槛 |
| 8 | 在会与买家竞争之处主动退后 | DGX Cloud 转向内部用途；Lepton 将需求导向合作伙伴云 🟡 S90068 | 平台供应商不与客户为敌，才能保住渠道 |

**这些经验没有说明什么。** 直到 2019 年，英伟达的历史都不是一个靠收购成长的故事。在 Mellanox 之前，其最大的收购是 PortalPlayer（~$357M，Tegra 的起源）和 Icera（~$367M）🟡 S484,S16009，而核心平台（GPU、CUDA、软件库）均为自主研发。它也不是一个关于远见的故事：深度学习和 ChatGPT 都来自外部。可借鉴的是一种经营习惯：在低谷中坚守平台押注，迅速砍掉旁支押注，并在下一个瓶颈出现时将其买下。每一种习惯的复制成本都低于它所造就的装机基础——后者用了二十年才积累而成，才是任何挑战者面临的真正壁垒（关于路线图如今如何守护这一基础，见第 17 章）。

> **注**
>
> 🐂 **看多观点：** 历史表明，这是一个能够从濒危中幸存、坚持十年期押注并迅速砍掉失败项目的组织。这种文化，加上每年 ~$18.5B 的研发投入 S401，比任何芯片都更难复制。

> **注意**
>
> 🐻 **看空观点：** 决定性的回报来自一个并非英伟达促成的外部事件[S9530]，而它在 GPU 平台之外的记录乏善可陈（Xbox 毛利率、Icera、Arm）。2025–26 年的押注（Groq ~$20B、Hugging Face $12.9B、~$99B 的股权投资组合）是其历史上规模最大的，也是与其过往成功案例最不相像的[S90019,S11500,S90073]。见第 18 章。

## 🎯 企业发展视角

1. **期权价值需要现金引擎。** CUDA ~$2.8B 的期权费（🔴 估计）[S22009] 之所以负担得起，是因为有游戏业务为其提供资金。挑战者的哪项业务能够为一项长达十年的平台押注提供资金，而不引发投资者反弹？
2. **止损标准是战略的一部分。** 英伟达在 1.4–4 年内退出了三次失败的押注[S16016]。全行业当今的数据中心押注——包括高通的 AI200/AI250 和 Dragonfly 项目（仅限公开信息）[S173,S90056]——附带了哪些明确的里程碑和退出触发条件？
3. **下一个 Mellanox。** 经验是在相邻瓶颈形成约束之前将其买下。在光学、800 V DC 电源、内存控制器或纵向扩展（scale-up）交换领域，还有哪些独立资产尚未被英伟达、AMD 或博通收入囊中？内存、纵向扩展、网络和系统的价值链页面列出了各领域的非上市公司。
4. **为替代架构定价。** 英伟达为 Groq 的授权和团队支付了 ~$20B，约为其上一轮 $6.9B 私募估值的 ~2.9 倍[S90019]。这对于经过验证的 SRAM、近存计算或容量优先型推理设计对在位者的价值意味着什么？
5. **由外而内的需求转变决定时代。** 开启第三阶段的是 AlexNet，而非英伟达；开启第四阶段的是 ChatGPT[S9530,S16014]。哪一种外部转变（智能体带来的 CPU 需求、电力受限的推理、端到云模型）可能为一位已备好合适平台的挑战者开启下一个时代？

# 17 —— 路线图 2025–2028

跨层专题 17 · 覆盖每一层、英伟达及其竞争对手，2025–2028 · 约 28 分钟阅读 · 最后核实：2026-11-05

## ⚡ 要点速览

- **计划进展到哪一步。** Vera Rubin NVL72 已于 2026 年 8 月初开始量产出货，并于 2026 年第四季度放量 [S500,S90009]。🟢 Rubin Ultra 定于 2027 年下半年推出，🟢 Feynman 定于 2028 年推出，并搭配 Rosa CPU、LP40 解码芯片、BlueField-5 和 ConnectX-10 🟡 [S35018,S109,S90004]。
- **每一层约每年更新一次。** 英伟达（NVIDIA）在全部六个硬件层都有定于 2027 年或之后的产品，而竞争对手定于 2027 年或之后的项目中有 68% 是芯片或机架（本资料库对 `data/roadmap.csv` 的统计）[S17006,S502,S538]。
- **2026 年，计划在四处走样。** 🟢 Rubin 标称的高带宽内存（HBM4）带宽从 22 降至 19.2 TB/s，每 GPU 的 NVLink 6 带宽从 3.6 降至 3.0 TB/s [S90006,S103]。🟡 Rubin CPX 一度从路线图上消失，据报道将于 1Q27 回归 [S115,S117]。🟡 据报道 Kyber 机架将推迟至 2028 年，英伟达对此予以否认 [S507,S508]。机架命名如今按封装数而非裸片（die）数计算 [S90009,S108]。
- **第二条推理产品线登场。** Groq 3 LPX 机架（256 颗 LPU）于 2026 年 8 月全面投产，LP35（2027）和 LP40（2028）将随后推出 [S506,S108,S109]。
- **路线图是一种销售工具。** 英伟达在 Rubin、Rubin Ultra 和 Feynman 上市前 26–40 个月就公布了时间表；谷歌（Google）只提前 ~7 个月公布 TPU 时间表（🔴 本资料库分析）[S17006,S17003,S35018]。在六次路线图发布期间，数据中心收入仍连续 14 个季度增长：迄今尚未出现奥斯本效应 [S405,S17006]。
- **竞争对手如今已跟上节奏。** AMD 在 Computex 2024 上转向年度节奏（2027 年 MI500，2028 年 MI600）[S17007,S538]。即将推出的还有：TPU 8t/8i（2026 年末）、Trainium4 和 Maia 300（2027，🟡）、Ascend 960（提前至 2027 年第一季度）以及高通（Qualcomm）AI250/AI300（2027/2028）[S550,S156,S90046,S567,S173,S90060]。
- **弱点：** 纸面上，AMD 的 MI455X 如今在 HBM 容量（432 对 288 GB）和带宽（23.3 对 19.2 TB/s，高 ~21%）上领先 Rubin [S144,S90093,S90006]。未来 18 个月考验的更多是执行力（Kyber、HBM4E、共封装光学（CPO）），而非愿景。
- **下一批观察节点：** 2026-11-17 发布 Q3 FY2027 业绩 [S17005]，2026-12-01 的 GTC DC 主题演讲 [S90047]，以及 2027 年 3 月 14–18 日在圣何塞举行的 GTC 2027 [S17000]。

**NVIDIA's roadmap refreshes every layer about yearly to 2028; 3 items carry reported slips**

NVIDIA availability windows by product line, 2024–2028 (bar runs to the next generation; dot = confidence)

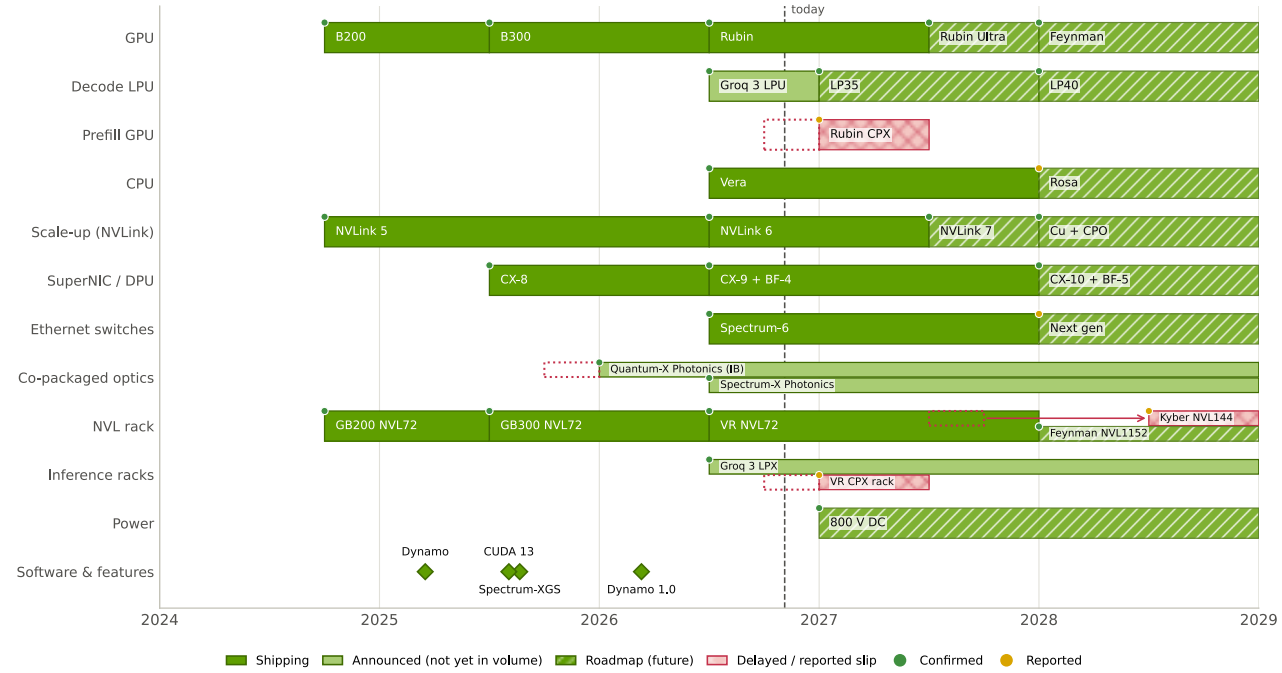


Source: data from NVIDIA keynotes, filings and trade press [S35014] [S121] [S32004] [S123] [S33020] [S554] …; chart by repo · As of 2026-11-05

> 英伟达 2024–2028 年数据中心产品甘特图，覆盖 12 条产品线：GPU 从 Blackwell（2024）演进到 Blackwell Ultra（2025）、Rubin（自 2026 年 8 月起出货）、Rubin Ultra（2H 2027）和 Feynman（2028），NVLink、网卡、CPU 和机架同步换代。15 个项目已发布或在路线图上；3 个项目（Rubin CPX、其 CPX 机架和 Kyber NVL144 机架）有推迟报道，图中对照其原定窗口显示。

交互版本

## 覆盖所有层的综合路线图

英伟达销售的是平台，因此其路线图是一组同步推进的产品线：GPU、解码加速器、内存、CPU、纵向扩展（scale-up）交换机、网卡（NIC）与数据处理器（DPU）、机架、电源和软件。每条产品线的每一代都设计为与其他产品线的对应一代同步出货，且每代 GPU 如今都会在约一年后迎来一次中期升级（“Ultra”）。下方甘特图将十二个层级的路线图整合为一张视图。标签：🟢 英伟达已确认，🟡 有报道，🔴 推测。各层自己的路线图页面提供详细信息，例如 GPU 芯片、纵向扩展和系统。

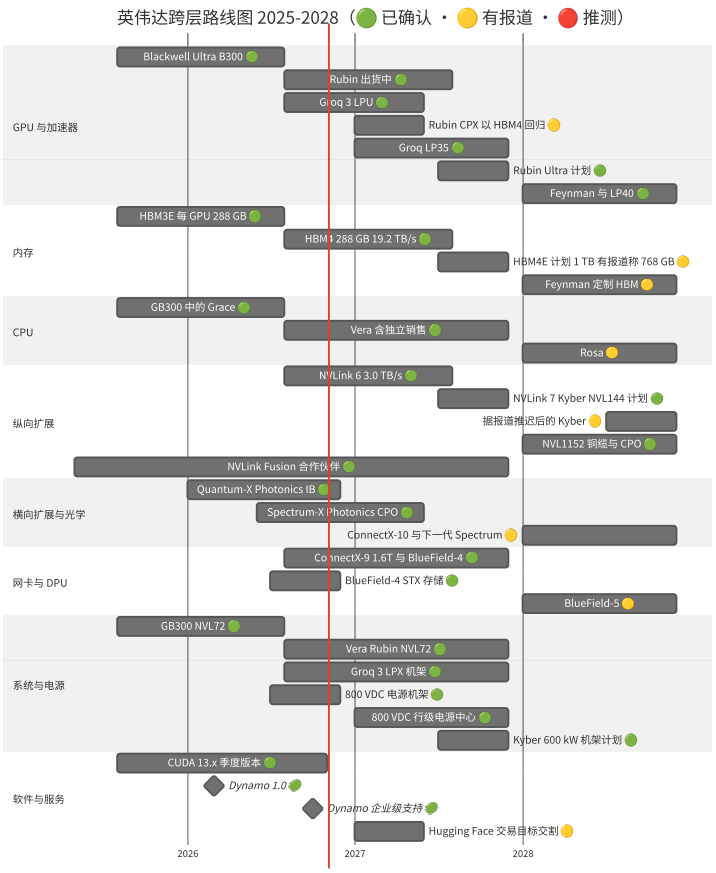


各行来源见下方综合表；未列入该表的条形：GB300 中的 Grace [S32004]；有关 Kyber 推迟的报道 [S507] 以及英伟达的否认 [S508]。

竞争对手的日程逐年与之对应。AMD 为截至 2028 年的每一年都命名了一款机架；云服务商提前一到两年公布时间表；华为公布的时间跨度仅次于英伟达。

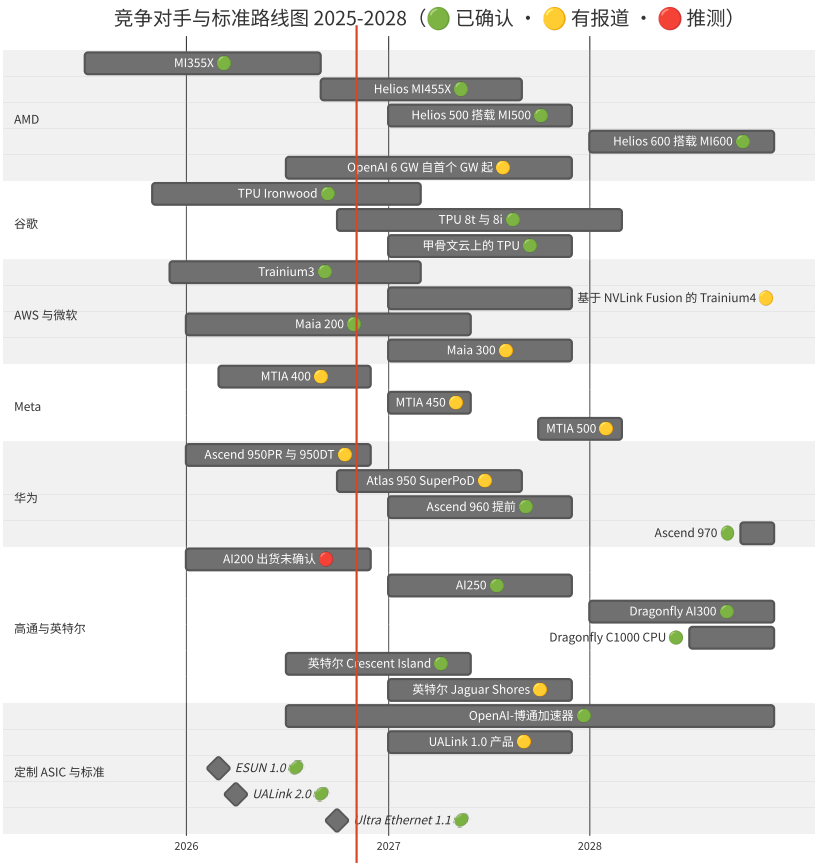


各行来源见下方综合表；未列入该表的条形：OpenAI–博通加速器，自 2026 年下半年起共 10 GW [S174]。

## 综合路线图表

数据来自 `data/roadmap.csv` 及各层路线图页面。时间窗口以日历季度或年份表示；“状态”截至 2026-11-05。

| 层 | 项目 | 时间窗口 | 状态 | 置信度 | 来源 |
|---|---|---|---|---|---|
| 02 | Rubin GPU（336B 晶体管，288 GB HBM4） | 2026 年第三季度出货，2026 年第四季度放量 | 出货中 | 🟢 | S100,S500,S90009 |
| 02 | Rubin CPX（预填充 GPU） | 原定 2026 年末；据报道改为 1Q27 并采用 HBM4 | 推迟 | 🟡 | S33023,S115,S117 |
| 02 | Groq 3 LPU（~500 MB SRAM） | 2026 年第三季度 | 全面投产 | 🟢 | S113,S506 |
| 02 | Groq LP35（新增 NVFP4） | 2027 | 路线图 | 🟢 | S108 |
| 02 | Rubin Ultra（4 颗裸片，发布时宣称 ~100 PFLOPS FP4） | 2027 年下半年；有报道称为双裸片版本 | 路线图 | 🟢 / 🟡 | S35018,S509 |
| 02 | Feynman GPU 搭配 LP40 | 2028 | 路线图 | 🟢 | S109,S502 |
| 03 | HBM4，每 GPU 288 GB、19.2 TB/s | 2026 | 出货中（已修订） | 🟢 | S102,S103,S104 |
| 03 | HBM4E，每颗 Rubin Ultra 1 TB（有报道称 768 GB） | 2027 年下半年 | 路线图 | 🟢 / 🟡 | S110,S111 |
| 03 | CoWoS 产能：2026 年末 ~105–130k 片晶圆/月，2028 年前 ~260k | 2026–2028 | 估计 | 🟡 | S90039,S3002 |
| 04 | Vera CPU（88 核），亦单独销售 | 2026 | 出货中 | 🟢 | S100,S90003 |
| 04 | Rosa CPU | 2028 | 路线图 | 🟡 | S109,S90004 |
| 05 | NVLink 6，每 GPU 3.0 TB/s（原为 3.6） | 2026 | 出货中（已修订） | 🟢 | S100,S103 |

| 层 | 项目 | 时间窗口 | 状态 | 置信度 | 来源 |
|---|---|---|---|---|---|
| 05 | Kyber NVL144 中的 NVLink 7 | 官方为 2027 年下半年；有报道称 2028 | 存在争议 | 🟡 | S108,S507,S508 |
| 05 | Feynman Kyber NVL1152，铜缆加 CPO | 2028 | 路线图 | 🟢 | S108,S112 |
| 05 | NVLink Fusion（采用者包括 Trainium4） | 2025–2027 | 出货中 / 路线图 | 🟢 / 🟡 | S131,S518 |
| 06 | Quantum-X Photonics InfiniBand | 2026 年初（由 2025 年推迟） | 部署中 | 🟡 | S515,S6022 |
| 06 | Spectrum-X Photonics 以太网（CPO） | 2026 年下半年 | 据报道已全面投产 | 🟡 | S514,S6020 |
| 06 | ConnectX-10 与下一代 Spectrum | 2028 | 路线图 | 🟡 | S109,S502 |
| 07 | ConnectX-9（1.6 Tb/s）与 BlueField-4 | 2026 | 出货中 | 🟢 | S33004,S512 |
| 07 | BlueField-4 STX 上下文存储设计 | 2026 年下半年 | 已发布 | 🟢 | S7511 |
| 07 | BlueField-5 | 2028 | 路线图 | 🟡 | S109,S90004 |
| 08 | Vera Rubin NVL72（~190–230 kW） | 2026 年第三季度 | 出货中 | 🟢 / 🟡 功耗 | S102,S500,S303 |
| 08 | 800 V DC 电源机架；行级电源中心 | 2026 年下半年；2027 | 路线图 | 🟢 | S90063 |
| 08 | 用于 Rubin Ultra 的 Kyber 机架（~600 kW） | 官方为 2027 年下半年；有报道称 2028 | 存在争议 | 🟡 | S305,S507 |
| 09 | CUDA 13.x，大约每季度一版（13.5 于 2026-11-04 发布） | 持续 | 出货中 | 🟢 | S523 |
| 11 | Dynamo 1.0 → 1.5.1，提供企业级支持 | 2026 年 3 月 → 10 月 | 出货中 | 🟢 | S520,S521 |
| 11 | Hugging Face 收购交割 | 2027 年上半年 | 待审批 | 🟡 | S11500,S11027 |
| 竞争对手 | AMD Helios（72 × MI455X） | 首批出货约在 2026 年第三季度末 | 出货中 | 🟢 | S538,S90020 |
| 竞争对手 | AMD MI500 / MI600 | 2027 / 2028 | 路线图 | 🟢 | S538 |
| 竞争对手 | 谷歌 TPU 8t / 8i | 2026 年末 | 已发布 | 🟢 | S550 |
| 竞争对手 | AWS Trainium4 | 2027（估计） | 路线图 | 🟡 | S156,S518 |
| 竞争对手 | 微软 Maia 300 | 2027 | 已发布 | 🟡 | S90046 |
| 竞争对手 | 华为 Ascend 960 / 970 | 2027 年第一季度 / 2028 年第四季度 | 路线图 | 🟢 | S163,S567 |
| 竞争对手 | 高通 AI250 / Dragonfly AI300 | 2027 / 2028 | 路线图 | 🟢 | S173,S90060 |
| 标准 | UALink 1.0 产品 | 2027 | 预期 | 🟡 | S90051 |

**提示**

**算例 —— 买方需要跟踪多少次英伟达产品发布。** 仅统计上表中的硬件行，英伟达在 2026 年有 7 个项目出货，2027 年约有 6 个，2028 年有 8 个，覆盖 GPU、解码芯片、内存、CPU、NVLink、网卡/DPU、交换机和机架。超大规模云厂商对每一项进行认证，都需要完成散热、电源、网络和软件验证。**结论：** 平台的迭代节奏同时也是一种认证负担。它有利于拥有大型工程团队的买方（超大规模云厂商）以及按原设计整机架采购的买方（新兴云服务商、主权买家），而夹在两者之间的买方则受到挤压。

## 规格演进：每一步换来了什么

规格图表让路线图更加具体。从 H100 到 Rubin，每 GPU 的低精度算力提升了 ~18 倍，而 HBM 带宽仅提升 ~5.7 倍，功耗提升 ~3.3 倍。这一差距即内存墙，也正是 2027–28 年路线图的大部分内容聚焦于内存与互连、而非 FLOPS 的原因。

纵向扩展域的增长甚至快于芯片本身。如今 NVLink 在一台 Vera Rubin 机架中连接 72 个 GPU 封装，在 Kyber 中连接 144 个（2027 年计划），在 Feynman 的 Kyber NVL1152 中连接 1,152 个（2028），最后一种采用共封装光学，因为铜缆无法覆盖如此远的距离 [S100,S108]。单机架功耗随之上升：GB300 NVL72 为 ~132 kW，Vera Rubin 为 ~190–230 kW，Kyber 为 ~600 kW [S337,S303,S305]。

**H100 → Rubin: low-precision compute 18×, HBM bandwidth 5.7×, capacity 3.6×, power 3.3×**

Per-GPU specs by generation, 2022–2028: dense FP8 (Hopper) or FP4 (Blackwell+) PFLOPS, HBM TB/s, HBM GB, W

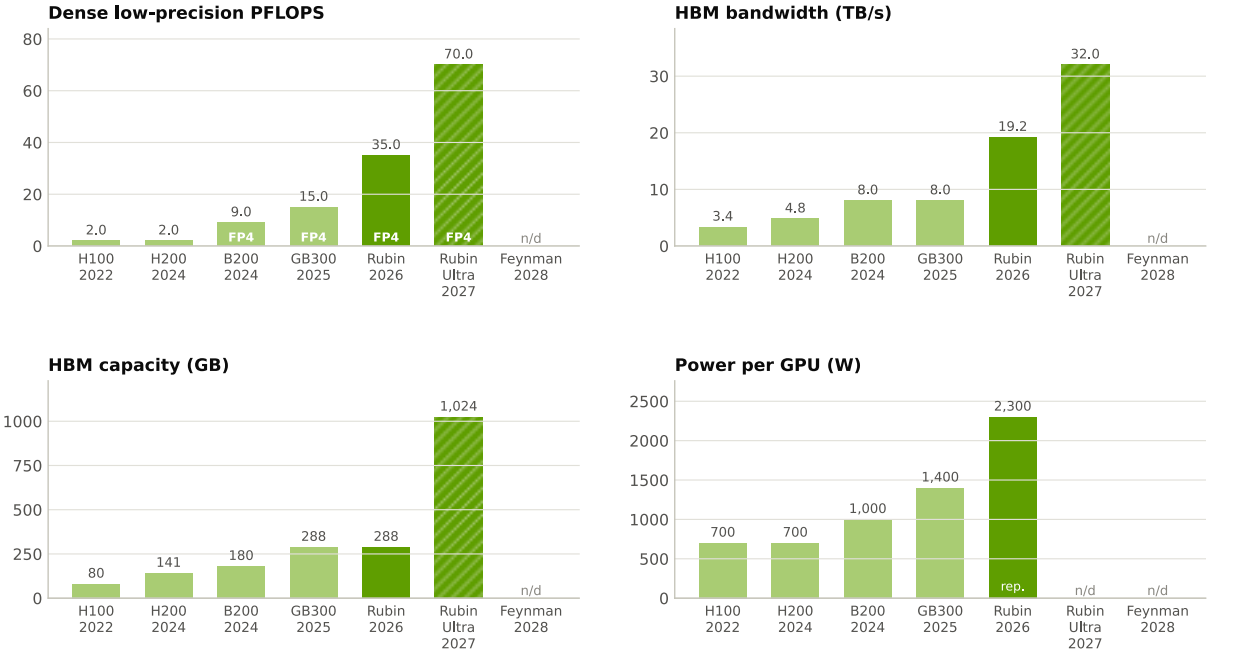


*Hatched = roadmap; n/d = not disclosed*

Source: data from NVIDIA specs and roadmap [S33002] [S35011] [S35013] [S32002] [S33003] [S35014] …; chart by repo · As of 2026-11-05

英伟达 GPU 规格从 H100（2022）到 Feynman（2028）的四个小型多重条形图。从 H100 到 Rubin，稠密低精度算力提升 18 倍（2.0 PFLOPS FP8 至 35 PFLOPS FP4），HBM 带宽提升 5.7 倍（3.35 至 19.2 TB/s），容量提升 3.6 倍（80 至 288 GB），功耗提升 3.3 倍（700 至约 2,300 W）。Rubin Ultra（2027）以阴影表示；Feynman 的数据尚未披露。

## Rubin and MI455X reach 17.5–20 PFLOPS FP8 in 2026: 3.5× Maia 200, 18× Ascend 950

Flagship dense FP8 PFLOPS per chip by year of volume availability (log scale); hollow = announced/roadmap, dashed = estimate LOG SCALE

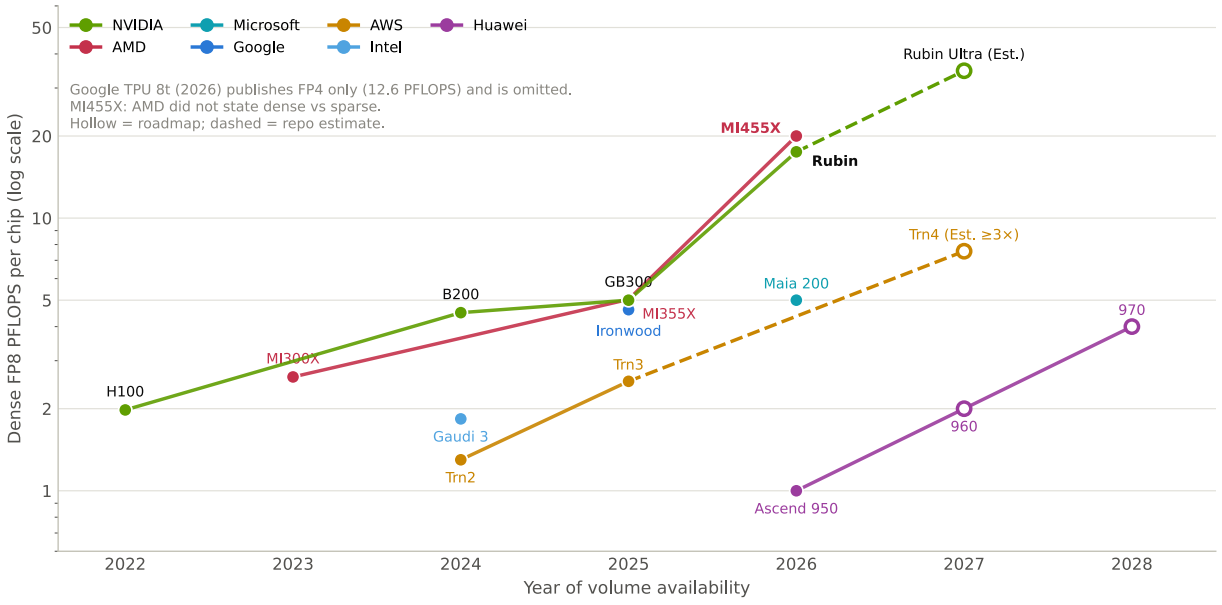


Source: data from vendor specs and roadmaps; repo Est. for Rubin Ultra, Trn4 [S33002] [S35011] [S35013] [S33003] [S35014] [S101] …; chart by repo · As of 2026-11-05

按年份划分的单芯片旗舰 FP8 算力对数刻度折线图：英伟达从 2.0 PFLOPS（H100，2022）升至 17.5（Rubin，2026），Rubin Ultra（2027）估计 ~35；AMD 从 2.6（MI300X，2023）升至 20（MI455X，2026，未说明口径）；谷歌 Ironwood 4.6（2025）；AWS Trainium2 1.3、Trainium3 2.5，Trainium4 估计 ~7.6；微软 Maia 200 5；英特尔 Gaudi 3 1.8；华为 Ascend 950 1、960 2，到 2028 年 970 达 4 PFLOPS。

### MI455X leads 2026 on bandwidth (23.3 vs Rubin's 19.2 TB/s); Rubin Ultra (1 TB HBM4E) targets the capacity lead in 2027

Memory per accelerator package by year: capacity (GB, left) and bandwidth (TB/s, right); hollow = roadmap or estimate

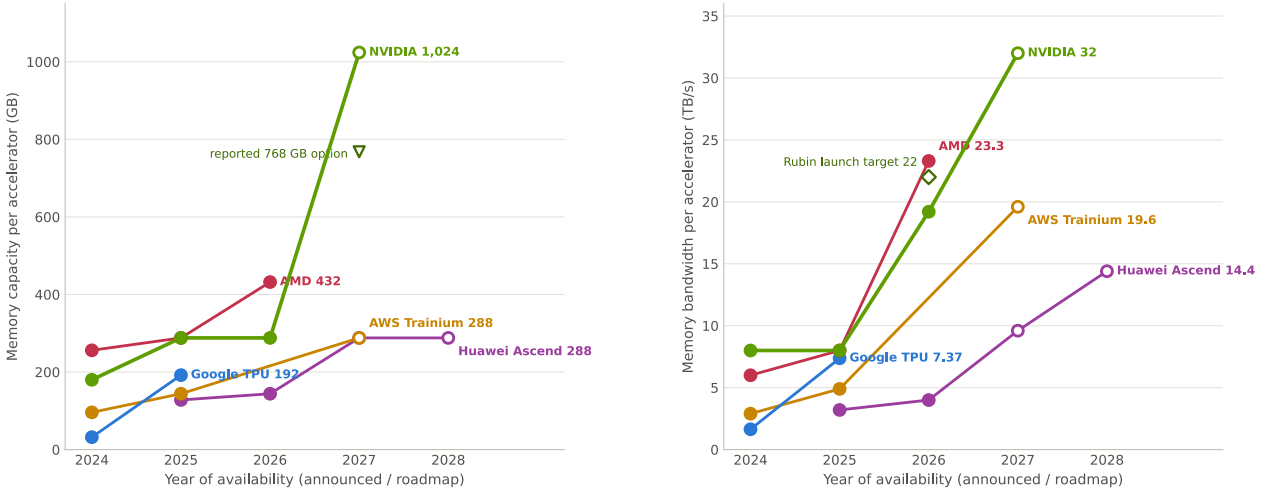


Source: data from vendor roadmaps; Trainium4 = repo Est. [S33003] [S101] [S123] [S102] [S103] [S104] …; chart by repo · As of 2026-11-05

每加速器内存的两张折线图，2024-2028。容量：英伟达 B200 180 GB，B300 288，Rubin 288，Rubin Ultra 宣布 2027 年达 1,024 GB（有报道称 768 GB）；AMD MI325X 256，MI355X 288，MI455X 432；谷歌 Trillium 32、Ironwood 192；AWS Trainium2 96，Trainium3 144，Trainium4 约 288（估计）；华为 910C 128，950DT 144，960 和 970 为 288。带宽：Rubin 19.2 TB/s（发布目标为 22），MI455X 23.3，Trainium4 约 19.6（估计），Ironwood 7.37，华为 950DT 4.0，到 2028 年升至 14.4，Rubin Ultra 约 32 TB/s。

**GB200 → Kyber: ~5× rack power (120 → ~600 kW) buys ~14× dense FP8 and ~10× HBM per rack**

Per rack or rack-equivalent: maximum power (kW), dense FP8 PFLOPS and HBM capacity (TB); hatched = roadmap or estimate

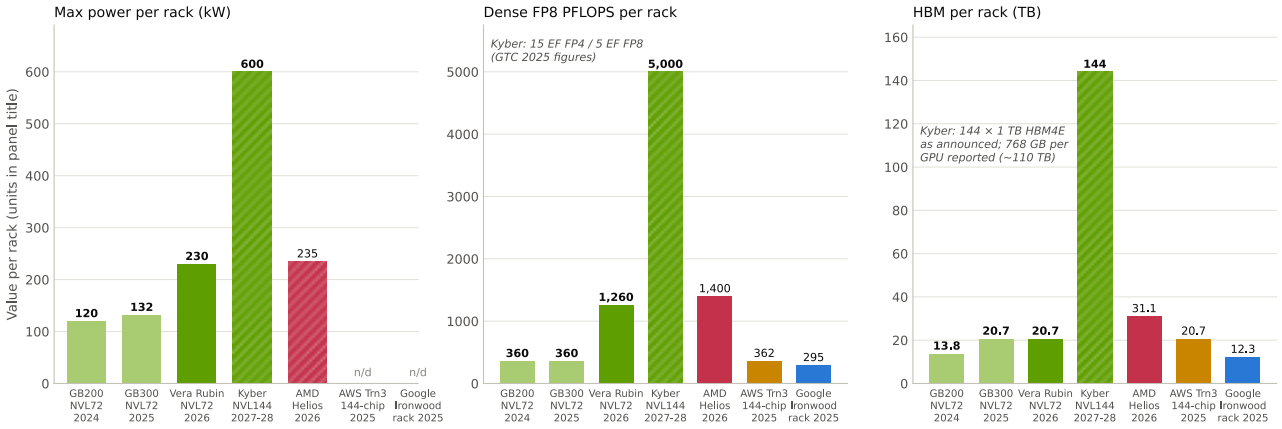


Kyber = GTC 2025/2026 targets; slip to 2028 reported

Source: data from vendor specs and estimates in system_specs.csv [S121] [S396] [S336] [S340] [S335] [S326] …; chart by repo · As of 2026-11-05

比较机架级系统的三个条形面板。功耗：GB200 NVL72 120 kW，GB300 132 kW，Vera Rubin NVL72 约 190-230 kW，AMD Helios 约 225-245 kW（估计），Kyber 约 600 kW（路线图）；AWS 和谷歌未公布机架功耗。稠密 FP8：GB200 与 GB300 360 PF，Vera Rubin 1,260 PF，Helios 1,400 PF，Kyber 5,000 PF，Trn3 144 芯片 362 PF，Ironwood 64 芯片机架 295 PF。HBM：13.8、20.7、20.7、31.1（Helios）、约 144 TB（Kyber，按发布口径）、20.7（Trn3）和 12.3 TB（Ironwood 机架）。

**提示**

**算例 —— Kyber 每千瓦能换来什么。** 一台 Vera Rubin NVL72 在 ~190–230 kW 下提供 ~1,260 PFLOPS 稠密 FP8 算力 🟡 S102,S303：每 kW ~5.5–6.6 PFLOPS。按发布口径，Kyber 的目标是在 ~600 kW 下提供 ~5,000 PFLOPS 稠密 FP8 S35018,S305：每 kW ~8.3 PFLOPS，提升 26–51%。按发布口径，机架 HBM 从 20.7 TB 增至 ~144 TB S102,S110，增长 ~7 倍，而功耗仅增长 ~3 倍。**结论：** 2027 年的这一步主要是内存容量的跃升。若有关每 GPU 削减至 768 GB 的报道属实 🟡 S111，机架 HBM 将降至 ~108 TB（本资料库测算：144 × 768/1,024），仍为当前机架的 ~5 倍。

**🔧 技术细节：为何内存与封装决定了路线图的节奏**

算力随晶体管数量和数值格式扩展；内存带宽则取决于 GPU 周围 HBM 堆栈的数量及每个堆栈的引脚速率。Rubin 使用 8 个 HBM4 堆栈；Rubin Ultra 计划采用 16 个 HBM4E 堆栈 S110，这需要更大的 CoWoS 中介层，每片晶圆可切出的封装也更少（见第 03 层路线图）。一位分析师将 2026 年 Rubin 的规格下调归因于 HBM4 引脚速率仅为 ~9.4 Gb/s 而非 ~10.7 Gb/s（🔴 原因未经证实）S90006。因此，此后的每一步都取决于内存厂商的良率：SK 海力士和三星已于 2026 年年中送样 HBM4E S3528，TrendForce 预计 HBM4E 将占 2027 年 HBM 市场的 ~40% S3531。

## 推理路线图如今有三款芯片

直到 2025 年，英伟达对每一种工作负载的回答都是下一代 GPU。2026 年的路线图则将推理拆分为不同阶段。预填充（prefill）即读取提示词，需要算力；解码（decode）即逐个生成 token（词元），需要内存带宽。搭载 HBM4 的 Rubin GPU 仍是通用引擎。Rubin CPX 于 2025 年 9 月发布，是一款基于 GDDR7 的预填充 GPU，具备 30 PFLOPS NVFP4 算力和 128 GB 内存 S33023；它从 GTC 2026 路线图上消失，据报道将于 1Q27 以 HBM4 版本回归 🟡 S115,S117。源自 Groq 的 LPU 占据了解码的位置：每颗 LP30 芯片拥有 ~500 MB 片上 SRAM，一台 256 芯片的 LPX 机架部署在 Vera Rubin 旁边 S114,S506。LP35（2027）新增 NVFP4，LP40 将于 2028 年与 Feynman 搭配 S108,S109。

**提示**

**算例 —— 为何解码转向了 SRAM。** 一台 LPX 机架搭载 256 × ~0.5 GB ≈ 128 GB 的 SRAM，聚合带宽 ~40 PB/s [S114]。一台 Vera Rubin NVL72 搭载 20.7 TB 的 HBM4，带宽 ~1,400 TB/s [S102,S90006]：容量约为前者的 ~160 倍，带宽却只有其 ~1/29。一个 FP8 精度的 70B 参数模型（~70 GB）可装入一台 LPX 机架的 SRAM，因此每个 token 都能以 SRAM 速度生成；而 1T 参数的模型装不下，仍需要 HBM。**结论：** 三芯片路线图押注的是：中等规模模型的延迟关键型解码市场足够大，足以支撑专用芯片——这与 Groq、Cerebras 和 d-Matrix 曾下的赌注相同，如今被纳入英伟达的机架之中。

## 逐层看：2026 至 2028 年有何变化

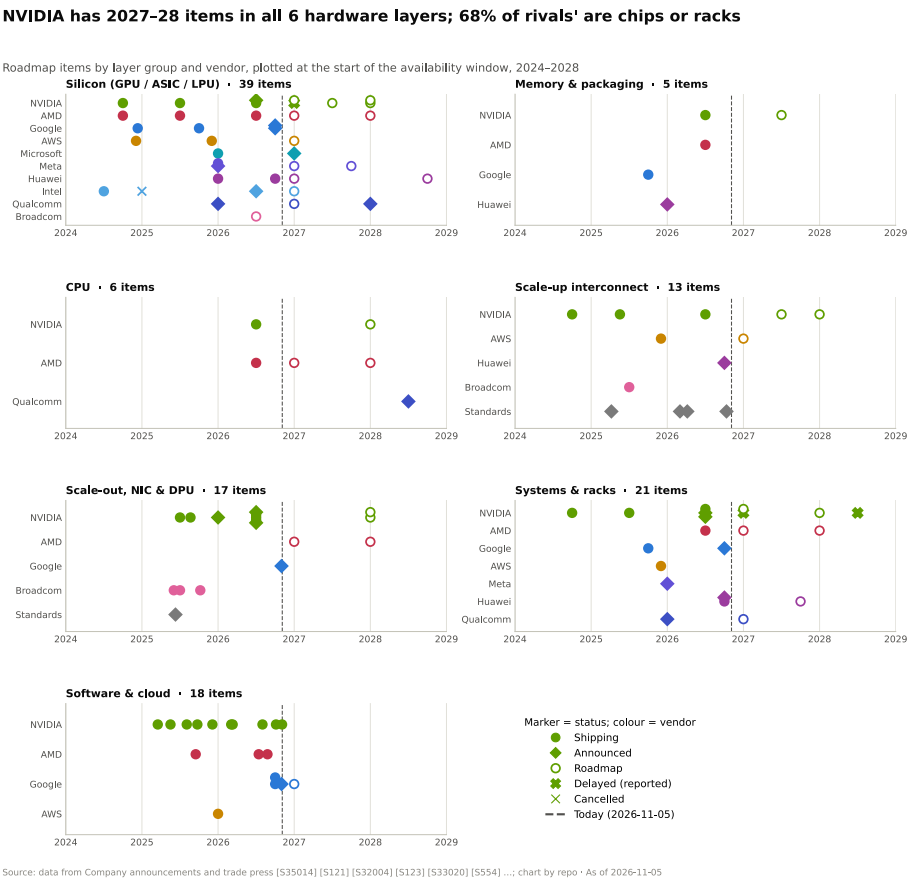


七个小型多重时间线（芯片、内存、CPU、纵向扩展、横向扩展/网卡、系统、软件）显示，英伟达有 15 个定于 2027 年或之后的项目，分布在全部 6 个硬件层；而 AMD、谷歌、AWS、微软、Meta、华为、英特尔、高通、博通和各标准组织共有 22 个此类项目，其中 68% 为加速器或机架。软件与云服务项目大多为近期项目（定于 2025–2026 年）。

| 层 | 2026（当前） | 2027 | 2028 | 可能改变格局的因素 | 层级路线图 |
|---|---|---|---|---|---|
| 02 GPU 芯片 | Rubin；Groq 3 LPU | Rubin Ultra；LP35；CPX? | Feynman；LP40 | 双裸片 Rubin Ultra；MI500 纸面领先 | 02 |
| 03 内存 | HBM4，19.2 TB/s | HBM4E，1 TB 计划 | 定制 HBM | HBM4E 引脚速率、三星的份额、内存价格 | 03 |
| 04 CPU | Vera、独立销售的 Vera | — | Rosa | 智能体带来的 CPU 需求；Fusion CPU 出货 | 04 |
| 05 纵向扩展 | NVLink 6，72 GPU | NVLink 7，144 个封装 | 采用 CPO 的 NVL1152 | Kyber 时间；UALink 芯片 | 05 |
| 06 横向扩展 | CX-9 1.6T；CPO 交换机 | — | CX-10；下一代 Spectrum | Ultra Ethernet 网卡规模化 | 06 |

| 层 | 2026（当前） | 2027 | 2028 | 可能改变格局的因素 | 层级路线图 |
|---|---|---|---|---|---|
| 07 DPU / 存储 | BlueField-4；STX | — | BlueField-5 | KV 缓存存储成为标准配置 | 07 |
| 08 系统 | VR NVL72；LPX；800 VDC 机架 | Kyber（~600 kW）；行级供电 | Kyber NVL1152 | 中板良率；电网电力 | 08 |
| 09–11 软件 | CUDA 13.x；Dynamo 1.x | HF 交割 | — | 开源推理服务在竞争对手机架上达到同等水平 | 09、11 |
| 12–13 云与资本 | Lepton；融资平台 | 合同分批交付 | — | 资本开支暂停；新兴云信用 | 12、13 |

本章在日期和标签上与各层页面保持一致。在侧重点上有一处不同：系统路线图将 Kyber 的时间视为一个存在争议的项目，而本章将其视为 2027 年最重要的路线图事实，因为 NVLink 7、HBM4E 和 800 V DC 三条产品线都汇聚于这一机架。

## 2026 年的变化：修订、推迟与更名

| 项目 | 首次发布时 | 截至 2026-11-05 | 标签 | 来源 |
|---|---|---|---|---|
| 每 GPU Rubin HBM4 带宽 | 22 TB/s | 19.2 TB/s | 🟢 | S100,S90006 |
| 每 GPU NVLink 6 | 3.6 TB/s | 3.0 TB/s | 🟢 | S33004,S103 |
| Vera Rubin NVL72 机架 HBM 带宽 | 1,580 TB/s | 1,400 TB/s | 🟢 | S102,S90006 |
| Rubin CPX | 2026 年末，GDDR7，30 PFLOPS NVFP4 | 从 GTC 2026 路线图上撤下；据报道改用 HBM4 重新设计，定于 1Q27 | 🟡 | S33023,S115,S117 |
| Kyber NVL144 机架 | 2027 年下半年 | 据报道推迟超过 12 个月；英伟达称“路线图保持不变” | 🟡 | S305,S507,S508 |
| Rubin Ultra 封装 | 4 颗光罩尺寸裸片，1 TB HBM4E | 有报道称为双裸片版本、768 GB | 🟡 | S35018,S509,S111 |
| 机架命名 | “Vera Rubin NVL144”、“Rubin Ultra NVL576” | Vera Rubin NVL72、Kyber NVL144（按封装而非裸片计数） | 🟢 | S90009,S108 |

**Rubin 的修订影响最大。** 英伟达在 2026 年 9–10 月修改了其产品页面，并表示新数据反映的是系统在高质量批量生产中可持续达到的水平 [S104]。容量（288 GB）和算力未变 [S90006]。其效果是扩大了 AMD MI455X 在带宽上的纸面领先优势（23.3 对 19.2 TB/s，此前为 23.3 对 22），并使其在容量上继续领先（432 对 288 GB）[S144,S90093]。AMD 也曾修订规格：MI325X 在 Computex 2024 上发布时宣称最高 288 GB HBM3E，上市时为 256 GB [S17007,S142]；而 MI455X 标称的 HBM4 带宽则朝相反方向变化，从 2025 年 6 月的 19.6 TB/s 升至 23.3 TB/s [S144,S90093]。

**英伟达的解释对未来所有规格都有影响。** 英伟达称发布时的数据是目标值，新数据反映的是量产水平 [S104]，这实际上等于告诉买方：应将其路线图上所有量产前的数字——包括 Rubin Ultra 的 1 TB 以及 Feynman 即将公布的规格——视为上限。为 2027–28 年部署做规划的买方，在量产产品页面公布之前，应对已宣布的带宽打折扣。

**更名并非表面文章。** “NVL144”计的是 GPU 裸片数；“NVL72”计的是封装数。同一台 Rubin 机架同时拥有这两个名字 [S90009]。跨厂商比较机架的读者应始终按封装计数（NVL 命名）。

### Rubin's 2026 revision cut HBM bandwidth 13% and NVLink 17%; MI455X now leads on paper

Per-GPU specs: Rubin at CES 2026 launch (hatched, superseded) vs revised pages (Sep–Oct 2026) vs AMD MI455X

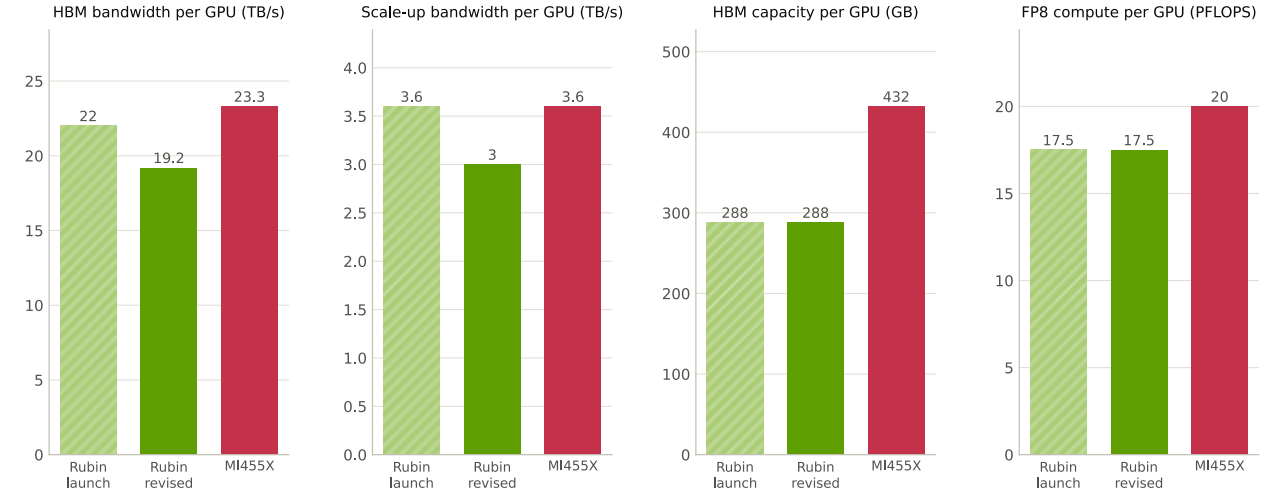


Source: data from NVIDIA product pages and statements; AMD; press coverage of the revision [S100] [S33004] [S33005] [S103] [S104] [S90006] ...; chart by repo · As of 2026-11-05

四面板条形图。每 GPU HBM 带宽：Rubin 发布时 22 TB/s，修订后 19.2，MI455X 23.3。纵向扩展带宽：Rubin 发布时 3.6 TB/s，修订后 3.0，MI455X 3.6。HBM 容量：Rubin 288 GB 不变，MI455X 432 GB。稠密 FP8：Rubin 17.5 PFLOPS 不变，MI455X 20 PFLOPS（AMD 未说明是稠密还是稀疏）。媒体报道援引英伟达的说法，将新数据与量产挂钩；原因尚无定论。

### 4 NVIDIA roadmap items slipped, led by Kyber's reported 12-month delay

Originally announced (hollow) vs current official or reported (filled) start of availability window

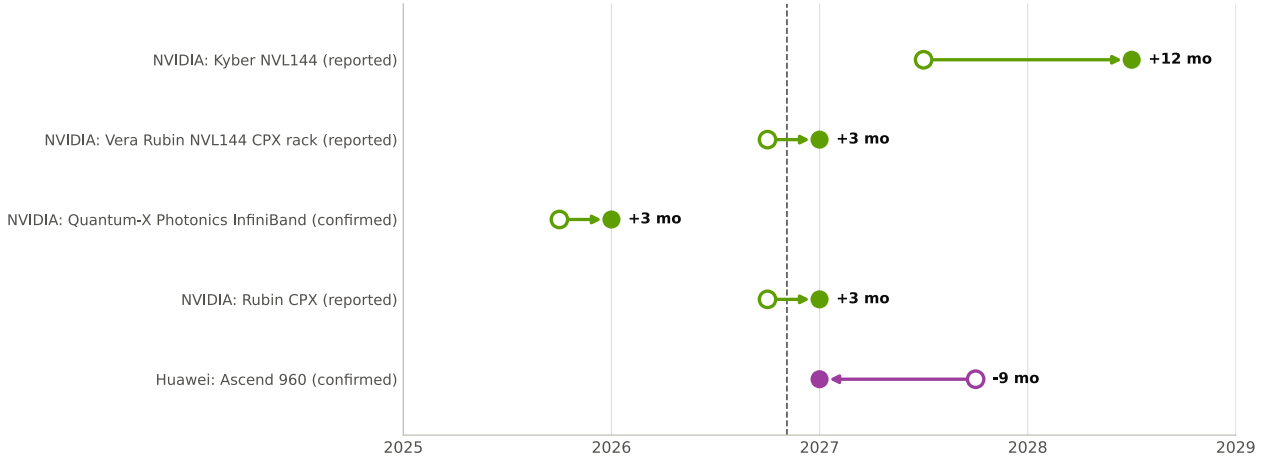


Source: data from Company statements, SemiAnalysis, TrendForce, trade press [S163] [S567] [S568] [S33023] [S115] [S116] ...; chart by repo · As of 2026-11-05

进度变化哑铃图（华为的变化为提前）：Ascend 960 -9 个月，Rubin CPX +3 个月，Quantum-X Photonics InfiniBand +3 个月，Vera Rubin NVL144 CPX 机架 +3 个月，Kyber NVL144 +12 个月。Kyber NVL144 的推迟由 SemiAnalysis 报道，英伟达对此提出异议；Rubin CPX 的回归为分析师说法。

**提示**

**算例 —— Rubin 的下调让买方损失了什么。** 解码，即推理中逐个生成 token 的阶段，受限于内存带宽（见 P2）。一台机架的 HBM 带宽从 1,580 降至 1,400 TB/s，−11% [S102,S90006]。对于固定批大小下受带宽约束的模型，峰值解码每秒 token 数大致按比例下降（🔴 本资料库近似）。以一台 ~$7.8M 的机架计（估计，摩根士丹利）[S331]，在每 token 价格不变的情况下，峰值解码吞吐量下降 11% 相当于 ~$0.9M 的机架价值。**结论：** 此次修订没有改变任何算力数据，但缩小了支撑英伟达在内存受限型推理上溢价的差距。

如今，一个路线图项目的生命周期已不止“已发布”和“出货中”两种状态。Rubin CPX 在十二个月内就经历了其中四种。

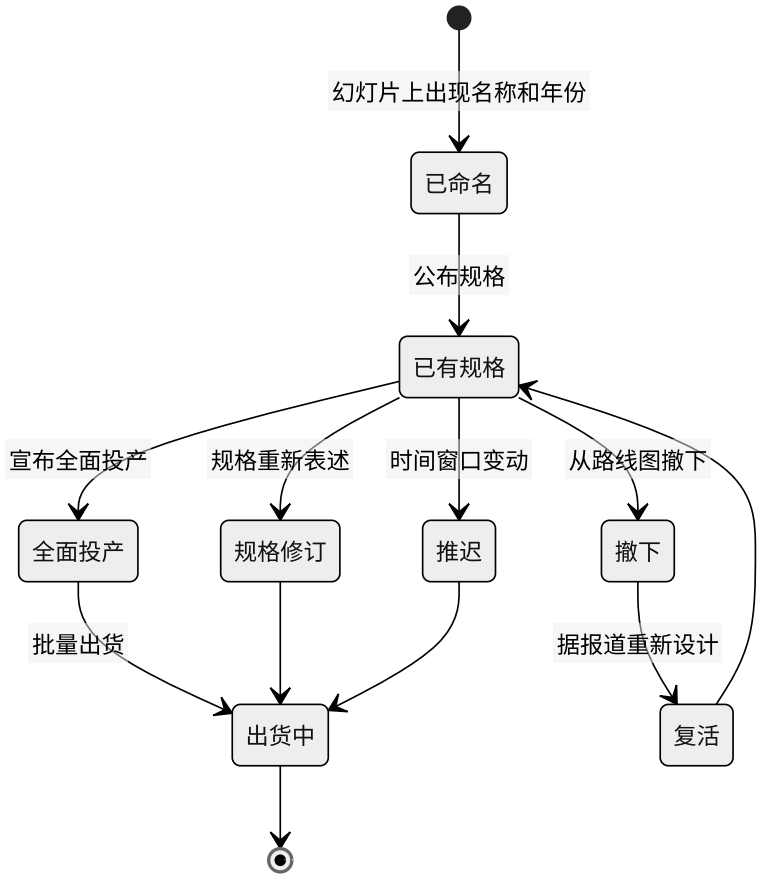


## 路线图有承诺作为支撑

只有在背后的供应已被锁定时，路线图才可信。截至 Q2 FY2027 末，英伟达的供应与产能承诺达 $279B，较上一季度的 $119B 大幅上升，主要是为 Rubin 一代锁定的内存与制造产能 [S407,S404]。在需求端，黄仁勋在 GTC 2026 上将截至 2027 年的 Blackwell 与 Vera Rubin 需求规模定为 $1 trillion；各媒体对他指的是订单还是收入机会说法不一 🟡 [S90001,S90002]。最大的买家已宣布了数吉瓦级的计划，但会将其分散到多家供应商。

### Supply commitments hit $279B: 2.9× quarterly revenue vs ~1.4× before the 2022 bust

Left: purchase/supply commitments vs inventory, US$ B at quarter end. Right: commitments ÷ that quarter's revenue

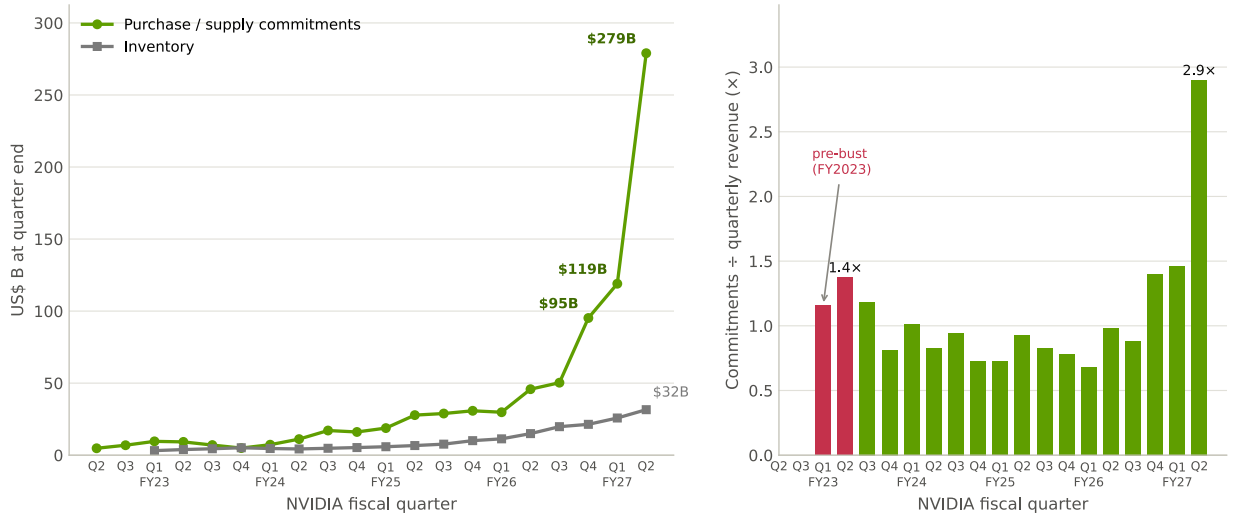


*Definition widened from Q3 FY2026*

Source: data from NVIDIA 10-Q/10-K [S420] [S421] [S432] [S433] [S434] [S435] …; chart by repo · As of 2026-11-05

双面板图。左：英伟达采购义务从 Q2FY22 的 $4.8B 升至 Q2FY27 的 $279B，同期存货达 $31.6B。右：在 FY2023 存货减记之前，承诺约为季度营收的 1.4 倍，如今为 2.9 倍，主要是为 Rubin 锁定的内存与产能。

### NVIDIA holds 10 of OpenAI's 26 announced GW and ~39% of four big buyers' total

Announced compute programmes by buyer and chip supplier, gigawatts (2025–2026 announcements; deployments 2026–2030)

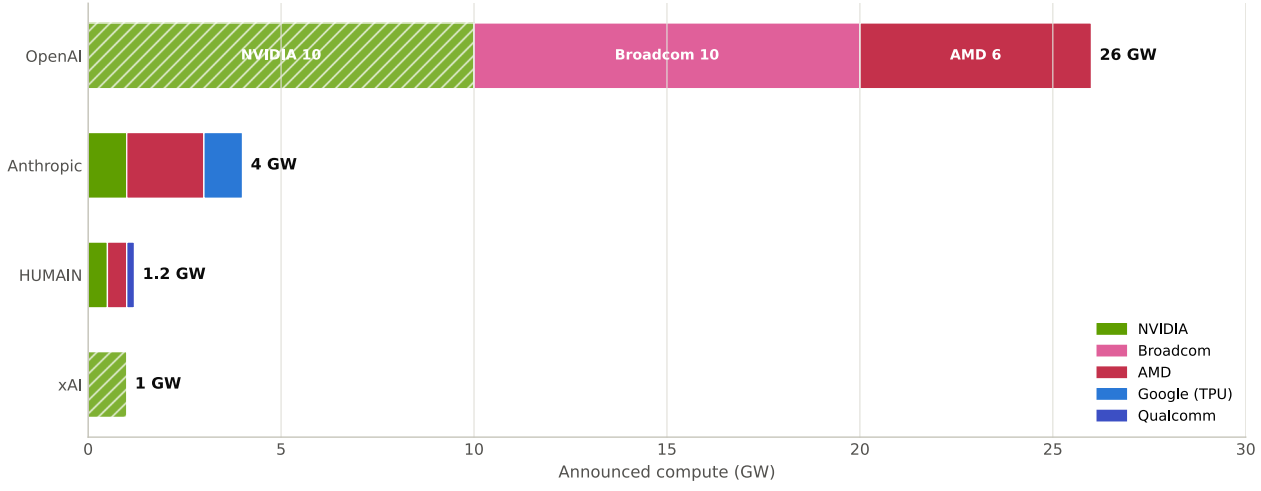


*Hatched = restructured LOI or contested*

Source: data from company announcements and press [S467] [S90016] [S174] [S13506] [S90020] [S90026] …; chart by repo · As of 2026-11-05

已宣布算力计划（以吉瓦计）的堆叠水平条形图。OpenAI 26 GW：英伟达 10（2025 年 9 月意向书，此后已重组）、博通定制加速器 10、AMD 6。Anthropic 4 GW：AMD Helios 最多 2（附 AMD 最多 $5B 的投资）、英伟达最多 1、谷歌 TPU 2026 年超过 1 GW（2027 年起进一步的数吉瓦级 TPU 扩容未量化）。HUMAIN：英伟达最多 0.5 GW、AMD 0.5 GW、高通 0.2 GW。xAI：约 1 GW 采用英伟达（公司说法，存在争议）。英伟达在这些计划中的份额约为 39%。

**提示**

**算例 —— $279B 的承诺对路线图意味着什么。** $279B 约为英伟达 Q2 FY2027 营收 $96.2B 的 ~2.9 倍[S407,S405]，而在 FY2023 减记之前为 ~1.4 倍（见上图）。如果 Rubin Ultra 推迟一年，为其锁定的内存与产能就必须由 Rubin 的需求消化，或作为存货持有。FY2023 的先例是 $2.17B 的存货准备以及一笔针对超出需求之承诺的 $348M 费用[S418,S421]。**结论：** 路线图如今已是一项资产负债表承诺。推迟对英伟达代价高昂，这也是它迅速否认推迟报道的原因之一[S508]。

## 作为竞争策略的路线图

产品路线图通常是一份内部计划。而英伟达的路线图是一件公开工具，承担三项任务：将买方的决策冻结在有利于英伟达的方向，设定竞争对手必须跟上的节奏，并在不拖累当前销售的情况下完成这两点。每项任务都有其机制和风险。

### 冻结客户决策

**机制在于规划提前期。** 一座 AI 工厂需要在芯片到货之前很久就确定电力、冷却、楼板承重和网络设计。美国发电项目要在并网排队中等待数年 [S8009]，而一个吉瓦级站点要围绕某一机架的功率密度来设计：GB300 NVL72 为 ~132 kW，Kyber 为 ~600 kW [S337,S305]。一个在 2026 年选定 2028 年设计方案的买方，只能围绕已公布 2028 年机架的供应商进行设计。以预先公布期衡量，英伟达提前 26–40 个月公布其 GPU 的时间表；谷歌只提前 ~7 个月公布 TPU，AMD 则提前 ~13–25 个月（🔴 本资料库分析）[S17006]。

**NVIDIA dates Rubin–Feynman GPUs 26–40 months ahead; Google dates TPUs ~7 months ahead**

Months from the first public, dated roadmap mention to (planned) volume availability, flagship accelerators announced 2024–2026

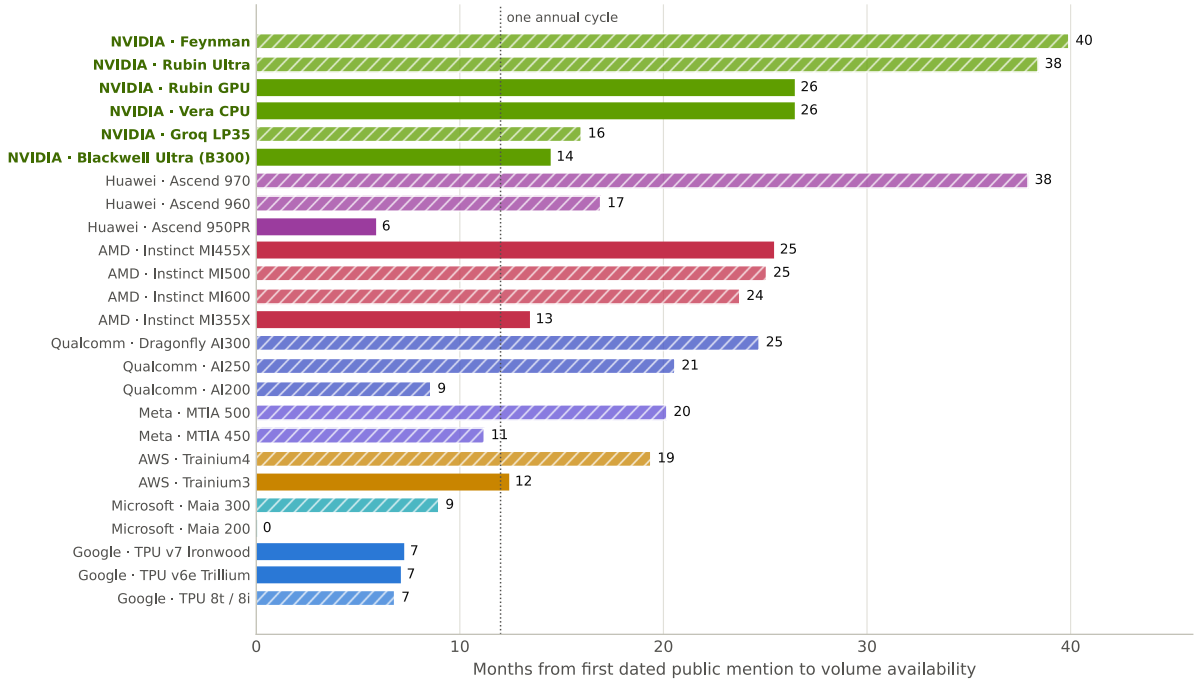


*Hatched = not yet shipping in volume (plan, or shipments unconfirmed); year-only plans placed at mid-year*

Source: data from vendor keynotes, press releases and trade press [S35018] [S109] [S17004] [S507] [S17003] [S500] …; chart by repo · As of 2026-11-05

> 各厂商提前多久公开其加速器时间表的水平条形图。英伟达在 Computex 2024 上公布了 Rubin 和 Rubin Ultra，在 GTC 2025 上公布了 Feynman，比计划批量上市时间提前 26 至 40 个月；华为提前约 38 个月公布 Ascend 970；AMD 按年度节奏提前 13–25 个月公布 Instinct 产品；AWS、Meta、微软和高通介于约 0 至 25 个月之间；谷歌每款 TPU 仅在全面上市前约 7 个月才发布。未来上市日期为计划值；仅有年份的计划按年中计。

**冻结一直延伸到建筑本身。** 英伟达的 800 V DC 电源架构是面向设施而非芯片的路线图项目：在 GTC DC 2025 上，约 20 家电源与电气合作伙伴展示了 800 V DC 部件，包括 CoreWeave、Lambda、Nebius、OCI 和 Together AI 在内的新兴云服务商表示正在为此进行设计 [S90061]。一款兼容 MGX 的 800 V DC 电源机架定于 2026 年下半年推出，行级电源中心定于 2027 年推出 [S90063]。一个按 800 V DC 和 ~600 kW 机架布线的数据机房，是围绕英伟达机架规划建造的长寿命资产——即便 Dell'Oro 称该设计为参考架构而非标准 [S90062]。

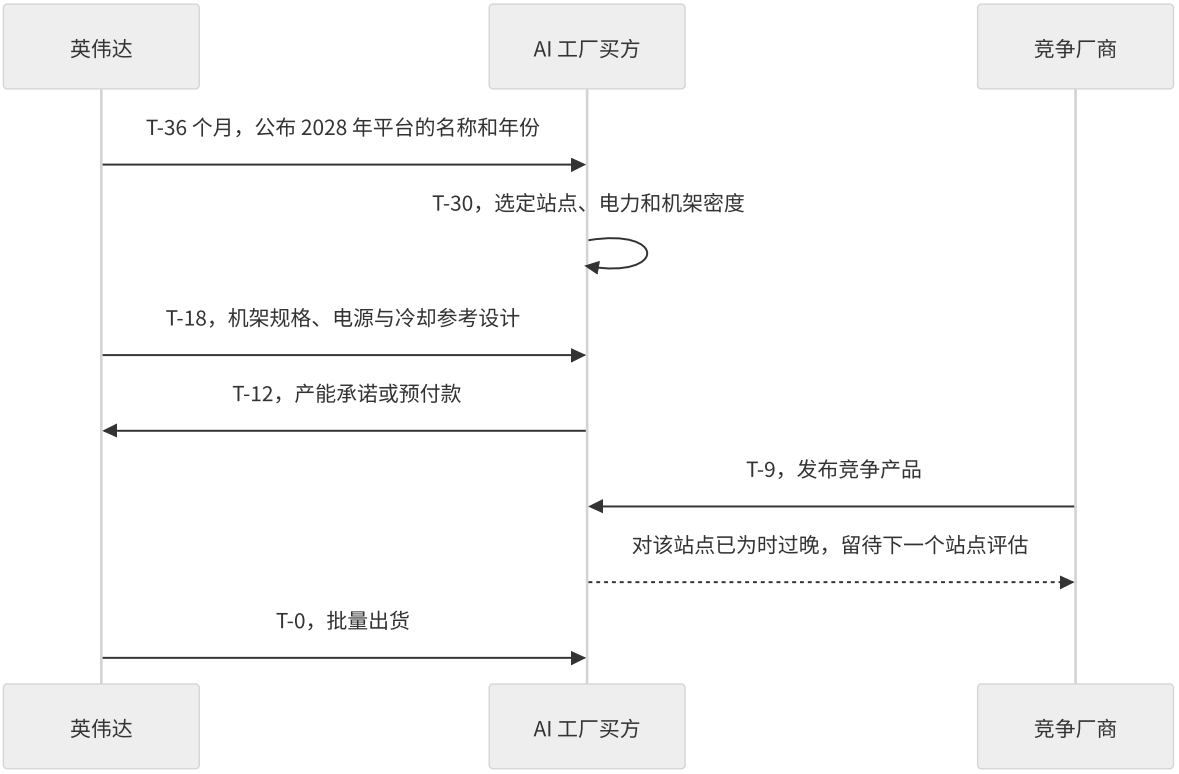


**提示**

**算例 —— 用日期来看规划窗口。** 一个在 2028 年年中通电的 1 GW 站点，需要在 ~2026 年之前确定电气设计（🔴 基于多年电力交付周期的假设 S8009）。届时，英伟达已将 Feynman 定于 2028 年并公布了 2028 年的机架类别（Kyber NVL1152）S109,S108，AMD 则为 2028 年命名了 Helios 600 但未公布规格 S538。谷歌 2028 年的 TPU 尚未发布：其 8t/8i 产品于 2026 年 4 月发布，定于 2026 年晚些时候全面上市 S550。**结论：** 对于 2028 年通电的站点，只有英伟达提供了有明确时间表的机架架构。AMD 只给出了一个名称，云厂商的 ASIC 则没有任何公开信息，因此规划的默认选项从结构上就归于英伟达。

## 设定竞争对手必须跟上的节奏

英伟达在 Computex 2024 上将数据中心产品转向“一年一代的节奏” S17003；AMD 在同一周宣布了 Instinct 的年度节奏 S17007,S17008。此后，英伟达和 AMD 已连续三年在同一季度推出旗舰产品。跟上这一节奏代价不菲：仅 Blackwell 的开发成本就达 ~$10B S35028，英伟达 FY2026 的研发支出为 $18.5B S401。

## NVIDIA's GPU cadence sped up from ~29 months per generation to ~11 (annual)

Months between first volume availability of successive NVIDIA data-center GPU architectures, Volta → Feynman

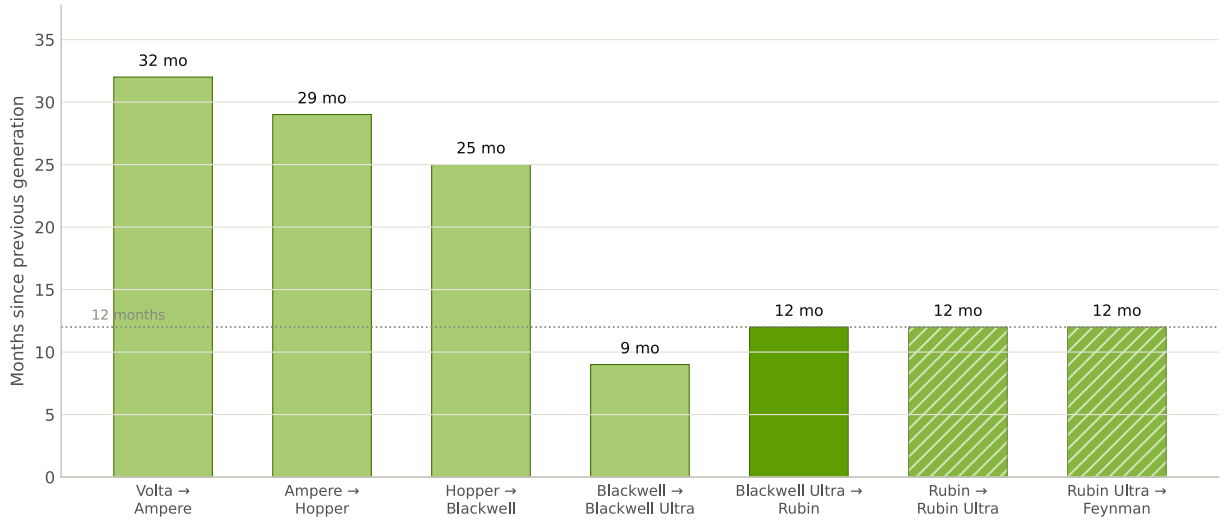


*Hatched = planned (roadmap)*

Source: data from NVIDIA keynotes and launch coverage [S126] [S312] [S127] [S315] [S35012] [S532] ...; chart by repo · As of 2026-11-05

英伟达 GPU 代际间隔月数条形图：Volta→Ampere、Ampere→Hopper 和 Hopper→Blackwell 平均约 29 个月；Blackwell→Blackwell Ultra 和 Blackwell Ultra→Rubin 平均约 11 个月；计划中的 Rubin Ultra（2H 2027）和 Feynman（2028）保持 ~12 个月的节奏，不过据报道 Kyber 机架将推迟至 2028 年。

## NVIDIA and AMD launched flagships in the same quarter 3 years running

Start of availability window for each vendor's flagship AI accelerator; both publish annual roadmaps to 2028

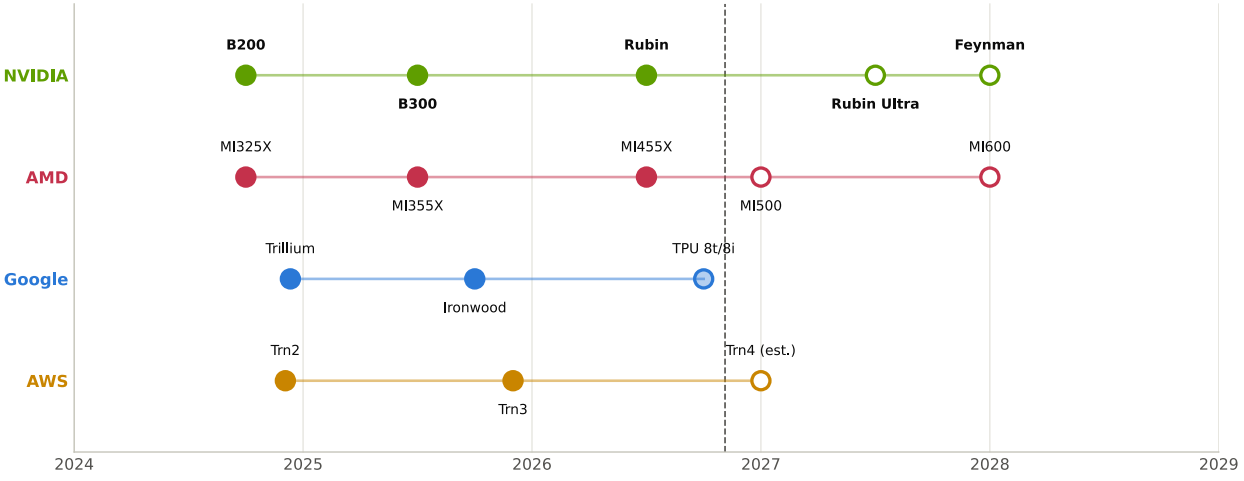


*Hollow = roadmap · pale = not yet GA*

Source: data from Company announcements [S35014] [S121] [S32004] [S123] [S33020] [S554] ...; chart by repo · As of 2026-11-05

旗舰加速器时间线：英伟达 B200（2024 年第四季度）、B300（2025 年第三季度）、Rubin（2026 年第三季度）、Rubin Ultra（2H 2027）、Feynman（2028）；AMD MI325X、MI355X 和 MI455X 均在相同季度推出（3 年中有 3 年），并计划推出 MI500（2027）和 MI600（2028）；谷歌 Trillium、Ironwood 和 TPU 8t/8i 均在当年 12 月或第四季度推出；AWS Trn2 和 Trn3 均在 12 月推出，Trn4 估计在 2027 年。

**提示**

**算例 —— 跟上节奏的代价。** 如果英伟达每一代的开发成本为 ~$10B [S35028]，且每 ~12 个月推出一代，那么仅平台开发每年就需 ~$10B，这包含在英伟达 FY2026 的 $18.5B 研发支出之内 [S401]。AMD 2024 年所有产品的研发支出为 ~$6.5B [S450]。超大规模云厂商与设计合作伙伴共同打造的 ASIC 每代成本为 ~$0.5–1.5B（估计）[S2501]，因为它只覆盖服务于单一客户工作负载的一款芯片，而非整个平台。**结论：** 在全平台规模上，只有英伟达负担得起年度节奏。竞争对手要么缩小范围（定制 ASIC），要么共享英伟达自己的平台（NVLink Fusion）来跟上节奏。

## 奥斯本效应风险，以及它为何尚未显现

奥斯本效应得名于 20 世纪 80 年代的一家电脑制造商，据称该公司过早宣布更好的新型号，导致现有型号的销售陷入停滞。英伟达每年都在冒这个险。在 GTC 2025 上，黄仁勋自称“首席收入破坏者”，同时告诉客户 Hopper 只在少数场景下还算够用 S17001。一份报道称，2024 年 Hopper 对四大云厂商的销量为 1.3M 块 GPU，而 2025 年 Blackwell 为 3.6M 块 🟡 S17002。

数据并未显示出冻结。从 Q1 FY2024 到 Q2 FY2027，历经六次路线图发布，数据中心收入连续 14 个季度环比增长 S405,S17006。最弱的季度（+5%，Q2 FY2026）恰逢 H20 出口禁令，而非买方观望 S90081。

**Data Center revenue grew 14 quarters in a row through six roadmap reveals: no Osborne dip so far**

NVIDIA Data Center revenue by fiscal quarter, US$ B, with q/q growth; lines mark roadmap announcements and the Rubin ramp

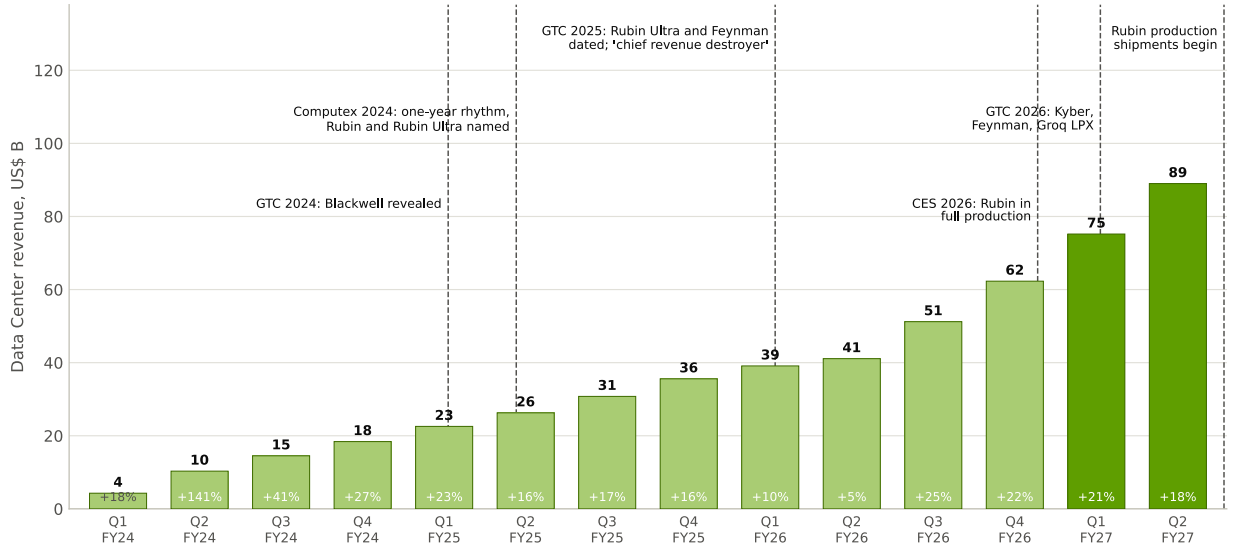


Source: data from NVIDIA quarterly results; roadmap dates from keynotes [S436] [S422] [S437] [S423] [S438] [S424] ...; chart by repo · As of 2026-11-05

英伟达季度数据中心收入条形图，从 Q1FY24（$4.3B）到 Q2FY27（$89.0B）。在英伟达发布 Blackwell（GTC 2024）、转向一年一代节奏并公布 Rubin（Computex 2024）、公布 Rubin Ultra 和 Feynman 时间表（GTC 2025）、宣布 Rubin 全面投产（CES 2026）、展示 Kyber 和 Feynman 细节（GTC 2026）以及开始 Rubin 出货（2026 年 8 月）期间，收入连续 14 个季度环比增长。最弱的季度 Q2FY26（+5%）恰逢 H20 出口禁令，而非买方观望；客户并未为了等待已宣布的新一代而停止购买当前一代。

**提示**

**算例 —— 为何手握电力的买方不会等待。** 一家拥有 10 MW IT 电力的新兴云服务商，现在就可以用 ~132 kW 的 GB300 NVL72 机架填满它 S337，~75 台机架（~5,400 块 GPU）。若采用 ~190–230 kW 的 Vera Rubin 机架 🟡 S303，可容纳 ~43–52 台，但在中等速度下每兆瓦的 DeepSeek-R1 token 产出约为 GB300 的 2 倍 🟡 S626。等待一个季度意味着放弃整个站点一年产出的 ~25%；而在 Rubin 量产后切换，则可在其余生命周期内使每兆瓦产出提高 ~100%。**结论：** 理性的买方会在新一代可供货时立即切换，但不会在此之前停止购买。在供应持续紧张的情况下，换代表现为产品结构的变化，而非收入缺口；CFO 称 FY2028 的前景“受供应约束” S90012。

> **注意**
>
> **奥斯本效应何时会显现。** 三种情况会让路线图变成负担：供应追上需求（据估计，到 2028 年 CoWoS 产能将达 ~260k 片晶圆/月 S3002）；出现明显的推迟，使买方等待某个承诺中的升级（Kyber 🟡 S507）；或者新一代每兆瓦的提升幅度大到足以在旧一代折旧期结束前使其沦为搁浅资产。超大规模云厂商按五到六年对服务器计提折旧 S383,S385，因此在每代 ~2 倍提升的情况下，一台机架在账面上仍有价值时，就可能已落后于前沿两到三代。FY2023 的危机——季度营收在两个季度内下降 28%——表明产能过剩的冲击可以来得多快 S432,S434。

## 过往记录：承诺与兑现

公开路线图的价值取决于其兑现记录。下表比较了各厂商在 2026 年末前到期项目上的承诺与实际出货情况。它只涵盖日期和标志性规格；实际交付的性能是另一个问题（见竞争格局）。

| 厂商 | 项目 | 承诺 | 兑现情况（截至 2026-11-05） | 评估（标签 = 对兑现事实的置信度） | 来源 |
|---|---|---|---|---|---|
| 英伟达 | Blackwell Ultra（GB300） | 2025 | 自 2025 年下半年起出货 | 🟢 按时 | S17003,S32004 |
| 英伟达 | Rubin / Vera Rubin NVL72 | 2026（2024 年公布） | 2026 年 8 月量产出货；带宽规格下调 | 🟢 按时，规格已修订 | S17003,S500,S90006 |
| 英伟达 | Quantum-X Photonics | 2025 年晚些时候 | 2026 年初部署 | 🟡 推迟 ~3 个月 | S514,S515 |
| 英伟达 | Spectrum-X Photonics | 2026，后改为 2026 年下半年 | 据报道已全面投产 | 🟡 按时 | S514,S6020 |
| 英伟达 | Rubin CPX | 2026 年末 | 从路线图撤下；据报道将于 1Q27 回归 | 🟡 未兑现 | S33023,S115,S117 |
| AMD | MI325X | 2024 年第四季度，最高 288 GB | 2024 年第四季度，256 GB | 🟢 按时，容量下调 | S17007,S142 |
| AMD | MI355X | 2025 | 自 2025 年第三季度起出货 | 🟢 按时 | S17007,S143 |
| AMD | MI455X / Helios | 2026 | 首批出货约在 2026 年第三季度末 | 🟡 按时 | S17007,S90020 |
| 谷歌 | TPU Ironwood | 2025 年末 | 2025-11-06 宣布全面上市 | 🟢 按时 | S151,S547 |
| 华为 | Ascend 960 | 2027 年第四季度 | 提前至 2027 年第一季度 | 🟢 提前（待兑现） | S163,S567 |
| 高通 | AI200 | 2026 | 未找到出货确认 | 🔴 未确认 | S173 |

规律是一致的：日期大体守住，而标志性规格和次要产品则会变动。英伟达的失误集中在其最新的产品类别（CPX、共封装光学、Kyber 中板），而非核心 GPU 节奏。

## 竞争对手如何应对

| 竞争对手 | 对英伟达路线图的应对 | 证据 | 效果 |
|---|---|---|---|
| AMD | 跟上节奏并在同一季度推出；用认股权证锁定锚定客户 | 自 Computex 2024 起年度更新；与 OpenAI 和 Meta 的 6 GW 认股权证交易 S17007,S13506,S24004 | 🟨 纸面规格持平；🟥 2027 年之后有明确时间表的机架架构落后 |
| 谷歌 | 公开时间跨度短；向谷歌以外销售 TPU | TPU 8t/8i 在全面上市前 ~6 个月发布；Anthropic 最多 1M 颗 TPU；2027 年 TPU 上架 OCI S550,S90026,S552 | 🟦 对已承诺的买方以成本取胜，而非以规划可见性取胜 |
| AWS | 借用英伟达的互连 | Trainium4 将支持 NVLink Fusion S518,S156 | 🟦 搭乘英伟达的机架路线图，而非与之竞争 |
| 微软 | 自研推理芯片，逐年迭代 | Maia 200（2026）、Maia 300，以及 2027 年起的数吉瓦级部署 S158,S90046,S90045 | 🟦 自有需求；对商用芯片买方影响甚微 |
| Meta | 定制 ASIC 中节奏最快 | 至 2027 年推出 MTIA 400、450、500，约每 ~6 个月一步 S561 | 🟦 工作负载范围窄（排序、推理） |

| 竞争对手 | 对英伟达路线图的应对 | 证据 | 效果 |
|---|---|---|---|
| 华为 | 公布的时间跨度长，并提前推出 | Ascend 960 提前三个季度；970 定于 2028 年第四季度 S567,S163 | 🟦 在出口管制下设定中国市场的规划默认选项 |
| 高通 | 年度节奏与开放互连架构（仅限公开信息） | AI200（2026）、AI250（2027）、支持 UALink 和 ESUN 的 AI300（2028） S173,S90060 | 🔴 可信度取决于首批出货，目前尚未确认 |
| 标准组织 | NVLink 和 InfiniBand 的开放替代方案 | UALink 2.0（2026 年 4 月）、ESUN 1.0、UEC 1.1；UALink 产品 2027 年推出 S574,S576,S575,S90051 | 🟥 落后 NVLink 两年，但正处于趋同路径 |

**AMD 的回应是跟上节奏，并用资本换时间。** 其年度节奏让旗舰产品与英伟达在同一季度推出，其认股权证交易使 OpenAI 和 Meta 在部署 6 GW 的条件下各自最多可获得 160M 股 AMD 股票 S13506,S24004。仍存在的路线图差距在于深度：AMD 已命名 Helios 500 和 Helios 600，但其公布的 2027–28 年各层级规格远少于英伟达 S538。

**谷歌的回应是不参与这场游戏。** 它在每款 TPU 上市前几个月才发布，销售的是算力而非路线图幻灯片，如今还将 TPU 部署到其他云以及客户自己的数据中心 S550,S552,S90027。它的买方承诺的是一种关系，而非一份规格表；Anthropic 最多 1M 颗 TPU 的交易就是范本 S90026。

> **注**
>
> 🐂 **看多观点：** 一份有明确时间表的多层路线图本身就是一道护城河。买方围绕它规划吉瓦级站点，竞争对手为跟上节奏而投入重金，而在六次发布期间连续 14 个季度的增长表明，只要供应紧张，奥斯本风险就是可控的 S17006。迄今为止的修订只是在边际上改变了规格，而非节奏。

> **注意**
>
> 🐻 **看空观点：** 路线图如今承诺的内容已超出供应链按时交付的能力。一年之内，英伟达下调了 Rubin 的带宽，撤下 CPX 后又据报道使其复活，并面临有关 Kyber 推迟 12 个月的报道 [S90006,S115,S117,S507]。由于计划是公开的，每一次失误都清晰可见，而时间跨度较短的竞争对手不可能错过它们从未承诺过的事情。如果 2027–28 年供应趋于宽松，同一份路线图反而会促使买方等待。

### 🔧 技术细节：时间跨度与提前期数据如何构建

`data/x17_preannouncement_horizon.csv` 记录了 25 款加速器首次附带目标年份的公开提及时间，以及（计划的）批量上市开始时间。仅有年份的计划按年中计，因此“2028”的项目按 2028 年 7 月计算。英伟达的 Rubin、Rubin Ultra 和 Vera 首次在 Computex 2024 上公布时间表 [S17003,S17004]，Feynman 则在 GTC 2025 上 [S35018]。对于竞争对手，首次提及通常是 `data/roadmap.csv` 中的发布活动，可能遗漏更早的非正式暗示；例如 AMD 的 MI400 系列在 Computex 2024 上就被定于 2026 年 [S17007]。季度检验使用 `data/financials.csv` 中的数据中心收入；它无法区分隐藏的奥斯本效应与强劲需求，但一次大到足以产生影响的冻结会表现为一个下滑的季度。

### 🔧 技术细节：2024–2026 年英伟达路线图披露方式的变化

- **Computex 2024：** “一年一代节奏”幻灯片公布了 Blackwell Ultra（2025）、Rubin（2026）和 Rubin Ultra（2027），外加 Vera CPU，给出了 HBM 堆叠高度，但其他规格很少 [S17003,S17004]。
- **GTC 2025：** Rubin 和 Rubin Ultra 给出了每 GPU 和每机架的数据（Rubin Ultra：四颗裸片、~100 PFLOPS FP4、1 TB HBM4E、600 kW 的 Kyber 机架），并新增了定于 2028 年的 Feynman [S35018,S305]。
- **2025 年 9 月：** 发布 Rubin CPX，定于 2026 年末 [S33023]。
- **CES 2026：** 宣布 Rubin 全面投产；机架命名从按裸片计改为按封装计（NVL144 → NVL72）[S33004,S90009]。
- **GTC 2026：** 公布 Kyber NVL144、采用铜缆加共封装光学的 Feynman NVL1152、Rosa CPU 以及 Groq LPU 产品线（LP30、LP35、LP40）；CPX 被撤下 [S108,S109,S115]。
- **2026 年 9–10 月：** 产品页面悄然修订了 Rubin 的内存与 NVLink 带宽 [S103,S105]。

每一步都披露了更多内容、覆盖更远的时间、涉及更多层级。代价是，每一次修订如今都清晰可见且有据可查。

## 观察要点：Q3 FY2027、GTC DC 与 GTC 2027

| 事件 | 日期 | 观察要点 | 可能改变格局的因素 |
|---|---|---|---|
| Q3 FY2027 业绩 | 2026-11-17 S17005 | Rubin 放量；数据中心收入对照 $108B 的总营收指引及 ~74% 的毛利率指引 [S3,S90085]；有关 FY2028 供应的表态 | 若“受供应约束”的表述减弱，奥斯本风险将上升 |
| GTC DC 主题演讲 | 2026-12-01 S90047 | Kyber 时间；800 V DC 合作伙伴；美国 AI 基础设施与政策公告 | 若确认 Kyber 推迟，Rubin Ultra 的机架将被推入 2028 年 |
| GTC DC 主题演讲 | 2026-12-01 S90047 | Rubin CPX 状态；LP35 规格 | 若 CPX 复活，将确认三芯片推理产品线（GPU、CPX、LPU） |
| GTC 2027 | 2027 年 3 月 14–18 日 S17000 | Rubin Ultra 最终内存配置（1 TB 对 768 GB）及裸片数量 | 若为双裸片、性能约减半，MI500 将追平差距 |
| GTC 2027 | 2027 年 3 月 14–18 日 S17000 | Feynman 制程、HBM 与 NVL1152 规格；Rosa CPU | 首批 Feynman 数据将设定 2028 年的规划默认选项 |
| NVLink Fusion 放量 | 2027 年全年 | NVLink Fusion 芯片（Trainium4、高通与富士通 CPU、英特尔 x86）S518,S90031 | Fusion 部件出货将把英伟达机架延伸至竞争对手的芯片 |
| 开放互连与竞争对手放量 | 2027 年全年 | UALink 1.0 产品；Helios 放量；TPU 8t 全面上市 S90051,S538,S550 | 开放互连若实现批量，将削弱 NVLink 的锁定效应 |
| Hugging Face 交割 | 2027 年上半年（目标） | Hugging Face 交割及欧盟或美国司法部可能附加的条件 S11500,S11027 | 附加条件将考验英伟达作为模型平台的中立性 |

**如何解读接下来的主题演讲。** 有三个信号比新产品名称更重要。第一，英伟达是否重新表述已在路线图上的项目（Kyber、Rubin Ultra、CPX）的日期：一个重新表述的日期比一个新代号更有信息量。第二，规格是以区间还是目标值给出——这已成为英伟达自己对 Rubin 修订的解释 [S104]。第三，哪些合作伙伴为 NVLink Fusion 和 800 V DC 站台：合作伙伴芯片出货将表明该平台正延伸至竞争对手的芯片和电力链 [S90031,S90063]。

## 🎯 企业发展视角

1. **可见性本身就是产品特性。** 买方提前两到三年规划吉瓦级站点；英伟达提前 26–40 个月公布时间表（🔴 本资料库分析）[S17006]。对于任何挑战者，包括高通的 AI250（2027）和 Dragonfly AI300（2028）[S173,S90060]，一份带有机架级规格的公开路线图，是否值得为其带来的可信度风险买单?
2. **可信度就是货币。** 英伟达 2026 年的修订以及 AMD MI325X 的容量下调 [S90006,S17007,S142] 表明，两家领先者都会过度承诺。尽职调查应将承诺与兑现的规格和日期作为一项硬指标来跟踪。
3. **跟上节奏每代需要 ~$10B** [S35028]。谁能转而搭乘这一节奏？NVLink Fusion 和设计合作伙伴让其他厂商得以纳入英伟达的机架日程出货（Trainium4 [S518]）；借力是否比竞争更便宜?
4. **在产能过剩时，奥斯本风险会反转。** 关注“受供应约束”的措辞 [S90012] 和 CoWoS 产能估计 [S3002]。2027–28 年若出现供应过剩，英伟达的长期时间表将成为买方等待的理由，从而为更便宜的当代替代方案打开机会。
5. **2027 年的窗口。** Kyber、HBM4E 和 UALink 产品都集中在 2027 年 [S507,S3531,S90051]。Kyber 若推迟到 2028 年，将使 Helios 500 等开放互连机架获得一年时间与 Vera Rubin 竞争。哪些合作关系能让挑战者把握这一窗口？纵向扩展和系统的价值链页面梳理了处于这场竞争双方的供应商。

# 18 —— 弱点与看空情景

跨层专题 18 · 十大风险：最强论证、逐项打分与持续跟踪 · 阅读约 38 分钟 · 最后核实：2026-11-05

## ⚡ 要点速览

- **看空逻辑并非“需求疲软”。** Q2 FY2027 营收为 $96.2B（同比 +106 %），GAAP 毛利率 75.0 %；Q3 指引为 $108B；管理层将 FY2028 约 70 % 的增长定性为供应所能支撑的水平 [S405,S90012,S18000]。最有力的看空逻辑是：当前需求高度集中、部分由英伟达（NVIDIA）自己出资、且可被替代，而这三点都会先体现在价格上，之后才体现在出货量上。
- **本资料库的风险热力图上有两项风险居首。** 🔴 超大规模云厂商自研芯片得分 16（满分 25；可能性 4 × 影响 4）：博通（Broadcom）单季 AI 营收已相当于英伟达数据中心营收的约 19 %，Anthropic 可使用多达 1M 颗 TPU [S2516,S653]。🔴 资本开支周期得分 15（3 × 5）：供应承诺已达 $279B，为季度营收的 2.9×，而 FY2023 库存危机之前约为 1.4× [S407]。
- **循环融资比率现已与朗讯（Lucent）相当。** 英伟达在 H1 FY2027 买入 $42.4B 股权，约占半年营收的 24 %，与朗讯 1999–2000 年以供应商融资形式提供的比例相同 [S90072,S18007]。区别在于谁来买单：英伟达仅 Q1 FY2027 一个季度就产生 $50.3B 经营现金流，其最大买家是现金充裕的超大规模云厂商，而非初创电信运营商 [S403]。
- **集中度是放大器。** 一家直接客户占 Q2 FY2027 营收的 16 %，三家合计占 H1 营收的 44 %，超大规模云厂商约占数据中心营收的 55 % [S90069,S90011,S406]。正是这些买家在打造 TPU、Trainium、Maia 和 MTIA，因此风险 1、2、7 实际上是同一个相互关联的押注。
- **政策风险发生概率高，但影响有限。** 中国占营收比例从约 26 %（FY2022）降至 FY2027 各季度的 5.6–8.2 %，且已不计入业绩指引 [S2,S90070,S90069]；若中国国家市场监督管理总局（SAMR）按上一年度在华销售额的 1–10 % 处以罚款，金额约为 $0.2–2.5B（本资料库计算）[S9505,S401]。
- **技术风险缓慢侵蚀定价权。** UALink 产品预计 2027 年面世，AMD 在新前沿模型上相对英伟达的滞后已缩短至 26 天 [S90051,S631]；🔴 本资料库对前沿实验室的 CUDA 锁定程度仅打 2.75/5 分。台湾（1 × 5）属于尾部风险：全部 CoWoS 封装产能都位于台湾岛内 [S18012]。
- **市场已经在为峰值定价。** 按约 $5.3–5.8T 市值（2026 年 8–10 月）计算，英伟达股价约为 FY2028 指引盈利的 14×，隐含此后年增长率仅约 2 %（🔴 本资料库测算）[S18004,S18005,S18027]。看空者需要论证的是 FY2028 之后盈利会 *下降*。🔴 最可能的看空结果是毛利率从 75 % 向 65 % 上下回落；2001 年式的断崖式下跌只是尾部情形。

**Repo view: custom ASICs (16) and the capex cycle (15) are NVIDIA's biggest risks; Taiwan is the tail**

Ten risks scored 1–5 for likelihood within their horizon and impact on FY2028–FY2030 gross profit; score = likelihood × impact (repo judgement; rationale and evidence in data/x18_risks.csv)

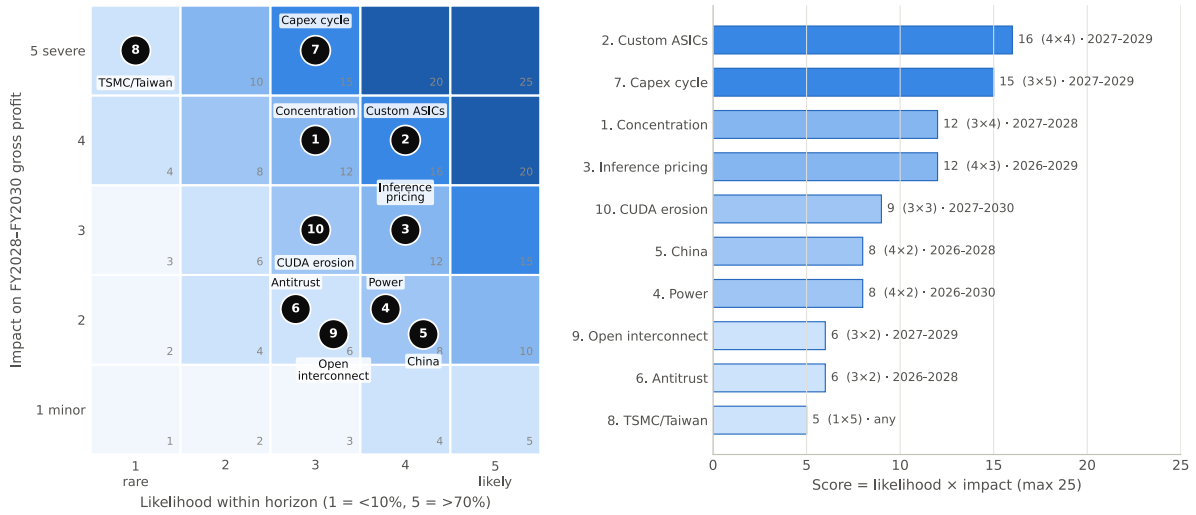


*Scores are repo judgement (speculative), not forecasts*

Source: data from repo scoring of cited evidence (see data/x18_risks.csv) [S18027] [S90069] [S2516] [S407] [S90072] [S379]; chart by repo · As of 2026-11-05

> 风险热力图：横轴为可能性、纵轴为影响，均按 1 至 5 打分，并附排序柱状图。得分（可能性 × 影响）：超大规模云厂商定制 ASIC 16（4x4）、循环融资与资本开支周期 15（3x5）、客户集中度 12（3x4）、推理商品化 12（4x3）、软件抽象层侵蚀 CUDA 9（3x3）、电力约束 8（4x2）、中国与出口管制 8（4x2）、反垄断 6（3x2）、开放互连标准 6（3x2），以及台积电/台湾集中度 5（1x5）——一项低概率、极端影响的尾部风险。所有分数均为本资料库的判断。

## 如何阅读本章

本资料库的其他各页都在解释英伟达为何胜出，本页则刻意反其道而行之。针对十项风险中的每一项，本页构建一个最强论证（steelman）：即以数据为支撑、最有力且诚实的看空论点；随后给出英伟达最有力的反驳，最后给出研判。研判对**可能性**（风险是否会在其时间窗口内兑现？）和**影响**（若兑现，FY2028–FY2030 有多少毛利润受到冲击？）打分，并列出需要关注的领先指标。分数为本资料库的判断（🔴），每一行的理由与证据见 `data/x18_risks.csv` [S18027]。请将其视为结构化论证，而非预测。

| 分值 | 可能性（在所述时间窗口内） | 影响（对 FY2028–FY2030 毛利润） |
|---|---|---|
| 1 | < 10 % | < 2 % |
| 2 | 10–30 % | 2–5 % |
| 3 | 30–50 % | 5–15 % |
| 4 | 50–70 % | 15–30 % |
| 5 | > 70 % | > 30 %，或营收连续多年下滑 |

风险通过四条渠道传导至英伟达的价值：出货量减少、价格下降（毛利率）、与承诺和持股相关的一次性费用，以及估值倍数下降。下图显示每项风险经由哪条渠道传导。多数风险都经由**价格**传导，这正是毛利率成为最佳单一预警指标的原因。

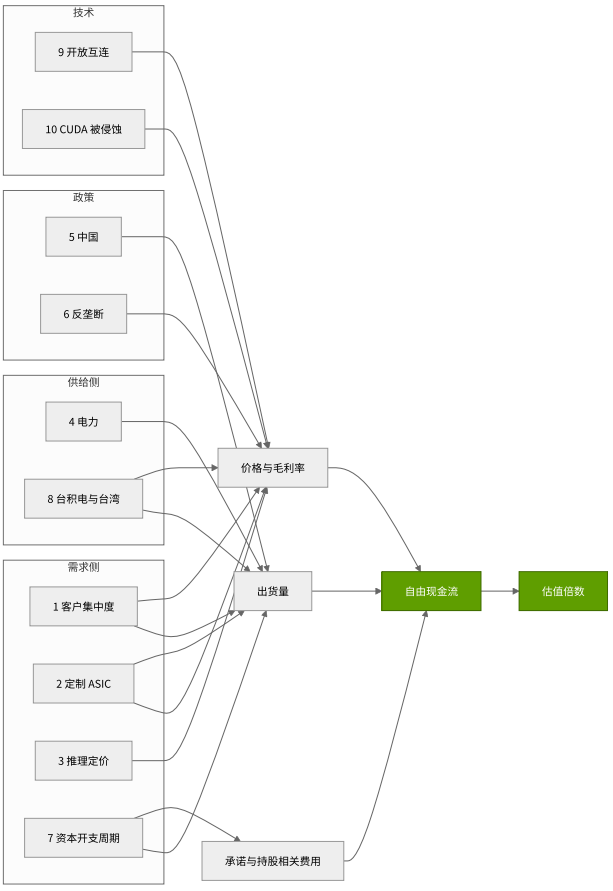


页首的风险热力图与下方的象限图以两种方式呈现同一组分数。右上象限是分析应重点投入精力的区域。

提示

**算例 —— 影响分值折合多少美元。** 按 FY2028 指引路径，营收约 $697B、毛利率约 72.5 %，毛利润约 $505B（🔴 本资料库根据 S18000 测算）。影响 4 意味着 15–30 % 的冲击：**每年 $76–152B**。若可能性为 4（50–70 %），概率加权敞口约为每年 $38–106B。影响 2 意味着 2–5 %，即 $10–25B。**结论：** 即便是该量表上的“低”分，其金额也相当于大多数半导体公司的全部业务；该量表是相对于英伟达的体量而言的。

🔧 **技术细节：风险为何相互关联，以及这为何重要**

十项风险并非相互独立的随机事件。风险 1（客户集中度）、2（自研芯片）和 7（资本开支周期）共享同样五六家交易对手：Alphabet、亚马逊（Amazon）、Meta、微软（Microsoft）、OpenAI 和 Anthropic。其中任何一家的单一决策——例如放缓 2028 年资本开支，并以自研芯片填补其余需求——都会同时触发这三项风险。风险 3（推理定价）与风险 10（CUDA 被侵蚀）同样相互关联：开源推理服务引擎既是推理负载可迁移的原因，也是 CUDA 重要性下降的原因。反过来，风险 2 在一定程度上对冲了风险 6：TPU 和 Trainium 越可信，指控英伟达控制市场的反垄断理由就越站不住脚。因此，组合视角不会把十项分数简单相加，而会把相互关联的风险簇（1 + 2 + 7）作为一个情景进行压力测试。估值部分正是这样做的。

## 风险 1 —— 客户集中度

### 🐻 最强看空论证

英伟达的客户集中度很高，而其最大的客户恰恰是其最有实力的竞争对手。在 Q2 FY2027 的 10-Q 中，一家直接客户占季度营收的 16 %；三家直接客户分别占上半年营收的 16 %、15 % 和 13 %，合计 44 % S90069。这些“直接”客户大多是组装机架的 OEM 和 ODM，其背后的资金来自少数几家超大规模云厂商和 AI 实验室。英伟达表示，有数家间接客户各自占营收比例超过 10 % S90069。Q2 FY2027 来自超大规模云厂商的营收约为 $48.7B，约占数据中心营收的 55 % S90011,S406。

有三个特点使这种情况比一般客户集中的供应商更糟。第一，客户基础变得*更加*美国化：总部不在美国的客户占 Q1 FY2027 营收的 22 %，一年前为 42 % S90070。第二，有一家 AI 研究实验室通过云服务商为营收作出了重大贡献 S90070，因此单个模型公司的一轮融资就可能左右英伟达的季度业绩。第三，英伟达还从同一批客户处“回购”：它持有 $29B 的多年期云服务协议和 $36B 的 AI 云算力协议 S407。一个同时身为供应商和竞争对手的买家，拥有非同寻常的议价能力。

**Customers at ≥10% of revenue rose from 1 (13%) in FY2024 to 4 (61%) in Q3FY26**

Share of revenue per disclosed direct customer, %; letters are not the same company across periods; mostly OEMs/ODMs

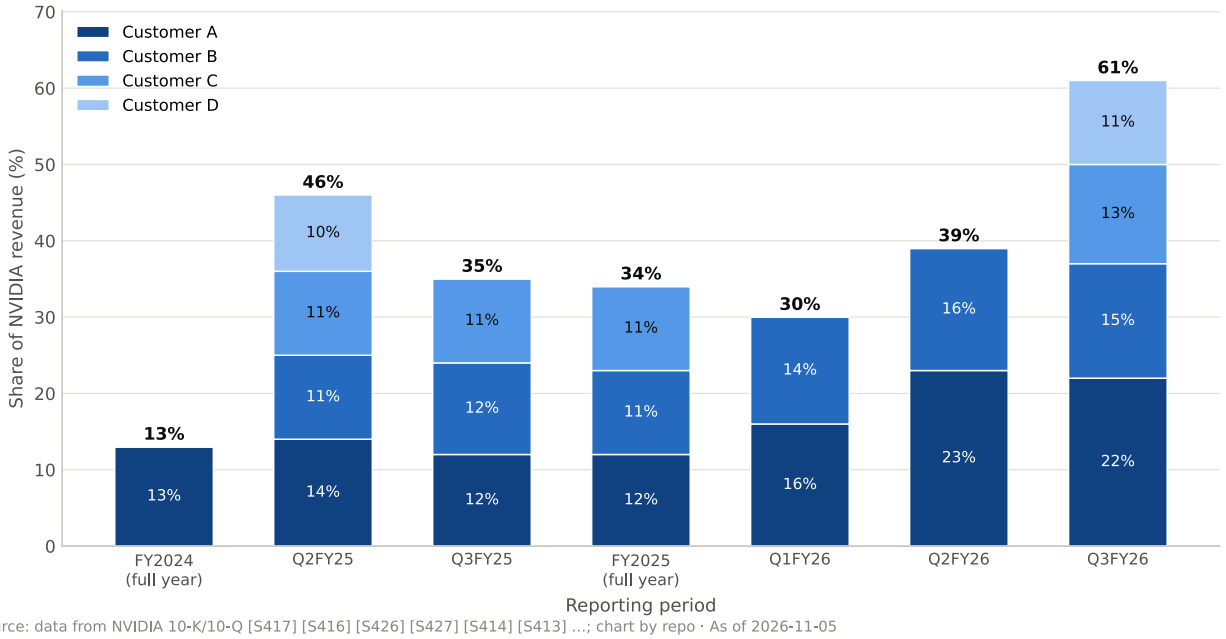


Source: data from NVIDIA 10-K/10-Q [S417] [S416] [S426] [S427] [S414] [S413] …; chart by repo · As of 2026-11-05

英伟达披露的营收占比超过 10% 的直接客户堆叠柱状图：FY2024 为 1 家客户、占 13%，FY2025 为 3 家客户、合计 34%，Q3FY26 为 4 家客户、合计 61%；其中多数是为超大规模云厂商组装的 OEM/ODM。

## 英伟达的反驳

最新披露的数据朝着有利于英伟达的方向变化。Q2 FY2027 的 10-Q 中，当季占比超过 10 % 的直接客户只有一家（16 %），而 Q3 FY2026 有四家、合计 61 % [S90069,S412]。非超大规模客户的业务规模很大：AI 云、工业与企业客户（ACIE）贡献约 $40.3B，占 Q2 FY2027 数据中心营收的 45 % [S406]；主权 AI 在 FY2026 超过约 $30B（+80 %）；区域性新兴云服务商（neocloud）在 Q2 环比增长 35 % [S90071]。最重要的是，英伟达处于供应受限状态。管理层表示，需求“远大于”其 FY2028 所能供应的约 70 % 增长 [S18000]。在这种格局下，被取消的订单会被重新分配，而不是流失。

**Direct-buyer concentration peaked at 61% (Q3 FY2026); in Q2 FY2027 one buyer was 16%**

Direct customers (mostly OEMs/ODMs building for hyperscalers) at ≥10% of NVIDIA revenue, % of revenue per period; hatched = quarterly rows pending re-verification against the 10-Q

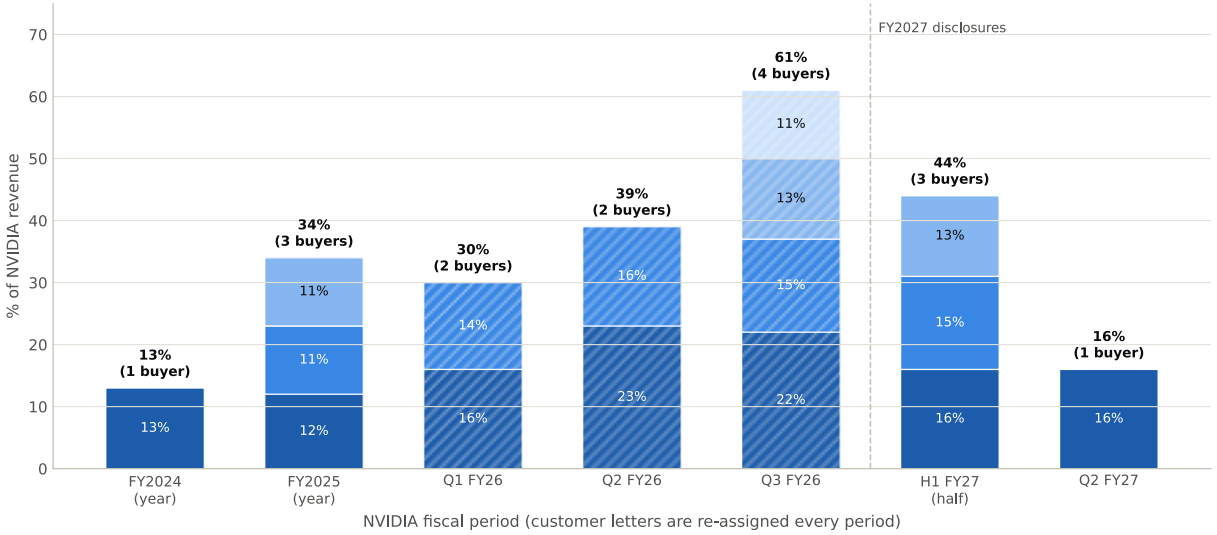


Source: data from NVIDIA 10-K and 10-Q customer-concentration notes [S417] [S416] [S414] [S413] [S412] [S90069]; chart by repo · As of 2026-11-05

营收占比超过 10% 的英伟达直接客户堆叠柱状图：FY2024 一家客户占 13%；FY2025 三家客户分别占 12%、11% 和 11%（合计 34%）；Q1 FY2026 为 16% 和 14%（30%）；Q2 FY2026 为 23% 和 16%（39%）；Q3 FY2026 四家客户分别占 22%、15%、13% 和 11%（61%）；FY2027 上半年三家客户分别占 16%、15% 和 13%（44%）；Q2 FY2027 仅一家客户、占 16%。超大规模云厂商等间接买家的实际体量大于这些直接 ODM 数据所显示的水平。

**提示**

**算例 —— 一家超大规模云厂商暂停采购的代价。** Q2 FY2027 来自超大规模云厂商的营收为 $48.7B [S90011]。假设（🔴）四家买家中最大的一家约占其中 30 %，即每季度约 $15B，并将三分之一的支出转向自研芯片：每季度营收减少 $5B，约占英伟达总营收的 5 %，按 75 % 毛利率计约合 $3.8B 毛利润。如果其余超大规模云厂商随后再谈下 5 个百分点的毛利率，则每季度还要再损失 $48.7B × 5 % ≈ **$2.4B**。**结论：**在供应受限的市场中，出货量可以转售给他人，因此客户集中度造成的持久损害在于价格让步；在本例中约为每年 $10B 毛利润。

**🔧 技术细节：如何解读英伟达的客户披露**

英伟达会披露占营收 10 % 以上的任何*直接*客户，以 A、B、C 标注，且每期重新分配字母，因此两份文件中的“客户 A”可能是不同公司。直接客户大多是 ODM（富士康、广达、纬创等）和 OEM，这也是当超大规模云厂商在不同组装商之间调配订单时，直接客户数据会大幅波动的原因。英伟达还会根据渠道数据*估计*间接客户（ODM 背后的最终买家）；这些数字未经审计。本资料库较早的季度数据（Q1–Q3 FY2026）系凭记忆录入，已标记待重新核实；FY2027 数据来自 Q2 FY2027 的 10-Q [S90069]。实操原则：跟踪超大规模云厂商占数据中心营收的比例（目前约 55 %），而不是直接客户的字母代号。

**重要**

**研判 —— 客户集中度。** 可能性 **3** · 影响 **4** · 得分 **12** · 时间窗口 **2027–2028**。集中度真实存在，且与风险 2 和风险 7 相关，但供应稀缺把其中大部分转化为定价风险。**关注：**超大规模云厂商占数据中心营收的比例（约 55 %；> 60 % 为警示信号）、每份 10-Q 中占比 ⩾ 10 % 的客户数量，以及英伟达的云算力协议是否继续增长。

# 风险 2 —— 超大规模云厂商自研芯片（TPU、Trainium、Maia、MTIA）

## 🐻 最强看空论证

如今每家大买家都拥有可信的 ASIC。谷歌（Google）的 TPU 就是明证：Ironwood 单芯片提供 4,614 TFLOPS 稠密 FP8 算力，组成 9,216 颗芯片的 pod [S151,S650]；TPU 8t 的 FP4 算力达 12.6 PFLOPS [S552]；而且这些芯片现在已对谷歌以外销售。Anthropic 可使用多达 1M 颗 TPU，2026 年超过 1 GW [S653]；Meta 租用 Ironwood 算力，并曾商讨为自有园区采购 TPU 🟡 [S90025]；甲骨文（Oracle）将托管 TPU [S552]。OpenAI 正与博通联合设计 10 GW 的加速器 [S174]，据报道其首款推理芯片单裸片 MXFP4 算力达 13.4 PFLOPS，而 Rubin 每颗裸片的 NVFP4 算力为 17.5 PFLOPS 🟡 [S628]。AWS 已全面推出基于 3 nm 的 Trainium3，并承诺 Trainium4 的 FP4 吞吐量将是其 6× [S90034,S90035]。微软在 Maia 200 上运行 Copilot，计划 2027 年推出 Maia 300，并自 2027 年起进行数吉瓦级 Maia 部署 [S90044,S90045,S90046]。Meta 的 MTIA 300 已投产，到 2027 年还有三代产品 [S561]。

资金已经在转移。博通在截至 2026-08-02 的季度确认 $16.7B AI 半导体营收，约为英伟达 $89.0B 数据中心营收的 19 %，并对下一季度给出 $21.7B 指引 [S2516]。两年前这一比例约为 11–14 % [S660,S661]。按台数计算，TrendForce 类机构估计基于 ASIC 的服务器约占 2026 年 AI 服务器出货量的 28 %（凭记忆引述，未经核实）[S666]。

经济账解释了原因。SemiAnalysis 估计，自有 Ironwood 每芯片小时成本约 $1.21，而 B200 约 $1.73、GB300 约 $2.31（估计）[S622]；在某一 FP8 工作负载上，每 token 成本比 B200 低约 18 % [S625]。超大规模云厂商对英伟达的“放弃价”就是其自研芯片的成本。这恰恰在占英伟达数据中心营收一半的那批客户身上，给英伟达的价格设定了上限。

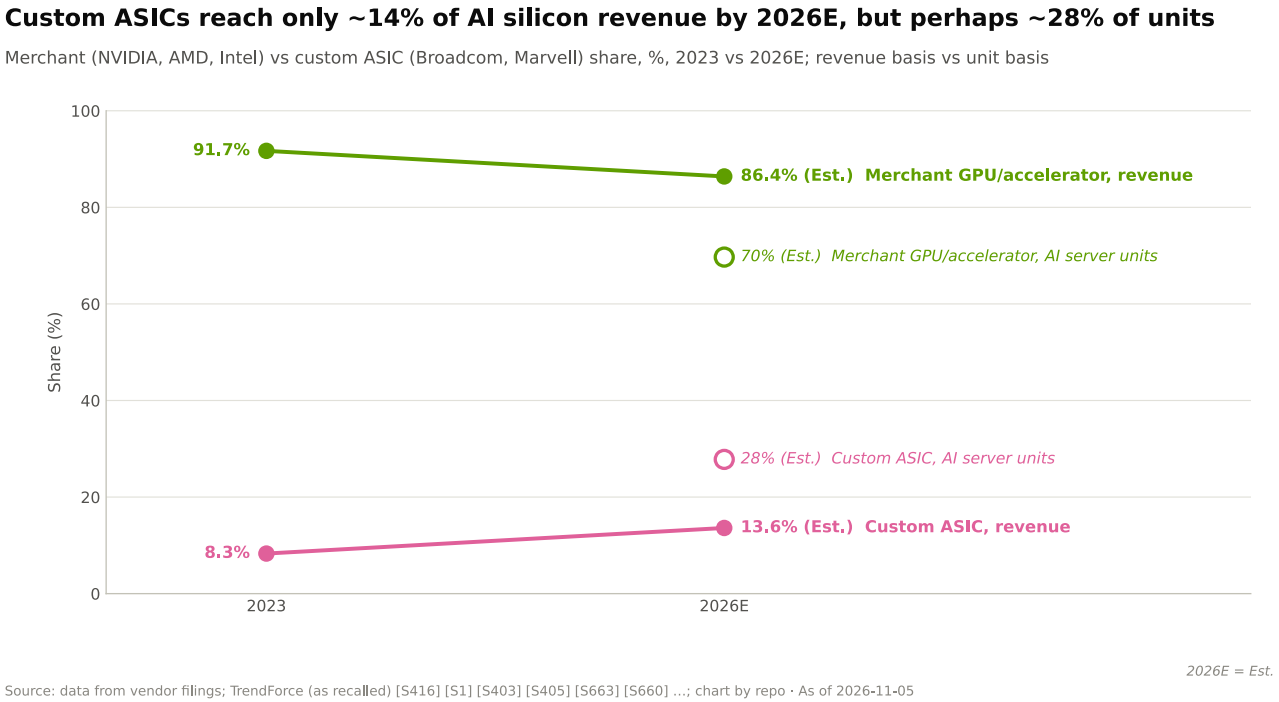


斜率图：2023 年至 2026E，商用 GPU 与加速器在 AI 数据中心芯片营收中的份额从 92% 降至约 86%，定制 ASIC 从 8% 升至约 14%。按台数计，TrendForce 类机构估计基于 ASIC 的服务器约占 2026 年 AI 服务器出货量的 28%，因为定制芯片的单价要低得多。

**Broadcom's AI revenue rose 2.8x in two years to $6.5B a quarter and tracks ~$57B for FY2026; Marvell's is ~1/8 the size**

Left: Broadcom AI semiconductor revenue by fiscal quarter (US$ B). Right: annual AI revenue, Broadcom vs Marvell (US$ B)

*Hatched = guidance or Est.*

Source: data from Broadcom, Marvell earnings releases [S660] [S661] [S451] [S2516] [S662] [S453] ...; chart by repo · As of 2026-11-05

两幅图。左：博通季度 AI 半导体营收从 2024 财年 Q1 的 $2.3B 攀升至 2025 财年 Q4 的 $6.5B，2026 财年 Q1 指引 $8.2B 以阴影表示。右：年度 AI 营收，博通约 $3.8B（2023）、$12.2B（2024）、$20.2B（2025），FY2026 约 $57B（Q1 和 Q4 为指引值、Q2 为推算值、Q3 为实际值）；美满电子（Marvell）分别为 $0.55B、$1.5B、$2.5B、约 $3.5B（2026E）。博通的数据既包括 AI 以太网网络业务，也包括谷歌 TPU 等定制 XPU。

## 🛡️ 英伟达的反驳

在价值池急剧膨胀的同时，份额几乎没有变化。2025 年英伟达保持了约 87 % 的 AI 芯片营收份额，而价值池较 2023 年扩大约 4.2×；定制 ASIC 份额维持在 10 % 左右（估计）[S416,S1,S660,S661,S662]。自研项目每代大约需要 130,000 颗芯片才能比购买 GPU 更划算（🔴，见 CS3）[S23010]，只有少数几家买家能跨过这一门槛。超大规模云厂商还要把英伟达 GPU 出租给指定使用 CUDA 的云客户，因此 ASIC 首先服务于内部工作负载。英伟达正在将威胁收编为己用：Trainium4 的设计可接入 NVLink Fusion 和英伟达的 MGX 机架[S518,S90034]。最后，英伟达可以针对 ASIC 定价：本资料库估计，英伟达即使将每 token 成本压到与 TPU 持平，仍能保留约 62 % 的毛利率（🔴）[S23010]。

**提示**

**算例 —— ASIC 设定的价格上限。** 采用本资料库 CS3 的估计：若要在每 token 成本上与 TPU 持平，英伟达该部分业务的毛利率将降至约 62 %（🔴）[S23010]。仅将其应用于超大规模云厂商（约占数据中心营收的 55 % [S90011]），其他业务仍按 75 % 计：混合毛利率为 0.55 × 62 % + 0.45 × 75 % ≈ **68 %**。以 FY2028 指引营收约 $697B 计，比指引的约 72.5 % 低 4.5 个百分点，相当于每年约 $31B 毛利润，约占总额的 6 %。**结论：**自研芯片远在成为出货量风险之前，就已是毛利率风险；它也是最有可能率先在毛利率这一行显现的风险。

**重要**

**研判 —— 超大规模云厂商 ASIC。** 可能性 **4** · 影响 **4** · 得分 **16**（最高）· 时间窗口 **2027–2029**。已经体现在*增量*份额和对外 TPU 交易中，但尚未体现在英伟达的绝对营收上。与 CS3 的结论一致：它限制的是定价权，而非出货量。**关注：**博通 AI 营收 ÷ 英伟达数据中心营收（约 19 %；> 25 % 为警示信号）、Meta 是否*采购* TPU、Maia 300 和 Trainium4 的出货量，以及英伟达的毛利率。

# 风险 3 —— 推理商品化

## 🐻 最强看空论证

推理是英伟达护城河最薄、增长最快的领域。管理层最近一次给出的数据是：截至 Q2 FY2025 的一年中，推理占数据中心营收的 40 % 以上 [S11011]。与前沿训练不同，推理可拆分为小型、独立的任务，易于进行基准测试，也易于迁移。

价格下降的速度快于任何硬件成本曲线。Token 价格通缩使 GPT-3.5 水平最便宜模型的价格在两年内从每百万 token $20 降至 $0.07，降幅约 286× [S11526]。H100 租金从 2023 年的每 GPU 小时约 $8 降至 2024 年底交易平台上的约 $2 以下 [S393]。推理服务层是中立的：vLLM 在主代码树中原生支持英伟达、AMD 和英特尔（Intel），并通过插件支持 TPU、Gaudi 和华为昇腾（Ascend） [S580]。专用推理芯片也不断涌现：OpenAI 与博通合作的芯片 [S628]、Cerebras 为 OpenAI 提供多达 750 MW 算力 [S11523]、TPU 在某一工作负载上每 token 成本比 B200 低约 18 % [S625]。英伟达自己据报道也斥资约 $20B 获得 Groq 的技术授权并聘用其团队 🟡 [S90019]，这一价格表明它对这一威胁有多重视。DeepSeek V4-Pro 的定价约为每百万输出 token $3.48 [S90080]。

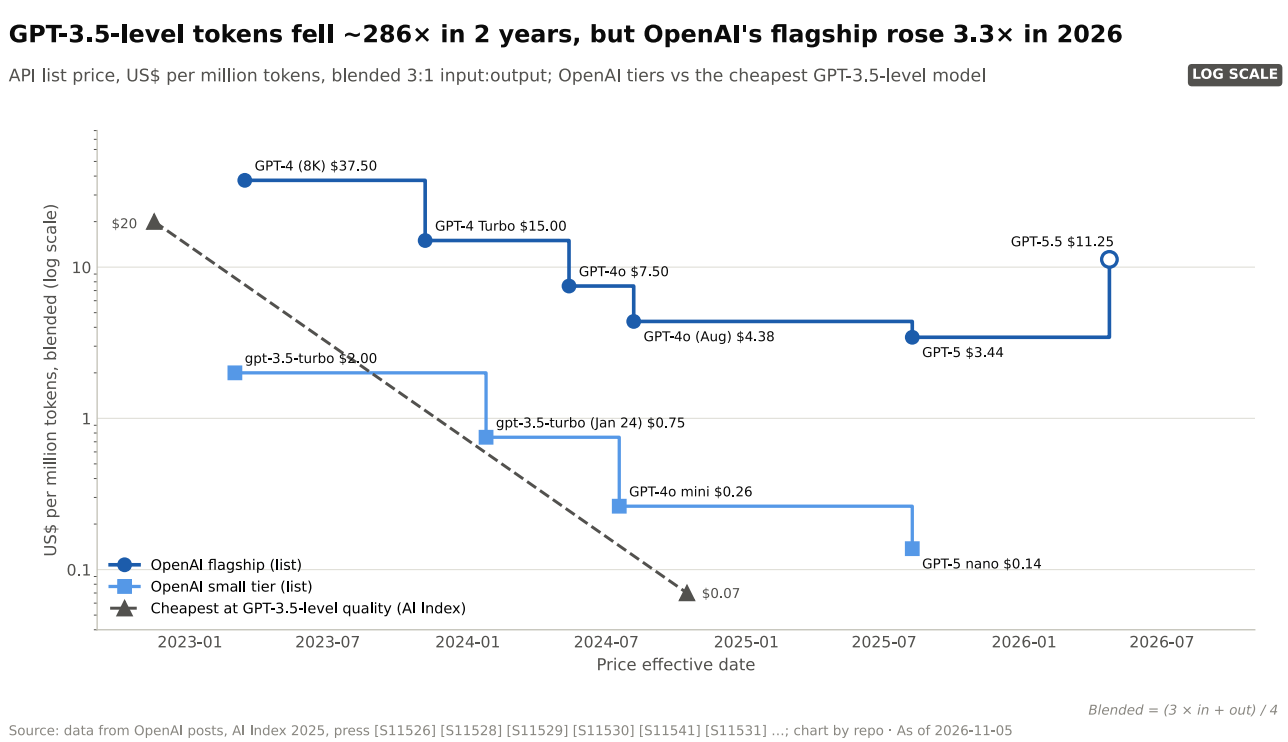


> 对数坐标图：每百万 token 的 API 价格。GPT-3.5 水平最便宜的模型从 $20（2022 年 11 月）降至 $0.07（2024 年 10 月），降幅约 286x。OpenAI 旗舰模型从 GPT-4 的混合价 $37.50（2023 年 3 月），经 GPT-4 Turbo（$15）、GPT-4o（$7.50，后降至 $4.38），降至 GPT-5 的 $3.44（2025 年 8 月），便宜约 11x；随后 GPT-5.5 以 $11.25 上市（2026 年 4 月，据报道），为 GPT-5 的 3.3x。OpenAI 小模型档位从 gpt-3.5-turbo 的 $2.00（2023）降至 GPT-4o mini（$0.26）和 GPT-5 nano（$0.14）。

**H100 rentals fell ~75% from ~$8/GPU-hr (2023) to ~$2-3 on neoclouds; AWS list −44%**

On-demand list/observed prices, US$ per GPU-hour (instance ÷ GPUs) · marker = provider type · contract rates are lower

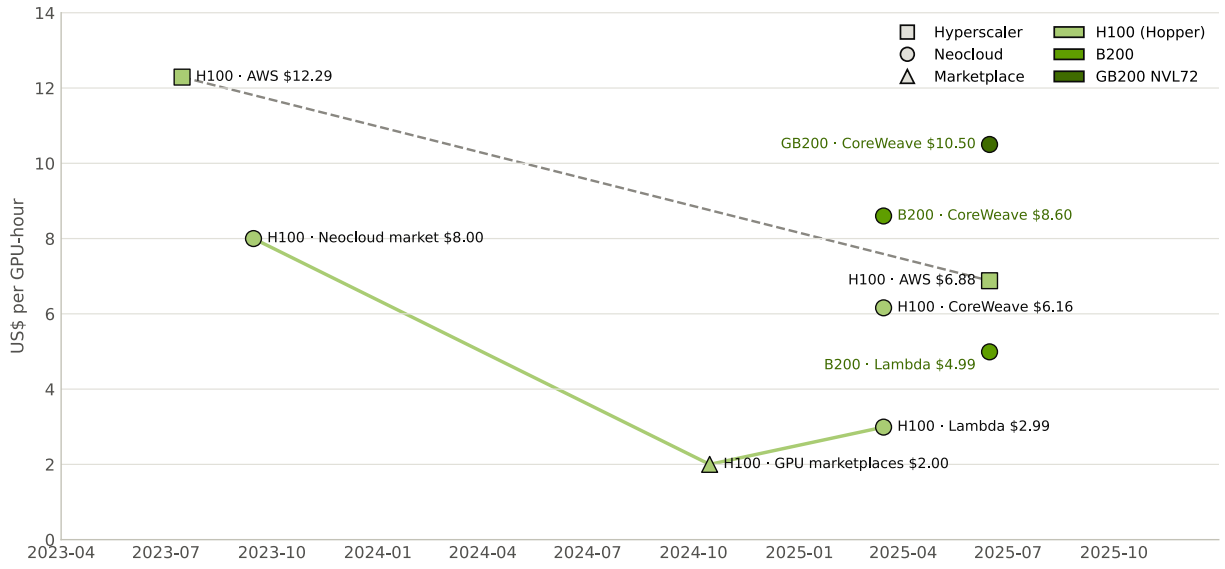


Source: data from AWS, CoreWeave, Lambda, Latent Space [S391] [S393] [S395] [S394] [S392]; chart by repo · As of 2026-11-05

> GPU 租金随时间变化的散点图。H100：AWS p5 按需价格在 2023 年 7 月上市时为每 GPU 小时 $12.29，2025 年 6 月降价后为 $6.88；新兴云服务商 H100 在 2023 年约 $8，到 2024 年底交易平台价格低于 $2，2025 年 Lambda 标价 $2.99、CoreWeave 标价 $6.16。2025 年 Blackwell 标价：B200 从 $4.99（Lambda）到 $8.60（CoreWeave），GB200 为 $10.50（CoreWeave）。

## 🛡️ 英伟达的反驳

到目前为止，更便宜的 token 带来的是更多支出，即杰文斯悖论（Jevons paradox）。谷歌每月处理的 token 量在 18 个月内增长约 134× [S32018,S32020]。SemiAnalysis 的 H100 一年期租金指数从 2025 年 10 月 $1.70 的低点反弹至 2026 年 3 月的 $2.35，涨幅 +38 %，旧 GPU 被重新上调定价 [S12516]。前沿模型价格不降反升：GPT-5.5 上市时的混合价格约为 GPT-5 的 3.3× 🟡 [S11535]。英伟达的机架级系统在最难的推理场景中胜出：在每用户 50 tokens/s 条件下，GB300 NVL72 运行 DeepSeek-R1 的每兆瓦 token 产出约为 H200 的 13×（估计）[S621,S622]；仅靠软件，同一套 GB300 NVL72 上的 DeepSeek-R1 吞吐量一年内就提升了 2.9× [S601,S603]。英伟达还选择把推理 ASIC 的思路买下来，而不是与之对抗：Groq 3 LPX 机架现已与 Vera Rubin 并列 [S90003]。

**H100 rentals rose 38% from a $1.70/hr low (Oct 2025) to $2.35 by Mar 2026**

H100 rental price observations by series, US$ per GPU-hour (different contract types: compare within a series)

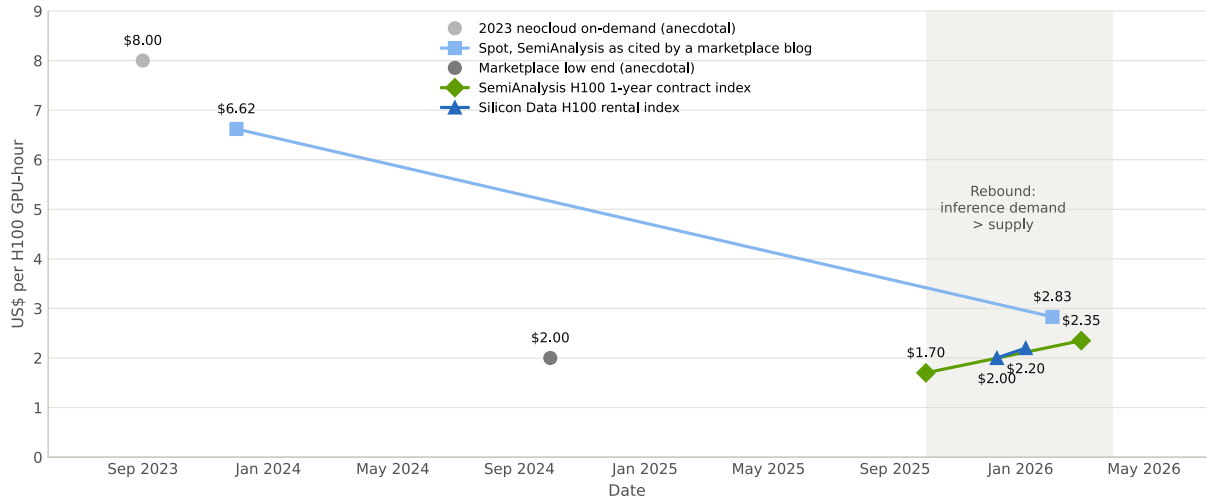


*Mixed contract types; 2023–24 points are anecdotal*

Source: data from SemiAnalysis, Silicon Data, Latent Space as cited [S393] [S12531] [S12516] [S12517]; chart by repo · As of 2026-11-05

H100 租金折线与散点图：2023 年 9 月新兴云服务商约为每 GPU 小时 $8，2023 年底现货价 $6.62，2024 年 10 月交易平台约 $2；随后 SemiAnalysis 一年期合约指数在 2025 年 10 月触及 $1.70 低点，2026 年 3 月升至 $2.35（+38%）；Silicon Data 指数在 2025 年 12 月至 2026 年 1 月间从 $2.00 升至 $2.20；2026 年 2 月引用的现货价为 $2.83。由于推理需求超过供给，旧 GPU 被重新上调定价。

**提示**

**算例 —— 看空者必须跨越的弹性分界线。** Token 支出 = 价格 × 数量。若固定质量 token 的价格下降 10×，而需求的价格弹性为 1.5，则数量增长 10^1.5 ≈ 32×，支出增长 **约 3.2×**。若弹性为 0.8，数量仅增长 10^0.8 ≈ 6.3×，支出反而*降至*约 0.63×（🔴 本资料库测算，见 CS5）。**结论：**看空逻辑并不是“token 变便宜”，而是在成熟工作负载中弹性降至 1 以下。租金反弹表明这种情况尚未发生。

**重要**

**研判 —— 推理商品化。** 可能性 **4** · 影响 **3** · 得分 **12** · 时间窗口 **2026–2029**。价格通缩是确定的；它是否造成伤害取决于弹性，而弹性目前仍高于 1。**关注：**H100 和 B200 租金指数（H100 为 $2.35；跌破 $1.70 低点为警示信号）、固定能力 token 的价格，以及英伟达是否再次披露推理营收占比。

## 风险 4 —— 电力约束

### 🐻 最强看空论证

英伟达交付芯片的速度快于全球建设变电站的速度。英伟达单套系统的功耗在十年间增长约 190×，从 3.2 kW（DGX-1）升至 2027 年 Kyber 机架的约 600 kW [S310,S305]。获取电力的过程很慢：美国项目从提交并网排队申请到投运的中位等待时间超过 48 个月 [S8009]；Dominion 在北弗吉尼亚供电区域内的大型数据中心可能要等待长达七年 [S8010]；ERCOT 跟踪的申请接入大型负荷约 410 GW，其中约 87 % 为数据中心 [S8011]。国际能源署（IEA）预计数据中心用电量将从约 415 TWh（2024）升至 2030 年的约 945 TWh，并指出约 20 % 的规划项目面临延期风险 [S33015]。

价格反映了稀缺程度。在美国最大的数据中心市场 PJM，容量市场价格从每 MW-日 $28.92（2024/25）升至 $333.44（2027/28），三次拍卖上涨约 11.5×，且只是因为协商设定的价格上限才被压住；PJM 估计若无上限将达约 $530 [S18018,S18016,S18017]。该区域距离其可靠性目标还差约 6,600 MW [S18019]。吉瓦级的宣称也在打

折扣：卫星分析发现，一个号称首个吉瓦级集群的园区只有约 350 MW 的冷却能力 S90077；Abilene 扩建项目因融资谈判失败而被放弃 S27001。

**Power per NVIDIA system rose ~190× in a decade: 3.2 kW (DGX-1) to ~600 kW (Kyber)**

Maximum IT power per system or rack, kW · 8/16-GPU DGX servers 2016–2024, NVLink racks from 2024 · hatched = announced/roadmap

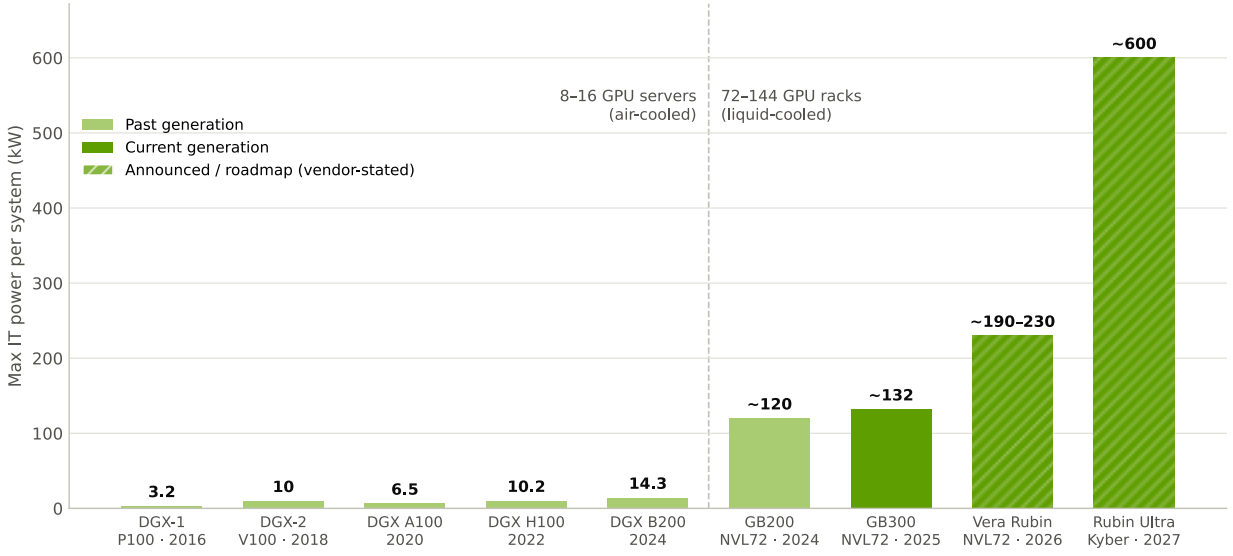


Source: data from NVIDIA, AnandTech, TweakTown, eeNews, Hashrate Index, DCD [S310] [S311] [S125] [S313] [S314] [S315] ...; chart by repo · As of 2026-11-05

英伟达单套系统最大功耗柱状图：DGX-1 为 3.2 kW（2016），DGX-2 为 10 kW，DGX A100 为 6.5 kW，DGX H100 为 10.2 kW，DGX B200 为 14.3 kW；之后的机架级系统 GB200 NVL72 约 120 kW、GB300 NVL72 约 132 kW、Vera Rubin NVL72 约 190-230 kW，Rubin Ultra Kyber 机架约 600 kW，约为 DGX-1 的 190 倍。

**Datacenter electricity could double globally by 2030 and up to triple in the US by 2028**

Annual datacenter electricity use, TWh; solid = estimate of actual, hatched = forecast range (low to high)

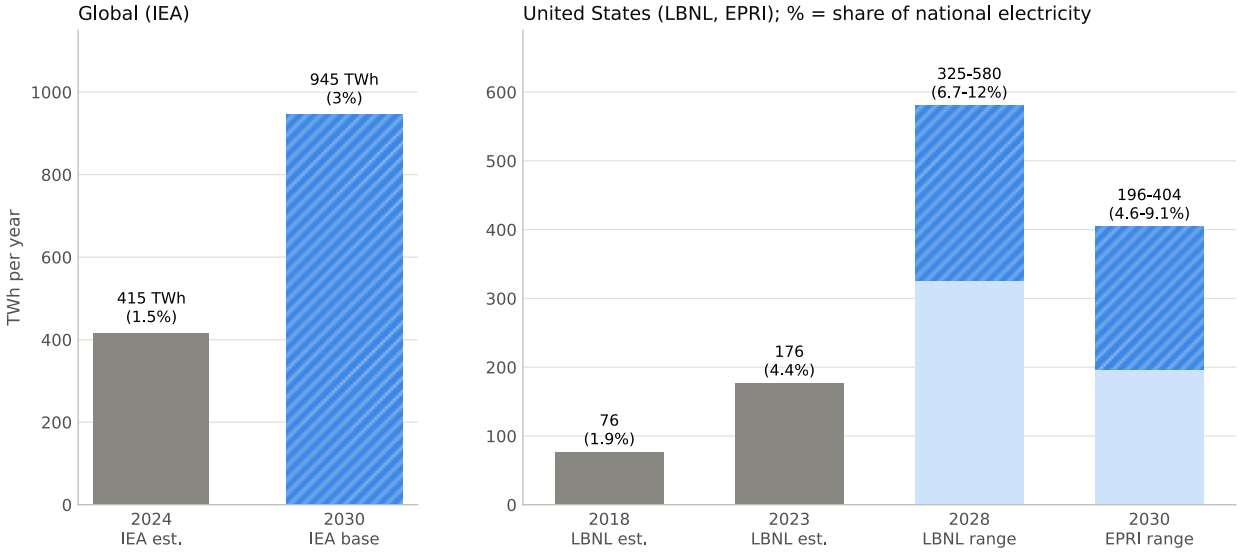


Source: data from IEA Energy and AI (2025); LBNL (2024); EPRI (2024) [S33015] [S33016] [S33017]; chart by repo · As of 2026-11-05

两幅柱状图。全球（IEA）：2024 年约 415 TWh，约占全球用电量的 1.5%，基准情景下 2030 年升至约 945 TWh。美国：2018 年 76 TWh，2023 年 176 TWh（占美国用电量的 4.4%，LBNL）；LBNL 预测 2028 年为 325 至 580 TWh（6.7% 至 12%），EPRI 预测 2030 年为 196 至 404 TWh（4.6% 至 9.1%）。

**PJM's grid-capacity price rose ~11.5× in three auctions as data centers drove demand**

PJM base residual auction clearing price, $ per MW-day of capacity, by delivery year; hatched = PJM's estimate without the negotiated price cap

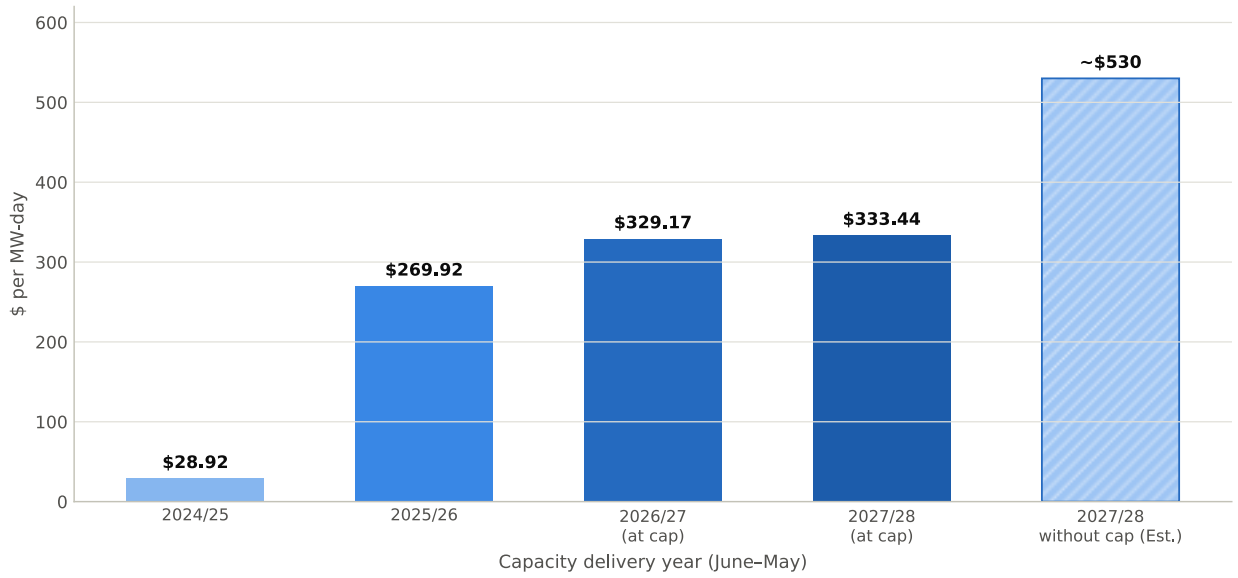


Source: data from PJM, Utility Dive, Citizens Utility Board, Maryland OPC [S18018] [S18016] [S18017] [S18019]; chart by repo · As of 2026-11-05

PJM 容量拍卖每兆瓦日出清价格柱状图：2024/25 为 $28.92，2025/26 为 $269.92，2026/27 为 $329.17，2027/28 为 $333.44，后两次拍卖均触及协商上限，三次拍卖上涨约 11.5 倍。PJM 估计若无上限，2027/28 价格约为 $530；预测负荷增量中约 5,100 MW 与数据中心相关，该区域距离可靠性目标还差约 6,600 MW。

## 🛡️ 英伟达的反驳

电力上限不会削减 AI 预算，而是把预算导向每兆瓦产出最高的方案，这正是英伟达最强的指标。拥有固定 1 GW 电力的买家会追求每兆瓦 token 产出最大化，而 GB300 NVL72 在这一指标上约为 H200 的 13×（估计）[S621,S622]。电费仅占 GPU 年度成本的约 12–19 % [S389,S382]，因此问题在于能否获得电力，而非电价；英伟达正在解决获取问题：约 20 家合作伙伴正在打造 800 V 直流供电设备，MGX 800 VDC 机架将于 2026 年下半年推出，另有用于园区设计的 Omniverse DSX 数字孪生蓝图 [S90061,S90063]。建设方还在采用表后（behind the meter）现场燃气发电，如 Colossus 2 [S8015]。

**提示**

**算例 —— 延后 1 GW 的价值。** 英伟达估计其在 1 GW AI 工厂中的价值含量约为 $35B [S398]。若 2027 年有 5 GW 的建设推迟一年（🔴），约 $175B 的英伟达营收会向后推移，约为 FY2028 指引营收的四分之一。但延后并不等于损失：营收只是晚到，而在供应受限的年份，芯片会流向已经通电的园区。**结论：** 电力是一项时间性风险，对近期损益影响大，对长期价值影响小——除非延期引发订单取消并传导至风险 7。

**重要**

**研判 —— 电力。** 可能性 **4** · 影响 **2** · 得分 **8** · 时间窗口 **2026–2030**。本资料库在此与第 08 层的表述（电力“往往是硬约束”）略有不同：我们同意它约束交付时间，但影响打分更低，因为递延营收并非损失的营收。**关注：** PJM 和 ERCOT 容量价格、排队时间、新兴云服务商已投运与已签约电力之比（CoreWeave 约 1.5 GW 已投运，约 3.7 GW 已签约 [S12010]），以及 GPU 因无电可用而闲置的报道。

# 风险 5 —— 中国与出口管制

## 🐻 最强看空论证

中国曾占英伟达业务的四分之一：按旧的开票地口径，占 FY2022 营收的 26.4 % [S2]。按客户总部所在地口径，FY2025 达到 $25.0B 的峰值，随后在 FY2026 降至 9.1 %，FY2027 各季度为 5.6–8.2 % [S401,S90070,S90069]。这一过程代价高昂：2025 年 4 月的出口管制迫使英伟达计提 $4.5B 的 H20 相关费用，使 GAAP 毛利率降至 60.5 % [S90081,S444]。许可证虽恢复发放，但需向美国政府上缴营收的 15 %（H20），后又提高至 25 %（H200）[S26004,S90032]；北京方面则要求买家避免采购英伟达产品，并禁止国资数据中心使用外国 AI 芯片 [S26006,S26007]。英伟达尚未确认任何 H200 营收，媒体报道称 Q2 FY2027 的中国 H200 销售额不到数据中心营收的 1 % 🟡 [S90081,S26009]。

长期代价是培育出一个受保护的对手。华为昇腾 950 系列将于 2026 年出货，其由 8,192 颗芯片组成的 Atlas 950 SuperPoD 承诺于 2026 年第四季度推出 [S90042,S90043]；DeepSeek V4 部分在昇腾上训练 [S90079]。外溢风险的范围更广：主权 AI 在 FY2026 为英伟达带来超过约 $30B 营收 [S90071]，而 HUMAIN 多达 600,000 颗 GPU 等海湾地区交易 [S13003] 都依赖美国许可证。完整细节见 CS6。

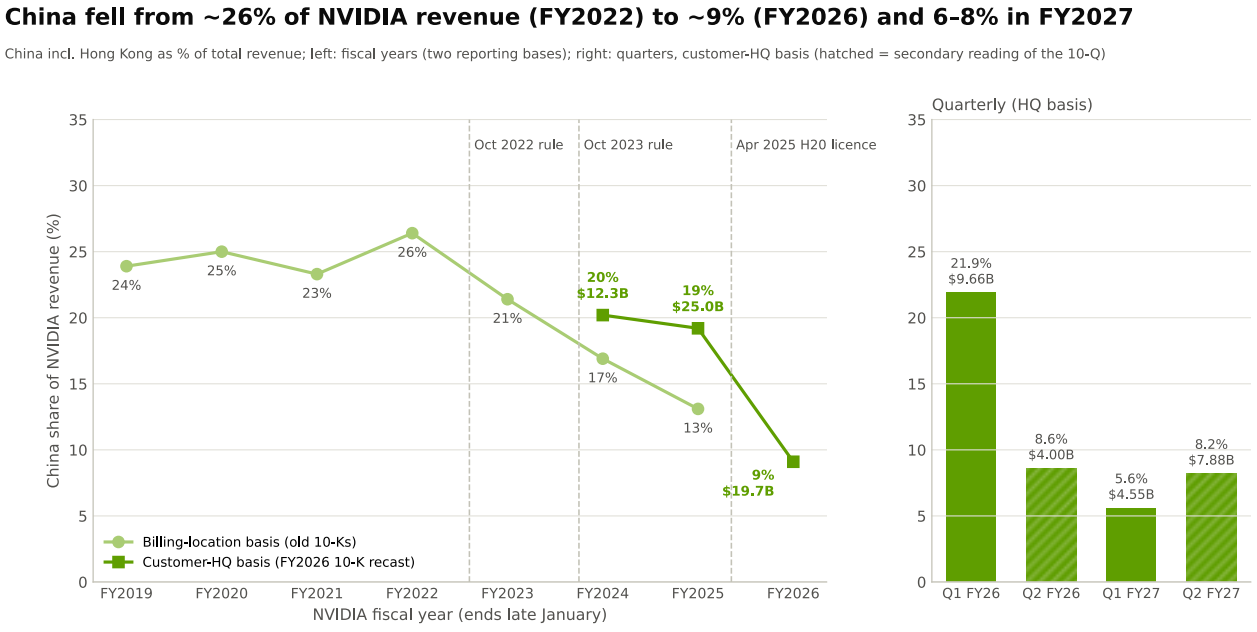


Source: data from NVIDIA 10-K and 10-Q geographic revenue notes [S400] [S2] [S418] [S417] [S416] [S26013] …; chart by repo · As of 2026-11-05

> 中国占英伟达营收比例的双联图。左：按财年、旧开票地口径：FY2019 23.9%、FY2020 25.0%、FY2021 23.3%、FY2022 26.4%、FY2023 21.4%、FY2024 16.9%、FY2025 13.1%；按新的客户总部口径：FY2024 20.2%、FY2025 19.2%（$25.0B，金额峰值）、FY2026 9.1%（$19.7B）。右：按季度、总部口径：Q1 FY2026 为 21.9%，H20 许可证要求出台后 Q2 FY2026 为 8.6%，Q1 FY2027 为 5.6%，Q2 FY2027 为 8.2%（全部平台，含游戏）。

## 🛡️ 英伟达的反驳

损害已经体现在数字中。自 2026 年初以来，业绩指引已不含中国数据中心计算业务 [S405]，因此任何 H200 出货都是上行空间。在中国份额骤降的同时，英伟达 FY2026 总营收仍增长 65 % [S1]。而且由于英伟达供应受限，未卖给中国的晶圆会以相同毛利率卖到其他地方；CS6 的情景分析认为，在这种情况下禁令的成本接近于零，而若产能无法转售，每年毛利润损失最多约 $13B（🔴）。

提示

**算例 —— 上缴比例的代价。** CS6 估计中国数据中心市场规模约为每年 $17.5B（🔴）。按 75 % 毛利率计约合 $13.1B 毛利润；25 % 的营收上缴使实际毛利率降至 50 %，即约 $8.8B。**上缴每年约损失 $4.4B**，约为 FY2028 指引毛利润的 1 %。**结论：**中国现在是一项期权，而非支柱；真正重要的风险是波及海湾地区或其他主权买家的规则。

重要

**研判 —— 中国与出口管制。** 可能性 **4** · 影响 **2** · 得分 **8** · 时间窗口 **2026–2028**。政策会继续变动，但中国仅占营收约 6–9 %，且不在指引之内。若管制扩展至中东，影响将升至 3–4。**关注：**实际确认的 H200 营收、美国商务部工业与安全局（BIS）针对第三国的新规、华为 SuperPoD 出货，以及每份 10-Q 中的中国营收数据。

## 风险 6 —— 反垄断

### 🐻 最强看空论证

有三家监管机构正在审视英伟达的经营行为。中国 SAMR 于 2024 年 12 月立案调查，并于 2025-09-15 发布初步认定，称英伟达违反了 2020 年批准其收购 Mellanox 时附加的条件；可能处以上一年度在华销售额 1–10 % 的罚款 [S9505,S21003]。美国司法部（DOJ）在竞争对手投诉后于 2024 年年中展开调查，随后发出传票；据报道，其关注点在于英伟达加大了客户转换供应商的难度，并惩罚不独家采用其产品的买家 [S9504,S9503]。交易又开辟了新的战线：$12.9B 收购 Hugging Face 可能面临欧盟审查，且据报道已引起 DOJ 关注 🟡 [S11027,S11028]；参议员 Warren 和 Blumenthal 质疑约 $20B 的 Groq“授权加招聘”交易是在规避并购审查，美国联邦贸易委员会（FTC）表示将审视此类交易结构 [S13511]。

更深层的风险敞口在于经营行为。供应短缺时，分配权就是权力：据报道 DOJ 的关注点直接对应谁能率先拿到 Rubin。英伟达还以机架形式销售，GPU、NVLink 交换机、网卡和软件打包交付，这是监管机构十分熟悉的搭售（tying）模式；同时英伟达现持有客户和合作伙伴约 $99B 的股权 [S90072]。若出台强制拆分定价或中立分配的行为性救济措施，将波及占数据中心营收约 20 % 的网络业务 [S90012]。

### 🛡️ 英伟达的反驳

市场看起来具备可竞争性：TPU、Trainium、Maia、MTIA，以及 AMD 与 OpenAI、Meta 各 6 GW 的交易都已存在，因此风险 2 恰恰是英伟达最好的反垄断抗辩 [S653,S546,S24004]。英伟达也在走向开放：它开源了 Run:ai 和 KAI 调度器 [S12510]，以 Apache 2.0 许可发布 Dynamo [S90066]，通过 NVLink Fusion 向第三方芯片开放 NVLink [S131]，作为创始成员加入 ESUN [S576]，并承诺 Hugging Face 不会强制要求使用英伟达芯片 [S11026]。Run:ai 收购在获得欧盟批准后完成交割 [S476]。

提示

**算例 —— 罚款规模与救济措施规模之比。** SAMR 的罚款上限为上一年度在华销售额的 10 %：10 % × $25.0B（FY2025）= **$2.5B** [S9505,S401]，约为单季净利润 $59.7B 的 4 % [S405]。若救济措施使网络产品的搭配率下降四分之一，将影响约 $17.5B × 25 % ≈ **每季度 $4.4B 营收**（🔴）[S90012]。**结论：**罚款只是噪音；针对捆绑销售或产能分配的行为性救济，才是这项风险中值得建模的版本。

**重要**

**研判 —— 反垄断。** 可能性 **3** · 影响 **2** · 得分 **6** · 时间窗口 **2026–2028**。SAMR 处罚很可能发生但金额小；美国或欧盟的行为性救济可能性较低但影响更大。**关注：** SAMR 的处罚决定、DOJ 对 Hugging Face 交易发出第二次信息请求或欧盟启动第二阶段审查、任何关于产能分配或捆绑销售的投诉，以及 FTC 对“授权加招聘”类交易采取的行动。

## 风险 7 —— 循环融资与资本开支周期

这是影响得分最高的风险，因为一旦下行，营收、承诺和持股会同时受到冲击。

### 🐻 最强看空论证

**资本开支规模史无前例。** Alphabet、亚马逊和 Meta 在 2022 年合计支出 $127B，最初对 2026 年的指引约为 $505B，此后上调至约 $558B [S12518,S12519,S455,S456,S457,S460,S461,S462]；到 2026 年年中，其指引已逐步上调至约 $558B，若计入微软则约为 $728B [S12518,S12519]。预测机构认为 2027 年将接近或超过 $1T [S18023]，仅 Alphabet 的 2027 年一致预期就达 $311.8B，而 2025 年为 $91.4B [S18022]。收入增长并未跟上：贝恩（Bain）估计，到 2030 年 AI 每年需要约 $2T 的收入才能支撑其算力投入，缺口约 $800B [S18024]。OpenAI 在 2026 年初的年化收入约为 $25B，其指引到 2030 年的算力支出约为 $600B，低于 2025 年约 $1.4T 的承诺口径 [S18026,S18025]。

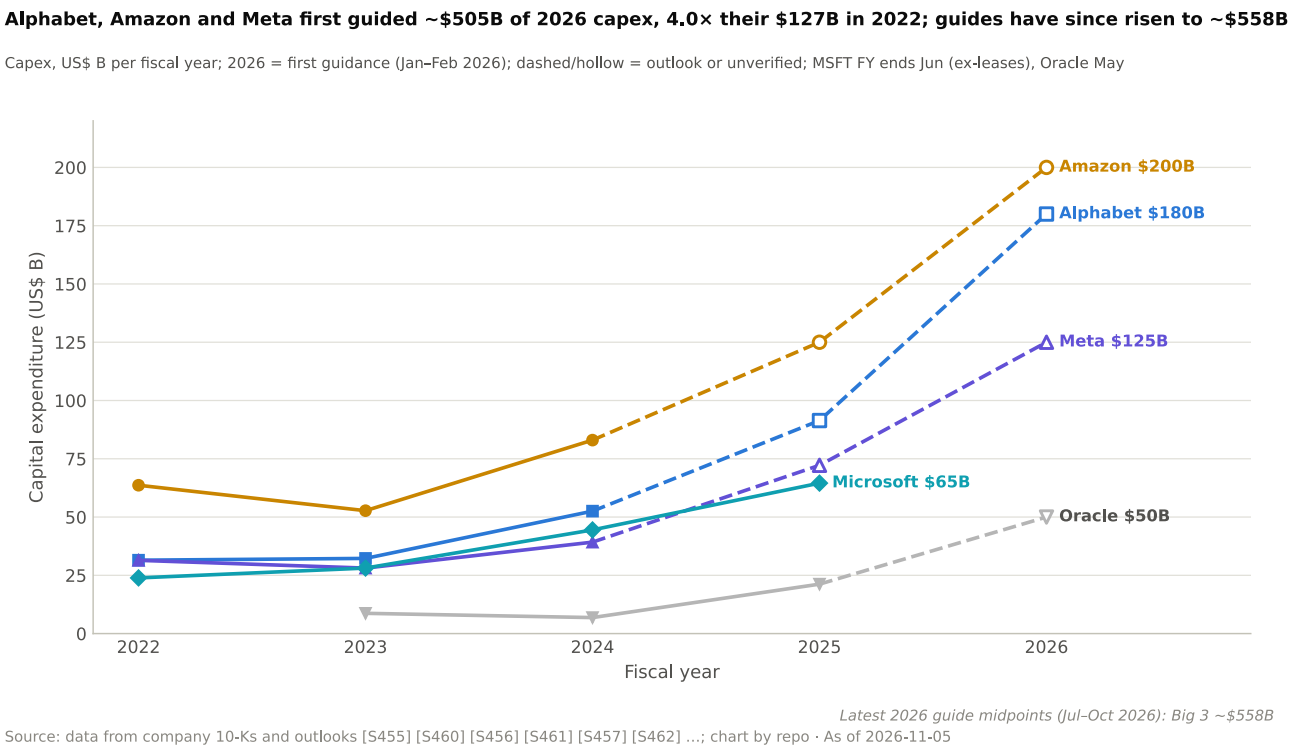


2022–2026 年超大规模云厂商资本开支折线图：Alphabet、亚马逊和 Meta 合计从 2022 年的 $127B 升至其最初 2026 年指引的约 $505B（亚马逊约 $200B，Alphabet 中值约 $180B，Meta 中值约 $125B），到 2026 年 10 月上调至约 $558B；微软 FY2025 达到 $65B，甲骨文对 FY2026 的指引约为 $50B。

**英伟达为自身需求提供了部分资金。** 这是循环融资批评的核心。截至 2026 年 7 月，英伟达的股权投资达到约 $99B（CNBC 汇总了 10-Q 中三个资产负债表科目）[S90073]；H1 FY2027 股权购买额为 $42.4B，上年同期为 $1.2B；H1 净股权收益 $23.7B，相当于 H1 净利润 $118B 的约 20 % [S90072,S90069,S403,S405]。最大的持股都投向客户：对 OpenAI 约 $30B，对 Anthropic 最多 $10B [S90015,S90075]。英伟达还为需求兜底：到 2032 年，它将购买 CoreWeave 最多 $6.3B 的未售出算力 [S90067]（算力兜底），并持有 $36B 的 AI 云算力协议和 $29B 的

云服务协议 [S407]。2026 年 8 月，英伟达与 Apollo、贝莱德（BlackRock）、黑石（Blackstone）、Brookfield、高盛（Goldman Sachs）和 KKR 共同设立平台，动员超过 $500B 的第三方资本 [S12528]，将风险转移到以 GPU 为抵押的信贷中。

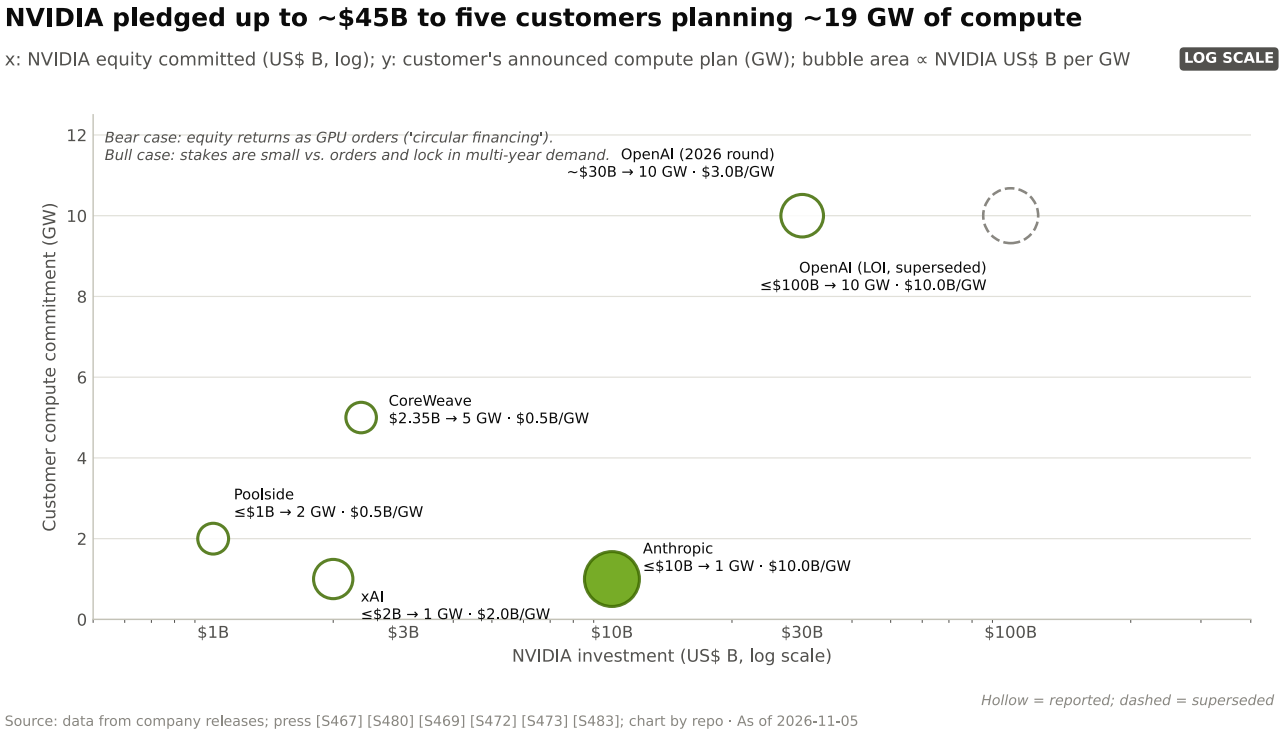


英伟达对客户投资的气泡图：OpenAI（2026 年约 $30B，此前为与 10 GW 挂钩、最高 $100B 的意向书）、Anthropic（最多 $10B，最多 1 GW）、CoreWeave（$2.35B 股权，>5 GW 规划）、xAI（最多 $2B，约 1 GW）和 Poolside（最多 $1B，2 GW）。合计约 $45B，对应约 19 GW，这是循环融资争论的核心。

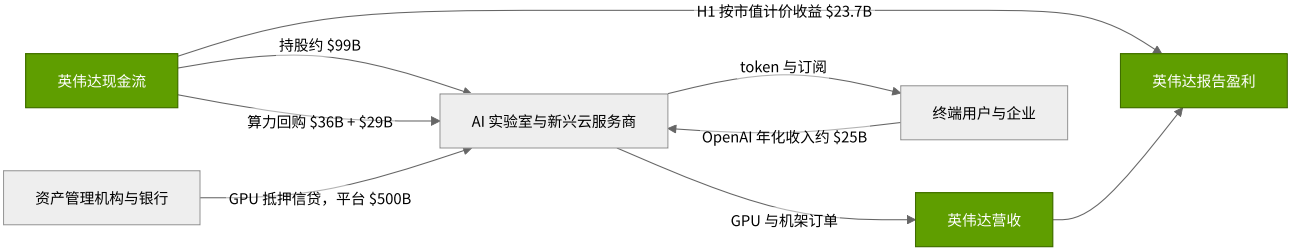


**供给侧会放大下行。** 英伟达的采购义务（供应与产能承诺）达到 $279B，上一季度为 $119B：相当于季度营收的 2.9×，而 FY2023 库存减记之前约为 1.4× [S407]。Michael Burry 在 2 月称 10-K 中 $95B 的采购义务“令人不安” [S431]；10-Q 中的 $279B 是一个口径更宽的科目，因此可比口径的增长是一个季度内从 $119B 增至 $279B [S90092]。在下游，CoreWeave 计划 2026 年资本开支 $35–39B，而营收为 $12.4–13.2B [S12500]；超大规模云厂商按 5.5–6 年对服务器计提折旧，而英伟达每年都推出新架构（使用寿命） [S382,S385]。

**Supply commitments hit $279B: 2.9× quarterly revenue vs ~1.4× before the 2022 bust**

Left: purchase/supply commitments vs inventory, US$ B at quarter end. Right: commitments ÷ that quarter's revenue

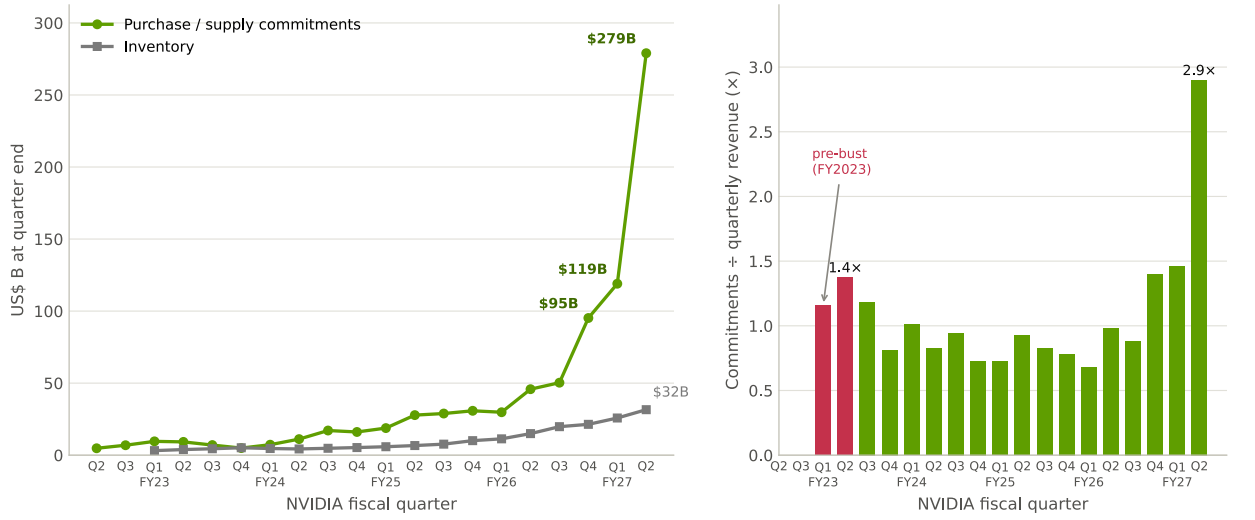


Source: data from NVIDIA 10-Q/10-K [S420] [S421] [S432] [S433] [S434] [S435] ...; chart by repo · As of 2026-11-05

双联图。左：英伟达采购义务从 Q2FY22 的 $4.8B 增至 Q2FY27 的 $279B，库存达到 $31.6B。右：FY2023 库存减记之前，承诺约为季度营收的 1.4 倍，现为 2.9 倍，主要是面向 Rubin 的内存与产能。

**电信业的先例近得令人不安。** 朗讯的供应商融资承诺在 1999–2000 年达到 $8.1B，约占其 $33.6B 营收的 24 % [S18007]。随着周期破裂，北电（Nortel）的融资协议从 2000 年的 $5.2B 降至 2001 年的 $2.1B [S18008]。思科（Cisco）在整个 2000 年都表示需求“持续超出我们的预期”，随后却给出营收环比下降约 30 % 的指引，并在 FY2001 第三季度计提 $2.25B 的过剩库存费用 [S18010,S18009]。英伟达 H1 FY2027 的股权购买额占营收的比例，现已与朗讯的峰值比例相当。

**H1 FY2027 equity buying was 24% of NVIDIA revenue, Lucent's ratio at the 2000 peak**

Financing extended to (or stakes held in) customers as % of revenue; Lucent 1999–2000 vs NVIDIA measures at July 2026 (LTM = last four quarters, $303B)

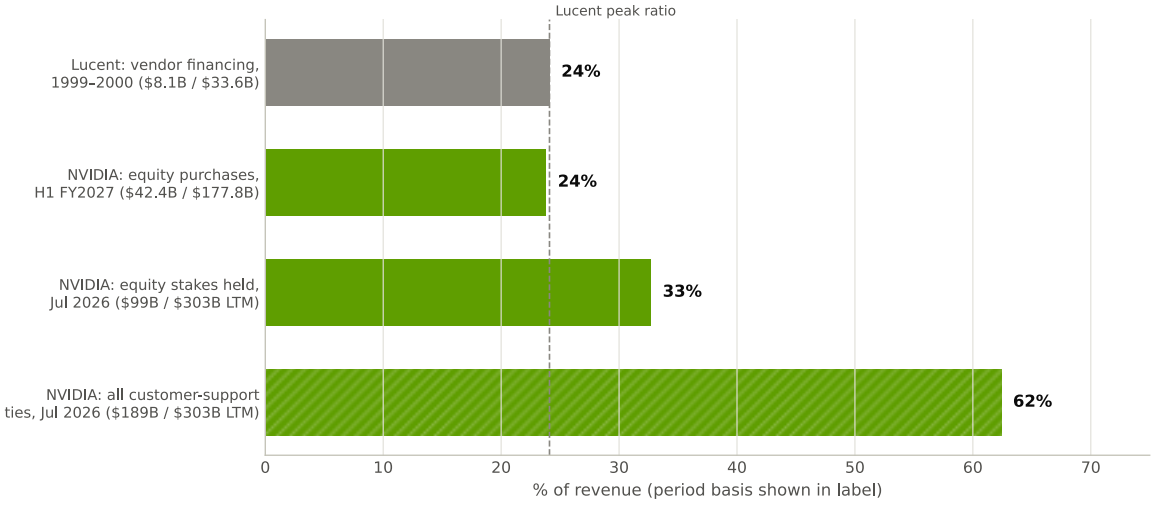


Source: data from Tunguz (Lucent), NVIDIA 10-Q readings, repo calculation [S18007] [S90072] [S403] [S405] [S90073] [S446] ...; chart by repo · As of 2026-11-05

客户融资占营收比例的横向柱状图。朗讯 1999-2000 年的供应商融资承诺为 $8.1B，占 $33.6B 营收的 24%。英伟达 H1 FY2027 股权证券购买额为 $42.4B，占 $177.8B 半年营收的 24%；其约 $99B 的持股相当于过去四个季度 $303B 营收的 33%；所有客户支持性关联（持股、后续股权承诺、AI 云算力协议和云服务协议，约 $189B）相当于 62%。英伟达以经营现金流为这些投入提供资金，而朗讯则是向资本薄弱的电信运营商放贷。

## 英伟达的反驳

英伟达自己的回应很简短：“与朗讯不同，英伟达并不依赖供应商融资安排来实现营收增长” [S18007]。数据部分支持这一说法。英伟达用经营现金流（仅 Q1 FY2027 就达 $50.3B）为其持股提供资金 [S403]，而非借债。

其最大的买家（超大规模云厂商，约占数据中心营收的 55 %）以自身经营现金流付款 S90011。与 OpenAI 的交易已从与部署挂钩、$100B 的意向书，重组为不设部署里程碑、约 $30B 的直接股权投资 🟡 S90015,S90016，这削弱了“以投资换订单”的关联。2026 年 8 月设立的平台让第三方资本而非英伟达的资金支撑未来的建设 S12528。需求信号依然紧俏：H100 租金较 2025 年 10 月低点上涨 38 % S12516，CoreWeave 的未交付订单为 $104.2B S12500，英伟达估计到 2027 年 Blackwell 加 Vera Rubin 的需求规模达 $1T S90001。正是这些供应承诺，才让英伟达在 FY2028 有可能实现约 70 % 的增长 S18000。

| 特征 | 电信业 1999–2001 | 英伟达 2026 | 类比是否成立? |
|---|---|---|---|
| 客户融资占营收比例 | 朗讯约 24 % S18007 | 股权购买约占 H1 营收的 24 %；所有关联约占过去十二个月营收的 62 % S90072,S407 | 🟥 规模上成立 |
| 谁在借钱 | 依靠高收益债的初创电信运营商 | 以现金流付款的超大规模云厂商；依靠股权与 GPU 抵押信贷的 AI 实验室和新兴云服务商 | 🟨 部分成立：新兴云服务商和 AI 实验室与当年的运营商相似，超大规模云厂商则不然 |
| 供应商的资金来源 | 债务与担保，部分在表外 | 经营现金流；第三方平台 S403,S12528 | 🟩 不成立 |
| 过度建设后的资产寿命 | 光纤可用数十年，过剩产能多年压制价格 | GPU 在 3–6 年内折旧完毕；过剩产能消化更快 S382,S385 | 🟨 周期更短但更剧烈 |
| 当时的价格信号 | 带宽价格崩溃 | H100 租金自 2025 年 10 月以来 +38 % S12516 | 🟩 尚不成立 |
| 供应商承诺 | 思科库存费用 $2.25B S18009 | 承诺 $279B，为季度营收的 2.9× S407 | 🟥 成立；规模更大 |

**提示**

**算例 —— 2001 年式的压力测试。** 假设（🔴）季度营收从 Q3 FY2027 指引的 $108B 下降 40 %，至约 $65B。届时 $279B 的承诺将相当于约 4.3 个季度的营收。若其中 5 % 变为过剩（如 H20 的情况），相关费用约为 **$14B**；约 $99B 持股的价值下跌 30 %，将通过其他收益再带来约 **$30B** 损失 S407,S90072。两者合计约 $44B，约为最近一个季度净利润（$59.7B）的四分之三 S405。**结论：**英伟达的资产负债表能轻松扛过这一冲击，但其盈利和估值倍数扛不住，因为营收下滑、费用计提和按市值计价损失会在同几个季度集中出现。

**🔧 技术细节：融资如何美化报告业绩**

有三条会计路径值得关注。(1) **持股收益。** 英伟达上市持股的价值变动，以及私募持股在新一轮融资定价时的重新计量，都计入“其他收益”，因此火热的一级市场会在没有卖出任何产品的情况下推高净利润；这也是本资料库跟踪净股权收益占净利润比例（H1 FY2027 约 20 %）的原因。(2) **支付给客户的对价。** 根据收入确认准则，供应商返还给客户的价值（返利、抵扣，以及部分算力采购）可能被视为营收的减项而非费用，除非它以公允价值换取了可明确区分的商品或服务。英伟达购买自己无法转售的算力的那些算力协议，是附注中需要细读的科目。(3) **承诺。** 供应与产能承诺在货物到达前不计入资产负债表；如果需求下降，过剩部分会变成库存或采购义务相关费用，正如 $4.5B 的 H20 费用所示 S90081。以上均不意味着存在错报，而是说明报告数字的周期性比营收这一行所显示的更强。

**重要**

**研判 —— 循环融资与资本开支周期。** 可能性 **3** · 影响 **5** · 得分 **15** · 时间窗口 **2027–2029**。这一类比在规模和供应商承诺上成立，在资金质量上不成立。资本开支周期终会转向；问题在于 2028 年是暂停还是削减。**关注：**超大规模云厂商资本开支指引的二阶导数（首次同比削减）、承诺 ÷ 季度营收（2.9×）、股权购买 ÷ 营收（约 24 %）、净股权收益 ÷ 净利润（约 20 %）、H100 租金指数，以及新兴云服务商的融资成本。

# 风险 8 —— 台积电与台湾集中度

## 🐻 最强看空论证

英伟达每一颗数据中心 GPU 裸片都由台积电（TSMC）制造，并采用 CoWoS 封装，而全部 CoWoS 产能都在台湾 [S18012]。Rubin 本身采用台积电 3 nm 工艺（据报道为 N3P）[S100,S35015]。英伟达预订了 2026 年约 60 % 的 CoWoS 晶圆（估计）[S379]，并成为台积电最大客户，约占其 2025 年营收的 19 %（约 $23.2B）[S18015]。多元化进展缓慢：台积电于 2025-10-17 在亚利桑那州生产出首片 Blackwell 晶圆 [S18013]，但这些晶圆仍需空运回台湾封装 [S18012]；亚利桑那州封装厂的目标是 2029 年，与 Amkor 的合作目标是 2028 年 [S18014]。内存带来了第二重集中：预计 SK 海力士将供应英伟达 2026 年一半以上的 HBM [S90039]。

急性情景是封锁或冲突。彭博经济研究估计，为期一年的封锁将在第一年使全球 GDP 减少约 5 %，战争则减少约 10.2 %，约 $10T [S18011]。在英伟达的量级上，先进制程逻辑加 CoWoS 不存在第二供应来源，因此在冲击持续期间其出货将停止。慢性情景是供应商的定价权：据报道台积电将 N3P 价格上调约 20 % [S35037]，N2 定价约每片晶圆 $30,000 [S35003]；美光（Micron）的毛利率（86.8 %）现已超过英伟达（75.0 %）[S3533,S405]；英伟达以内存成本为由，将 Q4 FY2027 毛利率指引下调至 71–72 %，FY2028 为 72–73 % [S18000,S18002,S18001]。Rubin 的 HBM4 带宽从 22 TB/s 下调至 19.2 TB/s，表明供应商如今也在影响英伟达的产品规格 [S90006]。

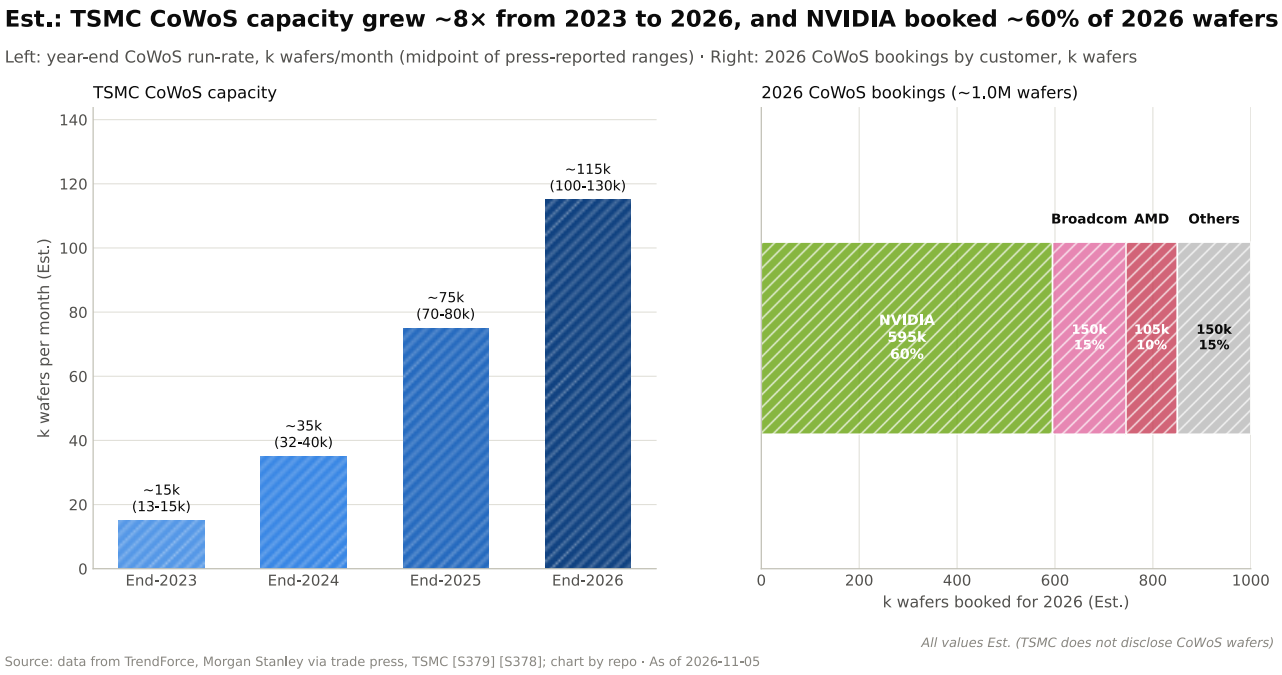


> 估计数据双联图。左：台积电 CoWoS 产能 2023 年底约每月 15k 片晶圆，2024 年 35k，2025 年 75k，2026 年约 115k，增长约 8 倍。右：2026 年约 1,000k 片 CoWoS 晶圆需求中，英伟达约 595k（60%），博通 150k，AMD 105k，其他约 150k。

## 🛡️ 英伟达的反驳

台湾是系统性风险，而非竞争性风险。AMD、博通的 TPU 与 OpenAI 项目、Trainium 和 Maia 都依赖同样的晶圆厂和封装线，因此一旦出现中断，份额不会转移到对手手中；买家将无处可去。作为锚定客户，英伟达优先获得产能分配；据报道，相关计划将使 CoWoS 产能到 2028 年达到约每月 260k 片晶圆，为 2023 年底的约 17× [S3002]。亚利桑那州晶圆（2025）和美国本土封装（2028–2029）将随时间推移减少单点故障。就慢性风险而言，英伟达的指引已假设提价，从而在 FY2028 让毛利率回升 [S18000]。

提示

**算例 —— 缓冲能维持多久。** 按 Q3 FY2027 指引（营收 $108B，毛利率 74 %），季度销售成本约为 $28B [S18000]。英伟达在 Q2 FY2027 末持有 $31.6B 库存 [S407]，约为 1.1 个季度的销售成本，其中一部分是在制品。**结论：**短于约一个季度的中断可以靠库存撑过去；更长的中断则是全行业的供给冲击，届时英伟达的相对地位不变，但绝对营收会受损。

重要

**研判 —— 台积电与台湾。** 可能性 **1**（急性）· 影响 **5** · 得分 **5** · 时间窗口 **随时**。这是需要对冲的尾部风险，而非基准情景。来自台积电和内存厂商的慢性毛利率挤压若单独计分，约为 4 × 2。**关注：**亚利桑那州 CoWoS 与 Amkor 的时间表、台积电晶圆涨价、HBM 合约价格，以及毛利率指引。

## 风险 9 —— 开放互连标准

### 🐻 最强看空论证

纵向扩展（scale-up）曾是英伟达最封闭的一层，如今正被标准化。UALink 2.0 于 2026-04-07 获批，涵盖网内计算、芯粒定义和 200G 链路；UALink 1.0 芯片于 2026 年下半年进入实验室，产品预计 2027 年推出 [S90050,S574,S90051]。其联盟拥有超过 65 家成员，董事会成员包括 AMD、AWS、谷歌、Meta、微软和苹果 [S5520,S5521]。以太网则从另一侧进攻纵向扩展：ESUN 于 2026 年 3 月发布 1.0 规范 [S576]，Ultra Ethernet 继 2025 年 6 月发布 1.0 之后 [S257]，1.1 版已扩展至纵向扩展 [S575]。AMD 的 Helios 已通过基于以太网的 UALink 和博通交换机连接 72 颗 GPU，带宽约 260 TB/s [S226,S5523,S5524]；在 Rubin 规格下调之后，Helios 每颗 GPU 的带宽为 3.6 TB/s，而 Rubin 为 3.0 TB/s [S226,S201]。在横向扩展领域，转变已经发生：2026 年第一季度，以太网约占 AI 后端交换机销售额的三分之二，且一家白牌厂商位居厂商排名首位 [S90054]。

受影响的是英伟达的网络业务（每季度约 $17.5B，约占数据中心营收的 20 % [S90012]），以及让英伟达能够按系统而非按芯片定价的机架级捆绑。详见第 05 层和第 06 层。

**AMD's Helios (3.6 TB/s per GPU) now out-specs NVIDIA Rubin's production NVLink 6 (3.0 TB/s)**

Scale-up bandwidth per accelerator, bidirectional TB/s. Google, AWS and Huawei next-gen parts: 2.0–2.4 TB/s

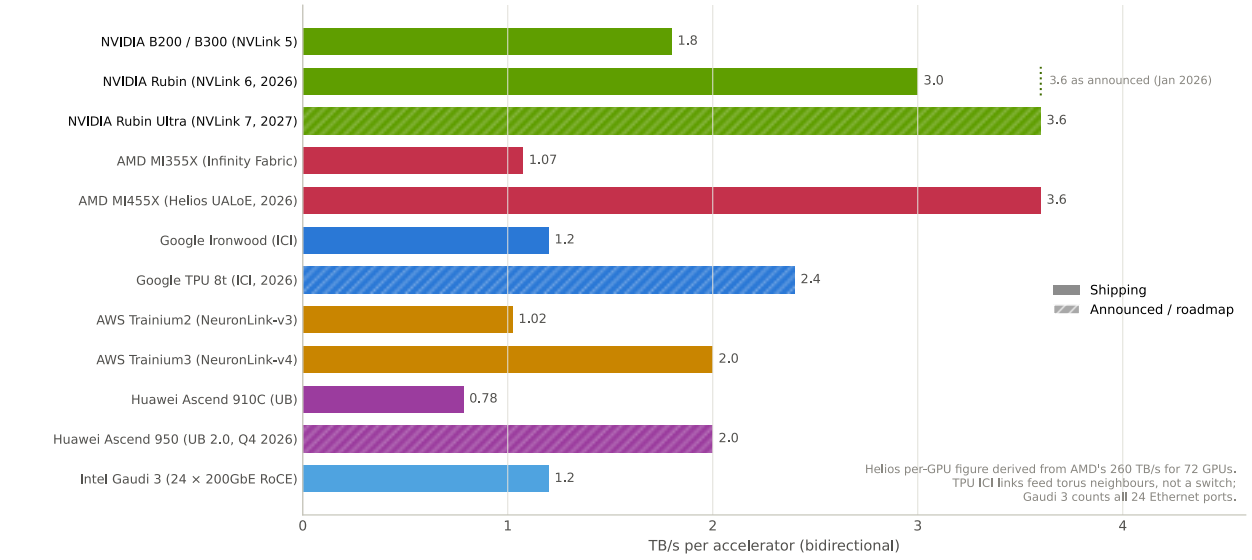


Source: data from NVIDIA, AMD, Google, AWS, Huawei, Intel; SemiAnalysis [S200] [S262] [S263] [S201] [S202] [S33004] ...; chart by repo · As of 2026-11-05

> 每颗加速器纵向扩展带宽横向柱状图：英伟达 Blackwell 1.8 TB/s、Rubin 3.0 TB/s（由 3.6 TB/s 下调）、Rubin Ultra 3.6 TB/s（路线图）；AMD MI355X 1.1 TB/s、MI455X 3.6 TB/s；谷歌 Ironwood 1.2 TB/s、TPU 8t 2.4 TB/s；AWS Trainium2 1.0 TB/s、Trainium3 2.0 TB/s；华为昇腾 910C 0.8 TB/s、昇腾 950 2.0 TB/s；英特尔 Gaudi 3 1.2 TB/s。

## 🛡️ 英伟达的反驳

英伟达在开放网络中同样胜出：Spectrum-X 以太网在 Q2 FY2027 同比增长 2.6× [S408]。它正把纵向扩展的威胁转化为授权业务：NVLink Fusion 的合作伙伴包括高通（Qualcomm）、富士通、英特尔，以及用于 Trainium4 的 AWS，且每套系统中都有英伟达芯片 [S131,S518]。NVLink 已发展到第六代，拥有经过验证的铜缆背板，而开放互连架构大约落后两年，这也是第 05 层的结论。此外，英伟达还作为创始成员身处 ESUN 之中 [S576]。

**提示**

**算例 —— 网络份额流失的代价。** 数据中心约占营收的 93 % [S405]；按 FY2028 指引路径约为 $648B（🔴）。若开放互连使英伟达网络业务的占比从约 20 % 降至约 15 %，将减少约 $32B 营收，按公司平均 72.5 % 毛利率计约合 $23B 毛利润，约占总额的 5 %。**结论：**这是真实但次要的损失，因此影响打 2 分；更大的影响在于失去机架捆绑这一定价工具。

**重要**

**研判 —— 开放互连。** 可能性 **3** · 影响 **2** · 得分 **6** · 时间窗口 **2027–2029**。与第 05 层的结论一致：NVLink Fusion 的窗口期就是现在；一旦 UALink 交换芯片大规模出货，标准的冲击就会显现。**关注：**UALink 交换芯片出货、Helios 在 Azure、OpenAI 和甲骨文的部署、英伟达网络业务增速与计算业务增速之比，以及 NVLink Fusion 的设计导入。

# 风险 10 —— 软件抽象层侵蚀 CUDA

## 🐻 最强看空论证

CUDA 护城河是为程序员手写内核的世界而建的，而那个世界正在消退。PyTorch 在主代码树中原生支持 CUDA、ROCm 和 Intel XPU 构建 [S587]；torch.compile 生成 Triton 代码 [S9021]，而 Triton 可在 AMD GPU 上运行 [S578]；Meta 的 MTIA 编译器基于 TorchInductor 和 Triton 构建 [S9028]；谷歌的 JAX 可运行在英伟达 GPU、TPU 上，并可通过 AMD 支持的插件运行在 AMD GPU 上 [S577]；vLLM 可在六类硬件上提供推理服务 [S580]。AMD 相对 CUDA 的滞后从约 8.8 年（平台 1.0）缩短到约 8 个月（FP4），再到可用部署 DeepSeek-V4-Pro 仅滞后 26 天 [S586,S631]。高通于 2026-07-29 完成对 Modular 约 $3.9B 的收购，并以 Apache 2.0 许可开源 Mojo [S9511,S9512]。如今 AI 已能自己写内核：字节跳动 Seed 与清华大学的一个智能体系统报告称，在 KernelBench 三个难度级别的任务上，分别有 100 %、100 % 和 92 % 胜过 torch.compile [S18020]；AMD 和 Anthropic 表示，它们使用 Claude 在 Instinct 上优化工作负载 [S9538]。

本资料库对前沿实验室的 CUDA 锁定程度仅打 2.75/5 分，对中国实验室打 2.5 分，而对企业客户打 4.5 分（🔴）。资金最雄厚的买家恰恰锁定程度最低。见第 09 层。

**Est.: CUDA lock-in is strongest in academia (4.75/5), weakest for Chinese labs (2.5)**

Repo scoring of switching cost off CUDA, 1 (can move within months) to 5 (prohibitive), by customer segment and workload - speculative

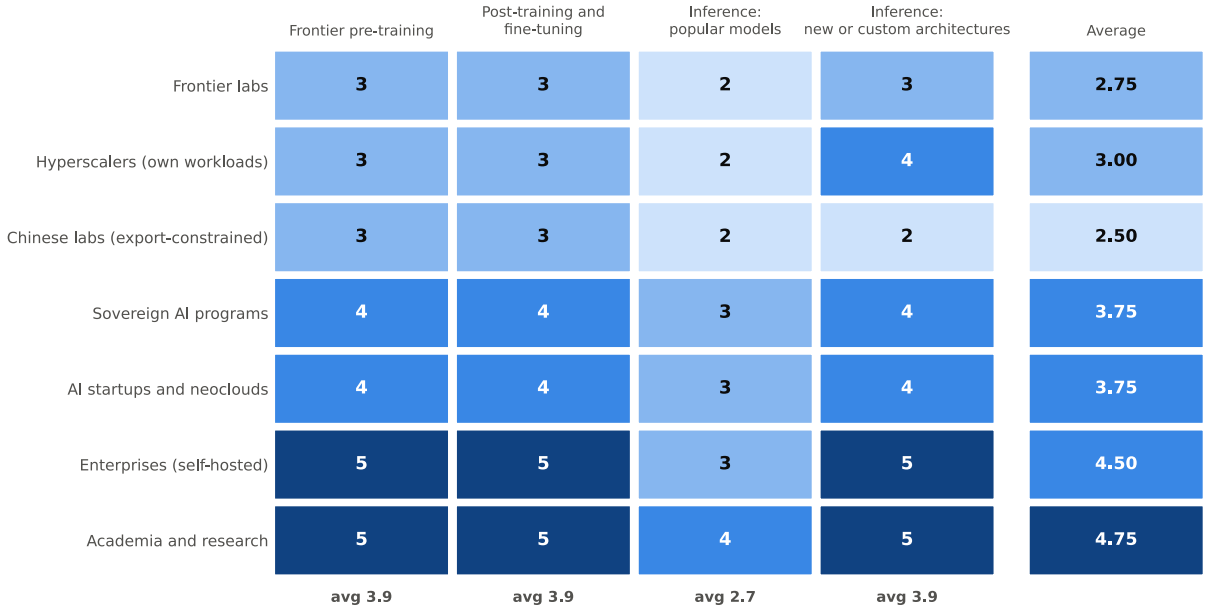


Source: data from repo judgement; lab and benchmark disclosures [S653] [S656] [S546] [S655] [S625] [S628] ...; chart by repo · As of 2026-11-05

> 热力图：在四类工作负载上，对七个客户群体的 CUDA 锁定程度按 1 至 5 打分。平均分：学术界 4.75、企业 4.50、主权 AI 3.75、初创公司与新兴云服务商 3.75、超大规模云厂商 3.00、前沿实验室 2.75、中国实验室 2.50。热门模型推理是最弱的一列（平均 2.7），而预训练和新架构约为 3.9。

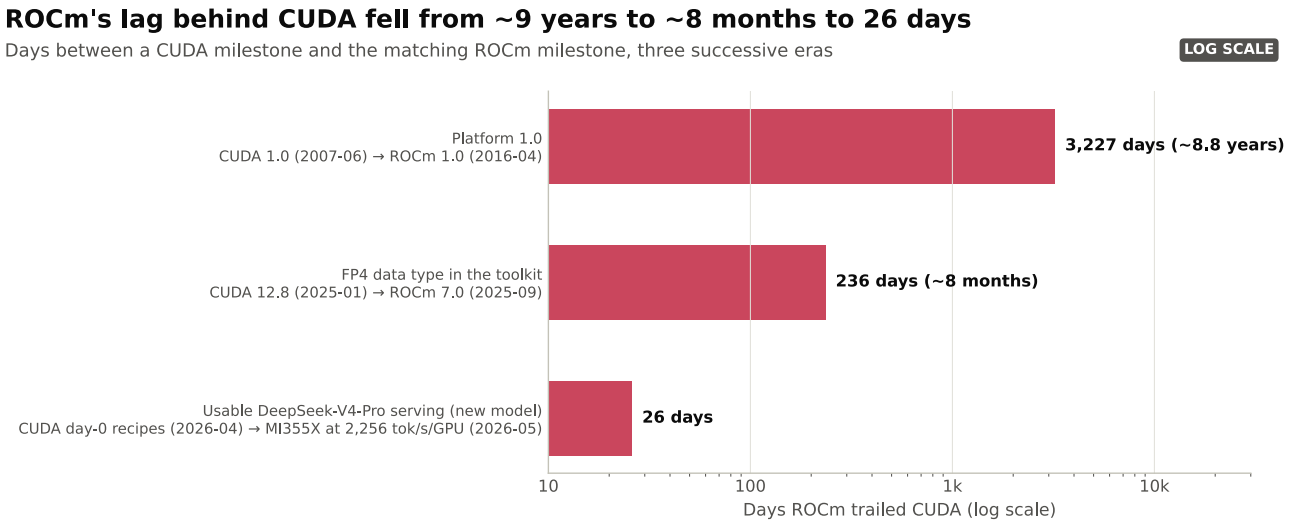


Source: data from CUDA/ROCm release histories; SemiAnalysis InferenceX [S525] [S586] [S524] [S90064] [S633] [S631]; chart by repo · As of 2026-11-05

AMD ROCm 落后英伟达 CUDA 程度的对数坐标横向柱状图：平台 1.0 晚了 3,227 天（约 8.8 年）（2007 年 6 月对 2016 年 4 月）；FP4 支持晚了 236 天（约 8 个月）（2025 年 1 月的 CUDA 12.8 对 2025 年 9 月的 ROCm 7.0）；DeepSeek-V4-Pro 的可用推理部署比 CUDA 首日方案晚 26 天（2026 年 4 月至 5 月）。每次差距大约缩短为上一次的十分之一，但每个新模型推出时差距仍会重现。

### 英伟达的反驳

抽象层缩小了差距，但并未消除差距。在本资料库跟踪的全部 12 个主要框架与引擎中，CUDA 均为原生支持（36/36），ROCm 为 26 [S587,S580,S586]。DeepSeek-V4-Pro 在首日（day 0）即可在 CUDA 上运行；MI355X 花了 27 天才达到每用户 50 tokens/s，且仍比 B200 慢约 5× [S633,S631]。内核生成的说法存在争议：经过校验的 KernelBench 版本发现，原版低估了 PyTorch 的速度，而且许多生成的内核在张量形状变化时就会失效 [S18021]。英伟达还在用 cuTile 和 CuTe DSL 在 Python 中迎合开发者 [S9007,S9030]；而且能写内核的 AI 智能体同样能写 CUDA 内核。

**提示**

**算例 —— “时间税”到底有多大。** 假设（🔴）一个 AMD 集群每颗 GPU 的成本是英伟达的一半，一年中大部分时间提供相同的 token 产出，但在每个重大模型发布后的第一个月慢 5×（DeepSeek-V4 的模式 [S631]）。其每 token 成本在 11 个月中为英伟达的 0.5×，在一个月中为 2.5×：$(11 \times 0.5 + 1 \times 2.5) \div 12 \approx \mathbf{0.67}\times$。**结论：**在价格差距较大时，CUDA 时间税救不了英伟达；只有在英伟达成本溢价较小，或抢先上线的价值高于一个月廉价 token 的场景下，它才能保护英伟达。这正是护城河在企业客户中最强、在 AI 实验室中最弱的原因。

**重要**

**研判 —— CUDA 被侵蚀。** 可能性 **3** · 影响 **3** · 得分 **9** · 时间窗口 **2027–2030**。与第 09 层的结论一致：护城河是每次模型发布时缴纳的时间税，而且正在缩小。**关注：**新开源模型在 AMD 和 TPU 上的首日支持、ROCm 与 TPU 在 vLLM/SGLang 部署中的占比、高通旗下 Mojo 的采用情况，以及前沿实验室的芯片组合。

## 看空情景成立需要满足哪些条件

看空情景是一组条件，而非一种情绪。下表列出需要发生的事件、各项条件目前的状态，以及本资料库对其可能性的判断。

| # | 条件 | 当前状态（2026 年 11 月） | 看空阈值 | 至 2028 年的可能性（🔴） |
|---|---|---|---|---|
| 1 | 超大规模云厂商资本开支停止增长 | 三大厂商 2026 年指引约 $558B；2027 年预测接近 $1T S12518,S18023 | 首次给出资本开支同比削减的指引 | 2027 年低，2028 年中等 |
| 2 | 定制芯片拿走增量 | 博通 AI 营收 ≈ 英伟达数据中心营收的 19 % S2516 | > 25 %，且与 Meta 达成商用 TPU 交易 | 中等 |
| 3 | 毛利率重置 | 目前 75.0 %；FY2028 指引 72–73 % S405,S18000 | 剔除一次性费用后连续数个季度 < 65 % | 中等 |
| 4 | Token 需求变得缺乏弹性 | H100 租金自 2025 年 10 月以来 +38 % S12516 | 租金指数跌破 $1.70 低点；token 用量持平 | 低至中等 |
| 5 | 融资收紧 | H1 股权购买 $42.4B；平台 > $500B S90072,S12528 | 新兴云服务商再融资失败；英伟达不得不扩大兜底 | 中等 |
| 6 | 供给追上需求，重复下单逐步解除 | FY2028 “供应受限”；CoWoS 到 2028 年向约每月 260k 片晶圆迈进 S18000,S3002 | 交货周期骤缩；客户库存累积 | 2028 年中等 |
| 7 | 软件实现首日持平 | AMD 在 DeepSeek-V4 上滞后 26 天 S631 | 主流开源模型在 AMD 和 TPU 上实现首日持平 | 中等 |
| 8 | 政策范围扩大 | 中国占营收 5.6–8.2 % S90070,S90069 | 管制扩展至海湾地区主权买家 | 低 |

条件 1、3、5 同时成立，描述的是 2001 年式的情景；条件 2、3、7 同时成立，描述的是较缓慢的“够用芯片”情景，本资料库认为后者的可能性更大。

## 领先指标仪表盘

以下是本资料库会放在同一屏上的各项指标。多数指标随财报按季度更新；租金指数和容量价格更新更快。

| 指标 | 当前值 | 看空阈值 | 来源与更新频率 |
|---|---|---|---|
| 超大规模云厂商占英伟达数据中心营收的比例 | 约 55 %（Q2 FY2027） | > 60 % | CFO 评论，按季度 S406 |
| 最大直接客户占营收比例 | 16 %（Q2 FY2027） | > 20 % | 10-Q，按季度 S90069 |
| 博通 AI 营收 ÷ 英伟达数据中心营收 | 约 19 % | > 25 % | 博通 8-K，按季度 S2516 |
| GAAP 毛利率 | 75.0 %；Q3 指引 74.0 % | 剔除一次性费用后 < 70 % | 财报新闻稿 S405,S18000 |
| 供应承诺 ÷ 季度营收 | 2.9×（$279B） | > 3.5× 且营收增速放缓 | 10-Q，按季度 S407 |
| 股权购买 ÷ 营收 | 约 24 %（H1 FY2027） | 再连续两个半年度上升 | 10-Q 现金流量表 S90072 |
| 净股权收益 ÷ 净利润 | 约 20 %（H1 FY2027） | > 25 % | 10-Q S90069 |
| 三大超大规模云厂商资本开支指引 | 约 $558B（2026） | 首次同比削减 | 财报电话会，按季度 S12518 |
| H100 一年期租金指数 | $2.35（2026 年 3 月） | < $1.70（2025 年 10 月低点） | SemiAnalysis，按月 S12516 |
| PJM 容量价格 | $333.44/MW-day，触及上限 | 上限持续生效且缺口扩大 | PJM 拍卖，按年 S18016 |
| AMD 在新开源模型上的首日差距 | 26 天（DeepSeek-V4） | < 7 天 | SemiAnalysis InferenceX S631 |
| UALink 交换芯片 | 已进入实验室（2026 年下半年） | 大规模出货 | 联盟与厂商 S90051 |
| SAMR 与 Hugging Face 审查 | 初步认定；可能面临欧盟/DOJ 审查 | 罚款 > $1B 或针对捆绑销售的救济措施 | 监管机构 S9505,S11027 |
| 美国本土先进封装 | 计划 2028–2029 年 | 推迟至 2029 年以后 | 台积电、Amkor S18014 |

下方的催化剂日历显示其中几项指标下一次变动的时间。

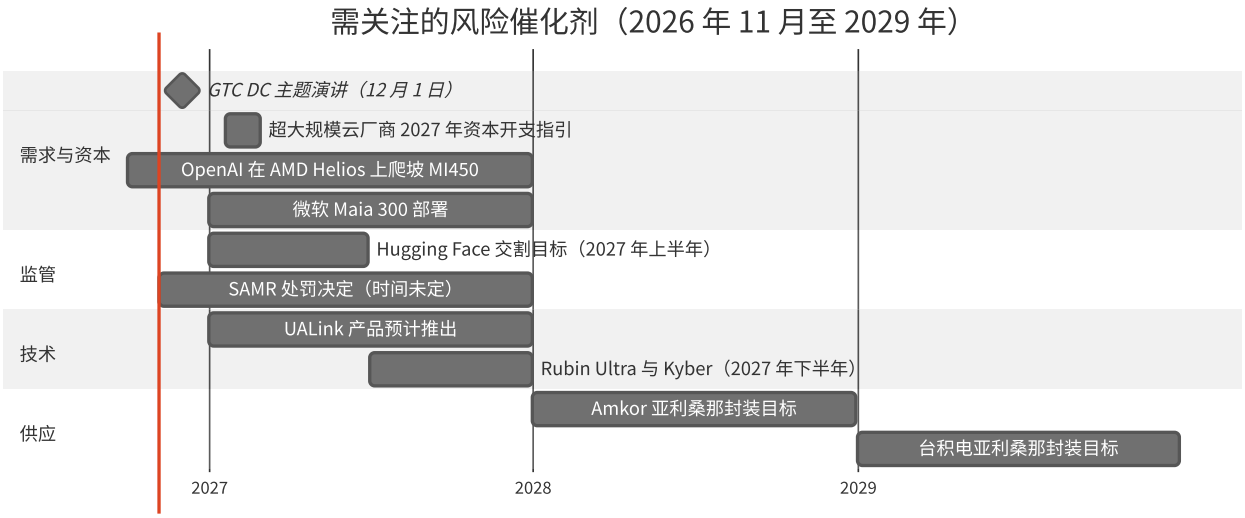


日历来源：GTC DC [S90047]，AMD Helios 与 OpenAI [S90020,S90021]，Maia 300 [S90046]，Hugging Face [S11026]，SAMR [S9505]，UALink [S90051]，Rubin Ultra [S90003]，亚利桑那封装 [S18014]。

## 估值：市场已经隐含了什么

看空情景只有与股价所隐含的假设相比较才有意义。英伟达市值在 2026-08-28 约为 $5.28T——此前 Q2 FY2027 财报发布后的两个交易日分别上涨 8.7 % 和下跌 4.6 % [S18004]——并在 2026-10-05 以创纪录收盘价达到约 $5.76T [S18005]；未找到可靠的 2026 年 11 月数据。2026 年 4 月，在市值约 $4.8T 时，其远期市盈率约为 24×，而标普 500 指数约为 21× [S18006]。随后盈利前景大幅跃升：英伟达给出 FY2028 营收增长约 70 % 的指引，而分析师此前预期约为 45–47 % [S18000,S18003]。

本资料库的测算（🔴）以 FY2027E 营收约 $410B 为基础（Q1 $81.6B + Q2 $96.2B + Q3 指引 $108B + 假设的 Q4 约 $124B）[S403,S405]，套用四条 FY2028 路径，再用约 $5.5T 的市值除以由此得出的净利润。按指引路径计算，远期市盈率约为 14×，低于标普 500 指数。

**At ~$5.5T NVIDIA trades near 14× guided FY2028 earnings; only a stall or a 2001-style reset makes it look expensive**

Market cap ÷ FY2028 net income under four revenue and margin paths (repo arithmetic, speculative; label = revenue · gross margin · net income · growth the price implies after FY2028)

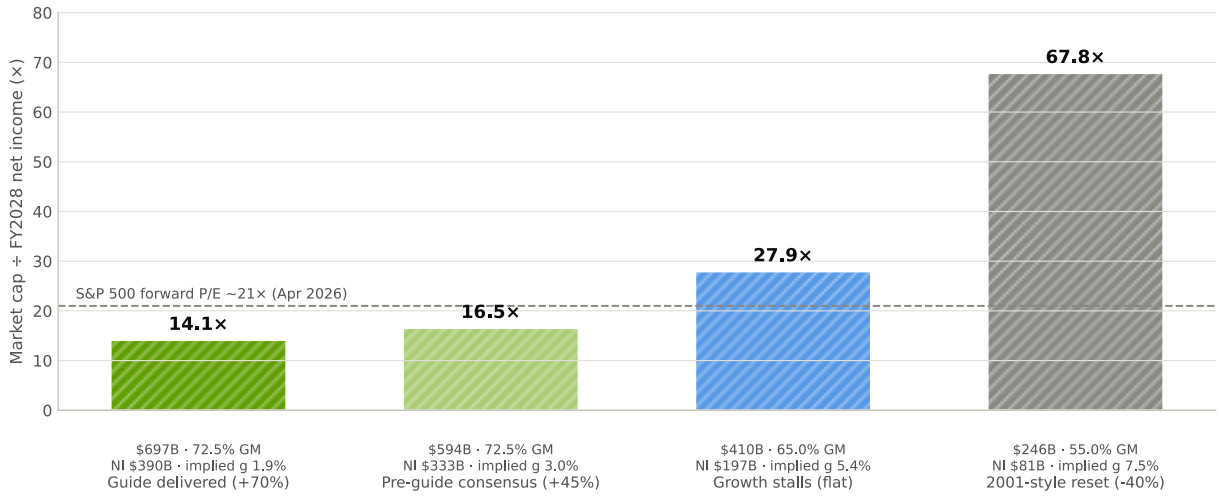


*All bars hatched: scenarios, not forecasts*

Source: data from NVIDIA results and guidance, market reports, repo scenarios [S18027] [S18000] [S403] [S405] [S18004] [S18005] ...; chart by repo · As of 2026-11-05

按约 $5.5 万亿美元市值计算的英伟达 FY2028 净利润市盈率柱状图。兑现指引（营收 +70% 至约 $697B，毛利率 72.5%，净利润约 $390B）：14.1 倍。指引前一致预期（+45%，$594B，$333B）：16.5 倍。增长停滞（持平于 $410B，毛利率 65%，$197B）：27.9 倍。2001 年式重置（营收下降 40% 至 $246B，毛利率 55%，$81B）：67.8 倍。2026 年 4 月标普 500 指数远期市盈率约为 21 倍。按指引路径，股价隐含 FY2028 之后年增长率仅约 2%。

**提示**

**算例 —— 一行式反向 DCF。** 在全额派息的反向 DCF 中，市盈率 = 1 ÷（股权成本 − 增长率）。按 FY2028 指引盈利约 14.1×、股权成本 9 % 计算，FY2028 之后的增长率 = 9 % − 1/14.1 ≈ 9 % − 7.1 % = **每年约 1.9 %**（🔴）[S18027]。在“增长停滞”路径下，同样的股价需要从更低的基数出发实现每年约 5.4 % 的增长；在 2001 年式重置下则需要约 7.5 %。**结论：**市场并未线性外推这轮繁荣，而是把 FY2028 视为接近平台期。因此，看空逻辑必须论证 FY2028 之后盈利会*下降*，而不仅仅是增长放缓。

**🔧 技术细节：估值情景中的假设与敏感性**

两条增长路径的净利率设为 56 %：FY2026 的 GAAP 净利率为 55.6 %，对应毛利率 71.1 %；Q2 FY2027 营业利润率约为 66 % [S1,S405]；股权收益不计入。“增长停滞”路径假设毛利率为 65 %（ASIC 价格竞争叠加内存成本）、净利率为 48 %；重置情景假设毛利率为 55 %（可比于毛利率 60.5 % 的 H20 季度再叠加承诺相关费用）、净利率为 33 %。敏感性：股权成本为 10 % 时，指引路径隐含约 2.9 % 的增长；为 8 % 时约为 0.9 %。市值每变动 ±$0.3T，各倍数约变动 ±5 %。全部输入见 `data/x18_valuation_scenarios.csv`。这些是用于检验论点的情景，而非目标价。

## 多空观点汇总

注

🐂 **看多观点。** 英伟达直到 FY2028 都处于供应受限状态，指引增长约 70 % [S18000]，毛利率维持在 70% 以上区间，资产负债表以经营现金流为其生态系统提供资金 [S403]。在价值池扩大约 4.2× 的同时，其 AI 芯片营收份额保持在约 87 % [S416,S660]。本页上的每一项风险要么已体现在数字中（中国），要么有边界（反垄断），要么是时间问题（电力），要么是系统性而非竞争性的（台湾），要么正在被收编（NVLink Fusion、Groq、开源 Dynamo）。而且按约 14× 的指引盈利计，股价已经假设这轮繁荣将进入平台期。任何更好的结果都是上行空间。

注意

🐻 **看空观点。** 英伟达最好的客户正在打造它的替代品，而这些客户恰恰构成了它的集中度，并为资本开支周期提供资金。定制芯片已相当于英伟达数据中心营收的约 19 % [S2516]；英伟达自身的股权购买比例与朗讯的供应商融资比例相当 [S18007,S90072]；供应承诺是季度营收的 2.9× [S407]；而且即使在 ASIC 竞争真正发力之前，毛利率指引就已下调 [S18000]。当 2028 年供给追上需求时，首先消退的是定价权，其次是重复订单的解除；而对峰值盈利给予 14× 的倍数并不便宜。

重要

**最需要记住的一点。** 十项风险可归结为一个问题：当供应不再是约束时，英伟达每单位算力的价格会怎样？毛利率是需要盯住的指标。

## 🎯 企业发展视角

1. **相互关联的风险簇同时也是客户名单。** 风险 1、2、7 都经由同样五六家买家传导。对任何挑战者而言，这些买家既是市场，*也*是最大的竞争来源。其中哪一家最有可能与商用芯片供应商合作实现多源采购，而非自研？又会在哪些工作负载上这样做？
2. **毛利率重置是机会，而不仅仅是风险。** 如果英伟达毛利率从 75 % 向 65 % 上下回落，每个商用芯片新进入者头顶的价格保护伞都会缩小。英伟达价格降到什么水平时，第二供应来源的推理方案（例如高通已公开的 AI200/AI250 和 Dragonfly AI300 路线图）仍能跨过自身的回报门槛 [S90028,S90060]？
3. **没有现金流就不要照搬融资打法。** 英伟达能在六个月内用经营现金流为约 $42B 的持股提供资金 [S90072,S403]。对于资产负债表较小的公司，哪些结构能把利用率风险转移给第三方（主权包销、预付款、资产管理机构平台），而不是压在供应商身上？
4. **电力约束与推理商品化有利于能效专家。** 在电表而非预算成为约束的地方，每兆瓦 token 产出决定胜负。受电力上限约束的买家需要哪些独立证据（MLPerf、InferenceX），才会相信非英伟达厂商关于每兆瓦 token 产出的宣称？
5. **软件可移植性如今已是一类资产。** Modular（高通）、Hugging Face（英伟达，待交割）以及开源内核生成工具决定了 CUDA 被侵蚀的速度 [S9511,S11026,S18020]。剩余的可移植性资产（编译器、内核库、推理服务引擎）中哪些仍保持独立？本仪表盘上的哪些风险会最快改变它们的价值？
6. **用仪表盘把握时机。** 超大规模云厂商首次削减资本开支，或 H100 指数跌破 $1.70，很可能迅速导致 AI 芯片初创公司重新定价。哪些领先指标应触发对合作或收购选项的重新评估？

# 19 —— 对高通的启示

跨层专题 19 · 英伟达的市场地位对一个拥有高通公开资产的挑战者意味着什么 · 阅读约 32 分钟 · 最后核实：2026-11-05

> **重要**
>
> **仅基于公开信息；提出问题与选项，而非建议。** 本页关于高通（Qualcomm）的每一项陈述均来自其公开公告、监管文件或媒体报道，并已在文中注明出处。没有任何内部信息，也没有任何杜撰内容。关于挑战者“能在哪里胜出”的判断属于本资料库的分析，并标注 🔴。本页以高通竞争对手概况为基础展开，而不重复其内容。

## ⚡ 要点速览

- **英伟达的领先在于平台与迭代节奏，因此挑战者要选择自己的战场。** 2025 年英伟达（NVIDIA）拿下约 87% 的 AI 数据中心芯片营收（估计），Q2 FY2027 毛利率为 75.0% [S660,S663,S405]。高通到 FY2029 实现 $15B 数据中心营收的目标，约为英伟达 FY2026 数据中心营收的 8% [S90059,S1]。
- **高通与英伟达的四种关系同时存在。** 按主要角色划分，高通在英伟达 12 个层中的 6 层与其竞争，在 1 层与其合作（通过 NVLink Fusion 接入的 Oryon CPU），在 2 层与其互补（Alphawave 连接 IP、Mojo），在 3 层缺席（DPU 与网卡、领域软件库、云算力）。它仅在 4 层有已出货产品（🔴 本资料库图谱）[S90031,S173,S4513,S9511]。
- **资产买得很快；客户还停留在合同层面。** NUVIA（$1.4B）、Alphawave（约 $2.4B）和 Modular（$3.9B）合计约 $7.7B，另有收购价未披露的 Ventana [S4538,S4514,S90057,S4512]。HUMAIN 计划部署 200 MW。🟢 Meta 是 Dragonfly C1000 的首个客户，自 2028 年下半年起部署。AWS 签约采购定制推理芯片，并获得一份认股权证，按截至 2036 年最多 $60B 的采购额归属 [S90030,S90058,S90087]。尚无公开的 AI200 批量出货记录或 MLPerf/InferenceX 结果 🔴 [S90028,S602,S620]。
- 🔴 **挑战者能在哪里胜出：**本资料库认为超大规模云厂商定制芯片和智能体（agentic）头节点 CPU 是最开放的细分市场；在定制芯片领域，主要对手是博通（Broadcom）而非英伟达。以聊天速度提供混合专家模型（MoE）推理服务时的每兆瓦产出是英伟达的堡垒：GB300 NVL72 每兆瓦约可提供 2.6M tokens/s，而已出货的竞品 ≤0.7M（估计）[S14000,S2516,S4522]。
- **LPDDR 容量是另一种押注，而非护城河。** 据报道 🟡，一个 AI200 机架的加速卡上共有约 43 TB 内存，是 Vera Rubin NVL72 的 20.7 TB HBM4 的 2×。但英伟达机架在 Vera CPU 一侧还有 54 TB LPDDR5X，而且 LPDDR 加速卡的带宽比 Rubin 低约 35×（0.548 对 19.2 TB/s）[S19003,S362,S172,S90006]。
- **边缘侧是挑战者体量更大的唯一领域。** 截至 2026 年 6 月的季度，高通芯片业务销售额约 $8.5B，而英伟达边缘计算平台为 $7.2B。在数据中心领域，英伟达单季 $89.0B 的营收约为高通 FY2027 目标对应季度营收水平的 71× [S19002,S405,S15512]。终端设备领域的既有地位能否赢得云端订单，尚未得到验证 🔴。
- **交易条款的差异比新闻标题显示的更大。** 签约时，AMD 的“一分钱认股权证”（penny warrant）价值约为 OpenAI 预计采购额的 29%。高通给 AWS 的认股权证为平值行权价，因此除非高通股价上涨，否则其价值为零：股价上涨 25% 时约为采购额的 1.7%（🔴 本资料库测算）[S24000,S24001,S15510]。

**Qualcomm competes with NVIDIA in 6 of 12 layers, partners in 1, complements 2 and is absent from 3; it ships in 4**

Qualcomm public efforts by NVIDIA stack layer; shade = evidence stage; bold outline = primary role; last column = chapter 15 score (0-5)

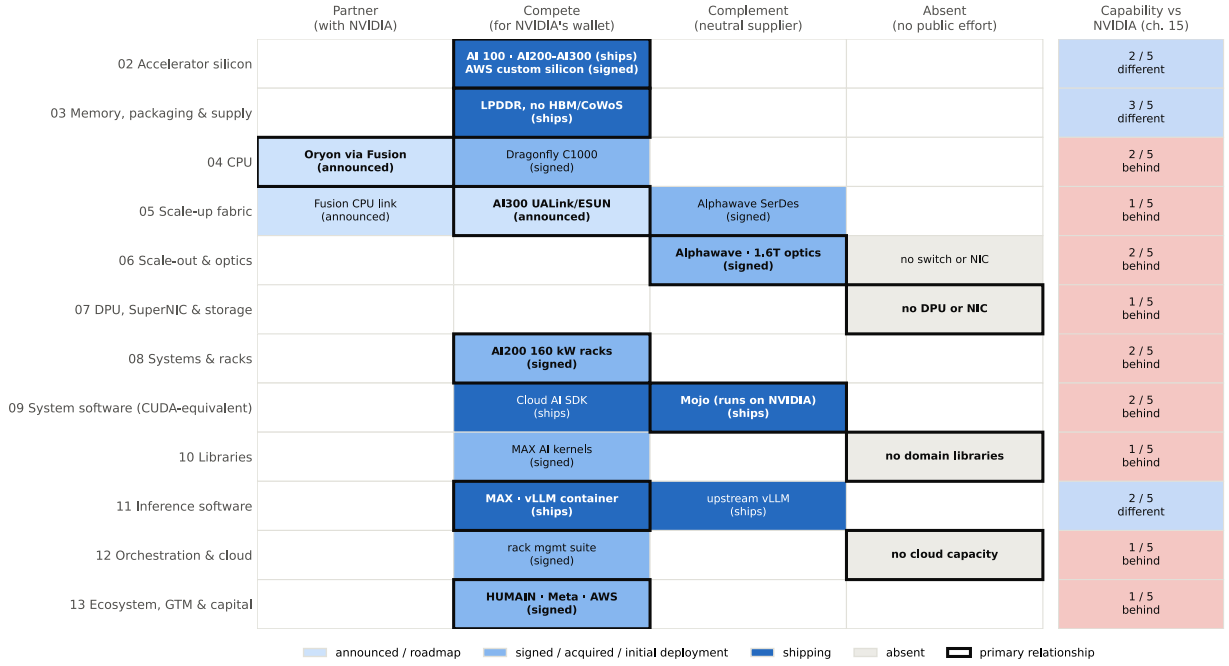


*Public information only. Stage: 1 announced/roadmap, 2 signed/acquired/initial deployment, 3 shipping.*

Source: data from Qualcomm, NVIDIA and press announcements; scores are repo judgement [S172] [S173] [S90060] [S4030] [S90087] [S15510] ...; chart by repo · As of 2026-11-05

> 高通公开的数据中心布局与英伟达 12 个技术栈层对照的热力图，按关系（合作、竞争、互补、缺席）和证据阶段划分。主要角色：在 6 层竞争（加速器、内存路线、纵向扩展、机架、推理软件、生态），在 1 层合作（经 NVLink Fusion 接入的 CPU），在 2 层互补（Alphawave 连接 IP 与 1.6T 光学器件；Mojo，也可在英伟达 GPU 上运行），在 3 层缺席（DPU 与网卡、领域软件库、云算力）。只有 4 层有已出货产品（Cloud AI 100、LPDDR 加速卡、Cloud AI SDK 与 Mojo、MAX 与 vLLM）；AI200 机架、C1000 和 AI300 处于已发布、已签约或初步部署阶段。第五列沿用第 15 章的分层评分：平均 1.7 分（满分 5），9 层落后、3 层路线不同。

## 1. 框架：英伟达的市场地位对挑战者意味着什么

其他章节将英伟达描述为一家全栈商用芯片供应商（full-stack merchant）。它向每一位买家销售芯片、机架、网络和免费软件，每年更新平台，并在新模型发布首日即提供支持（第 15 章、第 16 章、第 17 章）。同样这些章节也列出了它的弱点。75% 的毛利率是一把价格保护伞（price umbrella），竞争对手可以在其下方定价。三家直接客户分别占 H1 FY2027 营收的 16%、15% 和 13% [S90069]，而这些买家正在自研芯片：博通的 AI 营收已相当于英伟达数据中心营收的约 19% [S2516,S405]。许多园区的约束是电力而非资金（第 18 章）。

这给挑战者留下了三条大致路径，而高通的公开举措同时在走这三条路：

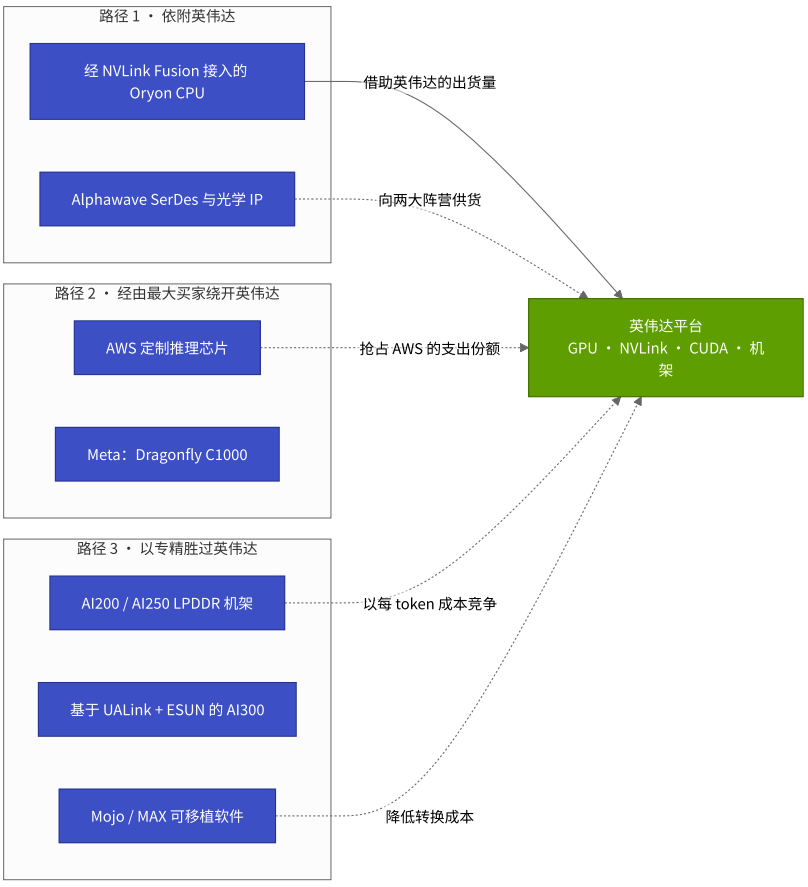


每条路径的经济引擎各不相同。依附英伟达可以借助其出货量，但每个机架赚到的金额很小：36 颗 Vera CPU 约占一个约 $7.8M 的 Vera Rubin 机架的 2%（估计）[S331]。通过超大规模云厂商绕开英伟达，可以在大批量上赚取设计服务利润，但依赖少数几家买家。以专精取胜则需要找到英伟达优势最不重要的工作负载，并拿出产品在该负载上胜出的独立证据。

| 公开资产 | 内容 | 状态（2026 年 11 月） | 来源 |
|---|---|---|---|
| Oryon CPU 内核（NUVIA） | 定制 Arm 内核，2021 年以 $1.4B 收购 | 已用于骁龙（Snapdragon）设备；面向 NVLink Fusion 的数据中心 CPU 于 2025 年 5 月发布 | S4538,S4516,S90031 |
| Dragonfly C1000 | >250 核芯粒 CPU，目标主频 >5 GHz，支持 PCIe Gen 7、CXL；面向智能体头节点 | Meta 为首个客户；2028 年下半年起部署 🟢 | S90056,S90058 |
| Hexagon NPU 系列：Cloud AI 100 Ultra | 150 W PCIe 卡，128 GB LPDDR4x、0.548 TB/s，870 TOPS INT8 | 自 2023 年起出货 | S172,S4514 |
| AI200 / AI250 | 每卡 768 GB LPDDR，置于 160 kW 液冷机架中；AI250 增加近存计算 | AI200 送样中，2026 年下半年初步部署 🟡；尚未确认批量出货 🔴 | S173,S4030 |
| Dragonfly AI300 | 第二代高带宽计算（High Bandwidth Compute）；带宽为 AI200 的“54×”（厂商宣称）；采用 UALink 和 ESUN 纵向扩展 | 2028 年送样 🟢 | S90060,S4029 |
| Ventana | RISC-V 服务器 CPU 团队 | 2025 年 12 月收购，条款未披露 | S4512 |
| Alphawave Semi | SerDes、芯粒与光互连 IP，约 $2.4B | 2025-12-18 完成交割 🟢 | S4513,S4514 |
| Modular | Mojo 语言与 MAX 推理引擎，$3.9B | 2026-07-29 完成交割；Mojo 于 2026 年 8 月开源 | S9511,S9512 |
| 边缘侧装机基础 | 单季手机芯片（$5.09B）、物联网（$1.83B）和汽车（$1.59B） | 出货中 | S19002 |
| 数据中心客户 | HUMAIN 200 MW；Meta（C1000）；AWS 定制芯片与 1.6T 光学器件 | 已签约 | S90030,S90058,S90087 |

| 公开资产 | 内容 | 状态（2026 年 11 月） | 来源 |
|---|---|---|---|
| 财务能力 | FY2026 营收 $43.1B；现金及有价证券 $7.7B，债务 $15.1B | 已披露 | S15513,S13503 |

**Qualcomm's datacenter push: 11 public moves since May 2025; accelerator volume is a 2026–28 target**

Public announcements only, by lane; filled = shipped / closed / signed, hollow = announced roadmap, × = exit

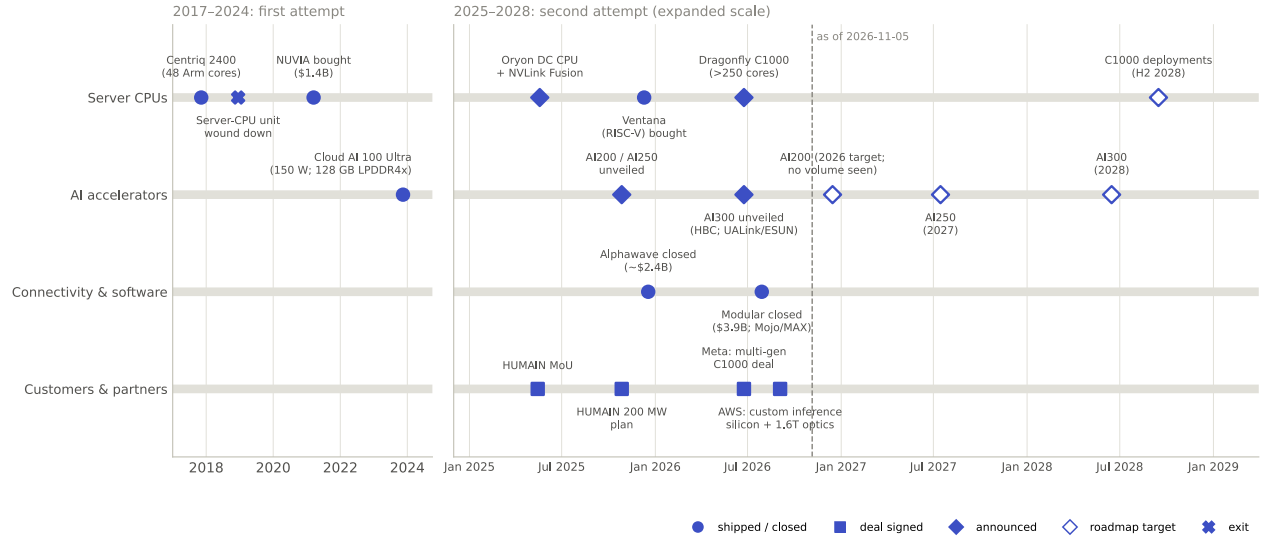


*Public information only; dates of roadmap items are company targets*

Source: data from Qualcomm releases, filings and press coverage (public information only) [S4542] [S4543] [S4544] [S4538] [S172] [S90031] ...; chart by repo · As of 2026-11-05

高通公开数据中心举措的时间线，分四条泳道。2025 年以前：Centriq 2400 服务器 CPU（2017 年 11 月）、该业务部门收缩（2018）、以 $1.4B 收购 NUVIA（2021）以及 Cloud AI 100 Ultra 加速卡（2023）。2025 年 5 月以来：NVLink Fusion CPU 合作与 HUMAIN 谅解备忘录（2025 年 5 月）；发布 AI200 和 AI250，以及 HUMAIN 的 200 MW 计划（2025 年 10 月）；收购 Ventana（RISC-V）和 Alphawave（约 $2.4B）（2025 年 12 月）；投资者日发布面向 Meta 的 Dragonfly C1000 CPU、AI300 加速器及 Modular 交易（2026 年 6 月）；以 $3.9B 完成 Modular 交割（2026 年 7 月）；与 AWS 达成多代定制推理芯片及 1.6T 光学器件交易，并以 $4B 认股权证为支撑（2026 年 9 月）。路线图：AI200 于 2026 年（截至 2026 年 11 月尚未确认批量出货）、AI250 于 2027 年、AI300 和 C1000 于 2028 年部署。

**提示**

**算例 —— 将目标与在位者的体量对比。** 截至 2026-07-26 的 13 周内，英伟达数据中心平台营收为 $89.0B [S405]，约合每周 $6.8B。高通 FY2029 年 $15B 的目标 [S90059] 约相当于该营收水平下的 2.2 周，约为高通自身 FY2026 营收 $43.1B 的 35% [S15513]。FY2027 的阶段性目标为 $5B，已于 2026-11-04 重申，其中至少 $1B 来自两份超大规模云厂商定制芯片合同 [S15513,S15511]。**结论：**该目标并不需要取代英伟达，只需要在英伟达占约 87% 的市场中拿下约 2–8%。问题在于拿哪一块。

**Qualcomm's $15B FY2029 datacenter goal is ~8% of NVIDIA's FY2026 data-center revenue**

US$ B per year: reported data-center / AI revenue vs Qualcomm's public targets (hatched); public information only

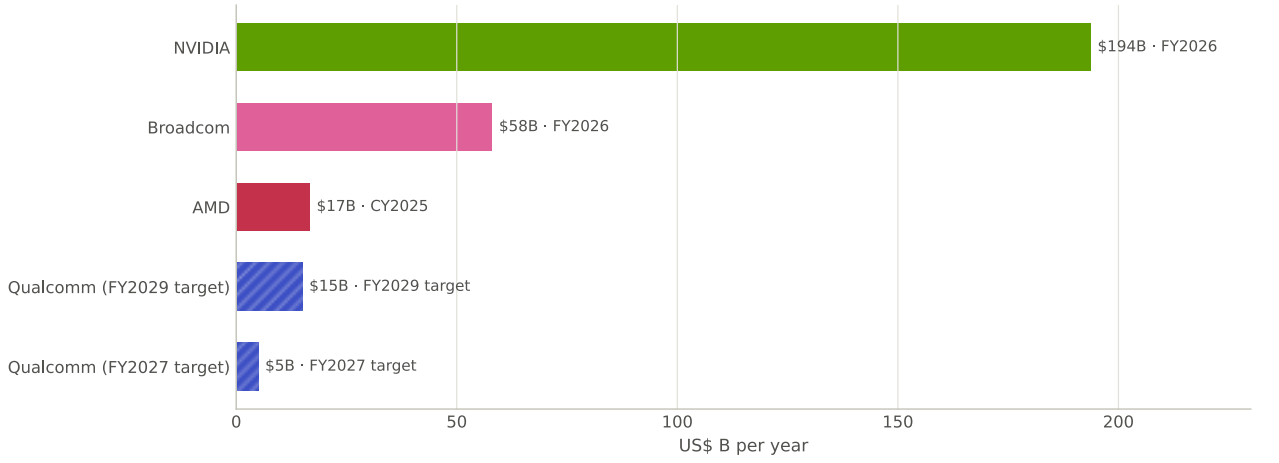


*Hatched = company target, not reported revenue*

Source: data from company filings, calls and Investor Day materials [S1] [S402] [S15501] [S450] [S15512] [S90059] …; chart by repo · As of 2026-11-05

横向柱状图：英伟达 FY2026 数据中心营收 $193.7B；博通 FY2026 AI 半导体营收约 $58B；AMD 2025 年数据中心营收约 $16.7B；高通公开目标为 FY2029 数据中心营收 $15B、FY2027 为 $5B（阴影表示）。FY2029 目标约为英伟达 FY2026 数据中心营收的 8%。

**🔧 技术细节：为什么芯片降价能换来的效果比看上去小**

第 14 章的模型显示，英伟达约 75% 的毛利率仅占 GB300 每 token 全部成本的约 24%。其余部分是机架、网络、设施、电力和运维的资本费用。即使英伟达毛利润减半，每 token 成本也只会下降约 18%（估计）[S14000]。同一模型还发现，在每用户 100 tokens/s 条件下，英伟达可以把 GB300 价格下调约 20% 以追平谷歌内部 TPU 的成本，同时仍保留约 66% 的毛利率（🔴）[S14000]。因此对挑战者而言，单靠更低的芯片价格是一个弱杠杆。强杠杆是每兆瓦 token 产出、利用率和部署速度。只靠价格销售的挑战者，面对的是英伟达可以有选择地动用的约 10 个百分点的缓冲（第 14 章第 6 节）。

## 2. 分层图谱：合作、竞争、互补或缺席

该图谱将高通的每一项公开举措与其涉及的英伟达技术层对应起来，回答两个问题：与英伟达是什么关系？该举措进展到哪一步？**关系**分为四类：🤝 合作（向英伟达平台供货）、⚔️ 竞争（争夺同一笔预算）、🧩 互补（中立供应商或同时服务两大阵营的可移植层）、⬜ 缺席（无公开举措）。**阶段**分为已发布、已签约（已签订合同、已完成收购或已初步部署）和已出货。最后一列沿用第 15 章的能力研判（🟩 领先 · 🟨 持平 · 🟥 落后 · 🟦 路线不同）以及 `competitor_matrix.csv` 中的 5 分制评分。数据：`data/x19_layer_map.csv`。

| 英伟达技术层 | 高通的公开举措 | 关系 | 阶段 | 第 15 章研判 | 来源 |
|---|---|---|---|---|---|
| 02 加速器芯片 | Cloud AI 100 Ultra；AI200、AI250、AI300；AWS 定制推理芯片 | ⚔️ 竞争 | 已出货（AI 100）；已签约（AWS） | 🟦 2/5 | S172,S173,S90060,S90087 |
| 03 内存与供应 | 无需 HBM 或 CoWoS 的 LPDDR 加速卡 | ⚔️ 以绕行方式竞争 | 已出货（AI 100） | 🟦 3/5 | S172,S173 |
| 04 CPU | 经 NVLink Fusion 接入的 Oryon CPU；Dragonfly C1000；Ventana | 🤝 合作与 ⚔️ 竞争 | 已发布；已签约（Meta） | 🟥 2/5 | S90031,S90058,S4512 |
| 05 纵向扩展 | 基于 UALink 和 ESUN 的 AI300；Fusion CPU 链路；Alphawave SerDes | ⚔️ 竞争（亦有 🤝、🧩） | 已发布 | 🟥 1/5 | S90060,S131,S4513 |
| 06 横向扩展与光学 | Alphawave IP；面向 AWS 的 1.6T 光学器件；无交换机或网卡 | 🧩 互补 | 已签约 | 🟥 2/5 | S4513,S90087 |
| 07 DPU、SuperNIC、存储 | 无；AI200 列出了机密计算功能 | ⬜ 缺席 | — | 🟥 1/5 | S173 |

| 英伟达技术层 | 高通的公开举措 | 关系 | 阶段 | 第 15 章研判 | 来源 |
|---|---|---|---|---|---|
| 08 系统与机架 | AI200 160 kW 机架；机架软件已在 HUMAIN 部署 | ⚔️ 竞争 | 已签约（初步部署） | 🟥 2/5 | S173,S19001 |
| 09 CUDA 对等层 | Mojo（也可在英伟达 GPU 上运行）；Cloud AI SDK | 🧩 互补（亦有 ⚔️） | 已出货 | 🟥 2/5 | S9512,S9023,S596 |
| 10 软件库 | 仅有 MAX AI 内核；无领域软件库 | ⬜ 缺席 | —（AI 内核处于早期） | 🟥 1/5 | S9513 |
| 11 推理软件 | MAX 引擎；vLLM 容器；上游 vLLM | ⚔️ 竞争（亦有 🧩） | 已出货 | 🟦 2/5 | S9511,S596 |
| 12 编排与云服务 | 机架管理套件；无自有云算力 | ⬜ 缺席 | — | 🟥 1/5 | S19001 |
| 13 生态与资本 | HUMAIN、Meta、AWS；FY2027 $5B 和 FY2029 $15B 目标 | ⚔️ 争夺同一批客户预算 | 已签约 | 🟥 1/5 | S90030,S90058,S90087,S90059 |

对该图谱的三点解读不同于或补充了第 15 章的高通页面：

- **第 07 层和第 10 层在此单独列出。** 第 15 章合并了第 09–11 层，且未纳入第 07 层。自建、收购与合作的问题恰恰集中在缺席的层（第 4 节），因此本页将其单独呈现。
- **当前的商用机架方案与英伟达最接近的商用对手合作。** MWC 2026 上的两篇低级别报道称，AI200 机架由 AMD EPYC CPU 托管 56 张加速卡，节点内通过 PCIe 互连，跨机架通过 800G 以太网互连 🟡 S19003,S19005。NVLink Fusion CPU 和 C1000 都是更晚的产品，因此在 2026 年，高通与英伟达在 CPU 上的“合作”角色仍停留在纸面上。
- **纵向扩展（scale-up）上的“竞争”关乎治理权，而非抵制。** ESUN 是英伟达自己参与创立的 OCP 工作组 S576。UALink 才是英伟达缺席的地方。双轨策略（Fusion CPU、UALink/ESUN 加速器）让高通同时站在两边，英特尔（Intel）也是如此（NVLink Fusion）。

> **提示**
>
> **算例 —— 清点已出货的产品。** 该图谱的数据文件在 12 个层中共收录 21 项公开举措，其中 6 项处于已出货阶段。这 6 项中有 2 项是硬件，而且两者属于同一条 2023 年的产品线：Cloud AI 100 及其 LPDDR 内存设计。其余 4 项是软件（Cloud AI SDK、Mojo、带 vLLM 容器的 MAX、上游 vLLM）S172,S596,S9511。机架、CPU、纵向扩展互连和 AWS 芯片将在 2026 至 2028 年间陆续推出。同一时期，英伟达将在 2026 年交付 Vera Rubin，2027 年下半年交付 Rubin Ultra，2028 年交付 Feynman S90009,S90003,S90004。**结论：**图谱的大部分内容仍是路线图。高通的每一代产品面对的，都将是英伟达当前出货产品的下一代。

### Qualcomm averages 2.7 of 5 vs NVIDIA's 4.7; it out-scores NVIDIA only on claimed cost per token

Repo scores 0-5 (analyst judgement, sourced): capability radar (left) and per-layer score with verdict vs NVIDIA (right)

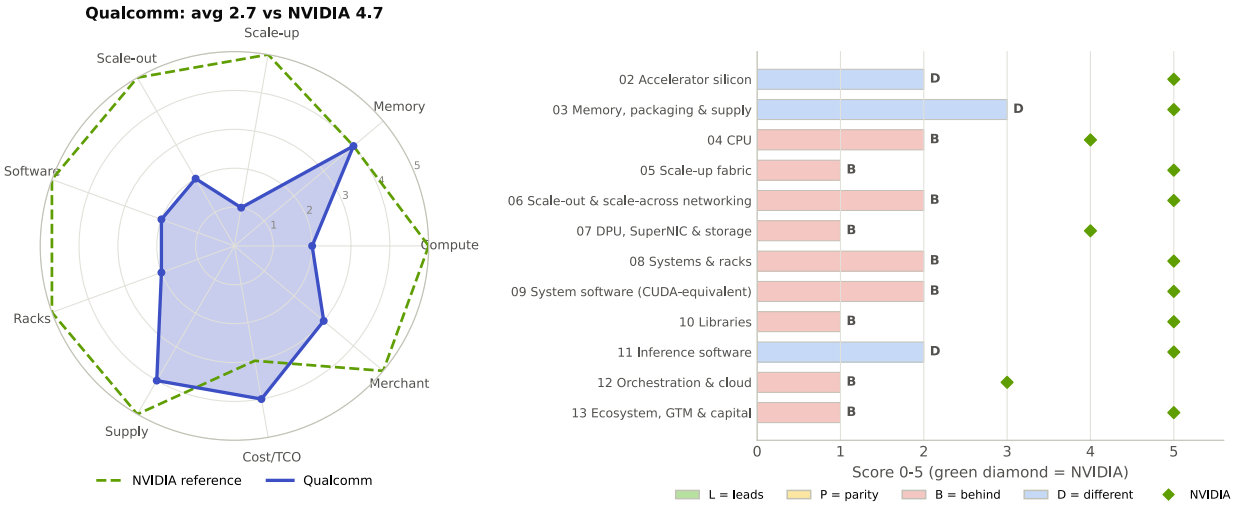


*Analyst judgement (speculative); L/P/B/D = leads / parity / behind / different approach*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S603] [S379] [S412] [S468] [S630] ...; chart by repo · As of 2026-11-05

双联图。左：高通与英伟达在九个能力维度上的雷达图，平均分为 2.7 对 4.7（满分 5）（计算 2 对 5；内存 4 对 4；纵向扩展 1 对 5；横向扩展 2 对 5；软件 2 对 5；机架 2 对 5；供应 4 对 5；成本/TCO 4 对 3；商用能力 3 对 5）。右：高通在英伟达 12 个技术栈层中各层的得分与研判：落后 9 层、路线不同 3 层。仅基于公开信息：高通基于 LPDDR 的设计在内存容量以及不依赖 CoWoS 和 HBM 方面得分，其成本优势为厂商宣称，纵向扩展、软件和机架均处于早期阶段。

### No rival matches NVIDIA across the stack: the closest, Google TPU, is level or ahead in only 5 of 12 layers

Repo verdict vs NVIDIA by stack layer (02-13) and competitor; letter = verdict, number = score 0-5 (analyst judgement, sourced)

| | 02 Silicon | 03 Memory & supply | 04 CPU | 05 Scale-up | 06 Scale-out | 07 DPU / SuperNIC | 08 Systems & racks | 09 System software | 10 Libraries | 11 Inference software | 12 Cloud & orchestr. | 13 Ecosystem & capital |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| AMD | P 4 | B 3 | **L 5** | B 2 | B 3 | B 3 | B 2 | B 3 | B 2 | B 3 | D 2 | B 3 |
| Google TPU | P 4 | B 4 | P 4 | D 5 | D 4 | D 3 | P 5 | B 3 | B 3 | **L 4** | **L 5** | B 4 |
| AWS Trainium | B 3 | B 3 | P 4 | B 3 | D 4 | D 4 | B 4 | B 2 | B 2 | B 3 | **L 5** | B 3 |
| Microsoft Maia | B 3 | B 2 | B 3 | B 3 | D 3 | D 3 | B 3 | B 2 | B 1 | B 2 | **L 5** | B 2 |
| Meta MTIA | D 2 | B 2 | B 1 | B 1 | D 4 | B 2 | D 3 | D 4 | B 2 | D 3 | D 1 | B 2 |
| Broadcom | D 4 | D 4 | B 1 | B 4 | **L 5** | B 3 | D 2 | D 1 | D 1 | D 1 | D 0 | B 4 |
| Marvell | D 3 | D 3 | B 1 | B 3 | B 4 | B 3 | D 1 | D 1 | D 1 | D 1 | D 0 | B 3 |
| Intel | B 2 | D 3 | P 4 | B 2 | B 2 | B 3 | B 1 | B 2 | B 2 | B 2 | B 1 | B 2 |
| Huawei | B 3 | B 1 | B 3 | D 4 | P 4 | B 3 | D 4 | B 2 | B 2 | B 3 | D 3 | D 3 |
| Qualcomm | D 2 | D 3 | B 2 | B 1 | B 2 | B 1 | B 2 | B 2 | B 1 | D 2 | B 1 | B 1 |
| Cerebras | D 4 | D 3 | B 1 | D 3 | B 2 | B 1 | B 3 | B 2 | B 1 | **L 4** | B 2 | B 2 |
| Groq | D 3 | D 3 | B 1 | D 2 | B 1 | B 1 | B 2 | B 2 | B 1 | D 3 | B 2 | B 1 |

L = leads NVIDIA　P = parity　B = behind　D = different approach

*Analyst judgement (speculative)*

Source: data from repo analysis (competitor_matrix.csv) [S602] [S143] [S361] [S379] [S144] [S624] ...; chart by repo · As of 2026-11-05

12 家竞争对手与英伟达 12 个技术栈层对照的热力图。谷歌 TPU 在 12 层中的 5 层持平或领先，为所有对手中最多；全部单元格中 60% 为“落后”，24 个软件与软件库单元格中有 19 个落后。超大规模云厂商仅在云服务上领先；博通在以太网交换上领先；谷歌 TPU 在推理成本上领先。

### 🔧 技术细节：关系与阶段如何认定

每一层有一个**主要**关系（在热力图中以粗边框标示），选取标准是在高通公开计划中涉及营收最多的那一种。次要关系仍然可见。第 04 层的主要角色为“合作”，因为这是高通与英伟达唯一的合作关系，尽管 C1000 已有签约客户而 Fusion CPU 没有。**阶段**依据最有力的公开证据认定：发布公告或路线图条目（1）；已签合同、已完成收购或有报道的初步部署（2）；或已在售产品（3）。阶段不反映质量：一张 2023 年已出货的加速卡，仍可能输给一个

已发布的 2028 年竞品。第 15 章的评分是分析师相对于 2026 年 11 月英伟达水平的判断（`competitor_matrix.csv`）。

## 3. 挑战者能在哪里胜出

本节在两个维度上对十一个细分市场打分（均为 🔴 本资料库判断）。**吸引力**综合考虑支出池的规模与增速，以及它与挑战者公开资产的契合度。**英伟达防御力**衡量英伟达的优势使夺取份额有多难：每兆瓦 token 产出、72 GPU 的 NVLink 域、CUDA、年度迭代节奏和供应分配。证据来自各层页面以及第 14、15、18 章。数据：`data/x19_win_matrix.csv`。

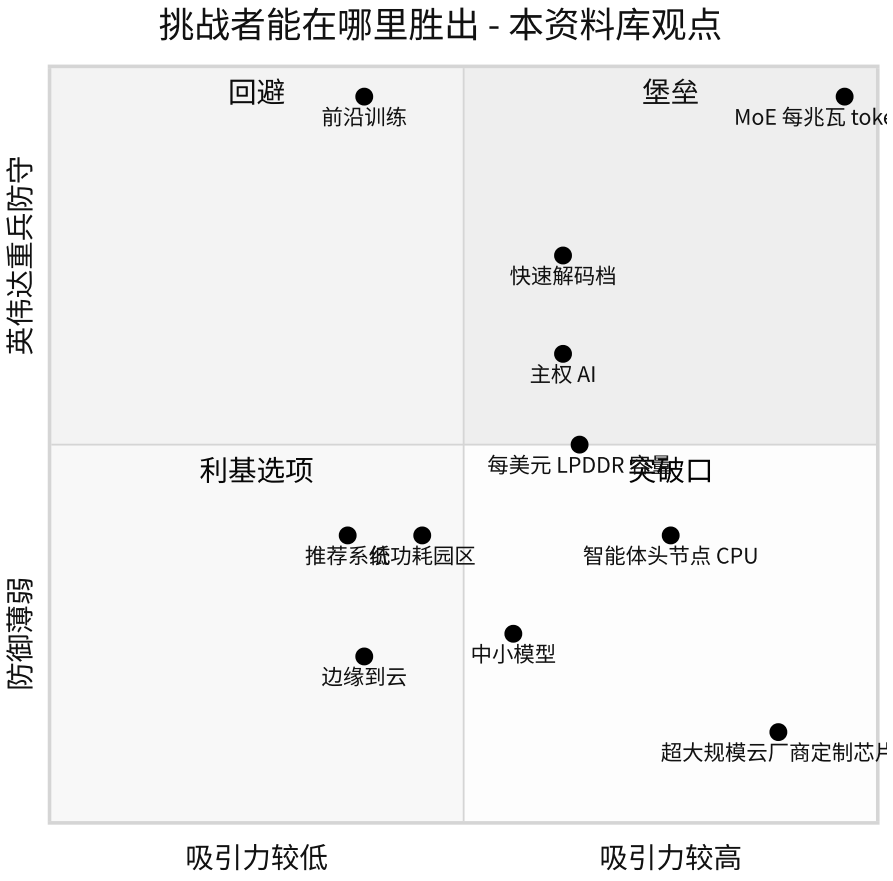

**Repo view: custom silicon and agentic CPUs look most open to a challenger; MoE tokens per MW is NVIDIA's fortress**

Eleven inference and CPU segments scored 1-5 on attractiveness to a challenger and on NVIDIA's defensibility (repo judgement, speculative)

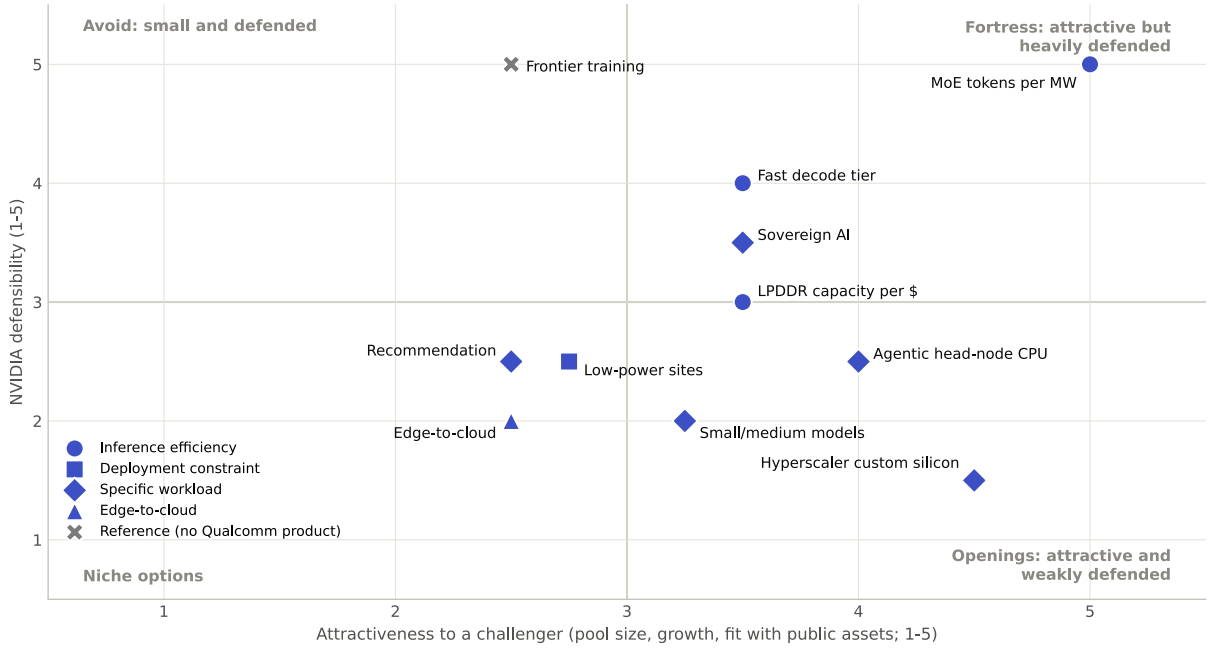


*Speculative scores; 2 segments in the open quadrant, 2 in the fortress.*

Source: data from repo analysis of layer pages and chapters 14-15 [S14000] [S621] [S622] [S173] [S333] [S332] ...; chart by repo · As of 2026-11-05

十一个细分市场的散点图：横轴为对挑战者的吸引力（x，1-5），纵轴为英伟达的防御力（y，1-5），均为本资料库判断。最开放（有吸引力、防御薄弱）：超大规模云厂商定制芯片（4.5, 1.5）和智能体头节点 CPU（4.0, 2.5）。英伟达的堡垒：以聊天速度提供 MoE 推理服务的每兆瓦产出（5.0, 5.0）和快速解码档（3.5, 4.0）；前沿训练（2.5, 5.0）仅作参考。中间地带：受容量约束的 LPDDR 推理服务（3.5, 3.0）和主权项目（3.5, 3.5）。防御力低但支出池较小、被锁定或未经验证的利基市场：中小型稠密模型（3.25, 2.0）、受电力上限约束的园区（2.75, 2.5）、推荐系统（2.5, 2.5）以及边缘到云的连续性（2.5, 2.0）。

| 细分市场 | 吸引力 | 英伟达防御力 | 🔴 理由 | 证据 |
|---|---|---|---|---|
| 以聊天速度提供 MoE 推理服务的每兆瓦产出 | 5 | 5 | 最大的推理支出池，但 NVL72 每兆瓦约可提供 2.6M tokens/s，竞品 ≤0.7M（估计） | 第 14 章 S14000 |
| 受容量约束的推理服务（每美元 LPDDR） | 3.5 | 3 | LPDDR 每 GB 更便宜，但英伟达有自己的 LPDDR 层级，且 1 TB HBM4E 即将推出 | 内存墙 S362,S305 |
| 快速解码档（每用户 ⩾100 tokens/s） | 3.5 | 4 | 受带宽约束；SRAM 方案领先，且英伟达现已销售 Groq 3 LPX | 第 11 层 S90003 |
| 受电力上限约束或风冷的园区 | 2.75 | 2.5 | NVL72 无法在此安装，150 W 加速卡可以；英特尔也瞄准这一市场 | 电力 S172,S162 |
| 智能体头节点 CPU | 4 | 2.5 | 在 GPU 机架之外，CPU 市场是开放的；英伟达自己估计其规模达数百亿美元 | 第 04 层 S4522 |
| 推荐与排序 | 2.5 | 2.5 | 受容量约束、适合 LPDDR，但最大的买家自研芯片 | MTIA S160 |
| 中小型稠密模型 | 3.25 | 2 | NVL72 的增益有限；竞争对手是旧款 GPU 和以价格取胜的 AMD | 第 14 章 S623,S12516 |
| 主权多供应商项目 | 3.5 | 3.5 | 买家多源采购，但已公布的主权 GPU 大部分来自英伟达 | 主权 AI S13003 |
| 边缘到云的连续性 | 2.5 | 2 | 高通的装机基础大于英伟达的边缘业务；数据中心回报尚未得到验证 | 第 3.4 节 S19002 |
| 超大规模云厂商定制芯片 | 4.5 | 1.5 | 增长最快的支出池；英伟达可以收编（Fusion）但无法阻止；对手是博通 | ASIC 设计服务商 S2516 |
| 前沿预训练（参考） | 2.5 | 5 | 只有约六家买家，需要大型纵向扩展域；高通无相关产品 | 第 14 章 S14000 |

## 3.1 推理效率：每瓦 token 产出与每美元 LPDDR 容量

解码（decode）是推理中逐个生成 token 的阶段，每生成一个 token 都要重新读取一遍模型权重。因此每用户速度由内存带宽决定。每瓦吞吐量则取决于每次读取由多少用户共享（批处理），以及机架能否把大型 MoE 模型高效地分布到多颗芯片上。英伟达在大型 MoE 模型的每兆瓦 token 产出上胜出，是因为其 72 GPU 的 NVLink 域允许一个模型以高带宽分布到整个机架（为什么域的规模很重要）。高通的 LPDDR 设计做出的是相反的取舍：每张卡拥有大量廉价、低功耗的容量，但每 GB 的带宽很低（内存墙）。

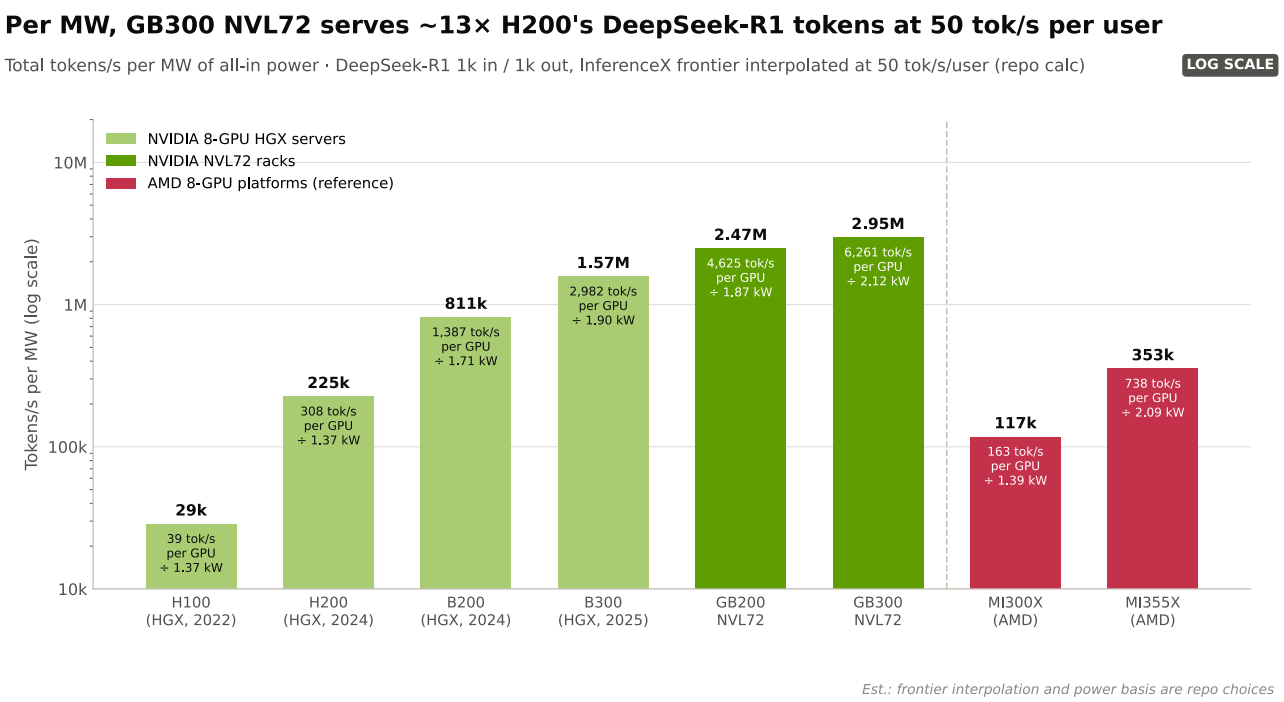


> 对数坐标柱状图：在每用户 50 tokens/s 条件下，DeepSeek-R1 每兆瓦全口径功耗的每秒 token 产出（InferenceX 前沿值除以 SemiAnalysis 的单 GPU 功耗）：H100 约 2.9 万，H200 约 22.5 万，B200 约 0.8 百万，B300 约 1.6 百万，GB200 NVL72 约 2.5 百万，GB300 NVL72 约 3.0 百万，约为 H200 的 13 倍；AMD MI300X 约 11.7 万，MI355X 约 35.3 万。

> 双联横向柱状图。在每用户 50 tokens/s 条件下，GB300 NVL72 按全价计算每百万 token 成本约 $0.156，而竞品在加速器系统免费赠送的情况下成本分别为：MI355X（8-GPU）$0.480、Trainium2 $0.817、Trainium3 $0.297、TPU v7（外部所有者）$0.242、TPU v7（谷歌自用）$0.214、Helios MI455X $0.062；只有 Helios MI455X 在免费时胜过 GB300。在每用户 100 tokens/s 条件下，GB300 成本约 $1.74，除 Trainium2 外所有免费版本都低于它（TPU v7 外部免费为 $0.78）。“免费也不够便宜”的论点只在英伟达机架级吞吐量领先幅度很大的地方成立。

上图的免费芯片测试是任何推理挑战者面临的最严格约束。在聊天速度（每用户 50 tokens/s）下，即使免费的 MI355X、TPU 或 Trainium，产出 token 的成本也高于付费购买的 GB300。在每用户 100 tokens/s 下，多数免费竞品的成本低于 GB300（估计）[S14000]。因此，挑战者选择在哪个工作点（operating point）上竞争，是一项战略决策，而非基准测试细节。

**提示**

**算例 —— LPDDR 与 HBM：按每 GB 和每次读取比较。** 摩根士丹利对 Vera Rubin 机架的数据隐含 54 TB LPDDR5X 约 $1.1M，约合每 GB $20（🔴 本资料库测算）[S332,S362]。伯恩斯坦（Bernstein）预计 2027 年 HBM4 约为每 GB $53 [S333]。按这些价格，768 GB 采用 LPDDR 约需 $15.6K，采用 HBM4 约需 $40.7K。带宽则恰恰相反。Cloud AI 100 Ultra 每秒约可完整读取其 128 GB 内存 4.3 次（0.548 TB/s ÷ 128 GB）。Rubin GPU 每秒约可读取其 288 GB 内存 67 次（19.2 TB/s ÷ 288 GB），频率约高 16× [S172,S90006]。**结论：**在容量受约束的场景（低批量下的超大模型、长 KV 缓存、同时常驻多个模型），LPDDR 胜出；在带宽受约束的场景（大型 MoE 模型上的快速聊天），HBM 胜出。AI200 的带宽尚未披露，因此还无法确定两者的交叉点。

**A reported AI200 rack holds ~43 TB on its cards, 2x Rubin's HBM4, but Vera Rubin adds 54 TB of LPDDR5X behind its CPUs**

Memory per rack in TB (accelerator-attached vs CPU-attached LPDDR5X) and accelerator memory per kW of rack power

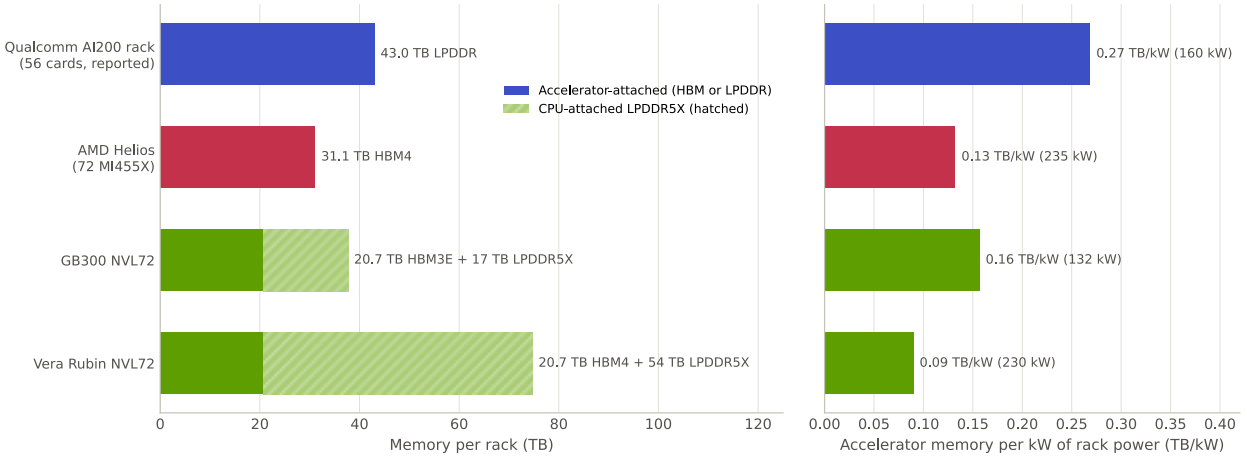


*AI200 rack configuration from low-tier reports (single configuration); host DRAM of AI200 and Helios not counted.*

Source: data from Qualcomm, NVIDIA, AMD specifications and press reports [S173] [S19003] [S19005] [S344] [S144] [S90021] ...; chart by repo · As of 2026-11-05

双联柱状图。左：每机架内存。据报道 MWC 2026 上展示的 56 卡配置中，一个高通 AI200 机架的加速器上共有约 43 TB LPDDR；AMD Helios 为 31.1 TB HBM4；GB300 NVL72 为 20.7 TB HBM3E 外加约 17 TB CPU 侧 LPDDR5X；Vera Rubin NVL72 为 20.7 TB HBM4 外加 Vera CPU 上的 54 TB LPDDR5X，合计约 75 TB。右：每 kW 机架功耗对应的加速器侧内存：AI200 在 160 kW 下约 0.27 TB/kW，GB300 为 0.16，Helios 为 0.13，Vera Rubin 为 0.09。每瓦容量有利于 LPDDR 设计；带宽（高通尚未披露 AI200 的带宽）则有利于 HBM（Vera Rubin 每机架 1,400 TB/s）。

**HBM4 is 16× faster than LPDDR5X but holds 1/5 as much; SRAM is ~8× faster again**

Memory bandwidth vs capacity per chip · marker = memory type, color = vendor · grey strip = bandwidth not disclosed

LOG SCALE

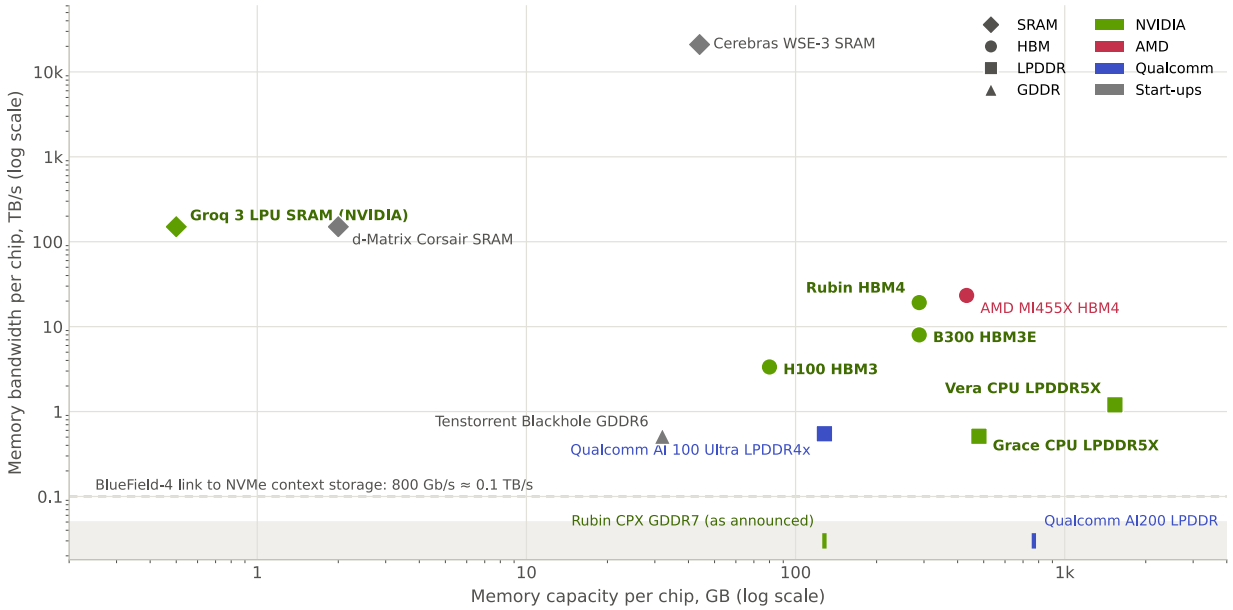


Source: data from NVIDIA, AMD, Cerebras, d-Matrix, Qualcomm, Tenstorrent specs [S100] [S101] [S33005] [S33004] [S103] [S33007] ...; chart by repo · As of 2026-11-05

每颗芯片内存容量与带宽的双对数散点图。SRAM 设计位于左上：英伟达 Groq 3 LPU 0.5 GB、约 150 TB/s，d-Matrix Corsair 2 GB、150 TB/s，Cerebras WSE-3 44 GB、21,000 TB/s。HBM 位于中间：H100 80 GB、3.35 TB/s，B300 288 GB、8 TB/s，Rubin 288 GB、19.2 TB/s，AMD MI455X 432 GB、23.3 TB/s。LPDDR 位于右下：Grace 480 GB、0.5 TB/s，Vera 1,536 GB、1.2 TB/s，高通 AI 100 Ultra 128 GB、0.55 TB/s；高通 AI200（768 GB）和 Rubin CPX（128 GB GDDR7）未披露带宽。通往 NVMe 上下文存储的 BlueField-4 链路传输速率约 0.1 TB/s。

**注意**

**误区与事实：“内存容量是高通的护城河。”** 容量是共有的阵地。每颗 Vera CPU 配备约 1.5 TB LPDDR5X（每机架 54 TB）[S362]，并通过 1.8 TB/s 的 NVLink-C2C 与 GPU 一致性互连 [S209]。Rubin Ultra 的目标是在 2027 年下半年实现每封装 1 TB HBM4E [S305]。英特尔的推理 GPU 配备 160 GB LPDDR5X，将于 2026 年下半年送样 [S162]；d-Matrix 则将 SRAM 与 LPDDR 搭配使用 [S2511]。容量优势只有与软件、成本，以及在明确工作点上公布的每 token 成本结果结合起来，才能守得住。

## 3.2 受电力约束的部署

“受电力约束”涵盖两种不同的情形，而且它们指向相反的方向。当**电网接入**是上限时，买家会追求每兆瓦 token 产出最大化。这是英伟达最强的指标，这也是第 18 章将电力评为英伟达的时间性风险而非份额流失风险的原因 [S18027]。当**园区条件**是上限时，机架根本进不了场。风冷机房、较老的企业机房和电信边缘站点无法容纳全口径功耗约 238 kW 的 Vera Rubin 机架（估计）[S622]。在这些地方，竞争发生在以每瓦性能衡量的 PCIe 加速卡之间。电网稀缺是真实存在的：PJM 的容量价格在三次拍卖中从每 MW-日 $28.92 升至 $333.44，美国新项目在并网排队中要等待超过 48 个月 [S18016,S8009]。

> **提示**
>
> **算例 —— 两种不同的兆瓦。** 在一个新建的 100 MW 园区，按第 14 章的模型，GB300 NVL72 在 70% 利用率下每年约可产出 5.7 千万亿（quadrillion）个 token。MI355X 集群在年度成本大致相当的情况下约为 0.7 千万亿（估计）[S14000]。挑战者在这里必须比拼的是每兆瓦 token 产出，而非每卡功耗。而在一个为约 15 kW 机架建造的现有机房中（🔴 示意），NVL72 级别的机架根本放不进去。一张 150 W 的 Cloud AI 100 Ultra 则可装入标准服务器 [S172]。**结论：**对低功耗设计而言，“受电力约束”带来的机会在于普通数据中心和边缘站点的存量设施，而不是新建的吉瓦级园区。

### 3.3 特定工作负载

**智能体编排 CPU。** 智能体 AI（agentic AI）工作负载需要调用工具、运行代码并协调大量模型调用，其中很多工作在 CPU 上运行。英伟达表示，本财年独立 CPU 营收的可见度接近 $20B，并提到“$200B”的 CPU 市场机会 🟡 [S4522]。C1000 的 >250 个内核约为 Vera 88 核的 2.8×，与 AMD 256 核的 EPYC Venice 持平 [S90056,S100,S144]。这一市场已相当拥挤：AMD 约占 x86 服务器 CPU 营收的 46%，Arm 现在也向 Meta 销售自己的 136 核 AGI CPU [S4503,S4510]。Meta 同时也是 C1000 的首个客户 [S90058]。

> **提示**
>
> **算例 —— 两个截然不同的 CPU 支出池。** 在英伟达机架内，36 颗 Vera CPU 约值 $0.18M，约占一个约 $7.8M 的 Vera Rubin NVL72 的 2%（估计）[S331]。经 Fusion 接入的 CPU 争夺的正是这一薄薄的份额。英伟达约 $20B 的独立 CPU 营收可见度，相当于约 110,000 个此类机架中的 Vera 价值含量（🔴 本资料库测算）[S4522]。**结论：**头节点 CPU 的价值主要在英伟达机架之外，这正是 C1000 这类独立芯片所瞄准的方向，也是 x86 和超大规模云厂商自研 Arm CPU 已在竞争的领域。

**推荐与排序。** 排序模型的主体是大型嵌入表。它们对容量的需求高于带宽，这适合 LPDDR：Meta 的 MTIA v2 以 128 GB LPDDR5、约 0.2 TB/s 带宽和 90 W 功耗运行这类模型 [S159,S160]。但推荐算力最大的买家已经自研芯片，并且此后已将 MTIA 转向 HBM [S15003]。商用芯片的机会在于第二梯队平台和企业，这是一个更小、可见度更低的支出池（🔴）。

**中小型稠密模型。** 一个 FP8 精度的 70B 参数模型（约 70 GB）可装入一张 Cloud AI 100 Ultra，并留出约 58 GB 用于 KV 缓存。由于 LPDDR 每 GB 带宽较低，单个用户只能获得约 8 tokens/s，而在 Rubin GPU 上约为 274 [S172,S90006]。为多个用户进行批处理可以恢复每卡吞吐量。稠密模型从 72 GPU 域中获益也很少。在 SemiAnalysis 的测试中，当每用户速度低于 225 tokens/s 时，MI355X 在 vLLM 每 token 成本上胜过 B200 [S623]；而一台已折旧的 H100 租金约为每小时 $2.35 [S12516]。这是一场与旧款 GPU 比拼每 token 成本的竞争，而在这个市场上，固定能力 token 的价格两年内下降了约 286×（token 价格通缩）[S11526]。

**主权项目。** 主权买家希望实现本地控制和多供应商采购。英伟达在 FY2026 统计的主权 AI 营收超过约 $30B [S90071]，而 HUMAIN 同时向三家商用芯片厂商采购 [S13003,S13517,S90030]。

**Sovereign deals name ~1.03M NVIDIA GPUs; HUMAIN and Korea are 84% of them**

GPUs named in country-level AI-factory announcements, May 2024 - Feb 2026; hatched = press-reported, solid = company-confirmed

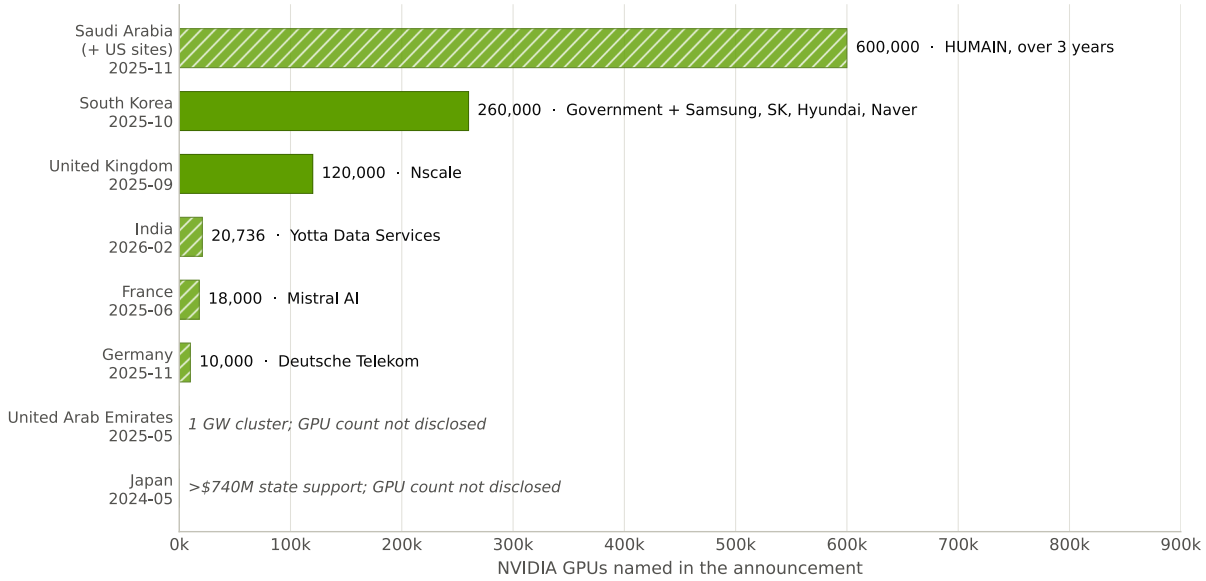


Source: data from NVIDIA and partner announcements and press [S13016] [S13007] [S13008] [S13011] [S13012] [S13009] ...; chart by repo · As of 2026-11-05

主权 AI 公告中提及的英伟达 GPU 数量横向柱状图：沙特阿拉伯 HUMAIN 三年内最多 600,000 颗（分布于沙特和美国，2025 年 11 月），韩国 260,000 颗（2025 年 10 月：政府 50,000 颗，三星、SK 和现代各 50,000 颗，Naver 60,000 颗），英国到 2026 年底 120,000 颗，印度 Yotta 20,736 颗 B300，法国 Mistral Compute 18,000 颗 Grace Blackwell，德国电信 10,000 颗。合计约 1.03M 颗 GPU，其中 84% 来自沙特和韩国的交易。Stargate UAE（1 GW）和日本的补贴云（>$740M）未披露 GPU 数量。

**提示**

**算例 —— 高通在单一主权买家中的份额。** HUMAIN 的公开计划：三年内最多 600,000 颗英伟达 GPU，最多 500 MW、金额最高 $10B 的 AMD 产品，以及 200 MW 的高通 AI200/AI250 [S13003,S13517,S90030]。按 SemiAnalysis 估算的每颗 GB300 或 Vera Rubin GPU 全口径 2.1–3.3 kW 计算，600,000 颗英伟达 GPU 约需 1.3–2.0 GW [S622]。因此，高通的 200 MW 约占 HUMAIN 已公布容量的 7–10%（🔴 本资料库测算）。**结论：**锚定客户是真实的，但需要与他人分享。英伟达是 HUMAIN 的主要供应商，因此第二供应来源靠的是价格或适配度取胜，而非独家地位。

## 3.4 边缘到云的连续性

边缘到云的连续性是指同一个模型系列、文件格式和工具链可以在终端设备、边缘服务器和云端机架上运行。混合 AI（hybrid AI）则将每个工作负载拆分到这些层级上执行。高通的资产覆盖每一个层级。骁龙的 Hexagon NPU 是 llama.cpp 和 ONNX Runtime（QNN）支持的后端 [S579,S585]。Mojo 宣称可以用一套代码覆盖 CPU、GPU 和 NPU [S9023]。Cloud AI 100 和 AI200 覆盖数据中心一端。英伟达自己的边缘计算平台（游戏、专业可视化、汽车和 OEM）在 Q2 FY2027 营收为 $7.2B [S405]。

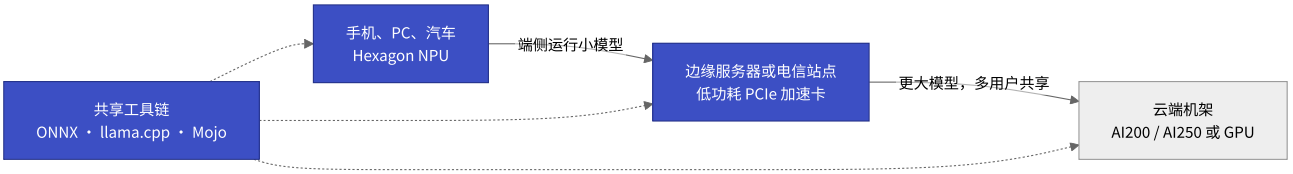

**Qualcomm out-sells NVIDIA at the edge ($8.5B vs $7.2B a quarter), but NVIDIA's datacenter quarter is ~71x Qualcomm's goal**

Quarterly revenue, US$ B: Qualcomm QCT Q3 FY2026 vs NVIDIA Q2 FY2027 (quarters ending June-July 2026)

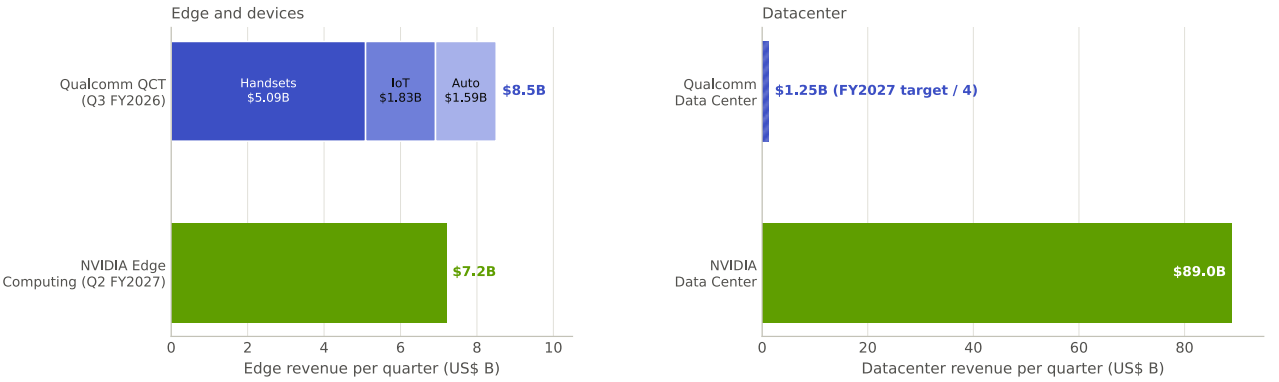


*Hatched = company target divided by four, not reported revenue. Segments are not like-for-like.*

Source: data from Qualcomm and NVIDIA quarterly results [S19002] [S405] [S90011] [S15512] [S15513]; chart by repo · As of 2026-11-05

季度营收双联横向柱状图。边缘：截至 2026-06-28 的季度，高通 QCT 芯片营收约 $8.5B（手机 $5.09B、物联网 $1.83B、汽车 $1.59B），而英伟达边缘计算平台在截至 2026-07-26 的季度为 $7.2B（原游戏、专业可视化、汽车和 OEM）。数据中心：同一季度英伟达数据中心平台为 $89.0B，而高通 FY2027 年 $5B 数据中心目标隐含每季度 $1.25B（阴影表示），比例约为 71 比 1。

**提示**

**算例 —— 相对于边缘基本盘，这些目标意味着什么。** 截至 2026-06-28 的季度，高通芯片营收为 $8.50B [S19002]。FY2027 年 $5B 的数据中心目标平均每季度 $1.25B，约为该基本盘的 15%。FY2029 年 $15B 的目标平均每季度 $3.75B，约为 44% [S15512,S90059]。高通还设定了到 FY2029 实现 $40B 非手机营收的目标 [S19004]。**结论：**相对于高通自身而言，数据中心目标规模很大，这也是连续性作为卖点很重要的原因。目前尚无公开证据表明有买家因为终端设备领域的既有地位而选择某款云端加速器（🔴）。

## 4. 逐层看自建、收购或合作

下表为每一层配对一个自建问题、一个收购问题和一个合作问题，并列出能够回答这些问题的证据。“收购”一栏只列出各层价值链页面上提及的私营公司或近期被收购的公司，并附其最近一次公开估值。这些只是说明市场上现有哪些公司的示例，而非收购目标。

| 层 | 自建问题 | 收购问题（公开示例） | 合作问题 | 能回答该问题的证据 |
|---|---|---|---|---|
| 02 加速器 | 一个团队能否同时维持年度商用迭代节奏（AI200 → AI250 → AI300）和 AWS 定制芯片项目? | SRAM 或近存解码 IP 能否补上一个快速档? d-Matrix（$2B）、Positron（$5B）、Etched（$10.3B） S2511,S11521,S2507 | 是否需要一家设计服务合作伙伴来获取台积电产能，就像世芯（Alchip）之于 Trainium3? S2517 | AI200 批量出货；MLPerf 或 InferenceX 提交结果；自 2027 财年第一季度起的 AWS 营收 |
| 03 内存与供应 | 近存计算和 HBC 能在多大程度上缩小带宽差距? | 容量层级是否值得拥有? Panmnesia（CXL，>$250M） S3523；Celestial AI 已以 $3.25B 归入美满电子（Marvell） S2513 | 在合约价格单季上涨 93–98% 之际，是否与 DRAM 厂商签订长期协议（LTA）或预付款? S3518 | LPDDR 合约价格；实测的 AI250 有效带宽 |
| 04 CPU | C1000 能否在 2028 年下半年面对下一代 Vera 和 EPYC 时如期达标? | 大部分独立 CPU 团队已被收购：Ampere 归软银（$6.5B），Rivos 归 Meta S4530,S4518 | 在英伟达机架内占据 Fusion 插槽，还是只做独立头节点? | Fusion CPU 出货日期；C1000 送样；Meta 部署量 |
| 05 纵向扩展 | 自建 UALink/ESUN 交换机，还是依靠商用厂商为 AI300 提供? | Upscale AI（约 $2B，UALink 交换机）、Ayar Labs（约 $3.75B，光 I/O）、Lightmatter（$4.4B） S6518,S5511,S2510 | NVLink Fusion（须使用英伟达芯片和交换机）vs UALink（产品 2027 年推出）vs ESUN S5018,S90051,S576 | 首批 UALink 交换机批量出货；Fusion 授权条款 |
| 06 横向扩展与光学 | Alphawave IP 能在面向 AWS 的 1.6T 光学器件之外走多远? | Nexthop AI（$4.2B）、Xscape Photonics（激光器） S6517,S6520 | AI200 机架是否需要商用以太网和 Ultra Ethernet 合作伙伴? | AWS 光学器件营收；英伟达分别向 Lumentum 和 Coherent 投资 $2B 之后的激光器供应情况 S6511 |

| 层 | 自建问题 | 收购问题（公开示例） | 合作问题 | 能回答该问题的证据 |
|---|---|---|---|---|
| 07 DPU 与网卡 | 是否基于 Alphawave SerDes 自建 UEC 网卡? | Xsight Labs（$2.8B）；Enfabrica 式的“授权加团队”交易（>$900M） S7517,S475 | 在高通机架中采用博通、AMD 还是英伟达的网卡? | 推理买家是否要求特定厂商的网卡；每机架网卡成本 |
| 08 机架 | 机架设计保留在内部（AI200）还是交给 OEM? | ZT 式设计团队（AMD 净成本约 $2B）；冷却与 800 V 供电初创公司 S5527,S8519 | 采用 ODM/EMS（Sanmina 模式）还是 OEM 品牌? S5528 | HUMAIN 机架交付；OEM 上架 AI200 系统 |
| 09 系统软件 | 扩大 Mojo 的采用，还是同时提供 Triton 和 vLLM 后端? | 仍有小型编译器团队（Luminal，种子轮） S9534 | 上游 PyTorch 和 Triton 维护者 | 高通芯片上的新模型首日支持；框架支持（目前 36 分中得 4 分） |
| 10 软件库 | 是否只对标 AI 核心（GEMM、注意力、集合通信）? | 领域软件库很少出售；厂商中立的 Voltron Data、Anyscale S10561,S10562 | 采用开放数据引擎，而非克隆 CUDA-X（第 10 层） | 推理买家实际需要哪些 CUDA-X 领域 |
| 11 推理软件 | 让 MAX 成为差异化所在，还是依托上游 vLLM? | 推理引擎公司：Inferact（$800M，vLLM）、RadixArk（$400M，SGLang） S11511,S11513 | 以推理云（Together AI $8.3B、Baseten $5B）作为首发客户? S11516,S11518 | InferenceX 结果；服务商上架高通算力 |
| 12 编排与云服务 | 没有自有算力，仅靠机架软件是否足够? | 像英伟达那样持有新兴云服务商股权 | 拥有已签约但尚未建成电力的新兴云服务商；谷歌式租约兜底 S12525 | 有新兴云服务商公开提供高通算力 |
| 13 生态与资本 | 是否建立能与 CUDA 覆盖面相匹配的开发者计划? | 以股权换产能（认股权证）以及与主权基金共同投资 | HUMAIN、Meta、AWS；资产管理机构融资平台 | 认股权证归属披露；已部署兆瓦数；单独披露的数据中心分部营收 |

**Qualcomm's three priced datacenter buys total $7.7B; the gaps it has not filled (NIC, DPU, rack teams) traded at $0.2-4.9B elsewhere**

Announced or reported deal value, US$ B (log scale), by capability bought and stack layer, 2015-2026

LOG SCALE

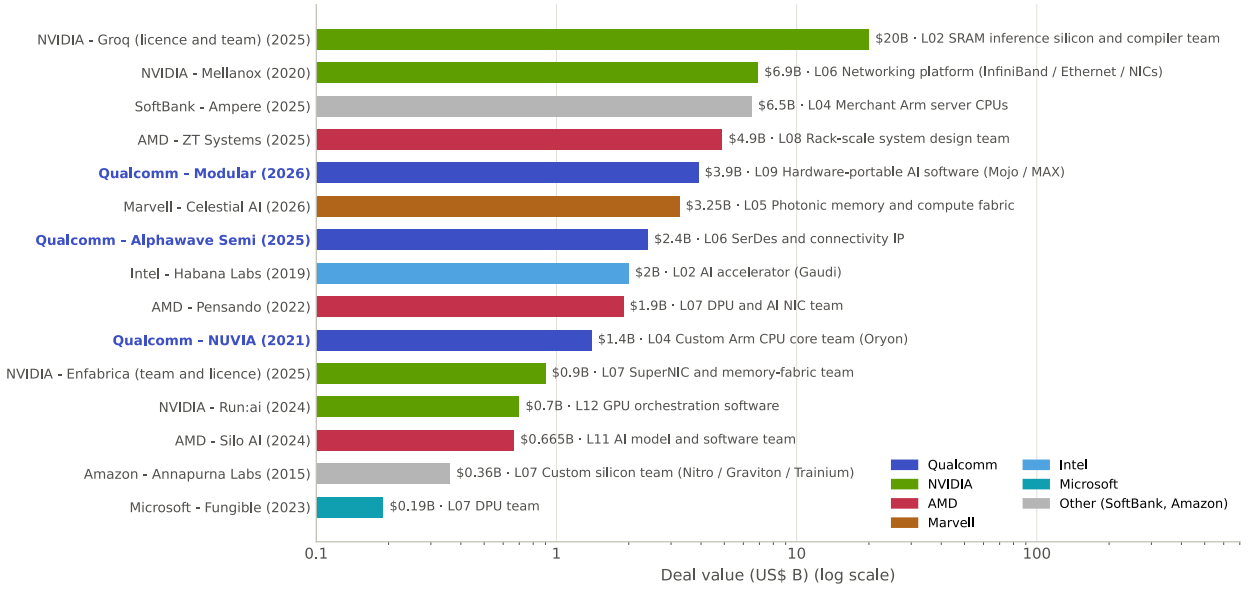


*Values are not like-for-like (licences, gross vs net, upfront vs earn-outs).*

Source: data from company announcements and press reports [S7504] [S4540] [S9506] [S476] [S475] [S4538] ...; chart by repo · As of 2026-11-05

数据中心能力交易的对数坐标横向柱状图。高通（靛蓝色）：NUVIA CPU 内核 $1.4B（2021）、Alphawave SerDes 与连接 IP 约 $2.4B（2025）、Modular 可移植 AI 软件 $3.9B（2026），合计 $7.7B；Ventana（RISC-V）金额未披露。作为对比：英伟达的 Groq 授权与团队约 $20B、Mellanox $6.9B、Enfabrica >$0.9B、Run:ai 约 $0.7B；软银收购 Ampere $6.5B；AMD 收购 ZT Systems $4.9B（净额约 $2B）、Pensando 约 $1.9B、Silo AI $0.665B；美满电子收购 Celestial AI 首付 $3.25B；英特尔收购 Habana 约 $2B；亚马逊收购 Annapurna 约 $0.36B；微软收购 Fungible 约 $0.19B。高通尚未公开收购的能力（如网卡、DPU 和机架设计团队）的成交价在 $0.19-4.9B 之间（第 07 层和第 08 层）。

> **提示**
>
> **算例 —— 网卡（NIC）的三种获取方式与价格。** AMD 斥资约 $1.9B 收购 Pensando，用了约 4 年才推出 800G AI 网卡。英伟达支付 >$900M 获得 Enfabrica 的团队与技术授权 [S7527,S475]。为每颗加速器采购两张商用 800G 网卡，每个 72 加速器机架约需 $0.2–0.4M，按每年 1,000 个机架计为每年 $0.2–0.4B（估计，第 07 层）（价值链）。**结论：**在每年数百个机架的规模下，合作更便宜。只有达到一定规模，或者网卡控制权决定了哪些机架能胜出时，自有网卡才划算。

**CUDA scores 36/36 on framework support; ROCm 26, Huawei 17, Qualcomm 4**

Sum of 0–3 support scores across 12 AI frameworks (max 36); TPU and Neuron lean on their own stacks (JAX, NxD)

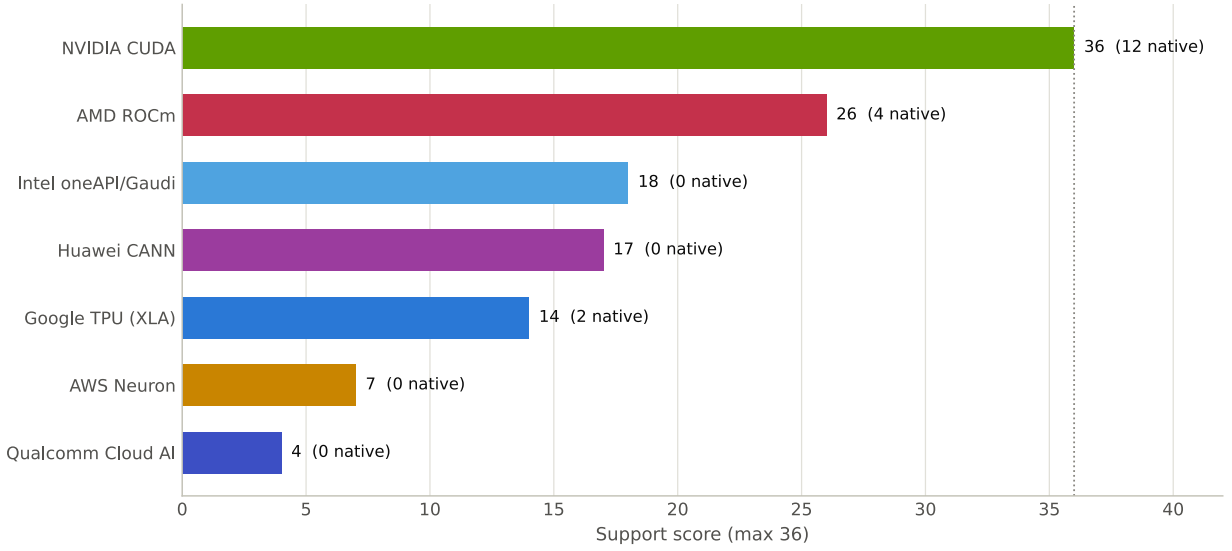


Source: data from Framework docs and READMEs (GitHub), vendor docs [S587] [S586] [S553] [S595] [S594] [S522] ...; chart by repo · As of 2026-11-05

12 个框架的支持得分加总横向柱状图：英伟达 CUDA 36 分（满分 36，12 个框架中原生支持 12 个），AMD ROCm 26 分（原生支持 4 个），英特尔 18 分，华为 CANN 17 分，谷歌 TPU 14 分（在 JAX 和 TensorFlow 中原生支持），AWS Neuron 7 分，高通 Cloud AI 4 分。

> **🔧 技术细节：纵向扩展互连的选择（NVLink Fusion vs UALink vs ESUN）**
>
> 三种互连方案在时间、控制权和开放性之间各有取舍（NVLink Fusion）：
>
> - **时间。** Fusion IP 自 2025 年 5 月起对外提供，AWS 于同年 12 月承诺 Trainium4 采用该方案 [S131,S518]。UALink 2.0 于 2026 年 4 月获批，但产品预计要到 2027 年才推出 🟡 [S90050,S90051]。
> - **控制权。** Fusion 是一项授权，而非标准。有报道称，英伟达要求链路中使用其自有芯片和交换机 [S5018]。UALink 允许任何厂商制造交换机；Upscale AI 的首款 UALink 交换机目标于 2026 年第四季度推出 🟡 [S5506]。ESUN 在 OCP 框架下基于商用以太网运行，英伟达是其创始成员之一 [S576,S90052]。
> - **可选性。** Alphawave 的 SerDes IP 在两个阵营中都可使用 [S4513]。高通的公开计划是 CPU 采用 Fusion，2028 年的加速器采用 UALink/ESUN [S90031,S90060]。这让两扇门都保持敞开，但代价是两套集成工作。决策路标是 2027 年 UALink 交换机的出货量，以及尚未公开的 Fusion 商业条款。

## 5. 情景推演（🔴）

2028–29 年的三种终局界定了选项的范围。路标（signpost）来自第 18 章的领先指标仪表盘。这些情景并不互斥。第 18 章认为，缓慢的“够用芯片”路径（第一种与第三种情景的混合）比急剧重置更有可能发生。

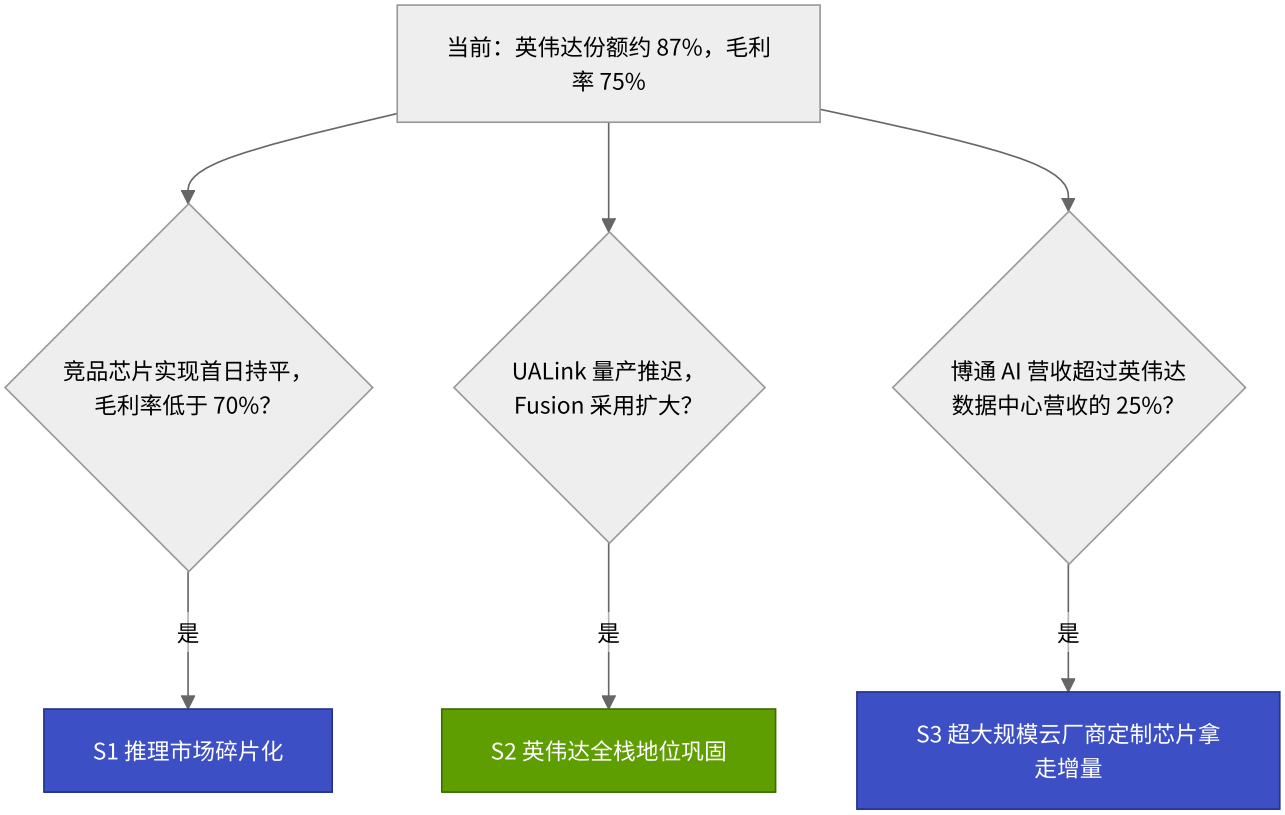


| 情景 🔴 | 需要满足的条件 | 对拥有高通公开资产的挑战者意味着什么 | 路标（第 18 章） | 2026 年 11 月的读数 |
|---|---|---|---|---|
| **S1 推理市场碎片化** | 开源推理服务引擎在各类芯片上实现首日持平；买家按工作负载、依据每 token 成本进行选择；英伟达毛利率向 65% 上下回落 | 商用推理利基市场和可移植软件（Mojo、MAX）的价值上升。价格下降，因此公开的基准测试结果和运营成本最为关键 | AMD 首日滞后低于 7 天（目前 26 天）[S631]；英伟达毛利率低于 70%（目前 75.0%；FY2028 指引 72–73%）[S405,S18000]；H100 指数低于 $1.70 | 正在演进：滞后缩短，毛利率指引下调 |
| **S2 英伟达全栈地位巩固** | NVL72 和 Kyber 保持每兆瓦 token 产出的领先；Groq 3 LPX 覆盖快速档；Fusion 把定制芯片拉进英伟达机架 | 合作角色（Fusion CPU、SerDes IP、光学器件）比商用加速器更有价值。利基市场在低功耗和边缘场景中得以存续 | Trainium4 搭载 NVLink 出货 [S518]；UALink 量产推迟到 2027 年以后 [S90051]；超大规模云厂商维持约 55% 的数据中心营收占比 [S406] | 部分成立：Fusion 采用在增加；UALink 芯片尚在实验室 |
| **S3 超大规模云厂商定制芯片拿走增量** | 到 2030 年 ASIC 出货量份额向约 40% 迈进；博通实现约 $115B 的 FY2027 目标 [S2517,S15501] | 面向超大规模云厂商的设计服务、IP 和 CPU 构成主要支出池。AWS 交易就是样板。单位利润率更低，且买家高度集中 | 博通 AI 营收 ÷ 英伟达数据中心营收超过 25%（上一季度约 19%）[S2516]；TPU 在谷歌以外的销售；AWS 认股权证的归属节奏 [S15510] | 演进最快 |
| **变体：受电力约束、偏重边缘** | 电网限制持续形成约束；更多推理转移到终端设备和小型站点 | 低功耗加速卡和终端设备基本盘的价值上升，但吉瓦级园区仍看重每兆瓦 token 产出 | PJM 价格触及上限 [S18016]；新兴云服务商已投运与已签约电力之比 [S12010]；端侧推理后端 [S579] | 电网偏紧；边缘拉动尚未得到验证 |

**提示**

**算例 —— 定制芯片路标还有多远？** 博通对截至 2026 年 11 月初的季度给出 $21.7B 的 AI 营收指引 [S2516]。与英伟达最近一次公布的数据中心季度营收（$89.0B）相比，约为 24% [S405]。如果在 $108B 的 Q3 指引中，数据中心业务维持 Q2 约 92% 的营收占比（$96.2B 中的 $89.0B）（🔴 假设），该比例约为 22% [S90012]。**结论：**距离第 18 章的 25% 阈值只差一两个季度的财报。S3 的路标可能先于 S1 或 S2 的路标亮起。

**Broadcom's AI revenue rose from ~12% to ~19% of NVIDIA's data-center revenue in 2026**

Broadcom AI semiconductor revenue ÷ NVIDIA Data Center revenue, same calendar quarter of quarter-end, %

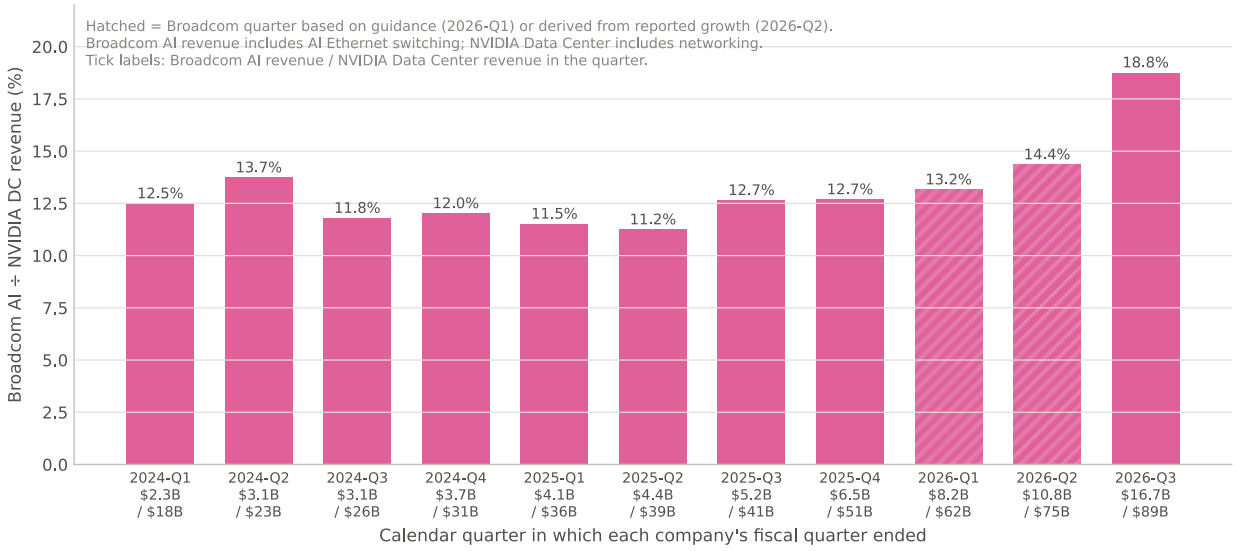


Source: data from Broadcom and NVIDIA filings; repo calculation [S660] [S661] [S451] [S2516] [S403] [S405]; chart by repo · As of 2026-11-05

> 柱状图：2024-Q1 至 2026-Q1，博通季度 AI 半导体营收维持在英伟达数据中心营收的约 11-14%，随后在 2026-Q2 升至 14%（推算值），2026-Q3 升至 19%，当季博通确认 $16.7B，而英伟达为 $89.0B。博通对下一季度的指引为 $21.7B。

## 6. 来自英伟达打法与同行的经验

英伟达的发展历程（第 16 章、第 13 层、CS1、CS2）和同行的举措（CS4、ASIC 设计服务商、CS3）引出了一系列问题。下面每条经验都是来自这些页面的证据。右侧一栏将其转化为一个问题，而非建议。

| # | 经验 | 证据 | 对挑战者提出的问题 |
|---|---|---|---|
| 1 | 用一台现金引擎为平台提供资金，并坚持十年 | CUDA 运行了约 11 年，数据中心营收才覆盖研发投入；FY2009 毛利率从 45.6% 降至 34.3% S400,S22000 | 鉴于 Centriq 在发布约 7 个月后即退出，哪项业务能在下行期为数据中心押注提供资金? S4543 |
| 2 | 在相邻瓶颈形成约束之前将其买下 | Mellanox（$6.9B）在 FY2026 变成了约 $31.4B 的网络营收 S464,S402 | 推理机架的下一个瓶颈是什么：网卡、光学器件、内存接口还是电力? |
| 3 | 不要收购人人依赖的中立层 | $40B 收购 Arm 的交易被阻止；计提约 $1.36B 费用 S466 | 拥有 Modular 是否会降低竞争对手采用 Mojo 的意愿? |
| 4 | 销售系统，并编写参考设计 | ODM 仅保留一个 Vera Rubin 机架价值的约 2%（估计） S332 | 对于 AI200 机架，参考设计由高通编写，还是由 OEM 编写? |
| 5 | 速度本身就是一种交易结构 | Groq 的授权加收购式招聘（licence plus acquihire）几天内即完成；Run:ai 花了八个月 S474,S476 | 这种速度是否值得承受该结构如今招致的监管审查? S13511 |
| 6 | 软件免费送，靠硬件变现 | 软件年化营收约 $1B，而数据中心营收为 $193.7B S9516,S1 | Mojo 和 MAX 应当收费，还是作为入场成本? |
| 7 | 用股权锁定供应 | 分别向 Lumentum 和 Coherent 投资 $2B，并与采购承诺挂钩 S6511 | LPDDR 或封装供应是否稀缺到值得预付款? |
| 8 | 在会与买家竞争的地方后退一步 | DGX Cloud 重新聚焦内部；Lepton 将需求导向合作伙伴云 🟡 S90068 | AWS 定制芯片与向 AWS 竞争对手销售商用 AI200 如何共存? |
| 9 | AMD：用股权换取产能承诺 | 向 OpenAI 和 Meta 发放 1.6 亿股“一分钱认股权证”；AMD 股价从约 $165 升至约 $612 S24000,S24004,S24005 | 平值（at-the-money）认股权证能否换来足够的承诺? |
| 10 | 博通：定制芯片即服务 | FY2026 AI 营收约 $58B；护城河在于 SerDes、封装和集成 S15501 | Alphawave 加 AWS 交易是否构成“简化版博通”模式？利润率能达到多少? |
| 11 | 谷歌：自有芯片的经济性需要规模 | 自研的盈亏平衡点约为每代 130,000 颗芯片（🔴） S23010 | 商用芯片厂商能否达到自研项目所需的出货量? |
| 12 | 英特尔–Habana：仅收购一家加速器公司是不够的 | 在约 $2B 的收购之后，Gaudi 未能实现 2024 年营收目标 S2514,S668 | 哪些里程碑能及早表明 AI200–AI300 走的是一条不同的道路? |

**Per purchase dollar, AMD's penny warrant gave OpenAI ~29% at signing; Qualcomm's AWS warrant pays only if its stock rises**

Intrinsic value of the fully vested warrant as % of the purchases that vest it, vs issuer share price as a multiple of the reference price

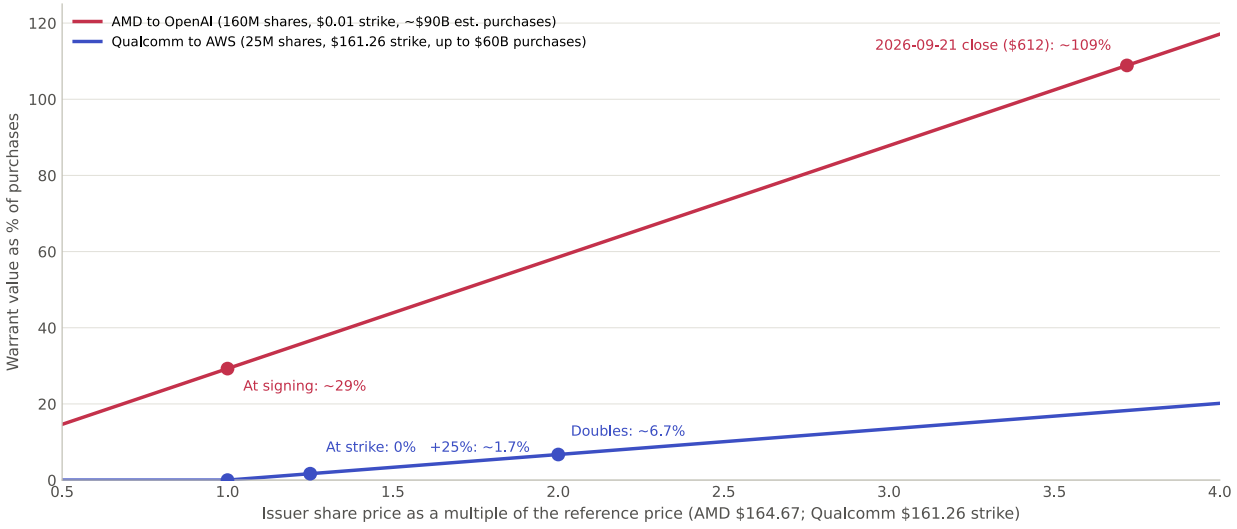


*Ignores time value, vesting hurdles and tax; AMD purchase basis is a repo scenario (speculative).*

Source: data from AMD and Qualcomm warrant terms as reported; CS4 spend scenario [S24000] [S13506] [S24001] [S24010] [S15510] [S90087] ...; chart by repo · As of 2026-11-05

认股权证内在价值占触发其归属的采购额比例的折线图。AMD 给 OpenAI 的认股权证（1.6 亿股，行权价 $0.01，对应本资料库基准情景下 6 GW 约 $90B 的 AMD 硬件采购）在交易前股价 $164.67 时约值采购额的 29%，在 2026-09-21 收盘价 $612.46 时约值 109%。高通给亚马逊的认股权证（2,500 万股，行权价 $161.26，按截至 2036 年最多 $60B 的采购额归属）在行权价时价值为 0%，股价上涨 25% 时约为 1.7%，股价翻倍时约为 6.7%。AMD 的结构是一笔大额股权返利；高通的结构是一份平值期权，只有在高通股价上涨时才有回报。

**提示**

**算例 —— 两份认股权证，同一美元采购额。** AMD 向 OpenAI 发放了行权价 $0.01 的 1.6 亿股认股权证。按交易前股价 $164.67 计，价值约 $26.3B，而 AMD 采购额估计约为 $90B（🔴 CS4 情景），相当于约 29% 的股权返利 S24000,S24001,S24010。高通给亚马逊的认股权证涵盖 2,500 万股，行权价 $161.26，按最多 $60B 的采购额归属 S15510。其内在价值在行权价时为零。股价为 $201.58（+25%）时，价值为 25M × $40.32 ≈ $1.0B，约为 $60B 的 1.7%；若股价翻倍，约为 $4.0B，即约 6.7%（🔴 本资料库测算）。**结论：**按每美元采购额计算，高通结构造成的股权稀释要小得多。它主要在高通股价上涨时才回报 AWS，因此其锁定效果弱于 AMD，但成本也更低。

### At the $600 hurdle, AMD's warrant (~$96B) ≈ OpenAI's 6 GW AMD hardware bill (Est. ~$90B)

Value of 160M AMD shares at $0.01 if fully vested (US$ B) vs share price; band = assumed 6 GW spend at $10–20B/GW

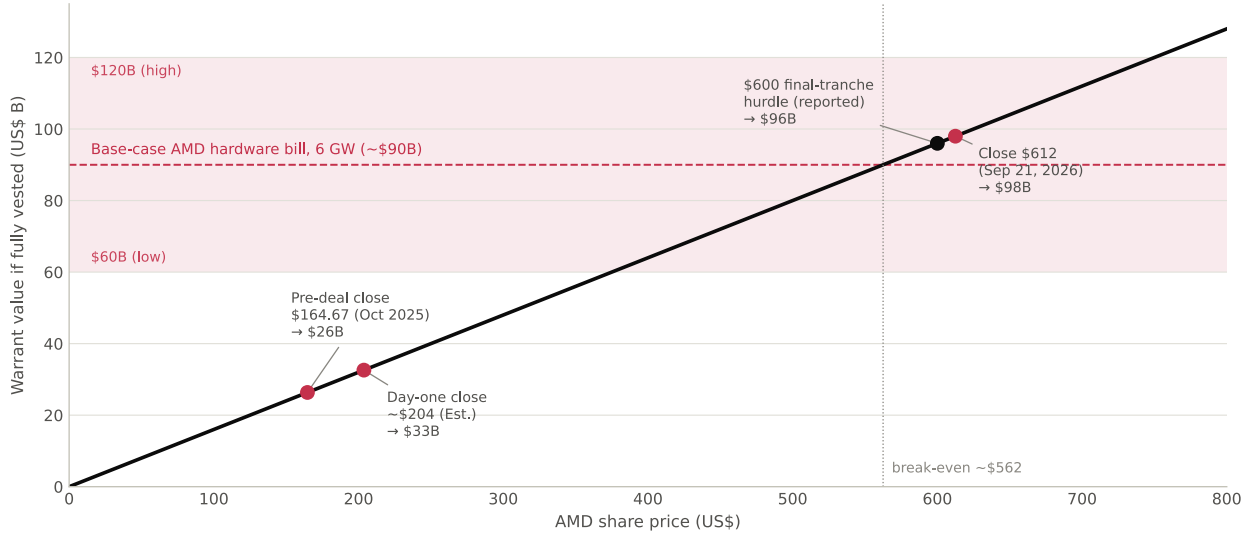


*Band = repo scenario*

Source: data from AMD/OpenAI terms and AMD share prices [S24001] [S24002] [S24005] [S13507] [S24003] [S24000] ...; chart by repo · As of 2026-11-05

折线图：行权价 $0.01 的 1.6 亿股 AMD 认股权证，在交易前股价 $164.67（2025-10-03）时约值 $26B，首日上涨约 24% 后约值 $33B，在据报道的最后一档 $600 股价门槛时约值 $96B，在 2026-09-21 收盘价 $612.46 时约值 $98B。阴影带表示本资料库对 OpenAI 为 6 GW 采购 AMD 硬件支出的假设：$60B 至 $120B（基准 $90B）。股价高于约 $562 时，完全归属的认股权证价值将与基准情景的硬件账单相当；归属还要求 6 GW 全部部署完毕。

### Est.: a custom ASIC repays ~$1.2B of fixed cost after ~87k GPU-equivalents; at half a GPU's speed it needs ~237k

Repo model: cumulative cost (US$ B) to deploy N GPU-equivalents of capacity, merchant GPU vs custom ASIC (NRE + team + unit cost)

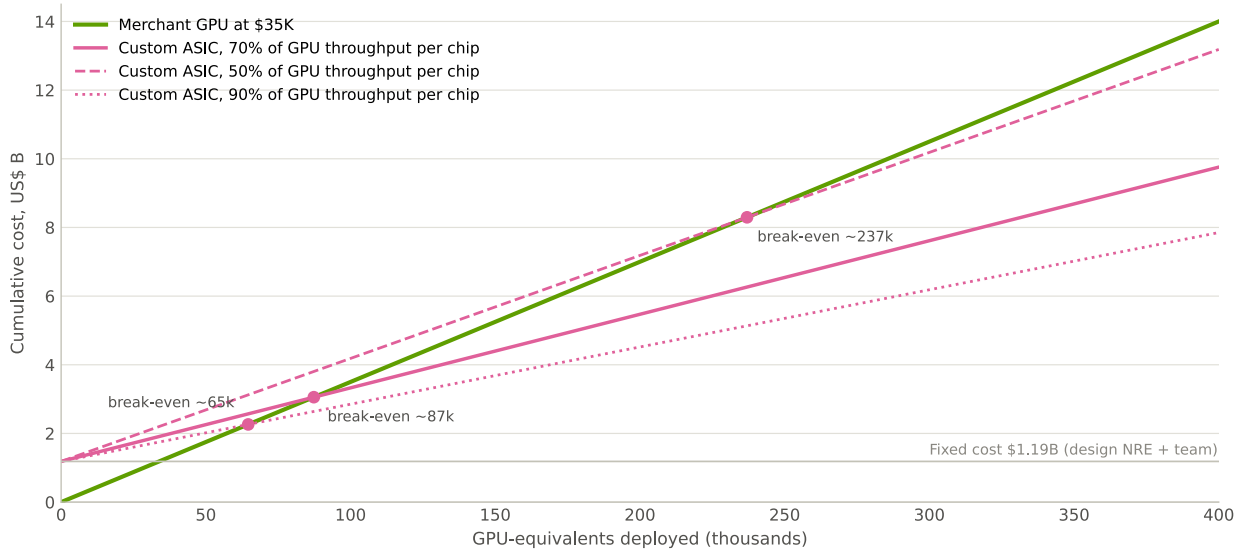


*Illustrative model (speculative inputs); excludes power, networking and opportunity cost*

Source: data from repo model; inputs from Epoch AI, NVIDIA CEO remarks, IBS/Silicon Analysts [S35026] [S35020] [S625] [S628] [S2501] [S401] ...; chart by repo · As of 2026-11-05

本资料库盈亏平衡模型折线图。购买商用 GPU 每颗 $35K，因此成本从零开始直线上升。定制 ASIC 起始固定成本为 $1.19B（约 $0.59B 的 3 nm 设计费和约 $0.6B 的软件与系统团队），每颗芯片成本 $15K。若每颗芯片能完成 GPU 70% 的有效工作，两条线在约 87k 颗 GPU 当量处相交；若为 50%，交点移至约 237k；若为 90%，降至约 65k。只有部署数十万颗加速器的买家才能轻松跨过这一门槛。

**NVIDIA's ~$57B cash pile beats AMD, Broadcom and Qualcomm combined (~$47B)**

Left: cash and liquid securities at latest quarter end (US$ B). Right: free cash flow in the latest quarter found (US$ B). Hatched = aggregator estimate

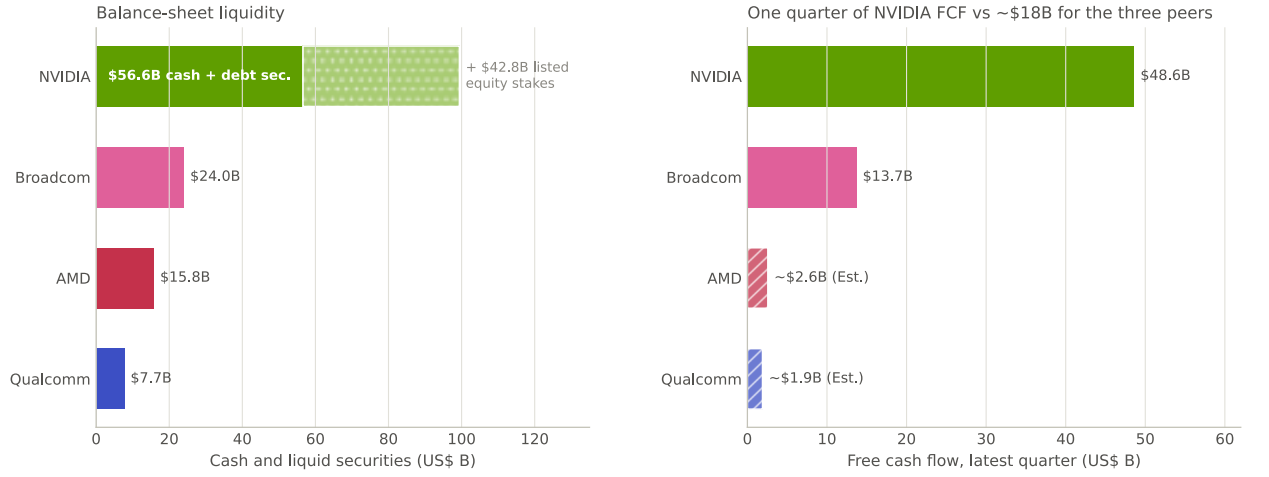


*Periods differ by up to a quarter*

Source: data from company filings and releases [S13500] [S90072] [S403] [S13501] [S13505] [S2516] ...; chart by repo · As of 2026-11-05

双联柱状图。左：最近一个季度末的现金及流动性证券：英伟达现金及债务证券 $56.6B（2026 年 7 月），另有 $42.8B 上市公司股权投资；博通 $24.0B（2026 年 8 月）；AMD $15.8B（2026 年 9 月，债务 $7.1B）；高通 $7.7B（2026 年 9 月，债务 $15.1B），三家同行合计约 $47B。右：最近一个季度的自由现金流：英伟达 $48.6B（Q1 FY2027），博通 $13.7B，AMD 约 $2.6B，高通约 $1.9B（数据汇总平台估计）。

**注**

🐂 **看多观点（对挑战者而言）。** 最重要的买家已经在多源采购。Meta 采购英伟达、AMD 和 TPU，并签约了 C1000。AWS 选择高通开发定制推理芯片。HUMAIN 同时向三家商用芯片厂商采购 S4006,S24004,S90025,S90058,S90087,S13517。增长最快的支出池——定制芯片——是英伟达可以收编但无法阻止的 S2516。高通已经拥有博通式模式中最难买到的几块拼图（SerDes IP、CPU 内核、可移植软件）。

**注意**

🐻 **看空观点（对挑战者而言）。** 目前已出货的只有一款 2023 年的加速卡加上软件。机架、CPU、互连和 AWS 芯片将在 2026–2028 年间推出，届时面对的是 Rubin、Rubin Ultra 和 Feynman S90003,S90004。英伟达持有约 $57B 现金，而高通为 $7.7B，且背负 $15.1B 债务 S13500,S13503。它无法匹敌英伟达的客户融资能力，其认股权证换来的承诺也少于 AMD。第一次尝试在发布约 7 个月后即告终止 S4543。

## 7. 供管理层思考的问题

1. 在 FY2029 年 $15B 的目标中，各角色预计贡献多少：商用 AI200–AI300、为 AWS 及两份 >$1B 超大规模云厂商合同提供的定制芯片、CPU，以及连接 IP？哪些公开披露能揭示这一构成？ S90059,S15511
2. 在哪些工作点（模型规模、批量、每用户 tokens/s）上，AI200 的每 token 成本能胜过 GB300，或胜过每小时约 $2.35 的已折旧 H100？独立结果（MLPerf、InferenceX）何时能证明这一点？ S12516,S602,S620
3. 双轨策略（CPU 采用 NVLink Fusion，AI300 采用 UALink 和 ESUN）是保持了选项开放，还是分散了工程资源？哪个路标（UALink 交换机出货量、Fusion 条款）能给出答案？
4. LPDDR 同样暴露于 DRAM 上行周期之中，而这一周期恰与高通手机营收下降 20% 同时出现 S19002,S3518。哪些合同或预付款能为 AI200 和 AI250 锁定供应？
5. 在新兴云服务商和主权买家采购 AI200 机架之前，哪些缺席的层（网卡/DPU、领域软件库、云算力）需要补齐？答案是自建、收购（先例价格在 $0.2–4.9B 之间）还是合作？

6. 为 AWS 打造的定制芯片与向 AWS 竞争对手销售的商用 AI200 如何共存而不产生渠道冲突?
7. 哪些里程碑能表明此次尝试已越过 Centriq 在发布约 7 个月后止步的那个节点：出货量、客户数量，还是单独披露的数据中心分部? S4543
8. Modular 作为一个也能在英伟达和 AMD 上运行的中立、跨厂商技术栈更有价值，还是作为高通的差异化手段更有价值? 哪些采用指标能说明这一点?
9. 在哪些场景中，边缘到云的连续性是真正的采购标准? 对谁而言（OEM、电信运营商、汽车厂商、主权买家）?
10. AWS 的 $60B 上限中需要有多少转化为确定订单，认股权证才会实质性归属? 归属节奏又会释放什么信号? S15510
11. 如果英伟达能将价格下调约 20% 并仍保留约 66% 的毛利率（🔴），那么英伟达价格降到多低时，AI200 和 AI250 仍能跨过自身的回报门槛? S14000
12. 哪些情景路标（博通超过英伟达数据中心营收的 25%、AMD 首日差距低于 7 天、UALink 出货量、英伟达毛利率低于 70%）会改变合作角色与竞争角色的相对价值?
13. 对于剩余的独立资产（光 I/O、UALink 交换机、网卡团队、推理引擎公司），通过少数股权加商业协议的方式接触，是否比取得控制权更好?
14. 在现金 $7.7B、债务 $15.1B 的情况下 S13503，哪些结构（主权包销、客户预付款、资产管理机构平台）可以在不采用英伟达式资产负债表融资的情况下培育需求?

## 🎯 企业发展视角

1. **价值池。** 对挑战者最开放的支出池是定制芯片：英伟达可以收编但无法阻止，博通单季确认了 $16.7B S2516。商用推理支出池更大，但受到每兆瓦 token 产出的防守（🔴）。高通的每个项目主要服务于哪个支出池? 它们是否在争夺同一批工程师?
2. **互补角色可能是最廉价的杠杆。** Alphawave IP、光学器件和 Mojo 向两大阵营销售，在第 5 节的每一种情景下都会受益（🔴）。哪些公开指标（授权收入、光学器件出货量、第三方对 Mojo 的使用）能表明它们正在持续累积价值?
3. **并购问题集中在缺席的层。** 网卡、DPU 和机架设计能力的成交价在 $0.2–4.9B 之间，而 Xsight Labs（$2.8B）和 Upscale AI（约 $2B）等独立公司仍然存在 S7517,S6518。对于必须从第一天起就能胜出的机架而言，持股加商业协议是否足够，还是控制权至关重要?
4. **交易结构即战略。** “一分钱认股权证”（AMD）以高稀释换取深度承诺；平值认股权证（高通–AWS）以低成本换取较轻的承诺 S24000,S15510。哪种结构适合未来的每一位锚定客户?
5. **时机。** 每款产品面对的都是英伟达的下一代产品，因此第 5 节中的路标是触发重新评估的信号，而非预测。其中哪两三个路标应当促使正式审视自建、收购与合作的选择?