英伟达全栈深度研究

NVIDIA 如何在 AI 训练与推理中变得不可或缺 —— 逐层解析

卷五 · 案例研究与附录

七个案例研究、术语表与参考文献

简体中文参考译文 · 仅供参考，如有出入以英文原文为准
数据与图表截至 2026-11-05 · 仅使用公开信息
英文原版：github.com/FrankHuang94/nvidia_deep_dive_claude

阅读说明

本册为英文研究资料库《NVIDIA Full-Stack Deep Dive》的**简体中文参考译文**，仅供参考；如与英文原文存在任何出入，以英文原文为准。全书共五册，可分册打印。

- **图表**：数据图表与架构图保留英文原版（由仓库中的 CSV 数据生成）；每张图下方的灰色文字为中文图注，概括该图的结论与关键数字。Mermaid 示意图已译为中文。
- **引用**：正文中的灰色上标（如 [S2031]）为来源编号，完整书目见卷五附录“参考文献”（保留英文原题）。
- **可信度标记**：🟢 已确认（公司官方公布）· 🟡 有报道（可信媒体或分析机构）· 🔴 推测（推断、传闻或本资料库的分析）；“估计”表示估算值。
- **对比标记**：🟩 领先 · 🟨 持平 · 🟥 落后 · 🟦 路线不同。
- **三层阅读深度**：每页以“⚡ 要点速览”开篇；正文“原理解析”含“算例”；虚线框为“🔧 技术细节”；页末“🎯 企业发展视角”列出供企业发展团队思考的问题。
- **时效**：数据截至 2026-11-05；英伟达 2027 财年第三季度财报（2026-11-17）与 GTC DC 大会（2026-12-01）晚于此日期。
- **公开信息**：本资料库仅使用公开信息；涉及高通的内容均以问题与选项的形式呈现，不构成建议。

目录

CS1 · Mellanox：最佳交易 4

CS2 · CUDA：十五年的赌注 13

CS3 · 谷歌 TPU：可信的替代方案 22

CS4 · AMD、OpenAI 与第二供应商 30

CS5 · DeepSeek 时刻与效率冲击 40

CS6 · 中国出口管制：H20 及之后 49

CS7 · 吉瓦级 AI 工厂：xAI、Stargate 等 59

术语表（Glossary） 69

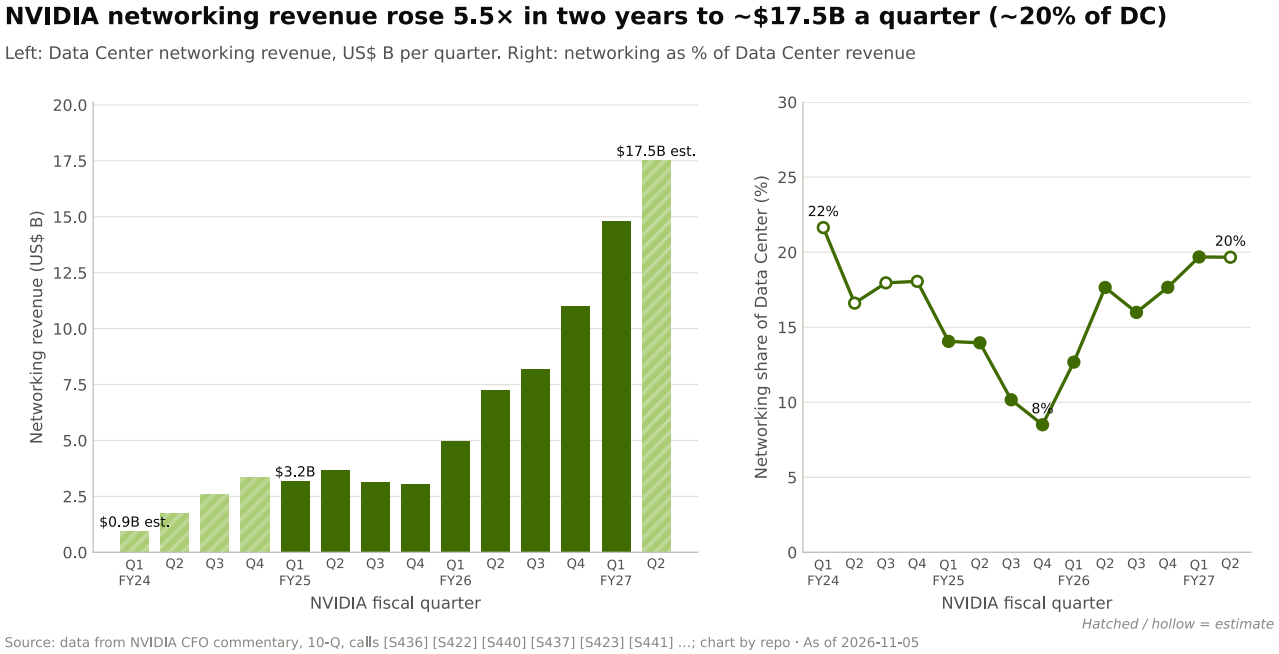
附录 · 参考文献（Bibliography） 94

CS1 · Mellanox：最佳交易

案例研究 · 阅读约 14 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **英伟达（NVIDIA）买下了紧邻自己的瓶颈。** Mellanox 是一家以色列 InfiniBand 与以太网芯片厂商，2019 年收入 $1.33B，毛利率 65.1% [S21000]。英伟达于 2019-03-11 宣布以全现金 $6.9B（每股 $125）收购 [S464]。
- **这是一场激烈竞购的胜出。** 激进投资者 Starboard 在 2018 年迫使董事会就范 [S21006]。随后共有七家竞购方参与，据报道英特尔（Intel）出价约 $6B [S6508,S6509]。
- **中国险些让交易搁浅。** 中国国家市场监督管理总局（SAMR）于 2020-04-16 附条件批准后，交易于 2020-04-27 完成交割，距宣布已过去 413 天 [S21002,S21003,S21005]。
- **回报远超收购价。** 英伟达网络业务 FY2026 收入约 $31.4B，约为 Mellanox 2019 年收入的 24 倍；仅 Q2 FY2027 一个季度就达约 $17.5B [S402,S21008,S408]。该业务线目前还包括 Mellanox 从未销售过的 NVLink 交换机。
- **即便采用严苛假设，回本也很快。** 若只把一半网络业务归功于 Mellanox，并按其自身 65% 的毛利率计算，累计毛利在 FY2025 即超过收购价，到 2026 年年中达到约 $30B（🔴 本资料库模型）[S21014]。
- **风险真实存在，部分至今仍在。** 市场已从 InfiniBand 转向以太网（2026 年第一季度以太网约占 AI 后端交换机销售额的三分之二）[S90054]。英伟达在以色列有 5,000 余名员工，是其美国以外最大的研发基地 [S21011]。SAMR 于 2025 年 9 月初步认定英伟达违反了 2020 年的附加条件 [S9505]。



双面板图表。左：英伟达季度网络收入从 Q1FY24 的 $0.9B（估计）增至 Q2FY27 的约 $17.5B，为 Q1FY25 的 5.5 倍。右：网络收入占数据中心收入的比重在 Blackwell 计算产品放量期间降至 8%，随后随 NVLink、Spectrum-X 与 InfiniBand 规模扩大回升至约 20%。

1. 背景

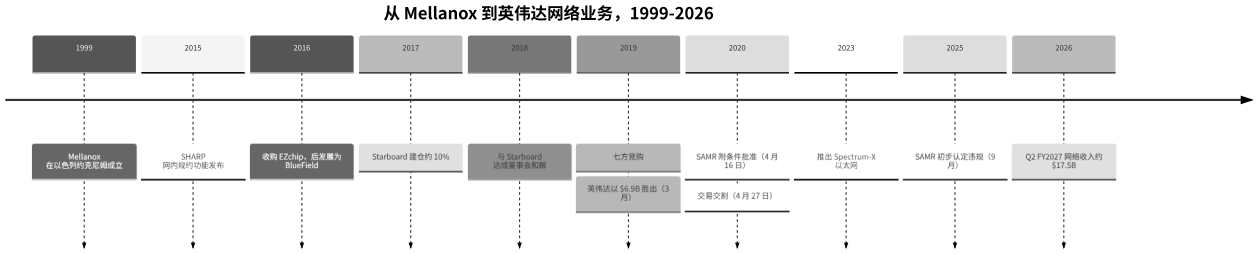
2019 年的 Mellanox 是一家盈利的细分市场供应商。它向超级计算机销售 InfiniBand 交换机和适配器，向云服务商销售以太网适配器（ConnectX）。InfiniBand 是专为集群打造的网络：数据传输延迟极低且可预

测，并允许一台机器直接写入另一台机器的内存。其交换机还能在网络内部执行运算（SHARP，2015 年起）[S273,S6013]。2016 年，Mellanox 以约 $811M 收购 EZchip，后者发展成为 BlueField 数据处理器（DPU）产品线 [S7507,S7509]。

股东们并不安分。Starboard Value 自 2017 年 11 月起建仓至约 10.5–10.7%，并于 2018 年 1 月提名了一整套董事候选人 [S21007]。2018 年 6 月达成的和解撤换了三名董事，其中两名由 Starboard 提名 [S21006]。出售流程随即启动。据报道，英特尔、赛灵思（Xilinx）和微软（Microsoft）都曾是潜在买家 [S6509]。

对英伟达而言，其逻辑在于 AI 训练的走向。训练正从单台 8-GPU 服务器扩展到数百乃至数千台服务器组成的集群。等待网络的 GPU 就是闲置的 GPU，而网络掌握在别人手中。英伟达已经掌控了服务器内部的互连（NVLink）；服务器之间的横向扩展（scale-out）网络是缺失的一块拼图。

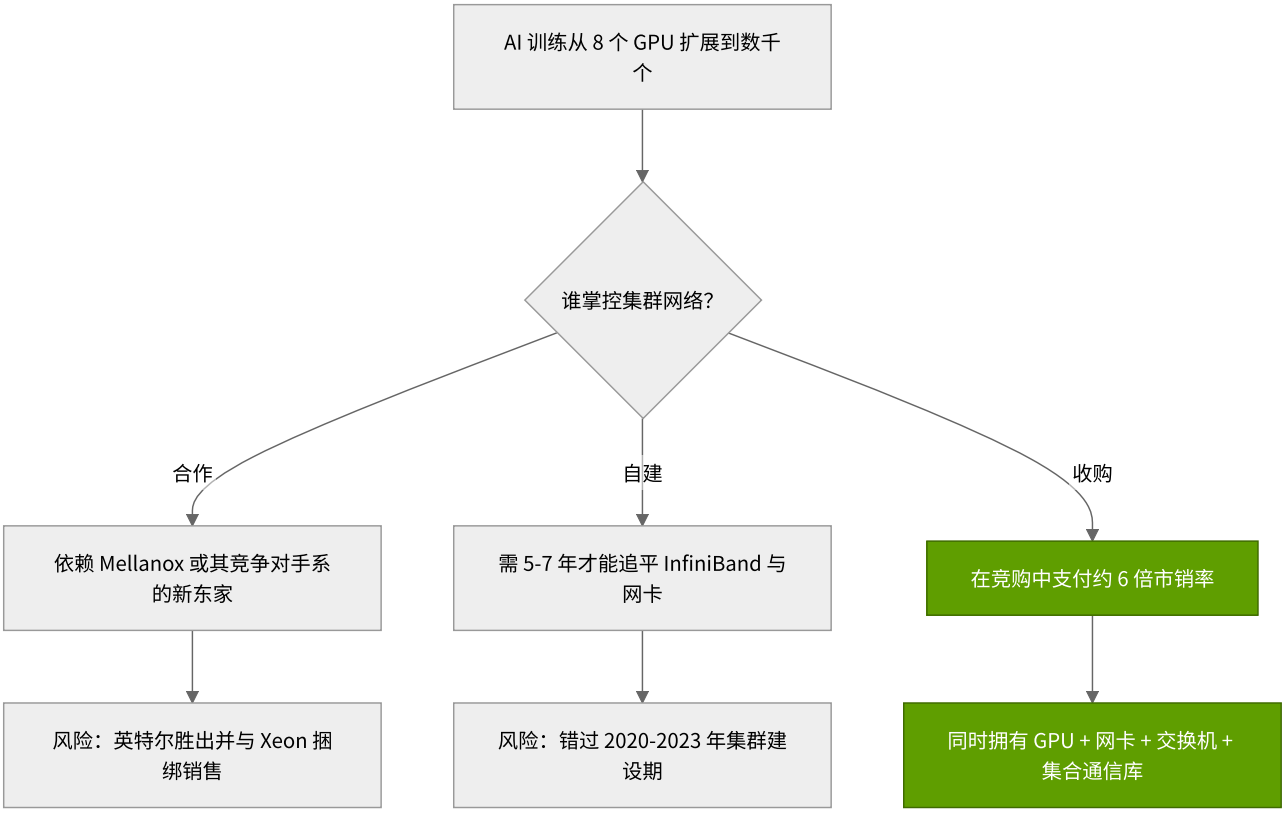
就当时的英伟达而言，这是一笔大赌注。其数据中心业务 FY2020 收入约 $2.98B [S2]。因此，$6.9B 的收购价约相当于 2.3 年的数据中心收入，且全部以现金支付，买下的业务主要面向超级计算机和云客户，而非 AI 实验室。2019 年 3 月的投资者完全有理由质疑：一家 GPU 公司为何要以约 6 倍市销率收购一家交换机公司？



> **提示**
>
> **算例 —— 英伟达支付了多少倍估值。** 宣布交易时，最近一个完整财年为 2018 年，收入约 $1.09B [S21000]。$6.9B ÷ $1.09B ≈ **6.3 倍历史市销率** [S464]。按 2019 年 $1.33B 的收入计算，倍数降至 5.2 倍；按 2019 年 $866.5M 的毛利计算，约为 8.0 倍 [S21000]。对于一家增速 22%、毛利率 65% 的硬件公司，这是足额定价，而非捡便宜。回报来自英伟达对这项资产的运用，而不是低价买入。

2. 决策

英伟达选择了收购，而非自建或合作。它将自己的报价从 2019 年 2 月下旬的每股 $115 提高到 $125 才最终胜出 [S6508,S464]。



交易条款	数值	来源
价格	股权价值 $6.9B，全现金，每股 $125（含承接的股权激励约 $7.1B）	S464
竞争报价	英特尔约 $6B；另有报道称微软与赛灵思参与	S6509
宣布 → 交割	2019-03-11 → 2020-04-27（413 天）	S464,S21005
最后一项审批	中国 SAMR，2020-04-16，附行为性救济措施	S21002,S21003
标的规模	2019 年收入 $1.33B；毛利率 65.1%	S21000

真正的约束在中国。Mellanox 约在 2019 年 4 月向 SAMR 提交申报 [S21004]。直到 2020-04-10 提出救济措施后才获批准：不得捆绑销售，在华销售不得附加不合理条件 [S21003]。美国与欧盟的批准早已到手，中国是最后一关 [S6510,S21003]。

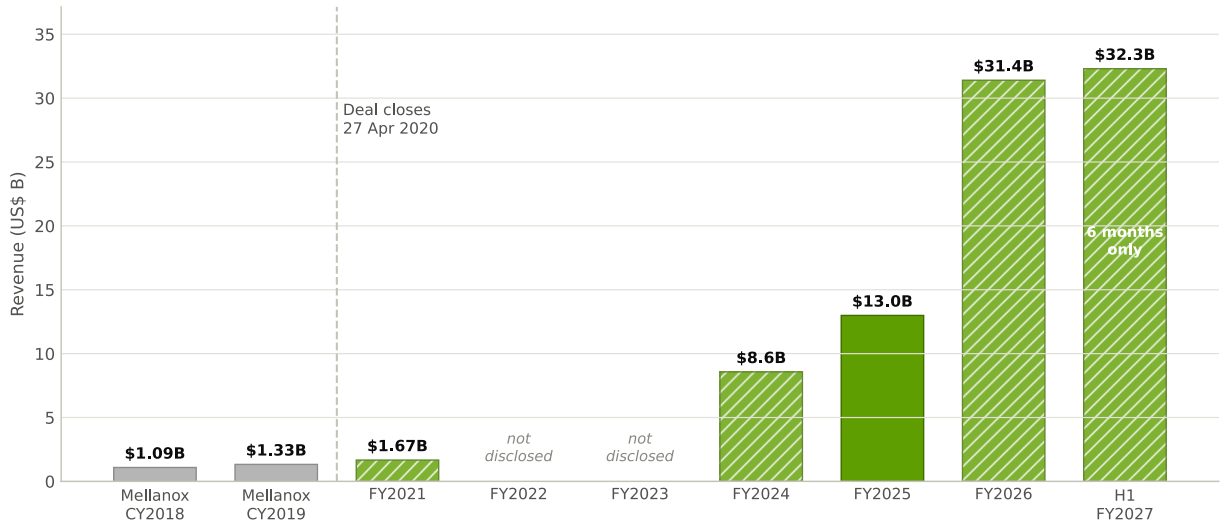
> **🔧 技术细节：中国附加的条件，以及它们为何卷土重来**
>
> SAMR 的条件属于行为性而非结构性救济。英伟达保留了全部资产，但就其在华销售方式作出承诺。据报道，条件涵盖 GPU 与 Mellanox 设备的捆绑销售、持续供货以及与第三方加速器的互操作性 [S21003,S21004]。审查期间曾有竞争对手提出反对 [S21013]。行为性救济会在监管机构手中留下一根杠杆。2024 年 12 月，SAMR 启动调查；2025-09-15，SAMR 发布初步认定，称英伟达违反了 2020 年的附加条件；罚款可达上一年度在华销售额的 1–10% [S9505]。这笔交易的监管风险并未随交割而终结。更宏观的中国形势参见 CS6。

3. 结果（用数据说话）

英伟达并不单独披露“Mellanox”业务线。公司表示，Mellanox 约占 FY2021 收入的 10%，即在被收购后的九个月内贡献约 $1.7B [S418,S2]。英伟达未披露 FY2022–FY2023 的网络收入。从 FY2024 起，数据中心网络业务线开始可见：约 $8.6B（估计）、$13.0B，然后是 FY2026 的约 $31.4B [S416,S402]。仅 FY2027 上半年就带来约 $32.3B [S21009]。

Networking revenue rose ~24× from Mellanox's $1.33B (2019) to ~$31.4B in FY2026

Annual revenue, US$ B: Mellanox as a standalone company (CY2018–19) vs NVIDIA's networking line after the deal



Hatched = Est.

Source: data from Mellanox 10-K; NVIDIA filings [S21000] [S21001] [S418] [S2] [S416] [S443] ...; chart by repo · As of 2026-11-05

网络收入柱状图。Mellanox 独立运营时 2018 年收入 $1.09B，2019 年 $1.33B。2020 年 4 月交割后，英伟达网络业务 FY2021 约 $1.67B（估计：约 9 个月、约占收入 10%），FY2022-FY2023 未披露，随后 FY2024 约 $8.6B（估计）、FY2025 $13.0B、FY2026 约 $31.4B，约为 Mellanox 2019 年收入的 24 倍；仅 FY2027 上半年就带来约 $32.3B。该业务线目前还包括 Mellanox 从未销售过的 NVLink 交换机。

对任何回本测算而言，有一项保留意见最为关键。网络业务线包含 GB200 与 GB300 机架所用的 NVLink 交换托盘 [S402]。这是英伟达自有的纵向扩展（scale-up）技术，而非 Mellanox 的技术。据 Calcalist 估计，英伟达约 70% 的互连业务依赖 Mellanox 及其以色列研发中心 [S21009]。因此，下文模型分别按 50%、70% 和 100% 将该业务线归功于 Mellanox。

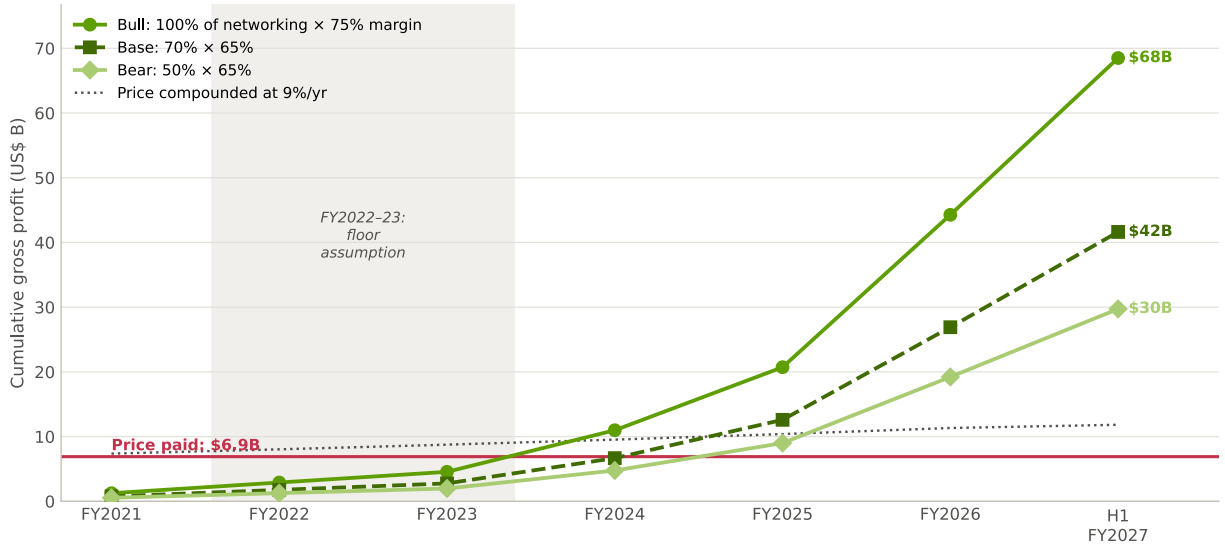
提示

算例 —— 交易回本，三种算法。 以网络收入为起点：FY2021 约 $1.67B [S418]；FY2022–FY2023 按每年 $2.2B 的下限设定（未披露，🔴）；随后为 $8.57B、$13.0B、$31.4B，以及 FY2027 上半年的 $32.3B [S416,S402,S21009]。 - **看空情景（50% 源自 Mellanox × 65.1% 毛利率）：** 归于该交易的毛利在 FY2025 超过 $6.9B 的收购价，到 2026 年 7 月达到约 $30B，为收购价的 **4.3 倍**。 - **基准情景（70% × 65.1%）：** 约 $42B，约 6 倍。 - **看多情景（100% × 75%）：** 在 FY2024 超过收购价，达到约 $68B，约 10 倍。

若将收购价按每年 9% 复利计算，看空情景在 FY2026 越过这一门槛，约为交割后第六年（🔴 本资料库模型）[S21014]。毛利不等于现金流：网络业务的研发和销售费用未计入。即便如此，看空情景仅 FY2026 一年就计入约 $10B 毛利，超过英伟达 FY2026 全部研发预算 $18.5B 的一半 [S401]。

At half of networking and a 65% margin, Mellanox's $6.9B was repaid by FY2025

Cumulative networking gross profit credited to the deal, US$ B, by fiscal year-end, three scenarios (repo model)



Repo model (speculative)

Source: data from NVIDIA and Mellanox filings; repo model [S21000] [S21001] [S464] [S6508] [S6509] [S21002] ...; chart by repo · As of 2026-11-05

折线图：在本资料库三种情景下，FY2021 至 FY2027 上半年归于 Mellanox 交易的累计网络业务毛利，对比 $6.9B 收购价及按每年 9% 复利计算的收购价。看多情景（网络业务 100%、毛利率 75%）在 FY2024 超过收购价，达到约 $68B；基准情景（70%、65%）达到约 $42B；看空情景（50%、65%）在 FY2025 超过收购价，在 FY2026 越过复利门槛，达到约 $30B，为收购价的 4.3 倍。FY2022-FY2023 网络收入未披露，按每年 $2.2B 的保守下限设定；毛利不等于现金流，因为未计入网络业务的研发及销售、一般和管理费用（SG&A）。

交易经济性指标	数值	依据
收购价 ÷ 宣布时历史收入	约 6.3 倍（2018 年收入）	S464,S21000
收购价 ÷ Mellanox 2019 年毛利	约 8.0 倍	S21000
FY2026 网络收入 vs Mellanox 2019 年收入	约 $31.4B vs $1.33B，约 24 倍	S402,S21000
回收期，看空情景（不折现 / 按 9% 折现）	FY2025 / FY2026	S21014
收购价占单季网络收入（Q2 FY2027）的比例	约 $17.5B 的约 39%	S408

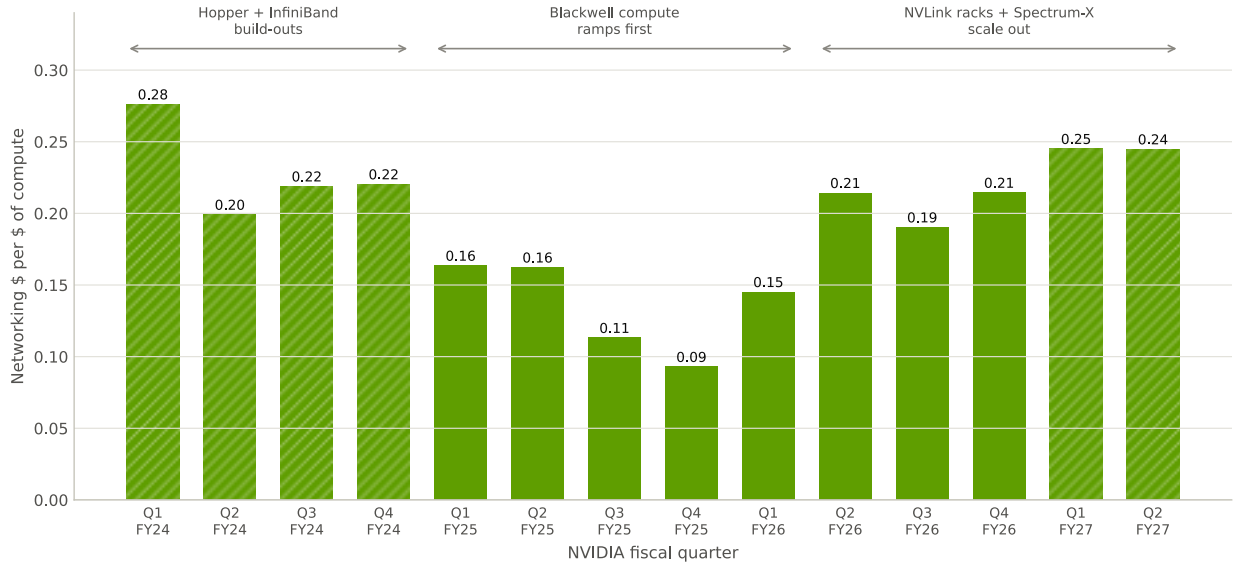
产品线的演变显示了这一业务在六年间走了多远。

	交易时的 Mellanox（2019）	英伟达网络业务（2026）
最快网卡	ConnectX-6，200 Gb/s S273	ConnectX-9，1.6 Tb/s，每个 Rubin GPU 配一块 S33004
InfiniBand 交换机	Quantum HDR，200 Gb/s 端口 S273	Quantum-X800，800 Gb/s 端口；另有硅光版本 S264,S90048
以太网	面向云与企业的 Spectrum 交换机 S273	面向 AI 集群的 Spectrum-X，同比增长 2.6 倍 S408
主要客户	超级计算机、云服务器网卡插槽	超大规模云厂商、AI 实验室、新兴云服务商（xAI、Meta、甲骨文（Oracle）） S6000,S6009
年收入	$1.33B S21000	约 $31.4B（FY2026），含 NVLink 交换机 S402

这笔交易还改变了英伟达的销售内容。网络与计算捆绑出货：Q2 FY2027 每 $1 计算收入约带动 $0.24 网络收入（估计）S408,S405。

NVIDIA sells ~$0.24 of networking per $1 of compute, up from $0.09 in Q4FY25

Data Center networking ÷ compute revenue by fiscal quarter (US$ per US$; networking incl. NVLink switches); hatched = estimate



Source: data from NVIDIA CFO commentary and filings; repo calculation [S440] [S441] [S442] [S443] [S425] [S426] ...; chart by repo · As of 2026-11-05

> 英伟达每美元计算收入对应的网络收入（按季度）柱状图：Q1FY24 约 $0.28（估计），随着 Blackwell 计算产品先于其网络产品放量，Q4FY25 降至 $0.09，随后随 NVLink 交换托盘、Spectrum-X 以太网和 800G InfiniBand 与 GB200/GB300 机架一同出货，Q2FY27 回升至 $0.24（估计：网络 $17.5B 对计算 $71.5B）。网络收入包含 NVLink 纵向扩展交换机，因此这并非纯粹的横向扩展配套率。

4. 为何奏效（或为何未能奏效）

机制 1：由一家厂商调优整条数据通路。 每个训练步骤都以一次全规约（all-reduce）结束，所有 GPU 相互交换梯度。最慢的数据包决定整体节奏。英伟达如今同时设计 GPU、网卡（NIC）、交换机和集合通信库（NCCL）[S10000]。SHARP 这类在交换机内部完成部分全规约运算的功能，需要这四个部分协同配合 [S6013]。可以将其想象为一场接力赛：同一位教练训练每一名选手，还亲自设计交接棒的方式。

机制 2：配套率（attach rate）。 参考设计为每个 GPU 配一块 ConnectX 适配器，在 Rubin 一代已达 1.6 Tb/s [S33004]。购买 GPU 的客户往往也会购买适配器，并常常连带购买交换机。

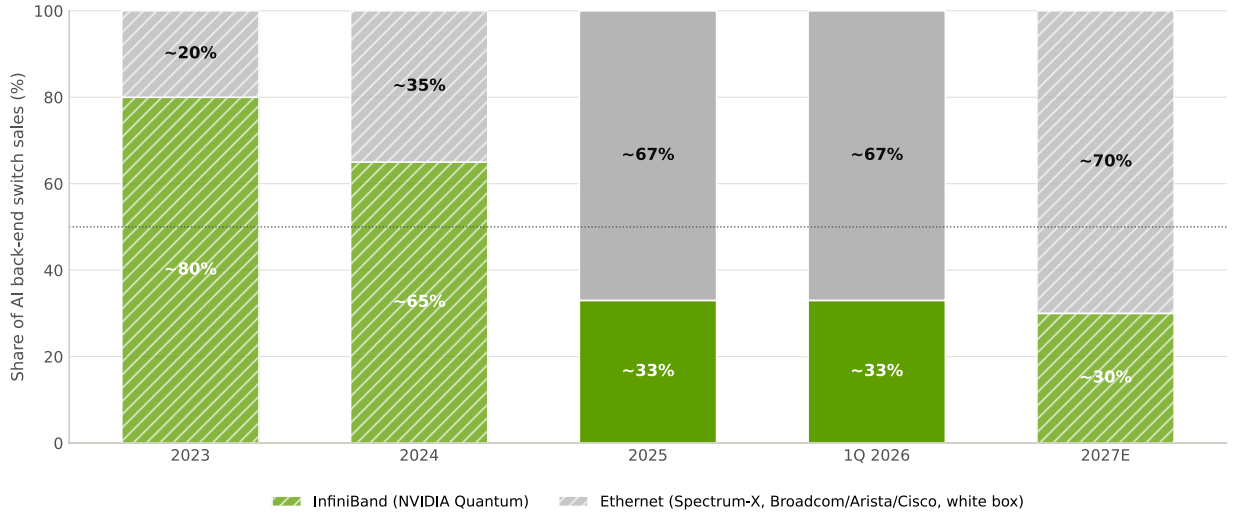
机制 3：转向以太网。 超大规模云厂商抵触 InfiniBand。英伟达在 2023 年 5 月以 Spectrum-X 作出回应——一款与 SuperNIC 配套的以太网交换机 [S271]。它赢得了 xAI 的 Colossus，随后又拿下 Meta 和甲骨文 [S6000,S6009]，并在 Q2 FY2027 实现同比 2.6 倍的增长 [S408]。若没有这次转向，Mellanox 的 InfiniBand 业务会随其份额一同萎缩。详见 Spectrum-X 以太网与 InfiniBand 与 SHARP。

机制 4：时机。 交易于 2020 年 4 月交割。GPT-3 时代的集群以及 2023 年的 H100 建设潮，所需要的恰恰是 Mellanox 所销售的产品。运气与远见同样重要。

反事实推演（🔴 分析）。 假如英特尔以据报道的约 $6B 胜出 [S6509]，英伟达最大的集群将运行在其 CPU 竞争对手所拥有的网络上。英伟达很可能会进一步延伸 NVLink，并与博通（Broadcom）合作开发以太网。它仍会保有 GPU 业务，但会同时失去网络收入以及对整个集群进行协同设计的能力。

Ethernet passed InfiniBand in AI back-end networks: ~67% of switch sales in 2025 (Dell'Oro)

Share of AI back-end (GPU-to-GPU scale-out) switch sales, %; 2025 and 1Q 2026 per Dell'Oro, other years directional estimates



Hatched = directional estimate (not Dell'Oro data)

Source: data from Dell'Oro Group (2025, 1Q26); directional estimates for other years; NVIDIA [S667] [S90053] [S90054]; chart by repo · As of 2026-11-05

> AI 后端网络交换机销售额 100% 堆叠柱状图：2023 年 InfiniBand 约占 80%（方向性数据）；据 Dell'Oro，2025 年以太网至少约占 67%，2026 年第一季度约占 67%（以太网规模是 InfiniBand 的两倍以上）；2027E 方向性预计为 70%。英伟达两边均有参与：Spectrum-X 以太网在 2025 年年化收入规模突破 $33B。

哪些环节可能出错，且至今仍可能出错：

- **协议转移。** 2025 年的两年前，InfiniBand 约占 AI 后端交换机销售额的 80%；到 2026 年第一季度，以太网已占约三分之二 [S90053,S90054]。英伟达靠自建以太网产品保住了席位。博通率先出货 102.4 Tb/s 交换机，现又推出 800G AI 网卡 [S274,S280]。
- **整合。** Spectrum-X 在交割三年后才问世 [S271]。若整合更慢，以太网市场将拱手让给博通和 Arista。
- **对以色列的集中依赖。** 英伟达在以色列拥有 5,000 余名员工，是其美国以外最大的研发中心，并正在建设可容纳多达 10,000 人的园区 [S21011,S21012]。
- **监管尾部风险。** 就目前所见来源而言，SAMR 2025 年 9 月的认定尚未了结 [S9505]。

提示

算例 —— 多少收入依赖以色列的工程团队。 Calcalist 估计约 70% 的互连业务依赖 Mellanox 及其以色列研发中心 [S21009]。将其应用于 FY2026 约 $31.4B 的网络收入 [S402]，即每年约 $22B，约占英伟达 $215.9B 总收入的 10% [S1]。若某次中断使一代交换机或网卡延迟六个月，约有 $11B 收入的确认时点将面临风险（🔴 本资料库测算）。

注

🐂 **看多观点：** 这笔交易让英伟达从芯片供应商转型为系统供应商。网络业务目前约占数据中心收入的 20%，并推动了协同设计的产品（NVLink Fusion、共封装光学），竞争对手必须逐一对标 [S408,S6511]。

注意

🐻 **看空观点：** 最好的回报期可能已经过去。以太网标准（Ultra Ethernet、ESUN）让买家可以混用多家厂商的产品，而博通在交换机带宽上领先。若配套率回落至 FY2025 每美元计算收入约 $0.09 的水平，网络业务增速将落后于 GPU 增速 [S90052,S274,S443]。

5. 对企业发展（corp dev）的启示

启示 1：在相邻瓶颈显而易见之前将其买下。 按收入衡量，2019 年的 Mellanox 并非 AI 的瓶颈；随着集群规模扩大，它才变成了瓶颈。下图按相邻程度和瓶颈的约束强度对可比交易进行定位（🔴 本资料库判断）。



启示 2：监管风险是价格的一部分。 同一家公司在两年内赢下了一笔交易，又输掉了另一笔。

	Mellanox（2019–20）	Arm（2020–22）
价格	$6.9B 现金 [S464]	$40B 现金加股票 [S465]
与竞争对手的关系	部分竞争对手的供应商	几乎所有竞争对手的授权方
结果	历经 413 天、附行为性救济措施后交割 [S21002]	2022-02-08 终止 [S466]
失败成本	不适用；2025 年 SAMR 认定 [S9505]	$1.36B 预付款核销 [S466,S418]

> **提示**
>
> **算例 —— 为监管风险定价。** Arm 的核销金额为 $1.36B，约为 $40B 标价的 3.4% [S466,S465]。Mellanox 等待了 13.5 个月，按 9% 的资本成本计算，时间价值损失约为 $6.9B × 9% × 1.1 年 ≈ $0.7B（🔴）。收购竞争对手供应商的买家应预设冗长的审查、行为性条件以及数年后的执法风险，并将其计入价格。

启示 3：不要因为最后一点加价而错失战略资产。 英伟达最后一次加价，从每股 $115 提高到 $125 [S6508,S464]，成本约为 $6.9B × 10/125 ≈ $0.55B，还不到如今一年网络收入的 2% [S402]。在争夺瓶颈资产的竞购中，多付钱的损失是有限的；被竞争对手买走的损失则没有上限。

启示 4：买下的既是产品，更是团队。 此后每一步网络布局（Spectrum-X、共封装光学、约 $900M 的 Enfabrica 团队交易、$4B 的激光器企业入股）都建立在 Mellanox 工程师的基础之上 [S271,S475,S6511]。完整的分层叙述参见第 06 层发展历程与英伟达的资本配置。

🎯 企业发展视角

1. Mellanox 以约 6 倍市销率被收购时，AI 逻辑尚未体现在其财务数据中。今天哪个相邻层（光学、SerDes、网卡固件、供电）具有同样的特征：盈利、规模不足，且即将成为硬约束?
2. 这笔回报依赖于收购方必须亲自执行的一次转向（InfiniBand → 以太网）。若一项资产的最佳用途需要标的尚未生产的产品，估值模型应如何为其定价?
3. 行为性救济措施在交割后延续了五年。对于涉及中国客户供应商的交易，应为执法风险敞口定价多少、定价多长时间?
4. 高通（Qualcomm）于 2025 年 12 月完成对 Alphawave（SerDes 与互连 IP）的收购 [S4513]。从 SerDes IP 走向网卡或交换机业务的“Mellanox 式”路径会是什么样子？应当自建、合作，还是进一步收购?
5. 英伟达网络业务目前每美元计算收入对应约 $0.24 的网络收入 [S408]。如果挑战者的加速器赢得一个插槽，哪些网络收入会随之转移，哪些仍会留在英伟达或博通手中?

CS2 · CUDA：十五年的赌注

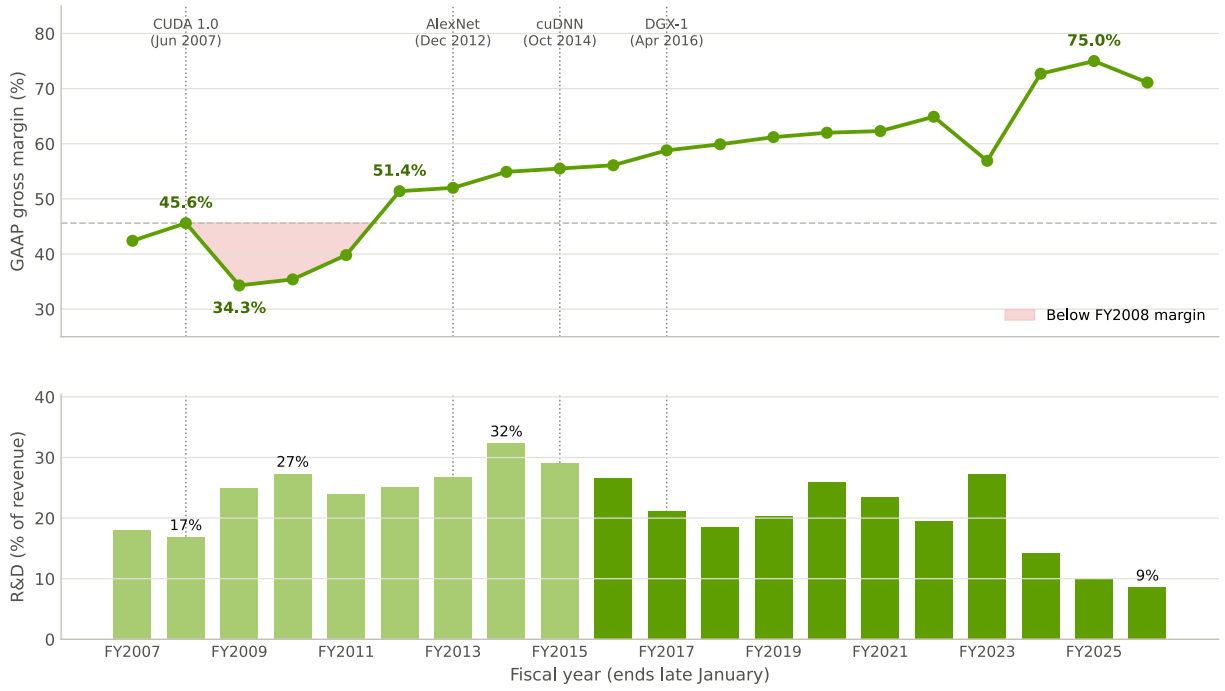
案例研究 · 阅读约 15 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **CUDA 是押注一个尚不存在的市场。** 英伟达（NVIDIA）于 2006-11-08 随 G80 GPU 发布 CUDA，并于 2007 年 6 月推出 CUDA 1.0 [S9528,S525]。它把这项能力放进了每一张 GeForce 显卡，而不仅限于高端计算板卡。
- **这一赌注恰逢毛利率崩塌。** 毛利率从 FY2008 的 45.6% 降至 FY2009 的 34.3% 和 FY2010 的 35.4% [S22000]。一笔 $196M 的封装缺陷费用和 2008 年经济衰退可以解释其中一部分 [S22000]。黄仁勋曾回忆，在英伟达毛利率约 35% 时，CUDA 使成本上升约 50%（🟡 有报道）[S22005,S22006]。
- **英伟达在低谷期持续投入。** 研发支出占收入的比重从 FY2008 的 17% 升至 FY2009–FY2015 的 24–32%，而同期收入一直停留在 $3.3–4.7B [S22001,S22003]。
- **回报来自英伟达计划之外。** 2012 年，AlexNet 在两张 GTX 580 游戏显卡上完成训练 [S9530]。英伟达随后推出 cuDNN（2014）和 DGX-1（2016）[S9531,S310]。数据中心收入在 FY2018 首次超过研发总支出，直到 FY2022 才突破每年 $10B，距 CUDA 1.0 约 15 年 [S400,S2]。
- **如今，生态就是护城河。** 英伟达称拥有约 600 万开发者 [S528]；在本资料库的支持矩阵中，CUDA 是唯一在全部 12 个主流 AI 框架中均获原生支持的技术栈（36/36）[S587,S577,S580]。每位开发者目前每年“承载”约 $32K 的数据中心收入，约为 FY2021 的 10 倍（🔴 本资料库指标）[S22009]。
- **护城河正在边缘处受到侵蚀。** PyTorch 编译器、Triton、JAX/XLA 以及 Modular 的 Mojo 让代码可以面向多家厂商的硬件 [S9021,S578,S9023]。AMD ROCm 对新模型的支持滞后已缩短至 26 天 [S633]。高通（Qualcomm）于 2026 年 6 月同意以 $3.9B 收购 Modular，并于 2026-07-29 完成交易 [S90057,S9511]。

Gross margin fell from 45.6% to 34.3% after CUDA 1.0 and took until FY2012 to recover

NVIDIA GAAP gross margin and R&D as % of revenue by fiscal year, FY2007–FY2026, with CUDA milestones



Some FY2007–15 values recalled

Source: data from NVIDIA 10-Ks [S400] [S22001] [S22000] [S22002] [S22003] [S22004] …; chart by repo · As of 2026-11-05

双面板折线图，FY2007 至 FY2026。上：英伟达 GAAP 毛利率 FY2007 为 42.4%，FY2008（CUDA 1.0 发布当年）为 45.6%，随后 FY2009 降至 34.3%（含 $196M 封装缺陷费用及经济衰退影响），FY2010 为 35.4%，直到 FY2012（51.4%）才恢复到 FY2008 水平，FY2025 达到 75.0%。下：研发支出占收入比重从 FY2008 的 17% 升至 FY2010 的 27%，并在 FY2014 达到 32% 的峰值，随后由于收入增速超过支出增速，FY2026 降至 9%。标注的里程碑：CUDA 1.0（FY2008）、AlexNet（FY2013）、cuDNN（FY2015）、DGX-1（FY2017）。

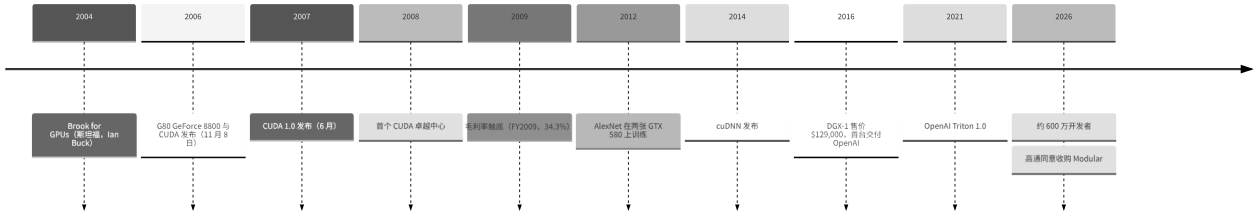
1. 背景

2000 年代中期，想利用 GPU 速度的研究人员必须把数学运算伪装成图形运算：矩阵变成纹理，乘法变成颜色混合。这就是 GPGPU 编程，过程十分痛苦。在斯坦福大学，Ian Buck 开发的 Brook 语言（2004）用类 C 代码把这套技巧隐藏了起来 [S9532]。Buck 随后加入英伟达，领导后来成为 CUDA 的项目。

硬件层面的推动者是 G80，于 2006-11-08 以 GeForce 8800 之名发布 [S2503]。它以统一着色器架构取代了固定的图形流水线阶段：由一组相同的可编程核心构成统一资源池。CUDA 补齐了通用代码所需的组件：C 编译器、线程调度器，以及线程间可协作使用的片上共享内存 [S9528]。

商业上的理由很单薄。英伟达当时是一家图形公司，FY2008 收入约 $4.1B [S400]。通用 GPU 计算的买家只是几百名物理学家、油气建模人员和金融量化分析师。不久之后，一个厂商中立的替代方案 OpenCL 在其他芯片厂商的支持下出现。短期内的理性做法，是把 CUDA 当作面向工作站和 Tesla 板卡的细分产品。

CUDA 从研究赌注到 AI 默认选择，2004-2026



2. 决策

关键选择在于把 CUDA 放在哪里。英伟达本可以将其限定在 Tesla 计算板卡上，以保护消费级产品的利润率。但它选择了每一张 GeForce，这让尝试 CUDA 的成本极低：任何拥有游戏电脑的学生都有一台 CUDA 设备。到 2020 年，英伟达统计的支持 CUDA 的 GPU 已超过 10 亿个 [S529]。



决策的另一半是培育需求。2008 年在伊利诺伊大学设立的首个 CUDA 卓越中心获得了 $500,000 捐款和一套价值约 $800,000 的集群；到 2008 年年中，已有 41 所大学开设 CUDA 课程 [S9529]。这一决策还需要耐心：在投资者质疑这一战略期间，英伟达仍持续为 CUDA 投入资金 [S22007]。

> **提示**
>
> **算例 —— 低谷期的代价。** 毛利从 FY2008 的约 $1.87B（$4.10B × 45.6%）降至 FY2010 的约 $1.18B（$3.33B × 35.4%），每年减少约 $0.69B [S400,S22000,S22002]。同样这两年，研发支出从 $691.6M 增至约 $908.9M，增加约 $217M [S22001,S22000]。这并非全部源于 CUDA：FY2009 包含一笔 $196M 的封装缺陷费用以及经济衰退的影响 [S22000]。但只要黄仁勋关于成本上升约 50% 的回忆在方向上大致正确 [S22005]，利润率缺口中的很大一部分就是在每张显卡里装进一台计算机的代价。

> **🔧 技术细节：为何“每张 GPU 都支持 CUDA”的维持成本始终很低**
>
> CUDA 代码被编译为 PTX，一种虚拟指令集。驱动程序会将 PTX 翻译为每代新 GPU 的原生代码，因此为某一代编写的内核仍能在下一代上运行。这正是装机基数得以复利增长的原因：每卖出一张 GeForce，都在扩大同一个软件目标，而不是使其碎片化。英伟达淘汰旧架构的速度很慢。CUDA 13 才放弃了 2014–2017 年推出的 Maxwell、Pascal 和 Volta GPU [S90065]。自 2024 年起，许可协议禁止在竞争对手芯片上运行 CUDA 输出的转译层，这提高了二进制兼容克隆方案的法律风险 [S9500]。

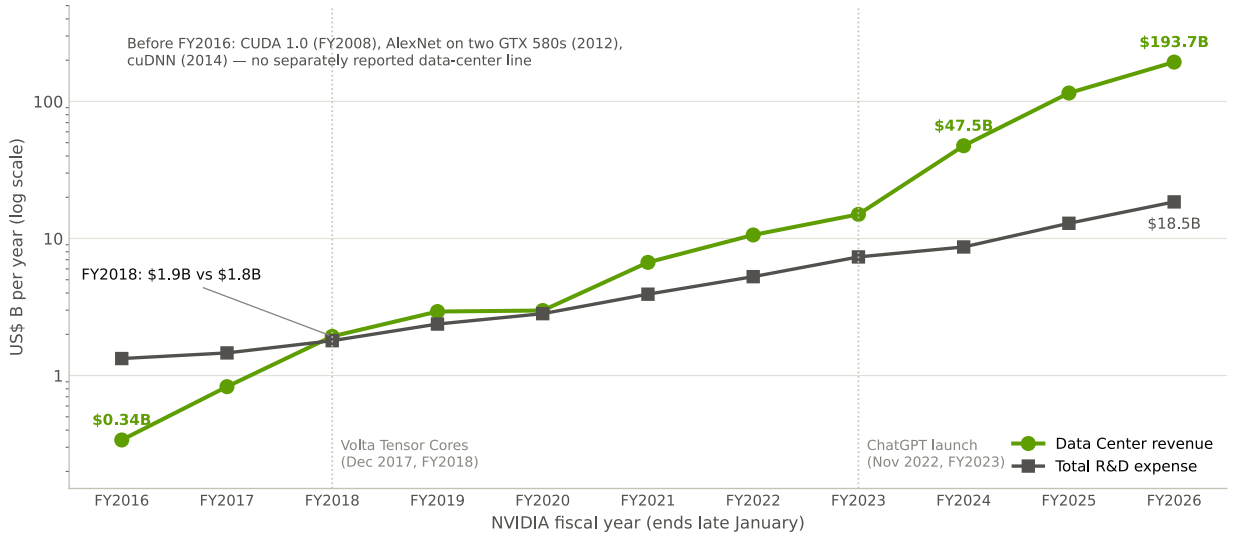
3. 结果（用数据说话）

漫长的回报期。 第一笔大回报来自英伟达并未付钱的人。2012 年，AlexNet 在两张 3 GB 的 GTX 580 上训练了五到六天后赢得 ImageNet 竞赛 [S9530]。英伟达随后将深度学习数学运算封装为软件库：cuDNN（2014）为各框架提供了调优好的卷积内核，框架不再需要自行编写；Caffe 是第一个集成它的框架 [S9531]。这为此后每个框架确立了模式：调用英伟达的库，继承英伟达的性能。2016 年 4 月，英伟达推出售价 $129,000 的 DGX-1 [S310]，并于同年 8 月亲手将首台交付给 OpenAI [S8522]。

Data Center revenue first topped NVIDIA's total R&D in FY2018, a decade after CUDA 1.0

NVIDIA Data Center revenue vs total company R&D, US$ B per fiscal year, FY2016–FY2026 (FY2026: 10× R&D)

LOG SCALE



Pre-FY2026 rows: QA pending

Source: data from NVIDIA 10-Ks (financials.csv) [S400] [S2] [S418] [S417] [S90090] [S416] ...; chart by repo · As of 2026-11-05

对数坐标折线图，FY2016 至 FY2026。英伟达数据中心收入在 FY2016 为 $0.34B，而研发总支出为 $1.33B；FY2018 数据中心收入超过研发支出（$1.93B 对 $1.80B），FY2024 达到 $47.5B，FY2026 达到 $193.7B，约为 $18.5B 研发支出的 10 倍。CUDA 1.0 于 2007 年 6 月（FY2008）发布，cuDNN 于 2014 年发布，因此该平台运行了约十年，数据中心业务才足以覆盖公司的研发投入。

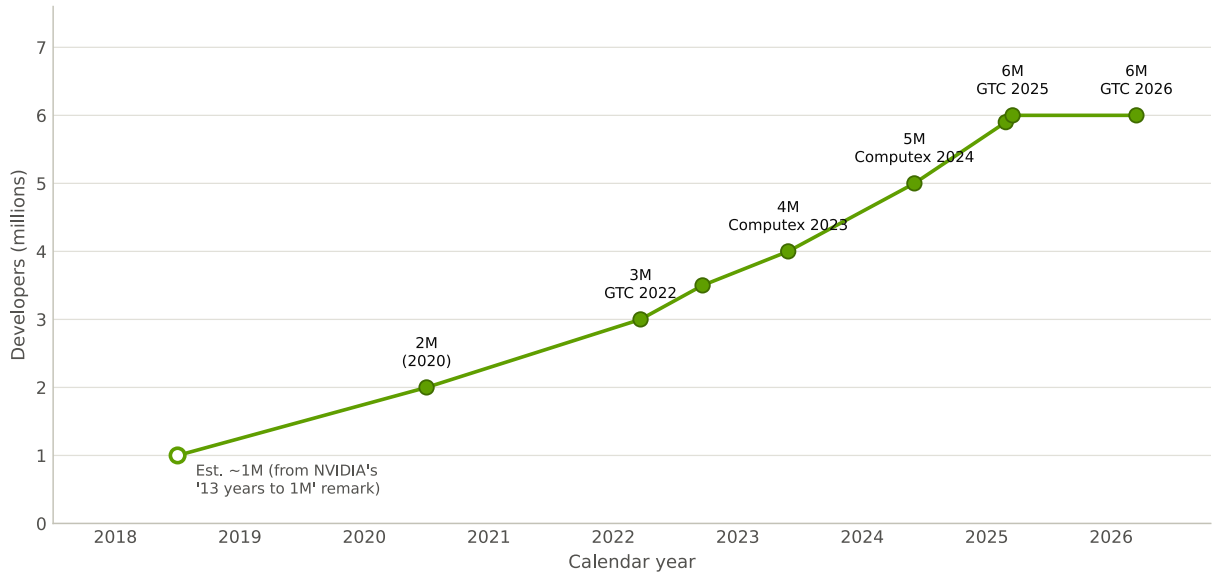
提示

算例 —— 为什么是“15 年”。 FY2008 至 FY2016，英伟达在所有产品上的研发投入约 $9.5B [S22001,S22003,S400]。FY2016 的数据中心收入仍仅为 $0.34B [S400]。它在 FY2018 首次超过研发总支出（$1.93B 对 $1.80B），距 CUDA 1.0 约十年；在 FY2022 首次突破每年 $10B（$10.6B），距 CUDA 1.0 约 14.5 年 [S400,S2]。到 FY2026 达到 $193.7B，约为 $18.5B 研发支出的 10 倍 [S402,S401]。

今天的生态。 英伟达的注册开发者数量从 2020 年的 200 万增至 2025 年的约 600 万，增长两倍，而在 GTC 2026 上仍引用约 600 万这一数字 [S529,S528]。这一取整数字的停滞值得注意。

CUDA developers tripled from 2M (2020) to ~6M (2025); NVIDIA still cited 6M in 2026

Registered CUDA / NVIDIA developer-program members as stated by NVIDIA, millions



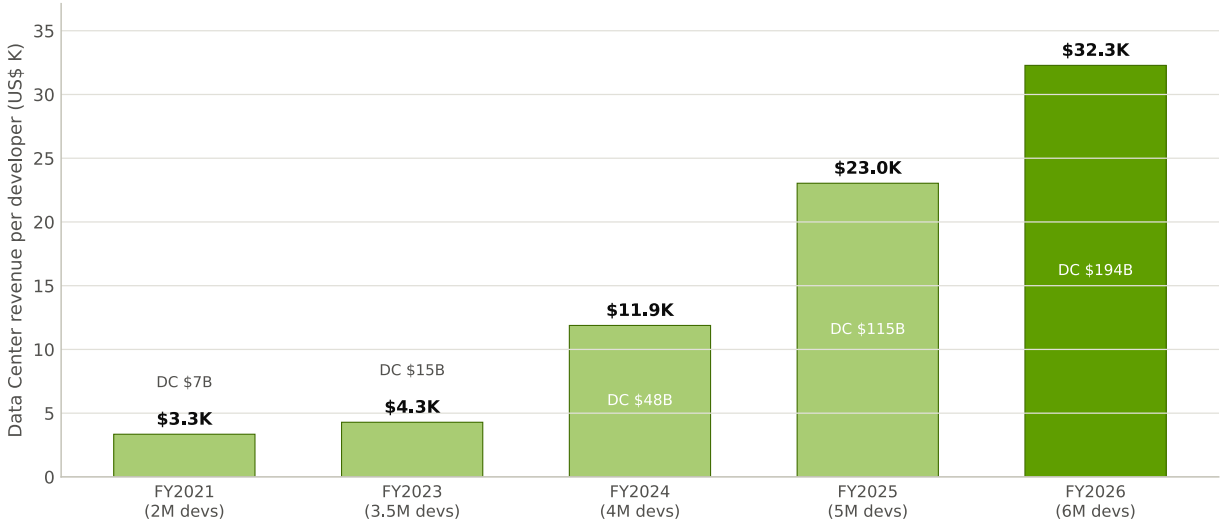
Source: data from NVIDIA keynotes, press releases and earnings calls [S529] [S530] [S531] [S532] [S533] [S534] …; chart by repo · As of 2026-11-05

> 英伟达公布的 CUDA 开发者数量折线图：2018 年前后约 100 万（估计），2020 年 200 万，2022 年 3 月 300 万，2023 年 5 月 400 万，2024 年 6 月 500 万，2025 年 2 月 590 万，GTC 2025 及 GTC 2026 均约 600 万——取整后的标题数字出现停滞。

收入增速远超开发者增速。以数据中心收入除以开发者数量，可以粗略衡量有多少支出依附于该生态。

Each CUDA developer now 'carries' ~$32K of Data Center revenue, ~10× FY2021

NVIDIA Data Center revenue in fiscal year N+1 ÷ CUDA registered developers stated in calendar year N, US$ thousands



Indicator, not causal

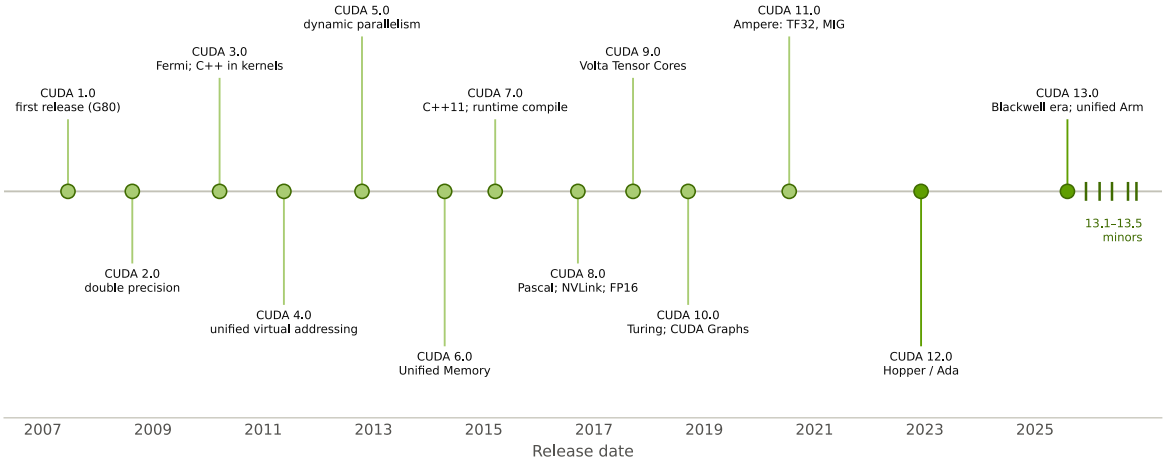
Source: data from NVIDIA developer counts and 10-Ks; repo calc. [S529] [S530] [S531] [S532] [S533] [S534] …; chart by repo · As of 2026-11-05

> 英伟达每位注册 CUDA 开发者对应的数据中心收入柱状图：FY2021 约 $3.3K（200 万开发者，$6.7B），逐年上升至 FY2026 约 $32K（600 万开发者，$193.7B），约高出 10 倍。收入增速远超开发者数量，后者停滞在约 600 万；该比率是衡量有多少支出依附于生态的指标，而非因果度量。

平台本身也在不断演进。CUDA 在 18 年间发布了 13 个主版本，每个版本都与张量核心（CUDA 9）等硬件特性绑定 [S525]。

CUDA shipped 13 major versions in 18 years; 13.x minors now land quarterly

CUDA Toolkit major versions with headline additions, and 13.x minor releases (pre-2019 months per NVIDIA's toolkit archive)



Source: data from NVIDIA CUDA Toolkit archive, release notes and PyPI [S525] [S526] [S524] [S523] [S527]; chart by repo · As of 2026-11-05

> CUDA 主版本时间线，从 1.0（2007 年 6 月）到 13.0（2025 年 8 月）：共 13 个主版本，每个都对应一种 GPU 架构或编程模型新增功能，如双精度（2.0）、统一内存（6.0）、张量核心（9.0）、CUDA Graphs（10.0）、TF32/MIG（11.0）和 Hopper（12.0）；截至 2026 年 11 月又发布了 5 个 13.x 小版本，其中 13.1 引入 CUDA Tile。

覆盖广度是最清晰的成果。在本资料库的支持矩阵中，CUDA 在全部 12 个框架中均获原生支持；AMD ROCm 得分为 36 分中的 26 分，谷歌（Google）TPU 技术栈 14 分，高通 Cloud AI 技术栈 4 分[S586,S580,S577,S596]。

Only CUDA is native in all 12 major AI frameworks; ROCm 26/36, Qualcomm 4/36

Support level by framework and vendor stack, 2026-11-05: 0 none · 1 experimental · 2 supported · 3 native (breadth, not performance)

	NVIDIA CUDA	AMD ROCm	Intel oneAPI/Gaudi	Google TPU (XLA)	AWS Neuron	Huawei CANN	Qualcomm Cloud AI
PyTorch	3 · Native	3 · Native	2 · Supported	2 · Supported	2 · Supported	2 · Supported	1 · Exp.
JAX	3 · Native	2 · Supported	1 · Exp.	3 · Native	1 · Exp. ?	0 · None	0 · None
TensorFlow	3 · Native	2 · Supported	1 · Exp.	3 · Native	1 · Exp. ?	1 · Exp. ?	0 · None
vLLM	3 · Native	3 · Native	2 · Supported	2 · Supported	1 · Exp.	2 · Supported	2 · Supported
SGLang	3 · Native	3 · Native	1 · Exp.	2 · Supported	0 · None	2 · Supported	0 · None
TensorRT-LLM	3 · Native	0 · None	0 · None	0 · None	0 · None	0 · None	0 · None
OpenAI Triton	3 · Native	3 · Native	2 · Supported	0 · None	0 · None	2 · Supported	0 · None
ONNX Runtime	3 · Native	2 · Supported	2 · Supported	0 · None	0 · None	1 · Exp.	1 · Exp.
llama.cpp	3 · Native	2 · Supported	2 · Supported	0 · None	0 · None	2 · Supported	0 · None
DeepSpeed	3 · Native	2 · Supported	2 · Supported	0 · None	0 · None	1 · Exp.	0 · None
Megatron-LM	3 · Native	2 · Supported	1 · Exp.	0 · None	0 · None	2 · Supported	0 · None
Ray	3 · Native	2 · Supported	2 · Supported	2 · Supported	2 · Supported	2 · Supported	0 · None
Total	**36/36**	**26/36**	**18/36**	**14/36**	**7/36**	**17/36**	**4/36**

? = speculative (not verified in vendor docs this session)

Source: data from Framework docs and READMEs (GitHub), vendor docs [S587] [S586] [S553] [S595] [S594] [S522] …; chart by repo · As of 2026-11-05

> 12 个框架 × 7 个厂商技术栈热力图：英伟达 CUDA 在所有框架中均为原生支持（3 分），合计 36/36；AMD ROCm 26 分，英特尔（Intel）18 分，华为 CANN 17 分，谷歌 TPU 14 分，AWS Neuron 7 分，高通 Cloud AI 4 分。TensorRT-LLM 仅支持英伟达；Ray 和 vLLM 的硬件覆盖最广。每个单元格均标注其等级。

	2007（CUDA 1.0）	2026
开发者	一个研究社区	约 600 万注册开发者 S528
版本	1.0	13.x，小版本大约每季度发布一次 S523
框架支持	无	12 个中 12 个原生支持 S586
英伟达毛利率	45.6%（FY2008） S22000	75.0%（FY2025），71.1%（FY2026，含 H20 费用） S416,S402
数据中心收入	未单独披露	$193.7B（FY2026） S402

提示

算例 —— 护城河在毛利率上值多少钱。 英伟达毛利率在 FY2008 为 45.6%，在 FY2026 为 71.1%，后者已计入一笔 $4.5B 的 H20 费用 S22000,S402。以 FY2026 $215.9B 的收入计算 S1，每个百分点的毛利率约对应 $2.2B 毛利，因此 25.5 个百分点的差距每年约值 $55B。这并非全部归功于 CUDA：稀缺性、高带宽内存（HBM）供应和机架级系统同样支撑着定价。但如果买家可以自由切换，利润率就会被压向商用芯片同业的水平。即使只把三分之一的差距归于软件锁定，每年也约有 $18B（🔴 本资料库测算）。

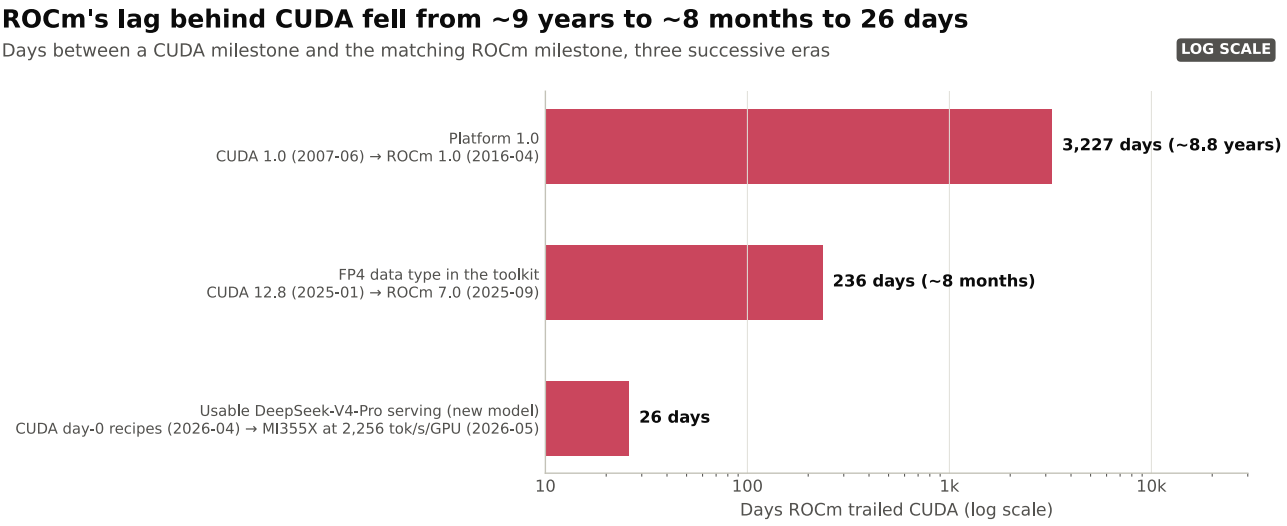
4. 为何奏效（或为何未能奏效）

1. **先有装机基数，后有需求。** 把 CUDA 放进消费级显卡，意味着 2012 年的 AI 研究人员手中早已有了硬件。没有任何竞争对手拥有这样的先发优势。
2. **软件库把一门语言变成了一个平台。** cuDNN 以及后来的 CUDA-X 让框架作者直接调用英伟达调优好的内核 S9531。每一个新框架都免费继承了英伟达的性能优化成果。
3. **与每一代 GPU 协同设计。** 新的数值格式和张量核心特性在发布当天即获得 CUDA 支持 S525。竞争对手只能事后移植，因此英伟达在每次模型发布时都能续写其首日支持（day-0）的领先优势。
4. **不断累积的转换成本。** 将一个注意力内核移植到新芯片上，估计需要 1.8–5.5 人年（🔴 本资料库估计） S633,S631。

金钱之外，英伟达付出的代价。 锁定会招致反制。2024 年针对转译层的许可条款 S9500，以及美国司法部同年启动、调查英伟达是否人为提高切换难度的调查 S9504,S9503，都表明这条护城河如今既在建设，也在防守。每一家自研芯片的超大规模云厂商也都在出资开发摆脱 CUDA 的软件。

反方论点与侵蚀。 最有力的看空论点是：护城河已经上移了一层，而英伟达并不拥有那一层的代码。如今大多数开发者编写的是 PyTorch，而不是 CUDA。PyTorch 2 的编译器会自动生成 Triton 内核 S9021。Triton 于 2021 年推出时仅支持英伟达 S22008，如今已支持 AMD GPU S578。谷歌通过 JAX/XLA 以及自 2026 年 10 月起的 TorchTPU 在 TPU 上部署前沿模型 S595,S553。Modular 声称，同一套 Mojo 内核无需修改即可在英伟达、AMD 和苹果 GPU 上运行 S9023。高通于 2026 年 6 月宣布、2026-07-29 完成的 $3.9B Modular 收购，为这一可移植性论点标上了价格 S90057,S4029,S9511。其成效尚未在规模化场景中得到验证。

绕开 CUDA 的路径	抽象的层次	CUDA 所处位置（2026）	来源
PyTorch eager	内核层之上的模型代码	🟩 参考后端；其他后端以插件方式接入	S587
torch.compile + Triton	内核生成	🟨 可移植到 AMD；最佳调优仍以英伟达优先	S9021,S578
JAX/XLA、TorchTPU	面向 TPU 的全图编译	🟦 谷歌与 Anthropic 规模下的独立技术栈	S595,S553
Mojo/MAX（Modular）	可移植内核与推理服务	🟦 早期阶段；仅有厂商自测基准	S9022,S9023
ROCm/HIP	AMD 上的类 CUDA API	头部模型 🟨（滞后 26 天）；覆盖广度 🟥（26/36）	S633,S586
vLLM、SGLang 插件	按厂商适配的推理服务引擎	🟨 已支持 TPU、昇腾、Gaudi	S580,S582



Source: data from CUDA/ROCm release histories; SemiAnalysis InferenceX [S525] [S586] [S524] [S90064] [S633] [S631]; chart by repo · As of 2026-11-05

对数坐标水平条形图，显示 AMD ROCm 落后英伟达 CUDA 的程度：平台 1.0 晚了 3,227 天（约 8.8 年）（2007 年 6 月对 2016 年 4 月）；FP4 支持晚了 236 天（约 8 个月）（2025 年 1 月的 CUDA 12.8 对 2025 年 9 月的 ROCm 7.0）；DeepSeek-V4-Pro 的可用推理服务比 CUDA 的首日方案晚 26 天（2026 年 4 月至 5 月）。每次差距大约缩短为上一次的十分之一，但每出现一个新模型，差距仍会重现。

提示

算例 —— 差距缩小得有多快。 AMD 的平台比 CUDA 1.0 晚约 3,227 天；FP4 支持比英伟达晚 236 天；DeepSeek-V4-Pro 的可用推理服务比 CUDA 的首日方案晚 26 天 [S525,S586,S633]。每次差距大约缩短为前一次的十分之一。如果一个前沿模型的商业价值集中在发布后的前 3 个月，26 天的滞后仍会让挑战者损失这一窗口期的约 30%；若滞后缩短到 3 天，损失约为 3%（🔴 本资料库测算）。

注

🐂 **看多观点：** 各类抽象层仍以 CUDA 作为参考目标 [S587,S578]。每位开发者对应约 $32K 的数据中心收入，说明客户仍在为默认路径付费 [S22009]。

注意

🐻 **看空观点：** 自 2025 年以来，开发者数量一直停留在约 600 万 [S528]。超大规模云厂商、AI 实验室以及归属高通的 Modular 都在为可移植性投入资金，美国和中国监管机构也在审查英伟达的行为 [S9503,S9505]。护城河可能会从“只有 CUDA 能用”转变为“CUDA 最先能用”。

5. 对企业发展（corp dev）的启示

耐心的平台投资，只有在别人找到用例时才会获得回报。 英伟达并没有预见到深度学习；它只是让试验变得廉价，然后等待。这一赌注之所以能坚持下来，是因为英伟达的游戏业务为其提供了资金。规模更小的公司很难在七年（FY2009–FY2015）里承受 24–32% 的研发强度 [S22001,S22003]。

提示

算例 —— 期权费。 假如英伟达将研发支出维持在 FY2008 约 16.9% 的收入占比，FY2009–FY2015 的研发支出约为 $4.6B（16.9% × $27.4B 收入）。而实际支出约为 $7.5B [S22001,S22003,S400]。约 $2.8B 的差额可以合理地视为英伟达为维持平台存续所付出的代价，尽管这笔钱同时投向了 GPU、移动芯片和软件。若将其视为期权费，它换来的是一项 FY2026 销售额达 $193.7B 的业务 [S402]。企业发展的估值模型很少会批准一笔行权日期未知的期权费，而这正是此类布局稀缺的原因。

如何为开发者生态估值。 开发者数量是累计注册数，而非活跃用户数。下表列出了尽职调查团队可以从公开数据中核查的信号。

信号	CUDA 现状	说明什么	注意事项
注册开发者	约 600 万，自 2025 年以来持平 S528	覆盖面	累计数，企业自报
框架覆盖	本资料库矩阵中 36/36 S587,S580	默认路径的广度	衡量的是支持情况，而非速度
首日模型支持	DeepSeek-V4 当天即有部署方案 S633	对研究的吸引力	一次只能看一个模型
每位开发者对应收入	每年约 $32K（🔴） S22009	依附于生态的支出	指标，而非因果
竞争对手的滞后	新模型滞后 26 天 S633	侵蚀速度	因模型和格式而异

> **提示**
>
> **算例 —— 解读 Modular 的价格。** Modular 于 2025 年 9 月融资 $380M，估值 $1.6B S9510。高通于 2026 年 6 月同意支付约 $3.9B S90057：约为上一轮私募估值的 2.4 倍、累计融资额的约 10 倍。按英伟达每位开发者约 $32K 的数据中心收入计算（🔴） S22009，$3.9B 相当于约 120,000 名 CUDA 开发者一年所对应的收入，约为英伟达约 600 万开发者的 2%。对任何买家而言，问题在于这项资产能撬动多少开发者，以及多少硬件收入。

软件领域的自建与收购。 英伟达用 20 年时间自建 CUDA，并围绕它进行收购（PGI 编译器、约 $700M 收购 Run:ai） S484,S479。挑战者则在用钱买时间：AMD 以 $665M 收购了 Silo AI S9506。完整的分层视角参见第 09 层发展历程与第 09 层竞争格局。

🎯 企业发展视角

1. CUDA 之所以能回本，只是因为一项能产生现金的游戏业务支撑了它十年。对于挑战者的软件平台而言，与之对应的“承载”业务是什么？它能为亏损提供多长时间的资金？
2. 开发者生态估值应以哪个指标为锚：注册开发者、框架覆盖、首日模型支持，还是每位开发者对应收入？每个指标都会指向不同的价格。
3. 护城河正在向编译器（Triton、XLA、Mojo）转移。2028 年谁将掌握这些层？掌握其中一层能否转化为硬件份额，还是只能转化为惠及所有芯片厂商的可移植性？
4. 高通已达成协议收购 Modular，这是对可移植 AI 软件的一次公开押注 S90057。哪些整合里程碑（框架上游合并、首日支持、第三方采用）能够表明它是否改变了转换成本？
5. 英伟达在 2008 年以低成本培育了学术界 S9529。如今哪些渠道的培育成本较低：开源模型实验室、智能体框架，还是 AI 编程工具？

CS3 · 谷歌 TPU：可信的替代方案

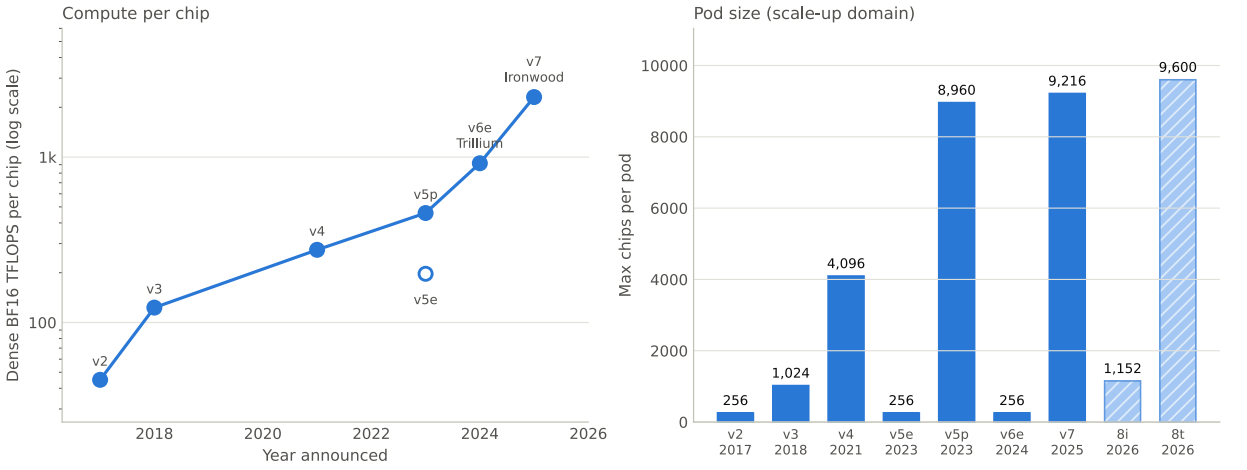
案例研究 · 阅读约 15 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **TPU 起源于一项防御性的成本决策。** 谷歌（Google）预测，若每位用户每天在 CPU 上使用三分钟语音搜索，公司将不得不把数据中心规模翻倍 [S23001]。其第一代 TPU 自 2015 年起投入生产，在谷歌的推理工作负载上，速度比当时的 CPU 和 GPU 快 15–30 倍，能效高 30–80 倍 [S23001,S23002]。
- **谷歌负责设计，合作伙伴负责实现。** 谷歌掌握架构；博通（Broadcom）长期担任其 ASIC 设计合作伙伴，据报道联发科（MediaTek）也已加入，负责 v7e 和 v8e 型号（🟡）[S23007,S23008]。
- **七代产品持续复利。** Ironwood（v7，2025）单芯片提供 4,614 TFLOPS 的稠密 FP8 算力和 192 GB HBM3E，每个 pod 含 9,216 颗芯片（42.5 EF）[S151,S650]。2026 年 4 月发布的 TPU 8t 达到 12.6 PFLOPS FP4，每个 pod 含 9,600 颗芯片（🟢 已发布）[S552,S239]。
- **如今它已对谷歌以外的客户销售。** Anthropic 可使用多达 100 万颗 TPU，2026 年远超 1 GW [S653]，2027 年起还将再增加数 GW [S655]。Meta 租用 Ironwood 算力，并曾商讨为自有数据中心采购 TPU（🟡）[S90025]。甲骨文（Oracle）将从 2027 年起托管 TPU [S552]。
- **经济性才是威胁所在。** SemiAnalysis 估计，自有 Ironwood 每芯片小时成本约 $1.21，而 B200 约为 $1.73，GB300 约为 $2.31（估计）[S622]。按每 token 计算差距较小：在某一 FP8 工作负载上比 B200 低约 18%（估计）[S625]。
- **局限性同样真实。** TPU 很少作为商用芯片出售；在框架支持上，TPU 技术栈得分为 36 分中的 14 分，而 CUDA 为 36 分 [S580,S577]；此外，谷歌在芯片、封装和供应上依赖博通。
- **对英伟达而言，它限制的是定价权，而非出货量。** 本资料库估计，英伟达可以降价至与 TPU 每 token 成本持平，同时仍保持约 62% 的毛利率（🔴）[S23010]。

TPU compute per chip rose ~51× from v2 (2017) to Ironwood (2025); pods grew 36× to 9,216 chips

Google TPU by generation: dense BF16 TFLOPS per chip (left, log scale) and max chips per pod (right)



Hatched = announced

Source: data from Google Cloud docs and blogs; ISCA papers [S23000] [S23001] [S23002] [S23003] [S23004] [S238] ...; chart by repo · As of 2026-11-05

谷歌 TPU 各代产品双面板图。左（对数坐标）：单芯片稠密 BF16 TFLOPS 从 45（TPU v2，2017）增至 123（v3，2018）、275（v4，2021）、459（v5p，2023）、918（v6e Trillium，2024）和约 2,307（v7 Ironwood，2025；BF16 按其 4,614 FP8 的一半计），八年约增长 51 倍；成本优化型 v5e 为 197。右：每个 pod 最大芯片数从 256（v2）增至 1,024（v3）、4,096（v4）、8,960（v5p）和 9,216（Ironwood），2026 年发布的 TPU 8t 为 9,600；v5e 与 Trillium 能效型产品仍为 256 芯片 pod。TPU v1（2015）是一张 INT8 推理卡，算力 92 TOPS，没有 pod。

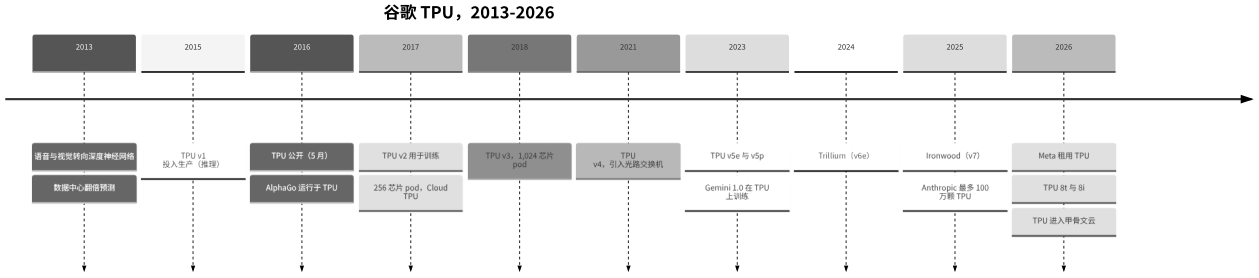
1. 背景

到 2013 年，谷歌的语音和视觉产品正在转向深度神经网络。模型效果很好，但计算账单不行。当年的一项预测显示，如果用户每天使用三分钟语音搜索，而神经网络运行在现有处理器上，谷歌将不得不把数据中心规模翻倍 S23002,S23001。

答案是 ASIC，即只做一件事的芯片。TPU v1 是一张推理卡，核心是由 65,536 个 8 位乘加单元组成的脉动阵列，峰值算力 92 TOPS，片上内存 28 MiB S23002。脉动阵列的工作方式就像传水桶的队伍：数字从一个单元传递给相邻单元，因此从内存取出的每个值都会被复用数百次。2015 年的 GPU 将大量硅面积和能耗花在 TPU 并不需要的灵活性上。

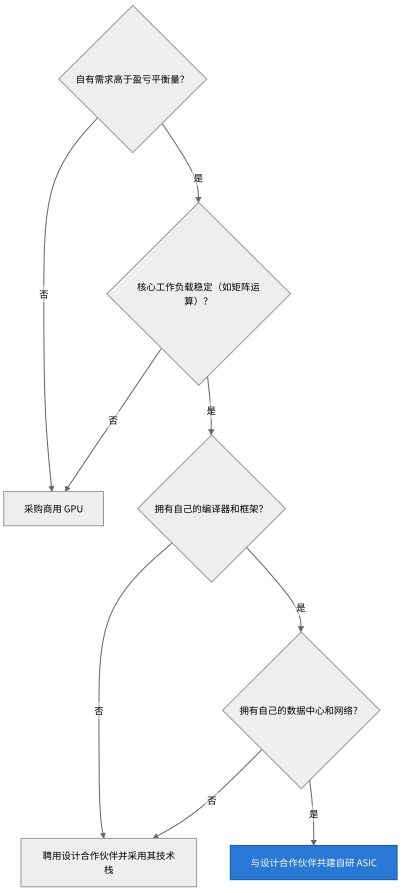
谷歌行动迅速。首批测试芯片到手后 22 天内，TPU 就已在其数据中心运行应用，支撑 RankBrain 搜索排序、街景（Street View）和 AlphaGo S23000。谷歌直到 2016 年 5 月才公开这款芯片，此时它已投产一年多 S23000。

> **提示**
>
> **算例 —— 30–80 倍每瓦性能意味着什么。** 假设一个推理集群在 2015 年代的 CPU 和 GPU 上需要 100 MW。按 TOPS/W 提升 30–80 倍计算 S23001，同样的工作只需约 1.3–3.3 MW 的 TPU。即使实际收益只有其十分之一，也能节省 10 MW：按约 $0.08/kWh 计算，仅电费每年就约 $7M，这还未计入省下的数据中心建设成本（🔴 本资料库测算）。



2. 决策

在核心 AI 工作负载上，谷歌选择自建芯片而非采购英伟达（NVIDIA）GPU，并选择与设计服务公司合作而非单打独斗。这种分工是自用芯片（captive silicon）的典型模式：谷歌的工程师定义架构、编译器和系统；设计合作伙伴将其转化为可量产的芯片，提供高速 SerDes 与封装经验，并管理台积电（TSMC）和内存供应。博通在大多数代际中承担这一角色；据报道，联发科负责某一 v7 型号的 I/O，并获得了 v7e 和 v8e 的订单（🟡）S23007,S23008。



提示

算例 —— 自研 ASIC 何时能回本? 一款先进制程芯片的设计成本约 $0.6–0.7B（IBS 对 3 nm 和 2 nm 的估计；业内人士认为偏高）[S2501,S2500]。将其翻倍至 $1.4B，以涵盖软件和系统（🔴）。SemiAnalysis 认为 Ironwood 每 token 成本比 B200 低约 18%，B200 每小时约 $1.73 [S625,S622]。每个 B200 等效芯片的节省约为 0.18 × $1.73 × 8,760 小时 ≈ **每年 $2,700**。盈亏平衡点约为 $1.4B ÷ $2,700 ≈ 520,000 芯片年，即在四年使用寿命内每代约需 130,000 颗芯片（🔴 本资料库测算）[S23010]。仅 Anthropic 最多 100 万颗 TPU 的使用权就已越过这一门槛 [S653]。每年采购 20,000 颗加速器的买家则达不到。

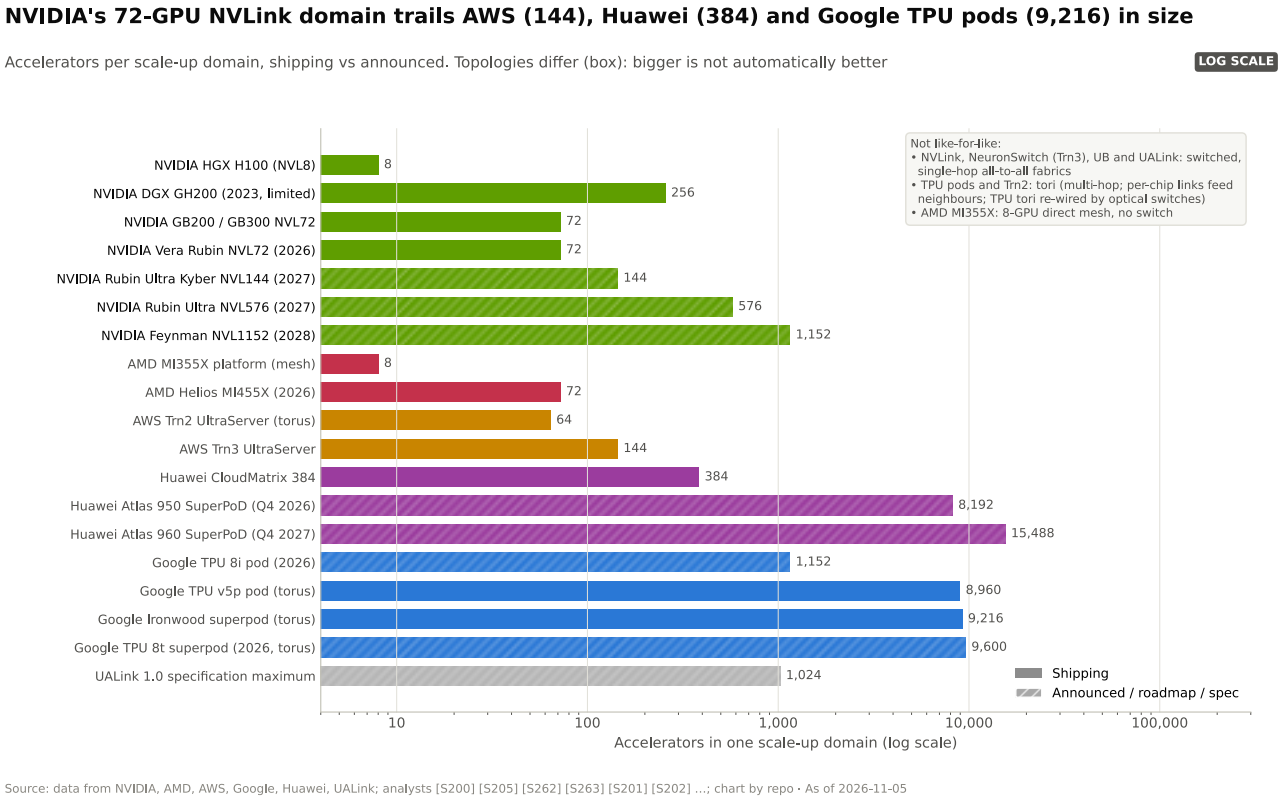
3. 结果（用数据说话）

代际	年份	定位	单芯片峰值	单芯片内存	最大 pod	来源
v1	2015	推理	92 TOPS INT8	28 MiB 片上内存	—	S23002
v2	2017	训练	45 TFLOPS BF16	HBM	256	S23003
v3	2018	训练	123 TFLOPS BF16	32 GiB，0.9 TB/s	1,024	S23004
v4	2021	训练	275 TFLOPS BF16	32 GB，1.2 TB/s	4,096	S146,S147
v5e	2023	能效型	197 TFLOPS BF16	16 GB，0.82 TB/s	256	S148
v5p	2023	训练	459 TFLOPS BF16	95 GB，2.77 TB/s	8,960	S149
v6e Trillium	2024	能效型	918 TFLOPS BF16	32 GB，1.64 TB/s	256	S150,S549
v7 Ironwood	2025	推理优先	4,614 TFLOPS FP8	192 GB HBM3E，7.37 TB/s	9,216	S151,S650
8t	2026（🟢 已发布）	训练	12.6 PFLOPS FP4	不适用	9,600	S552,S239
8i	2026（🟢 已发布）	推理	SRAM 约为 Ironwood 的 3 倍	不适用	1,152（🟡）	S550,S239

Ironwood 标志着重心的转移。谷歌称其为第一款“面向推理时代”的 TPU [S151]。谷歌宣称其峰值算力是 v5p 的 10 倍，单芯片性能是 Trillium 的 4 倍以上，每瓦性能是 Trillium 的 2 倍 [S547,S650]。一个完整的 superpod 拥有 1.77 PB 的高带宽内存（HBM） [S650]。2026 年这一代将产品线拆分为训练芯片（8t）和推理芯片（8i），后者拥有更多片上内存以容纳 KV 缓存 [S550]。

内部成果。 谷歌的前沿模型运行在 TPU 上。Gemini 1.0 技术报告描述了使用 JAX 在 TPU v4 和 v5e 集群上进行训练 [S23005]。据报道，Gemini 3（2025 年 11 月）也是在 TPU 上训练的（🟡） [S23006]。一周后，一则关于 Meta 正洽谈使用 TPU 的报道导致英伟达股价盘中最多下跌 7.1% [S23009]。

外部成果。 多年来，TPU 只能以谷歌云租赁的形式获得。这一点在 2025–26 年发生了变化。Anthropic 签约使用多达 100 万颗 TPU，算力价值数百亿美元 [S653]。据 SemiAnalysis 报道，其中约 400,000 颗为采购、600,000 颗为租赁（🟡） [S625]。Meta 租用 Ironwood，并曾商讨为自有数据中心采购 TPU（🟡） [S90025]；据报道谷歌已向客户自有站点销售 TPU [S90027]。甲骨文将从 2027 年起托管 TPU [S552]。



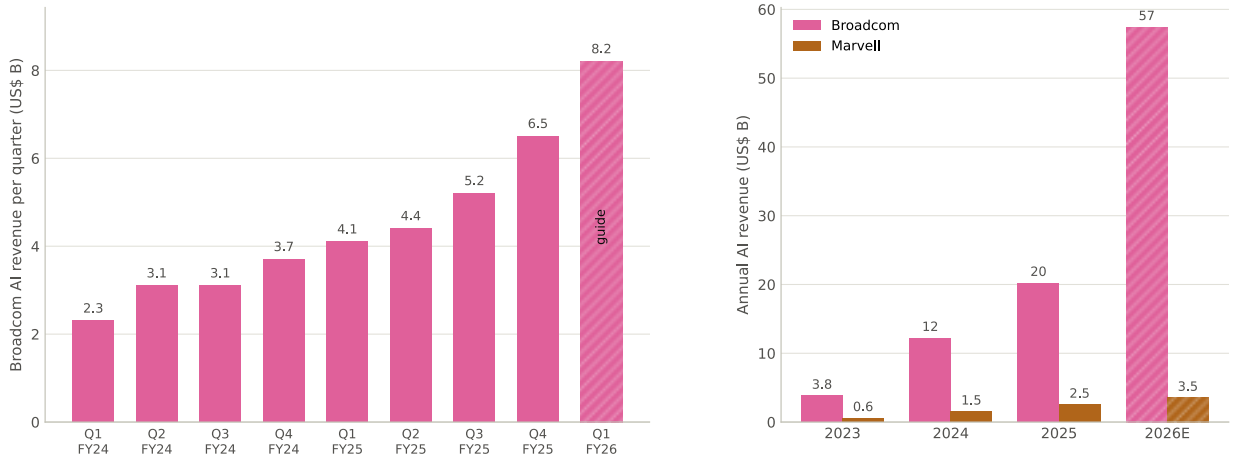
Source: data from NVIDIA, AMD, AWS, Google, Huawei, UALink; analysts [S200] [S205] [S262] [S263] [S201] [S202] ...; chart by repo · As of 2026-11-05

> 纵向扩展域规模对数坐标水平条形图：英伟达 NVL72 目前为 72 个 GPU，Kyber NVL144 与 NVL576 在 2027 年、NVL1152 在 2028 年（路线图）；AMD Helios 72；AWS Trn3 UltraServer 144；华为 CloudMatrix 384 与 Atlas 950 8,192（2026 年第四季度）；谷歌 Ironwood 9,216 颗、TPU 8t 9,600 颗芯片，但 TPU pod 是多跳环面拓扑，而非交换式全互连；UALink 1.0 支持 1,024。

合作伙伴同样受益。博通的 AI 收入（包括 TPU 等定制加速器以及 AI 以太网）从 2023 年的约 $3.8B 增长至 2025 财年的约 $20.2B（根据季报估计） [S660,S661]。

Broadcom's AI revenue rose 2.8x in two years to $6.5B a quarter and tracks ~$57B for FY2026; Marvell's is ~1/8 the size

Left: Broadcom AI semiconductor revenue by fiscal quarter (US$ B). Right: annual AI revenue, Broadcom vs Marvell (US$ B)



Hatched = guidance or Est.

Source: data from Broadcom, Marvell earnings releases [S660] [S661] [S451] [S2516] [S662] [S453] ...; chart by repo · As of 2026-11-05

> 双面板图。左：博通季度 AI 半导体收入从 2024 财年第一季度的 $2.3B 攀升至 2025 财年第四季度的 $6.5B，2026 年第一季度指引 $8.2B 以阴影表示。右：年度 AI 收入，博通约 $3.8B（2023）、$12.2B（2024）、$20.2B（2025），FY2026 约 $57B（第一、四季度为指引，第二季度为推算，第三季度为实际）；美满电子（Marvell）分别为 $0.55B、$1.5B、$2.5B、约 $3.5B（2026E）。博通的数据既包括 AI 以太网网络，也包括谷歌 TPU 等定制 XPU。

4. 为何奏效（或为何未能奏效）

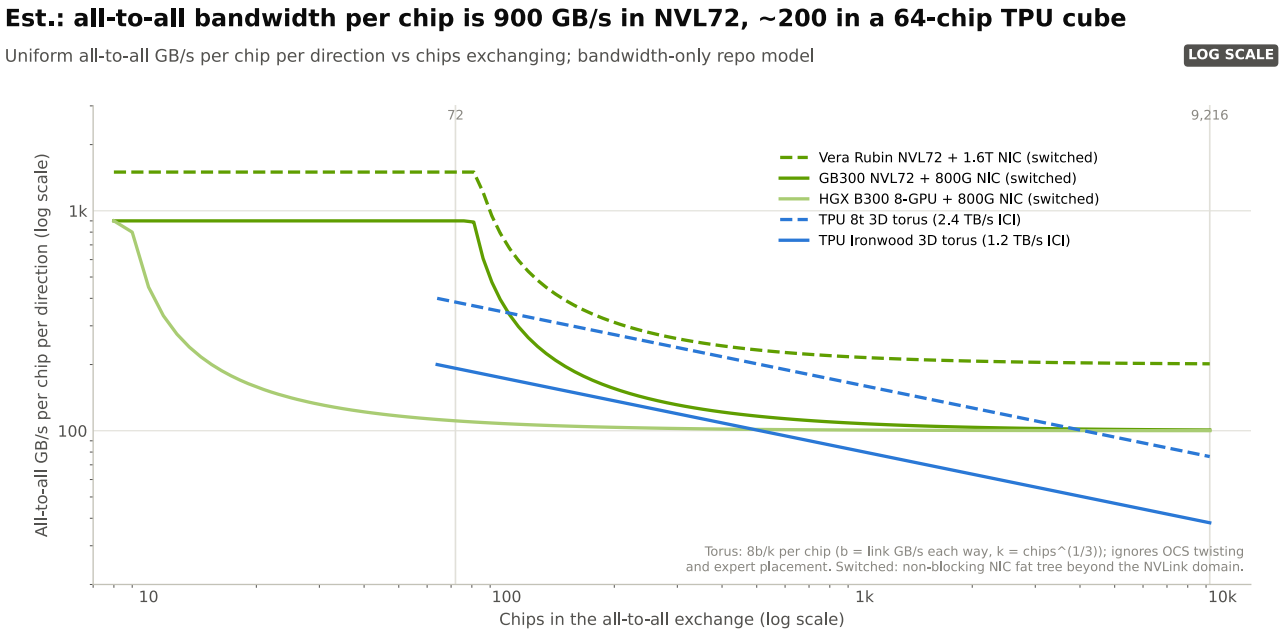
垂直整合是其机制。 谷歌拥有 AI 系统涉及的每一层：芯片、芯片间的 ICI 互连、可重新配置 pod 连接的光路交换机、数据中心、XLA 编译器、JAX 框架以及模型本身 [S650,S237]。每一层都可以针对其他层进行设计，层与层之间除设计合作伙伴外，无需向任何供应商支付利润。

拓扑是一种有意的取舍。 TPU 芯片以 3D 环面（torus）连接：每颗芯片与六个相邻芯片直接通信，发往远处芯片的流量需经其他芯片多跳转发 [S232]。这种方式扩展到 9,216 颗芯片的成本很低。英伟达的 NVL72 则通过交换机让每个 GPU 以全速与所有其他 GPU 互连，但仅限于 72 个 GPU。根据本资料库的模型，NVL72 内部每个 GPU 的全交换带宽约为 900 GB/s，而 64 芯片 TPU 立方体中每颗芯片约为 200 GB/s。

🔧 技术细节：矩阵单元、ICI 与光交换机

每一代 TPU 都在放大同一个思路。TPU v2 有两个 128 × 128 的脉动矩阵单元；Ironwood 有四个 256 × 256 的 BF16 阵列，并新增 FP8 支持 [S2016]。阵列越大，取出的每个数被复用的次数越多，从而节省内存带宽；但在处理小型或形状不规则的矩阵时，浪费的硅面积也更多。这就是编译器至关重要的原因：XLA 会对整个模型计算图进行变形与融合，使阵列保持满载。

在芯片之间，Ironwood 使用六条 ICI 链路，每条 200 GB/s（双向），每颗芯片合计 1.2 TB/s [S232]。64 颗芯片组成一个 4 × 4 × 4 的立方体，作为机架级构建单元。立方体之间通过光路交换机连接：这种交换机用镜面将光从一根光纤导向另一根，无需转换为电信号。TPU v4 使用 48 台此类交换机，将 64 个立方体连接成一台 4,096 芯片的机器 [S237]。由于光路可以重新指向，谷歌能够把一个 pod 切分为多个切片、绕开故障立方体，并为特定任务重塑环面拓扑。谷歌的 Jupiter 数据中心网络也采用同样的光学方案 [S293]。没有其他厂商销售这种组合，而且迄今为止它只在谷歌的数据中心中运行；2027 年起托管于甲骨文云的 TPU 将是第一个例外 [S552]。



Source: data from NVIDIA, Google Cloud, IEEE specs; repo model [S200] [S262] [S263] [S201] [S202] [S33004] ...; chart by repo · As of 2026-11-05

每芯片全交换带宽模型的双对数折线图。交换式 GB300 级 NVL72 在 72 个 GPU 以内为每个 GPU 提供每方向 900 GB/s，超过后降至 800G 网卡的约 100 GB/s（9,216 个 GPU 时为 101 GB/s）；8-GPU HGX 节点在超过 8 个 GPU 后降至约 100 GB/s；Vera Rubin NVL72 起点为 1,500，配 1.6T 网卡后稳定在 200 附近。TPU Ironwood 3D 环面（六条链路共 1.2 TB/s）在 64 芯片立方体内约为 200 GB/s，随芯片数的立方根下降，至 9,216 颗时约为 38；TPU 8t 为其两倍。环面链路需承载多跳流量，而交换式网络可以避免这一点。

维度	TPU（Ironwood / 8t）vs 英伟达（Rubin）	来源
单芯片算力	🟥 4.6 PFLOPS FP8 vs 17.5	S151,S33004
单芯片内存带宽	🟥 7.37 TB/s vs 19.2 TB/s	S151,S90006
纵向扩展域	🟦 9,216 芯片环面 vs 72 GPU 交换式 NVL72	S650,S33004
每 token 成本（单一工作负载）	🟩 比 B200 低约 18%（估计）	S625
谷歌以外的软件生态	🟥 框架支持 14/36 vs 36/36	S580,S577,S595
可获得性	🟥 云服务及部分直销交易 vs 商用芯片随处可得	S653,S90027
公开基准测试	🟥 Ironwood 未参加 MLPerf Inference 6.0	S613

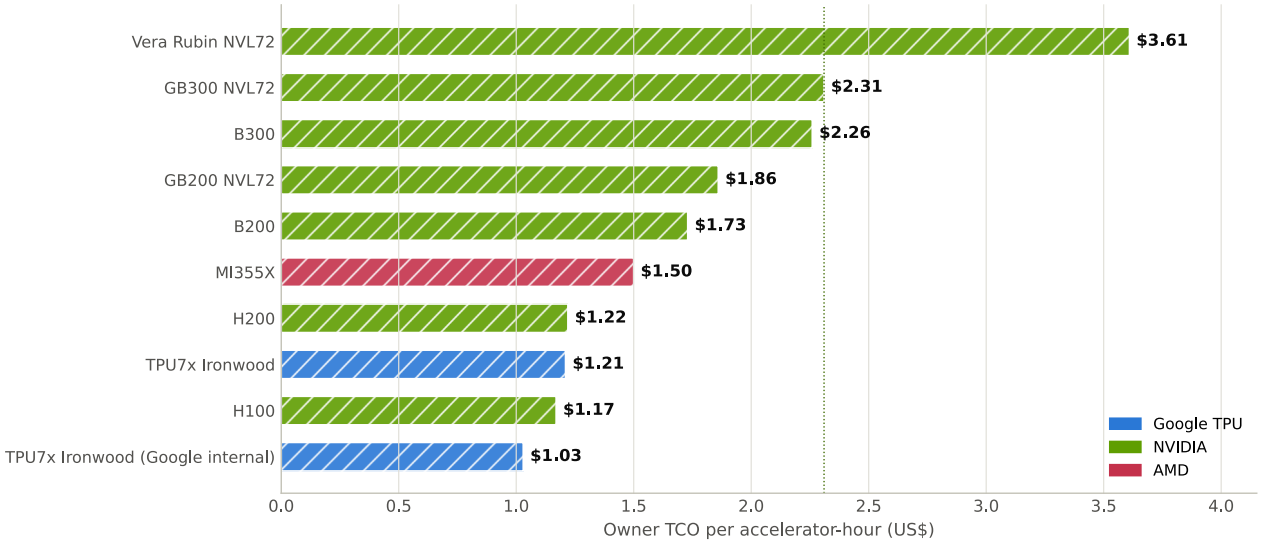
局限性。其一，可获得性：大多数买家只能在谷歌云内租用 TPU，在那里训练的模型更难迁移。其二，谷歌以外的软件：PyTorch 在 TPU 上曾依赖 PyTorch/XLA，现已被弃用，转而采用 2026 年 10 月与 Meta 共同开源的 TorchTPU [S595,S553]。其三，对博通的依赖：设计合作伙伴的利润包含在 TPU 成本之中，而博通同时也在为 OpenAI 打造定制加速器 [S174]。其四，透明度：由于缺少 MLPerf 结果，买家只能依赖谷歌和分析师的数据 [S613]。其五，时机（🔴 分析）：谷歌在十年间基本将 TPU 限于内部使用。对外推广直到 2025–26 年才开始，而此时 CUDA 已成为大多数买家的默认选择；更早推行商用芯片战略或许能建立更大的外部生态，但代价是要向竞争对手供货。

对英伟达定价权的影响

比较必须基于单位工作量，而非单颗芯片。芯片小时成本差距很大；由于不同芯片的吞吐量不同，每 token 成本差距则较小。

Est.: an owned Ironwood chip-hour costs ~$1.21, about half a GB300's $2.31

All-in owner cost per accelerator-hour (capex amortisation, power, hosting), US$, SemiAnalysis model, July 2026



Est. · per chip, not per token

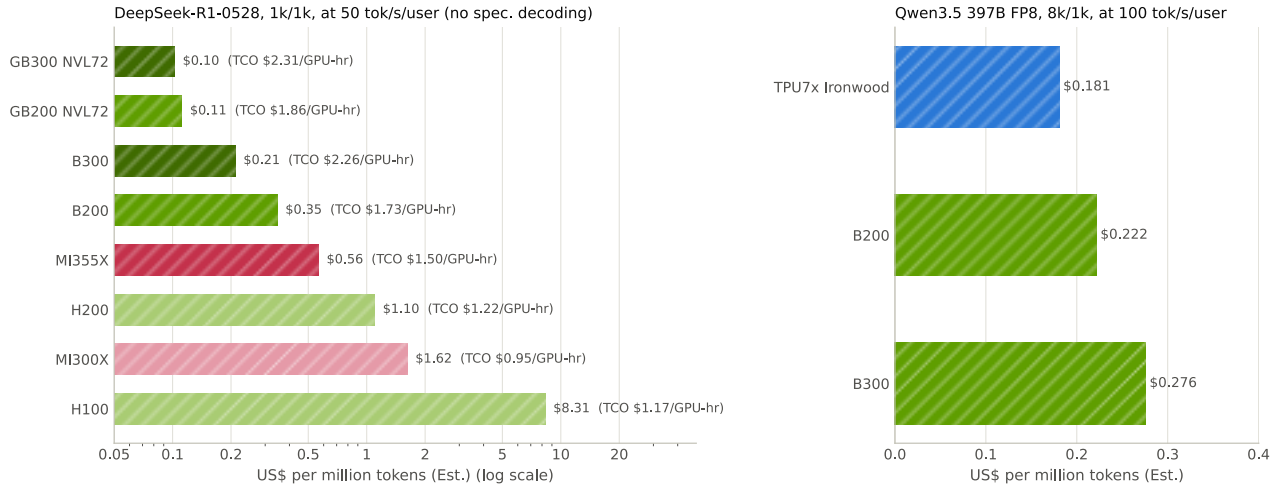
Source: data from SemiAnalysis InferenceX TCO registry [S622]; chart by repo · As of 2026-11-05

每加速器小时的所有者总拥有成本（TCO）估计水平条形图：TPU7x Ironwood 对谷歌自身为 $1.03，对外部所有者为 $1.21；H100 $1.17，H200 $1.22，AMD MI355X $1.50，B200 $1.73，GB200 NVL72 $1.86，B300 $2.26，GB300 NVL72 $2.31，Vera Rubin NVL72 $3.61。这些是单芯片成本，而非单位工作量成本：Ironwood 每小时成本比 B200 低 30%，但在 SemiAnalysis 的某一工作负载上，其每 token 成本仅低约 18%，因为不同芯片的吞吐量不同。

GB300 NVL72 serves DeepSeek-R1 for ~$0.10/M tokens at 50 tok/s/user, 11x below H200 (Est.)

Est. US$ per million total tokens = owner TCO $/GPU-hr ÷ measured throughput (InferenceX); two workloads

LOG SCALE



Est.: cost = TCO $/GPU-hr / throughput

Source: data from SemiAnalysis InferenceX (throughput; TCO $/GPU-hr); repo interpolation [S621] [S622] [S625]; chart by repo · As of 2026-11-05

每百万总 token 成本估计的双面板柱状图。左，DeepSeek-R1，每用户 50 tokens/s：GB300 NVL72 $0.10，GB200 NVL72 $0.11，B300 $0.21，B200 $0.35，MI355X $0.56，H200 $1.10，MI300X $1.62，H100 $8.31。右，Qwen3.5 397B FP8，每用户 100 tokens/s：TPU7x Ironwood $0.181，B200 $0.222，B300 $0.276，显示在该工作负载上谷歌 TPU 比 B200 便宜约 18%。

注意

请谨慎解读这些数字。 两个面板使用的模型、精度和交互速度目标各不相同，因此不能合并比较。TPU 的对比仅限 FP8；英伟达在 FP4 和机架级系统（GB300 NVL72）上的优势并未体现。所有数据均为 SemiAnalysis 基于同一套基准测试框架的估计，且会随软件成熟度逐月变化 [S625,S621]。

提示

算例 —— 英伟达需要降价多少才能持平？ 要与 Ironwood 每百万 token $0.181 的成本持平，B200 所有者的成本必须从 $0.222 下降 18.5% [S625]。假设英伟达的发票金额约占买家全口径小时成本的 55%（🔴：折旧是最大的成本项，而系统的大部分由英伟达销售）。那么英伟达的价格需要下降约 34%（18.5% ÷ 55%）。在 75% 的毛利率下，单位成本为原价格的 25%；降价 34% 后，毛利率为 (66 − 25) ÷ 66 ≈ **62%**（🔴 本资料库测算）[S23010]。英伟达能够打赢这样的价格战，但每一个拥有可信 TPU 选项的大买家，都能从这约 13 个百分点的利润缓冲中分走一部分。

注

🐂 **看多观点（对谷歌而言）：** TPU 是唯一一个拥有完整技术栈、十年量产经验、有前沿模型在其上训练，且拥有吉瓦级外部客户的替代方案 [S653,S23005]。

注意

🐻 **看空观点（对谷歌而言）：** 按单芯片计算，Ironwood 的 FP8 算力约为 Rubin 的四分之一，内存带宽约为其 40% [S151,S33004,S90006]。在谷歌之外，其软件路径尚不成熟，商用 GPU 仍是大多数买家的默认选择。

5. 对企业发展（corp dev）的启示

自研 ASIC 何时能回本。 TPU 之所以成功，是因为谷歌满足了流程图中的全部四个条件：自有需求远高于盈亏平衡点、核心工作负载稳定、拥有自己的编译器和框架，以及拥有自己的数据中心。它还花了十年时间、历经七代产品。很少有公司能同时满足这四个条件，这也是大多数定制芯片项目规模有限，或依赖租用合作伙伴技术栈的原因。

设计合作伙伴获取持久价值。 博通在每一代产品上都能获得收入，却无需拥有架构或模型 [S661]。联发科 2026 年 $2B 的 AI ASIC 收入目标表明，第二供应商角色同样有价值（🟡）[S2518]。对供应商而言，同时担任多家超大规模云厂商的设计服务方，可以将风险分散到多个客户身上。

替代方案先改变价格，后改变份额。 英伟达仍占据 AI 加速器收入的大部分，但对外销售的谷歌 TPU 为最大的买家提供了一个谈判锚点。更多内容参见竞争格局、第 05 层竞争格局与第 02 层竞争格局。

🎯 企业发展视角

1. 盈亏平衡测算表明，一个完整的自研项目每代约需 130,000 颗芯片（🔴）。哪些买家能越过这一门槛？哪些买家更愿意授权一套设计或与合作伙伴共同开发？
2. 设计服务公司（博通、联发科、美满电子、世芯（Alchip））无需拥有模型或云即可获取价值。哪些能力（SerDes、封装、HBM 供应）让设计服务公司不可或缺？其中哪些可以自建或收购？
3. 谷歌如今向 Anthropic 和 Meta 等竞争对手出售 TPU 算力 [S653,S90025]。商用 TPU 业务是否会改变超大规模云厂商对自有芯片项目的估值，以及它们与英伟达的议价方式？
4. 高通（Qualcomm）公开的 AI200/AI250 和 Dragonfly AI300 计划瞄准推理成本 [S90028,S90056]。挑战者需要在框架支持、公开基准测试和锚定客户方面做到什么程度，其每 token 成本主张才能像如今的 TPU 一样被市场采信？
5. 如果 TPU 级替代方案压缩了英伟达在最大买家处的利润率，释放出的预算会流向哪里：更多算力、网络还是软件？

CS4 · AMD、OpenAI 与第二供应商

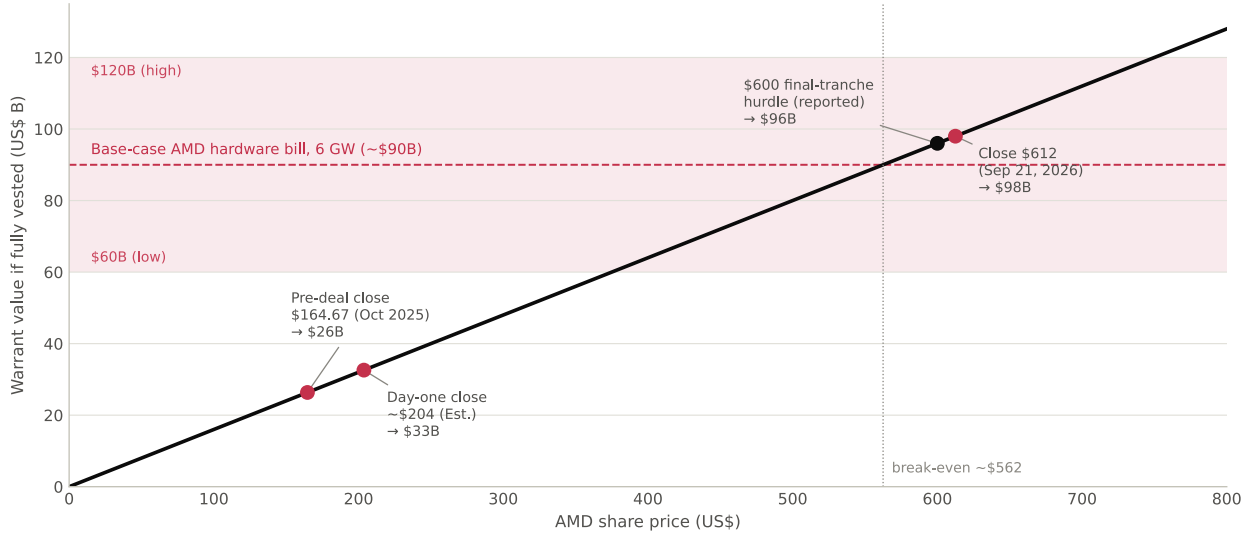
案例研究 · 阅读约 14 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **交易内容：** 2025-10-06，OpenAI 同意部署最多 6 GW 的 AMD Instinct GPU，首批为 2026 年下半年的 1 GW MI450。AMD 以自身股票支付对价：一份可按 $0.01 认购最多 1.6 亿股 AMD 股票的认股权证，随吉瓦级部署推进及 AMD 股价上涨分批归属 S24000,S13506。
- **这是对英伟达资本攻势的回应：** 两周前，英伟达（NVIDIA）签署了一份意向书（LOI），拟随 OpenAI 部署 10 GW 英伟达系统而投资最多 $100B S467。2026 年 2 月，这份意向书被搁置，改为一笔约 $30B、不附部署里程碑的直接股权投资 🟡 S90015,S90016。
- **市场认为交易具有增值效应：** AMD 股价在公告当天收涨约 23.7 % S24002，在 $267B 市值基础上增加约 $63B（本资料库计算）。按交易前股价计算，该认股权证价值约 $26B，对应 AMD 约 9.9 % 的股份 S24001。
- **折扣是或有的，且具有反身性：** 按报道的最后一批 $600 股价门槛计算，全部归属的认股权证价值约 $96B，与 OpenAI 6 GW AMD 硬件账单的估计值大致相当（估计约 $90B，🔴 本资料库情景）。AMD 股价于 2026-09-21 首次收于 $600 以上 S24005,S13507。
- **OpenAI 构建的是一个供应商组合，而非单一的第二供应商：** 与博通（Broadcom）合作的 10 GW 定制加速器 S174、来自 Cerebras 的最多 750 MW S11523、自 2025 年起租用并据报道将采购的谷歌（Google）TPU 🟡 S24007,S24008，而英伟达仍是压舱石。
- **已被证实的（2026 年 11 月）：** AMD 的 Helios 机架已投产，首批出货约在 2026 年第三季度末 S90020。AMD 与 Meta 签订了相同结构的协议 S24004。AMD 数据中心收入在 2026 年第三季度同比增长 97 % S542。
- **尚未被证实的：** OpenAI 的大规模 MI450 部署直到 2026 年第四季度才开始 🟢 S90021。没有任何一批认股权证公开归属 S24005。2023 年初至 2026 年年中，英伟达数据中心收入相对 AMD 的领先倍数从 3.3 倍扩大到 13 倍（本资料库根据财报计算） S450,S543,S405。

At the $600 hurdle, AMD's warrant (~$96B) ≈ OpenAI's 6 GW AMD hardware bill (Est. ~$90B)

Value of 160M AMD shares at $0.01 if fully vested (US$ B) vs share price; band = assumed 6 GW spend at $10–20B/GW



Band = repo scenario

Source: data from AMD/OpenAI terms and AMD share prices [S24001] [S24002] [S24005] [S13507] [S24003] [S24000] ...; chart by repo · As of 2026-11-05

> 折线图：行权价 $0.01、对应 1.6 亿股 AMD 股票的认股权证，按交易前股价 $164.67（2025-10-03）计算价值约 $26B，首日上涨约 24% 后为 $33B，按报道的最后一批 $600 门槛计算为 $96B，按 2026-09-21 收盘价 $612.46 计算为 $98B。阴影带表示本资料库对 OpenAI 6 GW AMD 硬件支出的假设：$60B 至 $120B（基准 $90B）。股价超过约 $562 时，全部归属的认股权证价值将与基准情景的硬件账单相当；归属还需要全部 6 GW 完成部署。

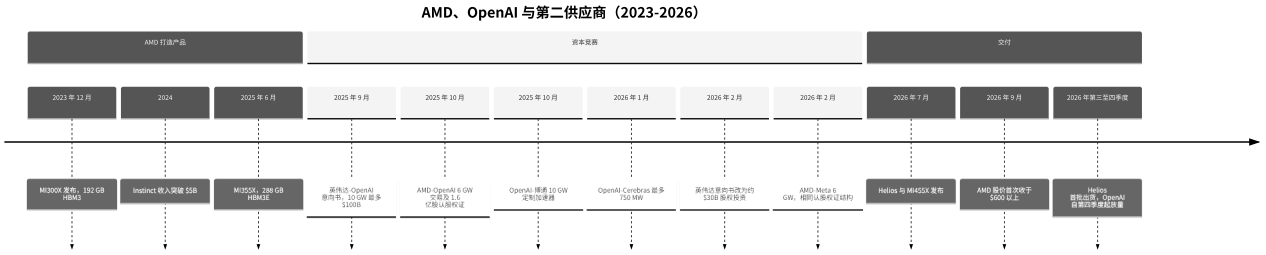
1. 背景

AMD Instinct 的放量。 AMD 进入 AI 加速器竞赛较晚。MI300X 于 2023-12-06 发布，配备 192 GB HBM3、带宽 5.3 TB/s，内存容量超过 H100 [S141]。AMD 数据中心 GPU 收入从 2023 年第四季度的数亿美元增至 2024 年的 $5B 以上 [S663]。MI355X（2025 年 6 月）配备 288 GB HBM3E、带宽 8 TB/s，稠密 FP4 算力 10.1 PFLOPS [S143]。在 MLPerf Inference v6.0 中，其在 Llama 2 70B 上的单 GPU 性能与 B200 持平（12,935 对 12,994 tokens/s）[S602]。AMD 缺少的是类似英伟达 NVL72 的机架级系统和成熟的软件栈（ROCm 对 CUDA）。最重要的是，它缺少一个愿意把前沿模型押在它身上的标杆客户。

OpenAI 的胃口。 截至 2025 年 10 月，OpenAI 已承诺约 30 GW 的算力，成本约 $1.4T，而其 2025 年底的年化收入预计仅约 $20B [S24006]。吉瓦级算力如今已成为这类交易的计量单位，因为电力和场地比芯片更早成为约束。

英伟达抢先出手。 2025-09-22，英伟达与 OpenAI 宣布一份意向书：英伟达投资最多 $100B，随 10 GW 中每 1 GW 上线逐步支付，首个吉瓦基于 Vera Rubin，于 2026 年下半年部署 [S467]。2026 年 2 月，该意向书被搁置，改为在 OpenAI 融资轮中进行约 $30B 的股权投资，不附部署里程碑 🟡 [S90015,S90016,S90017]。

> **提示**
>
> **算例 —— 为何 30 GW 迫使买家引入第二供应商。** 英伟达 CEO 曾表示，每 GW AI 工厂中英伟达的价值量约为 $35B（2025 年 8 月）[S398]。30 GW × $35B ≈ **$1.05T** 的英伟达价值量，约为英伟达 FY2026 全年收入 $215.9B 的 5 倍 [S1]。没有任何买家会在缺少可用于比价的替代方案时，向单一供应商承诺如此大的金额。这笔账单上 5 % 的让步就价值约 $52B。🔴 本资料库基于厂商与媒体数据的测算。



2. 决策

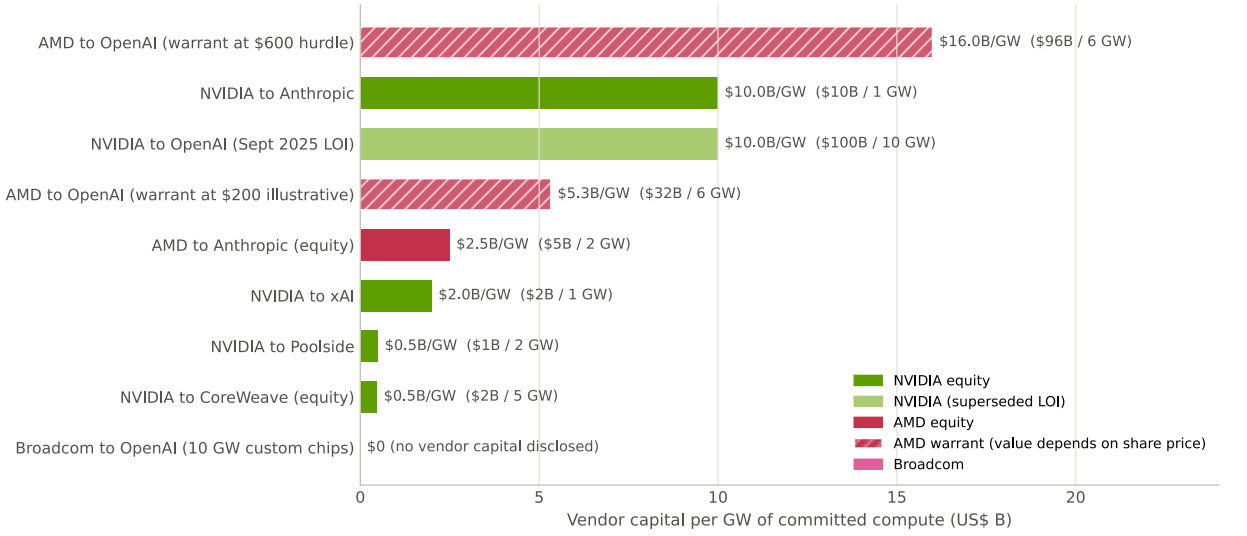
交易条款。 OpenAI 承诺在多代产品上部署最多 6 GW 的 AMD Instinct GPU，首批为 2026 年下半年的 1 GW MI450 [S24000]。作为回报，AMD 发行一份认股权证，可按每股 $0.01 认购最多 1.6 亿股 AMD 股票，期限五年 [S24003]。这约占 AMD 交易前约 16.23 亿股的 9.9 %（本资料库根据 $164.67 股价对应的 $267.23B 市值计算 [S24001]）。第一批随首个吉瓦部署而归属。后续各批需要更多吉瓦完成部署、AMD 股价达到逐级提高的目标（据报道最后一批为 $600），以及 OpenAI 的技术和商业里程碑 [S13507,S24003]。AMD CFO 表示，该交易将带来“数百亿美元”的收入，并将显著增厚非 GAAP 每股收益 [S24000]。媒体估计在数年内最高可达 $100B [S24010]。就连英伟达 CEO 也称这一结构“很聪明” [S24011]。

这是一种以股权换产能（equity-for-capacity）的结构，而且与英伟达的结构正好相反。英伟达是*买入客户的股权*：它向 OpenAI 提供现金，而在批评者看来，这些现金又以 GPU 订单的形式回流（循环融资）。AMD 则是*把自己的股权给客户*：OpenAI 按全价购买芯片，但若其大规模部署且 AMD 股价上涨，即可获得 AMD 股票。一周后宣布的博通 10 GW 项目则完全没有披露任何厂商出资。OpenAI 设计芯片，博通负责联合开发并供应机架 [S174]。

交易（日期）	产能	厂商出资	是否与部署挂钩？	状态（2026 年 11 月）
英伟达意向书（2025-09-22）	10 GW	最多 $100B，逐步支付	是，按 GW	🟡 2026 年 2 月搁置 [S90016]
英伟达股权投资（2026 年 2 月）	—	在 OpenAI 融资轮中投资约 $30B	否	🟡 据报道已达成 [S90015,S13526]
AMD 认股权证（2025-10-06）	6 GW	1.6 亿股 AMD 股票，行权价 $0.01	是，另附股价门槛	🟢 生效中；首个 GW 于 2026 年下半年 [S24000]
博通（2025-10-13）	10 GW	未披露	—	🟢 2026 年下半年至 2029 年部署 [S174]
Cerebras（2026-01-14）	最多 750 MW	无（约 $10B 采购）	—	🟡 有报道 [S11523]
AMD 向 Meta 发行的认股权证（2026-02-24）	6 GW	1.6 亿股 AMD 股票，行权价 $0.01	是，另附 $600 门槛	🟢 首个 GW 于 2026 年下半年 [S24004]

AMD's warrant may give OpenAI ~$16B/GW (at $600/share) vs NVIDIA's ~$10B/GW pledges

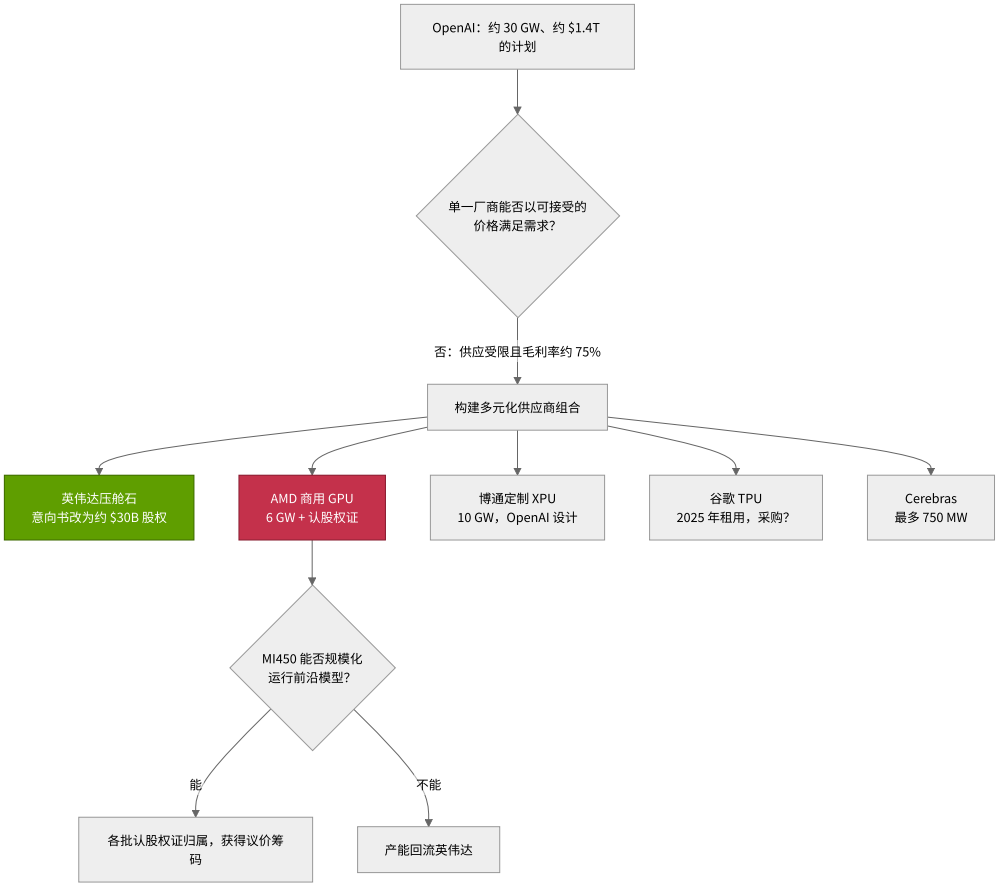
Vendor capital offered per gigawatt of committed compute, US$ B per GW (equity, or warrant value at a given AMD share price)



Hatched = repo calculation

Source: data from company announcements, press; repo arithmetic [S467] [S90016] [S90015] [S13526] [S469] [S90075] ...; chart by repo · As of 2026-11-05

水平条形图：客户每承诺 1 吉瓦算力所对应的厂商出资。若 AMD 股价达到报道的 $600 门槛，其 1.6 亿股认股权证对 OpenAI 的价值约为每 GW $16B，按示意性的 $200 股价计算约为每 GW $5.3B；英伟达对 Anthropic（最多 $10B，1 GW）以及对 OpenAI 已被取代的意向书（$100B，10 GW）的承诺约为每 GW $10B；AMD 对 Anthropic 最多 $5B 的入股约为每 GW $2.5B（2 GW）；英伟达对 xAI 的入股约为每 GW $2B，Poolside 约 $0.5B，CoreWeave 约 $0.47B；博通 10 GW 的 OpenAI 项目未披露任何厂商出资。英伟达 2026 年对 OpenAI 的 $30B 股权投资与 GW 无关。



提示

算例 —— 认股权证对 OpenAI 的价值与隐含的硬件折扣。 假设（🔴 均为本资料库情景）：OpenAI 的 AMD 硬件支出为每 GW $15B，以媒体对 AMD 与 Meta 同类交易的估值（6 GW 对应 $60–100B 以上）为锚 S24004,S24010。因此 6 GW ≈ **$90B**。全部归属时认股权证价值 = 1.6 亿股 × 股价。

AMD 股价	认股权证价值	相当于 $90B 账单的折扣
$164.67（交易前收盘价） S24001	$26B	29 %
$400（示意）	$64B	71 %
$600（最后一批门槛） S13507	$96B	107 %

有三项修正会缩小这一标题数字。(1) **分批：** 若每吉瓦对应的批次相等（条款未公开），1 GW 可获得约 2,700 万股。按 $600 计算约为 $16B，对应约 $15B 的硬件。如果 OpenAI 止步于 3 GW，最后几批高门槛认股权证将永远不会归属。(2) **时间价值：** 最后几批要在数年后才归属，因此应按 OpenAI 的资本成本折现。(3) **反身性：** 很大一部分价值来自 AMD 股价*因为*此类交易而上涨。首日市场增加了约 $63B（23.7 % × $267B），约为认股权证当时约 $26B 价值的 2.4 倍 S24002,S24001。对 AMD 的股东而言，这笔交易看起来是增值的。对 OpenAI 而言，这是一份押注 AMD 成功的免费期权，而且恰恰在 AMD 最不需要它的时候最值钱。

🔧 技术细节：一分钱认股权证如何像返利一样运作，以及它对 AMD 财务报表的影响

行权价为 $0.01 的认股权证在经济上相当于一笔或有的股票授予：行权价可以忽略不计，因此一旦归属，价值 ≈ 股数 × 股价。这使它成为一种**以股票支付的返利**，但有两点不同。其一，其规模随 AMD 股价而非硬件账单变动，因此实际折扣可能超过 100 %（如上所示），也可能缩小到微不足道。其二，股价门槛保护了 AMD 现有股东：稀释最严重的几批，只有在现有股东已经大幅获益后才会归属。

根据美国公认会计准则（US GAAP），授予客户的权益工具一般被视为应付客户对价。它们按公允价值计量，并在确认相关销售时记为*收入的减项*，而非经营费用。由此引出若干尽职调查问题：AMD 每吉瓦确认多少收入抵减、公允价值多久重新计量一次，以及非 GAAP 数据是否将其剔除。AMD 实际如何入账，应查阅其 10-K 和 10-Q 附注。🟡 本次未核实。

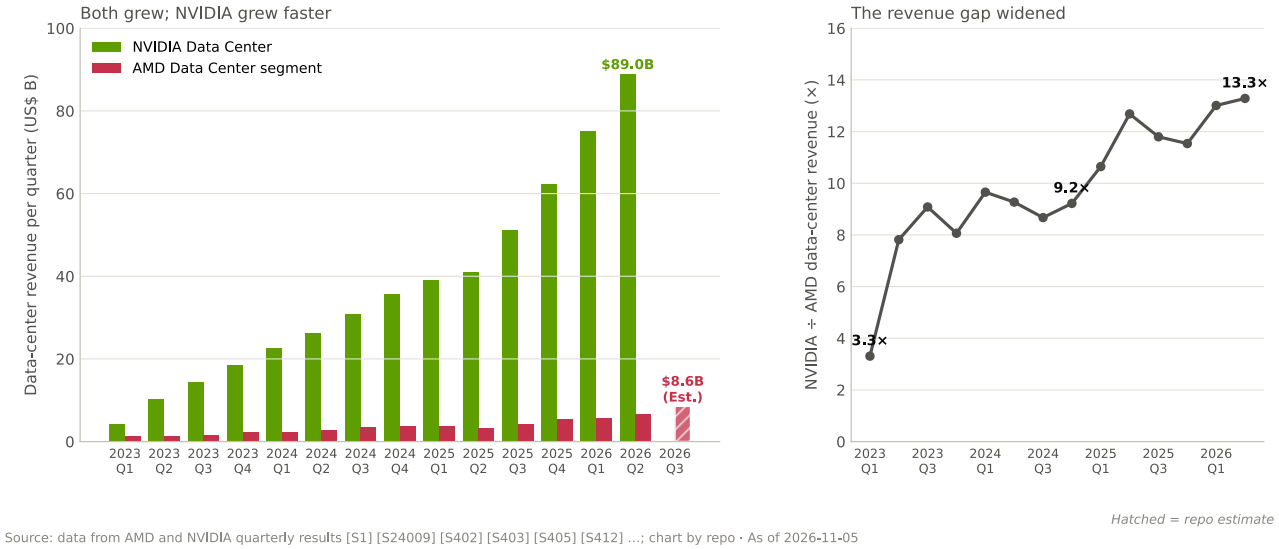
股权稀释会叠加。OpenAI 和 Meta 的认股权证合计涵盖 3.2 亿股 S24003，约占交易前股本的 20 %（行权后约 17 %；本资料库计算）。

3. 结果（用数据说话）

截至 2026-11-05，即签约约 13 个月后，这个第二供应商**已经建成，但尚未在 OpenAI 的规模上得到验证**。

事项	状态	来源
Helios（72 × MI455X、EPYC Venice、Pensando 网卡）于 2026-07-23 发布	🟢 已确认	S538,S539
Helios 已投产；首批出货约在 2026 年第三季度末	🟢/🟡	S90020,S90021
AMD 数据中心收入：2026 年第一季度 $5.8B（+57 %），第二季度 $6.7B（+107 %），第三季度同比 +97 %	🟢 已确认	S24009,S543,S542
与 Meta 签订相同的认股权证结构（6 GW）	🟢 已确认	S24004
Anthropic：最多 2 GW 的 MI450 级 Helios；AMD 拟投资最多 $5B	🟢/🟡	S538,S9538
AMD 股价突破 $600 门槛（2026-09-21 收盘价 $612.46；市值超过 $1T）	🟡 有报道	S24005
OpenAI 大规模部署 MI450，2026 年第四季度延续至 2027 年	🟡 待定	S90021
任何一批认股权证已归属或行权	🔴 未披露	S24005
Azure 成为首个大型 Helios 部署	🟡 有报道	S90024

事项	状态	来源
OpenAI 采购（而不仅是租用）谷歌 TPU	🔴 单一来源报道	S24008



双面板图，自然年 2023-Q1 至 2026-Q3。左：AMD 数据中心分部季度收入从 $1.3B 增至 $8.6B（2026-Q3 为本资料库根据 AMD 同比 +97% 推算的估计值），约 6.6 倍；同期英伟达数据中心收入从 $4.3B 增至 $89.0B（2026-Q2）。右：英伟达数据中心收入在 2023-Q1 为 AMD 的 3.3 倍，2024-Q4 为 9.2 倍，2026-Q2 为 13.3 倍：第二供应商尚未缩小收入差距。AMD 的数据包含 EPYC 服务器 CPU，因此仅就 GPU 而言差距更大。

收入差距是一个令人清醒的数字。AMD 数据中心分部（包括 EPYC CPU）从 2023 年第一季度到 2026 年第三季度增长约 6.6 倍 [S450,S542]。英伟达数据中心收入从 Q1 FY2024 到 Q2 FY2027 增长约 21 倍 [S436,S405]。2025 年 AMD 约占 AI 数据中心芯片收入的 3 %（估计，本资料库在 `data/market_share.csv` 中的计算）[S663,S416]。OpenAI 的这笔交易是 2027 年的收入事件，而非 2026 年的。

> **提示**
>
> **算例 —— OpenAI 的首个吉瓦对 AMD 意味着什么。** 按每 GW $15B 的基准情景（🔴），首个吉瓦约带来 $15B 收入。AMD 2026 年第三季度数据中心业务年化收入约为 $34B（估计约 $8.5B × 4）[S542]。因此，单一客户的首个吉瓦约相当于 AMD 整个数据中心业务 5 个月的收入。这使 AMD 2027 年的业绩高度依赖 OpenAI 的部署节奏和融资情况。六个吉瓦按 $15B 计算为 $90B，约相当于 AMD 当前数据中心年化收入的 2.6 年。

4. 为何奏效（或为何未能奏效）

买家为何需要第二供应商。 原因有二：价格与供应。英伟达在 Q2 FY2027 实现了 75.0 % 的 GAAP 毛利率 [S3]。可信的替代方案是买家影响这一利润率的唯一杠杆。另一个原因是供应：英伟达称其 FY2028 展望“受供应约束” [S90012]。拿不到足够 GPU 的实验室就无法交付产品。即使 AMD 永远拿不到一半的份额，一个*有能力*承接产能的第二供应商也会影响英伟达的定价和配货决策。英伟达自身在四个月后从附里程碑的意向书转向约 $30B 的直接股权投资，与这种压力是吻合的 🔴（推断）。

注

🐂 **看多观点（AMD 与第二供应商）。** 从纸面参数看，Helios 在内存上领先 Vera Rubin NVL72：HBM4 容量 31 TB 对 20.7 TB [S90021,S102]。在机架级高带宽内存（HBM）带宽上同样领先（约 1,678 对 1,400 TB/s，高出约 20%），而英伟达的规格修订还扩大了这一领先幅度 [S90006,S90093]。每 GPU 的纵向扩展（scale-up）带宽为 3.6 对 3.0 TB/s [S5522,S90007]。AMD 的 MI325X、MI355X 和 MI455X 均在英伟达旗舰产品推出后约一个季度内问世，因此代际节奏差距已基本消除 [S142,S143,S539]。三家前沿买家（OpenAI、Meta、Anthropic）已承诺最多 14 GW [S24000,S24004,S538]。

机架（2026）	AMD Helios	英伟达 Vera Rubin NVL72	对 AMD 的评价
每个纵向扩展域的 GPU 数	72 个 MI455X	72 个 Rubin	🟨 规模相同 [S344,S102]
HBM4 容量	约 31 TB	20.7 TB	🟩 约 1.5 倍 [S90021,S102]
HBM 带宽（机架）	约 1,678 TB/s	1,400 TB/s（修订后）	🟩 约 1.2 倍；也高于发布时的 1,580 规格 [S90093,S90006]
FP8 算力	1.4 EF	约 1.26 EF 稠密	🟩 纸面领先 [S90021,S33006]
纵向扩展互连	基于以太网的 UALink（UALoE），每 GPU 3.6 TB/s（机架约 260 TB/s）	NVLink 6，每 GPU 3.0 TB/s（修订后）	🟦 开放 vs 专有 [S226,S5522,S90007]
软件成熟度	ROCm 7.x	CUDA	🟥 落后（见下文） [S90064,S633]
机架级交付记录	第一代	第三代（GB200、GB300、VR）	🟥 落后 [S8527,S5501]

为何可能行不通。 共有三项风险，按权重排序：

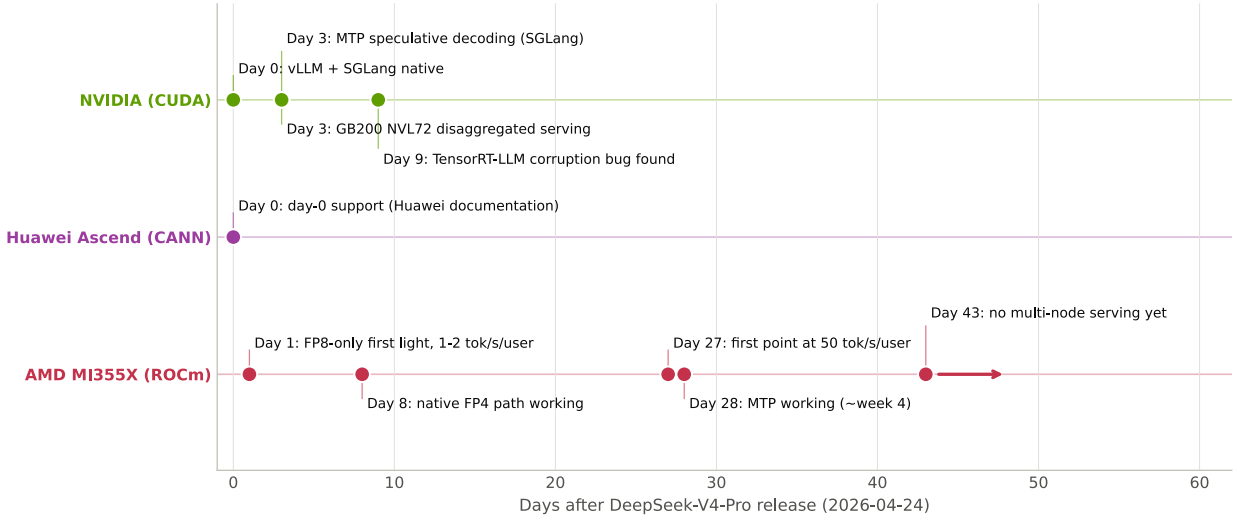
1. **软件。** DeepSeek-V4-Pro 于 2026 年 4 月发布时，首日即可在 CUDA 上运行。在 MI355X 上，FP4 在第 8 天可用，每用户 50 tokens/s 在第 27 天实现。到第 43 天，多节点推理服务仍无法运行 [S633,S631]。在一项智能体（agentic） GLM 5.3 测试中，在每用户 150 tokens/s 下，英伟达的每 token 成本最多低 5 倍 [S636]。在一项 GLM-5 吞吐量测试中，MI355X 比 B200 最多便宜 29.6 % [S637]。AMD 能在自己专门调优过的基准测试中胜出。实验室真正的风险在于大量尚未调优的新模型这一长尾。
2. **机架级可靠性。** Helios 是 AMD 的第一款机架级系统。它依赖随 ZT Systems（$4.9B，2025-03-31 完成交割）收购而来的设计团队 [S8527]，而 ZT Systems 的工厂已出售给 Sanmina [S5528]。英伟达自己的首款 NVL72 在放量期间也曾出现过热报道和客户反弹 [S5501]。2026 年 2 月一则关于 MI455X 延期的报道遭到 AMD 否认 [S2521,S2524]。
3. **英伟达的年度迭代节奏。** Vera Rubin 于 2026 年第三季度开始出货，第四季度放量 [S90009]。Rubin Ultra（Kyber，144 个封装）将于 2027 年下半年推出，Feynman 将于 2028 年推出 [S90003,S90004]。第二供应商每年都要追赶一个移动的目标，而其可用于投入的数据中心收入少了约 13 倍。

提示

算例 —— 第二供应商的软件税。 某实验室希望一个新的开源模型在发布时即可在 100,000 个 GPU 上提供服务。在 CUDA 上，DeepSeek-V4-Pro 首日即可运行。在 MI355X 上，达到每用户 50 tokens/s 用了 27 天 [S633]。按示意性的每 GPU 小时 $2 计算，100,000 个 GPU 利用不足 27 天的成本为 100,000 × 24 × 27 × $2 ≈ **$130M**，尚未计入任何收入损失。相对于一个 6 GW 项目（约 $90B，🔴 基准情景），这个数字很小，因此议价收益可能超过这笔税。但相对于前沿实验室的发布日程，这个数字很大：每个季度出现一次缓慢的发布，就会侵蚀硬件折扣。🔴 本资料库测算。

DeepSeek-V4-Pro ran on CUDA on day 0; ROCm needed 8 days for FP4, 27 for 50 tok/s/user

Days after the 2026-04-24 release to each serving milestone (open-source engines on InferenceX; Huawei per its own docs)



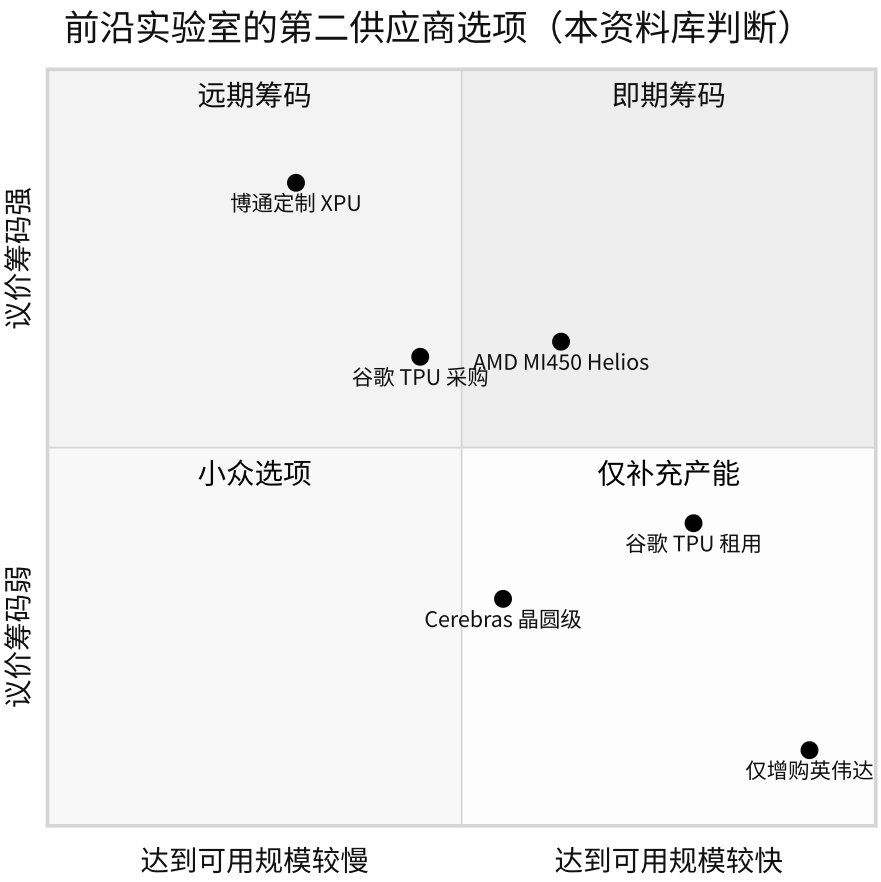
Arrow = not achieved by day 43

Source: data from SemiAnalysis InferenceX articles [S633] [S631]; chart by repo · As of 2026-11-05

DeepSeek-V4-Pro（2026-04-24 发布）适配进度的时间线点图：在英伟达 CUDA 上，vLLM 和 SGLang 首日即原生支持，GB200 NVL72 分离式推理和 MTP 在第 3 天前即可运行，第 9 天发现一个 TensorRT-LLM 输出损坏的缺陷；华为记录了昇腾的首日支持；在 AMD MI355X 上，第 1 天首次跑通时仅支持 FP8、每用户 1-2 tok/s，FP4 在第 8 天可用，每用户 50 tok/s 在第 27 天实现，MTP 约在第 28 天，到第 43 天多节点推理服务仍无法运行。

注意

🐻 **看空观点**。 认股权证买到的是承诺，而不是竞争力。如果 MI450 延期或表现不及预期，OpenAI 几乎没有损失：它少买几个吉瓦，高门槛的几批认股权证作废即可。届时 AMD 就为一个随时可以离开的客户稀释了股东权益。这一结构还助长了 AI 资本开支循环。AI 情绪高涨时，AMD 的股权“货币”更值钱；一旦板块估值下调，认股权证的价值和 AMD 重复这一手法的能力都会同时缩水。



5. 对企业发展（corp dev）的启示

1. **以股权换产能有两种方向。** 厂商可以买入客户的股权（英伟达 → OpenAI、Anthropic），也可以把自己的股权给客户（AMD → OpenAI、Meta）。前者动用现金并增加资产负债表风险。后者以稀释为代价，且只有在发行方股票是一种强势“货币”时才奏效：AMD 股价在交易第一年内从约 $165 涨至约 $612 [S24001,S24005]。股价门槛让发行方在其股东获益最多时付出最多。
2. **将价值与部署而非签约挂钩。** 英伟达最初的意向书和 AMD 的认股权证都按已部署的吉瓦付酬。这使激励保持一致，但也让标题数字（最多 $100B；最多 1.6 亿股）成为上限而非期望值。应为每一批次的概率建模。
3. **第二供应商的硬约束依次是软件、机架和迭代节奏。** AMD 的芯片在纸面上与英伟达旗鼓相当。其差距在于首日模型支持和机架级现场经验。能够弥补这些差距的资产，例如可移植编译器和运行时，或机架集成团队（ZT Systems，$4.9B [S8527]），对挑战者而言可能比再多一款芯片更有价值。
4. **客户集中是一把双刃剑。** OpenAI、Meta 和 Anthropic 合计可能吸收 AMD 最多 14 GW 的产能 [S24000,S24004,S538]。这证明了 AMD 的实力，但也将 AMD 2027–2028 年的收入与三家买家的融资状况绑在一起。

🎯 企业发展视角

1. **支付“货币”：** AMD 的认股权证之所以奏效，是因为其股价正在上涨，且交易前市值约 $267B [S24001]。市值较小的挑战者能提供哪些以股权换产能的条款，而不造成不可接受的稀释？收入返利、预付款或共同投资数据中心场地能否作为替代？
2. **买家视角的第二供应商经济学：** 按每 GW 约 $35B 的英伟达价值量计算 [S398]，一个可信的替代方案能换来英伟达多少个百分点的降价？谁能获得这部分价值：买家，还是永远达不到规模的挑战者？

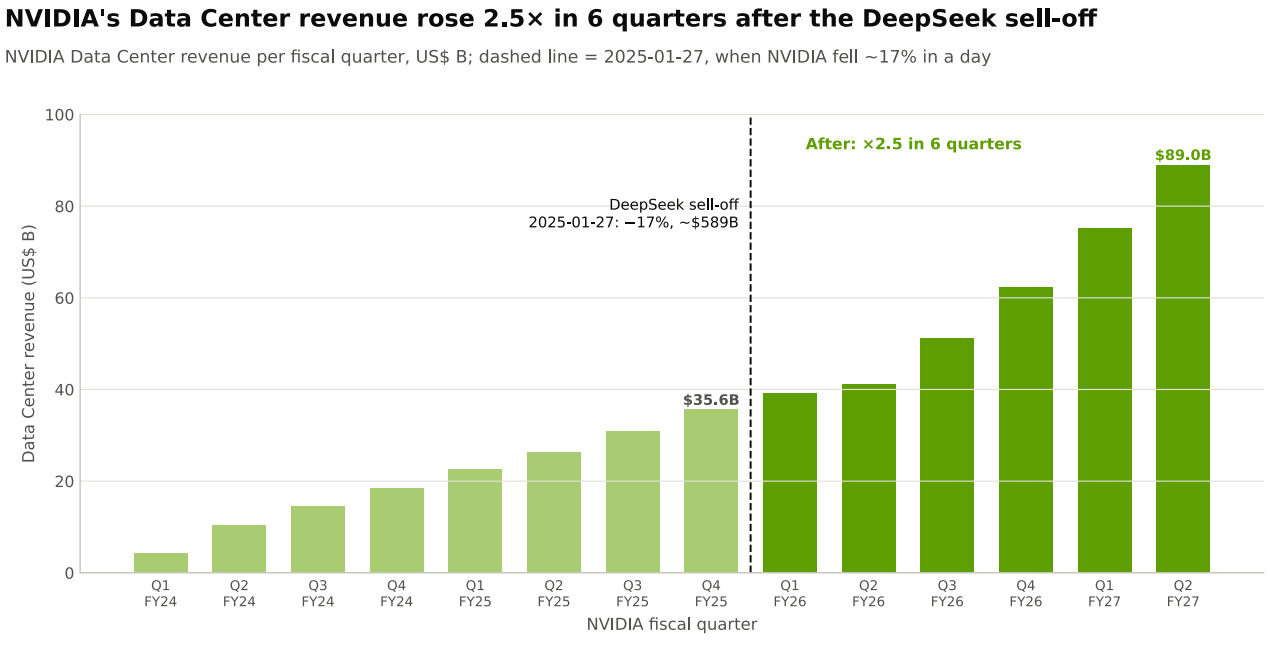
3. **软件是打破护城河的关键：** 高通（Qualcomm）于 2026-07-29 完成的 $3.9B Modular（Mojo/MAX）收购，瞄准的是可跨硬件移植的 AI 软件 [S90057,S9511]。非英伟达硬件上的首日模型支持，会在多大程度上改变实验室承诺吉瓦级采购的意愿?
4. **推理优先的第二供应商：** 高通的 AI200/AI250 机架和 HUMAIN 的 200 MW 计划已经公开 🟢/🔴 [S90028,S90030]。相比 AMD 和博通已深度参与的前沿训练，受电力约束的推理细分市场是否是更现实的第二供应商切入点?
5. **结构风险：** 对于任何提供与股权挂钩产能的合作伙伴，收入抵减、重新计量和非 GAAP 处理是如何进行的? 如果部署停滞，这一工具会怎样?

CS5 · DeepSeek 时刻与效率冲击

案例研究 · 阅读约 14 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **导火索：** DeepSeek-V3（2024 年 12 月）披露，其最终训练运行耗用 278.8 万 H800 GPU 小时，按每 GPU 小时 $2 计算约 $5.6M，训练对象是一个 671B 参数的混合专家模型（MoE） S34007。其推理模型兄弟版本 R1（2025-01-20）以开放权重形式发布 S25002，并登顶美国 App Store S25008。
- **冲击：** 2025-01-27，英伟达（NVIDIA）股价下跌约 17 %，市值蒸发约 $589B，创下有记录以来单一公司最大单日市值损失 S25000,S25001。担忧很简单：如果前沿 AI 所需算力减少 10 倍，GPU 需求就会下降。
- **标题数字的口径很窄：** $5.6M 仅涵盖最后一次训练运行。SemiAnalysis 估计 DeepSeek 拥有约 50,000 个 Hopper GPU，服务器资本开支约 $1.6B S25006,S31013。
- **英伟达的回应是杰文斯悖论（Jevons paradox）：** 智能越便宜，用得越多。英伟达表示，推理“需要大量英伟达 GPU” S25003。其 CEO 表示，推理模型和智能体（agentic） AI 所需的算力比一年前的预期高约 100 倍 S25005。
- **迄今为止的结果对英伟达有利：** 数据中心收入从 $35.6B（Q4 FY2025）增至 $89.0B（Q2 FY2027），增长 2.5 倍 S443,S405。2025-10-29，英伟达成为首家市值达 $5T 的公司 S25010。谷歌（Google）每月处理的 token 数在 18 个月内增长约 134 倍 S32018,S32020。
- **但这一机制有其限度：** 只有当 token 需求的价格弹性大于 1 时，支出才会上升。token 便宜 10 倍，仅为维持支出不变就需要 ⩾ 10 倍的 token 用量（🔴 本资料库模型）。
- **出口管制的转折：** H800 的限制迫使 DeepSeek 追求效率。DeepSeek V4（2026 年 4 月）部分在华为昇腾（Ascend）上训练，DeepSeek 也提及算力受限 🟢/🟡 S90079,S90080。



Source: data from NVIDIA quarterly results [S436] [S422] [S437] [S423] [S438] [S424] …; chart by repo · As of 2026-11-05

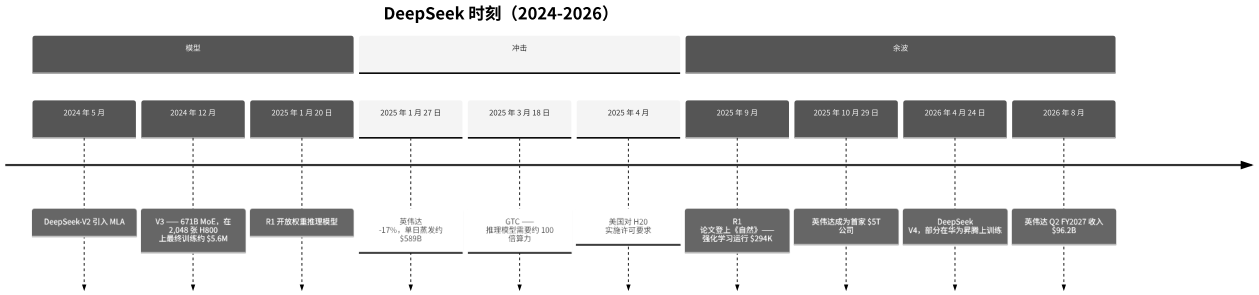
英伟达数据中心收入（按财季，Q1FY24 至 Q2FY27）柱状图。2025-01-27 DeepSeek 引发抛售之前，收入已从 $4.3B 攀升至 $35.6B（Q4FY25）；抛售后的 6 个季度中，收入继续升至 $89.0B（Q2FY27），为冲击前季度的 2.5 倍。效率冲击并未削弱已报告的需求。

1. 背景

DeepSeek 是谁。 DeepSeek（深度求索）是一家位于杭州的 AI 实验室，与其母公司、量化对冲基金幻方量化（High-Flyer）共享 GPU 集群 [S25006]。其 2024 年发布的 DeepSeek-V2 引入了多头潜在注意力（MLA）。MLA 将模型在生成过程中为每个 token 保留的内存（KV 缓存）压缩了 93.3 %，并将最大生成吞吐量提升了 5.76 倍 [S32026]。

V3 的声明（2024-12-27）。 V3 拥有 671B 参数，但每个 token 仅激活 37B。每个 token 被路由到 256 个“专家”子网络中的 8 个，外加一个共享专家 [S34007]。它在 2,048 个 H800 GPU 上以 FP8 精度训练了 14.8T token，并使用手工调优的 PTX（英伟达类似汇编的底层 GPU 代码）来压榨通信效率。最终训练运行耗用 278.8 万 GPU 小时，按假设的 $2 租赁价格计算约 $5.576M [S34007]。R1 随后加入大规模强化学习，形成一个推理模型，以开放许可发布，并附带更小的蒸馏版本 [S25002]。其 API 定价比 OpenAI 的 o1 低约 90–95 % [S25009]。

> **提示**
>
> **算例 —— 为何混合专家模型让账单降低约 18 倍。** 训练算力 ≈ 6 × 激活参数 × token 数。V3：6 × 37B × 14.8T ≈ **3.3 × 10^{24} FLOPs** [S34007]。一个 671B 的稠密模型在相同 token 上需要 6 × 671B × 14.8T ≈ 6.0 × 10^{25}，**约多 18 倍**。摊到 278.8 万 GPU 小时上，V3 每个 GPU 持续约 330 TFLOPS。这约为 Hopper GPU 1,979 TFLOPS 稠密 FP8 峰值的 17 %，或其 989 TFLOPS BF16 峰值的约 33 % [S33002]。这些数字可圈可点，但并不神奇。节省主要来自架构，而非超越了英伟达硬件的极限。🔴 本资料库测算。



2. 决策

2025-01-27 那一周，有两类群体作出了决策，而他们的押注方向截然相反。

投资者选择卖出。 看空逻辑如下：如果一个前沿级模型的训练成本约为 $6M，实验室就需要更少的 GPU，超大规模云厂商的资本开支就是过度建设，英伟达的定价权也会被侵蚀。英伟达约 17 % 的跌幅是自 2020 年 3 月以来最大的一次；标普 500 指数下跌 1.46 % [S25000]。

英伟达及其最大客户坚持原有路线。 英伟达没有下调价格或业绩指引。其声明称 DeepSeek 是“一项出色的 AI 进展”，也是测试时计算（test-time compute）扩展的一个例证。声明指出，DeepSeek 使用的是符合出口管制的硬件，而部署此类模型需要大量 GPU [S25003]。一个月后，英伟达将下一季度指引定为 $43B，高于上一季度的 $39.3B [S443]。微软（Microsoft）CEO 发帖称“杰文斯悖论再次应验” [S25004]。在 GTC 2025 上，英伟达发布了 Dynamo，宣称在 GB200 NVL72 上处理的 DeepSeek-R1 请求数最多可提升 30 倍（厂商宣称）[S32015]。

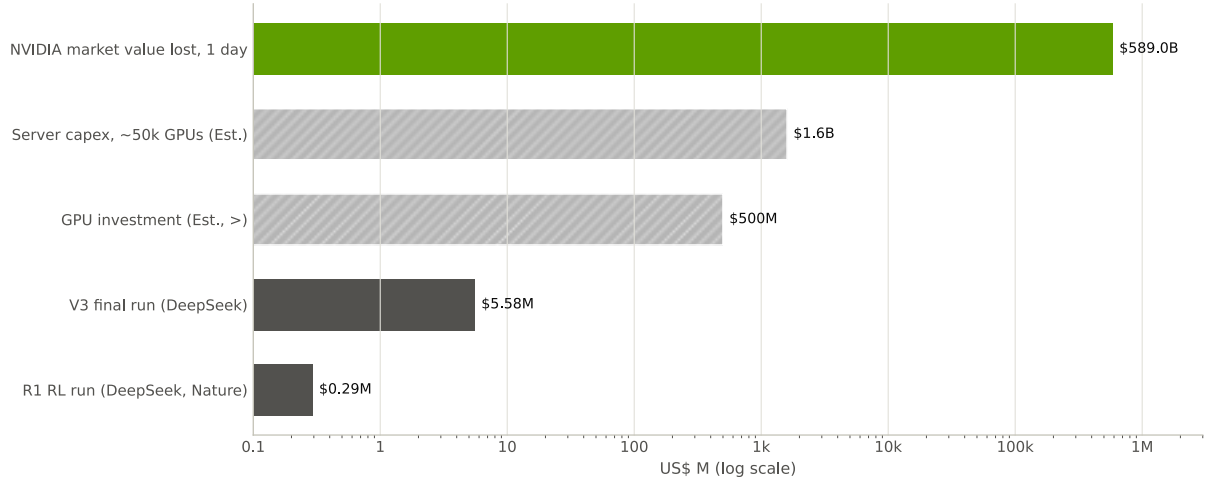
提示

算例 —— 抛售实际计入了什么。 约 17 % 的跌幅对应约 $589B 的损失，意味着英伟达前一天的市值约为 $3.5T（$589B ÷ 0.17；本资料库计算）[S25000]。假如看空逻辑成立、前沿算力需求下降约 10 倍，英伟达未来现金流的价值跌幅将远超 17 %。因此，市场定价的要么是需求大幅削减的小概率事件，要么是一次小幅的永久性削减，而非标题所暗示的崩塌。六个季度后，数据中心收入增长了 2.5 倍 [S443,S405]，英伟达市值也突破了 $5T [S25010]。🔴 本资料库测算。

DeepSeek's $5.6M run was ~1/287 of a ~$1.6B fleet; NVIDIA lost $589B in a day

US$ M (log scale): DeepSeek's own cost claims, SemiAnalysis fleet estimates, NVIDIA's 2025-01-27 market-value loss

LOG SCALE

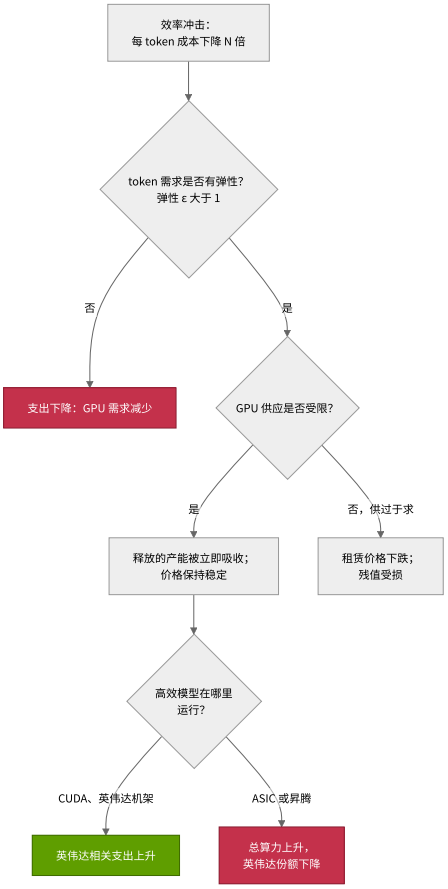


Hatched = estimate

Source: data from DeepSeek, SemiAnalysis, Bloomberg [S25007] [S34007] [S31013] [S25006] [S25000] [S25001]; chart by repo · As of 2026-11-05

对数坐标水平条形图：DeepSeek R1 强化学习运行成本约 $0.29M（《自然》论文，512 张 H800 运行约 80 小时），V3 最终预训练运行 $5.58M（278.8 万 H800 GPU 小时 × $2），两者均为公司口径；SemiAnalysis 估计其 GPU 投资超过 $500M，约 50,000 个 Hopper GPU 集群的服务器资本开支约 $1.6B，因此标题数字约为集群成本的 0.35%；2025-01-27 英伟达市值蒸发约 $589B，约为标题训练成本的 100,000 倍。

2025 年 1 月的说法	更完整的记录显示
“约 $6M 训练出前沿模型”	仅为最后一次运行；不含研究、消融实验和集群本身 [S31013]。集群约 5 万个 Hopper GPU，资本开支约 $1.6B（估计） [S25006]
“推理强化学习很便宜”	R1 的强化学习阶段在 512 张 H800 上花费约 $294K，且是*在* V3 基座模型*之上*；DeepSeek 还拥有 A100 [S25007]
“实验室将需要更少的 GPU”	前沿实验室把节省下来的资源再投入到更大规模的训练和推理模型；谷歌每月 token 数在 18 个月内增长约 134 倍 [S32018,S32020]
“出口管制失败了”	H800 在购买时是合法的 [S25003,S25011]；到 2026 年，DeepSeek 提及算力受限，并将 V4 的部分训练转移到昇腾上 [S90079]



3. 结果（用数据说话）

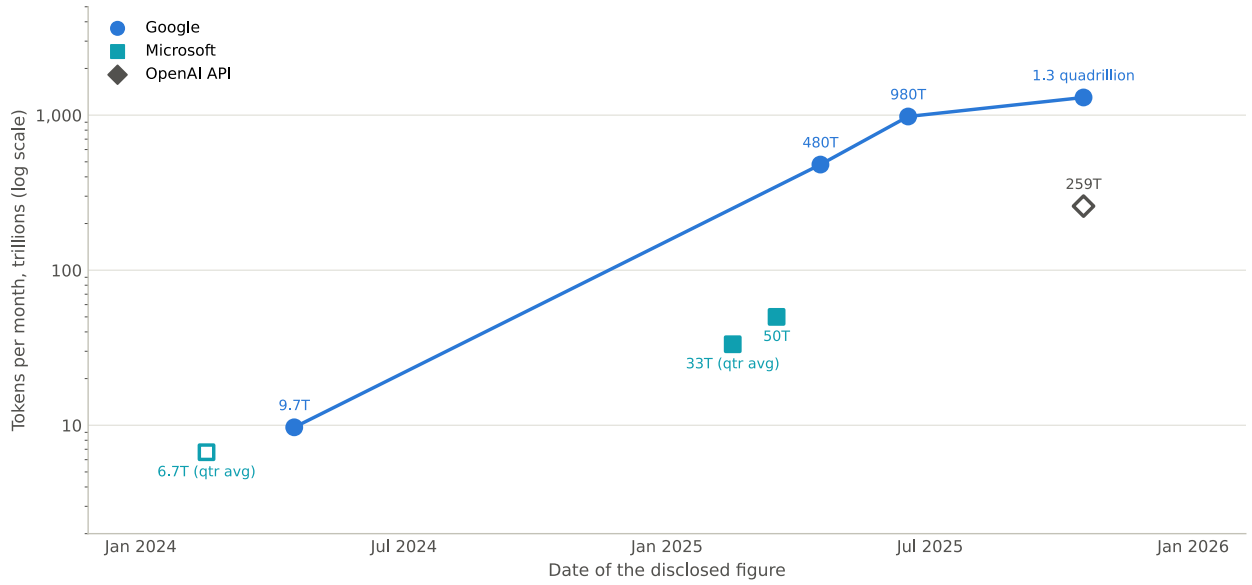
英伟达的收入并未受挫。 抛售后已披露的六个季度中，数据中心收入逐季增长，Q2 FY2027 达到 $89.0B [S405]。总收入达到 $96.2B，Q3 FY2027 指引为 $108B [S3]。超大规模云厂商 2026 年资本开支指引合计超过 $700B 🟡 [S12518,S12519]。股价在数月内收复失地：2025-10-29，英伟达收于 $207.04，市值 $5.03T [S25010]。

token 需求呈爆发式增长。 谷歌每月处理的 token 从 9.7T（2024 年 4 月）增至超过 1.3 千万亿（2025 年 10 月）[S32018,S32020]。

Google's monthly tokens rose ~134× in 18 months, to over 1.3 quadrillion

Tokens processed per month, trillions (log scale), as disclosed by companies; hollow = derived from a stated rate

LOG SCALE



Source: data from Alphabet, Microsoft and OpenAI executive remarks [S32018] [S32019] [S32020] [S32021] [S32022]; chart by repo · As of 2026-11-05

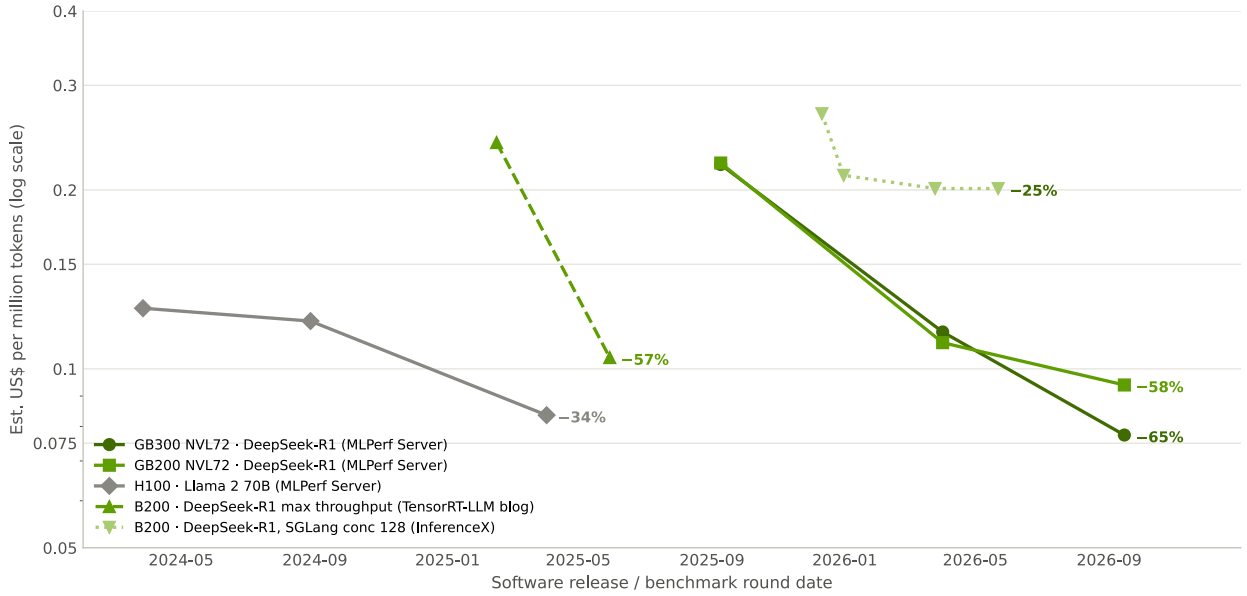
> 已披露 AI token 处理量的对数坐标图：谷歌从每月 9.7 万亿 token（2024 年 4 月）增至 480 万亿（2025 年 4 月）、约 980 万亿（2025 年年中）和超过 1.3 千万亿（2025 年 10 月），18 个月约增长 134 倍。微软在 2025 年 1–3 月处理了超过 100 万亿 token（为一年前的 5 倍），仅 3 月就达 50 万亿；OpenAI 的 API 在 2025 年 10 月约每分钟处理 60 亿 token，约合每月 259 万亿。

每 token 价格持续下降。 GPT-3.5 级输出的成本从每百万 token $20（2022 年 11 月）降至 $0.07（2024 年 10 月），降幅超过 280 倍 [S11526]。Epoch AI 测算，在能力不变的条件下，价格每年下降 9–900 倍 [S11525]。仅凭英伟达自身的软件优化，GB300 NVL72 上每百万 DeepSeek-R1 token 的估计成本在一年内下降了 65%，无需新硬件 [S603,S622]。前沿模型价格则是例外：GPT-5.5 于 2026 年 4 月发布，价格是其前代的两倍 [S11535]。买家持续向最好的模型升级。

Software alone cut GB300 NVL72's estimated cost per million tokens 65% in a year

Est. US$/M tokens = fixed owner TCO ÷ measured tokens/s per GPU on unchanged hardware; compare slopes, not levels

LOG SCALE



Source: data from MLPerf Inference; TensorRT-LLM blog; InferenceX + TCO; repo math [S601] [S602] [S603] [S604] [S605] [S600] ...; chart by repo · As of 2026-11-05

对数坐标折线图：在英伟达硬件不变、仅软件改进的情况下每百万 token 的估计成本，各 GPU 的所有者 TCO 固定不变（SemiAnalysis：GB300 $2.31、GB200 $1.86、B200 $1.73、H100 $1.17 每 GPU 小时）。GB300 NVL72 · DeepSeek-R1（MLPerf Server）：$0.221 降至 $0.077（降低 65%，2025 年 9 月至 2026 年 9 月）；GB200 NVL72 · DeepSeek-R1（MLPerf Server）：$0.222 降至 $0.094（降低 58%，2025 年 9 月至 2026 年 9 月）；H100 · Llama 2 70B（MLPerf Server）：$0.126 降至 $0.084（降低 34%，2024 年 3 月至 2025 年 4 月）；B200 · DeepSeek-R1 最大吞吐量（TensorRT-LLM 博客）：$0.240 降至 $0.104（降低 57%，2025 年 2 月至 2025 年 5 月）；B200 · DeepSeek-R1，SGLang 并发 128（InferenceX）：$0.269 降至 $0.201（降低 25%，2025 年 12 月至 2026 年 5 月）。硬件账单不变，每 GPU 吞吐量提升，因此每 token 成本下降。

DeepSeek V4（2026-04-24）提供两种规格：V4-Pro（约 1.6T 参数）和 V4-Flash（284B），均为开放权重。Flash 的部分训练在华为昇腾上完成，昇腾超节点（SuperNode）也已适配推理 [S90079]。V4-Pro 的定价约为每百万输出 token $3.48。DeepSeek 表示，在昇腾 950 超节点于 2026 年下半年规模化出货之前，吞吐量将持续受限 [S90080]。V4 首日仍可在 CUDA 上运行，而 AMD 的 MI355X 则需要数周 [S633]。

提示

算例 —— 每 token 成本下降 10 倍，以及支出上升所需的弹性。 某买家每年在推理上支出 $1B，价格为每百万 token $1.00：即 1 千万亿 token。效率提升使价格降至 $0.10。在弹性恒定的需求下，token 用量增加 10^ε 倍，支出变化为 10^(ε−1) 倍。

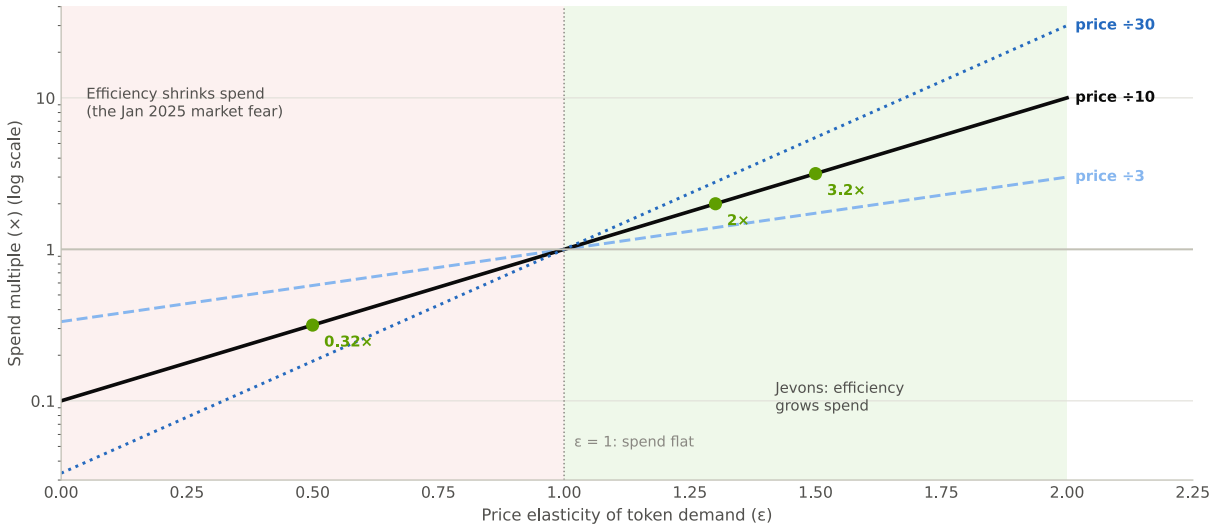
弹性 ε	购买的 token	支出	若每 token 算力下降 10 倍，算力（GPU）支出变化
0.5	3.2 千万亿	$0.32B	−68 %
1.0	10 千万亿	$1.00B	持平
1.3	20 千万亿	$2.0B	翻倍
1.5	32 千万亿	$3.2B	3.2 倍

谷歌 18 个月内 134 倍的 token 增长 [S32018,S32020] 远高于价格下降 10 倍时维持支出不变所需的 10 倍。但若以最陡峭的质量不变价格降幅（Epoch 的中位数约每年 50 倍 [S11525]）来衡量，隐含的 ε 小于 1。两者之所以能够吻合，只是因为买家转向了更昂贵的前沿模型和推理模型。即使每项能力都在变便宜，每次查询的支出仍在上升。🔴 本资料库模型；未考虑需求曲线的移动。

10× cheaper tokens raise compute spend only if demand elasticity exceeds 1 (ε 1.5 → 3.2×)

Spend after the price drop ÷ spend before, by price elasticity of token demand (constant-elasticity model, log scale)

LOG SCALE



Model, not a forecast

Source: data from repo model (Jevons-paradox arithmetic) [S25012] [S11525]; chart by repo · As of 2026-11-05

对数坐标折线图：在价格下降 3 倍、10 倍和 30 倍的情况下，支出倍数与需求弹性的关系。三条线均在弹性为 1 处穿过 1.0：低于 1 时，更便宜的 token 会使总支出缩小；高于 1 时，支出增长。价格下降 10 倍时，弹性 0.5 使支出降至原水平的 0.32 倍，弹性 1.5 使其升至 3.2 倍，弹性 2 使其升至 10 倍；弹性约为 1.30 时支出翻倍。价格降幅越大，两种结果都会被放大。

4. 为何奏效（或为何未能奏效）

效率冲击为何反而推高了需求。 杰文斯悖论可追溯至 1865 年：更高效的蒸汽机反而提高了英国的煤炭总消耗量，因为更便宜的动力找到了新的用途 [S25012]。在 AI 领域，有四个机制在起作用：

1. **需求富有弹性。** 更便宜的 token 解锁了此前不经济的用途，例如编程智能体、长文档分析和全天候助手。
2. **需求曲线外移。** 推理模型在回答前会先“思考”。这可能使每个回答生成的 token 增加约 21 倍，而一项智能体任务消耗的 token 可达一次聊天回复的约 1,100 倍（估计）[S32025,S32024]。DeepSeek R1 本身就推广了这一模式，这也是英伟达将其定位为测试时扩展的原因 [S25003]。
3. **供应受限。** 英伟达至今仍称其 FY2028 展望受供应约束 [S90012]。在供不应求的市场中，效率提升释放的产能会被立即吸收，而不是闲置。
4. **英伟达获取了部分效率收益。** 在 MLPerf 上，仅软件优化就使 GB300 NVL72 的 DeepSeek-R1 吞吐量在一年内提升 2.9 倍 [S601,S603]。更便宜的 token 运行在英伟达的机架上。

效率冲击何时会压低需求。 上方流程图展示了失败路径：

- **需求缺乏弹性或已饱和：** 如果企业采用停滞或投资回报令人失望，ε < 1，效率提升将导致支出收缩。
- **工作负载有上限：** 当买家服务的是固定任务（内部企业应用、既定的批处理流水线）时，效率提升只意味着完成同样工作所需的 GPU 更少。
- **供过于求：** 一旦供应追上需求，效率提升就会带来通缩。H100 租赁价格已从 2023 年的每 GPU 小时约 $8 降至新兴云服务商（neocloud）和算力交易市场上的约 $2–3 [S393,S395]。
- **外溢：** 高效模型可能运行在其他平台上。DeepSeek 的 DeepEP 和 DeepGEMM 库现已推出华为昇腾版本 [S9009,S9010]，TileLang 也有官方的昇腾 950 后端 [S9011]。

提示

算例 —— 杰文斯悖论失效时：既定的建设计划。 某云厂商计划采购 $10B 的推理 GPU 以满足其需求预测。一种新的模型架构使每 token 所需的 GPU 小时减少 3 倍。如果 token 需求仅增长 2 倍（相对于便宜 3 倍的 token，$\varepsilon \approx 0.63$），该云厂商只需要计划中三分之二的 GPU：约 $6.7B，采购额下降约 33 %。如果需求增长 3 倍，采购额持平；增长 6 倍，采购额翻倍。效率提升本身并不决定结果，决定结果的是需求增长相对于效率提升的幅度。🔴 本资料库测算。

出口管制的角度。 H800 是英伟达针对中国市场推出的 Hopper 版本，旨在符合 2022 年 10 月的规则；它本身又被 2023 年 10 月的规则所限制 [S25011]。出口管制塑造了 DeepSeek 的工程路线。DeepSeek 测得每张 H800 仅有约 160 GB/s 的 NVLink 带宽和约 50 GB/s 的 InfiniBand 带宽 [S34007,S5005]。因此 V3 避免使用张量并行，并让通信与计算重叠（见下文）。随后推出的 H20 于 2025 年 4 月被纳入许可要求，英伟达为此计提约 $4.5B 费用 [S90081,S90082]。H200 后来获准销售，但需将收入的 25 % 上缴美国政府；然而截至 2026 年年中，尚未确认任何 H200 收入 [S90081,S90032]。管制减缓了 DeepSeek 获取算力的速度，也迫使其更加努力地优化，并在 2026 年前移植到昇腾：这是 CUDA 转换成本上的一处慢性渗漏。参见 CS6。

注意

🐻 **看空观点。** 杰文斯式反弹之所以成立，是因为三个条件同时满足：买家资本充裕、供应紧张、高效模型运行在 CUDA 上。这三者都可能逆转。超大规模云厂商的资本开支如今越来越依赖债务和合作伙伴资本，例如据报道英伟达与私募资本机构合作的规模超过 $500B 的项目 [S90074]。随着 CoWoS 产能扩张，GPU 供应正在快速增加 [S90039]。中国实验室正在构建昇腾工具链 [S9009,S9011]。如果第二次效率冲击在供过于求的环境下到来，对这一论点的考验将远比 2025 年 1 月严峻。

注

🐂 **看多观点。** 2023 年以来的每一次效率提升，都被再投入到更大的模型、更长的推理和更多的用户上。在“DeepSeek 时刻”之后的六个季度里，英伟达数据中心收入增长了 2.5 倍 [S443,S405]。2026 年最便宜的 token 正是在英伟达最新的机架上提供的。

🔧 **技术细节：V3 中的 MoE、MLA、FP8、DualPipe 与 PTX**

- **MoE 路由：** 1 个共享专家 + 256 个路由专家，每个 token 激活 8 个，且每个 token 最多只能路由到分布在 4 个节点上的专家。这限制了慢速 InfiniBand 链路上的跨节点流量 [S34007]。
- **MLA：** 每层每个 token 只存储 576 个值的压缩潜在向量，而非完整的键和值。这缩小了 KV 缓存，使长上下文和大批量推理服务的成本更低 [S32009,S32026]。
- **FP8 训练：** 大多数矩阵乘法以 8 位浮点运行，采用细粒度缩放和更高精度累加。与 BF16 相比，内存流量大约减半 [S34007]。
- **DualPipe 与并行方式：** 16 路流水线并行 × 64 路专家并行 × ZeRO-1 数据并行，不使用张量并行。DualPipe 将一个微批次的计算与另一个微批次的全交换（all-to-all）通信重叠，从而把慢速网络隐藏在计算之后 [S34007]。
- **PTX 级调优：** 自定义 PTX，并为通信分配专用的流式多处理器（SM）。DeepSeek 后来的 DeepEP 库在 H800 上实现了约 153–158 GB/s 的节点内带宽和约 43–58 GB/s 的节点间带宽 [S5005]。DeepGEMM 在 H800 上最高达到 1,550 TFLOPS 的 FP8 算力 [S9010]。
- **推理服务：** 生产环境中的解码（decode）在 18 个节点上以专家并行方式运行（EP144），每个 H800 节点约输出 14.8k tokens/s [S5004]。

这些技术都不需要非英伟达硬件。它们是软件和架构层面的选择，英伟达自己的团队后来也针对 Blackwell 对同样的 DeepSeek 模型进行了调优 [S645,S646]。

5. 对企业发展（corp dev）的启示

如何针对效率冲击对 AI 基础设施投资论点进行压力测试：

步骤	问题	DeepSeek 检验
1. 分解	收入 = token 数 × 每 token 算力 × 单位算力价格。冲击作用于哪一项？	每 token 算力下降；token 数增长更快
2. 弹性	在该细分市场（编程智能体、消费级聊天、批处理）中 ε 是否大于 1？	2025–26 年整体大于 1；分细分市场尚未得到证实
3. 供应状态	受限还是过剩？前者会吸收效率提升，后者会带来通缩	受限 [S90012]
4. 价值获取	谁保留了节省：实验室、云厂商、芯片厂商还是用户？	实验室与用户；英伟达通过软件获取
5. 外溢	高效模型是否仍在你的平台上运行得最好？	V4 首日即可运行；昇腾份额在增长 [S633,S90079]
6. 解读标题数字	最终运行成本 vs 集群资本开支 vs 运营开支	$5.6M vs 约 $1.6B 集群 [S34007,S25006]

1. **区分标题数字与成本基础。** 一个“$6M 的模型”背后是约 $1.6B 的硬件（估计）[S25006]。对任何“便宜 10 倍”的说法进行尽职调查时，都应追问哪些成本被排除在外。
2. **明确为弹性建模。** 假设所有领域 ε > 1 的投资论点是一种押注，而非基准情景。应在成熟细分市场中以 ε < 1 进行下行情景测算。
3. **效率提升会让价值在技术栈中转移。** 模型实验室和应用开发者获得了更高的利润率。英伟达则通过发布软件、让自家机架成为运行高效模型最便宜的平台，守住了自己的利润率。
4. **市场对效率消息的反应可能方向错误，但风险识别正确。** 约 $589B 的市值回撤在数月内即告逆转。但它所提示的外溢风险（模型脱离 CUDA 进行优化）依然真实存在。

🎯 企业发展视角

1. **投资论点的规范性：** 对于任何 AI 硬件投资，按细分市场假设的 token 需求价格弹性是多少？如果 10 倍的效率提升出现在供过于求而非短缺的环境中，计划会怎样？
2. **谁获取效率收益：** 如果算法进步持续降低每 token 算力，价值是否会流向让模型*推理服务*成本最低的一方？这可能是推理专用芯片、大内存设计或软件层。这应如何影响自建/收购/合作的筛选标准？
3. **端侧与蒸馏：** R1 的蒸馏小模型表明推理能力可以被压缩 [S25002]。这是否会将部分推理转移到手机和 PC 上——高通（Qualcomm）在这些设备中出货 NPU？还是测试时计算会让最繁重的工作留在数据中心？应将此视为一个开放问题，而非预测。
4. **软件可移植性作为一种期权：** DeepSeek 的库现已支持昇腾 [S9009,S9010]。哪些可移植的内核与编译器项目（TileLang、Triton、Mojo）是预示高效开源模型能在 CUDA 之外良好运行的领先指标？
5. **信号与噪音：** 在市场裁决尘埃落定之前的最初 48 小时内，企业发展团队应如何区分真正的成本曲线断裂与被误读的标题？

CS6 · 中国出口管制：H20 及之后

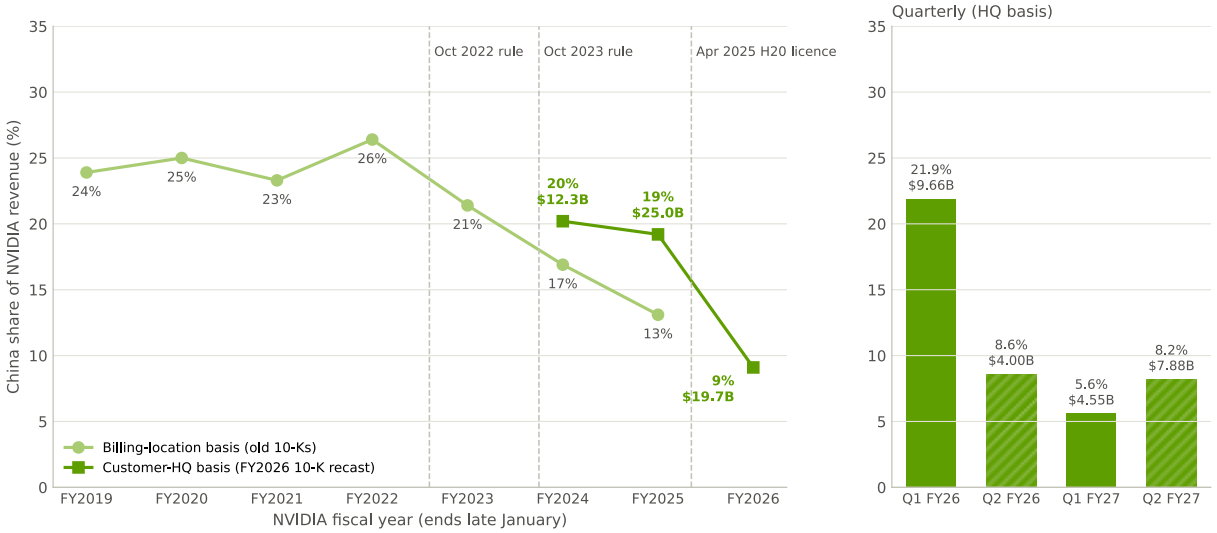
案例研究 · 阅读约 14 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **中国曾占英伟达的四分之一。** 按旧的账单地口径，中国（含香港）在 FY2022 占收入的 26.4 % [S2]；管理层也曾表示，在管制实施前，中国占数据中心收入的 20–25 % [S26008]。
- **英伟达一次次按规则重新设计产品。** 2022 年 10 月的规则要求，TPP 超过 4,800 且芯片间带宽超过 600 GB/s 的芯片须获得许可；英伟达以 A800/H800 应对（NVLink 降至 400 GB/s）。2023 年 10 月的规则堵上了这一缺口，英伟达随即推出 TPP 约 2,400 的 H20，约为 H200 的 1/7 [S26002,S26001,S26003]。
- **合规芯片曾在一段时间内守住了收入金额。** 按客户总部口径，中国收入在 FY2025 达到 $25.0B 的峰值，尽管其占比已在下降 [S401]。
- **2025 年 4 月的许可要求造成 $4.5B 损失。** 该要求“在可预见的未来”适用于 H20，迫使英伟达在 Q1 FY2026 计提 $4.5B 的存货及采购义务费用。GAAP 毛利率降至 60.5 % [S90081,S90082,S444]。
- **许可附带分成恢复，北京却说不。** H20 许可于 2025 年 8 月恢复，条件是将收入的 15 % 上缴美国政府；H200 于 2025 年 12 月获准销售，分成比例为 25 % [S26004,S90032]。北京随后要求买家避免采购英伟达产品，并引导国家资助的数据中心转用国产芯片 [S26006,S26007]。英伟达的文件显示尚未确认任何 H200 收入；媒体报道称 Q2 FY2027 对华 H200 销售额不到数据中心收入的 1 %（🟡）。业绩指引仍将中国数据中心计算业务排除在外 [S90081,S26009,S405]。
- **份额崩塌，但英伟达仍在增长。** 中国在 FY2026 收入中的占比降至 9.1 %，在 FY2027 各季度为 5.6–8.2 %，而总收入增长了 65 % [S401,S90070,S90069,S1]。长期代价在于，一个本土竞争对手如今拥有了受保护的市场。华为昇腾路线图以及 DeepSeek V4 对昇腾的支持就是证据 [S90042,S90079]。

China fell from ~26% of NVIDIA revenue (FY2022) to ~9% (FY2026) and 6–8% in FY2027

China incl. Hong Kong as % of total revenue; left: fiscal years (two reporting bases); right: quarters, customer-HQ basis (hatched = secondary reading of the 10-Q)



Source: data from NVIDIA 10-K and 10-Q geographic revenue notes [S400] [S2] [S418] [S417] [S416] [S26013] …; chart by repo · As of 2026-11-05

中国占英伟达收入比重的双面板图。左，按财年、旧账单地口径：FY2019 23.9%，FY2020 25.0%，FY2021 23.3%，FY2022 26.4%，FY2023 21.4%，FY2024 16.9%，FY2025 13.1%；按新的客户总部口径：FY2024 20.2%，FY2025 19.2%（$25.0B，金额峰值），FY2026 9.1%（$19.7B）。右，按季度、总部口径：Q1 FY2026 为 21.9%，H20 许可要求出台后的 Q2 FY2026 为 8.6%，Q1 FY2027 为 5.6%，Q2 FY2027 为 8.2%（全平台，含游戏）。

1. 背景

利害有多大。 英伟达按地区披露收入。在 Q3 FY2026 之前，它按客户账单地址分配收入；此后改用客户总部所在地，并对 FY2024–FY2025 进行了重述 [S26013]。无论采用哪种口径，中国都是英伟达最大的市场之一：FY2022 为 $7.1B、占 26.4 % [S2]，按总部口径 FY2025 为 $25.0B [S401]。这一市场包括正在构建与美国同行相同的大语言模型集群的超大规模云厂商（阿里巴巴、腾讯、字节跳动、百度）。

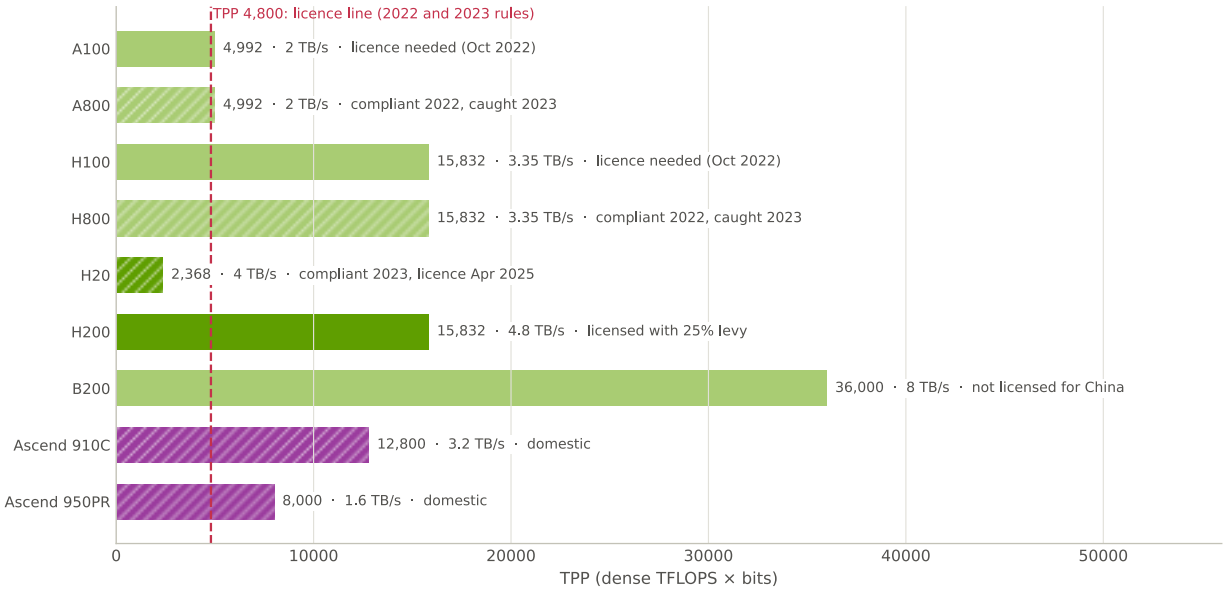
规则如何运作。 美国对 AI 芯片的出口管制由商务部下属的工业与安全局（BIS）制定。规则并不点名具体产品，而是设定性能阈值，任何超过阈值的芯片出口到中国都需要许可：

规则	触发许可要求的条件	英伟达的应对	来源
2022 年 10 月 7 日	TPP ⩾ 4,800 **且**芯片间聚合带宽 > 600 GB/s	A800 / H800：算力不变，NVLink 降至 400 GB/s	S26002,S26001
2023 年 10 月 17 日	取消带宽测试；TPP ⩾ 4,800，或 TPP ⩾ 1,600 且性能密度 ⩾ 5.92	H20：算力削减约 85 %，保留内存和 NVLink	S26000,S26003
2025 年 4 月	H20 及内存或互连带宽相当的产品：“在可预见的未来”需要许可	计提 $4.5B 费用；已无合规的数据中心产品	S90081
2025 年 12 月 – 2026 年 1 月	H200 可向获批买家发放许可，收入的 25 % 上缴美国政府	H200 恢复生产（2026 年 3 月）	S90032,S90033

机制至关重要。每条规则都针对一项物理属性，而每款合规型号（compliant SKU）恰好削减这一项属性，其余全部保留。2022 年的规则衡量互连，所以 A800 和 H800 保留了完整算力。2023 年的规则衡量算力，所以 H20 保留了 96 GB、约 4.0 TB/s 的高带宽内存（HBM）以及 900 GB/s 的 NVLink。其内存带宽甚至高于 H100 [S26003]。对于以解码（decode）为主、受内存带宽而非算力限制的推理工作负载，H20 是一款比其 TPP 所显示的更好的产品。这正是中国云厂商大量采购它的原因。

H20 was cut to ~2,400 TPP, half the 4,800 licence line and 1/7 of H200, but kept 4 TB/s HBM

TPP (dense TFLOPS × bit width) per package; label = TPP · HBM bandwidth · China status; hatched = reported/leaked



Source: data from NVIDIA datasheets, SemiAnalysis (H20 leak), Huawei, BIS [S33009] [S26002] [S26001] [S33002] [S34007] [S26003] ...; chart by repo · As of 2026-11-05

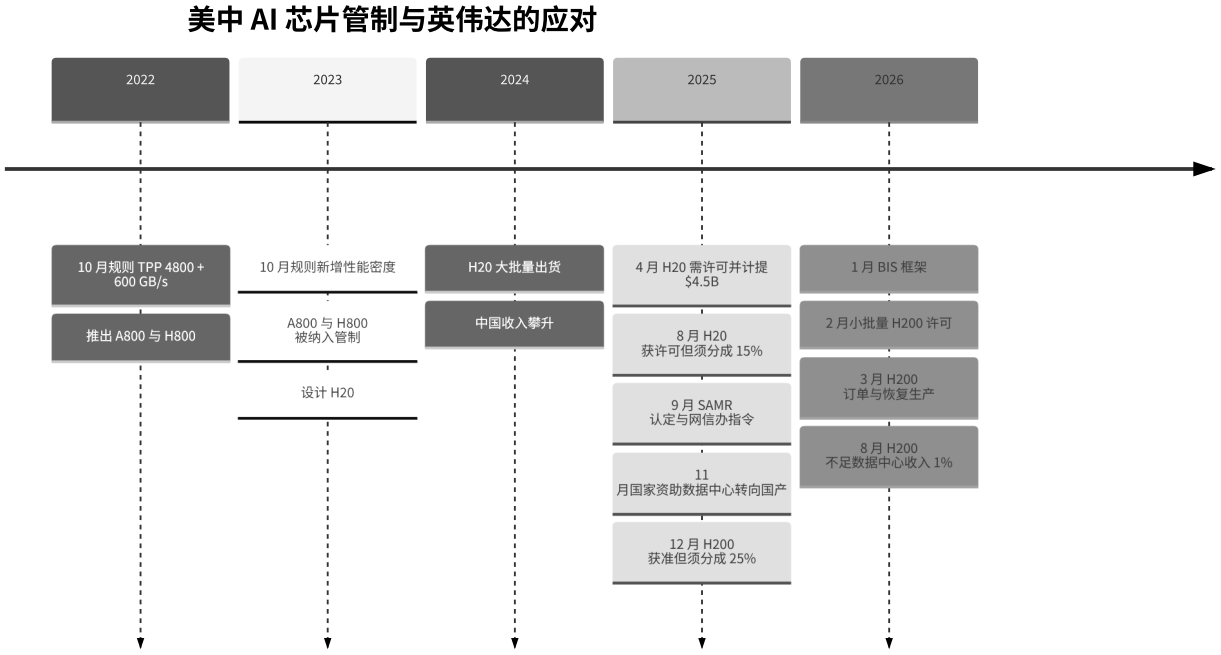
> 各加速器 TPP（美国出口管制指标）水平条形图，虚线表示 4,800 的许可阈值。英伟达 B200 36,000；H200 15,832；H800 15,832（NVLink 降至 400 GB/s）；H100 15,832；A800 4,992（NVLink 400 GB/s）；A100 4,992；H20 2,368，配 96 GB、4.0 TB/s 的 HBM；华为昇腾 910C 纸面上约 12,800（FP16），昇腾 950PR 约 8,000（FP8）。H20 的算力远低于阈值线，但内存带宽高于 H100。

🔧 技术细节：TPP 与性能密度如何计算

TPP = 2 ×（每秒乘加运算次数，以 tera 计）× 运算位宽，取得分最高的精度。一次乘加（MAC）等于两次运算，因此在实践中 TPP ≈ 稠密 TFLOPS（或 TOPS）× 位数。

- H100 / H200：1,979 稠密 FP8 TFLOPS × 8 = **15,832**（BF16 结果相同：989 × 16）[S33002]。
- A100：312 BF16 TFLOPS × 16 = **4,992**，略高于 4,800 的阈值线 [S33009]。
- H20：约 296 FP8 TFLOPS × 8 = **约 2,368**（报道中取整为约 2,400–2,500）[S26003]。
- 华为昇腾 910C：800 FP16 TFLOPS × 16 = 纸面上**约 12,800**。昇腾 950PR：1 PFLOPS FP8 × 8 = **约 8,000** [S163]。

性能密度 = TPP ÷ 裸片面积（mm^2）。2023 年的规则加入这一指标，是为了防止厂商把同样的算力分散到更多硅片上来规避 TPP 阈值。H20 恰好低于 2,400-TPP 档位，在约 814 mm^2 的 Hopper 级裸片上，其密度约为 2,368 ÷ 814 ≈ 2.9。这低于 3.2 和 5.92 两个密度触发值，因此按泄露的规格，它通过了 2023 年规则的所有档位（本资料库计算）[S26000,S26002,S33002]。在 2025 年 4 月的行动之前，内存带宽**并不是**管制参数，而这正是 H20 所利用的缺口。



2. 决策

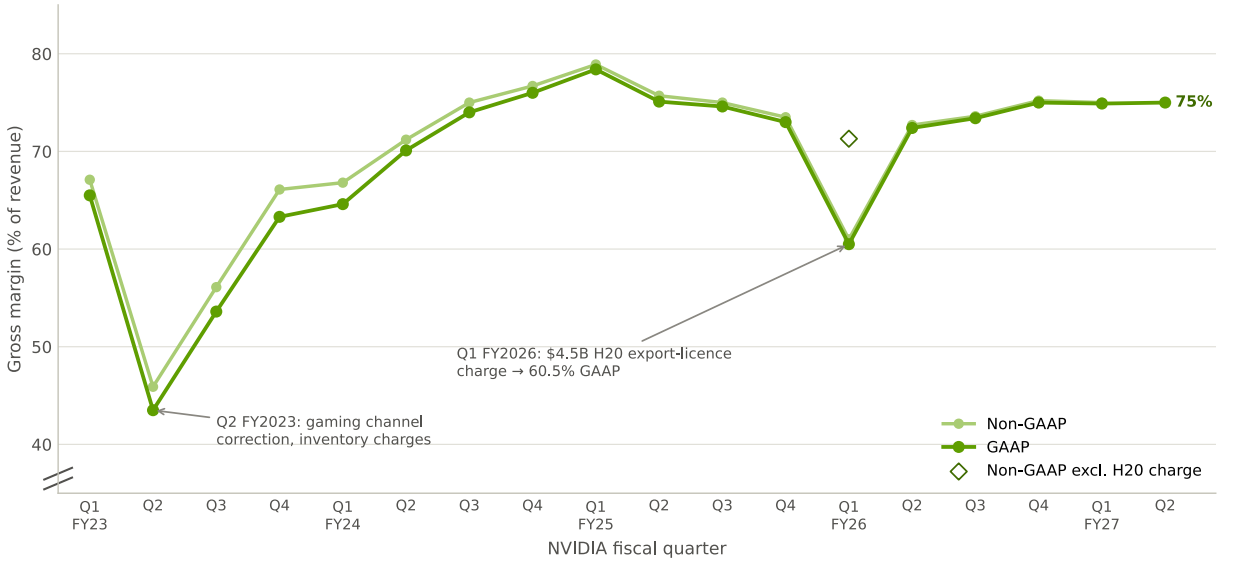
两组决策塑造了最终结果：英伟达的产品选择，以及两国政府的政策选择。

英伟达的决策：每次都按阈值线设计。 另一种选择是放弃四分之一的收入，把中国开发者拱手让给华为的软件。英伟达选择用阉割版硬件把 CUDA 开发者留在中国。每款合规产品都使用相同的裸片和软件栈，因此工程成本不高。风险在于存货和采购承诺，而英伟达需要在销售前数月作出这些承诺 [S414]。

华盛顿的决策（2025 年 4 月）：堵上带宽漏洞。 H20 许可要求在季度中途出台。英伟达为 H20 存货和采购义务计提了 $4.5B 费用。Q1 FY2026 有 $2.5B 的订单无法发货，Q2 展望中约有 $8.0B 的 H20 收入被剔除 [S444,S90082]。GAAP 毛利率降至 60.5 %，剔除该费用后为 71.3 % [S444]。

Gross margin climbed from 43.5% to ~75%, broken only by the H20 write-down

GAAP and non-GAAP gross margin, % of revenue, Q1 FY23–Q2 FY27; from Q1 FY2027 non-GAAP includes stock-based comp



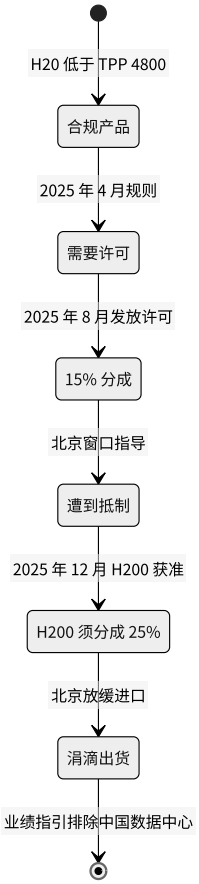
Axis starts at 35% (break marked)

Source: data from NVIDIA 8-K releases [S432] [S433] [S434] [S435] [S418] [S436] …; chart by repo · As of 2026-11-05

> 英伟达季度毛利率折线图：GAAP 毛利率在 Q2FY23 触底至 43.5%（游戏业务存货费用），在 Hopper 放量期间升至 75% 以上，Q1 FY2026 因 $4.5B 的 H20 出口管制费用降至 60.5%（剔除该费用的非 GAAP 毛利率为 71.3%），Q2FY27 约为 75%。

华盛顿的第二项决策（2025 年 8–12 月）：可以卖，但要分成。 部分 H20 出货的许可附带了一项不同寻常的出口收入分成。美国总统表示，英伟达将把 H20 对华收入的 15 % 支付给美国政府（AMD 的 MI308 适用相同条款）[S26004]。2025 年 12 月，H200 获准向获批买家销售，收入的 25 % 上缴政府。BIS 于 2026 年 1 月发布许可框架，英伟达于 2 月获得一份小批量许可 [S90032,S90083]。

北京的决策：不买。 2025 年 8 月，中国当局劝阻采购 H20，尤其是用于政府相关工作 [S26005]。2025-09-15，反垄断监管机构国家市场监督管理总局（SAMR）发布初步认定，称英伟达在其 Mellanox 承诺方面违反了反垄断法 [S9505,S90081]。两天后，国家互联网信息办公室（CAC）要求字节跳动和阿里巴巴取消 RTX Pro 6000D 订单 [S26006]。11 月，新的国家资助数据中心被要求只使用国产芯片，完工不足 30 % 的项目被要求拆除外国芯片 [S26007]。



产品	面向中国推出	相对旗舰的削减	截至 2026 年底的状态
A800	2022	NVLink 600 → 400 GB/s	被 2023 年 10 月规则纳入管制 S26001
H800	2023	NVLink 900 → 400 GB/s；DeepSeek-V3 在 2,048 张该卡上训练	被 2023 年 10 月规则纳入管制 S26001,S34007
H20	2024	算力约为 H100 的 15 %；保留 96 GB HBM3	需许可（2025 年 4 月）、15 % 分成（2025 年 8 月）、遭北京抵制 S90081,S26004,S26005
RTX Pro 6000D	2025	工作站级产品	网信办要求买家取消订单（2025 年 9 月） S26006
H200	2025–26	完整 Hopper；141 GB HBM3E	25 % 分成；据报道不到 Q2 FY2027 数据中心收入的 1 % S90032,S26009

3. 结果（用数据说话）

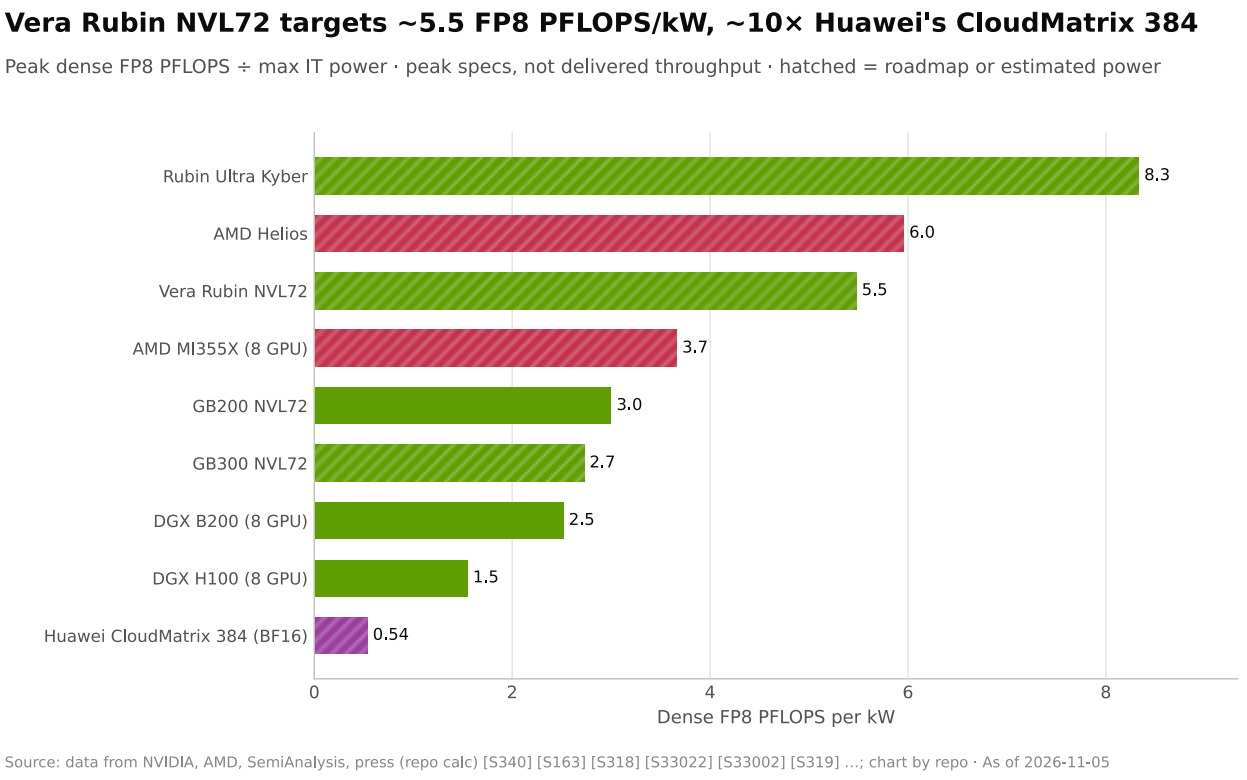
收入。 按总部口径，中国收入从 FY2025 的 $25.0B（19.2 %）降至 FY2026 的 $19.7B（9.1 %）S401。Q1 FY2027 为 $4.55B（5.6 %）S90070，Q2 FY2027 约为 $7.9B（8.2 %）S90069,S26014。该数据涵盖所有平台，包括游戏和汽车。数据中心部分接近于零：自 FY2026 起，英伟达的业绩指引已将中国数据中心计算业务排除在外 S405。

H200 迄今的情况。 据报道，北京在黄仁勋 2026 年 1 月访华期间批准了第一批 H200 进口，但同时据报道海关人员被告知这些芯片不予放行（🟡）S26011。英伟达的文件称迄今尚未确认任何 H200 收入 S90081。而媒体对 Q2 FY2027 业绩的报道则称，对中国买家的 H200（Hopper）销售额不到数据中心收入的 1 %，并因中方反对而受阻（🟡）S90011,S26009。另有报道称计提了约 $400M 的 H200 过剩存货准备（🟡）S26010，且英伟达据报道已将原本面向中国的 H200 产能转给 Vera Rubin（🟡）S26012。关于是否确认了任何 H200 收入，公司文件与媒体报道存在矛盾。无论如何，Q2 FY2027 只是涓滴出货，而非市场重新开放。

英伟达整体。这一损失在总数中几乎看不出来。FY2026 收入为 $215.9B（+65 %），Q2 FY2027 为 $96.2B（同比 +106 %）[S1,S405]。总部不在美国的客户在 Q1 FY2027 收入中的占比降至 22 %，一年前为 42 % [S90070]。毛利率恢复至约 75 % [S90011]。

中国的 AI 技术栈。黄仁勋表示，英伟达在中国的市场份额“从 95 % 降到了 0 %”。同时引用的伯恩斯坦（Bernstein）估计显示，英伟达在中国 AI 芯片市场的份额从 2024 年的 66 % 降至约 8 % [S26008]。华为发布了华为昇腾（Ascend） 950PR（2026 年第一季度）和 950DT（2026 年第四季度），以及 Atlas 950 SuperPoD：8,192 颗芯片，8 EF FP8 [S90042,S341]。在华为全联接大会 2026 上，华为将昇腾 960DT 提前至 2027 年第一季度，并称 Atlas 950 SuperPoD 已大规模商用（公司宣称）[S567]。DeepSeek 2026 年 4 月发布的 V4 预览版在 V4-Flash 的部分训练中使用了昇腾，并为推理适配了昇腾超节点，同时提及高端算力受限 [S90079,S90080]。华为还开源了其 CANN 软件栈 [S13521]。

完成同样的工作，国产技术栈仍需消耗更多电力。华为通过使用更多芯片和更多瓦数来追平英伟达的机架吞吐量：



每 kW 稠密 FP8 PFLOPS 水平条形图：华为 CloudMatrix 384 约 0.54（BF16），DGX H100 约 1.5，DGX B200 约 2.5，GB300 NVL72 约 2.7，GB200 NVL72 约 3.0，AMD MI355X 平台约 3.7，Vera Rubin NVL72 约 5.5，AMD Helios 按估计功耗约 6.0，Rubin Ultra Kyber 约 8.3。

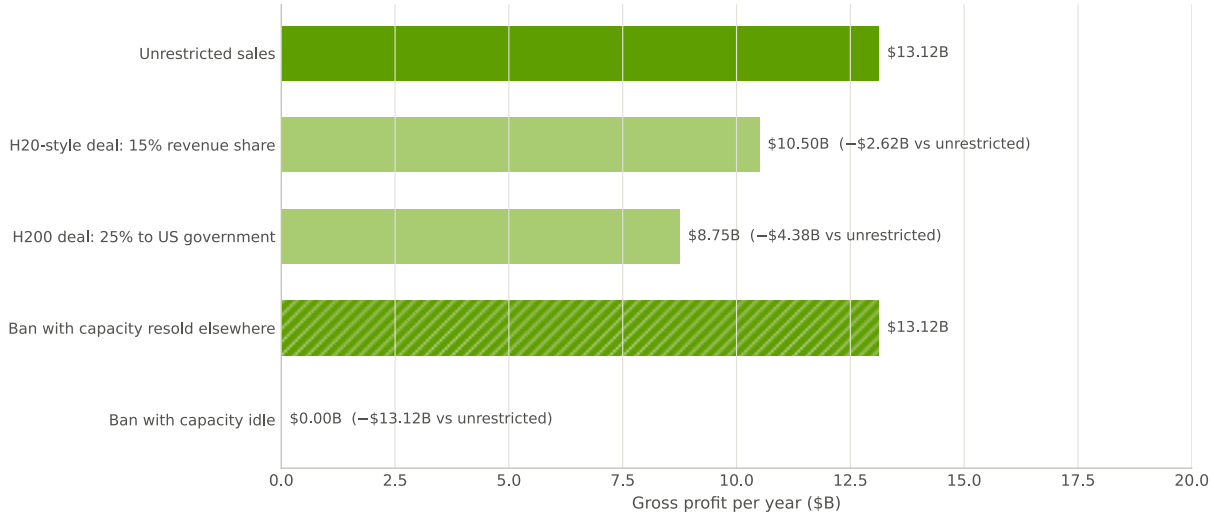
提示

算例 —— 不同管制机制下中国对英伟达的价值。 假设中国数据中心市场规模为**每年 $17.5B**，即 $15–20B 的中点。按账单地口径，FY2025 中国收入为 $17.1B [S416]，而 2025 年 4 月的行动从单季展望中抹去了约 $8.0B [S444]。毛利率为 **75 %** [S90011]。 1. **不受限制：** $17.5B × 75 % = 每年 **$13.1B** 毛利。 2. **H200 协议：** 25 % 的分成针对的是*收入*，因此直接从毛利中扣除：$17.5B × (75 % − 25 %) = **$8.75B**。即减少 $4.4B，实际毛利率为 50 %。15 % 的 H20 安排则对应 $10.5B。 3. **禁售，产能闲置：** **$0**，损失 $13.1B。这大致就是 2025 年 4 月的情形：需求存在，但产品无法发货。 4. **禁售，产能转售：** 在供应受限的年份，同样的晶圆、HBM 和 CoWoS 会以相同的毛利率转售给美国或主权 AI 买家。短期损失**约为 $0**。英伟达 CFO 称 FY2028 展望受供应约束 [S90012]。

结论： 分成会让英伟达损失三分之一的中国毛利。禁售是否会造成损失，取决于英伟达能否把其他所有产出都卖出去。而长期代价并未体现在这一计算中：华为获得了一个可以走向成熟的受保护本土市场。

Est.: the 25% levy costs ~$4.4B/yr of gross profit on $17.5B of sales; a ban up to ~$13B

Gross profit per year from a ~$17.5B China data-center market at 75% gross margin, by regime ($B; hatched = depends on resale)



Source: data from repo scenarios on NVIDIA filings and policy terms [S416] [S401] [S90011] [S26004] [S90032] [S90083] ...; chart by repo · As of 2026-11-05

本资料库对英伟达从 $17.5B 中国数据中心市场（毛利率 75%）获得的年度毛利的估计水平条形图：不受限制销售 $13.1B；H20 式 15% 收入分成 $10.5B；收入的 25% 上缴美国政府的 H200 协议 $8.75B；禁售但产能转售给其他买家约 $13.1B（供应受限时短期无损失）；禁售且产能闲置 $0。分成会一对一地减少毛利。

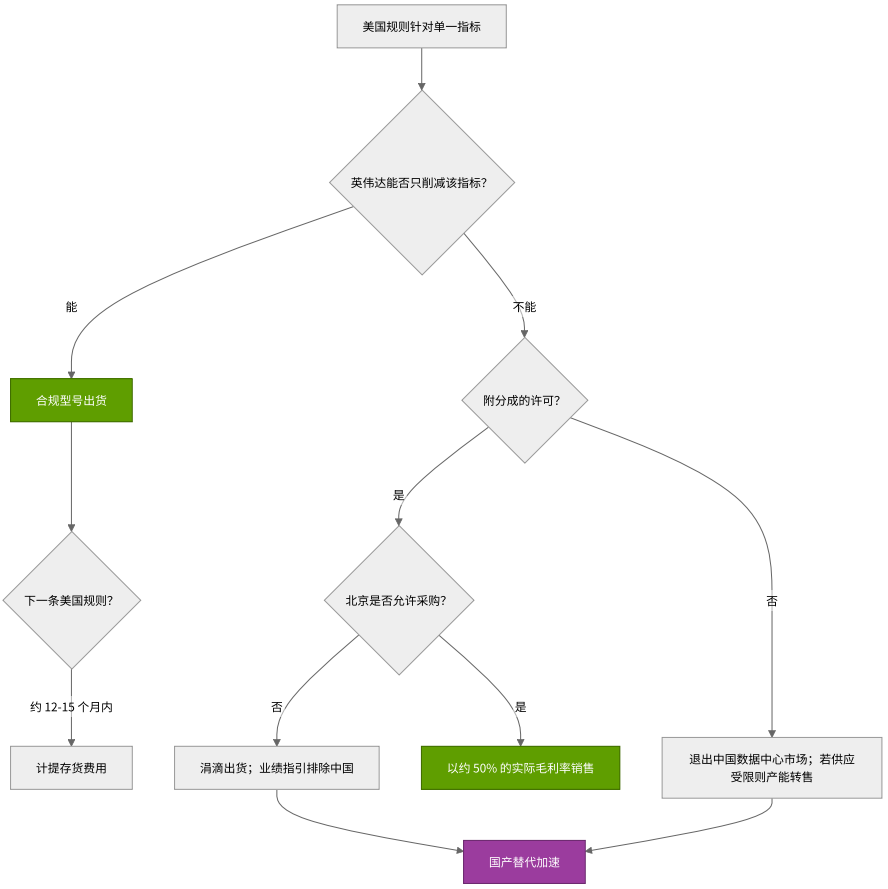
4. 为何奏效（或为何未能奏效）

奏效之处。 - **合规型号赢得了时间。** 在约 2.5 年里（FY2023–FY2025），重新设计让中国收入金额持续增长，尽管其占比在下降。由于每款产品都复用现有裸片，工程成本很低。 - **多元化吸收了冲击。** 来自美国超大规模云厂商、主权 AI 买家和新兴云服务商（neocloud）的需求增长超过了失去的市场。在中国市场关闭的那一年，收入仍增长了 65 % [S1]。

未奏效之处。 - **每款合规型号只能撑约一年。** A800/H800 撑了约 12 个月，H20 约 15 个月，随后便被新规则纳入管制。每一次重新设计都重新积累了存货风险敞口。结果就是 $4.5B 的 H20 费用，以及据报道约 $400M 的 H200 准备 [S90082,S26010]。 - **分成让中国成为英伟达毛利率最低的市场。** 按 25 % 计算，中国每美元收入的价值比任何其他买家低三分之一（见算例）。 - **北京决定了结果。** 美国一旦允许销售，中国自己的监管机构（SAMR、网信办、国家资金规则）就加以阻止 [S9505,S26006,S26007]。政策风险如今来自双方。 - **生态锁定被侵蚀。** DeepSeek 的内核和框架现已有昇腾路径，CANN 也已开源 [S90079,S13521]。在英伟达缺席的这些年里，中国市场脱离 CUDA 的转换成本下降了。

注意

误区与事实：“管制让中国落后约 2 年。” 规则限制的是*芯片*性能，而非*系统*性能。华为的 CloudMatrix 384 将 384 颗昇腾 910C 芯片连接成一个纵向扩展（scale-up）域。其稠密 BF16 吞吐量超过 GB200 NVL72（约 300 对约 180 PFLOPS），但功耗约为后者的 3.9 倍 [S340]。在增加电力比获得先进光刻更容易的地方，买瓦数可以替代买更好的芯片。管制提高了中国 AI 算力的成本，但并未给中国能够建设的规模设定硬上限。DeepSeek-V3 就是在 2,048 张符合出口管制的 H800 上训练的 [S34007]。如今的硬约束是产量（中芯国际（SMIC）产能、国产 HBM）和软件成熟度，而非单芯片峰值 FLOPS [S164,S3516]。



注

🐂 **看多观点。** 中国是一份看涨期权，而非基准情景中的窟窿。业绩指引已假设中国数据中心计算业务为零 [S405]。任何 H200 出货量，即使实际毛利率只有 50 %，也是上行空间，而且其所占用的产能本来也可以卖给别人。华为芯片的每瓦性能落后，且受供应限制（中芯国际 7 nm 级工艺、自研 HBM） [S164,S163,S340]。

注意

🐻 **看空观点。** 管制催生了英伟达资金最雄厚的竞争对手，并把全球第二大 AI 市场拱手相让。即使华盛顿松口，国产采购规则也会让这一损失难以逆转 [S26007]。华为每年迭代的昇腾节奏以及 DeepSeek 的支持表明，替代技术栈正在走向成熟 [S567,S90079]。一项能对一个市场征收 25 % 分成的政策，也可以推广到其他市场。投资者应将这一风险永久性地计入定价。

5. 对企业发展（corp dev）的启示

1. **把地缘政治敞口视为投资组合因子，而非脚注。** 相关的敞口衡量标准是按客户总部而非账单地址划分的收入。英伟达自身的口径重述使 FY2025 中国占比从 13 % 变为 19 % [S26013]。任何尽职调查都应同时索取两种口径的数据。
2. **规则针对指标，因此产品设计应预留管制余量。** 恰好低于 TPP 或带宽阈值的产品，会被下一条规则纳入管制。关键在于，当新增下一个指标时，还能保留多少性能。
3. **将政策风险作为永久性折价来定价。** H200 协议表明，政府可以把收入的 25 % 作为许可条件拿走 [S90032]。对中国收入进行概率加权估值（见算例），比使用标题上的可服务市场总额（TAM）更站得住脚。
4. **预期另一方会报复。** SAMR 利用的正是英伟达自己的 Mellanox 并购附加条件 [S9505]。过去在中国获得的并购批准，日后会成为北京手中的筹码。
5. **与高通相关的背景（仅限公开信息）。** 高通（Qualcomm）FY2026 10-K 显示，按客户总部口径，中国（含香港）占收入的 42 %（$18.1B），FY2025 为 46 % [S13503]。其数据中心业务的推进依赖主权 AI 买家，而这些买家的订单取决于美国的出口审批，HUMAIN 采购英伟达产品的情况就是如此 [S13515,S90030]。这些事实用于界定问题，而非得出结论（参见下文的企业发展视角及第 19 章）。

> 🔧 **技术细节：在估值中对中国收入进行折价**
>
> 为政策风险定价的一个简单方法，是对不同的政策机制进行概率加权，而非使用单一折现率。以下概率**仅为示意（🔴 本资料库分析）**。沿用算例中 $17.5B 的市场：20 % 的概率不受限制销售（毛利 $13.1B），30 % 的概率适用 25 % 分成（$8.75B），50 % 的概率无法进入且产能闲置（$0）。期望毛利为 $0.2 \times 13.1 + 0.3 \times 8.75 + 0.5 \times 0 \approx$ **$5.3B**，比不受限制情形**低约 60 %**。有两项修正很重要：
>
> - **与其他业务的相关性。** 如果产能可以转售（供应受限情形），“无法进入”分支在短期内的价值接近基准情景。此时折价只适用于供应追上需求之后的年份。
> - **终值。** 每缺席一年，国产供应商就更成熟一分。即使政策放松，重新夺回份额的概率也会随时间下降，北京的国产采购规则就说明了这一点 [S26007]。对中国采用逐年递减的终值权重，比使用固定权重更符合现实。
>
> 同样的框架适用于任何在单一政治敏感市场中收入占比较大的资产：列出各种机制，赋予毛利率和概率，然后对期望毛利进行估值。

相关内容：CS5 · DeepSeek · 第 18 章 · 看空情景 · 第 13 层 · 资本与生态 · 竞争格局。

🎯 企业发展视角

1. **标的公司的哪些产品接近某项管制指标（TPP、性能密度、内存或互连带宽）？** 如果再增加一项指标，能保留多少性能？这是针对任何 AI 芯片或互连资产的尽职调查问题。
2. **征收分成后，中国收入价值几何？** 按算例中的各种机制（不受限制、15 %、25 %、禁售）结合概率进行测算。应基于期望毛利而非收入倍数来为中国收入估值。
3. **就高通自身的敞口而言（公开数据）：** FY2026 约 42 % 的收入来自总部位于中国的客户 [S13503]，如果“许可加分成”机制被扩展到具备 AI 能力的 SoC 或推理加速器，将意味着什么？哪些产品线的管制余量最大？
4. **对挑战者而言，供应受限这一对冲是否真实存在？** 英伟达的中国损失之所以有缓冲，是因为它可以把每一片晶圆卖到别处。没有这种积压订单的小厂商无法转售产能。一家对中国有敞口的 AI 芯片标的，在中国以外是否有足够需求来吸收其供应？

5. **谁将从国产替代中受益？** 华为、寒武纪以及中国的 HBM 与封装力量（长鑫存储（CXMT）HBM3E）[S26007,S3516] 处于一个受保护的市场中。与它们开展合作或授权的空间同样受到这些管制的限制。现实的问题是，这些厂商日后可能向哪些中国以外的市场出口。

CS7 · 吉瓦级 AI 工厂：xAI、Stargate 等

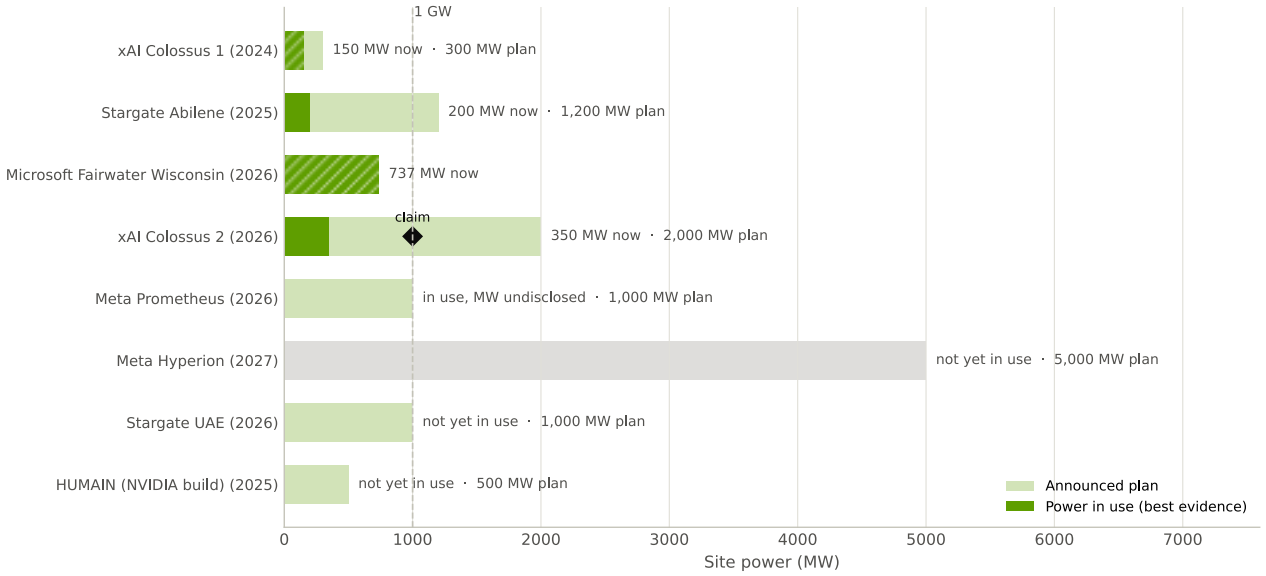
案例研究 · 阅读约 15 分钟 · 最后核实：2026-11-05

⚡ 要点速览

- **AI 基础设施的计量单位从集群变成了发电厂。** 2024 年，xAI 的 Colossus 1 在 122 天内让 100,000 张 H100 投入使用，功耗约 150 MW（根据 GPU 数量估计）[S6000,S318]。到 2026 年，单个站点的用电量达 0.35–0.74 GW，已宣布的园区规模达 1–5 GW [S90077,S27004,S27007]。
- **吉瓦级说法需要核实。** 马斯克在 2026 年 1 月称 Colossus 2 是首个吉瓦级训练集群。而当时的卫星分析只发现约 350 MW 的冷却能力（🔴 存在争议）[S90076,S90077]。Stargate Abilene 在 2025 年 9 月已有 200+ MW 投入运行，规划为 1.2 GW；2026 年 3 月，超出这一规模的扩建计划被放弃，但甲骨文（Oracle）对此有异议 [S8013,S27001,S27002]。
- **一个吉瓦的成本约为 $30–60B。** 英伟达（NVIDIA）CEO 估计为 $50–60B，其中英伟达价值量约 $35B [S398]。伯恩斯坦（Bernstein）估计约 $35B，巴克莱（Barclays）估计为 $32.5–42B [S6025,S27012]。本资料库自下而上测算的 Vera Rubin 站点约为 **$46B（估计）**，其中英伟达价值量约 $22B。
- **决定时间表的是电力，而非 GPU。** 一个站点可以在 4–24 个月内建成，但新的电网供电需要 4–7 年 [S8009,S8010]。仅 ERCOT 就追踪着约 410 GW 寻求并网的大型负荷 [S8011]。建设方的应对措施包括现场燃气发电、800 VDC 供电和液冷 [S8015,S90061]。
- **利用率决定经济性。** 在 89 % 的利用率下（Meta 将 Prometheus 超过 11 % 的 GPU 作为备件），一个 Vera Rubin 吉瓦的盈亏平衡价格约为每 GPU 小时 $4.8–5.4。在 60 % 的利用率下则需要约 $7–8（估计）[S27010]。
- **风险集中在融资环节。** Meta 将 Hyperion 移入与 Blue Owl 组建的约 $27–30B 合资企业 [S27008]；据报道，Abilene 的扩建因融资失败而告吹 [S27001]；而英伟达对自身客户的投资则加剧了关于循环融资的争论 [S90015,S12528]。

AI sites grew from ~150 MW (2024) to 0.35–0.74 GW in use in 2026; plans reach 1–5 GW

Site power (MW): solid = best public evidence of power in use (hatched = repo Est.); light = announced plan; ◆ = claim; gray = silicon undisclosed



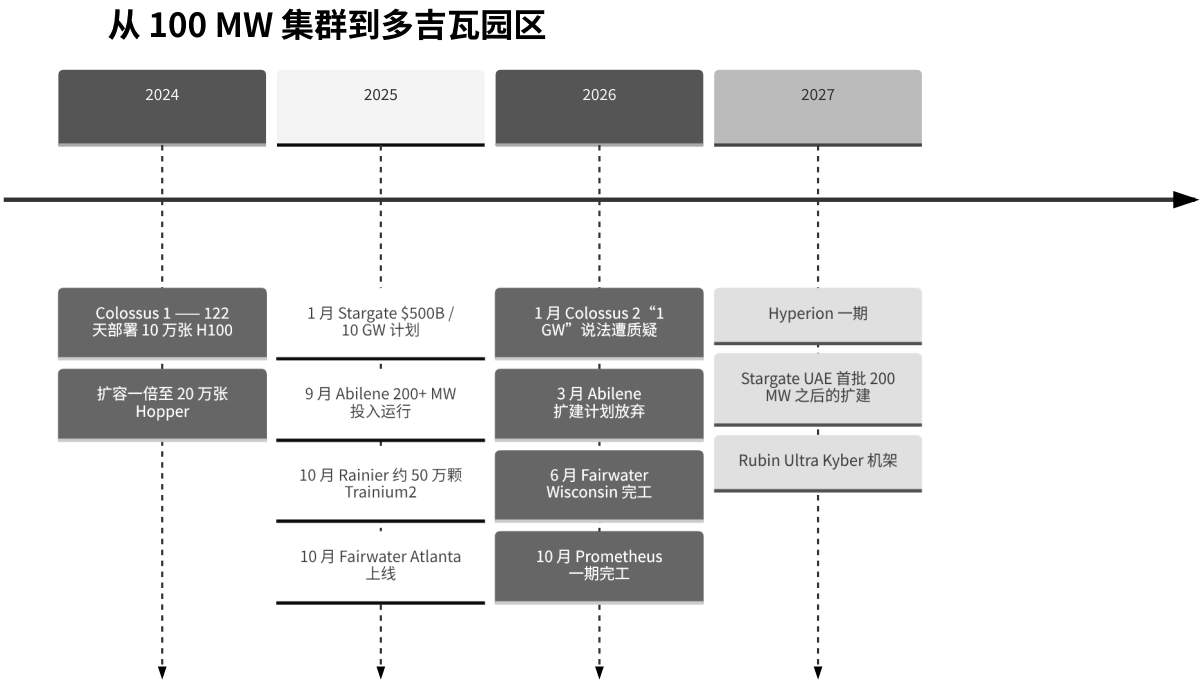
Source: data from company releases, Epoch AI, satellite analysis, repo estimates [S6000] [S6001] [S318] [S8013] [S27001] [S27003] ...; chart by repo · As of 2026-11-05

AI 站点电力规模水平条形图。xAI Colossus 1 约 150 MW（本资料库对 2024 年 100,000 张 H100 的估计，规划 200,000 个 GPU 时约 300 MW）；Stargate Abilene 2025 年 9 月 200+ MW 投入运行，园区规划 1.2 GW；微软 Fairwater Wisconsin 约 737 MW IT 功率（Epoch 估计，2026）；xAI Colossus 2 在 2026 年 1 月的卫星图像中显示约 350 MW 冷却能力，而其宣称 1 GW、规划约 2 GW；Meta Prometheus 规划 1 GW，第一期于 2026 年 10 月完工；Meta Hyperion 最高 5 GW；Stargate UAE 1 GW（首批 200 MW 于 2026 年）；HUMAIN 的英伟达项目最高 500 MW。

1. 背景

站点为何变得如此庞大。 前沿训练是一项同步作业。数千个 GPU 在每一步都要交换梯度，因此必须位于同一个低延迟网络上。训练更大模型最快的方式，就是建设更大的单一站点。物理条件随之而变。一个 NVL72 机架的功耗从约 120 kW（GB200）增至 190–230 kW（Vera Rubin），据报道 Kyber 机架约为 600 kW [S336,S302,S90061]。机架数量、冷却和变电站同步扩张。

“一个吉瓦”意味着什么。 各类公告混用三种数字：电网或合同电力、计量表处的电力，以及 IT 负载（服务器的实际用电）。三者之间的差距就是 PUE。在 PUE 为 1.15 时，1 GW 的计量电力可供应约 870 MW 的 IT 负载。因此，一个“1 GW 集群”能容纳的 GPU 可能比标题暗示的少 10–20 %。卫星统计冷水机组所衡量的又是另一回事：冷却能力 [S90077]。



2. 决策

每个建设方都下了同样的赌注：提前数年锁定电力和芯片，以应对未来需求。但各自的结构各不相同。

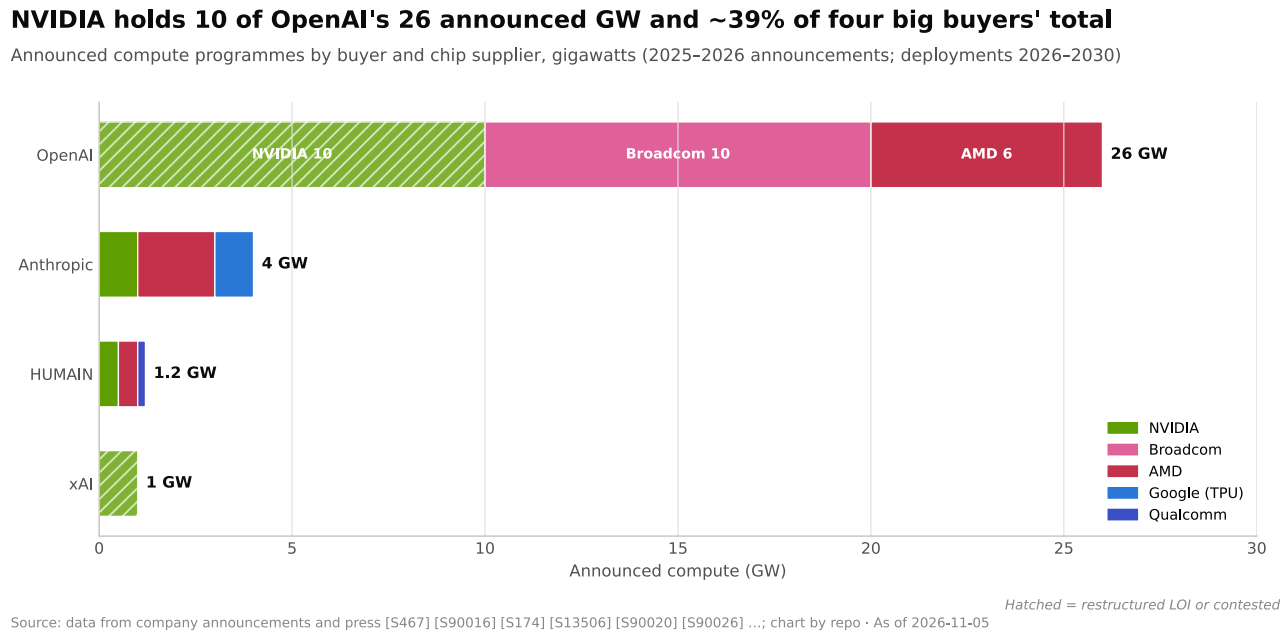
建设方 · 站点	芯片	规模（最佳证据 → 规划）	独特选择	来源
xAI · Colossus 1–2（孟菲斯）	英伟达 H100 → GB200/GB300	约 150 MW（估计）→ 观测到 350 MW，宣称 1 GW，规划约 2 GW	速度：改造既有建筑，现场燃气轮机发电	S6000,S90076,S90077,S8015
OpenAI / 甲骨文 / Crusoe · Stargate Abilene	英伟达 GB200/GB300	200+ MW（2025 年 9 月）→ 1.2 GW	开发商建设、甲骨文租赁；约 7 GW、超过 $400B 计划的一部分	S8013,S27000,S27003
Meta · Prometheus（俄亥俄州）、Hyperion（路易斯安那州）	英伟达 GB200/GB300（Prometheus）	一期于 2026 年 10 月完工 → 1 GW；Hyperion 最高 5 GW	Hyperion 采用表外 SPV 融资	S27007,S27008,S27009
微软（Microsoft）· Fairwater（威斯康星州、亚特兰大）	英伟达 GB200/GB300	威斯康星州约 737 MW IT 功率（Epoch 估计）	各站点通过 AI 广域网（WAN）连接成一个“超级工厂”	S27004,S27005,S27006
Anthropic · 多供应商	Trainium2、TPU、英伟达、AMD	约 50 万颗 Trainium2（Rainier）；2026 年超过 1 GW TPU；最多 1 GW 英伟达；2 GW AMD	将风险分散到四家芯片供应商	S27011,S653,S654,S9538
主权 AI · HUMAIN、Stargate UAE	英伟达 GB300 → Vera Rubin（HUMAIN 还采用 AMD、高通）	84 MW 确定期 → 500 MW；阿联酋 200 MW → 1 GW	国家支持的需求，与美国出口审批挂钩	S13514,S13516,S13008,S90030

xAI：以速度为战略。 Colossus 1 从第一个机架到开始训练仅用 19 天，采用 Spectrum-X 以太网网络[S6000]，随后开始扩容一倍至 200,000 个 Hopper GPU[S6001]。Colossus 2 的目标是约 550,000 个 GB200/GB300 GPU，部分电力来自计量表后的现场天然气发电[S90076,S8015]。英伟达也是 xAI 的投资方，据报道投资额最高 $2B[S483]。

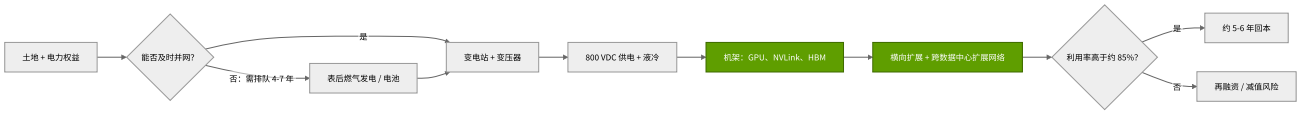
OpenAI 及其合作伙伴：站点组合。 2025 年 1 月的承诺为 $500B 和 10 GW。到 2025 年 9 月，各合作方已在 Abilene、五个新的美国站点和 CoreWeave 产能上规划了约 7 GW，并承诺在三年内投入超过 $400B [S27000]。甲骨文为 Abilene 设计的 Zettascale10 方案目标是最多 800,000 个 GPU [S6008]。Epoch AI 将 Abilene 列为已运营，目前约相当于 50.9 万个 H100，预计将达到约 102 万个 [S27003]。

Meta：自建，但在表外融资。 Prometheus 承诺于 2026 年投用，第一期已于 2026 年 10 月完工。Meta 正将其扩展至约 100 万个 GPU，平均中断间隔时间（MTBI）约为 47,000 GPU 小时 [S27009]。Hyperion 约 $27–30B 的融资安排中，Blue Owl 持有多数股权，Meta 约占 20 % [S27008]。

Anthropic：多供应商对冲。 Anthropic 运行在 Project Rainier（约 500,000 颗 Trainium2）[S27011]、最多 100 万颗谷歌（Google）TPU（2026 年超过 1 GW）[S653]、最多 1 GW 的英伟达系统（附带 $30B 的 Azure 承诺）[S654]以及 2 GW 的 AMD Helios 上 [S9538]。这是英伟达未能锁定的吉瓦级买家中最清晰的例子。



已宣布算力项目（以吉瓦计）堆叠水平条形图。OpenAI 26 GW：英伟达 10（2025 年 9 月意向书，后已重组）、博通（Broadcom）定制加速器 10、AMD 6。Anthropic 4 GW：AMD Helios 最多 2（附带 AMD 最多 $5B 的投资）、英伟达最多 1、谷歌 TPU 2026 年超过 1 GW（2027 年起的进一步多吉瓦 TPU 扩展未量化）。HUMAIN：英伟达最多 0.5 GW、AMD 0.5 GW、高通（Qualcomm）0.2 GW。xAI：英伟达约 1 GW（公司宣称，存在争议）。在这些项目中，英伟达的占比约为 39%。

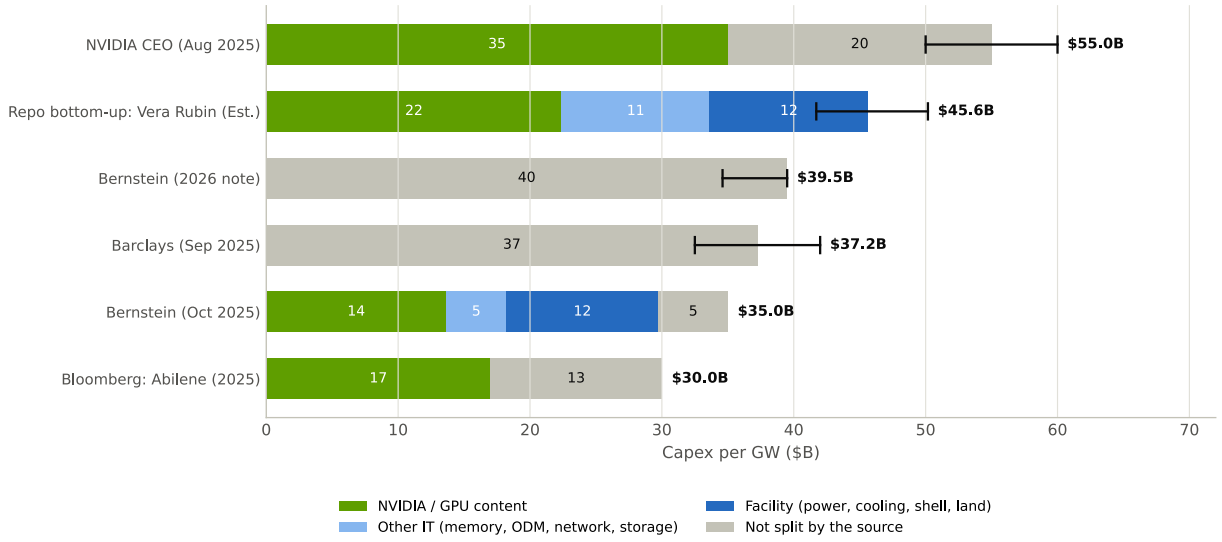


3. 结果（用数据说话）

一个吉瓦的成本。 黄仁勋估计，1 GW AI 工厂的成本为 $50–60B，其中英伟达价值量约 $35B（2025 年 8 月）[S398]。其他估计更低。伯恩斯坦估计约 $35B：GPU 约占 39 %，网络约 13 %，电气与机械设施约占三分之一 [S6025,S27013]。巴克莱估计为 $32.5–42B [S27012]，彭博对 Abilene 一个吉瓦的估价约为 $30B，其中芯片 $17B（🟡）[S27015]。伯恩斯坦后来的一份报告将 Vera Rubin 置于 $34.6–39.5B 区间的上端 [S27016]。差异主要源于各项估计把哪些计入“芯片”（内存、CPU、交换机），以及是否包含土地和发电设施。

A gigawatt of AI capacity costs ~$30–60B; the repo's Vera Rubin build-up lands at ~$46B

Capex per GW by estimator and component ($B); whiskers = stated range; NVIDIA CEO split = NVIDIA content vs the rest



Source: data from NVIDIA, Bernstein, Barclays, Bloomberg, Morgan Stanley BOM; repo model [S398] [S6025] [S27013] [S27015] [S27012] [S27016] …; chart by repo · As of 2026-11-05

每吉瓦 AI 数据中心资本成本堆叠水平条形图。英伟达 CEO（2025 年 8 月）：$50-60B，其中英伟达价值量约 $35B。本资料库对 Vera Rubin NVL72 的自下而上测算（估计）：约 $46B（区间 $42-50B），其中英伟达约 $22B，其他 IT 约 $11B，设施约 $12B。伯恩斯坦 2026 年报告：Vera Rubin 最高 $39.5B。巴克莱：$32.5-42B。伯恩斯坦（2025 年 10 月）：约 $35B，GPU 39%，网络 13%，电气与机械约三分之一。彭博对 Abilene 的估计：约 $30B，其中芯片 $17B。

提示

算例 —— 1 GW Vera Rubin 站点的 GPU、机架、MW 与资本开支（估计）。 1. **从计量电力到 IT 负载：** 1,000 MW ÷ PUE 1.15 = **约 870 MW** IT 负载。 2. **每机架功耗：** 一个 Vera Rubin NVL72 的功耗为 190 kW（Max-Q）至 230 kW（Max-P）[S302]。再加约 21 % 用于横向扩展（scale-out）交换机、存储和管理节点（GB200：全口径 145 kW 对 120 kW）[S340,S336]。由此得出每机架 230–278 kW，中值约 254 kW。 3. **机架与 GPU：** 870 MW ÷ 254 kW ≈ **3,420 个机架**，× 72 = **约 246,000 个 GPU**（区间 22.5 万–27.2 万）。 4. **资本开支：** 机架数 × $7.8M（摩根士丹利物料清单）[S330,S332] = **$26.7B**。网络和存储约增加机架支出的 26 % [S324] = **$6.9B**。设施（电力设备、冷却、厂房、土地）为 $11–13B [S6025]。合计**约 $45.6B**（区间 $41.7–50.2B）。 5. **谁拿到钱：** 英伟达占 Vera Rubin 机架价值的 62–72 %（它转售 HBM4），外加网络部分的 50–80 % [S332,S324]。即**约 $22.4B（约 49 %）**，按约 75 % 的毛利率计算，每吉瓦为英伟达带来约 $16.8B 毛利。

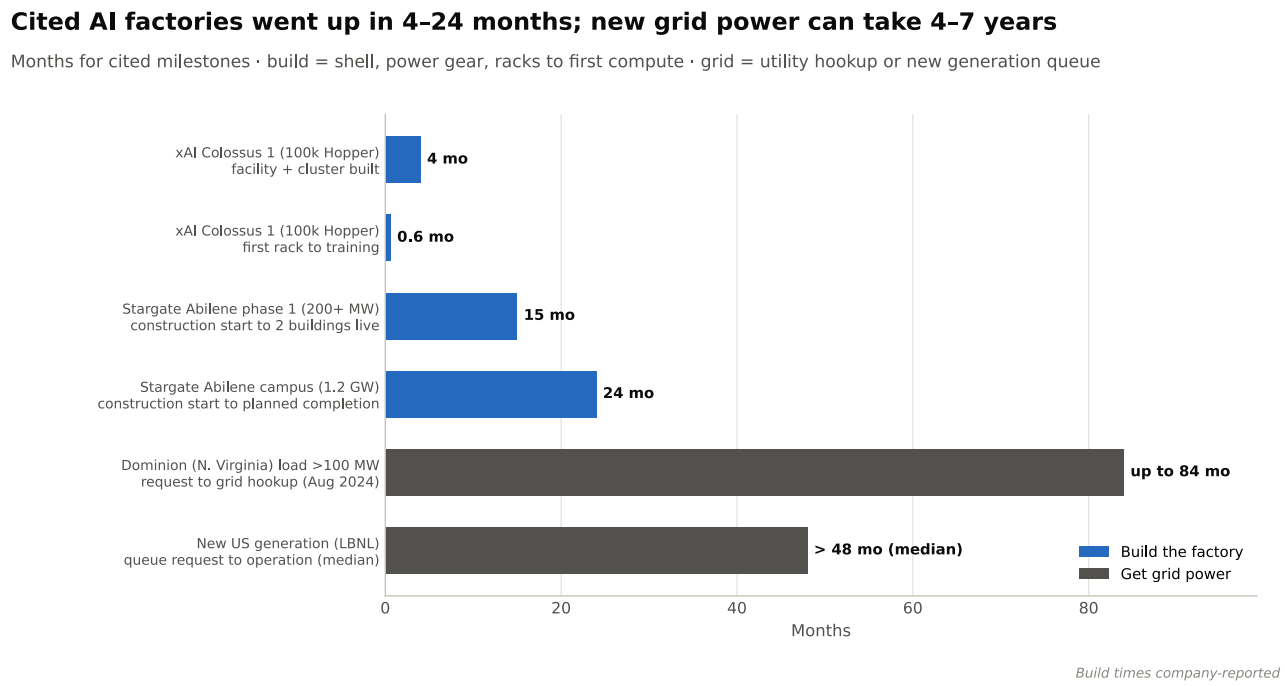
结论： 一个 Vera Rubin 吉瓦约有一半流向英伟达，低于黄仁勋在 Blackwell 时代所引用的约 $35B。HBM4 将内存推高至机架物料清单的约 26 %，因此如今每一美元中有更多流向 SK 海力士、三星和美光（Micron）[S330]。设施（电力设备、冷却、厂房、土地）约占四分之一。

🔧 技术细节：模型假设与敏感性

- **机架价格**是关键变量。若采用伯恩斯坦估计的每个 Vera Rubin 机架 $9.1M（HBM4 约 $53/GB）而非 $7.8M，机架资本开支将增加约 $4.4B。摩根士丹利 $6.7M 的直连 SOCAMM 情景则使其减少约 $3.8B（未计入对网络的连带影响）[S333,S332]。
- **Max-Q 与 Max-P：** 机架以 190 kW 运行时，在同样 870 MW 内可比 230 kW 时多容纳约 21 % 的机架。资本开支随之上升，但每 MW 的 token 产出也会提高。本资料库的“高”情景（27.2 万个 GPU）即 Max-Q 情景。
- **设施成本**采用伯恩斯坦对约 $35B 中电气与机械约占三分之一的估计，约 $11.6B，再加上土地和厂房的余量 [S6025]。像 Colossus 2 那样的表后发电，会增加本模型未计入的电厂资本开支 [S8015]。

- **盈亏平衡模型：** 资本费用 = IT 资本开支 × CRF(r, 6 年) + 设施 × CRF(r, 20 年)，其中资本回收系数 CRF = r / (1 − (1 + r)^−n)。r = 8 % 时为每年 $8.5B；12 % 时为 $9.8B。电价按 $0.081/kWh 计，满负荷用电每年约 $0.71B [S389,S382]。人员、软件、维护和税费未计入，因此实际盈亏平衡点更高。
- **输入数据**位于 `data/cs7_gw_build_inputs.csv`，公式位于 `scripts/charts/ch_cs7.py`。

电力与电网。 瓶颈已从 CoWoS 转移到了电力。建设需要 4–24 个月，但电网供电要 4–7 年才能到位：



> 以月为单位的水平条形图。建设里程碑：xAI Colossus 1 从第一个机架到开始训练用了 19 天（0.6 个月），设施加 100,000 个 GPU 集群用了 122 天（4 个月）；Stargate Abilene 前两栋建筑 200+ MW，自开工起约 15 个月；整个 1.2 GW 园区约 24 个月（目标 2026 年年中，后来的估计为 2026 年第四季度）。电网里程碑：美国新增发电项目从并网申请到投运的中位时间超过 48 个月（LBNL），在 Dominion 的北弗吉尼亚服务区，大型数据中心并网最长需 84 个月。

建设方通过三种方式绕开电网。一是自行发电（Colossus 2 的表后（behind-the-meter）燃气发电 [S8015]）。二是将一项作业分散到通过广域网连接的多个站点（跨数据中心扩展（scale-across），微软在各 Fairwater 站点之间就是这样做的 [S27006]）。三是重新设计供电方式：在 GTC DC 2025 上，约 20 家合作伙伴展示了 800 VDC 组件，800 VDC 行级电源中心（每行最高 2 MW）计划于 2027 年推出 [S90061,S90063]。相关机制参见第 08 层 · 系统、机架与 AI 工厂及其电力与冷却页面。

实际交付与宣称。 截至 2026 年底，有独立证据的项目是 Abilene（已运营，Epoch）、Fairwater Wisconsin（已完工，按 Epoch 估计约 737 MW IT 功率）和 Prometheus 一期 [S27003,S27004,S27005,S27009]。Colossus 2 的吉瓦规模仅基于公司自己的说法 [S90076]。Hyperion 和 Stargate UAE 仍在建设中，一期分别将于 2027 年和 2026 年完成 [S27007,S13008]。

4. 为何奏效（或为何未能奏效）

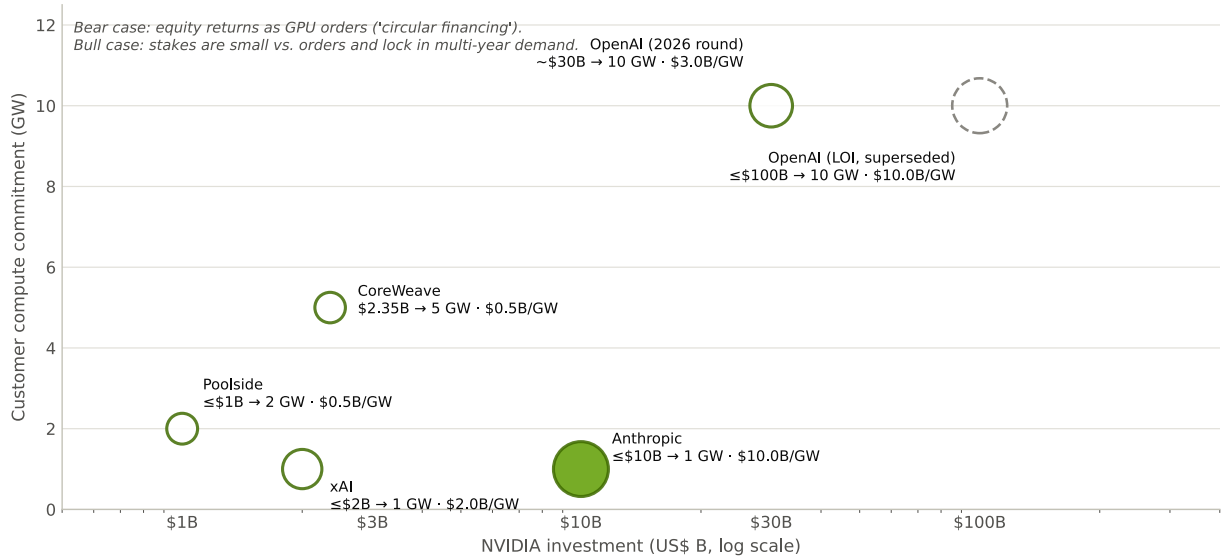
奏效之处。 - **速度会复利。** xAI 证明，改造既有厂房、现场发电和单一供应商技术栈可以把数年缩短到数月 [S6000]。其他所有人都采纳了这套打法的部分内容。 - **英伟达的全栈方案适合吉瓦级建设。** 购买机架、NVLink、Spectrum-X 或 InfiniBand 以及参考设计（Omniverse DSX、800 VDC）的建设方，面临的集成风险更少。这就是吉瓦级项目储备大部分属于英伟达的原因（见上图）。 - **融资创新。** 合资企业（Hyperion）、开发商-出租方模式（Abilene 的 Crusoe/甲骨文）以及英伟达 2026 年 8 月推出的、旨在调动超过 $500B 第三方资本的平台，分摊了资本开支 [S27008,S12528]。

未奏效或尚未证实之处。 - **融资可能在建设中途失败。** 据报道，Abilene 超出 1.2 GW 的扩建在融资谈判失败后搁浅（甲骨文对这一说法有异议）[S27001,S27002]。截至 2026 年年中，CoreWeave 背负约 $35B 债务，季度净利息支出 $640M [S12501]。 - **利用率低于铭牌值。** Meta 将 Prometheus 超过 11 % 的 GPU 作为备件或故障单元，在中断次数降低 99 % 之前，早期每 8,000 个 GPU 每天约发生 1,000 次中断 [S27010]。热备件本身不产生收入，但能保证训练作业持续运行。 - **循环性。** 英伟达已向多个吉瓦级买家（OpenAI、Anthropic、xAI、CoreWeave）承诺股权投资。它还以最多 $6.3B 为 CoreWeave 未售出的产能提供兜底 [S90015,S654,S483,S90067]。

NVIDIA pledged up to ~$45B to five customers planning ~19 GW of compute

x: NVIDIA equity committed (US$ B, log); y: customer's announced compute plan (GW); bubble area ∝ NVIDIA US$ B per GW

LOG SCALE



Hollow = reported; dashed = superseded

Source: data from company releases; press [S467] [S480] [S469] [S472] [S473] [S483]; chart by repo · As of 2026-11-05

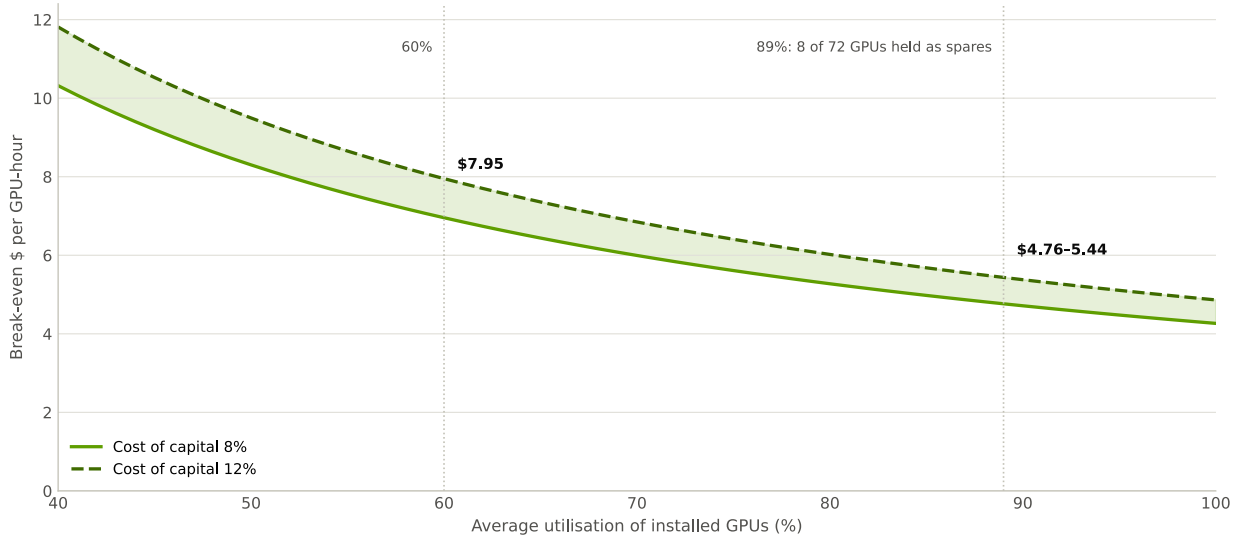
英伟达对客户投资的气泡图：OpenAI（2026 年约 $30B，此前为与 10 GW 挂钩、最多 $100B 的意向书）、Anthropic（最多 $10B，最多 1 GW）、CoreWeave（$2.35B 股权，规划超过 5 GW）、xAI（最多 $2B，约 1 GW）和 Poolside（最多 $1B，2 GW）。合计约 $45B，对应约 19 GW，这是循环融资争论的核心。

提示

算例 —— 一个吉瓦的盈亏平衡租赁价格。 以上文约 $45.6B、约 24.6 万个 GPU 的站点为例。在 8–12 % 的资本成本下，年度资本费用为 $8.5–9.8B，电费再加约 $0.7B。在 **89 %** 的利用率下（72 个 GPU 中有 8 个作为备件），站点需要**每 GPU 小时 $4.8–5.4** 才能盈亏平衡。在 **60 %** 的利用率下则需要 **$7.0–8.0**。利用率从 89 % 降至 60 %，盈亏平衡价格上升约 46 %。资本成本从 8 % 升至 12 %，盈亏平衡价格仅上升约 14 %。作为对比，某新兴云服务商（neocloud）对 B200 的挂牌价约为每 GPU 小时 $4.99 [S395]。黄仁勋所称一个吉瓦“每年租金 $50B” [S27014]，按这一 GPU 数量满负荷计算，意味着约每 GPU 小时 $23。这只有作为高端模型的 token 收入才可信，作为 GPU 租金则不可信（🔴 本资料库分析）。

Est.: a 1 GW Vera Rubin site breaks even at ~$4.8–5.4/GPU-hr at 89% use

Break-even $/GPU-hour vs utilisation: capital charge + power only (excl. staff, software, taxes); ~246k GPUs, ~$46B capex



Source: data from repo model on Morgan Stanley BOM, EIA power price, hyperscaler useful lives [S398] [S387] [S388] [S302] [S340] [S336] ...; chart by repo · As of 2026-11-05

折线图：一个约 24.6 万个 GPU、资本开支约 $46B 的 1 GW Vera Rubin NVL72 站点的每 GPU 小时盈亏平衡价格估计，仅计入资本费用（IT 寿命 6 年，设施寿命 20 年）和按 $0.081/kWh 计算的电费。资本成本为 8% 时，盈亏平衡价格从 40% 利用率时的约 $10.3 降至 100% 时的 $4.3；12% 时从 $11.8 降至 $4.9。在 89% 利用率（Meta 式 11% 热备件）下为 $4.8-5.4。利用率对结果的影响远大于资本成本。

注

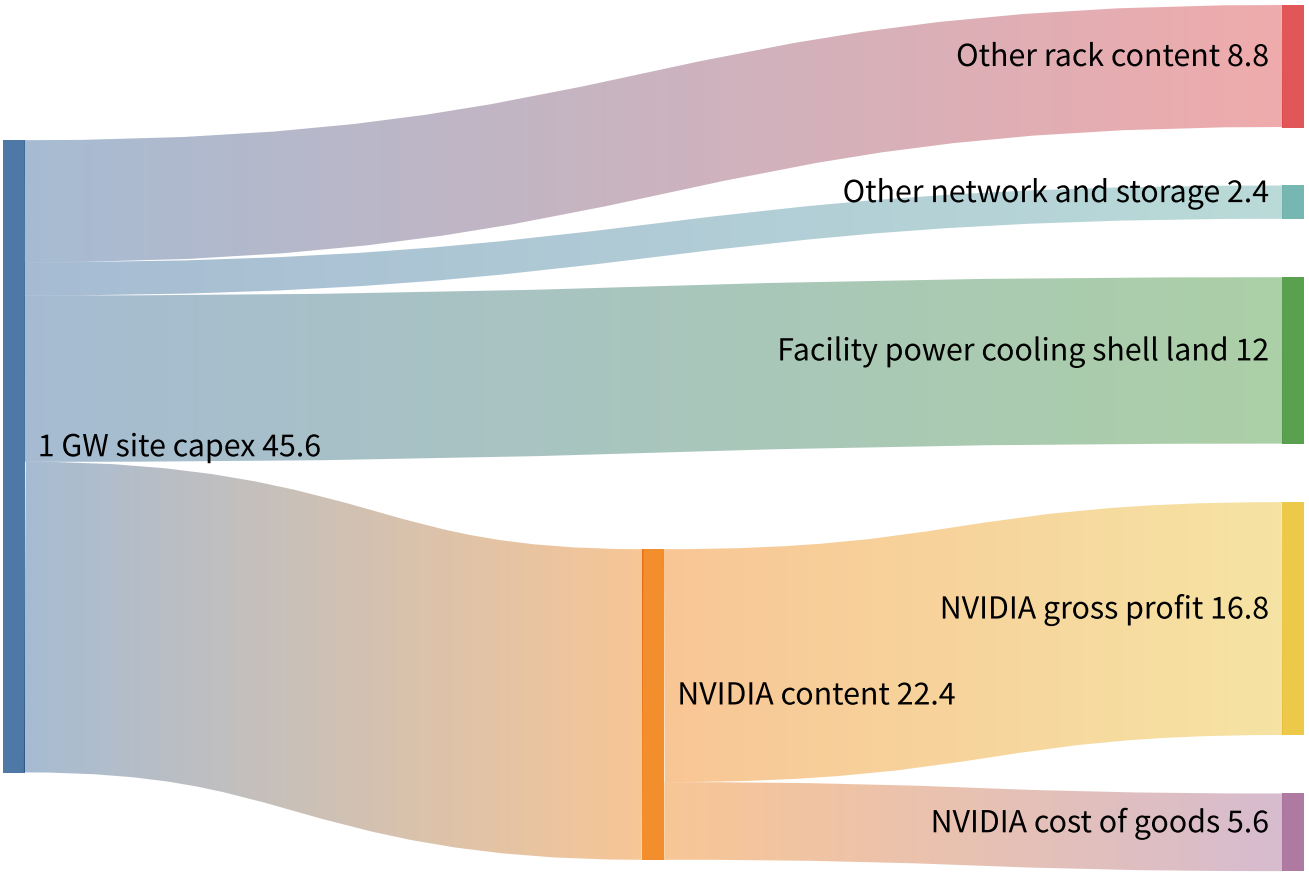
🐂 **看多观点**。 是需求在追赶站点，而不是相反。CFO 称 FY2028 受供应约束 [S90012]，每个吉瓦包含约 $22B 的英伟达价值量（估计），而电力稀缺保护了已经握有站点的现有玩家。像 Abilene 这样的延误只是推迟收入，而非取消收入；甲骨文也表示其与 OpenAI 的 4.5 GW 租约已经落实 [S27002]。

注意

🐻 **看空观点**。 吉瓦级公告是期权，而非订单。OpenAI 与英伟达的 10 GW 意向书最终变成了一笔不附部署里程碑的 $30B 股权投资 [S90015]。卫星数据与一项旗舰级说法相矛盾 [S90077]。决定最终能建成多少吉瓦的，将是利用率和融资，而非芯片供应。如果 token 价格的下降速度快于成本，2026–2027 年建成的 $45B 级站点可能在 6 年折旧期内就面临减值，英伟达在客户中的股权投资也会随之缩水。

5. 对企业发展（corp dev）的启示

吉瓦规模下价值流向何处。 逐一追踪约 $46B（估计）的 Vera Rubin 吉瓦中的每一美元：



1. **芯片仍拿走最大份额，但每吉瓦的占比在下降。** 英伟达在 Vera Rubin 机架中的占比（62–72 %）低于 GB200 机架的 72–84 %，因为 HBM4 及其他组件的价值增加了 [S326,S330,S332]。在整个站点中，英伟达的占比约为 49 %（估计）。存储厂商是主要受益者。
2. **电力设备和冷却是第二大价值池。** 站点资本开支的四分之一到三分之一流向电气与机械设施。变压器、开关柜和现场发电设备的交付周期决定了建设进度 [S6025,S90061]。
3. **拥有电力权益的土地是最稀缺的资产。** 已并网的站点可以跳过 4–7 年的排队 [S8009,S8010]，这就是开发商（Crusoe、Aligned、新兴云服务商）获得高估值的原因 [S8521]。
4. **利用率软件被低估了。** 利用率下降十个百分点（89 % → 79 %），盈亏平衡价格上升约 12 %，大致相当于资本成本上升四个百分点的影响（约 14 %），而利用率的波动幅度远大于融资成本（见算例）。调度、故障恢复和推理服务（第 11–12 层）守护着一个吉瓦的经济性。

🎯 企业发展视角

1. **哪个价值池的持有者不足？** 按每吉瓦约 $12B 的电力、冷却和厂房投入计算（估计），从 800 VDC 转换到液冷分配的电气链条是一个比网络更大的价值池。半导体公司可以在哪些环节增加价值量：功率转换芯片、传感器、控制器？
2. **高能效推理。** 能够在每兆瓦上交付更多 token 的挑战者，可以打入电力受限的站点——在那里，硬约束是电表而非预算。高通的 AI200/AI250 机架及其 200 MW 的 HUMAIN 计划是公开的参照点 [S90028,S90030]。吉瓦级买家会要求哪些证明指标（tokens/MW、利用率、可维护性）？
3. **在尽职调查中如何核实吉瓦级说法？** 索取计量电力、PUE、机架数量和利用率数据，并与卫星或许可证数据交叉核对，就像对 Colossus 2 所做的那样 [S90077]。
4. **谁的资产负债表承担风险？** SPV 融资（Hyperion）、厂商兜底（CoreWeave）和厂商股权投资（英伟达 → OpenAI、Anthropic、xAI）只是转移风险，而非消除风险。当合作伙伴提出一项产能交易时，谁来

承担利用率不足的后果?

5. **多供应商买家是突破口**。 Anthropic 运行着四个芯片平台，HUMAIN 同时采购了英伟达、AMD 和高通的产品 [S653,S9538,S13517,S90030]。吉瓦级买家需要第二供应商来获得价格和供应上的筹码。成为一个可信的第二供应商，是挑战者现实的切入点；在训练上击败英伟达则不是。

相关内容：CS4 · AMD、OpenAI 与第二供应商 · 第 13 层 · 资本配置 · 第 08 层 · AI 工厂 · 第 14 章 · 训练与推理经济学。

术语表（Glossary）

本资料库各章节所用的 658 个术语，均以浅白语言释义，面向具备技术素养（但非工程背景）的读者。 由 `make build` 根据 `docs/glossary/*.csv` 生成。词条沿用英文原文的字母顺序，标题格式为“英文术语（中文译名）”。

0–9

800 V DC power architecture（800 V 直流供电架构） — 英伟达的规划（自 2027 年起）：向机架输送 800 伏直流电，减少电能转换环节和铜材用量，使单个机架的功耗可达约 1 兆瓦。*另见：* 液冷。

A

ABF substrate（ABF 基板） — GPU 封装所承载的多层有机基板（以味之素积层膜 Ajinomoto Build-up Film 制造），负责把数以千计的连接引至电路板；供应商包括揖斐电（Ibiden）和欣兴电子（Unimicron）等。*另见：* 先进封装、中介层。

ACIE (AI clouds; industrial and enterprise)（AI 云、工业与企业客户） — 自 Q1 FY2027 起英伟达数据中心收入中非超大规模云厂商的那一半：AI 云与新兴云服务商（neocloud）、主权项目，以及工业与企业买家。*另见：* 新兴云服务商（neocloud）、超大规模云厂商。

Acquihire（收购式招聘） — 一种交易结构：聘用目标公司的团队（通常附带技术授权），而非直接收购整家公司。它比收购更快，且可能绕开并购审查；英伟达与 Groq 和 Enfabrica 的交易即采用这一结构。

Activation（激活值） — 前向传播中某一层产生、并为反向传播保留的中间结果。激活值所占内存随批大小和序列长度增长；重计算（recomputation）以额外算力换取这部分内存。*另见：* 前向传播、反向传播。

Active electrical cable (AEC)（有源电缆） — 在连接器中内置重定时器（retimer）芯片的铜缆，可在每通道 100-200G 速率下把传输距离延伸至数米；用于机架内及相邻机架互连时，比光学方案更便宜、功耗更低。Credo 是领先供应商。*另见：* SerDes。

Activist investor（维权投资者） — 持有相当规模股份、并向管理层施压要求变革（董事会席位、削减成本、出售公司）的股东。Starboard 在 2017-18 年对 Mellanox 发起的维权行动，是该公司后来进行出售竞拍的前奏。

Adam optimizer（Adam 优化器） — 大模型的标准优化器。它为每个参数维护两个滑动平均值（动量与方差），这正是混合精度训练中每个参数约需 16 字节的原因。*另见：* 优化器、混合精度训练。

Adaptive routing（自适应路由） — 依据实时队列深度而非固定哈希，为每个数据包（或一组数据包）选择路径，引导流量绕开拥塞热点。InfiniBand 原生支持这一能力；Spectrum-X 和超以太网（Ultra Ethernet）将其引入以太网。*另见：* ECMP（等价多路径）、数据包喷洒。

Advanced Matrix Extensions (AMX)（高级矩阵扩展） — 英特尔自 Sapphire Rapids（2023 年）起在 Xeon CPU 核心中加入的矩阵乘法单元；每个核心每个时钟周期最多可执行 1,024 次 BF16 运算，是其向量单元的 16 倍。*另见：* 张量核心。

Advanced packaging（先进封装） — 将多个裸片（die）与内存堆栈集成于同一封装、布线密度远高于电路板的技术，例如台积电的 CoWoS（2.5D）和 SoIC（3D 堆叠）。对 AI 加速器而言，先进封装已成为产能瓶颈和主要成本项。*另见：* CoWoS、中介层。

Agent sandbox（智能体沙箱） — 一种隔离环境（通常是绑定到某个 CPU 核心的容器或小型虚拟机），用于运行 AI 智能体生成的代码、浏览器会话或工具调用，或用于执行强化学习中的尝试并为其评分。*另见：* 智能体 AI、强化学习（RL）。

Agentic AI (agents)（智能体 AI） — 由模型在多个步骤中自主规划、调用工具、读取结果并反复迭代以完成任务的系统。一项任务可能消耗数百次模型调用和数百万个 token（词元）。*另见：* 测试时计算、推理。

AI Blueprint（AI 蓝图） — 英伟达的参考应用（例如研究型智能体或检索管线），由 NIM 微服务和 NeMo 工具构建，作为企业开发的起步代码发布。*另见：* NVIDIA NIM、NeMo。

AI factory（AI 工厂） — 英伟达提出的概念，指主要为生产 AI token 而建设和运营的数据中心，从供电、散热到机架、网络和软件均作为一个整体系统来设计。*另见：* 机架级系统、800 V 直流供电架构。

AI head node（AI 主控节点） — AI 系统中负责调度任务、运行智能体逻辑并向加速器供给数据的通用服务器 CPU。高通将其 Dragonfly C1000 定位于这一角色。*另见：* 主机 CPU。

AI-RAN（AI 无线接入网） — 在移动基站的同一批加速服务器上同时运行 AI 工作负载和无线网络信号处理。英伟达对诺基亚（Nokia）$1B 的入股正是瞄准这一市场。

AITER — AI Tensor Engine for ROCm：AMD 经过调优的大语言模型（LLM）算子库（注意力、MoE、GEMM），以 Triton、Composable Kernel 和汇编语言编写；是 vLLM 在 ROCm 上的默认注意力后端。*另见：* ROCm、Composable Kernel。

AlexNet — 2012 年由 Krizhevsky、Sutskever 和 Hinton 提出的神经网络，以大幅领先的成绩赢得 ImageNet 图像识别竞赛。它借助 CUDA 在两块 GeForce GTX 580 游戏 GPU 上完成训练。*另见：* CUDA。

All-gather（全收集） — 一种集合通信操作：每个 GPU 贡献一个分片，最终每个 GPU 都得到所有分片拼接而成的完整数据。*另见：* 全规约、规约散射。

All-in power per GPU（单 GPU 全口径功耗） — 数据中心为运行一块 GPU 所需配置的全部电力中由该 GPU 分摊的部分：GPU 本身、其主机 CPU、交换机和网卡，再加上散热与电能转换损耗。按兆瓦计的指标应除以这一数值，而非 GPU 的 TDP。*另见：* PUE（电能使用效率）、每兆瓦每秒 token 数。

All-reduce（全规约） — 一种集合通信操作：每个 GPU 贡献一组数值（如梯度），每个 GPU 都收到合并后的结果。其速度取决于 GPU 之间的网络。*另见：* NCCL、横向扩展（scale-out）。

All-to-all（全交换） — 一种集合通信操作：每个 GPU 同时向其他每个 GPU 发送各不相同的数据；这是混合专家层的通信模式，也是对网络要求最苛刻的一种。*另见：* 专家并行（EP）。

Allocation ratio（分配率） — 某一时刻已分配给某项作业的 GPU 占已装机 GPU 的比例。它并不说明被分配的 GPU 是否真正处于忙碌状态；是最基础、也最宽松的利用率指标。*另见：* MFU（模型 FLOPs 利用率）、SM 利用率。

AMD Helios — AMD 首个机架级 AI 系统（2026 年）：72 块 Instinct MI455X GPU、EPYC Venice CPU 和 Pensando 网卡装于双宽机架内，通过基于以太网的 UALink 互连，对标英伟达的 Vera Rubin NVL72。*另见：* 机架级系统、UALoE、NVL72。

AMD SEV-SNP — AMD 面向 EPYC CPU 的机密虚拟机技术（Secure Encrypted Virtualization with Secure Nested Paging，安全加密虚拟化与安全嵌套分页）：加密每台虚拟机的内存，并阻止虚拟机管理程序（hypervisor）篡改。SEV-TIO 借助 TDISP 将其扩展到 PCIe 设备。*另见：* 可信执行环境（TEE）、TDISP。

Amdahl's law（阿姆达尔定律） — 该定律指出：任务中无法加速的部分（在 AI 集群中通常是无法与计算重叠的通信）决定了增加处理器所能带来的总加速比的上限。*另见：* 横向扩展（scale-out）。

Annapurna Labs — 以色列芯片设计初创公司，亚马逊于 2015 年以据报约 $350-370M 将其收购；负责设计 AWS 的 Nitro、Graviton、Inferentia 和 Trainium 芯片。*另见：* AWS Nitro、Trainium。

Annual cadence（一年一代节奏） — 每年（而非每两年）推出新一代旗舰数据中心 GPU。这抬高了竞争对手和第二供应商的门槛——它们要追赶的是移动靶，而非固定靶。*另见：* NVL72。

Apache Spark — 应用最广泛的开源引擎，用于在服务器集群上进行大规模数据处理和 SQL 查询。*另见：* ETL、cuDF。

Architecture licence（架构授权） — Arm 的一种授权方式，允许企业自行设计实现 Arm 指令集的处理器核心，而不使用 Arm 提供的核心设计。苹果、高通和英伟达（Vera 的 Olympus 核心）均采用这一路线。*另见：* Arm 指令集、Neoverse。

Arithmetic intensity（算术强度） — 每从内存搬运一个字节所执行的浮点运算次数（FLOPs）。低于芯片“峰值 FLOPS 与内存带宽之比”（即屋脊点）的工作负载受内存带宽限制；小批量下的解码远低于这一水平。*另见：* 解码（decode）、内存墙。

Arm (instruction set)（Arm 指令集） — Arm Holdings 授权给芯片设计商使用的一系列指令集，被授权方需支付授权费和按芯片计收的版税。Grace、Vera、Graviton、Axion 和 Cobalt 均为 Arm CPU。*另见：* ISA（指令集架构）、Neoverse、IP 版税。

Arm CCA（Arm 机密计算架构） — Arm Confidential Compute Architecture：Armv9 中的“Realm”机制，将虚拟机与主机软件隔离，是 Arm 对标 SEV-SNP 和 TDX 的方案。*另见：* 可信执行环境（TEE）。

ASIC（专用集成电路） — Application-specific integrated circuit（专用集成电路）：为单一工作负载设计的芯片。在 AI 领域指谷歌 TPU、AWS Trainium 等定制加速器，以灵活性换取效率。*另见：* GPU。

ASIC design partner（ASIC 设计合作伙伴） — 将客户的芯片架构转化为可量产芯片的公司（如博通、美满电子、联发科、世芯电子（Alchip）、创意电子（GUC）），提供物理设计、高速 SerDes、封装和晶圆代工渠道。超大规模云厂商借助它们打造定制加速器，而无需组建完整的芯片团队。*另见：* ASIC、XPU（定制加速器）。

At the money（平价） — 行权价等于授予时股价的期权或认股权证。授予时没有内在价值，只有股价涨过行权价才会产生收益；这与行权价接近零的低价认股权证（penny warrant）不同。*另见：* 内在价值、认股权证。

Attach rate（附加率） — 客户在购买一种产品时连带购买另一种产品的数量，例如每 1 美元 GPU 支出所对应的网络设备支出。附加率上升意味着供应商在每个集群的预算中占取更大份额。*另见：* 装机量。

Attention（注意力机制） — Transformer 层中让每个 token 与此前的 token 逐一比对、以获取上下文的部分。其计算成本和内存占用（KV 缓存）随序列长度增长。*另见：* Transformer、KV 缓存。

Attestation（远程证明） — 由烧录在芯片中的密钥签名的密码学证明，证实可信执行环境（TEE）是运行着经批准固件与配置的真实硬件。客户在发送模型权重等机密数据前会先校验该证明。*另见：* 可信执行环境（TEE）、硬件信任根。

Autotuning（自动调优） — 在实际硬件和实际张量形状上，对内核的多个版本（分块大小、流水线深度、线程数）自动进行基准测试，并保留最快的版本。cuBLAS 的启发式选择、Triton 和 TorchInductor 均采用此法。*另见：* GPU 内核、Triton (OpenAI)。

AWS Nitro — AWS 自研的卸载卡与虚拟机管理程序系列，将 EC2 的网络、存储、管理和安全功能从主机 CPU 上卸载；源于 2015 年对 Annapurna Labs 的收购。*另见：* 数据处理器（DPU）、EFA (Elastic Fabric Adapter)。

Azure Cobalt — 微软为 Azure 自研的 Arm 服务器 CPU：Cobalt 100（128 个 Neoverse N2 核心）和 Cobalt 200（132 个 Neoverse V3 核心，2025 年）。*另见：* Maia、Neoverse。

B

Back-end network（后端网络） — 专用于 GPU 之间互连的网络（InfiniBand 或 AI 以太网），承载训练和大规模推理中的集合通信，独立于通用网络之外。*另见：* 前端网络、横向扩展（scale-out）。

Backside power delivery（背面供电） — 将芯片的供电线路布设在晶体管下方，而非穿过其上方的信号层，从而腾出布线空间并降低电压损耗。台积电将其方案称为 Super Power Rail（超级电轨），随 A16 节点推出。*另见：* 工艺节点。

Backward pass (backpropagation)（反向传播） — 沿各层逆向计算每个参数应如何调整以降低误差（即梯度）。其成本约为前向传播的两倍，因此训练总计约为每个参数每个 token 6 次浮点运算。*另见：* 前向传播、梯度。

Bare-metal instance（裸金属实例） — 不带云服务商虚拟机管理程序（hypervisor）的租用式云服务器：租户掌控整个操作系统。云服务商的控制软件因此必须部署在租户无法触及之处，例如 DPU 上。*另见：* 多租户、数据处理器（DPU）。

Base Command Manager — 英伟达的集群管理软件（源自 2022 年对 Bright Computing 的收购），用于部署、配置和监控 GPU 集群的服务器、操作系统镜像和调度器；现已并入 Mission Control。*另见：* NVIDIA Mission Control、Slurm。

baseband modem（基带调制解调器） — 处理手机蜂窝无线协议的芯片（或芯片模块）；英伟达于 2011 年收购 Icera 以获得这一能力，并于 2015 年关停该业务。*另见：* 片上系统。

Batching（批处理） — 在同一个 GPU 计算步骤中同时处理多个请求，使一次权重读取由所有请求共享。可提升单 GPU 吞吐量，但会拖慢每个用户的响应速度。*另见：* 连续批处理、吞吐量-交互速度帕累托前沿。

Behavioural remedy（行为性救济措施） — 一种并购附加条件：规范合并后公司的行为方式（例如不得捆绑销售、须继续向竞争对手供货、保持互操作性），而不是强制其剥离资产。*另见：* SAMR（国家市场监督管理总局）。

Behind-the-meter generation（表后发电） — 在数据中心场址内或邻近处建设、直接向其供电而不经过公用电网的发电设施（通常为燃气轮机、内燃机或燃料电池），使数据中心能在电网接入到位之前先行投运。*另见：* 通电时间、并网排队。

BF16 (bfloat16) — 一种 16 位（2 字节）数值格式，数值范围与 32 位浮点数相同、但精度较低；是当前 GPU 上训练和大部分推理的默认格式。*另见：* FP8、混合精度训练。

Bill of materials (BOM)（物料清单） — 构成一件产品的全部元器件清单及其成本。就 GPU 封装而言包括：逻辑裸片、HBM、封装、基板和测试。分析师估计 B200 的物料成本约为 $6,400。

Bin-packing (scheduling)（装箱式调度） — 一种放置策略：先填满一台服务器或一个机架，再启用下一台，从而为大型作业保留完整的空闲单元。与之相反的分散放置可提升容错能力，但会造成容量碎片化。*另见：* GPU 碎片化。

Binary translation（二进制翻译） — 在程序运行时将其机器码从一种指令集（或形式）转换为另一种。英伟达的 Denver 核心采用了与之相关的“动态代码优化”方案。*另见：* ISA（指令集架构）。

BioNeMo — 英伟达用于训练和部署生物与化学基础模型（蛋白质、分子、DNA）的框架与模型集合。*另见：* Parabricks。

BIS (Bureau of Industry and Security)（美国商务部工业与安全局） — 美国商务部下属机构，负责制定出口管制规则并审批出口许可，包括针对中国的 AI 芯片规则。*另见：* 出口管制。

Bisection bandwidth（对分带宽） — 将网络切分为相等两半的最窄切面上的总带宽。无阻塞胖树拥有全对分带宽：一半端点能够以线速与另一半端点通信。*另见：* 胖树、超额订阅。

Blended token price（混合 token 价格） — 将输入价格与输出价格加权平均后得到的单一每百万 token 价格，通常按 3 个输入 token 对 1 个输出 token 加权。*另见：* token 价格通缩。

Blind-mate connector（盲插连接器） — 托盘滑入机架时即自动对接、无需人工插拔线缆的连接器。NVL72 的托盘借此接入 NVLink 背板（spine），使托盘可整体插拔更换，也降低了布线出错的概率。*另见：* NVLink 线缆背板、NVLink 交换托盘。

BlueField — 英伟达（最初为 Mellanox）的 DPU 产品系列：将 ConnectX 网络适配器与 Arm CPU 核心相结合，把网络、存储和安全任务从主机 CPU 上卸载。*另见：* 数据处理器（DPU）、ConnectX。

BMC (baseboard management controller)（基板管理控制器） — 服务器或交换托盘上的小型服务处理器，通过独立的管理网络监控设备健康、电源和固件状态，即使主芯片断电也能工作。*另见：* NVLink 交换托盘。

Bounce buffer（中转缓冲区） — 位于 CPU 内存中的暂存区：数据先落到这里，再复制到真正的目的地（例如从网卡或 SSD 复制到 GPU 显存）。每次中转都会消耗主机内存带宽和 CPU 时间并增加延迟；GPUDirect 免去了这一环节。*另见：* GPUDirect RDMA、GPUDirect Storage。

Brook — 斯坦福大学于 2004 年推出、由 Ian Buck 主导的类 C 语言 GPU 流式编程语言。它证明通用代码可以编译到图形硬件上运行，是 CUDA 在研究阶段的前身。*另见：* GPGPU、CUDA。

Burn-in（老化测试） — 新硬件在正式投入生产前满负荷运行数日，以便在客户依赖它之前提前暴露 GPU、线缆、散热和电源的早期故障。*另见：* 计算托盘、NVL72。

Bus bandwidth（总线带宽） — NCCL 基准测试所报告的指标：集合通信期间每块 GPU 的链路实际维持的数据速率，经过归一化处理，以便与硬件链路速度相比较。*另见：* NCCL、全规约。

Busbar（母排） — 纵贯机架高度的粗铜排，把直流电从电源架输送到每个托盘。在约 50 V 电压下，132 kW 的机架需要约 2,600 A 电流，这正是更高电压方案即将到来的原因。*另见：* 电源架、800 V 直流供电架构。

Bytes per token（每 token 字节数） — GPU 生成一个 token 必须从内存读取的数据量：大致为模型权重（每个解码步骤读取一次，由整个批次共享）加上每个用户的 KV 缓存。用内存带宽除以该数值，即得到解码速度上限。*另见：* 解码速度上限、内存受限、KV 缓存。

C

Cache coherence（缓存一致性） — 由硬件保证各处理器缓存中的共享内存副本彼此一致，使 CPU 和 GPU 能用普通指针读写同一份数据，而无需显式复制。*另见：* NVLink-C2C。

CANN — 华为的神经网络计算架构（Compute Architecture for Neural Networks）：昇腾（Ascend）NPU 的驱动、编译器和内核层，相当于华为版的 CUDA；已于 2025 年开源。*另见：* CUDA。

Capacity allocation（产能分配） — 台积电或 HBM 厂商等供应商在客户之间分配稀缺产出的方式，通常偏向规模最大、下单最早、最可靠的买家。在 AI 硬件领域，拿到产能可能比拥有更好的设计更重要。*另见：* CoWoS、高带宽内存（HBM）、采购义务。

Capacity backstop（算力兜底承诺） — 由第三方（此处通常为英伟达或谷歌）作出的承诺：若运营方未能把数据中心容量卖给客户，由其购买或付费。这降低了运营方的融资风险和借贷成本。*另见：* 循环融资、新兴云服务商（neocloud）。

Capacity market（容量市场） — 一种电力市场：电网运营方提前数年向发电方付费（以每兆瓦·日美元计），换取其届时可供电的承诺；PJM 的拍卖价格是衡量美国最大数据中心区域稳定电力稀缺程度的公开指标。*另见：* 并网排队。

Capital recovery factor（资本回收系数） — 在资产寿命期内每年须赚取的投资比例，以连本带息收回投资：r / (1 - (1 + r)^-n)。用于把资本开支折算为年度成本。*另见：* 总拥有成本（TCO）。

Capital-for-capacity deal（以资本换产能交易） — 芯片厂商向客户提供资金或股权（现金入股、认股权证、兜底承诺），以换取客户承诺部署一定规模的该厂商算力（通常以吉瓦计）的交易。*另见：* 循环融资、认股权证。

Captive silicon（自用芯片） — 企业自行设计、仅供自用而不对外销售的芯片（例如 AWS Nitro 或微软的 Azure Boost DPU），与商用芯片相对。*另见：* 商用芯片。

CDNA — AMD 的数据中心 GPU 架构系列（Compute DNA），独立于其 RDNA 游戏产品线。CDNA 3 用于 MI300X/MI325X，CDNA 4 用于 MI350 系列；据报道 MI500 将采用 CDNA 6。*另见：* ROCm、AMD Helios。

Channel partner（渠道合作伙伴） — 转售、集成或服务某厂商产品的公司，例如 OEM、分销商或系统集成商，使厂商无需自建庞大的销售团队即可触达客户。*另见：* 全球系统集成商（GSI）、OEM。

Checkpoint（检查点） — 保存到存储中的模型权重与优化器状态快照，使训练作业在发生故障后可以从断点恢复，而不必从头开始。*另见：* 有效吞吐量。

China-compliant SKU（中国合规版 SKU） — 为恰好低于出口管制门槛而削减规格的产品型号（例如 A800、H800、H20），从而在规则变化之前无需许可证即可出货。*另见：* TPP（总处理性能）。

Chinchilla-optimal（Chinchilla 最优） — 2022 年的一项研究结论：在算力预算固定的情况下，参数量与训练 token 数应同步增长，比例约为每个参数 20 个 token。*另见：* 缩放定律、过度训练。

Chip-hour（芯片小时） — 一个加速器使用一小时：云租赁价格和自有总拥有成本（TCO）的计价单位。跨厂商比较芯片小时时，若不同时比较单芯片吞吐量，就会产生误导。*另见：* GPU 小时、总拥有成本（TCO）。

Chiplet（芯粒） — 为与其他裸片组合封装而设计的较小裸片，以取代单一的巨型单体裸片。芯粒能提升良率，并允许不同功能采用不同的工艺节点。*另见：* 裸片、中介层、裸片间互连。

Circular financing（循环融资） — 一种批评观点：供应商通过投资客户、向客户放贷或为客户的产能提供担保来抬高自身需求，而客户再用这些资金购买供应商的产品。此说法被用于评论英伟达对 AI 实验室和新兴云服务商的入股及其算力兜底承诺。*另见：* 新兴云服务商（neocloud）、采购义务。

Cloud credits（云积分） — 云服务商赠予初创企业的预付使用额度（例如谷歌云为 AI 原生初创企业提供最高 $350,000），以便尽早赢得其工作负载。

Co-design (hardware-software)（软硬件协同设计） — 将芯片与运行于其上的编译器、库和模型一并设计，使 FP4 数值格式等新特性在产品发布当天即可投入使用。2026 年英伟达在芯片上的主要优势在于协同设计的速度，而非纸面规格。*另见：* NVFP4、CUDA。

Co-packaged optics (CPO)（共封装光学） — 把将电信号转换为光信号的光引擎直接放在交换芯片旁边、置于同一封装内，而不是放在前面板的可插拔光模块中。这缩短了电气路径，降低了每比特功耗。*另见：* 可插拔光模块、微环调制器、外置激光光源。

Cold plate（冷板） — 直接贴装在 GPU 或 CPU 上、内部带有流道的金属块；流经其中的液体将热量带走（直触芯片液冷）。*另见：* 冷却液分配单元（CDU）、液冷。

Collective operation（集合通信操作） — 整组 GPU 同时交换数据的通信模式（全规约、全收集、规约散射、全交换、广播），与单个 GPU 向另一个 GPU 发送数据相对。*另见：* 全规约、NCCL。

Composable Kernel — AMD 用于在 ROCm 上编写融合 GPU 内核的 C++ 模板库；是 AMD 最接近 CUTLASS 的对应产品。*另见：* CUTLASS、ROCm。

Computational lithography（计算光刻） — 对光掩模上的芯片设计图形进行预先畸变处理（光学邻近效应修正）的软件，使图形能准确地印制在晶圆上；是芯片制造中规模最大的计算工作负载之一。*另见：* cuLitho、光掩模。

Compute margin（算力利润率） — 模型实验室的收入在扣除为付费用户提供服务的算力成本后剩余的比例；不含训练算力和研发支出。*另见：* 毛利率。

Compute Subsystem (CSS)（计算子系统） — Arm 预先集成并验证的模块，包含处理器核心、片上互连网格和 I/O，被授权方可直接将其放入自家芯片以节省设计时间。其版税高于单独授权核心。*另见：* Neoverse、IP 版税。

Compute tray（计算托盘） — NVL72 机架中的一个 1U 抽屉，容纳两块超级芯片板（2 个 CPU + 4 个 GPU）及其网卡、本地 SSD 和冷板。十八个计算托盘构成机架的 72 块 GPU。*另见：* NVL72、超级芯片、NVLink 交换托盘。

Compute-bound（计算受限） — 速度受芯片算术吞吐量限制的工作负载，因为它会对每个字节重复使用多次；增加内存带宽无济于事。*另见：* 内存受限、FLOPS。

Compute-in-memory（存内计算） — 在存储阵列内部或紧邻处执行乘累加运算的设计，减少搬运权重所耗费的能量。d-Matrix 的数字存内计算即为一例。*另见：* 近存计算、内存墙。

Confidential computing（机密计算） — 在受硬件保护的隔离区（可信执行环境）中运行代码和数据，使云运营方本身也无法读取；英伟达自 Hopper 起在 GPU 上支持该功能。*另见：* 数据处理器（DPU）。

Congestion control（拥塞控制） — 发送端和交换机在队列溢出前降低流量的规则，例如对数据包打标记（ECN）并由网卡降低发送速率。良好的拥塞控制能保持队列短、尾延迟低。*另见：* ECN（显式拥塞通知）、多对一拥塞、自适应路由。

ConnectX — 英伟达（最初为 Mellanox）面向 InfiniBand 和以太网的网络适配器系列。参考设计为每块 GPU 配一块 ConnectX 网卡或 SuperNIC，因此它随 GPU 订单一同出货。*另见：* SuperNIC、InfiniBand。

Context parallelism (CP)（上下文并行） — 将一个超长序列的 token 拆分到多个 GPU 上，各 GPU 再交换注意力的键和值（例如以环形方式）；用于 100K token 以上的长序列训练。*另见：* 序列并行。

Continuous batching（连续批处理） — 在每个生成步骤都进行调度，使请求可以随时加入或离开正在运行的批次，而不必等整个批次完成。现代推理服务引擎的标配。*另见：* 批处理、PagedAttention。

Contracted vs active power（签约电力与在用电力） — 签约电力指云厂商已签约锁定的数据中心容量（以 MW 或 GW 计）；在用电力指当前已通电并在计费的容量。二者之差是仍待融资和交付的建设量。*另见：* 新兴云服务商（neocloud）、收入积压。

Coolant distribution unit (CDU)（冷却液分配单元） — 由水泵和换热器组成的单元，将液态冷却剂循环输送至机架内的冷板，并把热量传递给建筑的水循环系统。一台 CDU 可服务一个或多个机架。*另见：* 冷板、液冷。

CoPoS (chip-on-panel-on-substrate)（面板级 CoWoS） — 台积电 CoWoS 的面板级版本，在大型方形面板而非 300 mm 圆形晶圆上制作封装，随着封装尺寸增大可减少面积浪费。2026 年试产；预计 2H 2028 之前不会量产。*另见：* CoWoS、CoWoS-L、先进封装。

Corporate venture capital（企业风险投资） — 实体经营企业对初创公司进行的少数股权投资，通常兼顾获取战略信息、扩大生态影响力和财务回报。*另见：* NVentures。

Cost of capital (WACC)（资本成本） — 投资者对占用在某项资产上的资金所要求的年回报率（加权平均资本成本）。在 TCO 模型中，它把前期资本开支转化为包含融资成本（而不仅是折旧）的均等年度费用。*另见：* 资本回收系数、使用寿命。

Cost per million tokens（每百万 token 成本） — 加速器在一段时期内的自有成本除以其产出的 token 数，再折算到一百万个 token。它既取决于硬件价格，也同样取决于在选定的单用户速度下的吞吐量以及利用率。*另见：* 自有 TCO、交互速度（每用户 tokens/s）、每兆瓦每秒 token 数。

CoWoS — Chip-on-Wafer-on-Substrate（晶圆上芯片再上基板）：台积电的 2.5D 先进封装，将 GPU 裸片和 HBM 堆栈并排置于硅中介层（CoWoS-S）或基于桥接的变体（CoWoS-L、CoWoS-R）上。其产能一直是 AI 加速器的关键瓶颈。*另见：* 高带宽内存（HBM）。

CoWoS-L — 台积电的 CoWoS 变体，以内嵌小型硅桥的重布线层中介层取代单一大型硅中介层，可支持数倍光罩尺寸的封装（自 Blackwell 起采用）。*另见：* CoWoS、中介层。

CoWoS-R — 台积电的 CoWoS 变体，其中介层仅由有机重布线层构成、不含硅。成本更低、更灵活，但布线精度低于 CoWoS-S 或 CoWoS-L。*另见：* CoWoS、重布线层（RDL）、CoWoS-L。

CoWoS-S — 台积电最初的 CoWoS 变体，将裸片置于单一的单体硅中介层上，中介层面积最大约为光罩面积的 3.3 倍。用于 A100、H100 和 H200。*另见：* CoWoS、CoWoS-L、中介层。

CPU (central processing unit)（中央处理器） — 一种通用处理器，拥有几十到几百个强大的核心，专为低延迟运行多样化、分支繁多的代码而设计。在 AI 服务器中，它是负责启动系统、运行操作系统并向 GPU 供给数据的主机。*另见：* 主机 CPU、GPU、超级芯片。

Credit-based flow control（基于信用的流量控制） — InfiniBand 避免丢包的机制：只有在接收端通告有空闲缓冲区（“信用”）时，发送端才能发送。无法存储的数据一律不发，因此链路在设计上就是无损的。*另见：* InfiniBand、PFC（基于优先级的流量控制）。

cuBLAS — 英伟达的 GPU 基础线性代数例程库，核心是矩阵乘法（GEMM）。大多数 AI 框架都把大型矩阵乘法交由它执行。*另见：* GEMM、CUTLASS。

CUDA — 英伟达于 2006 年推出的编程平台（语言扩展、编译器、运行时、驱动和库），让开发者能在 GPU 上运行通用代码。是英伟达软件护城河的基础。*另见：* CUDA-X。

CUDA core（CUDA 核心） — 英伟达对 SM 中简单算术通道的称呼，每个时钟周期执行一次标量运算（例如一次 32 位乘加）。数以千计的 CUDA 核心负责通用并行代码；矩阵运算则交由张量核心处理。*另见：* 流式多处理器（SM）、张量核心。

CUDA Graphs — CUDA 的一项功能：将一系列内核启动录制一次，之后以单次启动整体重放，从而降低 CPU 的启动开销——这对小而频繁的推理步骤很重要。*另见：* CUDA 流、GPU 内核。

CUDA stream（CUDA 流） — GPU 工作（数据复制和内核启动）的有序队列。同一个流内的工作按顺序执行；不同的流可以重叠执行，从而把数据传输隐藏在计算之后。*另见：* CUDA Graphs。

CUDA-Q — 英伟达面向量子-经典混合程序的开放平台和编译器，程序可跨量子处理器、GPU 和 CPU 运行。*另见：* cuQuantum。

CUDA-X — 英伟达对其基于 CUDA 构建的数百个领域库（cuBLAS、cuDNN、NCCL、RAPIDS 等）的统称。*另见：* CUDA。

cuDF — RAPIDS 的 GPU 数据框（dataframe）库：类似 pandas 的表格引擎，也为 Spark、Polars 和 Dask 提供 GPU 后端。*另见：* RAPIDS、数据框。

cudf.pandas — cuDF 的一种模式，可加速未经修改的 pandas 代码：GPU 支持的操作在 GPU 上运行，其余操作回退到 CPU 上的普通 pandas。*另见：* cuDF、零代码改动加速。

cuDNN — 英伟达经调优的深度学习内核库（卷积、注意力、归一化），2014 年首次发布。各框架直接调用它，而无需自行编写 GPU 代码。*另见：* CUDA-X、GPU 内核。

cuFFT — 英伟达的快速傅里叶变换库，用于信号处理、成像、地震分析和物理计算程序。*另见：* cuBLAS。

cuGraph — RAPIDS 的 GPU 图分析库（PageRank、最短路径、社区发现），适用于拥有数十亿条边的网络。*另见：* RAPIDS。

cuLitho — 英伟达的计算光刻库：完成为光掩模图形塑形的繁重计算，使芯片能被正确印制。台积电于 2024 年与新思科技（Synopsys）将其投入生产。*另见：* 计算光刻。

cuML — RAPIDS 的 GPU 机器学习库（随机森林、聚类、UMAP 等）。其 cuml.accel 模式可在 GPU 上运行未经修改的 scikit-learn 代码。*另见：* RAPIDS、零代码改动加速。

cuOpt — 英伟达用于线性规划和车辆路径规划的 GPU 优化引擎，2025 年以 Apache 2.0 许可开源。*另见：* 线性规划。

cuQuantum — 英伟达在 GPU 上模拟量子计算机的库（态矢量法和张量网络法），用于开发和测试量子算法。*另见：* CUDA-Q。

cuRAND — 英伟达的随机数生成库，用于蒙特卡洛模拟、风险模型以及神经网络的随机初始化。*另见：* cuBLAS。

cuSPARSE — 英伟达用于稀疏矩阵（大部分元素为零）线性代数运算的库，用于仿真、图分析和推荐模型。*另见：* cuBLAS。

Customer concentration（客户集中度） — 来自少数大客户的收入占比。集中度高意味着这些买家拥有议价能力，且收入对其中任何一家更换供应商都十分敏感。*另见：* 直接客户与间接客户。

Customer-owned tooling (COT)（客户自有工具模式） — 一种定制芯片模式：客户自己承担更多设计工作，只采购特定服务或 IP，再直接与晶圆代工厂签约；这会压低合作伙伴的单位利润率。*另见：* 交钥匙 ASIC、NRE（一次性工程费用）。

CuTe — CUTLASS 3 和 4 核心的布局与张量抽象。它描述数据如何在线程和内存之间分块；自 CUTLASS 4 起也以 Python 领域专用语言（DSL）形式提供。*另见：* CUTLASS、DSL（领域专用语言）。

CUTLASS — 英伟达开源的 CUDA C++ 模板集合，用于构建定制的高性能矩阵乘法及相关内核，在现成的 cuBLAS 例程不适用时使用（新数值格式、融合操作）。*另见：* cuBLAS、CuTe。

cuVS — 英伟达用于向量搜索（查找最近邻嵌入向量）和聚类的 GPU 库，已内置于 Faiss、Milvus 等向量数据库中。*另见：* 向量搜索、RAPIDS。

CXL (Compute Express Link) — 一种运行在 PCIe 线路之上的开放标准，增加了缓存一致的内存访问，使 CPU 能使用内存扩展器或与加速器共享内存。它是 NVLink-C2C 等专有一致性互连的开放标准替代方案。*另见：* PCIe (PCI Express)、缓存一致性。

D

Data center (NVIDIA segment)（数据中心分部） — 英伟达针对销往数据中心的 AI 和 HPC 产品设立的报告分部，分为计算（GPU、系统）和网络（NVLink、InfiniBand、以太网、网卡、DPU）两部分。

Data loader（数据加载器） — 通常在主机 CPU 核心上运行的软件管线，负责从存储读取训练样本、进行解码和数据增强，再把批数据交给 GPU。若其速度慢于 GPU，GPU 就只能空等。*另见：* GPU 饥饿、NVIDIA DALI。

Data parallelism (DP)（数据并行） — 在多块 GPU 上进行训练：每块 GPU 持有完整的模型副本、处理批次中不同的切片，并在每一步通过全规约对梯度求平均。*另见：* 全规约、ZeRO（零冗余优化器）、FSDP。

Dataflow architecture（数据流架构） — 一种芯片设计：由编译器把模型的运算映射到计算与存储单元构成的网格上，数据在各单元之间流动，而不是由处理器逐条读取指令执行。SambaNova 的 RDU 即为一例。*另见：* SRAM、ASIC。

Dataframe（数据框） — 驻留在内存中、由行和具名列组成的表格，是 pandas、Polars 和 Spark 的基本数据结构。*另见：* cuDF、ETL。

Day-0 support（首日支持） — 新模型发布当天，能否在某款芯片及其软件栈上良好运行。厂商之间软件成熟度的差距在这一点上体现得最为明显。*另见：* vLLM、GPU 内核。

DCGM (Data Center GPU Manager)（数据中心 GPU 管理器） — 英伟达开源的守护进程和工具集，用于监控和管理数据中心 GPU：健康检查、诊断、错误告警和功耗策略，并将数据输出给调度器和 Kubernetes。*另见：* 网络遥测、SM 利用率。

Decode (generation phase)（解码） — 推理请求的第二阶段：逐个生成输出 token，每生成一个都需要完整读取一遍模型权重。受内存带宽限制。*另见：* 预填充（prefill）、TPOT/ITL。

Decode ceiling（解码速度上限） — 解码阶段内存带宽所能支撑的最高每秒 token 数：带宽除以每个 token 需读取的字节数。一个 70B 参数的 FP8 模型，在 H100 上每个流的上限约为 48 tokens/s，在 Rubin 上约为 274。*另见：* 每 token 字节数、解码（decode）、内存墙。

Deep Learning Institute（深度学习学院） — 英伟达的培训部门（DLI），提供有关 GPU 编程和 AI 的付费及免费课程、讲师指导的工作坊和认证，通常通过高校和合作伙伴开展。*另见：* 开发者关系。

Deep-buffer switch（深缓冲交换机） — 配备大容量数据包缓存（通常为 HBM）的交换芯片，如博通 Jericho 或思科（Cisco）P200，能够吸收长距离链路上的突发流量。用于数据中心之间的跨数据中心扩展（scale-across）以及调度式 AI 网络。*另见：* 跨数据中心扩展（scale-across）。

Defect density (D0)（缺陷密度） — 晶圆上每平方厘米随机致命缺陷的平均数量，是晶圆厂工艺的关键质量指标。良率大致随“裸片面积 × 缺陷密度”呈指数下降。*另见：* 裸片良率。

Dense vs. sparse FLOPS（稠密与稀疏 FLOPS） — 厂商常引用“稀疏”峰值吞吐量，它假定采用 2:4 结构化稀疏（一半权重为零），恰为稠密数值的两倍。实际模型很少以稀疏方式运行，因此本资料库采用稠密数值。*另见：* 2:4 结构化稀疏、FLOPS。

Design win（设计导入） — 客户承诺在某一代具体产品中采用某供应商的芯片或设计服务。在定制芯片领域，它标志着一个多年期项目的开始，但尚未形成收入。*另见：* ASIC 设计合作伙伴、流片。

Developer relations（开发者关系） — 平台型公司为赢得并留住软件开发者而开展的各类项目：免费工具和库、文档、培训、会议和技术支持。对英伟达而言，它培养了开发者使用 CUDA 的习惯，从而抬高了客户的转换成本。*另见：* CUDA、NVIDIA Inception。

DGX — 英伟达自有品牌的 AI 系统（2016 年的 DGX-1，此后有 DGX-2、DGX A100、DGX H100 以及 DGX 机架系统），既直接销售，也经合作伙伴销售；同时充当英伟达的参考设计。*另见：* HGX、超节点。

DGX Cloud — 英伟达自营的 GPU 云服务（2023 年），托管在甲骨文、微软、谷歌和 AWS 的数据中心内、由英伟达租用的容量之上。据报道，其大部分容量已于 2025 年转用于英伟达内部研究。*另见：* DGX Cloud Lepton、新兴云服务商（neocloud）。

DGX Cloud Lepton — 英伟达的算力交易平台（2025 年），把开发者引导至 CoreWeave、Lambda、Nebius 和 Crusoe 等合作云厂商所拥有的 GPU 容量；英伟达本身不拥有这些硬件。*另见：* DGX Cloud、GPU 交易平台。

Die（裸片） — 从晶圆上切割下来的单块硅片。Blackwell 等现代 AI GPU 在一个封装内放置两颗（Rubin Ultra 为四颗）计算裸片。*另见：* GPU、光罩尺寸极限。

Die harvesting（裸片降级利用） — 将含有缺陷的裸片屏蔽其故障模块（例如几个流式多处理器）后，作为规格略低的型号出售。这提高了大型 GPU 的有效良率。*另见：* 裸片良率。

Die yield（裸片良率） — 晶圆上可正常工作的裸片所占比例。裸片越大良率越低，因为每颗裸片含有缺陷的可能性更大，这使大型 GPU 的成本不成比例地升高。*另见：* 缺陷密度（D0）、裸片降级利用。

Die-to-die interconnect（裸片间互连） — 同一封装内裸片之间极短、极宽的连接，使它们能像一颗芯片那样协同工作。英伟达 Blackwell 的两颗计算裸片之间采用 10 TB/s 的互连（NV-HBI）。*另见：* 芯粒、NVLink。

Dies per wafer（每片晶圆裸片数） — 一片晶圆上可容纳的完整裸片数量。这是一个几何计算，取决于裸片面积以及圆形晶圆边缘损失的不完整裸片。在 300 mm 晶圆上，814 mm^2 的 GPU 裸片约为 63 颗。*另见：* 裸片、裸片良率。

Digital twin (datacenter)（数字孪生） — 以物理精度模拟数据中心（供电、散热、气流、机架）的软件模型，用于在施工前进行设计和测试；英伟达的 Omniverse DSX 蓝图即为一例。*另见：* AI 工厂。

Dilution（稀释） — 公司发行新股（例如为支付收购对价或结算认股权证）时，原有股东持股比例的下降。*另见：* 认股权证。

Direct vs indirect customer（直接客户与间接客户） — 在英伟达的财报中，直接客户是直接向英伟达采购的客户（主要是 OEM 和 ODM）；间接客户（如云服务商或 AI 实验室）则从直接客户处购买整机系统。英伟达披露收入占比超过 10% 的直接客户，并对大型间接客户作出估计。*另见：* 客户集中度、OEM、ODM。

Direct-attach copper (DAC)（直连铜缆） — 两端带连接器、内部没有任何电子器件的无源铜缆。几乎不耗电、极少故障，但在每通道 200 Gb/s 的速率下，无源铜缆的传输距离仅约一米。*另见：* NVLink 线缆背板、有源电缆（AEC）、共封装光学（CPO）。

Direct-to-chip liquid cooling（直触芯片液冷） — 让液体流经安装在发热最高的芯片（GPU、CPU、交换芯片）上的冷板，从源头带走大部分热量；剩余热量由风扇或后门换热器处理。*另见：* 冷板、冷却液分配单元（CDU）、液冷。

Direct3D — 微软面向 Windows 的 3D 图形编程接口（DirectX 的组成部分）；它以三角形为标准图元，使围绕其他图元设计的芯片无法兼容大多数游戏。*另见：* 固定功能管线。

Disaggregated serving（分离式推理服务） — 将 LLM 推理的预填充（prefill，读取提示词）和解码（decode，生成 token）两个阶段放在不同的 GPU 池上运行，并在二者之间传送 KV 缓存；由英伟达 Dynamo 负责编排。*另见：* KV 缓存。

Dispatch and combine（分发与合并） — 每个混合专家层的两个通信步骤：分发（dispatch）将每个 token 的激活值发送到持有其所选专家的 GPU；合并（combine）将专家输出发回并求和。二者共同构成一次全交换。*另见：* 混合专家模型（MoE）、全交换、专家并行（EP）。

DOCA — 英伟达面向 BlueField DPU 和 SuperNIC 的软件开发工具包和运行时，是 DPU 领域与 CUDA 相对应的平台。*另见：* 数据处理器（DPU）。

Domestic substitution（国产替代） — 中国以本土芯片替代外国芯片的政策，例如引导国资背景的数据中心采用国产 AI 加速器。*另见：* 出口管制、华为昇腾。

Dominant resource fairness（主导资源公平） — 适用于拥有多种资源（GPU、CPU、内存）集群的公平分配规则：每个团队的份额按其使用最多的那种资源来衡量，因此任何团队都无法通过囤积某一种资源来挤占其他团队。*另见：* 抢占。

Double ordering（重复下单） — 短缺期间，买家为确保拿到配额而向多家供应商下同样的订单，或超出实际需要下单；供应跟上后多余订单随即消失，因而可能让需求显得比实际更强。*另见：* 供给受限。

DPU (data processing unit)（数据处理器） — 自带处理器核心和加速器的网卡，负责运行网络、存储和安全软件，从而为服务器的主 CPU 免去这些负担。*另见：* SuperNIC、SmartNIC、IPU（基础设施处理器）。

DRAM (dynamic random-access memory)（动态随机存取存储器） — 计算机的主流内存技术：每个比特以电荷形式存储在一个微小电容中，每秒须刷新多次。HBM、DDR、LPDDR 和 GDDR 都是 DRAM，只是封装和连接方式不同。*另见：* 高带宽内存（HBM）、LPDDR、GDDR。

DSL (domain-specific language)（领域专用语言） — 为单一任务设计的小型编程语言。CuTe DSL、Triton 和 Mojo 都是无需完整 C++ 即可编写 GPU 内核的 DSL。*另见：* CuTe、Triton (OpenAI)。

DSX OS — 英伟达于 2026 年推出的开放、模块化软件组合，用于运营多租户 AI 工厂，集成了 KAI Scheduler、Run:ai、Cloud Functions、Grove 和 Dynamo 等组件。*另见：* NVIDIA Mission Control、Run:ai。

DualPipe — DeepSeek 的流水线并行调度方案，将不同微批次的前向和反向计算与专家并行的全交换通信相互重叠，在带宽受限的 H800 集群上隐藏了大部分网络时间。*另见：* 流水线并行（PP）、专家并行（EP）、全交换。

DUV multi-patterning（DUV 多重曝光） — 通过对同一层进行多次曝光，印制出深紫外（DUV）光刻机单次曝光无法分辨的精细图形。这使中芯国际（SMIC）能在没有 EUV 的情况下制造 7 nm 级芯片，但良率更低、成本更高。*另见：* EUV 光刻、光刻。

Dynamo — 英伟达开源（Apache 2.0）、位于推理服务引擎之上的软件层，可把一个模型分布到大量 GPU 上运行：它将预填充与解码分离，把请求路由到已持有相应 KV 缓存的 GPU，并把缓存卸载到更便宜的存储层。1.0 版于 2026 年 3 月发布。*另见：* 分离式推理服务、KV 缓存。

E

Earn-out（业绩对赌付款） — 收购价款中延后支付的部分，仅在被收购业务达成约定里程碑（如收入目标）时才支付。用于弥合买卖双方的估值分歧，例如美满电子收购 Celestial AI 时即采用此安排。*另见：* 收购式招聘。

Earth-2 — 英伟达面向 AI 天气与气候模型以及地球数字孪生的平台；Earth2Studio 是其开源 Python 软件包。*另见：* Omniverse。

East-west traffic（东西向流量） — 数据中心内部服务器之间的流量（例如 GPU 之间的梯度交换），与进出数据中心的流量相对。AI 训练以东西向流量为主。*另见：* 南北向流量、后端网络。

ECMP (equal-cost multipath)（等价多路径） — 以太网的标准负载均衡方式，把每条流哈希到若干条等长路径之一。大型 AI 流可能挤在同一条路径上，而其他路径闲置，造成带宽浪费。*另见：* 自适应路由、数据包喷洒。

ECN (Explicit Congestion Notification)（显式拥塞通知） — 交换机在队列开始积压时在数据包中置位的一个比特。接收端将其回传，发送端随即降速，从而在不暂停链路的情况下避免丢包。*另见：* 拥塞控制。

Economic life（经济寿命） — 硬件创造的收入持续高于其现金运营成本的时长。当新一代芯片使 token 成本大幅下降时，经济寿命可能短于会计上的使用寿命，这正是 GPU 折旧看空情景的核心论点。*另见：* 使用寿命、残值、一年一代节奏。

EDA (electronic design automation)（电子设计自动化） — 用于设计和验证芯片的软件，涵盖从逻辑综合到物理版图和签核的全流程；新思科技（Synopsys）和楷登电子（Cadence）占据主导地位。每个新芯片项目都要支付 EDA 授权费，英伟达持有新思科技 $2B 的股份。*另见：* 流片、NRE（一次性工程费用）。

Edge-to-cloud continuity（端云一体） — 在终端设备、边缘服务器和云端机架上运行同一模型家族、文件格式和工具链，使工作负载能在各层级之间迁移而无需重写。这是在每个层级都拥有芯片的厂商的卖点。*另见：* 混合 AI、NPU（神经网络处理器）。

EFA (Elastic Fabric Adapter) — AWS 面向 HPC 和 AI 实例的网络接口，基于 Nitro 卡和 SRD 传输协议构建，而非 InfiniBand 或标准 RoCE。*另见：* SRD、AWS Nitro、数据包喷洒。

Effective training time（有效训练时间） — 训练运行的挂钟时间中，扣除故障、重启以及从上一个检查点起重算所损失的时间之后，真正用于推进训练的时间占比。Meta 报告 Llama 3 的这一比例超过 90%。*另见：* 有效吞吐量、检查点。

Efficiency shock（效率冲击） — 新的模型架构、训练方法或软件导致单位 AI 产出所需算力（进而成本）骤降。它最终是减少还是增加总算力支出，取决于需求的价格弹性。*另见：* 杰文斯悖论、需求价格弹性。

EMIB / EMIB-T — 英特尔的嵌入式多芯片互连桥（Embedded Multi-die Interconnect Bridge）：嵌入封装基板、用于连接裸片与内存的小型硅桥，作为台积电 CoWoS 的替代方案提供；EMIB-T 增加了面向 HBM 的硅通孔（TSV）。*另见：* CoWoS、先进封装。

EMS (electronics manufacturing services)（电子制造服务） — 按照其他公司的设计制造电子产品的代工厂商（例如 Sanmina、天弘（Celestica）、富士康）。在 AI 服务器领域，EMS 厂商和 ODM 以微薄的利润承担机架的组装和测试。*另见：* ODM、OEM。

Engineer-year（工程师人年） — 一名工程师工作一年；衡量软件工作量的标准单位。用工程师人年乘以每名工程师的全口径成本，即可得出以美元计的估算。*另见：* 软件移植版。

Entity List（实体清单） — 美国商务部发布的外国企业名单，名单上的企业须获许可才能获得原产于美国的技术。华为、中芯国际和多家中国 GPU 设计公司均在其列。*另见：* 出口管制、BIS（工业与安全局）。

Equity-for-capacity（股权换产能） — 将股权与采购承诺绑定的交易：要么由供应商向客户授予股权（AMD 向 OpenAI 发行的认股权证），要么由供应商购买客户的股权（英伟达对 OpenAI 的投资），使供需双方共享扩建带来的上行收益。*另见：* 认股权证、供应商融资、循环融资。

ESUN (Ethernet for Scale-Up Networking) — 开放计算项目（OCP）于 2025 年启动的工作组，定义如何通过以太网交换机承载纵向扩展（scale-up）流量，包括采用精简报头以降低开销。它以博通贡献的 Scale-Up Ethernet 规范为基础。*另见：* Scale-Up Ethernet（SUE）、UALink (Ultra Accelerator Link)、超以太网（UEC）。

ETL (extract, transform, load)（抽取、转换、加载） — 数据准备工作：从各数据源提取原始数据、进行清洗和关联，再加载到数据仓库或训练集中；往往是企业最大的一笔数据分析开支。*另见：* Apache Spark、数据框。

EUV lithography（EUV 光刻） — 极紫外光刻：使用 13.5 nm 波长的光进行曝光，使最精细的层能一次曝光完成，而不必多次曝光。EUV 光刻机仅由 ASML 制造；高数值孔径（High-NA）EUV 是下一代技术，其曝光视场仅为现有的一半。*另见：* 光刻、高数值孔径 EUV。

Expert parallelism (EP)（专家并行） — 将混合专家模型的不同专家放在不同 GPU 上，因此在每个 MoE 层，token 都须通过全交换发送至所选专家并返回。*另见：* 混合专家模型（MoE）、全交换。

Export controls（出口管制） — 政府要求向境外销售特定技术须取得许可证的规定。美国关于先进 GPU 的规定决定了哪些国家和买家能获得英伟达的顶级芯片，以及数量多少。*另见：* 主权 AI。

Export revenue share（出口收入分成） — 一种许可条件，出口商须将部分销售收入上缴美国政府：H20 对华销售为 15%（2025 年 8 月），H200 对华销售为 25%（2025 年 12 月）。*另见：* 出口管制。

External laser source（外置激光光源） — 在 CPO 设计中，激光器位于前面板上独立、可更换的模块内，通过光纤向光引擎供光；因为激光器是最容易失效的部件，而且不耐交换芯片旁边的高温。*另见：* 共封装光学（CPO）。

F

fabless（无晶圆厂） — 自行设计半导体、但付费委托台积电等晶圆代工厂制造的芯片公司；英伟达自成立以来一直采用无晶圆厂模式。*另见：* 晶圆代工厂。

Facility capex（设施资本开支） — IT 设备之外的建筑、电力设施、冷却系统和土地支出，通常按每兆瓦电力计（据本资料库估计，新建 AI 机房约为每兆瓦 $11-13M）。其使用寿命长于内部的服务器。*另见：* AI 工厂、PUE（电能使用效率）、通电时间。

Falcon (transport)（Falcon 传输协议） — 谷歌面向数据中心以太网的硬件辅助网络传输协议，于 2023 年贡献给开放计算项目（OCP）；英特尔 IPU E2000 是其首个硬件平台。*另见：* IPU（基础设施处理器）。

Fat tree (Clos network)（胖树） — 一种多层交换拓扑，越往上层链路越“胖”，使任意端点之间都能全速通信。使用端口数（radix）为 R 的交换机时，两层可连接 $R^2/2$ 个端点，三层可连接 $R^3/4$ 个。*另见：* 交换机端口数、对分带宽、超额订阅。

Fatbinary（胖二进制） — CUDA 应用程序随附的二进制包：包含针对构建时所面向的每一代 GPU 的 SASS 机器码，外加 PTX——新版驱动可将 PTX 编译到构建时尚不存在的 GPU 上。*另见：* PTX (Parallel Thread Execution)、JIT 编译。

Feynman — 英伟达计划于 2028 年推出的 GPU 架构，发布时展示的配套组件包括 Rosa CPU、LP40 解码芯片、BlueField-5、ConnectX-10，以及混用铜缆与共封装光学的 Kyber NVL1152 机架；规格尚未公布。*另见：* Rubin Ultra、共封装光学（CPO）。

fixed-function pipeline（固定功能管线） — 早期图形芯片的设计方式：每个渲染阶段都是只有少量可调设置的硬连线电路，而不是运行程序的处理器。*另见：* 可编程着色器。

FlashAttention — 一系列注意力内核（从 2022 年的 v1 到 2026 年的 v4），在片上存储中分块计算注意力，而不把完整的注意力矩阵写入 HBM。每个版本都最先为英伟达 GPU 编写。*另见：* 注意力机制、GPU 内核。

FLOPS（每秒浮点运算次数） — Floating-point operations per second（每秒浮点运算次数）：芯片执行算术运算的速率。引用时须注明数值格式（FP64、BF16、FP8、FP4）以及是稠密还是稀疏峰值；1 PFLOPS = 每秒 10^15 次运算。“FLOPs”（小写 s）表示运算次数，而非速率。*另见：* 张量核心。

Flywheel（飞轮） — 一组相互强化的循环，每转一圈都让下一圈更容易，从而随时间积累动能。本资料库中，英伟达的飞轮包含四个循环（开发者、规模/研发、全栈、资本），它们共用一个中枢：收入与毛利。*另见：* 装机量、循环融资。

Forward P/E（远期市盈率） — 股价除以未来十二个月或下一财年的预期每股收益（等同于市值除以预期净利润）。*另见：* 反向 DCF。

Forward pass（前向传播） — 将输入依次通过模型的每一层以产生预测。成本约为每个参数每个 token 2 次浮点运算。*另见：* 反向传播、激活值。

Foundry（晶圆代工厂） — 制造他人所设计芯片的公司（台积电、三星代工、英特尔代工、中芯国际）。英伟达、AMD、谷歌和高通均为“无晶圆厂”企业：它们设计芯片，并向晶圆代工厂采购晶圆。*另见：* 晶圆、OSAT（外包封测）。

Foveros — 英特尔的 3D 封装技术，将逻辑裸片面对面堆叠。与 EMIB 一起作为台积电封装的替代方案，面向多裸片 AI 芯片提供。*另见：* EMIB / EMIB-T、先进封装、混合键合。

FP16 (half precision)（半精度） — 一种 16 位浮点格式，含 5 位指数和 10 位尾数。其精度高于 BF16，但数值范围窄得多，因此以 FP16 训练需要损失缩放（loss scaling）；它已基本被 BF16 取代。*另见：* BF16 (bfloat16)、FP8、混合精度训练。

FP32 (single precision)（单精度） — 32 位浮点格式（8 位指数，23 位尾数）。AI 训练将主权重和许多累加运算保留为 FP32，而大部分矩阵运算以更低精度完成。*另见：* BF16 (bfloat16)、混合精度训练、FLOPS。

FP4 — 一种 4 位浮点格式（1 位符号、2 位指数、1 位尾数），只能表示从 0 到 6 的八个量级；必须搭配 MXFP4 或 NVFP4 等块缩放因子才能使用。*另见：* NVFP4、微缩放（MX）格式。

FP8 — 一种 8 位（1 字节）浮点格式，自 Hopper 起获得张量核心支持。与 BF16 相比，它使内存占用减半、张量吞吐量约翻倍，但需谨慎处理以保持精度。*另见：* BF16 (bfloat16)、NVFP4。

Fractional GPU（GPU 切分） — 通过硬件分区（MIG）、空间共享（MPS）或时间片轮转，为作业分配不足一整块的 GPU。它能提高 notebook、轻量推理等小型作业的利用率，代价是隔离性有所削弱。*另见：* MIG（多实例 GPU）、GPU 时间片轮转。

Free cash flow（自由现金流） — 经营现金流减去资本开支：公司产生的、可用于回报股东、进行收购或投资其他公司的现金。

Free-chip test（免费芯片测试） — 一个思想实验：即便竞争对手的加速器系统完全免费，其每 token 成本是否仍高于按全价购买的英伟达系统？只有当吞吐量差距大于芯片资本开支在总成本中的占比时，这一结论才成立。*另见：* 每百万 token 成本、自有 TCO。

Front-end network（前端网络） — 连接服务器与存储、用户、管理系统和互联网的传统数据中心网络。*另见：* 后端网络。

Frontier lab（前沿实验室） — 训练规模最大的通用 AI 模型的公司（例如 OpenAI、Anthropic、xAI、谷歌 DeepMind）；每家都以吉瓦级规模采购算力。

FSDP (Fully Sharded Data Parallel)（完全分片数据并行） — PyTorch 内置的完全分片数据并行实现（ZeRO 第 3 阶段风格）：权重在使用前即时全收集，梯度在计算后进行规约散射。*另见：* ZeRO（零冗余优化器）、全收集、规约散射。

Full-stack merchant（全栈商用供应商） — 向任何买家出售完整 AI 系统（芯片、互连、机架和软件）的厂商。英伟达是典型代表；AMD 正借助 Helios 和 ROCm 朝这一方向发展。*另见：* 商用芯片、垂直整合。

Fused multiply-add (FMA)（融合乘加） — 一步完成 a × b + c 计算的单条运算，计为两次浮点运算。矩阵乘法几乎完全由 FMA 构成。*另见：* FLOPS、GEMM。

G

Gang scheduling（成组调度） — 让分布式作业的所有部分同时启动、否则一个都不启动，避免 1,000 块 GPU 闲置等待第 1,001 块。Slurm、Kueue 和 KAI Scheduler 等调度器均支持此功能。*另见：* Slurm、Kubernetes。

Gap trend（差距趋势） — 在某一层中，英伟达相对最强挑战者的领先优势在过去约十二个月内是在扩大、持平还是收窄，以该层竞争页面的判断为准。*另见：* 护城河评分。

Gate-all-around (GAA)（全环绕栅极） — 一种晶体管结构，栅极从四面包围堆叠的硅纳米片，与较早的 FinFET 相比可降低漏电。台积电 N2 是其首个 GAA 节点。*另见：* 工艺节点。

GDDR (graphics DRAM)（图形 DRAM） — 焊接在电路板上、环绕处理器分布的图形内存芯片。比 HBM 更便宜、更简单，但每瓦和每平方毫米的带宽要低得多；英伟达的数据中心 GPU 在 P100 之前一直采用它。*另见：* 高带宽内存（HBM）、LPDDR。

GEMM (general matrix multiply)（通用矩阵乘法） — 占神经网络绝大部分算术运算的矩阵乘法操作。大型 GEMM 具有很高的算术强度，可接近 GPU 的峰值 FLOPS 运行。*另见：* 张量核心、算术强度。

Gigawatt of compute（吉瓦算力） — 如今衡量 AI 基础设施交易规模的单位：加速器、服务器和网络设备所消耗的电力（1 GW ≈ 数十万块当前一代 GPU）。买家以电力作为承诺单位，因为真正的约束是电力和场地，而非芯片。*另见：* AI 工厂、签约电力与在用电力。

Global systems integrator (GSI)（全球系统集成商） — 为企业设计、建设和运营技术项目的大型 IT 服务公司（例如埃森哲（Accenture））。客户部署哪些硬件和软件，很大程度上由 GSI 决定。*另见：* OEM、渠道合作伙伴。

Gloo — Meta 开源的集合通信库，是 PyTorch 的一个后端，主要用于 CPU 张量，并在 NCCL 不可用时充当备选。*另见：* NCCL。

Goodput（有效吞吐量） — 系统扣除各类损失后的有效产出：在训练中，指真正推进模型训练的 GPU 小时占比；在推理服务中，指仍能满足延迟目标的吞吐量。*另见：* MFU（模型 FLOPs 利用率）、检查点。

GPGPU (general-purpose GPU computing)（通用 GPU 计算） — 将图形芯片用于物理、金融或神经网络等非图形计算。在 CUDA 出现之前，这意味着要把计算伪装成像素着色任务。*另见：* CUDA、Brook。

GPU (graphics processing unit)（图形处理器） — 拥有数千个简单核心、可同时对大量数据执行同一条指令的处理器，非常适合神经网络核心的矩阵乘法。在本资料库中，“GPU”通常指客户购买的整个封装（例如一块 B200），其中可能包含不止一颗裸片。*另见：* 裸片、张量核心。

GPU fragmentation（GPU 碎片化） — 空闲 GPU 零散分布在许多服务器或机架上，每处的数量都太少，无法容纳下一个作业。集群看似部分空闲，大型作业却无法启动。*另见：* 装箱式调度、拓扑感知调度。

GPU kernel（GPU 内核） — 在数千个 GPU 线程上同时运行的小型函数，例如一次矩阵乘法或一个注意力步骤。框架把数千个内核串联成一个模型；内核的速度决定了模型的运行速度。*另见：* CUDA、cuDNN。

GPU marketplace（GPU 交易平台） — 汇集众多供应商的 GPU 容量、供买家按小时或按周租用的平台（例如 Vast.ai、SF Compute 或英伟达的 Lepton）。它们以价格和灵活性而非服务取胜。*另见：* DGX Cloud Lepton、新兴云服务商（neocloud）。

GPU starvation（GPU 饥饿） — 由于主机无法足够快地供给数据、启动内核或返回工具调用结果，GPU 处于闲置状态；表现为 GPU 利用率偏低，尽管 GPU 本身并非瓶颈。*另见：* 数据加载器、主机 CPU。

GPU time-slicing（GPU 时间片轮转） — 让多个工作负载轮流使用同一块 GPU。成本低、灵活，但没有内存或故障隔离：一个工作负载崩溃，共享该 GPU 的所有工作负载都会随之宕掉。*另见：* GPU 切分、MIG（多实例 GPU）。

GPU-backed loan（GPU 抵押贷款） — 以 GPU 集群及将其对外出租的客户合同作抵押的债务，通常随硬件交付分批提款（延迟提款定期贷款）。贷方的风险取决于合同质量和 GPU 的转售价值。*另见：* 照付不议合同、新兴云服务商（neocloud）。

GPU-hour（GPU 小时） — 一块 GPU 使用（或租用）一小时：GPU 云为容量定价、以及衡量利用率经济性所用的单位。*另见：* 总拥有成本（TCO）。

GPU-initiated networking（GPU 发起的网络通信） — 让 GPU 内核自行发起网络传输，而不必等待 CPU 代劳；NCCL 2.28 加入了这一功能（GIN），以降低 MoE 和推理流量的延迟。*另见：* NCCL、RDMA（远程直接内存访问）。

GPUDirect RDMA — 英伟达的一项功能，使网卡能直接读写 GPU 显存，省去经由 CPU 内存的一次复制。*另见：* RDMA（远程直接内存访问）。

GPUDirect Storage — 英伟达的一项技术，在存储（本地 NVMe 或经网络访问的存储）与 GPU 显存之间直接传输数据，绕过经由 CPU 内存的一次复制。*另见：* RDMA（远程直接内存访问）。

Gradient（梯度） — 对每个参数而言，能够降低损失的调整方向和幅度。每个训练步骤都要对所有 GPU 的梯度求平均。*另见：* 反向传播、全规约。

Graphics processing cluster (GPC)（图形处理簇） — 共享部分调度和路由硬件的一组 SM。Rubin 有 8 个 GPC，共含 224 个 SM；Hopper 的 H100 在其各 GPC 中共启用 132 个 SM。*另见：* 流式多处理器（SM）。

Graviton — AWS 自研的 Arm 服务器 CPU 产品线（由 Annapurna Labs 设计），2018 年首发；Graviton5（2026 年）拥有 192 个核心。*另见：* Annapurna Labs、Neoverse。

Grid (CUDA)（CUDA 网格） — 一次内核启动所创建的全部线程块。硬件在 SM 空闲时将线程块分派给它们，这使同一份代码能在不同规模的 GPU 上扩展。*另见：* 线程块、GPU 内核。

Gross margin（毛利率） — 收入减去销售成本后占收入的比例。2026 年年中英伟达的 GAAP 毛利率约为 75%；据估计，单看 GPU 芯片本身的毛利率接近 80%。*另见：* 物料清单。

Grouped-query attention (GQA)（分组查询注意力） — 一种注意力设计：多个查询头共享一个键/值头，在质量损失很小的情况下缩小 KV 缓存（Llama 3.1 70B 缩小 8 倍）。*另见：* KV 缓存、多头潜在注意力（MLA）。

Grove — 英伟达 Dynamo 项目中的开源 Kubernetes API，把由多个组件构成的整个推理系统描述为一个资源，并以分层成组调度和拓扑感知放置对其进行调度。*另见：* Dynamo、成组调度。

GTC — 英伟达 GPU 技术大会（GPU Technology Conference）。每年春季在圣何塞举办的大会（2009 年首届）是英伟达发布路线图主题演讲和合作伙伴新品的主要窗口；年内还在其他地区举办区域性大会。*另见：* 开发者关系。

H

H20 — 面向中国市场的 Hopper GPU（2024 年），算力远低于 H100，但 HBM 容量不减，旨在符合 2023 年 10 月的出口规则；2025 年 4 月起被纳入美国出口许可证管理。*另见：* 出口管制、H800。

H800 — 面向中国市场的英伟达 H100 版本（2023 年），算力相同但 NVLink 带宽被削减，旨在符合 2022 年 10 月的美国出口规则；自 2023 年 11 月起其本身也受到限制。DeepSeek-V3 即使用 2,048 块 H800 训练而成。*另见：* 出口管制、H20、NVLink。

Hardware plugin（硬件插件） — 单独维护的后端，使 vLLM 等推理服务引擎无需修改核心代码即可在新加速器上运行。*另见：* vLLM。

Hardware pull-through（硬件拉动） — 间接变现免费软件：免费提供软件，以促使客户购买更多在其上运行效果最佳的硬件。CUDA 是英伟达最主要的例子。*另见：* CUDA、转换成本。

Hardware root of trust（硬件信任根） — 芯片上一个小型、不可篡改的安全模块，保存身份密钥并在启动时验证固件；信任链中的其他一切都以它为基准进行校验。*另见：* 远程证明。

HBM (high-bandwidth memory)（高带宽内存） — 堆叠式 DRAM，经由硅中介层放置在距 GPU 仅数毫米处，并以极宽的总线连接，提供每秒数 TB 的带宽。HBM 的容量和带宽往往比原始算力更能制约 AI 性能。*另见：* CoWoS、内存墙。

HBM base die（HBM 基础裸片） — HBM 堆栈最底层的逻辑裸片，负责与 GPU 通信并管理其上方的 DRAM 层。从 HBM4 起可采用逻辑工艺制造（例如台积电 N3P 或 N12），让买家可以对其进行定制。*另见：* 高带宽内存（HBM）、HBM4E、近存计算。

HBM qualification（HBM 认证） — GPU 厂商在批量采购前，在自家封装内测试供应商 HBM 堆栈的速度、发热、功耗和良率，整个过程往往历时数月。认证失败可能使供应商错过整整一代产品。*另见：* 高带宽内存（HBM）、产能分配。

HBM3E — 高带宽内存的第五代扩展版本，在 1,024 位接口上引脚速率约 8–10 Gb/s（每个堆栈约 1–1.2 TB/s），堆栈最高 12 层裸片（36 GB）。Blackwell 和 Blackwell Ultra GPU 采用的就是这种内存。*另见：* 高带宽内存（HBM）、HBM4、HBM4E。

HBM4 — 第六代高带宽内存（JEDEC 标准于 2025 年发布），将每个堆栈的接口加倍至 2,048 位，并使基础裸片转向逻辑工艺。英伟达 Rubin 和 AMD MI455X 采用的就是这种内存。*另见：* 高带宽内存（HBM）、HBM4E、HBM 基础裸片。

HBM4E — HBM4 的增强版本，预计自 2027 年起量产，引脚速率更快（目标最高约 12.8 Gb/s），堆栈最高 16 层、容量约 48-64 GB，基础裸片也越来越多地按客户定制。*另见：* 高带宽内存（HBM）、HBM 基础裸片、引脚速率。

Heat flux（热通量） — 单位面积表面散出的热量，此处指每平方厘米芯片的瓦数。热通量越高，就越需要单位体积载热量更大的冷却剂：每升水的载热量约为空气的 3,500 倍。*另见：* 直触芯片液冷。

HGX — 英伟达的标准 GPU 基板（通常为八块 GPU 加 NVLink 交换芯片），戴尔、HPE、超微（Supermicro）和联想等服务器厂商围绕它打造各自的服务器。HGX-1（2017 年）确立了这一模式。*另见：* DGX、MGX、OEM。

High Bandwidth Compute (HBC)（高带宽计算） — 高通对其 2028 年 Dragonfly AI300 推理加速器内存架构的命名，高通称其内存带宽为 AI200 的 54 倍（厂商宣称）。*另见：* 近存计算。

High-NA EUV（高数值孔径 EUV） — 下一代 EUV 光刻机，数值孔径更大（0.55），可实现更精细的图形。其变形（anamorphic）光学系统将最大曝光视场减半至约 429 mm^2，从而推动大型芯片转向多裸片设计。*另见：* EUV 光刻、光罩尺寸极限。

HIP — AMD 的 C++ GPU 编程接口，刻意设计成与 CUDA API 一一对应，使代码只需重命名调用即可移植。HIP 代码也可编译后在英伟达 GPU 上运行。*另见：* ROCm、HIPIFY。

HIPIFY — AMD 将 CUDA 源代码自动转换为 HIP 源代码的工具。它们能完成移植的大部分工作；手工调优的内核和内联 PTX 仍需人工处理。*另见：* HIP、转译层。

Host CPU（主机 CPU） — 加速服务器中的通用处理器，负责启动系统、运行操作系统、调度任务，并在 GPU 与外部之间搬运数据。*另见：* 超级芯片、NVLink-C2C。

Hot spare（热备件） — 保持通电、处于空闲状态、随时可替换故障 GPU 或节点的备用设备，使训练作业得以继续。热备件提高了可靠性，但会降低利用率。*另见：* MTBI（平均中断间隔时间）。

HPC (high-performance computing)（高性能计算） — 在超级计算机上进行的科学与工程仿真（气象、物理、化学），传统上采用 64 位精度。它是英伟达数据中心 GPU 和 InfiniBand 的第一个市场。*另见：* InfiniBand、FLOPS。

Huawei Ascend（华为昇腾） — 华为的 AI 加速器系列（910B/910C、950PR/950DT、960、970），主要在中国销售，配套 CANN 软件栈和超节点（SuperPoD）机架级系统。*另见：* CANN。

Hugging Face — 全球最大的 AI 模型、数据集和演示共享公共平台，也是广泛使用的开源模型库的开发者。英伟达于 2026 年同意收购该公司（尚待监管审查）。*另见：* Nemotron。

Hybrid AI（混合 AI） — 将 AI 推理拆分到终端设备（手机、PC、汽车）和云端：小型或涉及隐私的请求在设备的 NPU 上运行，较大的请求交给数据中心加速器。*另见：* 端云一体、推理。

Hybrid bonding（混合键合） — 不使用焊料凸块，以铜对铜、氧化物对氧化物的方式直接接合两颗裸片。它能实现更致密、更薄、散热更好的堆叠，正被考虑用于 16 层 HBM4E 及后续产品。*另见：* 微凸块、硅通孔（TSV）、堆叠层数。

Hyperscaler（超大规模云厂商） — 规模最大的云运营商之一（AWS、微软 Azure、谷歌云、Meta、甲骨文），以数十万计的规模采购加速器，并越来越多地自研芯片。*另见：* XPU（定制加速器）、新兴云服务商（neocloud）。

Hypervisor（虚拟机管理程序） — 将一台物理服务器划分为多台虚拟机的软件层；把它卸载到 DPU 或 Nitro 卡上，可释放主机 CPU 核心并强化隔离。*另见：* AWS Nitro、数据处理器（DPU）。

I

I/O die（I/O 裸片） — 多芯片封装中负责输入/输出（内存控制器、SerDes、芯片间互连）的独立裸片，使计算裸片可以采用最先进的工艺节点。设计合作伙伴可以只供应 I/O 裸片。*另见：* 芯粒、SerDes。

ICI (inter-chip interconnect)（芯片间互连） — 谷歌 TPU 之间的互连链路。每颗芯片有四条或六条 ICI 链路连接相邻芯片，构成 2D 或 3D 环面（torus）拓扑；Ironwood 有六条链路，每条 200 GB/s（双向）。*另见：* 环面拓扑、光路交换机（OCS）。

Immersion cooling（浸没式冷却） — 将整台服务器浸入不导电液体槽中（单相），或浸入会在芯片表面沸腾的液体中（两相）进行冷却。密度极高，但会改变硬件的维护和认证方式。*另见：* 直触芯片液冷、液冷。

In-network computing（网内计算） — 在网络交换机内部（而非端点上）完成简单计算，例如梯度求和。它减少了穿越网络的数据量，并释放 GPU 时间。*另见：* SHARP (in-network reduction)。

Incast（多对一拥塞） — 多个发送端在同一时刻向一个接收端发送数据，使接收端前方的交换机端口溢出。集合通信操作在设计上就会产生 incast，这正是 AI 网络需要拥塞控制的原因。*另见：* 拥塞控制、PFC（基于优先级的流量控制）。

Inference（推理） — 运行已训练好的模型以产生输出（回答、代码、图像）。与训练不同，推理是持续进行的、对延迟敏感，并按 token 计价。*另见：* 预填充（prefill）、解码（decode）。

Inference context memory storage（推理上下文内存存储） — 英伟达在 CES 2026 上推出的、基于 BlueField-4 的存储层，在推理节点之间保存并共享 KV 缓存块，使长对话可以重新加载，而不必重新计算。*另见：* KV 缓存卸载、KV 缓存、分离式推理服务。

Inference provider（推理服务商） — 按 token 或按推理所用 GPU 时间出售模型输出的公司（例如 Together AI、Fireworks AI、Baseten、GroqCloud、Cerebras Cloud），通常基于租用或自有的 GPU。*另见：* 新兴云服务商（neocloud）。

InferenceX — SemiAnalysis 开源、持续重跑的推理基准测试，在英伟达、AMD 和谷歌的硬件上描绘单 GPU 吞吐量与交互速度及每百万 token 成本之间的关系。*另见：* MLPerf、吞吐量-交互速度帕累托前沿。

InfiniBand — 一种低延迟、无损的网络标准，用于横向扩展的 AI 集群；英伟达通过 2020 年收购 Mellanox 成为其主要供应商（Quantum 交换机、ConnectX 适配器）。*另见：* 横向扩展（scale-out）、Spectrum-X。

Infinity Fabric — AMD 的一致性互连系列，用于其芯片内部，以及在 MI300/MI350 系列 GPU 之间（作为 xGMI 链路）构成无交换机的八 GPU 网状互连。AMD 的 72 GPU Helios 机架则改用基于以太网的 UALink 实现纵向扩展。*另见：* UALoE、UALink (Ultra Accelerator Link)。

Infrastructure tax（基础设施税） — 服务器 CPU 周期中耗费在服务商“管道”工作（虚拟交换、存储协议、加密、遥测、管理）而非客户工作上的比例。公开估计大多在 19-33% 之间；也称数据中心税。*另见：* 数据处理器（DPU）。

Installed base（装机量） — 某厂商已投入使用的产品数量。庞大的支持 CUDA 的 GPU 装机量（据英伟达称，到 2020 年已超过 10 亿块）使 CUDA 成为开发者和研究人员的默认目标平台。*另见：* CUDA、飞轮。

Intel 18A — 英特尔 2025–26 年的工艺节点，采用全环绕栅极晶体管（RibbonFET）和背面供电（PowerVia）。它是英特尔代工业务对外推介的基础。*另见：* 全环绕栅极（GAA）、背面供电、晶圆代工厂。

Intel TDX — 英特尔信任域扩展（Trust Domain Extensions）：英特尔面向 Xeon CPU 的机密虚拟机技术。TDX Connect 借助 TDISP 将其扩展到 PCIe 设备。*另见：* 可信执行环境（TEE）、TDISP。

Interactivity (tokens/s per user)（交互速度） — 每个用户接收生成 token 的速度。同时服务更多用户会提高单 GPU 的 token 产出，但会降低交互速度，因此只有在相同交互速度下，吞吐量数据才具有可比性。*另见：* 吞吐量-交互速度帕累托前沿、每兆瓦每秒 token 数。

Interconnection queue（并网排队） — 等待电网运营方研究并批准接入输电网的项目队列。在美国，新增发电项目从提交申请到投运的等待时间中位数超过四年。*另见：* 通电时间、表后发电。

Interposer（中介层） — 一层薄硅片（或嵌有硅桥的有机层），GPU 裸片和 HBM 堆栈并排置于其上，其间承载数以万计的细微连线。正是它让 HBM 实现每秒数 TB 的带宽。*另见：* CoWoS、先进封装。

Intrinsic value（内在价值） — 期权或认股权证若在今日行权所值的金额：股价减去行权价，再乘以股数（若股价低于行权价则为零）。不考虑时间价值。*另见：* 平价、采购挂钩归属认股权证。

IP royalty（IP 版税） — 在前期授权费之外，按芯片向授权技术所有者支付的费用，通常为芯片售价的一定百分比或每颗固定金额。Arm 的大部分收入即来自这种方式。*另见：* Arm 指令集、计算子系统（CSS）。

IPsec — 在 IP 层对网络流量进行加密和认证的标准。以数百 Gb/s 的速率用软件实现会消耗大量 CPU 核心；DPU 和网卡可在数据通路上直接加密。*另见：* 数据处理器（DPU）。

IPU (infrastructure processing unit)（基础设施处理器） — 英特尔（及谷歌）对 DPU 的称呼：一种可编程网络设备，把云基础设施功能从主机 CPU 上卸载运行。*另见：* 数据处理器（DPU）。

Ironwood — 谷歌第七代 TPU（TPU v7，2025 年）：每颗芯片 4.6 PFLOPS 稠密 FP8 算力和 192 GB HBM3E，单个 pod 最多 9,216 颗芯片；是谷歌首款主要面向推理设计的 TPU。*另见：* TPU、ICI（芯片间互连）。

ISA (instruction set architecture)（指令集架构） — 处理器能理解的机器指令“词汇表”，例如 x86 或 Arm。为某一 ISA 编译的软件无法在另一 ISA 上原生运行，这就是 ISA 的选择会锁定生态的原因。*另见：* x86、Arm 指令集、RISC-V。

IT load（IT 负载） — 服务器、存储和网络设备本身消耗的电力，不含散热和电能转换损耗。设施电力 = IT 负载 × PUE。*另见：* PUE（电能使用效率）。

J

JAX — 谷歌面向机器学习的数值计算库，经 XLA 编译。它可原生运行于 TPU 和英伟达 GPU，是前沿实验室在 TPU 上进行训练的主要方式。*另见：* XLA。

JEDEC — 半导体标准组织，制定 DDR、LPDDR、GDDR 和 HBM 等内存标准，使三星、SK 海力士和美光的芯片能够互通。*另见：* 高带宽内存（HBM）、LPDDR、DRAM。

Jevons paradox（杰文斯悖论） — 当某种东西的使用成本下降时，总消费量可能增长到使总支出反而上升；用于 AI 领域，即更便宜的 token 可能推高总算力需求。*另见：* token 价格通缩。

JIT compilation（即时编译） — Just-in-time compilation（即时编译）：在程序加载或运行时（而非提前）把代码转换为机器指令。CUDA 驱动会为新 GPU 即时编译 PTX；Triton 和 DeepGEMM 会针对实际使用的张量形状即时编译内核。*另见：* PTX (Parallel Thread Execution)、胖二进制。

Job completion time (JCT)（作业完成时间） — 完成一个训练作业或训练步骤所需的挂钟时间。网络厂商喜欢引用 JCT 的改善，因为它同时反映了带宽和尾延迟的影响。*另见：* 尾延迟。

K

KAI Scheduler — 源自 Run:ai、由英伟达于 2025 年开源（Apache 2.0）的 Kubernetes GPU 调度器；负责 GPU 共享、队列、公平性以及拓扑感知放置。*另见：* Kubernetes、Run:ai。

Kernel fusion（内核融合） — 将多个小型 GPU 程序（内核）合并为一个，使中间结果留在片上存储中，而不必写入 HBM 再读回。它减少了内存流量和启动开销。*另见：* GPU 内核、TensorRT。

KernelBench — 一个公开的 PyTorch 操作基准测试，分为三个难度级别，用于检验 AI 模型能否编写出正确且比 PyTorch 自带实现更快的 GPU 内核。*另见：* Triton (OpenAI)。

Knowledge distillation（知识蒸馏） — 训练一个较小的“学生”模型去模仿较大“教师”模型的输出。它能以远低于教师模型的推理成本保留其大部分能力。*另见：* 推理型模型、开放权重模型。

Known good die (KGD)（已知合格裸片） — 在封装前已经过全面测试的裸片（或 HBM 堆栈）。由于成品封装无法返修，事先逐一测试可避免因一个坏件而报废其他昂贵的合格部件。*另见：* 芯粒、先进封装。

Kubernetes — 在机器集群上运行容器化软件的开源系统；云计算的默认控制平面。Kueue 和 KAI Scheduler 等插件让它具备了共享 GPU 的能力。*另见：* Slurm、KAI Scheduler。

KV block manager (KVBM)（KV 块管理器） — Dynamo 的组件，将 KV 缓存块分层存储（GPU 显存、CPU 内存、SSD、远端存储），并在对话恢复时将其移回 GPU。*另见：* KV 缓存卸载、Dynamo、NIXL。

KV cache（KV 缓存） — 此前每个 token 的键（key）和值（value），存储在 GPU 显存中，使注意力计算无需重新计算它们。其规模随上下文长度和用户数增长；往往是推理服务中起决定作用的内存约束。*另见：* 注意力机制、PagedAttention。

KV-aware routing（KV 感知路由） — 把每个新请求发送到 KV 缓存中已保存其对话或提示词最大部分的服务器，从而减少需要重算的提示词部分。它缩短了首 token 时间。*另见：* KV 缓存、Dynamo、TTFT（首 token 时间）。

KV-cache offload（KV 缓存卸载） — 把闲置对话或长对话的注意力缓存（KV 缓存）从稀缺的 GPU HBM 移到更便宜的 CPU 内存或存储中，待用户回来时重新加载，而不必从头重算。*另见：* KV 缓存、NVLink-C2C。

Kyber — 英伟达为 Rubin Ultra 设计的下一代机架：144 个 GPU 封装安装在垂直刀片上，通过印刷电路中板（midplane）互连，功耗约 600 kW。英伟达的目标是 H2 2027；有报道称可能推迟到 2028 年。*另见：* 中板、NVL72、Oberon、机架级系统、800 V 直流供电架构。

L

L2 cache（L2 缓存） — 片上最后一级存储，由所有 SM 共享：H100 为 50 MB，B200 约为 126 MB。它在数据从 HBM 传来的途中将其截留，使重复读取不占用稀缺的 HBM 带宽。*另见：* 共享内存、高带宽内存（HBM）。

L6 / L10 / L11 integration（L6/L10/L11 级集成） — 业界衡量服务器组装完成度的简称：L6 指已贴装元器件的电路板或模块，L10 指经过测试的完整服务器或托盘，L11 指包含网络、电源和散热、作为一个整体完成验证的整机架。*另见：* ODM、OEM。

Language processing unit (LPU)（语言处理单元） — Groq 的推理芯片设计（2025 年 12 月授权给英伟达），将模型权重保存在片上 SRAM（每颗芯片约 500 MB）而非 HBM 中，以容量换取解码时极高的带宽和极低的延迟。*另见：* 解码（decode）、高带宽内存（HBM）。

Leading indicator（领先指标） — 往往先于你所关心的结果而变动的可量化信号，例如超大规模云厂商的资本开支指引会先于英伟达的订单发生变化。*另见：* 风险热力图。

Letter of intent (LOI)（意向书） — 在签署最终协议之前列明交易拟定条款的、不具约束力的文件。英伟达与 OpenAI 最高 $100B 的意向书（2025 年）后来被规模较小的股权投资所取代。*另见：* 收购式招聘。

Licence plus acquihire（授权加收购式招聘） — 一种交易结构：买方付费取得初创公司技术的非独家授权，并聘用其创始人和工程师，而初创公司仍作为独立公司存续；这可能绕开正式的并购审查。*另见：* 收购式招聘、并购审查。

Linear pluggable optics (LPO)（线性可插拔光模块） — 自身不带 DSP 芯片、依靠交换机的 SerDes 驱动信号的可插拔模块。模块功耗约减半，但传输距离缩短，互操作性要求也更严格。*另见：* 可插拔光模块、共封装光学（CPO）。

Linear programming（线性规划） — 在线性约束条件下求线性目标（成本、利润）的最优值；是物流、排程和供应链规划的主力工具。*另见：* cuOpt。

Link-layer retry (LLR)（链路层重传） — 在两个直连端口之间重发受损帧的机制，而不依赖端到端重传。它使纵向扩展链路保持无损，且增加的延迟极低。*另见：* Scale-Up Ethernet（SUE）、基于信用的流量控制。

Liquid cooling（液冷） — 通过在芯片冷板中循环的液体（而非空气）带走热量；功率约 100 kW 及以上的机架（如 GB200 NVL72）必须采用。*另见：* 800 V 直流供电架构。

Liquid-to-air (L2A) cooling（液-气冷却） — 一种过渡性方案：机架的冷却液回路通过侧挂式散热器把热量排到室内空气中，使液冷机架能在没有设施冷却水的机房中运行。*另见：* 冷却液分配单元（CDU）、直触芯片液冷。

Lithography（光刻） — 芯片制造中的“印刷”步骤：光刻机将光线透过带图形的掩模投射到晶圆表面的感光涂层上，定义出电路的一层。一颗现代芯片需要数十个这样的层。*另见：* EUV 光刻、光掩模。

LLM (large language model)（大语言模型） — 拥有数十亿到数万亿参数的 Transformer 神经网络，在大规模文本语料上训练以预测下一个 token。聊天助手、编程工具和 AI 智能体都构建于 LLM 之上。*另见：* Transformer、参数、token。

llm-d — 一个开源 Kubernetes 项目（CNCF 沙箱项目，由红帽（Red Hat）、谷歌云、IBM Research、CoreWeave 和英伟达共同发起），在 vLLM 和 SGLang 之上为 GPU 和 TPU 集群增加类似 Dynamo 的路由以及预填充/解码分离功能。*另见：* Dynamo、vLLM。

Load factor（负载率） — 设施实际消耗功率占满载功率的平均比例。闲置的加速器仍会耗电，因此 TCO 模型按“底线功耗 + 忙碌部分”计费。*另见：* PUE（电能使用效率）、集群利用率。

Load/store semantics（加载/存储语义） — 一个处理器直接用普通内存指令读写另一个处理器内存的通信方式（NVLink 即支持这种方式），而不是把数据打包成网络消息。对小而频繁的传输，它降低了软件开销和延迟。*另见：* NVLink、RDMA（远程直接内存访问）、纵向扩展（scale-up）。

Local silicon interconnect (LSI) bridge（局部硅互连桥） — 一小块布线极精细的硅片，嵌在 CoWoS-L 封装中相邻裸片的边缘下方，使硅材料只用在需要密集连接的地方。*另见：* CoWoS-L、EMIB / EMIB-T、中介层。

Long-term agreement (LTA)（长期协议） — 锁定供货量、并常常锁定价格或定价公式的多年期供应合同，有时附带预付款；2026 年内存厂商借此提前数年锁定 HBM 和 DRAM 产出。*另见：* 供应预付款、采购义务。

Loss function（损失函数） — 衡量模型在一个批次上预测错误程度的单一数值；训练的目标就是把它降下来。*另见：* 梯度。

LPDDR — 最初为手机设计的低功耗 DRAM，以芯片或模块形式销售。每 GB 成本远低于 HBM、密度更高，但带宽要低得多；用于高通 AI200 等大容量推理卡。*另见：* LPDDR5X、SOCAMM、高带宽内存（HBM）。

LPDDR5X — 最初为手机设计的低功耗 DRAM，Grace 和 Vera 采用它而非标准服务器 DIMM，因为其每瓦带宽更高；它以焊接或贴装方式紧靠 CPU 放置。*另见：* SOCAMM。

M

Maia — 微软为 Azure 自研的 AI 加速器产品线：Maia 100（2024 年）、Maia 200（2026 年，面向推理，运行 Copilot）以及 Maia 300（宣布于 2027 年推出）。*另见：* Azure Cobalt、自用芯片。

Mamba (state-space layer)（状态空间层） — 一种神经网络层，在序列中携带固定大小的滚动状态，而非关注此前的每一个 token，因此其内存不随上下文长度增长。在混合模型中与注意力层搭配使用。*另见：* 注意力机制、KV 缓存。

Mark-to-market gain（按市值计价收益） — 因投资的市场价值或评估价值上升而入账的利润，并未实际出售。它会抬高报告利润，但并非现金，价格下跌时还会转回。*另见：* 非流通股权证券。

MAX (Modular) — Modular 公司以 Mojo 编写的推理框架和内核库，在英伟达和 AMD GPU 上提供兼容 OpenAI 接口的推理服务端点。*另见：* Mojo。

Mean time to recovery (MTTR)（平均恢复时间） — 从故障发生到作业重新有效运行的平均时间：包括检测、隔离故障节点、重启，以及重做自上一个检查点以来的工作。*另见：* 有效训练时间、检查点。

Memory pooling（内存池化） — 通过 CXL 或以太网等互连，在众多处理器之间共享一大块内存，使容量可以扩充而无需购买更多 GPU 或 HBM。*另见：* CXL (Compute Express Link)、KV 缓存。

Memory supercycle（内存超级周期） — 内存需求超过供给、DRAM 和 HBM 价格与利润率全面大幅上升的时期，例如 2026 年 DRAM 行业收入曾在一个季度内增长 81%。*另见：* 高带宽内存（HBM）、长期协议（LTA）。

Memory wall（内存墙） — 处理器计算速度与内存供数速度之间的差距。在 LLM 推理（尤其是解码阶段）中，性能往往受内存带宽而非 FLOPS 的限制。*另见：* 高带宽内存（HBM）。

Memory-bound（内存受限） — 速度受限于从内存读取数据的速度、而非芯片计算速度的工作负载；增加 FLOPS 无济于事，增加带宽才有效。*另见：* 计算受限、内存墙。

Merchant silicon（商用芯片） — 在公开市场上出售给任何买家的芯片（英伟达 GPU、AMD Instinct），与企业为自用而设计的定制芯片（谷歌 TPU、AWS Trainium）相对。*另见：* XPU（定制加速器）。

Merger review（并购审查） — 由美国 FTC/DOJ（Hart-Scott-Rodino 申报）、欧盟委员会、英国 CMA 和中国国家市场监督管理总局（SAMR）等机构对收购进行的反垄断审查；审查可能历时一年以上，并可能阻止交易，英伟达收购 Arm 一案即是如此。*另见：* 授权加收购式招聘。

MFU (model FLOPs utilization)（模型 FLOPs 利用率） — 训练期间 GPU 理论峰值 FLOPS 中转化为有效模型运算的比例。大型训练任务通常可达约 35-45%。*另见：* FLOPS、有效吞吐量。

MGX — 英伟达面向服务器和机架的模块化参考架构，合作伙伴借此围绕英伟达或合作伙伴的芯片构建系统。AWS 计划将 Trainium4 置于配备 NVLink 的 MGX 机架中。*另见：* NVLink Fusion、NVL72。

Micro-batch（微批次） — 训练批次中的一小片，作为一个单元流经流水线；每一步的微批次越多，流水线气泡越小。*另见：* 流水线气泡。

Micro-bump（微凸块） — 直径数十微米的微小焊点，用于连接上下堆叠的裸片，或连接裸片与中介层。HBM 堆栈每层使用数千个微凸块。*另见：* 硅通孔（TSV）、混合键合、中介层。

Micro-ring modulator（微环调制器） — 一种微小的环形硅光器件，通过开关光信号来编码数据。它尺寸极小、功耗很低，是英伟达在其 CPO 光引擎中采用的调制器（基于台积电 COUPE 工艺制造），但对温度敏感。*另见：* 共封装光学（CPO）。

Microscaling (MX formats)（微缩放格式） — 一项行业标准（开放计算项目，2023 年）：每 32 个低精度数值组成一块，共享一个 8 位、2 的幂次的缩放因子。主要成员为 MXFP8、MXFP6 和 MXFP4；英伟达的 NVFP4 是采用 16 值分块的变体。*另见：* NVFP4、FP4。

mid-cycle refresh（中期升级版） — 在原版发布约一年后推出的同代 GPU 升级版本，例如 Blackwell 之后的 Blackwell Ultra（B300）、Rubin 之后的 Rubin Ultra，通常在同一架构上增加内存和算力。*另见：* 一年一代节奏。

Midplane（中板） — 位于机架或机箱中部的大型印刷电路板，计算刀片和交换刀片从两侧插入，取代线缆。英伟达的 Kyber 机架采用中板，取代 NVL72 的线缆背板。*另见：* Kyber、NVLink 线缆背板。

MIG (Multi-Instance GPU)（多实例 GPU） — 一项硬件功能（自英伟达 Ampere 起），可将一块数据中心 GPU 划分为最多七个相互隔离的迷你 GPU，各自拥有独立的内存和计算资源，使多个小作业能共享一块 GPU 而互不干扰。*另见：* GPU 切分、GPU 时间片轮转。

Mixed-precision training（混合精度训练） — 以紧凑的数值格式（BF16 或 FP8）完成繁重的算术运算，同时保留一份全精度（FP32）的主权重副本，以免丢失微小的更新。*另见：* BF16 (bfloat16)、FP8、Adam 优化器。

Mixture-of-experts (MoE)（混合专家模型） — 一种模型设计，把每个 token 路由到众多专家子网络中的少数几个，因此每个 token 只激活一小部分参数（DeepSeek-V3：671B 中的 37B）。可节省算力，但仍需为所有专家提供内存，并需要快速的全交换网络。*另见：* 专家并行（EP）、NVLink。

MLIR — Multi-Level Intermediate Representation（多级中间表示）：开放的编译器基础设施（源自 LLVM 项目），用于构建 Mojo、IREE、Triton 和 NKI 等 AI 编译器。*另见：* XLA、Mojo。

MLPerf — 由 MLCommons 运营的行业基准测试套件；MLPerf Inference 在固定模型和精度目标下，测量经审计的单系统吞吐量。*另见：* InferenceX。

Moat（护城河） — 使竞争对手无法夺走企业客户或利润的持久优势，例如转换成本、规模经济、供应渠道或网络效应。本资料库以买家或竞争对手绕开护城河所需的时间和成本来评判其强弱。*另见：* 护城河评分。

Moat score（护城河评分） — 本资料库对在某一技术栈层级中绕开英伟达难度的 1-5 分判断：1 = 已商品化或英伟达落后，3 = 竞争对手在部分维度上持平、英伟达在集成上领先，5 = 无对手接近且切换需要数年。它综合了各层页面的结论，而非实测数值。*另见：* 差距趋势。

Model hub（模型中心） — 开发者查找、下载和部署模型与数据集的平台；Hugging Face 是其中最大的一家，正被英伟达收购（尚待完成）。*另见：* 开放权重模型。

Model-specific ASIC（模型专用 ASIC） — 为单一模型家族硬连线设计的芯片，例如 Etched 仅支持 Transformer 的 Sohu。若模型架构保持稳定，其效率可以非常高；一旦架构改变，就会沦为搁浅资产。*另见：* ASIC、Transformer。

MoE router（MoE 路由器） — 混合专家层中经训练得到的小型网络，为每个 token 给各专家打分，并选出由哪几个专家处理它。*另见：* 混合专家模型（MoE）。

Mojo — Modular 公司（现属高通）推出的 Python 超集编程语言，用于编写能在多家厂商 CPU 和 GPU 上运行的高性能内核；2026 年以 Apache 2.0 许可开源。*另见：* MAX (Modular)、MLIR。

Monte Carlo simulation（蒙特卡洛模拟） — 将模型重复运行数千次，每次从各输入的合理区间中随机抽取数值，然后报告输出的百分位数（如 P10-P90），而非单一数值。*另见：* 龙卷风图。

MPI (Message Passing Interface)（消息传递接口） — 超级计算领域沿用数十年的进程间通信标准；NCCL 可在 MPI 应用中运行，MPI 库也可调用 NCCL 处理 GPU 数据。*另见：* NCCL、UCC (Unified Collective Communication)。

MRDIMM — 多路复用 Rank DIMM（Multiplexed-rank DIMM）：一种服务器内存模块，交错使用两个 rank，使每通道数据速率约翻倍（例如 8,800 MT/s），在不增加通道数的情况下提升 CPU 内存带宽。*另见：* LPDDR5X。

MSCCL++ — 微软开源的 GPU 通信栈，让开发者用单边、由 GPU 驱动的原语编写自定义集合通信算法；可在英伟达和 AMD GPU 上运行。*另见：* NCCL、RCCL。

MTBI (mean time between interruptions)（平均中断间隔时间） — 大型训练作业在被硬件或软件故障中断之前平均运行的 GPU 小时数。MTBI 越高，因重启而损失的工作越少。*另见：* 热备件。

MTIA — Meta Training and Inference Accelerator（Meta 训练与推理加速器）：Meta 自研的芯片产品线，最初用于排序和推荐模型，现已扩展到生成式 AI 推理（MTIA 300-500）。*另见：* 推荐模型、自用芯片。

Multi-head latent attention (MLA)（多头潜在注意力） — DeepSeek 的注意力设计，为每个 token 缓存一个经压缩的小型潜在向量，而非完整的键和值，使 KV 缓存内存减少 90% 以上。*另见：* KV 缓存、分组查询注意力（GQA）。

Multi-plane network（多平面网络） — 由若干相互独立的并行网络（“平面”）构成的网络，每块 GPU 的网卡分拆接入各个平面。每个平面采用更低 radix 的端口，使两层网络即可覆盖更多 GPU；某个平面故障也只会损失部分带宽。*另见：* 胖树、交换机端口数。

Multi-tenancy（多租户） — 多个客户共享同一物理基础设施，同时在性能、网络可达性和数据方面彼此隔离。*另见：* 裸金属实例、零信任隔离。

Multi-token prediction (MTP)（多 token 预测） — DeepSeek 采用的一种模型特性，每一步预先起草若干个未来 token，由服务器一并验证：这是一种内置的推测解码，可在单用户速度相同的情况下将吞吐量提升数倍。*另见：* 推测解码、解码（decode）。

Multi-year cloud service agreement（多年期云服务协议） — 英伟达披露的、在数年内向云服务商支付容量费用的承诺（用于 DGX Cloud 及其自身研究）。它们在财报中列为采购承诺，而非收入。*另见：* DGX Cloud、算力兜底承诺。

MXFP4 — 开放计算项目的 4 位微缩放格式：每 32 个 FP4 数值组成一块，共享一个 8 位、2 的幂次的缩放因子。英伟达的 NVFP4 采用更小的 16 值分块和更精细的 FP8 缩放因子；AMD 等厂商支持 MXFP4。*另见：* FP4、NVFP4。

N

National champion（国家冠军企业） — 政府为替代外国技术而扶持的本土芯片供应商，通常受出口管制或采购规则的保护；中国的华为昇腾是主要例子。*另见：* 出口管制、华为昇腾。

NCCL — NVIDIA Collective Communications Library（英伟达集合通信库）：通过 NVLink、InfiniBand 或以太网在 GPU 之间执行全规约、全收集等操作的软件。*另见：* 全规约、CUDA-X。

Near-memory computing（近存计算） — 将计算逻辑放在内存内部或紧邻处，使数据传输距离更短，从而提高有效带宽并降低每次运算的能耗；高通 AI250 和 d-Matrix 采用了这一思路的不同变体。*另见：* 内存墙。

NeMo — 英伟达开源的 AI 模型构建与适配工具家族：数据整理、训练和微调、强化学习、评估以及护栏。*另见：* Nemotron、NeMo Guardrails。

NeMo Guardrails — 英伟达开源的工具包，在语言模型的输入和输出周围添加可编程规则，例如拦截离题回答或强制执行对话流程。*另见：* NeMo、NVIDIA NIM。

Nemotron — 英伟达的开放权重 AI 模型家族，发布时公开了大部分训练数据和训练方法。2025-26 年的 Nemotron 3 模型采用稀疏的 Mamba-Transformer 混合专家架构。*另见：* NeMo、混合专家模型（MoE）、Mamba（状态空间层）。

Neocloud（新兴云服务商） — 专门出租 AI 用 GPU 容量的云服务商（例如 CoreWeave、Lambda、Nebius、Crusoe），与通用型超大规模云厂商相对。其中数家是英伟达的被投企业或合作伙伴。*另见：* 循环融资。

Neoverse — Arm 的数据中心 CPU 核心设计系列（N 系列侧重能效，V 系列侧重性能）。Grace 和 Graviton4 均采用 Neoverse V2 核心。*另见：* Arm 指令集、计算子系统（CSS）。

Network operating system (NOS)（网络操作系统） — 运行交换机的软件：路由、遥测、配置。例如 Arista EOS、思科 NX-OS、英伟达 Cumulus Linux 以及开源的 SONiC。*另见：* 白盒交换机。

Neural network（神经网络） — 由多层堆叠而成，每一层将输入乘以一个由学习得到的数值（参数）构成的矩阵，再施加一个简单的非线性函数。GPU 加速的正是其中的矩阵乘法。*另见：* Transformer、参数。

Neuron SDK — AWS 面向 Trainium 和 Inferentia 芯片的软件栈：编译器、运行时、PyTorch 集成（TorchNeuron）以及 NKI 内核语言。*另见：* NKI (Neuron Kernel Interface)。

NeuronLink — AWS 面向 Trainium 芯片的纵向扩展互连。NeuronLink-v3 以环面拓扑连接 64 颗 Trainium2；NeuronLink-v4 配合 NeuronSwitch-v1 以全互连方式连接 144 颗 Trainium3，每颗芯片约 2 TB/s。*另见：* 纵向扩展（scale-up）、NVLink。

New product introduction (NPI)（新产品导入） — 将新设计在工厂产线上转化为可制造、经测试产品的工程阶段；对 AI 机架而言，包括在批量爬坡前完成散热、供电和线缆验证。*另见：* EMS（电子制造服务）、ODM。

NIC (network interface card)（网卡） — 将服务器或 GPU 连接到网络的适配器。AI 服务器通常为每块 GPU 配备一块 400–800 Gb/s 的网卡，用于横向扩展网络；SuperNIC 和 DPU 是能力更强的网卡类型。*另见：* SuperNIC、SmartNIC、数据处理器（DPU）。

NIXL — NVIDIA Inference Xfer Library（英伟达推理传输库）：开源软件，通过 NVLink 或 RDMA 在 GPU、CPU 内存和存储之间点对点传输 KV 缓存块等数据，被 Dynamo 用于分离式推理服务。*另见：* Dynamo、分离式推理服务、RDMA（远程直接内存访问）。

NKI (Neuron Kernel Interface) — AWS 基于 Python 的语言，用于为 Trainium 编写自定义内核，配有基于 MLIR 的开源编译器。*另见：* Neuron SDK、Triton (OpenAI)。

Non-marketable equity security（非流通股权证券） — 对私营公司（例如 OpenAI 或 Anthropic）的持股，没有公开报价；按成本入账，并在新一轮融资显示出不同价格时进行调整。*另见：* 按市值计价收益。

North-south traffic（南北向流量） — 数据中心与外部世界之间的流量：用户、互联网以及其他站点。*另见：* 东西向流量、前端网络。

NPU (neural processing unit)（神经网络处理器） — 专为神经网络运算打造的处理器，通常配备大型矩阵引擎，通用控制逻辑少于 GPU。华为昇腾和高通的 Cloud AI 产品都属于 NPU。*另见：* ASIC、GPU。

NRE (non-recurring engineering)（一次性工程费用） — 芯片在售出任何一颗之前的一次性设计成本，包括工程人力、EDA 工具、IP 授权和光掩模。大型先进制程芯片的估算约为 $0.5-0.7B。*另见：* 流片、EDA（电子设计自动化）。

NV-HBI (high-bandwidth interface) — 英伟达的裸片间互连，以 10 TB/s 的速率连接 Blackwell 或 Rubin GPU 中两颗光罩尺寸的计算裸片，速度之快使软件将其视为一块 GPU。*另见：* 裸片间互连、芯粒。

nvcc — 英伟达的 CUDA 编译器驱动程序。它将程序拆分为 CPU 代码（交给主机编译器）和 GPU 代码，后者先编译为 PTX，再编译为 SASS 机器码。*另见：* PTX (Parallel Thread Execution)、SASS。

NVentures — 英伟达的风险投资部门，在初创企业融资轮中购买少数股权。它独立于 Inception（免费会员计划），也独立于英伟达直接持有的大额战略股份。*另见：* NVIDIA Inception、企业风险投资。

NVFP4 — 英伟达面向 Blackwell 和 Rubin 的 4 位浮点格式：4 位数值，每 16 个数值一块共享一个 FP8 缩放因子，另加一个张量级缩放因子，合计每个数值约 4.5 位。*另见：* FP8、量化。

NVIDIA AI Enterprise — 英伟达的付费软件订阅（企业级支持、安全补丁以及经认证版本的 CUDA-X 库、NIM 和框架），2024 年定价约为每 GPU 每年 $4,500。*另见：* CUDA-X。

NVIDIA DALI — 英伟达的数据加载库（Data Loading Library），将图像、视频和音频的解码与增强从主机 CPU 转移到 GPU 上，以避免数据加载瓶颈。*另见：* 数据加载器。

NVIDIA Inception — 英伟达面向初创企业的免费会员计划（2016 年推出）。会员可获得技术帮助、培训以及与投资者和合作伙伴的对接；英伟达不通过该计划获取股权。*另见：* NVentures、企业风险投资。

NVIDIA Mission Control — 英伟达面向 AI 工厂的运维软件（2025 年）：结合 Base Command Manager 与 Run:ai，负责部署和监控 DGX 机架、诊断故障并调度作业。*另见：* AI 工厂、超节点。

NVIDIA NIM — NVIDIA Inference Microservices（英伟达推理微服务）：预先构建的容器，将模型与经优化的引擎及标准 API 打包在一起；生产环境使用须取得 NVIDIA AI Enterprise 许可。*另见：* NVIDIA AI Enterprise。

NVIDIA Warp — 英伟达的开源 Python 框架，可将普通 Python 函数编译为 GPU 内核，用于物理仿真、机器人和可微编程。不要与由 32 个线程组成的 GPU warp（线程束）混淆。*另见：* PhysX、线程束。

NVL naming（NVL 命名规则） — 英伟达的机架名称标明一个 NVLink 域中的 GPU 数量；自 CES 2026 起，该数字按 GPU 封装而非裸片计算，因此“Vera Rubin NVL144”更名为 Vera Rubin NVL72，“Rubin Ultra NVL576”更名为 Kyber NVL144。*另见：* NVL72、Kyber。

NVL72 — 英伟达的机架级系统，72 个 GPU 封装通过 18 颗（Blackwell）或 36 颗（Vera Rubin）NVLink 交换芯片共享一个 NVLink 域。该数字按 GPU 封装计算；英伟达曾短暂改按裸片计数（“NVL144”），2026 年又改了回来。*另见：* NVLink 域、NVLink 线缆背板、Oberon。

NVLink — 英伟达专有的高速 GPU 间互连，用于纵向扩展。NVLink 5（Blackwell）为每块 GPU 提供 1.8 TB/s 带宽，是 PCIe 插槽的许多倍。*另见：* NVSwitch、纵向扩展（scale-up）。

NVLink domain（NVLink 域） — 无需经过网卡、可通过 NVLink 直接互访的一组 GPU。在域内，GPU 以 NVLink 速度读写彼此的内存；域外的流量则只能退回到慢得多的横向扩展网络。*另见：* 纵向扩展（scale-up）、NVL72、NVSwitch。

NVLink Fusion — 英伟达 2025 年推出的计划，对外授权 NVLink，使合作伙伴的定制 CPU 和加速器能与英伟达 GPU 一同接入 NVLink 纵向扩展域。已公布的合作伙伴包括高通、富士通、联发科、美满电子和 AWS（Trainium4）。*另见：* NVLink、纵向扩展（scale-up）。

NVLink SHARP (NVLS) — NVLink 交换机内部的网内规约：交换机将所有 GPU 的数据相加并组播结果，使一次全规约中每块 GPU 的数据只需发送约一次，而非约两次。*另见：* SHARP (in-network reduction)、NCCL、NVSwitch。

NVLink spine（NVLink 线缆背板） — NVL72 机架后部的铜质双轴线缆束，将每个 GPU 托盘与每个交换托盘相连。英伟达称 GB200 NVL72 中约有 5,000 根线缆，总长约两英里。*另见：* NVL72、直连铜缆（DAC）、NVLink 交换托盘。

NVLink switch tray（NVLink 交换托盘） — NVL72 机架中的一个 1U 托盘，装有 NVLink 交换芯片（GB200 NVL72 中每个托盘两颗）、一个管理控制器，以及插入铜缆背板的后部连接器。九个托盘即可完成全部 72 块 GPU 的交换。*另见：* NVSwitch、NVLink 线缆背板、盲插连接器。

NVLink-C2C — 英伟达的芯片间互连，以 900 GB/s（Grace）或 1.8 TB/s（Vera）的速率将 Grace 或 Vera CPU 与其 GPU 相连，是 PCIe 插槽的数倍，并具备缓存一致性，使 GPU 可以直接使用 CPU 内存。*另见：* 缓存一致性、NVLink、超级芯片。

NVMe — 闪存 SSD 通过 PCIe 使用的命令协议。它支持数万个并行队列，这就是一块现代 SSD 能提供数 GB/s 速率的原因。*另见：* NVMe over Fabrics (NVMe-oF)。

NVMe over Fabrics (NVMe-oF) — 通过网络（RDMA、TCP 或光纤通道）承载 NVMe 命令，使服务器能像使用本地硬盘一样使用远端闪存。DPU 可在硬件中运行发起端或目标端。*另见：* NVMe、RDMA（远程直接内存访问）。

NVQLink — 英伟达 2025 年推出的互连架构，将量子处理器及其控制系统与 GPU 超级计算机相连，以实现实时纠错；发布时有 17 家量子硬件厂商参与。*另见：* CUDA-Q。

NVSwitch — 连接众多 GPU 的 NVLink 端口的交换芯片，使每块 GPU 都能以 NVLink 全速与其他任何 GPU 通信，构成一个纵向扩展域（例如 NVL72 机架中的 72 块 GPU）。*另见：* NVLink、纵向扩展（scale-up）。

O

Oberon — GB200、GB300 和 Vera Rubin NVL72 所用机架设计的内部代号：水平放置的计算托盘和交换托盘，通过后部的铜质 NVLink 线缆背板互连。*另见：* NVL72、Kyber、NVLink 线缆背板。

Object storage（对象存储） — 以完整对象形式保存数据、通过 HTTP（S3 API）按键寻址的存储，能以低成本扩展到 EB 级，但延迟高于并行文件系统；通常存放原始数据集和归档数据。*另见：* 并行文件系统。

ODM（原始设计制造商） — Original design manufacturer（原始设计制造商）：按照客户或英伟达的参考设计来设计和制造服务器、托盘和机架的代工厂商（富士康、广达、纬创等）。

OEM (original equipment manufacturer)（原始设备制造商） — 以自有品牌销售服务器的公司，其产品往往部分由 ODM 代工，并附加销售、服务和融资；在 AI 服务器领域，例如戴尔、HPE 和超微。*另见：* ODM、L6/L10/L11 级集成。

Offtake agreement（包销协议） — 大型买家（例如微软或 Meta）长期租用某服务商未来容量的承诺。它使服务商能在数据中心建成之前筹集资金。*另见：* 照付不议合同、算力兜底承诺。

Omniverse — 英伟达用于构建工厂、机器人和数据中心 3D 仿真与数字孪生的平台，基于 OpenUSD 和 PhysX 构建。*另见：* PhysX。

oneAPI — 英特尔基于 SYCL 的跨厂商编程模型和库，现由 Linux 基金会旗下的 UXL 基金会管理（创始成员包括英特尔、Arm、谷歌云和高通）。*另见：* SYCL。

Open Compute Project (OCP)（开放计算项目） — 由 Facebook（Meta）于 2011 年发起的行业基金会，超大规模云厂商和供应商在此发布服务器、机架和供电的开放硬件设计。英伟达贡献了其 GB200 NVL72 机架设计；AMD 的 Helios 采用 OCP 机架。*另见：* Open Rack Wide (ORW)、MGX。

Open Rack Wide (ORW) — 面向超重、高功率 AI 机架的 OCP 双宽机架规范；AMD 的 Helios 即基于该规范打造。*另见：* 开放计算项目（OCP）、机架级系统。

Open-weight model（开放权重模型） — 训练好的参数公开发布、任何人都可下载并部署的模型（例如 Llama、DeepSeek、Qwen、Nemotron），因此任何服务商都可以竞相提供该模型的推理服务。*另见：* 推理服务商。

OpenCL — 一项开放、免版税的 GPU 及其他处理器编程标准，自 2000 年代末起获得苹果、AMD 和英特尔的支持。由于英伟达的库和工具更胜一筹，它在 AI 领域的开发者心智份额输给了 CUDA。*另见：* CUDA、SYCL。

Operating leverage（经营杠杆） — 收入增速快于成本增速，使每增加一美元销售额所带来的利润高于平均水平。英伟达的研发支出从 FY2016 到 FY2026 增长了 14 倍，但占收入的比例却从 27% 降至约 9%。*另见：* 飞轮。

Operating point（工作点） — 系统运行时设定的单用户速度（每用户每秒 token 数）。沿吞吐量-交互速度前沿，吞吐量和每 token 成本变化剧烈，因此任何成本比较都必须注明其工作点。*另见：* 交互速度（每用户 tokens/s）、吞吐量-交互速度帕累托前沿、每百万 token 成本。

Optical circuit switch (OCS)（光路交换机） — 利用微小镜面引导光束、无需转换为电信号即可重新连接光纤的交换机。谷歌在 Jupiter 网络和 TPU pod 中用 OCS 取代了脊层（spine）交换机。*另见：* 胖树。

Optical DSP（光模块 DSP） — 可插拔光模块内部的数字信号处理器，负责清理并重定时高速信号。主要由美满电子和博通供应；去掉它（线性光学）可以省电，代价是传输距离缩短。*另见：* 可插拔光模块。

Optical I/O chiplet（光 I/O 芯粒） — 封装在处理器旁边的小型裸片，将其电信号转换为光信号，使数据能通过光纤离开封装。它有望以低于可插拔光模块的功耗实现跨越多个机架的纵向扩展链路；Ayar Labs 和 Lightmatter 在开发此类产品。*另见：* 共封装光学（CPO）、SerDes。

Optimizer（优化器） — 将梯度转化为参数更新的算法。它通常为每个参数额外维护滑动统计量，这会占用内存。*另见：* Adam 优化器、梯度。

OSAT（外包封测） — Outsourced semiconductor assembly and test（外包半导体封装与测试）：为无晶圆厂设计公司和晶圆代工厂提供芯片封装与测试服务的企业，例如日月光（ASE）和安靠（Amkor）。*另见：* 先进封装、晶圆代工厂。

Osborne effect（奥斯本效应） — 提前宣布更好的未来产品，导致客户停止购买现有产品、转而观望的风险；得名于 1980 年代的一家计算机厂商，据称其过早发布新品导致销售停滞。*另见：* 一年一代节奏。

Over-training（过度训练） — 有意用远超 Chinchilla 最优比例的 token 数训练模型，使较小的模型也能达到高质量，且推理成本更低。*另见：* Chinchilla 最优、推理。

Overlay network（叠加网络） — 通过给数据包封装外层报头（例如 VXLAN），在物理网络之上为每个租户构建的虚拟网络，使众多客户能共享同一批交换机而彼此不可见。*另见：* 虚拟交换机、多租户。

Oversubscription（超额订阅） — 某一交换层的下行带宽大于上行带宽（例如 3:1 的收敛比），可节省交换机和光模块，但意味着并非所有端点都能同时以全速跨层发送数据。*另见：* 胖树、对分带宽。

Owner TCO（自有 TCO） — 拥有并运营一个加速器的全口径年度成本（硬件、网络、设施的资本费用，以及电力和运维）除以其小时数。它是 GPU 小时对所有者而言的成本，与客户支付的租赁价格相对。*另见：* 总拥有成本（TCO）、GPU 小时、资本回收系数。

P

P4 (programming language)（P4 编程语言） — 用于编程网络芯片如何解析和转发数据包的语言，AMD Pensando 和英特尔 IPU 的处理管线采用该语言。*另见：* 数据处理器（DPU）。

Packet spraying（数据包喷洒） — 将单条流的数据包同时分散到多条路径上。它能均匀利用整个网络，但数据包会乱序到达，因此接收端网卡必须将其重新排序。*另见：* 自适应路由、SuperNIC。

PagedAttention — 一种技术（源自 vLLM），像虚拟内存那样以固定大小的页存储 KV 缓存，避免碎片化，并让请求之间共享已缓存的前缀。*另见：* KV 缓存、连续批处理。

Pallas — JAX 的内核语言，用于在 XLA 编译器的输出不够快时编写自定义 TPU（及 GPU）内核；是谷歌对标 Triton 或 CUTLASS 的工具。*另见：* XLA、CUTLASS。

PAM4 — 四电平脉冲幅度调制：线路上每个符号携带两个比特而非一个，在符号速率不变的情况下使数据速率翻倍。NVLink 自 Hopper 起改用 PAM4；它对噪声更敏感，因而缩短了铜缆的传输距离。*另见：* SerDes、直连铜缆（DAC）。

Panel-level packaging（面板级封装） — 在大型矩形面板而非 300 mm 圆形晶圆上制作先进封装。当每个封装跨越数个光罩尺寸时，矩形面板的边缘浪费更少，但面板更容易翘曲。*另见：* CoPoS、CoWoS、先进封装。

Parabricks — 英伟达的 GPU 加速基因组学软件，运行标准 DNA 测序流程（比对、变异检测）的速度比 CPU 工具快许多倍。*另见：* 变异检测。

Parallel file system（并行文件系统） — 将每个文件条带化分布到众多存储服务器上、使数千个客户端能同时读写的文件系统（例如 Lustre/DDN EXAScaler、IBM Storage Scale、WEKA）。适合检查点和训练 I/O。*另见：* 对象存储。

Parameter (weight)（参数） — 模型内部一个经学习得到的数值。“405B 模型”拥有 4,050 亿个参数；训练调整它们，推理则在每生成一个 token 时读取它们。*另见：* 神经网络、混合精度训练。

PAT (Parallel Aggregated Trees)（并行聚合树） — NCCL 的一种算法（2024 年），用于超大规模下的全收集和规约散射，所需步数呈对数增长，可在每块 GPU 发送数据量很小时降低延迟。*另见：* 树形全规约、NCCL。

Payback period（投资回收期） — 投资带来的累计利润或现金等于所付价格所需的时间。折现回收期先按资本成本对价格进行复利增长，因此耗时更长。

PCIe (PCI Express) — 将 GPU、网卡和 SSD 连接到主机 CPU 的标准扩展总线。一条 16 通道（x16）链路的总带宽（双向合计）在 Gen4 上约为 64 GB/s，Gen5 上为 128 GB/s，Gen6 上为 256 GB/s。*另见：* NVLink-C2C、CXL (Compute Express Link)。

PCIe switch（PCIe 交换芯片） — 将一路 PCIe 连接扇出到多个设备（GPU、网卡、SSD）的芯片，使这些设备无需经过 CPU 即可点对点交换数据。ConnectX-8 内置了一颗 PCIe 交换芯片。*另见：* PCIe (PCI Express)、GPUDirect RDMA。

Perf/W (performance per watt)（每瓦性能） — 单位功率所完成的有效工作，例如每瓦 FP8 TFLOPS 或每兆瓦每秒 token 数。在电力受限的数据中心，它决定了一个站点能卖出多少算力。*另见：* 总拥有成本（TCO）。

Performance density（性能密度） — TPP 除以以 mm^2 计的裸片面积。由 2023 年 10 月的规则新增，以防厂商把同样的算力分散到更多硅面积上来规避 TPP 门槛。*另见：* TPP（总处理性能）。

Performance per dollar（每美元性能） — 每美元自有成本或租赁价格所对应的有效工作量（例如每秒 token 数）；当定制 ASIC 在峰值性能上落后时，就以这一指标参与竞争。*另见：* 总拥有成本（TCO）、每瓦性能。

Photomask（光掩模） — 承载某一电路层图形的石英板，在光刻中用作模版。一颗先进制程芯片的全套光掩模耗资数百万美元，这也是芯片设计修改成本高昂的原因之一。*另见：* 光刻。

PhysX — 英伟达于 2008 年通过收购 Ageia 获得的物理引擎，用于游戏、机器人仿真和 Omniverse；现已开源。*另见：* Omniverse、NVIDIA Warp。

Picojoules per bit (pJ/bit)（皮焦每比特） — 通过链路传输一个比特所需的能量，即瓦数除以每秒比特数。基于 DSP 的光模块约为 15-19 pJ/bit，共封装光学约为 5 pJ/bit，而无源铜缆在芯片自身 SerDes 之外几乎不增加功耗。*另见：* 共封装光学（CPO）、线性可插拔光模块（LPO）、SerDes。

Pin speed（引脚速率） — 内存接口每根导线每秒传输的比特数（以 Gb/s 计）。每个堆栈的 HBM 带宽 = 接口宽度 x 引脚速率 / 8；Rubin 的 HBM4 规格修订源于引脚速率低于目标。*另见：* 高带宽内存（HBM）、HBM4E。

Pipeline bubble（流水线气泡） — 流水线并行中，各阶段等待流水线填满和排空时的空闲时间；对于 p 个阶段和 m 个微批次，约占每一步的 $(p-1)/(m+p-1)$。*另见：* 流水线并行（PP）、微批次。

Pipeline parallelism (PP)（流水线并行） — 将模型的各层切分为连续的阶段放在不同 GPU 上，让微批次像装配线一样依次流过；只有激活值跨越阶段边界。*另见：* 流水线气泡、微批次。

Pluggable transceiver（可插拔光模块） — 插入交换机或网卡端口、将电信号转换为光信号的可拆卸光学模块（例如 800G 或 1.6T OSFP）。易于更换，但需要一颗高功耗 DSP 来驱动信号穿过电路板。*另见：* 共封装光学（CPO）、线性可插拔光模块（LPO）。

Post-training（后训练） — 在原始文本预训练之后对模型所做的一切工作：指令微调、偏好微调和强化学习。在总训练算力中所占比例日益上升。*另见：* 强化学习（RL）、推理型模型。

Power shelf（电源架） — 一个 1U 的电源抽屉，将建筑的交流电转换为供机架使用的低压直流电；在 GB200 NVL72 中，每个电源架装有六个 5.5 kW 电源模块（最高 33 kW）。*另见：* 母排、800 V 直流供电架构。

pre-announcement horizon（提前公布期） — 厂商在产品批量上市前多久公开为其标注日期（名称加目标年份）；本资料库以从首次带日期的提及到计划上市之间的月数来衡量。*另见：* 一年一代节奏、奥斯本效应。

Preemption（抢占） — 调度器停止（通常是重新排队）较低优先级的作业，把其 GPU 让给更高优先级的作业。这使集群可以出借闲置容量，而不会阻塞紧急工作。*另见：* 成组调度。

Prefill (context phase)（预填充） — 推理请求的第一阶段：并行处理整个提示词，以构建 KV 缓存并生成第一个 token。受计算能力限制。*另见：* 解码（decode）、TTFT（首 token 时间）。

Price elasticity of demand（需求价格弹性） — 价格变动 1% 时购买量变动的百分比。大于 1（富有弹性）时，降价会增加总支出；小于 1（缺乏弹性）时，降价会减少总支出。*另见：* 杰文斯悖论。

Price umbrella（价格保护伞） — 市场领导者将价格维持在远高于成本的水平所形成的空间：竞争对手可以定价低于它而仍获得回报，领导者则可以有选择地降价来挤压对手。英伟达约 75% 的毛利率就是笼罩 AI 加速器市场的价格保护伞。*另见：* 毛利率、免费芯片测试。

Pricing power（定价权） — 提价或维持价格而不损失销量的能力。对英伟达而言，它体现为约 75% 的毛利率；竞争对手和自研芯片首先在最大的买家处对其形成制约。*另见：* 价格保护伞。

Priority Flow Control (PFC)（基于优先级的流量控制） — 一种以太网机制：缓冲区填满时通知上游设备暂停某一流量类别，以免丢包。它使以太网能为 RoCE 提供“无损”传输，但若过度使用，暂停可能在整个网络中扩散。*另见：* RoCE (RDMA over Converged Ethernet)、基于信用的流量控制。

Process node（工艺节点） — 一代芯片制造技术（例如台积电 N7、N4、N3、N2、A16）。这些名称是营销标签而非物理尺寸；每个新节点单位面积可容纳更多晶体管，但每片晶圆的价格也更高。*另见：* 晶圆、晶圆代工厂。

programmable shader（可编程着色器） — GPU 对每个顶点或每个像素运行一次的小程序；着色器变得可编程后（GeForce 3，2001 年），GPU 就成为通用并行处理器，这是 CUDA 的前身。*另见：* GPGPU。

PTX (Parallel Thread Execution) — 英伟达的虚拟指令集。CUDA 代码先编译为 PTX，再由驱动将 PTX 翻译为每一代 GPU 的原生代码，这就是旧 CUDA 程序能在新 GPU 上运行的原因。*另见：* CUDA、GPU 内核。

PUE (power usage effectiveness)（电能使用效率） — 设施总电力除以 IT 设备所用电力；1.0 意味着散热和电能转换的开销为零。*另见：* 液冷。

Purchase obligations（采购义务） — 在公司财报中披露的、未来购买存货、元器件或制造产能的约束性承诺。英伟达的供应与产能承诺在 Q2 FY2027 达到 $279B；它们锁定了稀缺供应，但即使需求下降也必须支付。*另见：* 飞轮。

Purchase-vested warrant（采购挂钩归属认股权证） — 仅在持有人购买发行人一定金额的产品后才按批次归属的认股权证；供应商借此与大客户分享上行收益。*另见：* 认股权证、股权换产能。

PyTorch — 由 Meta 创建（2016-17 年）的开源深度学习框架，现为 AI 研究的默认框架。模型用 Python 编写一次，再由各厂商后端（首先是 CUDA，其后是 ROCm、TPU 等）运行。*另见：* Triton (OpenAI)、XLA。

Q

quadratic surfaces（二次曲面） — 一种用二阶方程描述的曲面片来绘制 3D 形状的方法，英伟达首款芯片（NV1）采用了这一方法，而非业界后来标准化的平面三角形。*另见：* Direct3D。

Quantization（量化） — 以更少的比特数存储和计算每个数值（例如以 FP8 或 FP4 取代 BF16）。可降低每个 token 的内存和带宽需求，但存在一定的精度风险。*另见：* FP8、NVFP4。

R

Rack-scale system（机架级系统） — 作为整个机架（计算托盘、交换托盘、电源架、布线和液冷）而非单台服务器来设计和销售的 AI 计算机，使数十个加速器像一台机器那样协同工作。英伟达的 NVL72、AMD 的 Helios 和 AWS 的 UltraServer 都是例子。*另见：* 纵向扩展（scale-up）、NVLink、液冷。

Rail-optimized topology（轨道优化拓扑） — 一种集群布线方式：每台服务器的第 k 号网卡都连接到同一个“轨道”叶交换机，使不同服务器上编号相同的 GPU 之间只隔一跳交换。这与集合通信库搬运数据的方式相匹配。*另见：* 胖树、NCCL。

RAPIDS — 英伟达于 2018 年推出的开源 GPU 数据科学库套件（cuDF、cuML、cuGraph、cuVS 等），对应 pandas 和 scikit-learn 等流行的 Python 工具。*另见：* cuDF、cuML。

RCCL — AMD 的 ROCm 集合通信库（ROCm Communication Collectives Library），源自 NCCL 的代码和 API，通过 Infinity Fabric 及网络在 Instinct GPU 上执行集合通信。*另见：* NCCL、ROCm。

RDMA (remote direct memory access)（远程直接内存访问） — 一台机器的网卡直接读写另一台机器内存的方式，双方操作系统都无需复制数据。它降低了延迟和 CPU 负担，这正是 AI 集群用它承载 GPU 间流量的原因。*另见：* RoCE (RDMA over Converged Ethernet)、GPUDirect RDMA、InfiniBand。

Reasoning model（推理型模型） — 经训练（通常借助强化学习）在作答前先生成一段隐藏思维链的模型。在难题上回答质量更高，代价是生成的 token 大幅增加。*另见：* 测试时计算、强化学习（RL）。

Recommendation model（推荐模型） — 为每个用户对广告、帖子或商品进行排序的模型（例如 DLRM）。其主要负载是大规模嵌入表查找，而非 LLM 的稠密矩阵运算，因此青睐不同的芯片设计。*另见：* MTIA。

Redistribution layer (RDL)（重布线层） — 在有机或硅基底之上制作的薄层金属布线，用于在裸片之间以及向封装连接点传递信号；比芯片内部布线粗，但远比电路板精细。*另见：* CoWoS-R、CoWoS-L、中介层。

Reduce-scatter（规约散射） — 一种集合通信操作：各 GPU 对各自的向量求和，但每块 GPU 只保留结果中属于自己的那一片；是环形全规约的前半部分。*另见：* 全规约、全收集。

Reference architecture（参考架构） — 由厂商指定并经测试的物料清单和配置（服务器、网络、存储、软件），合作伙伴可将其作为完整系统报价和提供支持。英伟达的企业版称为“验证设计”（validated design）。*另见：* NVIDIA AI Enterprise、RTX PRO 服务器。

Reference design（参考设计） — 平台所有者发布的完整、有文档的设计，使合作伙伴能迅速打造兼容产品（英伟达的 HGX、MGX 和 DGX SuperPOD 架构都是参考设计）。*另见：* MGX、HGX。

Register file（寄存器堆） — GPU 上最快的存储：每个 SM 有 256 KB 寄存器，保存线程当前正在处理的数值。它紧邻算术单元，每个时钟周期为其供数。*另见：* 共享内存、流式多处理器（SM）。

Registered developer（注册开发者） — 已加入英伟达开发者计划的人员。该数字是累计且自行申报的，因此衡量的是覆盖面，而非当前有多少人在积极编写 CUDA 代码。*另见：* CUDA。

Reinforcement learning (RL)（强化学习） — 通过试错和奖励进行训练：模型生成许多候选答案，对其评分（例如检查数学结果或运行代码），再朝更好的答案更新模型。强化学习运行包含大量推理工作负载。*另见：* 后训练、推理型模型。

Residual value（残值） — 资产在使用期结束时可出售的价格。旧 GPU 若仍有正的转售价格，其真实成本就会降低；租赁价格下跌会压低残值，并可能导致资产减值。*另见：* 经济寿命、GPU 抵押贷款。

Reticle limit（光罩尺寸极限） — 光刻机单次曝光的最大面积（现有 EUV 设备约为 858 mm^2），它限制了单颗裸片的尺寸，迫使设计者转向多裸片封装。*另见：* 裸片。

Retimer（重定时器） — 接收衰减后的高速信号、恢复数据并重新干净地发送的芯片，可延长铜缆链路的传输距离。常见于 PCIe 和 CXL 链路；Astera Labs 是领先供应商。*另见：* 有源电缆（AEC）、SerDes。

Revenue backlog（收入积压） — 公司已签合同但尚未交付的收入（常称剩余履约义务）。它体现的是需求可见度，而非现金：合同可能被推迟或重新谈判。*另见：* 照付不议合同。

Revenue by customer headquarters（按客户总部所在地划分的收入） — 按客户总部所在国家（而非开票地）划分的地区收入。英伟达在 Q3 FY2026 改用这一口径，使中国的报告占比上升。*另见：* 出口管制。

Reverse DCF（反向 DCF） — 从当前市值倒推其隐含的增长率或利润率，而非预测现金流再推导估值；最简单的形式是 P/E = 1 / (股权成本 - 增长率)。*另见：* 远期市盈率。

Ridge point（屋脊点） — 芯片从内存受限转为计算受限时的算术强度：峰值 FLOPS 除以内存带宽。H100 在稠密 BF16 下约为每字节 295 FLOPs。*另见：* 屋顶线模型、算术强度。

Ring all-reduce（环形全规约） — 一种全规约算法，在 GPU 组成的环上依次传递数据块；无论参与的 GPU 有多少，每块 GPU 发送的数据量约为数据大小的两倍。*另见：* 全规约。

RISC-V — 任何人都可实现的开放、免版税指令集。Ventana、Rivos、Tenstorrent 和 Akeana 等初创公司设计高性能 RISC-V 核心，作为 Arm 的替代方案。*另见：* ISA（指令集架构）、Arm 指令集。

Risk heatmap（风险热力图） — 按可能性（x 轴）和影响（y 轴）为每项风险定位的网格，两项通常各按 1-5 分打分；二者的乘积决定哪些风险最值得优先关注。*另见：* 领先指标。

RoCE (RDMA over Converged Ethernet) — 承载于以太网数据包中的 RDMA（RoCEv2 使用 UDP/IP）。它将 InfiniBand 式的直接内存传输带到以太网上，但由于以太网在繁忙时本就设计为丢包，因此需要精心的拥塞控制。*另见：* RDMA（远程直接内存访问）、PFC（基于优先级的流量控制）、拥塞控制。

ROCm — AMD 的开源 GPU 软件栈（驱动、编译器、库、HIP），2016 年首次发布。是 AMD 对标 CUDA 的方案。*另见：* HIP、CUDA。

Roofline model（屋顶线模型） — 描述芯片可达速度的简单图表：取峰值算力（平顶）与“内存带宽 × 工作负载算术强度”（斜线）中的较小者。它让人一眼看出工作负载受计算还是受内存限制。*另见：* 算术强度、屋脊点。

RTX PRO server（RTX PRO 服务器） — 搭载英伟达 RTX PRO 6000 Blackwell Server Edition GPU 的风冷 x86 服务器，自 2025 年起由 OEM 销售，面向无法部署液冷机架级系统的企业。*另见：* 参考架构。

Rubin CPX — 英伟达于 2025 年 9 月发布、面向推理预填充（上下文）阶段的 GPU，配备 128 GB GDDR7 而非 HBM。它未出现在 2026 年 3 月的路线图中；有报道称其将以 HBM4 版本回归，但尚未证实。*另见：* 预填充（prefill）、分离式推理服务、GDDR。

Rubin Ultra — 英伟达 2027 年的 GPU 世代，发布时宣称每个封装含四颗光罩尺寸裸片、约 100 PFLOPS FP4 算力和 1 TB HBM4E，用于 Kyber 机架；2026 年的报道描述的是双裸片、768 GB 的版本。*另见：* Kyber、HBM4E。

Run:ai — 以色列 GPU 编排软件公司，英伟达于 2024 年将其收购（据报约 $700M）；其平台在团队之间池化 GPU，并于 2026 年 10 月完全开源。*另见：* KAI Scheduler、NVIDIA Mission Control。

S

Same-year flagship（同年旗舰） — 本资料库差距图表采用的约定：某一日历年中批量出货的英伟达数据中心 GPU（2023 年 H100、2024 年 H200、2025 年 GB300、2026 年 Rubin），作为 100% 基准。

SAMR（国家市场监督管理总局） — 中国国家市场监督管理总局。其反垄断局审查在华销售额较大的公司之间的合并，可附条件批准、拖延或否决交易。*另见：* 行为性救济措施。

SASS — 某一英伟达 GPU 家族的真实机器码（例如 Hopper 的 sm_90）。ptxas 汇编器将 PTX 转换为 SASS；与 PTX 不同，某一代的 SASS 通常无法在下一代上运行。*另见：* PTX (Parallel Thread Execution)、nvcc。

Scale-across（跨数据中心扩展） — 连接位于不同数据中心（相距数十到数千公里）的 AI 集群，使其能协同完成同一作业；英伟达的 Spectrum-XGS 瞄准的正是这一需求。*另见：* 横向扩展（scale-out）。

Scale-out（横向扩展） — 通过数据中心网络（InfiniBand 或以太网）连接大量纵向扩展域或服务器，以集群规模进行训练或推理。*另见：* 纵向扩展（scale-up）、跨数据中心扩展（scale-across）。

Scale-up（纵向扩展） — 以极快的内存语义互连（NVLink、ICI、Infinity Fabric）将一组加速器紧密耦合，使其表现得像一块大型 GPU。*另见：* 横向扩展（scale-out）、NVLink。

Scale-Up Ethernet (SUE)（纵向扩展以太网） — 博通于 2025 年贡献给 OCP 的框架，用于把 Tomahawk Ultra 等以太网交换机用作纵向扩展网络。它增加了链路层重传和基于信用的流量控制，使短小、无损的传输能够在以太网上运行。*另见：* ESUN (Ethernet for Scale-Up Networking)、链路层重传（LLR）、基于信用的流量控制。

Scaling laws（缩放定律） — 经验性发现：随着参数、数据和算力的增加，模型质量会以可预测的方式（幂律）提升。它为不断扩大的训练预算提供了依据。*另见：* Chinchilla 最优、过度训练。

Second source（第二供应商） — 承担同一任务的合格替代供应商。买家保留第二供应商以争取价格让步，并在主供应商缺货或延期时保障供应；只有当第二供应商的产品足够好、能承接实际销量时，这一策略才奏效。*另见：* 转换成本、钱包份额。

Sequence parallelism（序列并行） — 英伟达与张量并行配套的技术，沿序列维度拆分 LayerNorm 等操作，在不增加通信的情况下节省激活值内存；与上下文并行不同。*另见：* 张量并行（TP）、上下文并行（CP）。

SerDes — 串行器/解串器（Serializer/deserializer）：将大量片上并行信号转换为少数几条极高速串行通道（目前每条 100–200 Gb/s）并反向转换的电路。端口速率 = 通道数 × 单通道速率。*另见：* 交换机端口数。

Serving engine（推理服务引擎） — 为用户运行已训练模型的软件：它对请求进行批处理、管理 KV 缓存并调用 GPU 内核。例如 vLLM、SGLang 和英伟达 TensorRT-LLM。*另见：* vLLM、SGLang、TensorRT-LLM。

SGLang — 与 vLLM 竞争的开源 LLM 推理服务引擎，擅长结构化生成和大型混合专家模型；支持英伟达、AMD、TPU 和昇腾硬件。*另见：* vLLM。

Share of wallet（钱包份额） — 客户在某一类别的总支出中流向某一家供应商的比例。销售机架、网络、CPU 和软件（而不仅是 GPU）提高了英伟达在每一美元数据中心支出中的份额。*另见：* NVLink Fusion。

Shared memory (L1)（共享内存） — 每个 SM 内部的高速片上 SRAM（H100 和 B200 上为 256 KB，在 L1 缓存与程序员管理的共享内存之间分配），内核在此暂存矩阵分块，使张量核心能重复使用多次。*另见：* 寄存器堆、L2 缓存。

SHARP (in-network reduction) — 英伟达的可扩展分层聚合与规约协议（Scalable Hierarchical Aggregation and Reduction Protocol）：交换机在数据经过时将多块 GPU 的数据相加，使全规约中每块 GPU 只需发送一次数据，而非约两次。Quantum InfiniBand 和 NVLink 交换机均支持该功能。*另见：* 全规约、网内计算。

Signpost（路标） — 预先约定的可观察事件或指标阈值，用于判断正在展开的是哪种情景，例如定制 ASIC 收入超过英伟达数据中心收入的 25%。路标把情景分析转化为复盘的触发条件。*另见：* 领先指标。

Silicon photonics（硅光子） — 用芯片制造工具在硅晶圆上制作光学元件（调制器、波导、探测器），使光链路能够批量制造，并紧邻电子芯片放置。*另见：* 共封装光学（CPO）。

Simultaneous multithreading (SMT)（同时多线程） — 一种 CPU 功能，让两个（或更多）硬件线程共享同一核心的执行单元，从而在一个核心上同时运行，以单线程速度的可预测性下降为代价提高总吞吐量。英特尔称之为超线程（Hyper-Threading）。*另见：* 空间多线程。

Slurm — 开源的批处理调度器，在大多数超级计算机和许多 AI 训练集群上负责作业排队和放置。其开发商 SchedMD 于 2025 年 12 月被英伟达收购。*另见：* Kubernetes、成组调度。

SM utilization（SM 利用率） — GPU 流式多处理器实际的繁忙程度，由 DCGM 等遥测工具测量。一块 GPU 可能已被分配，并在简单工具中显示 100%“利用率”，而其 SM 大部分时间却处于空闲。*另见：* 分配率、MFU（模型 FLOPs 利用率）、DCGM。

SmartNIC（智能网卡） — 将部分数据包处理（例如虚拟交换或加密）从 CPU 上卸载的网卡；DPU 是带有通用处理器核心的 SmartNIC。*另见：* 数据处理器（DPU）。

SOCAMM — 一种紧凑、可更换的内存模块，承载 LPDDR5X 芯片，与 Vera 搭配使用，使低功耗内存能像普通 DIMM 一样维护更换。*另见：* LPDDR5X。

Software port（软件移植版） — 在兼容接口之后重新实现另一厂商的库（例如对应 NCCL 的 RCCL、对应 cuDF 的 hipDF）。移植版降低了采用门槛，但每次都要在原版发布后才能跟进复制，因而总是落后一步。*另见：* HIP、RCCL。

Solid-state transformer (SST)（固态变压器） — 由 SiC 或 GaN 开关器件构成的电力电子变换器，取代笨重的铜铁变压器，将中压电网电力直接转换为下一代 AI 机架所用的 800 V 直流电。*另见：* 800 V 直流供电架构。

Sovereign AI（主权 AI） — 由国家建设或出资（或为国家建设）的 AI 基础设施，使数据、模型和算力处于本国掌控之下；通常通过本土新兴云服务商或电信运营商交付。*另见：* ACIE、新兴云服务商（neocloud）。

Sparsity (2:4 structured)（2:4 结构化稀疏） — 一种硬件技巧：每四个权重中有两个为零，使张量核心可以跳过它们，从而使标称峰值 FLOPS 翻倍。英伟达的宣传数字常以此为前提；稠密数字则不然。*另见：* FLOPS、张量核心。

Spatial Multithreading（空间多线程） — 英伟达对其 Vera CPU 每核双线程方案的命名；英伟达称它在两个线程之间划分每个核心的资源，使单线程性能比传统 SMT 更可预测。*另见：* 同时多线程（SMT）。

Spectrum-X — 英伟达面向 AI 集群的以太网平台，将 Spectrum 交换机与 SuperNIC 及自适应路由相结合，在以太网上逼近 InfiniBand 级别的性能。*另见：* InfiniBand、横向扩展（scale-out）。

Spectrum-XGS — 英伟达 2025 年对 Spectrum-X 以太网的扩展，面向“跨数据中心扩展”（scale-across）：提供距离感知的拥塞控制和延迟管理算法，使不同数据中心的 GPU 网络能像一个整体那样运作。*另见：* Spectrum-X、跨数据中心扩展（scale-across）。

Speculative decoding（推测解码） — 由小型草稿模型提出若干个 token，大模型一次性验证并保留正确的部分。在解码受内存限制时，可在输出完全相同的情况下提速 2-3 倍。*另见：* 解码（decode）。

SPV financing（SPV 融资） — 通过主要由外部投资者持有的特殊目的载体或合资企业为数据中心融资，使大部分债务不进入运营方的资产负债表（例如 Meta 的 Hyperion）。*另见：* 循环融资。

SRAM — 静态随机存取存储器（Static RAM）：直接集成在处理器裸片上的极高速存储器。它带宽极高，但每平方毫米的容量很小，因此以 SRAM 为主的芯片（Groq、Cerebras、d-Matrix）以容量换速度。*另见：* 高带宽内存（HBM）、语言处理单元（LPU）、晶圆级引擎。

SRD (Scalable Reliable Datagram)（可扩展可靠数据报） — AWS 自研的传输协议，供 EFA 使用，将数据包喷洒到多条网络路径上，并在硬件中恢复丢包。*另见：* EFA (Elastic Fabric Adapter)、数据包喷洒。

Stack breadth（技术栈广度） — 在本资料库中，指竞争对手在英伟达十二个技术栈层级（02-13）中得分不低于 3 分（满分 5 分）的层数。深度则指其在最强层级中的实力。*另见：* 垂直整合。

Stack height（堆叠层数） — 一个 HBM 堆栈中堆叠的 DRAM 裸片数量（8 层、12 层或 16 层）。层数乘以裸片密度决定容量：十二颗 24 Gb 裸片为 36 GB，十六颗 32 Gb 裸片为 64 GB。*另见：* 高带宽内存（HBM）、引脚速率、硅通孔（TSV）。

Steelman（钢人论证） — 对你可能不认同的观点，以现有最佳证据构建出的最有力、最诚实的版本，与容易驳倒的“稻草人”相对。*另见：* 风险热力图。

Storage tiering（存储分层） — 把数据放在一个由小而快（HBM）到大而慢（共享闪存）的存储阶梯上，并按需在各层之间上下移动；英伟达将 KV 缓存的各层标记为 G1 到 G4。*另见：* KV 缓存卸载、推理上下文内存存储。

Straggler（掉队者） — 完成得较晚、使同步步骤中其他所有参与者都必须等待的 GPU、链路或数据流。原因包括路径拥塞、硬件缓慢或故障，以及工作量分配不均。*另见：* 尾延迟。

Straight-line depreciation（直线折旧） — 将资产成本在其使用寿命内平均分摊（例如一块 $70K 的 GPU 分六年折旧 = 每年约 $11.7K）。它忽略了融资成本，而资本回收系数会将其计入。*另见：* 使用寿命、资本回收系数。

Streaming multiprocessor (SM)（流式多处理器） — 英伟达 GPU 中重复出现的基本构建单元：一组 CUDA 核心、四个张量核心、一个寄存器堆以及自有的 L1/共享内存。H100 有 132 个 SM，Rubin GPU 有 224 个。*另见：* 张量核心、CUDA 核心、图形处理簇（GPC）。

Subnet manager（子网管理器） — InfiniBand 的控制软件，负责发现每台交换机和适配器、分配地址并计算整个网络的路由表。这使 InfiniBand 成为集中管理的网络，而不像以太网那样自组织。*另见：* InfiniBand。

Superchip（超级芯片） — 英伟达对以 NVLink-C2C 将一颗 CPU 与一到两块 GPU 连接在同一模块上的产品的称呼，例如 GH200（一颗 Grace、一块 Hopper）或 GB200（一颗 Grace、两块 Blackwell）。*另见：* NVLink-C2C。

SuperNIC — 英伟达对专为 GPU 间流量调优的网络适配器的称呼（ConnectX-8/9、BlueField-3 SuperNIC）：在硬件中实现 RDMA、拥塞控制以及对喷洒数据包的重排序，通常每块 GPU 配一块。*另见：* RDMA（远程直接内存访问）、数据包喷洒、Spectrum-X。

SuperPoD（超节点） — 厂商对作为一个整体销售的多机架 AI 系统的称呼：英伟达的 DGX SuperPOD（例如八个 GB200 NVL72 机架）或华为的 Atlas 超节点（SuperPoD，在一个纵向扩展域中集成数千颗昇腾芯片）。*另见：* DGX、纵向扩展（scale-up）。

Supply prepayment（供应预付款） — 买方为预留未来产能或产出而预先支付给供应商的现金；在买方资产负债表上列为预付资产，若需求崩塌则可能无法收回。*另见：* 采购义务、长期协议（LTA）。

Supply-constrained（供给受限） — 供应商能卖出其全部产出的市场。在这种情况下，失去一个客户短期内损失不大，因为产能会转售给其他客户。*另见：* 毛利率。

Switch radix（交换机端口数） — 交换机在给定速率下的端口数量（radix）。端口数越高，每层可连接的端点越多，同等规模的集群所需的层数、跳数和光模块都越少。*另见：* 胖树。

Switching cost（转换成本） — 客户转向竞争对手产品所承担的资金、时间和风险，此处指把内核、工具和团队技能从 CUDA 移植并重新验证到另一技术栈。*另见：* 硬件拉动、转译层。

SYCL — Khronos 组织的开放标准，用于编写可在不同厂商的 CPU、GPU 和加速器上运行的 C++ 代码。英特尔的 oneAPI 即基于它构建。*另见：* oneAPI。

system-on-chip（片上系统） — 在单颗芯片上集成 CPU 核心、图形、内存控制器及其他功能，用于手机和平板电脑（例如英伟达的 Tegra）。*另见：* 基带调制解调器。

Systolic array（脉动阵列） — 由乘累加单元组成的网格，数据以固定节拍流经其中，每个单元把结果传给相邻单元。谷歌 TPU 的矩阵单元是 128×128 或 256×256 的脉动阵列：处理大矩阵极其高效，但对不规则形状不够灵活。*另见：* ASIC。

T

Tail latency（尾延迟） — 最慢那部分消息的延迟（例如第 99 或第 99.9 百分位），而非平均值。在同步 AI 训练中，整个步骤都要等待最慢的传输完成，因此决定节奏的是尾部而非均值。*另见：* 掉队者、集合通信操作。

Take-or-pay contract（照付不议合同） — 买方无论是否使用都须为预留容量付费的合同。新兴云服务商与 AI 实验室和超大规模云厂商签订多年期照付不议合同，再以此为担保借款。*另见：* 收入积压、GPU 抵押贷款。

Tape-out（流片） — 完成的芯片设计交付晶圆代工厂制作光掩模和首批晶圆的时刻。流片失败会耽误数月，并在掩模上损失数千万美元。*另见：* NRE（一次性工程费用）、光掩模。

TCO (total cost of ownership)（总拥有成本） — 基础设施在整个生命周期内的全口径运行成本：资本成本（折旧）加上电力、散热、空间、网络、软件和运维。在 AI 领域常折算为每百万 token 的美元成本。

TDISP — PCI-SIG 的 TEE 设备接口安全协议（TEE Device Interface Security Protocol）：以经认证的加密链路（而非软件中转缓冲区）将 PCIe 设备（GPU、网卡、SSD）纳入 CPU 机密虚拟机的标准方式。*另见：* 可信执行环境（TEE）、AMD SEV-SNP、Intel TDX。

Telemetry (network)（网络遥测） — 持续测量网络和网卡内部的流量、拥塞、错误和延迟，用于发现掉队者并调优拥塞控制。*另见：* 数据处理器（DPU）。

Tensor core（张量核心） — 英伟达 GPU 内部的专用单元，一步完成小矩阵乘法，提供 GPU 的大部分 AI 吞吐量。随 Volta（2017 年）推出。*另见：* GPU、FLOPS。

Tensor memory (TMEM)（张量内存） — Blackwell 引入的每个 SM 256 KB 的暂存存储，保存张量核心的累加器和操作数，从而释放寄存器，并持续为更大的张量核心供数。*另见：* 张量核心、寄存器堆。

Tensor Memory Accelerator (TMA)（张量内存加速器） — Hopper 时代引入的硬件单元，在后台于 HBM/L2 与共享内存之间复制张量的整个分块，使线程能继续计算，而不必逐个发出加载指令。*另见：* 共享内存。

Tensor parallelism (TP)（张量并行） — 将每层的权重矩阵拆分到多块 GPU 上，由它们共同计算同一层；每层内部都需要一次全规约，因此通常限制在高速的 NVLink 域内。*另见：* NVLink、全规约。

TensorRT — 英伟达的推理优化器和运行时：接收训练好的模型，融合并量化其运算，生成针对特定英伟达 GPU 调优的引擎。TensorRT-LLM 是其大语言模型分支。*另见：* cuDNN、GPU 内核。

TensorRT-LLM — 英伟达用于在其 GPU 上高速运行大语言模型的开源库：定制内核，加上连续批处理、分页 KV 缓存、FP8/FP4 量化和推测解码等运行时功能。*另见：* TensorRT、Dynamo、连续批处理。

Test-time compute（测试时计算） — 为每个查询投入更多推理计算（更长的推理链、多次尝试、搜索）以获得更好的答案，而非训练更大的模型。*另见：* 推理型模型、智能体 AI。

TF32 (TensorFloat-32) — Ampere 引入的 19 位张量核心格式，保留 FP32 的数值范围，但只有 10 位尾数，使 FP32 代码无需修改即可使用张量核心；数值仍以 32 位存储。*另见：* BF16 (bfloat16)、FP8。

Thread block（线程块） — 最多 1,024 个 GPU 线程组成的一组，在同一个 SM 上运行，共享高速片上存储，并可相互同步。一次内核启动即由线程块构成的网格。*另见：* CUDA 网格、线程束、共享内存。

Through-silicon via (TSV)（硅通孔） — 蚀刻穿过减薄硅裸片的垂直铜导线，使堆叠的裸片能直接上下传递数据、电源和接地。每颗裸片上数以千计的 TSV 使 HBM 堆栈成为可能。*另见：* 高带宽内存（HBM）、HBM 基础裸片、微凸块。

Throughput-interactivity Pareto frontier（吞吐量-交互速度帕累托前沿） — 在每个单用户 tokens/s（交互速度）下所能达到的最佳单 GPU tokens/s（吞吐量）所构成的曲线。比较硬件和软件代际时，看的是它们把整条曲线向外推了多远。*另见：* 批处理、TPOT/ITL。

TileLang — tile-ai 项目推出的开源 Python 内核语言，用于 DeepSeek 的注意力内核。它支持英伟达 CUDA、AMD ROCm 和苹果 Metal，并自 2026 年 9 月起支持华为昇腾 950。*另见：* Triton (OpenAI)、MLIR。

Time to power（通电时间） — 数据中心站点从向电力公司提出申请到获得通电容量所需的时间。对 AI 项目而言，它往往比建造厂房本身还要长。*另见：* 并网排队、表后发电。

Time to train（训练时长） — 一次训练运行在给定集群上所需的日历天数。更快的芯片或更大的集群可以缩短它；对前沿实验室而言，提早发布模型的价值可能高于算力账单。*另见：* MFU（模型 FLOPs 利用率）、有效吞吐量。

Token（词元） — 语言模型读写文本的基本单位，大约相当于四分之三个英文单词。AI 经济学越来越多地以每秒 token 数和每百万 token 的美元成本来计量。

Token price deflation（token 价格通缩） — 达到固定模型质量所需的每百万 token 价格快速下降，视任务不同估计每年下降 9 倍至 900 倍；前沿模型的标价并不总是下降。*另见：* 混合 token 价格。

Token-parity rent（token 平价租金） — 租用旧款加速器时，使其每 token 成本与最新一代持平的小时价格。当新芯片降低每 token 成本时，旧芯片的平价租金随之下降，从而拉低租赁价格。*另见：* 经济寿命、token 价格通缩。

Tokens per second per megawatt（每兆瓦每秒 token 数） — AI 工厂的产出指标：在给定单用户速度下，集群每消耗一兆瓦电力每秒生成多少 token。它把固定的电力预算转化为收入产能。*另见：* AI 工厂、吞吐量-交互速度帕累托前沿、token、交互速度（每用户 tokens/s）、每瓦性能。

Topology-aware scheduling（拓扑感知调度） — 依据物理网络放置作业的 GPU：例如把一个张量并行组保持在同一个 NVLink 域或同一个机架内，使其大流量永远不必经过较慢的链路。*另见：* 成组调度、GPU 碎片化。

TOPS (tera-operations per second)（每秒万亿次运算） — 每秒万亿次运算，通常指整数（INT8）运算；是 NPU 和边缘 AI 芯片的标称指标。它与按浮点格式标注的 FLOPS 不能直接比较。*另见：* FLOPS。

torch.compile — PyTorch 2 的编译器：捕获模型的运算并生成融合内核（默认通过 Triton），而不是调用预先编写好的内核，这使硬件后端更易替换。*另见：* Triton (OpenAI)。

TorchInductor — PyTorch 2 中 torch.compile 的默认编译器后端。它融合运算，为 GPU 生成 Triton 内核，为 CPU 生成 C++ 代码。*另见：* torch.compile、Triton (OpenAI)。

TorchTPU — 谷歌面向 TPU 的原生 PyTorch 软件栈，2026 年 10 月与 Meta 共同开源，以取代 PyTorch/XLA，使 PyTorch 模型无需用 JAX 重写即可在 TPU 上运行。*另见：* PyTorch、JAX、XLA。

Tornado chart（龙卷风图） — 一种敏感性分析图表：每次只让一个输入在低值和高值之间变动，并按其对结果的影响幅度对输入排序，最宽的横条即显示最关键的假设。*另见：* 蒙特卡洛模拟。

Torus topology（环面拓扑） — 一种网络，每颗芯片只与各维度上的相邻芯片相连，两端首尾相接成环。它能以低成本扩展到数千颗芯片，但发往远端芯片的消息需经过许多跳，并沿途共享带宽。*另见：* ICI（芯片间互连）、光路交换机（OCS）、全交换。

TPC-DS — 一项标准的决策支持基准测试，包含约 100 个基于零售类数据的 SQL 查询。厂商“源自”该基准的测试并非官方经审计的 TPC 结果。*另见：* Apache Spark。

TPOT / ITL (time per output token / inter-token latency)（每输出 token 时间 / token 间延迟） — 流式输出中相邻两个 token 之间的间隔；1/TPOT 即每用户每秒 token 数。主要由解码带宽和批大小决定。*另见：* 解码（decode）、TTFT（首 token 时间）。

TPP (total processing performance)（总处理性能） — 美国出口管制衡量 AI 芯片算力的指标：大致为稠密 TFLOPS（或 TOPS）乘以运算的位宽。TPP 达到或超过 4,800 的芯片须获许可证才能运往中国。*另见：* 性能密度。

TPU (Tensor Processing Unit)（张量处理器） — 谷歌自研的 AI 加速器芯片系列，从 2015 年的推理卡（v1）到 Ironwood（v7，2025 年）以及 2026 年的 TPU 8t/8i。每颗芯片都围绕大型矩阵乘法单元构建，芯片互连组成最多约 9,600 颗的 pod。*另见：* ASIC、ICI（芯片间互连）、脉动阵列。

Trainium — AWS 自研的 AI 加速器，用于训练和推理，仅以 AWS 云容量形式出售；已有 Trn1（2022 年）、Trn2（2024 年）、Trn3（2025 年）三代，Trainium4 已宣布。*另见：* UltraServer、Neuron SDK。

transform and lighting（变换与光照） — 确定每个 3D 顶点在屏幕上的位置、并计算光线如何照射到它的步骤；GeForce 256（1999 年）把这些步骤从 CPU 转移到了图形硬件中。*另见：* 固定功能管线。

Transformer — 现代语言模型背后的神经网络设计：由一系列相同的层堆叠而成，每层包含一个注意力模块（token 关注此前的 token）和一个前馈模块（大部分参数位于其中）。*另见：* 注意力机制、神经网络。

Transformer Engine — 英伟达将张量核心硬件与软件库相结合的方案，自动选择数值格式（自 Hopper 起支持 FP8，自 Blackwell 起支持 FP4/NVFP4）以及张量级或块级缩放因子，使模型能以更低精度运行而不损失准确性。*另见：* FP8、NVFP4、微缩放（MX）格式。

Translation layer（转译层） — 使为某一平台构建的程序无需重新编译即可在另一平台上运行的软件，例如让未经修改的 CUDA 二进制文件在非英伟达 GPU 上运行的 ZLUDA。英伟达的 CUDA 许可协议限制此类用途。*另见：* HIPIFY、CUDA。

Tree all-reduce（树形全规约） — 一种全规约算法，沿节点树向上求和，再向下广播结果。它约需 2·log2(N) 跳，而环形算法需要 2(N−1) 跳，因此在大规模下延迟低得多。*另见：* 环形全规约、NCCL。

Triton (OpenAI) — 一种开源的类 Python 语言和编译器，用于编写 GPU 内核，最初由 OpenAI 开发。PyTorch 的编译器会生成 Triton 代码，且 Triton 拥有英伟达、AMD 等后端，因此内核不必用 CUDA 编写。*另见：* torch.compile、GPU 内核。

Triton Inference Server — 英伟达的通用开源模型服务器（2018 年推出，当时名为 TensorRT Inference Server），现更名为 Dynamo-Triton；通过统一的 API 服务多种模型类型和框架。*另见：* Dynamo。

Trusted execution environment (TEE)（可信执行环境） — 硬件隔离的区域（CPU 上的机密虚拟机、处于机密模式的 GPU），其内存和状态无法被主机操作系统、虚拟机管理程序和云运营方读取或篡改。*另见：* 机密计算、远程证明。

TTFT (time to first token)（首 token 时间） — 用户从发送请求到看到第一个 token 之间的等待时间。主要由预填充计算和排队时间决定。*另见：* 预填充（prefill）、TPOT/ITL。

Turnkey ASIC（交钥匙 ASIC） — 一种定制芯片模式：设计合作伙伴负责物理设计、IP、封装、测试和晶圆代工供应，并按单价向客户出售成品芯片。*另见：* 客户自有工具模式（COT）、ASIC 设计合作伙伴。

Tying (antitrust)（搭售） — 以购买另一产品作为销售某一产品的条件，例如只有搭配厂商自家的网络设备才出售 GPU；当卖方在第一种产品上拥有市场支配力时，这可能违反竞争法。*另见：* 行为性救济措施。

U

UALink (Ultra Accelerator Link) — 一项开放的纵向扩展互连标准，由 2024 年成立的联盟（AMD、英特尔、谷歌、微软、Meta、AWS 等）制定。它让加速器通过 UALink 交换机读写彼此的内存，采用 200G 通道，单个 pod 最多 1,024 个设备。*另见：* NVLink、ESUN (Ethernet for Scale-Up Networking)、纵向扩展（scale-up）。

UALink over Ethernet (UALoE)（基于以太网的 UALink） — 通过普通以太网交换芯片、而非专用 UALink 交换机承载 UALink 的内存式协议。在原生 UALink 芯片尚未问世之际，AMD 的 Helios 机架搭配博通 Tomahawk 6 交换机采用了这一方案。*另见：* UALink (Ultra Accelerator Link)、Scale-Up Ethernet（SUE）。

UCC (Unified Collective Communication) — Unified Communication Framework 联盟推出的开源集合通信库，面向 HPC 和 AI，并把硬件卸载的集合通信作为一等公民来支持。*另见：* MPI（消息传递接口）、NCCL。

UCIe (Universal Chiplet Interconnect Express) — 在同一封装内连接芯粒的开放标准。有报道称，在 NVLink Fusion 框架下，第三方芯片可经由 UCIe 接入 NVLink 芯粒。*另见：* 芯粒、NVLink Fusion。

Ultra Ethernet (UEC)（超以太网） — 超以太网联盟（Ultra Ethernet Consortium）发布的行业规范（1.0 版于 2025 年 6 月发布），在标准以太网上增加面向 AI 的传输层、数据包喷洒、拥塞控制等功能，使任何厂商的网卡和交换机都能比肩专有 AI 网络。*另见：* RoCE (RDMA over Converged Ethernet)、数据包喷洒。

UltraServer — AWS 对通过 NeuronLink 纵向扩展互连组成一个域的一组 Trainium 芯片的称呼：64 颗 Trainium2，或最多 144 颗 Trainium3。*另见：* NeuronLink、纵向扩展（scale-up）。

Unified memory（统一内存） — CPU 和 GPU 共享同一虚拟地址空间的编程模型，同一个指针在两者上都有效。借助一致性互连（NVLink-C2C），GPU 可以直接读取 CPU 内存；若经由 PCIe，则须由驱动迁移内存页，速度要慢得多。*另见：* 缓存一致性、NVLink-C2C。

Unified shader architecture（统一着色器架构） — 英伟达于 2006 年随 G80 推出的 GPU 设计，由一池相同的可编程核心处理所有图形阶段。CUDA 正是把这些通用核心开放给非图形工作使用。*另见：* GPGPU、CUDA。

UnifiedBus (UB)（灵衢） — 华为的纵向扩展互连（中文名“灵衢”），用于 CloudMatrix 384 和 Atlas 超节点。它通过 UB 交换机连接数百至数千颗昇腾 NPU，主要采用光互连。*另见：* 纵向扩展（scale-up）、光路交换机（OCS）。

Useful life (depreciation)（使用寿命） — 公司分摊 GPU 服务器等资产成本的年限；使用寿命越长，年度折旧越低，报告利润越高。*另见：* GPU 小时。

Utilization (fleet)（集群利用率） — 已装机加速器小时中用于付费或有效工作的比例。由于加速器的大部分成本是固定的，每个有效小时的成本与 1 ÷ 利用率成正比。*另见：* 分配率、MFU（模型 FLOPs 利用率）、有效吞吐量。

UXL Foundation（UXL 基金会） — Linux 基金会于 2023 年成立的联盟，负责管理 oneAPI 规范和库，作为与厂商无关的 CUDA 替代方案；创始成员包括英特尔、Arm、谷歌云和高通，据报道 AMD 已于 2026 年加入。*另见：* oneAPI。

V

Value pool（价值池） — 产业价值链某一环节（例如 HBM、交换芯片或机架组装）中可获取的利润，以及由谁获取。某一层级可能在战略上至关重要，但对掌控它的公司而言却只是一个很小的价值池。*另见：* 定价权。

Variant calling（变异检测） — 基因组分析中找出个人 DNA 与参考基因组差异位置的步骤；是临床测序流程中计算最密集的核心环节。*另见：* Parabricks。

Vector search（向量搜索） — 查找嵌入向量（编码语义的数值列表）与查询最接近的已存储条目；是 RAG 和推荐系统中的检索步骤。*另见：* cuVS。

Vendor financing（供应商融资） — 供应商向自己的客户放贷、投资或提供担保，使其能购买自家产品。在 1999–2001 年前后的电信设备行业很常见，并放大了随后的崩盘。*另见：* 循环融资、算力兜底承诺。

Vertical integration（垂直整合） — 拥有价值链上相继的多个层级（芯片、网络、编译器、数据中心、模型），使它们能被一体化设计，且各层之间无需支付供应商利润。*另见：* 软硬件协同设计。

Vesting milestone（归属里程碑） — 认股权证或股票奖励的某一批次可以行权之前必须满足的条件，例如部署达到一定吉瓦数，或股价达到某一水平。*另见：* 认股权证、稀释。

Virtual switch（虚拟交换机） — 在虚拟机或容器与物理网络之间转发数据包并执行租户规则的软件（例如 Open vSwitch，即 OVS）。在主机上运行它会占用 CPU 核心；DPU 则在硬件中运行它。*另见：* 叠加网络、数据处理器（DPU）。

vLLM — 使用最广泛的开源 LLM 推理引擎（PagedAttention、连续批处理）。它在主代码树中原生支持英伟达和 AMD GPU，并通过插件支持 TPU、Gaudi、昇腾、Trainium 和高通 Cloud AI。*另见：* SGLang、推理。

W

Wafer（晶圆） — 超高纯度硅制成的薄圆片，先进制程芯片所用晶圆直径为 300 mm，其上印制数百颗相同的裸片，随后切割分离。晶圆代工厂按加工完成的晶圆片数为产出定价。*另见：* 裸片、晶圆代工厂。

Wafer-scale engine（晶圆级引擎） — 以整片硅晶圆而非单颗裸片构建的处理器，例如 Cerebras 的 WSE-3（46,225 mm^2，44 GB 片上 SRAM）。它免去了芯片间互连，但需要特殊的封装、供电和散热。*另见：* 裸片、光罩尺寸极限。

Warp（线程束） — 在一个 SM 上以锁步方式执行同一条指令的 32 个 GPU 线程。它是硬件调度的单位，因此能让全部 32 个线程保持忙碌的代码运行最快。*另见：* 流式多处理器（SM）。

Warrant（认股权证） — 以固定价格购买公司股份的权利（AMD 给 OpenAI 的认股权证：每股 $0.01），通常仅在满足条件时才归属。发行人无需支付现金，但会稀释现有股东。*另见：* 稀释。

White-box switch（白盒交换机） — 由 ODM（例如天弘（Celestica）、智邦（Accton））基于商用芯片制造、不预装厂商操作系统出售的交换机；买家自行运行 SONiC、FBOSS 或自有软件。*另见：* 商用芯片、网络操作系统（NOS）。

Wide expert parallelism (wide EP)（大规模专家并行） — 将混合专家模型的专家分散到大量 GPU 上（例如 64-144 块），使每块 GPU 只承载少数几个专家。它为更大的批次和缓存腾出内存，但使分发与合并流量需跨越更多 GPU。*另见：* 专家并行（EP）、分发与合并、NVLink 域。

X

x86 — 英特尔和 AMD 处理器自 1970-80 年代以来使用的指令集。只有英特尔和 AMD 持有制造 x86 服务器 CPU 的授权，大多数传统企业软件都是为其编译的。*另见：* ISA（指令集架构）、Arm 指令集。

XLA — Accelerated Linear Algebra（加速线性代数）：将整个模型计算图编译为面向 TPU、GPU 或 CPU 的优化代码的编译器。被 JAX 以及（此前）TPU 上的 PyTorch 所采用。*另见：* JAX、MLIR。

XPU (custom accelerator)（定制加速器） — 业界对由某一客户自行设计或为其定制的 AI 加速器的简称，例如谷歌 TPU、AWS Trainium、微软 Maia 或 Meta MTIA。*另见：* ASIC、ASIC 设计合作伙伴。

Z

ZeRO (Zero Redundancy Optimizer)（零冗余优化器） — 微软的技术，把优化器状态（第 1 阶段）、梯度（第 2 阶段）和权重（第 3 阶段）分片分布到数据并行的各 GPU 上，而非在每块 GPU 上复制，从而降低每块 GPU 的内存占用。*另见：* FSDP、数据并行（DP）。

Zero-code-change acceleration（零代码改动加速） — 通过替换底层引擎，在 GPU 上运行现有代码（pandas、scikit-learn、Polars、Spark），无需重写，遇到不支持的操作时自动回退到 CPU。*另见：* cudf.pandas、cuML。

Zero-trust isolation（零信任隔离） — 一种安全设计，默认不信任任何组件（包括主机操作系统）；每次访问都需认证，策略在租户无法控制之处执行，例如在 DPU 上。*另见：* 多租户、硬件信任根。

ZT Systems — 美国机架级服务器设计公司，AMD 以 $4.9B 将其收购（2025 年 3 月完成）；AMD 保留了打造 Helios 的设计团队，并将工厂出售给 Sanmina。*另见：* AMD Helios、ODM。

附录 · 参考文献（Bibliography）

按来源编号排列；书目信息保留英文原文。完整链接见仓库 sources/bibliography.md。

S1 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Announces Financial Results for Fourth Quarter and Fiscal 2026 (Form 8-K exhibit 99.1)* · 2026-02-25

S2 · U.S. Securities and Exchange Commission (EDGAR) · *NVIDIA Corporation Form 10-K annual reports FY2020–FY2025 (filing index)* · 2025-02-26

S3 · StorageNewsletter · *NVIDIA Q2 Fiscal 2027 results coverage: revenue $96.2B* · 2026-08-27

S100 · NVIDIA Technical Blog · *Inside the NVIDIA Vera Rubin Platform: Six New Chips, One AI Supercomputer* · 2026-01-05

S101 · NVIDIA · *NVIDIA HGX Platform (HGX Rubin NVL8, HGX B300, HGX B200 specifications)* · 2026

S102 · NVIDIA · *NVIDIA DGX Vera Rubin NVL72* · 2026

S103 · VideoCardz · *NVIDIA quietly cuts Vera Rubin specs, HBM4 bandwidth and NVLink 6 speeds now lower* · 2026-10

S104 · Wccftech · *NVIDIA's Official Statement on Vera Rubin Spec Change* · 2026-10-29

S105 · Hardware Busters · *Nvidia Quietly Lowers Vera Rubin HBM4 Bandwidth, and the HGX NVL8 Loses a Quarter of It* · 2026-10

S106 · SemiAnalysis · *Vera Rubin - Extreme Co-Design: An Evolution* · 2026

S107 · Tom's Hardware · *Nvidia's Vera Rubin platform in depth - Inside Nvidia's most complex AI and HPC platform to date* · 2026

S108 · HPCwire / Alwire · *Huang Shares Nvidia Roadmap Showing More Chips, NVL1152, Scale-Up CPO* · 2026-03-18

S109 · NVIDIA Blog · *NVIDIA GTC 2026: Live Updates on What's Next in AI* · 2026-03-16

S110 · Tom's Hardware · *Nvidia demonstrates Rubin Ultra tray, the world's first AI GPU with 1TB of HBM4E memory* · 2026-03

S111 · Crypto Briefing · *Nvidia's Rubin Ultra targets 768GB of HBM4E as Kyber platform stays on schedule* · 2026

S112 · Glenn K. Lockwood (blog) · *GTC 2026 recap* · 2026-03

S113 · Tom's Hardware · *How Nvidia's $20 billion Groq 3 LPU deal reshapes the Nvidia Vera Rubin Platform* · 2026-03

S114 · StorageReview · *NVIDIA Groq 3 LPX: Everything we know* · 2026-03

S115 · Tom's Hardware · *Nvidia removes Rubin CPX accelerators from its roadmap - Groq 3 LPUs take center stage* · 2026-03

S116 · Wccftech · *NVIDIA's Rubin CPX Is Off the Roadmap, Replaced by Groq LPUs for Inference, But May Return With Feynman in 2028* · 2026-03

S117 · TechNews (Taiwan) · *Nvidia Rubin CPX re-enters roadmap with HBM4 for AI prefill* · 2026-09-02

S118 · Tom's Hardware · *Former Groq engineers sue board over $20 billion Nvidia deal* · 2026

S119 · XenoSpectrum · *NVIDIA's Feynman May Combine TSMC A16 and N3P, Reports Say* · 2026

S120 · SemiAnalysis · *Nvidia - The Inference Kingdom Expands (GTC 2026)* · 2026-03

S121 · NVIDIA · *NVIDIA GB200 NVL72* · 2024-03

S123 · Glenn K. Lockwood (blog) · *HGX B300 specifications compilation (B300 per-GPU figures)* · 2025

S125 · NVIDIA · *NVIDIA Tesla P100 (Pascal GP100) Architecture Whitepaper* · 2016-04

S126 · NVIDIA · *NVIDIA Tesla V100 GPU Architecture Whitepaper* · 2017-08

S127 · NVIDIA Technical Blog · *NVIDIA Ampere Architecture In-Depth* · 2020-05-14

S128 · NVIDIA · *NVIDIA GH200 Grace Hopper Superchip* · 2023-08

S129 · NVIDIA · *NVIDIA Grace CPU* · 2023

S130 · NVIDIA Newsroom · *NVIDIA and Intel to Develop AI Infrastructure and Personal Computing Products* · 2025-09-18

S131 · NVIDIA Newsroom · *NVIDIA NVLink Fusion: semi-custom AI infrastructure partner ecosystem (Computex 2025)* · 2025-05-19

S140 · AMD · *AMD Instinct MI250X Accelerator* · 2021-11-08

S141 · AMD · *AMD Instinct MI300X Accelerator* · 2023-12-06

S142 · AMD · *AMD Instinct MI325X Accelerator* · 2024-10-10

S143 · AMD · *AMD Instinct MI350 Series (MI350X, MI355X)* · 2025-06-12

S144 · AMD Newsroom · *AMD Unveils Vision for an Open AI Ecosystem, Detailing New Silicon, Software and Systems at Advancing AI 2025* · 2025-06-12

S145 · AMD · *AMD at CES 2026 (keynote: Helios, MI455X, MI440X, MI500 preview)* · 2026-01-05

S146 · Google Cloud · *Cloud TPU v4 documentation* · 2021

S147 · ISCA 2023 (arXiv 2304.01433) · *TPU v4: An Optically Reconfigurable Supercomputer for Machine Learning with Hardware Support for Embeddings* · 2023-04-04

S148 · Google Cloud · *Cloud TPU v5e documentation* · 2023-08

S149 · Google Cloud · *Cloud TPU v5p documentation* · 2023-12

S150 · Google Cloud · *Cloud TPU v6e (Trillium) documentation* · 2024-12

S151 · Google Blog · *Ironwood: The first Google TPU for the age of inference* · 2025-04-09

S152 · AWS Neuron SDK docs · *AWS Neuron documentation: Trainium (Trn1) architecture* · 2022

S153 · AWS Neuron SDK docs · *AWS Neuron documentation: Inferentia2 architecture* · 2023

S154 · AWS Neuron SDK docs · *AWS Neuron documentation: Trainium2 architecture* · 2024-12

S155 · Amazon Web Services · *AWS Trainium (product page: Trn2, Trn3)* · 2025-12

S156 · About Amazon · *AWS re:Invent 2025: top announcements (Trainium3 GA, Trainium4 preview, Graviton5)* · 2025-12-02

S157 · Microsoft Tech Community · *Inside Maia 100: Revolutionizing AI Workloads with Microsoft's Custom AI Accelerator* · 2024-08-27

S158 · Microsoft · *Maia 200: Microsoft's AI accelerator built for inference* · 2026-01

S159 · Meta AI Blog · *MTIA v1: Meta's first-generation AI inference accelerator* · 2023-05-18

S160 · Meta AI Blog · *Our next-generation Meta Training and Inference Accelerator* · 2024-04-10

S161 · Intel · *Intel Gaudi AI accelerators (Gaudi 2, Gaudi 3)* · 2024-04-09

S162 · Intel Newsroom · *Intel to Expand AI Accelerator Portfolio with New GPU (Crescent Island)* · 2025-10-14

S163 · Huawei · *Huawei Connect 2025 keynote: Ascend roadmap and SuperPoD interconnect (Eric Xu)* · 2025-09-18

S164 · CSIS · *DeepSeek, Huawei, Export Controls, and the Future of the U.S.-China AI Race* · 2025-03-07

S165 · Cambricon · *Cambricon Technologies (corporate site; Siyuan/MLU product line)* · 2025

S166 · Cerebras · *Cerebras Systems Unveils World's Fastest AI Chip with 4 Trillion Transistors (WSE-3)* · 2024-03-13

S167 · ISCA 2022 (ACM) · *A Software-defined Tensor Streaming Multiprocessor for Large-scale Machine Learning (Groq)* · 2022-06

S168 · arXiv 2405.07518 · *SambaNova SN40L: Scaling the AI Memory Wall with Dataflow and Composition of Experts* · 2024-05-13

S169 · Tenstorrent · *Tenstorrent Blackhole* · 2025

S170 · d-Matrix · *d-Matrix Corsair inference platform* · 2024-11-19

S171 · Etched · *Etched is Making the Biggest Bet in AI (Sohu announcement)* · 2024-06-25

S172 · Qualcomm · *Qualcomm Cloud AI 100 (incl. Cloud AI 100 Ultra)* · 2023-11

S173 · Qualcomm · *Qualcomm Unveils AI200 and AI250 - Redefining Rack-Scale Data Center Inference* · 2025-10-27

S174 · OpenAI · *OpenAI and Broadcom announce strategic collaboration to deploy 10 gigawatts of OpenAI-designed AI accelerators* · 2025-10-13

S175 · AMD · *AMD EPYC 9004 Series (Genoa)* · 2022-11-10

S176 · AMD · *AMD EPYC 9005 Series (Turin)* · 2024-10-10

S177 · AMD · *AMD EPYC 7742* · 2019-08-07

S178 · Intel ARK · *Intel Xeon Processor E5-2698 v4 specifications* · 2016-03

S179 · Intel · *Intel Xeon 6 processors with P-cores (Granite Rapids, 6900P/6700P)* · 2024-09-24

S180 · Intel · *Intel Xeon processors (family and roadmap: Xeon 6+ Clearwater Forest, Diamond Rapids)* · 2025

S181 · Amazon Web Services · *AWS Graviton Processor* · 2024

S182 · Google Cloud Blog · *Introducing Google Axion Processors, our new Arm-based CPUs* · 2024-04-09

S183 · Microsoft Azure Blog · *Azure Cobalt 100-based virtual machines are now generally available* · 2024-10

S184 · Microsoft Tech Community · *Announcing Cobalt 200: Azure's next cloud-native CPU* · 2025-11-18

S185 · Ampere Computing · *AmpereOne processors* · 2023-05

S186 · SoftBank Group · *SoftBank Group to acquire Ampere Computing for US$6.5 billion* · 2025-03-19

S187 · Fujitsu · *FUJITSU-MONAKA: next-generation Arm-based processor* · 2025

S188 · NVIDIA Docs · *NVIDIA DGX A100 User Guide - Introduction (system specifications)* · 2020

S189 · NVIDIA Docs · *NVIDIA DGX-1 User Guide - Introduction (system specifications)* · 2017

S200 · NVIDIA · *NVIDIA NVLink and NVLink Switch (product page with NVLink and NVLink Switch specification tables)* · 2026-09

S201 · VideoCardz · *NVIDIA quietly cuts Vera Rubin specs, HBM4 bandwidth and NVLink 6 speeds now lower* · 2026-10

S202 · Wccftech · *NVIDIA's official statement on Vera Rubin spec change* · 2026-11

S203 · SemiAnalysis · *Vera Rubin - Extreme Co-Design: An Evolution* · 2026-01

S204 · Network World · *At CES, Nvidia launches Vera Rubin platform for AI data centers* · 2026-01-06

S205 · NVIDIA Technical Blog · *Upgrading Multi-GPU Interconnectivity with the Third-Generation NVIDIA NVSwitch* · 2022-08

S206 · Hot Chips / NVIDIA · *NVSwitch and DGX-2 (Hot Chips 30 presentation)* · 2018-08

S207 · glennklockwood.com · *NVLink (digital garden notes)* · 2025

S208 · Wccftech · *NVIDIA deep dives into Blackwell infrastructure: NV-HBI used to fuse two AI GPUs together (Hot Chips 2024)* · 2024-08

S209 · DatacenterDynamics · *Nvidia announces Vera Rubin superchip for late 2026* · 2025-10-28

S210 · SemiAnalysis · *Nvidia - GTC 2026: The Inference Kingdom Expands* · 2026-03

S211 · glennklockwood.com · *GTC 2026 recap* · 2026-03

S212 · Tech Times · *Nvidia Kyber NVL144 slips to 2028 as physics, not software, defeats the backup plan* · 2026-07-09

S213 · Inside Deep Tech · *NVIDIA Feynman: Full Guide to the 2028 GPU, Rosa and Kyber* · 2026

S214 · Inside Deep Tech · *NVIDIA Rubin Ultra and Kyber: Full Guide to NVL144 and NVL576* · 2026

S215 · Tom's Hardware · *Nvidia announces NVLink Fusion to allow custom CPUs and AI accelerators to work with its products* · 2025-05-19

S216 · ServeTheHome · *NVIDIA announces NVLink Fusion bringing NVLink to third-party CPUs and accelerators (partner slide)* · 2025-05-19

S217 · NVIDIA via Barchart · *NVIDIA Unveils NVLink Fusion for Industry to Build Semi-Custom AI Infrastructure With NVIDIA Partner Ecosystem (press release, syndicated)* · 2025-05-19

S218 · Converge Digest · *NVIDIA invests $2B in Marvell to extend NVLink Fusion AI ecosystem* · 2026-03-31

S219 · Converge Digest · *Arm extends Neoverse with NVIDIA NVLink Fusion* · 2025-11

S220 · PCI-SIG via Business Wire · *PCI-SIG Releases PCIe 7.0 Specification to Support the Bandwidth Demands of AI at 128.0 GT/s* · 2025-06-11

S221 · PCI-SIG via Business Wire · *PCI-SIG announces PCIe 8.0 specification development at 256.0 GT/s* · 2025-08-05

S222 · Tom's Hardware · *PCI Express roadmap: the path to 1TB/s with PCIe 8.0, the challenges of integration, and beyond* · 2025

S223 · UALink Consortium · *UALink Consortium Releases the Ultra Accelerator Link 200G 1.0 Specification (news release)* · 2025-04-08

S224 · UALink Consortium · *UALink 200G 1.0 Specification Overview* · 2025-04-10

S225 · SDxCentral · *UALink Consortium 2.0 spec takes another swing at Nvidia's NVLink supremacy* · 2026-04

S226 · AMD · *AMD Helios Rackscale Solution (product page)* · 2026

S227 · AMD · *AMD Launches Helios: The Highest Performing Rackscale AI Infrastructure Solution* · 2026

S228 · Spheron · *AMD Helios rack-scale AI on GPU cloud: deploy MI455X inference with UALink and Ultra Ethernet (2026 guide)* · 2026

S229 · AMD · *AMD Instinct MI355X (product page)* · 2025-06-12

S230 · Lenovo Press · *AMD Instinct MI300X 192GB 750W Accelerator product guide (LP1943)* · 2024

S231 · Converge Digest · *Hot Chips 2025: AMD boosts Infinity Fabric* · 2025-08

S232 · Google Cloud · *TPU7x (Ironwood) - Cloud TPU documentation* · 2025-11

S233 · Google Cloud · *TPU v6e - Cloud TPU documentation* · 2024

S234 · Google Cloud · *TPU v5e - Cloud TPU documentation* · 2023

S235 · Google Cloud · *TPU v5p - Cloud TPU documentation* · 2023-12

S236 · Google Cloud · *TPU v4 - Cloud TPU documentation* · 2022

S237 · arXiv · *TPU v4: An Optically Reconfigurable Supercomputer for Machine Learning with Hardware Support for Embeddings (ISCA 2023)* · 2023-04

S238 · Google · *Our eighth generation TPUs: two chips for the agentic era* · 2026-04-22

S239 · DatacenterDynamics · *Google unveils eighth-generation TPUs, two dedicated training and inference chips* · 2026-04-22

S240 · StorageReview · *Google Announces TPU 8t Sunfish and TPU 8i Zebrafish* · 2026-04

S241 · i-SCOOP · *Inside Google's TPU 8t and TPU 8i, the silicon built for the agentic era* · 2026-04

S242 · Amazon Web Services · *Amazon EC2 Trn3 instances (product page)* · 2025-12-02

S243 · Amazon Web Services · *Trainium3 architecture (AWS Neuron documentation)* · 2025-12

S244 · Amazon Web Services · *Trainium2 architecture (AWS Neuron documentation)* · 2024-12

S245 · SemiAnalysis · *Amazon's AI self-sufficiency: Trainium2 architecture and networking* · 2024-12

S246 · HPCwire / AIwire · *AWS brings the Trainium3 chip to market with new EC2 UltraServers* · 2025-12-03

S247 · NAND Research · *Research Note: AWS releases Trainium3, teases Trainium4* · 2025-12

S248 · arXiv (Huawei) · *Serving Large Language Models on Huawei CloudMatrix384* · 2025-06

S249 · Huawei · *Groundbreaking SuperPoD Interconnect: Leading a New Paradigm for AI Infrastructure (Eric Xu keynote, Huawei Connect 2025)* · 2025-09-18

S250 · LightCounting · *July 2026 Atlas 950 SuperPoD: achieves all-optical interconnection with superior cost and power efficiency* · 2026-07

S251 · InfiniBand Trade Association · *InfiniBand Roadmap: charting speeds for future needs* · 2023

S252 · NVIDIA Docs · *InfiniBand Cables Primer Overview (DGX SuperPOD cabling design guide)* · 2024

S253 · FS Community · *Need for Speed - InfiniBand network bandwidth evolution* · 2023

S254 · IEEE 802.3 · *IEEE P802.3dj 200 Gb/s, 400 Gb/s, 800 Gb/s and 1.6 Tb/s Ethernet Task Force* · 2026

S255 · IEEE 802.3 · *IEEE 802.3df-2024: 400 Gb/s and 800 Gb/s Ethernet (100 Gb/s per lane)* · 2024-02

S256 · Ethernet Alliance · *The Ethernet Roadmap* · 2025

S257 · Ultra Ethernet Consortium · *Ultra Ethernet Consortium launches Specification 1.0* · 2025-06-11

S258 · Open Compute Project · *OCP launches Ethernet for Scale-Up Networking (ESUN) workstream (OCP Global Summit 2025)* · 2025-10-13

S259 · NVIDIA · *NVIDIA Tesla P100 (Pascal architecture) whitepaper* · 2016

S260 · NVIDIA · *NVIDIA Tesla V100 (Volta architecture) whitepaper* · 2017

S261 · NVIDIA · *NVIDIA A100 Tensor Core GPU Architecture (whitepaper)* · 2020

S262 · NVIDIA · *NVIDIA GB200 NVL72 (product page)* · 2024

S263 · NVIDIA · *NVIDIA Blackwell Architecture Technical Brief* · 2024-03

S264 · NVIDIA Newsroom · *NVIDIA Announces New Switches Optimized for Trillion-Parameter GPU Computing and AI Infrastructure (Quantum-X800, Spectrum-X800, ConnectX-8)* · 2024-03-18

S265 · NVIDIA Newsroom · *NVIDIA Announces Spectrum-X Photonics, Co-Packaged Optics Networking Switches to Scale AI Factories to Millions of GPUs* · 2025-03-18

S266 · NVIDIA Newsroom · *NVIDIA Quantum-2 Takes Supercomputing to New Heights, Into the Cloud* · 2021-11-09

S267 · NVIDIA Newsroom · *NVIDIA Spectrum-4 high-performance data center networking infrastructure platform (GTC 2022)* · 2022-03-22

S268 · NVIDIA Newsroom · *NVIDIA Introduces Spectrum-XGS Ethernet to Connect Distributed Data Centers Into Giga-Scale AI Super-Factories* · 2025-08-22

S269 · NVIDIA Newsroom · *NVIDIA Extends Data Center Infrastructure Processing Roadmap with BlueField-3* · 2021-04-12

S270 · NVIDIA Newsroom · *NVIDIA Introduces New Family of BlueField DPUs to Bring Breakthrough Networking, Storage and Security Performance to Every Data Center* · 2020-10-05

S271 · NVIDIA Newsroom · *NVIDIA Launches Accelerated Ethernet Platform for Hyperscale Generative AI (Spectrum-X)* · 2023-05-29

S272 · NVIDIA · *NVIDIA BlueField Networking Platform / DPU product page (BlueField-4)* · 2025-10

S273 · NVIDIA Docs · *NVIDIA Networking documentation hub (ConnectX adapter, Quantum and Spectrum switch product briefs and user manuals)* · 2025

S274 · Broadcom · *Broadcom ships Tomahawk 6: world's first 102.4 Tbps switch* · 2025-06-03

S275 · Broadcom · *Broadcom ships Tomahawk Ultra: reimagining the Ethernet switch for HPC and AI scale-up* · 2025-07-15

S276 · Broadcom · *Broadcom ships Jericho4, enabling distributed AI computing across data centers* · 2025-08-04

S277 · Broadcom · *Broadcom ships Tomahawk 5, industry's highest bandwidth switch chip* · 2022-08-16

S278 · Broadcom · *Broadcom ships Tomahawk 4, industry's highest bandwidth Ethernet switch chip at 25.6 Terabits per second* · 2019-12-09

S279 · Broadcom · *Broadcom introduces Jericho3-AI for AI networking* · 2023-04-18

S280 · Broadcom · *Broadcom introduces Thor Ultra, the industry's first 800G AI Ethernet NIC* · 2025-10-14

S281 · Broadcom · *Broadcom Tomahawk 6-Davisson co-packaged optics Ethernet switch* · 2025-10

S282 · Broadcom · *Broadcom delivers industry's first 51.2-Tbps co-packaged optics Ethernet switch platform (Bailly)* · 2024-03

S283 · Broadcom · *Broadcom StrataXGS Tomahawk switch family (product pages)* · 2025

S284 · Marvell · *Marvell Teralynx 10 51.2 Tbps data center switch* · 2023-03

S285 · Cisco · *Cisco Silicon One G200 and G202 for AI/ML networks* · 2023-06-20

S286 · Cisco · *Cisco Silicon One P200 and Cisco 8223 for scale-across AI networks* · 2025-10-08

S287 · Cisco · *Cisco Silicon One G300 102.4 Tbps AI networking silicon (Cisco Live EMEA 2026, recalled)* · 2026-02

S288 · Arista Networks · *Arista Etherlink AI networking platforms (7060X6, 7800R4)* · 2024

S289 · AMD · *AMD Advancing AI 2024: Pensando Pollara 400 AI NIC and Salina DPU* · 2024-10-10

S290 · AMD · *AMD Advancing AI 2025: Helios rack, MI400 preview and Pensando Vulcano 800G NIC* · 2025-06-12

S291 · Intel · *Intel Infrastructure Processing Unit (IPU) E2100 (Mount Evans)* · 2022

S292 · Amazon Web Services · *Elastic Fabric Adapter (EFA) and AWS Nitro System documentation* · 2025

S293 · ACM SIGCOMM / Google · *Jupiter Evolving: Transforming Google's Datacenter Network via Optical Circuit Switches and Software-Defined Networking (SIGCOMM 2022)* · 2022-08

S294 · SemiAnalysis · *100,000 H100 Clusters: Power, Network Topology, Ethernet vs InfiniBand, Reliability, Failures, Checkpointing* · 2024-06-17

S295 · LPO MSA · *Linear Pluggable Optics Multi-Source Agreement (LPO MSA)* · 2024

S296 · Intel · *Intel Gaudi 3 AI Accelerator white paper* · 2024-04

S301 · StorageReview · *NVIDIA launches Vera Rubin architecture at CES 2026: the VR NVL72 rack* · 2026-01

S302 · Hashrate Index · *NVIDIA Vera Rubin NVL72 specs breakdown* · 2026

S303 · Commercial Times (ctee.com.tw) · *Vera Rubin NVL72 Max-Q / Max-P rack power (Commercial Times report)* · 2026-01-07

S304 · Hackster.io · *NVIDIA unveils the 30-PetaFLOP Rubin CPX for million-token-scale context windows* · 2025-09-09

S305 · DatacenterDynamics · *Nvidia's Rubin Ultra NVL576 rack expected to be 600kW, coming second half of 2027* · 2025-03-19

S307 · Exxact Corp · *NVIDIA GTC 2026 recap: era of tokens and inference* · 2026-03

S308 · The Decoder · *GTC 2026: with Groq 3 LPX Nvidia adds dedicated inference hardware to its platform for the first time* · 2026-03

S309 · Spheron · *NVIDIA Kyber rack delayed to 2028: what it means for Rubin Ultra* · 2026

S310 · AnandTech · *NVIDIA unveils the DGX-1 HPC server: 8 Teslas, 3U, Q2 2016* · 2016-04-05

S311 · Colfax International · *NVIDIA DGX-1 deep learning system (specification page)* · 2016

S312 · AnandTech · *NVIDIA ships first Volta-based DGX systems* · 2017-09-07

S313 · NVIDIA (mirror hosted by M Computers) · *NVIDIA DGX-2 datasheet* · 2018

S314 · TweakTown · *NVIDIA's DGX-2: 16 x Tesla V100s, total of 512GB HBM2, $399K* · 2018-03-27

S315 · NVIDIA (mirror) · *NVIDIA DGX A100 system (40GB) datasheet* · 2020-05

S316 · Tom's Hardware · *AMD unveils Nvidia DGX A100 specs in formal announcement* · 2020-05-14

S318 · NVIDIA (mirror hosted by MEGWARE) · *NVIDIA DGX H100 datasheet* · 2023

S319 · NVIDIA (mirror hosted by OpenZeka) · *NVIDIA DGX B200 datasheet* · 2024

S320 · Hydra Host · *NVIDIA DGX B200 (configuration and pricing page)* · 2026

S321 · Colfax International · *NVIDIA DGX B300 (specification page)* · 2025

S322 · GPUPerHour · *NVIDIA GPU prices (H100/H200 and DGX/HGX system listings)* · 2026-09

S323 · AMCompute · *HGX H200 server value* · 2026-08

S324 · fal.ai · *NVIDIA GB200 price in 2026: what a GPU, a tray and an NVL72 rack cost* · 2026

S325 · Spheron · *GB300 NVL72 vs GB200 NVL72: pricing and availability 2026* · 2026

S326 · TweakTown · *NVIDIA's new GB200 Superchip costs up to $70,000: full B200 NVL72 AI server costs $3 million* · 2024-05

S327 · Wing VC · *How much does an NVIDIA NVL72 cost?* · 2026

S328 · Data Gravity · *How much does an NVIDIA NVL72 cost?* · 2026

S329 · Tom's Hardware · *Price of Nvidia's Vera Rubin NVL72 racks skyrockets to as much as $8.8 million apiece, but server makers' margins will be tight* · 2026

S330 · PC Gamer · *A single Nvidia Vera Rubin rack is estimated to cost $7,803,148 with over $2 million of that figure spent on memory alone* · 2026-05

S331 · Wccftech · *NVIDIA's Vera Rubin rack hit with 435% memory price surge, pushing HBM4 & LPDDR5X bill to $2M of $7.8M total* · 2026-05

S332 · Tiger Brokers (iTiger) · *Morgan Stanley's BOM analysis of NVIDIA's Rubin: GPU share declines; PCB, MLCC and ABF substrate values soar* · 2026-05-20

S333 · Wccftech · *Bernstein warns NVIDIA's Vera Rubin racks will hit $9.1 million as HBM4 prices triple to $53 per gigabyte* · 2026-07

S334 · Tom's Hardware · *Cooling system for a single Nvidia Blackwell Ultra NVL72 rack costs $50,000 - set to increase to $56,000 with next-generation NVL144 racks* · 2025-09

S335 · Spheron · *NVIDIA GB200 NVL72 guide* · 2026

S336 · eeNews Europe · *Nvidia offers 120kW liquid-cooled Blackwell rack as industry standard* · 2024-10

S337 · Spheron · *NVIDIA GB300 (rental and specifications)* · 2026

S338 · Morph · *NVIDIA GB300: specs, price, and GB300 NVL72 vs GB200* · 2026-10

S339 · TweakTown · *NVIDIA details Blackwell Ultra GB300: dual-die design, 208B transistors, up to 288GB HBM3E* · 2025-08

S340 · SemiAnalysis · *Huawei AI CloudMatrix 384 - China's answer to Nvidia GB200 NVL72* · 2025-04-16

S341 · Converge Digest · *Huawei unveils next-gen Ascend chips, SuperPoDs and UnifiedBus interconnect* · 2025-09-18

S342 · Mobile World Live · *Huawei Atlas 950/960 SuperPoD announcement coverage* · 2025-09

S343 · TrendForce · *Huawei unveils Ascend 950 with in-house HBM in 2026, touts SuperPoD to rival Nvidia* · 2025-09-18

S344 · AMD · *AMD Helios rack-scale AI infrastructure (product page)* · 2026

S345 · Flopper.io · *AMD Helios (system specification)* · 2026

S346 · Kad8 · *AMD Helios AI rack: MI455X, Zen 6 EPYC and Pensando* · 2026

S347 · AMD · *AMD Instinct MI355X platform brochure* · 2025-06

S348 · Flopper.io · *AMD Instinct MI355X Platform (system specification)* · 2025

S349 · AMD · *AMD Instinct MI300X platform data sheet* · 2023-12

S350 · Google Cloud · *TPU7x (Ironwood) documentation* · 2025-11

S352 · AWS News Blog · *Amazon EC2 Trn2 instances and Trn2 UltraServers for AI/ML training and inference are now available* · 2024-12-03

S353 · AWS · *Announcing Amazon EC2 Trn3 UltraServers for faster, lower-cost generative AI training* · 2025-12-02

S354 · AWS · *Trn3 architecture (AWS Neuron documentation)* · 2026

S355 · Epoch AI · *NVIDIA's B200 costs around $6,400 to produce, with memory accounting for half* · 2025-12

S356 · Tom's Hardware · *Nvidia makes nearly 1,000% profit on H100 GPUs: report* · 2023-08

S357 · Wccftech · *Morgan Stanley: NVIDIA GB200 NVL72 racks deliver a profit margin of 77.6% vs AMD MI355X while entailing nearly the same TCO (report later retracted)* · 2025-08

S358 · glennklockwood.com · *NVIDIA B200 processor notes* · 2025

S360 · glennklockwood.com · *NVIDIA Rubin (R200) processor notes* · 2026

S361 · Digital Citizen · *AMD Instinct MI455X brings 432GB of HBM4 and 40 PFLOPs of AI compute to Helios* · 2026-01

S362 · Digital Citizen · *NVIDIA Vera Rubin pushes memory costs higher as NVL72 rack reaches 74.7 TB of DRAM* · 2026-05

S365 · NVIDIA · *NVIDIA A100 Tensor Core GPU architecture whitepaper* · 2020

S368 · JEDEC · *JEDEC publishes HBM3 update to High Bandwidth Memory (HBM) standard (JESD238)* · 2022-01-27

S369 · JEDEC · *JESD270-4: High Bandwidth Memory (HBM4) standard* · 2025-04-16

S370 · JEDEC · *JESD235 High Bandwidth Memory (HBM / HBM2 / HBM2E) DRAM standard family* · 2013-10

S371 · Micron Technology · *Micron commences volume production of industry-leading HBM3E solution* · 2024-02-26

S372 · Samsung Electronics · *Samsung develops industry-first 36GB HBM3E 12H DRAM* · 2024-02-27

S373 · SK hynix Newsroom · *SK hynix begins industry's first mass production of 12-layer HBM3E* · 2024-09-26

S374 · SK hynix Newsroom · *SK hynix completes world-first HBM4 development and readies mass production* · 2025-09-12

S375 · SK hynix Newsroom · *SK hynix newsroom: 16-high 48GB HBM3E unveiled at SK AI Summit 2024* · 2024-11-04

S376 · TrendForce · *TrendForce press releases on HBM supplier market share (2022 actual; 2023 estimate)* · 2023-04

S377 · Counterpoint Research · *Counterpoint Research DRAM/HBM market trackers (Q1-Q3 2025 HBM shares)* · 2025

S378 · TSMC Investor Relations · *TSMC quarterly earnings conference calls (CoWoS capacity commentary)* · 2025

S379 · TrendForce News · *TSMC CoWoS capacity and customer allocation estimates (TrendForce / Morgan Stanley, as reported)* · 2025

S380 · TSMC · *TSMC 3DFabric: CoWoS-S, CoWoS-R and CoWoS-L technology overview and roadmap* · 2025

S382 · Microsoft via SEC EDGAR · *Microsoft Corporation Form 10-K filings (FY2021, FY2023) - property and equipment useful lives* · 2023-07-27

S383 · Alphabet via SEC EDGAR · *Alphabet Inc. Form 10-K filings (FY2020, FY2022) - useful lives of servers and network equipment* · 2023-02-03

S384 · Meta via SEC EDGAR · *Meta Platforms Form 10-K filings (FY2022, FY2024) - useful lives of servers and network assets* · 2025-01-30

S385 · Amazon via SEC EDGAR · *Amazon.com Form 10-K filings (FY2019-FY2024) - useful lives of servers* · 2025-02-07

S386 · CoreWeave via SEC EDGAR · *CoreWeave Form S-1 registration statement (2025) - technology equipment useful life* · 2025-03-03

S387 · Uptime Institute · *Uptime Institute Global Data Center Survey 2024* · 2024-07

S388 · Google · *Google data centers: efficiency (fleet-wide PUE)* · 2025

S389 · U.S. Energy Information Administration · *EIA Electric Power Monthly, Table 5.6.A: average price of electricity to ultimate customers by end-use sector* · 2025

S390 · LevelTen Energy · *LevelTen Energy PPA Price Index (North America)* · 2025

S391 · AWS · *Amazon EC2 P5 instances (NVIDIA H100) - product and on-demand pricing* · 2023-07-26

S392 · AWS · *AWS announces up to 45% price reduction for Amazon EC2 NVIDIA GPU-accelerated instances (P4, P5)* · 2025-06

S393 · Latent Space · *$2 H100s: how the GPU bubble burst* · 2024-10

S394 · CoreWeave · *CoreWeave GPU cloud pricing* · 2025

S395 · Lambda · *Lambda GPU cloud pricing* · 2025

S396 · NVIDIA Newsroom · *NVIDIA Blackwell platform arrives to power a new era of computing* · 2024-03-18

S398 · NVIDIA Investor Relations · *NVIDIA Q2 FY2026 earnings call (2025-08-27): AI factory economics commentary* · 2025-08-27

S399 · Micron Technology · *Micron fiscal Q1 2026 earnings (HBM total addressable market outlook)* · 2025-12-17

S400 · U.S. Securities and Exchange Commission (EDGAR) · *NVIDIA Corporation Form 10-K annual reports FY2001–FY2019 (EDGAR filing index)* · 2019-02-21

S401 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year ended January 25, 2026* · 2026-02-25

S402 · NVIDIA Corporation via SEC EDGAR · *CFO Commentary on Fourth Quarter and Fiscal 2026 Results (Form 8-K exhibit 99.2)* · 2026-02-25

S403 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Announces Financial Results for First Quarter Fiscal 2027 (Form 8-K exhibit 99.1)* · 2026-05-20

S404 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended April 26, 2026* · 2026-05-27

S405 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Announces Financial Results for Second Quarter Fiscal 2027 (Form 8-K exhibit 99.1)* · 2026-08-26

S406 · NVIDIA Corporation · *CFO Commentary on Second Quarter Fiscal 2027 Results* · 2026-08-26

S407 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended July 26, 2026* · 2026-08-28

S408 · NVIDIA Corporation · *NVIDIA Corp. (NVDA) Q2 Fiscal 2027 earnings call transcript (26 August 2026)* · 2026-08-26

S409 · NVIDIA Corporation · *NVIDIA Corp. (NVDA) Q1 Fiscal 2027 earnings call transcript (20 May 2026)* · 2026-05-20

S410 · CNBC · *Nvidia earnings takeaways: Data center revenue nearly doubles* · 2026-05-20

S411 · CNBC · *Nvidia reports earnings and guidance beat as AI boom pushes data center revenue up 75%* · 2026-02-25

S412 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended October 26, 2025* · 2025-11-19

S413 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended July 27, 2025* · 2025-08-27

S414 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended April 27, 2025* · 2025-05-28

S415 · NVIDIA Corporation · *CFO Commentary on Third Quarter Fiscal 2026 Results* · 2025-11-19

S416 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year ended January 26, 2025* · 2025-02-26

S417 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year ended January 28, 2024* · 2024-02-21

S418 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year ended January 29, 2023* · 2023-02-24

S419 · NVIDIA Corporation via SEC EDGAR · *CFO Commentary on Fourth Quarter and Fiscal 2023 Results (Form 8-K exhibit 99.2)* · 2023-02-22

S420 · NVIDIA Corporation (via CapEdge mirror of Form 8-K) · *CFO Commentary on Second Quarter Fiscal 2023 Results* · 2022-08-24

S421 · NVIDIA Corporation (via CapEdge mirror of Form 8-K) · *CFO Commentary on Third Quarter Fiscal 2023 Results* · 2022-11-16

S422 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended April 30, 2023* · 2023-05-26

S423 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended July 30, 2023* · 2023-08-28

S424 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended October 29, 2023* · 2023-11-21

S425 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended April 28, 2024 (filing folder)* · 2024-05-29

S426 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended July 28, 2024 (filing folder)* · 2024-08-28

S427 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-Q for quarter ended October 27, 2024 (filing folder)* · 2024-11-20

S428 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Announces Financial Results for Fourth Quarter and Fiscal 2022 (Form 8-K exhibit 99.1)* · 2022-02-16

S429 · NVIDIA Corporation via SEC EDGAR · *CFO Commentary on Third Quarter Fiscal 2022 Results (Form 8-K exhibit 99.2)* · 2021-11-17

S430 · FourWeekMBA · *Nvidia's 10-Q Lists $530B in Commitments and Guarantees* · 2026-08

S431 · Barchart · *Michael Burry called Nvidia's $95 billion in purchase obligations 'troubling' in February; six months later the filings show $279 billion* · 2026-09

S432 · NVIDIA Corporation · *NVIDIA Announces Financial Results for First Quarter Fiscal 2023 (press release with CFO commentary)* · 2022-05-25

S433 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Second Quarter Fiscal 2023 (press release with CFO commentary)* · 2022-08-24

S434 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Third Quarter Fiscal 2023 (press release with CFO commentary)* · 2022-11-16

S435 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Fourth Quarter and Fiscal 2023 (press release with CFO commentary)* · 2023-02-22

S436 · NVIDIA Corporation · *NVIDIA Announces Financial Results for First Quarter Fiscal 2024 (press release with CFO commentary)* · 2023-05-24

S437 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Second Quarter Fiscal 2024 (press release with CFO commentary)* · 2023-08-23

S438 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Third Quarter Fiscal 2024 (press release with CFO commentary)* · 2023-11-21

S439 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Fourth Quarter and Fiscal 2024 (press release with CFO commentary)* · 2024-02-21

S440 · NVIDIA Corporation · *NVIDIA Announces Financial Results for First Quarter Fiscal 2025 (press release with CFO commentary)* · 2024-05-22

S441 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Second Quarter Fiscal 2025 (press release with CFO commentary)* · 2024-08-28

S442 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Third Quarter Fiscal 2025 (press release with CFO commentary)* · 2024-11-20

S443 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Fourth Quarter and Fiscal 2025 (press release with CFO commentary)* · 2025-02-26

S444 · NVIDIA Corporation · *NVIDIA Announces Financial Results for First Quarter Fiscal 2026 (press release with CFO commentary)* · 2025-05-28

S445 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Second Quarter Fiscal 2026 (press release with CFO commentary)* · 2025-08-27

S446 · NVIDIA Corporation · *NVIDIA Announces Financial Results for Third Quarter Fiscal 2026 (press release with CFO commentary)* · 2025-11-19

S447 · NVIDIA Corporation (via CapEdge mirror of Form 8-K) · *CFO Commentary on First Quarter Fiscal 2024 Results* · 2023-05-24

S448 · NVIDIA Corporation (via CapEdge mirror of Form 8-K) · *CFO Commentary on Third Quarter Fiscal 2024 Results* · 2023-11-21

S449 · Fortune · *Nvidia's massive future spending commitments 'make the company's risk profile more complex,' Saxo says* · 2026-08-28

S450 · U.S. Securities and Exchange Commission (EDGAR) · *Advanced Micro Devices Form 10-K / 10-Q filings (EDGAR index)* · 2025-02-05

S451 · U.S. Securities and Exchange Commission (EDGAR) · *Broadcom Inc. Form 10-K / 8-K earnings filings (EDGAR index)* · 2025-12-11

S452 · U.S. Securities and Exchange Commission (EDGAR) · *Intel Corporation Form 10-K filings (EDGAR index)* · 2025-01-31

S453 · U.S. Securities and Exchange Commission (EDGAR) · *Marvell Technology Form 10-K filings (EDGAR index)* · 2025-03-13

S454 · U.S. Securities and Exchange Commission (EDGAR) · *Taiwan Semiconductor Manufacturing Co. Form 20-F and quarterly management reports (EDGAR index)* · 2025-04-17

S455 · U.S. Securities and Exchange Commission (EDGAR) · *Alphabet Inc. Form 10-K filings (EDGAR index)* · 2026-02-04

S456 · U.S. Securities and Exchange Commission (EDGAR) · *Amazon.com Inc. Form 10-K filings (EDGAR index)* · 2026-02-06

S457 · U.S. Securities and Exchange Commission (EDGAR) · *Meta Platforms Form 10-K filings (EDGAR index)* · 2026-01-29

S458 · U.S. Securities and Exchange Commission (EDGAR) · *Microsoft Corporation Form 10-K filings (EDGAR index)* · 2025-07-30

S459 · U.S. Securities and Exchange Commission (EDGAR) · *Oracle Corporation Form 10-K filings (EDGAR index)* · 2025-06-20

S460 · Alphabet Investor Relations · *Alphabet Q4 and fiscal year 2025 results and 2026 capex outlook* · 2026-02

S461 · Amazon Investor Relations · *Amazon.com Q4 2025 results and 2026 capex commentary* · 2026-02

S462 · Meta Investor Relations · *Meta Q4 and full year 2025 results and 2026 capex outlook* · 2026-01

S463 · Oracle Investor Relations · *Oracle fiscal 2026 Q2 results and FY2026 capex outlook* · 2025-12

S464 · NVIDIA Newsroom · *NVIDIA to Acquire Mellanox for $6.9 Billion* · 2019-03-11

S465 · NVIDIA Newsroom · *NVIDIA to Acquire Arm for $40 Billion, Creating World's Premier Computing Company for the Age of AI* · 2020-09-13

S466 · NVIDIA Newsroom · *NVIDIA and SoftBank Group Announce Termination of NVIDIA's Acquisition of Arm Limited* · 2022-02-08

S467 · NVIDIA Newsroom · *OpenAI and NVIDIA Announce Strategic Partnership to Deploy 10 Gigawatts of NVIDIA Systems* · 2025-09-22

S468 · NVIDIA Newsroom · *NVIDIA and Intel to Develop AI Infrastructure and Personal Computing Products* · 2025-09-18

S469 · Microsoft Official Blog · *Microsoft, NVIDIA and Anthropic announce strategic partnerships* · 2025-11-18

S470 · NVIDIA Newsroom · *NVIDIA and Nokia partnership on AI-RAN; NVIDIA $1B equity investment in Nokia* · 2025-10-28

S471 · NVIDIA Newsroom · *NVIDIA and Synopsys strategic partnership; NVIDIA $2B investment in Synopsys common stock* · 2025-12-01

S472 · CoreWeave Newsroom · *CoreWeave and NVIDIA expand partnership; NVIDIA invests $2B in CoreWeave Class A stock* · 2026-01-26

S473 · U.S. Securities and Exchange Commission (EDGAR) · *CoreWeave Inc. Form 8-K / S-1 filings (EDGAR index): NVIDIA capacity agreement and IPO participation* · 2025-09-15

S474 · Groq Newsroom · *Groq and NVIDIA enter non-exclusive inference technology licensing agreement* · 2025-12-24

S475 · CNBC · *Nvidia spends over $900 million on Enfabrica CEO, AI startup technology* · 2025-09-18

S476 · NVIDIA Blog · *NVIDIA to Acquire GPU Orchestration Software Provider Run:ai* · 2024-04-24

S477 · U.S. Securities and Exchange Commission (EDGAR) · *NVIDIA Corporation Form 13F-HR holdings reports (EDGAR index)* · 2026-08-14

S478 · NVIDIA · *NVIDIA Blog and Newsroom acquisition announcements (Cumulus, SwiftStack, DeepMap, Bright Computing, Excelero, Shoreline, Brev.dev, OctoAI, VinBrain, Gretel, Lepton AI, CentML, SchedMD)* · 2025-12

S479 · Various (press) · *Reporting on NVIDIA tuck-in acquisition prices (Run:ai, Deci, Shoreline, OctoAI, Gretel, Lepton, CentML) — The Information, Calcalist, Reuters, CNBC* · 2025-06

S480 · Various (press) · *Reporting on OpenAI's 2026 funding round with Amazon, NVIDIA and SoftBank (NVIDIA ~US$30B)* · 2026-02

S481 · Various (company announcements; Reuters, Bloomberg, TechCrunch) · *Reporting on NVIDIA participation in AI-lab and neocloud funding rounds 2023–2025 (Inflection, Cohere, Hugging Face, Databricks, Mistral, xAI, Perplexity, Crusoe, Lambda, Nebius, Nscale, Together AI, Poolside, Reflection AI, Thinking Machines, Cursor)* · 2025-11

S482 · Various (company announcements; Reuters, Bloomberg) · *Reporting on NVIDIA participation in robotics, autonomy, photonics, storage and energy rounds (Figure AI, Wayve, Scale AI, Ayar Labs, Enfabrica, VAST Data, Sakana AI, TerraPower, Commonwealth Fusion Systems, Applied Digital, Recursion)* · 2025-09

S483 · Various (Bloomberg, The Information, Reuters) · *Reporting on NVIDIA commitments to xAI (up to $2B in ~$20B raise), Poolside (up to $1B), Lambda (~$1.5B GPU lease-back) and Wayve ($500M LOI)* · 2025-10

S484 · NVIDIA press releases as summarised in NVIDIA 10-K filings and contemporaneous press · *History of NVIDIA acquisitions 2000–2013 (3dfx assets, MediaQ, ULi, Hybrid Graphics, PortalPlayer, mental images, Ageia, Icera, The Portland Group)* · 2013-07

S500 · NVIDIA Corporation · *NVIDIA Q2 Fiscal 2027 Quarterly Presentation (CFO commentary deck)* · 2026-08-26

S501 · eWeek · *Everything Nvidia Just Announced at GTC 2026: 7 Chips, 5 Racks, 1 Giant Bet on Agentic AI* · 2026-03-17

S502 · Tom's Hardware · *Nvidia updates data center roadmap with Rosa CPU and stacked Feynman GPUs; optical NVLink; Groq LPUs with NVFP4 and NVLink also on deck* · 2026-03-17

S506 · SamMobile · *Samsung Foundry begins mass production of NVIDIA Groq 3 LPX chip* · 2026-08-25

S507 · Tom's Hardware · *Nvidia's Kyber rack for Rubin Ultra slips to 2028* · 2026-07-06

S508 · Wccftech · *NVIDIA Quashes Rubin & Kyber Rack Delay Rumors, Says 'Chip Roadmap Is Intact'* · 2026-07

S509 · TrendForce · *NVIDIA Rubin Ultra four-die single-package design not adopted amid advanced-packaging constraints* · 2026-04-01

S510 · KGI Securities · *NVIDIA GTC 2026 (research note)* · 2026-03-19

S511 · Tom's Hardware · *Examining Nvidia's 60 exaflop Vera Rubin POD — how seven chips underpin company's 40 rack AI factory supercomputer* · 2026-03

S512 · NVIDIA Blog · *NVIDIA Launches BlueField-4: The Processor Powering the Operating System of AI Factories* · 2025-10-28

S513 · Tom's Hardware · *Nvidia launches BlueField-4 STX storage architecture for agentic AI at GTC 2026* · 2026-03-16

S514 · NVIDIA Investor Relations · *NVIDIA Announces Spectrum-X Photonics, Co-Packaged Optics Networking Switches to Scale AI Factories to Millions of GPUs* · 2025-03-18

S515 · Converge Digest · *NVIDIA debuts Spectrum-X and Quantum-X Photonics switches* · 2025-08

S516 · NVIDIA Newsroom · *NVIDIA Introduces Spectrum-XGS Ethernet to Connect Distributed Data Centers Into Giga-Scale AI Super-Factories* · 2025-08-22

S517 · Tom's Hardware · *Nvidia announces NVLink Fusion to allow custom CPUs and AI accelerators to work with its products* · 2025-05-19

S518 · ServeTheHome · *NVIDIA NVLink Fusion tapped for future AWS Trainium4 deployments* · 2025-12-02

S519 · South China Morning Post (Reuters) · *Amazon to use Nvidia tech in AI chips, roll out new servers (Reuters)* · 2025-12-02

S520 · NVIDIA via ResearchPool · *NVIDIA Enters Production With Dynamo, the Broadly Adopted Inference Operating System for AI Factories (press release mirror)* · 2026-03-16

S521 · NVIDIA Docs · *NVIDIA Dynamo release notes* · 2026-10

S522 · Python Package Index · *PyPI JSON API release histories (vllm, sglang, tensorrt-llm, ai-dynamo, torch-npu, jax-rocm7-plugin, tensorflow-rocm, intel-extension-for-tensorflow, onnxruntime-cann, onnxruntime-migraphx, torch-xla, torch-tpu)* · 2026-11-05

S523 · Python Package Index (NVIDIA) · *nvidia-cuda-runtime (CUDA 13.x runtime wheels) release history* · 2026-11-04

S524 · Python Package Index (NVIDIA) · *nvidia-cuda-runtime-cu12 (CUDA 12.x runtime wheels) release history* · 2025-06-05

S525 · NVIDIA Developer · *CUDA Toolkit Archive* · 2026

S526 · NVIDIA Developer · *CUPTI release history* · 2024

S527 · NVIDIA Docs · *CUDA Toolkit 13.2 Release Notes* · 2026-03-05

S528 · NVIDIA Developer Forums · *20 Years of CUDA: Honoring the Architects of the Accelerated Age* · 2026-03

S529 · NVIDIA Blog · *2 Million Registered Developers, Countless Breakthroughs* · 2020

S530 · NVIDIA press release via Stockhouse · *NVIDIA Introduces 60 Updates to CUDA-X Libraries, Opening New Science and Industries to Accelerated Computing* · 2022-03-22

S531 · TechRadar · *Nvidia GTC 2022 keynote: all the latest news, releases and more (live blog)* · 2022-03-22

S532 · NVIDIA · *NVIDIA GTC 2022 Fall Highlights* · 2022-09-20

S533 · TechCrunch · *Jensen Huang at Nvidia's Computex 2023 keynote* · 2023-05-29

S534 · Yahoo Finance · *An era of robotics, 'AI factories' powered by Nvidia's chips and software is 'in our near future', CEO Jensen Huang says* · 2024-06-02

S535 · AllMind (transcript) · *NVDA Q4 2025 (fiscal) earnings call* · 2025-02-26

S536 · TechRadar · *Nvidia GTC 2025 — all the news and updates from Jensen Huang's keynote (live blog)* · 2025-03-18

S537 · NVIDIA press release via Yahoo Finance · *NVIDIA Announces CPU for Giant AI and High Performance Computing Workloads* · 2021-04-12

S538 · AMD Investor Relations · *AAI 2026: AMD Delivers Full-Stack Compute for the Agentic AI Era* · 2026-07-23

S539 · Phoronix · *AMD Launches Instinct MI455X, Helios AI Rack* · 2026-07-23

S540 · Tom's Hardware · *AMD unwraps 2027 AI plans: Verano CPU, Instinct MI500X GPU, next-gen AI rack* · 2026-07

S541 · PC Games Hardware · *CDNA 6 und CDNA Next: AMD kündigt Instinct MI500 für 2027 und MI600 für 2028 an* · 2026-07

S542 · AMD via SEC EDGAR · *AMD Reports Third Quarter 2026 Financial Results (Form 8-K Exhibit 99.1)* · 2026-11-03

S543 · AMD via SEC EDGAR · *AMD Q2 2026 earnings slides (Form 8-K)* · 2026-08-04

S544 · DatacenterDynamics · *AMD unveils full MI400 product lineup, claims MI500 chips will deliver 1000x increase in AI performance* · 2026-01

S545 · Mashdigi · *AMD's data center GPUs are updated annually to compete with NVIDIA: MI400 in 2026, MI500 in 2027* · 2025-11-12

S546 · TechWire Asia · *AMD Advancing AI 2026: Helios, OpenAI, Meta, Anthropic* · 2026-07

S547 · Google Cloud Blog · *Ironwood TPUs and new Axion-based VMs for your AI workloads* · 2025-11-06

S548 · The Register · *Google offers 7th-gen Ironwood TPUs for AI, with AI-inspired comparisons* · 2025-04-10

S549 · Google Cloud Blog · *Trillium TPU is GA* · 2024-12-11

S550 · SiliconANGLE · *Google Cloud unveils eighth-generation TPUs (TPU 8t and TPU 8i)* · 2026-04-22

S551 · Techzine · *Google presents TPU 8t and TPU 8i chips; splits training and inference* · 2026-04-22

S552 · Google Cloud Blog · *Bringing Google TPUs to Oracle Cloud Infrastructure* · 2026-10-27

S553 · Google Cloud Blog · *What's new in AI infrastructure and orchestration in October* · 2026-11

S554 · Google Cloud Blog · *Google Cloud and NVIDIA expand co-engineering collaboration to scale infrastructure for the agentic era (NVIDIA GTC Berlin 2026)* · 2026-10-21

S555 · About Amazon · *Trainium3 UltraServer: faster AI training at lower cost* · 2025-12-02

S556 · HPCwire / AIwire · *AWS Trainium3 UltraServers now available* · 2025-12-02

S557 · SDxCentral · *AWS makes Trainium3 UltraServers generally available* · 2025-12-02

S558 · TechRadar · *Microsoft unveils Maia 200, its 'powerhouse' accelerator* · 2026-01-26

S559 · Techzine · *Microsoft aims to produce hundreds of thousands of Maia 300 AI chips* · 2026-08

S560 · DatacenterDynamics · *Microsoft unveils Azure Maia 300, says chip will be its primary inference system* · 2026

S561 · DatacenterDynamics · *Meta unveils next four generations of its MTIA chip* · 2026-03-11

S562 · ServeTheHome · *Meta MTIA 400 at Hot Chips 2026* · 2026-08

S563 · SiliconANGLE · *Intel announces Crescent Island inference GPU* · 2025-10-14

S564 · Tom's Hardware · *Intel's roadmaps examined — 14A, Nova Lake, Diamond Rapids & AI accelerator push* · 2026

S567 · Huawei · *Huawei Connect 2026: Ascend 960 SuperNode* · 2026-09

S568 · CRN Asia · *Huawei outlines Ascend 960 roadmap and million-processor AI systems* · 2026-09

S569 · HPCwire / AIwire · *Qualcomm debuts AI200 and AI250 chips as it moves into AI infrastructure* · 2025-10-27

S570 · TechPowerUp · *Broadcom ships Tomahawk 6 switch chip series with 102.4 Tbps* · 2025-06-03

S571 · Converge Digest · *Broadcom unveils 102.4 Tbps Davisson CPO switch for AI clusters* · 2025-10-08

S572 · Converge Digest · *Broadcom ships Jericho4, enabling distributed AI computing across data centers* · 2025-08

S573 · Business Wire · *UALink Consortium Releases the Ultra Accelerator Link 200G 1.0 Specification* · 2025-04-08

S574 · HPCwire · *UALink Consortium Publishes 4 Specifications Defining In-Network Compute, Chiplets, Manageability and 200G Performance* · 2026-04-07

S575 · Network World · *Ultra Ethernet 1.1 extends the specification to scale-up networks and adds programmable congestion control* · 2026-10

S576 · Converge Digest · *OCP releases ESUN 1.0 spec for Ethernet-based scale-up AI fabrics* · 2026-03

S577 · JAX (GitHub: jax-ml/jax docs/installation.md) · *JAX installation guide — supported platforms* · 2026-11

S578 · OpenAI Triton (GitHub) · *Triton (triton-lang/triton) README — supported hardware* · 2026-11

S579 · ggml-org (GitHub) · *llama.cpp README — supported backends* · 2026-11

S580 · vLLM project (GitHub) · *vLLM README and installation docs — supported hardware* · 2026-11

S581 · vLLM project (GitHub) · *vLLM hardware plugin repositories (tpu-inference/vLLM JAX, vllm-gaudi, vllm-ascend, vllm-neuron)* · 2026-11

S582 · SGLang project (GitHub: sgl-project/sglang) · *SGLang README — supported hardware* · 2026-11

S583 · DeepSpeed (GitHub: deepspeedai/DeepSpeed) · *DeepSpeed README and accelerator abstraction (real_accelerator.py)* · 2026-11

S584 · Ray project (GitHub: ray-project/ray) · *Ray accelerator managers (python/ray/_private/accelerators)* · 2026-11

S585 · Microsoft (GitHub: microsoft/onnxruntime gh-pages docs/execution-providers/index.md) · *ONNX Runtime Execution Providers (summary table)* · 2026-11

S586 · AMD (GitHub: ROCm/ROCm docs) · *ROCm documentation sources: release history, AI-ecosystem compatibility matrix, consolidated changelog* · 2026-08-26

S587 · PyTorch (GitHub: pytorch/pytorch) · *PyTorch README — building with CUDA, ROCm and Intel GPU support* · 2026-11

S588 · TensorFlow (GitHub: tensorflow/docs) · *TensorFlow install guides (pip; GPU device plugins)* · 2026-11

S589 · NVIDIA (GitHub: NVIDIA/TensorRT-LLM) · *TensorRT-LLM README* · 2026-11

S590 · NVIDIA (GitHub: NVIDIA/Megatron-LM) · *Megatron-LM / Megatron Core README* · 2026-11

S591 · AMD (GitHub: ROCm/Megatron-LM) · *ROCm/Megatron-LM (AMD-maintained fork)* · 2026-11

S592 · Huawei Ascend (GitHub: Ascend org) · *Huawei Ascend open-source adapters: torch_npu, MindSpeed, triton-ascend* · 2026-11

S593 · Intel Habana (GitHub: HabanaAI/Megatron-DeepSpeed) · *HabanaAI Megatron-DeepSpeed (LLM training on Intel Gaudi)* · 2026-11

S594 · AWS (GitHub: aws-neuron/neuronx-distributed) · *NeuronX Distributed (NxD) README* · 2026-11

S595 · PyTorch (GitHub: pytorch/xla) · *PyTorch/XLA README (deprecation notice)* · 2026-11

S596 · Qualcomm (GitHub: quic) · *Qualcomm Cloud AI SDK and Efficient Transformers repositories* · 2026-11

S597 · Intel (GitHub: intel/intel-xpu-backend-for-triton) · *Intel XPU backend for Triton* · 2026-11

S598 · NVIDIA Newsroom · *NVIDIA Announces DGX Cloud Lepton to Connect Developers to NVIDIA's Global Compute Ecosystem* · 2025-05-18

S600 · MLCommons · *MLPerf Inference v5.0 results (summary_results.json and per-submitter logs)* · 2025-04-02

S601 · MLCommons · *MLPerf Inference v5.1 results (summary_results.json and per-submitter logs)* · 2025-09-09

S602 · MLCommons · *MLPerf Inference v6.0 results (summary_results.json and per-submitter logs)* · 2026-04-01

S603 · MLCommons · *MLPerf Inference v6.1 results (summary.csv and per-submitter logs)* · 2026-09

S604 · MLCommons · *MLPerf Inference v4.0 results (per-submitter logs)* · 2024-03-27

S605 · MLCommons · *MLPerf Inference v4.1 results (per-submitter logs)* · 2024-08-28

S606 · MLCommons · *MLPerf Training v4.1 results (per-submitter logs and system descriptions)* · 2024-11-13

S607 · MLCommons · *MLPerf Training v5.0 results (per-submitter logs and system descriptions)* · 2025-06-04

S608 · MLCommons · *MLPerf Training v5.1 results (per-submitter logs and system descriptions)* · 2025-11-12

S609 · MLCommons · *MLPerf Training v6.0 results (per-submitter logs and system descriptions)* · 2026-06

S610 · HPCwire / AIwire (MLCommons press release) · *MLCommons Releases New MLPerf Inference v6.0 Benchmark Results* · 2026-04-01

S611 · MLCommons · *MLPerf logging package and result summarizer (training scoring rules)* · 2026

S612 · gentic.news · *Nvidia Claims MLPerf Inference v6.0 Records with 288-GPU Blackwell Ultra Systems, Highlights 2.7x Software Gains* · 2026-04-01

S613 · NAND Research · *MLPerf Inference 6.0: Software Gains, Broadening Competition Shake Things Up* · 2026-04

S620 · SemiAnalysis · *SemiAnalysis InferenceX (formerly InferenceMAX) open-source benchmark repository* · 2026-11

S621 · SemiAnalysis (InferenceX-app repository) · *InferenceX public API snapshot (benchmarks.json and benchmarks-history.json fixtures)* · 2026-10-17

S622 · SemiAnalysis (InferenceX-app repository) · *InferenceX hardware registry: TCO per GPU-hour by SKU (SemiAnalysis July 2026 pricing surveys and AI Cloud TCO Model)* · 2026-07

S623 · SemiAnalysis · *InferenceMAX: Open Source Inference Benchmarking* · 2025-10-09

S624 · SemiAnalysis · *InferenceX v2: NVIDIA Blackwell Vs AMD vs Hopper - Formerly InferenceMAX* · 2026-02-16

S625 · SemiAnalysis · *TPU Inference Externalization Full Steam Ahead* · 2026-09-07

S626 · SemiAnalysis · *Vera Rubin NVL72 vs GB200 NVL72? Inference TCO & Architecture Analysis* · 2026-07-23

S627 · SemiAnalysis · *AgentX - InferenceXv3: Does the CUDA Moat Hold Up in Agentic Inferencing?* · 2026-08-24

S628 · SemiAnalysis · *OpenAI Jalapeño: Better Than Nvidia Blackwell* · 2026-08-25

S629 · SemiAnalysis · *SGLang 0.5.6 on B200 DeepSeek R1 FP4: Up to 1.8x at Low Concurrency* · 2026-05-02

S630 · SemiAnalysis · *GB200 NVL72 vs B200 on Kimi K2.5: 3.1x from Wide EP vLLM* · 2026-04-23

S631 · SemiAnalysis · *MI355X DeepSeek-V4-Pro on SGLang: 110.5x Throughput per GPU in 26 Days* · 2026-05-26

S632 · SemiAnalysis · *AMD MI355X Qwen3.5 397B-A17B Inference: Up to 19x Throughput per GPU in 3 Months on SGLang FP8* · 2026-05-25

S633 · SemiAnalysis · *DeepSeekV4 1.6T Day 0 to Day 43 Performance Over Time — Huawei, GB300 NVL72, MI355X, B200* · 2026-06-09

S634 · SemiAnalysis · *Ultra-High Interactivity on NVIDIA GPUs? TileRT on InferenceX* · 2026-08-10

S635 · SemiAnalysis · *Rubin NVL72 Agentic Inference: 67x better Performance per Dollar* · 2026-09-14

S636 · SemiAnalysis · *GLM 5.3 on AgentX: NVIDIA Is Up to 5x Cheaper per Token at 150 tok/s/user* · 2026-08-25

S637 · SemiAnalysis · *AMD MI355X GLM-5 Inference: Up to 29.6% Lower Cost per Million Tokens than B200 on SGLang FP8* · 2026-05-25

S640 · NVIDIA · *TensorRT-LLM performance overview (release 0.17)* · 2025-02-06

S641 · NVIDIA · *TensorRT-LLM performance overview (release 0.19)* · 2025-05-16

S642 · NVIDIA · *TensorRT-LLM performance overview (release 0.21)* · 2025-07-30

S643 · NVIDIA · *TensorRT-LLM performance overview (release 1.0)* · 2025-09-21

S644 · NVIDIA · *TensorRT-LLM performance overview (release 1.1)* · 2025-12-09

S645 · NVIDIA TensorRT-LLM team · *Pushing Latency Boundaries: Optimizing DeepSeek-R1 Performance on NVIDIA B200 GPUs (TensorRT-LLM tech blog 1)* · 2025-05-16

S646 · NVIDIA TensorRT-LLM team · *Optimizing DeepSeek R1 Throughput on NVIDIA Blackwell GPUs: A Deep Dive for Developers (TensorRT-LLM tech blog 3)* · 2025-05-30

S650 · Google Cloud Blog · *Inside the Ironwood TPU codesigned AI stack* · 2025-11-06

S651 · Google Cloud Blog · *Scaling MoE inference with NVIDIA Dynamo on Google Cloud A4X* · 2026-01-23

S653 · Anthropic · *Expanding our use of Google Cloud TPUs and Services* · 2025-10-23

S654 · Anthropic · *Microsoft, NVIDIA, and Anthropic announce strategic partnerships* · 2025-11-18

S655 · Anthropic · *Anthropic expands partnership with Google and Broadcom for multiple gigawatts of next-generation compute* · 2026-04-06

S656 · Anthropic · *Powering the next generation of AI development with AWS (expanded Amazon partnership and Trainium)* · 2024-11-22

S660 · Broadcom Inc. · *Broadcom Inc. Announces Fourth Quarter and Fiscal Year 2024 Financial Results* · 2024-12-12

S661 · Broadcom Inc. · *Broadcom Inc. Announces Fourth Quarter and Fiscal Year 2025 Financial Results* · 2025-12-11

S662 · Marvell Technology · *Marvell Technology fourth quarter and fiscal 2025 results and AI revenue commentary* · 2025-03-04

S663 · AMD · *AMD Reports Fourth Quarter and Full Year 2024 Financial Results* · 2025-02-04

S664 · HPCwire · *Nvidia Shipped 3.76 Million Data-center GPUs in 2023, According to Study (TechInsights)* · 2024-06-10

S665 · TechInsights via The Register / HPCwire · *Google TPU shipment estimates (TechInsights) as reported in trade press* · 2024-05

S666 · TrendForce · *TrendForce AI server shipment forecasts (GPU-based vs ASIC-based share)* · 2025-10

S667 · Dell'Oro Group · *Dell'Oro Group AI back-end network (InfiniBand vs Ethernet) commentary* · 2025

S668 · Reuters (as reported) · *Intel says it will not hit $500 million Gaudi 3 revenue target for 2024* · 2024-10-31

S1500 · nvidia_deep_dive_claude repository · *Repo analysis: synthesis verdicts by layer (moat score, gap trend, NVIDIA value capture) and thesis metrics* · 2026-11-05

S1501 · nvidia_deep_dive_claude repository · *Repo statistics: words, visuals, sources, data files and charts (scripts/validate/stats.py and file counts, 2026-11-05)* · 2026-11-05

S1502 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 02, GPU silicon (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1503 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 03, memory, packaging and supply chain (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1504 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 04, CPU (Grace, Vera) (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1505 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 05, scale-up (NVLink, NVSwitch) (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1506 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 06, scale-out and scale-across networking (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1507 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 07, DPU, SuperNIC, storage and security (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1508 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 08, systems, racks and AI factories (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1509 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 09, CUDA and system software (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1510 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 10, libraries (CUDA-X) (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1511 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 11, inference and AI software (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1512 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 12, orchestration and cloud services (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S1513 · nvidia_deep_dive_claude repository · *Repo layer page: Layer 13, ecosystem, go-to-market and capital (index Executive Take, eight-question table, competition verdicts)* · 2026-11-05

S2000 · NVIDIA Technical Blog · *Inside NVIDIA Rubin GPU Architecture: Powering the Era of Agentic AI* · 2026-07-21

S2001 · Guru3D · *NVIDIA details Rubin GPU architecture with HBM4, NVLink 6 and 336 billion transistors* · 2026-07

S2002 · Wccftech · *NVIDIA Rubin GPU architecture (block-diagram analysis)* · 2026-07

S2003 · NVIDIA Technical Blog · *Inside NVIDIA Blackwell Ultra: The Chip Powering the AI Factory Era* · 2025-08

S2004 · Chips and Cheese · *Nvidia's B200: Keeping the CUDA Juggernaut Rolling* · 2026

S2005 · Chips and Cheese · *Nvidia's H100: Funny L2, and Tons of Bandwidth* · 2023-07

S2006 · arXiv (2512.02189) · *Microbenchmarking NVIDIA's Blackwell Architecture: An in-depth Architectural Analysis* · 2025-12

S2007 · Open Compute Project · *OCP Microscaling Formats (MX) Specification v1.0* · 2023-09

S2008 · arXiv (2509.23202) · *Bridging the Gap Between Promise and Performance for Microscaling FP4 Quantization* · 2025-09

S2009 · arXiv (2509.25149) / NVIDIA · *Pretraining Large Language Models with NVFP4* · 2025-09

S2010 · Tom's Hardware · *Nvidia details efficiency of the NVFP4 format for LLM training* · 2025

S2011 · Microsoft Tech Community (Microsoft Foundry Blog) · *Unlocking NVIDIA Blackwell for DeepSeek: a collaborative effort* · 2026

S2012 · arXiv (2104.08378) / NVIDIA · *Accelerating Sparse Deep Neural Networks* · 2021-04-16

S2013 · arXiv (2209.05433) · *FP8 Formats for Deep Learning* · 2022-09

S2014 · The Next Platform · *With AMX, Intel Adds AI/ML Sparkle to Sapphire Rapids* · 2021-08-19

S2015 · Intel · *Intel Architecture Day 2021 performance index (claims)* · 2021-08-19

S2016 · arXiv (2606.15870) · *Google's Training Supercomputers from TPU v2 to Ironwood: Architectural Stability, Scale, Resilience, Power Efficiency, and Sustainability Across Five Generations* · 2026-06

S2017 · SemiAnalysis InferenceX · *Systolic array (glossary)* · 2026

S2018 · igor'sLAB · *Nvidia soll Vier-Die-Version von Rubin Ultra gestrichen haben* · 2026-07

S2019 · ServeTheHome · *AMD dives deep on CDNA 4 architecture and MI350 accelerator at Hot Chips 2025* · 2025-08

S2020 · AMD ROCm documentation · *AMD Instinct MI350 Series microarchitecture* · 2025

S2021 · nvidia_deep_dive_claude repository · *Repo analysis: Layer 02 GPU silicon models (memory-hierarchy estimates; multi-die silicon cost; decode throughput by precision)* · 2026-11-05

S2022 · NVIDIA Docs · *CUDA C++ Programming Guide (compute capabilities; shared memory)* · 2025

S2023 · NVIDIA Technical Blog · *NVIDIA Hopper Architecture In-Depth* · 2022-03-22

S2024 · NVIDIA Docs · *Transformer Engine user guide (FP8 and block-scaled recipes)* · 2025

S2025 · Tom's Hardware · *Nvidia details Rubin architectural optimizations for inference* · 2026-07

S2500 · Tom's Hardware · *Firm Estimates a 2nm Chip Now Costs $725 Million to Design* · 2023

S2501 · Silicon Analysts · *Chip Design & NRE Cost by Node — Historical Time Series Data* · 2026

S2502 · Tom's Hardware · *Nvidia GeForce 256 celebrates its 25th birthday — company talks about a quarter century of GPU progression* · 2024-10

S2503 · TechSpot · *TechSpot's History of the GPU, Part 4: the coming of general-purpose GPUs* · 2013

S2504 · TechCrunch · *Cerebras raises $5.5B kicking off 2026's IPO season with a bang* · 2026-05-14

S2505 · Dealroom · *Cerebras raises $5.55B in biggest US IPO of 2026* · 2026-05

S2506 · DatacenterDynamics · *Etched raises $500m for a $5bn valuation - report* · 2026-01

S2507 · AI Weekly · *Etched closes $300M Series C at $10.3B led by Sequoia, books ~$1B in pre-orders for Sohu* · 2026-07

S2508 · AI2.Work · *MatX raises $500M to build AI chips* · 2026-02-24

S2509 · TechPowerUp · *Tenstorrent closes $693M+ of Series D funding led by Samsung Securities and AFW Partners* · 2024-12-02

S2510 · Bloomberg · *Photonic Computing Startup Lightmatter Reaches $4.4 Billion Valuation* · 2024-10-16

S2511 · Converge Digest · *d-Matrix raises $275 million to accelerate the age of AI inference* · 2025-11-12

S2512 · Verdict · *Intel pursues SambaNova acquisition amid AI expansion plans* · 2025-12

S2513 · Business Wire (Marvell) · *Marvell Completes Acquisition of Celestial AI* · 2026-02-02

S2514 · bit-tech · *Intel acquires AI chipmaker, Habana Labs* · 2019-12-16

S2515 · Ynetnews · *How Intel wrecked a $2B purchase of Israeli startup and fell behind in the AI race* · 2025

S2516 · Broadcom Inc. via SEC EDGAR · *Broadcom Inc. Announces Third Quarter Fiscal Year 2026 Financial Results (Form 8-K exhibit 99.1)* · 2026-09

S2517 · TrendForce · *CSPs accelerate ASIC push in 2H26, challenging NVIDIA as MediaTek, GUC, Alchip benefit* · 2026-03-20

S2518 · TrendForce · *MediaTek reportedly doubles 2026 AI ASIC revenue target to $2B* · 2026-04-30

S2521 · Tom's Hardware · *AMD denies report of MI455X delays as Nvidia VR200 systems are rumored to arrive early* · 2026-02

S2523 · PC Games Hardware · *Nvidia erklärt die Rubin-Kürzungen: Weniger HBM4-Bandbreite als angekündigt* · 2026-11

S2524 · The Next Platform · *AMD says Helios racks and MI400 series GPUs on track for 2H 2026* · 2026-02-23

S3000 · nvidia_deep_dive_claude repository · *Repo analysis: layer 03 memory, packaging and supply-chain models (decode ceilings, HBM sizing, CoWoS packages per wafer)* · 2026-11-05

S3001 · KGI Securities · *TSMC (2330 TT) research note: CoWoS expansion forecast raised* · 2026-03-09

S3002 · TrendForce · *TSMC reportedly targets 22% 2nm, 16% 3nm capacity boost by mid-2027; CoWoS to double by 2028* · 2026-09-14

S3003 · TrendForce · *TSMC reportedly expands outsourcing of key CoWoS front-end step to OSATs amid rising NVIDIA and ASIC demand* · 2026-08-05

S3004 · TrendForce · *TSMC advances panel-level packaging: CoPoS pilot line reportedly set for June completion; 2028-29 ramp eyed* · 2026-04-13

S3005 · TrendForce · *TSMC reportedly eyes two AUO fabs worth TWD 30B for FOPLP and CoPoS* · 2026-08-10

S3006 · Tom's Hardware · *Micron says the silicon gap between HBM and DDR5 is widening with every generation* · 2026-08

S3007 · Tom's Hardware · *Micron teams up with TSMC to deliver HBM4E, targeted for 2027* · 2025-09

S3008 · TrendForce · *TSMC unveils custom C-HBM4E details: N3P logic dies reportedly target 2x efficiency gain* · 2025-12-01

S3009 · Tom's Hardware · *HBM undergoes major architectural shakeup as TSMC and GUC detail HBM4, HBM4E and C-HBM4E 3nm base dies, up to 12.8 GT/s by 2027* · 2025

S3010 · TweakTown · *Micron begins shipping industry's fastest HBM4 at 11Gbps, to partner with TSMC for future HBM4E* · 2025-09

S3011 · TrendForce · *Samsung's custom HBM4E design reportedly aimed for mid-2026, parallels SK hynix and Micron* · 2026-01-23

S3012 · NVIDIA Newsroom · *NVIDIA BlueField-4 Powers New Class of AI-Native Storage Infrastructure for the Next Frontier of AI* · 2026-01-05

S3013 · Blocks and Files · *Nvidia standardizes GPU cluster KV cache offload to NVMe SSDs* · 2026-01-06

S3014 · Focus Taiwan (CNA) · *Foxconn expects AI server rack shipments to double in 2026* · 2026-03-16

S3015 · TechNews (Taiwan) · *Rubin CPX progress unclear; no memory or substrate orders seen in supply chain* · 2026-05-27

S3016 · I-Connect007 (TrendForce) · *Higher DDR5 profitability intensifies capacity crowding, strengthening HBM3e pricing momentum in 2026* · 2025-12

S3017 · TrendForce · *Micron reportedly to add 60K HBM wafers/month, reaching 100K by year-end to narrow gap with Samsung, SK hynix* · 2026-09-04

S3018 · The Express Tribune · *Micron secures $22B in long-term chip deals* · 2026-08-06

S3500 · Counterpoint Research (Korea) · *Global HBM market share Q2 2026* · 2026-09

S3501 · Edaily · *SK hynix keeps HBM lead at 50% in Q2 as Samsung jumps to 33% (Counterpoint)* · 2026-09-03

S3502 · The Korea Times · *SK hynix logs record Q3 operating profit* · 2026-10-28

S3503 · SammyFans · *SK hynix Q3 margin hits record 80%, secures 14 LTAs with memory supply booked to 2029* · 2026-10-28

S3504 · TrendForce · *SK hynix, Samsung reportedly deliver paid HBM4 samples to NVIDIA* · 2025-12-16

S3505 · TrendForce · *TSMC CoWoS supply-demand gap reportedly seen narrowing from 20% to 10% by end-2026 as capacity expands* · 2026-06-15

S3507 · AI Weekly · *TSMC pilots CoPoS panel packaging as CoWoS sells out to 2027* · 2026

S3508 · Tiger Brokers (iTiger) · *TSMC's advanced packaging timeline shifts: CoWoS gains extended lifespan, next-gen CoPoS delayed until late 2030* · 2026

S3509 · TrendForce · *TSMC CoWoS wafer ASP reportedly nears 7nm levels, advanced packaging poised to become a key profit driver* · 2026-04-28

S3510 · AI Weekly · *TSMC mulls up to 20% CoWoS hike and 2027 wafer price rise* · 2026

S3511 · ITPro · *AMD and Samsung forge closer ties on AI memory, potential foundry deal* · 2026-03

S3512 · Asia Economy (Asiae) · *Samsung Electronics to prioritize HBM4 supply for AMD AI accelerators* · 2026-03-18

S3513 · TrendForce · *Samsung 12H HBM3E reportedly clears NVIDIA tests after 18-month setback, HBM4 reaches final phase* · 2025-09-22

S3514 · Asia Economy (Asiae) · *Samsung Electronics passes NVIDIA HBM3E quality certification; supply resumes after 19 months* · 2025-09-19

S3515 · TrendForce · *Samsung's HBM3E reportedly passed NVIDIA's certification, though it denies the rumor* · 2024-07-04

S3516 · Korea JoongAng Daily · *China's CXMT begins HBM3E production as chip battle with Korean powerhouses widens* · 2026-08

S3517 · Tom's Hardware · *Chinese semiconductor industry gears up for domestic HBM3 production by the end of 2026* · 2025

S3518 · Tiger Brokers (iTiger) · *DRAM industry revenue soars 81% to $97 billion in Q1 amid accelerating price hikes (TrendForce)* · 2026-06

S3519 · TrendForce · *1Q26 HBM market dynamics and forecast (report listing)* · 2026-03-06

S3520 · Silicon Analysts · *TrendForce: 2027 HBM blended ASP to jump 121% as HBM4/HBM4E mix shifts* · 2026-10-06

S3521 · Advantest Corporation · *Advantest Q2 FY2026 financial results briefing (notes)* · 2026-10-28

S3522 · AI CERTS News · *Foxconn results and AI server margin pressure* · 2026

S3523 · Blocks and Files · *Panmnesia scores $60M to push CXL switch chip designs* · 2024-11-25

S3524 · Dealroom · *Astera Labs revenue doubles to $392M as new investors pile in* · 2026-08

S3525 · TS2 Tech · *Astera Labs climbs after hours as Q3 revenue forecast beats consensus* · 2026-08

S3526 · Tom's Hardware · *NVIDIA-backed startup invents Ethernet memory pool to help power AI (Enfabrica EMFASYS)* · 2025-07-29

S3528 · TrendForce · *SK hynix reportedly pulls forward HBM4E sample timeline, eyeing June-July shipments to key customers* · 2026-06-15

S3531 · TrendForce · *HBM4E seen hitting 40% of 2027 market; Samsung, SK hynix reportedly aim for 1H26 completion* · 2025-11-13

S3532 · Tom's Hardware · *Intel reportedly in talks with Google and Amazon over advanced packaging* · 2026

S3533 · Micron Technology via SEC EDGAR · *Micron Technology fiscal Q4 2026 results (Form 8-K exhibit 99.1)* · 2026-09

S3534 · The Next Platform · *Micron's numbers show why HBM4 memory is worth 15x its weight in gold* · 2026-10-02

S3535 · TechCrunch · *OpenAI ropes in Samsung and SK hynix to source memory chips for Stargate* · 2025-10-01

S3536 · The Register · *OpenAI ropes in Samsung and SK Hynix for Stargate memory* · 2025-10-02

S3537 · DIGITIMES Asia · *OpenAI, Samsung and SK hynix: supply-chain implications for NVIDIA* · 2025-10-03

S3538 · TSMC · *TSMC reports third quarter 2026 results* · 2026-10

S4000 · NVIDIA Newsroom · *NVIDIA Launches Vera CPU, Purpose-Built for Agentic AI* · 2026-03-16

S4001 · AI Weekly · *Nvidia details 88-core Vera CPU with six-chiplet Olympus design* · 2026-08

S4002 · Tom's Hardware · *Nvidia spills the beans on Vera CPU: spec benchmarks revealed, Olympus architecture detailed and more* · 2026-07

S4003 · PC Games Hardware · *Nvidia Vera: Whitepaper legt Olympus-Architektur und erste SPEC-Werte offen* · 2026-08

S4004 · NVIDIA Blog · *NVIDIA Vera CPU Is 'Packing a Heavy-Hitting Punch' Against Competition* · 2026-08

S4005 · Ecosistema Startup · *NVIDIA Vera CPU: análisis crítico del whitepaper y qué significa para founders* · 2026-08

S4006 · SiliconANGLE · *Meta agrees to buy millions of AI chips from Nvidia, raising doubts about its in-house hardware* · 2026-02-17

S4007 · Tom's Hardware (mirror at 3dtested.com) · *Meta will deploy standalone Nvidia Grace CPUs in production with Vera to follow* · 2026-02

S4008 · Futurum Group · *Will NVIDIA's Meta Deal Ignite a CPU Supercycle?* · 2026-02

S4009 · SDxCentral · *Intel gets hands on Nvidia's $5B investment* · 2025-12

S4010 · TechSpot · *Intel CEO promises partnership with Nvidia will produce exciting new products* · 2026-05

S4011 · Wccftech · *Intel, NVIDIA are building a custom Xeon CPU with NVLink tech; reaffirms Diamond Rapids 16-channel, Coral Rapids with SMT* · 2026-01

S4012 · Tom's Hardware · *CPUs are cool again: Intel and AMD reporting spikes in CPU demand due to agentic AI* · 2026-05

S4013 · TrendForce · *How agentic AI is reshaping the CPU-to-GPU ratio* · 2026-09-29

S4014 · Counterpoint Research · *Agentic AI-driven CPU renaissance helps AMD outpace Intel in Q1 2026* · 2026-05

S4015 · Tom's Hardware · *Shifting need for CPUs in AI workloads drives intensifying shortages and price hikes* · 2026

S4016 · NVIDIA Technical Blog · *NVIDIA GH200 Superchip Accelerates Inference by 2x in Multiturn Interactions with Llama Models* · 2024

S4017 · NVIDIA Technical Blog · *Case Study: ResNet50 with DALI* · 2019

S4018 · NVIDIA Technical Blog · *Loading Data Fast with DALI and the New Hardware JPEG Decoder in NVIDIA A100 GPUs* · 2020

S4019 · heise online · *Blackwell: Nvidia unveils its next generation of AI accelerators* · 2024-03-19

S4020 · NVIDIA (GitHub) · *NVIDIA Grace CPU Benchmarking Guide: STREAM* · 2024

S4021 · Amazon Web Services (GitHub) · *Trn2 architecture (AWS Neuron SDK documentation source)* · 2026

S4022 · Amazon Science · *Graviton5's improved design increases speed and energy efficiency beyond Moore's law* · 2025-12

S4023 · The Next Platform · *AWS Tunes Up Graviton5 For Agentic AI* · 2026-06-11
S4024 · DatacenterDynamics · *Microsoft reveals next-generation Cobalt CPU and Azure Boost* · 2025-11-18
S4025 · ServeTheHome · *Microsoft Azure Cobalt 200 launched with 132 Arm Neoverse V3 cores* · 2025-11
S4026 · Phoronix · *Google Axion CPU performance with the new Google Cloud N4A instances* · 2026-01
S4027 · Tom's Hardware · *Google deploys new Axion CPUs and seventh-gen Ironwood TPU training and inferencing pods* · 2025-11
S4028 · Digital Citizen · *AMD EPYC Venice launches with up to 256 Zen 6 cores and strong agentic AI performance claims* · 2026-07-22
S4029 · StorageReview · *Qualcomm unveils Dragonfly data center roadmap: C1000 CPU, AI300 accelerator* · 2026-06-24
S4030 · Counterpoint Research · *Qualcomm unveils data center roadmap at Investor Day 2026* · 2026-06
S4031 · Wccftech · *Huawei next-gen Kunpeng chips: 950 series up to 192 cores, 960 series over 256 cores* · 2025-09
S4032 · GamesBeat · *Nvidia touts adoption for Vera CPU from world's tech leaders* · 2026-03
S4033 · TechSpot · *Nvidia Jensen Huang: standalone Vera CPU to challenge AMD* · 2026-01
S4500 · TrendForce · *Server CPU shipments to grow over 40% in 2027 as Arm gains share (press release)* · 2026-10-22
S4501 · Tom's Hardware · *Arm servers capture over 45 percent of data center market revenue (IDC Q1 2026 server tracker)* · 2026-06
S4502 · Techzine · *AMD gains ground in servers thanks to AI boom; Intel remains market leader (Mercury Research Q1 2026)* · 2026-05
S4503 · Analytics Insight · *AMD server CPU revenue share hits record 46.2% as Intel faces pressure* · 2026-05
S4504 · CIO.com (Korea) · *AMD server CPU share expands to 27.2%, narrowing gap with Intel (Mercury Research)* · 2025-05
S4505 · CloudNews.tech · *AMD pushes Intel to its lowest x86 share in 31 years and closes in on servers* · 2026-08
S4506 · Arm Holdings plc via SEC EDGAR · *Arm Holdings plc Form 6-K, Exhibit 99.2: results for the quarter ended September 30, 2026 (Q2 FYE27)* · 2026-11
S4507 · The Star (Reuters) · *Exclusive: Tech supplier Arm plans to hike prices, has considered developing its own chips (Reuters)* · 2025-01-13
S4508 · TIKR · *How to value Arm: a royalty business trading like a growth stock* · 2025
S4509 · Kavout Market Lens · *Arm's royalty uplift is priced: a 49x sales multiple meets normalizing growth* · 2026
S4510 · TechCrunch · *Arm is releasing its first in-house chip in its 35-year history* · 2026-03-24
S4511 · MarketScreener · *Arm launches its first chip and shifts strategy with Meta as key client* · 2026-03
S4512 · DatacenterDynamics · *Qualcomm buys RISC-V server chip maker Ventana Micro Systems* · 2025-12-10
S4513 · I-Connect007 · *Qualcomm completes acquisition of Alphawave Semi* · 2025-12-18
S4514 · CRN Asia · *Qualcomm: US$2.4 billion Alphawave Semi buy to boost data center push* · 2025-06
S4515 · 3DNews · *Qualcomm server processor to get 80 Oryon cores, NVLink Fusion, PCIe 5.0 and HBM support (DigiTimes report)* · 2025
S4516 · DatacenterDynamics · *Qualcomm to return to data center market with AI CPUs* · 2025-05
S4517 · Futurum Group · *Qualcomm's Arm-based data center CPUs to smoothly integrate with NVIDIA* · 2025-05
S4518 · DatacenterDynamics · *Meta acquires RISC-V chip startup Rivos (report)* · 2025-10
S4519 · The Register · *GPU who? Meta to deploy Nvidia CPUs at large scale* · 2026-02-17
S4520 · Tom's Hardware · *Meta will deploy standalone Nvidia Grace CPUs in production, with Vera to follow* · 2026-02
S4521 · Tom's Hardware · *Nvidia has shipped hundreds of thousands of Grace standalone servers as CPUs take center stage in agentic data centers* · 2026
S4522 · The Stack · *Nvidia: Vera CPU opportunity sits on top of $1 trillion GPU forecast* · 2026-05
S4523 · TIKR · *Nvidia says its CPU revenue sits outside the $1 trillion forecast* · 2026-05
S4524 · TweakTown · *Intel Xeon 7 Diamond Rapids reportedly delayed to mid-2027, followed by Coral Rapids in 2028* · 2026-08
S4525 · TechSpot · *Intel launches Xeon 6+ Clearwater Forest with 288 E-cores on 18A, teases Diamond Rapids for 2027* · 2026-06
S4526 · Amazon Web Services · *Amazon EC2 M9g and M9gd instances powered by AWS Graviton5 are now available* · 2026-06-10
S4527 · Converge Digest · *AWS debuts Graviton5: 192 cores, bigger caches and new Nitro security* · 2025-12
S4528 · Wccftech · *Huawei next-gen Kunpeng chips: 950 series up to 192 cores in Q4 2026, 960 series over 256 cores in Q1 2028* · 2025-09
S4529 · Converge Digest · *Fujitsu taps NVLink Fusion for MONAKA CPUs + NVIDIA GPUs for industrial AI* · 2025-10
S4530 · SoftBank Group · *Completion of acquisition of Ampere Computing Holdings LLC* · 2025-11-26
S4531 · HPCwire · *SiPearl closes €130M Series A to advance sovereign European supercomputing processors* · 2025-07
S4532 · SiPearl · *SiPearl press corner (Rhea1 power-on, 2026-05-13)* · 2026-05-13
S4533 · SiliconANGLE · *RISC-V chip startup Akeana launches with $100M+ in funding* · 2024-08
S4534 · The Register · *Tenstorrent raises $693M Series D (Samsung, Jeff Bezos among backers)* · 2024-12-04
S4535 · GCN · *Tenstorrent raises $1.5 billion to challenge Nvidia on AI chips* · 2026
S4536 · Wikipedia · *Project Denver* · 2026
S4537 · AnandTech · *The Google Nexus 9 review (Denver CPU architecture)* · 2015-02
S4538 · Qualcomm Investor Relations · *Qualcomm completes acquisition of NUVIA* · 2021-03-16
S4539 · PYMNTS · *Qualcomm inks $1.4 billion acquisition deal with chip startup NUVIA* · 2021-01-13
S4540 · Global Venturing · *Arm exits Annapurna Labs in $370m acquisition* · 2015-01-23
S4541 · The Register · *Amazon AWS puts custom Arm server chip (Graviton) into the cloud: A1 instances* · 2018-11-27
S4542 · AnandTech · *Qualcomm launches 48-core Centriq for $1,995: Arm servers for cloud native applications* · 2017-11-08
S4543 · The Next Platform · *What Qualcomm's exit from Arm server chips means* · 2018-05-10
S4544 · Network World · *Qualcomm makes it official: no more data center chip* · 2018-12
S4545 · DatacenterDynamics · *Delaware judge rules in favor of Qualcomm and Nuvia in licensing dispute with Arm* · 2025-10
S4546 · Futurum Group · *Will NVIDIA's Meta deal ignite a CPU supercycle?* · 2026-02
S4547 · Tom's Hardware · *Arm aims to capture 50% of data center CPU market in 2025* · 2025-03
S5000 · SemiAnalysis · *Nvidia's Optical Boogeyman - NVL72, InfiniBand Scale Out, 800G & 1.6T Ramp* · 2024-03
S5001 · SiliconANGLE · *Nvidia aims to boost Blackwell by donating platform design to the Open Compute Project* · 2024-10-15
S5002 · NVIDIA Blog · *Mixture of Experts Powers the Most Intelligent Frontier AI Models, Runs 10x Faster on NVIDIA Blackwell NVL72* · 2025-12-03
S5003 · HotHardware · *NVIDIA Blackwell GPUs Supercharge MoE AI, Boosting Performance Up to 10X* · 2025-12
S5004 · DeepSeek-AI (GitHub open-infra-index) · *Day 6: One More Thing, DeepSeek-V3/R1 Inference System Overview* · 2025-03-01
S5005 · DeepSeek-AI (GitHub) · *DeepEP: an efficient expert-parallel communication library (README v1.2.1)* · 2025
S5006 · DeepSeek-AI (GitHub) · *DeepSeek-V3 inference configuration (config_671B.json)* · 2024-12-26
S5007 · NVIDIA Docs · *DGX SuperPOD reference architecture (GB200): key components of the DGX SuperPOD* · 2025
S5008 · NVIDIA Docs · *NVIDIA Mission Control: NVLink information (nvlinkinfo)* · 2025
S5010 · IEEE 802.3 · *IEEE P802.3dj adopted objectives (200 Gb/s per lane electrical and optical signaling)* · 2024-03-14
S5011 · Keysight Technologies · *Validation of Achieving 200 Gb/s Signaling per Electrical Lane Over 1 meter of Passive Twinaxial Copper Cable (application note)* · 2024
S5012 · SNIA · *Cabling, Connectors and Transceivers Questions Answered* · 2021
S5013 · Edgeoptic · *DAC cables (product page: passive 100G QSFP28 0.5-5 m)* · 2026
S5014 · XSNet · *Cisco QSFP-200-CU3M 200G QSFP56 DAC (200GBASE-CR4 passive copper 3 m) listing* · 2026

S5015 · FiberMall · *QSFP-DD price guide 2026* · 2026

S5016 · Fundamental Bottom (Substack) · *Optical module industry (long AAOI note)* · 2025

S5017 · NVIDIA Docs · *NVSHMEM API documentation: introduction* · 2025

S5018 · Tom's Hardware · *Alchip responds to report that Nvidia is reportedly keeping prized NVLink tech closely guarded (updated)* · 2025

S5019 · Counterpoint Research · *NVLink Fusion - Nvidia's Response to UALink?* · 2025

S5020 · PC Watch (Impress) · *Computex 2025: NVIDIA NVLink Fusion report* · 2025-05

S5021 · IT Home · *Report on NVIDIA NVLink Fusion guidance (third-party CPU and XPU on both ends via an NVLink chiplet over UCIe)* · 2025-08

S5022 · Independent tracker (vercel.app) · *Co-packaged optics joins NVLink Fusion: Ayar Labs and Lightmatter (June 2026)* · 2026-06-08

S5500 · TrendForce · *NVIDIA GB200 racks reportedly overheat, major clients cut orders* · 2025-01-14

S5501 · TechPowerUp · *NVIDIA's GB200 'Blackwell' racks face overheating issues* · 2025-01-14

S5502 · Amphenol Corporation via SEC EDGAR · *Amphenol Corporation Form 10-Q for the quarter ended 2026-09-30* · 2026-10

S5503 · MarketBeat · *Transcript: Amphenol Q3 2026 earnings call highlights* · 2026-10-28

S5504 · Credo Technology Group via SEC EDGAR · *Credo Technology Group Form 10-K for fiscal year ended 2026-05-02* · 2026-06

S5505 · Credo Technology Group via SEC EDGAR · *Credo Technology Group Form 10-Q for the quarter ended 2026-08-01* · 2026-09

S5506 · The Register · *AI networking startup Upscale AI scores $200M to challenge Nvidia's NVSwitch* · 2026-01-22

S5507 · HPCwire · *Upscale AI eyes late 2026 for scale-up UALink switch* · 2025-12-02

S5508 · Marvell Technology · *Marvell Completes Acquisition of XConn Technologies* · 2026-02-10

S5509 · Pulse 2.0 · *Marvell Technology completes XConn acquisition* · 2026-02

S5510 · Futurum Group · *Marvell's XConn buy yields a two-pronged open fabric play against NVLink* · 2026-03

S5511 · Berkeley Wireless Research Center (Ayar Labs announcement) · *Ayar Labs closes $500M Series E, accelerates volume production of co-packaged optics* · 2026-03

S5512 · Business Wire (Ayar Labs) · *Ayar Labs, with investments from AMD, Intel Capital and NVIDIA, secures $155 million* · 2024-12-11

S5513 · StockAnalysis · *Ayar Labs (private company profile and news)* · 2026-09

S5514 · SDxCentral · *Nvidia's networking arm hits $31B as new cornerstone of AI dominance* · 2026-02

S5515 · ServeTheHome · *This is the NVIDIA DGX GB200 NVL72* · 2024-03-19

S5516 · The Register · *Nvidia's DGX GB200 NVL72 rack (GTC 2024 coverage)* · 2024-03-21

S5517 · The Next Platform · *Copper wires have already failed clustered AI systems* · 2024-09-13

S5519 · Business Wire · *AMD, Broadcom, Cisco, Google, HPE, Intel, Meta and Microsoft form Ultra Accelerator Link (UALink) Promoter Group* · 2024-05-30

S5520 · Business Wire · *Ultra Accelerator Link Consortium incorporates and opens membership* · 2024-10-29

S5521 · Converge Digest · *UALink Consortium expands board with Alibaba, Apple and Synopsys* · 2025-01-14

S5522 · Remio · *AMD Helios unites 72 GPUs but NVIDIA sets the test* · 2026

S5523 · The Register · *HPE backs AMD's Helios AI rack with Juniper's scale-up switch* · 2025-12-02

S5524 · Fierce Network · *AMD's Helios bets AI networking on open Ethernet* · 2026

S5525 · NVIDIA Blog · *Embracing transformation: AWS and NVIDIA forge ahead in generative AI and cloud innovation* · 2023-11-28

S5526 · Business Wire · *AWS and NVIDIA announce strategic collaboration to offer new supercomputing infrastructure for generative AI* · 2023-11-28

S5527 · Evertiq · *AMD completes sale of ZT Systems manufacturing unit to Sanmina* · 2025-10-27

S5528 · Sanmina · *Sanmina completes acquisition of ZT Systems data center infrastructure manufacturing business from AMD* · 2025-10-27

S6000 · TechPowerUp (NVIDIA press release) · *NVIDIA Ethernet Networking Accelerates World's Largest AI Supercomputer, Built by xAI* · 2024-10-29

S6001 · DatacenterDynamics · *xAI to double Colossus compute capacity, reveals cluster uses Nvidia Spectrum-X Ethernet* · 2024-10

S6002 · Engineering at Meta · *Building Meta's GenAI Infrastructure* · 2024-03-12

S6003 · Engineering at Meta · *RoCE networks for distributed AI training at scale* · 2024-08-05

S6004 · Microsoft Official Blog · *Inside the world's most powerful AI datacenter (Fairwater)* · 2025-09-18

S6005 · Microsoft Official Blog · *Infinite scale: the architecture behind the Azure AI superfactory* · 2025-11-12

S6006 · The New Stack · *SC23: Microsoft now has the third-fastest computer in the world* · 2023-11

S6007 · DatacenterDynamics · *Microsoft deploying equivalent of five 561 petaflops supercomputers every month* · 2024-05

S6008 · Oracle · *Oracle Unveils Next-Generation Oracle Cloud Infrastructure Zettascale10 Cluster for AI* · 2025-10-14

S6009 · NVIDIA Investor Relations · *NVIDIA Spectrum-X Ethernet Switches Speed Up Networks for Meta and Oracle* · 2025-10-13

S6010 · NVIDIA · *NVIDIA Spectrum-X Ethernet Networking Platform (product page)* · 2025

S6011 · NVIDIA Technical Blog · *Giga-scale AI Ethernet evolution: Spectrum-X Ethernet rewrites the rules* · 2025

S6012 · Converge Digest · *NVIDIA cites Spectrum-X Ethernet wins with Meta and Oracle* · 2025-10-13

S6013 · HPCwire · *Accelerating HPC and AI workflows with Mellanox's Scalable Hierarchical Aggregation and Reduction Protocol (SHARP)* · 2019-05-06

S6014 · NVIDIA Technical Blog · *Advancing Performance with NVIDIA SHARP In-Network Computing* · 2023

S6015 · ISC High Performance 2020 (Springer LNCS; PMC open access) · *Scalable Hierarchical Aggregation and Reduction Protocol (SHARP) Streaming-Aggregation Hardware Design and Evaluation* · 2020-06

S6016 · optics.org · *NVIDIA reveals plan to scale AI factories with co-packaged optics* · 2025-03-19

S6017 · Fierce Network · *Nvidia tries to balance data center power equation with co-packaged optics* · 2025-03

S6018 · The Star (Reuters) · *Nvidia CEO says power-saving optical chip tech will need to wait for wider use* · 2025-03-19

S6019 · Focus Taiwan (CNA) · *Nvidia starts shipping TSMC-backed CPO switches (GTC Taipei / Computex 2026)* · 2026-06-03

S6020 · StorageReview · *NVIDIA Spectrum-X Ethernet Photonics enters full production with 4x fewer lasers and a five-vendor CPO supply chain* · 2026-08

S6021 · remio · *NVIDIA put CPO switches into production, but the hard part starts now* · 2026-08

S6022 · Fintool · *NVIDIA CPO webinar: co-packaged silicon photonics switches for gigawatt AI factories* · 2026-02

S6023 · Converge Digest · *NVIDIA unveils Spectrum-6 Ethernet stack* · 2026-03

S6024 · Techzine · *Nvidia unveils Spectrum-XGS Ethernet for 'scale-across' data centers* · 2025-08-22

S6025 · Reuters (via Investing.com) · *How much does a GW of data center capacity actually cost?* · 2025-10

S6026 · AMCompute (blog) · *AI Cluster Cost Breakdown: CapEx (2026)* · 2026

S6027 · DatacenterDynamics · *Nvidia Q2 2025: networking is booming, but your networks cost nothing* · 2025-08

S6028 · Tiger Brokers (iTiger) · *NVIDIA's AI expansion extends to network infrastructure, captures top spot in data center Ethernet switch revenue (IDC)* · 2026-06

S6029 · Cornell Systems Research Seminar · *Understanding Stragglers in Large Model Training Using What-if Analysis (OSDI '25 seminar listing)* · 2026-02-06

S6030 · bearblog (paper summary) · *[Paper notes] RDMA over Ethernet for Distributed AI Training at Meta Scale* · 2024

S6031 · glennklockwood.com · *Meta's H100 clusters (digital garden notes)* · 2024

S6500 · Nasdaq · *Arista Networks Q2 earnings call highlights* · 2026-08

S6501 · The Next Platform · *As AI networks scale in three directions so does Arista* · 2026-08-10

S6502 · Arista Networks via SEC EDGAR · *Arista Networks Q3 2026 earnings release (Form 8-K exhibit 99.1)* · 2026-11

S6503 · Cisco Investor Relations · *Cisco Announces New Silicon One G300, Advanced Systems and Optics to Power and Scale AI Data Centers for the Agentic Era* · 2026-02-10

S6504 · Broadcom Inc. via SEC EDGAR · *Broadcom Inc. Q3 fiscal 2026 financial results (Form 8-K exhibit 99)* · 2026-09

S6505 · Nasdaq · *Broadcom Q3 earnings call highlights* · 2026-09

S6507 · TrendForce · *NVIDIA and Broadcom begin CPO switch shipments (TrendForce press release)* · 2026-07-27

S6508 · Globes · *Seven companies took part in bidding war for Mellanox* · 2019-03

S6509 · Tom's Hardware · *Nvidia outbids Intel for Mellanox (Reuters via Calcalist)* · 2019-03

S6510 · Wikipedia · *Mellanox Technologies* · 2026

S6511 · SiliconANGLE · *Nvidia invests $4B in co-packaged optics suppliers Lumentum and Coherent* · 2026-03-02

S6512 · The Register · *Nvidia burns $4B to light up American photonics manufacturing* · 2026-03-02

S6513 · LightCounting · *LightTrends newsletter: May 2026 optical vendor landscape* · 2026-05

S6514 · Business Wire (Credo) · *Credo Technology Group Holding Ltd reports fourth quarter and fiscal year 2026 financial results* · 2026-06-01

S6515 · Let's Data Science · *Credo raises guidance as optical ramp accelerates* · 2026-06

S6516 · CXO Digital Pulse (company release) · *Eridu emerges from stealth with over $200M in funding to break through the network wall* · 2026-03

S6517 · Built In · *Nexthop AI raises $500M Series B at $4.2B valuation* · 2026-03-10

S6518 · Converge Digest · *Upscale AI secures $190 million for data center networking for AI* · 2026

S6519 · SiliconANGLE · *Ayar Labs raises $500M in late-stage funding at a $3.75B valuation* · 2026-03-03

S6520 · Let's Data Science · *Xscape Photonics raises $37 million Series A extension* · 2026-03-11

S6521 · Network World · *AMD grabs DPU-maker Pensando for a cool $1.9B* · 2022-04-04

S6522 · Bloomberg · *HPE to buy Juniper Networks for $14 billion in expansion bet* · 2024-01-09

S6523 · Dell'Oro Group · *AI back-end networks switch sales surpass front-end networks for the first time in 2Q2026* · 2026-08

S6524 · Counterpoint Research · *From Blackwell to Feynman: analyzing NVIDIA's optics roadmap* · 2026

S6525 · SDxCentral · *Nvidia targets 15x optics capacity expansion by 2027 to meet CPO demand* · 2026

S6527 · SDxCentral · *Nvidia backs copper in next-gen interconnects amid push into co-packaged optics* · 2026-03

S7000 · nvidia_deep_dive_claude repository · *Repo analysis: layer 07 models (DPU offload value per compute tray, checkpoint write time, KV-cache reload time by tier)* · 2026-11-05

S7001 · NVIDIA · *NVIDIA BlueField-4 DPU datasheet* · 2026-05

S7002 · ServeTheHome · *NVIDIA BlueField-4 with 64 Arm cores and 800G networking announced for 2026* · 2025-10-28

S7004 · NAND Research · *NVIDIA STX and CMX: infrastructure for agentic AI context storage (research note)* · 2026-03

S7005 · NVIDIA · *NVIDIA DPU Power Efficiency (white paper)* · 2022-11

S7006 · The Next Platform · *Economics and the inevitability of the DPU* · 2022-11-03

S7007 · arXiv:2511.06558 · *Offloading Data Center Tax* · 2025-11

S7008 · SDxCentral · *Nvidia unveils next-gen BlueField DPU* · 2021-04

S7009 · NVIDIA Technical Blog · *GPUDirect Storage: A Direct Path Between Storage and GPU Memory* · 2019-08

S7010 · Blocks and Files · *Nvidia's GPUDirect Storage software vanquishes AI bounce buffers* · 2020-07-23

S7011 · arXiv:2409.03992 · *Confidential Computing on NVIDIA Hopper GPUs: A Performance Benchmark Study* · 2024-09

S7012 · NVIDIA · *NVIDIA Confidential Computing (solutions page)* · 2026

S7013 · Microsoft Tech Community · *General availability: Azure confidential VMs with NVIDIA H100 Tensor Core GPUs* · 2024-09-24

S7014 · AMD · *AMD Secure Encrypted Virtualization (SEV) developer page* · 2026

S7015 · Phoronix · *AMD sends out Linux patches for enabling SEV-TIO TDISP with PCIe 6.0* · 2026-09

S7016 · GPU Smith · *Confidential GPU attestation deployment matrix* · 2026-09-24

S7017 · NVIDIA Technical Blog · *NVIDIA ConnectX-8 SuperNICs advance AI platform architecture with PCIe Gen6 connectivity* · 2025

S7018 · iThome · *NVIDIA RTX PRO server and ConnectX-8 SuperNIC switch board (review)* · 2025

S7020 · Hashrate Index · *NVIDIA Vera Rubin NVL72 specs breakdown* · 2026

S7021 · NVIDIA Blog · *Full Steam Ahead: NVIDIA-Certified Program Expands to Enterprise Storage for Faster AI Factory Deployment* · 2025-03

S7022 · TechPowerUp (NVIDIA press release) · *NVIDIA, Storage Industry Leaders Unveil New Class of Enterprise Infrastructure for the AI Era (AI Data Platform)* · 2025-03-18

S7023 · Blocks and Files · *Nvidia storage announcements (GTC 2025)* · 2025-03-18

S7024 · NVIDIA NGC Catalog · *DOCA Weave Service (dpf-weave Helm chart v26.8.0)* · 2026-10-12

S7025 · SDxCentral · *Nvidia unveils BlueField-4 STX architecture to power next-gen AI storage* · 2026-03

S7026 · Solidigm · *Inference Context Memory Storage (ICMS): why AI inference is becoming a problem only flash can solve* · 2026

S7027 · NAND Research · *Research note: Improving inference with NVIDIA's Inference Context Memory Storage platform* · 2026-01

S7028 · VentureBeat · *Nvidia Rubin brings rack-scale encryption to enterprise AI security* · 2026-01

S7500 · AMD · *AMD Pensando Vulcano 800 AI NIC: Built to Scale-Out and Across* · 2026

S7501 · ServeTheHome · *AMD Vulcano 800G NIC coming as AMD outlines its UALink and UEC scale plans* · 2025-06

S7502 · SDxCentral · *5 things we learned from AMD's Advancing AI 2026* · 2026-07

S7503 · Amazon Web Services · *Instances built on the AWS Nitro System (Amazon EC2 documentation)* · 2026

S7504 · Blocks & Files · *Microsoft boosts Azure infrastructure with Fungible-derived DPU* · 2024-11-20

S7505 · InfoQ · *Microsoft's Azure Boost DPU and in-house security chip* · 2024-12

S7506 · TechRadar · *Microsoft snaps up Fungible for Azure cloud and data center boost* · 2023-01

S7507 · Mellanox Technologies via SEC EDGAR · *Mellanox Technologies Form 8-K exhibit 99.1: Mellanox completes acquisition of EZchip* · 2016-02-23

S7508 · Globes · *Mellanox completes $811m acquisition of EZchip* · 2016-02-23

S7509 · HPCwire · *Mellanox spins EZchip acquisition into BlueField silicon* · 2016-06-01

S7510 · Converge Digest · *EZchip to acquire Tilera for its multicore processors* · 2014-07

S7511 · NVIDIA Newsroom · *NVIDIA Launches BlueField-4 STX Storage Architecture With Broad Industry Adoption* · 2026-03-16

S7512 · Bloomberg Law · *Nvidia-backed Vast Data triples value to $30 billion, mulls IPO* · 2026-04

S7513 · Built In · *VAST Data raises $1B Series F at $30B valuation* · 2026-04-23

S7514 · Blackstone · *Blackstone invests $300 million at a $5 billion valuation in DDN* · 2025-01-08

S7515 · Data Phoenix · *WEKA reached unicorn status after raising its Series E at a $1.6B valuation* · 2024-05

S7516 · TechCrunch · *Hammerspace, an unstructured data wrangler used by Nvidia, Meta and Tesla, raises $100M at $500M+ valuation* · 2025-04-16

S7517 · StorageNewsletter · *Xsight Labs raises more than $300 million at $2.8 billion valuation to power next-generation AI and cloud networks* · 2026-08-06

S7518 · Bloomberg · *Intel shelves plans to sell networking division after review* · 2025-12-03

S7519 · Converge Digest · *OCP Summit: Google opens Falcon for hardware transport* · 2023-10

S7520 · Google Cloud · *Titanium (Google Cloud product page)* · 2024

S7521 · Lightwave · *Smart NIC market to grow 42% through 2027 (Dell'Oro Group)* · 2023

S7522 · Converge Digest · *Dell'Oro: surging demand for AI infrastructure (data center components, 1Q 2025)* · 2025-06

S7523 · DQIndia · *Data center semiconductors and components up 44% on AI hardware demand in 2Q-2025 (Dell'Oro)* · 2025-09

S7524 · Netdev Conference · *Innovation from within: the story of Meta's host network interface and the fbnic driver (Netdev 0x18)* · 2024-07

S7525 · Marvell · *Marvell delivers custom Ethernet network interface controller solution at OCP* · 2024-10

S7526 · Marvell · *Marvell extends OCTEON leadership with industry's first 5nm DPUs* · 2021

S7527 · AMD Investor Relations · *AMD expands data center solutions capabilities with acquisition of Pensando* · 2022-05-26

S7528 · Converge Digest · *Ultra Ethernet Consortium releases Specification 1.0* · 2025-06

S7529 · StreetInsider (Broadcom press release) · *Broadcom introduces industry's first 800G AI Ethernet NIC (Thor Ultra)* · 2025-10-14

S7530 · StorageNewsletter (NVIDIA release) · *NVIDIA launches BlueField-4, the processor powering the operating system of AI factories* · 2025-11-04

S7531 · NADDOD · *NVIDIA BlueField-3 DPUs and SuperNICs (distributor listings)* · 2026

S7532 · ICD · *NVIDIA BlueField-3 B3220 DPU 200GbE listing (900-9D3B6-00SV-AA0)* · 2026

S7533 · hidekazu-konishi.com · *AWS custom silicon history and timeline: Nitro System, Graviton, Inferentia, Trainium* · 2025

S7534 · SiliconANGLE / theCUBE Research · *Breaking Analysis: AWS's secret weapon is revolutionizing computing* · 2021-06-18

S7535 · NVIDIA Docs · *NVIDIA ConnectX-9 SuperNIC firmware release notes v82.48.1000 (February 2026 GA release)* · 2026-02

S7536 · ServeTheHome · *This is the Meta FBNIC 4x 100G multi-host adapter by Marvell* · 2024-10

S8000 · NVIDIA Docs · *NVIDIA DGX GB200 User Guide: hardware overview* · 2025

S8001 · NVIDIA Docs · *NVIDIA Enterprise Reference Architecture: NVL72 AI factory - system hardware and components* · 2025

S8002 · COMPUTEX Taipei (TAITRA) · *NVIDIA Vera Rubin NVL72 (COMPUTEX 2026 Best Choice Award entry)* · 2026-05

S8004 · TrendForce · *Liquid Cooling to Scale in AI Data Centers, Penetration to Surpass 30% in 2025* · 2025-08-21

S8005 · TrendForce (Business Wire) · *NVIDIA Blackwell Platform and ASIC Chip Upgrades to Boost Liquid Cooling Penetration to Over 20% in 2025* · 2024-09-23

S8006 · TrendForce (via LEDinside) · *[Insight] AI to Reshape the Global Technology Landscape in 2026, Says TrendForce* · 2025-11

S8007 · Uptime Institute · *Uptime Institute Global Data Center Survey 2025* · 2025-07

S8008 · The Register · *Capacity planning a rising concern for datacenter operators as AI grows* · 2025-08-03

S8009 · Lawrence Berkeley National Laboratory · *Queued Up: 2025 Edition, Characteristics of Power Plants Seeking Transmission Interconnection As of the End of 2024* · 2025-12-15

S8010 · Bloomberg · *Data Centers Face Seven-Year Wait for Dominion Power Hookups* · 2024-08-29

S8011 · ERCOT · *ERCOT Large Load Update (April 2026 hearing)* · 2026-04-01

S8012 · Glenn K. Lockwood · *Stargate (system notes)* · 2026

S8013 · DatacenterDynamics · *Crusoe's Abilene data center officially live, serving Oracle and OpenAI's Stargate* · 2025-09

S8014 · Epoch AI (Substack) · *OpenAI Stargate: where the US sites stand* · 2026

S8015 · Cleanview · *Behind-the-meter data centers: Colossus (xAI) report* · 2026-05

S8016 · NVIDIA Technical Blog · *NVIDIA 800 V HVDC Architecture Will Power the Next Generation of AI Factories* · 2025-05-20

S8017 · NVIDIA Newsroom · *NVIDIA Releases Vera Rubin DSX AI Factory Reference Design and Omniverse DSX Digital Twin Blueprint With Broad Industry Support* · 2026-03

S8018 · The Register · *Nvidia Omniverse DSX: the future of the datacenter* · 2025-10-29

S8019 · NVIDIA Blog · *New NVIDIA Software for Blackwell Infrastructure Runs AI Factories at Light Speed (Mission Control)* · 2025-03-18

S8020 · NVIDIA Docs · *DGX SuperPOD reference architecture (GB200): DGX SuperPOD software* · 2025

S8021 · NVIDIA · *NVIDIA AI inference solutions page (AI factory metrics)* · 2026

S8022 · Tom's Hardware · *JP Morgan says Nvidia is gearing up to sell entire AI servers instead of just AI GPUs and componentry* · 2025

S8024 · DataCentreNews UK · *NVIDIA to build AI factories and data centres for the next industrial revolution (Computex 2024)* · 2024-06-02

S8025 · NVIDIA · *NVIDIA MGX (product page)* · 2026

S8500 · Pulse 2.0 · *Dell Technologies Q2 revenue hits record $47 billion as AI server backlog reaches $95 billion and FY27 outlook rises to $192 billion* · 2026-09

S8501 · Beancount.io · *Dell Q2 FY2027 earnings analysis* · 2026-09-02

S8502 · Futurum Group · *Dell Q4 FY 2026 earnings highlight AI-optimized server ramp* · 2026-02-27

S8503 · MarketBeat · *Dell Technologies Q4 earnings call highlights* · 2026-02-27

S8504 · Super Micro Computer via SEC EDGAR · *Supermicro announces fourth quarter and full fiscal year 2026 financial results (Form 8-K Exhibit 99.1)* · 2026-08

S8505 · Hewlett Packard Enterprise via SEC EDGAR · *Hewlett Packard Enterprise Q3 fiscal 2026 results (Form 8-K Exhibit 99.1)* · 2026-09-02

S8506 · Constellation Research · *HPE delivers strong Q3, ups fiscal 2026 outlook due to AI demand* · 2026-09

S8507 · Vertiv Holdings via investors.vertiv.com · *Vertiv reports strong third quarter 2026 with net sales growth of 61%, organic orders growth over 100%* · 2026-10-28

S8508 · Business Wire (Eaton) · *Eaton completes acquisition of leading liquid-cooling solutions provider Boyd Thermal* · 2026-03-12

S8509 · Data Centre Review · *Eaton completes Boyd Thermal acquisition as it bolsters liquid cooling offering* · 2026-03

S8510 · Vertiv Holdings via investors.vertiv.com · *Vertiv announces intent to acquire PurgeRite (specialized fluid management services for liquid cooling)* · 2025-11-03

S8511 · Vertiv Holdings via investors.vertiv.com · *Vertiv completes acquisition of PurgeRite, expanding leadership in liquid cooling services* · 2025-12-04

S8512 · DatacenterDynamics · *Vertiv plans $1bn PurgeRite acquisition to support data center mechanical flushing, purging and filtration* · 2025-11

S8513 · The Star (Reuters) · *Schneider Electric to buy data centre cooling firm Motivair for $850 million* · 2024-10-17

S8514 · Motivair Corporation · *Schneider Electric acquires controlling interest in Motivair* · 2024-10-17

S8515 · SiliconANGLE · *ZutaCore raises $100M to scale waterless cooling for AI data centers* · 2026-06-02

S8516 · SiliconANGLE · *Data center cooling tech startup Iceotope aims to scale after raising $26M* · 2026-05-14

S8517 · Pulse.bot (aggregator) · *Frore Systems raises $143M Series D, valued at $1.64B to cool AI chips* · 2026-03

S8518 · Pulse.bot (aggregator) · *Accelsius raises $65M in Series B funding* · 2026

S8519 · TechCrunch · *Heron Power raises $140M to ramp production of grid-altering tech* · 2026-02-18

S8520 · Data Center Richness (Substack) · *Solid-state transformers could reshape data center power (VC firms pour $280 million into Heron Power, DG Matrix and Amperesand)* · 2026-06-16

S8521 · DatacenterDynamics · *MGX, AIP and BlackRock's GIP complete $40bn acquisition of Aligned Data Centers* · 2026-07

S8522 · TOP500 · *NVIDIA delivers DGX-1 'supercomputer in a box' to OpenAI* · 2016-08-15

S8523 · insideHPC · *Nvidia donates DGX-1 machine learning supercomputer to OpenAI non-profit* · 2016-08

S8524 · NVIDIA Newsroom · *NVIDIA MGX gives system makers modular architecture to meet diverse accelerated computing needs of world's data centers* · 2023-05-28

S8525 · DatacenterDynamics · *OCP Summit: Nvidia, Microsoft announce HGX-1 hyperscale GPU accelerator* · 2017-03

S8526 · Tom's Hardware · *Nvidia joins Open Compute Project with HGX-1 hyperscale GPU accelerator* · 2017-03

S8527 · AMD Investor Relations · *AMD completes acquisition of ZT Systems* · 2025-03-31

S8528 · TrendForce · *Liquid cooling to reach 53% of high-end AI infrastructure in 2026 (TrendForce press release)* · 2026-08-17

S8529 · KGI Securities · *Quanta Computer (2382 TT) company update* · 2026-02-26

S8530 · DIGITIMES Asia · *Quanta posts record Q1 2026 results as AI server shift squeezes gross margin* · 2026-05-14

S9000 · Dao-AILab (GitHub) · *FlashAttention repository README (FlashAttention-2, -3 and -4; NVIDIA CUDA and AMD ROCm support)* · 2026-11

S9001 · arXiv:2205.14135 (NeurIPS 2022) · *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness* · 2022-05-27

S9002 · arXiv:2307.08691 (ICLR 2024) · *FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning* · 2023-07-17

S9003 · arXiv:2407.08608 (NeurIPS 2024) · *FlashAttention-3: Fast and Accurate Attention with Asynchrony and Low-precision* · 2024-07-11

S9004 · arXiv:2603.05451 · *FlashAttention-4: Algorithm and Kernel Pipelining Co-Design for Asymmetric Hardware Scaling* · 2026-03

S9005 · Lambda · *FlashAttention-4 gives the NVIDIA Blackwell platform its most optimized attention kernel yet* · 2026

S9006 · Python Package Index · *PyPI JSON release histories (flash-attn, flash-attn-4, triton, cuda-tile, cuda-python, modular, mojo, tilelang)* · 2026-11-05

S9007 · NVIDIA (GitHub: NVIDIA/cutile-python) · *cuTile Python README* · 2026-11

S9008 · NVIDIA (GitHub: NVIDIA/cuda-python) · *CUDA Python README (cuda-python metapackage)* · 2026-11

S9009 · DeepSeek-AI (GitHub) · *DeepEP README (main branch: V2.5 and Ascend version)* · 2026-11

S9010 · DeepSeek-AI (GitHub) · *DeepGEMM README* · 2026-09-30

S9011 · tile-ai (GitHub) · *TileLang README (news and backends)* · 2026-09-30

S9012 · Triton (GitHub: triton-lang/triton) · *Introduction to Gluon (Triton tutorial 01-intro)* · 2026-11

S9013 · JAX (GitHub: jax-ml/jax docs/pallas/index.rst) · *Pallas: a JAX kernel language* · 2026-11

S9014 · AWS (GitHub: aws-neuron/nki-samples) · *Neuron Kernel Interface (NKI) samples README* · 2026-11

S9015 · vLLM project (GitHub: vllm-project/tpu-inference) · *vLLM JAX (formerly tpu-inference) README* · 2026-11

S9016 · Stanford Scaling Intelligence Lab (GitHub; arXiv:2502.10517) · *KernelBench: Can LLMs Write Efficient GPU Kernels? (README; ICML 2025)* · 2025-02

S9017 · VentureBeat · *Meet AlphaEvolve: the Google AI that writes its own code and just saved millions in computing costs* · 2025-05

S9018 · TechCrunch · *Sakana walks back claims that its AI can dramatically speed up model training* · 2025-02-21

S9019 · alphaXiv (arXiv:2607.17979) · *Harness Engineering for LLM-Driven GPU Kernel Generation* · 2026-07

S9021 · ACM ASPLOS 2024 (PDF hosted by PyTorch) · *PyTorch 2: Faster Machine Learning Through Dynamic Python Bytecode Transformation and Graph Compilation* · 2024-04

S9022 · Modular · *Achieving state-of-the-art performance on AMD MI355 in just 14 days* · 2025-10-17

S9023 · Modular · *Modular 25.6: unifying the latest GPUs from NVIDIA, AMD and Apple* · 2025-09

S9025 · NVIDIA Technical Blog · *NVIDIA Blackwell and NVIDIA CUDA 12.9 introduce family-specific architecture features* · 2025-05

S9026 · Tom's Hardware · *New SCALE tool enables CUDA applications to run on AMD GPUs* · 2024-07

S9027 · NVIDIA Newsroom · *NVIDIA to Train 100,000 Developers on Deep Learning in 2017* · 2017-05

S9028 · StorageReview · *Meta's MTIA roadmap: four chip generations in two years put GenAI inference first* · 2026-03

S9029 · arXiv:2002.11054 · *MLIR: A Compiler Infrastructure for the End of Moore's Law* · 2020-02

S9030 · NVIDIA (GitHub: NVIDIA/cutlass) · *CUTLASS 4.8.1 README (CuTe DSL)* · 2026-10

S9500 · Tom's Hardware · *Nvidia bans using translation layers for CUDA software to run on other chips; new restriction apparently targets ZLUDA and some Chinese GPU makers* · 2024-03-05

S9501 · Wccftech · *NVIDIA Halts The Use of CUDA On Other Platforms; Lists New Warning in the EULA* · 2024-03

S9502 · vosen/ZLUDA (GitHub) · *ZLUDA README (drop-in CUDA replacement for non-NVIDIA GPUs)* · 2026-11

S9503 · Business Standard (Bloomberg) · *Nvidia gets subpoena from US Justice Dept as antitrust probe deepens* · 2024-09-04

S9504 · Business Standard · *US launches antitrust investigation into Nvidia over sales practices* · 2024-08-02

S9505 · JURIST · *China finds Nvidia violated antimonopoly law in preliminary probe* · 2025-09-15

S9506 · Converge Digest · *AMD completes $665 million acquisition of Silo AI* · 2024-08

S9507 · DatacenterDynamics · *AMD extends acquisition run: brings software optimization firm Brium and staff from recently shuttered Untether AI into the fold* · 2025-06

S9508 · PrivSource (deal record of AMD press release) · *AMD to Acquire Nod.ai to Expand Open-Source AI Software Capabilities* · 2023-10

S9509 · PrivSource (deal record) · *AMD Acquires MK1* · 2025-11

S9510 · SDxCentral · *Modular raises $250M for AI's unified compute layer at $1.6B valuation* · 2025-09-24

S9511 · Nasdaq (Qualcomm press release) · *Qualcomm Completes Acquisition of Modular* · 2026-07-29

S9512 · Phoronix · *Modular's Mojo Language Now Open-Source Following Qualcomm Acquisition* · 2026-08-18

S9513 · modular/modular (GitHub) · *Modular Platform repository README (MAX framework and Mojo language)* · 2026-11

S9514 · ITdaily · *Why Qualcomm is paying 3.9 billion dollars for a programming language almost no one speaks* · 2026

S9515 · The Register · *Nvidia's software empire (NVIDIA AI Enterprise licensing)* · 2024-08-06

S9516 · MarketBeat · *NVIDIA Q4 FY2024 earnings call transcript* · 2024-02-21

S9517 · TechSpot · *Nvidia's AI chips already make billions; now Jensen Huang wants $2,000 per GPU in annual software fees* · 2026-10

S9518 · StorageNewsletter · *AMD AAI 2026: AMD ROCm.ai accelerates AI development across AMD platforms* · 2026-07-27

S9519 · Blockchain.news · *AMD's Advancing AI 2026 draws 2,000+ developers; launches ROCm.ai* · 2026-07

S9521 · Hackster.io · *NVIDIA makes GPU acceleration easier and more portable with CUDA Tiles and cuTile Python* · 2025-12

S9522 · PyTorch Blog · *Helion: a high-level DSL for performant and portable ML kernels* · 2025-10

S9523 · PyTorch Foundation · *Helion (PyTorch Foundation project page)* · 2026

S9524 · TrendForce · *Huawei open-sources CANN toolkit for Ascend AI GPUs; taking aim at Nvidia's CUDA* · 2025-08-07

S9525 · AWS Neuron SDK docs · *AWS Neuron documentation: PyTorch on Neuron (TorchNeuron) and NKI* · 2026

S9526 · Intel Developer · *Open Source, Open Standard, Open Governance: happy birthday UXL Foundation* · 2024-09

S9527 · UXL Foundation · *UXL Foundation: advancing portable acceleration across architectures in 2025 and what's next for 2026* · 2026-03-10

S9528 · Digital Engineering 24/7 (NVIDIA press release) · *NVIDIA Unveils CUDA - The GPU Computing Revolution Begins* · 2006-11-08

S9529 · TechPowerUp · *NVIDIA appoints first CUDA Center of Excellence* · 2008-07-01

S9530 · NeurIPS 2012 (Advances in Neural Information Processing Systems 25) · *ImageNet Classification with Deep Convolutional Neural Networks* · 2012-12

S9531 · arXiv:1410.0759 · *cuDNN: Efficient Primitives for Deep Learning* · 2014-10-03

S9532 · Stanford Graphics Lab (SIGGRAPH 2004) · *Brook for GPUs: Stream Computing on Graphics Hardware* · 2004-08

S9533 · Red Hat Blog · *FAQ: Red Hat to acquire Neural Magic* · 2024-11-12

S9534 · Pulse (venture deals) · *Luminal secures $5.3M seed round led by Felicis* · 2025-11-20

S9535 · Tenstorrent (GitHub) · *tt-metal README and Apache-2.0 licence (TT-NN / TT-Metalium)* · 2026-11

S9536 · tiny corp (GitHub: tinygrad/tinygrad) · *tinygrad README* · 2026-11

S9537 · SemiAnalysis · *AMD 2.0: new sense of urgency; MI450X chance to beat Nvidia; Nvidia's new moat* · 2025-04

S9538 · The Next Web · *AMD is investing $5 billion in Anthropic and deploying 2 gigawatts of Helios GPUs to run Claude* · 2026

S10000 · NVIDIA (GitHub: NVIDIA/nccl) · *NCCL README and makefiles/version.mk (master)* · 2026-11

S10001 · NVIDIA (GitHub: NVIDIA/nccl) · *NCCL source: default tuner constants (src/tuning/cost_model.cc) and algorithm list (src/include/device.h)* · 2026-11

S10002 · AMD (GitHub: ROCm/rccl) · *RCCL README and LICENSE (develop branch)* · 2026-11

S10003 · Microsoft (GitHub: microsoft/mscclpp) · *MSCCL++ README* · 2026-11

S10004 · arXiv:2504.09014 · *MSCCL++: Rethinking GPU Communication Abstractions for AI Inference* · 2025-04

S10005 · UCF / OpenUCX (GitHub: openucx/ucc) · *Unified Collective Communication (UCC) README* · 2026-11

S10006 · Meta / PyTorch (GitHub: pytorch/gloo) · *Gloo README* · 2026-11

S10007 · arXiv:2511.15076 · *GPU-Initiated Networking for NCCL* · 2025-11

S10008 · NVIDIA Docs · *NCCL User Guide: Device-Initiated Communication (2.28.3 and 2.32.3 archives)* · 2025-09

S10009 · NVIDIA (GitHub: NVIDIA/cutlass) · *CUTLASS README (4.8.1)* · 2026-10

S10010 · NVIDIA (GitHub: NVIDIA/cutlass) · *CUTLASS CHANGELOG* · 2026-10-15

S10011 · NVIDIA RAPIDS (GitHub: rapidsai/cudf) · *cuDF README* · 2026-11

S10012 · NVIDIA RAPIDS (GitHub: rapidsai/cudf) · *cuDF CHANGELOG (to 24.02)* · 2024-02-12

S10013 · NVIDIA RAPIDS (GitHub: rapidsai/cudf docs) · *cudf.pandas documentation (index and benchmarks)* · 2026-11

S10014 · NVIDIA Technical Blog · *RAPIDS cuDF Accelerates pandas Nearly 150x with Zero Code Changes* · 2023-11

S10015 · NVIDIA RAPIDS (GitHub: rapidsai/cuml docs) · *cuml.accel overview and benchmarks* · 2026

S10016 · NVIDIA RAPIDS (GitHub: rapidsai/cuml) · *cuML CHANGELOG (to 25.06)* · 2025-06-05

S10017 · Polars (GitHub: pola-rs/polars docs) · *Polars user guide: GPU Support [Open Beta]* · 2026-11

S10018 · NVIDIA Technical Blog · *Polars GPU Engine Powered by RAPIDS cuDF Now Available in Open Beta* · 2024-09

S10019 · NVIDIA (GitHub: NVIDIA/cudf-spark) · *NVIDIA cuDF plugin for Apache Spark README and docs index* · 2026-11

S10020 · AWS Labs (GitHub: awslabs/data-on-eks) · *Apache Spark with NVIDIA RAPIDS GPU Acceleration Benchmarks (data-on-eks)* · 2026-01-12

S10021 · DEV Community · *AWS re:Invent 2025 - FINRA: accelerate massive data processing with NVIDIA on AWS EMR (AIM279), session recap* · 2025-12

S10022 · Saturn Cloud · *Crusoe NCCL cluster validation (guide)* · 2025

S10023 · NVIDIA RAPIDS (GitHub: rapidsai/cuvs; now NVIDIA/cuvs) · *cuVS README* · 2026-11

S10024 · NVIDIA RAPIDS (GitHub: rapidsai/cuvs; now NVIDIA/cuvs) · *cuVS CHANGELOG* · 2024-10-09

S10025 · Engineering at Meta · *Accelerating GPU indexes in Faiss with NVIDIA cuVS* · 2025-05-08

S10026 · NVIDIA (GitHub: NVIDIA/cuopt) · *cuOpt README and LICENSE* · 2026-11

S10027 · It's FOSS News · *NVIDIA cuOpt goes open source (with COIN-OR)* · 2025-03-19

S10028 · NVIDIA (GitHub: NVIDIA/warp) · *NVIDIA Warp README and CHANGELOG* · 2026-11-02

S10029 · NVIDIA (GitHub: NVIDIA/cuQuantum) · *cuQuantum repository README* · 2026-11

S10030 · NVIDIA (GitHub: NVIDIA/cuda-quantum) · *CUDA-Q repository README* · 2026-11

S10031 · NVIDIA Newsroom · *TSMC and Synopsys Bring Breakthrough NVIDIA Computational Lithography Platform to Production* · 2024-03-18

S10032 · AnandTech · *NVIDIA's 'cuLitho' Computational Lithography Adopted By TSMC and Synopsys For Production Use* · 2024-03-18

S10033 · BMC Bioinformatics (PMC open access) · *Accelerating genomic workflows using NVIDIA Parabricks* · 2023-05

S10034 · Terra (Broad Institute / Verily / Microsoft) · *NVIDIA's Clara Parabricks workflows in Terra bring GPU acceleration to genomic analysis* · 2022

S10035 · NVIDIA (GitHub: NVIDIA-Omniverse/PhysX) · *NVIDIA PhysX SDK README* · 2025

S10036 · NVIDIA (GitHub: NVIDIA/earth2studio) · *NVIDIA Earth2Studio README* · 2026-11

S10037 · NVIDIA (GitHub: NVIDIA/bionemo-framework) · *BioNeMo Recipes README (bionemo-framework)* · 2026-11

S10038 · Python Package Index · *PyPI JSON release histories for NVIDIA library packages (nvidia-nccl-cu11/cu12/cu13, cudf-cu12, cudf-polars-cu12, cuml-cu12, cugraph-cu12, cuvs-cu12, warp-lang, cuquantum-python, cuda-quantum, cudaq, cuopt-cu12, nvidia-cutlass-dsl, earth2studio, nvmath-python, cuequivariance, nvidia-cudss-cu12, nvidia-modulus, nvidia-physicsnemo)* · 2026-11-05

S10039 · arXiv:1410.0759 · *cuDNN: Efficient Primitives for Deep Learning* · 2014-10

S10040 · NVIDIA Technical Blog · *Fast Multi-GPU collectives with NCCL* · 2016-04

S10041 · NVIDIA Technical Blog · *Massively Scale Your Deep Learning Training with NCCL 2.4* · 2019-02

S10042 · NVIDIA Docs · *NCCL Release Notes (2.19.3)* · 2023-10

S10043 · NVIDIA Technical Blog · *New Scaling Algorithm and Initialization with NVIDIA Collective Communications Library 2.23* · 2024-09

S10044 · NVIDIA Technical Blog · *Enabling Fast Inference and Resilient Training with NCCL 2.27* · 2025-06

S10045 · NVIDIA (GitHub: NVIDIA/TensorRT) · *TensorRT Open Source Software README and CHANGELOG* · 2026-11

S10046 · Daily Dose of Data Science · *NVIDIA's latest update can make your pandas workflow 150x faster* · 2023-11

S10047 · NVIDIA Developer · *NVIDIA CUDA-X Libraries (developer page)* · 2026

S10048 · NVIDIA RAPIDS (GitHub: rapidsai/cugraph) · *cuGraph CHANGELOG (to 24.02)* · 2024-02

S10501 · Investing.com · *NVIDIA at GTC October: Accelerating AI and Computing Innovation (keynote transcript)* · 2025-10-28

S10502 · NVIDIA Developer · *NVIDIA Announces CUDA-X AI SDK* · 2019-03-18

S10503 · AnandTech · *The NVIDIA GPU Tech Conference 2019 Keynote Live Blog* · 2019-03-18

S10504 · Quartr · *NVIDIA (NVDA) GTC 2026 Keynote summary* · 2026-03-16

S10506 · GitHub (NVIDIA) · *NVIDIA/nccl tags* · 2026-09-17

S10507 · GitHub (NVIDIA) · *NVIDIA/nccl releases (release notes v2.28.3 to v2.32.3)* · 2026-09-17

S10509 · GitHub (ROCm/rccl) · *RCCL CHANGELOG* · 2026

S10510 · GitHub (rapidsai/cudf) · *cuDF v25.02.00 release* · 2025-02-13

S10511 · AMD ROCm Documentation · *ROCm-DS 25.10 release notes* · 2025-10

S10512 · AMD ROCm Documentation · *ROCm-DS 26.03 release notes* · 2026-03

S10513 · AMD ROCm Blogs · *Introducing ROCm-DS: GPU-Accelerated Data Science for AMD Instinct GPUs* · 2025

S10514 · GitHub (ROCm/aiter) · *AITER README* · 2026-04

S10516 · StorageReview · *NVIDIA GTC 2025 AI acceleration tools (cuOpt open-sourcing and CUDA-X updates)* · 2025-03

S10517 · Phoronix · *NVIDIA Announces "RAPIDS" Open-Source Data Analytics / Machine Learning Platform* · 2018-10-10

S10518 · Tom's Hardware · *Nvidia's generative AI tool delivers a radical 60x performance boost for chipmakers: TSMC and Synopsys are now using the cuLitho software in production* · 2024-03-18

S10519 · NVIDIA Newsroom · *NVIDIA Introduces NVQLink — Connecting Quantum and GPU Computing for 17 Quantum Builders and Nine Scientific Labs* · 2025-10-28

S10520 · Quantum Computing Report · *NVIDIA's NVQLink unites quantum ecosystem for real-time error correction* · 2025-10

S10521 · Snowflake via Business Wire · *Snowflake Supercharges Machine Learning for Enterprises with Native Integration of NVIDIA CUDA-X Libraries* · 2025-11-18

S10522 · NVIDIA Blog · *Every Company's Data Is Their 'Gold Mine,' NVIDIA CEO Says at Databricks Data + AI Summit* · 2024-06

S10523 · NVIDIA Technical Blog · *GPUs for ETL? Run Faster, Less Costly Workloads with NVIDIA RAPIDS Accelerator for Apache Spark and Databricks*

S10524 · DatacenterDynamics · *Synopsys closes $35bn acquisition of Ansys* · 2025-07-17

S10525 · The Motley Fool · *Here's Nvidia's Newest $1 Billion Business* · 2024-02-28

S10526 · Benzinga · *Jensen Huang Predicts Every Enterprise On The Planet Will Eventually Run On Nvidia's 'Operating System For AI'* · 2024-02

S10527 · AlphaSpread (transcript) · *NVIDIA Q2 fiscal 2025 earnings call* · 2024-08-28

S10528 · Insider Monkey · *NVIDIA Corporation (NASDAQ:NVDA) Q3 2024 Earnings Call Transcript* · 2023-11-21

S10529 · CB Insights · *Mipsology company profile* · 2023-08

S10530 · PrivSource · *AMD Acquires Nod.ai* · 2023-10-10

S10531 · Converge Digest · *AMD completes $665 million acquisition of Silo AI* · 2024-08-12

S10532 · I-Connect007 · *AMD Acquires Brium to Strengthen Open AI Software Ecosystem* · 2025-06-05

S10533 · Phoronix · *Intel Makes Another Exciting Software Acquisition (Codeplay)* · 2022-06

S10534 · Blocks and Files · *Nvidia buys Excelero to speed GPU cluster block data access* · 2022-03-07

S10535 · SemiAnalysis · *AMD 2.0 – New Sense of Urgency | MI450X Chance to Beat Nvidia | Nvidia's New Moat* · 2025-04

S10536 · TechPowerUp · *AMD's Pain Point is ROCm Software, NVIDIA's CUDA Software is Still Superior for AI Development: Report* · 2024-12-23

S10537 · TrendForce · *Huawei Open-Sources CANN Toolkit for Ascend AI GPUs, Taking Aim at NVIDIA's CUDA* · 2025-08-07

S10538 · Huawei Ascend (hiascend.com) · *CANN Ascend operator library (AOL) API reference* · 2026

S10539 · AWS Neuron Documentation · *About the NKI Library* · 2026

S10540 · Intel · *Intel oneAPI Toolkit Release Notes (2026)* · 2026

S10541 · UXL Foundation · *UXL Foundation: advancing portable acceleration across architectures in 2025 and what's next for 2026* · 2025-12

S10542 · Crypto Briefing · *AMD joins UXL Foundation as steering member, backs oneDNN for PyTorch* · 2026-10-20

S10543 · OpenXLA (GitHub) · *OpenXLA XLA compiler* · 2026

S10544 · Google (GitHub) · *OR-Tools* · 2026

S10545 · Google Research (GitHub) · *ScaNN (Scalable Nearest Neighbors)* · 2026

S10546 · Google (GitHub) · *DeepVariant* · 2026

S10547 · Google Quantum AI (GitHub: quantumlib) · *qsim* · 2026

S10548 · Amazon Web Services · *Amazon Braket* · 2026

S10549 · Amazon Web Services · *AWS HealthOmics* · 2026

S10550 · Amazon Web Services · *Amazon OpenSearch Service* · 2026

S10551 · Amazon Web Services · *Amazon Neptune* · 2026

S10552 · Google Cloud · *BigQuery (incl. BigQuery ML)* · 2026

S10553 · Intel (GitHub: openvinotoolkit) · *OpenVINO toolkit* · 2026

S10554 · UXL Foundation (GitHub) · *oneDNN* · 2026

S10555 · UXL Foundation (GitHub) · *oneCCL* · 2026

S10556 · UXL Foundation (GitHub) · *oneDAL (Data Analytics Library)* · 2026

S10557 · Intel · *Intel oneAPI Math Kernel Library (oneMKL) Release Notes and System Requirements* · 2026

S10558 · AMD ROCm (GitHub) · *Composable Kernel* · 2026

S10559 · AMD ROCm (GitHub) · *MIOpen* · 2026

S10560 · The Register · *Voltron Data's Theseus GPU SQL engine on AMD (article; title paraphrased)* · 2025-06-18

S10561 · FinSMEs · *Voltron Data receives investment from Accenture Ventures* · 2025-02

S10562 · Fenwick · *Fenwick represents Anyscale in $100 million Series C financing* · 2021-12

S10563 · Coiled via PR Newswire · *Coiled Announces $5M Seed Funding to Meet the Needs of Modern Data Teams* · 2020

S10564 · Tech.eu · *PhysicsX raises $300M at $2.4BN valuation* · 2026-06-08

S10565 · Built In · *Luminary Cloud Raises $72M to Develop Physics-Based AI Tools for Engineers* · 2025-09-17

S10566 · Global Venturing · *Nvidia backs three quantum startups amid investment boom* · 2025-09

S10567 · The Quantum Insider · *How is NVIDIA 'Betting' on Quantum? A Look at NVentures Quantum Investment Playbook* · 2025-09-13

S10569 · Google (GitHub) · *Brax* · 2026

S10570 · SemiAnalysis · *AMD's lack of disaggregated prefill inferencing and NVMe KV cache tiering (article section)* · 2025

S11000 · nvidia_deep_dive_claude repository · *Repo analysis: layer 11 inference models (disaggregation comparison, cost per million tokens across software releases, implied inference revenue, tokens per MW and per-request economics)* · 2026-11-05

S11001 · NVIDIA (GitHub) · *NVIDIA Dynamo README (ai-dynamo/dynamo)* · 2026-11

S11002 · NVIDIA (GitHub ai-dynamo/dynamo docs) · *Dynamo design docs: Disaggregated Serving* · 2026

S11003 · NVIDIA (GitHub ai-dynamo/nixl) · *NVIDIA Inference Xfer Library (NIXL) README* · 2026-11

S11004 · NVIDIA (GitHub NVIDIA/TensorRT-LLM docs) · *TensorRT-LLM docs: Paged Attention, IFB and Request Scheduling* · 2026

S11005 · NVIDIA (GitHub NVIDIA/TensorRT-LLM docs) · *TensorRT-LLM docs: KV Cache System* · 2026

S11006 · NVIDIA (GitHub NVIDIA/TensorRT-LLM docs) · *TensorRT-LLM docs: Speculative Decoding* · 2026

S11007 · NVIDIA (GitHub NVIDIA/TensorRT-LLM docs) · *TensorRT-LLM docs: Quantization* · 2026

S11008 · NVIDIA (GitHub NVIDIA/TensorRT) · *TensorRT Open Source Software README (TensorRT 11.x announcement)* · 2026-11

S11009 · NVIDIA (GitHub triton-inference-server/server) · *Triton Inference Server README* · 2026-11

S11010 · NVIDIA Developer · *NVIDIA Dynamo-Triton (product page)* · 2025-03-18

S11011 · MarketBeat · *NVIDIA Q2 Fiscal 2025 earnings call transcript (28 August 2024)* · 2024-08-28

S11012 · The Motley Fool · *NVIDIA (NVDA) Q4 fiscal 2026 earnings call transcript (25 February 2026)* · 2026-02-25

S11013 · NVIDIA (docs.api.nvidia.com) · *NVIDIA NIM FAQ* · 2025

S11014 · NVIDIA (press release via Nasdaq) · *NVIDIA launches generative AI microservices for developers to create and deploy generative AI copilots across NVIDIA CUDA GPU installed base* · 2024-03-18

S11015 · HPCwire (NVIDIA press release) · *NVIDIA NIM now available to transform world's millions of developers into generative AI developers* · 2024-06-02

S11016 · TweakTown · *Jensen Huang puts a $2000 per GPU yearly price on NVIDIA's AI agent software* · 2026-10

S11017 · TechSpot · *Nvidia's AI chips already make billions, now Jensen wants $2,000 a year per GPU for software* · 2026-10

S11018 · beri.net · *Pick vLLM or SGLang to skip NVIDIA AI Enterprise fees (per-GPU licence pricing)* · 2026

S11019 · NVIDIA (GitHub) · *NVIDIA Nemotron Developer Repository README (NVIDIA-NeMo/Nemotron)* · 2026-11

S11020 · NVIDIA (GitHub NVIDIA-NeMo/Nemotron docs) · *Nemotron 3 Super training guide* · 2026

S11021 · SiliconANGLE · *Nvidia launches Nemotron 3 open models to power multi-agent systems* · 2025-12-15

S11022 · Tom's Hardware · *Nvidia's Nemotron coalition brings eight AI labs together to build open frontier models* · 2026-03

S11023 · NVIDIA Developer Forums · *The NVIDIA Nemotron family just crossed 5M downloads on Hugging Face* · 2025-12

S11024 · NVIDIA · *NVIDIA Nemotron: LLM info* · 2026

S11025 · Fortune · *Nvidia's Hugging Face deal (report of a ~$12.9 billion acquisition)* · 2026-08-27

S11026 · Implicator.ai · *Nvidia confirms $12.9 billion Hugging Face deal, says its chips won't be required* · 2026-09

S11027 · MLex · *Nvidia may seek EU review of Hugging Face deal amid filing uncertainty* · 2026-09-23

S11028 · Stocktwits · *NVDA stock edges down on DOJ interest in $12.9 billion Hugging Face acquisition* · 2026-10-28

S11029 · NVIDIA (GitHub NVIDIA-NeMo/Guardrails) · *NVIDIA NeMo Guardrails library README* · 2026-11

S11030 · NVIDIA (GitHub NVIDIA/NeMo-Agent-Toolkit) · *NVIDIA NeMo Agent Toolkit README* · 2026-11

S11031 · NVIDIA (GitHub NVIDIA-AI-Blueprints/rag) · *NVIDIA RAG Blueprint README* · 2026-11

S11032 · NVIDIA (GitHub NVIDIA-AI-Blueprints/aiq) · *NVIDIA AI-Q Blueprint README* · 2026-11

S11033 · NVIDIA (GitHub NVIDIA/TensorRT-LLM docs) · *TensorRT-LLM docs: Disaggregated Serving* · 2026

S11034 · NVIDIA (GitHub NVIDIA-NeMo/Nemotron docs) · *Nemotron 3 Nano training guide* · 2026

S11035 · Techleap Finder (news feed) · *Nvidia unveils Nemotron Super 3 AI model ahead of GTC conference* · 2026-03-11

S11500 · TechRadar Pro · *'The planets aligned': Nvidia confirms $12.9bn Hugging Face deal in potentially huge AI shake-up* · 2026-09-03

S11501 · Dealroom · *Nvidia's $12.9B Hugging Face deal could be blocked by Europe* · 2026-09

S11502 · Hugging Face (GitHub: huggingface/text-generation-inference) · *Text Generation Inference (TGI) README: maintenance-mode notice* · 2026-11

S11503 · llm-d project (GitHub: llm-d/llm-d) · *llm-d README (distributed inference on Kubernetes)* · 2026-11

S11504 · NVIDIA (GitHub: NVIDIA/TensorRT) · *TensorRT open-source repository CHANGELOG* · 2026-10-09

S11505 · NVIDIA Developer Blog · *Production Deep Learning with NVIDIA GPU Inference Engine (Parallel Forall blog; update: GIE is now TensorRT)* · 2016-06

S11506 · NVIDIA Docs · *Triton Inference Server Release Notes* · 2026

S11509 · The Logic · *Nvidia's deal for CentML could be worth more than US$400M* · 2025-06

S11510 · Analytics Insight · *Top AI acquisitions of 2024: a detailed analysis* · 2024-12

S11511 · TechCrunch · *Inference startup Inferact lands $150M to commercialize vLLM* · 2026-01-22
S11512 · TechCrunch · *Sources: Project SGLang spins out as RadixArk with $400M valuation as inference market explodes* · 2026-01-21
S11513 · Doolpa · *RadixArk raises $100M seed to grow the SGLang inference engine* · 2026-05-05
S11514 · Bloomberg Government (Bloomberg) · *Fireworks AI in talks for funding at $15 billion valuation* · 2026-05
S11515 · Tech Funding News · *Nvidia-backed Fireworks AI eyes $30B to $40B valuation roughly double its July price* · 2026
S11516 · DatacenterDynamics · *Together AI raises $800m in Series C funding round* · 2026-07
S11517 · The Next Web · *Together AI raises 800 million dollars in Series C as open-source cloud demand surges* · 2026-07-01
S11518 · Pulse (venture deals aggregator) · *Baseten Labs raises $300M in growth-stage round, valuation hits $5B* · 2026-01-23
S11519 · Creati.ai · *Modal Labs negotiates funding at $2.5B valuation as AI inference market heats up* · 2026-02-12
S11520 · eWeek · *Positron secures $230M AI funding for $1B valuation* · 2026-02-04
S11521 · Latham & Watkins · *Latham & Watkins advises Positron AI on Series C* · 2026-09
S11522 · CB Insights · *FuriosaAI financials (funding rounds)* · 2026
S11523 · DatacenterDynamics · *OpenAI signs $10 billion deal with Cerebras with 750MW of big chip compute* · 2026-01-14
S11524 · TechCrunch · *OpenAI signs deal reportedly worth $10 billion for compute from Cerebras* · 2026-01-14
S11525 · Epoch AI · *LLM inference prices have fallen rapidly but unequally across tasks* · 2025-03
S11526 · Stanford HAI · *The 2025 AI Index Report* · 2025-04
S11527 · arXiv 2511.23455 (MIT FutureTech) · *The Price of Progress: Algorithmic Efficiency and the Falling Cost of AI Inference* · 2025-11
S11528 · OpenAI · *Introducing ChatGPT and Whisper APIs* · 2023-03-01
S11529 · OpenAI · *GPT-4 (research announcement and API pricing)* · 2023-03-14
S11530 · OpenAI · *New models and developer products announced at DevDay* · 2023-11-06
S11531 · OpenAI · *Hello GPT-4o* · 2024-05-13
S11532 · OpenAI · *GPT-4o mini: advancing cost-efficient intelligence* · 2024-07-18
S11533 · OpenAI · *Introducing Structured Outputs in the API* · 2024-08-06
S11534 · OpenAI · *Introducing GPT-5 for developers* · 2025-08-07
S11535 · Doolpa · *OpenAI launches GPT-5.5 with state-of-the-art agentic coding and doubles API prices (April 2026)* · 2026-04
S11536 · Pulse (news aggregator) · *GPT-5.5 costs 49 to 92 percent more than its predecessor depending on the input length* · 2026-04
S11537 · The Decoder · *OpenAI reportedly dramatically improved its compute profit margins* · 2025-12
S11538 · Bloomberg · *OpenAI sees better margins on business sales; report says* · 2025-12-21
S11539 · ggml-org/llama.cpp (GitHub) · *ggml.ai joins Hugging Face to ensure the long-term progress of Local AI (discussion #19759)* · 2026-02-20
S11540 · Pulse 2.0 · *Inferact launches with $150 million funding at $800M valuation to commercialize vLLM* · 2026-01-22
S11541 · OpenAI · *New embedding models and API updates* · 2024-01-25
S12000 · NVIDIA Blog · *NVIDIA Acquires Open-Source Workload Management Provider SchedMD* · 2025-12-15
S12001 · SiliconANGLE · *Nvidia acquires SchedMD, developer of the Slurm workload manager* · 2025-12-15
S12002 · KAI Scheduler project (originally NVIDIA Run:ai) · *KAI Scheduler (GitHub repository README)* · 2026-04
S12003 · The New Stack · *NVIDIA open sources KAI Scheduler to help AI teams optimize GPU utilization* · 2025-04
S12004 · NVIDIA · *NVIDIA Mission Control (product page)* · 2025
S12005 · NVIDIA Blog · *New NVIDIA Software for Blackwell Infrastructure Runs AI Factories at Light Speed* · 2025-03-18
S12006 · NVIDIA Technical Blog · *Automating AI Factory Operations with NVIDIA Mission Control* · 2026
S12007 · NVIDIA Newsroom · *NVIDIA Launches DGX Cloud, Giving Every Enterprise Instant Access to AI Supercomputer From a Browser* · 2023-03-21
S12008 · NVIDIA Newsroom · *NVIDIA DGX Cloud Lepton Connects Europe's Developers to Global NVIDIA Compute Ecosystem* · 2025-06-11
S12009 · DatacenterDynamics · *Nvidia launches Lepton AI platform connecting GPU cloud providers' resources* · 2025-05
S12010 · DatacenterDynamics · *Neocloud results Q2 2026: CoreWeave, Nebius, Cerebras* · 2026-08
S12011 · DatacenterDynamics · *CoreWeave files for IPO on Nasdaq stock market* · 2025-03
S12012 · CoreWeave via Business Wire · *CoreWeave Reports Strong Fourth Quarter and Fiscal Year 2025 Results* · 2026-02-26
S12013 · MarkTechPost · *Best GPU neoclouds 2026: CoreWeave, Nebius, Lambda, Crusoe and Groq ranked by published pricing and contracted power* · 2026-08-23
S12014 · DatacenterDynamics · *Microsoft bought twice as many Nvidia Hopper GPUs as other big tech companies - report* · 2024-12
S12015 · USENIX OSDI '26 · *Heterogeneity at Hyperscale: Characterization and Scheduling of Large Production AI Clusters at Alibaba* · 2026-07
S12016 · Alibaba (GitHub) · *Alibaba Cluster Trace Program (clusterdata) README incl. cluster-trace-gpu-v2026* · 2026
S12017 · USENIX NSDI '22 · *MLaaS in the Wild: Workload Analysis and Scheduling in Large-Scale Heterogeneous GPU Clusters* · 2022-04
S12018 · NVIDIA (GitHub) · *NVIDIA Kubernetes device plugin (GitHub README): MIG strategies and shared access via time-slicing and MPS* · 2026
S12019 · NVIDIA (GitHub) · *NVIDIA MIG Partition Editor (mig-parted) README* · 2026
S12020 · NVIDIA (GitHub) · *NVIDIA Data Center GPU Manager (DCGM) README* · 2026
S12021 · NVIDIA Dynamo project (GitHub) · *Grove: one API for any inference architecture (GitHub README)* · 2026
S12022 · Trending Topics · *Neoclouds challenge the hyperscalers in big bets on AI infrastructure* · 2026
S12500 · CoreWeave (press release via Seeking Alpha) · *CoreWeave Reports Strong Second Quarter 2026 Results* · 2026-08
S12501 · Runtime Wire · *CoreWeave reports $2.58 billion Q2 revenue with $35 billion in debt* · 2026-08
S12502 · MarketBeat · *CoreWeave Q2 earnings call highlights* · 2026-08-11
S12503 · Quartr · *Nebius Group (NBIS) Q2 2026 earnings summary* · 2026-08
S12504 · MarketBeat · *Nebius Group Q2 earnings call highlights* · 2026-08-12
S12506 · CoreWeave Investor Relations · *CoreWeave Completes Acquisition of Weights & Biases* · 2025-05-05
S12507 · Maginative · *CoreWeave acquires Weights & Biases in a $1.7 billion AI cloud play* · 2025-03
S12508 · SiliconANGLE · *Core Scientific shareholders dismiss $9B CoreWeave deal on valuation worries* · 2025-10-30
S12509 · NVIDIA Technical Blog · *NVIDIA open sources Run:ai Scheduler to foster community collaboration (KAI Scheduler)* · 2025-04
S12510 · NVIDIA Technical Blog · *NVIDIA Run:ai is now open source as part of NVIDIA DSX AI Factory platform* · 2026-10
S12511 · TechRepublic · *Nvidia Run:ai is now open source: what's free and paid* · 2026-10-15
S12512 · Techstrong.ai · *NVIDIA hands Run:ai to the open source community* · 2026-10
S12513 · NVIDIA Newsroom · *NVIDIA DSX Gives Infrastructure Builders the Playbook for AI Factories* · 2026-05-31
S12514 · NVIDIA · *NVIDIA DSX OS (product page)* · 2026
S12515 · Data Center Knowledge · *Nvidia says Vera Rubin, Vera CPU on track, launches DSX OS to run AI factories* · 2026-06
S12516 · SemiAnalysis · *The Great GPU Shortage - Rental Capacity - Launching our H100 1 Year Rental Price Index* · 2026-03
S12517 · Silicon Data · *H100 price spike (Silicon Data H100 rental index)* · 2026-01
S12518 · Datacentres.com · *Hyperscaler capex trends: over $700 billion for 2026* · 2026-08
S12519 · Hargreaves Lansdown · *AI hyperscalers are expected to finish the year spending a whopping $828 billion on capex* · 2026-10
S12520 · Fierce Network · *Neocloud Nscale raises $3.36B ahead of IPO* · 2026-09
S12521 · TechCrunch · *AI computing startup Lambda to raise $4B ahead of planned IPO* · 2026-10-06

S12522 · ValueAdd VC · *Neocloud valuations 2026 (tracker)* · 2026-10-31
S12523 · Dealroom · *Fluidstack raises $750M at $7B as Google and Anthropic anchor its AI data centres* · 2026-04-06
S12524 · DatacenterDynamics · *Anthropic plans $50bn US data center spend, starting with Fluidstack sites in Texas and New York* · 2025-11-12
S12525 · The Energy Mag · *Fluidstack seeks $700M at $7B valuation; TeraWulf and Cipher leases backstopped by Google* · 2025-12-07
S12526 · Introl · *Microsoft's $60B neocloud bet: buying time in the AI capacity crisis* · 2025-12
S12527 · TechRepublic · *Meta inks $14.2B AI infrastructure deal with CoreWeave* · 2025-09-30
S12528 · NVIDIA Newsroom · *NVIDIA Partners With Apollo, BlackRock, Blackstone, Brookfield, Goldman Sachs and KKR to Establish AI Compute Infrastructure Financing Platforms to Mobilize Over $500 Billion of Third-Party Capital* · 2026-08-10
S12529 · NVIDIA Technical Blog · *Introducing NVIDIA DGX Cloud Lepton: a unified AI platform built for developers* · 2025-05
S12530 · CoreWeave Blog · *New CoreWeave SUNK capabilities help teams build modern AI research clusters* · 2025
S12531 · Spheron Network (blog) · *The real cost of renting an H100 in 2026* · 2026-07
S12533 · Kubernetes SIGs on GitHub · *Kueue (README)* · 2026
S12534 · SkyPilot project on GitHub · *SkyPilot (README)* · 2026-10
S12535 · Ray project on GitHub (Anyscale) · *Ray (README)* · 2026
S12536 · DatacenterDynamics · *CoreWeave Q3 earnings show revenue backlog doubled to $55.6bn* · 2025-11
S13000 · The Korea Times · *Nvidia to supply 260,000 chips to Korea for AI factories with Samsung, SK, Hyundai* · 2025-10-31
S13001 · Data Center Knowledge · *South Korea to boost AI infrastructure with 260,000 Nvidia chips* · 2025-11
S13002 · The Korea Herald · *Naver and NVIDIA expand sovereign AI partnership toward gigawatt-scale AI factories* · 2026-06
S13003 · Middle East AI News · *HUMAIN to deploy 600,000 NVIDIA GPUs across KSA, USA* · 2025-11-19
S13004 · GIGAZINE · *xAI to co-develop 500MW+ data center in Saudi Arabia* · 2025-11-20
S13005 · Middle East AI News · *Saudi to build 500MW AI factories with NVIDIA tech* · 2025-05
S13006 · AGBI · *Humain receives first shipment of fast Nvidia AI chips* · 2025-12
S13007 · Intelligent CIO Middle East · *G42, OpenAI, Oracle, NVIDIA, SoftBank, Cisco launch Stargate UAE from UAE-US AI Campus in Abu Dhabi* · 2025-05-23
S13008 · Gulf News · *New update on Stargate UAE: first phase of 200MW to complete by 2026* · 2025-10
S13009 · NVIDIA Newsroom · *NVIDIA and United Kingdom Build Nation's AI Infrastructure and Ecosystem to Fuel Innovation, Economic Growth and Jobs* · 2025-09-16
S13010 · ITPro · *UK to host largest European GPU cluster under GBP 11 billion Nvidia investment plans* · 2025-09
S13011 · Sifted · *Mistral Compute launch* · 2025-06-11
S13012 · ActuIA · *Mistral AI and NVIDIA towards a sovereign AI infrastructure in Europe* · 2025-06
S13013 · DatacenterDynamics · *Deutsche Telekom launches NVIDIA-powered AI factory in Munich's Tucherpark* · 2026
S13014 · heise online · *Telekom data center with 10,000 Nvidia GPUs being built in Munich* · 2025-11-04
S13015 · eWEEK · *Nvidia and Deutsche Telekom unveil EUR 1B AI factory in Munich* · 2025-11
S13016 · NVIDIA Blog · *NVIDIA to Help Elevate Japan's Sovereign AI Efforts Through Generative AI Infrastructure Build-Out* · 2024-05
S13017 · Computer Weekly · *Nvidia backs India's sovereign AI push with gigawatt-scale infrastructure* · 2026-02
S13018 · Business Today · *Nvidia embeds itself at the heart of India's sovereign AI push* · 2026-02-18
S13019 · YourStory · *Yotta to spend $2B on NVIDIA chips* · 2026-02
S13020 · Quiver Quantitative (NVIDIA press release) · *NVIDIA Announces GTC 2025: Premier AI Conference Set for March 17-21 in San Jose* · 2025-01
S13021 · GamesBeat · *NVIDIA GTC 2024 preview: AI marches forward (Greg Estes interview)* · 2024-03
S13022 · NewsBytes · *NVIDIA's GTC 2026 is happening next week: here's what to expect* · 2026-03
S13023 · NVIDIA · *GTC 2026 Schedule at a Glance* · 2026
S13024 · Wikipedia · *Nvidia GTC* · 2026
S13025 · NVIDIA Blog · *Inception to the Rule: AI Startups Thrive Amid Tough 2020* · 2020-12-18
S13026 · AI Business · *Nvidia's Inception program now boasts 8,500 AI startup members* · 2021-08
S13027 · MarketScreener (NVIDIA press release) · *NVIDIA Inception Program for AI Startups Adds 2,000th Member* · 2017
S13028 · MarketScreener (NVIDIA Blog) · *Innovation Inspiration: 5 Startup Stories From NVIDIA Inception in 2021* · 2021-12
S13029 · TechCrunch · *Nvidia's AI empire: a look at its top startup investments* · 2026-01-02
S13030 · Rallies.ai · *Nvidia participates in 14 European funding rounds in 2025, including EUR 1.7B Mistral Series C* · 2026-01
S13031 · NVIDIA Newsroom · *NVIDIA to Train 100,000 Developers on Deep Learning in 2017* · 2017-05
S13032 · NVIDIA Blog · *NVIDIA Deep Learning Institute Instructor-Led Training Now Available Remotely* · 2020-05-06
S13033 · NVIDIA Newsroom · *NVIDIA RTX PRO Servers Speed Trillion-Dollar Enterprise IT Industry Transition to AI Factories* · 2025-05-19
S13034 · NVIDIA Investor Relations · *Industry Leaders Transform Enterprise Data Centers for the AI Era With NVIDIA RTX PRO Servers* · 2025-08-11
S13035 · Tom's Hardware · *Nvidia unveils 2U RTX Pro 6000 servers at SIGGRAPH* · 2025-08
S13036 · The Register · *Nvidia's software empire (NVIDIA AI Enterprise pricing)* · 2024-08-06
S13037 · The Motley Fool · *Here's Nvidia's newest $1 billion business* · 2024-02-28
S13038 · TechSpot · *Nvidia's AI chips already make billions; now Jensen Huang wants $2000 per GPU in annual software fees* · 2026
S13039 · xAI · *xAI raises $20B Series E (announcement)* · 2026-01-06
S13040 · Converge Digest · *xAI raises $20B in upsized Series E, supported by NVIDIA and Cisco* · 2026-01
S13041 · NVIDIA Blog · *NVIDIA Acquires Open-Source Workload Management Provider SchedMD* · 2025-12-15
S13042 · HPCwire / AIwire · *Accenture and NVIDIA strengthen partnership to accelerate deployment and scaling of AI-driven solutions* · 2024-10-09
S13043 · NVIDIA Corporation via SEC EDGAR · *NVIDIA FY2026 Form 10-K, note: non-marketable equity securities (XBRL R17)* · 2026-02-25
S13500 · Securities.io · *Nvidia board adds $150 billion to share repurchase program* · 2026-08
S13501 · Advanced Micro Devices via SEC EDGAR · *AMD Q3 2026 earnings slides (Form 8-K exhibit)* · 2026-11
S13503 · Qualcomm via SEC EDGAR · *Qualcomm Form 10-K for fiscal year ended September 27, 2026* · 2026-11
S13504 · OpenCapital · *QUALCOMM (QCOM) cash flow metrics* · 2026
S13505 · OpenCapital · *AMD free cash flow history* · 2026
S13506 · Tom's Hardware · *OpenAI signs 6 GW AMD GPU deal* · 2025-10-06
S13507 · The Motley Fool · *AMD pays a high price for blockbuster OpenAI deal* · 2025-10-07
S13511 · Kavout · *Is Nvidia's Groq deal a masterstroke or an antitrust minefield?* · 2026
S13513 · AOL / Yahoo Finance · *Nvidia steps up South Korea AI push with 260 000-chip rollout (Reuters)* · 2025-10-31
S13514 · The Daily Star · *Saudi AI firm Humain inks Nvidia deal (Reuters)* · 2025-05-13
S13515 · The Sun (Malaysia) · *Saudi AI firm Humain signs major Nvidia chip deal after US approval* · 2025-11
S13516 · The National · *Saudi Arabia's Humain expands Nvidia deal with 84 MW AI computing plan* · 2026-10-22
S13517 · Futuriom · *NVIDIA and AMD score AI hub deals in Saudi Arabia* · 2025-05
S13519 · Google Cloud · *Google for Startups Cloud Program* · 2026
S13520 · Fin.ai · *Startup programs compared 2026: AWS, Google, Microsoft* · 2026
S13521 · Huawei · *Huawei announces open-sourcing of CANN and Ascend ecosystem investments (HUAWEI CONNECT 2025)* · 2025-09
S13523 · Emerce (Industry Wire) · *Huawei industry release on the Ascend/CANN open-source community (Dutch)* · 2026-09-23
S13526 · Storyboard18 · *Nvidia CEO Jensen Huang hints no further investments in OpenAI, Anthropic* · 2026

S13528 · Digital Today (Korea) · *Nvidia emerges as major investor in AI ecosystem, puts in $40 billion this year* · 2026

S13529 · Bloomberg Government · *Nvidia to invest $4 billion in data center optics companies* · 2026-03-02

S13531 · Tom's Hardware · *Intel says it has two prospective customers for 14A and expects commitments in the second half of 2026* · 2026

S13532 · Borecraft · *Intel's post-18A roadmap hangs on landing 14A foundry customers* · 2026-06-17

S13533 · ResearchPool (NVIDIA press release) · *NVIDIA CEO Jensen Huang and global technology leaders to showcase age of AI at GTC 2026 (press release summary)* · 2026-02

S13536 · Techsoma · *Nvidia's free startup program just unlocked AI success for 22,000 companies* · 2025

S14000 · nvidia_deep_dive_claude repository · *Repo analysis: chapter 14 TCO model (scripts/tco/tco_model.py with data/x14_tco_scenarios.csv)* · 2026-11-05

S14001 · Wccftech · *AMD hikes the price of its Instinct MI350 AI accelerator by 70 percent* · 2025-07

S14002 · Wccftech · *AMD is reportedly pricing its Helios rack 40% above NVIDIA's second-gen Rubin, confident that customers will pay the premium* · 2026-07

S14003 · The Next Platform · *With Trainium4, AWS will crank up everything but the clocks* · 2025-12-03

S14004 · EvoKernel Specs · *AWS Trainium 2 (hardware specification page)* · 2026

S14005 · Datacentre Magazine · *AWS Trainium3 cuts AI data centre power consumption by 40%* · 2025-12

S14006 · Tom's Hardware · *Jensen Huang says even free AI chips from his competitors can't beat Nvidia's GPUs* · 2024-03

S15000 · About Amazon · *Amazon CEO Andy Jassy on Amazon's chips business (Q1 2026 earnings)* · 2026-04-29

S15001 · Nasdaq · *Andy Jassy says Amazon's chip business already has $225 billion in commitments* · 2026-05

S15002 · Tom's Hardware · *Meta's MTIA chip lineup joins hyperscaler push to replace Nvidia at inference* · 2026-03

S15003 · Meta AI Blog · *Meta MTIA: scaling AI chips for billions of users* · 2026-03-11

S15004 · TechCentral.ie · *Meta acquires chip developer Rivos to strengthen its position in AI* · 2025-10

S15005 · StorageReview · *Microsoft Maia 300: HBM4, N2P chiplet design and a 96-accelerator rack* · 2026-10

S15006 · Notebookcheck · *Microsoft Maia 300 AI chip arrives with 288 GB HBM4 memory and 18 TB/s bandwidth* · 2026-10

S15007 · Network World · *Microsoft launches its second-generation AI inference chip Maia 200* · 2026-01-26

S15008 · DatacenterDynamics · *Microsoft says it has access to the IP of OpenAI's custom AI chips* · 2025-11

S15009 · Axios · *What to know about OpenAI's new deal with Microsoft* · 2025-10-29

S15010 · StorageReview · *Google announces TPU 8t (Sunfish) and TPU 8i (Zebrafish)* · 2026-04

S15011 · Tom's Hardware · *Google splits its TPU into two chips for the first time with training and inference variants* · 2026-04

S15012 · AMD Newsroom · *AMD unveils strategy to lead the $1 trillion compute market and accelerate next phase of growth (Financial Analyst Day)* · 2025-11-11

S15013 · Built In · *OpenAI enters $38B partnership with AWS to scale compute capacity* · 2025-11-04

S15014 · nvidia_deep_dive_claude repository · *Repo analysis: Chapter 15A competitive-landscape calculations (gap-to-flagship ratios, implied AMD commitment value, hyperscaler wallet shares, breadth vs depth)* · 2026-11-05

S15500 · DatacenterDynamics · *Broadcom bulges with Anthropic AI orders* · 2025-12

S15501 · DatacenterDynamics · *Broadcom slams AI silicon-fuelled Q3, promises double-double on the way* · 2026-09-03

S15502 · ChannelWeb (CRN UK) · *Broadcom Q3 results: CEO Tan forecasts surging AI infrastructure buildout* · 2026-09

S15503 · TrendForce · *MediaTek forecasts $1B in ASIC sales for 2026; custom AI chips set for 20% revenue share in 2027* · 2026-02-05

S15504 · Futurum Group · *Marvell Q2 FY 2027: connectivity and custom silicon fuel AI growth* · 2026-08

S15505 · Zacks · *MRVL Q2 earnings beat on data center strength, outlook raised* · 2026-08

S15506 · Alchip Technologies (syndicated press release) · *Alchip Technologies reports Q4 and 2025 FY financial results* · 2026-02

S15507 · S&P Global Market Intelligence · *Alchip faces sharp 2025 decline; analysts forecast strong 2026 recovery* · 2026-02

S15508 · DIGITIMES Asia · *Alchip, Faraday and GUC 2026 revenue outlook* · 2026-02-02

S15509 · Mobile World Live · *Qualcomm lands custom AI chip deal with Amazon* · 2026-09

S15510 · Manufacturing Dive · *Qualcomm makes custom chips for Amazon in $4B partnership* · 2026-09

S15511 · Futurum Group · *Qualcomm lands $60 billion custom silicon and 1.6T optics deal with AWS, backed by a $4 billion warrant* · 2026-09

S15512 · Nasdaq · *Qualcomm Q3 earnings call highlights* · 2026-07-29

S15513 · Qualcomm via SEC EDGAR · *Qualcomm announces fourth quarter and fiscal 2026 results (Form 8-K exhibit 99.1)* · 2026-11-04

S15514 · Cerebras Systems via SEC EDGAR · *Cerebras Systems announces second quarter 2026 financial results (Form 8-K)* · 2026-08-12

S15515 · The Energy Mag · *Cerebras Systems reports $180 million Q2 2026 revenue, 600 MW of contracted data center capacity* · 2026-08

S15516 · DatacenterDynamics · *AI chip start-up Tenstorrent raises $1.5bn at $6.2bn valuation* · 2026-10-19

S15517 · The Star (Reuters) · *Vista Equity Partners and Intel to lead investment in AI chip startup SambaNova, sources say (Reuters)* · 2026-02-07

S15518 · Cadena 3 · *SambaNova capta 1.000 millones y alcanza una valoracion de 11.000 millones* · 2026-07

S15519 · insideHPC · *SoftBank acquires AI chip company Graphcore* · 2024-07-12

S15520 · AI News · *SoftBank acquires British AI chipmaker Graphcore* · 2024-07

S15521 · Caixin Global · *Tech brief, March 13: Cambricon annual results* · 2026-03-13

S15522 · Yicai Global · *Cambricon slides even as Chinese AI chipmaker's first-half earnings double* · 2026-08

S15523 · Shanghai Stock Exchange (Global Times) · *China's 'Nvidia alternative' Moore Threads posts 147.42% growth in H1 revenue (Global Times)* · 2026-08-11

S15524 · South China Morning Post · *MetaX swings to profit as Chinese AI chipmakers report diverging first-half results* · 2026-08

S15525 · Quartr · *Hygon Information Technology (688041) Q2 2026 earnings summary* · 2026-08

S15526 · The Register · *Chinese tech giants Hygon and Sugon call off merger* · 2025-12-11

S15527 · Tom's Hardware · *Huawei expects $12 billion in AI chip revenue this year as Nvidia's China market share hits zero* · 2026

S15528 · SemiAnalysis · *Huawei Ascend production ramp* · 2025-09

S15529 · TrendForce · *China reportedly aims to boost 7nm/5nm output fivefold* · 2026-02-25

S15530 · Wccftech · *Morgan Stanley cuts SMIC's Huawei AI GPU revenue estimate by more than 50% on yields* · 2025

S15531 · Tom's Hardware · *China's chip champions ramp up production of AI accelerators at domestic fabs, but HBM and fab capacity are towering bottlenecks* · 2025

S15532 · Invezz (Bloomberg) · *Huawei to double AI chip output in 2026, targeting 1.6 million dies* · 2025-09-29

S15533 · Tom's Hardware · *Alibaba's AI chip goes head-to-head with Nvidia H20 in state-backed benchmark demo* · 2025-09

S15534 · Caixin Global · *Tech brief, Jan. 30: Alibaba unveils new AI chip to rival Nvidia's China offerings* · 2026-01-30

S15535 · Geopolitechs · *Zhenwu AI chip and Alibaba's three-pillar AI stack: chips, cloud and models* · 2026

S15536 · MarketScreener (Reuters) · *Baidu's Kunlunxin valued at close to $3 billion, eyes Hong Kong IPO - sources (Reuters)* · 2025-12

S15537 · TrendForce · *Baidu chip unit Kunlunxin reportedly launches STAR Market IPO process; HK listing valuation seen near HK$100B* · 2026-05-08

S15538 · The Next Web · *Baidu's chip unit Kunlunxin is targeting a $50 billion Hong Kong IPO* · 2026-06

S15539 · NewsBytes · *China's AI chipmaker Moore Threads smashes IPO records on STAR Market* · 2025-12

S15540 · Tiger Brokers (Dow Jones Newswires) · *Chinese AI chip startup MetaX leaps in trading debut (Dow Jones)* · 2025-12

S15541 · Tom's Hardware · *Biren kicks off Hong Kong IPO* · 2025-12

S15542 · The Star (wire report) · *Intel Q3 revenue rises 21 pct, net income falls 18 pct* · 2026-10-30

S15543 · CloudNews.tech · *Intel posts 21% revenue growth on data center demand, seeks more capacity for Xeon* · 2026-10

S15544 · Tom's Hardware · *Intel jumps to HBM4 with Jaguar Shores, 2nd-gen MRDIMMs with Diamond Rapids* · 2025-07

S15545 · Wccftech · *Intel's Jaguar Shores rack-scale AI lineup expected to be finalized in H1 2026* · 2025-10

S15546 · TweakTown · *Intel kills off Falcon Shores AI chip, moves to rack-scale solution with Jaguar Shores* · 2025-01-31

S15547 · eeNews Europe · *Nvidia-Intel stake finalised with $5 billion share purchase* · 2025-12-30

S15548 · Tom's Hardware · *Intel's EMIB-T heads for fab rollout this year* · 2026

S15549 · DIGITIMES Asia · *Intel EMIB packaging customers and revenue timing* · 2026-05-05

S15550 · Converge Digest · *U.S. takes 9.9% stake in Intel with $8.9B equity investment* · 2025-08

S15551 · The Register · *Broadcom Q1 2026: custom accelerator business across five, then six, customers* · 2026-03-05

S15552 · Channel Insider · *Broadcom AI chip revenue jumps 221% as custom silicon challenges Nvidia* · 2026-09

S16000 · Electronic Design (Jon Peddie Research) · *Nvidia's Quadratic Processor: The NV1 (Famous Graphics Chips series)* · 2021

S16001 · Electronic Design (Jon Peddie Research) · *Nvidia's RIVA 128 (Famous Graphics Chips series)* · 2021

S16002 · NBC Miami (CNBC Make It) · *Jensen Huang started his $2 trillion company Nvidia at a Denny's breakfast booth* · 2024-03

S16003 · FundingUniverse (International Directory of Company Histories) · *NVIDIA Corporation History* · 2004

S16004 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corp Form 10-Q (1999) - initial public offering disclosure* · 1999

S16005 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2002* · 2002-04

S16006 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2005* · 2005-03

S16007 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2006* · 2006-03

S16008 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2003* · 2003-04

S16009 · PCWorld (IDG News Service) · *Nvidia's shift away from mobile devices cuts modem unit* · 2015-05

S16010 · Mobile World Live · *Nvidia facing $125M charge on modem business exit* · 2015-05

S16011 · Tom's Hardware · *The Nvidia GeForce3 launched 25 years ago - underappreciated at launch, its impact shaped the industry* · 2026-02

S16012 · Proactive Investors · *Nvidia closes in on $6 trillion as prediction markets back year-end break* · 2026-10

S16014 · OpenAI · *Introducing ChatGPT* · 2022-11-30

S16015 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corp Form 10-K405 for fiscal year 2001* · 2001-04

S16016 · nvidia_deep_dive_claude repository · *Repo analysis: chapter 16 era scorecard, revenue milestones and bet-to-payoff ledger* · 2026-11-05

S17000 · NVIDIA · *GTC 2027 Conference FAQs* · 2026

S17001 · TechCrunch · *'Chief revenue destroyer' (Jensen Huang at GTC 2025)* · 2025-03-18

S17002 · Barchart · *Nvidia GTC: 7 big takeaways from Jensen* · 2025-03

S17003 · Constellation Research · *Nvidia outlines roadmap including Rubin GPU platform, new Arm-based CPU Vera* · 2024-06-02

S17004 · Maginative · *NVIDIA unveils Rubin GPU architecture and roadmap at Computex 2024* · 2024-06-02

S17005 · NVIDIA Newsroom · *NVIDIA Sets Conference Call for Third-Quarter Financial Results* · 2026-10-28

S17006 · nvidia_deep_dive_claude repository · *Repo analysis: chapter 17 pre-announcement horizon and Osborne-effect test* · 2026-11-05

S17007 · AMD (press release) · *AMD Accelerates Pace of Data Center AI Innovation and Leadership with Expanded AMD Instinct GPU Roadmap* · 2024-06-02

S17008 · DatacenterDynamics · *AMD unveils new Instinct accelerator, plans to release new data center GPU every year* · 2024-06

S18000 · Implicator.ai · *Nvidia guides ~70% fiscal 2028 growth as memory costs squeeze margins* · 2026-08-27

S18001 · Saxo Bank · *Nvidia earnings: AI boom meets margin test* · 2026-08-27

S18002 · Zacks Investment Research (via Nasdaq) · *Memory costs rise: can NVIDIA protect its 70%+ gross margin?* · 2026-09

S18003 · Barchart · *Nvidia (NVDA) earns price target upgrades after monster Q2* · 2026-08

S18004 · TS2 Tech · *Nvidia shares fall 4.6%, wiping out $253 billion as margin concerns eclipse $108 billion forecast* · 2026-08-28

S18005 · Crowdfund Insider · *Nvidia ($NVDA) nears $6T market cap as company stock hits ATH* · 2026-10

S18006 · The Motley Fool · *Will Nvidia be worth $6 trillion a year from now?* · 2026-04-19

S18007 · tomtunguz.com · *Circular financing: does Nvidia's $110B bet echo the telecom bubble?* · 2025-11

S18008 · IT World Canada · *Telecom equipment giants rethink the value of vendor financing model* · 2002

S18009 · Cisco Systems via SEC EDGAR · *Cisco Systems Form 10-K for fiscal 2001 (Exhibit 13: annual report financial section)* · 2001-10

S18010 · Cisco Newsroom · *Cisco Systems offers business and financial update* · 2001-04-16

S18011 · Insurance Journal (Bloomberg) · *A war over Taiwan would cost the world $10 trillion (Bloomberg Economics)* · 2024-01-11

S18012 · TechSpot · *TSMC produces first Nvidia Blackwell GPU in the US, but it still has to fly to Taiwan for packaging* · 2025-10

S18013 · DatacenterDynamics · *First US-made Nvidia Blackwell wafer manufactured at TSMC's Arizona fab* · 2025-10-17

S18014 · Pulse (news aggregator) · *TSMC starts work on Arizona packaging plant* · 2026-04

S18015 · Taiwan News · *Nvidia overtakes Apple as TSMC's largest customer* · 2026

S18016 · PJM Interconnection · *PJM auction procures 134,479 MW of generation resources (2027/2028 Base Residual Auction)* · 2025-12-17

S18017 · Utility Dive · *PJM capacity auction hits price cap as data center demand strains grid* · 2025-12

S18018 · Citizens Utility Board · *PJM capacity auction prices (2024/25 to 2026/27)* · 2025

S18019 · Maryland Office of People's Counsel · *Data center power demands again drive record power auction prices* · 2025-12

S18020 · arXiv (ByteDance Seed and Tsinghua University) · *CUDA Agent: large-scale agentic reinforcement learning for high-performance CUDA kernel generation (arXiv 2602.24286)* · 2026-02

S18021 · Towards Data Science · *AI agents beat PyTorch writing faster CUDA kernels (with caveats)* · 2026-10

S18022 · S&P Global Market Intelligence · *Microsoft and Alphabet earnings previews (Research — October 26 2026)* · 2026-10-26

S18023 · DatacenterDynamics · *Moody's hyperscaler capex forecasts marked up by $85bn to close in on $1trn by 2027* · 2026

S18024 · Bain & Company · *$2 trillion in new revenue needed to fund AI's scaling trend (Bain & Company's 6th annual Global Technology Report)* · 2025-09-23

S18025 · TechCrunch · *Sam Altman says OpenAI has $20B ARR and about $1.4 trillion in data center commitments* · 2025-11-06

S18026 · Business Standard · *OpenAI expects $600 bn in compute spending through 2030 ahead of IPO (Reuters)* · 2026-02-21

S18027 · nvidia_deep_dive_claude repository · *Repo analysis: chapter 18 risk scores, financing ratios and valuation scenarios* · 2026-11-05

S19001 · Qualcomm (OnQ blog) · *AI inference that scales: Qualcomm AI200 Infrastructure Management Suite* · 2026-03

S19002 · Qualcomm via SEC EDGAR · *Qualcomm announces third quarter fiscal 2026 results (Form 8-K exhibit 99.1)* · 2026-07-29

S19003 · Serverflow (blog) · *Qualcomm showed an AI rack with AI200 accelerators at MWC 2026 (Qualcomm pokazala II-stoyku s uskoritelyami AI200 na vystavke MWC 2026)* · 2026-03

S19004 · MarketBeat · *Qualcomm Q3 earnings call highlights* · 2026-07-29

S19005 · abit.ee · *Qualcomm AI200 AI rack server at MWC 2026 with AMD EPYC host processors* · 2026-03

S21000 · Mellanox Technologies via SEC EDGAR · *Mellanox Technologies Ltd. Form 10-K for fiscal year 2019* · 2020-02

S21001 · Business Wire (Mellanox Technologies) · *Mellanox Delivers Record Fourth Quarter and Annual 2019 Financial Results* · 2020-01-29

S21002 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Form 8-K: Mellanox acquisition receives SAMR antitrust approval* · 2020-04-16

S21003 · Akin Gump · *Nvidia/Mellanox: China's close scrutiny of semiconductor deals continues* · 2020-04

S21004 · Caixin Global · *Beijing puts strings on approval for Nvidia's $6.9 billion deal for Israeli tech firm* · 2020-04-18

S21005 · Techzine · *Nvidia closes acquisition of Mellanox for 6.9 billion dollars* · 2020-04-27

S21006 · The Register · *Mellanox, Starboard declare peace (kind of)* · 2018-06-20

S21007 · Fox Business (Dow Jones) · *Starboard Value to launch proxy fight for entire board at Mellanox* · 2018-01

S21008 · SDxCentral · *Nvidia earnings soar as chip giant's networking segment continues to drive AI boom* · 2026-02

S21009 · Calcalist (CTech) · *Nvidia networking revenue and its Israeli operations (Calcalist analysis)* · 2026-09

S21010 · Calcalist (CTech) · *Nvidia's networking business passes ten times its fiscal 2021 size (Calcalist)* · 2026-02

S21011 · Ynet News · *Nvidia lands in Kiryat Tivon, turning pioneer hills into Israel's next tech battleground* · 2026

S21012 · i24NEWS · *Nvidia announces new Israeli campus, plans for 10,000 employees* · 2025

S21013 · Bloomberg · *Nvidia's Mellanox deal won China OK in face of rival opposition* · 2020-04-27

S21014 · nvidia_deep_dive_claude repository · *Repo analysis: CS1 Mellanox deal economics (multiples, cumulative networking gross profit, payback scenarios)* · 2026-11-05

S22000 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2010* · 2010-03

S22001 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2009* · 2009-03

S22002 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Reports Financial Results for Fourth Quarter and Fiscal Year 2010 (Form 8-K exhibit 99.1)* · 2010-02-17

S22003 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2013* · 2013-03

S22004 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Corporation Form 10-K for fiscal year 2015* · 2015-03

S22005 · Shortform (summary of Lex Fridman Podcast) · *Lex Fridman Podcast #494 - Jensen Huang: NVIDIA, the $4 trillion company and the AI revolution (episode summary)* · 2026-03-23

S22006 · Wccftech · *Nvidia CEO reveals how the company survived an existential threat after forcing CUDA on gaming GPUs* · 2026-03

S22007 · The Motley Fool · *Time to sell Nvidia?* · 2009-02-11

S22008 · OpenAI · *Introducing Triton: open-source GPU programming for neural networks* · 2021-07-28

S22009 · nvidia_deep_dive_claude repository · *Repo analysis: CS2 CUDA payback (gross-margin trough, R&D intensity, Data Center revenue per registered CUDA developer)* · 2026-11-05

S23000 · Google Cloud Blog · *Google supercharges machine learning tasks with TPU custom chip* · 2016-05-18

S23001 · Google Cloud Blog · *Quantifying the performance of the TPU, our first machine learning chip* · 2017-04-05

S23002 · Google Research · *In-Datacenter Performance Analysis of a Tensor Processing Unit (ISCA 2017)* · 2017-06

S23003 · Google (The Keyword) · *Build and train machine learning models on our new Google Cloud TPUs* · 2017-05-17

S23004 · Google Cloud · *TPU v3 - Cloud TPU documentation* · 2024

S23005 · Google DeepMind (arXiv 2312.11805) · *Gemini: A Family of Highly Capable Multimodal Models* · 2023-12

S23006 · Fortune · *Google's Gemini 3 vs ChatGPT and the market reaction behind the Nvidia sell-off* · 2025-11-25

S23007 · TechPowerUp · *Google teams up with MediaTek for next-generation TPU v7 design* · 2025-03-18

S23008 · TrendForce · *MediaTek reportedly secures Google v7e and v8e TPU orders* · 2025-12-15

S23009 · TMTPost · *Nvidia shares slide on report that Meta is in talks to use Google TPUs* · 2025-11-26

S23010 · nvidia_deep_dive_claude repository · *Repo analysis: CS3 TPU economics (break-even fleet for an in-house ASIC, per-token gap vs B200, implied GPU price cut)* · 2026-11-05

S24000 · AMD (press release PDF) · *AMD and OpenAI Announce Strategic Partnership to Deploy 6 Gigawatts of AMD GPUs* · 2025-10-06

S24001 · MarketBeat · *AMD (NASDAQ:AMD) stock price history and chart* · 2025-10-03

S24002 · Arabian Business · *AMD shares zoom 23.7% as OpenAI looks to take 10% stake in the company* · 2025-10-06

S24003 · Crypto Briefing · *AMD has promised OpenAI and Meta up to 320 million shares at a penny each* · 2026

S24004 · The Register · *AMD copy-pastes 6 GW chips-for-stock deal in new Meta agreement* · 2026-02-24

S24005 · Vested Finance · *OpenAI can buy 160 million shares of trillion-dollar AMD at just 1 cent each. How?* · 2026-09-24

S24006 · StreetInsider (Reuters) · *Altman touts trillion-dollar AI vision as OpenAI restructures to chase scale (Reuters)* · 2025-10-29

S24007 · The Star (Reuters) · *OpenAI says it has no plan to use Google's in-house chip (Reuters)* · 2025-07-01

S24008 · Decrypt · *OpenAI plans to buy Google's AI chips as it looks beyond Nvidia: report* · 2026-10-28

S24009 · HPCwire (AMD press release) · *AMD Reports First Quarter 2026 Financial Results* · 2026-05-05

S24010 · ITPro · *OpenAI signs another chip deal, this time with AMD* · 2025-10-06

S24011 · Stocktwits · *AMD hits all-time high after Nvidia CEO Jensen Huang calls offering 10% stake to OpenAI 'clever'* · 2025-10-08

S25000 · Bloomberg · *Nvidia's $589 Billion DeepSeek Rout Is Largest in Market History* · 2025-01-27

S25001 · Tom's Hardware · *Nvidia loses $589 billion in market cap - broad stock plunge triggered by DeepSeek AI release* · 2025-01-27

S25002 · DeepSeek-AI (arXiv 2501.12948) · *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning* · 2025-01-22

S25003 · TechRadar · *Nvidia calls DeepSeek an 'excellent AI advancement' and praises the Chinese AI app's ingenuity* · 2025-01-28

S25004 · Fortune · *Microsoft CEO Satya Nadella on DeepSeek optimism and the Jevons paradox* · 2025-01-27

S25005 · Fortune · *Jensen Huang at GTC 2025 (AI Super Bowl) answers the DeepSeek debate* · 2025-03-19

S25006 · Tom's Hardware · *DeepSeek might not be as disruptive as claimed: firm reportedly has 50,000 Nvidia GPUs and spent $1.6 billion on buildouts* · 2025-02

S25007 · CTV News (Reuters) · *China's DeepSeek says its hit AI model cost just US$294,000 to train (Reuters)* · 2025-09-18

S25008 · South China Morning Post · *Chinese AI disrupter DeepSeek claims top spot in US App Store, dethroning ChatGPT* · 2025-01-27

S25009 · TweakTown · *DeepSeek's new AI assistant app is the top free app on the Apple App Store, ahead of ChatGPT* · 2025-01-27

S25010 · Fox Business · *Nvidia becomes first company to hit $5 trillion market valuation as AI boom drives historic growth* · 2025-10-29

S25011 · Wccftech · *US Government restricts exports of NVIDIA's China-exclusive H800 and A800 AI GPUs to China* · 2023-10-17

S25012 · NPR Planet Money · *AI, DeepSeek and the economics of the Jevons paradox (Planet Money)* · 2025-02-04

S26000 · U.S. Federal Register (Bureau of Industry and Security) · *Implementation of Additional Export Controls: Certain Advanced Computing Items; Supercomputer and Semiconductor End Use (interim final rule, FR Doc 2023-22299)* · 2023-10

S26001 · Tom's Hardware · *US Prohibits Exports of Nvidia's A800 and H800 to China, Blacklists Chinese GPU Developers* · 2023-10

S26002 · GPUSmith · *ECCN 3A090/4A090: TPP and performance density explained* · 2025

S26003 · SemiAnalysis · *Nvidia's New China AI Chips Circumvent US Restrictions | H20 Faster Than H100 | Huawei Ascend 910B* · 2023-11

S26004 · NPR · *Trump says Nvidia will hand the U.S. 15% of its H20 chip sales to China* · 2025-08-11

S26005 · Tom's Hardware · *Nvidia responds to claim China is urging local companies to avoid Nvidia H20* · 2025-08

S26006 · DatacenterDynamics · *China's internet regulator tells Chinese tech companies to stop buying Nvidia AI chips - report* · 2025-09-17

S26007 · Tom's Hardware · *China bans foreign AI chips from state-funded data centers* · 2025-11

S26008 · Tom's Hardware · *Jensen Huang says Nvidia China market share has fallen to zero* · 2025-10

S26009 · South China Morning Post · *China freeze on H200 chip sales clouds Nvidia's record earnings* · 2026-08

S26010 · Crypto Briefing · *Nvidia incurs $400M charge from excess H200 inventory as single customer drives 16% of revenue* · 2026-08

S26011 · MarketScreener · *China clears first Nvidia H200 AI chips for import - sources (Reuters)* · 2026-01

S26012 · DatacenterDynamics · *Nvidia reallocates China H200 manufacturing capacity for Vera Rubin chips - report* · 2026

S26013 · FourWeekMBA · *Nvidia's China Revenue: 19% Under Its New Count, Not 13%* · 2026

S26014 · Crypto Briefing · *Nvidia proves reduced dependence on China amid global shifts* · 2026-08

S27000 · OpenAI · *OpenAI, Oracle, and SoftBank expand Stargate with five new AI data center sites* · 2025-09-23

S27001 · Tom's Hardware · *Oracle and OpenAI scrap planned 600MW Abilene expansion* · 2026-03

S27002 · Tom's Hardware · *Oracle hits back at Stargate data center cancellation reports — claims 4.5GW Oracle-OpenAI agreement still on track* · 2026-03

S27003 · Epoch AI · *Satellite explorer: OpenAI/Oracle Stargate Abilene (Texas)* · 2026-07-28

S27004 · Epoch AI · *AI data center directory: Microsoft Fairwater Wisconsin* · 2026-07-25

S27005 · Microsoft Source · *Microsoft completes construction on first datacenter facility in Mount Pleasant, Wisconsin* · 2026-06-23

S27006 · Microsoft Source · *From Wisconsin to Atlanta: Microsoft connects datacenters to build its first AI superfactory* · 2025-11-12

S27007 · The Register · *Meta reveals plan for several multi-gigawatt datacenter clusters* · 2025-07-15

S27008 · DatacenterDynamics · *Meta secures $30bn Blue Owl finance package for Louisiana data center - report* · 2025-10

S27009 · The Next Web · *Meta details Prometheus, the Ohio supercluster heading for 1 million GPUs* · 2026-10

S27010 · The Register · *Meta's Prometheus supercluster: more than 11 percent of GPUs dead or idle as hot spares* · 2026-10

S27011 · About Amazon · *AWS activates Project Rainier: one of the world's largest AI compute clusters* · 2025-10

S27012 · Benzinga · *Nvidia's 'Jensen math' of $50 billion revenue per GW gets a reality check: here's what Barclays analysts project* · 2025-09

S27013 · Tiger Brokers (iTiger) · *Is the soaring cost of NVIDIA's AI data centers still a viable investment for tech giants?* · 2025

S27014 · 24/7 Wall St. · *NVIDIA's CEO says a 1-gigawatt AI factory rents for $50 billion a year — as much as it costs to build* · 2026-09-24

S27015 · AI Weekly · *Bloomberg pegs Abilene 1GW AI data center at $30B, $17B on chips* · 2025

S27016 · Remio · *Bernstein: AI data center costs hit $39.5 billion per GW, but depreciation is the bigger issue* · 2026

S31002 · Meta (GitHub meta-llama/llama-models) · *Llama 3.1 model card (MODEL_CARD.md)* · 2024-07-23

S31003 · Tom's Hardware · *Faulty Nvidia H100 GPUs and HBM3 memory caused half of the failures during Llama 3 training — one failure every three hours for Meta's 16,384 GPU training cluster* · 2024-07

S31005 · Google DeepMind (arXiv 2203.15556) · *Training Compute-Optimal Large Language Models (Chinchilla)* · 2022-03-29

S31006 · OpenAI (arXiv 2001.08361) · *Scaling Laws for Neural Language Models* · 2020-01-23

S31007 · Epoch AI · *Training compute of frontier AI models grows by 4-5x per year* · 2024-05-28

S31008 · Epoch AI · *Grok 4 training resources (data insight)* · 2025

S31009 · Epoch AI · *Models over 1e25 FLOP (data insight)* · 2025

S31010 · Epoch AI (Gradient Updates) · *Why GPT-5 used less training compute than GPT-4.5 (but GPT-6 probably won't)* · 2025

S31011 · Epoch AI · *Data on Notable AI Models (database)* · 2026

S31013 · Interconnects · *DeepSeek V3 and the actual cost of training frontier AI models* · 2025-01

S31014 · arXiv 2504.16138 · *Trends in Frontier AI Model Count: A Forecast to 2028* · 2025-04

S31015 · OpenAI (arXiv 2005.14165) · *Language Models are Few-Shot Learners (GPT-3)* · 2020-05-28

S32002 · NVIDIA · *NVIDIA H200 Tensor Core GPU (product page)* · 2023-11

S32004 · NVIDIA · *NVIDIA GB300 NVL72 / Blackwell Ultra (product page)* · 2025-03

S32006 · Meta via Hugging Face · *Llama 3.1 70B configuration (config.json)* · 2024-07-23

S32007 · Meta via Hugging Face · *Llama 3.1 8B configuration (config.json)* · 2024-07-23

S32008 · Meta via Hugging Face · *Llama 3.1 405B configuration (config.json)* · 2024-07-23

S32009 · DeepSeek-AI via Hugging Face · *DeepSeek-V3 configuration (config.json)* · 2024-12-26

S32010 · Google Research (arXiv 2305.13245) · *GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints* · 2023-05

S32011 · SOSP 2023 (arXiv 2309.06180) · *Efficient Memory Management for Large Language Model Serving with PagedAttention (vLLM)* · 2023-09

S32012 · USENIX OSDI 2022 · *Orca: A Distributed Serving System for Transformer-Based Generative Models* · 2022-07

S32013 · Google Research (arXiv 2211.17192) · *Fast Inference from Transformers via Speculative Decoding* · 2022-11

S32014 · USENIX OSDI 2024 (arXiv 2401.09670) · *DistServe: Disaggregating Prefill and Decoding for Goodput-optimized LLM Serving* · 2024-01

S32015 · NVIDIA Newsroom · *NVIDIA Dynamo open-source inference framework announcement (GTC 2025)* · 2025-03-18

S32017 · NVIDIA Technical Blog · *Introducing NVFP4 for Efficient and Accurate Low-Precision Inference* · 2025-06

S32018 · Google (The Keyword) · *Google I/O 2025 keynote remarks (Sundar Pichai)* · 2025-05-20

S32019 · Alphabet / Google (The Keyword) · *Alphabet Q2 2025 earnings call - CEO remarks* · 2025-07-23

S32020 · Alphabet / Google (The Keyword) · *Alphabet CEO remarks on token volume (October 2025)* · 2025-10

S32021 · Microsoft Investor Relations · *Microsoft FY2025 Q3 earnings call (Satya Nadella remarks)* · 2025-04-30

S32022 · OpenAI · *OpenAI DevDay 2025 keynote* · 2025-10-06

S32024 · OpenAI · *Reasoning models guide (OpenAI API documentation)* · 2025

S32025 · nvidia_deep_dive_claude repository · *Repo analysis: inference token-budget scenarios and roofline serving model (Primer P2)* · 2026-11-05

S32026 · DeepSeek-AI (arXiv 2405.04434) · *DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model* · 2024-05

S32027 · NVIDIA Technical Blog · *Mastering LLM Techniques: Inference Optimization* · 2023-11

S33001 · Communications of the ACM · *Roofline: An Insightful Visual Performance Model for Multicore Architectures* · 2009-04

S33002 · NVIDIA · *NVIDIA H100 Tensor Core GPU (product page and datasheet)* · 2022-03-22

S33003 · Lenovo Press · *ThinkSystem NVIDIA B200 180GB 1000W GPU product guide* · 2025

S33004 · NVIDIA Newsroom · *NVIDIA Kicks Off the Next Generation of AI With Rubin — Six New Chips; One Incredible AI Supercomputer* · 2026-01-05

S33005 · NVIDIA · *NVIDIA Vera Rubin NVL72 (product page and specifications)* · 2026

S33006 · Tom's Hardware · *Nvidia launches Vera Rubin NVL72 AI supercomputer at CES* · 2026-01-05

S33007 · Dataconomy · *Nvidia Quietly Cuts Vera Rubin HBM4 And NVLink Bandwidth Specs* · 2026-11-02

S33008 · CloudNews.tech · *NVIDIA Vera Rubin: HBM4 and NVLink bandwidth cut in spec sheet* · 2026-11

S33009 · NVIDIA · *NVIDIA A100 Tensor Core GPU datasheet* · 2021

S33010 · NVIDIA · *NVIDIA V100 Tensor Core GPU datasheet* · 2018

S33011 · IEEE Micro (arXiv:2403.14123) · *AI and Memory Wall* · 2024-03-21

S33012 · arXiv:2211.05102 (MLSys 2023) · *Efficiently Scaling Transformer Inference* · 2022-11-09

S33013 · kipp.ly · *Transformer Inference Arithmetic* · 2022-03-30

S33014 · AFIPS Spring Joint Computer Conference · *Validity of the single processor approach to achieving large scale computing capabilities* · 1967-04

S33015 · International Energy Agency · *Energy and AI* · 2025-04-10

S33016 · Lawrence Berkeley National Laboratory · *2024 United States Data Center Energy Usage Report* · 2024-12

S33017 · Electric Power Research Institute (EPRI) · *Powering Intelligence: Analyzing Artificial Intelligence and Data Center Energy Consumption* · 2024-05-28

S33018 · PJM Interconnection · *2025 Long-Term Load Forecast Report* · 2025-01

S33019 · NVIDIA Technical Blog · *NVIDIA 800 V HVDC Architecture Will Power the Next Generation of AI Factories* · 2025-05-20

S33020 · NVIDIA · *NVIDIA GTC 2025 keynote (Jensen Huang)* · 2025-03-18

S33021 · SemiAnalysis · *GB200 Hardware Architecture — Component Supply Chain and BOM* · 2024-07-17

S33022 · NVIDIA Docs · *NVIDIA DGX H100 User Guide — Introduction (system specifications)* · 2023

S33023 · NVIDIA Newsroom · *NVIDIA Unveils Rubin CPX: A New Class of GPU Designed for Massive-Context Inference* · 2025-09-09

S33024 · NVIDIA · *NVIDIA H100 Tensor Core GPU Architecture (whitepaper)* · 2022

S33025 · arXiv:2402.16363 · *LLM Inference Unveiled: Survey and Roofline Model Insights* · 2024-02-26

S34001 · arXiv:1909.08053 · *Megatron-LM: Training Multi-Billion Parameter Language Models Using Model Parallelism* · 2019-09-17

S34002 · arXiv:2104.04473 (SC21) · *Efficient Large-Scale Language Model Training on GPU Clusters Using Megatron-LM* · 2021-04-09

S34003 · arXiv:1811.06965 (NeurIPS 2019) · *GPipe: Efficient Training of Giant Neural Networks using Pipeline Parallelism* · 2018-11-16

S34004 · arXiv:1910.02054 (SC20) · *ZeRO: Memory Optimizations Toward Training Trillion Parameter Models* · 2019-10-04

S34005 · arXiv:2304.11277 (VLDB 2023) · *PyTorch FSDP: Experiences on Scaling Fully Sharded Data Parallel* · 2023-04-21

S34006 · arXiv:2407.21783 · *The Llama 3 Herd of Models* · 2024-07-31

S34007 · arXiv:2412.19437 · *DeepSeek-V3 Technical Report* · 2024-12-27

S34008 · arXiv:2205.05198 (MLSys 2023) · *Reducing Activation Recomputation in Large Transformer Models* · 2022-05-10

S34009 · arXiv:2310.01889 · *Ring Attention with Blockwise Transformers for Near-Infinite Context* · 2023-10-03

S34010 · arXiv:2309.14509 · *DeepSpeed Ulysses: System Optimizations for Enabling Training of Extreme Long Sequence Transformer Models* · 2023-09-25

S34011 · Journal of Parallel and Distributed Computing · *Bandwidth optimal all-reduce algorithms for clusters of workstations* · 2009-02

S34012 · NVIDIA (GitHub) · *NCCL Tests — Performance reported (algbw vs busbw)* · 2024

S34013 · NVIDIA Docs · *NCCL User Guide — Collective Operations* · 2025

S34014 · NVIDIA · *NVIDIA NVLink and NVLink Switch* · 2025

S34015 · NVIDIA · *NVIDIA InfiniBand adapters (ConnectX-7 NDR 400Gb/s; ConnectX-8 XDR 800Gb/s)* · 2025

S34016 · PCI-SIG · *PCI Express Base Specification 5.0 and 6.0 (overview)* · 2022-01-11

S34017 · arXiv:2006.16668 · *GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding* · 2020-06-30

S34018 · arXiv:2201.11990 · *Using DeepSpeed and Megatron to Train Megatron-Turing NLG 530B* · 2022-01-28

S34019 · arXiv:2211.05100 · *BLOOM: A 176B-Parameter Open-Access Multilingual Language Model* · 2022-11-09

S34020 · arXiv:2406.11704 · *Nemotron-4 340B Technical Report* · 2024-06-17

S34021 · arXiv:2204.02311 · *PaLM: Scaling Language Modeling with Pathways* · 2022-04-05

S34022 · ACM SIGCOMM 2024 · *RDMA over Ethernet for Distributed AI Training at Meta Scale* · 2024-08

S34023 · arXiv:2101.03961 (JMLR) · *Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity* · 2021-01-11

S34024 · NVIDIA Docs · *NVIDIA Scalable Hierarchical Aggregation and Reduction Protocol (SHARP) documentation* · 2024

S35001 · Center for Security and Emerging Technology (CSET) · *AI Chips: What They Are and Why They Matter* · 2020-04

S35002 · Tom's Hardware · *TSMC Will Reportedly Charge $20,000 Per 3nm Wafer* · 2022-12

S35003 · TechNode · *TSMC sets 2nm wafer price at $30,000, far below earlier 50% increase speculation* · 2025-10-09

S35004 · Tom's Hardware · *TSMC could charge up to $45,000 for 1.6nm wafers — rumors allege a 50% increase in pricing over prior-gen wafers* · 2025

S35005 · Tom's Hardware · *TSMC's 2nm process will reportedly get another price hike — $30,000 per wafer for latest cutting-edge tech* · 2025

S35006 · Silicon Analysts · *Semiconductor Wafer Pricing by Process Node (2026)* · 2026

S35007 · Tom's Hardware · *Newer chips are rapidly becoming far more expensive: TSMC's average wafer price jumped 22% in one year* · 2024-01

S35008 · AnandTech · *'Better Yield on 5nm than 7nm': TSMC Update on Defect Rates for N5* · 2020-08-25

S35009 · Tom's Hardware · *TSMC discloses N2 defect density — lower than N3 at the same stage of development* · 2025-04

S35010 · Semiconductor Engineering · *Are Larger Reticle Sizes On The Horizon?* · 2024

S35011 · NVIDIA · *NVIDIA Hopper Architecture* · 2022-03

S35012 · Tom's Hardware · *Nvidia Reveals Hopper H100 GPU With 80 Billion Transistors* · 2022-03-22

S35013 · ComputerBase · *Nvidia Hopper: So schnell ist die neue Architektur für Supercomputer* · 2022-05

S35014 · NVIDIA · *NVIDIA Blackwell Architecture* · 2024-03

S35015 · Introl · *NVIDIA Rubin Enters Full Production: The 336 Billion Transistor GPU Reshaping AI Infrastructure* · 2026-01

S35016 · Bloomberg · *Nvidia CEO Says Rubin Chips Are on Track, Demand Is Strong* · 2026-01-05

S35017 · TweakTown · *NVIDIA unveils Vera Rubin at GTC 2026, the brain behind the next era AI* · 2026-03

S35018 · Tom's Hardware · *Nvidia announces Rubin GPUs in 2026, Rubin Ultra in 2027, Feynman also added to roadmap* · 2025-03-18

S35019 · DatacenterDynamics · *Nvidia's Rubin Ultra NVL576 rack expected to be 600kW, coming second half of 2027* · 2025-03

S35020 · Epoch AI · *NVIDIA's B200 costs around $6,400 to produce, with memory accounting for half* · 2025-12

S35021 · Epoch AI · *Memory has grown to nearly two-thirds of AI chip component costs* · 2026-05-21

S35022 · Silicon Analysts · *NVIDIA B200 (Blackwell) cost breakdown* · 2026

S35023 · Silicon Analysts · *AI Accelerator Manufacturing Cost (COGS) — Historical Time Series Data* · 2026

S35024 · The Decoder · *Nvidia's H100 GPU sells like hot cakes with high profit margins* · 2023-08

S35025 · TechSpot · *Nvidia garners reported 1000% profit on each H100 GPU* · 2023-08

S35026 · Tom's Hardware · *Nvidia's Jensen Huang says Blackwell GPU to cost $30,000-$40,000, later clarifies that pricing will vary as they won't sell just the chip* · 2024-03-19

S35027 · The Star (Reuters) · *Nvidia's new AI chip to be priced at over $30,000, CNBC reports* · 2024-03-19

S35028 · TweakTown · *NVIDIA spent $10 billion on developing its next-generation Blackwell GPU* · 2024-03

S35029 · Star Tribune (Associated Press) · *Taiwan computer chip maker TSMC to expand investment as profit jumps 35%* · 2026-01-15

S35030 · Nasdaq (Zacks) · *TSMC Commits Higher CapEx in 2026 While Raising Dividend Payouts* · 2026

S35031 · eeNews Europe · *TSMC to spend over $40bn on capex this year* · 2022-01

S35032 · SemiWiki · *How to spend 100 billion dollars in three years* · 2021-04

S35033 · TrendForce · *TSMC's capital expenditure expected to remain unchanged this year ahead of earnings call* · 2024-10-14

S35034 · TickerLeague · *TSMC (TSM) capital expenditure history* · 2026

S35035 · TrendForce · *TrendForce: global top-10 foundry revenue and ranking 2Q26* · 2026-09-09

S35036 · TSMC · *TSMC Showcases Leading Technologies at Online Technology Symposium and OIP Ecosystem Forum* · 2020-08-25

S35037 · TrendForce · *TSMC reportedly raising N3P prices 20% ahead of 2nm era; pressuring Qualcomm and MediaTek* · 2025-09-23

S35038 · Mark LaPedus (Semiecosystem) · *Q2 2026 foundry rankings: TSMC dominates* · 2026-09

S35039 · FourWeekMBA · *The 14% Paradox: Why Nvidia's GPU Silicon Costs Less Than Its Packaging* · 2026

S35040 · Silicon Analysts · *CoWoS packaging cost: chiplet vs monolithic (2026)* · 2026

S35041 · Glenn K. Lockwood · *Rubin Ultra (R300) notes* · 2026

S35042 · HWCooling · *Nvidia Hopper GPU architecture revealed. 4nm die & 18432 shaders* · 2022-03

S90001 · The Star (Reuters) · *Nvidia bets on AI inference as chip revenue opportunity hits $1 trillion (Reuters)* · 2026-03-17

S90002 · MarketScreener · *Nvidia forecasts $1 trillion in orders for its AI systems by 2027* · 2026-03-16

S90003 · eWeek · *Everything Nvidia Just Announced at GTC 2026: 7 Chips, 5 Racks, 1 Giant Bet on Agentic AI* · 2026-03-17

S90004 · TrendForce · *Key GTC takeaways: how Samsung, Micron, Intel and more power NVIDIA's Vera Rubin and Feynman* · 2026-03-17

S90005 · Jon Peddie Research · *NVIDIA GTC 2026 keynote* · 2026-03

S90006 · TweakTown · *Nvidia cuts Vera Rubin's memory bandwidth by up to 26% and AMD's Helios now leads in memory bandwidth* · 2026-10

S90007 · TechRadar Pro · *Nvidia forced to dial back key bandwidth targets on Vera Rubin* · 2026-10

S90008 · XenoSpectrum · *Nvidia Rubin bandwidth specification (HGX vs NVL72)* · 2026-10

S90009 · GamesBeat · *Nvidia Vera Rubin ramps into full production for fall launch* · 2026

S90010 · Wccftech · *Nvidia Rubin AI servers to ship to customers by August this year* · 2026

S90011 · Nasdaq (Zacks) · *NVIDIA Q2 earnings beat on Blackwell Ultra and Data Center strength* · 2026-08-27

S90012 · Tomasz Tunguz · *Nvidia Q2 FY27 earnings* · 2026-08

S90013 · Quartr · *NVIDIA (NVDA) Q2 2027 earnings summary* · 2026-08-26

S90014 · Global Data Center Hub · *NVIDIA posts $81.6 billion quarter and splits into two reporting platforms* · 2026-05

S90015 · DatacenterDynamics · *Nvidia plans $30bn investment in upcoming OpenAI funding round* · 2026-02

S90016 · Storyboard18 (Financial Times) · *Nvidia set for $30bn OpenAI deal as $100bn partnership shelved, report says (FT)* · 2026-02-20

S90017 · ITdaily · *Nvidia won't invest $100 billion in OpenAI after all* · 2026-02

S90018 · Constellation Research · *Nvidia's Groq deal: acquisition, acquihire or creative licensing deal?* · 2025-12

S90019 · TechSpot · *Nvidia's $20 billion Groq deal looks a lot like an acquisition* · 2025-12

S90020 · Shacknews · *AMD Helios AI rack system on track for initial shipments in Q3 2026* · 2026

S90021 · Igor's Lab · *AMD Helios in production: MI455X, EPYC Venice and OpenAI challenge Nvidia AI racks* · 2026

S90022 · Tom's Hardware · *AMD and Oracle partner to deploy 50,000 MI450 Instinct GPUs* · 2025-10

S90023 · Wccftech · *AMD has begun sampling MI450 GPUs and engaged with customers on MI500* · 2026

S90024 · Crypto Briefing · *AMD's Helios platform ships H2 2026 with Microsoft Azure as first major deployment* · 2026

S90025 · SiliconANGLE · *Google and Meta reportedly strike new multibillion-dollar AI chip deal* · 2026-02-26

S90026 · Maginative · *Anthropic secures 1M Google TPUs while keeping Amazon as primary training partner* · 2025-10

S90027 · The Next Web · *Google is building a four-partner chip supply chain to challenge Nvidia in AI inference* · 2026

S90028 · TechRepublic · *Qualcomm unveils AI chips to rival Nvidia, AMD* · 2025-10-27

S90029 · Verdict · *Qualcomm AI200 and AI250 racks for AI inference* · 2025-10

S90030 · Morningstar · *Qualcomm: Humain deal provides some AI upside* · 2025-10

S90031 · ServeTheHome · *NVIDIA announces NVLink Fusion bringing NVLink to third-party CPUs and accelerators* · 2025-05-19

S90032 · Bloomberg Government · *Nvidia gets US license for small amount of H200 exports to China* · 2026-02

S90033 · Tom's Hardware · *Nvidia has received POs from Chinese customers* · 2026-03-17

S90034 · NAND Research · *AWS releases Trainium3, teases Trainium4* · 2025-12

S90035 · Business Today ME · *Trainium3 UltraServers now available* · 2025-12

S90036 · Converge Digest · *Arm extends Neoverse with NVIDIA NVLink Fusion* · 2025-11

S90037 · Converge Digest · *NVIDIA invests $2B in Marvell to extend NVLink Fusion AI ecosystem* · 2026-03

S90038 · Tom's Hardware · *Nvidia announces NVLink Fusion to allow custom CPUs and AI accelerators to work with its products* · 2025-05-19

S90039 · TrendForce · *Samsung, SK hynix reportedly tapped as NVIDIA Rubin HBM4 suppliers; shipments could start in March* · 2026-03-09

S90040 · Tom's Hardware · *HBM4 mass production delayed as Nvidia pushes memory specs higher* · 2025

S90041 · I-Connect007 (TrendForce) · *NVIDIA seeks to raise HBM4 specs in response to AMD competition; SK hynix expected to remain largest supplier in 2026* · 2025-09

S90042 · TrendForce · *Huawei unveils Ascend 950 with in-house HBM in 2026, touts SuperPoD to rival NVIDIA* · 2025-09-18

S90043 · Tom's Hardware · *Huawei Ascend NPU roadmap examined: targets 4 zettaflops FP4 by 2028 amid manufacturing constraints* · 2025-09

S90044 · eWeek · *Microsoft introduces Maia 200, its most powerful AI chip yet* · 2026-01-27

S90045 · Pulse 2.0 · *Microsoft to expand Azure Maia AI infrastructure to multi-gigawatt deployments starting in 2027* · 2026-10

S90046 · IT Brief UK · *Microsoft unveils Maia 300 for 2027 AI deployments* · 2026-10

S90047 · NVIDIA · *NVIDIA GTC DC 2026 (November 30 – December 3, 2026)* · 2026

S90048 · Converge Digest · *NVIDIA debuts Spectrum-X and Quantum-X Photonics switches* · 2025-03-18

S90049 · Tom's Hardware · *Nvidia outlines plans for using light for communication between AI GPUs by 2026* · 2025-03

S90050 · HPCwire · *UALink Consortium publishes 4 specifications defining in-network compute, chiplets, manageability and 200G performance* · 2026-04-07

S90051 · SDxCentral · *UALink Consortium takes another swing at Nvidia's NVLink supremacy with specification 2.0* · 2026-04

S90052 · Synopsys · *Ethernet standards for scale-up AI: an overview of ESUN, SUE, and UALink* · 2025-11

S90053 · Dell'Oro Group · *Ethernet more than doubles size of InfiniBand as the leading fabric for AI scale-out networks in 2025* · 2026

S90054 · Dell'Oro Group · *Ethernet extends lead in AI scale-out networks despite strong InfiniBand rebound* · 2026

S90055 · Dell'Oro Group · *2026 predictions: data center switch, front-end and AI back-end networks* · 2026-01

S90056 · HPCwire (Qualcomm press release) · *Qualcomm unveils data center roadmap for the agentic AI era with new Dragonfly portfolio* · 2026-06-24

S90057 · StorageReview · *Qualcomm unveils Dragonfly data center roadmap: C1000 CPU, AI300 accelerator and Modular acquisition* · 2026-06-24

S90058 · Constellation Research · *Qualcomm outlines new CPU, AI accelerator roadmap, inks deal with Meta* · 2026-06-24

S90059 · Counterpoint Research · *Qualcomm unveils data center roadmap at Investor Day 2026* · 2026-06

S90060 · Qualcomm · *Qualcomm Dragonfly AI300 (product page)* · 2026-06

S90061 · DatacenterDynamics · *NVIDIA prepares data center industry for 1MW racks and 800 volt DC power architectures* · 2025-10

S90062 · Dell'Oro Group · *GTC 2026: moving from chip launches to infrastructure architecture* · 2026-03

S90063 · Converge Digest · *The megawatt shift: NVIDIA's 800 VDC strategy* · 2026

S90064 · The Register · *ROCm 7: AMD tries to catch CUDA with performance-boosting software* · 2025-09-17

S90065 · Spheron · *CUDA news today: NVIDIA toolkit, AMD ROCm and AI frameworks 2026* · 2026

S90066 · HPCwire (NVIDIA press release) · *NVIDIA enters production with Dynamo, the broadly adopted inference operating system for AI factories* · 2026-03-17

S90067 · DatacenterDynamics · *Nvidia to purchase unsold compute capacity from CoreWeave for $6.3bn* · 2025-09-16

S90068 · Tom's Hardware · *Nvidia steps back from DGX Cloud — stops trying to compete with AWS and Azure* · 2025-09

S90069 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Form 10-Q for the quarter ended July 26, 2026 (Q2 FY2027)* · 2026-08

S90070 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Form 10-Q for the quarter ended April 26, 2026 (Q1 FY2027)* · 2026-05

S90071 · Crypto Briefing · *Nvidia CFO emphasizes neutral partnership with AI customers as company diversifies beyond hyperscalers* · 2026

S90072 · Unite.AI · *Nvidia's AI sector equity stakes grow, SEC filing shows* · 2026-08

S90073 · FourWeekMBA · *NVIDIA's $99 billion investment portfolio and the circular financing loop at the center of AI* · 2026-08

S90074 · Kavout · *Nvidia's AI dominance meets circular financing: a systemic risk underpriced?* · 2026

S90075 · Windows Central · *NVIDIA joins Microsoft's push on Claude — piling billions into Anthropic's future* · 2025-11-18

S90076 · Introl · *xAI Colossus hits 2 GW: 555,000 GPUs, $18B, largest AI site* · 2026-01

S90077 · Tom's Hardware (via 3DTested mirror) · *Elon Musk's xAI Colossus 2 is nowhere near 1 gigawatt capacity, satellite imagery suggests* · 2026-01

S90078 · SemiAnalysis · *xAI's Colossus 2: first gigawatt datacenter* · 2025-09

S90079 · TechRepublic · *DeepSeek V4 AI model backed by Huawei* · 2026-04-24

S90080 · Asia Financial · *China's DeepSeek says new V4 AI model can run on Huawei chips* · 2026-04

S90081 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Form 10-K for fiscal year 2026 (ended January 25, 2026)* · 2026-02

S90082 · Verdict · *Nvidia writedown on H20 chip* · 2025-04

S90083 · Built In · *A guide to how America controls Nvidia chip exports to China* · 2026

S90084 · Advanced Television · *Nvidia acquires Hugging Face for $12.9bn* · 2026-09-04

S90085 · Shacknews · *NVIDIA (NVDA) expects gross margin decrease over next two quarters* · 2026-08-26

S90086 · Implicator.ai · *Nvidia's 70 percent growth forecast and margin outlook* · 2026-08-27

S90087 · HotHardware · *Qualcomm strikes major Amazon AWS deal for custom AI data center chips* · 2026-09-08

S90088 · Futurum Group · *Qualcomm lands $60 billion custom silicon and 1.6T optics deal with AWS, backed by a $4 billion warrant* · 2026-09

S90089 · The Next Web · *Qualcomm hands Amazon $4B of warrants to build custom silicon for AWS* · 2026-09-08

S90090 · NVIDIA Corporation via SEC EDGAR · *NVIDIA Form 10-K for fiscal year 2025 (ended January 26, 2025)* · 2025-02-26

S90091 · ServeTheHome · *NVIDIA reports Q4 FY2026 earnings: data center and ProViz drive revenue records* · 2026-02-25

S90092 · Nasdaq (Motley Fool) · *Nvidia's supply commitments more than doubled to $279 billion: here's what it does to the stock* · 2026-09

S90093 · Tom's Hardware · *AMD takes the wraps off its Instinct MI455X AI accelerator: CDNA 5 and Helios rack-scale architecture* · 2026

S90094 · ServeTheHome · *AMD Instinct MI455X deep dive: CDNA 5 marks the next era of Instinct* · 2026

S90095 · Chips and Cheese · *AMD Instinct MI455X: aiming for the sun* · 2026